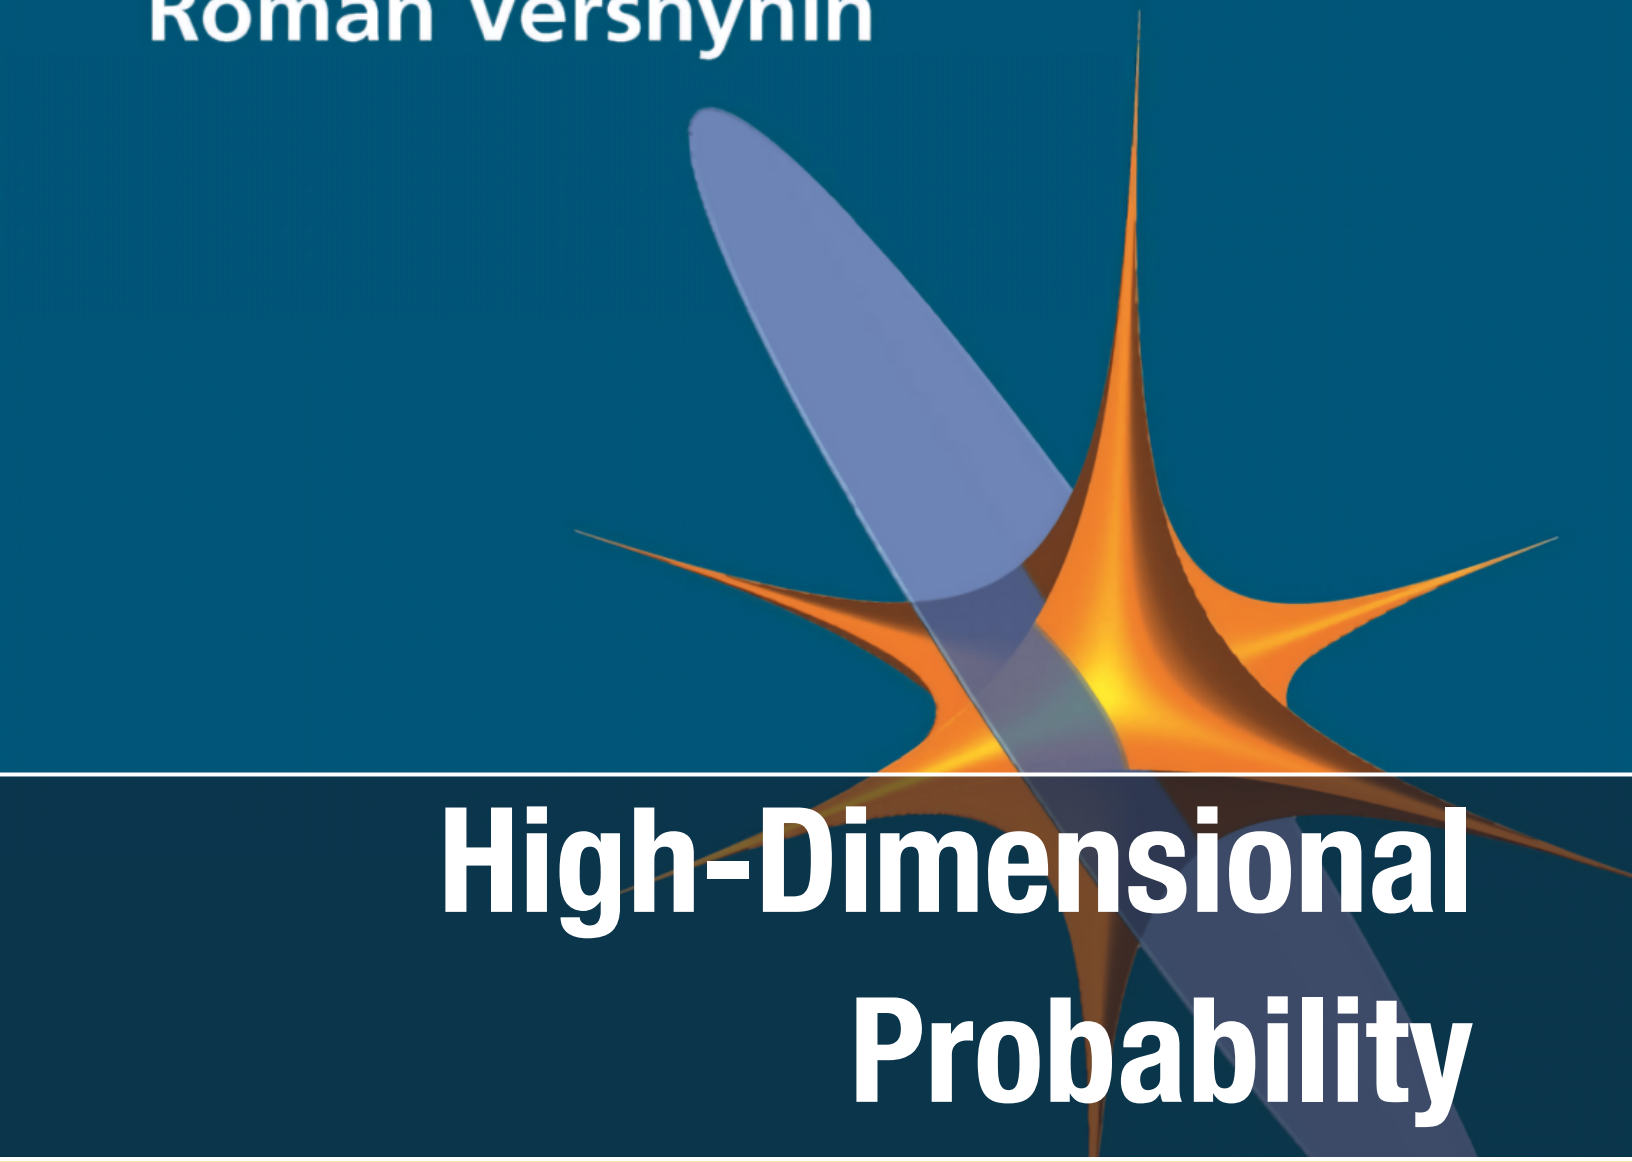
Second Edition

v1.0

Roman Vershynin



High-Dimensional Probability

Problems, Solutions and Proofs

WorseFive

2026/8/29

Feishu 仓库 - WorseFive
GitHub 仓库 - WorseFive

知乎主页 - WorseFive
小红书主页 - WorseFive
微信公众号 - WorseFive

Email: worsefive@gmail.com



扫码支持作者

前言

Roman Vershynin 所著的 *High-Dimensional Probability: An Introduction with Applications in Data Science* 是高维概率论的经典之作。与立足于概率空间公理化及渐近极限定理的传统教材不同，本书直面高维空间的随机现象，系统阐释了集中不等式、次高斯性质、随机矩阵、经验过程与随机几何及其在数据科学中的具体实现。第二版在初版基础上进行了全面修订与扩充。作者重构了部分核心章节的逻辑脉络，同时引入了大量新材料与补充习题。

(一) 何为高维概率论?

经典概率论主要研究有限维随机变量的统计特性，而高维概率论则探讨当系统维度极大时，复杂的随机性为何会呈现出某种高度确定的结构。比如说：

散落在高维空间中的随机点集，很可能自然而然地呈现出有规律的几何形态；

高维随机向量虽然有很多独立的随机坐标，但它的欧氏范数会常常集中在某个固定值附近；

高维随机矩阵里全是随机元素，可它的谱范数、奇异值等特征量依然能得到非常精细的非渐近估计；

……

可以看到，高维并不意味着混乱；相反，在合适的测度尺度下，高维随机系统反而有很强的规律性和可预测性。

(二) 对于初学者

虽然这本书的定位是针对博士生、高年级硕士生及相关领域初入研究者，但是如果你在大二已经学过了初等概率论和泛函分析，那么你可以无痛学完这本书，这也将是你第一次接触技术化证明。

对初次接触高维概率论的读者来说，真正的难点往往不是记住某个定理，而是弄清这些定理为什么成立、该在什么情况下使用，以及不同工具之间的关系。高维概率论涉及到许多新术语和新方法，初看时容易产生一种“公式很多、技巧很多”的感觉。但随着学习的深入，你会逐渐发现，真正反复出现的核心工具其实并没有那么多。很多证明最终都可以归结为几个基本问题：

随机变量的尾部衰减速度有多快?

随机向量的某个函数会不会出现集中现象?

怎样将涉及无穷多个方向的问题进行离散化?

如何用有限个点来覆盖整个球面?

怎样把点态估计提升为一致估计?

又如何将一个复杂的随机对象拆分成若干容易控制的部分?

……

当读者对这些理论日趋熟稔，高维概率论的许多技巧性证明便逐渐成为一种内化的思维框架。习题正是实现从“知其然”到“知其所以然”的最佳途径。

相较于第一版，Vershynin 的第二版补充了大量习题。这些习题并非机械地重复正文中的计算，而是承担着补充正文、训练证明技巧乃至延伸整个理论框架的作用。有些习题实际上给出了正文中某些结论的另一种证明方式；有些习题则要求读者把前面

几个章节中获得的工具组合起来；还有一些习题看似只是一个技术性的小问题，实际上却揭示了高维概率论中非常重要的思想。

(三) 解答的组织方式

本答案按照 Vershynin 第二版教材的章节顺序组织，与原书保持对应关系，以便读者随时查阅。在解答过程中，笔者并未完全照搬原教材的记号和术语，同时在必要的地方补充证明中的中间步骤。同时为了让证明过程更加清晰，笔者也会根据具体问题补充相应的文字说明或图片，以帮助读者理解证明的动机；对于一些比较重要或者容易产生误解的地方，也会给出额外说明。

9 **[Carl-Pajor 定理]** 改进定理 T0.1.4 (多面体的体积)，将 N 替换为 N/n。
设 $P \subset \mathbb{B}_2^n$ 为多胞形，其由 $N \geqslant n$ 个顶点生成。记 $B = \mathbb{B}_2^n$，证明：

$$\left(\frac{\mathrm{Vol}(P)}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant C\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}。 \qquad (C>0)$$

证明 设 $P = \mathrm{conv}\{\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N\}$，其中 $\|\boldsymbol{x}_i\|_2 \leqslant 1$。

解法一　Maurey 经验法

- 覆盖数估计

  根据定理 T0.1.2 (近似 Caratheodory 定理)，可得对于任意的 $\boldsymbol{x} \in P$，存在 $\boldsymbol{x}_{i_1}, \cdots, \boldsymbol{x}_{i_k}$，使得

  $$\left\| \boldsymbol{x} - \frac{1}{k}\sum^{k} \boldsymbol{x}_i \right\| \leqslant \frac{1}{\sqrt{k}}。$$

多种角度的解法

解法二　熵数法

构造线性算子 $T : \ell_1^N \to \ell_2^n$ 为

$$T(\boldsymbol{a}) = \sum_{i=1}^{N} a_i \boldsymbol{x}_i, \qquad (\boldsymbol{a} = (a_1, \cdots, a_N) \in \ell_1^N)$$

满足 $\|T\| = \max_{1\leqslant i\leqslant N} \|\boldsymbol{x}_i\|_2 \leqslant 1$，则 $T(\mathbb{B}_1^N) = \mathrm{conv}\{\pm\boldsymbol{x}_1, \cdots, \pm\boldsymbol{x}_N\}$，从而 $P \subset T(\mathbb{B}_1^N)$。
之后设 $e_k(T)$ 为 T 的第 k 个二进熵数 (能通过 2^{k-1} 个球覆盖 $T(\mathbb{B}_1^N)$ 的最小半径)，即

$$e_k(T) = \inf\{\varepsilon > 0 : \mathcal{N}(T(\mathbb{B}_1^N), \varepsilon\mathbb{B}_2^n \leqslant 2^{k-1})\}。$$

作出以下引理：

引理 1 (Carl 不等式, 1981)　设 T 满足 $\mathrm{rank}(T) = n$，$e_n(T)$ 为二进制熵数，则

$$\left(\frac{\mathrm{Vol}(T(\mathbb{B}_1^N))}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant c_1 e_n(T)。$$

43 **[sub-Gaussian 矩阵算子范数的上界：放宽独立性假设]**
(1) 矩阵级别的 sub-Gaussian 性：若将 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 视为 $\mathbb{R}^{m\times n}$ 空间的 K-sub-Gaussian 随机向量，其中 $K = \|\boldsymbol{A}\|_{\psi_2}$，证明：即使没有任何独立性假设，定理 T4.4.3 (sub-Gaussian 元素矩阵的范数) 的结论依然成立。
(2) 行 (或列) 级别的 sub-Gaussian 性：证明：若 $\boldsymbol{A}$ 的行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m \in \mathbb{R}^n$ 为相互独立, 零均值的 sub-Gaussian 随机向量，则定理 T4.4.3 (sub-Gaussian 元素矩阵的范数) 依然成立。此时 $K = \max_i \|\boldsymbol{A}_i\|_{\psi_2}$。(对于列向量结论同样成立)

注释　回顾定理 T4.4.3 (sub-Gaussian 元素矩阵的范数) 的 ε-网证明，主要分为三步：

1. 逼近 (Approximation)：选取确定性的 ε-网 $\mathcal{N} \subset \mathbb{S}^{n-1}, \mathcal{M} \subset \mathbb{S}^{m-1}$，将范数转化为 $\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$。
2. 集中 (Concentration)：证明对于固定的 $\boldsymbol{x} \in \mathcal{N}, \boldsymbol{y} \in \mathcal{M}$，双线性型 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 满足 sub-Gaussian 尾部界限 $\mathrm{P}\{|Z| \geqslant u\} \leqslant 2\exp(-cu^2/K^2)$。
3. 并集界 (Union Bound)：对所有的网点求并集。

由于步骤 1, 3 是确定性的几何操作，不依赖矩阵元素的随机性假设。因此，我们只需要证明于 (1)(2) 的新假设，步骤 2 的 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 依然满足相同的 sub-Gaussian 范数界限 $\|Z\|_{\psi_2} \leqslant C'K$ 即可。

证明 (1) 根据 sub-Gaussian 随机向量范数的定义 (D3.4.1 (sub-Gaussian 随机向量))，可得　阐述动机

$$\|\boldsymbol{A}\|_{\psi_2} = \sup_{\|\boldsymbol{W}\|_F=1} \|\langle \boldsymbol{A}, \boldsymbol{W}\rangle\|_{\psi_2} = K,$$

其中 $\boldsymbol{W} \in \mathbb{R}^{m\times n}$，矩阵内积定义为 $\langle \boldsymbol{A}, \boldsymbol{W}\rangle = \mathrm{tr}(\boldsymbol{W}^\top \boldsymbol{A})$。
对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，$\boldsymbol{y} \in \mathbb{S}^{m-1}$，考虑

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x} = \mathrm{tr}(\boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x}) = \mathrm{tr}(\boldsymbol{x}\boldsymbol{y}^\top \boldsymbol{A}),$$

令秩一矩阵 $\boldsymbol{W} = \boldsymbol{y}\boldsymbol{x}^\top$，则根据 Q4.3 (算子范数的特殊情形计算) (1)，可得

$$\|\boldsymbol{W}\|_F = \|\boldsymbol{y}\boldsymbol{x}^\top\|_F = \|\boldsymbol{y}\|_2\|\boldsymbol{x}\|_2 = 1 \cdot 1 = 1,$$

37 [ε-网上范数偏离的控制] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，$\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，其中 $\varepsilon\in[0,1/2)$。对于 $\mu\in\mathbb{R}$，分别定义全域偏离, ε-网的最大偏离为

$$E=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|,\quad \delta=\sup_{\boldsymbol{x}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|,$$

证明：于 $\mathbb{S}^{n-1}$ 的全域范数偏离可以由于 $\mathcal{N}$ 的局部范数偏离所控制，即

$$E\leqslant\frac{C}{1-2\varepsilon}\delta。\qquad(C>0)$$

证明 (以下是错误的尝试：

根据 ε-网的定义 (Q4.23 (ε-网的传递性))，可得对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，存在 $\boldsymbol{x}_0\in\mathcal{N}$，使得 $\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\leqslant\varepsilon$，因此

$$\begin{aligned}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|&\leqslant|\|\boldsymbol{A}\boldsymbol{x}\|_2-\|\boldsymbol{A}\boldsymbol{x}_0\|_2|+|\|\boldsymbol{A}\boldsymbol{x}_0\|_2-\mu|\\&\leqslant\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0)\|_2+(\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0)\|_2+\delta)。\end{aligned}$$

令 $\boldsymbol{h}=\boldsymbol{x}-\boldsymbol{x}_0$，满足 $\|\boldsymbol{h}\|_2\leqslant\varepsilon$。

若 $\boldsymbol{h}=\boldsymbol{0}$，则容易知道，结论成立；之后只需考虑 $\boldsymbol{h}\neq\boldsymbol{0}$ 的情况。

令 $\boldsymbol{u}=\boldsymbol{h}/\|\boldsymbol{h}\|_2\in\mathbb{S}^{n-1}$，则

$$\|\boldsymbol{A}\boldsymbol{h}\|_2=\|\boldsymbol{h}\|_2\cdot\|\boldsymbol{A}\boldsymbol{u}\|_2\leqslant\varepsilon\|\boldsymbol{A}\boldsymbol{u}\|_2,$$

其中

$$\|\boldsymbol{A}\boldsymbol{u}\|_2\leqslant|\|\boldsymbol{A}\boldsymbol{u}\|_2-\mu|+|\mu|\leqslant E+\mu,$$

因此

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|\leqslant\varepsilon(E+|\mu|)+\delta,$$

两侧取上确界，

$$E\leqslant\varepsilon E+\varepsilon|\mu|+\delta\implies E\leqslant\frac{\varepsilon|\mu|+\delta}{1-\varepsilon}。$$

可以发现，直接对绝对值进行放缩会不可避免地引入与 μ 相关的交叉项，导致证明陷入僵局。)

构造对称矩阵 $\boldsymbol{M}=\boldsymbol{A}^\top\boldsymbol{A}-\mu^2\boldsymbol{I}_n$，则

$$|\boldsymbol{x}^\top\boldsymbol{M}\boldsymbol{x}|=|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-\mu^2|。$$

根据引理 L4.4.2 (于网最大化二次型) (对称矩阵二次型于 ε-网的最大化)，可得

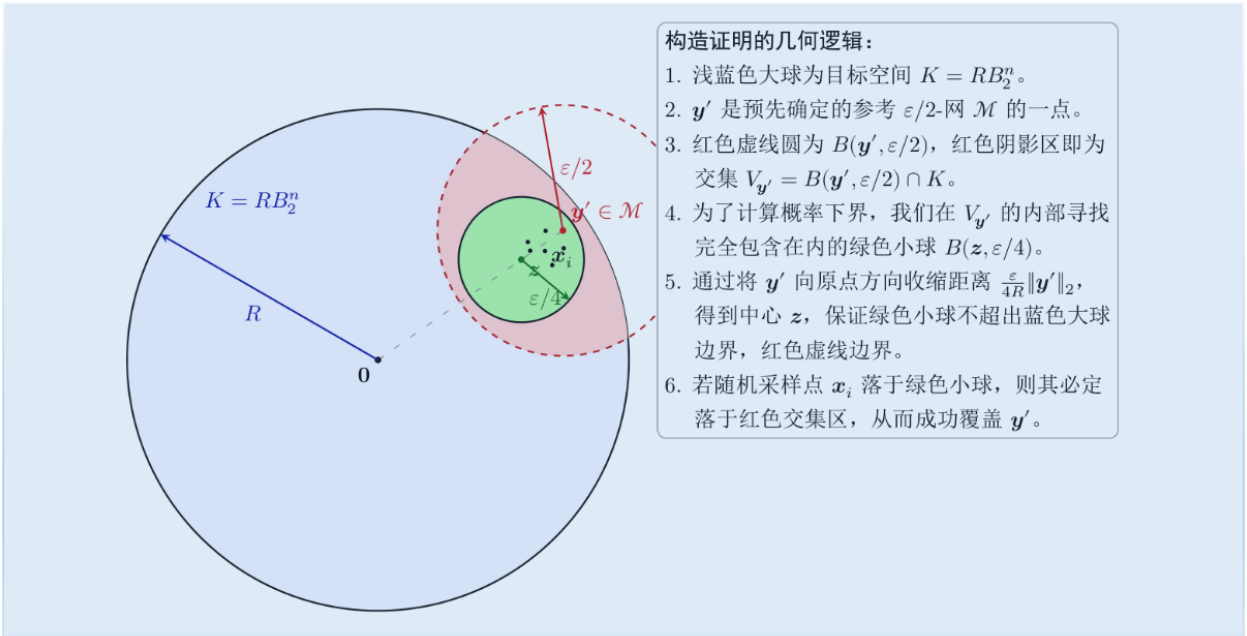
具有一定启发价值的错误解法

39 [随机点集构成 ε-网] 设 $\boldsymbol{g}_1,\cdots,\boldsymbol{g}_N$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。对于任意的半径 $R>0$, 精度 $\varepsilon>0$，证明：当 $N\geqslant\mathrm{e}^{C(R,\varepsilon)n}$ 时，随机点集

$$\mathcal{N}_X=\left\{\frac{\boldsymbol{g}_1}{\sqrt{n}},\cdots,\frac{\boldsymbol{g}_N}{\sqrt{n}}\right\}\cap R\mathbb{B}_2^n$$

以高概率 $1-\mathrm{e}^{-cn}$ 构成中心球 $K=R\mathbb{B}_2^n$ 的 ε-网。

补充图像说明



构造证明的几何逻辑：

1. 浅蓝色大球为目标空间 $K=RB_2^n$。
2. $\boldsymbol{y}'$ 是预先确定的参考 $\varepsilon/2$-网 $\mathcal{M}$ 的一点。
3. 红色虚线圆为 $B(\boldsymbol{y}',\varepsilon/2)$，红色阴影区即为交集 $V_{\boldsymbol{y}'}=B(\boldsymbol{y}',\varepsilon/2)\cap K$。
4. 为了计算概率下界，我们在 $V_{\boldsymbol{y}'}$ 的内部寻找完全包含在内的绿色小球 $B(\boldsymbol{z},\varepsilon/4)$。
5. 通过将 $\boldsymbol{y}'$ 向原点方向收缩距离 $\frac{\varepsilon}{4R}\|\boldsymbol{y}'\|_2$，得到中心 $\boldsymbol{z}$，保证绿色小球不超出蓝色大球边界，红色虚线边界。
6. 若随机采样点 $\boldsymbol{x}_i$ 落于绿色小球，则其必定落于红色交集区，从而成功覆盖 $\boldsymbol{y}'$。

证明 若 $\varepsilon>2R$，则原点本身即为平凡的 ε-网，结论是平凡的；之后只需考虑 $\varepsilon\leqslant2R$ 的情况。

54 **[最大割的近似算法：确定性输出，随机运行时间]** Goemans-Williamson 定理 (定理 T3.6.4 (最大割的 0.878-近似算法)) 通过 SDP 松弛和 Rounding (随机超平面舍入) 技术，使得能够找到在期望意义下不小于最大割的 0.878 倍的割。

对于任意的 $\varepsilon > 0$，设计针对最大割问题的 $(0.878 - \varepsilon)$-近似算法，使得最终输出的割总是满足近似比要求 (即确定性输出)，但是算法的运行时间是随机的。之后试求算法期望运行时间的上界。

证明 我们需要将 Monte Carlo 型算法 (运行时间固定，结果以概率保证) 转化为 Las Vegas 型算法 (结果确定，运行时间随机)。

设 $G = (V, E)$，边权为 $w_{ij} \geqslant 0$，记 W_{opt} 为 G 的最大割权值。

给出以下算法：

由于 $W_{SDP} \geqslant W_{opt}$，因此当满足判定条件时，$W \geqslant (0.878 - \varepsilon)W_{opt}$。

补充算法说明

Algorithm 1: Guaranteed-Max-Cut-Approximation(G, ε)

输入: 图 $G = (V, E)$，边权 $\{w_{ij}\}_{i,j \in V} \geqslant 0$，近似参数 $\varepsilon > 0$。

输出: 割 $S \subset V$，其权值满足 $W(S) \geqslant (\alpha_{GW} - \varepsilon)W_{opt}$。

Part 1: SDP 松弛问题求解

求解以下 SDP 松弛问题：

$$\begin{aligned} \text{maximize} \quad & \sum_{i<j} w_{ij} \frac{1 - \langle \boldsymbol{v}_i, \boldsymbol{v}_j \rangle}{2}, \\ \text{subject to} \quad & \boldsymbol{v}_i \in \mathbb{S}^{n-1}, \end{aligned}$$

记最优值为 W_{SDP}，最优向量解为 $\{\boldsymbol{v}_i\}_{i=1}^n$。

Part 2: 迭代随机舍入 (Las Vegas 过程)

设 $\alpha \leftarrow \alpha_{GW} \approx 0.878$;

while True do

  独立地于 $N(\mathbf{0}, \boldsymbol{I}_n)$ 抽取标准正态随机向量 $\boldsymbol{g}$;

  构造候选割：$S \leftarrow \{i \in V : \langle \boldsymbol{v}_i, \boldsymbol{g} \rangle \geqslant 0\}$;

  计算权值：$W \leftarrow \sum_{i \in S, j \notin S} w_{ij}$;

  if $W \geqslant (\alpha - \varepsilon)W_{SDP}$ **then**

    return S;

  end

end

设 W 为单次迭代所产生的割权值，则根据 Goemans-Williamson 定理，可得

$$\mathrm{E}[W] \geqslant \alpha_{GW} W_{SDP},$$

其中 $0 \leqslant W \leqslant W_{SDP}$。

考虑 $A = \{W < (\alpha_{GW} - \varepsilon)W_{SDP}\}$ (迭代失败)，设亏空随机变量 $Z = W_{SDP} - W \geqslant 0$，满足

$$\mathrm{E}[Z] = W_{SDP} - \mathrm{E}[W] \leqslant (1 - \alpha_{GW})W_{SDP},$$

则利用 Markov 不等式，可得

$$\mathrm{P}(A) = \mathrm{P}\{Z > (1 - \alpha_{GW} + \varepsilon)W_{SDP}\} \leqslant \frac{\mathrm{E}[Z]}{(1 - \alpha_{GW} + \varepsilon)W_{SDP}} \leqslant \frac{(1 - \alpha_{GW})W_{SDP}}{(1 - \alpha_{GW} + \varepsilon)W_{SDP}} = \frac{1 - \alpha_{GW}}{1 - \alpha_{GW} + \varepsilon},$$

(四) 最终

因时间紧迫，难免存有错讹与疏漏。笔者虽竭力勘校，仍恐百密一疏。若您在阅读中发现谬误，或对解题思路存有疑问，由衷期待您的批评与指正。希望本书能为诸位略尽绵薄之力。

AI 使用声明。当今的人工智能虽然可以轻易解决这些问题，但本答案并非由人工智能独立生成：笔者仅在完稿之后使用人工智能进行纠错。除此以外，笔者为中国人，初稿以中文完成，因此英文版本由中文版本机器翻译而成。

WorseFive

2026 年 8 月 22 日

目录

前言 1

何为高维概率论? 1

对于初学者 1

解答的组织方式 2

最终 4

目录 5

0 开胃菜：使用概率覆盖集合 7

1 要点梳理 7

2 习题解答 7

1 分析, 概率的快速回顾 18

1.1 要点梳理 18

1.2 习题解答 20

2 独立随机变量之和的集中性分析 34

2.1 要点梳理 34

2.2 习题解答 38

3 高维随机向量 86

3.1 要点梳理 86

3.2 习题解答 90

4 随机矩阵 136

4.1 要点梳理 136

4.2 习题解答 140

5 非独立情形的集中性 191

5.1 要点梳理 191

5.2 习题解答 194

6 二次型, 对称化, 收缩原理 231

6.1 要点梳理 231

6.2 习题解答 233

7 随机过程 281

7.1 要点梳理 281

7.2 习题解答 284

8 链化 319

8.1 要点梳理 319

8.2 习题解答 322

9 随机矩阵于集合的偏差 369

9.1 要点梳理 369

9.2 习题解答 372

开胃菜：使用概率覆盖集合 0

要点梳理

Section 0.1 开胃菜：覆盖集合 Q0.1 ~ Q0.9

定理 0.1.1 (Caratheodory 定理)
设 $T \subset \mathbb{R}^n$，则其凸包的任意一点均可表示为 T 的至多 $n+1$ 个点的凸组合。

定理 0.1.2 (近似 Caratheodory 定理)
设 $T \subset \mathbb{B}_2^n$，对于任意的 $\boldsymbol{x} \in \operatorname{conv}(T)$，存在 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_k \in T$，使得

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_2 \leqslant \frac{1}{\sqrt{k}}。$$

推论 0.1.3 (用球覆盖多面体)
设 P 为 $\mathbb{B}_2^n$ 的 N 个顶点的多面体，则 P 可被至多 N^k 个半径为 $1/\sqrt{k}$ 的 Euclidean 球所覆盖。

定理 0.1.4 (多面体的体积)
设 $P \subset \mathbb{B}_2^n = B$ 为 N 个顶点的多面体，则

$$\frac{\operatorname{Vol}(P)}{\operatorname{Vol}(B)} \leqslant \left(3\sqrt{\frac{\ln N}{n}} \right)^n。$$

习题解答

1 [两个关于方差的恒等式]

(1) 已知方差的矩展开形式为

$$\mathrm{Var}(X) = \mathrm{E}[(X - \mathrm{E}[X])^2] = \mathrm{E}[X^2] - (\mathrm{E}[X])^2。$$

证明上述恒等式的多维版本。

设 $\boldsymbol{Z} \in \mathbb{R}^n$ 为随机向量。证明：

$$\mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2 = \mathrm{E}\|\boldsymbol{Z}\|_2^2 - \|\mathrm{E}[\boldsymbol{Z}]\|_2^2。$$

(2) 已知方差的距离型形式为

$$\mathrm{Var}(Z) = \mathrm{E}[(Z - \mathrm{E}[Z])^2] = \frac{1}{2}\mathrm{E}[(Z - Z')^2]。$$

证明上述恒等式的多维版本。

设 $\boldsymbol{Z}, \boldsymbol{Z}' \in \mathbb{R}^n$ 为独立同分布的随机向量。证明：

$$\mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2 = \frac{1}{2}\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{Z}'\|_2^2。$$

证明 设 $\boldsymbol{\mu} = \mathrm{E}[\boldsymbol{Z}]$。

(1) 容易知道，

$$\begin{aligned}\|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 &= \langle \boldsymbol{Z} - \boldsymbol{\mu}, \boldsymbol{Z} - \boldsymbol{\mu}\rangle \\ &= \langle \boldsymbol{Z}, \boldsymbol{Z}\rangle - \langle \boldsymbol{Z}, \boldsymbol{\mu}\rangle - \langle \boldsymbol{\mu}, \boldsymbol{Z}\rangle + \langle \boldsymbol{\mu}, \boldsymbol{\mu}\rangle \\ &= \|\boldsymbol{Z}\|_2^2 - 2\langle \boldsymbol{Z}, \boldsymbol{\mu}\rangle + \|\boldsymbol{\mu}\|_2^2,\end{aligned}$$

两侧取期望，可得

$$\begin{aligned}\|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 &= \langle \boldsymbol{Z} - \boldsymbol{\mu}, \boldsymbol{Z} - \boldsymbol{\mu}\rangle \\ &= \|\boldsymbol{Z}\|_2^2 - 2\langle \boldsymbol{Z}, \boldsymbol{\mu}\rangle + \|\boldsymbol{\mu}\|_2^2,\end{aligned}$$

其中

$$\mathrm{E}[\langle \boldsymbol{Z}, \boldsymbol{\mu}\rangle] = \langle \mathrm{E}[\boldsymbol{Z}], \boldsymbol{\mu}\rangle = \langle \boldsymbol{\mu}, \boldsymbol{\mu}\rangle = \|\boldsymbol{\mu}\|_2^2,$$

因此

$$\begin{aligned}\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 &= \mathrm{E}\|\boldsymbol{Z}\|_2^2 - 2\|\boldsymbol{\mu}\|_2^2 + \|\boldsymbol{\mu}\|_2^2 \\ &= \mathrm{E}\|\boldsymbol{Z}\|_2^2 - \|\boldsymbol{\mu}\|_2^2,\end{aligned}$$

(2) 容易知道，

$$\begin{aligned}\|\boldsymbol{Z} - \boldsymbol{Z}'\|_2^2 &= \langle \boldsymbol{Z} - \boldsymbol{Z}', \boldsymbol{Z} - \boldsymbol{Z}'\rangle \\ &= \|\boldsymbol{Z}\|_2^2 - 2\langle \boldsymbol{Z}, \boldsymbol{Z}'\rangle + \|\boldsymbol{Z}'\|_2^2,\end{aligned}$$

两侧取期望，可得

$$\begin{aligned}\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{Z}'\|_2^2 &= \mathrm{E}\|\boldsymbol{Z}\|_2^2 - 2\mathrm{E}[\langle \boldsymbol{Z}, \boldsymbol{Z}'\rangle] + \mathrm{E}\|\boldsymbol{Z}'\|_2^2 \\ &= 2\mathrm{E}\|\boldsymbol{Z}\|_2^2 - 2\mathrm{E}[\langle \boldsymbol{Z}, \boldsymbol{Z}'\rangle]。\end{aligned}$$

其中

$$\mathrm{E}[\langle \boldsymbol{Z}, \boldsymbol{Z}'\rangle] = \langle \mathrm{E}[\boldsymbol{Z}], \mathrm{E}[\boldsymbol{Z}']\rangle = \langle \boldsymbol{\mu}, \boldsymbol{\mu}\rangle = \|\boldsymbol{\mu}\|_2^2,$$

因此

$$\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{Z}'\|_2^2 = 2\mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2,$$

即

$$\mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2 = \frac{1}{2}\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{Z}'\|_2^2。$$

2 [**期望最小化均方误差**] 已知方差的极值性为

$$\mathrm{Var}(X) = \min_{a \in \mathbb{R}} \mathrm{E}[(X - a)^2]。$$

证明上述性质的多维版本。

设 $\boldsymbol{Z} \in \mathbb{R}^n$ 为随机向量。证明：

$$\mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2 = \min_{\boldsymbol{a} \in \mathbb{R}^n} \mathrm{E}\|\boldsymbol{Z} - \boldsymbol{a}\|_2^2。$$

证明 设 $\boldsymbol{\mu} = \mathrm{E}[\boldsymbol{Z}]$，则

$$\begin{aligned}\|\boldsymbol{Z} - \boldsymbol{a}\|_2^2 &= \|(\boldsymbol{Z} - \boldsymbol{\mu}) + (\boldsymbol{\mu} - \boldsymbol{a})\|_2^2 \\ &= \langle (\boldsymbol{Z} - \boldsymbol{\mu}) + (\boldsymbol{\mu} - \boldsymbol{a}), (\boldsymbol{Z} - \boldsymbol{\mu}) + (\boldsymbol{\mu} - \boldsymbol{a}) \rangle \\ &= \|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 + \|\boldsymbol{\mu} - \boldsymbol{a}\|_2^2 + 2\langle \boldsymbol{Z} - \boldsymbol{\mu}, \boldsymbol{\mu} - \boldsymbol{a} \rangle,\end{aligned}$$

两侧取期望，可得

$$\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{a}\|_2^2 = \mathrm{E}\|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 + \|\boldsymbol{\mu} - \boldsymbol{a}\|_2^2 + 2\mathrm{E}[\langle \boldsymbol{Z} - \boldsymbol{\mu}, \boldsymbol{\mu} - \boldsymbol{a} \rangle],$$

其中

$$\mathrm{E}[\langle \boldsymbol{Z} - \boldsymbol{\mu}, \boldsymbol{\mu} - \boldsymbol{a} \rangle] = \langle \mathrm{E}[\boldsymbol{Z} - \boldsymbol{\mu}], \boldsymbol{\mu} - \boldsymbol{a} \rangle = \langle \boldsymbol{0}, \boldsymbol{\mu} - \boldsymbol{a} \rangle = 0,$$

因此

$$\mathrm{E}\|\boldsymbol{Z} - \boldsymbol{a}\|_2^2 = \mathrm{E}\|\boldsymbol{Z} - \boldsymbol{\mu}\|_2^2 + \|\boldsymbol{\mu} - \boldsymbol{a}\|_2^2。$$

当 $\boldsymbol{a} = \boldsymbol{\mu}$ 时，$\|\boldsymbol{\mu} - \boldsymbol{a}\|_2^2 = 0$，因此

$$\min_{\boldsymbol{a} \in \mathbb{R}^n} \mathrm{E}\|\boldsymbol{Z} - \boldsymbol{a}\|_2^2 = \mathrm{E}\|\boldsymbol{Z} - \mathrm{E}[\boldsymbol{Z}]\|_2^2。$$

3 [**和的方差**] 已知对于相互独立的零均值随机变量列 $Z_1, \cdots, Z_n$，其和的方差为

$$\mathrm{E}\left[\left(\sum_{j=1}^k Z_j\right)^2\right] = \sum_{j=1}^k \mathrm{E}[Z_j^2]。$$

证明上述恒等式的多维版本 (即 Parseval 恒等式或 Pythagorean 恒等式于随机向量空间的版本)。

设 $\boldsymbol{Z}_1, \cdots, \boldsymbol{Z}_k \in \mathbb{R}^n$ 为相互独立的零均值随机向量。证明：

$$\mathrm{E}\left[\left\|\sum_{j=1}^k \boldsymbol{Z}_j\right\|_2^2\right] = \sum_{j=1}^k \mathrm{E}\|\boldsymbol{Z}_j\|_2^2。$$

证明 容易知道，

$$\begin{aligned}\left\|\sum_{j=1}^k \boldsymbol{Z}_j\right\|_2^2 &= \left\langle \sum_{i=1}^k \boldsymbol{Z}_i, \sum_{j=1}^k \boldsymbol{Z}_j \right\rangle \\ &= \sum_{i=1}^k \sum_{j=1}^k \langle \boldsymbol{Z}_i, \boldsymbol{Z}_j \rangle,\end{aligned}$$

两侧取期望，可得

$$\begin{aligned}\mathrm{E}\left[\left\|\sum_{j=1}^k \boldsymbol{Z}_j\right\|_2^2\right] &= \mathrm{E}\left[\sum_{i=1}^k \sum_{j=1}^k \langle \boldsymbol{Z}_i, \boldsymbol{Z}_j \rangle\right] \\ &= \sum_{i=1}^k \sum_{j=1}^k \mathrm{E}[\langle \boldsymbol{Z}_i, \boldsymbol{Z}_j \rangle] \\ &= \sum_{i=1}^k \mathrm{E}[\langle \boldsymbol{Z}_i, \boldsymbol{Z}_i \rangle] + \sum_{i \neq j} \mathrm{E}[\langle \boldsymbol{Z}_i, \boldsymbol{Z}_j \rangle],\end{aligned}$$

其中当 $i \neq j$ 时，

$$\mathrm{E}[\langle \boldsymbol{Z}_i, \boldsymbol{Z}_j \rangle] = \langle \mathrm{E}[\boldsymbol{Z}_i], \mathrm{E}[\boldsymbol{Z}_j] \rangle = \langle \boldsymbol{0}, \boldsymbol{0} \rangle = 0。$$

当 $i=j$ 时，

$$\mathrm{E}[\langle \boldsymbol{Z}_i, \boldsymbol{Z}_i\rangle] = \mathrm{E}\|\boldsymbol{Z}_i\|_2^2,$$

因此

$$\mathrm{E}\left[\left\|\sum_{j=1}^{k}\boldsymbol{Z}_j\right\|_2^2\right] = \sum_{i=1}^{k}\mathrm{E}\|\boldsymbol{Z}_i\|_2^2 + 0 = \sum_{j=1}^{k}\mathrm{E}\|\boldsymbol{Z}_j\|_2^2。$$

4 [向量平衡问题] 设 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_n\in\mathbb{R}^n$ 满足 $\|\boldsymbol{x}_i\|_2\leqslant 1$。

(1) 证明：存在一种为任意的向量分配符号 $\pm$ 的方式，使得 $\pm\boldsymbol{x}_1\pm\boldsymbol{x}_2\pm\cdots\pm\boldsymbol{x}_n\in\sqrt{n}\mathbb{B}_2^n$，即存在 $\varepsilon_1,\cdots,\varepsilon_n\in\{-1,1\}$，使得

$$\left\|\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i\right\|_2\leqslant\sqrt{n}。$$

(2) 解释上述上界是最优的。

注释 事实上，我们可以证明

$$\left\|\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i\right\|_\infty\leqslant\sqrt{n\ln n}。$$

Joel Spencer 于 1985 年提出“Six Standard Deviations Suffice”(六个标准差足矣)，将上述不等式的上界优化为

$$\left\|\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i\right\|_\infty\leqslant 6\sqrt{n}。$$

Wojciech Banaszczyk 于 1998 年将 Spencer 型不等式进行推广：设 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_n\in\mathbb{R}^n$ 满足 $\|\boldsymbol{x}_i\|_2\leqslant 1$。对于任意的凸体 K，若其 Gaussian 测度满足 $\gamma_n(K)\geqslant 1/2$，则存在符号 $\varepsilon_i\in\{-1,1\}$，使得

$$\sum_{k=1}^{n}\varepsilon_k\boldsymbol{x}_k\in C\cdot K,$$

即

$$\left\|\sum_{k=1}^{n}\varepsilon_k\boldsymbol{x}_k\right\|_\infty\leqslant C\sqrt{\ln n}。$$

Nikhil Bansal 于 2010 年利用 SDP 和 Brownian 运动模拟，首次给出了寻找这种涂色的多项式时间算法。Lovett-Meka 于 2012 年提出了 Gram-Schmidt Walk 算法，通过于多面体进行随机游走，能够以构造性的方式达到 Spencer 的界。

证明 (1) 设 $\varepsilon_1,\cdots,\varepsilon_n$ i.i.d. $\sim$ Rademacher，$\boldsymbol{S}=\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i$，则

$$\begin{aligned}
\mathrm{E}\|\boldsymbol{S}\|_2^2 &= \mathrm{E}\left[\left\|\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i\right\|_2^2\right]\\
&= \mathrm{E}\left[\left\langle\sum_{i=1}^{n}\varepsilon_i\boldsymbol{x}_i,\sum_{j=1}^{n}\varepsilon_j\boldsymbol{x}_j\right\rangle\right]\\
&= \mathrm{E}\left[\sum_{i=1}^{n}\sum_{j=1}^{n}\varepsilon_i\varepsilon_j\langle\boldsymbol{x}_i,\boldsymbol{x}_j\rangle\right]\\
&= \sum_{i=1}^{n}\sum_{j=1}^{n}\langle\boldsymbol{x}_i,\boldsymbol{x}_j\rangle\mathrm{E}[\varepsilon_i\varepsilon_j],
\end{aligned}$$

其中

$$\mathrm{E}[\varepsilon_i\varepsilon_j]=\begin{cases}0, & i\neq j,\\ 1, & i=j\end{cases},$$

因此

$$\mathrm{E}\|\boldsymbol{S}\|_2^2=\sum_{i=1}^n\langle\boldsymbol{x}_i,\boldsymbol{x}_i\rangle\cdot 1=\sum_{i=1}^n\|\boldsymbol{x}_i\|_2^2\leqslant\sum_{i=1}^n 1=n,$$

从而根据均值原理 (概率方法)，可得存在 $\varepsilon_1,\cdots,\varepsilon_n\in\{-1,1\}$，使得

$$\left\|\sum_{i=1}^n\varepsilon_i\boldsymbol{x}_i\right\|_2^2\leqslant n,$$

即

$$\left\|\sum_{i=1}^n\varepsilon_i\boldsymbol{x}_i\right\|_2\leqslant\sqrt{n}。$$

(2) 令 $(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_n)=(\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n)$ 为标准正交基，满足 $\|\boldsymbol{x}_i\|_2=1\leqslant 1$，则

$$\boldsymbol{S}=\sum_{i=1}^n\varepsilon_i\boldsymbol{e}_i=(\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n)^\top,$$

因此

$$\|\boldsymbol{S}\|_2=\sqrt{\sum_{i=1}^n\varepsilon_i^2}=\sqrt{\sum_{i=1}^n 1}=\sqrt{n},$$

此时无论如何分配符号，向量和的范数都恒等于 $\sqrt{n}$，即上述构造的上界是不可改进的。

5 [**近似 Carathéodory 定理的渐近紧致性**] 构造反例，证明定理 T0.1.2 (近似 Caratheodory 定理) 的界几乎是紧致的。

构造 $T\subset\mathbb{R}^n$，设 $\boldsymbol{x}\in\mathrm{conv}(T)$，使得对于任意的 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_k\in T$ 的凸组合 $\sum_{j=1}^k\lambda_j\boldsymbol{x}_j$，均满足

$$\left\|\boldsymbol{x}-\sum_{j=1}^k\lambda_j\boldsymbol{x}_j\right\|_2\geqslant\sqrt{\frac{1}{k}-\frac{1}{n}}。$$

之后说明：当 $n\to\infty$ 时，定理 T0.1.2 (近似 Caratheodory 定理) 是渐近紧致的。

证明 构造 $T=\{\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_n\}$，设

$$\boldsymbol{x}=\frac{1}{n}\sum_{i=1}^n\boldsymbol{e}_i=\left(\frac{1}{n},\frac{1}{n},\cdots,\frac{1}{n}\right)^\top$$

为 T 的质心。

(将重复出现的顶点合并。若支撑大小为 $r<k$，则在之后的计算过程中，以 r 代替 k 所得的下界将更强；因此只需讨论 $r=k$ 的情况。)

不妨设 $(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_k)=(\boldsymbol{e}_1,\cdots,\boldsymbol{e}_k)$，则

$$\boldsymbol{y}=\sum_{j=1}^k\lambda_j\boldsymbol{e}_j=(\lambda_1,\lambda_2,\cdots,\lambda_k,0,\cdots,0)^\top,$$

因此

$$\|\boldsymbol{x}-\boldsymbol{y}\|_2^2=\sum_{j=1}^k\left(\frac{1}{n}-\lambda_j\right)^2+\sum_{j=k+1}^n\left(\frac{1}{n}\right)^2=\sum_{j=1}^k\left(\frac{1}{n}-\lambda_j\right)^2+\frac{1}{n}-\frac{k}{n^2},$$

问题转化为关于 $\lambda_1,\cdots,\lambda_k$ 的约束优化问题。

对于 $\sum_{j=1}^k\lambda_j=1$，根据对称性 (或者利用 Cauchy 不等式)，可得当 $\lambda_j=1/k$ 时，

$$\min_{\sum_{j=1}^k\lambda_j=1}\sum_{j=1}^k\left(\frac{1}{n}-\lambda_j\right)^2=\sum_{j=1}^k\left(\frac{1}{n}-\frac{1}{k}\right)^2=k\left(\frac{1}{n}-\frac{1}{k}\right)^2=\frac{1}{k}-\frac{2}{n}+\frac{k}{n^2},$$

因此

$$\min \|\boldsymbol{x}-\boldsymbol{y}\|_2^2=\left(\frac{1}{k}-\frac{2}{n}+\frac{k}{n^2}\right)+\left(\frac{1}{n}-\frac{k}{n^2}\right)=\frac{1}{k}-\frac{1}{n},$$

从而

$$\left\|\boldsymbol{x}-\sum_{j=1}^{k}\lambda_j\boldsymbol{x}_j\right\|_2\geqslant\sqrt{\frac{1}{k}-\frac{1}{n}}\to\frac{1}{\sqrt{k}},$$

此时上述构造的上界是不可改进的。

6 [**二项式系数的界**] 证明：

$$\left(\frac{n}{k}\right)^k\leqslant\binom{n}{k}\leqslant\sum_{j=0}^{k}\binom{n}{j}\leqslant\left(\frac{\mathrm{e}n}{k}\right)^k。\qquad(1\leqslant k\leqslant n)$$

证明 对于 $(n/k)^k\leqslant\binom{n}{k}$，

$$\binom{n}{k}=\frac{n(n-1)\cdots(n-k+1)}{k(k-1)\cdots1}=\prod_{i=0}^{k-1}\frac{n-i}{k-i}\geqslant\prod_{i=0}^{k-1}\frac{n}{k}=\left(\frac{n}{k}\right)^k。$$

对于 $\binom{n}{k}\leqslant\sum_{j=0}^{k}\binom{n}{j}$，

$$\sum_{j=0}^{k}\binom{n}{j}=\binom{n}{k}+\binom{n}{k-1}+\cdots+\binom{n}{0}\geqslant\binom{n}{k}。$$

对于 $\sum_{j=0}^{k}\binom{n}{j}\leqslant(\mathrm{e}n/k)^k$，利用二项式定理，可得

$$(1+x)^n=\sum_{j=0}^{n}\binom{n}{j}x^j\geqslant\sum_{j=0}^{k}\binom{n}{j}x^j,$$

两侧同除以 x^k，

$$\frac{(1+x)^n}{x^k}\geqslant\sum_{j=0}^{k}\binom{n}{j}x^{j-k}。$$

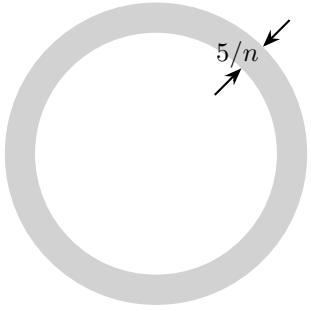
当 $x\in(0,1]$ 时，$x^{j-k}\geqslant1$，因此

$$\sum_{j=0}^{k}\binom{n}{j}\leqslant\sum_{j=0}^{k}\binom{n}{j}x^{j-k}\leqslant\frac{(1+x)^n}{x^k},$$

令 $x=k/n$，可得

$$\sum_{j=0}^{k}\binom{n}{j}\leqslant\frac{(1+k/n)^n}{(k/n)^k}=\left(\frac{n}{k}\right)^k\left(1+\frac{k}{n}\right)^n\leqslant\left(\frac{n}{k}\right)^k(\mathrm{e}^{\frac{k}{n}})^n=\left(\frac{\mathrm{e}n}{k}\right)^k,$$

7 [**薄壳现象**] 当 $n\geqslant6$ 时，如图所示，考虑 $\mathbb{B}_2^n$ 的内部距离表面 $5/n$ 的点集。证明：上述点集的体积占据球体总体积的 99% 以上。



证明 设 n 维球体的体积为 $V_n(R)=\mathrm{Vol}(B_n(R))$，则 $V_n(R)\propto R^n$，即

$$V_n(R)=\mathrm{Vol}(B_n(R))=C_nR^n,\qquad \left(C_n=\frac{\pi^{n/2}}{\Gamma(n/2+1)}\right)$$

因此

$$V_{\text{shell}}=V_n(1)-V_n\left(1-\frac{5}{n}\right),$$

之后只需证明

$$\frac{V_n(1-5/n)}{V_n(1)}<0.01。$$

当 $n>5$ 时，

$$\frac{V_n(1-5/n)}{V_n(1)}=\frac{C_n(1-5/n)^n}{C_n(1)^n}=\left(1-\frac{5}{n}\right)^n\leqslant(\mathrm{e}^{-5/n})^n=\mathrm{e}^{-5}=0.00673795。$$

8 [**薄壳现象 (续)**] 设 $\boldsymbol{X}\sim U(\mathbb{B}_2^n)$。证明：

$$\mathrm{E}\|\boldsymbol{X}\|_2=\frac{n}{n+1}。$$

证明 容易知道，

$$F_R(r)=\mathrm{P}\{\|\boldsymbol{X}\|_2\leqslant r\}=\frac{\mathrm{Vol}(B_n(r))}{\mathrm{Vol}(B_n(1))}=\frac{C_nr^n}{C_n1^n}=r^n,\qquad(0<r<1)$$

因此

$$f_R(r)=\frac{\mathrm{d}}{\mathrm{d}r}F_R(r)=nr^{n-1},\qquad(0<r<1)$$

从而

$$\mathrm{E}[R]=\int_{-\infty}^{+\infty}rf_R(r)\mathrm{d}r=\int_0^1nr^n\mathrm{d}r=\frac{n}{n+1}。$$

9 [**Carl-Pajor 定理**] 改进定理 T0.1.4 (多面体的体积)，将 N 替换为 N/n。
设 $P\subset\mathbb{B}_2^n$ 为多胞形，其由 $N\geqslant n$ 个顶点生成。记 $B=\mathbb{B}_2^n$，证明：

$$\left(\frac{\mathrm{Vol}(P)}{\mathrm{Vol}(B)}\right)^{1/n}\leqslant C\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}。\qquad(C>0)$$

证明 设 $P=\mathrm{conv}\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N\}$，其中 $\|\boldsymbol{x}_i\|_2\leqslant1$。

解法一　Maurey 经验法

- 覆盖数估计

  根据定理 T0.1.2 (近似 Caratheodory 定理)，可得对于任意的 $\boldsymbol{x}\in P$，存在 $\boldsymbol{x}_{i_1},\cdots,\boldsymbol{x}_{i_k}$，使得

  $$\left\|\boldsymbol{x}-\frac{1}{k}\sum_{j=1}^k\boldsymbol{x}_{i_j}\right\|_2\leqslant\frac{1}{\sqrt{k}}。$$

  构造所有可能的 k 项顶点平均点构成的集合，

  $$\mathcal{N}_k=\left\{\frac{1}{k}\sum_{j=1}^k\boldsymbol{x}_{i_j}:\ \boldsymbol{x}_{i_1},\cdots,\boldsymbol{x}_{i_k}\in\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N\}\right\}。$$

  由于均值不依赖顶点选取次序，因此利用隔板法，可得从 N 个不同顶点有放回地无序抽取 k 个的组合数为

  $$|\mathcal{N}_k|\leqslant\binom{N+k-1}{k}\leqslant\left(\frac{\mathrm{e}(N+k)}{k}\right)^k,$$

  (最后一步根据习题 Q0.6 (二项式系数的界) 得到。)

因此 P 可以被 $\mathcal{N}_k$ 为中心, 半径为 $1/\sqrt{k}$ 的至多 $|\mathcal{N}_k|$ 个 Euclidean 球完全覆盖，即

$$P \subset \bigcup_{c\in\mathcal{N}_k}\left(c+\frac{1}{\sqrt{k}}B\right)。$$

利用 Lebesgue 测度的次可加性，可得

$$\mathrm{Vol}(P) \leqslant |\mathcal{N}_k|\cdot k^{-n/2}\,\mathrm{Vol}(B),$$

即

$$\left(\frac{\mathrm{Vol}(P)}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant |\mathcal{N}_k|^{1/n}\cdot\frac{1}{\sqrt{k}} \leqslant \underbrace{\left(\frac{\mathrm{e}(N+k)}{k}\right)^{k/n}\frac{1}{\sqrt{k}}}_{F(k)},$$

(之后只需优化上界。)

- 选择最优系数 k

(为了让 $F(k)$ 得到 $\sqrt{\ln(\mathrm{e}N/n)/n}$ 的量级，$k^{-1/2}$ 应为 $\sqrt{L/n}$ 的量级，其中 $L=\ln(\mathrm{e}N/n)$。
当 k 为 n/L 的常数倍时，指数 k/n 为 $1/L$ 的常数倍；当对数项由 L 的常数倍控制时，$F(k)$ 的第一因子为绝对常数。)

对 L 的取值进行讨论：

a. 若 $L\geqslant n/4$，则 $P\subset B$，此时

$$\left(\frac{\mathrm{Vol}(P)}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant 1 \leqslant 2\sqrt{\frac{L}{n}}。$$

b. 当 $L<n/4$ 时，令 $k=\lfloor n/2L\rfloor$，则

$$\frac{\mathrm{e}(N+k)}{k} \leqslant \frac{2\mathrm{e}N}{k} \leqslant 8\mathrm{e}\left(\frac{N}{n}\right)L,$$

因此

$$\begin{aligned}\frac{k}{n}\ln\left(\frac{\mathrm{e}(N+k)}{k}\right) &\leqslant \frac{1}{2L}\ln\left[8\mathrm{e}\left(\frac{N}{n}\right)L\right]\\ &= \frac{\ln(8\mathrm{e})+\ln(N/n)+\ln L}{2L}\\ &\leqslant \frac{4L+\ln(N/n)+\ln L}{2L}\leqslant 3,\end{aligned}$$

从而

$$\left(\frac{\mathrm{Vol}(P)}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant \mathrm{e}^3\cdot 2\sqrt{\frac{L}{n}} =: C\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}。 \qquad (C=2\mathrm{e}^3)$$

解法二　熵数法

构造线性算子 $T:\ell_1^N\to\ell_2^n$ 为

$$T(\boldsymbol{a})=\sum_{i=1}^N a_i\boldsymbol{x}_i, \qquad (\boldsymbol{a}=(a_1,\cdots,a_N)\in\ell_1^N)$$

满足 $\|T\|=\max_{1\leqslant i\leqslant N}\|\boldsymbol{x}_i\|_2\leqslant 1$，则 $T(\mathbb{B}_1^N)=\mathrm{conv}\{\pm\boldsymbol{x}_1,\cdots,\pm\boldsymbol{x}_N\}$，从而 $P\subset T(\mathbb{B}_1^N)$。
之后设 $e_k(T)$ 为 T 的第 k 个二进熵数 (能通过 2^{k-1} 个球覆盖 $T(\mathbb{B}_1^N)$ 的最小半径)，即

$$e_k(T)=\inf\{\varepsilon>0:\mathcal{N}(T(\mathbb{B}_1^N),\varepsilon\mathbb{B}_2^n\leqslant 2^{k-1})\}。$$

作出以下引理：

引理 1 (Carl 不等式, 1981)　设 T 满足 $\mathrm{rank}(T)=n$，$e_n(T)$ 为二进制熵数，则

$$\left(\frac{\mathrm{Vol}(T(\mathbb{B}_1^N))}{\mathrm{Vol}(B)}\right)^{1/n} \leqslant c_1 e_n(T)。$$

引理 2 (Maurey 引理, 1988) 设 H 为 Hilbert 空间，线性算子 $T:\ell_1^N\to H$，则

$$e_k(T)\leqslant c_2\|T\|\sqrt{\frac{\ln(1+N/k)}{k}}。\qquad (1\leqslant k\leqslant n)$$

(证明过程见注释。)

若 $\operatorname{rank}(T)<n$，则 $\operatorname{Vol}(P)=0$，这是平凡的；之后只需考虑 $\operatorname{rank}(T)=n$ 的情况。

由于 $P\subset T(\mathbb{B}_1^N)$，因此根据引理 1，可得

$$\left(\frac{\operatorname{Vol}(P)}{\operatorname{Vol}(B)}\right)^{1/n}\leqslant c_1e_n(T),$$

根据引理 2，令 $k=n$，可得

$$\begin{aligned}e_n(T)&\leqslant c_2\|T\|\sqrt{\frac{\ln(1+N/n)}{n}}\\&\leqslant C'\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}。\end{aligned}$$

(当 $x\geqslant 1$ 时，$\ln(1+x)\leqslant\ln 2x=\ln 2+\ln x\leqslant c'\ln \mathrm{e}x$) 如此，

$$\begin{aligned}\left(\frac{\operatorname{Vol}(P)}{\operatorname{Vol}(B)}\right)^{1/n}&\leqslant c_1e_n(T)\\&\leqslant c_1\cdot C'\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}\\&=:C\sqrt{\frac{\ln(\mathrm{e}N/n)}{n}}。\end{aligned}\qquad (C=c_1C')$$

注释 引理 1 (Carl 不等式) 的证明：

根据二进制熵数 $e_n(T)$ 的定义，可得

$$e_n(T)=\inf\left\{\varepsilon>0:T(\mathbb{B}_1^N)\subset\bigcup_{j=1}^{2^{n-1}}B_2(\boldsymbol{x}_j,\varepsilon);\boldsymbol{x}_1,\cdots,\boldsymbol{x}_{2^{n-1}}\in\mathbb{R}^n\right\},$$

可得对于任意的 $\varepsilon>e_n(T)$，存在 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_{2^{n-1}}\in\mathbb{R}^n$，使得 $T(\mathbb{B}_1^N)$ 被这 2^{n-1} 个半径为 ε 的 Euclidean 球完全覆盖，

$$T(\mathbb{B}_1^N)\subset\bigcup_{j=1}^{2^{n-1}}(\boldsymbol{x}_j+\varepsilon B)。$$

因此利用 Lebesgue 测度的次可加性，可得

$$\operatorname{Vol}(T(\mathbb{B}_1^N))\leqslant\operatorname{Vol}\left(\bigcup_{j=1}^{2^{n-1}}(\boldsymbol{x}_j+\varepsilon B)\right)\leqslant\sum_{j=1}^{2^{n-1}}\operatorname{Vol}(\boldsymbol{x}_j+\varepsilon B)=2^{n-1}\cdot\varepsilon^n\operatorname{Vol}(B)。$$

两侧同除以 $\operatorname{Vol}(B)$ 并取 $1/n$ 次幂，

$$\left(\frac{\operatorname{Vol}(T(\mathbb{B}_1^N))}{\operatorname{Vol}(B)}\right)^{1/n}\leqslant(2^{n-1}\varepsilon^n)^{1/n}=2^{\frac{n-1}{n}}\varepsilon<2\varepsilon。$$

令 $\varepsilon\to e_n(T)^+$，即得

$$\left(\frac{\operatorname{Vol}(T(\mathbb{B}_1^N))}{\operatorname{Vol}(B)}\right)^{1/n}\leqslant 2^{\frac{n-1}{n}}e_n(T)\leqslant 2e_n(T)。\qquad (c_1=2^{\frac{n-1}{n}}\leqslant 2)$$

注释 引理 2 (Maurey 引理) 的证明

不妨设 $\|T\|=1$ (若 $\|T\|\neq 0$，则只需考虑 $T/\|T\|$ 即可)。

设 $\boldsymbol{e}_1,\cdots,\boldsymbol{e}_N$ 为 ℓ_1^N 的标准基向量，记 $\boldsymbol{v}_i=T(\boldsymbol{e}_i)\in H$，则根据算子范数的定义，可得

$$\|T\|=\sup_{\|\boldsymbol{a}\|_1\leqslant 1}\|T(\boldsymbol{a})\|_H=\max_{1\leqslant i\leqslant N}\|\boldsymbol{v}_i\|_H=1。$$

由于 ℓ_1^N 的闭单位球为 $\mathbb{B}_1^N = \operatorname{conv}\{\pm \boldsymbol{e}_1, \cdots, \pm \boldsymbol{e}_N\}$，因此其于算子 T 的像为对称凸包

$$T(\mathbb{B}_1^N) = \operatorname{conv}\{\pm \boldsymbol{v}_1, \cdots, \pm \boldsymbol{v}_N\},$$

记极点集为 $V = \{\pm \boldsymbol{v}_1, \cdots, \pm \boldsymbol{v}_N\} \subset H$。

- Maurey 经验逼近法 (方差缩减)

  设 $\boldsymbol{x} \in T(\mathbb{B}_1^N) = \operatorname{conv}(V)$，则存在非负权重 $\lambda_1, \cdots, \lambda_{2N} \geqslant 0$ (满足 $\sum_{j=1}^{2N} \lambda_j = 1$)，$\boldsymbol{w}_1, \cdots, \boldsymbol{w}_{2N} \in V$，使得

  $$\boldsymbol{x} = \sum_{j=1}^{2N} \lambda_j \boldsymbol{w}_j。$$

  定义离散随机向量 $Z \in H$ 为

  $$\mathrm{P}\{Z = \boldsymbol{w}_j\} = \lambda_j, \qquad (j = 1, \cdots, 2N)$$

  其数字特征为

  $$\mathrm{E}[Z] = \sum_{j=1}^{2N} \lambda_j \boldsymbol{w}_j = \boldsymbol{x}，\ \mathrm{E}[\|Z\|_H^2] = \sum_{j=1}^{2N} \lambda_j \|\boldsymbol{w}_j\|_H^2 \leqslant \sum_{j=1}^{2N} \lambda_j \cdot 1^2 = 1,$$

  则对于 $Z_1, \cdots, Z_m$ i.i.d. $\sim Z$，其经验均值 $\bar{Z}_m = \frac{1}{m}\sum_{l=1}^m Z_l$ 于 Hilbert 空间的均方误差为

  $$\mathrm{E}\left[\left\|\boldsymbol{x} - \frac{1}{m}\sum_{l=1}^m Z_l\right\|_H^2\right] = \mathrm{E}\left[\left\|\frac{1}{m}\sum_{l=1}^m (Z_l - \mathrm{E}[Z_l])\right\|_H^2\right] = \frac{1}{m^2}\sum_{l=1}^m\sum_{r=1}^m \mathrm{E}[\langle Z_l - \mathrm{E}[Z_l], Z_r - \mathrm{E}[Z_r]\rangle_H],$$

  其中当 $l \neq r$ 时，交叉项 $\mathrm{E}[\langle Z_l - \mathrm{E}[Z_l], Z_r - \mathrm{E}[Z_r]\rangle_H] = 0$，因此

  $$\mathrm{E}[\|\boldsymbol{x} - \bar{Z}_m\|_H^2] = \frac{1}{m^2}\sum_{l=1}^m \mathrm{E}[\|Z_l - \mathrm{E}[Z_l]\|_H^2] = \frac{1}{m}(\mathrm{E}[\|Z\|_H^2] - \|\boldsymbol{x}\|_H^2) \leqslant \frac{1}{m},$$

  从而利用概率方法，可得存在 $(\boldsymbol{z}_1, \cdots, \boldsymbol{z}_m) \in V^m$，使得

  $$\left\|\boldsymbol{x} - \frac{1}{m}\sum_{l=1}^m \boldsymbol{z}_l\right\|_H \leqslant \frac{1}{\sqrt{m}},$$

  这表明 $T(\mathbb{B}_1^N)$ 可以被所有形如 $\frac{1}{m}\sum_{l=1}^m \boldsymbol{z}_l$ 的均值点为球心, 半径为 $\varepsilon = 1/\sqrt{m}$ 的 Euclidean 球完全覆盖。

- 覆盖球心计数与隔板法

  利用隔板法，可得球心点集的总容量为 (从大小为 $2N$ 的集合 V 有放回地无序选取 m 个元素的总组合数)

  $$\mathcal{N}\left(T(\mathbb{B}_1^N), \frac{1}{\sqrt{m}}\mathbb{B}_H\right) = \binom{2N+m-1}{m} \leqslant \left(\frac{\mathrm{e}(2N+m)}{m}\right)^m \leqslant \left(1 + \frac{2\mathrm{e}N}{m}\right)^m, \tag{I}$$

  对于任意的连续精度 $\varepsilon \in (0, 1]$，令 $m = \lceil \varepsilon^{-2} \rceil \leqslant 2\varepsilon^{-2}$，将其代入于 (I)，之后两侧取以 2 为底的对数，可得

  $$\log_2 \mathcal{N}(T(\mathbb{B}_1^N), \varepsilon\mathbb{B}_H) \leqslant \frac{C_1}{\varepsilon^2}\log_2(1 + N\varepsilon^2)。$$

  根据二进制熵数的定义，可得

  $$e_k(T) = \inf\{\varepsilon > 0 : \log_2 \mathcal{N}(T(\mathbb{B}_1^N), \varepsilon\mathbb{B}_H) \leqslant k - 1\},$$

  可得要证明 $e_k(T) \leqslant \varepsilon$，只需寻找满足以下隐式不等式的 $\varepsilon > 0$，

  $$\frac{1}{\varepsilon^2}\log_2(1 + N\varepsilon^2) \leqslant c_0 k。 \tag{II}$$

  - 单调函数反解

    引入 $\delta = \varepsilon^{-2} \geqslant 1$，则 (II) 等价于

    $$\Phi(\delta) := \delta \log_2\left(1 + \frac{N}{\delta}\right) \leqslant c_0 k,$$

    其中 Φ 于 $[1, +\infty)$ 是递增的。

代入试探解 $\delta^* := \frac{c_1 k}{\log_2(1+N/k)}$，可得

$$\begin{aligned}
\Phi(\delta^*) &= \frac{c_1 k}{\log_2(1+N/k)} \log_2\left(1 + \frac{N\log_2(1+N/k)}{c_1 k}\right) \\
&\leqslant \frac{c_1 k}{\log_2(1+N/k)} \log_2\left[\left(1+\frac{N}{k}\right)^2\right] \qquad \left(\text{选取充分小的 } c_1\text{，使得 } \frac{\log_2(1+u)}{c_1} \leqslant (1+u)\right) \\
&= \frac{c_1 k}{\log_2(1+N/k)} \cdot 2\log_2\left(1+\frac{N}{k}\right) \\
&= 2c_1 k,
\end{aligned}$$

因此

$$e_k(T) \leqslant \frac{1}{\sqrt{\delta^*}} = \frac{1}{\sqrt{c_1}} \sqrt{\frac{\log_2(1+N/k)}{k}},$$

恢复算子范数因子 $\|T\|$，转化对数底数，可得

$$e_k(T) \leqslant c_2 \|T\| \sqrt{\frac{\ln(1+N/k)}{k}}。$$

1 分析，概率的快速回顾

要点梳理

Section 1.1　凸集与凸函数 Q1.1 ∼ Q1.6

Section 1.2　范数与内积

Section 1.3　随机变量与随机向量

Section 1.4　联合界 Q1.7 ∼ Q1.10

引理 1.4.1 (联合界)
对于任意的事件 $E_1, \cdots, E_n$，

$$\mathrm{P}\left(\bigcup_{i=1}^{n} E_i\right) \leqslant \sum_{i=1}^{n} \mathrm{P}(E_i)。$$

例 1.4.2 (稠密随机图没有孤立顶点)
n 名新生独立地随机交友，每对学生成为朋友的概率为 p。若 $p \geqslant 4\ln(n)/n$，则以高概率没有学生是孤立无友的 (w.p. $1-1/n$)。

Section 1.5　条件

例 1.5.1 (完全抵消的概率)
设 $a_1, \cdots, a_n$ 为不全为零的实数，$X_1, \cdots, X_n$ i.i.d. $\sim$ Rademacher，记 $S_n = \sum_{i=1}^{n} a_i X_i$，则

$$\mathrm{P}\{S_n = 0\} \leqslant \frac{1}{2}。$$

Section 1.6　概率不等式 Q1.15 ∼ Q1.16

引理 1.6.1 (积分尾部公式)
设 X 为非负随机变量，则

$$\mathrm{E}[X]=\int_0^\infty \mathrm{P}\{X>t\}\mathrm{d}t,$$

等式两侧或者是同时有限的，或者是同时无限的。

命题 1.6.2 (Markov 不等式)
设 X 为非负随机变量，则

$$\mathrm{P}\{X\geqslant t\}\leqslant\frac{\mathrm{E}[X]}{t}。\qquad(t>0)$$

推论 1.6.3 (Chebyshev 不等式)
设 X 为随机变量，其均值为 μ, 方差为 σ^2，则对于任意的 $t>0$，

$$\mathrm{P}\{|X-\mu|\geqslant t\}\leqslant\frac{\sigma^2}{t^2}。$$

Section 1.7 极限定理 Q1.17 ~ Q1.19

定理 1.7.1 (强大数定律)
设 $\{X_N\}$ 为均值 μ 的独立同分布的随机变量列，记 $S_N=\sum_{i=1}^N X_i$，则

$$\frac{S_N}{N}\to\mu\ (\text{a.s.})。$$

定义 1.7.2 (正态分布)
随机变量 X 称为标准正态随机变量，记作 $X\sim N(0,1)$，若 X 的密度为

$$f(x)=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2},$$

此时随机变量 X 的均值为零，方差为 1。

更一般地，$X\sim N(\mu,\sigma^2)$，若

$$f(x)=\frac{1}{\sigma\sqrt{2\pi}}\mathrm{e}^{-(x-\mu)^2/(2\sigma^2)},$$

此时 X 可以表示为 $X=\mu+\sigma Z$，其中 $Z\sim N(0,1)$。

定理 1.7.3 (Lindeberg–Levy 中心极限定理)
设 $\{X_N\}$ 为均值 μ, 方差 σ^2 的独立同分布的随机变量列，记 $S_N=\sum_{i=1}^N a_iX_i$，将其标准化为零均值, 单位方差的随机变量，

$$Z_N=\frac{S_N-\mathrm{E}[S_N]}{\sqrt{\mathrm{Var}(S_N)}}=\frac{1}{\sigma\sqrt{N}}\sum_{i=1}^N(X_i-\mu),$$

则

$$Z_N\xrightarrow{d}N(0,1)。$$

定义 1.7.5 (Poisson 分布)
随机变量 Z 服从参数 $\lambda>0$ 的 Poisson 分布，记作 $Z\sim P(\lambda)$，若 $\mathrm{supp}(Z)=\mathbb{Z}_0^+$，

$$\mathrm{P}\{Z=k\}=\mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}。\qquad(k\in\mathbb{Z}_0^+)$$

定理 1.7.6 (Poisson 极限定理)
考虑独立随机变量 $X_{N,i} \sim \text{Bernoulli}(p_{N,i})$，其中 $1 \leqslant i \leqslant N$，记 $S_N = \sum_{i=1}^{N} X_{N,i}$。若当 $N \to \infty$ 时，

$$\max_{i \leqslant N} p_{N,i} \to 0,\ \mathrm{E}[S_N] = \sum_{i=1}^{N} p_{N,i} \to \lambda < \infty,$$

则当 $N \to \infty$ 时，

$$S_N \xrightarrow{d} P(\lambda)。$$

引理 1.7.7 (Stirling 近似)
当 $n \to \infty$ 时，

$$n! = \sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^n (1 + o(1))。$$

引理 1.7.8 (阶乘的界)

$$\left(\frac{n}{\mathrm{e}}\right)^n \leqslant n! \leqslant \mathrm{e}n\left(\frac{n}{\mathrm{e}}\right)^n。$$

习题解答

1 设 $T \subset \mathbb{R}^n$。证明：$\text{conv}(T)$ 为凸集。

证明 容易知道，

$$\text{conv}(T) = \left\{ \sum_{i=1}^{k} \lambda_i \boldsymbol{x}_i : k \in \mathbb{N}^+, \boldsymbol{x}_i \in T, \lambda_i \geqslant 0, \sum_{i=1}^{k} \lambda_i = 1 \right\}。$$

要证明 $\text{conv}(T)$ 为凸集，只需证明对于任意的 $\boldsymbol{u}, \boldsymbol{v} \in \text{conv}(T)$，

$$\alpha\boldsymbol{u} + (1-\alpha)\boldsymbol{v} \in \text{conv}(T)。 \qquad (\alpha \in [0,1])$$

设 $\boldsymbol{u} = \sum_{i=1}^{p} \lambda_i \boldsymbol{x}_i$，$\boldsymbol{v} = \sum_{j=1}^{q} \mu_j \boldsymbol{y}_j$，令

$$\boldsymbol{w} = \alpha\boldsymbol{u} + (1-\alpha)\boldsymbol{v} = \sum_{i=1}^{p} (\alpha\lambda_i)\boldsymbol{x}_i + \sum_{j=1}^{q} ((1-\alpha)\mu_j)\boldsymbol{y}_j,$$

则 $\boldsymbol{w}$ 满足：

1. 非负性：

   由于 $\alpha \in [0,1]$，$\lambda_i, \mu_j \geqslant 0$，因此 $\alpha\lambda_i \geqslant 0$，$(1-\alpha)\mu_j \geqslant 0$。

2. 归一性：

$$\sum_{i=1}^{p} \alpha\lambda_i + \sum_{j=1}^{q} (1-\alpha)\mu_j = \alpha \underbrace{\sum_{i=1}^{p} \lambda_i}_{1} + (1-\alpha) \underbrace{\sum_{j=1}^{q} \mu_j}_{1} = \alpha + (1-\alpha) = 1。$$

因此 $\boldsymbol{w} \in \text{conv}(T)$，即 $\text{conv}(T)$ 为凸集。

2 设 $f_1,\cdots,f_m$ 为定义于凸集 $D\subset\mathbb{R}^n$ 的有限个凸函数，$f(\boldsymbol{x})=\max\{f_1(\boldsymbol{x}),\cdots,f_m(\boldsymbol{x})\}$。证明：$f$ 为凸函数。

证明 要证明 f 为凸函数，只需证明对于任意的 $\boldsymbol{x},\boldsymbol{y}\in D$，

$$f(\alpha\boldsymbol{x}+(1-\alpha)\boldsymbol{y})\leqslant\alpha f(\boldsymbol{x})+(1-\alpha)f(\boldsymbol{y})。\qquad(\alpha\in[0,1])$$

设 $f(\alpha\boldsymbol{x}+(1-\alpha)\boldsymbol{y})=f_k(\alpha\boldsymbol{x}+(1-\alpha)\boldsymbol{y})$，则根据 f_k 的凸性，可得

$$\begin{aligned}f(\alpha\boldsymbol{x}+(1-\alpha)\boldsymbol{y})&=f_k(\alpha\boldsymbol{x}+(1-\alpha)\boldsymbol{y})\\&\leqslant\alpha f_k(\boldsymbol{x})+(1-\alpha)f_k(\boldsymbol{y})\\&\leqslant\alpha f(\boldsymbol{x})+(1-\alpha)f(\boldsymbol{y}),\end{aligned}$$

因此 f 为凸函数。

3 [**Jensen 不等式**] (1) 已知凸函数的定义为

$$f(\lambda x+(1-\lambda)y)\leqslant\lambda f(x)+(1-\lambda)f(y),$$

证明上述定义的多维版本。

设 $K\subset\mathbb{R}^n$ 为凸子集。证明：$f:K\to\mathbb{R}$ 为凸函数，当且仅当对于任意的 $\sum_{i=1}^m\lambda_i=1$ $(\lambda_i\geqslant0)$，均满足

$$f\left(\sum_{i=1}^m\lambda_i\boldsymbol{x}_i\right)\leqslant\sum_{i=1}^m\lambda_i f(\boldsymbol{x}_i)。$$

(2) 设 $\boldsymbol{X}$ 为有限支持的随机向量，$f:\mathbb{R}^n\to\mathbb{R}$ 为凸函数。利用 (1) 的结论，推导 Jensen 不等式，

$$f(\mathrm{E}[\boldsymbol{X}])\leqslant\mathrm{E}[f(\boldsymbol{X})]。$$

证明 (1) ($\Longrightarrow$)

令 $m=2$，即为凸函数的二维定义，因此 f 为凸函数。($\Longleftarrow$)

设 f 为凸函数。

当 $m=1$ 时，$f(\boldsymbol{x}_1)\leqslant f(\boldsymbol{x}_1)$。

当 $m=2$ 时，$f(\lambda_1\boldsymbol{x}_1+\lambda_2\boldsymbol{x}_2)\leqslant\lambda_1f(\boldsymbol{x}_1)+\lambda_2f(\boldsymbol{x}_2)$。

假设当 $m=k$ 时，不等式成立，则当 $m=k+1$ 时，$\sum_{i=1}^{k+1}\lambda_i=1$：

a. 若 $\lambda_{k+1}=1$，则 $\lambda_i=0$ $(i\neq k+1)$，结论是平凡的。

b. 若 $\lambda_{k+1}<1$，令 $L=\sum_{i=1}^k\lambda_i=1-\lambda_{k+1}>0$，则

$$\sum_{i=1}^{k+1}\lambda_i\boldsymbol{x}_i=L\left(\sum_{i=1}^k\frac{\lambda_i}{L}\boldsymbol{x}_i\right)+\lambda_{k+1}\boldsymbol{x}_{k+1}。$$

利用 (1) 的凸函数的二维定义，可得

$$\begin{aligned}f\left(\sum_{i=1}^{k+1}\lambda_i\boldsymbol{x}_i\right)&\leqslant Lf\left(\sum_{i=1}^k\frac{\lambda_i}{L}\boldsymbol{x}_i\right)+\lambda_{k+1}f(\boldsymbol{x}_{k+1})\\&=L\sum_{i=1}^k\frac{\lambda_i}{L}f(\boldsymbol{x}_i)+\lambda_{k+1}f(\boldsymbol{x}_{k+1})\qquad\left(\sum_{i=1}^k\frac{\lambda_i}{L}=1\right)\\&=\sum_{i=1}^{k+1}\lambda_if(\boldsymbol{x}_i)。\end{aligned}$$

(2) 设 $\mathrm{supp}(\boldsymbol{X})=\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_m\}$，其对应的概率为 $p_i=\mathrm{P}\{\boldsymbol{X}=\boldsymbol{x}_i\}$，满足 $p_i\geqslant0$，$\sum_{i=1}^m p_i=1$，则

$$\mathrm{E}[\boldsymbol{X}]=\sum_{i=1}^m p_i\boldsymbol{x}_i,\ \mathrm{E}[f(\boldsymbol{X})]=\sum_{i=1}^m p_if(\boldsymbol{x}_i)。$$

利用 (1) 的结论，令 $\lambda_i=p_i$，可得

$$f\left(\sum_{i=1}^m p_i\boldsymbol{x}_i\right)\leqslant\sum_{i=1}^m p_if(\boldsymbol{x}_i),$$

即 $f(\mathrm{E}[\boldsymbol{X}]) \leqslant \mathrm{E}[f(\boldsymbol{X})]$。

4 [**最大值原理**] 设 $f : \mathbb{R}^n \to \mathbb{R}$ 为凸函数。证明：对于任意的 $T \subset \mathbb{R}^n$，

$$\sup_{\boldsymbol{x}\in\mathrm{conv}(T)} f(\boldsymbol{x}) = \sup_{\boldsymbol{x}\in T} f(\boldsymbol{x})。$$

证明 由于 $T \subset \mathrm{conv}(T)$，因此

$$\sup_{\boldsymbol{x}\in T} f(\boldsymbol{x}) \leqslant \sup_{\boldsymbol{x}\in\mathrm{conv}(T)} f(\boldsymbol{x})。$$

设 $\boldsymbol{x} \in \mathrm{conv}(T)$，则存在 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_m \in T$，使得 $\boldsymbol{x} = \sum_{i=1}^m \lambda_i \boldsymbol{x}_i$ $(\lambda_i \geqslant 0, \sum_{i=1}^m \lambda_i = 1)$，因此利用 Jensen 不等式，可得

$$f(\boldsymbol{x}) = f\left(\sum_{i=1}^m \lambda_i \boldsymbol{x}_i\right) \leqslant \sum_{i=1}^m \lambda_i f(\boldsymbol{x}_i),$$

注意到 $f(\boldsymbol{x}_i) \leqslant \sup_{\boldsymbol{y}\in T} f(\boldsymbol{y})$，将其代入，可得

$$f(\boldsymbol{x}) \leqslant \sum_{i=1}^m \lambda_i \sup_{\boldsymbol{y}\in T} f(\boldsymbol{y}) = \sup_{\boldsymbol{y}\in T} f(\boldsymbol{y}),$$

即

$$\sup_{\boldsymbol{x}\in\mathrm{conv}(T)} f(\boldsymbol{x}) \leqslant \sup_{\boldsymbol{y}\in T} f(\boldsymbol{y})。$$

如此，

$$\sup_{\boldsymbol{x}\in\mathrm{conv}(T)} f(\boldsymbol{x}) = \sup_{\boldsymbol{x}\in T} f(\boldsymbol{x})。$$

5 [**将单位立方体表示为其顶点的凸包**] 证明：$[-1,1]^n = \mathrm{conv}(\{-1,1\}^n)$。

证明

- 证明 $\mathrm{conv}(\{-1,1\}^n) \subset [-1,1]^n$

  注意到 $[-1,1]^n$ 可以表示为 $2n$ 个闭半空间的交集，

  $$[-1,1]^n = \bigcap_{i=1}^n \{x \in \mathbb{R}^n : x_i \leqslant 1\} \cap \{x \in \mathbb{R}^n : x_i \geqslant -1\},$$

  其中半空间为凸集，因此 $[-1,1]^n$ 为凸集，从而根据凸包的极小性，可得 $\mathrm{conv}(\{-1,1\}^n) \subset [-1,1]^n$。

- 证明 $[-1,1]^n \subset \mathrm{conv}(\{-1,1\}^n)$

  只需证明对于任意的 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n) \in [-1,1]^n$，存在 $\{\lambda_{\boldsymbol{v}}\}_{\boldsymbol{v}\in\{-1,1\}^n}$，满足 $\lambda_{\boldsymbol{v}} \geqslant 0$，$\sum_{\boldsymbol{v}\in\{-1,1\}^n} \lambda_{\boldsymbol{v}} = 1$，使得

  $$\boldsymbol{x} = \sum_{\boldsymbol{v}\in\{-1,1\}^n} \lambda_{\boldsymbol{v}} \boldsymbol{v}。$$

  对于任意的 $\boldsymbol{v} \in \{-1,1\}^n$，构造

  $$\lambda_{\boldsymbol{v}} = \prod_{i=1}^n \left(\frac{1 + v_i x_i}{2}\right),$$

  (具体构造过程见注释。)

  则：

  1. 非负性：证略。
  2. 归一性：

  $$\begin{aligned}\sum_{\boldsymbol{v}\in\{-1,1\}^n} \lambda_{\boldsymbol{v}} &= \sum_{v_1\in\{-1,1\}} \cdots \sum_{v_n\in-1,1} \prod_{i=1}^n \left(\frac{1 + v_i x_i}{2}\right) \\ &= \prod_{i=1}^n \left(\sum_{v_i\in\{-1,1\}} \frac{1 + v_i x_i}{2}\right)\end{aligned}$$

$$= \prod_{i=1}^{n} \left(\frac{1 + x_i + 1 - x_i}{2} \right) = \prod_{i=1}^{n} 1 = 1。$$

3. 分量线性重构：考虑 $\sum_{\boldsymbol{v} \in \{-1,1\}^n} \lambda_{\boldsymbol{v}} \boldsymbol{v}$ 的第 j 个分量，

$$\begin{aligned}
\left(\sum_{\boldsymbol{v} \in \{-1,1\}^n} \lambda_{\boldsymbol{v}} \boldsymbol{v} \right)_j &= \sum_{\boldsymbol{v} \in \{-1,1\}^n} \lambda_{\boldsymbol{v}} v_j = \sum_{\boldsymbol{v} \in \{-1,1\}^n} v_j \prod_{i=1}^{n} \left(\frac{1 + v_i x_i}{2} \right) \\
&= \left(\sum_{v_j \in \{-1,1\}} v_j \frac{1 + v_j x_j}{2} \right) \prod_{i \neq j} \left(\sum_{v_i \in \{-1,1\}} \frac{1 + v_i x_i}{2} \right) \\
&= \left((+1) \cdot \frac{1 + x_j}{2} + (-1) \cdot \frac{1 - x_j}{2} \right) \cdot \prod_{i \neq j} 1 \\
&= \left(\frac{1 + x_j - 1 + x_j}{2} \right) \cdot 1 = x_j,
\end{aligned}$$

因此

$$\sum_{\boldsymbol{v} \in \{-1,1\}^n} \lambda_{\boldsymbol{v}} \boldsymbol{v} = \boldsymbol{x}。$$

如此，$[-1,1]^n \subset \operatorname{conv}(\{-1,1\}^n)$。

注释 关于构造过程的解释：

高维单位超立方体本质上为 n 个相互独立的一维线段的直积，因此只需考虑一维情况即可。

将 x 写为 $\{-1,1\}$ 的凸组合，可得

$$x = p \cdot (+1) + (1 - p) \cdot (-1) \implies p = \frac{1 + x}{2},$$

因此 λ_v 的极值为

$$\begin{aligned}
(v = 1) \quad \lambda_{+1} &= p = \frac{1 + x}{2}, \\
(v = -1) \quad \lambda_{-1} &= 1 - p = \frac{1 - x}{2},
\end{aligned}$$

从而构造极值之间的线性插值 $\lambda_v = (1 + vx)/2$。

6 **[将正轴体表示为其顶点的凸包]** 设 $\mathbb{B}_1^n = \{\boldsymbol{x} \in \mathbb{R}^n : \sum_{i=1}^n |x_i| \leqslant 1\}$。证明：$\mathbb{B}_1^n$ 为 $\boldsymbol{e}_1, \cdots, \boldsymbol{e}_n$ 及其相反向量构成的集合的凸包，即

$$\mathbb{B}_1^n = \operatorname{conv}(\{\pm \boldsymbol{e}_1, \cdots, \pm \boldsymbol{e}_n\}),$$

之后试求 $\boldsymbol{x} \in \mathbb{B}_1^n$ 关于 $\pm \boldsymbol{e}_1, \cdots, \pm \boldsymbol{e}_n$ 的凸组合的表达式。

证明 容易知道，$\operatorname{conv}(\{\pm \boldsymbol{e}_i\}) \subset \mathbb{B}_1^n$。(之后只需证明 $\mathbb{B}_1^n \subset \operatorname{conv}(\{\pm \boldsymbol{e}_i\})$。)

对于任意的 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n) \in \mathbb{B}_1^n$，记 ℓ^1 范数为 $L = \|\boldsymbol{x}\|_1 = \sum_{i=1}^n |x_i| \leqslant 1$，设分量的正部, 负部分别为

$$x_i^+ = \max(0, x_i), \quad x_i^- = \max(0, -x_i),$$

则

$$\boldsymbol{x} = \sum_{i=1}^{n} x_i \boldsymbol{e}_i = \sum_{i=1}^{n} (x_i^+ \boldsymbol{e}_i + x_i^- (-\boldsymbol{e}_i))。$$

(容易知道，$\sum_{i=1}^n (x_i^+ + x_i^-) = L \leqslant 1$，若 $L < 1$，则需要分配多余的权重 $1 - L$。注意到

$$\boldsymbol{0} = \frac{1}{2} \boldsymbol{e}_1 + \frac{1}{2} (-\boldsymbol{e}_1),$$

因此可以将剩余的权重分配于任意的一对相反的顶点以抵消其贡献。)

构造 $\lambda_{i,\sigma}\geqslant 0$，其中 $i\in\{1,\cdots,n\},\sigma\in\{+,-\}$，满足 $\sum_{i=1}^{n}(\lambda_{i,+}+\lambda_{i,-})=1$，使得

$$\boldsymbol{x}=\sum_{i=1}^{n}(\lambda_{i,+}\boldsymbol{e}_i+\lambda_{i,-}(-\boldsymbol{e}_i)),$$

之后令

$$\lambda_{i,+}=\begin{cases}x_1^+ + \dfrac{1}{2}(1-L), i=1,\\ x_i^+, \qquad\qquad i\geqslant 2\end{cases},\quad \lambda_{i,-}=\begin{cases}x_1^- + \dfrac{1}{2}(1-L), i=1,\\ x_i^-, \qquad\qquad i\geqslant 2\end{cases},$$

则：

1. 非负性：由于 $x_i^{\pm}\geqslant 0$，$L\leqslant 1$，因此 $\lambda_{i,\sigma}\geqslant 0$。

2. 归一性：

$$\sum_{i=1}^{n}(\lambda_{i,+}+\lambda_{i,-})=[x_1^+ + x_1^- + (1-L)]+\sum_{i=2}^{n}(x_i^+ + x_i^-)=\sum_{i=1}^{n}|x_i|+1-L=L+1-L=1。$$

3. 等价性：

$$\sum_{i=1}^{n}(\lambda_{i,+}\boldsymbol{e}_i+\lambda_{i,-}(-\boldsymbol{e}_i))=(x_1^+ - x_1^-)\boldsymbol{e}_1+\frac{1-L}{2}(\boldsymbol{e}_1-\boldsymbol{e}_1)+\sum_{i=2}^{n}(x_i^+ - x_i^-)\boldsymbol{e}_i=\sum_{i=1}^{n}x_i\boldsymbol{e}_i=\boldsymbol{x}。$$

因此于 $\mathbb{B}_1^n$ 的任意点均可以被表示为 $\{\pm\boldsymbol{e}_1,\cdots,\pm\boldsymbol{e}_n\}$ 的凸组合。

7 对于例题 1.4.2，设入学的新生人数 N 不再为常数，而是满足 $N\sim P(\lambda)$。证明：若 $p\geqslant 2\ln\lambda/\lambda$，则不存在没有朋友的学生 (即不存在孤立顶点) 的概率至少为 $1-1/\lambda$。

证明 设 $X_i=\mathbf{1}_{A_i}$，其中 $A_i=\{$第 i 名学生为孤立顶点$\}$。

(这些指示变量一般并不独立，以下计算过程只使用期望的线性性。)

记 $S_n=\sum_{i=1}^{n}X_i$ 为孤立顶点的个数，则要证明 $\mathrm{P}\{S_n=0\}\geqslant 1-1/\lambda$，只需证明 $\mathrm{P}\{S_n\geqslant 1\}\leqslant 1/\lambda$。

在给定 $N=n$ 的条件下，S_n 的条件期望为

$$\begin{aligned}\mathrm{E}[S_n\mid N=n]&=\sum_{i=1}^{n}\mathrm{E}[X_i\mid N=n]\\ &=\sum_{i=1}^{n}\mathrm{P}\{A_i\mid N=n\}\\ &=\sum_{i=1}^{n}(1-p)^{n-1}=n(1-p)^{n-1},\end{aligned}$$

因此 S_n 的期望为

$$\begin{aligned}\mathrm{E}[S_n]=\mathrm{E}[\mathrm{E}[S_n\mid N]]&=\sum_{n=1}^{\infty}\mathrm{E}[S_n\mid N=n]\cdot\mathrm{P}\{N=n\}\\ &=\sum_{n=1}^{\infty}n(1-p)^{n-1}\cdot\frac{\mathrm{e}^{-\lambda}\lambda^n}{n!}\\ &=\lambda\mathrm{e}^{-\lambda}\sum_{n=1}^{\infty}\frac{\lambda^{n-1}(1-p)^{n-1}}{(n-1)!}\\ &=\lambda\mathrm{e}^{-\lambda}\sum_{k=0}^{\infty}\frac{[\lambda(1-p)]^k}{k!}\\ &=\lambda\mathrm{e}^{-\lambda}\cdot\mathrm{e}^{\lambda(1-p)}=\lambda\mathrm{e}^{-\lambda p}\leqslant\lambda\mathrm{e}^{-\lambda\frac{2\ln\lambda}{\lambda}}=\frac{1}{\lambda}。\end{aligned}$$

利用 Markov 不等式，可得

$$\mathrm{P}\{S_n\geqslant 1\}\leqslant\mathrm{E}[S_n]\leqslant\frac{1}{\lambda},$$

因此

$$\mathrm{P}\{S_n = 0\} = 1 - \mathrm{P}\{S_n \geqslant 1\} \geqslant 1 - \frac{1}{\lambda}。$$

8 [**随机图的独立集**] 设 $n \geqslant 7$ 名学生参加概率论课程。任意一对学生之间以概率 1/2 独立地成为朋友 (即以概率 1/2 存在边)。证明：不存在人数超过 $2\log_2 n$ 的独立集的概率至少为 $1 - 1/n$。

证明 对于任意的大小为 $k = \lfloor 2\log_2 n \rfloor + 1$ 的子集 $S \subset \{1, 2, \cdots, n\}$，设 X_S 为 S 为独立集的示性变量。

记 $X = \sum_{|S|=k} X_S$ 为大小为 k 的独立集的个数。只需证明 $\mathrm{P}\{X \geqslant 1\} \leqslant 1/n$，因为这等价于 $\mathrm{P}\{X = 0\} \geqslant 1 - 1/n$。

由于 S 含有 $\binom{k}{2}$ 个潜在的相互独立的边，因此

$$\mathrm{P}\{X_S = 1\} = \left(\frac{1}{2}\right)^{\binom{k}{2}} = 2^{-\frac{k(k-1)}{2}},$$

从而

$$\begin{aligned}
\mathrm{E}[X] = \sum_{|S|=k} \mathrm{E}[X_S] &= \binom{n}{k} 2^{-\frac{k(k-1)}{2}} \\
&\leqslant \frac{n^k}{k!} 2^{-\frac{k(k-1)}{2}} = \frac{1}{k!}\left(n \cdot 2^{-\frac{k-1}{2}}\right)^k && \left(\binom{n}{k} \leqslant \frac{n^k}{k!}\right) \\
&< \frac{1}{k!}\left(n \cdot 2^{-\frac{2\log_2 n - 1}{2}}\right)^k = \frac{1}{k!}\left(\frac{\sqrt{2}}{n}\right)^k。 && (k > 2\log_2 n)
\end{aligned}$$

当 $n \geqslant 7$ 时，$k \geqslant 6$，此时 $(\sqrt{2}/n)^k/k! < 1/n$，因此利用 Markov 不等式，可得

$$\mathrm{P}\{X \geqslant 1\} \leqslant \mathrm{E}[X] < \frac{1}{n}。$$

9 [**稠密随机图的孤立顶点 (一阶矩方法)**] 设 $G(n, p_n)$ 为随机图，其中 n 为学生 (顶点) 数，p_n 为任意的两名学生成为朋友 (存在边) 的概率。证明：若对于任意的 $\varepsilon > 0$，均满足

$$p_n > \frac{(1+\varepsilon)\ln n}{n}。$$

则当 $n \to \infty$ 时，不存在没有朋友的学生 (即不存在孤立顶点) 的概率收敛于 1。

证明 设 $X_i = \mathbf{1}_{A_i}$，其中 $A_i = \{$第 i 名学生为孤立顶点$\}$。

(这些指标变量一般并不独立；以下计算过程只使用一阶矩方法。)

记 $S_n = \sum_{i=1}^n X_i$ 为孤立顶点的个数，则要证明 $\mathrm{P}\{S_n = 0\} \to 1$，只需证明 $\mathrm{P}\{S_n \geqslant 1\} \to 0$。

利用 Markov 不等式，可得

$$\mathrm{P}\{S_n \geqslant 1\} \leqslant \mathrm{E}[S_n],$$

因此只需证明 $\mathrm{E}[S_n] \to 0$。

容易知道，

$$\begin{aligned}
\mathrm{E}[S_n] = \sum_{i=1}^n \mathrm{E}[X_i] &= n\mathrm{P}\{X_1 = 1\} = n(1-p_n)^{n-1} \\
&\leqslant n\mathrm{e}^{-p_n(n-1)} \leqslant n\mathrm{e}^{-\frac{(1+\varepsilon)\ln n}{n}(n-1)} \longrightarrow 0。
\end{aligned}$$

10 [**稀疏随机图的孤立顶点 (孤立点性质的逆命题)**] 设 $G(n, p_n)$ 为随机图，其中 n 为学生 (顶点) 数，p_n 为任意的两名学生成为朋友 (存在边) 的概率。证明练习 Q1.9 (稠密随机图的孤立顶点 (一阶矩方法)) 的逆命题：若对于任意的 $\varepsilon > 0$，均满足

$$p_n < \frac{(1-\varepsilon)\ln n}{n}。$$

则当 $n \to \infty$ 时，存在至少一名没有朋友的学生 (即存在孤立顶点) 的概率收敛于 1。

利用第二矩方法，按照以下步骤证明：

(1) 记无朋友的学生数为 $S_n=\sum_{i=1}^n X_i$，其中 X_i 为第 i 个学生为孤立顶点的示性变量。证明：$\mu_n=\mathrm{E}[S_n]\to\infty$。
(2) 展开平方，计算二阶矩 $\mathrm{E}[S_n^2]$。(之后证明：$\mathrm{Var}(S_n)/\mu_n^2\to 0$。)

(3) 利用 Chebyshev 不等式，完成证明。

证明 要证明存在孤立点的概率收敛于 1，只需证明 $\mathrm{P}\{S_n=0\}\to 0$。

(1) 证明 $\mu_n=\mathrm{E}[S_n]\to\infty$

由于各边是相互独立的，因此

$$\mathrm{P}\{X_i=1\}=(1-p_n)^{n-1},$$

从而

$$\mu_n=\mathrm{E}[S_n]=\sum_{i=1}^n \mathrm{E}[X_i] \qquad =n(1-p_n)^{n-1}$$

$$\geqslant n\exp\left(-\frac{(n-1)p_n}{1-p_n}\right)\geqslant n^{\varepsilon/2}\left(\text{由}\ln(1-p_n)\leqslant\frac{p_n}{1-p_n},\ \text{并且当 } n \text{ 充分大时}\frac{1}{1-p_n}\leqslant 1+\frac{\varepsilon}{2}\right)$$

- 证明 $\mathrm{Var}(S_n)/\mu_n^2\to 0$

容易知道，

$$\mathrm{E}[S_n^2]=\sum_{i=1}^n \mathrm{E}[X_i^2]+\sum_{i\neq j}\mathrm{E}[X_iX_j]=\mu_n+\sum_{i\neq j}\mathrm{P}\{X_i=1,X_j=1\}。$$

(之后只需考虑交叉项即可。)

$\{X_i=1,X_j=1\}$ 表示 i,j 均为孤立点，即“(i,j) 不存在，i 与剩余 $n-2$ 个顶点不存在边，j 与剩余 $n-2$ 个顶点不存在边”，其涉及的独立边的个数为 $1+(n-2)+(n-2)=2n-3$，因此

$$\mathrm{E}[X_iX_j]=(1-p_n)^{2n-3},$$

将其代入，可得

$$\mathrm{E}[S_n^2]=\mu_n+n(n-1)(1-p_n)^{2n-3},$$

从而

$$\frac{\mathrm{E}[S_n^2]}{\mu_n^2}=\frac{\mu_n}{\mu_n^2}+\frac{n(n-1)(1-p_n)^{2n-3}}{n^2(1-p_n)^{2n-2}}=\frac{1}{\mu_n}+\frac{n-1}{n}\cdot\frac{1}{1-p_n}\to 1,$$

从而

$$\frac{\mathrm{Var}(S_n)}{\mu_n^2}=\frac{\mathrm{E}[S_n^2]}{\mu_n^2}-1\to 0。$$

(3) 利用 Chebyshev 不等式，可得

$$\mathrm{P}\{S_n=0\}\leqslant\mathrm{P}\{|S_n-\mu_n|\geqslant\mu_n\}\leqslant\frac{\mathrm{Var}(S_n)}{\mu_n^2}\to 0。$$

11 [L^p **范数的单调性**] (1) 设 X 是于 $(\Omega,\mathscr{F},\mathrm{P})$ 的随机变量。证明：$\|X\|_{L^p}=(\mathrm{E}[|X|^p])^{1/p}$ 为关于 p 的单调递增函数，即对于任意的 $0<p\leqslant q\leqslant\infty$，均满足

$$\|X\|_{L^p}\leqslant\|X\|_{L^q}。$$

(2) 说明 (1) 的不等式通常是不可反向的，即构造反例 X，使得对于任意的 $0<p<q\leqslant\infty$，均满足 $\|X\|_{L^p}<\infty$，$\|X\|_{L^q}=\infty$。

证明 (1) 对 q 的取值进行讨论：

a. 当 $q<\infty$ 时，利用 Jensen 不等式 $\phi(\mathrm{E}[Y])\leqslant\mathrm{E}[\phi(Y)]$，令 $Y=|X|^p$，$\phi(x)=x^\alpha$ $(\alpha\geqslant 1)$，可得

$$(\mathrm{E}[|X|^p])^{q/p}\leqslant\mathrm{E}[(|X|^p)^{q/p}]=\mathrm{E}[|X|^q],$$

两侧取 $1/q$ 次幂，

$$(\mathrm{E}[|X|^p])^{\frac{1}{p}}\leqslant(\mathrm{E}[|X|^q])^{\frac{1}{q}},$$

即 $\|X\|_{L^p} \leqslant \|X\|_{L^q}$。

b. 当 $q=\infty$ 时，由于 $|X| \leqslant \|X\|_{L^\infty}$ (a.s.)，因此

$$|X|^p \leqslant \|X\|_{L^\infty}^p \text{ (a.s.)},$$

两侧取期望，

$$\mathrm{E}[|X|^p] \leqslant \mathrm{E}\|X\|_{L^\infty}^p = \|X\|_{L^\infty}^p,$$

两侧取 $1/p$ 次幂，

$$\|X\|_{L^p} \leqslant \|X\|_{L^\infty}。$$

(2) a. 当 $q<\infty$ 时，

(考虑构造厚尾分布的随机变量。)

令 $\Omega=[1,\infty)$，$X \sim \text{Pareto}$，即

$$f(x) = \frac{q}{x^{q+1}}\mathbf{1}_{\{x\geqslant 1\}},$$

则

$$\|X\|_{L^q}^q = \mathrm{E}[|X|^q] = \int_1^\infty x^q \cdot \frac{q}{x^{q+1}}\mathrm{d}x = \int_1^\infty \frac{q}{x}\mathrm{d}x = q[\ln x]_1^\infty = \infty,$$

$$\|X\|_{L^p}^p = \mathrm{E}[|X|^p] = \int_1^\infty x^p \cdot \frac{q}{x^{q+1}}\mathrm{d}x = q\int_1^\infty x^{p-q-1}\mathrm{d}x = \frac{q}{q-p} < \infty。$$

b. 当 $q=\infty$ 时，

(考虑构造无界随机变量，其 p 阶矩有限。)

令 $X \sim E(1)$，则

$$\|X\|_{L^\infty} = \infty,$$

$$\|X\|_{L^p}^p = \mathrm{E}[|X|^p] = \int_0^\infty x^p \mathrm{e}^{-x}\mathrm{d}x = \Gamma(p+1) < \infty。$$

12 [L^1, L^∞ 之间的插值不等式] 已知 $\|X\|_{L^p}$ 存在上界

$$\|X\|_{L^p} \leqslant \|X\|_{L^\infty}。$$

证明：当 X 的 L^1 范数较小时，存在更紧的上界

$$\|X\|_{L^p} \leqslant \|X\|_{L^1}^{\frac{1}{p}}\|X\|_{L^\infty}^{1-\frac{1}{p}}。$$

证明 根据 L^∞ 范数的定义 (本质上确界)，可得

$$|X(\omega)| \leqslant \|X\|_{L^\infty} \text{ (a.s.)},$$

因此

$$\begin{aligned} |X|^p &= |X| \cdot |X|^{p-1} \\ &\leqslant |X| \cdot (\|X\|_{L^\infty})^{p-1} \text{ (a.s.)}, \end{aligned}$$

两侧取期望，

$$\begin{aligned} \mathrm{E}[|X|^p] &\leqslant \mathrm{E}[|X| \cdot (\|X\|_{L^\infty})^{p-1}] \\ &= (\|X\|_{L^\infty})^{p-1} \cdot \mathrm{E}[|X|] \\ &= (\|X\|_{L^\infty})^{p-1} \cdot \|X\|_{L^1}, \end{aligned}$$

两侧取 $1/p$ 次幂，

$$\begin{aligned} \|X\|_{L^p} = (\mathrm{E}[|X|^p])^{\frac{1}{p}} &\leqslant (\|X\|_{L^1} \cdot \|X\|_{L^\infty}^{p-1})^{\frac{1}{p}} \\ &= \|X\|_{L^1}^{\frac{1}{p}} \cdot \|X\|_{L^\infty}^{\frac{p-1}{p}} \\ &= \|X\|_{L^1}^{\frac{1}{p}} \cdot \|X\|_{L^\infty}^{1-\frac{1}{p}}。 \end{aligned}$$

13 [**最大值的期望**] 设 $X_1,\cdots,X_n$ 为非负随机变量。

(1) 证明：

$$\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]\leqslant \mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\leqslant n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]。$$

(2) 证明：于 (1) 的不等号均是紧的，即构造反例 $\{X_n;Y_n\}$，使得

$$\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]>0，\ \mathrm{E}\left[\max_{1\leqslant i\leqslant n}Y_i\right]=n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[Y_i]>0。$$

(3) 证明：即使对于独立随机变量，(1) 的上界于量级是不可改进的，即构造反例 $X_1,\cdots,X_n$，使得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]>cn\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]。$$

证明 (1) 对于左侧，注意到 $\max_i X_i\geqslant X_k$，两侧取期望，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\geqslant\mathrm{E}[X_k]，$$

因此

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\geqslant\max_{1\leqslant k\leqslant n}\mathrm{E}[X_k]。$$

对于右侧，注意到 $\max_i X_i\leqslant\sum_{i=1}^n X_i$，两侧取期望，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\leqslant\mathrm{E}\left[\sum_{i=1}^n X_i\right]=\sum_{i=1}^n\mathrm{E}[X_i]，$$

其中

$$\sum_{i=1}^n\mathrm{E}[X_i]\leqslant\sum_{i=1}^n\left(\max_{1\leqslant j\leqslant n}\mathrm{E}[X_j]\right)=n\cdot\max_{1\leqslant j\leqslant n}\mathrm{E}[X_j]，$$

将其代入，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\leqslant n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]。$$

(2) (对于左侧，构造 $\{X_n\}$，使得 $\mathrm{E}[\max_i X_i]=\max_i\mathrm{E}[X_i]$。)

令 $X_1=\cdots=X_n\equiv 1$，则

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]=\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]=1。$$

(对于右侧，构造 $\{Y_n\}$，使得 $\mathrm{E}[\max Y_i]=n\cdot\max\mathrm{E}[Y_i]$。)

将 Ω 划分为 n 个等概率相的事件 $A_1,\cdots,A_n$，即

$$\Omega=\bigsqcup_{i=1}^n A_i，\ \mathrm{P}(A_i)=\frac{1}{n}。$$

令 $Y_i=\mathbf{1}_{A_i}$，则 $\max_i Y_i=1$ ($Y_1(\omega),\cdots,Y_n(\omega)$ 恰好含有一个取值为 1)，因此

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}Y_i\right]=n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[Y_i]=1。$$

(3) 设 $X_1,\cdots,X_n$ i.i.d. $\sim$ Bernoulli$(1/n)$，$M_n=\max_i X_i$，则

$$\begin{aligned}\mathrm{P}\{M_n=1\}&=1-\mathrm{P}\{M_n=0\}\\&=1-\mathrm{P}\{X_1=0,\cdots,X_n=0\}\\&=1-\prod_{i=1}^n\mathrm{P}\{X_n=0\}=1-\left(1-\frac{1}{n}\right)^n。\end{aligned}$$

因此

$$\mathrm{E}[M_n]=1\cdot\mathrm{P}\{M_n=1\}=1-\left(1-\frac{1}{n}\right)^n\to 1-\frac{1}{\mathrm{e}}。$$

从而存在 $c>0$，使得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n} X_i\right] > c\cdot\left(n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]\right)=c,$$

即

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n} X_i\right] \gtrsim \left(n\cdot\max_{1\leqslant i\leqslant n}\mathrm{E}[X_i]\right)。$$

14 [**Minkowski 不等式的积分形式**] 设 $\{X_n\}$ 是非负的。证明：对于任意的 $1\leqslant p<\infty$，

$$\left(\sum_{i=1}^n(\mathrm{E}[X_i])^p\right)^{1/p}\leqslant\mathrm{E}\left[\left(\sum_{i=1}^n X_i^p\right)^{1/p}\right]\leqslant\left(\sum_{i=1}^n\mathrm{E}[X_i^p]\right)^{1/p}。$$

证明 对于右侧，利用 Jensen 不等式 $\phi(\mathrm{E}[Y])\leqslant\mathrm{E}[\phi(Y)]$，令 $Y=\sum_{i=1}^n X_i^p$，$\phi(y)=y^{1/p}$，则

$$\mathrm{E}\left[\left(\sum_{i=1}^n X_i^p\right)^{1/p}\right]\leqslant\left(\mathrm{E}\left[\sum_{i=1}^n X_i^p\right]\right)^{1/p}=\left(\sum_{i=1}^n\mathrm{E}[X_i^p]\right)^{1/p}。$$

对于左侧，定义 $g:\mathbb{R}^n\to\mathbb{R}$ 为 (即为 ℓ^p 范数)

$$g(\boldsymbol{x})=\|\boldsymbol{x}\|_p=\left(\sum_{i=1}^n|x_i|^p\right)^{1/p},$$

则利用多维 Jensen 不等式，可得 $g(\mathrm{E}[\boldsymbol{X}])\leqslant\mathrm{E}[g(\boldsymbol{X})]$，即

$$\left(\sum_{i=1}^n|\mathrm{E}[X_i]|^p\right)^{1/p}\leqslant\mathrm{E}\left[\left(\sum_{i=1}^n|X_i|^p\right)^{1/p}\right]。$$

即

$$\left(\sum_{i=1}^n(\mathrm{E}[X_i])^p\right)^{1/p}\leqslant\mathrm{E}\left[\left(\sum_{i=1}^n X_i^p\right)^{1/p}\right]。$$

15 [**积分尾部公式**] 证明引理 L1.6.1 (积分尾部公式) 的一般版本。

(1) 设 X 为任意的随机变量 (未必非负)。证明：

$$\mathrm{E}[X]=\int_0^\infty\mathrm{P}\{X>t\}\mathrm{d}t-\int_{-\infty}^0\mathrm{P}\{X<t\}\mathrm{d}t。$$

(2) 设 X 为非负随机变量，$f:\mathbb{R}\to\mathbb{R}$ 为单调递增的可微函数，满足 $f(0)=0$。证明：

$$\mathrm{E}[f(X)]=\int_0^\infty\mathrm{P}\{X>t\}f'(t)\mathrm{d}t。$$

(3) 设 X 为任意的随机变量 (未必非负)。证明：对于任意的 $0<p<\infty$，均满足

$$\mathrm{E}[|X|^p]=\int_0^\infty\mathrm{P}\{|X|>t\}pt^{p-1}\mathrm{d}t。$$

证明 (1) 将 X 进行分解 $X=X^+-X^-$，则 $\mathrm{E}[X]=\mathrm{E}[X^+]-\mathrm{E}[X^-]$。

由于

$$X^+=\int_0^\infty\mathbf{1}_{\{X^+>t\}}\mathrm{d}t=\int_0^\infty\mathbf{1}_{\{X>t\}}\mathrm{d}t,$$

因此

$$\mathrm{E}[X^+]=\mathrm{E}\left[\int_0^\infty\mathbf{1}_{\{X>t\}}\mathrm{d}t\right]=\int_0^\infty\mathrm{E}[\mathbf{1}_{\{X>t\}}]\mathrm{d}t=\int_0^\infty\mathrm{P}\{X>t\}\mathrm{d}t;\qquad(t\geqslant 0)$$

同理，

$$\begin{aligned}\mathrm{E}[X^-] &= \int_0^\infty \mathrm{P}\{X^- > u\}\mathrm{d}u = \int_0^\infty \mathrm{P}\{X < -u\}\mathrm{d}u && (u \geqslant 0)\\ &= \int_{-\infty}^0 \mathrm{P}\{X < t\}\mathrm{d}t, && (t = -u)\end{aligned}$$

从而

$$\mathrm{E}[X] = \mathrm{E}[X^+] - \mathrm{E}[X^-] = \int_0^\infty \mathrm{P}\{X > t\}\mathrm{d}t - \int_{-\infty}^0 \mathrm{P}\{X < t\}\mathrm{d}t。$$

(2) 由于 $f(0) = 0$，因此

$$f(X) = \int_0^X f'(t)\mathrm{d}t = \int_0^\infty f'(t)\mathbf{1}_{\{t<X\}}\mathrm{d}t = \int_0^\infty f'(t)\mathbf{1}_{\{X>t\}}\mathrm{d}t,$$

两侧取期望，根据 Fubini 定理，可得

$$\begin{aligned}\mathrm{E}[f(X)] &= \mathrm{E}\left[\int_0^\infty f'(t)\mathbf{1}_{\{X>t\}}\mathrm{d}t\right]\\ &= \int_0^\infty \mathrm{E}[f'(t)\mathbf{1}_{\{X>t\}}]\mathrm{d}t\\ &= \int_0^\infty f'(t)\mathrm{E}[\mathbf{1}_{\{X>t\}}]\mathrm{d}t\\ &= \int_0^\infty f'(t)\mathrm{P}\{X > t\}\mathrm{d}t,\end{aligned}$$

(3) 利用 (2) 的结论，令 $Y = |X|$，$f(y) = y^p$，则

$$\mathrm{E}[f(Y)] = \mathrm{E}[|X|^p] = \int_0^\infty \mathrm{P}\{Y > t\}f'(t)\mathrm{d}t,$$

即

$$\mathrm{E}[|X|^p] = \int_0^\infty \mathrm{P}\{|X| > t\}pt^{p-1}\mathrm{d}t。$$

16 [**Paley-Zygmund 不等式**] Markov 不等式告诉我们，随机变量远大于其期望的概率是很小的。反之，非负随机变量远小于其期望的概率是否也是很小的？答案通常是否定的，但是，若随机变量的二阶矩不是太大，则可以给出肯定的回答。

设非负随机变量 X 满足 $\mathrm{E}[X^2] < \infty$。证明：对于任意的 $\varepsilon \in [0, 1]$，均满足

$$\mathrm{P}\{X > \varepsilon\mathrm{E}[X]\} \geqslant (1-\varepsilon)^2\frac{(\mathrm{E}[X])^2}{\mathrm{E}[X^2]}。$$

证明 设 $A = \{X > \varepsilon\mathrm{E}[X]\}$，将 X 以 A 进行分解，

$$\mathrm{E}[X] = \mathrm{E}[X\mathbf{1}_A] + \mathrm{E}[X\mathbf{1}_{A^c}],$$

其中

$$\mathrm{E}[X\mathbf{1}_{A^c}] \leqslant \mathrm{E}[\varepsilon\mathrm{E}[X]\cdot\mathbf{1}_{A^c}] = \varepsilon\mathrm{E}[X]\mathrm{P}(A^c) \leqslant \varepsilon\mathrm{E}[X],$$

因此

$$\mathrm{E}[X] \leqslant \mathrm{E}[X\mathbf{1}_A] + \varepsilon\mathrm{E}[X],$$

即

$$\mathrm{E}[X\mathbf{1}_A] \geqslant (1-\varepsilon)\mathrm{E}[X]。$$

利用 Cauchy 不等式，可得

$$(\mathrm{E}[X\mathbf{1}_A])^2 \leqslant \mathrm{E}[X^2]\mathrm{E}[\mathbf{1}_A^2] = \mathrm{E}[X^2]\mathrm{E}[\mathbf{1}_A] = \mathrm{E}[X^2]\mathrm{P}(A),$$

从而

$$(1-\varepsilon)^2(\mathrm{E}[X])^2 \leqslant \mathrm{E}[X^2]\mathrm{P}(A),$$

即

$$\mathrm{P}(A) \geqslant (1-\varepsilon)^2\frac{(\mathrm{E}[X])^2}{\mathrm{E}[X^2]}。$$

(若 $\mathrm{E}[X^2]=0$，则 $X=0$ (a.s.)，不等式的两侧均为 0，结论是平凡的。)

17 [ℓ^p **范数的比较**] 设 $\boldsymbol{x}=(x_1,\cdots,x_n)\in\mathbb{R}^n$，对于 $p\in\bar{\mathbb{R}}^+$，定义 ℓ^p 范数为

$$\|\boldsymbol{x}\|_p=\begin{cases}\left(\sum\limits_{i=1}^n|x_i|^p\right)^{1/p}, & 0<p<\infty,\\ \max\limits_{1\leqslant i\leqslant n}|x_i|, & p=\infty\end{cases},$$

(1) 证明：对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\|\boldsymbol{x}\|_q\leqslant\|\boldsymbol{x}\|_p\leqslant n^{\frac{1}{p}-\frac{1}{q}}\|\boldsymbol{x}\|_q,$$

其中当 $q=\infty$ 时，约定 $1/q=0$。

(2) 说明 (1) 的两个不等式均是紧的，即构造 $\boldsymbol{x},\boldsymbol{y}\neq\boldsymbol{0}$，使得 $\|\boldsymbol{x}\|_p=\|\boldsymbol{x}\|_q$，

$$\|\boldsymbol{y}\|_p=n^{\frac{1}{p}-\frac{1}{q}}\|\boldsymbol{y}\|_q。$$

证明 (1) 对于左侧：

a. 当 $q=\infty$ 时，由于

$$|x_j|^p\leqslant\sum_{i=1}^n|x_i|^p,$$

两侧开 p 次方，

$$|x_j|\leqslant\left(\sum_{i=1}^n|x_i|^p\right)^{1/p}=\|\boldsymbol{x}\|_p,$$

因此

$$\|\boldsymbol{x}\|_\infty=\max_{1\leqslant j\leqslant n}|x_j|\leqslant\|\boldsymbol{x}\|_p。$$

b. 当 $q<\infty$ 时，不妨设 $\|\boldsymbol{x}\|_p=1$ (若 $\boldsymbol{x}=\boldsymbol{0}$，则结论成立；否则，考虑归一化向量 $\bar{\boldsymbol{x}}=\boldsymbol{x}/\|\boldsymbol{x}\|_p$)，则 $\sum_{i=1}^n|x_i|^p=1$，因此 $|x_i|\in[0,1]$。

由于 $p\leqslant q$，因此 $|x_i|^q\leqslant|x_i|^p$，两侧求和，

$$\sum_{i=1}^n|x_i|^q\leqslant\sum_{i=1}^n|x_i|^p=1,$$

两侧取 $1/q$ 次幂，

$$\|\boldsymbol{x}\|_q=\left(\sum_{i=1}^n|x_i|^q\right)^{1/q}\leqslant1^{1/q}=1=\|\boldsymbol{x}\|_p。$$

对于右侧：

a. 当 $q=\infty$ 时，

$$\|\boldsymbol{x}\|_p=\left(\sum_{i=1}^n|x_i|^p\right)^{1/p}\leqslant\left(\sum_{i=1}^n(\|\boldsymbol{x}\|_\infty)^p\right)^{1/p}=(n\|\boldsymbol{x}\|_\infty^p)^{1/p}=n^{1/p}\|\boldsymbol{x}\|_\infty。$$

b. 当 $q<\infty$ 时，利用 Holder 不等式，令 $\alpha=q/p$，$\beta=q/(q-p)$，可得

$$\sum_{i=1}^{n}|x_i|^p\cdot 1\leqslant\left(\sum_{i=1}^{n}(|x_i|^p)^{\alpha}\right)^{1/\alpha}\left(\sum_{i=1}^{n}1^{\beta}\right)^{1/\beta},$$

即

$$\|\boldsymbol{x}\|_p^p\leqslant\left(\sum_{i=1}^{n}|x_i|^q\right)^{p/q}\cdot n^{\frac{q-p}{q}}=\|\boldsymbol{x}\|_q^p\cdot n^{1-p/q},$$

两侧取 $1/p$ 次幂，

$$\|\boldsymbol{x}\|_p\leqslant\|\boldsymbol{x}\|_q\cdot n^{\frac{1}{p}-\frac{1}{q}}。$$

(2) 对于左侧，令 $\boldsymbol{x}=\boldsymbol{e}_1=(1,0,\cdots,0)^{\top}$ (稀疏向量)，则

$$\|\boldsymbol{x}\|_p=\|\boldsymbol{x}\|_q=1。$$

对于右侧，令 $\boldsymbol{y}=(1,1,\cdots,1)^{\top}$，则

$$\|\boldsymbol{y}\|_p=\left(\sum_{i=1}^{n}1^p\right)^{\frac{1}{p}}=n^{\frac{1}{p}},\ \|\boldsymbol{y}\|_q=\left(\sum_{i=1}^{n}1^q\right)^{\frac{1}{q}}=n^{\frac{1}{q}},$$

因此

$$n^{\frac{1}{p}-\frac{1}{q}}\|\boldsymbol{y}\|_q=n^{\frac{1}{p}}\cdot n^{-\frac{1}{q}}\cdot n^{\frac{1}{q}}=n^{\frac{1}{p}}=\|\boldsymbol{y}\|_p。$$

(若 $q=\infty$，则 $\|\boldsymbol{y}\|_{\infty}=1$，可得 $n^{1/p-0}\cdot 1=n^{1/p}$。)

18 [ℓ^{∞} 范数为 ℓ^p 范数的极限] 设 $\boldsymbol{x}\in\mathbb{R}^n$。

(1) 证明：当 $p\to\infty$ 时，$\|\boldsymbol{x}\|_p\to\|\boldsymbol{x}\|_{\infty}$。

(2) 事实上，为了使 ℓ^p 范数充分地接近于 ℓ^{∞} 范数，p 不需要特别大。证明：若 $p\geqslant\ln n$，则

$$\|\boldsymbol{x}\|_{\infty}\leqslant\|\boldsymbol{x}\|_p\leqslant\mathrm{e}\|\boldsymbol{x}\|_{\infty}。$$

证明 若 $\boldsymbol{x}=\boldsymbol{0}$，则任意的范数均为 0，结论是平凡的；之后只需考虑 $\boldsymbol{x}\neq\boldsymbol{0}$ 即可。

(1) 对于下界，根据 $\|\boldsymbol{x}\|_{\infty}$ 的定义，存在下标 k，使得 $|x_k|=\|\boldsymbol{x}\|_{\infty}$，则

$$\|\boldsymbol{x}\|_p=\left(\sum_{i=1}^{n}|x_i|^p\right)^{1/p}\geqslant(|x_k|^p)^{1/p}=|x_k|=\|\boldsymbol{x}\|_{\infty}。$$

对于上界，由于 $|x_i|\leqslant\|\boldsymbol{x}\|_{\infty}$，因此

$$\|\boldsymbol{x}\|_p=\left(\sum_{i=1}^{n}|x_i|^p\right)^{1/p}\leqslant\left(\sum_{i=1}^{n}\|\boldsymbol{x}\|_{\infty}^p\right)^{1/p}=(n\cdot\|\boldsymbol{x}\|_{\infty}^p)^{1/p}=n^{1/p}\|\boldsymbol{x}\|_{\infty}。$$

如此，

$$\|\boldsymbol{x}\|_{\infty}\leqslant\|\boldsymbol{x}\|_p\leqslant n^{1/p}\|\boldsymbol{x}\|_{\infty},$$

因此根据夹逼定理，可得

$$\lim_{p\to\infty}\|\boldsymbol{x}\|_p=\|\boldsymbol{x}\|_{\infty}。$$

(2) 当 $p\geqslant\ln n$ 时，$n^{1/p}\leqslant n^{1/\ln n}=\mathrm{e}$，因此

$$\|\boldsymbol{x}\|_{\infty}\leqslant\|\boldsymbol{x}\|_p\leqslant\mathrm{e}\|\boldsymbol{x}\|_{\infty}。$$

19 [ℓ_p 范数的对偶性] 设 $p,p'\in[1,\infty]$ 为共轭指数 (即满足 $1/p+1/p'=1$)。

(1) 证明 Hölder 不等式是紧的，即对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，存在 $\boldsymbol{y}\neq\boldsymbol{0}$，使得

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle=\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_{p'}。$$

(2) 利用 (1) 的结论，证明：对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，均满足

$$\|\boldsymbol{x}\|_p=\max\{\langle\boldsymbol{x},\boldsymbol{y}\rangle:\boldsymbol{y}\in\mathbb{B}_{p'}^n\},$$

其中 $\mathbb{B}_{p'}^n=\{\boldsymbol{y}\in\mathbb{R}^n:\|\boldsymbol{y}\|_{p'}\leqslant 1\}$ 为 $\ell_{p'}$ 范数的单位球。

证明 若 $\boldsymbol{x}=\boldsymbol{0}$，则两侧均为 0，结论是平凡的；之后只需考虑 $\boldsymbol{x}\neq\boldsymbol{0}$ 的情况。

(1) (之后只需根据 p 的取值分情况构造 $\boldsymbol{y}$。)

a. 若 $1<p'<\infty$，令 $y_i=\operatorname{sgn}(x_i)|x_i|^{p-1}$，则

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle=\sum_{i=1}^n x_i\cdot\operatorname{sgn}(x_i)|x_i|^{p-1}=\sum_{i=1}^n|x_i|\cdot|x_i|^{p-1}=\sum_{i=1}^n|x_i|^p=\|\boldsymbol{x}\|_p^p,$$

$$\|\boldsymbol{y}\|_{p'}=\left(\sum_{i=1}^n|y_i|^{p'}\right)^{1/p'}=\left(\sum_{i=1}^n(|x_i|^{p-1})^{p'}\right)^{1/p'}=\left(\sum_{i=1}^n|x_i|^p\right)^{1/p'}=\|\boldsymbol{x}\|_p^{p/p'},$$

因此

$$\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_{p'}=\|\boldsymbol{x}\|_p\|\boldsymbol{x}\|_p^{p/p'}=\|\boldsymbol{x}\|_p^{1+p/p'}=\|\boldsymbol{x}\|_p^p。$$

b. 若 $p=1,p'=\infty$，令 $y_i=\operatorname{sgn}(x_i)$，则

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle=\sum_{i=1}^n x_i\operatorname{sgn}(x_i)=\sum_{i=1}^n|x_i|=\|\boldsymbol{x}\|_1,$$

$$\|\boldsymbol{y}\|_\infty=\max_{1\leqslant i\leqslant n}|\operatorname{sgn}(x_i)|=1,$$

可得

$$\|\boldsymbol{x}\|_1\|\boldsymbol{y}\|_\infty=\|\boldsymbol{x}\|_1\cdot 1=\langle\boldsymbol{x},\boldsymbol{y}\rangle。$$

c. 若 $p=\infty,p'=1$，令下标 k 满足 $|x_k|=\|\boldsymbol{x}\|_\infty$，之后构造

$$\boldsymbol{y}=(0,\cdots,0,\underbrace{\operatorname{sgn}(x_k)}_{y_k},0,\cdots,0),$$

则

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle=x_k\operatorname{sgn}(x_k)=|x_k|=\|\boldsymbol{x}\|_\infty,$$
$$\|\boldsymbol{y}\|_1=|\operatorname{sgn}(x_k)|=1,$$

因此

$$\|\boldsymbol{x}\|_\infty\|\boldsymbol{y}\|_1=\|\boldsymbol{x}\|_\infty\cdot 1=\langle\boldsymbol{x},\boldsymbol{y}\rangle。$$

(2) 要证明 $\|\boldsymbol{x}\|_p=\max\{\langle\boldsymbol{x},\boldsymbol{y}\rangle:\boldsymbol{y}\in\mathbb{B}_{p'}^n\}$，只需证明

$$\|\boldsymbol{x}\|_p=\sup\{\langle\boldsymbol{x},\boldsymbol{y}\rangle:\|\boldsymbol{y}\|_{p'}\leqslant 1\}。$$

(首先证明 $\|\boldsymbol{x}\|_p\leqslant\max\{\langle\boldsymbol{x},\boldsymbol{y}\rangle:\|\boldsymbol{y}\|_{p'}\leqslant 1\}$。)

对于任意的 $\boldsymbol{y}\in\mathbb{B}_{p'}^n$，利用 Hölder 不等式，可得

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle\leqslant|\langle\boldsymbol{x},\boldsymbol{y}\rangle|\leqslant\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_{p'}\leqslant\|\boldsymbol{x}\|_p\cdot 1=\|\boldsymbol{x}\|_p。$$

(之后证明 $\|\boldsymbol{x}\|_p\geqslant\max\{\langle\boldsymbol{x},\boldsymbol{y}\rangle:\|\boldsymbol{y}\|_{p'}\leqslant 1\}$ (可达性)。)

考虑于 (1) 构造的 $\boldsymbol{y}$，其满足 $\langle\boldsymbol{x},\boldsymbol{y}\rangle=\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_{p'}$，设 $\bar{\boldsymbol{y}}\in\mathbb{B}_{p'}^n$，则

$$\langle\boldsymbol{x},\bar{\boldsymbol{y}}\rangle=\left\langle\boldsymbol{x},\frac{\boldsymbol{y}}{\|\boldsymbol{y}\|_{p'}}\right\rangle=\frac{1}{\|\boldsymbol{y}\|_{p'}}\langle\boldsymbol{x},\boldsymbol{y}\rangle=\frac{1}{\|\boldsymbol{y}\|_{p'}}(\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_{p'})=\|\boldsymbol{x}\|_p,$$

独立随机变量之和的集中性分析

2

要点梳理

Section 2.1 为什么研究集中不等式？ Q2.1 ∼ Q2.4

命题 2.1.2 (Gaussian 尾部)

设 $g \sim N(0,1)$，则对于任意的 $t>0$，

$$\frac{t}{t^2+1}\cdot\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-t^2/2} \leqslant \mathrm{P}\{g \geqslant t\} \leqslant \frac{1}{t}\cdot\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-t^2/2}。$$

特别地，当 $t \geqslant 1$ 时，尾部被密度控制，

$$\mathrm{P}\{g \geqslant t\} \leqslant \frac{1}{\sqrt{2\pi}}\mathrm{e}^{-t^2/2}。$$

定理 2.1.4 (Berry–Esseen 中心极限定理)

关于定理 T1.7.3 (Lindeberg–Levy 中心极限定理) 的设定，

$$|\mathrm{P}\{Z_N \geqslant t\} - \mathrm{P}\{g \geqslant t\}| \leqslant \frac{\rho}{\sqrt{N}},$$

其中 $g \sim N(0,1)$，$\rho = \mathrm{E}[|X_1-\mu|^3]/\sigma^3$。

Section 2.2 Hoeffding 不等式 Q2.5 ∼ Q2.10

定理 2.2.1 (Hoeffding 不等式)

设 $X_1,\cdots,X_N$ i.i.d. $\sim$ Rademacher，$\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\left\{\sum_{i=1}^N a_iX_i \geqslant t\right\} \leqslant \exp\left(-\frac{t^2}{2\|\boldsymbol{a}\|_2^2}\right)。$$

定理 2.2.5 (Hoeffding 不等式，双侧)

设 $X_1,\cdots,X_N$ i.i.d. $\sim$ Rademacher，$\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$，则对于任意的 $t>0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N a_iX_i\right|\geqslant t\right\}\leqslant 2\exp\left(-\frac{t^2}{2\|\boldsymbol{a}\|_2^2}\right)。$$

定理 2.2.6 (有界随机变量的 Hoeffding 不等式)

设 $X_1,\cdots,X_N$ 为相互独立的随机变量，满足 $\mathrm{supp}(X_i)\subset[m_i,M_i]$，则对于任意的 $t>0$，

$$\mathrm{P}\left\{\sum_{i=1}^N(X_i-\mathrm{E}[X_i])\geqslant t\right\}\leqslant\exp\left(-\frac{2t^2}{\sum_{i=1}^N(M_i-m_i)^2}\right)。$$

Section 2.3 Chernoff 不等式 Q2.11 ∼ Q2.15

定理 2.3.1 (Chernoff 不等式)

设 $X_1,\cdots,X_N\sim\mathrm{Bernoulli}(p)$，$S_N=\sum_{i=1}^N X_i$，$\mu=\mathrm{E}[S_N]$，则对于任意的 $t>\mu$，

$$\mathrm{P}\{S_N\geqslant t\}\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

注记 2.3.2 (Chernoff 不等式：左尾)

对 Chernoff 不等式的证明略作修改，可得左尾界：关于定理 T2.3.1 (Chernoff 不等式) 的设定，对于任意的 $0<t\leqslant\mu$，

$$\mathrm{P}\{S_N\leqslant t\}\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

推论 2.3.4 (Chernoff 不等式：小偏离)

关于定理 T2.3.1 (Chernoff 不等式) 的设定，对于任意的 $\delta\in(0,1]$，

$$\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}\leqslant 2\exp(-c\mu\delta^2)。$$

Section 2.4 中位数均值估计量 Q2.16 ∼ Q2.17

定理 2.4.1 (中位数均值估计量)

设 X 为随机变量，其均值为 μ, 方差为 σ^2。将数据划分为 k 个等大小的块。令 $\hat{\mu}_{MOM}$ 为 k 个块均值的中位数，则对于任意的 $\varepsilon\in(0,1)$，

$$\mathrm{P}\{|\hat{\mu}_{MOM}-\mu|\geqslant\varepsilon\sigma\}\leqslant\mathrm{e}^{-ck\varepsilon^2}。\qquad(c>0)$$

Section 2.5 随机图的度 Q2.18 ∼ Q2.21

命题 2.5.1 (稠密图几乎正则)

设 $G\sim G(n,p)$ 为 Erdos–Renyi 随机图，其中 $p\geqslant\ln n/n$，则 G 的所有顶点的度以高概率下均为 $(1\pm o(1))np$。

Section 2.6 sub-Gaussian 分布 Q2.22 ∼ Q2.28

命题 2.6.1 (sub-Gaussian 性质)

设 X 为随机变量。以下性质在绝对常数倍的意义下等价：

(1) 对于任意的 $t\geqslant 0$，均满足 $\mathrm{P}\{|X|\geqslant t\}\leqslant 2\exp(-t^2/K_1^2)$。

(2) 对于任意的 $p\geqslant 1$，均满足 $(\mathrm{E}|X|^p)^{1/p}\leqslant K_2\sqrt{p}$。

(3) 对于任意的 $|\lambda| \leqslant 1/K_3$，$\mathrm{E}[\exp(\lambda^2 X^2)] \leqslant \exp(K_3^2\lambda^2)$。
(4) 若 $\mathrm{E}[X]=0$，则 $\mathrm{E}[\exp(\lambda X)] \leqslant \exp(K_4^2\lambda^2)$。

定义 2.6.4 (sub-Gaussian 分布)
随机变量 X 的 sub-Gaussian 范数定义为

$$\|X\|_{\psi_2} = \inf\{t>0 : \mathrm{E}[\exp(X^2/t^2)] \leqslant 2\}。$$

若 $\|X\|_{\psi_2} < \infty$，则称 X 为 sub-Gaussian 随机变量。

命题 2.6.6 (sub-Gaussian 界)
若 X 为 sub-Gaussian 随机变量，则：
(1) 对于任意的 $t \geqslant 0$，$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\exp(-ct^2/\|X\|_{\psi_2}^2)$。
(2) 对于任意的 $p \geqslant 1$，$\|X\|_{L_p} \leqslant C\|X\|_{\psi_2}\sqrt{p}$。
(3) 若 $\mathrm{E}[X]=0$，则 $\mathrm{E}[\exp(\lambda X)] \leqslant \exp(C\lambda^2\|X\|_{\psi_2}^2)$。

Section 2.7 sub-Gaussian Hoeffding 和 Khintchine 不等式 Q2.29 ~ Q2.40

命题 2.7.1 (和式的 sub-Gaussian 范数)
设 $X_1,\cdots,X_N$ 为相互独立, 零均值的 sub-Gaussian 随机变量，则

$$\left\|\sum_{i=1}^N X_i\right\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|X_i\|_{\psi_2}^2。$$

定理 2.7.3 (sub-Gaussian Hoeffding 不等式)
设 $X_1,\cdots,X_N$ 为相互独立, 零均值的 sub-Gaussian 随机变量，记 $K=\max_i \|X_i\|_{\psi_2}$ (之后将简写为 K-sub-Gaussian 随机变量)，$\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$，则对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\sum_{i=1}^N a_i X_i \geqslant t\right\} \leqslant \exp\left(-\frac{ct^2}{K^2\|\boldsymbol{a}\|_2^2}\right)。$$

定理 2.7.5 (Khintchine 不等式)
设 $\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$，$\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，则对于任意的 $p \geqslant 1$，

$$\left(\mathrm{E}\left|\sum_{i=1}^N a_i\varepsilon_i\right|^p\right)^{1/p} \leqslant C\sqrt{p}\|\boldsymbol{a}\|_2。$$

若将 ε_i i.i.d. $\sim$ Rademacher 替换为 g_i i.i.d. $\sim N(0,1)$，上述结论依旧成立。

命题 2.7.6 (sub-Gaussian 随机变量的最大值)
设 $X_1,\cdots,X_N$ 为 K-sub-Gaussian 随机变量 (不必独立)，则

$$\mathrm{E}\left[\max_{i\leqslant N}|X_i|\right] \leqslant CK\sqrt{\ln N}。$$

引理 2.7.8 (中心化)
对于任意的随机变量 X，

$$\|X-\mathrm{E}[X]\|_{\psi_2} \leqslant C\|X\|_{\psi_2}。$$

Section 2.8 sub-Exponential 分布 Q2.41 ~ Q2.44

命题 2.8.1 (sub-Exponential 性质)
设 X 为随机变量，则以下性质在绝对常数倍的意义下等价：
(1) 对于任意的 $t \geqslant 0$，$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\exp(-t/K_1)$。
(2) 对于任意的 $p \geqslant 1$，$(\mathrm{E}|X|^p)^{1/p} \leqslant K_2 p$。
(3) 对于任意的 $|\lambda| \leqslant 1/K_3$，$\mathrm{E}[\exp(\lambda X)] \leqslant \exp(K_3^2\lambda^2)$。

定义 2.8.4 (sub-Exponential 分布)
随机变量 X 的 sub-Exponential 范数定义为

$$\|X\|_{\psi_1} = \inf\{t > 0 : \mathrm{E}[\exp(|X|/t)] \leqslant 2\}。$$

若 $\|X\|_{\psi_1} < \infty$，则称 X 为 sub-Exponential 随机变量。

引理 2.8.5 (sub-Exponential 即 sub-Gaussian 的平方)
X 为 sub-Gaussian 随机变量，当且仅当 X^2 为 sub-Exponential 随机变量，此时

$$\|X^2\|_{\psi_1} \asymp \|X\|_{\psi_2}^2。$$

引理 2.8.6 (sub-Gaussian × sub-Gaussian = sub-Exponential)
设 X, Y 为 sub-Gaussian 随机变量，则 XY 为 sub-Exponential 随机变量，满足

$$\|XY\|_{\psi_1} \leqslant \|X\|_{\psi_2}\|Y\|_{\psi_2}。$$

Section 2.9 Bernstein 不等式 Q2.45 ∼ Q2.48

定理 2.9.1 (sub-Exponential Bernstein 不等式)
设 $X_1, \cdots, X_N$ 为相互独立, 零均值的 K-sub-Exponential 随机变量，$\boldsymbol{a} = (a_1, \cdots, a_N) \in \mathbb{R}^N$，则对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\sum_{i=1}^N a_i X_i \geqslant t\right\} \leqslant 2\exp\left[-c\min\left(\frac{t^2}{K^2\|\boldsymbol{a}\|_2^2}, \frac{t}{K\|\boldsymbol{a}\|_\infty}\right)\right],$$

其中 $K = \max_i \|X_i\|_{\psi_1}$。

推论 2.9.2 (sub-Exponential Bernstein 不等式，简化形式)
关于定理 T2.9.1 (sub-Exponential Bernstein 不等式) 的设定，对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N a_i X_i\right| \geqslant t\right\} \leqslant 2\exp\left[-c\min\left(\frac{t^2}{K^2\|\boldsymbol{a}\|_2^2}, \frac{t}{K\|\boldsymbol{a}\|_\infty}\right)\right]。$$

定理 2.9.5 (有界分布的 Bernstein 不等式)
设 $X_1, \cdots, X_N$ 为相互独立, 零均值的随机变量，满足 $|X_i| \leqslant M$ (a.s.)，则对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\sum_{i=1}^N X_i \geqslant t\right\} \leqslant \exp\left(-\frac{t^2/2}{\sum_{i=1}^N \mathrm{E}[X_i^2] + Mt/3}\right)。$$

习题解答

1 [独立同分布的随机变量乘积的非集中性] 通常而言，大量独立随机变量的平均值会集中于其期望附近。然而，对于乘积而言，情况可能大不相同。这里有一个“非集中性”的例子，即变量乘积超过其期望的概率是指数级小的。

设 $X_1,\cdots,X_n$ i.i.d. $\sim U(0,1)$，$Y_n=\prod_{i=1}^n X_i$。证明：

$$(0.5)^n\leqslant \mathrm{P}\{Y_n\geqslant \mathrm{E}[Y_n]\}\leqslant (0.95)^n。$$

证明 对于下界，由于

$$\mathrm{E}[Y_n]=\mathrm{E}\left[\prod_{i=1}^n X_i\right]=\prod_{i=1}^n \mathrm{E}[X_i]=\left(\frac{1}{2}\right)^n=2^{-n},$$

因此

$$\mathrm{P}\{Y_n\geqslant 2^{-n}\}\geqslant \prod_{i=1}^n \mathrm{P}\{X_i\geqslant 1/2\}=\prod_{i=1}^n\left(1-\frac{1}{2}\right)=(0.5)^n。$$

对于上界，考虑 Chernoff 界，令 $Z_n=-\ln X_n$ i.i.d. $\sim E(1)$，记 $S_n=\sum_{i=1}^n Z_i$，则

$$\begin{aligned}\{Y_n\geqslant 2^{-n}\}&=\{\ln Y_n\geqslant -n\ln 2\}\\&=\left\{\sum_{i=1}^n \ln X_i\geqslant -n\ln 2\right\}\\&=\left\{\sum_{i=1}^n Z_i\leqslant n\ln 2\right\}\\&=\{S_n\leqslant \lambda n\}。\end{aligned}\qquad(\lambda=\ln 2)$$

（注意到 $\lambda<1$，因此上述问题是小偏差的（偏差于均值左侧）。）

利用 Chernoff 界，可得对于任意的 $t<0$，

$$\mathrm{P}\{S_n\leqslant n\lambda\}=\mathrm{P}\{\mathrm{e}^{tS_n}\leqslant \mathrm{e}^{tn\lambda}\}\leqslant \mathrm{e}^{-tn\lambda}\mathrm{E}[\mathrm{e}^{tS_n}]=\mathrm{e}^{-tn\lambda}(\mathrm{E}[\mathrm{e}^{tZ_1}])^n=(\mathrm{e}^{-t\lambda}\mathrm{E}[\mathrm{e}^{tZ_1}])^n,$$

其中 $\mathrm{E}[\mathrm{e}^{tZ_1}]=1/(1-t)$，将其代入，可得

$$\mathrm{P}\{S_n\leqslant n\lambda\}\leqslant\left(\frac{\mathrm{e}^{-t\lambda}}{1-t}\right)^n。$$

（令右侧上界为 $g(t)$，对 $\ln g(t)=-t\lambda-\ln(1-t)$ 求导，之后令其为 0，解得

$$t_0=1-\frac{1}{\lambda}<0,$$

之后的行文过程将省略求导过程，直接给出参数的取值。）

右侧的最优参数为 $t_0=1-1/\lambda$，将其代入，可得

$$\min_{t<0} g(t)=g(t_0)=\frac{\mathrm{e}^{-(1-1/\lambda)\lambda}}{1/\lambda}=\lambda\mathrm{e}^{1-\lambda}=\frac{\mathrm{e}\ln 2}{2},$$

从而

$$\mathrm{P}\{Y_n\geqslant \mathrm{E}[Y_n]\}\leqslant\left(\frac{\mathrm{e}\ln 2}{2}\right)^n\leqslant(0.95)^n。$$

2 [**Gaussian 尾部的下界**] 命题 P2.1.2 (Gaussian 尾部) 的下界部分尚未证明，现在进行证明。

设 $g\sim N(0,1)$。证明：对于任意的 $t>0$，

$$\mathrm{P}\{g\geqslant t\}\geqslant\frac{t}{t^2+1}\cdot\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-t^2/2}。$$

证明 构造辅助函数

$$f(t)=\mathrm{P}\{g\geqslant t\}-\frac{t}{t^2+1}\phi(t)=\int_t^{\infty}\phi(x)\mathrm{d}x-\frac{t}{t^2+1}\phi(t),$$

则

$$f'(t)=\frac{\mathrm{d}}{\mathrm{d}t}\left(\int_t^{\infty}\phi(x)\mathrm{d}x\right)-\frac{\mathrm{d}}{\mathrm{d}t}\left(\frac{t}{t^2+1}\phi(t)\right),$$

其中

$$\begin{aligned}\frac{\mathrm{d}}{\mathrm{d}t}\left(\int_t^{\infty}\phi(x)\mathrm{d}x\right)&=-\phi(t),\\ \frac{\mathrm{d}}{\mathrm{d}t}\left(\frac{t}{t^2+1}\phi(t)\right)&=\left(\frac{t}{t^2+1}\right)'\phi(t)+\frac{t}{t^2+1}\phi'(t)\\ &=\frac{1\cdot(t^2+1)-t\cdot(2t)}{(t^2+1)^2}\phi(t)+\frac{t}{t^2+1}(-t)\phi(t) && (\phi'(t)=-t\phi(t))\\ &=\frac{1-2t^2-t^4}{(t^2+1)^2}\phi(t),\end{aligned}$$

将其代入，可得

$$f'(t)=-\phi(t)\frac{2}{(t^2+1)^2}<0,$$

因此 $f(t)$ 于 $\mathbb{R}^+$ 是递减的，注意到 $\lim_{t\to\infty}f(t)=0$，从而 $f(t)>0$，即

$$\mathrm{P}\{g\geqslant t\}\geqslant\frac{t}{t^2+1}\cdot\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-t^2/2}。$$

3 [**Mills 比率的渐近界**] 设 $g\sim N(0,1)$。证明：对于任意的 $t>0$，其尾部概率, 密度的比率 (Mills Ratio) 满足

$$\frac{1}{t}-\frac{1}{t^3}<\frac{\mathrm{P}\{g>t\}}{\phi(t)}<\frac{1}{t}-\frac{1}{t^3}+\frac{3}{t^5}。$$

按照以下步骤证明：

(1) 证明：

$$\phi'(x)+x\phi(x)=0。$$

(2) 利用 (1) 的结论，对

$$\mathrm{P}\{g>t\}=\int_t^{\infty}\phi(x)\mathrm{d}x$$

反复进行分部积分，完成证明。

证明 (1) 证略。

(2) 令 $I(t)=\mathrm{P}\{g>t\}$，第一次分部积分，

$$\begin{aligned}I(t)&=\int_t^{\infty}\phi(x)\mathrm{d}x\\ &=\int_t^{\infty}-\frac{1}{x}\phi'(x)\mathrm{d}x && (\phi'(x)=-x\phi(x))\\ &=\left[-\frac{1}{x}\phi(x)\right]_t^{\infty}-\int_t^{\infty}(-\phi(x))\left(-\frac{1}{x^2}\right)\mathrm{d}x && \left(u=\frac{1}{x},\mathrm{d}v=-\phi'(x)\mathrm{d}x\right)\\ &=\frac{\phi(t)}{t}-\int_t^{\infty}\frac{1}{x^2}\phi(x)\mathrm{d}x,\end{aligned}$$

因此

$$\mathrm{P}\{g>t\}<\frac{\phi(t)}{t}\implies\frac{\mathrm{P}\{g>t\}}{\phi(t)}<\frac{1}{t}。$$

对于余项，第二次分部积分，

$$\begin{aligned}\int_t^\infty\frac{1}{x^2}\phi(x)\mathrm{d}x&=\int_t^\infty\frac{1}{x^3}(-\phi'(x))\mathrm{d}x&&(\phi'(x)=-x\phi(x))\\&=\left[-\frac{\phi(x)}{x^3}\right]_t^\infty-\int_t^\infty(-\phi(x))\left(-\frac{3}{x^4}\right)\mathrm{d}x&&\left(u=\frac{1}{x^3},\mathrm{d}v=-\phi'(x)\mathrm{d}x\right)\\&=\frac{\phi(t)}{t^3}-\int_t^\infty\frac{3}{x^4}\phi(x)\mathrm{d}x,\end{aligned}$$

将其代入，可得

$$\begin{aligned}I(t)&=\frac{\phi(t)}{t}-\left(\frac{\phi(t)}{t^3}-\int_t^\infty\frac{3}{x^4}\phi(x)\mathrm{d}x\right)\\&=\phi(t)\left(\frac{1}{t}-\frac{1}{t^3}\right)+\int_t^\infty\frac{3}{x^4}\phi(x)\mathrm{d}x,\end{aligned}$$

因此

$$\mathrm{P}\{g>t\}>\phi(t)\left(\frac{1}{t}-\frac{1}{t^3}\right)\implies\frac{\mathrm{P}\{g>t\}}{\phi(t)}>\frac{1}{t}-\frac{1}{t^3}。$$

对于余项，第三次分部积分，

$$\begin{aligned}\int_t^\infty\frac{3}{x^4}\phi(x)\mathrm{d}x&=\int_t^\infty\frac{3}{x^5}(-\phi'(x))\mathrm{d}x&&(\phi'(x)=-x\phi(x))\\&=\left[-\frac{3\phi(x)}{x^5}\right]_t^\infty-\int_t^\infty(-\phi(x))\left(-\frac{15}{x^6}\right)\mathrm{d}x&&\left(u=\frac{3}{x^5},\mathrm{d}v=-\phi'(x)\mathrm{d}x\right)\\&=\frac{3\phi(t)}{t^5}-\int_t^\infty\frac{15}{x^6}\phi(x)\mathrm{d}x,\end{aligned}$$

将其代入，可得

$$\begin{aligned}I(t)&=\phi(t)\left(\frac{1}{t}-\frac{1}{t^3}\right)+\left(\frac{3\phi(t)}{t^5}-\int_t^\infty\frac{15}{x^6}\phi(x)\mathrm{d}x\right)\\&=\phi(t)\left(\frac{1}{t}-\frac{1}{t^3}+\frac{3}{t^5}\right)-\int_t^\infty\frac{15}{x^6}\phi(x)\mathrm{d}x,\end{aligned}$$

因此

$$\mathrm{P}\{g>t\}<\phi(t)\left(\frac{1}{t}-\frac{1}{t^3}+\frac{3}{t^5}\right)\implies\frac{\mathrm{P}\{g>t\}}{\phi(t)}<\frac{1}{t}-\frac{1}{t^3}+\frac{3}{t^5}。$$

如此，

$$\frac{1}{t}-\frac{1}{t^3}<\frac{\mathrm{P}\{g>t\}}{\phi(t)}<\frac{1}{t}-\frac{1}{t^3}+\frac{3}{t^5}。$$

4 [**截断 Gaussian 分布的矩**] 设 $g\sim N(0,1)$。证明：

(1) (一阶截断矩) 对于任意的 $t>0$，

$$\mathrm{E}[g\mathbf{1}_{\{g>t\}}]=\phi(t)。$$

(2) (二阶截断矩) 对于任意的 $t>0$，

$$\mathrm{E}[g^2\mathbf{1}_{\{g>t\}}]\leqslant\left(t+\frac{1}{t}\right)\phi(t)。$$

证明 (1) 将期望表示为积分的形式，之后分部积分，可得

$$\begin{aligned}
\mathrm{E}[g\mathbf{1}_{\{g>t\}}] &= \int_{-\infty}^{\infty} x\mathbf{1}_{\{x>t\}}\phi(x)\mathrm{d}x \\
&= \int_{t}^{\infty} x\phi(x)\mathrm{d}x \\
&= \int_{t}^{\infty} -\phi'(x)\mathrm{d}x && (\phi'(x) = -x\phi(x)) \\
&= [-\phi(x)]_t^{\infty} = \phi(t)。
\end{aligned}$$

(2) 同理于 (1) 的结论，将期望表示为积分的形式，之后分部积分，可得

$$\begin{aligned}
\mathrm{E}[g^2\mathbf{1}_{\{g>t\}}] &= \int_{-\infty}^{\infty} x^2\mathbf{1}_{\{x>t\}}\phi(x)\mathrm{d}x \\
&= \int_{t}^{\infty} x^2\phi(x)\mathrm{d}x \\
&= \int_{t}^{\infty} x\cdot(-\phi'(x))\mathrm{d}x && (\phi'(x) = -x\phi(x)) \\
&= [-x\phi(x)]_t^{\infty} - \int_{t}^{\infty}(-\phi(x))\mathrm{d}x && (u = x, \mathrm{d}v = x\phi(x)\mathrm{d}x) \\
&= t\phi(t) + \mathrm{P}\{g > t\}。
\end{aligned}$$

根据 Mills 比率 (Q2.3 (Mills 比率的渐近界))，可得

$$\mathrm{P}\{g > t\} < \frac{\phi(t)}{t},$$

(或者利用简单的放缩，

$$\int_t^{\infty}\phi(x)\mathrm{d}x = \int_t^{\infty}\frac{x}{x}\phi(x)\mathrm{d}x < \frac{1}{t}\int_t^{\infty}x\phi(x)\mathrm{d}x = \frac{\phi(t)}{t}。)$$

将其代入，可得

$$\mathrm{E}[g^2\mathbf{1}_{\{g>t\}}] \leqslant t\phi(t) + \frac{1}{t}\phi(t) = \left(t + \frac{1}{t}\right)\phi(t)。$$

5 [**Hoeffding 不等式证明的补全**] 于 Hoeffding 不等式的证明过程，需要利用一个关键的数值界。
证明：

$$\cosh(x) \leqslant \mathrm{e}^{x^2/2}。$$

证明 **解法一 Taylor 级数展开**

容易知道，

$$\begin{aligned}
\cosh(x) &= \sum_{n=0}^{\infty}\frac{x^{2n}}{(2n)!} = 1 + \frac{x^2}{2!} + \frac{x^4}{4!} + \cdots, \\
\mathrm{e}^{x^2/2} &= \sum_{n=0}^{\infty}\frac{(x^2/2)^n}{n!} = \sum_{n=0}^{\infty}\frac{x^{2n}}{2^n n!} = 1 + \frac{x^2}{2} + \frac{x^4}{8} + \cdots,
\end{aligned}$$

因此要证明 $\cosh(x) \leqslant \mathrm{e}^{x^2/2}$，只需证明

$$\frac{1}{(2n)!} \leqslant \frac{1}{2^n n!},$$

即 $(2n)! \geqslant 2^n n!$。
容易知道，

$$(2n)! = (2n)!!\cdot(2n-1)!! = (2^n n!)\cdot(2n-1)!! \geqslant 2^n n!。$$

解法二　导数的性质

构造辅助函数 $f(x)=x^2/2-\ln(\cosh(x))$，满足 $f(x)$ 为偶函数，$f(0)=0$。

求导，当 $x>0$ 时，$f'(x)=x-\tanh(x)>0$，因此 $f(x)\geqslant 0$，即

$$\frac{x^2}{2}\geqslant \ln(\cosh(x)) \implies \mathrm{e}^{x^2/2}\geqslant \cosh(x)。$$

6 [**利用指数矩法估计 Gaussian 尾部**] 设 $g\sim N(0,1)$。利用 Chernoff 界，证明：对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{g\geqslant t\}\leqslant \mathrm{e}^{-t^2/2}。$$

(注：尽管这个上界比精确的 Mills 比率略松，但在一些根据中，这已经足够有效。)

证明　利用 Chernoff 界，可得

$$\mathrm{P}\{g\geqslant t\}=\mathrm{P}\{\mathrm{e}^{\lambda g}\geqslant \mathrm{e}^{\lambda t}\}\leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda g}],$$

其中

$$\begin{aligned}\mathrm{E}[\mathrm{e}^{\lambda g}]&=\int_{-\infty}^{\infty}\mathrm{e}^{\lambda x}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2}\mathrm{d}x\\&=\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-(x^2-2\lambda x)/2}\mathrm{d}x\\&=\mathrm{e}^{\lambda^2/2}\underbrace{\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{(x-\lambda)^2}{2}}\mathrm{d}x}_{1}\\&=\mathrm{e}^{\lambda^2/2},\end{aligned}$$

将其代入，可得

$$\mathrm{P}\{g\geqslant t\}\leqslant \mathrm{e}^{-\lambda t}\cdot\mathrm{e}^{\lambda^2/2}。$$

右侧的最优参数为 $\lambda_0=t$，将其代入，可得

$$\mathrm{P}\{g\geqslant t\}\leqslant \mathrm{e}^{-t^2/2}。$$

7 [**小球概率**] 设 $X_1,\cdots,X_N$ 为相互独立的非负随机变量，满足 $X_i\sim f_{X_i}$，记 $S_N=\sum_{i=1}^N X_i$。证明：若密度函数是一致有界的，即

$$\|f_{X_i}\|_\infty=\operatorname*{ess\,sup}_{x\in\mathbb{R}} f_{X_i}(x)\leqslant K,$$

则对于任意的 $\varepsilon>0$，

$$\mathrm{P}\{S_N\leqslant \varepsilon N\}\leqslant (\mathrm{e}K\varepsilon)^N。$$

注释　事件 $\{S_N\leqslant \varepsilon N\}$ 等价于经验平均值落于原点附近的小球以内 $\{\frac{1}{N}\sum_{i=1}^N X_i\leqslant \varepsilon\}$，因此称为小球概率。

证明　利用 Chernoff 界，可得

$$\begin{aligned}\mathrm{P}\{S_N\leqslant \varepsilon N\}&=\mathrm{P}\{\mathrm{e}^{-tS_N}\geqslant \mathrm{e}^{-t\varepsilon N}\}\\&\leqslant \mathrm{e}^{t\varepsilon N}\mathrm{E}[\mathrm{e}^{-tS_N}]\\&=\mathrm{e}^{t\varepsilon N}\prod_{i=1}^N\mathrm{E}[\mathrm{e}^{-tX_i}],\end{aligned}$$

其中

$$\mathrm{E}[\mathrm{e}^{-tX_i}]=\int_0^\infty \mathrm{e}^{-tx}f_i(x)\mathrm{d}x\leqslant\int_0^\infty \mathrm{e}^{-tx}K\mathrm{d}x=K\left[-\frac{1}{t}\mathrm{e}^{-tx}\right]_0^\infty=\frac{K}{t},$$

将其代入，可得

$$\mathrm{P}\{S_N\leqslant \varepsilon N\}\leqslant \mathrm{e}^{t\varepsilon N}\left(\frac{K}{t}\right)^N。$$

右侧的最优参数为 $t_0 = 1/\varepsilon$，将其代入，可得

$$\mathrm{P}\{S_N \leqslant \varepsilon N\} \leqslant (\mathrm{e}K\varepsilon)^N。$$

8 [**矩母函数比较不等式**] 设 X, Y 满足 $\mathrm{E}[X] = \mathrm{E}[Y] = \mu$，$\mathrm{supp}(X) = [a, b]$，$\mathrm{supp}(Y) = \{a, b\}$。证明：对于任意的 $\lambda \in \mathbb{R}$，

$$\mathrm{E}[\mathrm{e}^{\lambda X}] \leqslant \mathrm{E}[\mathrm{e}^{\lambda Y}]。$$

证明 对于 Y，其为两点分布，设 $p = \mathrm{P}\{Y = b\}$，则

$$\mathrm{E}[Y] = \mu = a(1-p) + bp \implies p = \frac{\mu - a}{b - a},$$

因此

$$\mathrm{E}[\mathrm{e}^{\lambda Y}] = (1-p)\mathrm{e}^{\lambda a} + p\mathrm{e}^{\lambda b} = \frac{b-\mu}{b-a}\mathrm{e}^{\lambda a} + \frac{\mu - a}{b-a}\mathrm{e}^{\lambda b}。$$

对于 X，考虑 $X = x \in [a, b]$ 将表示为凸组合的形式，

$$x = (1-\alpha)a + \alpha b,$$

由于 $f(x) = \mathrm{e}^{\lambda x}$ 为凸函数，因此

$$f(x) \leqslant (1-\alpha)f(a) + \alpha f(b),$$

即

$$\mathrm{e}^{\lambda x} \leqslant \frac{b-x}{b-a}\mathrm{e}^{\lambda a} + \frac{x-a}{b-a}\mathrm{e}^{\lambda b},$$

即

$$\mathrm{e}^{\lambda X} \leqslant \frac{b-X}{b-a}\mathrm{e}^{\lambda a} + \frac{X-a}{b-a}\mathrm{e}^{\lambda b},$$

两侧取期望，

$$\begin{aligned}\mathrm{E}[\mathrm{e}^{\lambda X}] &\leqslant \mathrm{E}\left[\frac{b-X}{b-a}\mathrm{e}^{\lambda a} + \frac{X-a}{b-a}\mathrm{e}^{\lambda b}\right] \\ &= \frac{b-\mathrm{E}[X]}{b-a}\mathrm{e}^{\lambda a} + \frac{\mathrm{E}[X]-a}{b-a}\mathrm{e}^{\lambda b} \\ &= \frac{b-\mu}{b-a}\mathrm{e}^{\lambda a} + \frac{\mu-a}{b-a}\mathrm{e}^{\lambda b} = \mathrm{E}[\mathrm{e}^{\lambda Y}]。\end{aligned}$$

9 [**Hoeffding 引理**] 设 $\mathrm{supp}(X) = [a, b]$。证明：对于任意的 $\lambda \in \mathbb{R}$，

$$\mathrm{E}[\mathrm{e}^{\lambda(X - \mathrm{E}[X])}] \leqslant \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)。$$

按照以下步骤证明：

(1) 说明可以简化假设：不妨设 X 为零均值随机变量，$b - a = 1$，此时 X 取值于 $\{a, b\}$。

(2) 计算 $K(\lambda) = \ln \mathrm{E}[\mathrm{e}^{\lambda X}]$，满足 $K(0) = K'(0) = 0$，$K''(\lambda) \leqslant 1/4$。之后推导 $K(\lambda) \leqslant \lambda^2/8$。

证明 (1) 令 $Y = X - \mathrm{E}[X]$，则 $\mathrm{E}[Y] = 0$，$\mathrm{supp}(Y) = [a - \mathrm{E}[X], b - \mathrm{E}[X]]$，此时证明目标转化为

$$\mathrm{E}[\mathrm{e}^{\lambda Y}] \leqslant \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)。$$

因此只需考虑 $\mu = 0$ 的情况。

根据习题 Q2.8 (*矩母函数比较不等式*)，可得只需考虑 $\mathrm{supp}(X) = \{a, b\}$ 的情况。

令 $W = X/(b-a)$，则 $\mathrm{supp}(W) = [a/(b-a), b/(b-a)]$，区间长度为 1，此时证明目标转化为

$$\mathrm{E}[\mathrm{e}^{\mu W}] \leqslant \exp\left(\frac{\mu^2}{8}\right)。$$

如此，上述问题简化为：设 X 满足 $\mathrm{supp}(X) = \{a, b\}$ $(b - a = 1)$，满足 $\mathrm{E}[X] = 0$。证明：

$$\ln \mathrm{E}[\mathrm{e}^{\lambda X}] \leqslant \frac{\lambda^2}{8}。$$

(2) 设 $\mathrm{P}\{X=b\}=p$，则

$$\begin{cases} b-a=1, \\ \mathrm{E}[X]=bp+a(1-p)=0 \end{cases},$$

解得 $(a,b)=(-p,1-p)$。

设

$$K(\lambda)=\ln \mathrm{E}[\mathrm{e}^{\lambda X}]=\ln((1-p)\mathrm{e}^{-p\lambda}+p\mathrm{e}^{(1-p)\lambda}),$$

利用 Taylor 展开，可得

$$K(\lambda)=K(0)+\lambda K'(0)+\frac{\lambda^2}{2}K''(\xi), \qquad (\xi \text{ 介于 } 0,\lambda \text{ 之间})$$

之后只需计算 $K(0),K'(0)$, 界定 $K''(\xi)$ 即可。

求导，

$$K'(\lambda)=\frac{(1-p)(-p)\mathrm{e}^{-p\lambda}+p(1-p)\mathrm{e}^{(1-p)\lambda}}{(1-p)\mathrm{e}^{-p\lambda}+p\mathrm{e}^{(1-p)\lambda}},$$

可得 $K(0)=K'(0)=0$ (事实上，$K'(0)=\mathrm{E}[X]$)。

再次求导，

$$\begin{aligned} K''(\lambda)&=\frac{p\mathrm{e}^{\lambda}(1-p+p\mathrm{e}^{\lambda})-p\mathrm{e}^{\lambda}(p\mathrm{e}^{\lambda})}{(1-p+p\mathrm{e}^{\lambda})^2} \\ &=\frac{p\mathrm{e}^{\lambda}(1-p)}{(1-p+p\mathrm{e}^{\lambda})^2}, \end{aligned}$$

注意到

$$K''(\lambda)=\frac{p\mathrm{e}^{\lambda}}{1-p+p\mathrm{e}^{\lambda}}\cdot\frac{1-p}{1-p+p\mathrm{e}^{\lambda}}=:\theta(1-\theta), \qquad \left(\theta=\frac{p\mathrm{e}^{\lambda}}{1-p+p\mathrm{e}^{\lambda}}\in[0,1]\right)$$

因此 $K''(\lambda)\leqslant 1/4$。

如此，

$$K(\lambda)=K(0)+\lambda K'(0)+\frac{\lambda^2}{2}K''(\xi)\leqslant 0+0+\frac{\lambda^2}{2}\cdot\frac{1}{4}=\frac{\lambda^2}{8},$$

可得

$$\ln \mathrm{E}[\mathrm{e}^{\lambda X}]\leqslant\frac{\lambda^2}{8}。$$

10 [**有界随机变量的 Hoeffding 不等式**] 证明定理 T2.2.6 (有界随机变量的 Hoeffding 不等式)。

设 $X_1,\cdots,X_N$ 为相互独立的随机变量，满足 $\mathrm{supp}(X_i)=[a_i,b_i]$。利用习题 Q2.9 (Hoeffding 引理)，证明：对于任意的 $t>0$，

$$\mathrm{P}\left\{\sum_{i=1}^{N}(X_i-\mathrm{E}[X_i])\geqslant t\right\}\leqslant\exp\left(-\frac{2t^2}{\sum_{i=1}^{N}(b_i-a_i)^2}\right)。$$

证明 设 $S_N=\sum_{i=1}^{N}(X_i-\mathrm{E}[X_i])$，则

$$\begin{aligned} \mathrm{E}[\mathrm{e}^{\lambda S_N}]&=\mathrm{E}\left[\exp\left(\lambda\sum_{i=1}^{N}(X_i-\mathrm{E}[X_i])\right)\right] \\ &=\prod_{i=1}^{N}\mathrm{E}\left[\mathrm{e}^{\lambda(X_i-\mathrm{E}[X_i])}\right], \end{aligned}$$

利用 Hoeffding 引理 (Q2.9 (Hoeffding 引理))，可得

$$\mathrm{E}[\mathrm{e}^{\lambda S_N}]\leqslant\prod_{i=1}^{N}\exp\left(\frac{\lambda^2(b_i-a_i)^2}{8}\right)$$

$$= \exp\left(\sum_{i=1}^{N} \frac{\lambda^2 (b_i - a_i)^2}{8}\right)$$
$$= \exp\left(\frac{\lambda^2}{8} \sum_{i=1}^{N} (b_i - a_i)^2\right)。$$

利用 Chernoff 界，可得

$$\mathrm{P}\{S_N \geqslant t\} = \mathrm{P}\{\mathrm{e}^{\lambda S_N} \geqslant \mathrm{e}^{\lambda t}\} \leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda S_N}] \leqslant \exp\left(-\lambda t + \frac{\lambda^2}{8} \sum_{i=1}^{N} (b_i - a_i)^2\right),$$

右侧的最优参数为 $\lambda_0 = 4t / \sum_{i=1}^{N} (b_i - a_i)^2$，将其代入，可得

$$\mathrm{P}\left\{\sum_{i=1}^{N} (X_i - \mathrm{E}[X_i]) \geqslant t\right\} \leqslant \exp\left(-\frac{2t^2}{\sum_{i=1}^{N} (b_i - a_i)^2}\right)。$$

11 [**Chernoff 不等式：左尾界**] 设 $X_1, \cdots, X_N$ 为相互独立的随机变量，满足 $X_i \sim \mathrm{Bernoulli}(p_i)$，记 $\mu = \mathrm{E}[S_N] = \sum_{i=1}^{N} p_i$。根据注记 R2.3.2 (Chernoff 不等式：左尾)，已知对于任意的 $0 < t < \mu$，

$$\mathrm{P}\{S_N \leqslant t\} \leqslant \mathrm{e}^{-\mu} \left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

证明：对于任意的 $0 < \delta < 1$，以下左尾偏差不等式成立，

$$\mathrm{P}\{S_N \leqslant (1-\delta)\mu\} \leqslant \exp\left(-\frac{\mu\delta^2}{2}\right)。$$

(注：此结论比右尾偏差 $\exp(-\mu\delta^2/3)$ 的界更紧。)

证明 根据注记 R2.3.2 (Chernoff 不等式：左尾)，令 $t = (1-\delta)\mu$，可得

$$\begin{aligned}
\mathrm{P}\{S_N \leqslant (1-\delta)\mu\} &\leqslant \mathrm{e}^{-\mu} \left(\frac{\mathrm{e}\mu}{(1-\delta)\mu}\right)^{(1-\delta)\mu} \\
&= \mathrm{e}^{-\mu} \left(\frac{\mathrm{e}}{1-\delta}\right)^{(1-\delta)\mu} \\
&= \mathrm{e}^{-\delta\mu} \cdot (1-\delta)^{-(1-\delta)\mu} \\
&= \exp[-\mu(\delta + (1-\delta)\ln(1-\delta))],
\end{aligned}$$

因此只需证明

$$\delta + (1-\delta)\ln(1-\delta) \geqslant \frac{\delta^2}{2}。$$

容易知道，

$$\begin{aligned}
\delta + (1-\delta)\ln(1-\delta) &= \delta + (1-\delta)\left(-\delta - \frac{\delta^2}{2} - \frac{\delta^3}{3} - \cdots\right) \\
&= \delta - \delta - \frac{\delta^2}{2} - \frac{\delta^3}{3} - \cdots + \delta^2 + \frac{\delta^3}{2} + \frac{\delta^4}{3} + \cdots \\
&= (\delta - \delta) + \left(\delta^2 - \frac{\delta^2}{2}\right) + \left(\frac{\delta^3}{2} - \frac{\delta^3}{3}\right) + \cdots \\
&= \frac{\delta^2}{2} + \frac{\delta^3}{6} + \cdots \\
&\geqslant \frac{\delta^2}{2}。
\end{aligned}$$

12 [**逆 Chernoff 不等式**] 设 $S_N \sim B(N,\mu/N)$。证明：对于任意的满足 $\mu \leqslant t \leqslant N$ 的整数 t，

$$\mathrm{P}\{S_N = t\} \geqslant \mathrm{e}^{-\mu}\left(\frac{\mu}{t}\right)^t。$$

证明 容易知道，

$$\begin{aligned}\mathrm{P}\{S_N = t\} &= \binom{N}{t}\frac{\mu^t}{N^t}\left(1-\frac{\mu}{N}\right)^{N-t}\\ &= \left[\binom{N}{t}\frac{t^t}{N^t}\right]\left(\frac{\mu}{t}\right)^t\left(1-\frac{\mu}{N}\right)^{N-t},\end{aligned}$$

因此要证明 $\mathrm{P}\{S_N = t\} \geqslant \mathrm{e}^{-\mu}(\mu/t)^t$，只需证明

$$\left[\binom{N}{t}\left(\frac{t}{N}\right)^t\right]\cdot\left(1-\frac{\mu}{N}\right)^{N-t} \geqslant \mathrm{e}^{-\mu}。$$

作出以下引理：

引理 1 对于 $1 \leqslant t \leqslant N$，

$$\binom{N}{t}\left(\frac{t}{N}\right)^t \geqslant 1。$$

引理 2 对于 $\mu \leqslant t \leqslant N$，

$$\left(1-\frac{\mu}{N}\right)^{N-t} \geqslant \mathrm{e}^{-\mu}。$$

注释 引理 1 的证明过程：

容易知道，

$$\begin{aligned}\binom{N}{t}\left(\frac{t}{N}\right)^t &= \frac{N(N-1)\cdots(N-t+1)}{t!}\cdot\frac{t^t}{N^t}\\ &= \frac{N(N-1)\cdots(N-t+1)}{N^t}\cdot\frac{t^t}{t!}\\ &= \left(\frac{N}{N}\cdot\frac{N-1}{N}\cdots\frac{N-t+1}{N}\right)\cdot\left(\frac{t}{1}\cdot\frac{t}{2}\cdots\frac{t}{t}\right)\\ &= \prod_{k=0}^{t-1}\left(\frac{N-k}{N}\cdot\frac{t}{t-k}\right)\\ &= \prod_{k=0}^{t-1}\frac{Nt-kt}{Nt-Nk} \geqslant 1。\end{aligned}$$

根据引理 1, 2，可得

$$\begin{aligned}\mathrm{P}\{S_N = t\} &= \left[\binom{N}{t}\left(\frac{t}{N}\right)^t\right]\cdot\left(1-\frac{\mu}{N}\right)^{N-t}\cdot\left(\frac{\mu}{t}\right)^t\\ &\geqslant 1\cdot\mathrm{e}^{-\mu}\cdot\left(\frac{\mu}{t}\right)^t\\ &= \mathrm{e}^{-\mu}\left(\frac{\mu}{t}\right)^t。\end{aligned}$$

注释 引理 2 的证明过程：

容易证明，

$$\left(1-\frac{\mu}{N}\right)^{N-t} \geqslant \left(1-\frac{\mu}{N}\right)^{N-\mu},$$

令 $x=\mu/N\in(0,1)$ (若 $\mu=N$，则结论是平凡的)，则只需证明

$$(1-x)^{N(1-x)}\geqslant \mathrm{e}^{-Nx},$$

两侧开 N 次方，之后取对数，等价于证明

$$(1-x)\ln(1-x)\geqslant -x。$$

构造辅助函数 $f(x)=(1-x)\ln(1-x)+x$，满足 $f(0)=0$，则

$$f'(x)=-1\cdot\ln(1-x)+(1-x)\cdot\frac{-1}{1-x}+1=-\ln(1-x)>0,$$

因此 $f(x)>0$，即 $(1-x)\ln(1-x)>-x$。

13 [**Poisson 分布的尾部界**] 根据定理 T1.7.6 (Poisson 极限定理)，我们有理由相信，Chernoff 不等式同样适用于 Poisson 分布的随机变量。事实的确如此。

具体而言，设 $X\sim P(\mu)$。利用指数矩法，证明：

(1) 根据定理 T2.3.1 (Chernoff 不等式)，对于任意的 $t\geqslant\mu$，

$$\mathrm{P}\{X\geqslant t\}\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

(2) 根据注记 R2.3.2 (Chernoff 不等式：左尾)，对于任意的 $0<t\leqslant\mu$，

$$\mathrm{P}\{X\leqslant t\}\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

(3) 根据推论 C2.3.4 (Chernoff 不等式：小偏离)，对于任意的 $0\leqslant\delta\leqslant 1$，

$$\mathrm{P}\{|X-\mu|\geqslant\delta\mu\}\leqslant 2\exp\left(-\frac{\delta^2\mu}{3}\right)。$$

(4) (练习 Q2.12 (逆 Chernoff 不等式) 的版本) 对于任意的整数 $t>0$，

$$\mathrm{P}\{X=t\}\geqslant \mathrm{e}^{-\mu}\left(\frac{\mu}{t}\right)^t。$$

证明 (1) 利用 Chernoff 界，可得对于任意的 $\lambda>0$，

$$\mathrm{P}\{X\geqslant t\}=\mathrm{P}\{\mathrm{e}^{\lambda X}\geqslant \mathrm{e}^{\lambda t}\}\leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda X}]=\exp(-\lambda t+\mu(\mathrm{e}^{\lambda}-1)),$$

右侧的最优参数为 $\lambda_0=\ln(t/\mu)$，将其代入，可得

$$\begin{aligned}\mathrm{P}\{X\geqslant t\}&\leqslant \exp\left(\ln\left(\left(\frac{\mu}{t}\right)^t\right)+t-\mu\right)\\&=\left(\frac{\mu}{t}\right)^t\mathrm{e}^t\mathrm{e}^{-\mu}\\&=\mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。\end{aligned}$$

(2) 同理于 (1) 的结论，可得对于任意的 $\lambda<0$，

$$\mathrm{P}\{X\leqslant t\}=\mathrm{P}\{\mathrm{e}^{\lambda X}\geqslant \mathrm{e}^{\lambda t}\}\leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda X}]=\exp(-\lambda t+\mu(\mathrm{e}^{\lambda}-1)),$$

右侧的最优参数为 $\lambda_0=\ln(t/\mu)$，将其代入，可得

$$\mathrm{P}\{X\geqslant t\}=\mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

(3) 将 $\mathrm{P}\{|X-\mu|\geqslant\delta\mu\}$ 进行分解，

$$\mathrm{P}\{|X-\mu|\geqslant\delta\mu\}=\mathrm{P}\{X\geqslant(1+\delta)\mu\}+\mathrm{P}\{X\leqslant(1-\delta)\mu\}。$$

对于右尾，利用 (1) 的结论，令 $t=(1+\delta)\mu$，可得

$$\begin{aligned}\mathrm{P}\{X\geqslant(1+\delta)\mu\}&\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{(1+\delta)\mu}\right)^{(1+\delta)\mu}\\&=\mathrm{e}^{-\mu}\cdot\mathrm{e}^{(1+\delta)\mu}\cdot(1+\delta)^{-(1+\delta)\mu}\\&=\exp(-\mu+(1+\delta)\mu-(1+\delta)\mu\ln(1+\delta))\\&=\exp[-\mu((1+\delta)\ln(1+\delta)-\delta)]\\&\leqslant\exp\left(-\frac{\delta^2\mu}{3}\right),\end{aligned}$$

对于左尾，利用 (2) 的结论，令 $t=(1-\delta)\mu$，可得

$$\begin{aligned}\mathrm{P}\{X\geqslant(1-\delta)\mu\}&\leqslant \mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{(1-\delta)\mu}\right)^{(1-\delta)\mu}\\&=\mathrm{e}^{-\mu}\cdot\mathrm{e}^{(1+\delta)\mu}\cdot(1-\delta)^{-(1-\delta)\mu}\\&=\exp(-\mu+(1-\delta)\mu-(1-\delta)\mu\ln(1-\delta))\\&=\exp[-\mu((1-\delta)\ln(1-\delta)+\delta)]\\&\leqslant\exp\left(-\frac{\delta^2\mu}{2}\right),\end{aligned}$$

因此

$$\begin{aligned}\mathrm{P}\{|X-\mu|\geqslant\delta\mu\}&=\mathrm{P}\{X\geqslant(1+\delta)\mu\}+\mathrm{P}\{X\leqslant(1-\delta)\mu\}\\&\leqslant\exp\left(-\frac{\delta^2\mu}{2}\right)+\exp\left(-\frac{\delta^2\mu}{3}\right)\\&\leqslant 2\exp\left(-\frac{\delta^2\mu}{3}\right)。\end{aligned}$$

(4) 容易知道，

$$\mathrm{P}\{X=t\}=\frac{\mu^t\mathrm{e}^{-\mu}}{t!}\geqslant\frac{\mu^t\mathrm{e}^{-\mu}}{t^t}=\mathrm{e}^{-\mu}\left(\frac{\mu}{t}\right)^t。$$

14 [**Chernoff 不等式：小偏差推广**] 将推论 C2.3.4 (Chernoff 不等式：小偏离) 进行推广。
设 $X_1,\cdots,X_N$ 为相互独立的随机变量，满足 $X_i\sim\mathrm{Bernoulli}(p_i)$，记 $S_N=\sum_{i=1}^N X_i$，$\mu=\mathrm{E}[S_N]=\sum_{i=1}^N p_i$。证明：对于任意的 $\delta\geqslant 0$，以下双边偏差不等式成立，

$$\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}\leqslant 2\exp\left(-\frac{\delta^2\mu}{2+\delta}\right)。$$

证明 将 $\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}$ 进行分解，

$$\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}=\mathrm{P}\{S_N\geqslant(1+\delta)\mu\}+\mathrm{P}\{S_N\leqslant(1-\delta)\mu\}。$$

- 对于右尾，利用 Chernoff 界，可得对于任意的 $\delta>0$，

$$\mathrm{P}\{S_N\geqslant(1+\delta)\mu\}\leqslant\left(\frac{\mathrm{e}^\delta}{(1+\delta)^{1+\delta}}\right)^\mu=\exp(-\mu((1+\delta)\ln(1+\delta)-\delta)),$$

之后只需证明

$$(1+\delta)\ln(1+\delta)-\delta\geqslant\frac{\delta^2}{2+\delta}。$$

构造辅助函数 $f(\delta)=(1+\delta)\ln(1+\delta)-\delta-\delta^2/(2+\delta)$，求导，

$$f'(\delta)=\ln(1+\delta)-\frac{\delta(\delta+4)}{(\delta+2)^2},$$

可得 $f(0)=f'(0)=0$，再次求导，

$$f''(\delta)=\frac{1}{1+\delta}-\frac{8}{(\delta+2)^3}\geqslant 0,$$

可得 $f'(\delta)>0$，因此 $f(\delta)>0$。

- 对于左尾：

a. 当 $\delta>1$ 时，$(1-\delta)\mu<0$，此时 $\mathrm{P}\{S_N<0\}=0$，这是平凡的。

b. 当 $0\leqslant\delta\leqslant 1$ 时，利用 Chernoff 界，可得对于任意的 $\delta>0$，

$$\mathrm{P}\{S_N\geqslant(1+\delta)\mu\}\leqslant\left(\frac{\mathrm{e}^{-\delta}}{(1-\delta)^{1-\delta}}\right)^{\mu}=\exp(-\mu((1-\delta)\ln(1-\delta)+\delta)),$$

之后只需证明

$$(1-\delta)\ln(1-\delta)+\delta\geqslant\frac{\delta^2}{2+\delta}。$$

容易知道，

$$(1-\delta)\ln(1-\delta)+\delta\geqslant\frac{\delta^2}{2}\geqslant\frac{\delta^2}{2+\delta}。$$

如此，

$$\begin{aligned}\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}&=\mathrm{P}\{S_N\geqslant(1+\delta)\mu\}+\mathrm{P}\{S_N\leqslant(1-\delta)\mu\}\\&\leqslant\exp\left(-\frac{\delta^2\mu}{2+\delta}\right)+\exp\left(-\frac{\delta^2\mu}{2+\delta}\right)\\&=2\exp\left(-\frac{\delta^2\mu}{2+\delta}\right)。\end{aligned}$$

15 [**有界随机变量的 Chernoff 不等式推广**] 说明定理 T2.3.1 (Chernoff 不等式), 注记 R2.3.2 (Chernoff 不等式：左尾), 推论 C2.3.4 (Chernoff 不等式：小偏离) 的所有版本不仅适用于 Bernoulli 随机变量，而且对于任意的取值于 $[0,1]$ 的相互独立的随机变量 X_i 依然成立。

具体而言，设 $X_1,\cdots,X_N$ 为相互独立的随机变量，满足 $\mathrm{supp}(X_i)=[0,1]$，$\mathrm{E}[X_i]=p_i$，记 $S_N=\sum_{i=1}^N X_i$，$\mu=\mathrm{E}[S_N]=\sum_{i=1}^N p_i$。

证明：

(1) 根据定理 T2.3.1 (Chernoff 不等式)，对于任意的 $t\geqslant\mu$，

$$\mathrm{P}\{S_N\geqslant t\}\leqslant\mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

(2) 根据注记 R2.3.2 (Chernoff 不等式：左尾)，对于任意的 $0<t\leqslant\mu$，

$$\mathrm{P}\{S_N\leqslant t\}\leqslant\mathrm{e}^{-\mu}\left(\frac{\mathrm{e}\mu}{t}\right)^t。$$

(3) 根据推论 C2.3.4 (Chernoff 不等式：小偏离)，对于任意的 $0\leqslant\delta\leqslant 1$，

$$\mathrm{P}\{|S_N-\mu|\geqslant\delta\mu\}\leqslant 2\exp\left(-\frac{\delta^2\mu}{3}\right)。$$

证明 根据习题 Q2.8 (矩母函数比较不等式)，可得对于 $Y\sim\mathrm{Bernoulli}(p)$，

$$\mathrm{E}[\mathrm{e}^{\lambda X}]\leqslant\mathrm{E}[\mathrm{e}^{\lambda Y}]=1-p+p\mathrm{e}^{\lambda},$$

因此

$$\begin{aligned}\mathrm{E}[\mathrm{e}^{\lambda S_N}]=\prod_{i=1}^N\mathrm{E}[\mathrm{e}^{\lambda X_i}]&\leqslant\prod_{i=1}^N(1-p_i+p_i\mathrm{e}^{\lambda})\\&=\prod_{i=1}^N(1+p_i(\mathrm{e}^{\lambda}-1))\end{aligned}$$

$$\leqslant \prod_{i=1}^{N} \exp(p_i(\mathrm{e}^{\lambda}-1))$$
$$= \exp\left((\mathrm{e}^{\lambda}-1)\sum_{i=1}^{N} p_i\right)$$
$$= \exp(\mu(\mathrm{e}^{\lambda}-1)),$$

注意到上述不等式的右侧恰好为 $P(\mu), B(N,\mu/N)$ 的 MGF，由于 Chernoff 界的推导仅依赖于对此 MGF 上界根据 Markov 不等式，之后对参数 λ 进行极值优化，不依赖于 X_i 的具体分布，因此 (1)(2)(3) 的证明同理于习题 Q2.13 (Poisson 分布的尾部界)。

16 [**均值中位数法：修正证明**] 定理 T2.4.1 (中位数均值估计量) 的证明存在一个轻微的瑕疵：原始证明为了方便，将样本分为 $B = t^2/4$ 组，之后假设任意一组的大小 $L = N/B$ 为整数，满足 $B \mid N$。但是这通常并不成立。

修正上述证明，使其当 $B \nmid N$ 时，上述依然成立。

证明 • 定义分组参数

对 B 的取值进行讨论：

a. (小偏差情形) 当 $t < 4$ 时，令 $c = \ln 2/16$，则 $2\mathrm{e}^{-ct^2} \geqslant 1$，结论是平凡的。

b. (大偏差情形) 当 $t \geqslant 4$ 时，设组数为 $B = \lfloor t^2/8 \rfloor$，$G_1, \cdots, G_B$ 为不相交的索引集合，则其尺寸均为 $L = \lfloor N/B \rfloor$。(即只利用前 $B \cdot L$ 个样本，舍弃剩余的 $N - BL$ 个样本，最多舍弃 $B-1$ 个样本。由于 $B \leqslant N/8$，故 $N/B \geqslant 8$，从而 $L \geqslant 1$。)

• 分析单组均值的性质

对于任意的组 $b \in \{1, \cdots, B\}$，构造第 b 组的组内样本均值为

$$\mu_b = \frac{1}{L}\sum_{i \in G_b} X_i。$$

满足

$$\mathrm{E}[\mu_b] = \mu, \quad \mathrm{Var}(\mu_b) = \frac{\sigma^2}{L},$$

记 p_b 为单独估计失败的概率，则利用 Chebyshev 不等式，可得

$$p_b = \mathrm{P}\left\{|\mu_b - \mu| \geqslant \frac{t\sigma}{\sqrt{N}}\right\} \leqslant \frac{\mathrm{Var}(\mu_b)}{(t\sigma/\sqrt{N})^2} = \frac{\sigma^2/L}{t^2\sigma^2/N} = \frac{N}{Lt^2}$$
$$\leqslant \frac{N}{(N/2B)t^2} = \frac{2B}{t^2} \leqslant \frac{1}{4},$$

(当 $x \geqslant 1$ 时，$\lfloor x \rfloor \geqslant x/2$，因此这里需要保证 $N/B \geqslant 1$，从而解释了之前为什么需要讨论 $B < 1$ 的情况。)

• 利用中位数性质与 Hoeffding 不等式

定义均值中位数估计量为 B 个组均值的中位数，即

$$\hat{\mu} := \mathrm{Med}(\mu_1, \cdots, \mu_B),$$

之后定义单组失败指示变量

$$Z_b = \mathbf{1}_{\{|\mu_b - \mu| \geqslant \varepsilon\}},$$

满足 $\mathrm{E}[Z_b] = p_b \leqslant 1/4$。

若 $\hat{\mu}$ 偏离 μ 超过 ε，则必定存在至少一半的组内均值 μ_b，其偏离 μ 超过 ε，即

$$\{|\hat{\mu} - \mu| \geqslant \varepsilon\} \subset \left\{\sum_{b=1}^{B} Z_b \geqslant \frac{B}{2}\right\}。$$

(之后只需界定右侧事件的概率即可。)

将事件中心化，

$$\begin{aligned}\mathrm{P}\left\{\sum_{b=1}^{B} Z_b \geqslant \frac{B}{2}\right\} &= \mathrm{P}\left\{\frac{1}{B}\sum_{b=1}^{B} Z_b \geqslant \frac{1}{2}\right\} \\ &= \mathrm{P}\left\{\frac{1}{B}\sum_{b=1}^{B}(Z_b - \mathrm{E}[Z_b]) \geqslant \frac{1}{2} - \mathrm{E}[Z_b]\right\} \\ &\leqslant \mathrm{P}\left\{\frac{1}{B}\sum_{b=1}^{B}(Z_b - \mathrm{E}[Z_b]) \geqslant \frac{1}{4}\right\},\end{aligned}$$

之后利用 Hoeffding 不等式，可得

$$\begin{aligned}\mathrm{P}\left\{\frac{1}{B}\sum_{b=1}^{B} Z_b \geqslant \frac{1}{2}\right\} &\leqslant \mathrm{P}\left\{\frac{1}{B}\sum_{b=1}^{B}(Z_b - \mathrm{E}[Z_b]) \geqslant \frac{1}{4}\right\} \\ &\leqslant \exp\left(-2B\left(\frac{1}{4}\right)^2\right) = \exp\left(-\frac{B}{8}\right) \\ &\leqslant \exp\left(-\frac{t^2}{128}\right), \qquad (B = \lfloor t^2/8 \rfloor \geqslant t^2/16)\end{aligned}$$

因此

$$\mathrm{P}\left\{|\hat{\mu} - \mu| \geqslant \frac{t\sigma}{\sqrt{N}}\right\} \leqslant 2\mathrm{e}^{-ct^2}。 \qquad (c = \tfrac{1}{128})$$

17 [**不存在处处 sub-Gaussian 的均值估计量**] 我们考虑定理 T2.4.1 (中位数均值估计量) 是否对于任意的 $t > 0$ 均成立，答案是否定的。实际上，不存在均值估计量能够对所有的置信水平均提供 sub-Gaussian 的尾部界。

利用 Le Cam 两点法的变体，证明以下断言是错误的：

错误的断言 设 $\{X_N\}$ 为独立同分布的随机变量，满足 $\mu = \mathrm{E}[X_1]$，$\sigma^2 = \mathrm{Var}(X_1)$，对于任意的 $t \geqslant 0$，均存在 $\hat{\mu} : \mathbb{R}^N \to \mathbb{R}$，使得

$$\mathrm{P}\left\{|\hat{\mu}(X_1, \cdots, X_N) - \mu| \geqslant \frac{t\sigma}{\sqrt{N}}\right\} \leqslant 2\mathrm{e}^{-ct^2}。 \qquad (c > 0)$$

按照以下步骤证明：

(1) 考虑

$$\boldsymbol{X} = (X_1, \cdots, X_N)，\ \boldsymbol{Y} = (Y_1, \cdots, Y_N)，$$

其坐标是相互独立的，满足

$$X_i \sim \mathrm{Laplace}(0, 1)，\ Y_i \sim \mathrm{Laplace}(\mu, 1)。 \qquad (\mu > 0)$$

证明：对于 $\mathbb{R}^N$ 的任意可测子集 $B \in \mathscr{B}(\mathbb{R}^N)$，均满足

$$\mathrm{P}\{\boldsymbol{X} \in B\} \leqslant \mathrm{e}^{\mu}\mathrm{P}\{\boldsymbol{Y} \in B\}。$$

(2) 利用反证法，假设上述断言成立，将其利用于事件 $\{|\hat{\mu}(\boldsymbol{X})| \geqslant \mu/2\}, \{|\hat{\mu}(\boldsymbol{Y}) - \mu| \geqslant \mu/2\}$，计算概率。

(3) 选取足够大的 μ，利用 (1)，将 $\boldsymbol{Y}$ 替换为 $\boldsymbol{X}$，使得 $\{|\hat{\mu}(\boldsymbol{X})| < \mu/2\} \cup \{|\hat{\mu}(\boldsymbol{X}) - \mu| < \mu/2\}$ 同时成立，之后利用三角不等式导出矛盾；如此，上述断言不成立。

证明 我们只需证明，当 $N = 1$ 时，上述断言导致矛盾即可，此时观测值为单个随机变量，$\hat{\mu}$ 为一元函数 $\hat{\mu}(x)$。

(1) 定义 $\mathrm{P}_0, \mathrm{P}_\mu$ 均为 $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ 诱导的测度：

i. $\mathrm{P}_0 : X \sim \mathrm{Laplace}(0, 1)$，满足

$$\mu_0 = 0，\ \sigma^2 = 2，\ f_0(x) = \frac{1}{2}\mathrm{e}^{-|x|}；$$

ii. $\mathrm{P}_\mu : Y \sim \mathrm{Laplace}(\mu, 1)$，满足

$$\mu_Y = \mu,\ \sigma^2 = 2,\ f_\mu(x) = \frac{1}{2}\mathrm{e}^{-|x-\mu|}; \qquad (\mu > 0)$$

则

$$\frac{\mathrm{dP}_0}{\mathrm{dP}_\mu}(x) = \frac{\mathrm{dP}_0/\mathrm{d}\lambda}{\mathrm{dP}_\mu/\mathrm{d}\lambda}(x) = \frac{f_0(x)}{f_\mu(x)} = \frac{\mathrm{e}^{-|x|}/2}{\mathrm{e}^{-|x-\mu|}/2} = \mathrm{e}^{|x-\mu|-|x|} \leqslant \mathrm{e}^{\mu},$$

因此

$$\mathrm{P}_0(B) = \int_B \mathrm{dP}_0 = \int_B \frac{\mathrm{dP}_0}{\mathrm{dP}_\mu}\mathrm{dP}_\mu \leqslant \int_B \mathrm{e}^{\mu}\mathrm{dP}_\mu = \mathrm{e}^{\mu}\mathrm{P}_\mu(B)。$$

(2) 假设上述断言成立，令

$$\frac{t\sigma}{\sqrt{N}} = \frac{t\sqrt{2}}{\sqrt{1}} = \frac{\mu}{2} \implies t = \frac{\mu}{2\sqrt{2}},$$

则上界函数为

$$\delta(\mu) := 2\mathrm{e}^{-ct^2} = 2\exp\left(-\frac{c\mu^2}{8}\right),$$

因此对于相同的估计量 $\hat{\mu}$，

$$\mathrm{P}_0\left\{|\hat{\mu}(X)| \geqslant \frac{\mu}{2}\right\} \leqslant \delta(\mu),\ \mathrm{P}_\mu\left\{|\hat{\mu}(Y) - \mu| \geqslant \frac{\mu}{2}\right\} \leqslant \delta(\mu)。$$

(3) 定义判决集合 $B = \{x \in \mathbb{R} : |\hat{\mu}(x)| < \mu/2\}$，则：

i. 在零假设 P_0 下，

$$\mathrm{P}_0(B) = 1 - \mathrm{P}_0\left\{|\hat{\mu}(X)| \geqslant \frac{\mu}{2}\right\} \geqslant 1 - \delta(\mu); \qquad \text{(I)}$$

ii. 在备择假设 P_μ 下，对于任意的 $y \in B$，利用三角不等式，可得

$$|\hat{\mu}(y) - \mu| \geqslant |\mu| - |\hat{\mu}(y)| > \mu - \frac{\mu}{2} = \frac{\mu}{2},$$

因此 $B \subset \{y : |\hat{\mu}(y) - \mu| \geqslant \mu/2\}$，从而

$$\mathrm{P}\{Y \in B\} \leqslant \mathrm{P}\left\{|\hat{\mu}(Y) - \mu| \geqslant \frac{\mu}{2}\right\} \leqslant \delta(\mu)。 \qquad \text{(II)}$$

如此，联立 (I)(II)，可得

$$1 - \delta(\mu) \leqslant \mathrm{P}_0(B) \leqslant \mathrm{e}^{\mu}\mathrm{P}_\mu(B) \leqslant \mathrm{e}^{\mu}\delta(\mu),$$

即

$$1 \leqslant (\mathrm{e}^{\mu} + 1)\delta(\mu) = (\mathrm{e}^{\mu} + 1) \cdot 2\exp\left(-\frac{c\mu^2}{8}\right) \to 0,$$

这是矛盾的；如此，上述断言是错误的。

18 [**稀疏随机图的大多数顶点的度数是正常的**] 在之前的练习 Q1.10 (稀疏随机图的孤立顶点 (孤立点性质的逆命题)) 中，我们知道一个典型的稀疏随机图 $G \sim G(n, p)$ 往往存在孤立点，这导致最小度数为 0。尽管如此，绝大多数顶点的度数仍然集中于期望度数 $d = (n-1)p$ 附近。

证明：存在 $C > 0$，使得若期望度数 $d \geqslant C$，则以高概率至少存在 99% 的顶点，其度数 D_v 满足

$$D_v \in [0.9d, 1.1d] \text{ (w.p. 0.99)}。$$

证明 设 G 的顶点集为 $V = \{1, \cdots, n\}$，D_v 为顶点 v 的度数，则 $D_v \sim B(n-1, p)$，可得 $\mathrm{E}[D_v] = (n-1)p = d$。

称 v 为坏顶点，若 v 的度数偏离期望值超过 10%，定义坏事件 $B_v = \{|D_v - d| > 0.1d\}$，设 $N_{\mathrm{bad}} = \sum_{v=1}^{n} \mathbf{1}_{B_v}$，则证明目

标转化为

$$\mathrm{P}\{N_{\text{bad}} \leqslant 0.01n\} \geqslant 0.99,$$

之后只需证明 $\mathrm{P}\{N_{\text{bad}} > 0.01n\} \leqslant 0.01$ 即可。

利用 Chernoff 不等式，可得对于任意的 $\delta \in (0,1)$，

$$\mathrm{P}\{|D_v - d| > \delta d\} \leqslant 2\mathrm{e}^{-\frac{\delta^2 d}{3}},$$

令 $\delta = 0.1$，则

$$p_{\text{bad}} = \mathrm{P}(B_v) \leqslant 2\mathrm{e}^{-\frac{(0.1)^2 d}{3}} = 2\mathrm{e}^{-\frac{d}{300}},$$

因此

$$\mathrm{E}[N_{\text{bad}}] = \mathrm{E}\left[\sum_{v=1}^{n} \mathbf{1}_{B_v}\right] = \sum_{v=1}^{n} \mathrm{P}(B_v) = n \cdot p_{\text{bad}} = 2n\mathrm{e}^{-\frac{d}{300}},$$

从而利用 Markov 不等式，可得

$$\mathrm{P}\{N_{\text{bad}} > 0.01n\} \leqslant \frac{\mathrm{E}[N_{\text{bad}}]}{0.01n} = \frac{2n\mathrm{e}^{-\frac{d}{300}}}{0.01n} = 200\mathrm{e}^{-\frac{d}{300}}。$$

若证明目标成立，则

$$200\mathrm{e}^{-\frac{d}{300}} \leqslant \frac{1}{100} \implies d \geqslant 300\ln(20000) = 2970,$$

因此存在 $C = 3000$，使得当 $d \geqslant C$ 时，

$$\mathrm{P}\{N_{\text{bad}} > 0.01n\} \leqslant 0.01。$$

19 [**稀疏随机图的最大度**] 对于练习 Q1.10 (稀疏随机图的孤立顶点 (孤立点性质的逆命题))，我们观察到典型的稀疏随机图 $G \sim G(n,p)$ 的最小度通常为零。现在我们关注最大度 $\Delta(G)$ (即拥有最多朋友的学生的度数)。

证明：若期望度数 $d = (n-1)p$ 满足稀疏条件 $d \leqslant c(\ln n)^{0.99}$，则当 $n \geqslant 3$ 时，

$$c_1 \frac{\ln n}{\ln\ln n} \leqslant \Delta(G) \leqslant c_2 \frac{\ln n}{\ln\ln n} \text{ (w.p. 0.99)。} \qquad (c, c_1, c_2 > 0)$$

证明 设 G 的顶点集为 $V = \{1, 2, \cdots, n\}$，D_v 为顶点 v 的度数，则 $D_v \sim B(n-1,p) \xrightarrow{\mathrm{d}} P(d)$。

- 证明上界

  利用 Chernoff 界，可得对于任意的 $k > d$，

  $$\mathrm{P}\{D_v \geqslant k\} \leqslant \left(\frac{\mathrm{e}d}{k}\right)^k,$$

  两侧取对数，

  $$\ln \mathrm{P}\{D_v \geqslant k\} \leqslant k(\ln(\mathrm{e}d) - \ln k)。$$

  令目标度数 $k = c_2 K$，其中 $K = \ln n / \ln\ln n$，则

  $$\ln k = \ln c_2 + \ln\ln n - \ln\ln\ln n \sim \ln\ln n,$$
  $$\ln(\mathrm{e}d) = 1 + \ln c + 0.99\ln\ln n \sim 0.99\ln\ln n,$$

  将其代入，可得

  $$\ln \mathrm{P}\{D_v \geqslant k\} \lesssim c_2 \frac{\ln n}{\ln\ln n}((0.99-1)\ln\ln n) = -0.01c_2 \ln n,$$

  即

  $$\mathrm{P}\{D_v \geqslant k\} \leqslant n^{-0.01c_2 + o(1)},$$

  因此

  $$\mathrm{P}\{\Delta(G) \geqslant k\} = \mathrm{P}\left\{\bigcup_{v=1}^{n} \{D_v \geqslant k\}\right\} \leqslant \sum_{v=1}^{n} \mathrm{P}\{D_v \geqslant k\} = n\mathrm{P}\{D_1 \geqslant k\}$$

$$\leqslant n \cdot n^{-0.01c_2} = n^{1-0.01c_2},$$

为了使得 $\mathrm{P}\{\Delta(G) \geqslant k\} \leqslant 0.005$。(之后只需令 $c_2 > 100$ 即可。)

- 证明下界

解法一

(证明下界的核心难点在于顶点度数 $d_1, \cdots, d_n$ 存在弱相关性。我们采用二分子图独立性技巧 (Bipartite Subgraph Trick) 克服相关性。)

将 $V = \{1, \cdots, n\}$ 划分为两个大小相等的互不相交的子集 $V_1 \sqcup V_2$，

$$V_1 = \{1, \cdots, \lfloor n/2 \rfloor\},\ V_2 = \{\lfloor n/2 \rfloor + 1, \cdots, n\}。$$

考虑跨越 V_1, V_2 之间的二分边，对于任意的 $i \in V_1$，记其向 V_2 发射的边数为

$$d_i' = \sum_{j \in V_2} \mathbf{1}_{\{(i,j) \in E(G)\}},$$

则：

1. 独立性：由于任意的顶点 $i \in V_1$ 所连接的潜在边集合 $\{(i,j) : j \in V_2\}$ 是互不相交的，因此 $\{d_i'\}_{i \in V_1}$ 是相互独立的。
2. 下界关系：由于 $d_i \geqslant d_i'$，因此

$$\Delta(G) \geqslant \max_{i \in V_1} d_i', \tag{I}$$

令目标度数 $k = c_1 K$ $(c_1 \in (0,1))$，则

$$\mathrm{P}\{\Delta(G) \geqslant k\} \geqslant \mathrm{P}\left\{\max_{i \in V_1} d_i' \geqslant k\right\}。$$

(之后只需考虑界定 $\mathrm{P}\{\max_{i \in V_1} d_i' \geqslant c_1 K\}$ 即可。)

- 单点二分度数的渐近尾部估计

容易知道，

$$\begin{aligned}\ln \mathrm{P}\{d_i' \geqslant k\} &\geqslant \ln \mathrm{P}\{d_i' = k\} \\ &= \ln\left(\binom{|V_2|}{k} p^k (1-p)^{|V_2|-k}\right),\end{aligned}$$

利用 Strling 对数渐近展开

$$\ln \binom{m}{k} = k \ln\left(\frac{\mathrm{e}m}{k}\right) + O(\ln k),$$

可得

$$\begin{aligned}\ln \mathrm{P}\{d_i' \geqslant k\} &= k \ln\left(\frac{\mathrm{e}|V_2|p}{k}\right) - |V_2|p + O(\ln k + kp) \\ &= -k \ln\left(\frac{2k}{\mathrm{e}d}\right) - O(d + \ln k),\end{aligned}$$

其中

$$\begin{aligned}\ln\left(\frac{2k}{\mathrm{e}d}\right) &\leqslant \ln k = (1 + o(1)) \ln \ln n, \\ k \ln\left(\frac{2k}{\mathrm{e}d}\right) &\leqslant \left(c_1 \frac{\ln n}{\ln \ln n}\right) \cdot (1 + o(1)) \ln \ln n = (c_1 + o(1)) \ln n, \\ d + \ln k &= O\big((\ln n)^{0.99}\big) = o(\ln n),\end{aligned}$$

将其代入，可得

$$\ln \mathrm{P}\{d_i' \geqslant k\} \geqslant -c_1 \ln n - o(\ln n) \implies \mathrm{P}\{d_i' \geqslant k\} = n^{-c_1 + o(1)}。$$

- 利用独立性推导极大值极限

由于 $\{d_i'\}_{i\in V_1}$ 是相互独立的，因此

$$\begin{aligned}\mathrm{P}\left\{\max_{i\in V_1} d_i' < k\right\} &= \prod_{i\in V_1}(1-\mathrm{P}\{d_i' \geqslant k\}) \\ &\leqslant \exp(-|V_1|\cdot \mathrm{P}\{d_i' \geqslant k\}) \\ &= \exp\left(-\left(\frac{1}{2}+o(1)\right)n\cdot n^{-c_1+o(1)}\right) \\ &= \exp(-\Omega(n^{1-c_1+o(1)}))。\end{aligned}$$

其中 $c_1<1$，即幂次 $1-c_1>0$，因此

$$\mathrm{P}\left\{\max_{i\in V_1} d_i' < k\right\} = o(1)\ (n\to\infty)。 \tag{II}$$

如此，联立 (I)(II)，可得

$$\Delta(G) \geqslant c_1\frac{\ln n}{\ln\ln n}\ (\text{w.p. } 1-o(1)\geqslant 0.99)。$$

解法二

(只需证明至少存在一个顶点的度数，以高概率大于等于 $k'=c_1K$。)

设 $X_v=\mathbf{1}_{\{D_v\geqslant k'\}}$，$Y=\sum_{v=1}^n X_v$ 为度数大于等于 k' 的顶点数，则只需证明 $\mathrm{P}\{Y>0\}\geqslant 0.99$。

当 $k'\gg d$ 时，

$$p_{k'}=\mathrm{P}\{D_v=k'\}\sim \mathrm{e}^{-d}\frac{d^{k'}}{k'!}\geqslant \mathrm{e}^{-d}\left(\frac{d}{k'}\right)^{k'},$$

由于

$$\begin{aligned}\ln p_{k'} &\sim k'(\ln d-\ln k') \\ &\sim c_1\frac{\ln n}{\ln\ln n}(O(\ln\ln n)-\ln\ln n) \\ &\sim -c_1\ln n,\end{aligned}$$

因此 $p_{k'}\sim n^{-c_1}$，从而

$$\mathrm{E}[Y]=np_{k'}\sim n\cdot n^{-c_1}=n^{1-c_1},$$

从而令 $c_1<1$，此时 $\mathrm{E}[Y]\sim n^{1-c_1}\to\infty$。

作出以下推断：

推断 $\mathrm{Var}(Y)\sim \mathrm{E}[Y]$，即 $\mathrm{Var}(Y)=o(\mathrm{E}[Y]^2)$。

容易知道，

$$\begin{aligned}\mathrm{Var}(Y) &= \sum_{v=1}^n \mathrm{Var}(X_v)+\sum_{u\neq v}\mathrm{Cov}(X_u,X_v) \\ &\leqslant \sum_{v=1}^n \mathrm{E}[X_v]+\sum_{u\neq v}\mathrm{Cov}(X_u,X_v) \\ &= \mathrm{E}[Y]+\sum_{u\neq v}\mathrm{Cov}(X_u,X_v),\end{aligned}$$

之后只需计算 $\mathrm{Cov}(X_u,X_v)$ 即可设 I_{uv} 为边 (u,v) 存在的指示变量，满足 $I_{uv}\sim\mathrm{Bernoulli}(p)$，则 D_u',D_v' i.i.d. $\sim B(n-2,p)$，可得

$$\mathrm{E}[X_u]=\mathrm{E}[\mathbf{1}_{\{D_u'+I_{uv}\geqslant k\}}],\ \mathrm{E}[X_uX_v]=\mathrm{E}[\mathbf{1}_{\{D_u'+I_{uv}\geqslant k\}}\cdot\mathbf{1}_{\{D_v'+I_{uv}\geqslant k\}}],$$

之后记 $A_k=\mathrm{P}\{D_u'\geqslant k\}$，则

$$\mathrm{E}[X_u]=\mathrm{E}[\mathbf{1}_{\{D_u'+I_{uv}\geqslant k\}}]=pA_{k-1}+(1-p)A_k,$$

$$\begin{aligned}\mathrm{E}[X_uX_v] &= p\cdot\mathrm{P}\{D'_u+1\geqslant k\}\mathrm{P}\{D'_v+1\geqslant k\}+(1-p)\cdot\mathrm{P}\{D'_u\geqslant k\}\mathrm{P}\{D'_v\geqslant k\}\\ &= pA_{k-1}^2+(1-p)A_k^2,\end{aligned}$$

因此

$$\begin{aligned}\mathrm{Cov}(X_u,X_v) &= (pA_{k-1}^2+(1-p)A_k^2)-(pA_{k-1}+(1-p)A_k)^2\\ &= p(1-p)(A_{k-1}-A_k)^2,\end{aligned}$$

其中

$$A_{k-1}-A_k=\mathrm{P}\{D'_u\geqslant k-1\}-\mathrm{P}\{D'_u\geqslant k\}=\mathrm{P}\{D'_u=k-1\},$$

将其代入，可得

$$\mathrm{Cov}(X_u,X_v)=p(1-p)(\mathrm{P}\{D'_u=k-1\})^2\leqslant p(\mathrm{P}\{D'_u=k-1\})^2,$$

从而

$$\begin{aligned}\frac{\mathrm{Var}(Y)}{(\mathrm{E}[Y])^2} &\leqslant \frac{\mathrm{E}[Y]+\sum_{u\neq v}\mathrm{Cov}(X_u,X_v)}{(\mathrm{E}[Y])^2}=\frac{1}{\mathrm{E}[Y]}+\frac{n(n-1)\,\mathrm{Cov}(X_1,X_2)}{n^2(\mathrm{E}[X_1])^2}\\ &\sim \frac{\mathrm{Cov}(X_1,X_2)}{(\mathrm{E}[X_1])^2}=\frac{p(\mathrm{P}\{D'_1=k-1\})^2}{(\mathrm{P}\{D_1\geqslant k\})^2}。\end{aligned}$$

由于 $D_1\sim D'_1$，$k\gg d$，因此尾部概率由首项主导，即

$$\mathrm{P}\{D_1\geqslant k\}\sim\mathrm{P}\{D_1=k\}=\frac{d}{k}\frac{k!}{d^k}\frac{d^{k-1}}{(k-1)!}\sim\frac{d}{k}\mathrm{P}\{D_1=k-1\},$$

从而

$$\begin{aligned}\frac{\mathrm{Var}(Y)}{(\mathrm{E}[Y])^2} &\sim \frac{p(\mathrm{P}\{D'_1=k-1\})^2}{(d/k)^2(\mathrm{P}\{D'_1=k-1\})^2}=p\left(\frac{k}{d}\right)^2\\ &\sim \frac{d}{n}\frac{k^2}{d^2}=\frac{k^2}{nd}\sim\frac{(\ln n)^2}{nd}\to 0。 \qquad \left(p=\frac{d}{n-1}\sim\frac{d}{n},k\sim\ln n\right)\end{aligned}$$

根据推断，利用 Chebyshev 不等式，可得

$$\mathrm{P}\{Y=0\}\leqslant\mathrm{P}\{|Y-\mathrm{E}[Y]|\geqslant\mathrm{E}[Y]\}\leqslant\frac{\mathrm{Var}(Y)}{(\mathrm{E}[Y])^2}\sim\frac{1}{\mathrm{E}[Y]}\to 0。$$

综上，存在 $c_1,c_2>0$，使得 $\Delta(G)$ 以高概率落于 $[c_1K,c_2K]$ (w.p. 0.99)。

20 [**随机图的扩展性质**] 随机图 $G(n,p)$ 表现一种显著的性质：对于任意的 $S,T\subset V$，只要它们不是过小的，则连接它们的边数 $e(S,T)$ 与上述集合的大小之积成正比。

设 $S,T\subset V$，满足 $S\cap T=\emptyset$。证明：当 $|S||T|\geqslant Cn/p$ 时，

$$0.9p\leqslant\frac{e(S,T)}{|S||T|}\leqslant 1.1p\ (\text{w.p.}1-2^{-n})^1。 \qquad (C>0)$$

证明 设 $|S|=s,|T|=t$，则 $e(S,T)\sim B(st,p)$，可得 $\mu_{S,T}:=\mathrm{E}[e(S,T)]=stp$，因此只需证明

$$|e(S,T)-\mu_{S,T}|\leqslant 0.1\mu_{S,T}。$$

- 首先考虑单对固定子集 (S,T) 的情况

  利用 Chernoff 界，可得对于任意的 $\delta\in(0,1)$，

  $$\mathrm{P}\{|X-\mu|\geqslant\delta\mu\}\leqslant 2\exp\left(-\frac{\delta^2\mu}{3}\right),$$

  令 $\delta=0.1$，$\mu=stp$，则对于固定的 (S,T)，目标不成立的概率为

  $$p_{\text{fail}}(S,T)=\mathrm{P}\{|e(S,T)-stp|>0.1stp\}\leqslant 2\exp\left(-\frac{0.01stp}{3}\right)。$$

[1] 原文为 $1-2^n$，此处已修正。

代入 $st \geqslant Cn/p$，可得

$$p_{\text{fail}}(S,T) \leqslant 2\exp\left(-\frac{Cn}{300}\right)。$$

- 之后考虑全空间不相交子集对的情况

令 $\mathcal{F}$ 为所有不相交子集对 (S,T) 的集合，则总失效概率的上界为

$$P_{\text{fail}} \leqslant \sum_{\substack{(S,T):S\cap T=\emptyset \\ stp\geqslant Cn}} p_{\text{fail}}(S,T) = 2\exp\left(-\frac{Cn}{300}\right),$$

其中当 $S\cap T=\emptyset$ 时，或者 $v\in S$，或者 $v\in T$，或者 $v\notin S\cup T$，此时 $\sum_{(S,T):S\cap T=\emptyset} = 3^n$，将其代入，可得

$$P_{\text{fail}} \leqslant 3^n\cdot 2\exp\left(-\frac{Cn}{300}\right) = 2\exp\left(n\ln 3-\frac{Cn}{300}\right)。$$

如此，要满足 $P_{\text{fail}} \leqslant 2^{-n} = \exp(-n\ln 2)$，只需满足

$$n\ln 3-\frac{Cn}{300} \leqslant -n\ln 2-\ln 2 \implies C\geqslant 300\left(\ln 6+\frac{\ln 2}{n}\right)。$$

21 [**随机算法的增强**] 考虑用于解决判定问题 (Decision Problem，如素数判定) 的随机算法 $\mathcal{A}$，其正确率略高于随机猜测，即对于任意的输入，算法给出正确答案的概率为 $p=1/2+\varepsilon$，其中 $\varepsilon>0$。

为了提高准确率，将 $\mathcal{A}$ 独立地运行 N 次，并采用多数表决规则 (Majority Vote) 作为最终输出。证明：对于任意给定的错误率容忍度 $\delta\in(0,1)$，若

$$N\geqslant \frac{1}{2\varepsilon^2}\ln\left(\frac{1}{\delta}\right)$$

则最终输出正确的概率至少为 $1-\delta$。

证明 设 X_i 为第 i 次运行算法的指示变量，则 $\{X_N\}$ i.i.d. $\sim$ Bernoulli(p)，可得 $\mu=\mathrm{E}[S_N]=Np=N/2+N\varepsilon$，此时

$$P_{\text{fail}} = \mathrm{P}\left\{S_N\leqslant\frac{N}{2}\right\} = \mathrm{P}\{S_N-\mu\leqslant -N\varepsilon\},$$

因此利用 Hoeffding 不等式，令 $a_i=0,b_i=1,t=N\varepsilon$，可得

$$P_{\text{fail}} = \mathrm{P}\{S_N-\mu\leqslant -N\varepsilon\} \leqslant \exp\left(-\frac{2(N\varepsilon)^2}{N}\right) = \exp(-2N\varepsilon^2)。$$

如此，要满足 $P_{\text{fail}}\leqslant\delta$，只需满足

$$\exp(-2N\varepsilon^2)\leqslant\delta \implies N\geqslant\frac{1}{2\varepsilon^2}\ln\left(\frac{1}{\delta}\right)。$$

22 [**正态分布的绝对矩**] 设 $g\sim N(0,1)$。

(1) 证明：对于任意的 $p\geqslant 1$，

$$\mathrm{E}[|g|^p] = \frac{2^{p/2}}{\sqrt{\pi}}\Gamma\left(\frac{p+1}{2}\right)。$$

(2) 证明：当 $p\to\infty$ 时，

$$\|g\|_{L^p} = \left(\mathrm{E}[|g|^p]\right)^{1/p} = \sqrt{\frac{p}{\mathrm{e}}}(1+o(1))。$$

证明 (1) 容易知道，

$$\begin{aligned}\mathrm{E}[|g|^p] &= \int_{-\infty}^{\infty}|x|^p\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2}\mathrm{d}x \\ &= \sqrt{\frac{2}{\pi}}\int_0^{\infty}x^p\mathrm{e}^{-x^2/2}\mathrm{d}x,\end{aligned}$$

其中

$$\int_0^\infty x^p \mathrm{e}^{-x^2/2}\mathrm{d}x = \int_0^\infty (2^{1/2}u^{1/2})^p \mathrm{e}^{-u}\frac{1}{2^{1/2}u^{1/2}}\mathrm{d}u \qquad \left(u=\frac{x^2}{2}\right)$$
$$= 2^{(p-1)/2}\int_0^\infty u^{\frac{p+1}{2}-1}\mathrm{e}^{-u}\mathrm{d}u$$
$$= 2^{(p-1)/2}\Gamma\left(\frac{p+1}{2}\right),$$

将其代入，可得

$$\mathrm{E}[|g|^p] = \frac{2^{p/2}}{\sqrt{\pi}}\Gamma\left(\frac{p+1}{2}\right)。$$

(2) 利用 (1) 的结论，可得

$$\|g\|_{L^p} = \left(\frac{2^{p/2}}{\sqrt{\pi}}\Gamma\left(\frac{p+1}{2}\right)\right)^{1/p} = \frac{\sqrt{2}}{(\sqrt{\pi})^{1/p}}\left[\Gamma\left(\frac{p+1}{2}\right)\right]^{1/p},$$

利用 Stirling 公式 $\Gamma(z)\sim\sqrt{2\pi}z^{z-1/2}\mathrm{e}^{-z}$，可得

$$[\Gamma(z)]^{1/p} \sim [\sqrt{2\pi}z^{z-1/2}\mathrm{e}^{-z}]^{1/p}$$
$$= (2\pi)^{\frac{1}{2p}}\cdot z^{\frac{z-1/2}{p}}\cdot \mathrm{e}^{-\frac{z}{p}},$$

其中

$$\mathrm{e}^{-\frac{z}{p}} = \mathrm{e}^{-\frac{p+1}{2p}} \to \frac{1}{\sqrt{\mathrm{e}}},$$
$$z^{\frac{z-1/2}{p}} = \left(\frac{p+1}{2}\right)^{\frac{p}{2p}} = \left(\frac{p(1+1/p)}{2}\right)^{\frac{1}{2}} = \left(\frac{p}{2}\right)^{1/2}\left(1+\frac{1}{p}\right)^{1/2} \sim \sqrt{\frac{p}{2}},$$

将其代入，可得

$$\|g\|_{L^p} \sim \sqrt{2}\cdot 1\cdot\sqrt{\frac{p}{2\mathrm{e}}} = \sqrt{\frac{p}{\mathrm{e}}}。$$

23 [**sub-Gaussian MGF 性质蕴含零均值**] 于 sub-Gaussian 随机变量的定义 (例如命题 P2.6.1 (sub-Gaussian 性质) 的性质 (iv))，通常假设或包含均值为零的条件。证明这是必须的。

具体而言，设 X 为随机变量。证明：若对于任意的 $\lambda\in\mathbb{R}$，

$$\mathrm{E}[\mathrm{e}^{\lambda X}] \leqslant \mathrm{e}^{C\lambda^2}, \qquad (C>0)$$

则 $\mathrm{E}[X]=0$。

证明 **解法一 Jensen 不等式**

利用 Jensen 不等式，令 $\phi(x)=\mathrm{e}^x$，$Y=\lambda X$，则 $\mathrm{e}^{\mathrm{E}[\lambda X]}\leqslant\mathrm{E}[\mathrm{e}^{\lambda X}]$，即

$$\mathrm{e}^{\lambda\mathrm{E}[X]} \leqslant C\lambda^2。$$

a. 若 $\lambda>0$，则 $\mathrm{E}[X]\leqslant C\lambda$，令 $\lambda\to 0^+$，可得 $\mathrm{E}[X]\leqslant 0$。

b. 若 $\lambda<0$，则 $\mathrm{E}[X]\geqslant C\lambda$，令 $\lambda\to 0^-$，可得 $\mathrm{E}[X]\geqslant 0$。

如此，$\mathrm{E}[X]=0$。

解法二 导数的性质

构造辅助函数

$$h(\lambda) = M(\lambda) - g(\lambda) = \mathrm{E}[\mathrm{e}^{\lambda X}] - \mathrm{e}^{C\lambda^2},$$

其中 $M(0)=g(0)=1$，$M(\lambda)\leqslant g(\lambda)$，则 $h(0)=0$，$h(\lambda)\leqslant 0$，因此 $\lambda=0$ 为 $h(\lambda)$ 的全局最大值点，从而

$$h'(0) = M'(0) - g'(0) = 0,$$

代入 $g'(0)=0$，$M'(0)=\mathrm{E}[X]$，可得 $\mathrm{E}[X]=0$。

24 [**sub-Gaussian 分布的例子**] 证明以下随机变量的 sub-Gaussian 范数 $\|\cdot\|_{\psi_2}$。

(1) (常数) 若 $X = c$ (a.s.)，则

$$\|X\|_{\psi_2} = \frac{|c|}{\sqrt{\ln 2}}。$$

(2) (有界) 若 $\|X\|_\infty < \infty$，则

$$\|X\|_{\psi_2} \leqslant \frac{\|X\|_\infty}{\sqrt{\ln 2}}。$$

(3) (Rademacher) 若 $X \sim \text{Rademacher}$，则

$$\|X\|_{\psi_2} = \frac{1}{\sqrt{\ln 2}}。$$

(4) (正态) 若 $X \sim N(0, \sigma^2)$，则

$$\|X\|_{\psi_2} = \sqrt{\frac{8}{3}}\sigma。$$

(5) (Bernoulli) 若 $X \sim \text{Bernoulli}(p)$，则

$$\|X\|_{\psi_2} = \frac{1}{\sqrt{\ln(1+1/p)}}。$$

证明 (1) 设 $X = c$ (a.s.)，则

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] = \exp\left(\frac{c^2}{K^2}\right) \leqslant 2 \implies K \geqslant \frac{|c|}{\sqrt{\ln 2}},$$

因此 $\|X\|_{\psi_2} = |c|/\sqrt{\ln 2}$。

(2) 设 $|X| \leqslant \|X\|_\infty = M$ (a.s.)，则

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] \leqslant \exp\left(\frac{M^2}{K^2}\right) \leqslant 2 \implies K \geqslant \frac{M}{\sqrt{\ln 2}},$$

因此 $\|X\|_{\psi_2} \leqslant \|X\|_\infty/\sqrt{\ln 2}$。

(3) 注意到 $X^2 = 1$，这等同于 (1) 的 $c = 1$ 的情况，可得

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] = \exp\left(\frac{1}{K^2}\right) \leqslant 2 \implies K \geqslant \frac{1}{\sqrt{\ln 2}},$$

因此 $\|X\|_{\psi_2} = 1/\sqrt{\ln 2}$。

(4) 容易知道，

$$\begin{aligned}\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] &= \int_{-\infty}^{\infty} \mathrm{e}^{x^2/K^2} \frac{1}{\sqrt{2\pi}\sigma} \mathrm{e}^{-x^2/(2\sigma^2)} \mathrm{d}x \\ &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} \exp\left(-\frac{x^2}{2}\left(\frac{1}{\sigma^2} - \frac{2}{K^2}\right)\right) \mathrm{d}x,\end{aligned}$$

若上述积分收敛，则 $1/\sigma^2 - 2/K^2 > 0$，即 $K^2 > 2\sigma^2$，此时

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] = \frac{1}{\sqrt{2\pi}\sigma} \cdot \sqrt{\frac{2\pi}{1/\sigma^2 - 2/K^2}} = \frac{1}{\sqrt{1 - 2\sigma^2/K^2}} \leqslant 2 \implies K^2 \geqslant \frac{8}{3}\sigma^2,$$

因此 $\|X\|_{\psi_2} = \sqrt{8/3}\sigma$。

(5) 容易知道，

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] = (1-p)\mathrm{e}^{0^2/K^2} + p\mathrm{e}^{1^2/K^2} = 1 - p + p\mathrm{e}^{1/K^2} \leqslant 2 \implies K \geqslant \frac{1}{\sqrt{\ln(1+1/p)}},$$

因此 $\|X\|_{\psi_2} = 1/\sqrt{\ln(1+1/p)}$。

25 [**非 sub-Gaussian 分布的反例**] sub-Gaussian 分布要求其尾部概率的衰减速度至少像 Gaussian 分布一样快 (即 $\exp(-ct^2)$)。解释以下常见的概率分布不是 sub-Gaussian 分布。

(1) sub-Exponential 类：指数分布, Gamma 分布, chi-Square 分布, 几何分布, Poisson 分布。

(2) 重尾类 (多项式衰减)：Cauchy 分布, Pareto 分布。

解答 (1) 对于 $X\sim E(\lambda)$，$\mathrm{P}\{X\geqslant t\}=\mathrm{e}^{-\lambda t}$。

对于 $X\sim G(p)$，$\mathrm{P}\{X\geqslant k\}=(1-p)^k=\mathrm{e}^{-k\ln(1-p)}$。

对于 $X\sim\Gamma(k,\theta)$，$f(x)\propto x^{k-1}\mathrm{e}^{-x/\theta}$。

对于 $X\sim P(\lambda)$，利用 Chernoff 界，可得

$$\mathrm{P}\{X\geqslant t\}\leqslant \mathrm{e}^{-st}\mathrm{E}[\mathrm{e}^{sX}]=\exp(-st+\lambda(\mathrm{e}^s-1)),$$

右侧的最优参数为 $s_0=\ln(t/\lambda)$，将其代入，可得

$$\mathrm{P}\{X\geqslant t\}\leqslant \exp(-t(\ln t-\ln\lambda)+t-\lambda)\sim\exp(-t\ln t)。$$

(当 t 接近于 λ 时，$P(\lambda)$ 是局部 sub-Gaussian 的。)

(2) 对于 $X\sim\mathrm{Pareto}(\alpha,x_m)$，$\mathrm{P}\{X>t\}=(x_m/t)^\alpha$。

对于 $X\sim\mathrm{Cauchy}(0,1)$，其不存在一阶矩，因此不是 sub-Gaussian 的 (sub-Gaussian 分布的必要条件为各阶矩均存在且有限)。

综上，

分布类型	尾部衰减形式	结论
Gaussian, sub-Gaussian	$\sim\exp(-t^2)$	基准
Exponential, Gamma, chi-Squared	$\sim\exp(-t)$	否
Poisson	$\sim\exp(-t\ln t)$	否
Cauchy, Pareto	$\sim t^{-\alpha}$	否

26 [**sub-Gaussian 的等价刻画：X^2 的 MGF**] 关于命题 P2.6.1 (sub-Gaussian 性质)，我们已知几种描述 sub-Gaussian 分布的等价方式 (例如尾部概率衰减, 矩的增长速度等)。这里提供另一种刻画方式。

证明：X 为 sub-Gaussian 随机变量，当且仅当存在 $K>0$，使得当 $|\lambda|\leqslant 1/K$ 时，

$$\mathrm{E}[\exp(\lambda^2X^2)]\leqslant\exp(\lambda^2K^2)。$$

证明 ($\Longrightarrow$)

若 X 为 K-sub-Gaussian 随机变量，则 $\mathrm{E}[\exp(X^2/K^2)]\leqslant 2$。

利用 Jensen 不等式，令 $\phi(y)=y^\alpha$，其中 $\alpha=\lambda^2K^2\in[0,1]$，可得

$$\mathrm{E}[\exp(\lambda^2X^2)]=\mathrm{E}\left[\left(\exp\left(\frac{X^2}{K^2}\right)\right)^\alpha\right]\leqslant\left(\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right]\right)^\alpha\leqslant 2^\alpha<\mathrm{e}^\alpha=\exp(\lambda^2K^2)。$$

($\Longleftarrow$)

要证明 X 为 K-sub-Gaussian 随机变量，只需证明存在 $t>0$，使得 $\mathrm{E}[\exp(X^2/t^2)]\leqslant 2$。

令 $\lambda=1/t$，则 t 满足：

1. 定义域：若 $|\lambda|\leqslant 1/K$，则 $t\geqslant K$；

2. 上界不超过 2：若 $\exp(\lambda^2K^2)=\exp(K^2/t^2)\leqslant 2$，则 $t\geqslant K/\sqrt{\ln 2}$；

因此令 $t=2K$，可得

$$\mathrm{E}[\exp(\lambda^2K^2)]=\mathrm{E}\left[\exp\left(\frac{X^2}{4K^2}\right)\right]\leqslant\exp\left(\frac{K^2}{4K^2}\right)=\mathrm{e}^{1/4}<2,$$

即 $\|X\|_{\psi_2}<2K$。

27 [**sub-Gaussian 分布的刻画：几乎随机占优**] 设 X,Y 为随机变量，若 $\mathrm{P}\{X\geqslant t\}\leqslant 2\mathrm{P}\{Y\geqslant t\}$，则记为 $X\precsim Y$。

(1) 证明：X 服从 sub-Gaussian 分布，当且仅当存在 $K>0$，使得

$$|X| \precsim K|g|, \qquad (g \sim N(0,1))$$

即

$$K \leqslant C\|X\|_{\psi_2}。 \qquad (C>0)$$

(2) 举例说明，若将 $X \precsim Y$ 定义的因子 2 替换为 1，则 (1) 的结论未必成立。

证明 (1) ($\Longleftarrow$)

若 $X \precsim K|g|$，则

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{P}\{K|g| \geqslant t\} = 2\mathrm{P}\left\{|g| \geqslant \frac{t}{K}\right\}。$$

利用 Gaussian 分布的尾部上界 $\mathrm{P}\{|g| \geqslant x\} \leqslant 2\exp(-x^2/2)$，令 $x = t/K$，可得

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2 \cdot 2\exp\left(-\frac{t^2}{2K^2}\right) = 4\exp\left(-\frac{t^2}{2K^2}\right),$$

因此 X 为 sub-Gaussian 随机变量。

($\Longrightarrow$)

若 X 为 sub-Gaussian 随机变量，则存在 $c>0$，使得

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{\sigma^2}\right), \qquad (\sigma = \|X\|_{\psi_2})$$

($\Longrightarrow$)

因此之后只需证明

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{P}\left\{|g| \geqslant \frac{t}{K}\right\},$$

简化上述证明目标，令 $y = t/K$，可得

$$\mathrm{P}\{|X| \geqslant Ky\} \leqslant 2\mathrm{P}\{|g| \geqslant y\}。$$

记 M 为 g 的绝对值中位数，即 $\mathrm{P}\{|g| \geqslant M\} = 1/2$，对 y 的取值进行讨论：

a. 若 $0 \leqslant y \leqslant M$，则 $\mathrm{P}\{|g| \geqslant y\} \geqslant \mathrm{P}\{|g| \geqslant M\} = 1/2$，因此

$$2\mathrm{P}\{|g| \geqslant y\} \geqslant 2\left(\frac{1}{2}\right) = 1,$$

从而 $\mathrm{P}\{|X| \geqslant Ky\} \leqslant 2\mathrm{P}\{|g| \geqslant y\}$。

b. 若 $y > M$，则只需证明存在 K，使得

$$\mathrm{P}\{|X| \geqslant Ky\} \leqslant 2\exp\left(-\frac{K^2y^2}{\sigma^2}\right) \leqslant 2\mathrm{P}\{|g| \geqslant y\},$$

即

$$\frac{K^2}{\sigma^2} \geqslant \underbrace{-\frac{\ln \mathrm{P}\{|g| \geqslant y\}}{y^2}}_{f(y)}。$$

对于右侧，代入 Mills 比率 $\ln \mathrm{P}\{|g| \geqslant y\} \sim -y^2/2$，可得 $f(y) \sim -1/2$，因此存在 $C_{\sup} = \sup_{y \geqslant M} g(y)$，使得

$$\frac{K^2}{\sigma^2} \geqslant C_{\sup} \Longrightarrow K \geqslant \sqrt{C_{\sup}}\sigma。$$

(2) 只需推翻以下结论：

$$\mathrm{P}\{|X| \geqslant t\} \leqslant \mathrm{P}\{K|g| \geqslant t\}。$$

假设上述结论成立，令 $X \sim$ Rademacher，则根据习题 Q2.24 (sub-Gaussian 分布的例子)，可得 X 为 sub-Gaussian

随机变量，此时

$$\mathrm{P}\{1 \geqslant t\} \leqslant \mathrm{P}\left\{|g| \geqslant \frac{t}{K}\right\}。$$

但是当 $t \in (0,1]$ 时，

$$1 \leqslant \mathrm{P}\left\{|g| \geqslant \frac{t}{K}\right\} < 1,$$

这是矛盾的。

28 [**sub-Gaussian 分布的特征：凸优势定义**] 设 X, Y 为随机变量，若对于任意的凸递增函数 $\phi : \mathbb{R} \to \mathbb{R}$，均满足

$$\mathrm{E}[\phi(X)] \leqslant \mathrm{E}[\phi(Y)],$$

则记为 $X \precsim Y$ (递增凸序)。证明：X 为 sub-Gaussian 随机变量，当且仅当存在 $K > 0$，使得 $|X| \precsim K|g|$。

证明 若 $X \precsim Y$，则对于任意的 $t \geqslant 0$，

$$\int_x^\infty \mathrm{P}\{X \geqslant t\}\mathrm{d}t \leqslant \int_x^\infty \mathrm{P}\{Y \geqslant t\}\mathrm{d}t。$$

- $(\Longrightarrow)$

  若 X 为 sub-Gaussian 随机变量，则对于任意的 $t \geqslant 0$，

  $$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{e}^{-ct^2/L^2},$$

  之后只需证明

  $$f(x) := \int_x^\infty \mathrm{P}\{|X| \geqslant t\}\mathrm{d}t \leqslant \int_x^\infty \mathrm{P}\{K|g| \geqslant t\}\mathrm{d}t =: h(x,K)。$$

  分别计算 $f(x), h(x,K)$，

  $$\begin{aligned}
  f(x) &= \int_x^\infty 2\mathrm{e}^{-ct^2/L^2}\mathrm{d}t \\
  &= \frac{L}{\sqrt{2c}}\int_{x\sqrt{2c}/L}^\infty 2\mathrm{e}^{-u^2/2}\mathrm{d}u && \left(u = \frac{t\sqrt{2c}}{L}\right) \\
  &= \frac{L\sqrt{2\pi}}{\sqrt{c}}\mathrm{P}\left\{|g| \geqslant \frac{x\sqrt{2c}}{L}\right\} \\
  &\sim \frac{L^2}{cx}\mathrm{e}^{-cx^2/L^2}, && \left(\mathrm{P}\{|g| \geqslant x\} \sim \frac{2}{x\sqrt{2\pi}}\mathrm{e}^{-x^2/2}\right) \\
  h(x,K) &= \int_x^\infty \mathrm{P}\{K|g| \geqslant t\}\mathrm{d}t \\
  &= 2K\int_{x/K}^\infty (1-\Phi(u))\mathrm{d}u \\
  &\sim \frac{2K^3}{x^2\sqrt{2\pi}}\mathrm{e}^{-x^2/(2K^2)}, && \left(\int_y^\infty (1-\Phi(u))\mathrm{d}u \sim \frac{1}{y^2\sqrt{2\pi}}\mathrm{e}^{-y^2/2}\right)
  \end{aligned}$$

  因此若满足 $f(x) \leqslant h(x,K)$，则两侧的幂次满足

  $$\frac{1}{2K^2} < \frac{c}{L^2} \Longrightarrow K > \frac{L}{\sqrt{2C}},$$

  其中 C 充分大，使得 $h(0,K) = \mathrm{E}[K|g|] \geqslant \mathrm{E}[|X|]$，$h(x,K) \geqslant f(x)$。

- $(\Longleftarrow)$

  令 $\Psi(t) = \mathrm{e}^{t^2/a^2}$，若 $|X| \precsim K|g|$，则

  $$\mathrm{E}[\mathrm{e}^{X^2/a^2}] = \mathrm{E}[\Psi(|X|)] \leqslant \mathrm{E}[\Psi(K|g|)] = \mathrm{E}[\mathrm{e}^{K^2g^2/a^2}] = \left(1 - \frac{2K^2}{a^2}\right)^{-1/2},$$

(注意到 $g^2 \sim \chi^2(1)$ 的 MGF 为 $\mathrm{E}[\mathrm{e}^{\lambda g^2}] = (1-2\lambda)^{-1/2}$ $(\lambda < 1/2)$，因此令 $\lambda = K^2/a^2$，即可得到最后一个等号。)

因此若满足 $\mathrm{E}[\mathrm{e}^{X^2/a^2}] \leqslant 2$，则满足

$$\left(1 - \frac{2K^2}{a^2}\right)^{-1/2} \leqslant 2 \Longrightarrow a > \sqrt{\frac{8}{3}}K,$$

即 $\|X\|_{\psi_2} \leqslant \sqrt{8/3}K$。

29 [**有界随机变量的 Hoeffding 不等式**] 利用定理 T2.7.3 (sub-Gaussian Hoeffding 不等式)，推导定理 T2.2.6 (有界随机变量的 Hoeffding 不等式)。

定理 T2.2.6：设 $\{X_N\}$ 是相互独立的，满足 $\mathrm{supp}(X_i) = [a_i, b_i]$，则对于任意的 $t > 0$，

$$\mathrm{P}\left\{\sum_{i=1}^N (X_i - \mathrm{E}[X_i]) \geqslant t\right\} \leqslant \exp\left(-\frac{2t^2}{\sum_{i=1}^N (b_i - a_i)^2}\right)。$$

定理 T2.7.3：设 $\{X_N\}$ 为相互独立的零均值 sub-Gaussian 分布，则对于任意的 $t \geqslant 0$，存在 $c > 0$，使得

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right| \geqslant t\right\} \leqslant 2\exp\left(-\frac{ct^2}{\sum_{i=1}^N \|X_i\|_{\psi_2}^2}\right)。$$

证明 (要利用定理 T2.7.3 (sub-Gaussian Hoeffding 不等式)，首先将 X_i 中心化。)

设中心化随机变量 $Y_i = X_i - \mathrm{E}[X_i]$，则 $\mathrm{supp}(Y_i)$ 的长度为 $b_i - a_i$，因此根据 Hoeffding 引理 (Q2.9 (Hoeffding 引理))，可得

$$\mathrm{E}[\exp(\lambda Y_i)] \leqslant \exp\left(\frac{\lambda^2 (b_i - a_i)^2}{8}\right)。$$

根据 sub-Gaussian 分布的 ψ_2 范数条件 $\|Y_i\|_{\psi_2} \leqslant CK$，令 $K^2 = (b_i - a_i)^2/8$，可得

$$\|Y_i\|_{\psi_2} \leqslant C \cdot \frac{b_i - a_i}{2\sqrt{2}} = C_1(b_i - a_i)。 \qquad \left(C_1 = \frac{C}{2\sqrt{2}}\right)$$

因此 Y_i 为 $C_1(b_i - a_i)$-sub-Gaussian 随机变量。

根据定理 T2.7.3 (sub-Gaussian Hoeffding 不等式)，可得

$$\mathrm{P}\left\{\left|\sum_{i=1}^N Y_i\right| \geqslant t\right\} \leqslant 2\exp\left(-\frac{ct^2}{\sum_{i=1}^N \|Y_i\|_{\psi_2}^2}\right),$$

其中

$$\sum_{i=1}^N \|Y_i\|_{\psi_2}^2 \leqslant \sum_{i=1}^N C_1^2 (b_i - a_i)^2 = C_1^2 \sum_{i=1}^N (b_i - a_i)^2,$$

将其代入，可得

$$\mathrm{P}\left\{\left|\sum_{i=1}^N (X_i - \mathrm{E}[X_i])\right| \geqslant t\right\} \leqslant 2\exp\left(-\frac{ct^2}{C_1^2 \sum_{i=1}^N (b_i - a_i)^2}\right),$$

即

$$\mathrm{P}\left\{\sum_{i=1}^N (X_i - \mathrm{E}[X_i]) \geqslant t\right\} \leqslant 2\exp\left(-\frac{C't^2}{\sum_{i=1}^N (b_i - a_i)^2}\right)。 \qquad \left(C' = \frac{c}{C_1^2}\right)$$

30 [**逆 Hoeffding 不等式**] 设 $\{X_N\}$ 为相互独立的中心化 K-sub-Gaussian 随机变量。证明：对于任意的 $\boldsymbol{a} \in \mathbb{R}^N$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N a_i X_i\right| \geqslant \frac{1}{2}\left(\sum_{i=1}^N a_i^2\right)^{1/2}\right\} \geqslant \frac{c}{K^4}。 \qquad (c > 0)$$

(注：此结论为例 E1.5.1 (完全抵消的概率) 的一个通用的定量版本，尽管它没有达到 1/2 的精确概率值。)

证明 • 将证明目标转化为高偏离形式

记 $S=\sum_{i=1}^N a_iX_i$，$\sigma^2=\sum_{i=1}^N a_i^2$，则

$$\mathrm{E}[S^2]=\mathrm{Var}(S)=\sum_{i=1}^N a_i^2\,\mathrm{Var}(X_i)=\sum_{i=1}^N a_i^2=\sigma^2,$$

因此证明目标转化为

$$\mathrm{P}\left\{|S|\geqslant\frac{1}{2}\sigma\right\}\geqslant\frac{c}{K^4},$$

即

$$\mathrm{P}\left\{S^2\geqslant\frac{1}{4}\sigma^2\right\}\geqslant\frac{c}{K^4}。$$

(回顾习题 Q1.16 (Paley-Zygmund 不等式)，

$$P\{Z>\theta\mathrm{E}[Z]\}\geqslant(1-\theta)^2\frac{(\mathrm{E}[Z])^2}{\mathrm{E}[Z^2]}。$$

要利用 Paley-Zygmund 不等式，只需令 $Z=S^2,\theta=1/4$，其中 $\mathrm{E}[S^2]$ 已知，$\mathrm{E}[S^4]$ 未知；之后只需控制 $\mathrm{E}[S^4]$ 即可。)

• 控制 $\mathrm{E}[S^4]$

根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\|S\|_{\psi_2}^2\leqslant C_1\sum_{i=1}^N a_i^2\|X_i\|_{\psi_2}^2\leqslant C_1\sum_{i=1}^N a_i^2K^2=C_1K^2\sigma^2,\qquad(C_1>0)$$

两侧开方，

$$\|S\|_{\psi_2}\leqslant\sqrt{C_1}K\sigma。$$

根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (2) (矩界) $(\mathrm{E}|Z|^p)^{1/p}\leqslant C\sqrt{p}\|Z\|_{\psi_2}$，令 $p=4$，可得

$$(\mathrm{E}[S^4])^{1/4}\leqslant C_2\sqrt{4}\|S\|_{\psi_2}=2C_2\|S\|_{\psi_2}\leqslant 2C_2(\sqrt{C_1}K\sigma),\qquad(C_2>0)$$

两侧取 4 次方，

$$\mathrm{E}[S^4]\leqslant C_3K^4\sigma^4。\qquad(C_3>0)$$

如此，利用习题 Q1.16 (Paley-Zygmund 不等式)，令 $Z=S^2$，$\theta=1/4$，可得

$$\mathrm{P}\left\{|S|\geqslant\frac{1}{2}\sigma\right\}=\mathrm{P}\left\{S^2\geqslant\frac{1}{4}\sigma^2\right\}\geqslant\left(1-\frac{1}{4}\right)^2\frac{(\mathrm{E}[S^2])^2}{\mathrm{E}[S^4]}=\frac{9}{16}\frac{\sigma^4}{C_3K^4\sigma^4}=\frac{c}{K^4}。\qquad\left(c=\frac{9}{16C_3}\right)$$

31 [**Hoeffding 不等式要求零均值**] 设 $\{X_N\}$ 是独立同分布的，满足对于任意的 $\boldsymbol{a}\in\mathbb{R}^N$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N a_iX_i\right|\geqslant t\right\}\leqslant 2\exp\left(-\frac{ct^2}{\|\boldsymbol{a}\|_2^2}\right)。\qquad(c>0)$$

证明：$\mathrm{E}[X_i]=0$。

证明 假设 $\mu=\mathrm{E}[X_1]\neq 0$，则令 $\boldsymbol{a}=(1,1,\cdots,1)$，可得

$$\mathrm{P}\{|S_N|\geqslant t\}\leqslant 2\exp\left(-\frac{ct^2}{N}\right)。\qquad(t\geqslant 0)$$

一方面，令 $t=N|\mu|/2$，可得

$$\begin{aligned}\mathrm{P}\left\{|S_N|\geqslant\frac{N|\mu|}{2}\right\}&\leqslant 2\exp\left(-\frac{c(N|\mu|/2)^2}{N}\right)\\&=2\exp\left(-\frac{cN^2\mu^2}{4N}\right)\\&=2\exp\left(-\frac{c\mu^2}{4}N\right)\to 0。\end{aligned}\qquad(\mathrm{I})$$

另一方面，根据 WLLN，可得对于任意的 $\varepsilon>0$，

$$\mathrm{P}\left\{\left|\frac{S_N}{N}-\mu\right|<\varepsilon\right\}\to 1,$$

令 $\varepsilon=|\mu|/2$，可得

$$\mathrm{P}\left\{|S_N|>\frac{N|\mu|}{2}\right\}\to 1, \tag{II}$$

这是矛盾的；如此，$\mu=0$。

32 [**和的 sub-Gaussian 范数**] 设 X,Y 为相互独立的零均值 sub-Gaussian 随机变量。证明：

$$\|X+Y\|_{\psi_2}\asymp\|X\|_{\psi_2}+\|Y\|_{\psi_2},$$

其中符号“$\asymp$”表示在相差绝对常数因子的意义下等价，即存在 $c,C>0$，使得

$$c(\|X\|_{\psi_2}+\|Y\|_{\psi_2})\leqslant\|X+Y\|_{\psi_2}\leqslant C(\|X\|_{\psi_2}+\|Y\|_{\psi_2})。$$

证明 • ($\lesssim$)

由于 $\|\cdot\|_{\psi_2}$ 为 Orlicz 空间的范数，因此利用三角不等式，可得

$$\|X+Y\|_{\psi_2}\leqslant\|X\|_{\psi_2}+\|Y\|_{\psi_2}。\qquad (C=1)$$

• ($\gtrsim$)

注意到

$$\mathrm{E}[X+Y\mid X]=X+\mathrm{E}[Y]=X,$$

因此利用 Jensen 不等式，令 $\phi(u)=\mathrm{e}^{u^2}$，可得

$$\exp\left(\frac{X^2}{t^2}\right)=\exp\left(\frac{(\mathrm{E}[X+Y\mid X])^2}{t^2}\right)\leqslant\mathrm{E}\left[\exp\left(\frac{(X+Y)^2}{t^2}\right)\middle|X\right],$$

两侧取期望，

$$\mathrm{E}\left[\exp\left(\frac{X^2}{t^2}\right)\right]\leqslant\mathrm{E}\left[\mathrm{E}\left[\exp\left(\frac{(X+Y)^2}{t^2}\right)\middle|X\right]\right]=\mathrm{E}\left[\exp\left(\frac{(X+Y)^2}{t^2}\right)\right],$$

令 $t=\|X+Y\|_{\psi_2}$，可得

$$\mathrm{E}\left[\exp\left(\frac{X^2}{\|X+Y\|_{\psi_2}^2}\right)\right]\leqslant\mathrm{E}\left[\exp\left(\frac{(X+Y)^2}{\|X+Y\|_{\psi_2}^2}\right)\right]\leqslant 2,$$

因此

$$\|X\|_{\psi_2}\leqslant\|X+Y\|_{\psi_2}。$$

($\|X\|_{\psi_2}$ 的定义是最小的合格参数，因此 $\|X\|_{\psi_2}\leqslant t=\|X+Y\|_{\psi_2}$。)

同理，根据对称性，可得

$$\|Y\|_{\psi_2}\leqslant\|X+Y\|_{\psi_2}。$$

如此，

$$\|X\|_{\psi_2}+\|Y\|_{\psi_2}\leqslant 2\|X+Y\|_{\psi_2}。$$

综上，

$$\frac{1}{2}(\|X\|_{\psi_2}+\|Y\|_{\psi_2})\leqslant\|X+Y\|_{\psi_2}\leqslant 1\cdot(\|X\|_{\psi_2}+\|Y\|_{\psi_2}),$$

即 $\|X+Y\|_{\psi_2}\asymp\|X\|_{\psi_2}+\|Y\|_{\psi_2}$。

33 [**独立同分布的和的 sub-Gaussian 范数**] 关于 Pythagorean 恒等式 (2.19，即 L^2 范数的平方和性质)，很自然地会考虑命题 P2.7.1 (和式的 sub-Gaussian 范数) 的不等式是否可以反向成立。在本题和下一题中，您将证明：若 $\{X_N\}$ 是独立同分布的，则答案是肯定的；但对于一般情况，答案是否定的。

(1) 设 $X, X_1, \cdots, X_N$ 为独立同分布的零均值 sub-Gaussian 随机变量。证明：

$$\left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2} \asymp \sqrt{N} \|X\|_{\psi_2}$$

(2) 设 $S_N \sim B(N, p)$，证明：

$$\|S_N - Np\|_{\psi_2} \asymp \sqrt{\frac{N}{\ln(2/p)}}。$$

证明 (1) ($\lesssim$)

根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2}^2 \leqslant C \sum_{i=1}^{N} \|X_i\|_{\psi_2}^2 = CN \|X\|_{\psi_2}^2, \qquad (C > 0)$$

两侧开方，

$$\left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2} \leqslant C' \sqrt{N} \|X\|_{\psi_2}。$$

($\gtrsim$)

记 $L = \|S_N\|_{\psi_2}$，则

$$\mathrm{E}[\exp(\lambda S_N)] \leqslant \exp(C_1 \lambda^2 L^2),$$

其中

$$\mathrm{E}\left[\exp\left(\lambda \sum_{i=1}^{N} X_i\right)\right] = \mathrm{E}\left[\prod_{i=1}^{N} \exp(\lambda X_i)\right] = \prod_{i=1}^{N} \mathrm{E}[\exp(\lambda X_i)] = (\mathrm{E}[\exp(\lambda X)])^N,$$

将其代入，可得

$$(\mathrm{E}[\exp(\lambda X)])^N \leqslant \exp(C_1 \lambda^2 L^2),$$

两侧开 N 次方，

$$\mathrm{E}[\exp(\lambda X)] \leqslant \exp\left(\frac{C_1 \lambda^2 L^2}{N}\right) := \exp(\lambda^2 \sigma^2), \qquad \left(\sigma^2 := \frac{C_1 L^2}{N}\right)$$

因此

$$\|X\|_{\psi_2} \leqslant c_2 \cdot \sigma = c_2 \sqrt{\frac{C_1}{N}} L = c_2 \sqrt{\frac{C_1}{N}} \left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2},$$

即

$$\left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2} \geqslant c_2 \sqrt{\frac{C_1}{N}} \|X\|_{\psi_2}。$$

(2) (同理于习题 Q2.29 (有界随机变量的 Hoeffding 不等式) 的证明过程，要利用 (1) 的结论，首先需要将普通随机变量中心化为 sub-Gaussian 随机变量。)

设 $S_N = \sum_{i=1}^{N} Y_i$，其中 $Y_i \sim \mathrm{Bernoulli}(p)$，记中心化随机变量 $X_i = Y_i - p$，则

$$S_N - Np = \sum_{i=1}^{N} (Y_i - p) = \sum_{i=1}^{N} X_i,$$

因此利用 (1) 的结论，可得

$$\|S_N - Np\|_{\psi_2} = \left\| \sum_{i=1}^{N} X_i \right\|_{\psi_2} \asymp \sqrt{N} \|X_1\|_{\psi_2},$$

从而只需证明

$$\|X_1\|_{\psi_2} \asymp \frac{1}{\sqrt{\ln(2/p)}}。$$

根据 sub-Gaussian 随机变量的定义，可得

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right] = \underbrace{p\cdot\exp\left(\frac{(1-p)^2}{K^2}\right)}_{I_1} + \underbrace{(1-p)\cdot\exp\left(\frac{p^2}{K^2}\right)}_{I_2} \leqslant 2,$$

(注意到上式关于 $p, 1-p$ 是对称的，因此不妨设 $p \leqslant 1/2$，只界定其中一项即可。)

对于上界，当 $p \leqslant 1/2$ 时，

$$I_1 = p\exp\left(\frac{(1-p)^2}{K^2}\right) \leqslant 2 \implies \frac{1}{4K^2} \leqslant \ln\left(\frac{2}{p}\right) \implies K \geqslant \frac{1}{2\sqrt{\ln(2/p)}},$$

即

$$\|X\|_{\psi_2} \geqslant \frac{c}{2\sqrt{\ln(2/p)}}。 \tag{I}$$

对于下界，代入 $K = C/\sqrt{\ln(2/p)}$ $(C \geqslant 1)$，可得

$$I_1 = p\exp\left(\frac{(1-p)^2}{K^2}\right) \leqslant p\exp\left(\frac{\ln(2/p)}{C^2}\right) = p\left(\frac{2}{p}\right)^{1/C^2} = 2^{1/C^2}p^{1-1/C^2} \leqslant 1,$$

$$I_2 = (1-p)\exp\left(\frac{p^2}{K^2}\right) \leqslant (1-p)\exp\left(\frac{p^2\ln(2/p)}{C^2}\right) \leqslant 1,$$

因此 $\mathrm{E}[\exp(X^2/K^2)] = I_1 + I_2 \leqslant 2$，可得

$$\|X\|_{\psi_2} \leqslant \frac{C}{\sqrt{\ln(2/p)}}。 \tag{II}$$

如此，联立 (I)(II)，可得

$$\|X_1\|_{\psi_2} \asymp \frac{1}{\sqrt{\ln(2/p)}}。$$

34 [非独立同分布的随机变量和的 sub-Gaussian 范数]

(1) 构造相互独立的零均值 sub-Gaussian 随机变量 $\{X_N\}$，使得对于任意的 $\boldsymbol{a} = (a_1, \cdots, a_N) \in \mathbb{R}^N$，均满足

$$\left\|\sum_{i=1}^N a_i X_i\right\|_{\psi_2} \asymp \|\boldsymbol{a}\|_\infty。$$

(2) 利用 (1) 的结论，证明命题 P2.7.1 (和式的 sub-Gaussian 范数) 的不等式 (sub-Gaussian 随机变量和的 Hoeffding 型不等式) 通常是不可逆的。

证明 (1) 不妨设 $\|\boldsymbol{a}\|_\infty = 1$。

- 构造稀疏的随机变量

  构造相互独立的随机变量列 $\{X_N\}$ 为

  $$\mathrm{P}\{X_i = \sqrt{i}\} = \mathrm{P}\{X_i = -\sqrt{i}\} = \frac{1}{2}\mathrm{e}^{-i},\ \mathrm{P}\{X_i = 0\} = 1 - \mathrm{e}^{-i}。$$

  则 $\{X_N\}$ 为 sub-Gaussian 随机变量列 (有界随机变量必定为 sub-Gaussian 随机变量)，满足 $\mathrm{E}[X_i] = 0$，$\mathrm{E}[|X_i|^p] = i^{p/2}\mathrm{e}^{-i}$，因此

  $$\|X_i\|_{L_p} = (i^{p/2}\mathrm{e}^{-i})^{1/p} = \sqrt{i}\mathrm{e}^{-i/p},$$

从而

$$\|X_i\|_{\psi_2} \asymp \sup_{p\geqslant 1}\frac{\sqrt{i}\mathrm{e}^{-i/p}}{\sqrt{p}} = \sup_{p\geqslant 1}\sqrt{\frac{i}{p}}\mathrm{e}^{-i/p},$$

右侧上确界的最优参数为 $u=i/p=1/2$，其值为 $1/\sqrt{2\mathrm{e}}$，将其代入，可得

$$\|X_i\|_{\psi_2} \asymp 1。$$

- 估计 $S=\sum_{i=1}^N a_iX_i$ 的上下界

  对于下界，利用 Jensen 不等式，可得

$$\|S\|_{\psi_2} \geqslant c\max_{1\leqslant i\leqslant N}\|a_iX_i\|_{\psi_2} = c\|\boldsymbol{a}\|_\infty \max_{1\leqslant i\leqslant N}\|X_i\|_{\psi_2} \asymp \|\boldsymbol{a}\|_\infty。 \tag{I}$$

  对于上界，利用独立随机变量和的 Rosenthal 不等式 (或者广义 Marcinkiewicz-Zygmund 不等式)，可得对于任意的 $p\geqslant 2$，

$$\|S\|_{L_p} \leqslant C\left[\underbrace{\sqrt{p}\left(\sum_{i=1}^N \mathrm{E}[a_i^2X_i^2]\right)^{1/2}}_{I_1} + \underbrace{\left(\sum_{i=1}^N \mathrm{E}[|a_iX_i|^p]\right)^{1/p}}_{I_2}\right],$$

  其中

$$\begin{aligned}
I_1 &= \sqrt{p}\left(\sum_{i=1}^N a_i^2 i\mathrm{e}^{-i}\right)^{1/2} \leqslant \sqrt{p}\left(\sum_{i=1}^\infty i\mathrm{e}^{-i}\right)^{1/2} \leqslant C_1\sqrt{p},\\
I_2 &= \left(\sum_{i=1}^N |a_i|^p i^{p/2}\mathrm{e}^{-i}\right)^{1/p} \leqslant \left(\sum_{i=1}^\infty i^{p/2}\mathrm{e}^{-i}\right)^{1/p}\\
&\sim \left(\int_0^\infty t^{p/2}\mathrm{e}^{-t}\mathrm{d}t\right)^{1/p} = \left(\Gamma\left(\frac{p}{2}+1\right)\right)^{1/p}\\
&\sim \left(\sqrt{2\pi\frac{p}{2}}\left(\frac{p}{2\mathrm{e}}\right)^{p/2}\right)^{1/p} \asymp \sqrt{p},
\end{aligned}$$

  将其代入，可得

$$\|S\|_{L_p} \leqslant C\sqrt{p}。 \tag{II}$$

  如此，联立 (I)(II)，可得

$$\|S\|_{\psi_2} \asymp \sup_{p\geqslant 2}\frac{\|S\|_{L_p}}{\sqrt{p}} \leqslant C = C\|\boldsymbol{a}\|_\infty,$$

  即

$$\left\|\sum_{i=1}^N a_iX_i\right\|_{\psi_2} \asymp \|\boldsymbol{a}\|_\infty。$$

(2) 命题 P2.7.1 (和式的 sub-Gaussian 范数) 为基于 ℓ_2 范数的上界，

$$\left\|\sum_{i=1}^N a_iX_i\right\|_{\psi_2} \leqslant C\sqrt{\sum_{i=1}^N a_i^2\|X_i\|_{\psi_2}^2} \asymp \sqrt{\sum a_i^2} = \|\boldsymbol{a}\|_2,$$

令 $\boldsymbol{a}=(1,1,\cdots,1)$，则命题 P2.7.1 (和式的 sub-Gaussian 范数) 的上界量级为 $\|\boldsymbol{a}\|_2=\sqrt{N}$，真实的 sub-Gaussian 范数量级为 $\|\boldsymbol{a}\|_\infty=1$，因此这是不可逆的。

35 [L^1 与 L^∞ 之间的插值] 关于练习 Q1.12 (L^1, L^∞ 之间的插值不等式)，我们展示了如何利用随机变量 X 的 L^1 范数和 L^∞ 范数的上界来界定其 L^p 范数。现在，让我们为 sub-Gaussian 范数证明一个类似的结果。

(1) 证明：若 $\|X\|_{L^1}=a$，$\|X\|_{L^\infty}=b$，则

$$\|X\|_{\psi_2}\leqslant\frac{Cb}{\sqrt{\ln(2b/a)}}。\qquad(C>0)$$

(2) 证明：对于任意的 $a\leqslant b$，(1) 的上界在绝对常数意义下是最佳的。

注释 倘若 (1) 的结论为

$$\|X\|_{\psi_2}\leqslant\frac{Cb}{\sqrt{\ln(b/a)}},$$

则当 $a\to b$ 时 (非稀疏情况)，上界将无意义地爆炸，因此出于防御目的，必须于对数内部增加常数偏置，或者为 $\ln(2b/a)$，或者为 $\ln(1+b/a)$。

证明 (1) 由于 $\mathrm{E}[|X|]=a$，$|X|\leqslant b$ (a.s.)，因此

$$\mathrm{E}[|X|^p]=\mathrm{E}[|X|\cdot|X|^{p-1}]\leqslant\mathrm{E}[|X|]\cdot\|X\|_{L^\infty}^{p-1}=a\cdot b^{p-1},$$

从而

$$\|X\|_{L^p}\leqslant\mathrm{E}[|X|^p]^{1/p}=(a\cdot b^{p-1})^{1/p}=b\left(\frac{a}{b}\right)^{1/p},$$

从而

$$\|X\|_{\psi_2}\leqslant C_0\sup_{p\geqslant1}\frac{\|X\|_{L^p}}{\sqrt{p}}\leqslant C_0\sup_{p\geqslant1}\frac{b(a/b)^{1/p}}{\sqrt{p}}=C_0\sup_{p\geqslant1}\frac{br^{1/p}}{\sqrt{p}}=:C_0\sup_{p\geqslant1}f(p),\qquad\left(r=\frac{a}{b}\in(0,1)\right)$$

$f(p)$ 的最优参数为 $p_0=2\ln(1/r)=2\ln(b/a)$，将其代入，可得：

a. 若 $p_0\geqslant1$，即 $b/a\geqslant\sqrt{\mathrm{e}}$，则

$$\max_{p\geqslant1}f(p)=f(p_0)=\frac{\mathrm{e}^{-1/2}}{\sqrt{2\ln(b/a)}},$$

其中 $\ln(2b/a)=\ln2+\ln(b/a)\leqslant(2\ln2+1)\ln(b/a)$，将其代入，可得

$$f(p_0)\leqslant\frac{C_1}{\sqrt{\ln(2b/a)}}。$$

b. 若 $p_0<1$，即 $1\leqslant b/a\leqslant\sqrt{\mathrm{e}}$，由于 $f(p)$ 于 $[1,+\infty)$ 是递减的，因此

$$\max_{p\geqslant1}f(p)=f(1)=\frac{a}{b},$$

其中 $\ln(2b/a)\leqslant\ln(2\sqrt{\mathrm{e}})$，将其代入，可得

$$\frac{a}{b}\leqslant1\leqslant\frac{\sqrt{\ln(2\sqrt{\mathrm{e}})}}{\sqrt{\ln(2b/a)}}=\frac{C_2}{\sqrt{\ln(2b/a)}}。$$

如此，

$$\|X\|_{\psi_2}=b\max_{p\geqslant1}f(p)\leqslant\frac{C_3b}{\sqrt{\ln(2b/a)}}。$$

(2) 对于任意的 $0<a\leqslant b$，构造 X 服从

$$\mathrm{P}\{X=b\}=\frac{a}{b},\ \mathrm{P}\{X=0\}=1-\frac{a}{b},$$

则 $\|X\|_{L^1}=b\cdot(a/b)+0\cdot(1-a/b)=a$，$\|X\|_{L^\infty}=b$。

记 $K=\|X\|_{\psi_2}$，则

$$\mathrm{E}\left[\exp\left(\frac{X^2}{K^2}\right)\right]=(1-p_0)\mathrm{e}^0+p_0\mathrm{e}^{b^2/K^2}=1-\frac{a}{b}+\frac{a}{b}\mathrm{e}^{b^2/K^2}\leqslant2\implies K\geqslant\frac{b}{\sqrt{\ln(2b/a)}}。$$

36 [$p<2$ 时的 **Khintchine 不等式**] 关于定理 T2.7.5 (Khintchine 不等式)，我们证明了对于 $p\in[2,\infty)$ 的 Khintchine 不等式。

现在将上述结果扩展到 $p \in [1,2]$ 的情况。

(1) (外推性质) 证明：对于任意 L^3 范数有限的随机变量 Z，均满足

$$\|Z\|_{L^2} \leqslant \|Z\|_{L^1}^{1/4} \|Z\|_{L^3}^{3/4}。$$

(2) 设 $\{X_N\}$ 为相互独立的中心化 K-sub-Gaussian 随机变量。证明：对于任意的 $\boldsymbol{a} \in \mathbb{R}^N$，

$$cK^{-3}\left(\sum_{i=1}^N a_i^2\right)^{1/2} \leqslant \mathrm{E}\left[\left|\sum_{i=1}^N a_i X_i\right|\right] \leqslant \left(\sum_{i=1}^N a_i^2\right)^{1/2}。 \qquad (c>0)$$

(3) 利用 (2) 的结论，证明：对于任意的 $p \in [1,2]$，上述关于和的 L^p 范数的不等式亦成立。

证明 (1) 利用 L^p 空间的插值性质 (Hölder 不等式或 Lyapunov 不等式)，可得对于 $1 \leqslant p < q < r$，若 $1/q = \theta/p + (1-\theta)/r$，则

$$\|Z\|_{L^q} \leqslant \|Z\|_{L^p}^{\theta} \|Z\|_{L^r}^{1-\theta},$$

令 $p=1, q=2, r=3$，此时 $\theta = 1/4$，可得

$$\|Z\|_{L^2} \leqslant \|Z\|_{L^1}^{1/4} \|Z\|_{L^3}^{3/4},$$

即

$$\mathrm{E}[Z^2]^{1/2} \leqslant (\mathrm{E}|Z|)^{1/4} (\mathrm{E}|Z|^3)^{1/4}。$$

(2) 设 $S = \sum_{i=1}^N a_i X_i$，则

$$\|S\|_{L^2} = (\mathrm{E}[S^2])^{1/2} = \left(\sum_{i=1}^N a_i^2 \operatorname{Var}(X_i)\right)^{1/2} = \left(\sum_{i=1}^N a_i^2\right)^{1/2}。$$

对于右侧，利用 Jensen 不等式，可得

$$\mathrm{E}|S| \leqslant (\mathrm{E}[S^2])^{1/2} = \|S\|_{L^2} \leqslant \left(\sum_{i=1}^N a_i^2\right)^{1/2}。$$

对于左侧，利用 (1) 的结论，可得 $\|S\|_{L^2} \leqslant \|S\|_{L^1}^{1/4} \|S\|_{L^3}^{3/4}$，即

$$\|S\|_{L^1} \geqslant \frac{\|S\|_{L^2}^4}{\|S\|_{L^3}^3}。$$

(之后只需计算 $\|S\|_{L^3}$ 的上界。)

根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得 S 为 sub-Gaussian 随机变量，其范数满足

$$\|S\|_{\psi_2} \leqslant C_1 \left(\sum_{i=1}^N a_i^2 \|X_i\|_{\psi_2}^2\right)^{1/2} \leqslant C_1 K \left(\sum_{i=1}^N a_i^2\right)^{1/2},$$

因此

$$\|S\|_{L^3} \leqslant C_2\sqrt{3}\|S\|_{\psi_2} \leqslant C_3 K \left(\sum_{i=1}^N a_i^2\right)^{1/2} = C_3 K \|S\|_{L^2},$$

将其代入，可得

$$\|S\|_{L^1} \geqslant \frac{\|S\|_{L^2}^4}{(C_3 K \|S\|_{L^2})^3} = \frac{1}{C_3^3 K^3}\|S\|_{L^2} = cK^{-3}\left(\sum_{i=1}^N a_i^2\right)^{1/2}。$$

(3) 对于任意的 $p \in [1,2]$，根据 L^p 范数的单调性，可得

$$\|S\|_{L^1} \leqslant \|S\|_{L^p} \leqslant \|S\|_{L^2}。$$

利用 (2) 的结论，可得对于左侧，

$$\|S\|_{L^p} \geqslant \|S\|_{L^1} \geqslant cK^{-3}\|S\|_{L^2} = cK^{-3}\left(\sum_{i=1}^N a_i^2\right)^{1/2},$$

对于右侧，

$$\|S\|_{L^p} \leqslant \|S\|_{L^2} = \left(\sum_{i=1}^N a_i^2\right)^{1/2},$$

如此，联立对于任意的 $p \in [1,2]$，

$$cK^{-3}\left(\sum_{i=1}^N a_i^2\right)^{1/2} \leqslant \left(\mathrm{E}\left|\sum_{i=1}^N a_i X_i\right|^p\right)^{1/p} \leqslant \left(\sum_{i=1}^N a_i^2\right)^{1/2}。$$

37 [**极大值不等式**] 证明命题 P2.7.6 (sub-Gaussian 随机变量的最大值) 的加强形式。

设 $\{X_N\}$ 为 sub-Gaussian 随机变量 (未必独立)。证明：

$$\left\|\sup_N \frac{X_N}{\sqrt{\ln(2N)}}\right\|_{\psi_2} \leqslant C \sup_N \|X_N\|_{\psi_2}。 \qquad (C>0)$$

证明 不妨设 $K = \max_i \|X_i\|_{\psi_2} = 1$，则只需证明

$$\left\|\sup_{i\geqslant 1} \frac{X_i}{\sqrt{\ln(2i)}}\right\|_{\psi_2} \leqslant C。$$

- 首先考虑正部

  对于 Y_+，对于任意的 $t \geqslant 0$，

  $$\mathrm{P}\{Y_+ \geqslant t\} = \mathrm{P}\left\{\exists i : \frac{X_i}{\sqrt{\ln(2i)}} \geqslant t\right\} \leqslant \sum_{i=1}^\infty \mathrm{P}\{X_i \geqslant t\sqrt{\ln(2i)}\},$$

  其中

  $$\mathrm{P}\{X_i \geqslant t\sqrt{\ln(2i)}\} \leqslant 2\mathrm{e}^{-(t\sqrt{\ln(2i)})^2/1} = 2\mathrm{e}^{-t^2\ln(2i)} = 2(2i)^{-t^2},$$

  将其代入，可得

  $$\mathrm{P}\{Y_+ \geqslant t\} \leqslant \sum_{i=1}^\infty 2(2i)^{-t^2} = 2^{1-t^2}\sum_{i=1}^\infty i^{-t^2} = 2^{1-t^2}\zeta(t^2)。$$

  对 t^2 的取值进行讨论：

  a. 若 $t^2 < 2$，即 $0 \leqslant t < \sqrt{2}$，则 $\mathrm{P}\{Y_+ \geqslant t\} \leqslant 1$，这是平凡的。

  b. 若 $t^2 \geqslant 2$，即 $t \geqslant \sqrt{2}$，此时 $\zeta(t^2) \leqslant \zeta(2) = \pi^2/6$，则

  $$\mathrm{P}\{Y_+ \geqslant t\} \leqslant 2^{1-t^2}\cdot\frac{\pi^2}{6} = \frac{\pi^2}{3}\mathrm{e}^{-t^2\ln 2}。$$

  因此

  $$\mathrm{P}\{Y_+ \geqslant t\} \leqslant A\mathrm{e}^{-c_0 t^2}, \qquad (A, c_0 > 0)$$

  从而 $\|Y_+\|_{\psi_2} \leqslant C_1$。

- 之后考虑负部

  对于 Y_-，由于 $Y \geqslant X_1/\sqrt{\ln 2}$，因此 $Y_- \leqslant X_1/\sqrt{\ln 2}$，可得

  $$\|Y_-\|_{\psi_2} \leqslant \frac{1}{\sqrt{\ln 2}}\|X_1\|_{\psi_2} \leqslant \frac{1}{\sqrt{\ln 2}},$$

  从而利用三角不等式，可得

  $$\|Y\|_{\psi_2} = \|Y_+ - Y_-\|_{\psi_2} \leqslant \|Y_+\|_{\psi_2} + \|Y_-\|_{\psi_2} \leqslant C_1 + \frac{1}{\sqrt{\ln 2}} = C。$$

综上，$\|Y\|_{\psi_2} \leqslant C$，即

$$\left\| \sup_{N\geqslant 1} \frac{X_N}{\sqrt{\ln(2N)}} \right\|_{\psi_2} \leqslant CK = C \sup_{N\geqslant 1} \|X_N\|_{\psi_2}。$$

38 [**Gaussian 随机变量的极大值**] 让我们为标准正态随机变量证明极大值不等式 (2.22) 的一个渐近紧 (asymptotically sharp) 的版本。

(1) 设 $g_1, \cdots, g_N \sim N(0,1)$ (未必独立)。证明：

$$\mathrm{E}\left[\max_{i\leqslant N} g_i\right] \leqslant \sqrt{2\ln N}，\ \mathrm{E}\left[\max_{i\leqslant N} |g_i|\right] \leqslant \sqrt{2\ln(2N)}。$$

(2) 设 $g_1, \cdots, g_N$ i.i.d. $\sim N(0,1)$。证明：

$$\mathrm{E}\left[\max_{i\leqslant N} g_i\right] = \sqrt{2\ln N}(1+o(1))，\ \mathrm{E}\left[\max_{i\leqslant N} |g_i|\right] = \sqrt{2\ln N}(1+o(1))。$$

证明 (1) • 利用 Jensen 不等式，可得对于任意的 $\lambda > 0$，

$$\exp\left(\lambda \mathrm{E}\left[\max_{i\leqslant N} g_i\right]\right) \leqslant \mathrm{E}\left[\exp\left(\lambda \max_{i\leqslant N} g_i\right)\right] = \mathrm{E}\left[\max_{i\leqslant N} \mathrm{e}^{\lambda g_i}\right]$$
$$\leqslant \sum_{i=1}^{N} \mathrm{E}[\mathrm{e}^{\lambda g_i}] = N\mathrm{e}^{\lambda^2/2},$$

两侧取对数，

$$\lambda \mathrm{E}\left[\max_{i\leqslant N} g_i\right] \leqslant \ln N + \frac{\lambda^2}{2} \implies \mathrm{E}\left[\max_{i\leqslant N} g_i\right] \leqslant \frac{\ln N}{\lambda} + \frac{\lambda}{2}.$$

右侧的最优参数为 $\lambda = \sqrt{2\ln N}$，将其代入，可得

$$\mathrm{E}\left[\max_{i\leqslant N} g_i\right] \leqslant \sqrt{2\ln N}。$$

• 注意到 $\max_{i\leqslant N} |g_i| = \max(g_1, \cdots, g_N, -g_1, \cdots, -g_N)$ 为 $2N$ 个标准正态随机变量的极大值，因此将 N 替换为 $2N$，可得

$$\mathrm{E}\left[\max_{i\leqslant N} |g_i|\right] \leqslant \sqrt{2\ln(2N)}。$$

(2) • 设 $M_N = \max_{i\leqslant N} g_i$，对于任意的 $\varepsilon > 0$，令阈值 $T_N = (1-\varepsilon)\sqrt{2\ln N}$，则

$$\mathrm{P}\{M_N \leqslant T_N\} = \prod_{i=1}^{N} \mathrm{P}\{g_i \leqslant T_N\} = (1 - \mathrm{P}\{g_1 > T_N\})^N \leqslant \exp(-N\mathrm{P}\{g_1 > T_N\}),$$

其中

$$\mathrm{P}\{g_1 > T_N\} \sim \frac{1}{(1-\varepsilon)\sqrt{2\ln N}\sqrt{2\pi}} \mathrm{e}^{-(1-\varepsilon)^2 \ln N} \qquad \left(\mathrm{P}\{g_1 > t\} \sim \frac{1}{t\sqrt{2\pi}} \mathrm{e}^{-t^2/2}\right)$$
$$= C_\varepsilon \frac{1}{\sqrt{\ln N} N^{(1-\varepsilon)^2}},$$

将其代入，可得

$$\mathrm{P}\{M_N \leqslant T_N\} \leqslant \exp\left(-C_\varepsilon \frac{N^{1-(1-\varepsilon)^2}}{\sqrt{\ln N}}\right) \to 0,$$

因此 $M_N > (1-\varepsilon)\sqrt{2\ln N}$ (w.h.p.)。

由于 M_N 是一致可积的 (其 sub-Gaussian 范数有界的)，因此

$$\liminf_{N\to\infty} \frac{\mathrm{E}[M_N]}{\sqrt{2\ln N}} \geqslant 1-\varepsilon,$$

从而利用 (1) 的结论

$$\frac{\mathrm{E}[M_N]}{\sqrt{2\ln N}} \leqslant 1,$$

可得

$$\mathrm{E}\left[\max_{i\leqslant N} g_i\right] = \sqrt{2\ln N}(1+o(1))。$$

- 由于 $\max_{i\leqslant N}|g_i| \geqslant \max_{i\leqslant N} g_i$，因此

$$\mathrm{E}\left[\max_{i\leqslant N}|g_i|\right] \geqslant \mathrm{E}\left[\max_{i\leqslant N} g_i\right] = \sqrt{2\ln N}(1+o(1)),$$

从而利用 (1) 的结论

$$\mathrm{E}\left[\max_{i\leqslant N}|g_i|\right] \leqslant \sqrt{2\ln(2N)} = \sqrt{2\ln N + 2\ln 2} = \sqrt{2\ln N}(1+o(1)),$$

可得

$$\mathrm{E}\left[\max_{i\leqslant N}|g_i|\right] = \sqrt{2\ln N}(1+o(1))。$$

注释 事实上，根据 Gumbel 分布，可得

$$\mathrm{E}\left[\max_{i} X_i\right] = \sqrt{2\ln n} - \frac{\ln\ln n + \ln(4\pi)}{2\sqrt{2\ln n}} \sim \sqrt{2\ln n},$$

39 [**sub-Gaussian 分布的刻画：极大值不等式**] 证明：X 为 sub-Gaussian 随机变量，当且仅当

$$\mathrm{E}\left[\max_{i\leqslant N}|X_i|\right] \leqslant K\sqrt{\ln N}。 \qquad (K>0)$$

其中 $\{X_N\}_{N\geqslant 2}$ 为 X 的独立副本。

注释 命题 P2.7.6 (sub-Gaussian 随机变量的最大值) 已经证明其必要性，即若 X 为 sub-Gaussian 随机变量，则存在 K，满足 $K\leqslant C\|X\|_{\psi_2}$，使得 (2.35) 成立。现在证明其充分性，即若 (2.35) 成立，则 X 为 sub-Gaussian 随机变量，满足 $\|X\|_{\psi_2}\leqslant CK$。

证明 要证明 X 为 sub-Gaussian 随机变量，只需证明对于任意的 $t\geqslant 0$，

$$p_t := \mathrm{P}\{|X|\geqslant t\} \leqslant 2\exp\left(-c\frac{t^2}{K^2}\right)。 \qquad (c>0)$$

对 p_t 的取值进行讨论：

a. (大偏差情形) 若 $p_t \leqslant 1/2$，即 $t\geqslant 2K\sqrt{\ln 2}$，则令 $N=\lfloor 1/p_t\rfloor \geqslant 2$，可得

$$\mathrm{E}\left[\max_{i\leqslant N}|X_i|\right] \geqslant t\cdot \mathrm{P}\left\{\max_{i\leqslant N}|X_i|\geqslant t\right\} = t(1-(1-p_t)^N),$$

其中

$$1-(1-p_t)^N \geqslant 1-\mathrm{e}^{-Np_t} \geqslant 1-\mathrm{e}^{-1/2} =: c_0>0,$$

将其代入，可得

$$c_0 t \leqslant \mathrm{E}\left[\max_{i\leqslant N}|X_i|\right] \leqslant K\sqrt{\ln N} \leqslant K\sqrt{\ln\left(\frac{1}{p_t}\right)} \implies p_t \leqslant \exp\left(-\frac{c_0^2t^2}{K^2}\right)。$$

b. 若 $p_t > 1/2$，即 $0\leqslant t < 2K\sqrt{\ln 2}$，则

$$\frac{c_0^2t^2}{K^2} < \frac{c_0^2\cdot(2K\sqrt{\ln 2})^2}{K^2} = 4c_0^2\ln 2 < \ln 2 \implies 2\exp\left(-\frac{c_0^2t^2}{K^2}\right) > 1,$$

因此

$$p_t \leqslant 1 < 2\exp\left(-\frac{c_0^2t^2}{K^2}\right)。$$

综上，对于任意的 $t\geqslant 0$，均满足

$$\mathrm{P}\{|X|\geqslant t\} \leqslant 2\exp\left(-c\frac{t^2}{K^2}\right)。$$

40 [**精准视角：精确 sub-Gaussian 范数**] 经典的 sub-Gaussian 范数的结果通常仅在绝对常数因子的意义下成立。为了获得更

加精确的精确界，我们可以利用命题 P2.6.1 (sub-Gaussian 性质) 的等价性质 (4)，重新定义 sub-Gaussian 范数。

回忆 $X \sim N(\mu, \sigma^2)$ 的 MGF 为 $\mathrm{E}[\exp(\lambda(X-\mu))] = \exp(\sigma^2\lambda^2/2)$，$L^2$ 范数为 $\|X\|_{L^2}^2 = \mathrm{E}[X^2] = \mathrm{Var}(X) + (\mathrm{E}[X])^2$。受此启发，定义 X 的 sub-Gaussian 方差为

$$\mathrm{Var}_G(X) = \inf\left\{\sigma^2 : \mathrm{E}[\exp(\lambda(X-\mathrm{E}[X]))] \leqslant \exp\left(\frac{\sigma^2\lambda^2}{2}\right)\right\},$$

X 的精确 sub-Gaussian 范数为

$$\|X\|_G^2 = \mathrm{Var}_G(X) + (\mathrm{E}[X])^2。$$

证明：

(1) (范数公理) $\|\cdot\|_G$ 于 sub-Gaussian 随机变量空间为范数。

(2) (范数等价性) 精确 sub-Gaussian 范数等价于标准 sub-Gaussian 范数，即

$$\|X\|_{\psi_2} \asymp \|X\|_G。$$

(3) (与 L^2 矩的比较)

$$\mathrm{Var}(X) \leqslant \mathrm{Var}_G(X)，\ \|X\|_{L^2} \leqslant \|X\|_G，$$

当且仅当 X 服从正态分布时，等号成立。

(4) (独立和的可加性) 若 $\{X_N\}$ 是相互独立的，则

$$\mathrm{Var}_G(\sum_{i=1}^N X_i) \leqslant \sum_{i=1}^N \mathrm{Var}_G(X_i)；$$

若 $\mathrm{E}[X_i] = 0$，则

$$\left\|\sum_{i=1}^N X_i\right\|_G^2 \leqslant \sum_{i=1}^N \|X_i\|_G^2，$$

即为命题 P2.7.1 (和式的 sub-Gaussian 范数) 的精确版本。

(5) (精确中心化不等式)

$$\|X - \mathrm{E}[X]\|_G \leqslant \|X\|_G，$$

即为引理 L2.7.8 (中心化) 的精确版本。

注释 在证明 (1) 之前，首先证明以下引理：

引理 ($\sigma_G(\cdot)$ 的次可加性) 定义

$$\sigma_G(X) = \sqrt{\mathrm{Var}_G(X)} = \inf\left\{\sigma : \mathrm{E}[\exp(\lambda(X-\mathrm{E}[X]))] \leqslant \exp\left(\frac{\sigma^2\lambda^2}{2}\right)\right\},$$

则 $\sigma_G(\cdot)$ 满足次可加性。

利用 Hölder 不等式，令 $p, q > 1$ 满足 $1/p + 1/q = 1$，可得

$$\begin{aligned}
\mathrm{E}[\exp(\lambda(X+Y-\mathrm{E}[X+Y]))] &= \mathrm{E}[\exp(\lambda(X-\mathrm{E}[X])) \cdot \exp(\lambda(Y-\mathrm{E}[Y]))] \\
&\leqslant (\mathrm{E}[\exp(p\lambda(X-\mathrm{E}[X]))])^{1/p} (\mathrm{E}[\exp(q\lambda(Y-\mathrm{E}[Y]))])^{1/q} \\
&\leqslant \left(\exp\left(\frac{\sigma_G(X)^2(p\lambda)^2}{2}\right)\right)^{1/p} \left(\exp\left(\frac{\sigma_G(Y)^2(q\lambda)^2}{2}\right)\right)^{1/q} \\
&= \exp\left(\frac{(p\sigma_G(X)^2 + q\sigma_G(Y)^2)\lambda^2}{2}\right)。
\end{aligned}$$

注意到

$$\min_{\substack{p,q>1 \\ 1/p+1/q=1}} (pA^2 + qB^2) = \frac{A+B}{A}A^2 + \frac{A+B}{B}B^2 = (A+B)^2，$$

因此令 $A=\sigma_G(X), B=\sigma_G(Y)$，将其代入，可得

$$\mathrm{E}[\exp(\lambda(X+Y-\mathrm{E}[X+Y]))]\leqslant\exp\left(\frac{(\sigma_G(X)+\sigma_G(Y))^2\lambda^2}{2}\right),$$

从而根据 $\mathrm{Var}_G(\cdot)$ 的定义，可得 $\sigma_G(X+Y)\leqslant\sigma_G(X)+\sigma_G(Y)$。

证明 (1) 要证明 $\|X\|_G$ 是范数，只需证明：

1. 非负性：

   由于 $\mathrm{Var}_G(X)\geqslant 0$，$(\mathrm{E}[X])^2\geqslant 0$，因此 $\|X\|_G\geqslant 0$。

2. 齐次性：

   由于 $\mathrm{Var}_G(\alpha X)=\alpha^2\mathrm{Var}_G(X)$ (通过 $\lambda\to\alpha\lambda$ 代换即可得到)，$\mathrm{E}[\alpha X]^2=\alpha^2(\mathrm{E}[X])^2$，因此 $\|\alpha X\|_G=|\alpha|\|X\|_G$。

3. 三角不等式：

   根据引理，利用 Minkowski 不等式，可得

$$\begin{aligned}\|X+Y\|_G&=\sqrt{\sigma_G(X+Y)^2+(\mathrm{E}[X+Y])^2}\\&\leqslant\sqrt{(\sigma_G(X)+\sigma_G(Y))^2+(\mathrm{E}[X]+\mathrm{E}[Y])^2}&(\sigma_G(\cdot)\text{ 的次可加性})\\&\leqslant\sqrt{\sigma_G(X)^2+(\mathrm{E}[X])^2}+\sqrt{\sigma_G(Y)^2+(\mathrm{E}[Y])^2}\\&=\|X\|_G+\|Y\|_G。\end{aligned}$$

(2) 要证明 $\|X\|_{\psi_2}\asymp\|X\|_G$，只需证明 $c_1\|X\|_{\psi_2}\leqslant\|X\|_G\leqslant c_2\|X\|_{\psi_2}$。

- 证明 $\|X\|_G\leqslant c_2\|X\|_{\psi_2}$

  只需证明 $\|X\|_G^2=\mathrm{Var}_G(X)+(\mathrm{E}[X])^2$ 的任意的部分均被 $\|X\|_{\psi_2}^2$ 控制。

  对于 $\mathrm{Var}_G(X)$，根据命题 P2.6.1 (sub-Gaussian 性质)，可得

$$\mathrm{E}[\exp(\lambda(X-\mathrm{E}[X]))]\leqslant\exp(C\lambda^2\|X\|_{\psi_2}^2),$$

  因此根据 $\mathrm{Var}_G(\cdot)$ 的定义 (Q2.40 (精准视角：精确 sub-Gaussian 范数))，可得

$$\frac{1}{2}\mathrm{Var}_G(X)\leqslant C\|X\|_{\psi_2}^2\implies\mathrm{Var}_G(X)\leqslant 2C\|X\|_{\psi_2}^2。\tag{I}$$

  对于 $(\mathrm{E}[X])^2$，根据范数的性质 (Q1.16 (Paley-Zygmund 不等式))，可得 (绝对期望小于等于二阶矩，而二阶矩受限于 sub-Gaussian 范数)

$$|\mathrm{E}[X]|\leqslant\|X\|_{L^2}\leqslant C'\|X\|_{\psi_2}\implies(\mathrm{E}[X])^2\leqslant(C')^2\|X\|_{\psi_2}^2。\tag{II}$$

  如此，联立 (I)(II)，可得

$$\|X\|_G^2\leqslant(2C+(C')^2)\|X\|_{\psi_2}^2=:c_2\|X\|_{\psi_2}。\qquad(c_2=2C+(C')^2)$$

- 证明 $c_1\|X\|_{\psi_2}\leqslant\|X\|_G$

  根据 $\mathrm{Var}_G(\cdot)$ 的定义，可得

$$\mathrm{E}[\exp(\lambda(X-\mathrm{E}[X]))]\leqslant\exp\left(\frac{\mathrm{Var}_G(X)\lambda^2}{2}\right),$$

  因此根据 sub-Gaussian 分布的等价性质 (或者利用 Chernoff 不等式)，可得

$$\mathrm{P}\{|X-\mathrm{E}[X]|\geqslant t\}\leqslant 2\exp\left(-\frac{t^2}{2\,\mathrm{Var}_G(X)}\right),$$

  因此

$$\|X-\mathrm{E}[X]\|_{\psi_2}\leqslant C''\sqrt{\mathrm{Var}_G(X)},$$

  从而利用三角不等式，可得

$$\|X\|_{\psi_2}=\|(X-\mathrm{E}[X])+\mathrm{E}[X]\|_{\psi_2}\leqslant\|X-\mathrm{E}[X]\|_{\psi_2}+\|\mathrm{E}[X]\|_{\psi_2}\leqslant C''\sqrt{\mathrm{Var}_G(X)}+C'''|\mathrm{E}[X]|。$$

(3) 将 $\exp(\lambda(X-\mathrm{E}[X]))$ 于 $\lambda=0$ 进行 Taylor 展开，

$$\mathrm{E}[\exp(\lambda(X-\mathrm{E}[X]))]=1+\lambda\mathrm{E}[X-\mathrm{E}[X]]+\frac{\lambda^2}{2}\mathrm{E}[(X-\mathrm{E}[X])^2]+o(\lambda^2)$$

$$= 1 + \frac{\lambda^2}{2}\operatorname{Var}(X) + o(\lambda^2),$$

其中根据 $\operatorname{Var}_G(\cdot)$ 的定义，可得

$$1 + \frac{\lambda^2}{2}\operatorname{Var}(X) + o(\lambda^2) \leqslant \exp\left(\frac{\operatorname{Var}_G(X)\lambda^2}{2}\right) = 1 + \frac{\lambda^2}{2}\operatorname{Var}_G(X) + o(\lambda^2),$$

因此 $\operatorname{Var}(X) \leqslant \operatorname{Var}_G(X)$，即 $\|X\|_{L^2}^2 \leqslant \|X\|_G^2$。

(4) 令 $S = \sum_{i=1}^N X_i$，可得

$$\mathrm{E}[\mathrm{e}^{\lambda S}] = \prod_{i=1}^N \mathrm{E}[\mathrm{e}^{\lambda X_i}] \leqslant \prod_{i=1}^N \exp\left(\frac{\operatorname{Var}_G(X_i)\lambda^2}{2}\right) = \exp\left(\frac{(\sum_{i=1}^N \operatorname{Var}_G(X_i))\lambda^2}{2}\right),$$

因此根据 $\operatorname{Var}_G(\cdot)$ 的定义，可得

$$\operatorname{Var}_G(S) \leqslant \sum_{i=1}^N \operatorname{Var}_G(X_i)。$$

由于 $\mathrm{E}[X_i] = 0$，因此 $\|S\|_G^2 = \operatorname{Var}_G(S)$，$\|X_i\|_G^2 = \operatorname{Var}_G(X_i)$，从而

$$\|S\|_G^2 \leqslant \sum_{i=1}^N \|X_i\|_G^2。$$

(5) 根据 $\|X\|_G$ 的极小性定义，可得

$$\|X - \mathrm{E}[X]\|_G^2 = \operatorname{Var}_G(X - \mathrm{E}[X]) + (\mathrm{E}[X - \mathrm{E}[X]])^2 = \operatorname{Var}_G(X) + 0 = \operatorname{Var}_G(X) \leqslant \|X\|_G^2,$$

即 $\|X - \mathrm{E}[X]\|_G \leqslant \|X\|_G$，这避免了标准 sub-Gaussian 范数的中心化可能导致的常数因子增加。

41 [**sub-Gaussian 分布的性质**] 通过修改命题 P2.6.1 (sub-Gaussian 性质) 的证明过程，证明命题 P2.8.1 (sub-Exponential 性质) 的性质 (1) ∼ (3) 的等价性。

根据命题 P2.8.1 (sub-Exponential 性质)，设 X 为随机变量，则以下性质是等价的，其参数 $K_i > 0$ 之间最多相差一个常数因子。

(1) (尾概率) 对于任意的 $t \geqslant 0$，存在 $K_1 > 0$，使得

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\exp\left(-\frac{t}{K_1}\right)。$$

(2) (矩时) 存在 $K_2 > 0$，使得对于任意的 $p \geqslant 1$，

$$\|X\|_{L^p} = (\mathrm{E}[|X|^p])^{1/p} \leqslant K_2 p。$$

(3) ($|X|$ 的矩母函数) 存在 $K_3 > 0$，使得

$$\mathrm{E}\left[\exp\left(\frac{|X|}{K_3}\right)\right] \leqslant 2。$$

证明 (我们将按照 (1) $\Longrightarrow$ (2) $\Longrightarrow$ (3) $\Longrightarrow$ (1) 的顺序证明循环等价性。)

- (1) $\Longrightarrow$ (2)

  若 $\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{e}^{-t/K_1}$，则

$$\begin{aligned}
\mathrm{E}[|X|^p] &= \int_0^\infty pt^{p-1}\mathrm{P}\{|X| \geqslant t\}\mathrm{d}t \\
&\leqslant \int_0^\infty pt^{p-1} \cdot 2\mathrm{e}^{-t/K_1}\mathrm{d}t \\
&\leqslant 2pK_1^p \int_0^\infty v^{p-1}\mathrm{e}^{-v}\mathrm{d}v \qquad \left(v = \frac{t}{K_1}\right) \\
&= 2pK_1^p\Gamma(p) = 2K_1^p\Gamma(p+1)。
\end{aligned}$$

  利用 Stirling 公式 $\Gamma(p+1) \sim \sqrt{2\pi p}(p/\mathrm{e})^p$，可得存在 $C > 0$，使得 $\Gamma(p+1)^{1/p} \leqslant Cp$，因此

$$\|X\|_{L^p} \leqslant (2\Gamma(p+1))^{1/p}K_1 \leqslant K_2 p, \qquad (K_2 \leqslant CK_1)$$

- (2) $\Longrightarrow$ (3)

  若 $\|X\|_{L^p} \leqslant K_2 p$，则 $\mathrm{E}[|X|^p] \leqslant (K_2 p)^p$。

  考虑 $\exp(|X|/K)$ 的 Taylor 展开，

$$\mathrm{E}\left[\exp\left(\frac{|X|}{K}\right)\right] = \mathrm{E}\left[\sum_{p=0}^{\infty} \frac{(|X|/K)^p}{p!}\right] = 1 + \sum_{p=1}^{\infty} \frac{\mathrm{E}[|X|^p]}{K^p p!}$$
$$\leqslant 1 + \sum_{p=1}^{\infty} \frac{(K_2 p)^p}{K^p p!} \leqslant 1 + \sum_{p=1}^{\infty} \left(\frac{\mathrm{e} K_2}{K}\right)^p \qquad \left(p! \geqslant \left(\frac{p}{\mathrm{e}}\right)^p\right)$$

  因此令 $K_3 = 2\mathrm{e}K_2$，当 $K \geqslant K_3$ 时，

$$\mathrm{E}\left[\exp\left(\frac{|X|}{K_3}\right)\right] \leqslant 1 + \sum_{p=1}^{\infty} \left(\frac{1}{2}\right)^p = 1 + 1 = 2。$$

- (3) $\Longrightarrow$ (1)

  若 $\mathrm{E}[\exp(|X|/K_3)] \leqslant 2$，则利用 Chernoff 界，可得

$$\mathrm{P}\{|X| \geqslant t\} = \mathrm{P}\left\{\exp\left(\frac{|X|}{K_3}\right) \geqslant \exp\left(\frac{t}{K_3}\right)\right\} \leqslant \frac{\mathrm{E}[\exp(|X|/K_3)]}{\exp(t/K_3)} \leqslant 2\mathrm{e}^{-t/K_3},$$

  因此令 $K_1 = K_3$。

42 [**鸟瞰视角：Orlicz 范数**] 这是一个通用的框架，涵盖了目前见过的绝大多数范数。

设 $\psi : \mathbb{R}_0^+ \to \mathbb{R}_0^+$ 为非减的凸函数，满足 $\psi(0) = 0$，定义随机变量 X 的 Orlicz 范数为

$$\|X\|_\psi = \inf\left\{K > 0 : \mathrm{E}\left[\psi\left(\frac{|X|}{K}\right)\right] \leqslant 1\right\}。$$

(1) 证明：全体满足 $X_\psi < \infty$ 的随机变量所构成的集合于此定义构成规范的线性范数空间。

(2) 证明：L^p $(1 \leqslant p < \infty)$ 范数, sub-Gaussian 范数 $\|X\|_{\psi_2}$, sub-Exponential 范数 $\|X\|_{\psi_1}$ 均为 Orlicz 范数的特例。

证明 (1) 设 $\mathcal{L}_\psi$ 为所有满足 $\|X\|_\psi < \infty$ 的随机变量所构成的空间。

1. 非负性, 定性：

   容易知道，$\|X\|_\psi \geqslant 0$。

   若 $\|X\|_\psi = 0$，则对于任意的 $K > 0$，均满足 $\mathrm{E}[\psi(|X|/K)] \leqslant 1$。

   假设 $X \neq 0$ (a.s.)，则若存在 $\varepsilon > 0$，使得 $\mathrm{P}\{|X| > \varepsilon\} > 0$，因此

$$\lim_{K \to 0} \psi\left(\frac{\varepsilon}{K}\right) \to \infty,$$

   从而

$$\lim_{K \to 0} \mathrm{E}\left[\psi\left(\frac{\varepsilon}{K}\right)\right] \to \infty,$$

   与 $\mathrm{E}[\psi(|X|/K)] \leqslant 1$ 矛盾；如此，$X = 0$ (a.s.)。

2. 齐次性：

   只需证明

$$\|\alpha X\|_\psi = \inf\left\{K > 0 : \mathrm{E}\left[\psi\left(\frac{|\alpha X|}{K}\right)\right] \leqslant 1\right\},$$

   若 $\alpha = 0$，则结论是平凡的；之后只需考虑 $\alpha \neq 0$ 的情况。

   令 $K' = K/|\alpha|$，即 $K = |\alpha| K'$，则

$$\inf\left\{|\alpha| K' > 0 : \mathrm{E}\left[\psi\left(\frac{|X|}{K'}\right)\right] \leqslant 1\right\} = |\alpha| \inf\left\{K' > 0 : \mathrm{E}\left[\psi\left(\frac{|X|}{K'}\right)\right] \leqslant 1\right\} = |\alpha| \|X\|_\psi。$$

3. 三角不等式：

   设 $\|X\|_\psi = K_X$，$\|Y\|_\psi = K_Y$，则 $\mathrm{E}[\psi(|X|/K_X)], \mathrm{E}[\psi(|Y|/K_Y)] \leqslant 1$。

利用 ψ 的凸性，可得

$$\begin{aligned}\psi\left(\frac{|X+Y|}{K_X+K_Y}\right) &\leqslant \psi\left(\frac{|X|+|Y|}{K_X+K_Y}\right)\\ &= \psi\left(\frac{K_X}{K_X+K_Y}\cdot\frac{|X|}{K_X}+\frac{K_Y}{K_X+K_Y}\cdot\frac{|Y|}{K_Y}\right),\end{aligned}$$

两侧取期望，

$$\begin{aligned}\mathrm{E}\left[\psi\left(\frac{|X+Y|}{K_X+K_Y}\right)\right] &\leqslant \frac{K_X}{K_X+K_Y}\mathrm{E}\left[\psi\left(\frac{|X|}{K_X}\right)\right]+\frac{K_Y}{K_X+K_Y}\mathrm{E}\left[\psi\left(\frac{|Y|}{K_Y}\right)\right]\\ &\leqslant \frac{K_X}{K_X+K_Y}\cdot 1+\frac{K_Y}{K_X+K_Y}\cdot 1=1,\end{aligned}$$

因此根据下确界的定义，可得 $\|X+Y\|_\psi \leqslant \|X\|_\psi+\|Y\|_\psi$。

(2) • L^p 范数 $\|X\|_{L^p}$

令 $\psi(x)=x^p$ $(p\geqslant 1)$，满足 ϕ_1 于 $\mathbb{R}_0^+$ 是非减凸的，$\phi(0)=0$，则

$$\|X\|_\psi=\inf\{K>0:\mathrm{E}[|X|^p/K^p]\leqslant 1\}=\inf\{K>0:\mathrm{E}[|X|^p]\leqslant K^p\}=(\mathrm{E}[|X|^p])^{1/p}=\|X\|_{L^p}。$$

• sub-Gaussian 范数 $\|X\|_{\psi_2}$

令 $\psi_2(x)=\mathrm{e}^{x^2}-1$，满足 ϕ_2 于 $\mathbb{R}_0^+$ 是非减凸的，$\phi_2(0)=0$，则

$$\|X\|_{\psi_2}=\inf\{K>0:\mathrm{E}[\mathrm{e}^{X^2/K^2}-1]\leqslant 1\}=\inf\{K>0:\mathrm{E}[\mathrm{e}^{X^2/K^2}]\leqslant 2\}。$$

• sub-Exponential 范数 $\|X\|_{\psi_1}$：

令 $\psi_1(x)=\mathrm{e}^x-1$，满足 ϕ_1 于 $\mathbb{R}_0^+$ 是非减凸的，$\phi_1(0)=0$，则

$$\|X\|_{\psi_1}=\inf\{K>0:\mathrm{E}[\mathrm{e}^{|X|/K}-1]\leqslant 1\}=\inf\{K>0:\mathrm{E}[\mathrm{e}^{|X|/K}]\leqslant 2\}。$$

43 [ψ_α **分布**] 考虑其尾概率以 $\exp(-ct^\alpha)$ 或更快的速率衰减的分布族。当 $\alpha=2$ 时，即为 sub-Gaussian 分布；当 $\alpha=1$ 时，即为 sub-Exponential 分布。针对此类分布，给出命题 P2.8.1 (sub-Exponential 性质) (i)-(iii) 的推广版本，定义对应的 ψ_α 范数，并证明上述性质的等价性。

(1) (尾概率) 存在 $K_1>0$，使得对于任意的 $t\geqslant 0$，均满足 $\mathrm{P}\{|X|\geqslant t\}\leqslant 2\exp(-(t/K_1)^\alpha)$。

(2) (矩时) 存在 $K_2>0$，使得对于任意的 $p\geqslant 1$，均满足 $\|X\|_{L^p}=(\mathrm{E}[|X|^p])^{1/p}\leqslant K_2p^{1/\alpha}$。

(3) (矩母函数) 存在 $K_3>0$，使得 $\mathrm{E}[\exp(|X|^\alpha/K_3^\alpha)]\leqslant 2$。

证明 (我们将按照 (1) $\Longrightarrow$ (2) $\Longrightarrow$ (3) $\Longrightarrow$ (1) 的顺序证明循环等价性。)

• (1) $\Longrightarrow$ (2)

容易知道，

$$\begin{aligned}\mathrm{E}[|X|^p] &= \int_0^\infty pt^{p-1}\mathrm{P}\{|X|\geqslant t\}\mathrm{d}t\\ &\leqslant \int_0^\infty pt^{p-1}\cdot 2\mathrm{e}^{-(t/K_1)^\alpha}\mathrm{d}t\\ &\leqslant \frac{2pK_1^p}{\alpha}\int_0^\infty v^{p/\alpha-1}\mathrm{e}^{-v}\mathrm{d}v \qquad \left(v=\left(\frac{t}{K_1}\right)^\alpha\right)\\ &= \frac{2pK_1^p}{\alpha}\Gamma\left(\frac{p}{\alpha}\right)=2K_1^p\Gamma\left(\frac{p}{\alpha}+1\right)。\end{aligned}$$

根据 Stirling 公式，可得存在 $C>0$，使得 $\Gamma(p/\alpha+1)^{1/p}\leqslant Cp^{1/\alpha}$，因此

$$\|X\|_{L^p}\leqslant(2\Gamma(p/\alpha+1))^{1/p}K_1\leqslant K_2p^{1/\alpha}, \qquad (K_2\leqslant CK_1)$$

• (2) $\Longrightarrow$ (3)

若 $\|X\|_{L^p}\leqslant K_2p^{1/\alpha}$，则 $\mathrm{E}[|X|^{\alpha k}]\leqslant(K_2(\alpha k)^{1/\alpha})^{\alpha k}=K_2^{\alpha k}\alpha^k k^k$。

考虑 $\exp(|X|^\alpha/K^\alpha)$ 的 Taylor 展开，

$$\begin{aligned}\mathrm{E}\left[\exp\left(\frac{|X|^\alpha}{K^\alpha}\right)\right] &= 1+\sum_{k=1}^{\infty}\frac{\mathrm{E}[|X|^{\alpha k}]}{K^{\alpha k}k!}\\ &\leqslant 1+\sum_{k=1}^{\infty}\frac{K_2^{\alpha k}\alpha^k k^k}{K^{\alpha k}k!}\\ &\leqslant 1+\sum_{k=1}^{\infty}\left(\frac{\mathrm{e}\alpha K_2^\alpha}{K^\alpha}\right)^k \qquad (k!\geqslant (k/\mathrm{e})^k)\end{aligned}$$

因此令 $K_3^\alpha = 2\mathrm{e}\alpha K_2^\alpha$，当 $K\geqslant K_3$ 时，

$$\mathrm{E}\left[\exp\left(\frac{|X|^\alpha}{K_3^\alpha}\right)\right]\leqslant 2。$$

- (3) $\Longrightarrow$ (1)

  利用 Chernoff 界，可得

$$\mathrm{P}\{|X|\geqslant t\} = \mathrm{P}\left\{\exp\left(\frac{|X|^\alpha}{K_3^\alpha}\right)\geqslant \exp\left(\frac{t^\alpha}{K_3^\alpha}\right)\right\}\leqslant 2\mathrm{e}^{-(t/K_3)^\alpha},$$

  因此令 $K_1 = K_3$。

44 [**sub-Exponential 分布性质的推广**] sub-Gaussian 随机变量的许多性质在经过适当修正之后，都可以平行地推广于 sub-Exponential 随机变量。

定义 X 的 sub-Exponential 范数为

$$\|X\|_{\psi_1} = \inf\{t>0:\mathrm{E}[\exp(|X|/t)]\leqslant 2\},$$

证明以下性质：

(1) 中心化性质 (Centering，引理 L2.7.8 (中心化))：若 X 为 sub-Exponential 随机变量，则

$$\|X-\mathrm{E}[X]\|_{\psi_1}\leqslant C\|X\|_{\psi_1}。 \qquad (C>0)$$

(2) 极大值不等式 (Maximal Inequality，练习 Q2.39 (sub-Gaussian 分布的刻画：极大值不等式))：X 为 sub-Exponential 随机变量，当且仅当

$$\mathrm{E}\left[\max_{i\leqslant N}|X_i|\right]\leqslant K\ln N, \qquad (K>0)$$

其中 $\{X_N\}$ 为 X 的独立副本。

(3) 凸支配刻画 (Convex Dominance，练习 Q2.28 (sub-Gaussian 分布的特征：凸优势定义))：X 为 sub-Exponential 随机变量，当且仅当

$$|X|\precsim KE, \qquad (K>0)$$

其中 $E\sim E(1)$。

证明 (1) 由于 $\|\cdot\|_{\psi_1}$ 为 Orlicz 范数 (见练习 Q2.45 (重述 Bernstein 不等式))，因此利用三角不等式，可得

$$\|X-\mathrm{E}[X]\|_{\psi_1}\leqslant\|X\|_{\psi_1}+\|\mathrm{E}[X]\|_{\psi_1}。$$

对于 $\|\mathrm{E}[X]\|_{\psi_1}$，根据命题 P2.8.1 (sub-Exponential 性质)，可得

$$\|X\|_{L^1}\leqslant C_1\|X\|_{\psi_1} = \frac{C_1}{\ln 2}|X|, \qquad \left(\|a\|_{\psi_1}=\frac{|a|}{\ln 2}\right)$$

因此

$$\|X-\mathrm{E}[X]\|_{\psi_1}\leqslant\|X\|_{\psi_1}+\frac{C_1}{\ln 2}\|X\|_{\psi_1} = \left(1+\frac{C_1}{\ln 2}\right)\|X\|_{\psi_1},$$

从而令 $C = 1+C_1/\ln 2$。

(2) ($\Longrightarrow$)

若 X 为 sub-Exponential 随机变量，令 $L = \|X\|_{\psi_1}$，则

$$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{e}^{-ct/L}。 \qquad (c > 0)$$

设 $M_N = \max_{i \leqslant N} |X_i|$，则

$$\mathrm{P}\{M_N \geqslant t\} \leqslant N\mathrm{P}\{|X| \geqslant t\} \leqslant 2N\mathrm{e}^{-ct/L}。$$

将 $\mathrm{E}[M_N]$ 于 t_0 分割，

$$\begin{aligned}
\mathrm{E}[M_N] &= \int_0^\infty \mathrm{P}\{M_N \geqslant t\}\mathrm{d}t \\
&= \int_0^{t_0} \mathrm{P}\{M_N \geqslant t\}\mathrm{d}t + \int_{t_0}^\infty \mathrm{P}\{M_N \geqslant t\}\mathrm{d}t \\
&\leqslant \int_0^{t_0} 1\mathrm{d}t + \int_{t_0}^\infty 2N\mathrm{e}^{-ct/\|X\|_{\psi_1}}\mathrm{d}t \\
&= t_0 + \left[2N\left(-\frac{L}{c}\right)\mathrm{e}^{-ct/L}\right]_{t_0}^\infty \\
&= t_0 + \frac{L}{c}(2N\mathrm{e}^{-ct_0/L}),
\end{aligned}$$

令 $2N\mathrm{e}^{-ct_0/L} = 1$，即 $t_0 = L\ln(2N)/c$，则

$$\mathrm{E}[M_N] \leqslant \frac{L}{c}\ln(2N) + \frac{L}{c} \lesssim \ln N。$$

($\Longleftarrow$)

若 $\mathrm{E}[M_N] \leqslant K\ln N$，令 $p = \mathrm{P}\{|X| \geqslant t\}$，则

$$\begin{aligned}
\mathrm{E}[M_N] &\geqslant t \cdot \mathrm{P}\{M_N \geqslant t\} \\
&= t[1 - (1-p)^N],
\end{aligned}$$

令 $N = \lfloor 1/p \rfloor$，则

$$t\left[1 - \left(1 - \frac{1}{N}\right)^N\right] \to t(1 - \mathrm{e}^{-1}) =: c_0 t, \qquad (c_0 = 1 - \mathrm{e}^{-1})$$

因此

$$\begin{aligned}
K\ln N \geqslant t \cdot c_0 &\implies \ln N \geqslant \frac{c_0}{K}t \\
&\implies \ln\left(\frac{1}{p}\right) \geqslant \frac{c_0}{K}t \\
&\implies p = \mathrm{P}\{|X| \geqslant t\} \leqslant \mathrm{e}^{-c_0 t/K}。
\end{aligned}$$

(3) ($\Longrightarrow$)

要证明 $|X| \precsim KE$，只需证明二阶随机支配条件，即对于任意的 $x \geqslant 0$，

$$\int_x^\infty \mathrm{P}\{|X| \geqslant t\}\mathrm{d}t \leqslant \int_x^\infty \mathrm{P}\{KE \geqslant t\}\mathrm{d}t。$$

对于左侧，由于 $\mathrm{P}\{|X| \geqslant t\} \leqslant 2\mathrm{e}^{-ct/L}$，其中 $L = \|X\|_{\psi_1}$，因此

$$\int_x^\infty \mathrm{P}\{|X| \geqslant t\}\mathrm{d}t = \int_x^\infty 2\mathrm{e}^{-ct/L}\mathrm{d}t = \frac{2L}{c}\mathrm{e}^{-cx/L};$$

对于右侧，由于 $\mathrm{P}\{KE \geqslant t\} = \mathrm{e}^{-t/K}$，因此

$$\mathrm{P}\{KE \geqslant t\}\mathrm{d}t = \int_x^\infty \mathrm{e}^{-t/K}\mathrm{d}t = K\mathrm{e}^{-x/K},$$

因此若 $|X| \precsim KE$，则 $K\mathrm{e}^{-x/K} \geqslant \frac{2L}{c}\mathrm{e}^{-cx/L}$，因此令 K 满足

$$K \geqslant \frac{2L}{c},\ \frac{1}{K} \leqslant \frac{c}{L} \implies K = \max\left(\frac{2L}{c}, \frac{L}{c}\right) = \frac{2L}{c}。$$

($\Longleftarrow$)

若 $|X| \precsim KE$，则只需证明对于任意的单调递增的凸函数 $\Phi : \mathbb{R} \to \mathbb{R}$，均满足 $\mathrm{E}[\Phi(|X|)] \leqslant \mathrm{E}[\Phi(KE)]$。

令 $\Phi(u) = \mathrm{e}^{u/T}$ $(T > 0)$，则

$$\mathrm{E}[\mathrm{e}^{|X|/T}] \leqslant \mathrm{E}[\mathrm{e}^{(KE)/T}],$$

其中

$$\mathrm{E}[\mathrm{e}^{(KE)/T}] = \mathrm{E}[\mathrm{e}^{(K/T)E}] = \int_0^\infty \mathrm{e}^{(K/T)t} \cdot \mathrm{e}^{-t}\mathrm{d}t = \int_0^\infty \mathrm{e}^{(K/T-1)t}\mathrm{d}t,$$

当 $K/T < 1$ 时，即 $T > K$，上述积分收敛，此时

$$\mathrm{E}[\mathrm{e}^{(KE)/T}] = \frac{1}{1 - K/T},$$

因此令

$$\frac{1}{1 - K/T} \leqslant 2 \implies T \geqslant 2K,$$

可得 $\mathrm{E}[\mathrm{e}^{|X|/(2K)}] \leqslant 2$，从而 $\|X\|_{\psi_1} \leqslant 2K < \infty$。

45 [**重述 Bernstein 不等式**] 定理 T2.9.1 (sub-Exponential Bernstein 不等式) 给出了随机变量和的尾概率界限。于概率论, 高维统计，有一种更为流行，直观的方式来表述此类结果：通过指定置信度 (即尾概率水平 u) 来反向给出随机变量和的误差界限。

设 $\{X_N\}$ 为相互独立的 K-sub-exponential 随机变量，满足 $\mathrm{E}[X_i] = 0$。证明：对于任意的 $u \geqslant 0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right| \geqslant C(\sigma\sqrt{u} + Ku)\right\} \leqslant 2\mathrm{e}^{-u}。 \qquad (C > 0)$$

其中 $\sigma^2 = \sum_{i=1}^N \|X_i\|_{\psi_1}^2$。

证明 根据定理 T2.9.1 (sub-Exponential Bernstein 不等式)，可得对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{|S_N| \geqslant t\} \leqslant 2\exp\left[-c\min\left(\frac{t^2}{\sigma^2}, \frac{t}{K}\right)\right],$$

之后只需证明存在 t，使得

$$c\min\left(\frac{t^2}{\sigma^2}, \frac{t}{K}\right) = u \implies \min\left(\frac{t^2}{\sigma^2}, \frac{t}{K}\right) = \frac{u}{c}。$$

a. 当 $t^2/\sigma^2 \leqslant t/K$ 时，即 $t \leqslant \sigma^2/K$，此时不等式表现 sub-Gaussian 特性，满足

$$\frac{t^2}{\sigma^2} = \frac{u}{c} \implies t = \frac{\sigma\sqrt{u}}{\sqrt{c}},$$

因此

$$u \leqslant \frac{c\sigma^2}{K^2}。$$

b. 当 $t^2/\sigma^2 > t/K$ 时，即 $t > \sigma^2/K$，此时不等式表现 sub-Exponential 特性，满足

$$\frac{t}{K} = \frac{u}{c} \implies t = \frac{Ku}{c},$$

因此

$$u > \frac{c\sigma^2}{K^2},$$

如此，临界值为

$$t=\max\left(\frac{\sigma\sqrt{u}}{\sqrt{c}},\frac{Ku}{c}\right),$$

利用不等式 $\max(A,B)\leqslant A+B$，可得

$$t\leqslant\frac{1}{\sqrt{c}}\sigma\sqrt{u}+\frac{1}{c}Ku=C(\sigma\sqrt{u}+Ku)。\qquad\left(C=\max\left(\frac{1}{\sqrt{c}},\frac{1}{c}\right)\right)$$

注释 这种重述方式展现了 Bernstein 不等式的混合尾部特性：

1. 波动主导项：$\sigma\sqrt{u}$ 反映了类似于 CLT 的正态波动，与方差相关。
2. 极值主导项：Ku 反映了最恶劣单体 (sub-Exponential 最厚尾部) 的 Poisson 型波动。
3. 相变：当 u 较小时 (置信度要求不高)，$\sqrt{u}$ 占主导，系统表现为类 Gaussian 分布；当 u 较大时 (极小概率事件)，u 占主导，系统受限于个体最大厚尾。

46 [**sub-Exponential Khintchine 不等式**] 证明定理 T2.7.5 (Khintchine 不等式) 的 sub-Exponential 版本。

设 $\{X_N\}$ 为相互独立的零均值 K-sub-Exponential 随机变量。证明：对于任意的 $\boldsymbol{a}\in\mathbb{R}^N$，当 $p\in[2,\infty)$ 时，

$$\left\|\sum_{i=1}^N a_iX_i\right\|_{L^p}\leqslant CK(\sqrt{p}\|\boldsymbol{a}\|_2+p\|\boldsymbol{a}\|_\infty)。\qquad(C>0)$$

证明 记 $S_N=\sum_{i=1}^N a_iX_i$，则根据定理 T2.9.1 (sub-Exponential Bernstein 不等式)，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|S_N|\geqslant t\}\leqslant 2\exp\left[-c\min\left(\frac{t^2}{\sigma^2},\frac{t}{L}\right)\right],\qquad(c>0)$$

其中

$$\sigma^2=\sum_{i=1}^N a_i^2\|X_i\|_{\psi_1}^2\leqslant K^2\sum_{i=1}^N a_i^2=K^2\|\boldsymbol{a}\|_2^2,$$

$$L=\max_{i\leqslant N}|a_i|\|X_i\|_{\psi_1}\leqslant K\max_{i\leqslant N}|a_i|=K\|\boldsymbol{a}\|_\infty,$$

记 $A=K\|\boldsymbol{a}\|_2$，$B=K\|\boldsymbol{a}\|_\infty$，则

$$\mathrm{P}\{|S_N|\geqslant t\}\leqslant 2\exp\left[-c\min\left(\frac{t^2}{A^2},\frac{t}{B}\right)\right]。$$

将尾部界代入矩时，可得

$$\begin{aligned}\|S_N\|_{L^p}^p=\mathrm{E}[|S_N|^p]&=\int_0^\infty pt^{p-1}\mathrm{P}\{|S_N|\geqslant t\}\mathrm{d}t\\&\leqslant\int_0^\infty 2pt^{p-1}\exp\left(-c\frac{t^2}{A^2}\right)\mathrm{d}t+\int_0^\infty 2pt^{p-1}\exp\left(-c\frac{t}{B}\right)\mathrm{d}t\\&\leqslant(C_1A\sqrt{p})^p+(C_2Bp)^p\\&\leqslant(C_1A\sqrt{p}+C_2Bp)^p,\end{aligned}$$

因此

$$\|S_N\|_{L^p}\leqslant C_1K\sqrt{p}\|\boldsymbol{a}\|_2+C_2Kp\|\boldsymbol{a}\|_\infty\leqslant CK(\sqrt{p}\|\boldsymbol{a}\|_2+p\|\boldsymbol{a}\|_\infty)。$$

47 [**有界分布的 Bernstein 不等式**]

(1) 设 X 满足 $\mathrm{E}[X]=0$，$|X|\leqslant K$ (a.s.)，证明：当 $|\lambda|<3/K$ 时，

$$\mathrm{E}[\mathrm{e}^{\lambda X}]\leqslant\exp(g(\lambda)\mathrm{E}[X^2]),$$

其中

$$g(\lambda)=\frac{\lambda^2/2}{1-|\lambda|K/3}。$$

(2) 通过指数矩方法，推导定理 T2.9.5 (有界分布的 Bernstein 不等式)。

证明 (1) 容易知道，$|X^k| = |X|^{k-2} \cdot X^2 \leqslant K^{k-2}X^2$，两侧取期望，

$$\mathrm{E}[X^k] \leqslant K^{k-2}\mathrm{E}[X^2]。$$

考虑 $\mathrm{e}^{\lambda X}$ 的 Taylor 展开，

$$\begin{aligned}\mathrm{E}[\mathrm{e}^{\lambda X}] &= 1 + \lambda\mathrm{E}[X] + \sum_{k=2}^{\infty}\frac{\lambda^k\mathrm{E}[X^k]}{k!}\\ &\leqslant 1 + \sum_{k=2}^{\infty}\frac{|\lambda|^k K^{k-2}\mathrm{E}[X^2]}{k!}\\ &= 1 + \mathrm{E}[X^2]\lambda^2\sum_{k=2}^{\infty}\frac{|\lambda|^{k-2}K^{k-2}}{k!},\end{aligned}$$

其中当 $|\lambda| < 3/K$ 时，代入 $k! \geqslant 2\cdot 3^{k-2}$，可得

$$\sum_{k=2}^{\infty}\frac{|\lambda|^{k-2}K^{k-2}}{k!} \leqslant \frac{1}{2}\sum_{j=0}^{\infty}\left(\frac{|\lambda|K}{3}\right)^j = \frac{1/2}{1-|\lambda|K/3},$$

将其代入，可得

$$\mathrm{E}[\mathrm{e}^{\lambda X}] \leqslant 1 + \mathrm{E}[X^2]\cdot\frac{\lambda^2/2}{1-|\lambda|K/3} \leqslant \exp(g(\lambda)\mathrm{E}[X^2])。 \tag{I}$$

(2) 记 $S_N = \sum_{i=1}^N X_i$，方差和为 $\Sigma^2 = \sum_{i=1}^N \mathrm{E}[X_i^2]$。

利用 Chernoff 界，可得

$$\mathrm{P}\{S_N \geqslant t\} = \mathrm{P}\{\mathrm{e}^{\lambda S_N} \geqslant \mathrm{e}^{\lambda t}\} \leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda S_N}] = \mathrm{e}^{-\lambda t}\prod_{i=1}^N \mathrm{E}[\mathrm{e}^{\lambda X_i}], \tag{II}$$

将 (II) 代入于 (I)，可得

$$\mathrm{P}\{S_N \geqslant t\} \leqslant \exp\left(-\lambda t + \frac{\lambda^2\Sigma^2/2}{1-\lambda K/3}\right)。$$

右侧的最优参数为 $\lambda = t/(\Sigma^2 + Kt/3) < 3/K$，将其代入，可得

$$\mathrm{P}\{S_N \geqslant t\} \leqslant \exp\left(-\frac{t^2}{2\Sigma^2 + 2Kt/3}\right),$$

两侧取并集界，

$$\mathrm{P}\{|S_N| \geqslant t\} \leqslant 2\exp\left(-\frac{t^2}{2\Sigma^2 + 2Kt/3}\right)。$$

48 [**Bennett 不等式**] 证明下述定理 T2.9.5 (有界分布的 Bernstein 不等式) 的加强版。

设 $\{X_N\}$ 为相互独立的零均值随机变量，满足 $|X_i| \leqslant K$。证明：对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right| \geqslant t\right\} \leqslant 2\exp\left[-\frac{\sigma^2}{K^2}h\left(\frac{Kt}{\sigma^2}\right)\right],$$

其中 $\sigma^2 = \sum_{i=1}^N \mathrm{E}[X_i^2]$，$h(u) = (1+u)\ln(1+u) - u$。

按照以下步骤证明：

(1) 设 X 为零均值随机变量，满足 $|X| \leqslant K$ (a.s.)。证明：对于任意的 $\lambda > 0$，

$$\mathrm{E}[\mathrm{e}^{\lambda X}] \leqslant \exp\left(\frac{\mathrm{E}[X^2]}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K)\right)。$$

(2) 利用指数矩法，证明上述 Bennett 不等式。

(3) (小偏差情形：sub-Gaussian 尾部界) 证明：当 $u = Kt/\sigma^2 \to 0$ 时，$h(u) \sim u^2/2$，此时 Bennett 不等式退化为 Gaussian 尾

部界 $\exp(-t^2/\sigma^2)$。

(4) (大偏差情形：Poisson 尾部界) 证明：当 u 充分大时，$h(u) \geqslant u\ln u/2$，此时 Bennett 不等式退化为 Poisson 尾部界 $2(\sigma^2/Kt)^{t/(2K)}$，同理于练习 Q2.13 (Poisson 分布的尾部界)。

证明 (1) 设 $f(x) = (\mathrm{e}^{\lambda x} - 1 - \lambda x)/x^2$，于 $x = 0$ 补充定义 $f(0) = \lambda^2/2$，则

$$f(x) = \sum_{k=2}^{\infty} \frac{\lambda^k x^{k-2}}{k!} = \frac{\lambda^2}{2!} + \frac{\lambda^3 x}{3!} + \frac{\lambda^4 x^2}{4!} + \cdots,$$

两侧求导，

$$f'(x) = \sum_{k=3}^{\infty} \frac{\lambda^k (k-2) x^{k-3}}{k!} = \frac{\lambda^3}{3!} + \frac{2\lambda^4 x}{4!} + \cdots = \frac{\lambda^3 g(\lambda x)}{(\lambda x)^3},$$

其中 $g(y) = y\mathrm{e}^y - 2\mathrm{e}^y + 2 + y$。

由于 $g(0) = g'(0) = 0$，$g''(y) = y\mathrm{e}^y$，因此 $f'(x) > 0$ $(x \neq 0)$，可得 $f(x)$ 是递增的，从而

$$f(X) \leqslant f(K) = \frac{\mathrm{e}^{\lambda K} - 1 - \lambda K}{K^2},$$

两侧同乘 X^2，

$$\mathrm{e}^{\lambda X} - 1 - \lambda X = X^2 f(X) \leqslant X^2 f(K) = X^2 \cdot \frac{\mathrm{e}^{\lambda K} - 1 - \lambda K}{K^2},$$

之后两侧取期望，代入 $\mathrm{E}[X] = 0$，可得

$$\mathrm{E}[\mathrm{e}^{\lambda X}] - 1 \leqslant \mathrm{E}[X^2] \cdot \frac{\mathrm{e}^{\lambda K} - 1 - \lambda K}{K^2}。$$

即

$$\begin{aligned} \mathrm{E}[\mathrm{e}^{\lambda X}] &\leqslant 1 + \frac{\mathrm{E}[X^2]}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K) \\ &\leqslant \exp\left(\frac{\mathrm{E}[X^2]}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K)\right)。 \end{aligned}$$

(2) 记 $S_N = \sum_{i=1}^N X_i$，则利用 (1) 的结论，可得

$$\mathrm{E}[\mathrm{e}^{\lambda S_N}] = \prod_{i=1}^N \mathrm{E}[\mathrm{e}^{\lambda X_i}] \leqslant \prod_{i=1}^N \exp\left(\frac{\mathrm{E}[X_i^2]}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K)\right) = \exp\left(\frac{\sigma^2}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K)\right),$$

因此利用 Chernoff 界，可得对于任意的 $\lambda > 0$，

$$\mathrm{P}\{S_N \geqslant t\} \leqslant \mathrm{e}^{-\lambda t}\mathrm{E}[\mathrm{e}^{\lambda S_N}] \leqslant \exp\left(-\lambda t + \frac{\sigma^2}{K^2}(\mathrm{e}^{\lambda K} - 1 - \lambda K)\right),$$

右侧的最优参数为 $\lambda_0 = \ln(1+u)/K$，将其代入，可得

$$\begin{aligned} \mathrm{P}\{S_N \geqslant t\} &\leqslant \exp\left(-\frac{\sigma^2}{K^2}[(1+u)\ln(1+u) - u]\right) \\ &\leqslant \exp\left[-\frac{\sigma^2}{K^2} h\left(\frac{Kt}{\sigma^2}\right)\right]。 \end{aligned} \tag{I}$$

同理，将 X_i 替换为 $-X_i$，取并集界，可得

$$\mathrm{P}\{S_N \leqslant -t\} \leqslant \exp\left[-\frac{\sigma^2}{K^2} h\left(\frac{Kt}{\sigma^2}\right)\right]。 \tag{II}$$

如此，联立 (I)(II)，可得

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right| \geqslant t\right\} \leqslant 2\exp\left[-\frac{\sigma^2}{K^2} h\left(\frac{Kt}{\sigma^2}\right)\right]。$$

(3) 当 $u = Kt/\sigma^2 \to 0$ 时，

$$h(u) = (1+u)\left(u - \frac{u^2}{2} + O(u^3)\right) - u = u - \frac{u^2}{2} + u^2 + O(u^3) - u = \frac{u^2}{2} + O(u^3) \sim \frac{u^2}{2},$$

将其代入，可得指数项为

$$-\frac{\sigma^2}{K^2}h(u) \sim -\frac{\sigma^2}{K^2} \cdot \frac{1}{2}\left(\frac{Kt}{\sigma^2}\right)^2 = -\frac{t^2}{2\sigma^2},$$

因此

$$\mathrm{P}\left\{\left|\sum_{i=1}^{N} X_i\right| \geqslant t\right\} \lesssim 2\exp\left(-\frac{t^2}{2\sigma^2}\right),$$

(4) 当 u 充分大时，不妨设当 $u \geqslant \mathrm{e}^2$ 时，

$$h(u) = (1+u)\ln(1+u) - u \geqslant u\ln u - u \geqslant \frac{1}{2}u\ln u。$$

将其代入，可得指数项为

$$-\frac{\sigma^2}{K^2}h(u) \leqslant -\frac{\sigma^2}{K^2}\left(\frac{1}{2}u\ln u\right) = -\frac{t}{2K}\ln\left(\frac{Kt}{\sigma^2}\right) = \ln\left[\left(\frac{\sigma^2}{Kt}\right)^{t/(2K)}\right],$$

因此

$$\mathrm{P}\left\{\left|\sum_{i=1}^{N} X_i\right| \geqslant t\right\} \leqslant 2\exp\left[-\frac{\sigma^2}{K^2}h\left(\frac{Kt}{\sigma^2}\right)\right] \leqslant 2\left(\frac{\sigma^2}{Kt}\right)^{t/(2K)}。$$

3 高维随机向量

要点梳理

Section 3.1 范数的集中 Q3.1 ~ Q3.3

定理 3.1.1 (范数的集中)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为随机向量，其元素为相互独立, 中心化的 K-sub-Gaussian 随机变量，则对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{|\|\boldsymbol{X}\|_2 - \sqrt{n}| \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{K^4}\right)。$$

Section 3.2 协方差矩阵与 PCA Q3.4

命题 3.2.1 (协方差矩阵有助于计算感兴趣的量)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为零均值随机向量，其协方差矩阵记为 $\boldsymbol{\Sigma} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$，则：

(1) 对于任意的 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，

$$\mathrm{Var}(\langle \boldsymbol{X}, \boldsymbol{v}\rangle) = \boldsymbol{v}^\top \boldsymbol{\Sigma}\boldsymbol{v}。$$

(2) 对于任意的 $S \subset \{1, \cdots, n\}$，子随机向量 $\boldsymbol{X}_S := (X_i)_{i\in S}$ 的协方差矩阵为 $\boldsymbol{\Sigma}_S$，即 $\boldsymbol{\Sigma}$ 为限制于 S 的主子矩阵。

命题 3.2.2 (特征值的优化刻画)

设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称矩阵，则其最大特征值, 最小特征值的 Rayleigh 商极值形式为

$$\lambda_{\max}(\boldsymbol{A}) = \max_{\|\boldsymbol{x}\|_2=1} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}，\ \lambda_{\min}(\boldsymbol{A}) = \min_{\|\boldsymbol{x}\|_2=1} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}。$$

推论 3.2.3 (主成分分析)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为零均值随机向量，协方差矩阵记为 $\boldsymbol{\Sigma} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$。定义第一主方向 $\boldsymbol{v}_1$ 为使得投影方差达到最大的单位方向，即

$$\boldsymbol{v}_1 := \arg\max_{\|\boldsymbol{v}\|_2=1} \mathrm{Var}(\langle \boldsymbol{X}, \boldsymbol{v}\rangle)，$$

则 $\boldsymbol{v}_1$ 恰好为 $\boldsymbol{\Sigma}$ 对应于最大特征值 $\lambda_{\max}(\boldsymbol{\Sigma})$ 的单位特征向量，此时最大投影方差即为此特征值，

$$\max_{\|\boldsymbol{v}\|_2=1} \mathrm{Var}(\langle \boldsymbol{X}, \boldsymbol{v}\rangle) = \lambda_{\max}(\boldsymbol{\Sigma})。$$

定义 3.2.5 (各向同性随机向量)

称随机向量 $\boldsymbol{X} \in \mathbb{R}^n$ 是各向同性的，若其协方差矩阵为单位阵，即

$$\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \boldsymbol{I}_n。$$

等价地 (等距投影性质)，对于任意的 $\boldsymbol{v} \in \mathbb{R}^n$，

$$\mathrm{E}[\langle \boldsymbol{X}, \boldsymbol{v}\rangle^2] = \|\boldsymbol{v}\|_2^2。$$

(当 $\boldsymbol{X}$ 满足零均值 $\mathrm{E}[\boldsymbol{X}] = \boldsymbol{0}$ 时，二阶矩矩阵与协方差矩阵重合，此时各向同性等价于 $\mathrm{Cov}(\boldsymbol{X}) = \boldsymbol{I}_n$。)

Section 3.3 高维分布的例子 Q3.5 ∼ Q3.31

命题 3.3.1 (旋转不变性)

标准正态分布 $N(\boldsymbol{0}, \boldsymbol{I}_n)$ 是旋转不变的：若 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，$\boldsymbol{Q} \in \mathbb{R}^{n\times n}$ 为正交矩阵，则 $\boldsymbol{Q}\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。

推论 3.3.2 (标准正态分布的一维边缘)

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则对于任意的 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，

$$\langle \boldsymbol{g}, \boldsymbol{v}\rangle \sim N(0, 1)。$$

推论 3.3.3 (独立正态随机变量之和仍为正态)

设 X, Y 为相互独立的随机变量，满足 $X \sim N(\mu_X, \sigma_X^2)$，$Y \sim N(\mu_Y, \sigma_Y^2)$，则

$$X + Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)。$$

定义 3.3.4 (一般正态分布)

若 $\boldsymbol{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，则存在矩阵 $\boldsymbol{B}$，使得 $\boldsymbol{X}$ 可以表示为 $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{B}\boldsymbol{g}$，其中 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_k)$，$\boldsymbol{\Sigma} = \boldsymbol{B}\boldsymbol{B}^\top$。

命题 3.3.5 (唯一性)

若 $\boldsymbol{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，则 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 由 $\boldsymbol{X}$ 的分布唯一确定；事实上，$\boldsymbol{\mu} = \mathrm{E}[\boldsymbol{X}]$，$\boldsymbol{\Sigma} = \mathrm{Cov}(\boldsymbol{X})$。

命题 3.3.6 (一般正态密度)

若 $\boldsymbol{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，$\boldsymbol{\Sigma}$ 是可逆的，则 $\boldsymbol{X}$ 的密度为

$$f(\boldsymbol{x}) = \frac{1}{(2\pi)^{n/2}\sqrt{\det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right), \quad \boldsymbol{x} \in \mathbb{R}^n。$$

推论 3.3.7 (联合正态随机变量)

随机变量 $X_1, \cdots, X_n$ 服从联合正态 (即 $(X_1, \cdots, X_n)$ 服从多元正态分布)，当且仅当其任意的线性组合 $\sum_{i=1}^n a_i X_i$ 均为正态随机变量。

命题 3.3.8 (球面是各向同性的)

设 $\boldsymbol{\theta} \in \mathbb{S}^{n-1}$，则 $\boldsymbol{\theta}$ 是各向同性的，即

$$\mathrm{E}[\boldsymbol{\theta}\boldsymbol{\theta}^\top] = \frac{1}{n}\boldsymbol{I}_n。$$

定理 3.3.9 (投影中心极限定理)

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为各向同性的随机向量，其元素是相互独立的，则对于绝大多数的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，一维边际投影满足

$$\langle \boldsymbol{X},\boldsymbol{v}\rangle \overset{d}{\approx} N(0,1)。$$

命题 3.3.11 (Parseval 框架)

设 $\{\boldsymbol{u}_i\}_{i=1}^m\in\mathbb{R}^n$。若存在 $A>0$ (框架界)，使得对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，均满足能量守恒，

$$\sum_{i=1}^m\langle \boldsymbol{x},\boldsymbol{u}_i\rangle^2=A\|\boldsymbol{x}\|_2^2,$$

则称 $\{\boldsymbol{u}_i\}_{i=1}^m$ 为 A-紧框架。

特别地，当 $A=1$ 时，上述不等式即为 Parseval 框架 (Parseval 恒等式)。

Section 3.4 高维 sub-Gaussian 分布 Q3.32 ~ Q3.46

定义 3.4.1 (sub-Gaussian 随机向量)

称 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量，若其于任意方向的一维编辑投影 $\langle \boldsymbol{X},\boldsymbol{v}\rangle$ 均为 sub-Gaussian 随机变量。

定义 $\boldsymbol{X}$ 的 sub-Gaussian 范数为

$$\|\boldsymbol{X}\|_{\psi_2}=\sup_{\|\boldsymbol{v}\|_2=1}\|\langle \boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}。$$

引理 3.4.2 (独立 sub-Gaussian 坐标的分布)

若 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，若其元素为相互独立, 零均值的 sub-Gaussian 变量，则 $\boldsymbol{X}$ 为 sub-Gaussian 随机向量，满足

$$\|\boldsymbol{X}\|_{\psi_2}\leqslant C\max_{i\leqslant n}\|X_i\|_{\psi_2}。$$

定理 3.4.5 (球面的均匀分布是 sub-Gaussian 的)

设 $\boldsymbol{\theta}\sim\sqrt{n}\mathbb{S}^{n-1}$，则 $\boldsymbol{\theta}$ 为 sub-Gaussian 随机向量，满足

$$\|\boldsymbol{\theta}\|_{\psi_2}\leqslant C。$$

Section 3.5 Grothendieck 不等式与 SDP Q3.47 ~ Q3.52

定理 3.5.1 (Grothendieck 不等式)

存在 $K_G\in[1,\pi/2\ln(1+\sqrt{2})]\approx[1,1.782]$ (称为 Grothendieck 常数)，使得对于任意的 $\boldsymbol{A}=\in\mathbb{R}^{m\times n}$，离散双线性型与其 SDP 向量松弛之间满足

$$\max_{u_i,v_j\in\{-1,1\}}\sum_{i,j}a_{ij}u_iv_j\leqslant\max_{\boldsymbol{u}_i,\boldsymbol{v}_j\in\mathbb{S}^{m+n-1}}\sum_{i,j}a_{ij}\langle \boldsymbol{u}_i,\boldsymbol{v}_j\rangle\leqslant K_G\cdot\max_{u_i,v_j\in\{-1,1\}}\sum_{i,j}a_{ij}u_iv_j,$$

其中中间的最大值取遍 Hilbert 空间的单位向量 $\boldsymbol{u}_i,\boldsymbol{v}_j$。

注记 3.5.3 (二次 Grothendieck：$x_i=y_i$)

当 $x_i=y_i$ 时，Grothendieck 不等式的前提条件可以放宽，此时输入端被限定为二次型而非双线性型。

设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 满足 $\boldsymbol{A}\succeq\boldsymbol{0}$ 或者 $\operatorname{diag}(\boldsymbol{A})=\boldsymbol{0}$。若对于任意的 $x_i\in\{-1,1\}$，均满足二次型有界条件，

$$\left|\sum_{i,j}a_{ij}x_ix_j\right|\leqslant 1。$$

则对于任意的 Hilbert 空间 $\mathcal{H}$ 的单位向量组 $\{\boldsymbol{u}_i\}_{i=1}^n\subset\mathcal{H}$，均满足

$$\left|\sum_{i,j}a_{ij}\langle \boldsymbol{u}_i,\boldsymbol{v}_j\rangle\right|\leqslant 2K_G。$$

其中 $\boldsymbol{u}_i, \boldsymbol{v}_j \in \mathcal{H}$ 为单位向量，K_G 为 Grothendieck 常数。具体证明过程见练习 Q3.49 (半正定矩阵的二次 Grothendieck 不等式), 练习 Q3.50 (无对角元矩阵的二次 Grothendieck 不等式)。

定义 3.5.4 (半定规划)

半定规划 (SDP) 为以下形式的凸优化问题：

$$\begin{aligned} \max_{\boldsymbol{X}\in\mathbb{R}^{n\times n}} \quad & \langle \boldsymbol{C}, \boldsymbol{X}\rangle_F \\ \text{s.t.} \quad & \langle \boldsymbol{A}_i, \boldsymbol{X}\rangle_F = b_i, \quad i = 1, \cdots, m, \\ & \boldsymbol{X} \succeq \boldsymbol{0}, \end{aligned}$$

其中 $\langle \boldsymbol{A}, \boldsymbol{B}\rangle_F = \operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{B})$。

命题 3.5.6 (Grothendieck 松弛的 SDP 表示)

Grothendieck 极大化问题的 SDP 松弛等价于标准 SDP。

引入单位向量组 $\{\boldsymbol{u}_i\}_{i=1}^m, \{\boldsymbol{v}_j\}_{j=1}^n$ 构成的 Gram 矩阵变量 $\boldsymbol{Z} \in \mathbb{R}^{(m+n)\times(m+n)}$，则 Grothendieck 极大化问题可以显示表达为：

$$\begin{aligned} \max_{\boldsymbol{Z}} \quad & \sum_{i=1}^m \sum_{j=1}^n a_{ij} z_{i,m+j} \\ \text{s.t.} \quad & \boldsymbol{Z} \succeq \boldsymbol{0}, \\ & z_{kk} = 1, \quad k = 1, \cdots, m+n。 \end{aligned}$$

定理 3.5.7 (松弛的保证)

对于任意的矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，记 $\mathrm{SDP}(\boldsymbol{A})$ 上述半定松弛的最优值，则

$$\mathrm{SDP}(\boldsymbol{A}) \leqslant K_G \cdot \mathrm{OPT}(\boldsymbol{A}),$$

其中 $\mathrm{OPT}(\boldsymbol{A}) := \max_{u_i, v_j \in \{-1,1\}} \sum_{i,j} a_{ij} u_i v_j$ 为原离散优化问题的最优值。

Section 3.6 图的最大割 Q3.53 ∼ Q3.54

定义 3.6.1 (最大割)

设无向图 $G = (V, E)$ 的顶点集为 $V = \{1, \cdots, n\}$，边权为 $w_{ij} \geqslant 0$。最大割问题 (MAX-CUT) 的目标为寻找顶点集的二划分 $V = S \sqcup S^c$，使得跨越划分的边的总权重最大。

引入二元符号变量 $x_i \in \{-1, 1\}$，其中 $x_i = 1$ 表示 $i \in S$，$x_i = -1$ 表示 $i \in S^c$，则割权重可以显式表示为离散二次型优化问题：

$$\text{MAX-CUT}(G) = \max_{\boldsymbol{x}\in\{-1,1\}^n} \frac{1}{4} \sum_{i,j=1}^n w_{ij}(1 - x_i x_j)。$$

定义 3.6.2 (加权邻接矩阵)

带权图 $G = (V, E)$ 的加权邻接矩阵定义为 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，满足对角元 $a_{ii} = 0$，非对角元为

$$a_{ij} = \begin{cases} w_{ij}, & (i,j) \in E, \\ 0, & (i,j) \notin E \end{cases},$$

总边权记为 $W = \sum_{i<j} w_{ij} = \frac{1}{2} \sum_{i,j} a_{ij}$。

命题 3.6.3 (最大割的 0.5-近似算法)

存在简单的随机化多项式时间算法 (即对每个顶点以 1/2 的概率独立地分配为 S 或 S^c)，使得对于任意的非负权图 G，其输出割集的期望权重满足

$$\mathrm{E}[\mathrm{CUT}(\boldsymbol{x})] = \frac{1}{2} W \geqslant 0.5 \cdot \text{MAX-CUT}(G)。$$

等价地，设对称矩阵 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 满足 $a_{ii}=0$，则存在 $\boldsymbol{u}\in\{-1,1\}^n$，使得

$$\sum_{i,j}a_{ij}u_iu_j\leqslant 0。$$

定理 3.6.4 (最大割的 0.878-近似算法)

存在基于 SDP 松弛与随机超平面舍入 (Random Hyperplane Rounding) 的多项式时间算法 (Goemans-Williamson 算法)，使得对于任意的非负权图 G，其输出割集的期望权重满足

$$\mathrm{E}[\mathrm{CUT}(\boldsymbol{x})]\geqslant\alpha_{\mathrm{GW}}\cdot\text{MAX-CUT}(G)\geqslant 0.878\cdot\text{MAX-CUT}(G)。\qquad\left(\alpha_{\mathrm{GW}}=\min_{0\leqslant\theta\leqslant\pi}\frac{2}{\pi}\frac{\theta}{1-\cos\theta}\right)$$

引理 3.6.5 (Grothendieck 恒等式)

设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则对于任意的 $\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}$，

$$\mathrm{E}[\mathrm{sgn}(\langle\boldsymbol{g},\boldsymbol{u}\rangle)\cdot\mathrm{sgn}(\langle\boldsymbol{g},\boldsymbol{v}\rangle)]=\frac{2}{\pi}\arcsin(\langle\boldsymbol{u},\boldsymbol{v}\rangle)。$$

Section 3.7 核技巧 Q3.55 ~ Q3.58

定义 3.7.1 (张量)

称 $T=(T_{i_1\cdots i_d})\in\mathbb{R}^{n\times\cdots\times n}$ 为 d 阶实张量，若其元素由多重指标 $(i_1,\cdots,i_d)\in\{1,\cdots,n\}^d$ 索引。几何上，T 可以视为张量积空间 $(\mathbb{R}^n)^{\otimes d}\cong\mathbb{R}^{n^d}$ 的多维数组。

引理 3.7.4 (幂)

对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，幂函数可以显式表示为张量空间的内积形式，

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle^d=\langle\boldsymbol{x}^{\otimes d},\boldsymbol{y}^{\otimes d}\rangle,$$

其中 $\boldsymbol{x}^{\otimes d}=\boldsymbol{x}\otimes\cdots\otimes\boldsymbol{x}\in(\mathbb{R}^n)^{\otimes d}$ 为 $\boldsymbol{x}$ 的 d 重自张量积 (在标准正交基下对应于 $\mathbb{R}^{n^d}$ 中的向量化特征映射)，内积为张量空间的 Frobenius 典范内积。

引理 3.7.7 (实解析函数)

设实解析函数 $f:(-1,1)\to\mathbb{R}$ 于原点的 Taylor 展开系数均是非负的，则其诱导的核函数 $K(\boldsymbol{x},\boldsymbol{y}):=f(\langle\boldsymbol{x},\boldsymbol{y}\rangle)$ 于 $\mathbb{S}^{n-1}$ 构成正定核。

习题解答

1 [薄壳现象] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其元素为相互独立的标准化 K-sub-Gaussian 随机变量。根据定理 T3.1.1 (范数的集中)，证明：

$$\mathrm{Var}(\|\boldsymbol{X}\|_2)\leqslant CK^4。\qquad(C>0)$$

证明 令 $Z=\|\boldsymbol{X}\|_2-\sqrt{n}$，利用方差的极小性质 $\mathrm{Var}(Y)\leqslant\mathrm{E}[(Y-a)^2]$，可得

$$\mathrm{Var}(\|\boldsymbol{X}\|_2)\leqslant\mathrm{E}[(\|\boldsymbol{X}\|_2-\sqrt{n})^2]=\mathrm{E}[Z^2]。\qquad(\mathrm{I})$$

(我们只需控制 $\mathrm{E}[Z^2]$ 即可。)

根据定理 T3.1.1 (范数的集中)，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|Z|\geqslant t\}\leqslant 2\exp\left(-\frac{ct^2}{K^4}\right),\qquad(c>0)$$

利用非负变量的尾积分公式，可得

$$\mathrm{E}[Z^2]=\int_0^\infty 2t\mathrm{P}\{|Z|\geqslant t\}\mathrm{d}t\leqslant 4\int_0^\infty t\exp\left(-\frac{ct^2}{K^4}\right)\mathrm{d}t=\frac{2}{c}K^4=:CK^4, \tag{II}$$

将 (II) 代入于 (I)，可得

$$\mathrm{Var}(\|\boldsymbol{X}\|_2)\leqslant CK^4。$$

2 [**广义薄壳现象**] 放宽习题 Q3.1 (薄壳现象) 的 sub-Gaussian 假设，证明：对于任意四阶矩有界的分布，相应的方差界依然成立。

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其元素是相互独立的，满足 $\mathrm{E}[X_i^2]=1$，$\mathrm{E}[X_i^4]\leqslant K^4$。证明：

$$\mathrm{Var}(\|\boldsymbol{X}\|_2)\leqslant K^4,\ \sqrt{n}-\frac{K^4}{\sqrt{n}}\leqslant\mathrm{E}\|\boldsymbol{X}\|_2\leqslant\sqrt{n}。$$

证明 设 $Y=\|\boldsymbol{X}\|_2$，则 $\mathrm{E}[Y^2]=\mathrm{E}[\sum_{i=1}^n X_i^2]=\sum_{i=1}^n 1=n$。

(1) 利用方差的极小性质 $\mathrm{Var}(Y)\leqslant\mathrm{E}[(Y-a)^2]$，可得

$$\mathrm{Var}(Y)\leqslant\mathrm{E}[(Y-\sqrt{n})^2]=\mathrm{E}\left[\frac{(Y^2-n)^2}{(Y+\sqrt{n})^2}\right]\leqslant\frac{1}{n}\mathrm{E}[(Y^2-n)^2]=\frac{1}{n}\mathrm{Var}(Y^2),$$

其中

$$\mathrm{Var}(Y^2)=\sum_{i=1}^n\mathrm{Var}(X_i^2)=\sum_{i=1}^n(\mathrm{E}[X_i^4]-(\mathrm{E}[X_i^2])^2)\leqslant\sum_{i=1}^n(K^4-1)\leqslant nK^4,$$

将其代入，可得

$$\mathrm{Var}(Y)\leqslant\mathrm{E}[(Y-\sqrt{n})^2]\leqslant\mathrm{Var}(Y^2)\leqslant\frac{1}{n}\cdot nK^4=K^4。$$

(2) 对于上界，利用 Jensen 不等式，令 $\phi(y)=\sqrt{y}$，可得

$$\mathrm{E}[Y]=\mathrm{E}[\sqrt{Y^2}]\leqslant\sqrt{\mathrm{E}[Y^2]}=\sqrt{n}。$$

对于下界，利用方差的定义式，

$$\mathrm{Var}(Y)=\mathrm{E}[Y^2]-(\mathrm{E}[Y])^2=n-(\mathrm{E}[Y])^2=(\sqrt{n}-\mathrm{E}[Y])(\sqrt{n}+\mathrm{E}[Y]),$$

因此利用 (1) 的结论，可得

$$\begin{aligned}(\sqrt{n}-\mathrm{E}[Y])(\sqrt{n}+\mathrm{E}[Y])\leqslant K^4\ &\Longrightarrow\ \sqrt{n}-\mathrm{E}[Y]\leqslant\frac{K^4}{\sqrt{n}+\mathrm{E}[Y]}\leqslant\frac{K^4}{\sqrt{n}}\\&\Longrightarrow\ \mathrm{E}[Y]\geqslant\sqrt{n}-\frac{K^4}{\sqrt{n}}。\end{aligned}$$

3 [**逆向薄壳现象**] 证明习题 Q3.2 (广义薄壳现象) 的结论的反向估计。

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其元素是相互独立的，满足 $\mathrm{E}[X_i^2]=1$, $\mathrm{Var}(X_i^2)>\alpha$, $\mathrm{E}[X_i^6]\leqslant\beta$。

(1) 证明：当 n 充分大时 (依赖于 α 和 β)，

$$\mathrm{Var}(\|\boldsymbol{X}\|_2)\geqslant c\alpha,\ \mathrm{E}\|\boldsymbol{X}\|_2\leqslant\sqrt{n}-\frac{c\alpha}{\sqrt{n}}。\qquad(c>0)$$

(2) 说明方差下界条件是必要的。

解答 (1) 设 $S=\|\boldsymbol{X}\|_2^2=\sum_{i=1}^n X_i^2$，则

$$\mathrm{E}[S]=\sum_{i=1}^n\mathrm{E}[X_i^2]=n,\ \ \mathrm{Var}(S)=\sum_{i=1}^n\mathrm{Var}(X_i^2)>n\alpha;$$

由于 $\mathrm{E}[X_i^6]\leqslant\beta$，因此 X_i^2 的高阶矩有界，即存在常数 C_β，使得 $\mathrm{E}[|X_i^2-1|^3]\leqslant C_\beta$。

- 证明 $\mathrm{E}\|\boldsymbol{X}\|_2\leqslant\sqrt{n}-c\alpha/\sqrt{n}$

利用 Delta 方法，考虑 $f(s)=\sqrt{s}$ 于 $s=n$ 的二阶 Taylor 展开，

$$\sqrt{s}=\sqrt{n}+\frac{s-n}{2\sqrt{n}}-\frac{(s-n)^2}{8n^{3/2}}+R_2(s,n),$$

其中

$$R(s,n)=\frac{1}{16\xi^{5/2}}(s-n)^3,\qquad (\xi\text{ 介于 }s,n\text{ 之间})$$

令 $s=S$，两侧取期望，

$$\begin{aligned}\mathrm{E}\|\boldsymbol{X}\|_2=\mathrm{E}[\sqrt{S}]&=\sqrt{n}+\frac{\mathrm{E}[S-n]}{2\sqrt{n}}-\frac{\mathrm{E}[(S-n)^2]}{8n^{3/2}}+\mathrm{E}[R_2(S,n)]\\&=\sqrt{n}-\frac{\mathrm{Var}(S)}{8n^{3/2}}+\mathrm{E}[R_2(S,n)]\\&>\sqrt{n}-\frac{\alpha}{8\sqrt{n}}+\mathrm{E}[R_2(S,n)]。\end{aligned}$$

(之后只需估计 $\mathrm{E}[R(S,n)]$。直观而言，

$$\mathrm{E}[R(s,n)]\approx\frac{1}{6}f'''(n)\mathrm{E}[(S-n)^3]\sim n^{-5/2}\cdot O(n)=O(n^{-3/2}),$$

此处假设 $f'''(\xi)\approx f'''(n)$，即 s,n 是接近的，但当 s 接近于 0 时，$f'''(\xi)$ 可能为无穷大，这是不严谨的。)

作出以下推断：

推断 $\mathrm{E}[R(S,n)]=O(n^{-1})$。

(具体证明过程见注释。)

根据推断，可得

$$\mathrm{E}\|\boldsymbol{X}\|_2\leqslant\sqrt{n}-\frac{\alpha}{8\sqrt{n}}+o(n^{-1/2})\leqslant\sqrt{n}-\frac{c\alpha}{\sqrt{n}}。\qquad (c>0)$$

- 证明 $\mathrm{Var}(\|\boldsymbol{X}\|_2)\geqslant c\alpha$

  容易知道，

$$\begin{aligned}\mathrm{Var}(\|\boldsymbol{X}\|_2)&=\mathrm{E}\|\boldsymbol{X}\|_2^2-(\mathrm{E}\|\boldsymbol{X}\|_2)^2\\&=n-\left(\sqrt{n}-\frac{\alpha}{8\sqrt{n}}+O(n^{-1})\right)^2\\&=n-\left(n-\frac{\alpha}{4}+O(n^{-1})\right)\\&=\frac{\alpha}{4}+O(n^{-1})\geqslant c\alpha。\end{aligned}$$

(2) 若忽略条件 $\mathrm{Var}(X_i^2)>\alpha$，则可能出现 X_i^2 几乎处处为 1 的情况。

考虑以下反例：令 $X_1,\cdots,X_n$ i.i.d. $\sim$ Rademacher，此时 $\|\boldsymbol{X}\|_2=\sqrt{\sum_{i=1}^n 1}=\sqrt{n}$，因此 $\mathrm{Var}(\|\boldsymbol{X}\|_2)=0$，$\mathrm{E}\|\boldsymbol{X}\|_2=\sqrt{n}$，即“壳”的厚度完全坍缩为 0。

如此，方差的下界 α 衡量了坐标模长的波动程度，逆向薄壳界成立的前提是：构成向量的各个分量的“长度”必须存在不随维数增加而消失的随机波动 α。

注释 关于 $\mathrm{E}[R(s,n)]=O(n^{-1})$ 的证明过程：

定义“好集合” $A=\{|S-n|\leqslant n/2\}$，使得 $\xi\in[n/2,3n/2]$，此时

$$|f'''(\xi)|\leqslant\frac{3}{8(n/2)^{5/2}}=Cn^{-5/2},$$

因此

$$\mathrm{E}[|R(S,n)|\mathbf{1}_A]\leqslant Cn^{-5/2}\mathrm{E}[|S-n|^3]。$$

- 对于 A，注意到 $S-n$ 为独立零均值变量之和，因此利用 Rosenthal 不等式，令 $W_i = X_i^2 - 1$, $p=3$，可得

$$\mathrm{E}[|S-n|^3] \leqslant C_3\left(\sum_{i=1}^n \mathrm{E}[|W_i|^3] + \left(\sum_{i=1}^n \mathrm{E}[W_i^2]\right)^{3/2}\right) \leqslant C'(n+n^{3/2}) \leqslant C''n^{3/2};$$

从而 $\mathrm{E}[|R(S,n)|\mathbf{1}_A] \leqslant O(n^{-5/2}\cdot n^{3/2}) = O(n^{-1})$。

- 对于 A^c，利用 Chebyshev 不等式，可得

$$\mathrm{P}(A^c) = \mathrm{P}\left\{|S-n| > \frac{n}{2}\right\} \leqslant \frac{\mathrm{E}[|S-n|^3]}{(n/2)^3} \leqslant \frac{C''n^{3/2}}{n^3/8} = O(n^{-3/2})。$$

(之后只需证明

$$R(S,n) = \sqrt{S} - \left(\sqrt{n} + \frac{S-n}{2\sqrt{n}} - \frac{(S-n)^2}{8n^{3/2}}\right)$$

的任意一项于 A^c 的积分贡献均为 $O(n^{-1})$。)

对于第二项，

$$\mathrm{E}[\sqrt{n}\mathbf{1}_{A^c}] = \sqrt{n}\mathrm{P}(A^c) \leqslant \sqrt{n}\cdot O(n^{-3/2}) = O(n^{-1});$$

对于第三项，利用不等式 $\mathrm{E}[|Y|\mathbf{1}_{\{|Y|>\varepsilon\}}] \leqslant \mathrm{E}[|Y|^3]/\varepsilon^2$，令 $Y = S-n, \varepsilon = n/2$，可得

$$\mathrm{E}[|S-n|\mathbf{1}_{A^c}] \leqslant \frac{\mathrm{E}[|S-n|^3]}{(n/2)^2} \sim \frac{n^{3/2}}{n^2} = n^{-1/2},$$

因此

$$\mathrm{E}\left[\frac{|S-n|}{2\sqrt{n}}\mathbf{1}_{A^c}\right] = \frac{1}{\sqrt{n}}\cdot O(n^{-1/2}) = O(n^{-1});$$

对于第四项，

$$\mathrm{E}\left[\frac{(S-n)^2}{8n^{3/2}}\mathbf{1}_{A^c}\right] \leqslant \frac{1}{n^{3/2}}\frac{\mathrm{E}[|S-n|^3]}{n/2} \sim \frac{n^{3/2}}{n^{5/2}} = O(n^{-1});$$

对于第一项，不能直接使用 Taylor 展开 (S 可能接近于 0)，将 A^c 进一步拆分为 $\{S<n/2\}\sqcup\{S>3n/2\}$：

a. 当 $S<n/2$ 时，

$$\mathrm{E}[\sqrt{S}\mathbf{1}_{\{S<n/2\}}] \leqslant \sqrt{n}\mathrm{P}(A^c) = \sqrt{n}\cdot O(n^{-3/2}) = O(n^{-1})。$$

b. 当 $S>3n/2$ 时，利用凹函数的切线上界 $\sqrt{S} \leqslant (S+n)/2\sqrt{n}$，可得

$$\mathrm{E}[\sqrt{S}\mathbf{1}_{\{S>3n/2\}}] \leqslant \mathrm{E}\left[\frac{S+n}{2\sqrt{n}}\mathbf{1}_{\{S>3n/2\}}\right] = \frac{1}{2\sqrt{n}}\left(\mathrm{E}[S\mathbf{1}_{\{S>3n/2\}}] + n\mathrm{P}\left\{S>\frac{3n}{2}\right\}\right),$$

其中

$$\mathrm{E}[S\mathbf{1}_{A^c}] = \mathrm{E}[(n+S-n)\mathbf{1}_{A^c}] = O(n\cdot n^{-3/2} + n^{-1/2}) = O(n^{-1/2}),$$

将其代入，可得

$$\mathrm{E}[\sqrt{S}\mathbf{1}_{\{S>3n/2\}}] = \frac{1}{\sqrt{n}}\cdot O(n^{-1/2}) = O(n^{-1})。$$

4 [**PCA 最大化解释方差**] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为零均值随机向量，记 $\boldsymbol{\Sigma} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$ 的特征值为 $\lambda_1 \geqslant \lambda_2 \geqslant \cdots \geqslant \lambda_n$，其对应的单位正交特征向量为 $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_n$。

(1) 证明：向子空间 $\mathrm{span}\{\boldsymbol{v}_1, \cdots, \boldsymbol{v}_k\}$ 的正交投影算子 $\boldsymbol{P}_k$ 满足

$$\mathrm{E}\|\boldsymbol{P}_k\boldsymbol{X}\|_2^2 = \sum_{i=1}^k \mathrm{Var}(\langle\boldsymbol{X}, \boldsymbol{v}_i\rangle) = \sum_{i=1}^k \lambda_i。$$

(2) 证明：对于任意的满足 $\mathrm{rank}(\boldsymbol{P}) = k$ 的 $\boldsymbol{P}\in\mathbb{R}^n$，均满足

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{X}\|_2^2 \leqslant \mathrm{E}\|\boldsymbol{P}_k\boldsymbol{X}\|_2^2。$$

从而说明 PCA 最大化数据的解释方差，其解释比例由 s_k/s_n 给出，其中 $s_k = \sum_{i=1}^k \lambda_i$。

证明 由于 $\mathrm{E}[\boldsymbol{X}]=\boldsymbol{0}$，因此 $\mathrm{E}[\langle \boldsymbol{X},\boldsymbol{v}_i\rangle]=0$，可得

$$\begin{aligned}\mathrm{E}[\langle \boldsymbol{X},\boldsymbol{v}_i\rangle^2] &= \mathrm{Var}(\langle \boldsymbol{X},\boldsymbol{v}_i\rangle)\\ &= \boldsymbol{v}_i^\top \boldsymbol{\Sigma}\boldsymbol{v}_i = \boldsymbol{v}_i^\top(\lambda_i\boldsymbol{v}_i)=\lambda_i\|\boldsymbol{v}_i\|_2^2=\lambda_i。\end{aligned}$$

(1) 由于 $\boldsymbol{v}_1,\cdots,\boldsymbol{v}_k$ 为标准正交基，因此

$$\boldsymbol{P}_k\boldsymbol{X}=\sum_{i=1}^k\langle \boldsymbol{X},\boldsymbol{v}_i\rangle\boldsymbol{v}_i,$$

利用范数的正交分解性质，可得

$$\|\boldsymbol{P}_k\boldsymbol{X}\|_2^2=\sum_{i=1}^k\langle \boldsymbol{X},\boldsymbol{v}_i\rangle^2,$$

两侧取期望，

$$\mathrm{E}\|\boldsymbol{P}_k\boldsymbol{X}\|_2^2=\sum_{i=1}^k\mathrm{E}[\langle \boldsymbol{X},\boldsymbol{v}_i\rangle^2]=\sum_{i=1}^k\lambda_i。$$

(2) 设 $\boldsymbol{P}\in\mathbb{R}^n$ 为正交投影算子，满足 $\mathrm{rank}(\boldsymbol{P})=k$，则存在标准正交向量 $\boldsymbol{u}_1,\cdots,\boldsymbol{u}_k$，使得

$$\boldsymbol{P}\boldsymbol{X}=\sum_{j=1}^k\langle \boldsymbol{X},\boldsymbol{u}_j\rangle\boldsymbol{u}_j,$$

同理于 (1) 的结论，可得其投影的期望平方范数为

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{X}\|_2^2=\sum_{j=1}^k\boldsymbol{u}_j^\top\boldsymbol{\Sigma}\boldsymbol{u}_j=\mathrm{tr}(\boldsymbol{U}^\top\boldsymbol{\Sigma}\boldsymbol{U})。$$

根据特征值的变分刻画 (即 Poincaré 分离定理或 Ky Fan 迹定理)，可得对于对称半正定矩阵 $\boldsymbol{\Sigma}$，其前 k 个最大特征值之和满足

$$\sum_{i=1}^k\lambda_i=\max_{\boldsymbol{U}^\top\boldsymbol{U}=\boldsymbol{I}_k}\mathrm{tr}(\boldsymbol{U}^\top\boldsymbol{\Sigma}\boldsymbol{U}),$$

因此

$$\mathrm{tr}(\boldsymbol{U}^\top\boldsymbol{\Sigma}\boldsymbol{U})\leqslant\sum_{i=1}^k\lambda_i,$$

从而利用 (1) 的结论，可得

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{X}\|_2^2\leqslant\mathrm{E}\|\boldsymbol{P}_k\boldsymbol{X}\|_2^2。$$

这说明 PCA 选择的投影空间 (由前 k 个主特征向量张成) 能够最大限度地保留数据的方差 (即解释方差)。

5 [**随机向量的期望 ℓ^p 范数**] 设 $p\in[1,\infty]$。设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其中 X_i 是相互独立的 K-sub-Gaussian 随机变量。证明：

$$\mathrm{E}\|\boldsymbol{X}\|_p\leqslant\begin{cases}CK\sqrt{p}n^{1/p}, & p\leqslant\ln n,\\ CK\sqrt{\ln n}, & p\geqslant\ln n\end{cases}。$$

证明 对于任意的 $q\geqslant 1$，

$$\|X_i\|_{L_q}=(\mathrm{E}[|X_i|^q])^{1/q}\leqslant C_1K\sqrt{q},$$

因此 $\mathrm{E}[|X_i|^q]\leqslant(C_1K\sqrt{q})^q$。

对 p 的取值进行讨论：

a. 若 $p\leqslant\ln n$，则利用 Jensen 不等式，令 $\phi(x)=x^{1/p}$，可得

$$\mathrm{E}\|\boldsymbol{X}\|_p=\mathrm{E}\left[\left(\sum_{i=1}^n|X_i|^p\right)^{1/p}\right]\leqslant\left(\mathrm{E}\left[\sum_{i=1}^n|X_i|^p\right]\right)^{1/p}=\left(\sum_{i=1}^n\mathrm{E}[|X_i|^p]\right)^{1/p}$$

$$\leqslant \left(\sum_{i=1}^{n}(C_1K\sqrt{p})^p\right)^{1/p} = (n(C_1K\sqrt{p})^p)^{1/p} = C_1K\sqrt{p}n^{1/p}。$$

b. 若 $p \geqslant \ln n$，则

$$\begin{aligned}\mathrm{E}\|\boldsymbol{X}\|_p &\leqslant \mathrm{E}\|\boldsymbol{X}\|_{\ln n}\\ &\leqslant C_1K\sqrt{\ln n}n^{1/\ln n} = \mathrm{e}C_1K\sqrt{\ln n} = CK\sqrt{\ln n}。\end{aligned} \qquad (C, C_1 > 0, C = \mathrm{e}C_1)$$

6 [**Gaussian 向量期望 ℓ^p 范数的下界**] 证明习题 Q3.5 (随机向量的期望 ℓ^p 范数) 的界限对于标准 Gaussian 随机向量是可逆的。

具体而言，设 $\boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。证明：对于任意的 $p \in [1, \infty]$，

$$\mathrm{E}\|\boldsymbol{X}\|_p \geqslant \begin{cases} c\sqrt{p}n^{1/p}, & p \leqslant \ln n, \\ c\sqrt{\ln n}, & p \geqslant \ln n \end{cases}。$$

注释 回顾习题 Q2.22 (正态分布的绝对矩)，对于 $X \sim N(0,1)$，

$$\|X\|_{L_p} = (\mathrm{E}[|X|^p])^{1/p} = \left(\frac{2^{p/2}\Gamma((p+1)/2)}{\sqrt{\pi}}\right)^{1/p} \sim (c_1\sqrt{p})^p。 \qquad (c_1 > 0)$$

证明 对 p 的取值进行讨论：

a. 若 $p \leqslant \ln n$，令 $Z = \|\boldsymbol{X}\|_p^p = \sum_{i=1}^n |X_i|^p$，则

$$\mathrm{E}[Z] = \mathrm{E}\left[\sum_{i=1}^{n}|X_i|^p\right] = \sum_{i=1}^{n}\mathrm{E}[|X_i|^p] = n\mathrm{E}[|X|^p],$$

$$(\mathrm{E}[Z])^{1/p} = (n\mathrm{E}[|X|^p])^{1/p} = n^{1/p}\cdot(\mathrm{E}[|X|^p])^{1/p} = n^{1/p}\|X\|_{L_p} \geqslant c_1\sqrt{p}n^{1/p},$$

因此只需证明 $\mathrm{E}[Z^{1/p}] \geqslant c(\mathrm{E}[Z])^{1/p}$。

(Jensen 不等式只能得到 $\mathrm{E}[Z^{1/p}]$ 的上界；要想反转凹函数的 Jensen 不等式，必须证明 Z 满足反集中性，即 Z 不会塌缩到 0 附近。

最常用的方法即为示性函数截断，

$$\mathrm{E}[Z^{1/p}] \geqslant \mathrm{E}[Z^{1/p}\cdot\mathbf{1}_{\{Z\geqslant\theta\mathrm{E}[Z]\}}] \geqslant (\theta\mathrm{E}[Z])^{1/p}\cdot\mathrm{P}\{Z \geqslant \theta\mathrm{E}[Z]\},$$

其中 $(\mathrm{E}[Z])^{1/p}$ 已知，$\mathrm{P}\{Z \geqslant \theta\mathrm{E}[Z]\}$ 未知，之后只需使用 Paley-Zygmund 不等式 (二阶矩方法) 进行估计。)

Z 的的二阶矩比值为

$$\frac{\mathrm{E}[Z^2]}{(\mathrm{E}[Z])^2} = 1 + \frac{1}{n}\frac{\mathrm{Var}(|X|^p)}{(\mathrm{E}[|X|^p])^2} = 1 + \frac{1}{n}\frac{n(\mathrm{E}[|X|^{2p}] - (\mathrm{E}[|X|^p])^2)}{(\mathrm{E}[|X|^p])^2} \leqslant 1 + \frac{1}{n}\frac{\mathrm{E}[|X|^{2p}]}{(\mathrm{E}[|X|^p])^2},$$

其中

$$\frac{\mathrm{E}[|X|^{2p}]}{(\mathrm{E}[|X|^p])^2} \sim \frac{\sqrt{2}(2p/\mathrm{e})^p}{(\sqrt{2}(p/\mathrm{e})^{p/2})^2} = \frac{1}{\sqrt{2}}2^p \leqslant \frac{1}{\sqrt{2}}2^{\ln n} \leqslant \frac{1}{\sqrt{2}}n^{\ln 2},$$

将其代入，可得

$$\frac{\mathrm{E}[Z^2]}{(\mathrm{E}[Z])^2}\sqrt{2}n^{\ln 2 - 1} \leqslant 1 + \sqrt{2} =: C_0 \implies \mathrm{E}[Z^2] \leqslant C_0(\mathrm{E}[Z])^2,$$

因此利用 Paley-Zygmund 不等式，令 $\theta = 1/2$，可得

$$\mathrm{P}\left\{Z > \frac{1}{2}\mathrm{E}[Z]\right\} \geqslant \frac{(1-1/2)^2}{C_0} = \frac{1}{4C_0} =: \delta,$$

从而

$$\mathrm{E}[Z^{1/p}] \geqslant \mathrm{E}[Z^{1/p}\cdot\mathbf{1}_{\{Z>\frac{1}{2}\mathrm{E}[Z]\}}] \geqslant \left(\frac{1}{2}\mathrm{E}[Z]\right)^{1/p}\cdot\mathrm{P}\left\{Z > \frac{1}{2}\mathrm{E}[Z]\right\}$$

$$\geqslant \frac{1}{2^{1/p}} \cdot \delta \cdot (\mathrm{E}[Z])^{1/p} \geqslant \frac{1}{2} \cdot \delta \cdot (n(c_1\sqrt{p})^p)^{1/p}$$
$$= \frac{\delta c_1}{2}\sqrt{p}n^{1/p} = C\sqrt{p}n^{1/p}。 \qquad \left(C = \frac{\delta c_1}{2}\right)$$

b. 若 $p \geqslant \ln n$，则

$$\|\boldsymbol{X}\|_p \geqslant \|\boldsymbol{X}\|_\infty = \max_{1\leqslant i\leqslant n} |X_i|,$$

两侧取期望，

$$\mathrm{E}\|\boldsymbol{X}\|_p \geqslant \mathrm{E}\left[\max_{1\leqslant i\leqslant n} |X_i|\right],$$

其中根据习题 Q2.38 (Gaussian 随机变量的极大值)，可得 $\mathrm{E}[\max_i X_i] \sim \sqrt{2\ln n}$，将其代入，

$$\mathrm{E}\|\boldsymbol{X}\|_p \geqslant c_2\sqrt{\ln n}。 \qquad (c_2 > 0)$$

7 [**小球概率**] 设 $\boldsymbol{X} \in \mathbb{R}^n$ 为随机向量，其元素服从相互独立的连续分布，满足 $\sup f_i(x) \leqslant K$。

(1) 证明：$\boldsymbol{X}$ 落于半径为 $o(\sqrt{n})$ 的球体的概率极低。具体而言，对于任意的 $\boldsymbol{a} \in \mathbb{R}^n$，

$$\mathrm{P}\{\|\boldsymbol{X} - \boldsymbol{a}\|_2 \leqslant \varepsilon\sqrt{n}\} \leqslant (\sqrt{2\pi\mathrm{e}}K\varepsilon)^n。$$

(2) 利用 (1) 的结论，证明：当 $n \geqslant 2$ 时，

$$\mathrm{E}\left[\frac{1}{\|\boldsymbol{X}\|_2}\right] \leqslant \frac{CK}{\sqrt{n}}。$$

之后解释当 $n = 1$ 时，上述期望值可能发散为无穷。

证明 (1) 容易知道，

$$f(\boldsymbol{x}) = \prod_{i=1}^n f_i(x_i) \leqslant \prod_{i=1}^n K = K^n。$$

$\boldsymbol{X}$ 落于 $B(\boldsymbol{a}, r)$ 内部的概率等于密度函数于球体的积分，即

$$\mathrm{P}\{\|\boldsymbol{X} - \boldsymbol{a}\|_2 \leqslant r\} = \int_{B(\boldsymbol{a},r)} f(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \leqslant \int_{B(\boldsymbol{a},r)} K^n \mathrm{d}\boldsymbol{x} = K^n \cdot \mathrm{Vol}(B(\boldsymbol{a}, r)),$$

其中

$$\mathrm{Vol}(B(\boldsymbol{a}, r)) = \frac{\pi^{n/2}r^n}{\Gamma(n/2+1)} \leqslant \frac{\pi^{n/2}(\varepsilon\sqrt{n})^n}{(n/2\mathrm{e})^{n/2}} = \frac{\pi^{n/2}\varepsilon^n n^{n/2}}{n^{n/2}(2\mathrm{e})^{-n/2}} = (2\pi\mathrm{e})^{n/2}\varepsilon^n = (\sqrt{2\pi\mathrm{e}}\varepsilon)^n,$$

将其代入，可得

$$\mathrm{P}\{\|\boldsymbol{X} - \boldsymbol{a}\|_2 \leqslant \varepsilon\sqrt{n}\} \leqslant K^n(\sqrt{2\pi\mathrm{e}}\varepsilon)^n = (\sqrt{2\pi\mathrm{e}}K\varepsilon)^n。$$

(2) 令 $t_0 = \sqrt{2\pi\mathrm{e}}K/\sqrt{n}$，将积分于 t_0 分解，

$$\mathrm{E}\left[\frac{1}{\|\boldsymbol{X}\|_2}\right] = \int_0^\infty \mathrm{P}\left\{\|\boldsymbol{X}\|_2 \leqslant \frac{1}{t}\right\}\mathrm{d}t$$
$$= \underbrace{\int_0^{t_0} \mathrm{P}\left\{\|\boldsymbol{X}\|_2 \leqslant \frac{1}{t}\right\}\mathrm{d}t}_{I_1} + \underbrace{\int_{t_0}^\infty \mathrm{P}\left\{\|\boldsymbol{X}\|_2 \leqslant \frac{1}{t}\right\}\mathrm{d}t}_{I_2},$$

对于 I_1，

$$I_1 \leqslant \int_0^{t_0} 1\mathrm{d}t = t_0 = \frac{\sqrt{2\pi\mathrm{e}}K}{\sqrt{n}};$$

对于 I_2，令 $1/t = \varepsilon\sqrt{n}$，即 $\varepsilon = 1/t\sqrt{n}$，则利用 (1) 的结论，令 $\boldsymbol{a} = \boldsymbol{0}$，可得

$$\mathrm{P}\left\{\|\boldsymbol{X}\|_2 \leqslant \frac{1}{t}\right\} \leqslant \left(\sqrt{2\pi\mathrm{e}}K \cdot \frac{1}{t\sqrt{n}}\right)^n = \left(\frac{t_0}{t}\right)^n,$$

将其代入，可得

$$I_2 \leqslant \int_{t_0}^{\infty} \left(\frac{t_0}{t}\right)^n \mathrm{d}t = t_0^n \left[\frac{t^{-n+1}}{-n+1}\right]_{t_0}^{\infty} = \frac{t_0^n \cdot t_0^{-n+1}}{n-1} = \frac{t_0}{n-1} \leqslant t_0。 \qquad (n \geqslant 2)$$

如此，

$$\mathrm{E}\left[\frac{1}{\|\boldsymbol{X}\|_2}\right] \leqslant t_0 + \frac{t_0}{n-1} \leqslant 2t_0 = \frac{2\sqrt{2\pi\mathrm{e}}K}{\sqrt{n}} = \frac{CK}{\sqrt{n}}。 \qquad (C = 2\sqrt{2\pi\mathrm{e}})$$

当 $n = 1$ 时，$\|\boldsymbol{X}\|_2 = |X_1|$，此时

$$\mathrm{E}\left[\frac{1}{|X_1|}\right] = \int_{-\infty}^{\infty} \frac{1}{|x|} f_1(x)\mathrm{d}x,$$

若 $f_1(x)$ 于原点附近不为零，则被积函数类似于 $1/|x|$，上述积分将发散。

8 [各向同性随机向量的期望]

(1) 证明：若 $\boldsymbol{X} \in \mathbb{R}^n$ 是各向同性的，则 $\|\mathrm{E}[\boldsymbol{X}]\|_2 \leqslant 1$。

(2) 证明：上述上界通常是最优的，即存在各向同性随机向量 $\boldsymbol{X} \in \mathbb{R}^n$，使得 $\|\mathrm{E}[\boldsymbol{X}]\|_2 = 1$。

证明 (1) 容易知道，

$$\mathrm{Cov}(\boldsymbol{X}) = \mathrm{E}[(\boldsymbol{X}-\boldsymbol{\mu})(\boldsymbol{X}-\boldsymbol{\mu})^\top] = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] - \mathrm{E}[\boldsymbol{X}]\mathrm{E}[\boldsymbol{X}]^\top = \boldsymbol{I}_n - \boldsymbol{\mu}\boldsymbol{\mu}^\top,$$

因此对于任意的 $\boldsymbol{u} \in \mathbb{R}^n$，

$$\boldsymbol{u}^\top \mathrm{Cov}(\boldsymbol{X})\boldsymbol{u} = \boldsymbol{u}^\top(\boldsymbol{I}_n - \boldsymbol{\mu}\boldsymbol{\mu}^\top)\boldsymbol{u} = \boldsymbol{u}^\top\boldsymbol{u} - (\boldsymbol{u}^\top\boldsymbol{\mu})(\boldsymbol{\mu}^\top\boldsymbol{u}) = \|\boldsymbol{u}\|_2^2 - \langle \boldsymbol{u}, \boldsymbol{\mu}\rangle^2 \geqslant 0。$$

当 $\boldsymbol{\mu} \neq \boldsymbol{0}$ 时，令 $\boldsymbol{u} = \boldsymbol{\mu}$，则

$$\begin{aligned} \|\boldsymbol{\mu}\|_2^2 - \langle \boldsymbol{\mu}, \boldsymbol{\mu}\rangle^2 = \|\boldsymbol{\mu}\|_2^2 - \|\boldsymbol{\mu}\|_2^4 \geqslant 0 &\implies \|\boldsymbol{\mu}\|_2^2(1 - \|\boldsymbol{\mu}\|_2^2) \geqslant 0 \\ &\implies \|\boldsymbol{\mu}\|_2^2 \leqslant 1, \end{aligned}$$

两侧开方，可得 $\|\mathrm{E}[\boldsymbol{X}]\|_2 \leqslant 1$。

(2) 令 $\boldsymbol{X} = (X_1, \cdots, X_n)$，其中 $X_1 = 1$ (a.s.)，$X_2, \cdots, X_n$ i.i.d. $\sim N(0,1)$ (或者令 $X_2, \cdots, X_n$ i.i.d. $\sim$ Rademacher)，则

$$\mathrm{E}[\boldsymbol{X}] = (1, 0, \cdots, 0)^\top,\ \|\mathrm{E}[\boldsymbol{X}]\|_2 = \sqrt{1^2 + 0 + \cdots + 0} = 1,$$

之后只需验证各向同性条件 $\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \boldsymbol{I}_n$。

a. 对于对角线元素，当 $i = 1$ 时，$\mathrm{E}[X_1^2] = 1^2 = 1$；当 $i \geqslant 2$ 时，$\mathrm{E}[X_i^2] = \mathrm{Var}(X_i) + (\mathrm{E}[X_i])^2 = 1 + 0^2 = 1$。

b. 对于非对角线元素，当 $i \geqslant 2$ 时，$\mathrm{E}[X_1X_i] = \mathrm{E}[1 \cdot X_i] = \mathrm{E}[X_i] = 0$；当 $i, j \geqslant 2, i \neq j$ 时，$\mathrm{E}[X_iX_j] = \mathrm{E}[X_i]\mathrm{E}[X_j] = 0 \cdot 0 = 0$。

如此，$\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \boldsymbol{I}_n$。

9 [各向同性分布的一维边际] 设 $\boldsymbol{X} \in \mathbb{R}^n$ 为各向同性的随机向量，对于任意的 $\boldsymbol{u} \in \mathbb{R}^n$，考虑随机变量 $X_{\boldsymbol{u}} = \langle \boldsymbol{X}, \boldsymbol{u}\rangle$。证明：

$$\mathrm{E}[X_{\boldsymbol{u}}X_{\boldsymbol{v}}] = \langle \boldsymbol{u}, \boldsymbol{v}\rangle,\ \|X_{\boldsymbol{u}} - X_{\boldsymbol{v}}\|_{L^2} = \|\boldsymbol{u} - \boldsymbol{v}\|_2。$$

证明 (1) 容易知道，

$$X_{\boldsymbol{u}}X_{\boldsymbol{v}} = (\boldsymbol{u}^\top\boldsymbol{X})(\boldsymbol{v}^\top\boldsymbol{X}) = \boldsymbol{u}^\top\boldsymbol{X}\boldsymbol{X}^\top\boldsymbol{v},$$

两侧取期望，

$$\mathrm{E}[X_{\boldsymbol{u}}X_{\boldsymbol{v}}] = \mathrm{E}[\boldsymbol{u}^\top\boldsymbol{X}\boldsymbol{X}^\top\boldsymbol{v}] = \boldsymbol{u}^\top\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]\boldsymbol{v} = \boldsymbol{u}^\top\boldsymbol{v} = \langle \boldsymbol{u}, \boldsymbol{v}\rangle。$$

(2) 容易知道，

$$X_{\boldsymbol{u}} - X_{\boldsymbol{v}} = \langle \boldsymbol{X}, \boldsymbol{u}\rangle - \langle \boldsymbol{X}, \boldsymbol{v}\rangle = \langle \boldsymbol{X}, \boldsymbol{u} - \boldsymbol{v}\rangle = X_{\boldsymbol{u}-\boldsymbol{v}} = X_{\boldsymbol{w}}, \qquad (\boldsymbol{w} = \boldsymbol{u} - \boldsymbol{v})$$

利用 (1) 的结论，令 $\boldsymbol{u} = \boldsymbol{v} = \boldsymbol{w}$，可得

$$\mathrm{E}[X_{\boldsymbol{w}}^2] = \mathrm{E}[X_{\boldsymbol{w}}X_{\boldsymbol{w}}] = \langle \boldsymbol{w}, \boldsymbol{w}\rangle = \|\boldsymbol{w}\|_2^2,$$

因此

$$\|X_{\boldsymbol{u}} - X_{\boldsymbol{v}}\|_{L^2}^2 = \mathrm{E}[(X_{\boldsymbol{u}} - X_{\boldsymbol{v}})^2] = \mathrm{E}[X_{\boldsymbol{u}-\boldsymbol{v}}^2] = \|\boldsymbol{u} - \boldsymbol{v}\|_2^2,$$

两侧开方，可得 $\|X_{\boldsymbol{u}} - X_{\boldsymbol{v}}\|_{L^2} = \|\boldsymbol{u} - \boldsymbol{v}\|_2$。

10 [随机向量的标准分数]

(1) 设 $\boldsymbol{\mu} \in \mathbb{R}^n$，$\boldsymbol{\Sigma} \in \mathbb{R}^{n\times n}$ 为半正定矩阵，$\boldsymbol{Z} \in \mathbb{R}^n$ 为各向同性的标准化随机向量。证明：$\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}$ 满足

$$\mathrm{E}[\boldsymbol{X}] = \boldsymbol{\mu},\ \ \mathrm{Cov}(\boldsymbol{X}) = \boldsymbol{\Sigma}。$$

(2) 反之，设 $\boldsymbol{X}$ 满足 $\mathrm{E}[\boldsymbol{X}] = \boldsymbol{\mu}$，$\mathrm{Cov}(\boldsymbol{X}) = \boldsymbol{\Sigma}$。构造各向同性的随机向量 $\boldsymbol{Z}$，满足 $\mathrm{E}[\boldsymbol{Z}] = 0$，使得 $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}$ (a.s.)。

证明 (1) 对于期望，

$$\mathrm{E}[\boldsymbol{X}] = \mathrm{E}[\boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}] = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\mathrm{E}[\boldsymbol{Z}] = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\cdot\boldsymbol{0} = \boldsymbol{\mu}。$$

对于协方差矩阵，

$$\begin{aligned}\mathrm{Cov}(\boldsymbol{X}) &= \mathrm{E}[(\boldsymbol{X}-\boldsymbol{\mu})(\boldsymbol{X}-\boldsymbol{\mu})^\top] = \mathrm{E}[(\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z})(\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z})^\top] = \mathrm{E}[\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}\boldsymbol{Z}^\top(\boldsymbol{\Sigma}^{1/2})^\top]\\ &= \boldsymbol{\Sigma}^{1/2}\mathrm{E}[\boldsymbol{Z}\boldsymbol{Z}^\top]\boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Sigma}^{1/2}\boldsymbol{I}\boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Sigma}。\end{aligned}$$

(2) 设 $\mathrm{rank}(\boldsymbol{\Sigma}) = r$，$\boldsymbol{\Sigma}$ 的特征分解为

$$\boldsymbol{\Sigma} = \sum_{i=1}^{n}\lambda_i\boldsymbol{u}_i\boldsymbol{u}_i^\top,$$

其中 $\lambda_1 \geqslant \cdots \geqslant \lambda_r > \lambda_{r+1} = \cdots = \lambda_n = 0$，$\{\boldsymbol{u}_i\}_{i=1}^n$ 是标准正交特征向量，则

$$\boldsymbol{\Sigma}^{1/2} = \sum_{i=1}^{r}\sqrt{\lambda_i}\boldsymbol{u}_i\boldsymbol{u}_i^\top。$$

注意到 $\boldsymbol{X} - \boldsymbol{\mu} \in \mathcal{C}(\boldsymbol{\Sigma})$，进行以下构造：

i. 首先于 $\mathcal{C}(\boldsymbol{\Sigma})$ 构造主分量，

$$\boldsymbol{Z}_0 = \sum_{i=1}^{r}\frac{1}{\sqrt{\lambda_i}}\langle\boldsymbol{X}-\boldsymbol{\mu},\boldsymbol{u}_i\rangle\boldsymbol{u}_i,$$

则 $\mathrm{E}[\boldsymbol{Z}_0] = \boldsymbol{0}$，$\mathrm{Cov}(\boldsymbol{Z}_0) = \sum_{i=1}^r \boldsymbol{u}_i\boldsymbol{u}_i^\top$ (即子空间的投影矩阵)。

ii. 之后于 $\ker(\boldsymbol{\Sigma})$ 补充独立各向同性白噪声，引入独立于 $\boldsymbol{X}$ 的标准随机向量 $\boldsymbol{W} = (W_{r+1},\cdots,W_n)^\top$，满足 $\mathrm{E}[\boldsymbol{W}] = \boldsymbol{0}$，$\mathrm{Cov}(\boldsymbol{W}) = \boldsymbol{I}_{n-r}$ (例如独立标准正态分布)，令

$$\boldsymbol{Z} = \boldsymbol{Z}_0 + \sum_{i=r+1}^{n}W_i\boldsymbol{u}_i,$$

则

$$\mathrm{E}[\boldsymbol{Z}] = \boldsymbol{0},\ \ \mathrm{Cov}(\boldsymbol{Z}) = \sum_{i=1}^{r}\boldsymbol{u}_i\boldsymbol{u}_i^\top + \sum_{i=r+1}^{n}\boldsymbol{u}_i\boldsymbol{u}_i^\top = \boldsymbol{I}_n,$$

可得 $\boldsymbol{Z}$ 是各向同性的。

由于 $\boldsymbol{u}_i \in \ker(\boldsymbol{\Sigma}^{1/2})$，因此当 $i > r$ 时，

$$\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z} = \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}_0 + \boldsymbol{0} = \sum_{j=1}^{r}\sqrt{\lambda_j}\boldsymbol{u}_j\boldsymbol{u}_j^\top\left(\sum_{i=1}^{r}\frac{1}{\sqrt{\lambda_i}}\langle\boldsymbol{X}-\boldsymbol{\mu},\boldsymbol{u}_i\rangle\boldsymbol{u}_i\right) = \sum_{i=1}^{r}\langle\boldsymbol{X}-\boldsymbol{\mu},\boldsymbol{u}_i\rangle\boldsymbol{u}_i = \boldsymbol{X}-\boldsymbol{\mu}\ \text{(a.s.)}。$$

即 $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}$ (a.s.)。

11 [随机排列向量] 设 $\boldsymbol{x} \in \mathbb{R}^n$ 满足 $\sum_{i=1}^n x_i = 0$，$\sum_{i=1}^n x_i^2 = 1$，$\boldsymbol{X}$ 为通过随机排列 $\boldsymbol{x}$ 的坐标得到的随机向量，即 $\boldsymbol{X} = (X_1,\cdots,X_n) = (x_{\sigma(1)},\cdots,x_{\sigma(n)})$，其中 σ 为集合 $\{1,\cdots,n\}$ 的随机置换。

(1) 试求 $\mathrm{E}[\boldsymbol{X}], \mathrm{Cov}(\boldsymbol{X})$。

(2) 说明 $\boldsymbol{X}$ 的各个坐标之间是负相关的原因。

解答 (1) 置换 σ 是均匀随机选择的，即 $\mathrm{P}\{\sigma(i) = j\} = 1/n$，因此

$$\mathrm{E}[X_i] = \sum_{j=1}^{n}\mathrm{P}\{\sigma(i)=j\}x_j = \frac{1}{n}\sum_{j=1}^{n}x_j = 0,$$

即 $\mathrm{E}[\boldsymbol{X}]=\mathbf{0}$，从而

$$\mathrm{Var}(X_i)=\mathrm{E}[X_i^2]=\sum_{j=1}^{n}\mathrm{P}\{\sigma(i)=j\}x_j^2=\sum_{j=1}^{n}\frac{1}{n}x_j^2=\frac{1}{n}\sum_{j=1}^{n}x_j^2=\frac{1}{n}。$$

注意到 $\boldsymbol{X}$ 为 $\boldsymbol{x}$ 的排列，满足 $\sum_{k=1}^{n}X_k=\sum_{k=1}^{n}x_k=0$，因此

$$0=\mathrm{Var}\left(\sum_{k=1}^{n}X_k\right)=\sum_{k=1}^{n}\mathrm{Var}(X_k)+\sum_{k\neq l}\mathrm{Cov}(X_k,X_l),$$

其中根据对称性，所有非对角线处的协方差均相等，记为 $\mathrm{Cov}(X_i,X_j)=\rho$，将其代入，可得

$$0=n\cdot\frac{1}{n}+n(n-1)\rho\implies\rho=-\frac{1}{n(n-1)},$$

即

$$\mathrm{Cov}(\boldsymbol{X})=\frac{1}{n-1}\left(\boldsymbol{I}_n-\frac{1}{n}\mathbf{1}\mathbf{1}^{\top}\right)。$$

(2) 受限于 $\sum_{i=1}^{n}X_i=0$，若其中的分量 X_i 取得了较大的正值，则剩余的分量 $\{X_k\}_{k\neq i}$ 必须共同承担对应的负值，表现为负相关。于高维空间，这种约束说明随机点被限制于垂直于全 1 向量的超平面，导致分量之间不能完全独立波动。

12 [**独立各向同性随机向量之间的距离**] 设 $\boldsymbol{X},\boldsymbol{Y}\in\mathbb{R}^n$ 为独立的各向同性的随机向量，满足 $\mathrm{E}[\boldsymbol{X}]=\mathrm{E}[\boldsymbol{Y}]=\mathbf{0}$。证明：

$$\mathrm{E}\|\boldsymbol{X}-\boldsymbol{Y}\|_2^2=2n。$$

证明 将 Euclidean 范数展开，

$$\|\boldsymbol{X}-\boldsymbol{Y}\|_2^2=\|\boldsymbol{X}\|_2^2+\|\boldsymbol{Y}\|_2^2-2\langle\boldsymbol{X},\boldsymbol{Y}\rangle,$$

两侧取期望，

$$\mathrm{E}\|\boldsymbol{X}-\boldsymbol{Y}\|_2^2=\mathrm{E}\|\boldsymbol{X}\|_2^2+\mathrm{E}\|\boldsymbol{Y}\|_2^2-2\mathrm{E}[\langle\boldsymbol{X},\boldsymbol{Y}\rangle],$$

其中

$$\begin{aligned}\mathrm{E}\|\boldsymbol{X}\|_2^2&=\mathrm{E}[\mathrm{tr}(\boldsymbol{X}\boldsymbol{X}^{\top})]=\mathrm{tr}(\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^{\top}])=\mathrm{tr}(\boldsymbol{I}_n)=n,\\ \mathrm{E}\|\boldsymbol{Y}\|_2^2&=\mathrm{E}[\mathrm{tr}(\boldsymbol{Y}\boldsymbol{Y}^{\top})]=\mathrm{tr}(\mathrm{E}[\boldsymbol{Y}\boldsymbol{Y}^{\top}])=\mathrm{tr}(\boldsymbol{I}_n)=n,\\ \mathrm{E}[\langle\boldsymbol{X},\boldsymbol{Y}\rangle]&=\sum_{i=1}^{n}\mathrm{E}[X_iY_i]=\sum_{i=1}^{n}\mathrm{E}[X_i]\mathrm{E}[Y_i]=\sum_{i=1}^{n}0\cdot0=0,\end{aligned}$$

将其代入，可得

$$\mathrm{E}\|\boldsymbol{X}-\boldsymbol{Y}\|_2^2=n+n-2\cdot0=2n。$$

13 [**随机向量的最大范数**] 证明命题 P2.7.6 (sub-Gaussian 随机变量的最大值) 的高维版本。

(1) 设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N\in\mathbb{R}^n$ 为随机向量 (未必独立)，其内部元素为相互独立, 中心化的 K-sub-Gaussian 随机变量。证明：

$$\mathrm{E}\left[\max_{i\leqslant N}\|\boldsymbol{X}_i\|_2\right]\leqslant\sqrt{n}+CK^2\sqrt{\ln N}。\qquad(C>0)$$

(2) 说明 (1) 的界限对于独立同分布的标准正态随机向量是渐近紧的。具体而言，若 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ i.i.d. $\sim N(\mathbf{0},\boldsymbol{I}_n)$，证明：

$$\mathrm{E}\left[\max_{i\leqslant N}\|\boldsymbol{X}_i\|_2\right]\geqslant c(\sqrt{n}+\sqrt{\ln N})。\qquad(c>0)$$

证明 (1) 为了控制随机向量的最大模长，将其分解为确定性几何半径 $\sqrt{n}$ 与随机残差项，

$$\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2=\sqrt{n}+\max_{1\leqslant i\leqslant N}(\|\boldsymbol{X}_i\|_2-\sqrt{n}),$$

令 $Z_i:=\|\boldsymbol{X}_i\|_2-\sqrt{n}$，则根据定理 T3.1.1 (范数的集中)，可得对于任意的 $t\geqslant0$，

$$\mathrm{P}\{|\|\boldsymbol{X}_i\|_2-\sqrt{n}|\geqslant t\}\leqslant2\exp\left(-\frac{c_0t^2}{K^4}\right)\implies\|Z_i\|_{\psi_2}\leqslant C_1K^2,$$

因此根据命题 P2.7.6 (sub-Gaussian 随机变量的最大值)，可得

$$\mathrm{E}\left[\max_{i\leqslant N} Z_i\right] \leqslant C_2\sqrt{\ln N}\max_{i\leqslant N}\|Z_i\|_{\psi_2} \leqslant C_2\sqrt{\ln N}(C_1K^2) =: CK^2\sqrt{\ln N}, \qquad (C = C_1C_2)$$

从而

$$\mathrm{E}\left[\max_{i\leqslant N}\|\boldsymbol{X}_i\|_2\right] = \mathrm{E}\left[\max_{i\leqslant N}(\sqrt{n}+Z_i)\right] = \sqrt{n}+\mathrm{E}\left[\max_{i\leqslant N} Z_i\right] \leqslant \sqrt{n}+CK^2\sqrt{\ln N}。$$

(2) 若 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则 $K = O(1)$。

同理于 (1) 的结论，令 $\mathrm{E}\|\boldsymbol{X}_i\|_2 = \mu_n \asymp \sqrt{n}$，$Z_i = \|\boldsymbol{X}_i\|_2 - \mu_n$，则

$$\begin{aligned}\mathrm{E}\left[\max_{i\leqslant N}\|\boldsymbol{X}_i\|_2\right] &= \mathrm{E}\left[\max_{i\leqslant N}(\mu_n+Z_i)\right] = \mu_n+\mathrm{E}\left[\max_{i\leqslant N} Z_i\right]\\ &\geqslant c_1'\sqrt{n}+c_2\sqrt{\ln N} \geqslant c(\sqrt{n}+\sqrt{\ln N})。 \qquad (c=\min(c_1,c_2))\end{aligned}$$

14 [正态分布的一维边际] 证明：若 $\boldsymbol{X}\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，则对于任意的 $\boldsymbol{v}\in\mathbb{R}^n$，

$$\langle\boldsymbol{X},\boldsymbol{v}\rangle \sim N(\langle\boldsymbol{\mu},\boldsymbol{v}\rangle, \boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})。$$

证明 对于 $\boldsymbol{X}\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，其特征函数为

$$\varphi_{\boldsymbol{X}}(\boldsymbol{t}) = \mathrm{E}[\exp(\mathrm{i}\boldsymbol{t}^\top\boldsymbol{X})] = \exp\left(\mathrm{i}\boldsymbol{t}^\top\boldsymbol{\mu}-\frac{1}{2}\boldsymbol{t}^\top\boldsymbol{\Sigma}\boldsymbol{t}\right),$$

对于 $Y = \langle\boldsymbol{X},\boldsymbol{v}\rangle = \boldsymbol{v}^\top\boldsymbol{X}$，其特征函数为

$$\varphi_Y(t) = \mathrm{E}[\exp(\mathrm{i}tY)] = \mathrm{E}[\exp(\mathrm{i}t(\boldsymbol{v}^\top\boldsymbol{X}))] = \mathrm{E}[\exp(\mathrm{i}(t\boldsymbol{v})^\top\boldsymbol{X})],$$

因此

$$\begin{aligned}\varphi_Y(t) = \varphi_{\boldsymbol{X}}(t\boldsymbol{v}) &= \exp\left(\mathrm{i}(t\boldsymbol{v})^\top\boldsymbol{\mu}-\frac{1}{2}(t\boldsymbol{v})^\top\boldsymbol{\Sigma}(t\boldsymbol{v})\right)\\ &= \exp\left(\mathrm{i}t(\boldsymbol{v}^\top\boldsymbol{\mu})-\frac{1}{2}t^2(\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})\right)\\ &:= \exp\left(\mathrm{i}t\mu_Y-\frac{1}{2}t^2\sigma_Y^2\right), \qquad (\mu_Y=\langle\boldsymbol{\mu},\boldsymbol{v}\rangle, \sigma_Y^2=\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})\end{aligned}$$

从而根据特征函数的唯一性定理，可得

$$\langle\boldsymbol{X},\boldsymbol{v}\rangle \sim N(\langle\boldsymbol{\mu},\boldsymbol{v}\rangle, \boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})。$$

15 [一般正态密度函数] 证明命题 P3.3.6 (一般正态密度)。

证明 对于任意的 $B\in\mathscr{B}(\mathbb{R}^n)$，

$$\mathrm{P}\{\boldsymbol{X}\in B\} = \int_B f_{\boldsymbol{X}}(\boldsymbol{x})\mathrm{d}\boldsymbol{x}。$$

设 $\boldsymbol{Y} = \boldsymbol{X}-\boldsymbol{\mu}\sim N(\boldsymbol{0},\boldsymbol{\Sigma})$，则 $f_{\boldsymbol{X}}(\boldsymbol{x}) = f_{\boldsymbol{Y}}(\boldsymbol{x}-\boldsymbol{\mu})$，因此只需推导零均值情况的密度函数即可。

设 $\boldsymbol{Z}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，其密度函数为

$$f_{\boldsymbol{Z}}(\boldsymbol{z}) = \frac{1}{(2\pi)^{n/2}}\mathrm{e}^{-\frac{1}{2}\|\boldsymbol{z}\|_2^2},$$

则根据正态分布的线性变换不变性，可得 $\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}\sim N(\boldsymbol{0},\boldsymbol{\Sigma}^{1/2}\boldsymbol{I}_n(\boldsymbol{\Sigma}^{1/2})^\top) = N(\boldsymbol{0},\boldsymbol{\Sigma})$，因此令 $\boldsymbol{X} = \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}$，可得对于任意的 $B\in\mathscr{B}(\mathbb{R}^n)$，

$$\mathrm{P}\{\boldsymbol{X}\in B\} = \mathrm{P}\{\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}\in B\} = \mathrm{P}\{\boldsymbol{Z}\in\boldsymbol{\Sigma}^{-1/2}B\} = \int_{\boldsymbol{\Sigma}^{-1/2}B}\frac{1}{(2\pi)^{n/2}}\mathrm{e}^{-\frac{1}{2}\boldsymbol{z}^\top\boldsymbol{z}}\mathrm{d}\boldsymbol{z},$$

令 $\boldsymbol{x} = \boldsymbol{\Sigma}^{1/2}\boldsymbol{z}$，则 $\boldsymbol{z} = \boldsymbol{\Sigma}^{-1/2}\boldsymbol{x}$，此时

$$\boldsymbol{z}^\top\boldsymbol{z} = (\boldsymbol{\Sigma}^{-1/2}\boldsymbol{x})^\top(\boldsymbol{\Sigma}^{-1/2}\boldsymbol{x}) = \boldsymbol{x}^\top(\boldsymbol{\Sigma}^{-1/2})^\top\boldsymbol{\Sigma}^{-1/2}\boldsymbol{x} = \boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x},$$

其 Jacobi 行列式为

$$\left|\det\left(\frac{\mathrm{d}\boldsymbol{z}}{\mathrm{d}\boldsymbol{x}}\right)\right| = |\det(\boldsymbol{\Sigma}^{-1/2})| = \frac{1}{\sqrt{\det\boldsymbol{\Sigma}}},$$

将其代入，可得

$$\mathrm{P}\{\boldsymbol{X}\in B\}=\int_B\frac{1}{(2\pi)^{n/2}}\mathrm{e}^{-\frac{1}{2}\boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x}}\frac{1}{\sqrt{\det\boldsymbol{\Sigma}}}\mathrm{d}\boldsymbol{x}=\int_B\frac{1}{(2\pi)^{n/2}\sqrt{\det\boldsymbol{\Sigma}}}\mathrm{e}^{-\frac{1}{2}\boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x}}\mathrm{d}\boldsymbol{x}。$$

如此，令 $\boldsymbol{x}\leftarrow\boldsymbol{x}-\boldsymbol{\mu}$，可得一般情况的密度函数为

$$f_{\boldsymbol{X}}(\boldsymbol{x})=\frac{1}{(2\pi)^{n/2}\sqrt{\det\boldsymbol{\Sigma}}}\mathrm{e}^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})}。$$

16 [联合正态分布的刻画]

(1) 证明：$\boldsymbol{X}\in\mathbb{R}^n$ 服从正态分布，当且仅当对于任意的 $\boldsymbol{u}\in\mathbb{R}^n$，其一维边际 $\langle\boldsymbol{X},\boldsymbol{u}\rangle$ 均服从正态分布。

(2) 利用 (1) 的结论，证明：$X_1,\cdots,X_n$ 是联合正态的，当且仅当其线性组合 $a_1X_1+\cdots+a_nX_n$ 均服从正态分布。

证明 (1) ($\Longrightarrow$)

若 $\boldsymbol{X}\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，则对于任意的 $\boldsymbol{u}\in\mathbb{R}^n$，$\langle\boldsymbol{X},\boldsymbol{u}\rangle\sim N(\boldsymbol{u}^\top\boldsymbol{\mu},\boldsymbol{u}^\top\boldsymbol{\Sigma}\boldsymbol{u})$。

($\Longleftarrow$)

设 $Y_{\boldsymbol{u}}=\langle\boldsymbol{X},\boldsymbol{u}\rangle$，则

$$\mathrm{E}[Y_{\boldsymbol{u}}]=\mathrm{E}[\boldsymbol{u}^\top\boldsymbol{X}]=\boldsymbol{u}^\top\boldsymbol{\mu},\quad\mathrm{Var}(Y_{\boldsymbol{u}})=\mathrm{Var}(\boldsymbol{u}^\top\boldsymbol{X})=\boldsymbol{u}^\top\boldsymbol{\Sigma}\boldsymbol{u},$$

其特征函数为

$$\varphi_{Y_{\boldsymbol{u}}}(t)=\mathrm{E}[\mathrm{e}^{\mathrm{i}tY_{\boldsymbol{u}}}]=\mathrm{e}^{\mathrm{i}t(\boldsymbol{u}^\top\boldsymbol{\mu})-\frac{1}{2}t^2(\boldsymbol{u}^\top\boldsymbol{\Sigma}\boldsymbol{u})},$$

因此 $\varphi_{\boldsymbol{X}}(\boldsymbol{u})=\varphi_{Y_{\boldsymbol{u}}}(1)$，从而令 $t=1$，可得

$$\varphi_{\boldsymbol{X}}(\boldsymbol{u})=\mathrm{e}^{\mathrm{i}\boldsymbol{u}^\top\boldsymbol{\mu}-\frac{1}{2}\boldsymbol{u}^\top\boldsymbol{\Sigma}\boldsymbol{u}},$$

即为 $N(\boldsymbol{\mu},\boldsymbol{\Sigma})$ 的特征函数，从而根据特征函数的唯一性定理，可得 $\boldsymbol{X}$ 必定服从多元正态分布。

(2) 容易知道，

$$a_1X_1+\cdots+a_nX_n=\langle\boldsymbol{X},\boldsymbol{a}\rangle,$$

因此利用 (1) 的结论，可得 $\boldsymbol{X}$ 服从正态分布 (即 $X_1,\cdots,X_N$ 联合正态)，当且仅当对于任意的 $\boldsymbol{a}\in\mathbb{R}^n$，$\langle\boldsymbol{X},\boldsymbol{a}\rangle$ 均服从正态分布。

17 构造服从正态分布的随机变量 X,Y，满足 X,Y 是不相关的，但 X,Y 不是相互独立的。

解答 令 $X\sim N(0,1)$，$S\sim\text{Rademacher}$，$Y=SX$，则

$$\begin{aligned}\mathrm{P}\{Y\leqslant y\}&=\mathrm{P}\{SX\leqslant y\}=\mathrm{P}\{SX\leqslant y\mid S=1\}\mathrm{P}\{S=1\}+\mathrm{P}\{SX\leqslant y\mid S=-1\}\mathrm{P}\{S=-1\}\\&=\frac{1}{2}\mathrm{P}\{X\leqslant y\}+\frac{1}{2}\mathrm{P}\{-X\leqslant y\}\\&=\frac{1}{2}\Phi(y)+\frac{1}{2}\Phi(y)=\Phi(y),\end{aligned}$$

可得 $Y\sim N(0,1)$。

由于 $\mathrm{E}[XY]=\mathrm{E}[SX^2]=\mathrm{E}[S]\mathrm{E}[X^2]=0$，因此

$$\mathrm{Cov}(X,Y)=\mathrm{E}[XY]-\mathrm{E}[X]\mathrm{E}[Y]=0-0\cdot0=0。$$

由于 $Y^2=X^2$，因此 X^2,Y^2 不是相互独立的，从而 X,Y 不是相互独立的。

18 [**Ginibre 随机矩阵**] Ginibre 系综为随机矩阵的基本模型。

$\boldsymbol{G}\in\mathbb{R}^{n\times n}$ 被称为 Ginibre 随机矩阵，若 g_{ij} i.i.d. $\sim N(0,1)$。证明：Ginibre 分布于正交矩阵乘法是不变的，即对于任意的正交矩阵 $\boldsymbol{U}\in\mathbb{R}^{n\times n}$，均满足

$$\boldsymbol{U}\boldsymbol{G}\overset{d}{=}\boldsymbol{G}\boldsymbol{U}\overset{d}{=}\boldsymbol{G}。$$

证明 设 $\boldsymbol{G}=(\boldsymbol{Z}_1,\cdots,\boldsymbol{Z}_n)$ 满足 $\boldsymbol{Z}_j$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

- 对于左乘，考虑 $\boldsymbol{G}'=\boldsymbol{U}\boldsymbol{G}$，其列向量为 $\boldsymbol{Z}'_j=\boldsymbol{U}\boldsymbol{Z}_j$，则

$$\mathrm{E}[\boldsymbol{Z}'_j]=\mathrm{E}[\boldsymbol{U}\boldsymbol{Z}_j]=\boldsymbol{U}\mathrm{E}[\boldsymbol{Z}_j]=\boldsymbol{0},$$

$$\mathrm{Cov}(\boldsymbol{Z}_j') = \mathrm{Cov}(\boldsymbol{U}\boldsymbol{Z}_j) = \boldsymbol{U}\,\mathrm{Cov}(\boldsymbol{Z}_j)\boldsymbol{U}^\top = \boldsymbol{U}\boldsymbol{I}_n\boldsymbol{U}^\top = \boldsymbol{U}\boldsymbol{U}^\top,$$

因此 $\boldsymbol{Z}_j'$ i.i.d. $\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，从而 $\boldsymbol{G}'$ 服从 Ginibre 分布。

- 对于右乘，考虑 $\boldsymbol{G}'' = \boldsymbol{G}\boldsymbol{U}$，注意到

$$\boldsymbol{G}'' = (\boldsymbol{U}^\top\boldsymbol{G}^\top)^\top,$$

由于 $\boldsymbol{U}^\top$ 为正交矩阵，$\boldsymbol{G}^\top$ 为 Ginibre 随机矩阵，因此利用 (1) 的结论，可得 $\boldsymbol{U}^\top\boldsymbol{G}^\top \overset{d}{=} \boldsymbol{G}^\top$ 服从 Ginibre 分布，从而 $\boldsymbol{G}'' = (\boldsymbol{U}^\top\boldsymbol{G}^\top)^\top$ 服从 Ginibre 分布。

19 [**GOE 随机矩阵**] Gaussian 正交系综为对称随机矩阵的基本模型。

对称矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 被称为 GOE 随机矩阵，若其主对角线及其上方的元素为相互独立的正态随机变量，满足

$$A_{ij} \sim \begin{cases} N(0,2), i = j, \\ N(0,1), i < j \end{cases}。$$

证明：

(1) 设 $\boldsymbol{G}$ 为练习 Q3.18 (Ginibre 随机矩阵) 所定义的 Ginibre 随机矩阵，则

$$\boldsymbol{A} \overset{d}{=} \frac{1}{\sqrt{2}}(\boldsymbol{G} + \boldsymbol{G}^\top)。$$

这解释了定义的对角元, 上方元素方差不同的原因。

(2) GOE 分布于正交相似变换是不变的，即对于任意的正交矩阵 $\boldsymbol{U} \in \mathbb{R}^{n\times n}$，

$$\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U} \overset{d}{=} \boldsymbol{A},$$

这解释了名称“Gaussian 正交 (不变) 系综”的由来。

证明 **解法一**

对于 $\boldsymbol{M} = \frac{1}{\sqrt{2}}(\boldsymbol{G} + \boldsymbol{G}^\top)$：

1. 正态性：

$$M_{ii} = \sqrt{2}G_{ii} \sim N(0,2)，\ M_{ij}\frac{1}{\sqrt{2}}(G_{ij} + G_{ji}) \sim N(0,1)。$$

2. 独立性：由于 $\{G_{ii}\}$ 是相互独立的，$\{(G_{ij}, G_{ji})\}_{i<j}$ 是相互独立的，因此 $\{M_{ii}, M_{ij}\}$ 是相互独立的，从而 $\boldsymbol{A} \overset{d}{=} \boldsymbol{M}$，可得

$$\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U} \overset{d}{=} \frac{1}{\sqrt{2}}(\boldsymbol{U}^\top(\boldsymbol{G} + \boldsymbol{G}^\top)\boldsymbol{U}) = \frac{1}{\sqrt{2}}(\boldsymbol{U}^\top\boldsymbol{G}\boldsymbol{U} + \boldsymbol{U}^\top\boldsymbol{G}^\top\boldsymbol{U}) = \frac{1}{\sqrt{2}}(\boldsymbol{U}^\top\boldsymbol{G}\boldsymbol{U} + (\boldsymbol{U}^\top\boldsymbol{G}\boldsymbol{U})^\top)。$$

利用习题 Q3.18 (Ginibre 随机矩阵) 的结论，可得 $\boldsymbol{U}^\top\boldsymbol{G}\boldsymbol{U} \overset{d}{=} \boldsymbol{G}$，将其代入，

$$\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U} \overset{d}{=} \frac{1}{\sqrt{2}}(\boldsymbol{G} + \boldsymbol{G}^\top) \overset{d}{=} \boldsymbol{A}。$$

解法二　密度函数法

由于 $A_{ii} \sim N(0,2)$, $A_{ij} \sim N(0,1)$，因此

$$f(\boldsymbol{A}) = \left(\prod_{i=1}^n \frac{1}{\sqrt{4\pi}}\exp\left(-\frac{A_{ii}^2}{4}\right)\right)\cdot\left(\prod_{i<j}\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{A_{ij}^2}{2}\right)\right) \propto \exp\left(-\frac{1}{4}\sum_{i=1}^n A_{ii}^2 - \frac{1}{2}\sum_{i<j}A_{ij}^2\right)。$$

注意到右侧即为 $\mathrm{tr}(\boldsymbol{A}^2)$，利用 $\boldsymbol{A}$ 的对称性，可得

$$\mathrm{tr}(\boldsymbol{A}^2) = \sum_{i=1}^n(\boldsymbol{A}^2)_{ii} = \sum_{i=1}^n\sum_{j=1}^n A_{ij}A_{ji} = \sum_{i,j=1}^n A_{ij}^2 = \sum_{i=1}^n A_{ii}^2 + 2\sum_{i<j}A_{ij}^2,$$

将其代入，可得

$$f(\boldsymbol{A}) = C_n\exp\left(-\frac{1}{4}\mathrm{tr}(\boldsymbol{A}^2)\right)。$$

对于任意的正交矩阵 $\boldsymbol{U} \in \mathbb{R}^{n\times n}$：

1. 指数项不变性：

$$\mathrm{tr}((\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U})^2)=\mathrm{tr}(\boldsymbol{U}^\top\boldsymbol{A}^2\boldsymbol{U})=\mathrm{tr}(\boldsymbol{A}^2)。$$

2. 测度体积不变性：映射 $\boldsymbol{A}\mapsto\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U}$ 为对称矩阵空间 $\mathbb{S}^n$ 的线性正交等距同构，即

$$\|\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U}\|_F^2=\mathrm{tr}((\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U})^2)=\mathrm{tr}(\boldsymbol{A}^2)=\|\boldsymbol{A}\|_F^2。$$

因此其 Jacobi 行列式的绝对值恒等于 1，即微分体积元满足 $\mathrm{d}(\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U})=\mathrm{d}\boldsymbol{A}$。

因此密度函数在正交相似变换下的形式与测度保持不变，即 $\boldsymbol{U}^\top\boldsymbol{A}\boldsymbol{U}\overset{d}{=}\boldsymbol{A}$。

20 [**Gaussian 随机矩阵使正交向量独立**] 设 $\boldsymbol{G}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\boldsymbol{u},\boldsymbol{v}\in\mathbb{R}^n$ 满足 $\|\boldsymbol{u}\|=\|\boldsymbol{v}\|=1$，$\boldsymbol{u}^\top\boldsymbol{v}=0$。证明：$\boldsymbol{G}\boldsymbol{u},\boldsymbol{G}\boldsymbol{v}$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_m)$。

证明 设 $Y_i=\boldsymbol{Z}_i^\top\boldsymbol{u}$，则

$$\mathrm{E}[Y_i]=\mathrm{E}[\boldsymbol{Z}_i^\top\boldsymbol{u}]=\mathrm{E}[\boldsymbol{Z}_i^\top]\boldsymbol{u}=0,$$
$$\mathrm{Var}(Y_i)=\boldsymbol{u}^\top\mathrm{Var}(\boldsymbol{Z}_i)\boldsymbol{u}=\boldsymbol{u}^\top\boldsymbol{I}_n\boldsymbol{u}=\|\boldsymbol{u}\|^2=1,$$

由于 $Y_1,\cdots,Y_m$ 相互独立 (因为 $\boldsymbol{Z}_1,\cdots,\boldsymbol{Z}_m$ 是相互独立的)，因此 $\boldsymbol{G}\boldsymbol{u}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$；同理，$\boldsymbol{G}\boldsymbol{v}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$。

设 $\boldsymbol{W}=\begin{pmatrix}\boldsymbol{G}\boldsymbol{u}\\ \boldsymbol{G}\boldsymbol{v}\end{pmatrix}$，则 $\boldsymbol{W}$ 服从多元正态分布，因此要证明 $\boldsymbol{G}\boldsymbol{u},\boldsymbol{G}\boldsymbol{v}$ 是相互独立的，只需证明 $\mathrm{Cov}(\boldsymbol{G}\boldsymbol{u},\boldsymbol{G}\boldsymbol{v})=\boldsymbol{O}_{m\times m}$。

考虑 $\mathrm{Cov}(\boldsymbol{Z}_i^\top\boldsymbol{u},\boldsymbol{Z}_j^\top\boldsymbol{v})$：

a. 当 $i\neq j$ 时，由于 $\boldsymbol{Z}_i,\boldsymbol{Z}_j$ 是相互独立的，因此 $\mathrm{Cov}(\boldsymbol{Z}_i^\top\boldsymbol{u},\boldsymbol{Z}_j^\top\boldsymbol{v})=0$。

b. 当 $i=j$ 时，

$$\begin{aligned}\mathrm{Cov}(\boldsymbol{Z}_i^\top\boldsymbol{u},\boldsymbol{Z}_i^\top\boldsymbol{v})&=\mathrm{E}[(\boldsymbol{Z}_i^\top\boldsymbol{u})(\boldsymbol{Z}_i^\top\boldsymbol{v})]-\mathrm{E}[\boldsymbol{Z}_i^\top\boldsymbol{u}]\mathrm{E}[\boldsymbol{Z}_i^\top\boldsymbol{v}]\\&=\mathrm{E}[\boldsymbol{u}^\top\boldsymbol{Z}_i\boldsymbol{Z}_i^\top\boldsymbol{v}]=\boldsymbol{u}^\top\mathrm{E}[\boldsymbol{Z}_i\boldsymbol{Z}_i^\top]\boldsymbol{v}=\boldsymbol{u}^\top\boldsymbol{v}=0。\end{aligned}$$

因此 $\mathrm{Cov}(\boldsymbol{Z}_i^\top\boldsymbol{u},\boldsymbol{Z}_j^\top\boldsymbol{v})=0$，可得 $\mathrm{Cov}(\boldsymbol{G}\boldsymbol{u},\boldsymbol{G}\boldsymbol{v})=\boldsymbol{O}_{m\times m}$。

21 [**Gaussian 随机向量的正交变换不变性**] 设 $\boldsymbol{X},\boldsymbol{Y}$ i.i.d. $\sim(0,\boldsymbol{I}_n)$，定义

$$\boldsymbol{U}=\frac{\boldsymbol{X}+\boldsymbol{Y}}{\sqrt{2}},\quad\boldsymbol{V}=\frac{\boldsymbol{X}-\boldsymbol{Y}}{\sqrt{2}},$$

证明：$\boldsymbol{U},\boldsymbol{V}$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

证明 容易知道，

$$\begin{pmatrix}\boldsymbol{U}\\ \boldsymbol{V}\end{pmatrix}=\frac{1}{\sqrt{2}}\begin{pmatrix}\boldsymbol{I}_n & \boldsymbol{I}_n\\ \boldsymbol{I}_n & -\boldsymbol{I}_n\end{pmatrix}\begin{pmatrix}\boldsymbol{X}\\ \boldsymbol{Y}\end{pmatrix},$$

因此 $\boldsymbol{U},\boldsymbol{V}$ 服从联合正态分布，其中

$$\mathrm{E}[\boldsymbol{U}]=\frac{1}{\sqrt{2}}(\mathrm{E}[\boldsymbol{X}]+\mathrm{E}[\boldsymbol{Y}])=\boldsymbol{0},$$
$$\mathrm{E}[\boldsymbol{V}]=\frac{1}{\sqrt{2}}(\mathrm{E}[\boldsymbol{X}]-\mathrm{E}[\boldsymbol{Y}])=\boldsymbol{0},$$
$$\mathrm{Var}(\boldsymbol{U})=\frac{1}{2}(\mathrm{Var}(\boldsymbol{X})+\mathrm{Var}(\boldsymbol{Y}))=\frac{1}{2}(\boldsymbol{I}_n+\boldsymbol{I}_n)=\boldsymbol{I}_n,$$
$$\mathrm{Var}(\boldsymbol{V})=\frac{1}{2}(\mathrm{Var}(\boldsymbol{X})+\mathrm{Var}(\boldsymbol{Y}))=\frac{1}{2}(\boldsymbol{I}_n+\boldsymbol{I}_n)=\boldsymbol{I}_n,$$

从而 $\boldsymbol{U},\boldsymbol{V}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

由于

$$\begin{aligned}\mathrm{Cov}(\boldsymbol{U},\boldsymbol{V})&=\mathrm{E}[\boldsymbol{U}\boldsymbol{V}^\top]-\mathrm{E}[\boldsymbol{U}]\mathrm{E}[\boldsymbol{V}]^\top=\mathrm{E}[\boldsymbol{U}\boldsymbol{V}^\top]\\&=\mathrm{E}\left[\frac{\boldsymbol{X}+\boldsymbol{Y}}{\sqrt{2}}\left(\frac{\boldsymbol{X}-\boldsymbol{Y}}{\sqrt{2}}\right)^\top\right]=\frac{1}{2}\mathrm{E}[(\boldsymbol{X}+\boldsymbol{Y})(\boldsymbol{X}^\top-\boldsymbol{Y}^\top)]\end{aligned}$$

$$
\begin{aligned}
&= \frac{1}{2}\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top - \boldsymbol{X}\boldsymbol{Y}^\top + \boldsymbol{Y}\boldsymbol{X}^\top - \boldsymbol{Y}\boldsymbol{Y}^\top] \\
&= \frac{1}{2}(\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] - \mathrm{E}[\boldsymbol{Y}\boldsymbol{Y}^\top]) \\
&= \frac{1}{2}(\boldsymbol{I}_n - \boldsymbol{I}_n) = \boldsymbol{O},
\end{aligned}
$$

因此 $\boldsymbol{U}, \boldsymbol{V}$ 是相互独立的。

22 [**正态随机向量的模长, 方向**] 设 $\boldsymbol{Z} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，定义

$$R = \|\boldsymbol{Z}\|_2, \ \boldsymbol{U} = \bar{\boldsymbol{Z}}。$$

证明：$\|\boldsymbol{Z}\|_2, \bar{\boldsymbol{Z}}$ 是相互独立的。

证明 考虑映射 $\mathbb{R}^n \to (r, \boldsymbol{\theta})$，其中 $r \geqslant 0$，$\boldsymbol{\theta} \in \mathbb{S}^{n-1}$，则

$$\mathrm{d}\boldsymbol{x} = r^{n-1}\mathrm{d}r\mathrm{d}\sigma(\boldsymbol{\theta}),$$

其中 σ 为单位球面 $\mathbb{S}^{n-1}$ 的表面积测度，因此对于任意的可测集 $A \in \mathscr{B}([0,\infty)), B \in \mathscr{B}(\mathbb{S}^{n-1})$，

$$
\begin{aligned}
\mathrm{P}\{R \in A, \boldsymbol{U} \in B\} &= \int_{\mathbb{R}^n} \mathbf{1}_{\{\|\boldsymbol{x}\|_2 \in A, \bar{\boldsymbol{x}} \in B\}} f_{\boldsymbol{Z}}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \\
&= \int_{r\in A}\int_{\boldsymbol{\theta}\in B} \frac{1}{(2\pi)^{n/2}} \mathrm{e}^{-\frac{1}{2}r^2} \cdot r^{n-1}\mathrm{d}r\mathrm{d}\sigma(\boldsymbol{\theta}) \\
&= \underbrace{\left(\int_A \frac{r^{n-1}\mathrm{e}^{-\frac{1}{2}r^2}}{(2\pi)^{n/2}}\mathrm{d}r\right)}_{I_1(A)} \cdot \underbrace{\left(\int_B \mathrm{d}\sigma(\boldsymbol{\theta})\right)}_{I_2(B)}。
\end{aligned}
$$

(之后通过全空间取值确定边缘分布。)

对于 R 的边缘分布，令 $B = \mathbb{S}^{n-1}$，记 $C_{\boldsymbol{U}} = I_2(\mathbb{S}^{n-1}) = \int_{\mathbb{S}^{n-1}} \mathrm{d}\sigma(\boldsymbol{\theta})$ 单位球面的总面积，则

$$\mathrm{P}\{R \in A\} = \mathrm{P}\{R \in A, \boldsymbol{U} \in \mathbb{S}^{n-1}\} = I_1(A) \cdot I_2(\mathbb{S}^{n-1}) =: I_1(A) \cdot C_U \implies I_1(A) = \frac{\mathrm{P}\{R \in A\}}{C_{\boldsymbol{U}}}。$$

对于 $\boldsymbol{U}$ 的边缘分布，令 $A = [0,\infty)$，记 $C_{\boldsymbol{U}} = I_2(\mathbb{S}^{n-1}) = \int_{\mathbb{S}^{n-1}} \mathrm{d}\sigma(\boldsymbol{\theta})$ 为径向积分常数，则

$$\mathrm{P}\{\boldsymbol{U} \in B\} = \mathrm{P}\{R \in [0,\infty), \boldsymbol{U} \in B\} = I_1([0,\infty)) \cdot I_2(B) =: C_R \cdot I_2(B) \implies I_2(B) = \frac{\mathrm{P}\{\boldsymbol{U} \in B\}}{C_R}。$$

之后考虑 A, B 同时取全空间的情况，令 $A = [0,\infty), B = \mathbb{S}^{n-1}$，根据总概率的归一化条件，可得

$$1 = \mathrm{P}\{R \in [0,\infty), \boldsymbol{U} \in \mathbb{S}^{n-1}\} = C_R \cdot C_{\boldsymbol{U}}。$$

如此，

$$
\begin{aligned}
I_1(A) \cdot I_2(B) &= \left(\frac{\mathrm{P}\{R \in A\}}{C_{\boldsymbol{U}}}\right) \cdot \left(\frac{\mathrm{P}\{\boldsymbol{U} \in B\}}{C_R}\right) \\
&= \frac{1}{C_R \cdot C_{\boldsymbol{U}}} \cdot \mathrm{P}\{R \in A\} \cdot \mathrm{P}\{\boldsymbol{U} \in B\} \\
&= \mathrm{P}\{R \in A\} \cdot \mathrm{P}\{\boldsymbol{U} \in B\},
\end{aligned}
$$

即 $\mathrm{P}\{R \in A, \boldsymbol{U} \in B\} = \mathrm{P}\{R \in A\} \cdot \mathrm{P}\{\boldsymbol{U} \in B\}$，从而 $R, \boldsymbol{U}$ 是相互独立的。

23 [**高维随机点集的凸位置性质**] 称定义于 $\mathbb{R}^n$ 的有限点集处于凸位置 (Convex Position)，若其中任意一点均不落于其余所有点所构成的凸包 (Convex Hull) 内部。

设 $N \leqslant \mathrm{e}^{cn}$，其中 $c > 0$ 为充分小的常数。设 $\boldsymbol{g}_1, \cdots, \boldsymbol{g}_N$ i.i.d. $\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。按以下步骤证明：上述 N 个随机点以高概率处于凸位置 (w.p. $1 - \mathrm{e}^{-cn}$)：

(1) 证明：$\boldsymbol{g}_1$ 与其余点线性可分，即存在法向量 $\boldsymbol{x} \in \mathbb{R}^n$ (可为随机向量)，满足

$$\langle \boldsymbol{g}_1, \boldsymbol{x}\rangle > \max_{j=2,\cdots,N} \langle \boldsymbol{g}_j, \boldsymbol{x}\rangle \text{ (w.h.p.)}。$$

(2) 利用 (1) 的结论，证明：

$$\boldsymbol{g}_1 \notin \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N) \text{ (w.h.p.)}。$$

(3) 利用并集界，完成 N 个点处于凸位置的证明。

证明 (1) 不妨设分离法向量为 $\boldsymbol{x} = \boldsymbol{g}_1$，令线性可分事件

$$\mathcal{B} = \left\{ \|\boldsymbol{g}_1\|_2^2 > \max_{2\leqslant j\leqslant N} \langle \boldsymbol{g}_j, \boldsymbol{g}_1 \rangle \right\},$$

则只需证明 $\mathrm{P}(\mathcal{B}^c) \leqslant exp(-c_2 n)$。

定义模长集中的良性事件

$$\mathcal{A} = \left\{ \frac{n}{2} \leqslant \|\boldsymbol{g}_1\|_2^2 \leqslant \frac{3n}{2} \right\},$$

则根据全概率公式，可得

$$\mathrm{P}(\mathcal{B}^c) \leqslant \mathrm{P}(\mathcal{B}^c \mid \mathcal{A})\mathrm{P}(\mathcal{A}) + \mathrm{P}(\mathcal{A}^c) \leqslant \mathrm{P}(\mathcal{B}^c \mid \mathcal{A}) + \mathrm{P}(\mathcal{A}^c)。 \tag{I}$$

(之后只需分别控制 $\mathrm{P}(\mathcal{B}^c \mid \mathcal{A}), \mathrm{P}(\mathcal{A}^c)$。)

对于 $\mathcal{A}^c$，由于 $\|\boldsymbol{g}_1\|_2^2 \sim \chi^2(n)$，因此利用定理 T3.1.1 (范数的集中)，可得

$$\mathrm{P}(\mathcal{A}^c) = \mathrm{P}\left\{ \left| \|\boldsymbol{g}_1\|_2^2 - n \right| > \frac{n}{2} \right\} \leqslant 2\mathrm{e}^{-c_1 n}, \tag{II}$$

对于 $\mathcal{B}^c \mid \mathcal{A}$，定义一维内积投影变量 $Z_j = \langle \boldsymbol{g}_j, \boldsymbol{g}_1 \rangle = \sum_{k=1}^n g_{jk} x_k$，则

$$\mathrm{E}[Z_j \mid \boldsymbol{g}_1 = \boldsymbol{x}] = \sum_{k=1}^n x_k \mathrm{E}[g_{jk}] = 0,$$

$$\mathrm{Var}(Z_j \mid \boldsymbol{g}_1 = \boldsymbol{x}) = \sum_{k=1}^n x_k^2 \,\mathrm{Var}(g_{jk}) = \sum_{k=1}^n x_k^2 = \|\boldsymbol{x}\|_2^2,$$

可得 $Z_j \mid \boldsymbol{g}_1 = \boldsymbol{x} \sim N(0, \|\boldsymbol{x}\|_2^2)$。

利用命题 P2.1.2 (Gaussian 尾部) (Gaussian 尾部)，令 $t = \|\boldsymbol{x}\|_2^2$，可得

$$\mathrm{P}\{Z_j \geqslant \|\boldsymbol{x}\|_2^2 \mid \boldsymbol{g}_1 = \boldsymbol{x}\} \leqslant \exp\left(-\frac{(\|\boldsymbol{x}\|_2^2)^2}{2\|\boldsymbol{x}\|_2^2} \right) = \exp\left(\frac{1}{2}\|\boldsymbol{x}\|_2^2 \right),$$

对其余 $N-1$ 个点应用并集界，代入 $\|\boldsymbol{x}\|_2^2 \geqslant n/2$, $N \leqslant \exp(cn)$，可得

$$\begin{aligned} \mathrm{P}\left\{ \max_{2\leqslant j\leqslant N} Z_j \geqslant \|\boldsymbol{x}\|_2^2 \mid \boldsymbol{g}_1 = \boldsymbol{x} \right\} &\leqslant \sum_{j=2}^N \mathrm{P}\{Z_j \geqslant \|\boldsymbol{x}\|_2^2 \mid \boldsymbol{g}_1 = \boldsymbol{x}\} \\ &\leqslant N\mathrm{e}^{-\frac{1}{2}\|\boldsymbol{x}\|_2^2} \leqslant \exp(cn) \cdot \exp\left(-\frac{n}{4} \right) = \exp\left(-\left(\frac{1}{4} - c \right) n \right)。 \end{aligned} \tag{III}$$

将 (II)(III) 代入于 (I)，令 $c < 1/4$，可得

$$\mathrm{P}(\mathcal{B}^c) \leqslant \mathrm{P}(\mathcal{B}^c \mid \mathcal{A})\mathrm{P}(\mathcal{A}) + \mathrm{P}(\mathcal{A}^c) \leqslant \exp\left(-\left(\frac{1}{4} - c \right) n \right) + 2\exp(-c_1 n) \leqslant \exp(-c_2 n), \qquad (c_2 > 0)$$

(2) (考虑利用反证法，证明 $\mathcal{B}$ 蕴含 $\boldsymbol{g}_1 \notin \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N)$。)

假设 $\boldsymbol{g}_1 \in \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N)$，则存在 $\lambda_2, \cdots, \lambda_N \geqslant 0$，满足 $\sum_{j=2}^N \lambda_j = 1$，使得

$$\boldsymbol{g}_1 = \sum_{j=2}^N \lambda_j \boldsymbol{g}_j,$$

因此

$$\|\boldsymbol{g}_1\|_2^2 = \langle \boldsymbol{g}_1, \boldsymbol{g}_1 \rangle = \left\langle \sum_{j=2}^N \lambda_j \boldsymbol{g}_j, \boldsymbol{g}_1 \right\rangle = \sum_{j=2}^N \lambda_j \langle \boldsymbol{g}_j, \boldsymbol{g}_1 \rangle$$

$$\leqslant \sum_{j=2}^{N} \lambda_j \left(\max_{2\leqslant k\leqslant N} \langle \boldsymbol{g}_k, \boldsymbol{g}_1 \rangle \right) = \left(\sum_{j=2}^{N} \lambda_j \right) \max_{2\leqslant k\leqslant N} \langle \boldsymbol{g}_k, \boldsymbol{g}_1 \rangle = \max_{2\leqslant k\leqslant N} \langle \boldsymbol{g}_k, \boldsymbol{g}_1 \rangle,$$

矛盾；如此，$\mathcal{B}$ 蕴含 $\boldsymbol{g}_1 \notin \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N)$，从而

$$\mathrm{P}\{\boldsymbol{g}_1 \in \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N)\} \leqslant \mathrm{P}(\mathcal{B}^c) \leqslant \exp(-c_2 n)。$$

(3) 定义全局失效事件 (即存在至少一个点落于其余点的凸包内部)

$$E = \bigcup_{i=1}^{N} \{\boldsymbol{g}_i \in \operatorname{conv}(\{\boldsymbol{g}_j\}_{j\neq i})\}。$$

对 N 个点取并集界，

$$\begin{aligned} \mathrm{P}(E) &\leqslant \sum_{i=1}^{N} \mathrm{P}\{\boldsymbol{g}_i \in \operatorname{conv}(\{\boldsymbol{g}_j\}_{j\neq i})\} \\ &= N \cdot \mathrm{P}\{\boldsymbol{g}_1 \in \operatorname{conv}(\{\boldsymbol{g}_j\}_{j=2}^N)\} \leqslant \exp(cn) \cdot \exp(-c_2 n) = \exp(-(c_2 - c)n), \end{aligned}$$

令 $c < \min\{1/4, c_2/2\}$，此时 $c_2 - c \geqslant c$，可得 $\mathrm{P}(E) \leqslant \exp(-cn)$，因此

$$\mathrm{P}(E^c) = 1 - \mathrm{P}(E) \geqslant 1 - \mathrm{e}^{-cn}。$$

24 [**单位球均匀分布的极分解**] 设 $\boldsymbol{X} \sim U(\mathbb{B}_2^n)$，将其分解为

$$\boldsymbol{X} = R\boldsymbol{Z},$$

其中 $R = \|\boldsymbol{X}\|_2$ 为随机模长，$\boldsymbol{Z} = \bar{\boldsymbol{X}}$ 为随机方向向量。证明：

$$\boldsymbol{Z} \sim U(\mathbb{S}^{n-1}),\ R \sim f_R(r) = nr^{n-1}\mathbf{1}_{r\in[0,1]},$$

满足 $R, \boldsymbol{Z}$ 是相互独立的。

证明 记 $V_n = \mathrm{Vol}(\mathbb{B}_2^n)$，$A_{n-1} = \mathrm{Area}(\mathbb{S}^{n-1})$，则 $A_{n-1} = nV_n$。

考虑极坐标变换 $\boldsymbol{x} \to (r, \boldsymbol{\theta})$，其中 $r = \|\boldsymbol{x}\|_2 \in [0,1]$，$\boldsymbol{\theta} = \bar{\boldsymbol{x}} \in \mathbb{S}^{n-1}$，则

$$\mathrm{d}\boldsymbol{x} = r^{n-1}\mathrm{d}r\mathrm{d}\sigma(\boldsymbol{\theta}),$$

因此对于任意的 $A \in \mathscr{B}([0,1]), B \in \mathscr{B}(\mathbb{S}^{n-1})$，

$$\begin{aligned} \mathrm{P}\{R \in A, \boldsymbol{Z} \in B\} &= \int_{\mathbb{R}^n} \mathbf{1}_{\{\|\boldsymbol{x}\|_2 \in A, \bar{\boldsymbol{x}} \in B\}} f_{\boldsymbol{X}}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \\ &= \int_{r\in A} \int_{\boldsymbol{\theta}\in B} \frac{1}{V_n} r^{n-1}\mathrm{d}r\mathrm{d}\sigma(\boldsymbol{\theta}) \\ &= \left(\int_A \frac{1}{V_n} r^{n-1}\mathrm{d}r \right) \cdot \left(\int_B \mathrm{d}\sigma(\boldsymbol{\theta}) \right), \end{aligned}$$

从而 $R, \boldsymbol{Z}$ 是相互独立的。

(之后通过全空间取值确定边缘分布。)

令 $A = [0,1]$，则

$$\mathrm{P}\{\boldsymbol{Z} \in B\} = \left(\int_0^1 \frac{r^{n-1}}{V_n}\mathrm{d}r \right) \cdot \int_B \mathrm{d}\sigma(\boldsymbol{\theta}) = \frac{1}{nV_n} \int_B \mathrm{d}\sigma(\boldsymbol{\theta}) = \frac{\sigma(B)}{A_{n-1}},$$

因此 $\boldsymbol{Z}$ 于球面的概率与面积成正比，即 $\boldsymbol{Z} \sim U(\mathbb{S}^{n-1})$。

令 $B = \mathbb{S}^{n-1}$，则

$$\mathrm{P}\{R \in A\} = \int_A \frac{r^{n-1}}{V_n} \cdot \sigma(\mathbb{S}^{n-1})\mathrm{d}r = \int_A \frac{A_{n-1}}{V_n} r^{n-1}\mathrm{d}r = \int_A nr^{n-1}\mathrm{d}r,$$

因此 $f_R(r) = nr^{n-1}$。

25 [**Euclidean 球分布的各向同性**] 设 $\boldsymbol{Y} \sim U(\mathbb{B}_2^n(0, \sqrt{n+2}))$。证明：$\boldsymbol{Y}$ 是各向同性的。

证明 根据对称性，可得 $\mathrm{E}[\boldsymbol{Y}] = \boldsymbol{0}$。

根据旋转不变性，可得 $\mathrm{E}[\boldsymbol{Y}\boldsymbol{Y}^\top]$ 为单位矩阵的倍数，记为

$$\mathrm{E}[\boldsymbol{Y}\boldsymbol{Y}^\top] = \lambda \boldsymbol{I}_n,$$

两侧求迹，

$$\mathrm{E}\|\boldsymbol{Y}\|_2^2 = \mathrm{tr}(\lambda \boldsymbol{I}_n) = n\lambda,$$

解得 $\lambda = n/\mathrm{E}\|\boldsymbol{Y}\|_2^2$。

(之后只需计算 $\mathrm{E}\|\boldsymbol{Y}\|_2^2$。)

设 $L = \|\boldsymbol{Y}\|_2$，利用习题 Q3.24 (单位球均匀分布的极分解) 的结论，可得

$$f_L(r) = \frac{nr^{n-1}}{R^n}\mathbf{1}_{[0,R]},$$

因此

$$\mathrm{E}\|\boldsymbol{Y}\|_2^2 = \int_0^R r^2 \cdot \frac{nr^{n-1}}{R^n}\mathrm{d}r = \frac{n}{R^n}\int_0^R r^{n+1}\mathrm{d}r = \frac{nR^2}{n+2} = \frac{n\cdot(\sqrt{n+2})^2}{n+2} = n,$$

可得 $\lambda = 1$，从而

$$\mathrm{E}[\boldsymbol{Y}\boldsymbol{Y}^\top] = 1\cdot \boldsymbol{I}_n = \boldsymbol{I}_n,$$

可得 $\boldsymbol{Y}$ 是各向同性的。

26 [**单位球面的随机向量的去局域化**] 若 $\boldsymbol{x} \in \mathbb{R}^n$ 满足所有坐标的大小相等，即对于任意的 i，均满足 $|x_i| = 1/\sqrt{n}$，则其是完全散开或去局域化的。

事实上，单位球面的随机向量几乎是去局域化的。证明：若 $\boldsymbol{X} \sim U(\mathbb{S}^{n-1})$，则

$$\mathrm{E}\|\boldsymbol{X}\|_\infty \asymp \sqrt{\frac{\ln n}{n}}。$$

证明 设 $\boldsymbol{G} = (G_1, \cdots, G_n)^\top \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则根据球面均匀分布的构造性，可得

$$\boldsymbol{X} \overset{d}{=} \bar{\boldsymbol{G}}。$$

利用 Gaussian 随机向量的旋转不变性 (Q3.22 (正态随机向量的模长, 方向))，可得 $\|\boldsymbol{G}\|_2, \bar{\boldsymbol{G}}$ 是相互独立的，因此

$$\mathrm{E}\|\boldsymbol{X}\|_\infty = \mathrm{E}\left[\frac{\max_{1\leqslant i\leqslant n}|G_i|}{\|\boldsymbol{G}\|_2}\right] = \mathrm{E}\left[\max_{1\leqslant i\leqslant n}|G_i|\right]\cdot \mathrm{E}\left[\frac{1}{\|\boldsymbol{G}\|_2}\right]。$$

(之后只需对右侧两项积分进行估计。)

- 证明 $\mathrm{E}[\max_{1\leqslant i\leqslant n}|G_i|] \asymp \sqrt{\ln n}$
  - 对于上界，利用 Jensen 不等式，可得

$$\mathrm{e}^{\lambda \mathrm{E}[\max|G_i|]} \leqslant \mathrm{E}[\mathrm{e}^{\lambda\max|G_i|}] = \mathrm{E}\left[\max_{1\leqslant i\leqslant n}|G_i|\right] \leqslant \sum_{i=1}^n \mathrm{E}[\mathrm{e}^{\lambda|G_i|}],$$

  其中 $\mathrm{e}^{\lambda|G_i|} \leqslant \mathrm{e}^{\lambda G_i} + \mathrm{e}^{-\lambda G_i}$，满足 $\mathrm{E}[\mathrm{e}^{\lambda G_i}] = \mathrm{e}^{\lambda^2/2}$，因此

$$\mathrm{e}^{\lambda \mathrm{E}[\max_{1\leqslant i\leqslant n}|G_i|]} \leqslant 2n\mathrm{e}^{\lambda^2/2},$$

  两侧取对数，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|G_i|\right] \leqslant \frac{\ln(2n)}{\lambda} + \frac{\lambda}{2},$$

  右侧的最优参数为 $\lambda_0 = \sqrt{2\ln(2n)}$，将其代入，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|G_i|\right] \leqslant \sqrt{2\ln(2n)}。$$

  - 对于下界，令 $M = \max_{1\leqslant i\leqslant n}|G_i|$，则

$$\mathrm{E}[M] = \int_0^\infty \mathrm{P}\{M > t\}\mathrm{d}t$$

$$\geqslant \int_0^{t_0} \mathrm{P}\{M > t\}\mathrm{d}t \geqslant \int_0^{t_0} \mathrm{P}\{M > t_0\}\mathrm{d}t \qquad (t_0 > 0)$$
$$= t_0 \mathrm{P}\{M > t_0\}。$$

容易知道，

$$\mathrm{P}\{M > t_0\} = 1 - \mathrm{P}\{M \leqslant t_0\} = 1 - [1 - \mathrm{P}\{|G_1| > t_0\}]^n,$$

其中利用 Mill's Ratio，可得

$$\mathrm{P}\{|G_1| > t\} = 2\mathrm{P}\{G > t\} \geqslant 2 \cdot \frac{1}{\sqrt{2\pi}} \cdot \frac{t}{t^2+1} \mathrm{e}^{-t^2/2} \geqslant \frac{\mathrm{e}^{-t^2/2}}{t},$$

因此令 $t_0 = \sqrt{\ln n}$，可得

$$\mathrm{P}\{|G_1| > \sqrt{\ln n}\} \geqslant \frac{\mathrm{e}^{-\frac{1}{2}\ln n}}{\sqrt{\ln n}} = \frac{n^{-1/2}}{\sqrt{\ln n}} = \frac{1}{\sqrt{n \ln n}},$$

从而

$$\mathrm{P}\{M \leqslant \sqrt{\ln n}\} = [1 - \mathrm{P}\{|G_1| > \sqrt{\ln n}\}]^n \leqslant \left(1 - \frac{1}{\sqrt{n \ln n}}\right)^n \leqslant \mathrm{e}^{-\frac{n}{\sqrt{n \ln n}}} = \mathrm{e}^{-\sqrt{\frac{n}{\ln n}}} \to 0,$$

从而当 n 充分大时，

$$\mathrm{P}\{M > \sqrt{\ln n}\} = 1 - \mathrm{P}\{M \leqslant \sqrt{\ln n}\} \geqslant 1 - \mathrm{e}^{-\sqrt{\frac{n}{\ln n}}} > \frac{1}{2},$$

从而

$$\mathrm{E}[M] \geqslant t_0 \cdot \mathrm{P}\{M > t_0\} \geqslant \sqrt{\ln n} \cdot \frac{1}{2},$$

即存在 $c > 0$，使得 $\mathrm{E}[M] \geqslant c\sqrt{\ln n}$。

- 证明 $\mathrm{E}[1/\|\boldsymbol{G}\|_2] \asymp 1/\sqrt{n}$

设 $R = \|\boldsymbol{G}\|_2 \sim \chi(n)$，其密度函数为

$$f_R(r) = \frac{2^{1-n/2}}{\Gamma(n/2)} r^{n-1} \mathrm{e}^{-r^2/2} \mathbf{1}_{(0,\infty)},$$

则

$$\mathrm{E}[R^{-1}] = \int_0^\infty \frac{1}{r} f_R(r)\mathrm{d}r = \frac{2^{1-n/2}}{\Gamma(n/2)} \int_0^\infty r^{n-2}\mathrm{e}^{-r^2/2}\mathrm{d}r$$
$$= \frac{2^{1-n/2}}{\Gamma(n/2)} \int_0^\infty (2u)^{\frac{n-2}{2}} \mathrm{e}^{-u}(2u)^{-1/2}\mathrm{d}u = \frac{1}{\sqrt{2}} \frac{\Gamma((n-1)/2)}{\Gamma(n/2)} \qquad \left(u = \frac{r^2}{2}\right)$$
$$\sim \frac{1}{\sqrt{2}} \frac{1}{\sqrt{n/2}} \asymp \frac{1}{\sqrt{n}}。 \qquad \left(\frac{\Gamma(z+1/2)}{\Gamma(z)} \sim \sqrt{z}\right)$$

如此，

$$\mathrm{E}\|\boldsymbol{X}\|_\infty \asymp \sqrt{\ln n} \cdot \frac{1}{\sqrt{n}} = \sqrt{\frac{\ln n}{n}}。$$

27 [球面，球体的一维边缘分布] 设 $\boldsymbol{X} \sim U(\mathbb{S}^{n-1})$，$\boldsymbol{Y} \sim U(\mathbb{B}_2^n)$。

(1) 证明：$\boldsymbol{Y}$ 的任意的一维边缘分布 (投影分布) 的密度函数正比于 $(1-x^2)^{\frac{n-1}{2}}$，其中 $x \in [-1,1]$。

(2) 证明：$\boldsymbol{X}$ 的任意的一维边缘分布的密度函数正比于 $(1-x^2)^{\frac{n-3}{2}}$，其中 $x \in [-1,1]$。

注释 利用 (2) 的结论，可得三维球面的一维边缘分布即为 $U(-1,1)$，称为阿基米德帽盒定理 (Archimedes' hat-box theorem)

证明 (1) 由于 $\boldsymbol{Y} \sim U(\mathbb{B}_2^n)$，因此 $f_{\boldsymbol{Y}}(\boldsymbol{y}) \propto \mathbf{1}_{\{\|\boldsymbol{y}\|_2 \leqslant 1\}}$，从而

$$f_{Y_1}(x) \propto \int \cdots \int_{\sum_{i=2}^n y_i^2 \leqslant 1-x^2} \mathrm{d}y_2 \cdots \mathrm{d}y_n = \int_{B(0,\sqrt{1-x^2})} \mathrm{d}y_2 \cdots \mathrm{d}y_n = V_{n-1}(\sqrt{1-x^2}),$$

其中 $V_k(r)=V_k(1)\cdot r^k$，从而

$$f_{Y_1}(x)\propto V_{n-1}(1)\cdot(\sqrt{1-x^2})^{n-1}\propto(1-x^2)^{\frac{n-1}{2}}。$$

(2) (对于 $\boldsymbol{X}\sim U(\mathbb{S}^{n-1})$，其一维边缘分布的密度 $f_{X_1}(x)$ 与球面对应高度 x 的“环带”表面积成正比。)

考虑区域 $X_1\in[x,x+\mathrm{d}x]$，其为 $(n-2)$ 维的球面，半径为 $r=\sqrt{1-x^2}$，则环带的表面积 $\mathrm{d}A$ 由两部分决定：

1. 截面 ($(n-2)$ 维球面) 的表面积测度 $\mathrm{d}\sigma$，满足

$$\mathrm{d}\sigma\propto r^{n-2}=(1-x^2)^{\frac{n-2}{2}}。$$

2. 沿球面经线方向的弧长 $\mathrm{d}s$，满足

$$\mathrm{d}s=\frac{\mathrm{d}x}{\sin\theta}=\frac{\mathrm{d}x}{\sqrt{1-x^2}}=(1-x^2)^{-1/2}\mathrm{d}x,$$

其中 θ 为切向量, 垂直轴的夹角。

因此

$$f_{X_1}(x)\propto(1-x^2)^{\frac{n-2}{2}}\cdot(1-x^2)^{-1/2}=(1-x^2)^{\frac{n-3}{2}}。$$

注释 特别地，当 $n=3$ 时，$f_{X_1}(x)\propto(1-x^2)^0=1$，即 $X_1\sim U(-1,1)$；当 $n=2$ 时，$f_{X_1}(x)\propto(1-x^2)^{-1/2}$，即为 Arcsine 分布。

28 [**大立方体概率悖论**] 设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。我们将证明：$\boldsymbol{g}$ 以高概率在 Euclidean 距离的意义下靠近一个边长固定的单位立方体，但是同时极难落于一个边长即使大出百倍的立方体内部。

(1) 设 $\pi_a:\mathbb{R}^n\to[-a,a]^n$ 为向立方体 $[-a,a]^n$ 的度量投影，即

$$\pi_a(\boldsymbol{x})=\arg\min_{\boldsymbol{y}\in[-a,a]^n}\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

证明：$\boldsymbol{y}=\pi_a(\boldsymbol{x})$ 可以通过对坐标进行截断得到，即对于任意的 i，

$$y_i=\begin{cases}x_i, & |x_i|\leqslant a,\\ a\cdot\operatorname{sgn}(x_i), & |x_i|>a\end{cases}。$$

(2) 证明：存在 a,n_0，使得当 $n>n_0$ 时，$\boldsymbol{g}\sim N(0,\boldsymbol{I}_n)$ 以高概率同时满足

$$\operatorname{dist}(\boldsymbol{g},[-a,a]^n)<0.01\|\boldsymbol{g}\|_2,\ \boldsymbol{g}\notin[-100a,100a]^n\ (\text{w.p. }0.99)。$$

证明 (1) 容易知道，π_a 即为优化问题

$$\min_{\boldsymbol{y}}\sum_{i=1}^n(x_i-y_i)^2\quad\text{s.t.}\quad|y_i|\leqslant a$$

的解。

由于目标函数可分离的 ((x_i,y_i) 是不耦合的)，其约束条件为超立方体，因此上述问题等价于

$$\min_{|y_i|\leqslant a}(x_i-y_i)^2。$$

a. 若 $|x_i|\leqslant a$，则最小值于 $y_i=x_i$ 取得，此时距离为 0。

b. 若 $x_i>a$，则最小值于边界 $y_i=a$ 取得。

c. 若 $x_i<-a$，则最小值于边界 $y_i=-a$ 取得。

如此，$y_i=\operatorname{clip}(x_i,-a,a)$。

(2) 设 $\mathcal{E}_1=\{\operatorname{dist}(\boldsymbol{g},[-a,a]^n)<0.01\|\boldsymbol{g}\|_2\}$，$\mathcal{E}_2=\{\boldsymbol{g}\notin[-100a,100a]^n\}$。

(之后只需证明 $\mathrm{P}(\mathcal{E}_1\cap\mathcal{E}_2)\geqslant0.99$，即只需证明 $\mathrm{P}(\mathcal{E}_1),\mathrm{P}(\mathcal{E}_2)\geqslant0.995$。)

- 证明 $\mathrm{P}(\mathcal{E}_1)\geqslant0.995$

设 $D_n^2=\operatorname{dist}(\boldsymbol{g},[-a,a]^n)^2$，$V_n^2=\|\boldsymbol{g}\|_2^2=\sum_{i=1}^n G_i^2$。

对于 V_n^2，根据 WLLN，可得

$$\frac{1}{n}V_n^2\xrightarrow{\mathrm{P}}\mathrm{E}[G_1^2]=1。$$

对于 D_n^2，由于

$$D_n^2 = \operatorname{dist}(\boldsymbol{g}, [-a,a]^n)^2 = \sum_{i=1}^n (|g_i| - a)_+^2,$$

其中 $g_1, \cdots, g_n$ i.i.d. $\sim N(0,1)$，因此根据 WLLN，记 $h(s) = (|s|-a)_+^2$，可得

$$\frac{1}{n} D_n^2 = \frac{1}{n} \sum_{i=1}^n h(G_i) \xrightarrow{\mathrm{P}} \mathrm{E}[h(G_1)]。$$

定义

$$f(a) = \mathrm{E}[(|g_1| - a)_+^2] = 2\int_a^\infty (x-a)^2 \frac{1}{\sqrt{2\pi}} \mathrm{e}^{-x^2/2} \mathrm{d}x,$$

则根据 Lebesgue 控制收敛定理，可得 $\lim_{a\to\infty} f(a) = 0$。因此存在 $a_0 > 0$，使得当 $a > a_0$ 时，

$$f(a) < \frac{(0.01)^2}{2},$$

从而

$$\frac{D_n^2}{V_n^2} = \frac{D_n^2/n}{V_n^2/n} \xrightarrow{\mathrm{P}} \frac{f(a)}{1} < \frac{(0.01)^2}{2},$$

从而存在 n_1，使得当 $n \geqslant n_1$ 时，$\mathrm{P}\{D_n/V_n < 0.01\} \geqslant 0.995$，即 $\mathrm{P}(\mathcal{E}_1) \geqslant 0.995$。

- 证明 $\mathrm{P}(\mathcal{E}_2) \geqslant 0.995$

对于 $\mathcal{E}_2$，考虑 $\mathcal{E}_2^c = \{\boldsymbol{g} \in [-100a, 100a]^n\}$，则

$$\mathrm{P}(\mathcal{E}_2^c) = \mathrm{P}\Big\{\max_{1\leqslant i\leqslant n} |G_i| \leqslant 100a\Big\} = \prod_{i=1}^n \mathrm{P}\{|G_i| \leqslant 100a\} = [\mathrm{P}\{|G_1| \leqslant 100a\}]^n \to 0,$$

因此存在 n_2，使得当 $n \geqslant n_2$ 时，$\mathrm{P}(\mathcal{E}_2^c) \leqslant 0.005$，即 $\mathrm{P}(\mathcal{E}_2) \geqslant 0.995$。

如此，令 $n_0 = \max\{n_1, n_2\}$，则当 $n > n_0$ 时，

$$\mathrm{P}(\mathcal{E}_1 \cap \mathcal{E}_2) \geqslant \mathrm{P}(\mathcal{E}_1) + \mathrm{P}(\mathcal{E}_2) - 1 \geqslant 0.995 + 0.995 - 1 = 0.99。$$

29 [**Parseval 框架，正交矩阵的关系**] 设 $\boldsymbol{U} \in \mathbb{R}^{n\times N}$，证明：$\boldsymbol{U}$ 的列向量构成 $\mathbb{R}^n$ 的 Parseval 框架，当且仅当 $\boldsymbol{U}$ 的行向量组是正交规范的。

证明 记 $\boldsymbol{U}$ 的列向量, 行向量分别为 $\{\boldsymbol{u}_i\}_{i=1}^N, \{\boldsymbol{r}_i\}_{i=1}^n$。

对于列向量，若 $\{\boldsymbol{u}_i\}_{i=1}^N$ 构成 $\mathbb{R}^n$ 的 Parseval 框架，则首先考虑列向量，根据 Parseval 框架性，可得

$$\boldsymbol{U}\boldsymbol{U}^\top = \sum_{i=1}^N \boldsymbol{u}_i \boldsymbol{u}_i^\top = \boldsymbol{I}_n。$$

之后考虑行向量，由于 $(\boldsymbol{U}\boldsymbol{U}^\top)_{jk} = \langle \boldsymbol{r}_j, \boldsymbol{r}_k \rangle$，因此 $\boldsymbol{U}\boldsymbol{U}^\top = \boldsymbol{I}_n$，当且仅当

$$\langle \boldsymbol{r}_j, \boldsymbol{r}_k \rangle = \delta_{jk} = \begin{cases} 1, j = k, \\ 0, j \neq k \end{cases},$$

即 $\{\boldsymbol{r}_j\}_{j=1}^n$ 为 $\mathbb{R}^N$ 的正交规范向量组。

30 [**Mercedes-Benz 框架**] 考虑分布于 $\mathbb{S}^2(0, \sqrt{2/N})$ 的 N 个等间距点 (当 $N = 3$ 时，其构型类似于奔驰汽车的标志)。证明：由上述 N 个点所构成的向量集合 $\{\boldsymbol{x}_k\}_{k=1}^N$ 为 $\mathbb{R}^2$ 的 Parseval 框架 (也被称为 1-紧框架)。

证明 (当 $N = 2$ 时，两点共线，无法张成 $\mathbb{R}^2$，因此之后只需考虑 $N \geqslant 3$ 的情况。)

记 $R = \sqrt{2/N}$，设

$$\boldsymbol{x}_k = R\begin{pmatrix} \cos\theta_k \\ \sin\theta_k \end{pmatrix}, \ \theta_k = \frac{2\pi(k-1)}{N},$$

则

$$\boldsymbol{x}_k\boldsymbol{x}_k^\top = R^2\begin{pmatrix}\cos^2\theta_k & \cos\theta_k\sin\theta_k\\ \cos\theta_k\sin\theta_k & \sin^2\theta_k\end{pmatrix}$$
$$= \frac{R^2}{2}\begin{pmatrix}1+\cos 2\theta_k & \sin 2\theta_k\\ \sin 2\theta_k & 1-\cos 2\theta_k\end{pmatrix},$$

其中当 $N \geqslant 3$ 时，(保证 $2\theta_k$ 的间隔不是 π 的倍数)，由于 N 次单位根之和为零，可得

$$\sum_{k=1}^N \cos 2\theta_k = \sum_{k=1}^N \sin 2\theta_k = 0,$$

因此

$$S_{11} = \frac{R^2}{2}\sum_{k=1}^N(1+\cos 2\theta_k) = \frac{R^2}{2}(N+0) = \frac{NR^2}{2},$$
$$S_{22} = \frac{R^2}{2}\sum_{k=1}^N(1-\cos 2\theta_k) = \frac{R^2}{2}(N-0) = \frac{NR^2}{2},$$
$$S_{12} = S_{21} = \frac{R^2}{2}\sum_{k=1}^N \sin 2\theta_k = 0,$$

即

$$\boldsymbol{S} = \begin{pmatrix}1 & 0\\ 0 & 1\end{pmatrix} = \boldsymbol{I}_2。$$

31 [**各向同性分布与 Parseval 框架的转化**] 设 $\boldsymbol{X} \in \mathbb{R}^n$ 为各向同性的随机变量，其取值于有限点集 $\{\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N\} \subset \mathbb{R}^n$，对应的概率为 $\mathrm{P}\{\boldsymbol{X} = \boldsymbol{x}_k\} = p_k$ (满足 $\sum_{k=1}^N p_k = 1$)。证明：通过概率加权的向量集合 $\{\sqrt{p_1}\boldsymbol{x}_1, \cdots, \sqrt{p_N}\boldsymbol{x}_N\}$ 构成 $\mathbb{R}^n$ 的 Parseval 框架。

证明 令 $\boldsymbol{u}_k = \sqrt{p_k}\boldsymbol{x}_k$，则

$$\boldsymbol{I}_n = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \sum_{k=1}^N p_k(\boldsymbol{x}_k\boldsymbol{x}_k^\top) = \sum_{k=1}^N \boldsymbol{u}_k\boldsymbol{u}_k^\top,$$

因此对于任意的 $\boldsymbol{v} \in \mathbb{R}^n$，

$$\sum_{k=1}^N \langle \boldsymbol{v}, \boldsymbol{u}_k\rangle^2 = \sum_{k=1}^N \boldsymbol{v}^\top(\boldsymbol{u}_k\boldsymbol{u}_k^\top)\boldsymbol{v} = \boldsymbol{v}^\top\left(\sum_{k=1}^N \boldsymbol{u}_k\boldsymbol{u}_k^\top\right)\boldsymbol{v} = \boldsymbol{v}^\top\boldsymbol{I}_n\boldsymbol{v} = \|\boldsymbol{v}\|^2,$$

可得 $\{\sqrt{p_k}\boldsymbol{x}_k\}_{k=1}^N$ 构成 $\mathbb{R}^n$ 的 Parseval 框架。

32 [**一维边缘分布的 sub-Gaussian 范数性质**] 设 $\boldsymbol{X} \in \mathbb{R}^n$ 为 sub-Gaussian 随机向量。证明：对于任意的 $\boldsymbol{v} \in \mathbb{R}^n$，其一维边缘分布 (即内积 $\langle \boldsymbol{X}, \boldsymbol{v}\rangle$) 的 sub-Gaussian 范数满足

$$\|\langle \boldsymbol{X}, \boldsymbol{v}\rangle\|_{\psi_2} \leqslant \|\boldsymbol{X}\|_{\psi_2}\|\boldsymbol{v}\|_2,$$

证明 若 $\boldsymbol{v} = \boldsymbol{0}$，则 $\langle \boldsymbol{X}, \boldsymbol{0}\rangle = 0$，结论是平凡的；之后只需考虑 $\boldsymbol{v} \neq \boldsymbol{0}$ 的情况。

将 $\boldsymbol{v}$ 分解为 $\boldsymbol{v} = \|\boldsymbol{v}\|_2 \cdot \bar{\boldsymbol{v}}$，则

$$\|\langle \boldsymbol{X}, \boldsymbol{v}\rangle\|_{\psi_2} = \|\langle \boldsymbol{X}, \|\boldsymbol{v}\|_2\bar{\boldsymbol{v}}\rangle\|_{\psi_2} = \|\boldsymbol{v}\|_2\|\langle \boldsymbol{X}, \bar{\boldsymbol{v}}\rangle\|_{\psi_2},$$

其中

$$\|\langle \boldsymbol{X}, \bar{\boldsymbol{v}}\rangle\|_{\psi_2} \leqslant \sup_{\boldsymbol{z}\in\mathbb{S}^{n-1}}\|\langle \boldsymbol{X}, \boldsymbol{z}\rangle\|_{\psi_2} = \|\boldsymbol{X}\|_{\psi_2},$$

将其代入，可得

$$\|\langle \boldsymbol{X}, \boldsymbol{v}\rangle\|_{\psi_2} \leqslant \|\boldsymbol{v}\|_2 \cdot \|\boldsymbol{X}\|_{\psi_2}。$$

33 [**sub-Gaussian 范数的旋转不变性**] 命题 P3.3.1 (旋转不变性) 说明标准正态分布满足旋转不变性。sub-Gaussian 分布通常未必满足旋转不变性，但是 sub-Gaussian 范数满足。

设 $\boldsymbol{U} \in \mathbb{R}^{n\times n}$ 为正交矩阵，$\boldsymbol{X} \in \mathbb{R}^n$ 为 sub-Gaussian 随机向量。证明：$\boldsymbol{UX}$ 为 sub-Gaussian 随机向量，满足

$$\|\boldsymbol{UX}\|_{\psi_2} = \|\boldsymbol{X}\|_{\psi_2}。$$

证明 对于

$$\|\boldsymbol{UX}\|_{\psi_2} = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{UX}, \boldsymbol{v}\rangle\|_{\psi_2} = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X}, \boldsymbol{U}^\top\boldsymbol{v}\rangle\|_{\psi_2},$$

令 $\boldsymbol{w} = \boldsymbol{U}^\top\boldsymbol{v}$，则

$$\|\boldsymbol{w}\|_2 = \|\boldsymbol{U}^\top\boldsymbol{v}\|_2 = \|\boldsymbol{v}\|_2,$$

因此 $\boldsymbol{v} \mapsto \boldsymbol{U}^\top\boldsymbol{v}$ 为从 $\mathbb{S}^{n-1}$ 到自身的双射，从而

$$\|\boldsymbol{UX}\|_{\psi_2} = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X}, \boldsymbol{U}^\top\boldsymbol{v}\rangle\|_{\psi_2} = \sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X}, \boldsymbol{w}\rangle\|_{\psi_2} = \|\boldsymbol{X}\|_{\psi_2}。$$

即 $\boldsymbol{UX}$ 为 sub-Gaussian 随机向量。

34 [**sub-Gaussian 双线性型**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m \in \mathbb{R}^n$ 为相互独立的零均值 K-sub-Gaussian 随机向量。

(1) 证明：对于任意的 $\boldsymbol{u} \in \mathbb{R}^m, \boldsymbol{v} \in \mathbb{R}^n$，$\boldsymbol{u}^\top\boldsymbol{Av}$ 为 sub-Gaussian 随机向量，满足

$$\|\boldsymbol{u}^\top\boldsymbol{Av}\|_{\psi_2} \leqslant C\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2 \max_{1\leqslant i\leqslant m} \|\boldsymbol{A}_i\|_{\psi_2}。 \qquad (C>0)$$

(2) 证明：将行独立的 sub-Gaussian 随机向量的条件更改为列独立的 sub-Gaussian 随机向量，结论仍然成立。

证明 (1) 容易知道，

$$\boldsymbol{u}^\top\boldsymbol{Av} = \sum_{i=1}^m u_i(\boldsymbol{A}_i\boldsymbol{v}) = \sum_{i=1}^m u_i\langle \boldsymbol{A}_i, \boldsymbol{v}\rangle,$$

设 $Z_i = \langle \boldsymbol{A}_i, \boldsymbol{v}\rangle$，则利用习题 Q3.32 (一维边缘分布的 sub-Gaussian 范数性质) 的结论，可得

$$\|Z_i\|_{\psi_2} \leqslant K\|\boldsymbol{v}\|_2,$$

因此根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\begin{aligned}\|\boldsymbol{u}^\top\boldsymbol{Av}\|_{\psi_2}^2 = \left\|\sum_{i=1}^m u_iZ_i\right\|_{\psi_2}^2 &\leqslant C'\sum_{i=1}^m \|u_iZ_i\|_{\psi_2}^2 = C'\sum_{i=1}^m u_i^2\|Z_i\|_{\psi_2}^2 \qquad (C'>0)\\ &\leqslant C'\sum_{i=1}^m u_i^2(K\|\boldsymbol{v}\|_2)^2 = C'K^2\|\boldsymbol{v}\|_2^2\sum_{i=1}^m u_i^2 = C'K^2\|\boldsymbol{v}\|_2^2\|\boldsymbol{u}\|_2^2,\end{aligned}$$

两侧开方，

$$\|\boldsymbol{u}^\top\boldsymbol{Av}\|_{\psi_2} \leqslant C\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2 \max_i \|\boldsymbol{A}_i\|_{\psi_2}。 \qquad (C=\sqrt{C'}>0)$$

(2) 若 $\boldsymbol{A}$ 的列向量 $\boldsymbol{C}_1, \cdots, \boldsymbol{C}_n \in \mathbb{R}^m$ 为相互独立的 sub-Gaussian 随机向量，则 $\boldsymbol{A}^\top$ 的行向量 $\boldsymbol{C}_1^\top, \cdots, \boldsymbol{C}_n^\top \in \mathbb{R}^m$ 为相互独立的 sub-Gaussian 随机向量。

注意到双线性型 $\boldsymbol{u}^\top\boldsymbol{Av}$ 为标量，满足

$$\boldsymbol{u}^\top\boldsymbol{Av} = (\boldsymbol{u}^\top\boldsymbol{Av})^\top = \boldsymbol{v}^\top\boldsymbol{A}^\top\boldsymbol{u},$$

因此利用 (1) 的结论，可得

$$\|\boldsymbol{v}^\top\boldsymbol{A}^\top\boldsymbol{u}\|_{\psi_2} \leqslant C\|\boldsymbol{v}\|_2\|\boldsymbol{u}\|_2 \max_{1\leqslant j\leqslant n} \|\boldsymbol{C}_j^\top\|_{\psi_2},$$

即

$$\|\boldsymbol{u}^\top\boldsymbol{Av}\|_{\psi_2} \leqslant C\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2 \max_{1\leqslant j\leqslant n} \|\boldsymbol{C}_j\|_{\psi_2}。$$

35 [**随机向量和的 sub-Gaussian 范数**] 一维随机变量的性质可以推广到高维空间，即命题 P2.7.1 (和式的 sub-Gaussian 范数)

的推广。

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N\in\mathbb{R}^n$ 为相互独立的零均值 sub-Gaussian 随机向量。证明：

$$\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|\boldsymbol{X}_i\|_{\psi_2}^2。 \qquad (C>0)$$

证明 设 $\boldsymbol{S}=\sum_{i=1}^N \boldsymbol{X}_i$，则对于任意的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，

$$\langle \boldsymbol{S},\boldsymbol{v}\rangle = \left\langle \sum_{i=1}^N \boldsymbol{X}_i,\boldsymbol{v}\right\rangle = \sum_{i=1}^N \langle \boldsymbol{X}_i,\boldsymbol{v}\rangle,$$

记 $Y_i=\langle \boldsymbol{X}_i,\boldsymbol{v}\rangle$，则 $Y_1,\cdots,Y_N$ 是相互独立的零均值随机变量，因此根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\left\|\sum_{i=1}^N Y_i\right\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|Y_i\|_{\psi_2}^2, \qquad (C>0)$$

即

$$\|\langle \boldsymbol{S},\boldsymbol{v}\rangle\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|\langle \boldsymbol{X}_i,\boldsymbol{v}\rangle\|_{\psi_2}^2,$$

其中

$$\|\langle \boldsymbol{X}_i,\boldsymbol{v}\rangle\|_{\psi_2} \leqslant \sup_{\boldsymbol{u}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X}_i,\boldsymbol{u}\rangle\|_{\psi_2} = \|\boldsymbol{X}_i\|_{\psi_2},$$

将其代入，可得

$$\|\langle \boldsymbol{S},\boldsymbol{v}\rangle\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|\boldsymbol{X}_i\|_{\psi_2}^2,$$

两侧关于 $\boldsymbol{v}$ 取上确界，

$$\|\boldsymbol{S}\|_{\psi_2}^2 = \left(\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{S},\boldsymbol{v}\rangle\|_{\psi_2}\right)^2 = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{S},\boldsymbol{v}\rangle\|_{\psi_2}^2,$$

即

$$\|\boldsymbol{S}\|_{\psi_2}^2 \leqslant C\sum_{i=1}^N \|\boldsymbol{X}_i\|_{\psi_2}^2。$$

36 [**sub-Gaussian 坐标的随机向量**] 在引理 L3.4.2 (独立 sub-Gaussian 坐标的分布) 中，若各分量相互独立，高维次高斯范数满足维数无关界 $\|\boldsymbol{X}\|_{\psi_2}\leqslant C\max_{1\leqslant i\leqslant n}\|X_i\|_{\psi_2}$。本题考查忽略独立性假设之后的范数界限变化。

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其中 $X_1,\cdots,X_n$ 为 sub-Gaussian 随机变量 (未必独立)。

(1) 证明：$\boldsymbol{X}$ 为 sub-Gaussian 随机向量，满足

$$\max_{i\leqslant n}\|X_i\|_{\psi_2} \leqslant \|\boldsymbol{X}\|_{\psi_2} \leqslant \sqrt{n}\max_{i\leqslant n}\|X_i\|_{\psi_2}。$$

(2) 说明 (1) 的界限是最优的。

证明 (1) 根据定义 D3.4.1 (sub-Gaussian 随机向量)，可得

$$\|\boldsymbol{X}\|_{\psi_2} = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}。$$

对于下界，令 $\boldsymbol{v}=\boldsymbol{e}_i=(0,\cdots,1,\cdots,0)^\top\in\mathbb{S}^{n-1}$，则

$$\|\boldsymbol{X}\|_{\psi_2} \geqslant \|\langle \boldsymbol{X},\boldsymbol{e}_i\rangle\|_{\psi_2} = \|X_i\|_{\psi_2}。$$

对于上界，令 $\boldsymbol{v}=(v_1,\cdots,v_n)^\top\in\mathbb{S}^{n-1}$ 满足 $\sum_{i=1}^n v_i^2=1$，则

$$\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}=\left\|\sum_{i=1}^n v_iX_i\right\|_{\psi_2}\leqslant\sum_{i=1}^n|v_i|\|X_i\|_{\psi_2}\leqslant K\sum_{i=1}^n|v_i|,\qquad\left(K=\max_{1\leqslant i\leqslant n}\|X_i\|_{\psi_2}\right)$$

其中利用 Cauchy 不等式，可得

$$\sum_{i=1}^n|v_i|\cdot 1\leqslant\sqrt{\sum_{i=1}^n v_i^2}\sqrt{\sum_{i=1}^n 1^2}=1\cdot\sqrt{n}=\sqrt{n},$$

将其代入

$$\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}\leqslant\sqrt{n}K,$$

两侧取上确界，

$$\|\boldsymbol{X}\|_{\psi_2}\leqslant\sqrt{n}\max_{i\leqslant n}\|X_i\|_{\psi_2}。$$

(2) 对于下界，设 $X_1,\cdots,X_n$ i.i.d. $\sim N(0,1)$，则对于任意的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，

$$\langle\boldsymbol{X},\boldsymbol{v}\rangle=\sum_{i=1}^n v_iX_i=N\left(0,\sum_{i=1}^n v_i^2\right)=N(0,1),$$

因此 $\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}=\|g\|_{\psi_2}$。

对于上界，设 $X_1=\cdots=X_n=X\sim N(0,1)$，则

$$\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}=\left\|\sum_{i=1}^n v_iX\right\|_{\psi_2}\leqslant\|X\|_{\psi_2}\sum_{i=1}^n|v_i|,$$

令 $\boldsymbol{v}=(1/\sqrt{n},\cdots,1/\sqrt{n})^\top$，则

$$\|\boldsymbol{X}\|_{\psi_2}=\sqrt{n}\|X\|_{\psi_2},$$

即

$$\|\boldsymbol{X}\|_{\psi_2}=\sqrt{n}\max_{1\leqslant i\leqslant n}\|X_i\|_{\psi_2}。$$

37 [**sub-Gaussian 向量范数未必浓度的反例**] 定理 T3.1.1 (范数的集中) 指出，若随机向量 $\boldsymbol{X}=(X_1,\cdots,X_n)$ 的坐标分量 X_i 为相互独立，标准化的 sub-Gaussian 随机变量，则其 Euclidean 范数 $\|\boldsymbol{X}\|_2$ 高度集中于 $\sqrt{n}$ 附近。

事实上，Euclidean 范数的浓度高度依赖于坐标的独立性。即使 sub-Gaussian 随机向量满足各向同性，若坐标之间存在强耦合，范数可能完全不集中于 $\sqrt{n}$。若忽略坐标独立性假设，构造反例，使得上述结论未必成立。

解答 设 $\boldsymbol{G}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，$\eta\sim\text{Bernoulli}(1/2)$，定义 $\boldsymbol{X}=\sqrt{2}\eta\boldsymbol{G}$，则：

1. 各向同性：

$$\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]=\mathrm{E}[(\sqrt{2}\eta\boldsymbol{G})(\sqrt{2}\eta\boldsymbol{G})^\top]=2\mathrm{E}[\eta^2]\mathrm{E}[\boldsymbol{G}\boldsymbol{G}^\top]=2\mathrm{E}[\eta]\mathrm{E}[\boldsymbol{G}\boldsymbol{G}^\top]=2\cdot\frac{1}{2}\cdot\boldsymbol{I}_n=\boldsymbol{I}_n。$$

2. sub-Gaussian 性质：

对于任意的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，考虑投影 $\langle\boldsymbol{X},\boldsymbol{v}\rangle=\sqrt{2}\eta\langle\boldsymbol{G},\boldsymbol{v}\rangle$，其中 $Z=\langle\boldsymbol{G},\boldsymbol{v}\rangle\sim N(0,1)$，因此

$$\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2}=\sqrt{2}\|\eta Z\|_{\psi_2}\leqslant\sqrt{2}\|Z\|_{\psi_2}=\sqrt{2}K_0,$$

对 $\boldsymbol{v}$ 取上确界，

$$\|\boldsymbol{X}\|_{\psi_2}\leqslant\sqrt{2}K_0。$$

可得 $\boldsymbol{X}$ 为各向同性的 sub-Gaussian 向量。

但是，对于 $\|\boldsymbol{X}\|_2=\sqrt{2}\eta\|\boldsymbol{G}\|_2$，其服从

$$\mathrm{P}\{\|\boldsymbol{X}\|_2=0\}=\mathrm{P}\{\|\boldsymbol{X}\|_2=\sqrt{2}\|\boldsymbol{G}\|_2\}=\frac{1}{2},$$

因此

$$\mathrm{P}\{|\|\boldsymbol{X}\|_2-\sqrt{n}|\geqslant 0.1\sqrt{n}\}=\frac{1}{2}+\frac{1}{2}=1。$$

38 [**Gaussian 随机向量的 sub-Gaussian 范数**] 在习题 Q2.24 (sub-Gaussian 分布的例子) (3) 中，我们已经证明一维正态随机变量 $Y\sim N(0,\sigma^2)$ 的 sub-Gaussian 范数满足 $\|Y\|_{\psi_2}=\sqrt{8/3}\sigma$。

将上述结论推广至高维情形：设 $\boldsymbol{X}\sim N(\boldsymbol{0},\boldsymbol{\Sigma})$。证明：

$$\|\boldsymbol{X}\|_{\psi_2}=\sqrt{\frac{8}{3}}\|\boldsymbol{\Sigma}\|^{1/2},$$

其中 $\|\boldsymbol{\Sigma}\|=\lambda_{\max}(\boldsymbol{\Sigma})$。

证明 $\boldsymbol{X}$ 的 sub-Gaussian 范数为

$$\|\boldsymbol{X}\|_{\psi_2}=\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}}\|\langle\boldsymbol{X},\boldsymbol{v}\rangle\|_{\psi_2},$$

设 $Y_{\boldsymbol{v}}=\langle\boldsymbol{X},\boldsymbol{v}\rangle\sim N(0,\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})$，则

$$\|\boldsymbol{X}\|_{\psi_2}=\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}}\sqrt{\frac{8}{3}}(\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})^{1/2}=\sqrt{\frac{8}{3}}\left(\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}}\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}\right)^{1/2},$$

因此

$$\|Y_{\boldsymbol{v}}\|_{\psi_2}=\sqrt{\frac{8}{3}}\sigma_{\boldsymbol{v}}=\sqrt{\frac{8}{3}}(\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v})^{1/2}=\sqrt{\frac{8}{3}}\lambda_{\max}(\boldsymbol{\Sigma})=\sqrt{\frac{8}{3}}\|\boldsymbol{\Sigma}\|。$$

39 [**sub-Gaussian 随机向量的 Euclidean 范数性质**]

(1) 设 $X_1,\cdots,X_n$ 为 sub-Gaussian 随机变量 (未必独立)。证明：

$$\left\|\left(\sum_{i=1}^n X_i^2\right)^{1/2}\right\|_{\psi_2}\leqslant\left(\sum_{i=1}^n\|X_i\|_{\psi_2}^2\right)^{1/2}。$$

(2) 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量。证明：$\|\boldsymbol{X}\|_2$ 为 sub-Gaussian 随机变量，满足

$$\|\|\boldsymbol{X}\|_2\|_{\psi_2}\leqslant\sqrt{n}\|\boldsymbol{X}\|_{\psi_2}。$$

之后解释 $\sqrt{n}$ 是最优的。在命题 P6.2.1 (sub-Gaussian 随机向量的范数) 中，我们将证明一个更精细的界限。

证明 (1) 记

$$K_i=\|X_i\|_{\psi_2},\ K=\left(\sum_{i=1}^n K_i^2\right)^{1/2}=\left(\sum_{i=1}^n\|X_i\|_{\psi_2}^2\right)^{1/2},$$

则要证明 $Y:=(\sum_{i=1}^n X_i^2)^{1/2}$ 满足 $\|Y\|_{\psi_2}\leqslant K$，只需证明

$$\mathrm{E}\left[\exp\left(\frac{Y^2}{K^2}\right)\right]=\mathrm{E}\left[\exp\left(\frac{\sum_{i=1}^n X_i^2}{K^2}\right)\right]\leqslant 2。$$

构造非负凸组合权重 $w_i=K_i^2/K^2$，满足 $w_i\geqslant 0$，$\sum_{i=1}^n w_i=1$，将指数项重写为基于权重 w_i 的凸组合形式，

$$\frac{\sum_{i=1}^n X_i^2}{K^2}=\sum_{i=1}^n\left(\frac{K_i^2}{\sum_{j=1}^n K_j^2}\right)\frac{X_i^2}{K_i^2}=\sum_{i=1}^n w_i\frac{X_i^2}{K_i^2},$$

因此利用 Jensen 不等式，可得

$$\exp\left(\sum_{i=1}^n w_i\frac{X_i^2}{K_i^2}\right)\leqslant\sum_{i=1}^n w_i\exp\left(\frac{X_i^2}{K_i^2}\right),$$

两侧取期望，

$$\mathrm{E}\left[\exp\left(\frac{\sum_{i=1}^n X_i^2}{K^2}\right)\right] \leqslant \sum_{i=1}^n w_i \mathrm{E}\left[\exp\left(\frac{X_i^2}{K_i^2}\right)\right] \leqslant \sum_{i=1}^n w_i \cdot 2 = 2。$$

(2) 利用 (1) 的结论，可得

$$\|\|\boldsymbol{X}\|_2\|_{\psi_2} \leqslant \left(\sum_{i=1}^n \|X_i\|_{\psi_2}^2\right)^{1/2},$$

其中

$$\|X_i\|_{\psi_2} = \|\langle \boldsymbol{X}, \boldsymbol{e}_i\rangle\|_{\psi_2} \leqslant \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{X}, \boldsymbol{v}\rangle\|_{\psi_2} = \|\boldsymbol{X}\|_{\psi_2},$$

将其代入，可得

$$\|\|\boldsymbol{X}\|_2\|_{\psi_2} \leqslant \left(\sum_{i=1}^n \|\boldsymbol{X}\|_{\psi_2}^2\right)^{1/2} = \sqrt{n}\|\boldsymbol{X}\|_{\psi_2}。$$

40 [**高维随机向量的几乎正交性**] 从 $\mathbb{S}^{n-1}$ 独立均匀抽取的两个随机向量以高概率满足“几乎正交”。本题旨在将这一几何现象推广至一般分量独立的 sub-Gaussian 随机向量。

(1) 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为随机向量，其元素均为相互独立的标准化 K-sub-Gaussian 随机变量。定义方向向量

$$\boldsymbol{\theta} = \begin{cases} \bar{\boldsymbol{X}}, & \boldsymbol{X}\neq\boldsymbol{0}, \\ \boldsymbol{0}, & \boldsymbol{X}=\boldsymbol{0} \end{cases},$$

令 $\boldsymbol{\eta}$ 为 $\boldsymbol{\theta}$ 的独立副本。证明：

$$|\langle\boldsymbol{\theta},\boldsymbol{\eta}\rangle| \leqslant \frac{C_K}{\sqrt{n}} \text{ (w.p. 0.99)。} \qquad (C_K>0)$$

(2) 之后只需说明 (1) 的坐标的独立性假设对于随机向量的几乎正交性是至关重要的。构造独立同分布，各向同性的 K-sub-Gaussian 随机向量 $\boldsymbol{X},\boldsymbol{Y}$，使得

$$\mathrm{P}\{\boldsymbol{X}=\boldsymbol{Y}\} \geqslant 0.99,$$

这说明若失去分量独立性假设，则 $\langle\boldsymbol{\theta},\boldsymbol{\eta}\rangle$ 无法产生 $O(1/\sqrt{n})$ 的衰减。

证明 (1) 设 $\boldsymbol{Y}$ 为 $\boldsymbol{X}$ 的独立副本，$\boldsymbol{\eta}=\bar{\boldsymbol{Y}}$。

- Euclidean 范数的集中估计

  根据定理 T3.1.1 (范数的集中)，可得

$$\mathrm{P}\{|\|\boldsymbol{X}\|_2-\sqrt{n}| \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{K^4}\right)。 \qquad (c>0)$$

  令 $t=\sqrt{n}/2$，定义 $\boldsymbol{X}$ 集中于期望附近的良性事件为 $\mathcal{E}_X=\{\sqrt{n}/2\leqslant\|\boldsymbol{X}\|_2\leqslant 3\sqrt{n}/2\}$，可得

$$\mathrm{P}(\mathcal{E}_X^{\mathrm{c}}) \leqslant \mathrm{P}\left\{|\|\boldsymbol{X}\|_2-\sqrt{n}| \geqslant \frac{1}{2}\sqrt{n}\right\} \leqslant 2\exp\left(-\frac{cn}{4K^4}\right), \qquad (c>0)$$

  (无需通过定义 $\mathcal{E}_Y$ 控制 $\boldsymbol{Y}$ 的范数上限，因为方向向量 $\boldsymbol{\eta}$ 本身即为单位向量，直接对 $\boldsymbol{\eta}$ 条件化即可。)

  因此当 n 充分大时，

$$\mathrm{P}(\mathcal{E}_X^{\mathrm{c}}) \leqslant 0.005。 \qquad (\mathrm{I})$$

- 条件内积的 sub-Gaussian 性质

  给定 $\boldsymbol{\eta}=\boldsymbol{v}$，此时

$$\langle\boldsymbol{X},\boldsymbol{v}\rangle \mid \boldsymbol{\eta}=\boldsymbol{v} = \sum_{i=1}^n v_i X_i$$

为相互独立的 sub-Gaussian 随机变量的加权和，因此根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\|\langle \boldsymbol{X}, \boldsymbol{v}\rangle\|_{\psi_2}^2 \leqslant C_1 \sum_{i=1}^n \|v_i X_i\|_{\psi_2}^2 \leqslant C_1 \sum_{i=1}^n v_i^2 K^2 = C_1 K^2 \|\boldsymbol{v}\|_2^2 = C_1 K^2, \qquad (C_1 > 0)$$

从而

$$\mathrm{P}\{|\langle \boldsymbol{X}, \boldsymbol{v}\rangle| \geqslant t \mid \boldsymbol{\eta} = \boldsymbol{v}\} \leqslant 2\exp\left(-\frac{c_1 t^2}{C_1 K^2}\right)。 \qquad (c_1 > 0)$$

- 对内积进行全概率估计

考虑方向向量的内积，

$$|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| = \frac{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle|}{\|\boldsymbol{X}\|_2},$$

将其于 $\mathcal{E}_X^{\mathrm{c}}$ 分解，

$$\mathrm{P}\left\{|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| \geqslant \frac{C_K}{\sqrt{n}}\right\} \leqslant \mathrm{P}(\mathcal{E}_X^{\mathrm{c}}) + \mathrm{P}\left\{\frac{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle|}{\|\boldsymbol{X}\|_2} \geqslant \frac{C_K}{\sqrt{n}} \cap \mathcal{E}_X\right\}。$$

(之后只需估计第二项即可。)

当 $\mathcal{E}_X$ 发生时，$\|\boldsymbol{X}\|_2 \geqslant \sqrt{n}/2$，可得

$$\mathrm{P}\left\{\frac{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle|}{\|\boldsymbol{X}\|_2} \geqslant \frac{C_K}{\sqrt{n}} \cap \mathcal{E}_X\right\} \leqslant \mathrm{P}\left\{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle| \geqslant \frac{C_K}{2}\right\} = \mathrm{E}\left[\mathrm{P}\left\{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle| \geqslant \frac{C_K}{2} \;\middle|\; \boldsymbol{\eta}\right\}\right] \leqslant 2\exp\left(-\frac{c_2 (C_K/2)^2}{C_1 K^2}\right),$$

因此 C_K 充分大时，

$$\mathrm{P}\left\{\frac{|\langle \boldsymbol{X}, \boldsymbol{\eta}\rangle|}{\|\boldsymbol{X}\|_2} \geqslant \frac{C_K}{\sqrt{n}} \cap \mathcal{E}_X\right\} \leqslant 0.005, \qquad (\mathrm{II})$$

如此，联立 (I)(II)，可得

$$\mathrm{P}\left\{|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| \geqslant \frac{C_K}{\sqrt{n}}\right\} \leqslant 0.005 + 0.005 = 0.01 \implies \mathrm{P}\left\{|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| \leqslant \frac{C_K}{\sqrt{n}}\right\} \geqslant 0.99。$$

(2) **反例一　一维空间的反例**

定义 $\boldsymbol{X} = 1$ (a.s.)，则：

1. 各向同性：$\mathrm{E}[\boldsymbol{X}^2] = 1^2 \cdot 1 = 1$。

2. sub-Gaussian 性：$\boldsymbol{X}$ 为常数，满足 $\|\boldsymbol{X}\|_{\psi_2} = 1/\sqrt{\ln 2}$。

3. 独立副本概率：设 $\boldsymbol{Y}$ 为 $\boldsymbol{X}$ 的独立副本，则 $\mathrm{P}\{\boldsymbol{X} = \boldsymbol{Y}\} = 1 \geqslant 0.99$。

但是，$\boldsymbol{\theta} = \boldsymbol{X}/|\boldsymbol{X}| = 1$，$\boldsymbol{\eta} = \boldsymbol{Y}/|\boldsymbol{Y}| = 1$，此时 $|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| = 1 \gg n^{-1/2}$，这是矛盾的。

反例二　高维空间的反例

设 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，令 $\varepsilon = 0.005$ (满足 $(1-\varepsilon)^2 \approx 0.99$)。

定义 $\boldsymbol{X}$ 为

$$\boldsymbol{X} = \begin{cases} \xi \cdot \frac{1}{\sqrt{1-\varepsilon}} \boldsymbol{v}, & \text{w.p. } 1-\varepsilon, \\ \boldsymbol{Z}, & \text{w.p. } \varepsilon, \end{cases}$$

其中 $\xi \sim$ Rademacher (即 $\boldsymbol{X}$ 分别以概率 $\frac{1-\varepsilon}{2}$ 取值为 $\pm\frac{\boldsymbol{v}}{\sqrt{1-\varepsilon}}$)，$\boldsymbol{Z} \sim N\big(\boldsymbol{0}, \frac{1}{\varepsilon}(\boldsymbol{I}_n - \boldsymbol{v}\boldsymbol{v}^\top)\big)$ (即支撑于 $\boldsymbol{v}^\perp$ 的退化零均值 Gaussian 随机向量)，则：

1. 零均值：

$$\mathrm{E}[\boldsymbol{X}] = (1-\varepsilon)\mathrm{E}[\xi]\frac{\boldsymbol{v}}{\sqrt{1-\varepsilon}} + \varepsilon \mathrm{E}[\boldsymbol{Z}] = \boldsymbol{0}。$$

2. 各向同性：

$$\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = (1-\varepsilon) \cdot \frac{1}{1-\varepsilon}\boldsymbol{v}\boldsymbol{v}^\top + \varepsilon \cdot \frac{1}{\varepsilon}(\boldsymbol{I}_n - \boldsymbol{v}\boldsymbol{v}^\top) = \boldsymbol{v}\boldsymbol{v}^\top + (\boldsymbol{I}_n - \boldsymbol{v}\boldsymbol{v}^\top) = \boldsymbol{I}_n。$$

3. sub-Gaussian 范数有界：对于任意的 $\boldsymbol{u} \in \mathbb{S}^{n-1}$，分解 $\boldsymbol{u} = a\boldsymbol{v} + b\boldsymbol{w}$ (其中 $\boldsymbol{w} \perp \boldsymbol{v}$，$a^2 + b^2 = 1$)，则：

a. 于概率 $1-\varepsilon$ 的分支，

$$|\langle \boldsymbol{X}, \boldsymbol{u}\rangle| = \frac{|a|}{\sqrt{1-\varepsilon}} \leqslant \frac{1}{\sqrt{1-\varepsilon}},$$

其为有界量。

b. 于概率 ε 的分支，

$$\langle \boldsymbol{X}, \boldsymbol{u}\rangle = b\langle \boldsymbol{Z}, \boldsymbol{w}\rangle \sim N\left(0, \frac{b^2}{\varepsilon}\right),$$

其 sub-Gaussian 范数被 $C/\sqrt{\varepsilon}$ 控制。

因此

$$\|\boldsymbol{X}\|_{\psi_2} \leqslant \max\left\{\frac{1}{\sqrt{1-\varepsilon}}, \frac{C}{\sqrt{\varepsilon}}\right\} \leqslant K。$$

设 $\boldsymbol{Y}$ 为 $\boldsymbol{X}$ 的独立副本，其方向向量分别为 $\boldsymbol{\theta}, \boldsymbol{\eta}$，则

$$\mathrm{P}\{\boldsymbol{\theta} \in \{\pm \boldsymbol{v}\}, \boldsymbol{\eta} \in \{\pm \boldsymbol{v}\}\} = (1-\varepsilon)^2 = (0.995)^2 \geqslant 0.99,$$

当上述事件发生时，

$$|\langle \boldsymbol{\theta}, \boldsymbol{\eta}\rangle| = |\langle \pm \boldsymbol{v}, \pm \boldsymbol{v}\rangle| = 1 \gg O\left(\frac{1}{\sqrt{n}}\right) \text{ (w.p. 0.99)}。$$

41 [**指数多个几乎正交的向量**] 于线性代数，我们知道 $\mathbb{R}^n$ 的相互正交的向量的个数不超过 n。但令人惊讶的是，$\mathbb{R}^n$ 可以存在指数级数量的“几乎正交”的向量。

按照以下步骤证明：对于任意的整数 $N \leqslant \mathrm{e}^{cn}$ 存在 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_N \in \mathbb{S}^{n-1}$，满足

$$|\langle \boldsymbol{X}_i, \boldsymbol{X}_j\rangle| \leqslant 0.01。 \qquad (i \neq j)$$

(1) 证明：若 $\boldsymbol{X}, \boldsymbol{Y}$ i.i.d. $\sim U(\mathbb{S}^{n-1})$，则

$$|\langle \boldsymbol{X}, \boldsymbol{Y}\rangle| \leqslant 0.01 \text{ (w.p.1} - 4\mathrm{e}^{-c_0 n})。$$

(2) 对所有满足 $i \neq j$ 的二元组 (i, j) 取并集界，推导上述事件以正概率成立。

证明 • 估计两个随机向量的几乎正交性

设 $\boldsymbol{X}, \boldsymbol{Y} \sim U(\mathbb{S}^{n-1})$，则根据旋转不变性，可得

$$\langle \boldsymbol{X}, \boldsymbol{Y}\rangle \overset{d}{=} \langle \boldsymbol{X}, \boldsymbol{e}_1\rangle = X_1。$$

作出以下推断：

推断 设 $\boldsymbol{X} \in \mathbb{S}^{n-1}$，则

$$\|X_1\|_{\psi_2} \leqslant \frac{C}{\sqrt{n}}。$$

(具体证明过程见注释。)

根据推断，可得

$$\mathrm{P}\{|X_1| \geqslant t\} \leqslant 2\exp\left(-\frac{c' t^2}{\|X_1\|_{\psi_2}^2}\right) \leqslant 2\exp(-c'' t^2 n), \qquad (c', c'' > 0, c'' = C^2 c')$$

令 $t = 0.01$，可得

$$\mathrm{P}\{|\langle \boldsymbol{X}, \boldsymbol{Y}\rangle| > 0.01\} \leqslant 2\mathrm{e}^{-c_0 n}。 \qquad (c_0 = c''(0.01)^2)$$

即 $\mathrm{P}\{|\langle \boldsymbol{X}, \boldsymbol{Y}\rangle| \leqslant 0.01\} \geqslant 1 - 2\mathrm{e}^{-c_0 n}$。

• 利用并集界证明存在性

利用概率方法，设 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_N$ i.i.d. $\sim U(\mathbb{S}^{n-1})$，构造

$$\mathcal{E} = \bigcup_{1 \leqslant i < j \leqslant N} \{|\langle \boldsymbol{X}_i, \boldsymbol{X}_j\rangle| > 0.01\},$$

则

$$\mathrm{P}(\mathcal{E}) \leqslant \sum_{1\leqslant i<j\leqslant N} \mathrm{P}\{|\langle \boldsymbol{X}_i, \boldsymbol{X}_j\rangle| > 0.01\} \leqslant \binom{N}{2} \cdot 2\mathrm{e}^{-c_0 n},$$

因此当 $N \leqslant \mathrm{e}^{cn}$ 时，

$$\mathrm{P}(\mathcal{E}) \leqslant \sum_{1\leqslant i<j\leqslant N} \mathrm{P}\{|\langle \boldsymbol{X}_i, \boldsymbol{X}_j\rangle| > 0.01\} < N^2 \cdot 2\mathrm{e}^{-c_0 n} \leqslant (\mathrm{e}^{cn})^2 \cdot \mathrm{e}^{-c_0 n} = \mathrm{e}^{(2c-c_0)n},$$

此时令 $2c < c_0$。可得 $\mathrm{P}(\mathcal{E}) \to 0$，从而 $\mathrm{P}(\mathcal{E}^c) > 0$。

注释 关于推断的证明过程：

解法一

利用习题 Q3.27 (球面, 球体的一维边缘分布) (2) 的结论，可得

$$f_{X_1}(x) = \frac{1}{C_n}(1-x^2)^{\frac{n-3}{2}}\mathbf{1}_{[-1,1]},$$

其中

$$(1-x^2)^{\frac{n-3}{2}} \leqslant (\mathrm{e}^{-x^2})^{\frac{n-3}{2}} = \mathrm{e}^{-\frac{n-3}{2}x^2},$$

因此

$$f_{X_1}(x) \leqslant \frac{1}{C_n}\mathrm{e}^{-\frac{(n-3)}{2}x^2},$$

即 $f_{X_1}(x)$ 被均值为 0, 方差为 $\sigma^2 = 1/(n-3)$ 的 Gaussian 核所控制，从而

$$\mathrm{P}\{|X_1| \geqslant t\} = 2\int_t^1 f_{X_1}(x)\mathrm{d}x \leqslant \frac{2}{C_n}\int_t^\infty \mathrm{e}^{-\frac{n-3}{2}x^2}\mathrm{d}x \leqslant 2\mathrm{e}^{-\frac{n-3}{2}t^2},$$

对比 sub-Gaussian 随机变量的定义

$$\mathrm{P}\{|X_1| \geqslant t\} \leqslant 2\mathrm{e}^{-\frac{n-3}{2}t^2},$$

令 $K = 1/\sqrt{n-3}$，可得

$$\|X_1\|_{\psi_2} \leqslant \frac{C}{\sqrt{n-3}} \leqslant \frac{C'}{\sqrt{n}}。$$

解法二　Gaussian 表示法

设 $\boldsymbol{G} = (G_1, \cdots, G_n)^\top \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则

$$\boldsymbol{X} \overset{d}{=} \bar{\boldsymbol{G}},\ X_1 = \frac{G_1}{\sqrt{G_1^2 + \cdots + G_n^2}},$$

因此根据 SLLN，可得

$$X_1 \sim \frac{G_1}{\sqrt{n}} = O\left(\frac{1}{\sqrt{n}}\right)。$$

42 [**单位球的均匀分布是 sub-Gaussian 的**] 设 $\boldsymbol{Y} \sim U(\mathbb{B}_2^n)$。证明：$\boldsymbol{Y}$ 为 sub-Gaussian 随机向量，满足定理 T3.4.5 (球面的均匀分布是 sub-Gaussian 的) 的结论 (即其所有一维边缘分布均为 sub-Gaussian 随机变量，sub-Gaussian 范数满足特定阶数)。

证明 **解法一**

根据习题 Q3.24 (单位球均匀分布的极分解)，进行极分解 $\boldsymbol{Y} = R\boldsymbol{X}$，其中 $\boldsymbol{X} = \bar{\boldsymbol{Y}} \sim U(\mathbb{S}^{n-1})$，$R = \|\boldsymbol{Y}\|_2 \in [0,1]$，则对于任意的 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，

$$|\langle \boldsymbol{Y}, \boldsymbol{v}\rangle| = R|\langle \boldsymbol{X}, \boldsymbol{v}\rangle| \leqslant |\langle \boldsymbol{X}, \boldsymbol{v}\rangle|,$$

因此

$$\mathrm{P}\{\langle \boldsymbol{Y}, \boldsymbol{v}\rangle \geqslant t\} \leqslant \mathrm{P}\{\langle \boldsymbol{X}, \boldsymbol{v}\rangle \geqslant t\} \leqslant 2\exp\left(-\frac{t^2 n}{2}\right),$$

从而 $\langle \boldsymbol{Y}, \boldsymbol{v}\rangle$ 为 sub-Gaussian 随机变量，满足

$$\mathrm{P}\{|\langle \boldsymbol{Y}, \boldsymbol{v}\rangle| \geqslant t\} \leqslant 4\exp\left(-\frac{t^2 n}{2}\right) \implies |\langle \boldsymbol{Y}, \boldsymbol{v}\rangle|_{\psi_2} \leqslant C_0\sqrt{\frac{2}{n}} = \frac{C_1}{\sqrt{n}}, \qquad (C_0, C_1 > 0)$$

从而根据 sub-Gaussian 随机向量范数的定义 (D3.4.1 (sub-Gaussian 随机向量)) $\|\boldsymbol{Y}\|_{\psi_2} = \sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \|\langle \boldsymbol{Y}, \boldsymbol{v}\rangle\|_{\psi_2}$，可得

$$\|\boldsymbol{Y}\|_{\psi_2} \leqslant \frac{C}{\sqrt{n}}。 \qquad (C > 0)$$

解法二

(证明方法与习题 Q3.42 (单位球的均匀分布是 sub-Gaussian 的) 相同。)

根据 $\boldsymbol{Y} \sim U(\mathbb{B}_2^n)$ 的旋转不变性，可得对于任意的 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，$\langle \boldsymbol{Y}, \boldsymbol{v}\rangle \overset{d}{=} \langle \boldsymbol{Y}, \boldsymbol{e}_1\rangle = Y_1$。

(之后只需考虑 Y_1 的 sub-Gaussian 性质。)

- 计算 $f_{Y_1}(x)$

  利用习题 Q3.27 (球面, 球体的一维边缘分布) (1) 的结论，可得

  $$f_{Y_1}(x) = \frac{1}{C_n}(1-x^2)^{\frac{n-1}{2}}\mathbf{1}_{[-1,1]},$$

  其中归一化常数 C_n 为

  $$C_n = \int_{-1}^{1}(1-x^2)^{\frac{n-1}{2}}\mathrm{d}x = \beta\left(\frac{1}{2}, \frac{n+1}{2}\right) = \frac{\sqrt{\pi}\Gamma((n+1)/2)}{\Gamma(n/2+1)} \asymp \frac{1}{\sqrt{n}},$$

  表达式的上界为

  $$(1-x^2)^{\frac{n-1}{2}} \leqslant (\mathrm{e}^{-x^2})^{\frac{n-1}{2}} = \mathrm{e}^{-\frac{n-1}{2}x^2},$$

  将其代入，可得

  $$f_{Y_1}(x) \leqslant c_1\sqrt{n}\mathrm{e}^{-\frac{n-1}{2}x^2}, \qquad (c_1 > 0)$$

- 计算 $\mathrm{P}\{|Y_1| \geqslant t\}$

  对于任意的 $t \in (0, 1]$，

  $$\mathrm{P}\{|Y_1| \geqslant t\} = 2\int_t^1 f_{Y_1}(x)\mathrm{d}x \leqslant 2c_1\sqrt{n}\int_t^\infty \mathrm{e}^{-\frac{n-1}{2}x^2}\mathrm{d}x。$$

  即为 $N(0, \sigma^2)$ 的尾部积分，其中 $\sigma^2 = 1/(n-1)$，利用 Mill's Ratio，可得

  $$\int_t^\infty \mathrm{e}^{-x^2/2\sigma^2}\mathrm{d}x \leqslant \frac{\sigma^2}{t}\mathrm{e}^{-t^2/2\sigma^2},$$

  因此

  $$\mathrm{P}\{|Y_1| \geqslant t\} \leqslant 2c_1\sqrt{n}\cdot\frac{1}{(n-1)t}\mathrm{e}^{-\frac{n-1}{2}t^2} = \frac{2c_1\sqrt{n}}{(n-1)t}\mathrm{e}^{-\frac{n-1}{2}t^2}。$$

  (注意到分母含有 t，当 t 很小时，上述系数趋向于无穷大，因此需要分段讨论。)

  a. 当 $t \geqslant 1/\sqrt{n}$ 时，

  $$\frac{\sqrt{n}}{(n-1)t} \leqslant \frac{n}{(n-1)} \leqslant 2, \qquad (n \geqslant 2)$$

  因此

  $$\mathrm{P}\{|Y_1| \geqslant t\} \leqslant 2\mathrm{e}^{-c_2 n t^2}。$$

  b. 当 $t < 1/\sqrt{n}$ 时，$\mathrm{e}^{-c_2 n t^2} \geqslant 1$，此时

  $$\mathrm{P}\{|Y_1| \geqslant t\} \leqslant 1 \leqslant 2\mathrm{e}^{-c_2 n t^2},$$

  结论是平凡的。

如此，

$$\mathrm{P}\{|Y_1|\geqslant t\}\leqslant 2\mathrm{e}^{-c_2nt^2}。$$

从而根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (i) (若 $\mathrm{P}\{|Y_1|\geqslant t\}\leqslant 2\mathrm{e}^{-t^2/K^2}$，则 $\|Y_1\|_{\psi_2}\leqslant C'K$)，令 $1/K^2=c_2n$，可得

$$\|Y_1\|_{\psi_2}\leqslant\frac{C}{\sqrt{n}},$$

上述估计估计对于任意的投影方向均成立，从而

$$\|\boldsymbol{Y}\|_{\psi_2}\leqslant\frac{C}{\sqrt{n}}。$$

注释 根据习题 Q3.25 (Euclidean 球分布的各向同性)，可得 $\boldsymbol{Y}\sim U(\mathbb{B}_2^n)$ 不是各向同性的，其协方差矩阵为

$$\boldsymbol{\Sigma}=\frac{1}{n+2}\boldsymbol{I}_n,$$

进行修正 $\tilde{\boldsymbol{Y}}=\sqrt{n+2}\boldsymbol{Y}$，则 $\tilde{\boldsymbol{Y}}$ 是各向同性的，可得

$$\|\tilde{\boldsymbol{Y}}\|_{\psi_2}=\sqrt{n+2}\|\boldsymbol{Y}\|_{\psi_2}\leqslant\sqrt{n+2}\cdot\frac{C}{\sqrt{n}}=C\cdot O(1)。$$

43 [**标准基分布的 sub-Gaussian 范数**] 设 $\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n$ 为 $\mathbb{R}^n$ $(n\geqslant 2)$ 的标准正交基，$\boldsymbol{X}\sim U\{\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n\}$。证明：

$$\|\boldsymbol{X}\|_{\psi_2}\asymp\frac{1}{\sqrt{\ln n}}。$$

证明 设 $\boldsymbol{v}=(v_1,v_2,\cdots,v_n)^\top\in\mathbb{S}^{n-1}$ 满足 $\sum_{k=1}^n v_k^2=1$，$Y_{\boldsymbol{v}}=\langle\boldsymbol{X},\boldsymbol{v}\rangle\sim U\{v_1,\cdots,v_n\}$ 为 $\boldsymbol{v}$ 方向投影，是 sub-Gaussian 随机变量，则根据 sub-Gaussian 随机向量范数的定义 (D3.4.1 (sub-Gaussian 随机向量))，可得

$$\|\boldsymbol{X}\|_{\psi_2}=\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}}\|Y_{\boldsymbol{v}}\|_{\psi_2}。$$

其中 $\|Y_{\boldsymbol{v}}\|_{\psi_2}$ 为使得下式成立的最小正数 t 的阶数，

$$G(\boldsymbol{v},t)=\mathrm{E}\left[\exp\left(\frac{Y_{\boldsymbol{v}}^2}{t^2}\right)\right]=\frac{1}{n}\sum_{k=1}^n\exp\left(\frac{v_k^2}{t^2}\right)\leqslant 2。$$

令 $u_i=v_i^2$ 满足 $\sum_{i=1}^n u_i=1$，$u_i\geqslant 0$，构造

$$\phi(u)=\exp\left(\frac{u_i}{t^2}\right),\ \Phi(u_1,\cdots,u_n)=\sum_{i=1}^n\phi(u_i)=\sum_{i=1}^n\exp\left(\frac{u_i}{t^2}\right),\qquad(t>0)$$

则 $\phi(u)$ 于 $u\geqslant 0$ 为严格凸函数，其最大值于极值点取得 (概率单纯形的极值点为 $\boldsymbol{u}\in\{\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n\}$)，因此当 $\boldsymbol{v}$ 为标准基向量时 (不妨设为 $\boldsymbol{e}_1$)，$\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}}G(\boldsymbol{v},t)$ 取得最大值，此时

$$\begin{aligned}G(\boldsymbol{e}_1,t)=2&\implies\frac{1}{n}\left(\exp\left(\frac{1}{t^2}\right)+(n-1)\exp(0)\right)=2\\&\implies t=\frac{1}{\sqrt{\ln(n+1)}},\end{aligned}$$

从而

$$\|\boldsymbol{X}\|_{\psi_2}=\frac{1}{\sqrt{\ln(n+1)}}\asymp\frac{1}{\sqrt{\ln n}}。$$

44 [ℓ^1 **球的 sub-Gaussian 性质分析**] 考虑 $\mathbb{R}^n$ 的 n 维 ℓ^1 正轴体

$$K=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_1\leqslant r\},$$

设 $\boldsymbol{X}\sim U(K)$。

(1) 试求 $f_{X_1}(x)$。

(2) 证明：存在 $r\asymp n$，使得 $\boldsymbol{X}$ 是各向同性的。

(3) 对于 (2) 的选择的 r，证明：$\|\boldsymbol{X}\|_{\psi_2} \asymp \sqrt{n}$。

解答 (1) 容易知道，

$$V_n(r) = V(K) = \frac{2^n r^n}{n!},$$

因此

$$\begin{aligned} f_{X_1}(x) &= \int \cdots \int_{\sum_{i=2}^n |x_i| \leqslant r-|x|} \frac{1}{V_n(r)} \mathrm{d}x_2 \cdots \mathrm{d}x_n \\ &= \frac{V_{n-1}(r-|x|)}{V_n(r)} = \frac{2^{n-1}(r-|x|)^{n-1}}{(n-1)!} \Big/ \frac{2^n r^n}{n!} \\ &= \frac{n}{2r}\left(1 - \frac{|x|}{r}\right)^{n-1}。 \end{aligned}$$

(2) 由于 K 关于坐标轴是对称的，因此 $\mathrm{E}[\boldsymbol{X}] = \boldsymbol{0}$，$\mathrm{Cov}(\boldsymbol{X})$ 为对角矩阵。

(之后只需证明 $\mathrm{E}[X_1^2] = 1$。)

容易知道，

$$\begin{aligned} \mathrm{E}[X_1^2] &= \int_{-r}^{r} x^2 \frac{n}{2r}\left(1 - \frac{|x|}{r}\right)^{n-1} \mathrm{d}x = \frac{n}{r}\int_0^r x^2 \left(1 - \frac{x}{r}\right)^{n-1} \mathrm{d}x \\ &= nr^2 \int_0^1 u^2 (1-u)^{n-1} \mathrm{d}u \qquad \left(u = \frac{x}{r}\right) \\ &= nr^2 \frac{\Gamma(3)\Gamma(n)}{\Gamma(n+3)} = nr^2 \frac{2 \cdot (n-1)!}{(n+2)!} = \frac{2r^2}{(n+1)(n+2)}, \end{aligned}$$

令 $\mathrm{E}[X_1^2] = 1$，

$$\frac{2r^2}{(n+1)(n+2)} = 1 \implies r \asymp n。$$

(3) 根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (2) (矩刻画)，可得

$$\|\boldsymbol{X}\|_{\psi_2} \geqslant \|X_1\|_{\psi_2} \asymp \sup_{p \geqslant 1} \frac{(\mathrm{E}|X_1|^p)^{1/p}}{\sqrt{p}},$$

之后只需估计 $\mathrm{E}[|X_1|^p]$。

容易知道，

$$\mathrm{E}[|X_1|^p] = 2\int_0^r x^p \frac{n}{2r}\left(1 - \frac{x}{r}\right)^{n-1} \mathrm{d}x = nr^p \beta(p+1, n) = \frac{nr^p \Gamma(p+1)\Gamma(n)}{\Gamma(n+p+1)},$$

令 $p = n$，利用 Stirling 公式，可得

$$\begin{aligned} \mathrm{E}[|X_1|^n] &= \frac{nr^n n!(n-1)!}{(2n)!} = \frac{r^n (n!)^2}{(2n)!} \\ &\asymp \frac{r^n (2\pi n)(n/\mathrm{e})^{2n}}{\sqrt{4\pi n}(2n/\mathrm{e})^{2n}} \asymp \sqrt{n}\left(\frac{r}{4}\right)^n, \end{aligned}$$

因此

$$\|X_1\|_n = (\mathrm{E}|X_1|^n)^{1/n} \asymp (\sqrt{n})^{1/n} \frac{r}{4} \asymp r,$$

利用 (2) 的结论，令 $r \asymp n$，可得

$$\|X_1\|_{\psi_2} \geqslant C\frac{\|X_1\|_n}{\sqrt{n}} \asymp \frac{n}{\sqrt{n}} = \sqrt{n}。$$

45 [**sub-Gaussian 随机向量的概率质量函数界限**] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 K-sub-Gaussian 随机向量。证明：对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\mathrm{P}\{\boldsymbol{X}=\boldsymbol{x}\}\leqslant 2\exp\left(-\frac{\|\boldsymbol{x}\|_2^2}{K^2}\right)。$$

证明 若 $\boldsymbol{x}=\boldsymbol{0}$，则不等式右侧为 $2\exp(0)=2$，左侧为 $\mathrm{P}\{\boldsymbol{X}=\boldsymbol{0}\}\leqslant 1$，结论是平凡的；之后只需考虑 $\boldsymbol{x}\neq\boldsymbol{0}$ 的情况。

当给定 $\boldsymbol{X}=\boldsymbol{x}$ 时，

$$\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle=\langle\boldsymbol{x},\bar{\boldsymbol{x}}\rangle=\left\langle\boldsymbol{x},\frac{\boldsymbol{x}}{\|\boldsymbol{x}\|_2}\right\rangle=\frac{\|\boldsymbol{x}\|_2^2}{\|\boldsymbol{x}\|_2}=\|\boldsymbol{x}\|_2,$$

因此 $\{\boldsymbol{X}=\boldsymbol{x}\}\subset\{\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle=\|\boldsymbol{x}\|_2\}$，从而

$$\mathrm{P}\{\boldsymbol{X}=\boldsymbol{x}\}\leqslant\mathrm{P}\{\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle=\|\boldsymbol{x}\|_2\}\leqslant\mathrm{P}\{|\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle|\geqslant\|\boldsymbol{x}\|_2\}。$$

设 $Y_{\bar{\boldsymbol{x}}}=\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle$，则根据 sub-Gaussian 随机向量范数的定义 (D3.4.1 (sub-Gaussian 随机向量))，可得

$$\|Y_{\bar{\boldsymbol{x}}}\|_{\psi_2}\leqslant\|\boldsymbol{X}\|_{\psi_2}\leqslant K\implies\mathrm{P}\{|Y_{\bar{\boldsymbol{x}}}|\geqslant t\}\leqslant 2\exp\left(-\frac{t^2}{\|Y_{\bar{\boldsymbol{x}}}\|_{\psi_2}^2}\right),$$

因此

$$\mathrm{P}\{|\langle\boldsymbol{X},\bar{\boldsymbol{x}}\rangle|\geqslant\|\boldsymbol{x}\|_2\}\leqslant 2\exp\left(-\frac{\|\boldsymbol{x}\|_2^2}{\|Y_{\bar{\boldsymbol{x}}}\|_{\psi_2}^2}\right)\leqslant 2\exp\left(-\frac{\|\boldsymbol{x}\|_2^2}{K^2}\right),$$

即

$$\mathrm{P}\{\boldsymbol{X}=\boldsymbol{x}\}\leqslant 2\exp\left(-\frac{\|\boldsymbol{x}\|_2^2}{K^2}\right)。$$

46 [**各向同性 sub-Gaussian 分布的高熵性**] 设离散随机向量 $\boldsymbol{X}$ 以概率 p_i 取值为 $\boldsymbol{x}_i$，定义其熵为

$$H(\boldsymbol{X})=-\sum_i p_i\ln p_i,$$

直观而言，$H(\boldsymbol{X})$ 与对 $\boldsymbol{X}$ 进行编码所需的二进制位数成正比。

(1) (极散分布的低熵性) 证明：对于任意的含有 N 个可能取值的随机向量 $\boldsymbol{X}$ (即 $|\mathrm{supp}(\boldsymbol{X})|=N$)，均满足 $H(\boldsymbol{X})\leqslant\ln N$。

(2) (各向同性 sub-Gaussian 分布的高熵性) 若 $\boldsymbol{X}\in\mathbb{R}^n$ 为离散, 各向同性, K-sub-Gaussian 的随机向量，证明：

$$H(\boldsymbol{X})\geqslant\frac{n}{K^2}-\ln 2。$$

(3) (各向同性 sub-Gaussian 分布的巨大 supp) 证明：满足条件 (2) 的随机向量 $\boldsymbol{X}$ 至少含有 $\mathrm{e}^{K^{-2}n}/2$ 个可能取值。

证明 (1) 设 $\mathrm{supp}(P)=\{p_1,\cdots,p_N\}$，构造凸函数 $g(x)=\ln x$，则利用 Jensen 不等式，可得

$$H(\boldsymbol{X})=\sum_{i=1}^N p_i\ln\frac{1}{p_i}\leqslant\ln\left(\sum_{i=1}^N p_i\cdot\frac{1}{p_i}\right)=\ln\left(\sum_{i=1}^N 1\right)=\ln N,$$

当且仅当 $p_i=1/N$ (均匀分布) 时取等。

(2) 由于 $\boldsymbol{X}$ 是各向同性的，因此

$$\mathrm{E}[\|\boldsymbol{X}\|_2^2]=\mathrm{E}[\mathrm{tr}(\boldsymbol{X}\boldsymbol{X}^\top)]=\mathrm{tr}(\boldsymbol{I}_n)=n。$$

根据习题 Q3.45 (sub-Gaussian 随机向量的概率质量函数界限)，可得

$$p_i=\mathrm{P}\{\boldsymbol{X}=\boldsymbol{x}_i\}\leqslant 2\mathrm{e}^{-\|\boldsymbol{x}_i\|_2^2/K^2},$$

两侧取对数，

$$\ln p_i\leqslant\ln 2-\frac{\|\boldsymbol{x}_i\|_2^2}{K^2},$$

因此

$$H(\boldsymbol{X})=\sum_i p_i(-\ln p_i)=\mathrm{E}[-\ln p_{\boldsymbol{X}}]$$

$$\geqslant \mathrm{E}\left[\frac{\|\boldsymbol{X}\|_2^2}{K^2} - \ln 2\right] = \frac{1}{K^2}\mathrm{E}\|\boldsymbol{X}\|_2^2 - \ln 2 = \frac{n}{K^2} - \ln 2。$$

(3) 利用 (1)(2) 的结论，可得

$$\ln N \geqslant H(\boldsymbol{X}) \geqslant \frac{n}{K^2} - \ln 2,$$

两侧取指数，

$$N \geqslant \mathrm{e}^{n/K^2} \cdot \mathrm{e}^{-\ln 2} = \frac{1}{2}\mathrm{e}^{n/K^2} = \frac{1}{2}\exp(K^{-2}n)。$$

47 [**重写 Grothendieck 不等式的假设条件**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$。证明：以下四个性质是等价的：

(1) 对于任意的 $\boldsymbol{x} \in \{-1,1\}^m, \boldsymbol{y} \in \{-1,1\}^n$，均满足 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1$。

(2) 对于任意的 $\boldsymbol{x} \in [-1,1]^m, \boldsymbol{y} \in [-1,1]^n$，均满足 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1$。

(3) 对于任意的 $\boldsymbol{x} \in \mathbb{R}^m, \boldsymbol{y} \in \mathbb{R}^n$，均满足 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant \|\boldsymbol{x}\|_\infty \|\boldsymbol{y}\|_\infty$。

(4) 将上述任意的性质的 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}$ 替换为其绝对值 $|\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}|$ 之后，上述性质仍然成立。

证明 (首先证明 (1) $\iff$ (2) $\iff$ (3)。)

对于 (3) $\iff$ (2)，若 $\boldsymbol{x} \in [-1,1]^m$，$\boldsymbol{y} \in [-1,1]^n$，则 $\|\boldsymbol{x}\|_\infty, \|\boldsymbol{y}\|_\infty \leqslant 1$，因此 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1 \cdot 1 = 1$。

对于 (2) $\iff$ (3)，若 $\boldsymbol{x} = \boldsymbol{0}$ 或 $\boldsymbol{y} = \boldsymbol{0}$，则结论是平凡的；之后只需考虑 $\boldsymbol{x}, \boldsymbol{y} \neq \boldsymbol{0}$ 的情况。

令 $\boldsymbol{x}' = \boldsymbol{x}/\|\boldsymbol{x}\|_\infty \in [-1,1]^m$，$\boldsymbol{y}' = \boldsymbol{y}/\|\boldsymbol{y}\|_\infty \in [-1,1]^n$，则

$$(\boldsymbol{x}')^\top \boldsymbol{A}\boldsymbol{y}' \leqslant 1 \implies \frac{\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}}{\|\boldsymbol{x}\|_\infty \|\boldsymbol{y}\|_\infty} \leqslant 1$$
$$\implies \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant \|\boldsymbol{x}\|_\infty \|\boldsymbol{y}\|_\infty。$$

对于 (2) $\iff$ (1)，由于 $\{-1,1\}^m \subset [-1,1]^m$，$\{-1,1\}^n \subset [-1,1]^n$，结论是平凡的。

对于 (1) $\iff$ (2)，设 $f(\boldsymbol{x},\boldsymbol{y}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}$，线性函数于凸紧集 ($[-1,1]^m$) 的最大值于其极值点 ($\{-1,1\}^m$) 取得，因此

$$\max_{\boldsymbol{x}\in[-1,1]^m} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} = \max_{\boldsymbol{x}\in\{-1,1\}^m} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1, \quad \max_{\boldsymbol{y}\in[-1,1]^n} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} = \max_{\boldsymbol{y}\in\{-1,1\}^n} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1,$$

从而 $f(\boldsymbol{x},\boldsymbol{y}) \leqslant 1$。

(之后证明 (1)(2)(3) $\iff$ (4)。)

我们只需证明 (1) $\iff$ (1′)，其中 (1') 为 $|\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| \leqslant 1$。

对于 (1′) $\implies$ (1)，结论是平凡的。

对于 (1) $\implies$ (1′)，若 $\boldsymbol{x} \in \{-1,1\}^m$，因此 $-\boldsymbol{x} \in \{-1,1\}^m$，从而

$$(-\boldsymbol{x})^\top \boldsymbol{A}\boldsymbol{y} \leqslant 1 \implies \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} \geqslant -1,$$

即 $|\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| \leqslant 1$。

48 [**Grothendieck 不等式概率证明的精细化**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，满足对于任意的 $x_i, y_j \in \{-1,1\}$，$\left|\sum_{i,j} a_{ij}x_i y_j\right| \leqslant 1$。定理 T3.5.1 (Grothendieck 不等式) 指出，对于任意的单位向量 $\boldsymbol{u}_i, \boldsymbol{v}_j \in \mathcal{H}$，

$$\left|\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant K_G。 \qquad (K_G > 0)$$

于正文的初步概率证明，利用了粗略的上界 $4/R^2$ 以处理 Taylor 级数残项。试通过保留级数的精确形式，对缩放参数 R 进行数值优化，证明可以得到更紧的界 $K_G \leqslant 14.1$。

证明 • 引入概率构造与 Grothendieck 恒等式

设 $\mathcal{H} = \mathbb{R}^d$，$\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_d)$，定义

$$X_i = \operatorname{sgn}(\langle \boldsymbol{u}_i, \boldsymbol{g}\rangle), \quad Y_j = \operatorname{sgn}(\langle \boldsymbol{v}_j, \boldsymbol{g}\rangle),$$

则利用 Grothendieck 恒等式 (Q3.53 (Grothendieck 恒等式))，可得对于任意的单位向量 $\boldsymbol{u}, \boldsymbol{v}$，

$$\mathrm{E}[X_i Y_j] = \frac{2}{\pi}\arcsin(\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle)。$$

令 $\rho_{ij}=\langle \boldsymbol{u}_i,\boldsymbol{v}_j\rangle$，注意到 $X_i,Y_j\in\{-1,1\}$，因此

$$\left|\sum_{i,j}a_{ij}\mathrm{E}[X_iY_j]\right|=\left|\mathrm{E}\left[\sum_{i,j}a_{ij}X_iY_j\right]\right|\leqslant \mathrm{E}\left|\sum_{i,j}a_{ij}X_iY_j\right|\leqslant 1,$$

从而

$$\left|\sum_{i,j}a_{ij}\frac{2}{\pi}\arcsin(\rho_{ij})\right|\leqslant 1。$$

引入缩放参数 $R>1$，令与 $\mathcal{H}$ 正交的 $\{\boldsymbol{e}_i\}_{i=1}^m,\{\boldsymbol{f}_j\}_{j=1}^n$ 为相互正交的正交系，之后令

$$\boldsymbol{u}_i'=R^{-1}\boldsymbol{u}_i+\sqrt{1-R^{-2}}\,\boldsymbol{e}_i,\qquad \boldsymbol{v}_j'=R^{-1}\boldsymbol{v}_j+\sqrt{1-R^{-2}}\,\boldsymbol{f}_j.$$

则 $\boldsymbol{u}_i',\boldsymbol{v}_j'$ 为单位向量，满足 $\langle \boldsymbol{u}_i',\boldsymbol{v}_j'\rangle=\rho_{ij}/R^2$。

再次使用上述随机符号构造，可得

$$\left|\sum_{i,j}a_{ij}\frac{2}{\pi}\arcsin\left(\frac{\rho_{ij}}{R^2}\right)\right|\leqslant 1,$$

其中

$$\frac{2}{\pi}\arcsin(z)=\frac{2}{\pi}z+\frac{2}{\pi}\sum_{k=1}^{\infty}c_{2k+1}z^{2k+1},\qquad \left(c_{2k+1}=\frac{(2k)!}{4^k(k!)^2(2k+1)}\right)$$

因此

$$\left|\frac{2}{\pi R^2}\sum_{i,j}a_{ij}\rho_{ij}+\sum_{k=1}^{\infty}\frac{2c_{2k+1}}{\pi R^{2(2k+1)}}\sum_{i,j}a_{ij}\rho_{ij}^{2k+1}\right|\leqslant 1。$$

- 利用张量积的内积性质界定高阶项

注意到

$$\rho_{ij}^{2k+1}=\langle \boldsymbol{u}_i,\boldsymbol{v}_{ij}\rangle^{2k+1}=\langle \boldsymbol{u}_i^{\otimes(2k+1)},\boldsymbol{v}_j^{\otimes(2k+1)}\rangle,$$

其中 $\boldsymbol{u}_i^{\otimes(2k+1)},\boldsymbol{v}_j^{\otimes(2k+1)}$ 仍然为某个高维 Hilbert 空间的单位向量，因此当 K_G 为最佳系数时，

$$\left|\sum_{i,j}a_{ij}\rho_{ij}^{2k+1}\right|\leqslant K_G,$$

从而利用三角不等式，可得

$$\underbrace{\frac{2}{\pi R^2}\left|\sum_{i,j}a_{ij}\rho_{ij}\right|}_{\leqslant K_G\cdot\frac{2}{\pi R^2}}\leqslant 1+K_G\cdot\sum_{k=1}^{\infty}\frac{2c_{2k+1}}{\pi R^{2(2k+1)}}。$$

定义右侧的级数剩余项为 $S(R)=\sum_{k=1}^{\infty}c_{2k+1}(R^{-2})^{2k}$，注意到 $\arcsin(z)-z=\sum_{k=1}^{\infty}c_{2k+1}z^{2k+1}$，因此

$$S(R)=R^2\big(\arcsin(R^{-2})-R^{-2}\big)=R^2\arcsin(R^{-2})-1,$$

从而

$$\begin{aligned}K_G\frac{2}{\pi R^2}\leqslant 1+K_G\cdot\frac{2}{\pi R^2}S(R)\ &\Longrightarrow\ K_G\leqslant\frac{\pi R^2}{2(1-S(R))}=\frac{\pi R^2}{2(2-R^2\arcsin(R^{-2}))}\\ &\Longrightarrow\ K_G\leqslant\underbrace{\frac{\pi}{4z-2\arcsin z}}_{h(z)},\qquad (z=R^{-2}\in(0,1))\end{aligned}$$

其中

$$\min_{z\in(0,1)}h(z)=h\left(\frac{\sqrt{3}}{2}\right)\approx 2.29,$$

从而 $K_G \leqslant 2.29$，远优于题目要求的上界 14.1。

注释 事实上，我们无需对原向量 $\boldsymbol{u}_i$ 直接投影，可以先通过非线性算子将向量“预处理”为新向量 $\tilde{\boldsymbol{u}}_i$，之后进行随机投影，最终得到最优上界 $K_G = \pi/(2\ln(1+\sqrt{2})) \approx 1.783$。

49 [**半正定矩阵的二次 Grothendieck 不等式**] 本题, 下一题通过假设 $x_i = y_i$ 来放宽 Grothendieck 不等式的假设条件，如注记 R3.5.3 (二次 Grothendieck：$x_i = y_i$) 所述。

(1) (极化恒等式) 设 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$，记 $\bar{\boldsymbol{x}} = (\boldsymbol{x}+\boldsymbol{y})/2$，$\bar{\boldsymbol{y}} = (\boldsymbol{x}-\boldsymbol{y})/2$。证明：对于任意的对称矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，

$$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} = \bar{\boldsymbol{x}}^\top \boldsymbol{A}\bar{\boldsymbol{x}} - \bar{\boldsymbol{y}}^\top \boldsymbol{A}\bar{\boldsymbol{y}}。$$

(2) (二次 Grothendieck 不等式) 设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称半正定矩阵，满足对于任意的 $x_i \in \{-1,1\}$，$\sum_{i,j} a_{ij}x_i x_j \leqslant 1$。证明：对于任意的单位向量 $\boldsymbol{u}_i, \boldsymbol{v}_j \in \mathcal{H}$，

$$\left|\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant 2K_G,$$

其中 $K_G \leqslant 1.783$ 为 Grothendieck 常数。

(3) 证明：若忽略半正定假设，(2) 可能失效 (即左侧可能无法由常数控制)。

证明 (1) 由于 $\boldsymbol{A}$ 为对称矩阵，因此

$$\begin{aligned}
\bar{\boldsymbol{x}}^\top \boldsymbol{A}\bar{\boldsymbol{x}} &= \left(\frac{\boldsymbol{x}+\boldsymbol{y}}{2}\right)^\top \boldsymbol{A}\left(\frac{\boldsymbol{x}+\boldsymbol{y}}{2}\right) \\
&= \frac{1}{4}(\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} + \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} + \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x} + \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{y}) \\
&= \frac{1}{4}(\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} + \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{y} + 2\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}), \\
\bar{\boldsymbol{y}}^\top \boldsymbol{A}\bar{\boldsymbol{y}} &= \frac{1}{4}(\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} + \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{y} - 2\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}),
\end{aligned}$$

从而

$$\bar{\boldsymbol{x}}^\top \boldsymbol{A}\bar{\boldsymbol{x}} - \bar{\boldsymbol{y}}^\top \boldsymbol{A}\bar{\boldsymbol{y}} = \frac{1}{4}(4\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}。$$

(2) 构造凸函数 $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$，满足当 $\boldsymbol{x} \in \{-1,1\}^n$ 时，$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} \leqslant 1$，则根据凸函数的极值性质 (凸函数于紧凸集 $[-1,1]^n$ 的最大值于其极值点 $\{-1,1\}^n$ 取得，见 Q3.50 (无对角元矩阵的二次 Grothendieck 不等式) 的 (1)(ii))，可得当 $\boldsymbol{z} \in [-1,1]^n$ 时，$\boldsymbol{z}^\top \boldsymbol{A}\boldsymbol{z} \leqslant 1$。

设 $\boldsymbol{x}, \boldsymbol{y} \in \{-1,1\}^n$，则利用 (1) 的结论，可得

$$|\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| = |\bar{\boldsymbol{x}}^\top \boldsymbol{A}\bar{\boldsymbol{x}} - \bar{\boldsymbol{y}}^\top \boldsymbol{A}\bar{\boldsymbol{y}}| \leqslant |\bar{\boldsymbol{x}}^\top \boldsymbol{A}\bar{\boldsymbol{x}}| + |\bar{\boldsymbol{y}}^\top \boldsymbol{A}\bar{\boldsymbol{y}}|,$$

其中 $\bar{\boldsymbol{x}}, \bar{\boldsymbol{y}} \in [-1,1]^n$，因此

$$|\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| \leqslant 1+1 = 2,$$

从而根据习题 Q3.27 (球面, 球体的一维边缘分布)，利用定理 T3.5.1 (Grothendieck 不等式) (Grothendieck 不等式)，可得对于任意的单位向量 $\boldsymbol{u}_i, \boldsymbol{v}_j \in \mathcal{H}$，

$$\left|\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant K_G \cdot \max_{\boldsymbol{x},\boldsymbol{y}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| \leqslant 2K_G。$$

(3) 若 $\boldsymbol{A}$ 不满足半正定性，则 $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ 未必为凸函数。

构造以下反例：令

$$\boldsymbol{A} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix},$$

则对于 $x_i \in \{-1,1\}$，$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} = x_1^2 - x_2^2 = 1-1 = 0 \leqslant 1$。

令顶点 $\boldsymbol{x} = (1,1)^\top, \boldsymbol{y} = (1,-1)^\top$，则 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} = (1)(1) + (1)(-1)(-1) = 1+1 = 2$，此时二次型, 双线性型之间不存在

固定的常数比例关系。

(同理，对于高维情况，构造 $\boldsymbol{A}$ 的所有对角元为 $a_{ii}=1$，之后对非对角元进行配凑，使得二次型恒为 0，但是双线性型随 n 增长。)

50 [无对角元矩阵的二次 Grothendieck 不等式]

(1) (逐分量凸性) 若 $f(x_1,\cdots,x_n)$ 对于任意的变量 x_i 均是凸的 (当固定其他变量时，f 为关于 x_i 的凸函数)，则称其为逐分量凸函数。

i. 给出一个逐分量凸但整体非凸的函数示例。

ii. 证明：定义于超立方体 $[-1,1]^n$ 的逐分量凸函数 f 必定于其顶点集 $\{-1,1\}^n$ 取得最大值。

(2) (无对角元二次 Grothendieck 不等式) 设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 为对称的无对角元实矩阵 (即 $\boldsymbol{A}=\boldsymbol{A}^\top$，$a_{ii}=0$)。证明：若对于任意的 $x_i\in\{-1,1\}$，均满足 $\left|\sum_{i,j}a_{ij}x_ix_j\right|\leqslant 1$，则对于任意的 $\boldsymbol{u}_i,\boldsymbol{v}_j\in\mathcal{H}\cap\mathbb{S}^{n-1}$，

$$\left|\sum_{i,j}a_{ij}\langle\boldsymbol{u}_i,\boldsymbol{v}_j\rangle\right|\leqslant 2K_G。$$

证明 (1) • 示例

构造逐分量凸函数 $f(x,y)=xy$，其 Hessian 矩阵为

$$\boldsymbol{H}=\begin{pmatrix}0&1\\1&0\end{pmatrix},$$

特征值为 $1,-1$ (既非正定也非负定，即为鞍点)，因此 f 是整体非凸的。

• 顶点取得最大值的证明

利用数学归纳法：

a. 当 $n=1$ 时，$f(x)$ 为 $[-1,1]$ 的凸函数，其最大值必定于 $\{-1,1\}$ 取得。

b. 假设上述结论对于 $n-1$ 维成立，则对于 n 维，固定前 $n-1$ 个变量 $(x_1,\cdots,x_{n-1})$，此时 $g(x_n)=f(x_1,\cdots,x_n)$ 为关于 x_n 的凸函数，其最大值于 $x_n\in\{-1,1\}$ 取得，因此

$$\max_{\boldsymbol{x}\in[-1,1]^n}f(\boldsymbol{x})=\max_{x_1,\cdots,x_{n-1}\in[-1,1]}\left(\max_{x_n\in\{-1,1\}}f(x_1,\cdots,x_n)\right),$$

对剩余的 $n-1$ 个变量重复上述过程，可得

$$\max_{\boldsymbol{x}\in[-1,1]^n}f(\boldsymbol{x})=\max_{x_1\in\{-1,1\}}\left(\cdots\left(\max_{x_n\in\{-1,1\}}f(x_1,\cdots,x_n)\right)\right),$$

即 $f(x_1,\cdots,x_n)$ 的最大值于 $x_i\in\{-1,1\}$ 取得。

(2) 设 $f(\boldsymbol{z})=\boldsymbol{z}^\top\boldsymbol{A}\boldsymbol{z}=\sum_{i,j}a_{ij}z_iz_j$，满足当 $\boldsymbol{x}\in\{-1,1\}^n$ 时，$|f(\boldsymbol{x})|\leqslant 1$，即

$$\max_{\boldsymbol{z}\in[-1,1]^n}|\boldsymbol{z}^\top\boldsymbol{A}\boldsymbol{z}|\leqslant 1。$$

由于 $a_{ii}=0$，则 z_i^2 不存在于上述求和，因此

$$\frac{\partial^2 f}{\partial z_i^2}=2a_{ii}=0。$$

即 f 关于 z_i 是线性的，从而利用 (1) 的结论，可得 f 于立方体 $[-1,1]^n$ 的最值必定于顶点 $\{-1,1\}^n$ 取得。

• 首先考虑 $\boldsymbol{A}$ 为对称矩阵的情况

利用习题 Q3.49 (半正定矩阵的二次 Grothendieck 不等式) (1) 的结论，可得对于对称矩阵 $\boldsymbol{A}$，

$$\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{y}=\bar{\boldsymbol{x}}^\top\boldsymbol{A}\bar{\boldsymbol{x}}-\bar{\boldsymbol{y}}^\top\boldsymbol{A}\bar{\boldsymbol{y}},$$

其中 $\bar{\boldsymbol{x}}=(\boldsymbol{x}+\boldsymbol{y})/2,\bar{\boldsymbol{y}}=(\boldsymbol{x}-\boldsymbol{y})/2$，则当 $\boldsymbol{x},\boldsymbol{y}\in\{-1,1\}^n$ 时，$\bar{\boldsymbol{x}},\bar{\boldsymbol{y}}\in[-1,1]^n$，因此

$$|\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{y}|\leqslant|\bar{\boldsymbol{x}}^\top\boldsymbol{A}\bar{\boldsymbol{x}}|+|\bar{\boldsymbol{y}}^\top\boldsymbol{A}\bar{\boldsymbol{y}}|\leqslant 1+1=2,$$

从而利用定理 T3.5.1 (Grothendieck 不等式) (Grothendieck 不等式) 的等价形式 (Q3.47 (重写 Grothendieck 不等

式的假设条件))，可得

$$\left|\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant K_G \cdot \sup_{\boldsymbol{x},\boldsymbol{y}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}| \leqslant K_G \cdot 2 = 2K_G。$$

- 首先考虑 $\boldsymbol{A}$ 为一般矩阵的情况

  设 $\boldsymbol{B} = (\boldsymbol{A} + \boldsymbol{A}^\top)/2$，满足 $\boldsymbol{x}^\top \boldsymbol{B}\boldsymbol{x} = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$，$\boldsymbol{B}_{ii} = (a_{ii} + a_{ii})/2 = 0$，则同理于之前的证明，可得

$$\left|\sum_{i,j} b_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant K_G \cdot \sup_{\boldsymbol{x},\boldsymbol{y}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{B}\boldsymbol{y}| \leqslant K_G \cdot 2 = 2K_G,$$

  其中

$$\sum_{i,j} b_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle = \sum_{i,j} \frac{a_{ij} + a_{ji}}{2}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle,$$

  因此

$$\left|\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{v}_j\rangle\right| \leqslant 2K_G。$$

51 [**Gram 矩阵的性质, 表征**] 设 $\mathcal{H}$ 为实内积空间，对于任意的 $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_n \in \mathcal{H}$，定义其 Gram 矩阵 $\boldsymbol{G} \in \mathbb{R}^{n\times n}$ 为 $g_{ij} = \langle \boldsymbol{v}_i, \boldsymbol{v}_j\rangle$。证明：

(1) 任意向量组的 Gram 矩阵必定为对称半正定的。

(2) 反之，任意对称半正定矩阵都是某个向量组的 Gram 矩阵。

证明 ($\Longrightarrow$)。

对称性：

$$g_{ij} = \langle \boldsymbol{v}_i, \boldsymbol{v}_j\rangle = \langle \boldsymbol{v}_j, \boldsymbol{v}_i\rangle = g_{ji}。$$

半正定性：对于任意的 $\boldsymbol{c} = (c_1, \cdots, c_n)^\top \in \mathbb{R}^n$，

$$\begin{aligned}\boldsymbol{c}^\top \boldsymbol{G}\boldsymbol{c} &= \sum_{i=1}^n \sum_{j=1}^n c_i c_j g_{ij} = \sum_{i=1}^n \sum_{j=1}^n c_i c_j \langle \boldsymbol{v}_i, \boldsymbol{v}_j\rangle \\ &= \left\langle \sum_{i=1}^n c_i \boldsymbol{v}_i, \sum_{j=1}^n c_j \boldsymbol{v}_j \right\rangle = \left\| \sum_{i=1}^n c_i \boldsymbol{v}_i \right\|^2 \geqslant 0。\end{aligned}$$

($\Longleftarrow$)。

设 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$，其中 $\boldsymbol{Q}$ 为正交矩阵，$\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \cdots, \lambda_n)$ 为对角矩阵，记 $\boldsymbol{B} = \boldsymbol{Q}\boldsymbol{\Lambda}^{1/2} = (\boldsymbol{v}_1, \cdots, \boldsymbol{v}_n)$，则

$$\boldsymbol{B}\boldsymbol{B}^\top = (\boldsymbol{Q}\boldsymbol{\Lambda}^{1/2})(\boldsymbol{Q}\boldsymbol{\Lambda}^{1/2})^\top = \boldsymbol{Q}\boldsymbol{\Lambda}^{1/2}(\boldsymbol{\Lambda}^{1/2})^\top \boldsymbol{Q}^\top = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top = \boldsymbol{A},$$

满足

$$A_{ij} = \sum_{k=1}^n B_{ik} B_{jk} = \langle \boldsymbol{v}_i, \boldsymbol{v}_j\rangle,$$

因此 $\boldsymbol{A}$ 恰好为 $\{\boldsymbol{v}_1, \cdots, \boldsymbol{v}_n\} \subset \mathbb{R}^n$ 的 Gram 矩阵。

52 [**Boolean 双线性规划的半正定松弛**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，考虑以下 Boolean 双线性规划：

$$\begin{aligned}\text{maximize} \quad & \sum_{i=1}^m \sum_{j=1}^n A_{ij} x_i y_j, \\ \text{subject to} \quad & x_i, y_j \in \{-1, 1\},\end{aligned} \tag{I}$$

将上述问题松弛为以下向量形式的优化问题：

$$\text{maximize} \quad \sum_{i=1}^m \sum_{j=1}^n A_{ij}\langle \boldsymbol{X}_i, \boldsymbol{Y}_j\rangle,$$

$$\text{subject to} \quad \|\boldsymbol{X}_i\|_2 = \|\boldsymbol{Y}_j\|_2 = 1, \tag{II}$$

其最大值于某个固定维度 $k \in \mathbb{N}$ 的全体单位向量 $\boldsymbol{X}_i, \boldsymbol{Y}_j \in \mathbb{R}^k$ 取值。

(1) 将 (II) 改写为 SDP 形式。

(2) 证明：(I)(II) 在绝对常数因子的意义下是近似的。

证明 (1) 构造 Gram 矩阵 $\boldsymbol{M} \in \mathbb{R}^{(m+n)\times(m+n)}$，其元素为 $\{\boldsymbol{X}_1, \cdots, \boldsymbol{X}_m, \boldsymbol{Y}_1, \cdots, \boldsymbol{Y}_n\}$ 的内积，

$$\boldsymbol{M} = \begin{pmatrix} \langle \boldsymbol{X}_i, \boldsymbol{X}_{i'} \rangle & \langle \boldsymbol{X}_i, \boldsymbol{Y}_j \rangle \\ \langle \boldsymbol{Y}_j, \boldsymbol{X}_i \rangle & \langle \boldsymbol{Y}_j, \boldsymbol{Y}_{j'} \rangle \end{pmatrix},$$

则根据习题 Q3.51 (Gram 矩阵的性质, 表征)，可得 $\boldsymbol{M} \succcurlyeq 0$；根据单位向量的约束条件 $\|\boldsymbol{X}_i\|_2 = \|\boldsymbol{Y}_j\|_2 = 1$，可得 $M_{ii} = 1$。

定义分块矩阵 $\tilde{\boldsymbol{A}}$ 为

$$\tilde{\boldsymbol{A}} = \frac{1}{2} \begin{pmatrix} \boldsymbol{O} & \boldsymbol{A} \\ \boldsymbol{A}^\top & \boldsymbol{O} \end{pmatrix},$$

则

$$\sum_{i,j} A_{ij} \langle \boldsymbol{X}_i, \boldsymbol{Y}_j \rangle = \operatorname{tr}(\tilde{\boldsymbol{A}} \boldsymbol{M}) = \langle \tilde{\boldsymbol{A}}, \boldsymbol{M} \rangle,$$

因此 (II) 的 SDP 形式为

$$\begin{aligned} \text{maximize} \quad & \langle \tilde{\boldsymbol{A}}, \boldsymbol{M} \rangle, \\ \text{subject to} \quad & \boldsymbol{M} \succcurlyeq 0, \\ & M_{ii} = 1。 \end{aligned}$$

(2) 设 $V_{\int}$ 为原问题 (I) 的最优值，V_{SDP} 为松弛问题 (II) 的最优值。

- 下界 (平凡情况)

  注意到任意的标量 $x_i, y_j \in \{-1, 1\}$ 都可以被表达为 $\mathbb{R}^1$ 的单位向量，因此 (I) 的可行域为 (II) 的可行域的子集，从而 $V_{\int} \leqslant V_{\text{SDP}}$。

- 上界 (利用 Grothendieck 不等式)

  利用定理 T3.5.1 (Grothendieck 不等式) (Grothendieck 不等式)，可得对于任意的单位向量 $\boldsymbol{X}_i, \boldsymbol{Y}_j \in \mathcal{H}$，

  $$\left| \sum_{i,j} A_{ij} \langle \boldsymbol{X}_i, \boldsymbol{Y}_j \rangle \right| \leqslant K_G \cdot \max_{x_i, y_j \in \{-1,1\}} \left| \sum_{i,j} A_{ij} x_i y_j \right|,$$

  即 $V_{\text{SDP}} \leqslant K_G \cdot V_{\int}$。

如此，$V_{\int} \leqslant V_{\text{SDP}} \leqslant K_G \cdot V_{\int}$，即 $V_{\int} \asymp V_{\text{SDP}}$。

53 [**Grothendieck 恒等式**] 证明引理 L3.6.5 (Grothendieck 恒等式)。

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。证明：对于任意的 $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{S}^{n-1}$，

$$\mathrm{E}[\operatorname{sgn}(\langle \boldsymbol{g}, \boldsymbol{u} \rangle) \operatorname{sgn}(\langle \boldsymbol{g}, \boldsymbol{v} \rangle)] = \frac{2}{\pi} \arcsin \langle \boldsymbol{u}, \boldsymbol{v} \rangle。$$

证明 设 $X = \langle \boldsymbol{g}, \boldsymbol{u} \rangle$，$Y = \langle \boldsymbol{g}, \boldsymbol{v} \rangle$，则 $(X, Y) \sim N(0, 0, 1, 1, \rho)$，其中 $\rho = \langle \boldsymbol{u}, \boldsymbol{v} \rangle$。

(之后只需计算 $I = \mathrm{E}[\operatorname{sgn}(X)\operatorname{sgn}(Y)]$。)

容易知道，

$$\begin{aligned} 1 &= \mathrm{P}\{X, Y \text{ 同号}\} + \mathrm{P}\{X, Y \text{ 异号}\}, \\ I &= \mathrm{P}\{X, Y \text{ 同号}\} - \mathrm{P}\{X, Y \text{ 异号}\}, \end{aligned}$$

解得 $I = 2\mathrm{P}\{X, Y \text{ 同号}\} - 1$。

(之后只需计算 X, Y 同号的概率。)

$\{\operatorname{sgn}(\langle \boldsymbol{g}, \boldsymbol{u} \rangle) = 1\}, \{\operatorname{sgn}(\langle \boldsymbol{g}, \boldsymbol{v} \rangle) = 1\}$ 分别对应于两个半圆区域 (因为 $\operatorname{sgn}(\langle \boldsymbol{g}, \boldsymbol{u} \rangle)$ 的取值取决于 $\boldsymbol{g}$ 位于由 $\boldsymbol{u}$ 定义的超平面

的哪一侧)，其相交部分 (即同为正的区域) 的张角为 $\pi-\alpha$，其中 $\alpha\in[0,\pi]$ 为单位向量 $\boldsymbol{u},\boldsymbol{v}$ 之间的夹角，满足 $\rho=\cos\alpha$；同理，同为负的区域的张角为 $\pi-\alpha$，因此

$$\mathrm{P}\{X,Y\text{ 同号}\}=\frac{2(\pi-\alpha)}{2\pi}=1-\frac{\alpha}{\pi},$$

将其代入，可得

$$\begin{aligned}I&=2\left(1-\frac{\alpha}{\pi}\right)-1=1-\frac{2\alpha}{\pi}\\&=1-\frac{2}{\pi}\left(\frac{\pi}{2}-\arcsin\rho\right)=\frac{2}{\pi}\arcsin\rho,\end{aligned}\qquad(\alpha=\arccos\rho)$$

即

$$\mathrm{E}[\mathrm{sgn}(\langle\boldsymbol{g},\boldsymbol{u}\rangle)\mathrm{sgn}(\langle\boldsymbol{g},\boldsymbol{v}\rangle)]=\frac{2}{\pi}\arcsin\langle\boldsymbol{u},\boldsymbol{v}\rangle。$$

54 [**最大割的近似算法：确定性输出，随机运行时间**] 定理 T3.6.4 (最大割的 0.878-近似算法) 通过 SDP 松弛和 Rounding (随机超平面舍入) 技术，使得能够找到在期望意义下不小于最大割的 0.878 倍的割。

对于任意的 $\varepsilon>0$，设计针对最大割问题的 $(0.878-\varepsilon)$-近似算法，使得最终输出的割总是满足近似比要求 (即确定性输出)，但是算法的运行时间是随机的。之后试求算法期望运行时间的上界。

证明 之后只需将 Monte Carlo 型算法 (运行时间固定，结果以概率保证) 转化为 Las Vegas 型算法 (结果确定，运行时间随机)。

设 $G=(V,E)$，边权为 $w_{ij}\geqslant 0$，记 W_{opt} 为 G 的最大割权值。

给出以下算法：

由于 $W_{\text{SDP}}\geqslant W_{\text{opt}}$，因此当满足判定条件时，$W\geqslant(0.878-\varepsilon)W_{\text{opt}}$。

Algorithm 1: Guaranteed-Max-Cut-Approximation(G,ε)

输入: 图 $G=(V,E)$，边权 $\{w_{ij}\}_{i,j\in V}\geqslant 0$，近似参数 $\varepsilon>0$。

输出: 割 $S\subset V$，其权值满足 $W(S)\geqslant(\alpha_{GW}-\varepsilon)W_{\text{opt}}$。

Part 1: SDP 松弛问题求解

求解以下 SDP 松弛问题：

$$\begin{aligned}\text{maximize}\quad&\sum_{i<j}w_{ij}\frac{1-\langle\boldsymbol{v}_i,\boldsymbol{v}_j\rangle}{2},\\\text{subject to}\quad&\boldsymbol{v}_i\in\mathbb{S}^{n-1},\end{aligned}$$

记最优值为 W_{SDP}，最优向量解为 $\{\boldsymbol{v}_i\}_{i=1}^n$。

Part 2: 迭代随机舍入 (Las Vegas 过程)

设 $\alpha\leftarrow\alpha_{GW}\approx 0.878$;

while True do

  独立地于 $N(\mathbf{0},\boldsymbol{I}_n)$ 抽取标准正态随机向量 $\boldsymbol{g}$;

  构造候选割：$S\leftarrow\{i\in V:\langle\boldsymbol{v}_i,\boldsymbol{g}\rangle\geqslant 0\}$;

  计算权值：$W\leftarrow\sum_{i\in S,j\notin S}w_{ij}$;

  if $W\geqslant(\alpha-\varepsilon)W_{\text{SDP}}$ **then**

    return S;

  end

end

设 W 为单次迭代所产生的割权值，则根据 Goemans-Williamson 定理，可得

$$\mathrm{E}[W]\geqslant\alpha_{GW}W_{\text{SDP}},$$

其中 $0 \leqslant W \leqslant W_{\mathrm{SDP}}$。

考虑 $A = \{W < (\alpha_{GW} - \varepsilon)W_{\mathrm{SDP}}\}$ (迭代失败)，设亏空随机变量 $Z = W_{\mathrm{SDP}} - W \geqslant 0$，满足

$$\mathrm{E}[Z] = W_{\mathrm{SDP}} - \mathrm{E}[W] \leqslant (1 - \alpha_{GW})W_{\mathrm{SDP}},$$

则利用命题 P1.6.2 (Markov 不等式) (Markov 不等式)，可得

$$\mathrm{P}(A) = \mathrm{P}\{Z > (1 - \alpha_{GW} + \varepsilon)W_{\mathrm{SDP}}\} \leqslant \frac{\mathrm{E}[Z]}{(1 - \alpha_{GW} + \varepsilon)W_{\mathrm{SDP}}} \leqslant \frac{(1 - \alpha_{GW})W_{\mathrm{SDP}}}{(1 - \alpha_{GW} + \varepsilon)W_{\mathrm{SDP}}} = \frac{1 - \alpha_{GW}}{1 - \alpha_{GW} + \varepsilon},$$

因此单次迭代成功的概率为

$$p = \mathrm{P}(A^c) \geqslant 1 - \frac{1 - \alpha_{GW}}{1 - \alpha_{GW} + \varepsilon} = \frac{\varepsilon}{1 - \alpha_{GW} + \varepsilon}。$$

设 $K \sim G(p)$ 为迭代次数，满足

$$\mathrm{E}[K] = \frac{1}{p} = \frac{1 - \alpha_{GW}}{\varepsilon} + 1 \sim \frac{0.122}{\varepsilon} + 1,$$

设单次 SDP 求解时间为 T_{SDP}，单次随机投影时间为 T_{round}，则总期望运行时间为

$$\mathrm{E}[T_{total}] = T_{SDP} + \left(\frac{1 - \alpha_{GW} + \varepsilon}{\varepsilon}\right) T_{round},$$

其与 $1/\varepsilon$ 成线性关系，从而对于固定的 ε，上述算法在期望意义下是多项式时间的。

55 [**实解析函数的核技巧**] 为了证明引理 L3.7.7 (实解析函数)，之后只需引入 $\mathbb{R}^n$ 的无穷维版本，即平方可和序列空间 ℓ^2，其定义为全体满足 $\sum_{i=1}^{\infty} x_i^2 < \infty$ 的序列 $\boldsymbol{x} = (x_1, x_2, \cdots)$ 所构成的集合，赋予以下范数, 内积：

$$\|\boldsymbol{x}\|_2 = \left(\sum_{i=1}^{\infty} x_i^2\right)^{1/2}, \quad \langle \boldsymbol{x}, \boldsymbol{y} \rangle = \sum_{i=1}^{\infty} x_i y_i。$$

设实解析函数 $f(z) = \sum_{k=0}^{\infty} a_k z^k$，其幂级数在 $\mathbb{R}$ 上绝对收敛。证明：存在 Hilbert 空间 $\mathcal{H}$ (此处取为序列空间 ℓ^2) 和变换 $\Phi, \Psi : \mathbb{R}^n \to \mathcal{H}$，使得：

(1) 对于任意的 $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$，满足

$$\langle \Phi(\boldsymbol{u}), \Psi(\boldsymbol{v}) \rangle = f(\langle \boldsymbol{u}, \boldsymbol{v} \rangle)。$$

(2) 对于任意的 $\boldsymbol{u} \in \mathbb{S}^{n-1}$，其映射后的范数满足

$$\|\Phi(\boldsymbol{u})\|_2^2 = \|\Psi(\boldsymbol{u})\|_2^2 = \sum_{k=0}^{\infty} |a_k|。$$

证明 (1) 利用内积的性质，可得

$$\langle \boldsymbol{u}^{\otimes k}, \boldsymbol{v}^{\otimes k} \rangle = (\langle \boldsymbol{u}, \boldsymbol{v} \rangle)。$$

以系数绝对值的平方根为权定义 Φ，

$$\Phi(\boldsymbol{u}) = (\sqrt{|a_0|}, \sqrt{|a_1|}\boldsymbol{u}^{\otimes 1}, \sqrt{|a_2|}\boldsymbol{u}^{\otimes 2}, \cdots, \sqrt{|a_k|}\boldsymbol{u}^{\otimes k}, \cdots),$$

Ψ 为基于加权引入原系数的符号 s_k，

$$\Phi(\boldsymbol{u}) = (\sqrt{|a_0|}, \sqrt{|a_1|}\boldsymbol{u}^{\otimes 1}, \sqrt{|a_2|}\boldsymbol{u}^{\otimes 2}, \cdots, \sqrt{|a_k|}\boldsymbol{u}^{\otimes k}, \cdots),$$

则

$$\begin{aligned} \langle \Phi(\boldsymbol{u}), \Psi(\boldsymbol{v}) \rangle &= \sum_{k=0}^{\infty} \langle \sqrt{|a_k|}\boldsymbol{u}^{\otimes k}, s_k\sqrt{|a_k|}\boldsymbol{v}^{\otimes k} \rangle \\ &= \sum_{k=0}^{\infty} s_k |a_k| \langle \boldsymbol{u}^{\otimes k}, \boldsymbol{v}^{\otimes k} \rangle = \sum_{k=0}^{\infty} a_k (\langle \boldsymbol{u}, \boldsymbol{v} \rangle)^k = f(\langle \boldsymbol{u}, \boldsymbol{v} \rangle)。 \qquad (a_k = s_k |a_k|) \end{aligned}$$

(2) 注意到 $\|\boldsymbol{u}^{\otimes k}\|_2 = \|\boldsymbol{u}\|_2^k = 1$，$s_k^2 \in \{0,1\}$，因此

$$\|\Phi(\boldsymbol{u})\|_2^2 = \sum_{k=0}^{\infty} \|\sqrt{|a_k|}\boldsymbol{u}^{\otimes k}\|_2^2 = \sum_{k=0}^{\infty} |a_k| \cdot \|\boldsymbol{u}\|_2^{2k} = \sum_{k=0}^{\infty} |a_k|,$$

$$\|\Psi(\boldsymbol{u})\|_2^2 = \sum_{k=0}^{\infty} (s_k\sqrt{|a_k|})^2 \cdot \|\boldsymbol{u}\|_2^{2k} = \sum_{k\in\{k:a_k\neq 0\}} |a_k| = \sum_{k=0}^{\infty} |a_k|,$$

其中 $\sum_{k=0}^{\infty} |a_k| < \infty$，从而 $\|\Phi(\boldsymbol{u})\|_2^2, \|\Psi(\boldsymbol{u})\|_2^2 < \infty$，即映射于 ℓ^2 是有定义的。

56 [**Grothendieck 恒等式的线性化**] 设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。为了消除引理 L3.6.5 (Grothendieck 恒等式) 中 arcsin 函数的非线性影响，我们通过添加修正项对其进行线性化处理。

证明：对于任意的 $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{S}^{n-1}$，满足：

(1)

$$\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{u}\rangle \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{v}\rangle)] = \sqrt{\frac{2}{\pi}}\langle \boldsymbol{u}, \boldsymbol{v}\rangle。$$

(2)

$$\mathrm{E}[\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}\rangle)\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{v}\rangle)] = \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle + \mathrm{E}[Z_{\boldsymbol{u}} Z_{\boldsymbol{v}}]。$$

其中修正随机变量定义为

$$Z_{\boldsymbol{w}} = \sqrt{\frac{2}{\pi}}\langle \boldsymbol{g}, \boldsymbol{w}\rangle - \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{w}\rangle)。 \qquad (\boldsymbol{w} \in \{\boldsymbol{u}, \boldsymbol{v}\})$$

证明 (1) 设 $X = \langle \boldsymbol{g}, \boldsymbol{u}\rangle$，$Y = \langle \boldsymbol{g}, \boldsymbol{v}\rangle$，则 $(X, Y) \sim N(0, 0, 1, 1, \rho)$，其中 $\rho = \langle \boldsymbol{u}, \boldsymbol{v}\rangle$。

进行分解 $X = \rho Y + \sqrt{1-\rho^2}W$，其中 $Y \perp W \sim N(0,1)$，则

$$\begin{aligned}\mathrm{E}[X\mathrm{sgn}(Y)] &= \mathrm{E}[(\rho Y + \sqrt{1-\rho^2}W)\mathrm{sgn}(Y)] \\ &= \rho\mathrm{E}[Y\mathrm{sgn}(Y)] + \sqrt{1-\rho^2}\mathrm{E}[W]\mathrm{E}[\mathrm{sgn}(Y)] \\ &= \rho\mathrm{E}[|Y|] = \sqrt{\frac{2}{\pi}}\langle \boldsymbol{u}, \boldsymbol{v}\rangle。\end{aligned}$$

(2) 设 $L_{\boldsymbol{w}} = \sqrt{2/\pi}\langle \boldsymbol{g}, \boldsymbol{w}\rangle$，$S_{\boldsymbol{w}} = \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{w}\rangle)$，则

$$\begin{aligned}\mathrm{E}[Z_{\boldsymbol{u}} Z_{\boldsymbol{v}}] &= \mathrm{E}[(L_{\boldsymbol{u}} - S_{\boldsymbol{u}})(L_{\boldsymbol{v}} - S_{\boldsymbol{v}})] \\ &= \mathrm{E}[L_{\boldsymbol{u}} L_{\boldsymbol{v}}] - \mathrm{E}[L_{\boldsymbol{u}} S_{\boldsymbol{v}}] - \mathrm{E}[S_{\boldsymbol{u}} L_{\boldsymbol{v}}] + \mathrm{E}[S_{\boldsymbol{u}} S_{\boldsymbol{v}}],\end{aligned}$$

其中

$$\mathrm{E}[L_{\boldsymbol{u}} L_{\boldsymbol{v}}] = \frac{2}{\pi}\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{u}\rangle\langle \boldsymbol{g}, \boldsymbol{v}\rangle] = \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle,$$

$$\mathrm{E}[L_{\boldsymbol{u}} S_{\boldsymbol{v}}] = \sqrt{\frac{2}{\pi}}\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{u}\rangle \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{v}\rangle)] = \sqrt{\frac{2}{\pi}} \cdot \sqrt{\frac{2}{\pi}}\langle \boldsymbol{u}, \boldsymbol{v}\rangle = \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle,$$

$$\mathrm{E}[S_{\boldsymbol{u}} L_{\boldsymbol{v}}] = \sqrt{\frac{2}{\pi}}\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{v}\rangle \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}\rangle)] = \sqrt{\frac{2}{\pi}} \cdot \sqrt{\frac{2}{\pi}}\langle \boldsymbol{u}, \boldsymbol{v}\rangle = \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle,$$

将其代入，可得

$$\begin{aligned}\mathrm{E}[Z_{\boldsymbol{u}} Z_{\boldsymbol{v}}] &= \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle - \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle - \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle + \mathrm{E}[S_{\boldsymbol{u}} S_{\boldsymbol{v}}] \\ &= -\frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle + \mathrm{E}[\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}\rangle)\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{v}\rangle)],\end{aligned}$$

即

$$\mathrm{E}[\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}\rangle)\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{v}\rangle)] = \frac{2}{\pi}\langle \boldsymbol{u}, \boldsymbol{v}\rangle + \mathrm{E}[Z_{\boldsymbol{u}} Z_{\boldsymbol{v}}]。$$

57 [**正半定矩阵的精细 Grothendieck 不等式**] 对于半正定矩阵，定理 T3.5.1 (Grothendieck 不等式) 以更优的常数 $\pi/2 \approx 1.571$ 成立，并且证明更简单。设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称正半定矩阵，满足对于任意的 $\boldsymbol{x} \in \{-1, 1\}^n$，$\sum_{i,j} a_{ij} x_i x_j \leqslant 1$。利用练习 Q3.56

(Grothendieck 恒等式的线性化) 证明：对于任意的单位向量 $\boldsymbol{u}_i \in \mathcal{H}$，

$$\sum_{i,j=1}^{n} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle \leqslant \frac{\pi}{2}。$$

证明 根据习题 Q3.56 (Grothendieck 恒等式的线性化)，可得对于任意的单位向量 $\boldsymbol{u}_i, \boldsymbol{u}_j \in \mathcal{H}$，

$$\mathrm{E}[\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_i\rangle)\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_j\rangle)] = \frac{2}{\pi}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle + \mathrm{E}[Z_i Z_j],$$

其中 $Z_k = \sqrt{2/\pi}\langle \boldsymbol{g}, \boldsymbol{u}_k\rangle - \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_k\rangle)$ 为修正随机变量。

两侧乘以 a_{ij}，之后关于 i, j 求和，

$$\sum_{i,j} a_{ij}\mathrm{E}[\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_i\rangle)\mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_j\rangle)] = \frac{2}{\pi}\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle + \sum_{i,j} a_{ij}\mathrm{E}[Z_i Z_j],$$

令 $X_k = \mathrm{sgn}(\langle \boldsymbol{g}, \boldsymbol{u}_k\rangle) \in \{-1, 1\}$ (由于 $\boldsymbol{u}_k$ 为单位向量)，则

$$\frac{2}{\pi}\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle = \mathrm{E}\left[\sum_{i,j} a_{ij} X_i X_j\right] - \mathrm{E}\left[\sum_{i,j} a_{ij} Z_i Z_j\right],$$

即

$$\frac{2}{\pi}\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle = \mathrm{E}[\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}] - \mathrm{E}[\boldsymbol{Z}^{\top}\boldsymbol{A}\boldsymbol{Z}]。 \tag{I}$$

(之后只需分别控制右侧两项即可。)

对于第一项，由于 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} \leqslant 1$，因此

$$\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} \leqslant 1 \implies \sum_{i,j} a_{ij} X_i X_j \leqslant 1 \implies \mathrm{E}\left[\sum_{i,j} a_{ij} X_i X_j\right] \leqslant 1。 \tag{II}$$

对于第二项，由于 $\boldsymbol{A}$ 是正半定的，因此对于任意的 $\boldsymbol{z} \in \mathbb{R}^n$，

$$\boldsymbol{z}^{\top}\boldsymbol{A}\boldsymbol{z} \geqslant 0 \implies \sum_{i,j} a_{ij} Z_i Z_j \geqslant 0 \implies \mathrm{E}\left[\sum_{i,j} a_{ij} Z_i Z_j\right] \geqslant 0。 \tag{III}$$

将 (II)(III) 分别代入于 (I)，可得

$$\frac{2}{\pi}\sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle \leqslant 1 - 0 = 1 \implies \sum_{i,j} a_{ij}\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle \leqslant \frac{\pi}{2}。$$

58 [**基于 Grothendieck 不等式的 SDP 松弛分析**] 利用习题 Q3.57 (正半定矩阵的精细 Grothendieck 不等式) 的结论，改进定理 T3.5.7 (松弛的保证)。

设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称正半定矩阵，定义其对应的 Boolean 二次规划最优值为

$$\mathrm{int}(\boldsymbol{A}) = \max\left\{\sum_{i,j=1}^{n} A_{ij} x_i x_j : x_i \in \{-1, 1\}\right\},$$

SDP 松弛的最优值为

$$\mathrm{sdp}(\boldsymbol{A}) = \max\left\{\sum_{i,j=1}^{n} A_{ij}\langle \boldsymbol{X}_i, \boldsymbol{X}_j\rangle : \boldsymbol{X}_i \in \mathbb{S}^{n-1}\right\}。$$

(1) 证明：

$$\mathrm{int}(\boldsymbol{A}) \leqslant \mathrm{sdp}(\boldsymbol{A}) \leqslant \frac{\pi}{2}\cdot \mathrm{int}(\boldsymbol{A})。$$

(2) 设计随机化算法，将 SDP 问题的解 $\{\boldsymbol{X}_i\}$ 映射为整数解 $x_i = \pm 1$，之后证明上述解在期望意义下近似原问题的最优值。

证明 (1) • 证明左侧不等式

定义整数规划的可行集为

$$\mathcal{F}_{\text{int}} = \{\boldsymbol{x} \in \mathbb{R}^n : x_i \in \{-1, 1\}\},$$

SDP 松弛问题的可行集为

$$\mathcal{F}_{\text{sdp}} = \{(\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n) : \boldsymbol{X}_i \in \mathbb{S}^{n-1}\},$$

(之后考虑构造嵌入映射 $\phi : \mathcal{F}_{\text{int}} \to \mathcal{F}_{\text{sdp}}$。)

对于任意的 $\boldsymbol{x} \in \mathcal{F}_{\text{int}}$，设 $\boldsymbol{X}_i = x_i \boldsymbol{e}_1 \in \mathbb{R}^n$，满足

$$\|\boldsymbol{X}_i\|_2 = |x_i| \cdot \|\boldsymbol{e}_1\|_2 = 1,$$

则 $(\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n) \in \mathcal{F}_{\text{sdp}}$，此时

$$\langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle = \langle x_i \boldsymbol{e}_1, x_j \boldsymbol{e}_1 \rangle = x_i x_j \langle \boldsymbol{e}_1, \boldsymbol{e}_1 \rangle = x_i x_j,$$

因此 SDP 目标函数简化为

$$\sum_{i,j=1}^n A_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle = \sum_{i,j=1}^n A_{ij} x_i x_j。$$

设 $f(\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n) = \sum_{i,j} A_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle$，则整数规划的所有可能取值均包含于 SDP 目标函数的取值集合，即

$$\left\{ \sum_{i,j} A_{ij} x_i x_j : \boldsymbol{x} \in \mathcal{F}_{\text{int}} \right\} \subset \{ f(\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n) : (\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n) \in \mathcal{F}_{\text{sdp}} \},$$

两侧取上确界，可得

$$\max_{\mathcal{F}_{\text{int}}} \sum_{i,j} A_{ij} x_i x_j \leqslant \max_{\mathcal{F}_{\text{sdp}}} f(\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n),$$

即 $\text{int}(\boldsymbol{A}) \leqslant \text{sdp}(\boldsymbol{A})$。

- 证明右侧不等式

对于

$$\text{int}(\boldsymbol{A}) = \max_{\boldsymbol{x} \in \{-1,1\}^n} \sum_{i,j=1}^n a_{ij} x_i x_j, \quad \text{sdp}(\boldsymbol{A}) = \max_{\boldsymbol{X}_i \in \mathbb{S}^{n-1}} \sum_{i,j=1}^n a_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle,$$

若 $\boldsymbol{A} = \boldsymbol{O}$，则结论是平凡的；之后只需考虑 $\boldsymbol{A} \neq \boldsymbol{O}$ 的情况。

(我们考虑构造规范化矩阵。)

构造新的正半定矩阵 $\tilde{\boldsymbol{A}} = (\tilde{a}_{ij})$ 为

$$\tilde{a}_{ij} = \frac{a_{ij}}{\text{int}(\boldsymbol{A})},$$

则对于任意的 $\boldsymbol{x} \in \{-1, 1\}^n$，

$$\sum_{i,j=1}^n \tilde{a}_{ij} x_i x_j = \frac{1}{\text{int}(\boldsymbol{A})} \sum_{i,j=1}^n a_{ij} x_i x_j \leqslant \frac{\text{int}(\boldsymbol{A})}{\text{int}(\boldsymbol{A})} = 1,$$

因此根据习题 Q3.57 (正半定矩阵的精细 Grothendieck 不等式)，可得

$$\sum_{i,j=1}^n \tilde{a}_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle \leqslant \frac{\pi}{2} \implies \sum_{i,j=1}^n a_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle \leqslant \frac{\pi}{2} \cdot \text{int}(\boldsymbol{A})。$$

如此，

$$\text{sdp}(\boldsymbol{A}) = \max_{\boldsymbol{X}_i \in \mathbb{S}^{n-1}} \sum_{i,j=1}^n a_{ij} \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle \leqslant \frac{\pi}{2} \text{int}(\boldsymbol{A})。$$

(2) 给出以下算法：

Algorithm 2: 随机超平面舍入算法

求解 SDP 问题，获得最优向量组 $\{\boldsymbol{X}_1, \cdots, \boldsymbol{X}_n\} \subset \mathbb{S}^{n-1}$;
独立地于 $N(\boldsymbol{0}, \boldsymbol{I}_n)$ 抽取标准正态随机向量 $\boldsymbol{g}$;
for $i = 1, \cdots, n$ **do**
    $x_i \leftarrow \operatorname{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{g} \rangle)$;
end
return $\{x_1, \cdots, x_n\}$;

设 $V_{round} = \sum_{i,j} A_{ij} x_i x_j$ 为算法输出的随机值，则

$$\mathrm{E}[V_{round}] = \sum_{i,j} A_{ij} \mathrm{E}[x_i x_j],$$

因此利用 Grothendieck 恒等式 (Q3.53 (Grothendieck 恒等式))，可得

$$\mathrm{E}[\operatorname{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{g} \rangle) \operatorname{sgn}(\langle \boldsymbol{X}_j, \boldsymbol{g} \rangle)] = \frac{2}{\pi} \arcsin(\langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle),$$

令 $\rho_{ij} = \langle \boldsymbol{X}_i, \boldsymbol{X}_j \rangle$，可得

$$\mathrm{E}[V_{round}] = \frac{2}{\pi} \sum_{i,j} A_{ij} \arcsin(\rho_{ij}),$$

其中 $\arcsin \rho = \sum_{k=0}^{\infty} c_{2k+1} \rho^{2k+1}$，将其代入，可得

$$\begin{aligned} \mathrm{E}[V_{round}] &= \frac{2}{\pi} \sum_{i,j} A_{ij} \rho_{ij} + \frac{2}{\pi} \sum_{k=1}^{\infty} c_{2k+1} \left(\sum_{i,j} A_{ij} \rho_{ij}^{2k+1} \right) \\ &\geqslant \frac{2}{\pi} \sum_{i,j} A_{ij} \rho_{ij} = \frac{2}{\pi} \operatorname{sdp}(\boldsymbol{A}) \geqslant \frac{2}{\pi} \operatorname{int}(\boldsymbol{A}), \end{aligned}$$

即上述算法在期望意义下达到了至少 $2/\pi \approx 0.637$ 的近似比。

4 随机矩阵

要点梳理

Section 4.1 线性代数回顾 Q4.1 ~ Q4.17

定理 4.1.1 (SVD 分解)
任意的 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 可写为

$$\boldsymbol{A} = \sum_{i=1}^{r} s_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}, \qquad (r = \min(m,n))$$

此时称 $s_i \geqslant 0$ 为奇异值，$\boldsymbol{u}_i \in \mathbb{R}^m$ 为标准正交的左奇异向量，$\boldsymbol{v}_i \in \mathbb{R}^n$ 为标准正交的右奇异向量。

定理 4.1.6 (特征值的极小极大定理)
对于对称矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，第 k 个主特征值满足

$$\lambda_k(\boldsymbol{A}) = \max_{\dim E = k} \min_{\boldsymbol{x}\in\mathbb{S}(E)} \boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} = \min_{\dim E = n-k+1} \max_{\boldsymbol{x}\in\mathbb{S}(E)} \boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x},$$

其中 $\mathbb{S}(E)$ 为子空间 E 的单位球面。

推论 4.1.7 (奇异值的极小极大定理)
设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 的奇异值为 $s_1 \geqslant s_2 \geqslant \cdots$，则

$$s_k(\boldsymbol{A}) = \max_{\dim E = k} \min_{\boldsymbol{x}\in\mathbb{S}(E)} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \min_{\dim E = n-k+1} \max_{\boldsymbol{x}\in\mathbb{S}(E)} \|\boldsymbol{A}\boldsymbol{x}\|_2。$$

定义 4.1.8 (算子范数)

$$\|\boldsymbol{A}\| = \max_{\boldsymbol{x}\neq 0} \frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} = \max_{\|\boldsymbol{x}\|_2=1} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \max_{\|\boldsymbol{x}\|_2=\|\boldsymbol{y}\|_2=1} |\boldsymbol{y}^{\top}\boldsymbol{A}\boldsymbol{x}|。$$

引理 4.1.10 (正交不变性)
设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，$\boldsymbol{U} \in \mathbb{R}^{m\times m}$，$\boldsymbol{V} \in \mathbb{R}^{n\times n}$ 为正交矩阵，则

$$\|\boldsymbol{U}\boldsymbol{A}\boldsymbol{V}\|_F = \|\boldsymbol{A}\|_F，\ \|\boldsymbol{U}\boldsymbol{A}\boldsymbol{V}\| = \|\boldsymbol{A}\|。$$

引理 4.1.11 (通过奇异值表示矩阵范数)
设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的奇异值为 $s_1\geqslant s_2\geqslant\cdots$，则

$$\|\boldsymbol{A}\|_F=\left(\sum_i s_i(\boldsymbol{A})^2\right)^{1/2},\quad \|\boldsymbol{A}\|=s_1(\boldsymbol{A})。$$

定理 4.1.13 (Eckart–Young–Mirsky 定理)
设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的 SVD 分解为 $\boldsymbol{A}=\sum_i s_i\boldsymbol{u}_i\boldsymbol{v}_i^\top$，则对于任意的 $1\leqslant k<r$，在秩不超过 k 的矩阵类中，$\boldsymbol{A}$ 的最佳算子范数逼近误差为

$$\min_{\operatorname{rank}(\boldsymbol{B})\leqslant k}\|\boldsymbol{A}-\boldsymbol{B}\|=s_{k+1},$$

最小值于截断奇异值矩阵 $\boldsymbol{A}_k=\sum_{i=1}^k s_i\boldsymbol{u}_i\boldsymbol{v}_i^\top$ 取得。

引理 4.1.14 (Weyl 不等式)
对于任意的对称矩阵 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{n\times n}$，

$$|\lambda_i(\boldsymbol{A}+\boldsymbol{B})-\lambda_i(\boldsymbol{A})|\leqslant\|\boldsymbol{B}\|。$$

定理 4.1.15 (Davis–Kahan 不等式)
设 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{n\times n}$ 为对称矩阵，其单位特征向量为 $\boldsymbol{v}_i(\boldsymbol{A})$, $\boldsymbol{v}_i(\boldsymbol{B})$，则

$$\|\boldsymbol{v}_i(\boldsymbol{A})-\boldsymbol{v}_i(\boldsymbol{B})\|_2\leqslant\frac{\|\boldsymbol{A}-\boldsymbol{B}\|}{\min_{j\neq i}|\lambda_i(\boldsymbol{A})-\lambda_j(\boldsymbol{A})|}。$$

引理 4.1.16 (谱投影的 Davis–Kahan 不等式)
设 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{n\times n}$ 为对称矩阵，令 $\boldsymbol{P}_A$, $\boldsymbol{P}_B$ 为对应于 $I\subset\mathbb{R}$ 的特征向量张成空间的正交投影，则

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\frac{\|\boldsymbol{A}-\boldsymbol{B}\|}{\operatorname{dist}(I,\sigma(\boldsymbol{A})\setminus I)}。$$

引理 4.1.17 (近似等距)
若 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 满足 $\|\boldsymbol{A}^\top\boldsymbol{A}-\boldsymbol{I}_n\|\leqslant\varepsilon$ $(\varepsilon\in(0,1))$，则对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$(1-\varepsilon)\|\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_2\leqslant(1+\varepsilon)\|\boldsymbol{x}\|_2。$$

Section 4.2 网, 覆盖, 填充 Q4.18 ∼ Q4.32

定义 4.2.1 (ε-网)
设 $\mathbb{T}\subset\mathbb{R}^n$，$\mathcal{N}\subset\mathbb{T}$。若对于任意的 $\boldsymbol{x}\in\mathbb{T}$，存在 $\boldsymbol{y}\in\mathcal{N}$，满足 $\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant\varepsilon$，则称 $\mathcal{N}$ 为 $\mathbb{T}$ (关于 Euclidean 度量) 的 ε-网。(若集合是无界的，则覆盖数为 $+\infty$，这是平凡的；在之后的行文中，$\mathbb{T}$ 特指有界子集。)

定义 4.2.2 (覆盖数)
$\mathbb{T}\subset\mathbb{R}^n$ 的覆盖数 $\mathcal{N}(\mathbb{T},\varepsilon)=\mathcal{N}(\mathbb{T},\|\cdot\|_2,\varepsilon)$ 定义为 $\mathbb{T}$ 的 ε-网的最小基数，

$$\mathcal{N}(T,\varepsilon):=\inf\{|\mathcal{N}|:\mathcal{N}\subset\mathbb{T}\text{ 为 }\mathbb{T}\text{ 的 }\varepsilon\text{-网}\}。$$

定义 4.2.4 (填充数)

$\mathbb{T}\subset\mathbb{R}^n$ 的填充数 $\mathcal{P}(\mathbb{T},\varepsilon)$ 定义为 $\mathbb{T}$ 的 ε-分离子集的最大基数，

$$\mathcal{P}(\mathbb{T},\varepsilon):=\sup\{|\mathcal{P}|:\mathcal{P}\subset\mathbb{T}\text{ 为 }\mathbb{T}\text{ 的 }\varepsilon\text{-分离集}\}。$$

注记 4.2.5 (球装箱的几何原理)

若 $\mathcal{P}\subset\mathbb{T}$ 为 ε-分离集，则利用三角不等式，可得 $\{B(\boldsymbol{x},\varepsilon/2):\boldsymbol{x}\in\mathcal{P}\}$ 是两两不交的，因此 $\mathbb{T}$ 至多可以装入 $\mathcal{P}(\mathbb{T},\varepsilon)$ 个两两不交的 $\varepsilon/2$-球。

引理 4.2.6 (极大分离集构造网)

$\mathbb{T}\subset\mathbb{R}^n$ 的任意极大 ε-分离子集必定为 $\mathbb{T}$ 的 ε-网。

注记 4.2.7 (构造 ε-网)

引理 **??** 作出了构造给定集合 $\mathbb{T}$ 的 ε-网的贪心迭代算法：

1. 任意选取初始点 $\boldsymbol{x}_1\in\mathbb{T}$；
2. 依序选取与已有各点距离均不小于 ε 的点 $\boldsymbol{x}_{k+1}\in\mathbb{T}\setminus\bigcup_{i=1}^{k}B(\boldsymbol{x}_i,\varepsilon)$；
3. 继续上述过程，直至无法选取新点为止。

若 $\mathbb{T}$ 为紧集，则上述过程必定于有限步终止 (否则由紧性存在收敛子列，与任意互异点间距不小于 ε 矛盾)，从而输出 $\mathbb{T}$ 的一个有限 ε-网。

引理 4.2.8 (覆盖数, 填充数的等价性)

设 $\mathbb{T}\subset\mathbb{R}^n$，则对于任意的 $\varepsilon>0$，

$$\mathcal{P}(\mathbb{T},2\varepsilon)\leqslant\mathcal{N}(\mathbb{T},\varepsilon)\leqslant\mathcal{P}(\mathbb{T},\varepsilon)。$$

定义 4.2.9 (Minkowski 和)

$A+B=\{a+b:a\in A,b\in B\}$。

命题 4.2.10 (体积比较法估计覆盖数)

设 $\mathbb{T}\subset\mathbb{R}^n$，则

$$\mathcal{N}(\mathbb{T},\varepsilon)\leqslant\frac{\mathrm{Vol}(\mathbb{T}+(\varepsilon/2)\mathbb{B}_2^n)}{\mathrm{Vol}((\varepsilon/2)\mathbb{B}_2^n)}。$$

推论 4.2.11 (Euclidean 球的覆盖数)

对于 $\varepsilon\in(0,1)$，

$$\mathcal{N}(\mathbb{B}_2^n,\varepsilon)\leqslant\left(\frac{3}{\varepsilon}\right)^n。$$

定义 4.2.14 (Hamming 距离)

对于 $\boldsymbol{x},\boldsymbol{y}\in\{0,1\}^n$，其 Hamming 距离定义为两向量不同坐标的个数，

$$d_H(\boldsymbol{x},\boldsymbol{y}):=|\{i\in\{1,\cdots,n\}:x_i\neq y_i\}|。$$

命题 4.2.15 (Hamming 立方体的覆盖数, 填充数)

对于归一化 Hamming 距离 $d(\boldsymbol{x},\boldsymbol{y})=\frac{1}{n}d_H(\boldsymbol{x},\boldsymbol{y})$ 的 Hamming 立方体 $\{0,1\}^n$：

$$\exp(nh(\varepsilon/2))\lesssim\mathcal{N}(\{0,1\}^n,\varepsilon)\lesssim\exp(nh(\varepsilon))，$$

其中 $h(p)=-p\ln p-(1-p)\ln(1-p)$ 为二元熵。

命题 4.3.1 (度量熵, 编码)
将点 $\boldsymbol{x} \in \mathbb{T}$ 编码至精度 ε 所需的二进制位数至少为 $\log_2 \mathcal{N}(\mathbb{T}, \varepsilon)$。

定义 4.3.3 (纠错码)
(n, M, d)-码为 $\{0,1\}^n$ 的 M 个码字的集合，其 Hamming 距离至少为 d。

引理 4.3.4 (纠错, 填充)
(n, M, d)-码可纠正至多 $\lfloor (d-1)/2 \rfloor$ 个错误。

定理 4.3.5 (纠错码的保证)
对于任意的 $\delta \in (0, 1/2)$，存在 (n, M, d)-码，其码率 $R = \log_2 M/n$, 相对距离 d/n 满足：

$$R = \frac{\log_2 M}{n} \geqslant 1 - h(\delta), \quad \frac{d}{n} \geqslant \delta,$$

其中 h 为二元熵函数。

Section 4.4 sub-Gaussian 随机矩阵的上界 Q4.34 ~ Q4.44

引理 4.4.1 (于离散网估计算子范数)
设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$，$\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，$\mathcal{M}$ 为 $\mathbb{S}^{m-1}$ 的 ε-网，其中 $\varepsilon < 1/2$，则

$$\|\boldsymbol{A}\| \leqslant \frac{1}{1-2\varepsilon} \max_{\boldsymbol{x} \in \mathcal{N}, \boldsymbol{y} \in \mathcal{M}} \langle \boldsymbol{y}, \boldsymbol{A}\boldsymbol{x} \rangle。$$

引理 4.4.2 (于离散网估计对称矩阵的二次型)
设 $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ 为对称矩阵，$\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，其中 $\varepsilon < 1/2$，则

$$\|\boldsymbol{A}\| \leqslant \frac{1}{1-2\varepsilon} \max_{\boldsymbol{x} \in \mathcal{N}} |\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{x} \rangle|。$$

定理 4.4.3 (独立 sub-Gaussian 矩阵的范数界)
设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ 为随机矩阵，其元素为相互独立, 零均值的 K-sub-Gaussian 随机变量，则:
(1)

$$\mathrm{E}\|\boldsymbol{A}\| \leqslant CK(\sqrt{m} + \sqrt{n}),$$

(2) 对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{A}\| \geqslant CK(\sqrt{m} + \sqrt{n} + t)\} \leqslant 2\exp(-ct^2)。$$

推论 4.4.7 (对称 sub-Gaussian 矩阵的范数界)
设 $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ 为对称随机矩阵，其对角线及以上元素为相互独立, 零均值的 K-sub-Gaussian 随机变量，则:
(1)

$$\mathrm{E}\|\boldsymbol{A}\| \leqslant CK\sqrt{n},$$

(2) 对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{A}\| \geqslant CK(\sqrt{n} + t)\} \leqslant 2\exp(-ct^2)。$$

Section 4.5 网络社区检测 Q4.45

定义 4.5.1 (随机块模型)
两个等大小社区的随机块模型 $\mathrm{SBM}(n, p, q)$ 按照以下方式生成 n 个顶点的随机图：

1. 将前 $n/2$ 个顶点标记为社区 $+1$，剩余 $n/2$ 个顶点标记为社区 -1；
2. 相同社区的顶点对以概率 p 独立连边，不同社区之间的顶点对以概率 q 独立连边。

定理 4.5.2 (随机块模型的谱聚类)

考虑 SBM，其中 $p = a\ln n/n$，$q = b\ln n/n$。若 $|\sqrt{a}-\sqrt{b}| > \sqrt{2}$，则利用于邻接矩阵的谱聚类以高概率精确恢复所有顶点的社区划分。

Section 4.6 sub-Gaussian 矩阵的双侧界 Q4.46 ~ Q4.47

定理 4.6.1 (sub-Gaussian 矩阵的双侧界)

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其元素为相互独立, 中心化的 K-sub-Gaussian 随机变量，则对于任意的 $t \geqslant 0$，

$$\sqrt{m} - CK\sqrt{n} - t \leqslant s_{\min}(\boldsymbol{A}) \leqslant s_{\max}(\boldsymbol{A}) \leqslant \sqrt{m} + CK\sqrt{n} + t \ (\text{w.p.1} - 2\exp(-ct^2)),$$

其中 $s_{\min}(\boldsymbol{A}), s_{\max}(\boldsymbol{A})$ 分别表示 $\frac{1}{\sqrt{n}}\boldsymbol{A}$ 的最小, 最大奇异值。

Section 4.7 协方差估计与聚类 Q4.48 ~ Q4.51

定理 4.7.1 (协方差估计)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为协方差 $\boldsymbol{\Sigma}$ 的 sub-Gaussian 随机向量，令 $\{\boldsymbol{X}_N\}$ 为 $\boldsymbol{X}$ 的独立副本。定义样本协方差

$$\boldsymbol{\Sigma}_N = \frac{1}{N}\sum_{i=1}^{N} \boldsymbol{X}_i\boldsymbol{X}_i^{\top},$$

若 $N \geqslant Cn/\varepsilon^2$，则

$$\|\boldsymbol{\Sigma}_N - \boldsymbol{\Sigma}\| \leqslant \varepsilon\|\boldsymbol{\Sigma}\| \ (\text{w.h.p.})。$$

注记 4.7.3 (高概率界)

事实上，定理 T4.7.1 (协方差估计) 的证明给出了以下非渐近高概率界：对于任意的 $u \geqslant 0$，

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant CK^2\left(\sqrt{\frac{n+u}{m}} + \frac{n+u}{m}\right)\|\boldsymbol{\Sigma}\| \ (\text{w.p. } 1 - 2\mathrm{e}^{-u})。$$

定义 4.7.4 (Gaussian 混合模型)

两分量 Gaussian 混合模型 (GMM) 为于 $\mathbb{R}^n$ 的概率分布，定义为以 $1/2$ 的等概率抽取样本 $X \sim N(\boldsymbol{\mu}, \boldsymbol{I}_n)$ 或 $X \sim N(-\boldsymbol{\mu}, \boldsymbol{I}_n)$，其中 $\boldsymbol{\mu} \in \mathbb{R}^n$ 未知。

定理 4.7.5 (Gaussian 混合模型的谱聚类)

若 $\|\boldsymbol{\mu}\|_2 \geqslant C\sqrt{n}$，样本量满足 $N \geqslant Cn$，则利用样本协方差矩阵最大特征向量进行谱聚类，能够以高概率精确恢复所有聚类成员。

习题解答

1 [逆矩阵的 SVD] 设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 的 SVD 为

$$\boldsymbol{A} = \sum_{i=1}^{n} s_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top},$$

其中 $s_1 \geqslant \cdots \geqslant s_n \geqslant 0$ 为其奇异值，$\{\boldsymbol{u}_i\}_{i=1}^n, \{\boldsymbol{v}_i\}_{i=1}^n$ 分别为对应的左, 右奇异向量组 (均为 $\mathbb{R}^n$ 的标准正交基)。

(1) 证明：$\boldsymbol{A}$ 是可逆的充要条件为 $s_i \neq 0$。

(2) 证明：若 $\boldsymbol{A}$ 是可逆的，则 $\boldsymbol{A}^{-1}$ 的 SVD 为

$$\boldsymbol{A}^{-1} = \sum_{i=1}^n s_i^{-1} \boldsymbol{v}_i \boldsymbol{u}_i^\top。$$

证明 (1) ($\Longrightarrow$)

若 $\boldsymbol{A}$ 是可逆的，则

$$0 \neq \det(\boldsymbol{A}) = \det(\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top) = \det(\boldsymbol{U})\det(\boldsymbol{\Sigma})\det(\boldsymbol{V}^\top),$$

其中 $\boldsymbol{U}, \boldsymbol{V}$ 为正交矩阵，满足 $|\det(\boldsymbol{U})| = |\det(\boldsymbol{V})| = 1$，因此

$$0 \neq |\det(\boldsymbol{A})| = |\det(\boldsymbol{\Sigma})| = \prod_{i=1}^n s_i,$$

解得 $s_i \neq 0$。

($\Longleftarrow$)

若 $s_i > 0$，则 $\boldsymbol{\Sigma}$ 是可逆的，满足 $\boldsymbol{\Sigma}^{-1} = \operatorname{diag}(s_1^{-1}, \cdots, s_n^{-1})$，因此 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ 是可逆的。

(2) 设 $\boldsymbol{B} = \sum_{j=1}^n s_j^{-1} \boldsymbol{v}_j \boldsymbol{u}_j^\top$，则

$$\begin{aligned}
\boldsymbol{A}\boldsymbol{B} &= \left(\sum_{i=1}^n s_i \boldsymbol{u}_i \boldsymbol{v}_i^\top\right)\left(\sum_{j=1}^n s_j^{-1} \boldsymbol{v}_j \boldsymbol{u}_j^\top\right) \\
&= \sum_{i=1}^n \sum_{j=1}^n s_i s_j^{-1} \boldsymbol{u}_i (\boldsymbol{v}_i^\top \boldsymbol{v}_j) \boldsymbol{u}_j^\top \\
&= \sum_{i=1}^n \sum_{j=1}^n s_i s_j^{-1} \boldsymbol{u}_i \delta_{ij} \boldsymbol{u}_j^\top \\
&= \sum_{i=1}^n s_i s_i^{-1} \boldsymbol{u}_i \boldsymbol{u}_i^\top \\
&= \sum_{i=1}^n \boldsymbol{u}_i \boldsymbol{u}_i^\top = \boldsymbol{I}_n;
\end{aligned}$$

同理，

$$\boldsymbol{B}\boldsymbol{A} = \boldsymbol{I}_n;$$

因此 $\boldsymbol{B}$ 为逆矩阵，其奇异值为 $s_n^{-1} \geqslant \cdots \geqslant s_1^{-1}$，左右奇异向量组分别为 $\{\boldsymbol{v}_i\}_{i=1}^n, \{\boldsymbol{u}_i\}_{i=1}^n$。

2 [**算子范数的基本性质**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$。定义 $\boldsymbol{A}$ 的算子范数 $\|\boldsymbol{A}\|$ 为

$$\|\boldsymbol{A}\| = \sup\{\|\boldsymbol{A}\boldsymbol{x}\|_2 : \boldsymbol{x} \in \mathbb{R}^n, \|\boldsymbol{x}\|_2 = 1\}。$$

(1) 证明：上述定义的算子范数为 $\mathbb{R}^{m\times n}$ 的范数。

(2) 证明：$\|\boldsymbol{A}^\top\| = \|\boldsymbol{A}\|$。

(3) 证明 (次可乘性)：对于任意的维数相容的矩阵 $\boldsymbol{A}, \boldsymbol{B}$，均满足 $\|\boldsymbol{A}\boldsymbol{B}\| \leqslant \|\boldsymbol{A}\| \cdot \|\boldsymbol{B}\|$。之后举例，使得左侧为 0，右侧不为 0。

(4) 证明：矩阵的任意子矩阵的算子范数均不超过原矩阵的算子范数。

证明 (1) 1. 非负性, 确定性：

由于 $\|\boldsymbol{A}\boldsymbol{x}\|_2 \geqslant 0$，因此 $\|\boldsymbol{A}\| \geqslant 0$。

若 $\|\boldsymbol{A}\| = 0$，则对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，均满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，因此 $\boldsymbol{A} = \boldsymbol{O}$。

2. 齐次性：

$$\|c\boldsymbol{A}\| = \sup_{\|\boldsymbol{x}\|_2=1} \|c\boldsymbol{A}\boldsymbol{x}\|_2 = \sup_{\|\boldsymbol{x}\|_2=1} |c| \cdot \|\boldsymbol{A}\boldsymbol{x}\|_2 = |c| \cdot \|\boldsymbol{A}\|。$$

3. 三角不等式：对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，

$$\|(\boldsymbol{A}+\boldsymbol{B})\boldsymbol{x}\|_2=\|\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_2+\|\boldsymbol{B}\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}\|+\|\boldsymbol{B}\|,$$

两侧取上确界，可得 $\|\boldsymbol{A}+\boldsymbol{B}\|\leqslant\|\boldsymbol{A}\|+\|\boldsymbol{B}\|$。

(2) 根据算子范数的变分刻画 4.1.8，可得

$$\|\boldsymbol{A}\|=\sup_{\|\boldsymbol{x}\|_2=1,\|\boldsymbol{y}\|_2=1}\langle\boldsymbol{y},\boldsymbol{A}\boldsymbol{x}\rangle,$$

其中 $\langle\boldsymbol{y},\boldsymbol{A}\boldsymbol{x}\rangle=\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}=(\boldsymbol{A}^\top\boldsymbol{y})^\top\boldsymbol{x}=\langle\boldsymbol{A}^\top\boldsymbol{y},\boldsymbol{x}\rangle$，因此

$$\|\boldsymbol{A}\|=\sup_{\|\boldsymbol{x}\|_2=1,\|\boldsymbol{y}\|_2=1}\langle\boldsymbol{A}^\top\boldsymbol{y},\boldsymbol{x}\rangle=\sup_{\|\boldsymbol{y}\|_2=1}\|\boldsymbol{A}^\top\boldsymbol{y}\|_2=\|\boldsymbol{A}^\top\|。$$

（对于固定的 $\boldsymbol{y}$，$\sup_{\|\boldsymbol{x}\|_2=1}\langle\boldsymbol{A}^\top\boldsymbol{y},\boldsymbol{x}\rangle$ 在当 $\boldsymbol{x}$ 与 $\boldsymbol{A}^\top\boldsymbol{y}$ 同向时取得，其值为 $\|\boldsymbol{A}^\top\boldsymbol{y}\|_2$。）

(3) 对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，

$$\|\boldsymbol{A}\boldsymbol{B}\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}\|\cdot\|\boldsymbol{B}\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}\|\cdot\|\boldsymbol{B}\|\cdot\|\boldsymbol{x}\|_2=\|\boldsymbol{A}\|\cdot\|\boldsymbol{B}\|,$$

两侧取上确界，可得 $\|\boldsymbol{A}\boldsymbol{B}\|\leqslant\|\boldsymbol{A}\|\cdot\|\boldsymbol{B}\|$。

构造以下反例：令

$$\boldsymbol{A}=\begin{pmatrix}1&0\\0&0\end{pmatrix},\ \boldsymbol{B}=\begin{pmatrix}0&0\\0&1\end{pmatrix},$$

则 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{O}$，即 $\|\boldsymbol{A}\boldsymbol{B}\|=0$，但是 $\|\boldsymbol{A}\|=1,\|\boldsymbol{B}\|=1$，此时 $\|\boldsymbol{A}\|\cdot\|\boldsymbol{B}\|=1\neq0$。

(4) 设 $\boldsymbol{A}_0\subset\boldsymbol{A}$，不妨设 $\boldsymbol{A}_0=(\boldsymbol{A})_{1:k;1:l}$。

对于任意的 $\boldsymbol{x}_0\in\mathbb{S}^{l-1}$，构造 $\boldsymbol{x}=(\boldsymbol{x}_0^\top,0,\cdots,0)^\top$，满足 $\|\boldsymbol{x}\|_2=\|\boldsymbol{x}_0\|_2=1$，$(\boldsymbol{A}\boldsymbol{x})_{1:k}=\boldsymbol{A}_0\boldsymbol{x}_0$，则

$$\|\boldsymbol{A}_0\boldsymbol{x}_0\|_2^2\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_2^2\leqslant\|\boldsymbol{A}\|^2,$$

两侧对 $\boldsymbol{x}_0$ 取上确界，可得 $\|\boldsymbol{A}_0\|\leqslant\|\boldsymbol{A}\|$。

3 [算子范数的特殊情形计算]

(1) 秩一矩阵：设 $\boldsymbol{u},\boldsymbol{v}\in\mathbb{R}^n$。证明：其构成的秩一矩阵 $\boldsymbol{u}\boldsymbol{v}^\top$ 的算子范数与 Frobenius 范数相等，均等于分量模长之积，即

$$\|\boldsymbol{u}\boldsymbol{v}^\top\|=\|\boldsymbol{u}\boldsymbol{v}^\top\|_F=\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2。$$

(2) 对角矩阵：设 $\boldsymbol{A}=\mathrm{diag}(a_1,\cdots,a_n)\in\mathbb{R}^{n\times n}$。证明：其算子范数等于对角元绝对值的最大值，即

$$\|\boldsymbol{A}\|=\max_{1\leqslant i\leqslant n}|a_i|。$$

证明 (1) • 算子范数部分

容易知道，

$$\|\boldsymbol{u}\boldsymbol{v}^\top\|=\sup_{\|\boldsymbol{x}\|_2=1}\|\boldsymbol{u}\boldsymbol{v}^\top\boldsymbol{x}\|_2=\|\boldsymbol{u}\|_2\cdot\sup_{\|\boldsymbol{x}\|_2=1}|\boldsymbol{v}^\top\boldsymbol{x}|,$$

其中利用 Cauchy 不等式，对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，

$$|\boldsymbol{v}^\top\boldsymbol{x}|\leqslant\|\boldsymbol{v}\|_2\|\boldsymbol{x}\|_2=\|\boldsymbol{v}\|_2,$$

当且仅当 $\boldsymbol{x}=\bar{\boldsymbol{v}}$ 时等号成立，从而

$$\|\boldsymbol{u}\boldsymbol{v}^\top\|=\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2。$$

• Frobenius 范数部分

容易知道，

$$\|\boldsymbol{u}\boldsymbol{v}^\top\|_F^2=\sum_{i=1}^m\sum_{j=1}^n(u_iv_j)^2=\sum_{i=1}^m u_i^2\left(\sum_{j=1}^n v_j^2\right)=\|\boldsymbol{u}\|_2^2\|\boldsymbol{v}\|_2^2,$$

即 $\|\boldsymbol{u}\boldsymbol{v}^\top\|_F=\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2$。

(2) 对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_{i=1}^{n} a_i^2 x_i^2,$$

令 $M = \max_{1 \leqslant i \leqslant n} |a_i|$，满足 $a_i^2 \leqslant M^2$，则

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 \leqslant \sum_{i=1}^{n} M^2 x_i^2 = M^2 \sum_{i=1}^{n} x_i^2 = M^2,$$

即 $\|\boldsymbol{A}\boldsymbol{x}\|_2 \leqslant M$。

之后说明上界是可达的：设 k 满足 $|a_k| = M$，令 $\boldsymbol{x} = \boldsymbol{e}_k$，则

$$\|\boldsymbol{A}\boldsymbol{e}_k\|_2 = \sqrt{a_k^2} = |a_k| = M,$$

因此

$$\|\boldsymbol{A}\| = \sup_{\|\boldsymbol{x}\|_2 = 1} \|\boldsymbol{A}\boldsymbol{x}\|_2 = M = \max_{1 \leqslant i \leqslant n} |a_i|。$$

4 [算子范数与 Frobenius 范数的关系和性质] 设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$。

(1) 设 $\operatorname{rank}(\boldsymbol{A}) = r$，证明：

$$\|\boldsymbol{A}\| \leqslant \|\boldsymbol{A}\|_F \leqslant \sqrt{r}\|\boldsymbol{A}\|。$$

之后说明对于任意的 $1 \leqslant r \leqslant \min(m, n)$，上述界限均是可达的。

(2) 设 $\boldsymbol{Z} \in \mathbb{R}^n$ 为各向同性的随机向量。证明：

$$\mathrm{E}\|\boldsymbol{A}\boldsymbol{Z}\|_2^2 = \|\boldsymbol{A}\|_F^2。$$

(3) 设 $\boldsymbol{B} \in \mathbb{R}^{k \times m}$。证明：

$$\|\boldsymbol{B}\boldsymbol{A}\|_F \leqslant \|\boldsymbol{B}\| \cdot \|\boldsymbol{A}\|_F。$$

(4) 设 $\boldsymbol{A}$ 为对角矩阵，证明：(3) 的界限可以被改进为

$$\|\boldsymbol{B}\boldsymbol{A}\|_F \leqslant \|\boldsymbol{B}\|_{1\to 2}\|\boldsymbol{A}\|_F,$$

其中 $\|\boldsymbol{B}\|_{1\to 2} = \max_{1 \leqslant j \leqslant m} \|\boldsymbol{b}_j\|_2$ 为 $\boldsymbol{B}$ 的列向量的 Euclidean 范数的最大值。

证明 (1) 设 $\boldsymbol{A}$ 的奇异值为 $s_1 \geqslant s_2 \geqslant \cdots \geqslant s_r > 0$，则对于左侧，

$$\|\boldsymbol{A}\|_F = \left(\sum_{i=1}^{r} s_i^2\right)^{1/2} \geqslant (s_1^2)^{1/2} = s_1 = \|\boldsymbol{A}\|。$$

对于右侧，

$$\|\boldsymbol{A}\|_F^2 = \sum_{i=1}^{r} s_i^2 \leqslant \sum_{i=1}^{r} s_1^2 = r s_1^2 = r\|\boldsymbol{A}\|^2,$$

即 $\|\boldsymbol{A}\|_F \leqslant \sqrt{r}\|\boldsymbol{A}\|$。

(2) 根据循环不变性 $\operatorname{tr}(\boldsymbol{X}\boldsymbol{Y}) = \operatorname{tr}(\boldsymbol{Y}\boldsymbol{X})$，可得

$$\begin{aligned}
\mathrm{E}\|\boldsymbol{A}\boldsymbol{Z}\|_2^2 &= \mathrm{E}[(\boldsymbol{A}\boldsymbol{Z})^\top(\boldsymbol{A}\boldsymbol{Z})] = \mathrm{E}[\operatorname{tr}(\boldsymbol{Z}^\top\boldsymbol{A}^\top\boldsymbol{A}\boldsymbol{Z})] \\
&= \mathrm{E}[\operatorname{tr}(\boldsymbol{A}^\top\boldsymbol{A}\boldsymbol{Z}\boldsymbol{Z}^\top)] = \operatorname{tr}(\boldsymbol{A}^\top\boldsymbol{A}\mathrm{E}[\boldsymbol{Z}\boldsymbol{Z}^\top]) \\
&= \operatorname{tr}(\boldsymbol{A}^\top\boldsymbol{A}) = \|\boldsymbol{A}\|_F^2。
\end{aligned}$$

(3) 容易知道，

$$\|\boldsymbol{B}\boldsymbol{A}\|_F^2 = \sum_{j=1}^{n} \|\boldsymbol{B}\boldsymbol{a}_j\|_2^2 \leqslant \sum_{j=1}^{n} \|\boldsymbol{B}\|^2\|\boldsymbol{a}_j\|_2^2 = \|\boldsymbol{B}\|^2\left(\sum_{j=1}^{n} \|\boldsymbol{a}_j\|_2^2\right) = \|\boldsymbol{B}\|^2\|\boldsymbol{A}\|_F^2,$$

即 $\|\boldsymbol{B}\boldsymbol{A}\|_F \leqslant \|\boldsymbol{B}\| \cdot \|\boldsymbol{A}\|_F$。

(4) 设 $\boldsymbol{A}=\operatorname{diag}(d_1,\cdots,d_n)$，$\boldsymbol{B}=(\boldsymbol{b}_1,\cdots,\boldsymbol{b}_n)$，则 $\boldsymbol{BA}=(d_1\boldsymbol{b}_1,\cdots,d_n\boldsymbol{b}_n)$，可得

$$\|\boldsymbol{BA}\|_F^2=\sum_{j=1}^n\|d_j\boldsymbol{b}_j\|_2^2=\sum_{j=1}^n d_j^2\|\boldsymbol{b}_j\|_2^2。$$

令 $M=\|\boldsymbol{B}\|_{1\to2}^2=\max_j\|\boldsymbol{b}_j\|_2^2$，则

$$\|\boldsymbol{BA}\|_F^2\leqslant\sum_{j=1}^n d_j^2M=M\sum_{j=1}^n d_j^2=M\cdot\|\boldsymbol{A}\|_F^2,$$

即 $\|\boldsymbol{BA}\|_F\leqslant\|\boldsymbol{B}\|_{1\to2}\|\boldsymbol{A}\|_F$。

5 [奇异值的 Frobenius 范数界限] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的奇异值为 $s_1(\boldsymbol{A})\geqslant\cdots\geqslant s_r(\boldsymbol{A})>0$，其中 $r=\operatorname{rank}(\boldsymbol{A})$。证明：对于任意的 $k\in\{1,\cdots,r\}$，

$$s_k(\boldsymbol{A})\leqslant\frac{\|\boldsymbol{A}\|_F}{\sqrt{k}}。$$

证明 容易知道，

$$\|\boldsymbol{A}\|_F^2=\sum_{i=1}^r s_i(\boldsymbol{A})^2\geqslant\sum_{i=1}^k s_i(\boldsymbol{A})^2=k\cdot s_k(\boldsymbol{A})^2\implies s_k(\boldsymbol{A})\leqslant\frac{\|\boldsymbol{A}\|_F}{\sqrt{k}}。$$

6 [幂法估计算子范数] 幂法是一种于不进行全谱分解的情况估计矩阵算子范数的计算友好型方法。设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 为对称矩阵 (若非对称，则该限制收敛于谱半径 $\rho(\boldsymbol{A})$)，初始向量 $\boldsymbol{x}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。证明：

$$\sqrt[k]{\|\boldsymbol{A}^k\boldsymbol{x}\|_2}\to\|\boldsymbol{A}\|\ (\text{a.s.})。$$

证明 若 $\boldsymbol{A}=\boldsymbol{O}$，则 $\|\boldsymbol{A}\|=0$，结论是平凡的；之后只需考虑 $\boldsymbol{A}\neq\boldsymbol{O}$ 的情况。

由于 $\boldsymbol{A}$ 为对称矩阵，因此存在标准正交基 $\{\boldsymbol{v}_1,\cdots,\boldsymbol{v}_n\}$，其对应的特征值记为 $\lambda_1,\cdots,\lambda_n$。

不妨设 $|\lambda_1|=\cdots=|\lambda_r|>|\lambda_{r+1}|\geqslant\cdots\geqslant|\lambda_n|\geqslant0$，其中 r 为主特征值模长 $|\lambda_1|$ 的重数，则 $\|\boldsymbol{A}\|=|\lambda_1|$。

对 $\boldsymbol{x}$ 于 $\{\boldsymbol{v}_1,\cdots,\boldsymbol{v}_n\}$ 进行正交分解，

$$\boldsymbol{x}=\sum_{i=1}^n\xi_i\boldsymbol{v}_i,\qquad(\xi_i=\langle\boldsymbol{x},\boldsymbol{v}_i\rangle\ \text{i.i.d.}\sim N(0,1))$$

则

$$\boldsymbol{A}^k\boldsymbol{x}=\sum_{i=1}^n\xi_i\lambda_i^k\boldsymbol{v}_i,$$

可得

$$\|\boldsymbol{A}^k\boldsymbol{x}\|_2^2=\sum_{i=1}^n\xi_i^2\lambda_i^{2k}=|\lambda_1|^{2k}\left(\sum_{i=1}^r\xi_i^2+\sum_{i=r+1}^n\xi_i^2\left(\frac{\lambda_i}{\lambda_1}\right)^{2k}\right)。$$

对于右侧，注意到当 $i>r$ 时，$|\lambda_i/\lambda_1|<1$，因此

$$\sum_{i=1}^r\xi_i^2\leqslant\sum_{i=1}^r\xi_i^2+\sum_{i=r+1}^n\xi_i^2\left(\frac{\lambda_i}{\lambda_1}\right)^{2k}\leqslant\sum_{i=1}^n\xi_i^2=\|\boldsymbol{x}\|_2^2,$$

将其代入，之后两侧开 $2k$ 次方，

$$|\lambda_1|\cdot\left(\sum_{i=1}^r\xi_i^2\right)^{\frac{1}{2k}}\leqslant\sqrt[k]{\|\boldsymbol{A}^k\boldsymbol{x}\|_2}\leqslant|\lambda_1|\cdot(\|\boldsymbol{x}\|_2^2)^{\frac{1}{2k}},$$

因此当 $\sum_{i=1}^r\xi_i^2,\|\boldsymbol{x}\|_2^2\neq0$ 时 (概率均为 1)，根据夹逼定理，可得

$$\lim_{k\to\infty}\sqrt[k]{\|\boldsymbol{A}^k\boldsymbol{x}\|_2}=|\lambda_1|=\|\boldsymbol{A}\|\ (\text{a.s.})。$$

7 [算子范数，列向量范数的关系] 矩阵的算子范数通常难以通过其元素显式表达，但可以通过其列向量进行有效的界定。

设 $\boldsymbol{A}=(\boldsymbol{a}_1,\cdots,\boldsymbol{a}_n)\in\mathbb{R}^{m\times n}$。

(1) 证明：

$$\|\boldsymbol{A}\|\geqslant\max_{1\leqslant i\leqslant n}\|\boldsymbol{a}_i\|_2,$$

当且仅当 $\{\boldsymbol{a}_1,\cdots,\boldsymbol{a}_n\}$ 是相互正交的，上述等号成立。

(2) 证明：若存在下标 i，使得 $\|\boldsymbol{A}\|=\|\boldsymbol{a}_i\|_2$，则 $\boldsymbol{a}_i$ 必定正交于其他列向量。

(3) 证明：(1)(2) 的结论对于矩阵的行向量亦成立。

注释 回顾算子范数的单线性定义 (D4.1.8 (算子范数))，

$$\|\boldsymbol{A}\|=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}\|\boldsymbol{A}\boldsymbol{x}\|_2。$$

证明 (1) 令 $\boldsymbol{x}=\boldsymbol{e}_i$，则

$$\|\boldsymbol{A}\|\geqslant\|\boldsymbol{A}\boldsymbol{e}_i\|_2=\|\boldsymbol{a}_i\|_2,$$

两侧取上确界，

$$\|\boldsymbol{A}\|\geqslant\max_{1\leqslant i\leqslant n}\|\boldsymbol{a}_i\|_2。$$

当 $\langle\boldsymbol{a}_i,\boldsymbol{a}_j\rangle=0\ (i\neq j)$ 时，考虑对称矩阵 $\boldsymbol{M}=\boldsymbol{A}^\top\boldsymbol{A}=\operatorname{diag}(\|\boldsymbol{a}_1\|_2^2,\cdots,\|\boldsymbol{a}_n\|_2^2)$，则

$$\|\boldsymbol{A}\|^2=\lambda_{\max}(\boldsymbol{A}^\top\boldsymbol{A})=\max_{1\leqslant i\leqslant n}\|\boldsymbol{a}_i\|_2^2,$$

两侧开方，

$$\|\boldsymbol{A}\|=\max_{1\leqslant i\leqslant n}\|\boldsymbol{a}_i\|_2。$$

(2) 同理于 (1) 的结论，设 k 为 $\boldsymbol{M}$ 的最大特征值的下标，满足

$$M_{kk}=\langle\boldsymbol{a}_k,\boldsymbol{a}_k\rangle=\|\boldsymbol{a}_k\|_2^2=\lambda_{\max}(\boldsymbol{M})。$$

根据 Rayleigh-Ritz 变分原理，对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，满足 $\boldsymbol{x}^\top\boldsymbol{M}\boldsymbol{x}\leqslant\lambda_{\max}(\boldsymbol{M})$，注意到 $\boldsymbol{x}=\boldsymbol{e}_k$ 时，

$$\boldsymbol{e}_k^\top\boldsymbol{M}\boldsymbol{e}_k=M_{kk}=\lambda_{\max}(\boldsymbol{M}),$$

因此 $\boldsymbol{e}_k$ 为 $\boldsymbol{M}$ 对应于最大特征值的特征向量，满足

$$\boldsymbol{m}_k=\boldsymbol{M}\boldsymbol{e}_k=\lambda_{\max}(\boldsymbol{M})\boldsymbol{e}_k=(0\quad\cdots\quad\lambda_{\max}\quad\cdots\quad0)^\top,$$

从而 $M_{ik}=0\ (i\neq k)$，其中 $M_{ik}=\langle\boldsymbol{a}_i,\boldsymbol{a}_k\rangle$，从而 $\boldsymbol{a}_k$ 正交于其他列向量。

(3) 利用习题 Q4.2 (算子范数的基本性质) (2) 的结论，可得 $\|\boldsymbol{A}\|=\|\boldsymbol{A}^\top\|$，因此利用 (1)(2) 的结论，可得：

1. $\|\boldsymbol{A}\|=\|\boldsymbol{A}^\top\|\geqslant\max_j\|\operatorname{row}_j(\boldsymbol{A})\|_2$，当且仅当行向量正交时，取等。
2. 若 $\|\boldsymbol{A}\|$ 等于某个行向量的范数，则其正交于其他行向量。

8 **[Schur 界限]** 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，记 $\boldsymbol{r}_i^\top=\boldsymbol{A}_{i*}$，$\boldsymbol{a}_j=\boldsymbol{A}_{*j}$。证明：

$$\|\boldsymbol{A}\|\leqslant\sqrt{\left(\max_{1\leqslant i\leqslant m}\|\boldsymbol{r}_i\|_1\right)\cdot\left(\max_{1\leqslant j\leqslant n}\|\boldsymbol{a}_j\|_1\right)}。$$

注释 回顾算子范数的双线性形式定义 (D4.1.8 (算子范数))，

$$\|\boldsymbol{A}\|=\sup_{\|\boldsymbol{x}\|_2=1,\|\boldsymbol{y}\|_2=1}\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}。$$

证明 考虑

$$\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}=\sum_{i=1}^m\sum_{j=1}^n a_{ij}y_ix_j,$$

利用绝对值不等式, Cauchy 不等式，可得

$$|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|\leqslant\sum_{i=1}^m\sum_{j=1}^n|a_{ij}|\cdot|y_i|\cdot|x_j|$$

$$= \sum_{i,j} (\sqrt{|a_{ij}|}|y_i|) \cdot (\sqrt{|a_{ij}|}|x_j|)$$

$$\leqslant \left(\sum_{i,j} |a_{ij}| y_i^2 \right)^{1/2} \cdot \left(\sum_{i,j} |a_{ij}| x_j^2 \right)^{1/2},$$

其中

$$\sum_{i=1}^{m} \sum_{j=1}^{n} |a_{ij}| y_i^2 = \sum_{i=1}^{m} y_i^2 \left(\sum_{j=1}^{n} |a_{ij}| \right) = \sum_{i=1}^{m} y_i^2 \|\boldsymbol{r}_i\|_1$$

$$\leqslant \left(\max_{1 \leqslant i \leqslant m} \|\boldsymbol{r}_i\|_1 \right) \sum_{i=1}^{m} y_i^2 = \max_{1 \leqslant i \leqslant m} \|\boldsymbol{r}_i\|_1,$$

$$\sum_{j=1}^{n} \sum_{i=1}^{m} |a_{ij}| x_j^2 = \sum_{j=1}^{n} x_j^2 \left(\sum_{i=1}^{m} |a_{ij}| \right) = \sum_{j=1}^{n} x_j^2 \|\boldsymbol{a}_j\|_1$$

$$\leqslant \left(\max_{1 \leqslant j \leqslant n} \|\boldsymbol{a}_j\|_1 \right) \sum_{j=1}^{n} x_j^2 = \max_{1 \leqslant j \leqslant n} \|\boldsymbol{a}_j\|_1,$$

将其代入，可得

$$|\boldsymbol{y}^\top \boldsymbol{A} \boldsymbol{x}| \leqslant \sqrt{\max_i \|\boldsymbol{r}_i\|_1} \cdot \sqrt{\max_j \|\boldsymbol{a}_j\|_1} = \sqrt{\max_i \|\boldsymbol{r}_i\|_1 \cdot \max_j \|\boldsymbol{a}_j\|_1},$$

两侧取上确界，

$$\|\boldsymbol{A}\| \leqslant \sqrt{\max_i \|\boldsymbol{r}_i\|_1 \cdot \max_j \|\boldsymbol{a}_j\|_1}。$$

9 [**Walsh 矩阵的构造, 正交性**] 为了构造元素绝对值均相等的“最散开”的正交矩阵，我们通过递归方式定义序列 $\{\boldsymbol{W}_k\}$。首先定义 2×2 矩阵，

$$\boldsymbol{W}_1 = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix},$$

之后迭代定义分块矩阵，

$$\boldsymbol{W}_{k+1} = \begin{pmatrix} \boldsymbol{W}_k & \boldsymbol{W}_k \\ \boldsymbol{W}_k & -\boldsymbol{W}_k \end{pmatrix},$$

容易知道，$\boldsymbol{W}_k$ 的阶数为 $n = 2^k$，其元素均为 ± 1。证明：$\boldsymbol{W}_k / \sqrt{n}$ 为正交矩阵。

证明 要证明

$$\left(\frac{1}{\sqrt{n}} \boldsymbol{W}_k \right) \left(\frac{1}{\sqrt{n}} \boldsymbol{W}_k \right)^\top = \boldsymbol{I}_n,$$

只需证明 $\boldsymbol{W}_k \boldsymbol{W}_k^\top = n \boldsymbol{I}_n$。

利用数学归纳法：

a. 当 $k = 1$ 时，

$$\boldsymbol{W}_1 \boldsymbol{W}_1^\top = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 1+1 & 1-1 \\ 1-1 & 1+1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 2\boldsymbol{I}_2。$$

b. 假设当 $k = m$ 时，结论成立，即对于阶数 $n_m = 2^m$，满足

$$\boldsymbol{W}_m \boldsymbol{W}_m^\top = n_m \boldsymbol{I}_{n_m},$$

则当 $k = m + 1$ 时，对于阶数 $n_{m+1} = 2^{m+1} = 2n_m$，

$$\boldsymbol{W}_{m+1} \boldsymbol{W}_{m+1}^\top = \begin{pmatrix} \boldsymbol{W}_m & \boldsymbol{W}_m \\ \boldsymbol{W}_m & -\boldsymbol{W}_m \end{pmatrix} \begin{pmatrix} \boldsymbol{W}_m^\top & \boldsymbol{W}_m^\top \\ \boldsymbol{W}_m^\top & -\boldsymbol{W}_m^\top \end{pmatrix}$$

$$= \begin{pmatrix} \boldsymbol{W}_m\boldsymbol{W}_m^\top + \boldsymbol{W}_m\boldsymbol{W}_m^\top & \boldsymbol{W}_m\boldsymbol{W}_m^\top - \boldsymbol{W}_m\boldsymbol{W}_m^\top \\ \boldsymbol{W}_m\boldsymbol{W}_m^\top - \boldsymbol{W}_m\boldsymbol{W}_m^\top & \boldsymbol{W}_m\boldsymbol{W}_m^\top + \boldsymbol{W}_m\boldsymbol{W}_m^\top \end{pmatrix}$$

$$= \begin{pmatrix} 2n_m\boldsymbol{I}_{n_m} & \boldsymbol{O} \\ \boldsymbol{O} & 2n_m\boldsymbol{I}_{n_m} \end{pmatrix} = 2n_m \begin{pmatrix} \boldsymbol{I}_{n_m} & \boldsymbol{O} \\ \boldsymbol{O} & \boldsymbol{I}_{n_m} \end{pmatrix} = 2^{m+1}\boldsymbol{I}_{n_{m+1}}。$$

10 [元素为 ±1 的矩阵范数界限] 设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 满足 $a_{ij} \in \{-1, 1\}$。证明：

$$\sqrt{n} \leqslant \|\boldsymbol{A}\| \leqslant n,$$

之后说明对于无穷多个 n，上述界限均是可达的。之后在练习 Q4.18 ($p \to q$ 算子范数), Q4.19 ($1 \to \infty$ 与 $1 \to 2$ 算子范数的显式表示) 中，我们将探讨 $1 \to 2$ 范数, 一般的 $p \to q$ 范数。

证明 容易知道，

$$\|\boldsymbol{A}\|_F = \left(\sum_{i=1}^n\sum_{j=1}^n a_{ij}^2\right)^{1/2} = \left(\sum_{i=1}^n\sum_{j=1}^n 1\right)^{1/2} = n。$$

- 证明上界 $\|\boldsymbol{A}\| \leqslant n$

  根据引理 L4.4.1 (于离散网估计算子范数)，可得

  $$\|\boldsymbol{A}\| \leqslant \|\boldsymbol{A}\|_F = n。$$

  对于取等情况，令 $\boldsymbol{A}$ 为全 1 矩阵 (或任意的秩为 1 且元素为 ±1 的矩阵，例如 $\boldsymbol{x}\boldsymbol{y}^\top$，其中 $x_i, y_j \in \{-1, 1\}$)，令单位向量 $\boldsymbol{u} = (1, 1, \cdots, 1)^\top/\sqrt{n}$，则

  $$\boldsymbol{A}\boldsymbol{u} = \frac{1}{\sqrt{n}}(n, n, \cdots, n)^\top = \sqrt{n}(1, 1, \cdots, 1)^\top,$$

  因此对于任意的 $n \geqslant 1$，

  $$\|\boldsymbol{A}\boldsymbol{u}\|_2 = \sqrt{n \cdot n} = n。$$

- 证明下界 $\|\boldsymbol{A}\| \geqslant \sqrt{n}$

  设 $\boldsymbol{A}$ 的奇异值为 $s_1 \geqslant \cdots \geqslant s_n \geqslant 0$，则 $\|\boldsymbol{A}\| = s_1$，因此

  $$n^2 = \|\boldsymbol{A}\|_F^2 = \sum_{i=1}^n s_i^2 \leqslant ns_1^2 = n\|\boldsymbol{A}\|^2 \implies \|\boldsymbol{A}\| \geqslant \sqrt{n}。$$

  对于取等情况，令 $s_1^2 = \cdots = s_n^2 = n$，则 $\boldsymbol{A}^\top\boldsymbol{A} = n\boldsymbol{I}_n$ (即 $\boldsymbol{A}$ 的向量组是相互正交的)，此时 $\boldsymbol{A}$ 为 Hadamard 矩阵。

  根据习题 Q4.9 (Walsh 矩阵的构造, 正交性)，可得

  $$\boldsymbol{W}_k^\top\boldsymbol{W}_k = n\boldsymbol{I}_n, \qquad (n = 2^k)$$

  因此对于任意的 $n = 2^k$，令 $\boldsymbol{A} = \boldsymbol{W}_k$。

注释 上界对应于分量高度相关的“最不均匀”情况 (秩为 1)，而下界对应于分量完全正交的“最均匀”情况 (Hadamard 矩阵)。

11 [正交投影算子之差的范数] 设 $\boldsymbol{P}, \boldsymbol{Q} \in \mathbb{R}^{n\times n}$ 为正交投影矩阵。证明：算子之差的算子范数 (谱范数) 满足

$$\|\boldsymbol{P} - \boldsymbol{Q}\| \leqslant 1。$$

注释 根据 Loewner 偏序，可得 $\boldsymbol{O} \preccurlyeq \boldsymbol{P}, \boldsymbol{Q} \preccurlyeq \boldsymbol{I}_n$，因此

$$-\boldsymbol{I}_n \preccurlyeq \boldsymbol{P} - \boldsymbol{Q} \preccurlyeq \boldsymbol{I}_n。$$

由于 $\boldsymbol{P} - \boldsymbol{Q}$ 为对称矩阵，上述 Loewner 偏序说明其特征值满足 $\mu \in [-1, 1]$，可得

$$\|\boldsymbol{P} - \boldsymbol{Q}\| = \max_i |\mu_i| \leqslant 1。$$

12 [正交投影算子之差, 乘积的范数关系] 设 $\boldsymbol{P}, \boldsymbol{Q} \in \mathbb{R}^{n\times n}$ 为正交投影矩阵，分别对应于子空间 U, V。记 $\boldsymbol{P}_\perp = \boldsymbol{I}_n - \boldsymbol{P}$ 为向 $U^\perp$ 的正交投影，$\boldsymbol{Q}_\perp = \boldsymbol{I}_n - \boldsymbol{Q}$ 为向 $V^\perp$ 的正交投影。证明：

(1) (范数的极大值等价性)

$$\|\boldsymbol{P} - \boldsymbol{Q}\| = \max(\|\boldsymbol{P}_\perp\boldsymbol{Q}\|, \|\boldsymbol{P}\boldsymbol{Q}_\perp\|)。$$

(2) (秩不等时范数为 1) 若 $\operatorname{rank}(\boldsymbol{P}) \neq \operatorname{rank}(\boldsymbol{Q})$，则

$$\|\boldsymbol{P}-\boldsymbol{Q}\| = 1。$$

(3) (秩相等时三者等价) 若 $\operatorname{rank}(\boldsymbol{P}) = \operatorname{rank}(\boldsymbol{Q})$，则

$$\|\boldsymbol{P}-\boldsymbol{Q}\| = \|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \|\boldsymbol{P}\boldsymbol{Q}_\perp\|。$$

证明 (1) 注意到 $\boldsymbol{I}_n = \boldsymbol{P}+\boldsymbol{P}_\perp = \boldsymbol{Q}+\boldsymbol{Q}_\perp$，因此

$$\begin{aligned}\boldsymbol{P}-\boldsymbol{Q} &= \boldsymbol{P}(\boldsymbol{Q}+\boldsymbol{Q}_\perp)-(\boldsymbol{P}+\boldsymbol{P}_\perp)\boldsymbol{Q}\\ &= \boldsymbol{P}\boldsymbol{Q}+\boldsymbol{P}\boldsymbol{Q}_\perp-\boldsymbol{P}\boldsymbol{Q}-\boldsymbol{P}_\perp\boldsymbol{Q}\\ &= \boldsymbol{P}\boldsymbol{Q}_\perp-\boldsymbol{P}_\perp\boldsymbol{Q},\end{aligned}$$

令 $\boldsymbol{A} = \boldsymbol{P}\boldsymbol{Q}_\perp$，$\boldsymbol{B} = -\boldsymbol{P}_\perp\boldsymbol{Q}$，则 $\boldsymbol{P}-\boldsymbol{Q} = \boldsymbol{A}+\boldsymbol{B}$。

对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，由于

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{P}(\boldsymbol{Q}_\perp\boldsymbol{x})\in\operatorname{Range}(\boldsymbol{P})，\ \boldsymbol{B}\boldsymbol{x} = -\boldsymbol{P}_\perp(\boldsymbol{Q}\boldsymbol{x})\in\operatorname{Range}(\boldsymbol{P}_\perp)。$$

因此

$$\|(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{x}\|_2^2 = \|\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{x}\|_2^2 = \|\boldsymbol{A}\boldsymbol{x}\|_2^2+\|\boldsymbol{B}\boldsymbol{x}\|_2^2。\tag{I}$$

- 证明上界 (定义域正交分解)

  对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，注意到 $\mathbb{R}^n = \operatorname{Range}(\boldsymbol{Q})\oplus\operatorname{Range}(\boldsymbol{Q}_\perp)$，将其唯一分解为

  $$\boldsymbol{x} = \boldsymbol{x}_Q+\boldsymbol{x}_{Q_\perp},$$

  其中 $\boldsymbol{x}_Q\in\operatorname{Range}(\boldsymbol{Q}),\boldsymbol{x}_{Q_\perp}\in\operatorname{Range}(\boldsymbol{Q}_\perp)$，满足 $\|\boldsymbol{x}\|_2^2 = \|\boldsymbol{x}_Q\|_2^2+\|\boldsymbol{x}_{Q_\perp}\|_2^2 = 1$，则

  $$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{x}_{Q_\perp}，\ \boldsymbol{B}\boldsymbol{x} = \boldsymbol{B}\boldsymbol{x}_Q,$$

  将其代入于 (I)，可得

  $$\begin{aligned}\|(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{x}\|_2^2 &= \|\boldsymbol{A}\boldsymbol{x}_{Q_\perp}\|_2^2+\|\boldsymbol{B}\boldsymbol{x}_Q\|_2^2\\ &\leqslant \|\boldsymbol{A}\|^2\|\boldsymbol{x}_{Q_\perp}\|_2^2+\|\boldsymbol{B}\|^2\|\boldsymbol{x}_Q\|_2^2\\ &\leqslant \max(\|\boldsymbol{A}\|^2,\|\boldsymbol{B}\|^2)\cdot(\|\boldsymbol{x}_{Q_\perp}\|_2^2+\|\boldsymbol{x}_Q\|_2^2)\\ &= \max(\|\boldsymbol{P}\boldsymbol{Q}_\perp\|^2,\|\boldsymbol{P}_\perp\boldsymbol{Q}\|^2),\end{aligned}$$

  两侧对 $\boldsymbol{x}$ 取上确界，之后开方，

  $$\|\boldsymbol{P}-\boldsymbol{Q}\|\leqslant\max(\|\boldsymbol{P}\boldsymbol{Q}_\perp\|,\|\boldsymbol{P}_\perp\boldsymbol{Q}\|)。\tag{II}$$

- 证明下界 (构造极值向量取等)

  对于 $\|\boldsymbol{P}\boldsymbol{Q}_\perp\|$，令 $\boldsymbol{u}\in\operatorname{Range}(\boldsymbol{Q}_\perp)\cap\mathbb{S}^{n-1}$，满足 $\|\boldsymbol{A}\boldsymbol{u}\|_2 = \|\boldsymbol{A}\| = \|\boldsymbol{P}\boldsymbol{Q}_\perp\|$，则 $\boldsymbol{u}_Q = \boldsymbol{0}$，将其代入于 (I)，可得

  $$\|(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{u}\|_2^2 = \|\boldsymbol{A}\boldsymbol{u}\|_2^2+\|\boldsymbol{B}\boldsymbol{0}\|_2^2 = \|\boldsymbol{P}\boldsymbol{Q}_\perp\|^2。$$

  因此根据定义 4.1.8，可得

  $$\|\boldsymbol{P}-\boldsymbol{Q}\|\geqslant\|(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{u}\|_2 = \|\boldsymbol{P}\boldsymbol{Q}_\perp\|。$$

  对于 $\|\boldsymbol{P}_\perp\boldsymbol{Q}\|$，令 $\boldsymbol{w}\in\operatorname{Range}(\boldsymbol{Q})\cap\mathbb{S}^{n-1}$，满足 $\|\boldsymbol{B}\boldsymbol{w}\|_2 = \|\boldsymbol{B}\| = \|\boldsymbol{P}_\perp\boldsymbol{Q}\|$，则 $\boldsymbol{w}_{Q_\perp} = \boldsymbol{0}$，因此

  $$\|\boldsymbol{P}-\boldsymbol{Q}\|\geqslant\|(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{w}\|_2 = \|\boldsymbol{P}_\perp\boldsymbol{Q}\|。$$

  如此，

  $$\|\boldsymbol{P}-\boldsymbol{Q}\|\geqslant\max(\|\boldsymbol{P}\boldsymbol{Q}_\perp\|,\|\boldsymbol{P}_\perp\boldsymbol{Q}\|)。\tag{III}$$

  综上，联立 (II)(III)，可得

  $$\|\boldsymbol{P}-\boldsymbol{Q}\| = \max(\|\boldsymbol{P}\boldsymbol{Q}_\perp\|,\|\boldsymbol{P}_\perp\boldsymbol{Q}\|)。$$

(2) 设 $\operatorname{rank}(\boldsymbol{P}) = \dim(U) = d_1$，$\operatorname{rank}(\boldsymbol{Q}) = \dim(V) = d_2$，不妨设 $d_1 > d_2$，则

$$\dim(U\cap V^\perp)\geqslant\dim(U)+\dim(V^\perp)-n = d_1+(n-d_2)-n = d_1-d_2>0,$$

因此存在单位向量 $\boldsymbol{u}\in U\cap V^\perp$，使得 $\boldsymbol{P}\boldsymbol{u} = \boldsymbol{u}$，$\boldsymbol{Q}\boldsymbol{u} = \boldsymbol{0}$，从而

$$(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{u} = \boldsymbol{P}\boldsymbol{u}-\boldsymbol{Q}\boldsymbol{u} = \boldsymbol{u}-\boldsymbol{0} = \boldsymbol{u},$$

从而

$$\|\boldsymbol{P}-\boldsymbol{Q}\| \geqslant \|\boldsymbol{u}\|_2 = 1。$$

根据习题 Q4.11 (正交投影算子之差的范数)，可得 $\|\boldsymbol{P}-\boldsymbol{Q}\| \leqslant 1$，因此 $\|\boldsymbol{P}-\boldsymbol{Q}\| = 1$。

(3) 当 $\operatorname{rank}(\boldsymbol{P}) = \operatorname{rank}(\boldsymbol{Q})$ 时，$\dim(U) = \dim(V)$，此时考虑算子 $\boldsymbol{P}_\perp\boldsymbol{Q}$。**版本一　变分几何法**

- 明确动机与目标

  根据算子范数的定义 4.1.8，可得

  $$\|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \sup_{\boldsymbol{v}\in V, \|\boldsymbol{v}\|_2=1} \|\boldsymbol{P}_\perp\boldsymbol{v}\|_2。$$

  因为 $\boldsymbol{Q}$ 是向子空间 V 的正交投影，所以对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，$\boldsymbol{Q}\boldsymbol{x}$ 是 V 的向量。求 $\|\boldsymbol{P}_\perp\boldsymbol{Q}\|$ 等价于在 V 的所有单位向量中，寻找被 $\boldsymbol{P}_\perp$ 投影后模长最大的那一个。
- 利用勾股定理将正交补转化为主空间投影

  对于 V 的任意单位向量 $\boldsymbol{v}$ (满足 $\|\boldsymbol{v}\|_2 = 1$)，向量 $\boldsymbol{v}$ 可以正交分解为向 U 的投影 $\boldsymbol{P}\boldsymbol{v}$, 向 $U^\perp$ 的投影 $\boldsymbol{P}_\perp\boldsymbol{v}$。根据勾股定理，可得

  $$\|\boldsymbol{P}_\perp\boldsymbol{v}\|_2^2 = \|\boldsymbol{v}\|_2^2 - \|\boldsymbol{P}\boldsymbol{v}\|_2^2 = 1 - \|\boldsymbol{P}\boldsymbol{v}\|_2^2,$$

  因此想让 $\|\boldsymbol{P}_\perp\boldsymbol{v}\|_2$ 最大，等价于让 $\|\boldsymbol{P}\boldsymbol{v}\|_2$ 最小。
- 与主夹角自然对接

  根据 U, V 之间主夹角 $\theta_1 \leqslant \cdots \leqslant \theta_d = \theta_{\max}$ 的几何定义，V 的单位向量向 U 投影的模长范围恰好为 $[\cos\theta_{\max}, \cos\theta_1]$，其中

  $$\min_{\boldsymbol{v}\in V, \|\boldsymbol{v}\|_2=1} \|\boldsymbol{P}\boldsymbol{v}\|_2 = \cos\theta_{\max}。$$

  将其代入勾股定理关系式，可得

  $$\|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \sup_{\boldsymbol{v}\in V, \|\boldsymbol{v}\|_2=1} \sqrt{1-\|\boldsymbol{P}\boldsymbol{v}\|_2^2} = \sqrt{1-\left(\min_{\boldsymbol{v}\in V, \|\boldsymbol{v}\|_2=1} \|\boldsymbol{P}\boldsymbol{v}\|_2\right)^2} = \sqrt{1-\cos^2\theta_{\max}} = \sin\theta_{\max}。$$

版本二　主正交基 / CS 分解法

- 主正交基与配对的投影关系

  根据子空间主夹角理论，于子空间 U, V 分别存在一组标准正交基 $\{\boldsymbol{u}_1, \cdots, \boldsymbol{u}_d\}$, $\{\boldsymbol{v}_1, \cdots, \boldsymbol{v}_d\}$，使得它们满足两两配对的投影关系

  $$\boldsymbol{P}\boldsymbol{v}_i = \cos\theta_i\boldsymbol{u}_i, \quad i = 1, \cdots, d。$$
- 算子 $\boldsymbol{P}_\perp\boldsymbol{Q}$ 于基向量上的几何效果

  考察算子 $\boldsymbol{P}_\perp\boldsymbol{Q}$ 作用于基向量 $\boldsymbol{v}_i$ 的几何效果：

  $$\boldsymbol{P}_\perp\boldsymbol{Q}\boldsymbol{v}_i = \boldsymbol{P}_\perp\boldsymbol{v}_i = \boldsymbol{v}_i - \boldsymbol{P}\boldsymbol{v}_i = \boldsymbol{v}_i - \cos\theta_i\boldsymbol{u}_i。$$

  计算这一残差向量的模长平方 (由于 $\langle\boldsymbol{v}_i, \boldsymbol{u}_i\rangle = \cos\theta_i$)，可得

  $$\|\boldsymbol{P}_\perp\boldsymbol{v}_i\|_2^2 = \|\boldsymbol{v}_i\|_2^2 - 2\cos\theta_i\langle\boldsymbol{v}_i, \boldsymbol{u}_i\rangle + \cos^2\theta_i\|\boldsymbol{u}_i\|_2^2 = 1 - 2\cos^2\theta_i + \cos^2\theta_i = 1 - \cos^2\theta_i = \sin^2\theta_i。$$
- 非零奇异值与算子范数

  因为各主方向彼此正交，算子 $\boldsymbol{P}_\perp\boldsymbol{Q}$ 将基底 $\{\boldsymbol{v}_i\}$ 映射为一组长度分别为 $\sin\theta_i$ 的正交向量系。因此，$\boldsymbol{P}_\perp\boldsymbol{Q}$ 的非零奇异值集合恰为 $\{\sin\theta_1, \cdots, \sin\theta_d\}$，其算子范数由最大主夹角决定：

  $$\|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \max_{1\leqslant i\leqslant d} \sin\theta_i = \sin\theta_{\max}。$$
- 对偶对称性与结论综合

根据算子范数的转置不变性，可得

$$\|\boldsymbol{P}\boldsymbol{Q}_\perp\| = \|(\boldsymbol{P}\boldsymbol{Q}_\perp)^\top\| = \|\boldsymbol{Q}_\perp\boldsymbol{P}\|。$$

由于 $\dim(U) = \dim(V)$，交换 U, V 的角色，主夹角保持不变，同理可得

$$\|\boldsymbol{Q}_\perp\boldsymbol{P}\| = \sin\theta_{\max}。$$

于是结合 $\|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \sin\theta_{\max}$，可得

$$\|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \|\boldsymbol{P}\boldsymbol{Q}_\perp\| = \sin\theta_{\max}。$$

结合 (1) 的结论 $\|\boldsymbol{P}-\boldsymbol{Q}\| = \max(\|\boldsymbol{P}\boldsymbol{Q}_\perp\|, \|\boldsymbol{P}_\perp\boldsymbol{Q}\|)$，可得

$$\|\boldsymbol{P}-\boldsymbol{Q}\| = \|\boldsymbol{P}_\perp\boldsymbol{Q}\| = \|\boldsymbol{P}\boldsymbol{Q}_\perp\| = \sin\theta_{\max}。$$

13 [**谱投影的 Davis-Kahan 定理**] 本题旨在证明定理 T4.1.15 (Davis–Kahan 不等式) 的一个变体，即针对前 k 个特征向量所构成的子空间的扰动界限。

设 $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n\times n}$ 为对称矩阵，其谱分解分别表示为

$$\boldsymbol{A} = \sum_{i=1}^{n} \lambda_i \boldsymbol{u}_i\boldsymbol{u}_i^\top,\quad \boldsymbol{B} = \sum_{i=1}^{n} \mu_i \boldsymbol{v}_i\boldsymbol{v}_i^\top,$$

其中 $\lambda_1 \geqslant \cdots \geqslant \lambda_n$，$\mu_1 \geqslant \cdots \geqslant \mu_n$，并取 $1 \leqslant k < n$。

定义前 k 个特征值对应的谱投影算子 (Spectral Projections) 分别为

$$\boldsymbol{P}_A = \sum_{i=1}^{k} \boldsymbol{u}_i\boldsymbol{u}_i^\top,\quad \boldsymbol{P}_B = \sum_{i=1}^{k} \boldsymbol{v}_i\boldsymbol{v}_i^\top,$$

证明：若 $\lambda_k > \lambda_{k+1}$，则投影算子之差的算子范数满足

$$\|\boldsymbol{P}_A - \boldsymbol{P}_B\| \leqslant \frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{\lambda_k - \lambda_{k+1}}。$$

证明　解法一　Weyl 摄动法

- 建立残差算子的 Sylvester 方程

  记扰动矩阵 $\boldsymbol{E} = \boldsymbol{A}-\boldsymbol{B}$；记 $\boldsymbol{P}_A^\perp = \boldsymbol{I}_n - \boldsymbol{P}_A$ 为向 $\boldsymbol{A}$ 的剩余特征空间的投影。考虑算子乘积 $\boldsymbol{P}_A^\perp\boldsymbol{E}\boldsymbol{P}_B$，

  $$\boldsymbol{P}_A^\perp\boldsymbol{E}\boldsymbol{P}_B = \boldsymbol{P}_A^\perp(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{P}_B = \boldsymbol{P}_A^\perp\boldsymbol{A}\boldsymbol{P}_B - \boldsymbol{P}_A^\perp\boldsymbol{B}\boldsymbol{P}_B。$$

  由于 $\boldsymbol{A}$ 与自身的主谱投影 $\boldsymbol{P}_A$ 对易，因此 $\boldsymbol{P}_A^\perp\boldsymbol{A} = \boldsymbol{P}_A^\perp\boldsymbol{A}\boldsymbol{P}_A^\perp$；由于 $\boldsymbol{B}$ 与自身的主谱投影 $\boldsymbol{P}_B$ 对易，因此 $\boldsymbol{B}\boldsymbol{P}_B = \boldsymbol{P}_B\boldsymbol{B}\boldsymbol{P}_B$。

  代入上式，令 $\boldsymbol{A}_2 = \boldsymbol{P}_A^\perp\boldsymbol{A}\boldsymbol{P}_A^\perp$，$\boldsymbol{B}_1 = \boldsymbol{P}_B\boldsymbol{B}\boldsymbol{P}_B$，$\boldsymbol{Y} = \boldsymbol{P}_A^\perp\boldsymbol{P}_B$，可得 Sylvester 方程

  $$\boldsymbol{A}_2\boldsymbol{Y} - \boldsymbol{Y}\boldsymbol{B}_1 = \boldsymbol{P}_A^\perp\boldsymbol{E}\boldsymbol{P}_B。$$

- 利用谱间隔下界估计算子范数

  考察两矩阵在相应子空间上的谱范围：将 $\boldsymbol{A}_2$ 看作 $\mathrm{Range}(\boldsymbol{P}_A^\perp)$ 上的压缩，将 $\boldsymbol{B}_1$ 看作 $\mathrm{Range}(\boldsymbol{P}_B)$ 上的压缩，则 $\boldsymbol{A}_2$ 的特征值为 $\{\lambda_{k+1}, \cdots, \lambda_n\}$，$\boldsymbol{B}_1$ 的特征值为 $\{\mu_1, \cdots, \mu_k\}$。因此 $\boldsymbol{A}_2 \preccurlyeq \lambda_{k+1}\boldsymbol{I}$ 且 $\boldsymbol{B}_1 \succcurlyeq \mu_k\boldsymbol{I}$，其中单位算子分别作用于这两个子空间。

  若 $\mu_k > \lambda_{k+1}$，则两矩阵的谱间隔为 $\mu_k - \lambda_{k+1} > 0$。根据 Sylvester 算子的逆估计 (Bhatia-Davis 引理)，可得

  $$\|\boldsymbol{A}_2\boldsymbol{Y} - \boldsymbol{Y}\boldsymbol{B}_1\| \geqslant (\mu_k - \lambda_{k+1})\|\boldsymbol{Y}\|。$$

  结合右端放缩，可得

  $$(\mu_k - \lambda_{k+1})\|\boldsymbol{Y}\| \leqslant \|\boldsymbol{P}_A^\perp\boldsymbol{E}\boldsymbol{P}_B\| \leqslant \|\boldsymbol{P}_A^\perp\| \cdot \|\boldsymbol{E}\| \cdot \|\boldsymbol{P}_B\| \leqslant \|\boldsymbol{A}-\boldsymbol{B}\|,$$

  由于 $\mathrm{rank}(\boldsymbol{P}_A) = \mathrm{rank}(\boldsymbol{P}_B) = k$，利用习题 Q4.12 (正交投影算子之差, 乘积的范数关系) (3) 的结论，可得

  $$\|\boldsymbol{Y}\| = \|\boldsymbol{P}_A^\perp\boldsymbol{P}_B\| = \|\boldsymbol{P}_A - \boldsymbol{P}_B\|,$$

  由此可得条件扰动界 (当 $\mu_k > \lambda_{k+1}$ 时)

  $$\|\boldsymbol{P}_A - \boldsymbol{P}_B\| \leqslant \frac{\|\boldsymbol{A}-\boldsymbol{B}\|}{\mu_k - \lambda_{k+1}}。$$

- 应用 Weyl 特征值不等式进行分情况闭环

记 $\delta=\lambda_k-\lambda_{k+1}$。根据 Weyl 特征值扰动定理，矩阵 $\boldsymbol{B}$ 的第 k 个特征值满足 $|\mu_k-\lambda_k|\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|$，因此

$$\mu_k\geqslant\lambda_k-\|\boldsymbol{A}-\boldsymbol{B}\|,$$

两侧同时减去 λ_{k+1}，可得

$$\mu_k-\lambda_{k+1}\geqslant(\lambda_k-\lambda_{k+1})-\|\boldsymbol{A}-\boldsymbol{B}\|=\delta-\|\boldsymbol{A}-\boldsymbol{B}\|。$$

a. 小扰动 ($\|\boldsymbol{A}-\boldsymbol{B}\|\leqslant\frac{1}{2}\delta$)：此时分母满足

$$\mu_k-\lambda_{k+1}\geqslant\delta-\frac{1}{2}\delta=\frac{1}{2}\delta>0,$$

将其代入条件扰动界，可得

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\frac{\|\boldsymbol{A}-\boldsymbol{B}\|}{\frac{1}{2}\delta}=\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{\lambda_k-\lambda_{k+1}}。$$

b. 大扰动 ($\|\boldsymbol{A}-\boldsymbol{B}\|>\frac{1}{2}\delta$)：此时右端项本身已大于 1，

$$\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{\lambda_k-\lambda_{k+1}}>\frac{2\cdot(\frac{1}{2}\delta)}{\delta}=1,$$

而任意两个正交投影算子之差的算子范数恒满足平凡上界

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\max(\|\boldsymbol{P}_A\|,\|\boldsymbol{P}_B\|)=1,$$

因此不等式成立

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant1<\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{\lambda_k-\lambda_{k+1}}。$$

于是，对于满足 $\lambda_k>\lambda_{k+1}$ 的对称矩阵 $\boldsymbol{A},\boldsymbol{B}$，可得

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{\lambda_k-\lambda_{k+1}}。$$

补充：交换子估计

- 构造并分解交换子

定义交换子 $\boldsymbol{R}=\boldsymbol{A}\boldsymbol{P}_B-\boldsymbol{P}_B\boldsymbol{A}$，将其展开，

$$\boldsymbol{R}=\boldsymbol{A}\boldsymbol{P}_B-\boldsymbol{P}_B\boldsymbol{B}+\boldsymbol{P}_B\boldsymbol{B}-\boldsymbol{P}_B\boldsymbol{A}=(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{P}_B+\boldsymbol{P}_B(\boldsymbol{B}-\boldsymbol{A}),$$

因此利用三角不等式，代入 $\|\boldsymbol{P}_B\|=1$，可得

$$\|\boldsymbol{R}\|\leqslant\|(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{P}_B\|+\|\boldsymbol{P}_B(\boldsymbol{B}-\boldsymbol{A})\|\leqslant2\|\boldsymbol{A}-\boldsymbol{B}\|。\tag{I}$$

记 $\boldsymbol{P}_A^\perp=\boldsymbol{I}_n-\boldsymbol{P}_A$ 为向 $\boldsymbol{A}$ 的剩余特征空间 (第 $k+1$ 到 n 个特征向量) 的投影，将 $\boldsymbol{R}$ 限制于 $\mathrm{Range}(\boldsymbol{P}_A),\mathrm{Range}(\boldsymbol{P}_A^\perp)$ 之间，

$$\begin{aligned}\boldsymbol{P}_A\boldsymbol{R}\boldsymbol{P}_A^\perp&=\boldsymbol{P}_A(\boldsymbol{A}\boldsymbol{P}_B-\boldsymbol{P}_B\boldsymbol{A})\boldsymbol{P}_A^\perp\\&=(\boldsymbol{P}_A\boldsymbol{A}\boldsymbol{P}_A)(\boldsymbol{P}_A\boldsymbol{P}_B\boldsymbol{P}_A^\perp)-(\boldsymbol{P}_A\boldsymbol{P}_B\boldsymbol{P}_A^\perp)(\boldsymbol{P}_A^\perp\boldsymbol{A}\boldsymbol{P}_A^\perp),\end{aligned}$$

令 $\boldsymbol{A}_1=\boldsymbol{P}_A\boldsymbol{A}\boldsymbol{P}_A$ (其特征值为 $\lambda_1,\cdots,\lambda_k$)，$\boldsymbol{A}_2=\boldsymbol{P}_A^\perp\boldsymbol{A}\boldsymbol{P}_A^\perp$ (其特征值为 $\lambda_{k+1},\cdots,\lambda_n$)，$\boldsymbol{X}=\boldsymbol{P}_A\boldsymbol{P}_B\boldsymbol{P}_A^\perp$，则

$$\boldsymbol{A}_1\boldsymbol{X}-\boldsymbol{X}\boldsymbol{A}_2=\boldsymbol{P}_A\boldsymbol{R}\boldsymbol{P}_A^\perp,\tag{II}$$

即为 Sylvester 方程。

- 估计交换子分块

之后考虑线性算子 $T(\boldsymbol{X})=\boldsymbol{A}_1\boldsymbol{X}-\boldsymbol{X}\boldsymbol{A}_2$，其特征值为 $\{\lambda_i-\lambda_j\}_{i\in\{1,\cdots,k\},j\in\{k+1,\cdots,n\}}$。

由于特征值是降序排列的，因此

$$\min_{i\leqslant k,j>k}(\lambda_i-\lambda_j)=\lambda_k-\lambda_{k+1},$$

将其代入于 (II)，可得

$$\|\boldsymbol{P}_A\boldsymbol{R}\boldsymbol{P}_A^\perp\|=\|\boldsymbol{A}_1\boldsymbol{X}-\boldsymbol{X}\boldsymbol{A}_2\|\geqslant(\lambda_k-\lambda_{k+1})\|\boldsymbol{X}\|。\tag{III}$$

由于

$$\boldsymbol{X} = -\boldsymbol{P}_A \boldsymbol{P}_B^{\perp} \boldsymbol{P}_A^{\perp},$$

利用习题 Q4.12 (正交投影算子之差, 乘积的范数关系) (3) 的结论，可得

$$\begin{aligned} \|\boldsymbol{X}\| &\leqslant \|\boldsymbol{P}_A \boldsymbol{P}_B^{\perp}\| \\ &= \|\boldsymbol{P}_A - \boldsymbol{P}_B\|。 \end{aligned}$$

联立 (I)(III)，可得

$$(\lambda_k - \lambda_{k+1})\|\boldsymbol{X}\| \leqslant 2\|\boldsymbol{A} - \boldsymbol{B}\|。$$

14 [**Hermitian 扩张的谱性质**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$。为了利用对称矩阵的性质研究 $\boldsymbol{A}$，一种常用的方法是构造其 Hermitian 扩张。定义分块对称矩阵 $\boldsymbol{H} \in \mathbb{R}^{(m+n)\times(m+n)}$

$$\boldsymbol{H} = \begin{pmatrix} \boldsymbol{O} & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{O} \end{pmatrix},$$

设 $\boldsymbol{A}$ 的 SVD 为 $\boldsymbol{A} = \sum_i s_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}$，其中 $s_i > 0$ 为奇异值，$\boldsymbol{u}_i \in \mathbb{R}^m, \boldsymbol{v}_i \in \mathbb{R}^n$ 分别为对应的左, 右奇异向量。
证明：$\boldsymbol{H}$ 的所有非零特征值恰好为 $\pm s_i$，并且对应的特征向量为

$$\boldsymbol{w}_i^{(\pm)} = \begin{pmatrix} \boldsymbol{u}_i \\ \pm \boldsymbol{v}_i \end{pmatrix}。$$

证明 容易知道，

$$\boldsymbol{A}\boldsymbol{v}_i = s_i \boldsymbol{u}_i, \quad \boldsymbol{A}^{\top}\boldsymbol{u}_i = s_i \boldsymbol{v}_i,$$

之后只需验证 $\boldsymbol{H}\boldsymbol{w} = \lambda \boldsymbol{w}$。
对于正, 负特征值 $\pm s_i$，分别考虑

$$\boldsymbol{w}_i^{(+)} = \begin{pmatrix} \boldsymbol{u}_i \\ \boldsymbol{v}_i \end{pmatrix}, \quad \boldsymbol{w}_i^{(-)} = \begin{pmatrix} \boldsymbol{u}_i \\ -\boldsymbol{v}_i \end{pmatrix},$$

由于

$$\begin{aligned} \boldsymbol{H}\boldsymbol{w}_i^{(+)} &= \begin{pmatrix} \boldsymbol{O} & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{O} \end{pmatrix} \begin{pmatrix} \boldsymbol{u}_i \\ \boldsymbol{v}_i \end{pmatrix} = \begin{pmatrix} \boldsymbol{A}\boldsymbol{v}_i \\ \boldsymbol{A}^{\top}\boldsymbol{u}_i \end{pmatrix} \\ &= \begin{pmatrix} s_i \boldsymbol{u}_i \\ s_i \boldsymbol{v}_i \end{pmatrix} = s_i \begin{pmatrix} \boldsymbol{u}_i \\ \boldsymbol{v}_i \end{pmatrix} = s_i \boldsymbol{w}_i^{(+)}, \\ \boldsymbol{H}\boldsymbol{w}_i^{(-)} &= \begin{pmatrix} \boldsymbol{O} & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{O} \end{pmatrix} \begin{pmatrix} \boldsymbol{u}_i \\ -\boldsymbol{v}_i \end{pmatrix} = \begin{pmatrix} \boldsymbol{A}(-\boldsymbol{v}_i) \\ \boldsymbol{A}^{\top}\boldsymbol{u}_i \end{pmatrix} \\ &= \begin{pmatrix} -s_i \boldsymbol{u}_i \\ s_i \boldsymbol{v}_i \end{pmatrix} = -s_i \begin{pmatrix} \boldsymbol{u}_i \\ -\boldsymbol{v}_i \end{pmatrix} = -s_i \boldsymbol{w}_i^{(-)}, \end{aligned}$$

因此 $s_i, -s_i$ 为 $\boldsymbol{H}$ 的特征值。
如此，若 $\operatorname{rank}(\boldsymbol{A}) = r$，则通过上述构造，可得 $\boldsymbol{H}$ 的 $2r$ 个特征值 $(\pm s_1, \cdots, \pm s_r)$。
由于 $\boldsymbol{H}$ 为对称矩阵，其特征向量张成 $m+n$ 维空间，因此剩余的 $(m+n)-2r$ 维空间对应于 $\boldsymbol{H}$ 的零特征值，其中零特征空间的特征向量由 $\boldsymbol{A}$ 的左核空间 $(\boldsymbol{u} \perp \operatorname{Range}(\boldsymbol{A}))$ 和右核空间 $(\boldsymbol{v} \in \ker(\boldsymbol{A}))$ 的分块组合构成。

15 [**Wedin 定理：SVD 的稳定性**] 定理 T4.1.15 (Davis–Kahan 不等式) 适用于对称矩阵。
本题旨于证明其在一般长方形矩阵的版本。
设 $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{m\times n}$，其 SVD 分别表示为

$$\boldsymbol{A} = \sum_i s_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}, \quad \boldsymbol{B} = \sum_i t_i \boldsymbol{w}_i \boldsymbol{z}_i^{\top},$$

记 $r=\min(m,n)$，其中奇异值分别为 $s_1\geqslant\cdots\geqslant s_r\geqslant 0$，$t_1\geqslant\cdots\geqslant t_r\geqslant 0$。

定义前 k 个左奇异向量构成的投影算子为

$$\boldsymbol{P}_A=\sum_{i=1}^{k}\boldsymbol{u}_i\boldsymbol{u}_i^{\top},\quad \boldsymbol{P}_B=\sum_{i=1}^{k}\boldsymbol{w}_i\boldsymbol{w}_i^{\top}。$$

(1) 证明，若 $1\leqslant k<r$，谱间隙 $s_k-s_{k+1}>0$，则左奇异投影满足

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{s_k-s_{k+1}}。$$

(2) 对于前 k 个右奇异向量投影

$$\boldsymbol{Q}_A=\sum_{i=1}^{k}\boldsymbol{v}_i\boldsymbol{v}_i^{\top},\ \boldsymbol{Q}_B=\sum_{i=1}^{k}\boldsymbol{z}_i\boldsymbol{z}_i^{\top},$$

试给出类似界限。

(3) 证明第 k 个奇异向量 (设 $1\leqslant k<r$，$s_{k-1}>s_k>s_{k+1}$，并约定 $s_0=+\infty$) 的 Davis-Kahan 型不等式。

注释 以下内容为错误的尝试：设

$$\boldsymbol{W}_A=\sum_{i=1}^{k}\zeta_i\zeta_i^{\top}=\frac{1}{2}\sum_{i=1}^{k}\begin{pmatrix}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}&\boldsymbol{u}_i\boldsymbol{v}_i^{\top}\\\boldsymbol{v}_i\boldsymbol{u}_i^{\top}&\boldsymbol{v}_i\boldsymbol{v}_i^{\top}\end{pmatrix}=\frac{1}{2}\begin{pmatrix}\boldsymbol{P}_A&\boldsymbol{X}_A\\\boldsymbol{X}_A^{\top}&\boldsymbol{Q}_A\end{pmatrix}$$

为前 k 个正特征值的谱投影算子，则根据习题 Q4.13 (谱投影的 Davis-Kahan 定理)，可得

$$\|\boldsymbol{W}_A-\boldsymbol{W}_B\|\leqslant\frac{2\|\boldsymbol{H}_A-\boldsymbol{H}_B\|}{s_k-s_{k+1}}=\frac{2\|\boldsymbol{A}-\boldsymbol{B}\|}{s_k-s_{k+1}}。$$

注意到 $(\boldsymbol{P}_A-\boldsymbol{P}_B)/2$ 为 $\boldsymbol{W}_A-\boldsymbol{W}_B$ 的左上角分块，因此利用习题 Q4.2 (算子范数的基本性质) (4) 的结论，可得

$$\frac{1}{2}\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\|\boldsymbol{W}_A-\boldsymbol{W}_B\|,$$

从而

$$\|\boldsymbol{P}_A-\boldsymbol{P}_B\|\leqslant\frac{4\|\boldsymbol{A}-\boldsymbol{B}\|}{s_k-s_{k+1}}。$$

可以发现，这并不是我们想要的系数 2，其原因在于我们没有考虑正负奇异值对称分布。

证明 (1) 根据习题 Q4.14 (Hermitian 扩张的谱性质)，构造对称矩阵 $\boldsymbol{H}_A,\boldsymbol{H}_B\in\mathbb{R}^{(m+n)\times(m+n)}$

$$\boldsymbol{H}_A=\begin{pmatrix}\boldsymbol{O}&\boldsymbol{A}\\\boldsymbol{A}^{\top}&\boldsymbol{O}\end{pmatrix},\ \boldsymbol{H}_B=\begin{pmatrix}\boldsymbol{O}&\boldsymbol{B}\\\boldsymbol{B}^{\top}&\boldsymbol{O}\end{pmatrix},$$

其中 $\boldsymbol{H}_A$ 的特征值为 $\{\pm s_i\}$，其前 k 个正特征值 $s_1,\cdots,s_k$ 对应的标准正交特征向量为

$$\zeta_i=\frac{1}{\sqrt{2}}\begin{pmatrix}\boldsymbol{u}_i\\\boldsymbol{v}_i\end{pmatrix}。$$

设 $\pm s_i$ 对应的单位特征向量分别为

$$\zeta_i=\frac{1}{\sqrt{2}}\begin{pmatrix}\boldsymbol{u}_i\\\boldsymbol{v}_i\end{pmatrix},\ \boldsymbol{\chi}_i=\frac{1}{\sqrt{2}}\begin{pmatrix}\boldsymbol{u}_i\\-\boldsymbol{v}_i\end{pmatrix},$$

则其投影和为

$$\zeta_i\zeta_i^{\top}+\boldsymbol{\chi}_i\boldsymbol{\chi}_i^{\top}=\frac{1}{2}\begin{pmatrix}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}&\boldsymbol{u}_i\boldsymbol{v}_i^{\top}\\\boldsymbol{v}_i\boldsymbol{u}_i^{\top}&\boldsymbol{v}_i\boldsymbol{v}_i^{\top}\end{pmatrix}+\frac{1}{2}\begin{pmatrix}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}&-\boldsymbol{u}_i\boldsymbol{v}_i^{\top}\\-\boldsymbol{v}_i\boldsymbol{u}_i^{\top}&\boldsymbol{v}_i\boldsymbol{v}_i^{\top}\end{pmatrix}=\begin{pmatrix}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}&\boldsymbol{O}\\\boldsymbol{O}&\boldsymbol{v}_i\boldsymbol{v}_i^{\top}\end{pmatrix},$$

因此总投影矩阵为

$$\boldsymbol{\Pi}_A=\sum_{i=1}^{k}(\zeta_i\zeta_i^{\top}+\boldsymbol{\chi}_i\boldsymbol{\chi}_i^{\top})=\begin{pmatrix}\sum_{i=1}^{k}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}&\boldsymbol{O}\\\boldsymbol{O}&\sum_{i=1}^{k}\boldsymbol{v}_i\boldsymbol{v}_i^{\top}\end{pmatrix}=\begin{pmatrix}\boldsymbol{P}_A&\boldsymbol{O}\\\boldsymbol{O}&\boldsymbol{Q}_A\end{pmatrix},$$

同理，$\boldsymbol{\Pi}_B = \operatorname{diag}(\boldsymbol{P}_B, \boldsymbol{Q}_B)$。

记 $\delta = s_k - s_{k+1}$，并记 $e = \|\boldsymbol{A} - \boldsymbol{B}\| = \|\boldsymbol{H}_A - \boldsymbol{H}_B\|$。

若 $e < \delta/2$，根据 Weyl 特征值不等式，可得

$$\begin{aligned} t_k - t_{k+1} &\geqslant (s_k - e) - (s_{k+1} + e) \\ &= \delta - 2e > 0。 \end{aligned}$$

因此 $\boldsymbol{\Pi}_B$ 为对应于 $\boldsymbol{H}_B$ 的双侧谱簇 $\{\pm t_1, \cdots, \pm t_k\}$ 的谱投影。由于 $\boldsymbol{H}_A$ 的谱簇 $\{\pm s_1, \cdots, \pm s_k\}$ 同其余谱之间的距离为 δ，根据引理 L4.1.16 (谱投影的 Davis–Kahan 不等式) 的谱投影形式，可得

$$\|\boldsymbol{\Pi}_A - \boldsymbol{\Pi}_B\| \leqslant \frac{e}{\delta - e} \leqslant \frac{2e}{\delta}。$$

若 $e \geqslant \delta/2$，由于 $\boldsymbol{\Pi}_A, \boldsymbol{\Pi}_B$ 的秩相同，利用习题 Q4.12 (正交投影算子之差, 乘积的范数关系) (3) 的结论，可得

$$\|\boldsymbol{\Pi}_A - \boldsymbol{\Pi}_B\| \leqslant 1 \leqslant \frac{2e}{\delta}。$$

因此

$$\begin{aligned} \max\{\|\boldsymbol{P}_A - \boldsymbol{P}_B\|, \|\boldsymbol{Q}_A - \boldsymbol{Q}_B\|\} &= \|\boldsymbol{\Pi}_A - \boldsymbol{\Pi}_B\| \\ &\leqslant \frac{2\|\boldsymbol{A} - \boldsymbol{B}\|}{s_k - s_{k+1}}。 \end{aligned}$$

(2) 设 s_k 为简单奇异值，$1 \leqslant k < r$ (约定 $s_0 = +\infty$)，则 s_k 对应的谱间隙为 $\delta_k = \min\{s_{k-1} - s_k, s_k - s_{k+1}\}$。

令 $\boldsymbol{u}_k, \boldsymbol{w}_k$ 分别为 $\boldsymbol{A}, \boldsymbol{B}$ 的第 k 个左奇异向量，$\boldsymbol{v}_k, \boldsymbol{z}_k$ 分别为相应的右奇异向量。根据单向量谱投影的 Davis–Kahan 不等式，可得

$$\max\{\sin\Theta(\boldsymbol{u}_k, \boldsymbol{w}_k), \sin\Theta(\boldsymbol{v}_k, \boldsymbol{z}_k)\} \leqslant \frac{2\|\boldsymbol{A} - \boldsymbol{B}\|}{\delta_k}。$$

因此左, 右奇异向量的稳定性取决于扰动大小, 此奇异值同相邻奇异值之间的隔离程度。

16 [向量之间的角度与 Euclidean 距离] 定理 T4.1.15 (Davis–Kahan 不等式) 给出了特征投影之间偏差的界限。为了简化结论，我们考察单位向量之间的几何关系。

设 $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ 为单位向量。记 $\alpha \in [0, \pi/2]$ 为 $\boldsymbol{u}, \boldsymbol{v}$ 所张成的直线之间的夹角 (即主夹角)，满足：

$$\sin\alpha \leqslant \varepsilon。 \qquad (\varepsilon > 0)$$

证明：$\boldsymbol{u}, \boldsymbol{v}$ 在相差一个符号的意义下是接近的，即存在 $\theta \in \{-1, 1\}$，使得

$$\|\boldsymbol{u} - \theta\boldsymbol{v}\|_2 \leqslant \sqrt{2}\varepsilon。$$

证明 设 $\boldsymbol{u}, \boldsymbol{v}$ 之间的夹角为 $\phi \in [0, \pi]$，满足 $\langle \boldsymbol{u}, \boldsymbol{v}\rangle = \cos\phi$，则

$$\|\boldsymbol{u} - \theta\boldsymbol{v}\|_2^2 = \|\boldsymbol{u}\|_2^2 + \|\theta\boldsymbol{v}\|_2^2 - 2\langle \boldsymbol{u}, \theta\boldsymbol{v}\rangle = 1 + 1 - 2\theta\langle \boldsymbol{u}, \boldsymbol{v}\rangle = 2(1 - \theta\cos\phi)。$$

要使得上述距离取得最小值：

a. 若 $\cos\phi \geqslant 0$，选取 $\theta = 1$，此时 $\boldsymbol{u}, \boldsymbol{v}$ 的夹角为 $\alpha = \phi \in [0, \pi/2]$。

b. 若 $\cos\phi < 0$，选取 $\theta = -1$，此时 $\boldsymbol{u}, -\boldsymbol{v}$ 的夹角为 $\alpha = \pi - \phi \in [0, \pi/2]$。

因此 $\cos\alpha = |\cos\phi| \geqslant 0$，满足

$$\|\boldsymbol{u} - \theta\boldsymbol{v}\|_2^2 = 2(1 - \cos\alpha) = 4\sin^2\left(\frac{\alpha}{2}\right),$$

其中

$$\sin\alpha = 2\sin\left(\frac{\alpha}{2}\right)\cos\left(\frac{\alpha}{2}\right) \geqslant 2\sin\left(\frac{\alpha}{2}\right)\cos\left(\frac{\pi}{4}\right) \geqslant 2\sin\left(\frac{\alpha}{2}\right)\cdot\frac{1}{\sqrt{2}} = \sqrt{2}\sin\left(\frac{\alpha}{2}\right),$$

从而

$$\|\boldsymbol{u} - \theta\boldsymbol{v}\|_2 = 2\sin\left(\frac{\alpha}{2}\right) \leqslant \sqrt{2}\sin\alpha \leqslant \sqrt{2}\varepsilon。$$

17 [近似投影, 近似等距变换] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ $(m \geqslant n)$，令 $\varepsilon \geqslant 0$ 为误差常数。回忆引理 L4.1.17 (近似等距)：

$\boldsymbol{A}$ 被称为 ε-近似等距变换，若其满足以下等价性质之一：

(1) $\|\boldsymbol{A}^\top\boldsymbol{A}-\boldsymbol{I}_n\|\leqslant\varepsilon$；

(2) 对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，满足 $(1-\varepsilon)\|\boldsymbol{x}\|_2^2\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_2^2\leqslant(1+\varepsilon)\|\boldsymbol{x}\|_2^2$；

(3) 其所有奇异值 $s_i(\boldsymbol{A})$ 均满足 $1-\varepsilon\leqslant s_i(\boldsymbol{A})^2\leqslant 1+\varepsilon$。

证明：

(1) $\boldsymbol{A}$ 为等距变换 (即 $\boldsymbol{A}^\top\boldsymbol{A}=\boldsymbol{I}_n$)，当且仅当 $\boldsymbol{A}\boldsymbol{A}^\top\in\mathbb{R}^{m\times m}$ 为秩 n 正交投影矩阵。

(2) 更一般地，$\boldsymbol{A}$ 为 ε-近似等距变换，当且仅当存在秩 n 的正交投影矩阵 $\boldsymbol{P}\in\mathbb{R}^{m\times m}$，使得

$$\|\boldsymbol{A}\boldsymbol{A}^\top-\boldsymbol{P}\|\leqslant\varepsilon。$$

证明 (1) ($\Longrightarrow$)

若 $\boldsymbol{A}$ 为等距变换，则 $\boldsymbol{A}^\top\boldsymbol{A}=\boldsymbol{I}_n$。

设 $\boldsymbol{Q}=\boldsymbol{A}\boldsymbol{A}^\top$，则：

1. 对称性：$\boldsymbol{Q}^\top=(\boldsymbol{A}\boldsymbol{A}^\top)^\top=\boldsymbol{A}\boldsymbol{A}^\top=\boldsymbol{Q}$。

2. 幂等性：$\boldsymbol{Q}^2=(\boldsymbol{A}\boldsymbol{A}^\top)(\boldsymbol{A}\boldsymbol{A}^\top)=\boldsymbol{A}(\boldsymbol{A}^\top\boldsymbol{A})\boldsymbol{A}^\top=\boldsymbol{A}\boldsymbol{I}_n\boldsymbol{A}^\top=\boldsymbol{A}\boldsymbol{A}^\top=\boldsymbol{Q}$。

3. 秩的性质：由于 $\boldsymbol{A}^\top\boldsymbol{A}=\boldsymbol{I}_n$，因此 $\boldsymbol{A}$ 为满列秩，从而 $\operatorname{rank}(\boldsymbol{Q})=\operatorname{rank}(\boldsymbol{A}\boldsymbol{A}^\top)=\operatorname{rank}(\boldsymbol{A})=n$。

($\Longleftarrow$)

若 $\boldsymbol{Q}=\boldsymbol{A}\boldsymbol{A}^\top$ 为秩 n 正交投影矩阵，令 $\boldsymbol{A}$ 的 SVD 为 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，其中 $\boldsymbol{U}\in\mathbb{R}^{m\times m},\boldsymbol{V}\in\mathbb{R}^{n\times n}$ 为正交矩阵，$\boldsymbol{\Sigma}\in\mathbb{R}^{m\times n}$ 含有奇异值 $s_1,\cdots,s_n$，则

$$\boldsymbol{Q}=\boldsymbol{U}(\boldsymbol{\Sigma}\boldsymbol{\Sigma}^\top)\boldsymbol{U}^\top。$$

由于 $\boldsymbol{Q}$ 为投影矩阵，其特征值只能为 $1,0$。

注意到 $\boldsymbol{Q}$ 的非零特征值恰好是 $\boldsymbol{\Sigma}\boldsymbol{\Sigma}^\top$ 的非零对角元 s_i^2，满足 $\operatorname{rank}(\boldsymbol{Q})=n$，因此

$$s_i^2=1\implies s_i=1,$$

从而 $\boldsymbol{\Sigma}^\top\boldsymbol{\Sigma}=\boldsymbol{I}_n$，从而 $\boldsymbol{A}^\top\boldsymbol{A}=\boldsymbol{V}(\boldsymbol{\Sigma}^\top\boldsymbol{\Sigma})\boldsymbol{V}^\top=\boldsymbol{V}\boldsymbol{I}_n\boldsymbol{V}^\top=\boldsymbol{I}_n$。

(2) 设 $\boldsymbol{A}$ 的奇异值为 $s_1,\cdots,s_n$，则根据引理 L4.1.17 (近似等距)，$\boldsymbol{A}$ 是 ε-近似等距变换等价于

$$\max_i|s_i^2-1|\leqslant\varepsilon。$$

($\Longleftarrow$)

若存在秩 n 正交投影矩阵 $\boldsymbol{P}$，满足 $\|\boldsymbol{A}\boldsymbol{A}^\top-\boldsymbol{P}\|\leqslant\varepsilon$，则考虑特征值摄动。

作出以下引理：

引理 (Weyl 不等式)　若两个对称矩阵之差的范数不超过 ε，则其排序之后的特征值之差也不超过 ε。

容易知道，$\boldsymbol{P}$ 的特征值为 n 个 1 和 $m-n$ 个 0，$\boldsymbol{A}\boldsymbol{A}^\top$ 的特征值为 $s_1^2,\cdots,s_n^2$ 和 $m-n$ 个 0，因此根据引理，对于前 n 个特征值，满足

$$|s_i^2-1|\leqslant\|\boldsymbol{A}\boldsymbol{A}^\top-\boldsymbol{P}\|\leqslant\varepsilon,$$

从而 $\boldsymbol{A}$ 为 ε-近似等距变换。

($\Longrightarrow$)

若 $\boldsymbol{A}$ 为 ε-近似等距变换，即满足 $|s_i^2-1|\leqslant\varepsilon$，令 $\boldsymbol{A}$ 的 SVD 为 $\boldsymbol{A}=\sum_{i=1}^n s_i\boldsymbol{u}_i\boldsymbol{v}_i^\top$，构造投影矩阵

$$\boldsymbol{P}=\sum_{i=1}^n\boldsymbol{u}_i\boldsymbol{u}_i^\top$$

为向 $\boldsymbol{A}$ 的值域空间 (即前 n 个左奇异向量张成的空间) 的投影，则

$$\boldsymbol{A}\boldsymbol{A}^\top-\boldsymbol{P}=\left(\sum_{i=1}^n s_i^2\boldsymbol{u}_i\boldsymbol{u}_i^\top\right)-\left(\sum_{i=1}^n\boldsymbol{u}_i\boldsymbol{u}_i^\top\right)=\sum_{i=1}^n(s_i^2-1)\boldsymbol{u}_i\boldsymbol{u}_i^\top$$

为对称矩阵，因此

$$\|\boldsymbol{A}\boldsymbol{A}^\top-\boldsymbol{P}\|=\max_{1\leqslant i\leqslant n}|s_i^2-1|\leqslant\varepsilon。$$

18 [$p\to q$ **算子范数**] $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的算子范数刻画了该矩阵对向量的“拉伸”能力。为了度量这种拉伸，我们可以利用任意 ℓ^p 和 ℓ^q 范数，其中 $p,q\in[1,\infty]$。

定义 $\boldsymbol{A}$ 的 $p\to q$ 算子范数为

$$\|\boldsymbol{A}\|_{p\to q}=\max_{\boldsymbol{x}\neq\boldsymbol{0}}\frac{\|\boldsymbol{A}\boldsymbol{x}\|_q}{\|\boldsymbol{x}\|_p}$$

(1) 证明上述定义等价于以下双线性形式，

$$\|\boldsymbol{A}\|_{p\to q}=\max_{\|\boldsymbol{x}\|_p=1,\|\boldsymbol{y}\|_{q'}=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|。$$

其中 q' 是 q 的共轭指数。

(2) 证明：$\|\cdot\|_{p\to q}$ 定义矩阵空间 $\mathbb{R}^{m\times n}$ 的范数。

(3) (对偶性) 证明：$\|\boldsymbol{A}^\top\|_{p\to q}=\|\boldsymbol{A}\|_{q'\to p'}$，其中 p',q' 分别是 p,q 的共轭指数。

证明 (1) 作出以下引理：

引理 (ℓ^q 范数的对偶性表示 / Holder 不等式的推论) 对于任意的 $\boldsymbol{z}\in\mathbb{R}^m$，

$$\|\boldsymbol{z}\|_q=\max_{\|\boldsymbol{y}\|_{q'}=1}|\boldsymbol{y}^\top\boldsymbol{z}|。$$

根据 $p\to q$ 算子范数的定义 (Q4.18 ($p\to q$ 算子范数))，

$$\|\boldsymbol{A}\|_{p\to q}=\max_{\|\boldsymbol{x}\|_p=1}\|\boldsymbol{A}\boldsymbol{x}\|_q,$$

因此根据引理，令 $\boldsymbol{z}=\boldsymbol{A}\boldsymbol{x}$，可得

$$\|\boldsymbol{A}\|_{p\to q}=\max_{\|\boldsymbol{x}\|_p=1}\left(\max_{\|\boldsymbol{y}\|_{q'}=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|\right)=\max_{\|\boldsymbol{x}\|_p=1,\|\boldsymbol{y}\|_{q'}=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|。$$

(由于目标函数于紧集是连续的，因此上确界由最大值取得。)

(2) 1. 非负性, 确定性：

容易知道，$\|\boldsymbol{A}\boldsymbol{x}\|_q\geqslant 0$。

若 $\|\boldsymbol{A}\|_{p\to q}=0$，则对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，均满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，因此 $\boldsymbol{A}=\boldsymbol{O}$。

2. 绝对齐次性：

$$\|c\boldsymbol{A}\|_{p\to q}=\max_{\|\boldsymbol{x}\|_p=1}\|c\boldsymbol{A}\boldsymbol{x}\|_q=\max_{\|\boldsymbol{x}\|_p=1}|c|\cdot\|\boldsymbol{A}\boldsymbol{x}\|_q=|c|\cdot\|\boldsymbol{A}\|_{p\to q}。$$

3. 三角不等式：

对于任意的 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{m\times n}$，

$$\|(\boldsymbol{A}+\boldsymbol{B})\boldsymbol{x}\|_q=\|\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{x}\|_q\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_q+\|\boldsymbol{B}\boldsymbol{x}\|_q\leqslant(\|\boldsymbol{A}\|_{p\to q}+\|\boldsymbol{B}\|_{p\to q})\|\boldsymbol{x}\|_p,$$

两侧对 $\|\boldsymbol{x}\|_p=1$ 取最大值，

$$\|\boldsymbol{A}+\boldsymbol{B}\|_{p\to q}\leqslant\|\boldsymbol{A}\|_{p\to q}+\|\boldsymbol{B}\|_{p\to q}。$$

(3) 利用 (1) 的结论，可得

$$\|\boldsymbol{A}\|_{q'\to p'}=\max_{\|\boldsymbol{x}\|_{q'}=1,\|\boldsymbol{y}\|_{(p')'}=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|=\max_{\|\boldsymbol{x}\|_{q'}=1,\|\boldsymbol{y}\|_p=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|,$$

$$\|\boldsymbol{A}^\top\|_{p\to q}=\max_{\|\boldsymbol{y}\|_p=1,\|\boldsymbol{x}\|_{q'}=1}|\boldsymbol{x}^\top\boldsymbol{A}^\top\boldsymbol{y}|=\max_{\|\boldsymbol{y}\|_p=1,\|\boldsymbol{x}\|_{q'}=1}|\boldsymbol{y}^\top\boldsymbol{A}\boldsymbol{x}|,$$

因此 $\|\boldsymbol{A}^\top\|_{p\to q}=\|\boldsymbol{A}\|_{q'\to p'}$。

19 [$1\to\infty$ **与** $1\to 2$ **算子范数的显式表示**] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，其第 i 行记为 $\boldsymbol{r}_i^\top$，第 j 列记为 $\boldsymbol{a}_j$。回忆 $p\to q$ 算子范数的定义为

$$\|\boldsymbol{A}\|_{p\to q}=\sup_{\|\boldsymbol{x}\|_p=1}\|\boldsymbol{A}\boldsymbol{x}\|_q。$$

(1) 证明：$1\to\infty$ 范数等于矩阵元素绝对值的最大值，即

$$\|\boldsymbol{A}\|_{1\to\infty}=\max_{1\leqslant i\leqslant m,1\leqslant j\leqslant n}|a_{ij}|。$$

(2) 证明：$1\to 2$ 范数等于列向量 Euclidean 范数的最大值，而 $2\to\infty$ 范数等于行向量 Euclidean 范数的最大值，即

$$\|\boldsymbol{A}\|_{1\to 2}=\max_{1\leqslant j\leqslant n}\|\boldsymbol{a}_j\|_2,\quad \|\boldsymbol{A}\|_{2\to\infty}=\max_{1\leqslant i\leqslant m}\|\boldsymbol{r}_i\|_2。$$

证明 (1) 根据 $p\to q$ 算子范数的定义 (Q4.19 ($1\to\infty$ 与 $1\to 2$ 算子范数的显式表示))，

$$\|\boldsymbol{A}\|_{1\to\infty}=\sup_{\|\boldsymbol{x}\|_1=1}\max_{1\leqslant i\leqslant m}|(\boldsymbol{A}\boldsymbol{x})_i|。$$

- 上界估计

  对于任意的满足 $\|\boldsymbol{x}\|_1=\sum_{j=1}^n|x_j|=1$ 的向量 $\boldsymbol{x}$，考虑其第 i 个分量，

  $$\begin{aligned}|(\boldsymbol{A}\boldsymbol{x})_i|&=\left|\sum_{j=1}^n a_{ij}x_j\right|\leqslant\sum_{j=1}^n|a_{ij}|\cdot|x_j|\\&\leqslant\left(\max_{1\leqslant j\leqslant n}|a_{ij}|\right)\sum_{j=1}^n|x_j|=\max_j|a_{ij}|,\end{aligned}$$

  对所有行 i 取最大值，

  $$\|\boldsymbol{A}\boldsymbol{x}\|_\infty\leqslant\max_{i,j}|a_{ij}|,$$

  即 $\|\boldsymbol{A}\|_{1\to\infty}\leqslant\max_{i,j}|a_{ij}|$。
- 下界估计

  设最大绝对值于 (i^*,j^*) 取得，即 $|A_{i^*j^*}|=\max_{i,j}|a_{ij}|$，令 $\boldsymbol{x}=\boldsymbol{e}_{j^*}$，此时 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{a}_{j^*}$，则

  $$\|\boldsymbol{A}\boldsymbol{x}\|_\infty=\max_i|A_{ij^*}|\geqslant|A_{i^*j^*}|=\max_{i,j}|a_{ij}|,$$

  因此 $\|\boldsymbol{A}\|_{1\to\infty}\geqslant\max_{i,j}|a_{ij}|$。

(2)
- 证明 $\|\boldsymbol{A}\|_{1\to 2}=\max_j\|\boldsymbol{a}_j\|_2$

  对于上界，令 $\|\boldsymbol{x}\|_1=1$，则 $\boldsymbol{A}\boldsymbol{x}=\sum_{j=1}^n x_j\boldsymbol{a}_j$，因此利用三角不等式，可得

  $$\|\boldsymbol{A}\boldsymbol{x}\|_2=\left\|\sum_{j=1}^n x_j\boldsymbol{a}_j\right\|_2\leqslant\sum_{j=1}^n|x_j|\cdot\|\boldsymbol{a}_j\|_2\leqslant\max_j\|\boldsymbol{a}_j\|_2\left(\sum_{j=1}^n|x_j|\right)=\max_j\|\boldsymbol{a}_j\|_2。$$

  对于下界，令 $\boldsymbol{x}=\boldsymbol{e}_{j^*}$，其中 j^* 为使得列范数最大的下标，则

  $$\|\boldsymbol{A}\boldsymbol{e}_{j^*}\|_2=\|\boldsymbol{a}_{j^*}\|_2=\max_j\|\boldsymbol{a}_j\|_2,$$

  即 $\|\boldsymbol{A}\|_{1\to 2}=\max_j\|\boldsymbol{a}_j\|_2$。
- 证明 $\|\boldsymbol{A}\|_{2\to\infty}=\max_i\|\boldsymbol{r}_i\|_2$

  对于上界，根据 $p\to q$ 算子范数的定义 (Q4.19 ($1\to\infty$ 与 $1\to 2$ 算子范数的显式表示))，

  $$\|\boldsymbol{A}\|_{2\to\infty}=\sup_{\|\boldsymbol{x}\|_2=1}\max_i|\langle\boldsymbol{r}_i,\boldsymbol{x}\rangle|,$$

  利用 Cauchy 不等式，可得

  $$|\langle\boldsymbol{r}_i,\boldsymbol{x}\rangle|\leqslant\|\boldsymbol{r}_i\|_2\cdot\|\boldsymbol{x}\|_2=\|\boldsymbol{r}_i\|_2,$$

  即 $\max_i|\langle\boldsymbol{r}_i,\boldsymbol{x}\rangle|\leqslant\max_i\|\boldsymbol{r}_i\|_2$。

  对于下界，令 $\boldsymbol{x}=\boldsymbol{r}_{i^*}/\|\boldsymbol{r}_{i^*}\|_2$，其中 i^* 为使得行范数最大的下标，则

  $$\|\boldsymbol{A}\boldsymbol{x}\|_\infty\geqslant|\langle\boldsymbol{r}_{i^*},\boldsymbol{x}\rangle|=\frac{\|\boldsymbol{r}_{i^*}\|_2^2}{\|\boldsymbol{r}_{i^*}\|_2}=\|\boldsymbol{r}_{i^*}\|_2=\max_i\|\boldsymbol{r}_i\|_2,$$

  即 $\|\boldsymbol{A}\|_{2\to\infty}=\max_i\|\boldsymbol{r}_i\|_2$。

20 [$\infty \to 1$ **算子范数的性质, 对偶**] 我们之前见过这个范数！它隐含于定理 T3.5.1 (Grothendieck 不等式) 的假设。设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$。回想算子范数的定义

$$\|\boldsymbol{A}\|_{p\to q} = \sup_{\|\boldsymbol{y}\|_p \leqslant 1} \|\boldsymbol{A}\boldsymbol{y}\|_q。$$

(1) 证明：$\infty \to 1$ 范数可以通过离散顶点集 $\{-1,1\}$ 的最大化来表示，

$$\|\boldsymbol{A}\|_{\infty\to 1} = \max_{\boldsymbol{x}\in\{-1,1\}^m, \boldsymbol{y}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}|。$$

(2) (对偶性) 证明：$\infty \to 1$ 范数等价于秩 1 矩阵的搜索，

$$\|\boldsymbol{A}\|_{\infty\to 1} = \sup\{|\langle \boldsymbol{A}, \boldsymbol{Z}\rangle| : \|\boldsymbol{Z}\|_\infty \leqslant 1, \operatorname{rank}(\boldsymbol{Z}) = 1\}。$$

其中 $\|\boldsymbol{Z}\|_\infty = \max_{i,j}|Z_{ij}|$ 为矩阵元素的极大值范数，矩阵内积定义为 $\langle \boldsymbol{A}, \boldsymbol{Z}\rangle = \operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{Z})$。

(3) (二次型的非泛化性) 证明 (2) 不能直接推广到二次型。构造的对称矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，使得

$$\max_{\boldsymbol{x}\in[-1,1]^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}| \neq \max_{\boldsymbol{x}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}|。$$

证明 (1) 根据 $p \to q$ 算子范数的定义 (Q4.20 ($\infty \to 1$ 算子范数的性质, 对偶))，

$$\|\boldsymbol{A}\|_{\infty\to 1} = \sup_{\|\boldsymbol{y}\|_\infty \leqslant 1} \|\boldsymbol{A}\boldsymbol{y}\|_1。$$

利用 ℓ^1 范数的对偶性 $\|\boldsymbol{z}\|_1 = \sup_{\|\boldsymbol{x}\|_\infty \leqslant 1}\langle \boldsymbol{x}, \boldsymbol{z}\rangle$，可得

$$\|\boldsymbol{z}\|_1 = \sup_{\|\boldsymbol{x}\|_\infty \leqslant 1} \langle \boldsymbol{x}, \boldsymbol{z}\rangle,$$

其中 $f(\boldsymbol{x}, \boldsymbol{y}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}$ 为双线性函数，$K = [-1,1]^k$ 为凸多面体，因此上确界于离散集取得，

$$\|\boldsymbol{A}\|_{\infty\to 1} = \max_{\boldsymbol{x}\in\{-1,1\}^m, \boldsymbol{y}\in\{-1,1\}^n} \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y},$$

即

$$\|\boldsymbol{A}\|_{\infty\to 1} = \max_{\boldsymbol{x}\in\{-1,1\}^m, \boldsymbol{y}\in\{-1,1\}^n} |\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}|。$$

(2) 设 $\boldsymbol{Z} = \boldsymbol{x}\boldsymbol{y}^\top$，满足 $\operatorname{rank}(\boldsymbol{Z}) = 1$，$\|\boldsymbol{Z}\|_\infty \leqslant 1$ (由于 $|x_i|, |y_j| \leqslant 1$，因此 $|Z_{ij}| \leqslant 1$)，则

$$\langle \boldsymbol{A}, \boldsymbol{Z}\rangle = \operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{x}\boldsymbol{y}^\top) = \operatorname{tr}(\boldsymbol{y}^\top \boldsymbol{A}^\top \boldsymbol{x}) = \boldsymbol{y}^\top \boldsymbol{A}^\top \boldsymbol{x} = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y},$$

因此利用 (1) 的结论，可得

$$\begin{aligned}\|\boldsymbol{A}\|_{\infty\to 1} &= \sup\{\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y} : \boldsymbol{x} \in [-1,1]^m, \boldsymbol{y} \in [-1,1]^n\} \\ &= \sup\{|\langle \boldsymbol{A}, \boldsymbol{Z}\rangle| : \|\boldsymbol{Z}\|_\infty \leqslant 1, \operatorname{rank}(\boldsymbol{Z}) = 1\}。\end{aligned}$$

(3) 构造

$$\boldsymbol{A} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix},$$

考虑其二次型 $g(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} = x_1^2 - x_2^2$，则

$$\max_{\boldsymbol{x}\in\{-1,1\}^2} |x_1^2 - x_2^2| = |1-1| = 0, \quad \max_{\boldsymbol{x}\in[-1,1]^2} |g(\boldsymbol{x})| = 1。$$

(二次型的最大值未必于顶点取得，其原因在于 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ 不是线性的或半正定的。)

21 [**割范数及其与** $\infty \to 1$ **范数的等价性**] 于理论计算机科学，图论，割范数是一个衡量矩阵性质的重要度量。对于 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，其割范数定义为所有可能子矩阵元素之和的绝对值的最大值，

$$\|\boldsymbol{A}\|_{\text{cut}} = \max_{I,J} \left| \sum_{i\in I, j\in J} a_{ij} \right|,$$

其中最大值是于指标集的所有子集 $I \subset \{1, \cdots, m\}$ 和 $J \subset \{1, \cdots, n\}$ 取值。

证明：割范数在绝对常数因子意义下等价于 $\infty \to 1$ 算子范数，即

$$\|\boldsymbol{A}\|_{\text{cut}} \leqslant \|\boldsymbol{A}\|_{\infty\to 1} \leqslant 4\|\boldsymbol{A}\|_{\text{cut}}。$$

证明 • 左侧不等式 $\|\boldsymbol{A}\|_{\text{cut}} \leqslant \|\boldsymbol{A}\|_{\infty\to 1}$

根据习题 Q4.20 ($\infty \to 1$ 算子范数的性质, 对偶)，可得 $\infty \to 1$ 范数等价于在超立方体的双线性型最大化，即

$$\|\boldsymbol{A}\|_{\infty\to 1} = \max_{\boldsymbol{u}\in[-1,1]^m, \boldsymbol{v}\in[-1,1]^n} \left|\boldsymbol{u}^\top \boldsymbol{A}\boldsymbol{v}\right|。$$

对于任意给定的子集 I, J，定义对应的示性向量 $\boldsymbol{u}_I = \mathbf{1}_I \in \{0,1\}^m, \boldsymbol{v}_J = \mathbf{1}_J \in \{0,1\}^n$，满足 $\boldsymbol{u}_I, \boldsymbol{v}_J \in [-1,1]^m \times [-1,1]^n$，则

$$\sum_{i\in I, j\in J} a_{ij} = \boldsymbol{u}_I^\top \boldsymbol{A}\boldsymbol{v}_J,$$

因此

$$\left|\sum_{i\in I, j\in J} a_{ij}\right| = \left|\boldsymbol{u}_I^\top \boldsymbol{A}\boldsymbol{v}_J\right| \leqslant \max_{\boldsymbol{u}\in[-1,1]^m, \boldsymbol{v}\in[-1,1]^n} |\boldsymbol{u}^\top \boldsymbol{A}\boldsymbol{v}| = \|\boldsymbol{A}\|_{\infty\to 1},$$

两侧取最大值，

$$\|\boldsymbol{A}\|_{\text{cut}} \leqslant \|\boldsymbol{A}\|_{\infty\to 1}。$$

• 右侧不等式 $\|\boldsymbol{A}\|_{\infty\to 1} \leqslant 4\|\boldsymbol{A}\|_{\text{cut}}$

设使得 $\|\boldsymbol{A}\|_{\infty\to 1}$ 取得最大值的向量为 $\boldsymbol{x} \in \{-1,1\}^n, \boldsymbol{y} \in \{-1,1\}^m$，则

$$\|\boldsymbol{A}\|_{\infty\to 1} = \left|\sum_{i=1}^m \sum_{j=1}^n a_{ij} y_i x_j\right|,$$

将指标集根据分量的正负进行划分，

$$I^+ = \{i : y_i = 1\}, \quad I^- = \{i : y_i = -1\},$$
$$J^+ = \{j : x_j = 1\}, \quad J^- = \{j : x_j = -1\},$$

将双重求和展开，

$$\begin{aligned}\sum_{i,j} a_{ij} y_i x_j &= \sum_{i\in I^+, j\in J^+} a_{ij}(1)(1) + \sum_{i\in I^-, j\in J^-} a_{ij}(-1)(-1) + \sum_{i\in I^+, j\in J^-} a_{ij}(1)(-1) + \sum_{i\in I^-, j\in J^+} a_{ij}(-1)(1) \\ &= \sum_{i\in I^+, j\in J^+} a_{ij} + \sum_{i\in I^-, j\in J^-} a_{ij} - \sum_{i\in I^+, j\in J^-} a_{ij} - \sum_{i\in I^-, j\in J^+} a_{ij},\end{aligned}$$

因此利用三角不等式，

$$\|\boldsymbol{A}\|_{\infty\to 1} \leqslant \left|\sum_{i\in I^+, j\in J^+} a_{ij}\right| + \left|\sum_{i\in I^-, j\in J^-} a_{ij}\right| + \left|\sum_{i\in I^+, j\in J^-} a_{ij}\right| + \left|\sum_{i\in I^-, j\in J^+} a_{ij}\right|,$$

即

$$\|\boldsymbol{A}\|_{\infty\to 1} \leqslant \|\boldsymbol{A}\|_{\text{cut}} + \|\boldsymbol{A}\|_{\text{cut}} + \|\boldsymbol{A}\|_{\text{cut}} + \|\boldsymbol{A}\|_{\text{cut}} = 4\|\boldsymbol{A}\|_{\text{cut}}。$$

22 [**算子范数的 SDP 松弛近似**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$。证明：$\|\boldsymbol{A}\|_{\infty\to 1}$、割范数 $\|\boldsymbol{A}\|_{\text{cut}}$ (见练习 Q4.21 (割范数及其与 $\infty \to 1$ 范数的等价性))、$\|\boldsymbol{A}\|_{\infty\to 2}$ 均在绝对常数因子的意义下，通过求解 SDP 问题计算其近似解。

证明 根据习题 Q4.20 ($\infty \to 1$ 算子范数的性质, 对偶)，可得 $\infty \to 1$ 范数定义为以下整数规划问题，

$$\|\boldsymbol{A}\|_{\infty\to 1} = \max_{x_j, y_i \in \{-1,1\}} \sum_{i,j} a_{ij} x_j y_i。$$

构造其 SDP 松弛，将标量 x_j, y_i 替换为 Hilbert 空间的单位向量 $\boldsymbol{u}_j, \boldsymbol{v}_i \in \mathbb{S}^{k-1}$，

$$\text{sdp}(\boldsymbol{A}) = \max_{\|\boldsymbol{u}_j\|_2=1, \|\boldsymbol{v}_i\|_2=1} \sum_{i,j} a_{ij} \langle \boldsymbol{u}_j, \boldsymbol{v}_i \rangle,$$

因此利用定理 T3.5.1 (Grothendieck 不等式)，可得

$$\|\boldsymbol{A}\|_{\infty\to 1} \leqslant \mathrm{sdp}(\boldsymbol{A}) \leqslant K_G \|\boldsymbol{A}\|_{\infty\to 1}, \qquad (K_G > 0)$$

即 $\|\boldsymbol{A}\|_{\infty\to 1} \asymp \mathrm{sdp}(\boldsymbol{A})$。

根据习题 Q4.21 (割范数及其与 $\infty \to 1$ 范数的等价性)，

$$\|\boldsymbol{A}\|_{\mathrm{cut}} \asymp \|\boldsymbol{A}\|_{\infty\to 1},$$

其中利用 (1) 的结论，$\|\boldsymbol{A}\|_{\infty\to 1}$ 可以通过求解 SDP 问题计算其近似解，因此 $\|\boldsymbol{A}\|_{\mathrm{cut}}$ 可以通过求解 SDP 问题计算其近似解。

令 $\boldsymbol{B} = \boldsymbol{A}^\top \boldsymbol{A}$，则

$$\|\boldsymbol{A}\|_{\infty\to 2}^2 = \left(\max_{\|\boldsymbol{x}\|_\infty \leqslant 1} \|\boldsymbol{A}\boldsymbol{x}\|_2\right)^2 = \max_{\boldsymbol{x}\in\{-1,1\}^n} \boldsymbol{x}^\top (\boldsymbol{A}^\top \boldsymbol{A})\boldsymbol{x} = \max_{\boldsymbol{x}\in\{-1,1\}^n} \boldsymbol{x}^\top \boldsymbol{B}\boldsymbol{x},$$

即为 PSD 矩阵的 Boolean 二次规划。

根据习题 Q3.58 (基于 Grothendieck 不等式的 SDP 松弛分析)，可得

$$\mathrm{int}(\boldsymbol{B}) \leqslant \mathrm{sdp}(\boldsymbol{B}) \leqslant \frac{\pi}{2}\,\mathrm{int}(\boldsymbol{B}),$$

即 $\|\boldsymbol{A}\|_{\infty\to 2}^2 \asymp \mathrm{sdp}(\boldsymbol{A}^\top \boldsymbol{A})$。

23 [ε-网的传递性] 设 (K, d) 为度量空间，对于 $\mathcal{M}, \mathcal{N} \subset K$，若满足：

1. $\mathcal{M}$ 为 K 的 δ-网，即对于任意的 $\boldsymbol{x} \in K$，均存在 $\boldsymbol{m} \in \mathcal{M}$，使得 $d(\boldsymbol{x}, \boldsymbol{m}) \leqslant \delta$。
2. $\mathcal{N}$ 为 $\mathcal{M}$ 的 ε-网，即对于任意的 $\boldsymbol{m} \in \mathcal{M}$，均存在 $\boldsymbol{n} \in \mathcal{N}$，使得 $d(\boldsymbol{m}, \boldsymbol{n}) \leqslant \varepsilon$。

证明：$\mathcal{N}$ 为 K 的 $(\varepsilon + \delta)$-网。

证明 利用三角不等式，可得

$$d(\boldsymbol{x}, \boldsymbol{n}) \leqslant d(\boldsymbol{x}, \boldsymbol{m}) + d(\boldsymbol{m}, \boldsymbol{n}) \leqslant \delta + \varepsilon。$$

24 [球填充与 ε-分离集] 设 $(\mathbb{T}, d)$ 为度量空间。称 $\mathcal{N} \subset \mathbb{T}$ 是 ε-分离的，若对于任意的 $x, y \in \mathcal{N}$，均满足 $d(x, y) > \varepsilon$。回忆注记 R4.2.5 (球装箱的几何原理)，$\{B(x, \varepsilon/2)\}_{x\in\mathcal{N}}$ 是两两不交的。

(1) 证明：于一般的度量空间，上述命题的逆命题不成立。即：即使 $\{B(x, \varepsilon/2)\}_{x\in\mathcal{N}}$ 是两两不交的，$\mathcal{N}$ 未必是 ε-分离的。

(2) 证明：若 $(\mathbb{T}, d)$ 为赋范向量空间 (即 $d(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\|$)，则上述逆命题成立。

证明 (1) (构造度量空间 $(\mathbb{T}, d)$，使得 $B(x, \varepsilon/2) \cap B(y, \varepsilon/2) = \emptyset$，但是 $d(x, y) \leqslant \varepsilon$。)

令 $\mathbb{T} = \{0, 1\}$，$d(x, y) = |x - y|$，$\varepsilon = 1$，则 $B(0, 0.5) \cap B(1, 0.5) = \emptyset$。

若 $\mathcal{N} = \{0, 1\}$ 是 ε-分离的，则 $d(0, 1) > \varepsilon$，但是 $d(0, 1) = 1 \not> \varepsilon = 1$。

(2) 利用反证法，假设存在 $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{N}$，其不是 ε-分离的，即 $\|\boldsymbol{x} - \boldsymbol{y}\| \leqslant \varepsilon$。

令 $\boldsymbol{m} = (\boldsymbol{x} + \boldsymbol{y})/2$，则

$$\|\boldsymbol{x} - \boldsymbol{m}\| = \|\boldsymbol{y} - \boldsymbol{m}\| = \frac{1}{2}\|\boldsymbol{x} - \boldsymbol{y}\| \leqslant \frac{\varepsilon}{2},$$

因此 $\boldsymbol{m} \in B(\boldsymbol{x}, \varepsilon/2), B(\boldsymbol{y}, \varepsilon/2)$，即 $B(\boldsymbol{x}, \varepsilon/2) \cap B(\boldsymbol{y}, \varepsilon/2) = \emptyset$，矛盾；如此，$\mathcal{N}$ 中任意两点均为 ε-分离的。

25 [外部覆盖数及其等价性] 设 $(\mathbb{T}, d)$ 为度量空间，$K \subset \mathbb{T}$。一般而言，覆盖数 $\mathcal{N}(K, d, \varepsilon)$ 要求球心 $x_i \in K$ (即内部覆盖)。若放宽此限制，允许球心位于 K 以外 (即 $x_i \in \mathbb{T}$)，则得到的最小球个数称为外部覆盖数，记作 $\overline{\mathcal{N}}(K, d, \varepsilon)$。

证明：内部覆盖数, 外部覆盖数于本质是等价的，即

$$\overline{\mathcal{N}}(K, d, \varepsilon) \leqslant \mathcal{N}(K, d, \varepsilon) \leqslant \overline{\mathcal{N}}(K, d, \varepsilon/2)。$$

证明 由定义，可得外部覆盖数的可行解空间不小于内部覆盖数，因此

$$\overline{\mathcal{N}}(K, d, \varepsilon) \leqslant \mathcal{N}(K, d, \varepsilon),$$

之后只需证明右侧不等式。

设 $\{y_1, y_2, \cdots, y_m\}$ 为 K 的最优外部 $(\varepsilon/2)$-网，其中 $m = \overline{\mathcal{N}}(K, d, \varepsilon/2)$。(此时 $y_j \in \mathbb{T}$，$K \subset \bigcup_{j=1}^m B(y_j, \varepsilon/2)$。)

a. 若 $B(y_j,\varepsilon/2)\cap K=\emptyset$，则将其删除。

b. 若 $B(y_j,\varepsilon/2)\cap K\neq\emptyset$，则选取 $x_j\in B(y_j,\varepsilon/2)\cap K$。

作出以下推断：

推断 $\{x_1,x_2,\cdots,x_m\}$ 为 K 的内部 ε-网。

对于任意的 $z\in K$，存在 j，使得

$$d(z,y_j)\leqslant\frac{\varepsilon}{2};$$

同理，

$$d(x_j,y_j)\leqslant\frac{\varepsilon}{2},$$

因此

$$d(z,x_j)\leqslant d(z,y_j)+d(y_j,x_j)\leqslant\frac{\varepsilon}{2}+\frac{\varepsilon}{2}=\varepsilon。$$

根据推断，可得 $\mathcal{N}(K,d,\varepsilon)\leqslant m=\overline{\mathcal{N}}(K,d,\varepsilon/2)$。

26 [**覆盖数的单调性分析**] 设 $(\mathbb{T},d)$ 为度量空间，$K,L\subset\mathbb{T}$。记 $\mathcal{N}(K,d,\varepsilon)$ 为 K 的内部覆盖数。已知覆盖数关于半径 ε 满足单调性：若 $\varepsilon_1\leqslant\varepsilon_2$，则 $\mathcal{N}(K,d,\varepsilon_1)\geqslant\mathcal{N}(K,d,\varepsilon_2)$ (思考：为什么?)。但是，其关于 K 并不满足直接的单调性。

(1) 构造反例，说明 $L\subset K$ 未必可以推导 $\mathcal{N}(L,d,\varepsilon)\leqslant\mathcal{N}(K,d,\varepsilon)$。

(2) 证明：覆盖数满足“近似单调性”，即

$$L\subset K\implies\mathcal{N}(L,d,\varepsilon)\leqslant\mathcal{N}(K,d,\varepsilon/2)。$$

注释 覆盖数关于半径 ε 满足单调性的证明：

设 $\mathcal{N}_1=\{x_1,\cdots,x_M\}$ 为 K 的最优内部 ε_1-网，其中 $M=\mathcal{N}(K,d,\varepsilon_1)$。(此时 $x_i\in K$，$K\subset\bigcup_{i=1}^{M}B(x_i,\varepsilon_1)$。)

由于

$$\varepsilon_1\leqslant\varepsilon_2\implies B(x,\varepsilon_1)\subset B(x,\varepsilon_2),$$

因此

$$K\subset\bigcup_{i=1}^{M}B(x_i,\varepsilon_1)\subset\bigcup_{i=1}^{M}B(x_i,\varepsilon_2),$$

从而 $\mathcal{N}_1$ 为 K 的内部 ε_2-网，从而

$$\mathcal{N}(K,d,\varepsilon_2)\leqslant\operatorname{card}(\mathcal{N}_1)=\mathcal{N}(K,d,\varepsilon_1)。$$

证明 (1) 构造以下反例：令 $(\mathbb{T},d)$ 为标准度量空间，令 $\varepsilon=1$，$L=\{-1,1\}$，$K=\{-1,0,1\}$，则 $\mathcal{N}(K,d,1)=1$，$\mathcal{N}(L,d,1)=2$，不满足关于集合的单调性。

(2) 根据习题 Q4.25 (外部覆盖数及其等价性)，可得

$$\overline{\mathcal{N}}(K,d,\varepsilon)\leqslant\mathcal{N}(K,d,\varepsilon)\leqslant\overline{\mathcal{N}}(K,d,\varepsilon/2);\tag{I}$$

根据外部覆盖数关于集合的单调性，可得

$$\overline{\mathcal{N}}(L,d,\varepsilon)\leqslant\overline{\mathcal{N}}(K,d,\varepsilon)。\tag{II}$$

利用 (I)，可得

$$\mathcal{N}(L,d,\varepsilon)\leqslant\overline{\mathcal{N}}(L,d,\varepsilon/2),\ \overline{\mathcal{N}}(K,d,\varepsilon/2)\leqslant\mathcal{N}(K,d,\varepsilon/2);$$

利用 (II)，可得

$$\overline{\mathcal{N}}(L,d,\varepsilon/2)\leqslant\overline{\mathcal{N}}(K,d,\varepsilon/2),$$

因此

$$\mathcal{N}(L,d,\varepsilon)\leqslant\overline{\mathcal{N}}(L,d,\varepsilon/2)\leqslant\overline{\mathcal{N}}(K,d,\varepsilon/2)\leqslant\mathcal{N}(K,d,\varepsilon/2)。$$

27 [**Euclidean 球的体积：几何法**] 本题及其后续练习将通过三种不同的方法 (几何法, 概率法, 分析法) 计算 $\mathbb{B}_2^n$ 的体积。

首先，我们从几何角度进行推导。

(1) 标准单纯形：定义 $\mathbb{R}^n$ 的标准单纯形 Δ_n 为所有坐标非负，坐标之和不超过 1 的点集：

$$\Delta_n = \left\{ \boldsymbol{x} \in \mathbb{R}^n : x_i \geqslant 0, \sum_{i=1}^{n} x_i \leqslant 1 \right\}。$$

证明：$\mathrm{Vol}(\Delta_n) = 1/n!$。

(2) ℓ^1 单位球：定义 $\mathbb{R}^n$ 的 ℓ^1 单位球为

$$\mathbb{B}_1^n = \{ \boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\|_1 \leqslant 1 \}。$$

利用 (1) 的结论，证明：

$$\mathrm{Vol}(\mathbb{B}_1^n) = \frac{2^n}{n!} \leqslant \left(\frac{2\mathrm{e}}{n} \right)^n。$$

(3) 夹逼估计：将单位 Euclidean 球 $\mathbb{B}_2^n = \{ \boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\|_2 \leqslant 1 \}$ 夹逼于适当缩放的超立方体与 ℓ^1 球之间，证明：

$$\left(\frac{2}{\sqrt{n}} \right)^n \leqslant \mathrm{Vol}(\mathbb{B}_2^n) \leqslant \left(\frac{2\mathrm{e}}{\sqrt{n}} \right)^n。$$

因此，于高维空间，单位球的体积随维度 n 的增加呈指数级减小。

证明 (1) 利用数学归纳法。

a. 当 $n = 1$ 时，$\Delta_1 = \{ x_1 \in \mathbb{R} : x_1 \geqslant 0, x_1 \leqslant 1 \}$，容易知道，其测度为 1。

b. 假设结论对于 $n-1$ 维成立，则对于 n 维的情况，考虑对 x_n 进行切片积分，满足 $\sum_{i=1}^{n-1} x_i \leqslant 1 - x_n$，此时截面为 $(n-1)$ 维单纯形，其线性缩放因子为 $r = 1 - x_n$。

根据 Lebesgue 测度的齐次性，可得

$$\mathrm{Vol}_{n-1}(\Delta_{n-1} \cdot r) = r^{n-1} \mathrm{Vol}_{n-1}(\Delta_{n-1}),$$

因此

$$\begin{aligned} \mathrm{Vol}(\Delta_n) &= \int_0^1 \mathrm{Vol}_{n-1}(\Delta_{n-1}(1-x_n)) \mathrm{d}x_n = \int_0^1 \frac{(1-x_n)^{n-1}}{(n-1)!} \mathrm{d}x_n \\ &= \frac{1}{(n-1)!} \int_0^1 u^{n-1} \mathrm{d}u = \frac{1}{(n-1)!} \cdot \frac{1}{n} = \frac{1}{n!}。 \qquad (u = 1 - x_n) \end{aligned}$$

(2) $\mathbb{B}_1^n$ 可以被划分为 2^n 个全等的象限部分，任意的象限恰好为标准单纯形 Δ_n，因此

$$\mathrm{Vol}(\mathbb{B}_1^n) = 2^n \cdot \mathrm{Vol}(\Delta_n) = \frac{2^n}{n!} \leqslant 2^n \left(\frac{\mathrm{e}}{n} \right)^n = \left(\frac{2\mathrm{e}}{n} \right)^n。$$

(3) 对于下界，构造内接于 $\mathbb{B}_2^n$ 的超立方体 C，满足

$$\|\boldsymbol{x}\|_2^2 = \sum_{i=1}^{n} x_i^2 \leqslant \sum_{i=1}^{n} \frac{1}{n} = 1,$$

因此 $C = [-1/\sqrt{n}, 1/\sqrt{n}]^n$，其体积为

$$\mathrm{Vol}(\mathbb{B}_2^n) \geqslant \mathrm{Vol}(C) = \left(\frac{2}{\sqrt{n}} \right)^n。$$

对于上界，利用 Cauchy 不等式，可得

$$\|\boldsymbol{x}\|_1 \leqslant \sqrt{n} \|\boldsymbol{x}\|_2 \leqslant \sqrt{n},$$

因此 $\mathbb{B}_2^n \subset \sqrt{n}\mathbb{B}_1^n$，从而利用 (2) 的结论，可得

$$\begin{aligned} \mathrm{Vol}(\mathbb{B}_2^n) &\leqslant \mathrm{Vol}(\sqrt{n}\mathbb{B}_1^n) = (\sqrt{n})^n \mathrm{Vol}(\mathbb{B}_1^n) \\ &\leqslant n^{n/2} \cdot \left(\frac{2\mathrm{e}}{n} \right)^n = \frac{(2\mathrm{e})^n}{n^{n/2}} = \left(\frac{2\mathrm{e}}{\sqrt{n}} \right)^n。 \end{aligned}$$

28 [**Euclidean 球的体积：概率法**] 设 $\mathbb{B}_2^n$ 为 $\mathbb{R}^n$ 的单位 Euclidean 球。本题旨于利用概率论方法收紧习题 Q4.27 (Euclidean 球的体积：几何法) 的界。

利用小球概率估计 (Q3.7 (小球概率))，证明：

$$\operatorname{Vol}(\mathbb{B}_2^n) \leqslant \left(\sqrt{\frac{2\pi \mathrm{e}}{n}}\right)^n,$$

此界限在 $n \to \infty$ 是渐近紧的。

证明 设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，其概率密度函数为

$$f_{\boldsymbol{g}}(\boldsymbol{x}) = \frac{1}{(2\pi)^{n/2}} \mathrm{e}^{-\|\boldsymbol{x}\|_2^2/2},$$

因此

$$\begin{aligned}
\mathrm{P}\{\|\boldsymbol{g}\|_2 \leqslant \varepsilon\} &= \int_{\varepsilon \mathbb{B}_2^n} \frac{1}{(2\pi)^{n/2}} \mathrm{e}^{-\|\boldsymbol{x}\|_2^2/2} \mathrm{d}\boldsymbol{x} \\
&\geqslant \frac{\mathrm{e}^{-\varepsilon^2/2}}{(2\pi)^{n/2}} \int_{\varepsilon \mathbb{B}_2^n} \mathrm{d}\boldsymbol{x} = \frac{\mathrm{e}^{-\varepsilon^2/2}}{(2\pi)^{n/2}} \operatorname{Vol}(\varepsilon \mathbb{B}_2^n) \\
&= \frac{\mathrm{e}^{-\varepsilon^2/2}}{(2\pi)^{n/2}} \varepsilon^n \operatorname{Vol}(\mathbb{B}_2^n),
\end{aligned}$$

即

$$\operatorname{Vol}(\mathbb{B}_2^n) \leqslant \frac{(2\pi)^{n/2} \mathrm{e}^{\varepsilon^2/2}}{\varepsilon^n} \mathrm{P}\{\|\boldsymbol{g}\|_2 \leqslant \varepsilon\}。$$

根据习题 Q3.7 (小球概率)，可得对于任意的 $\varepsilon > 0$，

$$\mathrm{P}\{\|\boldsymbol{g}\|_2 \leqslant \varepsilon\} \leqslant \left(\frac{\varepsilon}{\sqrt{n}} \mathrm{e}^{\frac{n-\varepsilon^2}{2n}}\right)^n,$$

因此

$$\operatorname{Vol}(\mathbb{B}_2^n) \leqslant \frac{(2\pi)^{n/2} \mathrm{e}^{\varepsilon^2/2}}{\varepsilon^n} \cdot \left[\frac{\varepsilon}{\sqrt{n}} \exp\left(\frac{1}{2} - \frac{\varepsilon^2}{2n}\right)\right]^n = \left(\sqrt{\frac{2\pi \mathrm{e}}{n}}\right)^n。$$

29 [**Euclidean 球的体积：分析法**] 本题旨在通过分析方法精确计算 $\mathbb{B}_2^n$ 的体积。

(1) 径向积分恒等式：设 $\|\cdot\|$ 为 $\mathbb{R}^n$ 的范数，$B = \{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\| \leqslant 1\}$ 为此范数的单位球。设 $f : [0, \infty) \to [0, \infty)$ 为单调递减的可微函数，满足 $\lim_{t \to \infty} f(t) = 0$ 及 $\lim_{t \to \infty} t^n f(t) = 0$，并假设下述积分有限。证明：

$$\int_{\mathbb{R}^n} f(\|\boldsymbol{x}\|) \mathrm{d}\boldsymbol{x} = -\operatorname{Vol}(B) \int_0^\infty t^n f'(t) \mathrm{d}t。$$

(2) 精确体积公式：于 Euclidean 空间，令 $f(t) = \mathrm{e}^{-t^2/2}$，利用 (1) 的结论，证明

$$\operatorname{Vol}(\mathbb{B}_2^n) = \frac{\pi^{n/2}}{\Gamma(n/2+1)}。$$

(3) 单位体积球的半径：令 R_n 表示体积为 1 的 n 维 Euclidean 的半径。证明：

$$R_n = \sqrt{\frac{n}{2\pi \mathrm{e}}}(1 + o(1))。$$

因此 R_n 随维度增加而增长，侧面反映了单位球的体积在高维下迅速衰减。

证明 (1) 令 $V(t) = \operatorname{Vol}(tB)$ 为半径为 t 的球的体积，则 $V(t) = t^n \operatorname{Vol}(B)$。

利用分部积分法，可得

$$\int_{\mathbb{R}^n} f(\|\boldsymbol{x}\|) \mathrm{d}\boldsymbol{x} = \int_0^\infty f(t) \mathrm{d}V(t)$$

$$
\begin{aligned}
&= [f(t)V(t)]_0^\infty - \int_0^\infty V(t)f'(t)\mathrm{d}t \\
&= -\int_0^\infty \mathrm{Vol}(B)t^n f'(t)\mathrm{d}t \qquad (V(0)=0, \lim_{t\to\infty} t^n f(t)=0) \\
&= -\mathrm{Vol}(B)\int_0^\infty t^n f'(t)\mathrm{d}t,
\end{aligned}
$$

(2) 令 $f(t)=\mathrm{e}^{-t^2/2}$，则

$$
\int_{\mathbb{R}^n} \mathrm{e}^{-\|\boldsymbol{x}\|_2^2/2}\mathrm{d}\boldsymbol{x} = \prod_{j=1}^n \int_{-\infty}^\infty \mathrm{e}^{-x_j^2/2}\mathrm{d}x_j = (2\pi)^{n/2},
$$

利用 (1) 的结论，可得

$$
(2\pi)^{n/2} = -\mathrm{Vol}(\mathbb{B}_2^n)\int_0^\infty t^n(-t\mathrm{e}^{-t^2/2})\mathrm{d}t = \mathrm{Vol}(\mathbb{B}_2^n)\int_0^\infty t^{n+1}\mathrm{e}^{-t^2/2}\mathrm{d}t,
$$

其中

$$
\int_0^\infty t^{n+1}\mathrm{e}^{-t^2/2}\mathrm{d}t = \int_0^\infty (2u)^{n/2}\mathrm{e}^{-u}\mathrm{d}u = 2^{n/2}\int_0^\infty u^{n/2}\mathrm{e}^{-u}\mathrm{d}u = 2^{n/2}\Gamma\Big(\frac{n}{2}+1\Big), \qquad \Big(u=\frac{t^2}{2}\Big)
$$

因此

$$
(2\pi)^{n/2} = \mathrm{Vol}(\mathbb{B}_2^n)\cdot 2^{n/2}\Gamma\Big(\frac{n}{2}+1\Big),
$$

即

$$
\mathrm{Vol}(\mathbb{B}_2^n) = \frac{\pi^{n/2}}{\Gamma(n/2+1)}。
$$

(3) 容易知道，

$$
\mathrm{Vol}(R_n\mathbb{B}_2^n) = R_n^n\,\mathrm{Vol}(\mathbb{B}_2^n) = 1 \implies R_n^n = \frac{1}{\mathrm{Vol}(\mathbb{B}_2^n)} = \frac{\Gamma(n/2+1)}{\pi^{n/2}},
$$

其中利用 Stirling 公式 $\Gamma(k+1)\sim\sqrt{2\pi k}(k/\mathrm{e})^k$，令 $k=n/2$，

$$
\Gamma(n/2+1) \sim \sqrt{\pi n}\Big(\frac{n}{2\mathrm{e}}\Big)^{n/2},
$$

因此

$$
R_n^n \sim \frac{\sqrt{\pi n}\big(\frac{n}{2\mathrm{e}}\big)^{n/2}}{\pi^{n/2}} = \sqrt{\pi n}\Big(\frac{n}{2\pi\mathrm{e}}\Big)^{n/2},
$$

即

$$
R_n = \Big(\frac{n}{2\pi\mathrm{e}}\Big)^{1/2}(1+o(1))。
$$

30 [n 维 ℓ^p 球的体积分析] 设 $p\in[1,\infty]$，定义 $\mathbb{R}^n$ 的单位 ℓ^p 球为

$$
\mathbb{B}_p^n = \{\boldsymbol{x}\in\mathbb{R}^n : \|\boldsymbol{x}\|_p \leqslant 1\},
$$

其中 $\|\boldsymbol{x}\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$ (对于 $p=\infty$，$\|\boldsymbol{x}\|_p = \max|x_i|$)。

(1) 几何夹逼估计：参考习题 Q4.27 (Euclidean 球的体积：几何法) 的几何证明方法，证明 $\mathbb{B}_p^n$ 的体积满足

$$
\Big(\frac{2}{n^{1/p}}\Big)^n \leqslant \mathrm{Vol}(\mathbb{B}_p^n) \leqslant \Big(\frac{2\mathrm{e}}{n^{1/p}}\Big)^n。
$$

(2) 解析精确计算：当 $1\leqslant p<\infty$ 时，参考习题 Q4.29 (Euclidean 球的体积：分析法) 的解析恒等式方法，证明 $\mathbb{B}_p^n$ 的精确体积

公式为

$$\mathrm{Vol}(\mathbb{B}_p^n)=\frac{(2\Gamma(1/p+1))^n}{\Gamma(n/p+1)}。$$

证明 (1) 对于下界，构造内接于 $\mathbb{B}_p^n$ 的超立方体 $C=[-1/n^{1/p},1/n^{1/p}]^n$，则对于任意的 $\boldsymbol{x}\in C$，满足

$$\|\boldsymbol{x}\|_p^p=\sum_{i=1}^n|x_i|^p\leqslant\sum_{i=1}^n\left(\frac{1}{n^{1/p}}\right)^p=\sum_{i=1}^n\frac{1}{n}=1,$$

因此 $C\subset\mathbb{B}_p^n$，从而

$$\mathrm{Vol}(\mathbb{B}_p^n)\geqslant\mathrm{Vol}(C)=\left(\frac{2}{n^{1/p}}\right)^n。$$

对于上界，利用 Hölder 不等式，可得 $\|\boldsymbol{x}\|_1\leqslant n^{1-1/p}\|\boldsymbol{x}\|_p$，因此 $\mathbb{B}_p^n\subset n^{1-1/p}\mathbb{B}_1^n$，从而

$$\mathrm{Vol}(\mathbb{B}_p^n)\leqslant(n^{1-1/p})^n\,\mathrm{Vol}(\mathbb{B}_1^n)。$$

利用习题 Q4.27 (Euclidean 球的体积：几何法) (2) 的结论，可得

$$\mathrm{Vol}(\mathbb{B}_p^n)\leqslant n^{n-n/p}\cdot\left(\frac{2\mathrm{e}}{n}\right)^n=\frac{n^n}{n^{n/p}}\cdot\frac{(2\mathrm{e})^n}{n^n}=\left(\frac{2\mathrm{e}}{n^{1/p}}\right)^n。$$

(2) 当 $1\leqslant p<\infty$ 时，利用习题 Q4.29 (Euclidean 球的体积：分析法) (1) 的结论，

$$\int_{\mathbb{R}^n}f(\|\boldsymbol{x}\|_p)\mathrm{d}\boldsymbol{x}=-\mathrm{Vol}(\mathbb{B}_p^n)\int_0^\infty t^n f'(t)\mathrm{d}t,$$

令 $f(t)=\mathrm{e}^{-t^p}$，则

$$\begin{aligned}\int_{\mathbb{R}^n}f(\|\boldsymbol{x}\|_p)\mathrm{d}\boldsymbol{x}&=\int_{\mathbb{R}^n}\mathrm{e}^{-\|\boldsymbol{x}\|_p^p}\mathrm{d}\boldsymbol{x}=\left(\int_{-\infty}^\infty\mathrm{e}^{-|x|^p}\mathrm{d}x\right)^n=\left(2\int_0^\infty\mathrm{e}^{-|x|^p}\mathrm{d}x\right)^n\\&=\left(\frac{2}{p}\int_0^\infty u^{1/p-1}\mathrm{e}^{-u}\mathrm{d}u\right)^n=\left(\frac{2}{p}\Gamma\left(\frac{1}{p}\right)\right)^n=\left(2\Gamma\left(\frac{1}{p}+1\right)\right)^n,&(u=x^p)\\\int_0^\infty t^n f'(t)\mathrm{d}t&=-p\int_0^\infty t^{n+p-1}\mathrm{e}^{-t^p}\mathrm{d}t\\&=-p\int_0^\infty t^{n+p-1}\mathrm{e}^{-t^p}\mathrm{d}t=-\int_0^\infty u^{n/p}\mathrm{e}^{-u}\mathrm{d}u=-\Gamma\left(\frac{n}{p}+1\right),&(u=t^p)\end{aligned}$$

因此

$$\left(2\Gamma\left(\frac{1}{p}+1\right)\right)^n=\mathrm{Vol}(\mathbb{B}_p^n)\cdot\Gamma\left(\frac{n}{p}+1\right),$$

即

$$\mathrm{Vol}(\mathbb{B}_p^n)=\frac{(2\Gamma(1/p+1))^n}{\Gamma(n/p+1)}。$$

(3) 当 $p=\infty$ 时，$\mathbb{B}_\infty^n=[-1,1]^n$，因此 $\mathrm{Vol}(\mathbb{B}_\infty^n)=2^n$；这也是上述公式在 $p\to\infty$ 时的极限。

31 [**基于格点的 ε-网构造, 基数估计**] 于度量空间，利用贪心迭代法构造 ε-网 (见注记 R4.2.7 (构造 ε-网)) 通常缺乏结构性，难以存储。

现考虑一种更具算法效率的构造方法：设

$$\mathcal{N}=\left(\frac{\varepsilon}{\sqrt{n}}\mathbb{Z}^n\right)\cap\mathbb{B}_2^n。$$

证明：

(1) $\mathcal{N}$ 为 $\mathbb{B}_2^n$ 在 Euclidean 度量的意义下的 ε-网。

(2) 该格点网的基数满足

$$|\mathcal{N}|\leqslant\mathrm{e}^n\left(\frac{2}{\varepsilon}+1\right)^n。$$

(3) 说明如何快速地将单位球的任意的向量映射为 $\mathcal{N}$ 的近似向量。

证明 (1) 只需证明对于任意的 $\boldsymbol{x}\in\mathbb{B}_2^n$，至少存在 $\boldsymbol{u}\in\mathcal{N}$，满足 $\|\boldsymbol{x}-\boldsymbol{u}\|_2\leqslant\varepsilon$。

设格点步长为 $h=\varepsilon/\sqrt{n}$，$\boldsymbol{x}\in\mathbb{B}_2^n$。

对于任意的分量 x_i，选取格点 u_i，其原则为向原点方向取整，

$$u_i=\begin{cases}h\cdot\lfloor x_i/h\rfloor, x_i\geqslant 0,\\ h\cdot\lceil x_i/h\rceil\ \ x_i<0\end{cases},$$

则 $u_i\in h\mathbb{Z}$，满足

$$\|\boldsymbol{u}\|_2^2=\sum_{i=1}^n u_i^2\leqslant\sum_{i=1}^n x_i^2=\|\boldsymbol{x}\|_2^2\implies\|\boldsymbol{u}\|_2\leqslant\|\boldsymbol{x}\|_2=1,$$

因此

$$\boldsymbol{u}\in\left(\frac{\varepsilon}{\sqrt{n}}\mathbb{Z}^n\right)\cap\mathbb{B}_2^n=\mathcal{N}。$$

由于 $|x_i-u_i|\leqslant h$，因此

$$\|\boldsymbol{x}-\boldsymbol{u}\|_2^2=\sum_{i=1}^n(x_i-u_i)^2\leqslant\sum_{i=1}^n h^2=nh^2=\varepsilon^2,$$

即 $\|\boldsymbol{x}-\boldsymbol{u}\|_2\leqslant\varepsilon$，从而 $\mathcal{N}$ 为 $\mathbb{B}_2^n$ 在 Euclidean 度量的意义下的 ε-网。

(2) 对于任意的格点 $\boldsymbol{x}\in\mathcal{N}$，以其为中心构造边长为 h 的超立方体 $Q_{\boldsymbol{x}}$，其体积为 $h^n=(\varepsilon/\sqrt{n})^n$。

由于 $\boldsymbol{x}\in\mathbb{B}_2^n$，超立方体的任意一点距离中心 $\boldsymbol{x}$ 的最大距离为 $\frac{h\sqrt{n}}{2}=\varepsilon/2$，因此所有立方体均包含于半径为 $1+\varepsilon/2$ 的大球，即

$$\bigcup_{\boldsymbol{x}\in\mathcal{N}}Q_{\boldsymbol{x}}\subset\left(1+\frac{\varepsilon}{2}\right)\mathbb{B}_2^n,$$

从而

$$|\mathcal{N}|\cdot\left(\frac{\varepsilon}{\sqrt{n}}\right)^n\leqslant\mathrm{Vol}\left(\left(1+\frac{\varepsilon}{2}\right)\mathbb{B}_2^n\right)=\left(1+\frac{\varepsilon}{2}\right)^n\mathrm{Vol}(\mathbb{B}_2^n),$$

根据习题 Q4.28 (Euclidean 球的体积：概率法) 得到的上界 $\mathrm{Vol}(\mathbb{B}_2^n)\leqslant(\sqrt{2\pi\mathrm{e}/n})^n$，可得

$$\begin{aligned}|\mathcal{N}|&\leqslant\left(\frac{\sqrt{n}(1+\varepsilon/2)}{\varepsilon}\right)^n\left(\sqrt{\frac{2\pi\mathrm{e}}{n}}\right)^n=\left(\frac{\sqrt{2\pi\mathrm{e}}(1+\varepsilon/2)}{\varepsilon}\right)^n\\&\leqslant(2\mathrm{e})^n\left(\frac{1+\varepsilon/2}{\varepsilon}\right)^n=\mathrm{e}^n\left(\frac{2}{\varepsilon}+1\right)^n。\end{aligned}$$

(3) 构造以下算法：

容易知道，上述算法的时间复杂度为 $O(n)$。

32 [**Hamming 立方体的覆盖数，填充数估计**] 设 $K=\{0,1\}^n$ 为 n 维 Hamming 立方体，赋予 Hamming 度量 $d_H(\boldsymbol{x},\boldsymbol{y})=\sum_{i=1}^n\mathbf{1}_{\{x_i\neq y_i\}}$。对于 $m\in[\![0,n]\!]$，令 $\mathcal{N}(K,d_H,m)$ 表示 K 的 m-覆盖数，$\mathcal{P}(K,d_H,m)$ 表示 K 的 m-填充数。

试通过改进体积方法 (将 Lebesgue 测度替换为集合基数)，证明命题 P4.2.15 (Hamming 立方体的覆盖数, 填充数) 的结论，

$$\frac{2^n}{\sum_{k=0}^m\binom{n}{k}}\leqslant\mathcal{N}(K,d_H,m)\leqslant\mathcal{P}(K,d_H,m)\leqslant\frac{2^n}{\sum_{k=0}^{\lfloor m/2\rfloor}\binom{n}{k}}。$$

注释 于 Hamming 空间，以 $\boldsymbol{x}\in K$ 为中心、整数半径 r 的闭球定义为

$$B(\boldsymbol{x},r)=\{\boldsymbol{y}\in K:d_H(\boldsymbol{x},\boldsymbol{y})\leqslant r\},$$

其基数为 $|B(\boldsymbol{x},r)|=\sum_{k=0}^r\binom{n}{k}$，不依赖中心。这里使用基数而非 Euclidean 体积。

解答 • 证明左侧不等式

Algorithm 3: Fast-Lattice-Quantization$(\boldsymbol{x}, \varepsilon)$

输入: $\boldsymbol{x} \in \mathbb{B}_2^n$，近似参数 $\varepsilon > 0$。

输出: 格点向量

$$\boldsymbol{u} \in \mathcal{N} = \left(\frac{\varepsilon}{\sqrt{n}}\mathbb{Z}^n\right) \cap \mathbb{B}_2^n,$$

满足 $\|\boldsymbol{x} - \boldsymbol{u}\|_2 \leqslant \varepsilon$。

Part 1: 参数预设, 空间缩放

计算格点步长：$h \leftarrow \frac{\varepsilon}{\sqrt{n}}$;

将输入向量映射于整数标架空间：$\tilde{\boldsymbol{x}} \leftarrow \frac{\boldsymbol{x}}{h}$;

Part 2: 逐分量量化 (Coordinate-wise Quantization)

for $i = 1$ **to** n **do**

// 执行向原点方向取整，确保 $\|\boldsymbol{u}\|_2 \leqslant \|\boldsymbol{x}\|_2 \leqslant 1$

if $\tilde{x}_i \geqslant 0$ **then**

$\hat{x}_i \leftarrow \lfloor \tilde{x}_i \rfloor$;

end

else

$\hat{x}_i \leftarrow \lceil \tilde{x}_i \rceil$;

end

end

Part 3: 逆映射, 格点还原

构造量化之后的格点向量：$\boldsymbol{u} \leftarrow h \cdot (\hat{x}_1, \hat{x}_2, \cdots, \hat{x}_n)^\top$;

return $\boldsymbol{u}$;

设 $\mathcal{C} = \{\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N\}$ 为 K 的最小 m-覆盖，其中 $N = \mathcal{N}(K, d_H, m)$，则

$$K \subset \bigcup_{i=1}^{N} B(\boldsymbol{x}_i, m),$$

因此

$$|K| \leqslant \sum_{i=1}^{N} |B(\boldsymbol{x}_i, m)| = N \cdot \sum_{k=0}^{m} \binom{n}{k},$$

其中 $|K| = 2^n$，从而

$$N \geqslant \frac{2^n}{\sum_{k=0}^{m} \binom{n}{k}}。$$

- 证明中间不等式

  设 $\mathcal{S} = \{\boldsymbol{y}_1, \cdots, \boldsymbol{y}_P\}$ 为 K 的极大 m-填充，则 $d_H(\boldsymbol{y}_i, \boldsymbol{y}_j) > m$。

  由于上述填充是极大的，因此对于任意的 $\boldsymbol{z} \in K \setminus \mathcal{S}$，$\mathcal{S} \cup \{\boldsymbol{z}\}$ 均不再为 m-填充，从而存在 $\boldsymbol{x} \in \mathcal{S}$，使得 $d_H(\boldsymbol{x}, \boldsymbol{z}) \leqslant m$，从而 $\mathcal{S}$ 为 K 的 m-覆盖，满足

  $$\mathcal{N}(K, d_H, m) \leqslant \operatorname{card}(\mathcal{S}) = \mathcal{P}(K, d_H, m)。$$

- 设 $\mathcal{S} = \{\boldsymbol{y}_1, \cdots, \boldsymbol{y}_P\}$ 为 K 的 m-填充，其中 $P = \mathcal{P}(K, d_H, m)$。

  假设存在 $\boldsymbol{z} \in B(\boldsymbol{y}_i, r) \cap B(\boldsymbol{y}_j, r)$ $(i \neq j)$，则利用三角不等式，可得

  $$d_H(\boldsymbol{y}_i, \boldsymbol{y}_j) \leqslant d_H(\boldsymbol{y}_i, \boldsymbol{z}) + d_H(\boldsymbol{z}, \boldsymbol{y}_j) \leqslant r + r = 2\lfloor m/2 \rfloor \leqslant m,$$

这与填充条件 $d_H(\boldsymbol{y}_i,\boldsymbol{y}_j)>m$ 矛盾；如此，$\{B(\boldsymbol{y}_i,\lfloor m/2\rfloor)\}_{i=1}^{P}$ 是两两不交的，从而

$$\left|\bigcup_{i=1}^{P}B(\boldsymbol{y}_i,r)\right|=\sum_{i=1}^{P}|B(\boldsymbol{y}_i,r)|=P\cdot\sum_{k=0}^{r}\binom{n}{k}\leqslant 2^n,$$

解得

$$P\leqslant\frac{2^n}{\sum_{k=0}^{\lfloor m/2\rfloor}\binom{n}{k}}。$$

33 [**纠错码的局限性：定理 T4.3.5 的逆命题**] 考虑一个纠错码，其将 k 位信息字符串编码为 n 位代码字符串 (即码率 $R=k/n$)。若 $1\leqslant r\leqslant n$ 且此编码方案能够纠正最多 r 个错误，证明：其冗余位数 $n-k$ 满足

$$n-k\geqslant r\log_2\left(\frac{n}{r}\right)。$$

证明 设 $K=\{0,1\}^n$ 为所有可能的 n 位字符串构成的 Hamming 立方体，纠错码 $\mathcal{C}\subset K$，则 $|K|=2^n$，$|\mathcal{C}|=2^k$。

若此编码能纠正 r 个错误，则对于任意的 $\boldsymbol{c}_1,\boldsymbol{c}_2\in\mathcal{C}$，

$$d_H(\boldsymbol{c}_1,\boldsymbol{c}_2)\geqslant 2r+1,$$

因此 $B_H(\boldsymbol{c},r)=\{\boldsymbol{x}\in\{0,1\}^n:d_H(\boldsymbol{c},\boldsymbol{x})\leqslant r\}$ 对于不同的码字是互斥的。

由于

$$|B_H(\boldsymbol{c},r)|=\sum_{i=0}^{r}\binom{n}{i}\geqslant\binom{n}{r},$$

因此利用 Hamming 界，可得

$$\sum_{\boldsymbol{c}\in\mathcal{C}}|B_H(\boldsymbol{c},r)|\leqslant|K|\quad 2^k\cdot\binom{n}{r}\leqslant 2^n,$$

解得

$$n-k\geqslant\log_2\binom{n}{r}\geqslant\log_2\left(\frac{n}{r}\right)^r=r\log_2\left(\frac{n}{r}\right)。\qquad\left(\binom{n}{r}\geqslant\left(\frac{n}{r}\right)^r\right)$$

34 [**ε-网级数展开及其根据**] 设 $\mathcal{N}$ 为单位球面 $\mathbb{S}^{n-1}=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_2=1\}$ 的 ε-网 (其中 $0<\varepsilon<1$)。

(1) 级数表示：证明：对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，均可以表示为

$$\boldsymbol{x}=\sum_{k=0}^{\infty}\lambda_k\boldsymbol{x}_k。$$

其中 $0\leqslant\lambda_k\leqslant\varepsilon^k$，$\boldsymbol{x}_k\in\mathcal{N}$。

(2) 算子范数的界限：利用 (1) 的级数展开，给出引理 L4.4.1 (于离散网估计算子范数) 的另证。

注释 引理 L4.4.1 (于离散网估计算子范数)：设 $\boldsymbol{A}$ 为对称矩阵，则

$$\|\boldsymbol{A}\|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|。$$

对于一般矩阵 $\boldsymbol{A}$，

$$\|\boldsymbol{A}\|\leqslant\frac{1}{1-\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N}}\|\boldsymbol{A}\boldsymbol{x}\|_2。$$

证明 利用迭代逼近法。

1. 当 $k=0$ 时，由于 $\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，因此对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，存在 $\boldsymbol{x}_0\in\mathcal{N}$，使得

$$\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\leqslant\varepsilon。$$

此时令剩余向量为 $\boldsymbol{r}_1=\boldsymbol{x}-\boldsymbol{x}_0$，记 $\lambda_0=1$ (满足 $\lambda_0\leqslant\varepsilon^0$)。

2. 假设已经得到了前 m 项，使得 $\boldsymbol{x}=\sum_{k=0}^{m-1}\lambda_k\boldsymbol{x}_k+\boldsymbol{r}_m$，满足 $\|\boldsymbol{r}_m\|_2\leqslant\varepsilon^m$。

a. 若 $\boldsymbol{r}_m=\boldsymbol{0}$，则令后续项均为 0 即可。

b. 若 $\boldsymbol{r}_m \neq \boldsymbol{0}$，设 $\bar{\boldsymbol{r}}_m \in \mathbb{S}^{n-1}$，则存在 $\boldsymbol{x}_m \in \mathcal{N}$，使得 $\|\bar{\boldsymbol{r}}_m - \boldsymbol{x}_m\|_2 \leqslant \varepsilon$。

令 $\lambda_m = \|\boldsymbol{r}_m\|_2$，满足 $\lambda_m \leqslant \varepsilon^m$，更新剩余向量

$$\boldsymbol{r}_{m+1} = \boldsymbol{r}_m - \lambda_m \boldsymbol{x}_m = \lambda_m(\bar{\boldsymbol{r}}_m - \boldsymbol{x}_m),$$

满足 $\|\boldsymbol{r}_{m+1}\|_2 = \lambda_m \|\bar{\boldsymbol{r}}_m - \boldsymbol{x}_m\|_2 \leqslant \varepsilon^m \cdot \varepsilon = \varepsilon^{m+1}$。

重复上述过程，此时 $\|\boldsymbol{r}_m\|_2 \leqslant \varepsilon^m \to 0$，因此级数收敛，满足

$$\boldsymbol{x} = \sum_{k=0}^{\infty} \lambda_k \boldsymbol{x}_k, \quad 0 \leqslant \lambda_k \leqslant \varepsilon^k。$$

3. 利用 (1) 的结论，对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\left(\sum_{k=0}^{\infty} \lambda_k \boldsymbol{x}_k\right) = \sum_{k=0}^{\infty} \lambda_k \boldsymbol{A}\boldsymbol{x}_k,$$

令 $M = \sup_{\boldsymbol{u} \in \mathcal{N}} \|\boldsymbol{A}\boldsymbol{u}\|_2$，则

$$\|\boldsymbol{A}\boldsymbol{x}\|_2 \leqslant \sum_{k=0}^{\infty} \lambda_k \|\boldsymbol{A}\boldsymbol{x}_k\|_2 \leqslant \sum_{k=0}^{\infty} \varepsilon^k M = M \cdot \frac{1}{1-\varepsilon},$$

两侧取上确界，

$$\|\boldsymbol{A}\| \leqslant \frac{1}{1-\varepsilon} \sup_{\boldsymbol{x} \in \mathcal{N}} \|\boldsymbol{A}\boldsymbol{x}\|_2。$$

如此，我们将复杂的上确界问题转化为 ε-网的有限搜索, 简单的几何级数常数的乘积。

35 [于 ε-网计算向量范数] 设 $\boldsymbol{x} \in \mathbb{R}^n$，$\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，其中 $\varepsilon \in (0,1)$。证明：

$$\sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle \leqslant \|\boldsymbol{x}\|_2 \leqslant \frac{1}{1-\varepsilon} \sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle。$$

证明 证明下界。

容易知道，

$$\sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle \leqslant \sup_{\boldsymbol{u} \in \mathbb{S}^{n-1}} \langle \boldsymbol{x}, \boldsymbol{u} \rangle = \|\boldsymbol{x}\|_2。$$

证明上界。

若 $\boldsymbol{x} = \boldsymbol{0}$，则结论是平凡的；之后只需考虑 $\boldsymbol{x} \neq \boldsymbol{0}$ 的情况。

令 $\bar{\boldsymbol{x}} \in \mathbb{S}^{n-1}$，则 $\|\boldsymbol{x}\|_2 = \langle \boldsymbol{x}, \bar{\boldsymbol{x}} \rangle$。

由于 $\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，因此存在 $\boldsymbol{y}_0 \in \mathcal{N}$，使得 $\|\bar{\boldsymbol{x}} - \boldsymbol{y}_0\|_2 \leqslant \varepsilon$。

将 $\|\boldsymbol{x}\|_2$ 的内积表达式于网点 $\boldsymbol{y}_0$ 展开，

$$\begin{aligned} \|\boldsymbol{x}\|_2 = \langle \boldsymbol{x}, \bar{\boldsymbol{x}} \rangle &= \langle \boldsymbol{x}, \boldsymbol{y}_0 \rangle + \langle \boldsymbol{x}, \bar{\boldsymbol{x}} - \boldsymbol{y}_0 \rangle \\ &\leqslant \langle \boldsymbol{x}, \boldsymbol{y}_0 \rangle + \|\boldsymbol{x}\|_2 \|\bar{\boldsymbol{x}} - \boldsymbol{y}_0\|_2 \\ &\leqslant \langle \boldsymbol{x}, \boldsymbol{y}_0 \rangle + \varepsilon \|\boldsymbol{x}\|_2, \end{aligned}$$

解得

$$\|\boldsymbol{x}\|_2 \leqslant \frac{1}{1-\varepsilon} \sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle。$$

如此，

$$\sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle \leqslant \|\boldsymbol{x}\|_2 \leqslant \frac{1}{1-\varepsilon} \sup_{\boldsymbol{y} \in \mathcal{N}} \langle \boldsymbol{x}, \boldsymbol{y} \rangle。$$

36 [于 ε-网最大化双线性型, 二次型] 证明引理 L4.4.2 (于离散网估计对称矩阵的二次型)，方法是对引理 L4.4.1 (于离散网估计算子范数) 的证明进行修改。

设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$，令 $\varepsilon \in [0, 1/2)$。设 $\mathcal{N}, \mathcal{M}$ 分别为 $\mathbb{S}^{n-1}, \mathbb{S}^{m-1}$ 的 ε-网。

(1) 证明：

$$\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle|\leqslant\|\boldsymbol{A}\|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle|。$$

(2) 特别地，若 $m=n$，$\boldsymbol{A}$ 为对称矩阵，证明：当 $\mathcal{N}=\mathcal{M}$ 时，算子范数可以由二次型控制，

$$\|\boldsymbol{A}\|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|。$$

证明 (1) • 下界证明

由于 $\mathcal{N}\subset\mathbb{S}^{n-1}$，$\mathcal{M}\subset\mathbb{S}^{m-1}$，因此根据算子范数的变分定义 4.1.8，可得

$$\|\boldsymbol{A}\|=\sup_{\|\boldsymbol{u}\|_2=1,\|\boldsymbol{v}\|_2=1}|\langle\boldsymbol{A}\boldsymbol{u},\boldsymbol{v}\rangle|。$$

因此

$$\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle|\leqslant\|\boldsymbol{A}\|。$$

• 上界证明

根据算子范数的定义 4.1.8，可得存在 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{S}^{n-1}$，使得 $\|\boldsymbol{A}\|=\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle$。

根据 ε-网的定义 (Q4.23 (ε-网的传递性))，可得存在 $\boldsymbol{x}_0\in\mathcal{N}$，$\boldsymbol{y}_0\in\mathcal{M}$，满足

$$\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\leqslant\varepsilon，\ \|\boldsymbol{y}-\boldsymbol{y}_0\|_2\leqslant\varepsilon。$$

将双线性展开，

$$\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle=\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{y}_0\rangle+\langle\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0),\boldsymbol{y}\rangle+\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{y}-\boldsymbol{y}_0\rangle，$$

两侧取绝对值，

$$\begin{aligned}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle|&\leqslant|\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{y}_0\rangle|+\|\boldsymbol{A}\|\cdot\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\cdot\|\boldsymbol{y}\|_2+\|\boldsymbol{A}\|\cdot\|\boldsymbol{x}_0\|_2\cdot\|\boldsymbol{y}-\boldsymbol{y}_0\|_2\\&\leqslant\sup_{\boldsymbol{x}_0\in\mathcal{N},\boldsymbol{y}_0\in\mathcal{M}}|\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{y}_0\rangle|+2\varepsilon\|\boldsymbol{A}\|，\end{aligned}$$

即

$$\|\boldsymbol{A}\|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle|。$$

(2) 若 $\boldsymbol{A}$ 为对称矩阵，则 $\|\boldsymbol{A}\|=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|$。

设 $\boldsymbol{x}\in\mathbb{S}^{n-1}$ 使得 $\|\boldsymbol{A}\|=|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|$，令 $\boldsymbol{x}_0\in\mathcal{N}$ 使得 $\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\leqslant\varepsilon$。

考虑二次型的偏差，

$$|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle-\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{x}_0\rangle|=|\langle\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0),\boldsymbol{x}\rangle+\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{x}-\boldsymbol{x}_0\rangle|，$$

因此

$$\begin{aligned}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|&\leqslant|\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{x}_0\rangle|+\|\boldsymbol{A}\|\cdot\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\cdot\|\boldsymbol{x}\|_2+\|\boldsymbol{A}\|\cdot\|\boldsymbol{x}_0\|_2\cdot\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\\&\leqslant\sup_{\boldsymbol{x}_0\in\mathcal{N}}|\langle\boldsymbol{A}\boldsymbol{x}_0,\boldsymbol{x}_0\rangle|+2\varepsilon\|\boldsymbol{A}\|，\end{aligned}$$

即

$$\|\boldsymbol{A}\|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N}}|\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{x}\rangle|。$$

37 [ε-网上范数偏离的控制] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，$\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，其中 $\varepsilon\in[0,1/2)$。对于 $\mu\in\mathbb{R}$，分别定义全域偏离, ε-网的最大偏离为

$$E=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|，\ \delta=\sup_{\boldsymbol{x}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|，$$

证明：于 $\mathbb{S}^{n-1}$ 的全域范数偏离可以由于 $\mathcal{N}$ 的局部范数偏离所控制，即

$$E\leqslant\frac{C}{1-2\varepsilon}\delta。\qquad(C>0)$$

注释 以下是错误的尝试：

根据 ε-网的定义 (Q4.23 (ε-网的传递性))，可得对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，存在 $\boldsymbol{x}_0\in\mathcal{N}$，使得 $\|\boldsymbol{x}-\boldsymbol{x}_0\|_2\leqslant\varepsilon$，因此

$$\begin{aligned}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|&\leqslant|\|\boldsymbol{A}\boldsymbol{x}\|_2-\|\boldsymbol{A}\boldsymbol{x}_0\|_2|+|\|\boldsymbol{A}\boldsymbol{x}_0\|_2-\mu|\\&\leqslant\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0)\|_2+(\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_0)\|_2+\delta)。\end{aligned}$$

令 $\boldsymbol{h}=\boldsymbol{x}-\boldsymbol{x}_0$，满足 $\|\boldsymbol{h}\|_2\leqslant\varepsilon$。

若 $\boldsymbol{h}=\boldsymbol{0}$，则结论是平凡的；之后只需考虑 $\boldsymbol{h}\neq\boldsymbol{0}$ 的情况。

令 $\boldsymbol{u}=\bar{\boldsymbol{h}}\in\mathbb{S}^{n-1}$，则

$$\|\boldsymbol{A}\boldsymbol{h}\|_2=\|\boldsymbol{h}\|_2\cdot\|\boldsymbol{A}\boldsymbol{u}\|_2\leqslant\varepsilon\|\boldsymbol{A}\boldsymbol{u}\|_2,$$

其中

$$\|\boldsymbol{A}\boldsymbol{u}\|_2\leqslant|\|\boldsymbol{A}\boldsymbol{u}\|_2-\mu|+|\mu|\leqslant E+|\mu|,$$

因此

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|\leqslant\varepsilon(E+|\mu|)+\delta,$$

两侧取上确界，

$$E\leqslant\varepsilon E+\varepsilon|\mu|+\delta\implies E\leqslant\frac{\varepsilon|\mu|+\delta}{1-\varepsilon}。$$

可以发现，直接对绝对值进行放缩会不可避免地引入与 μ 相关的交叉项，导致证明陷入僵局。

证明 先处理 $\mu\leqslant0$ 的情形。令 $M=\|\boldsymbol{A}\|$，并令 $a_0=\sup_{\boldsymbol{y}\in\mathcal{N}}\|\boldsymbol{A}\boldsymbol{y}\|_2$。由习题 Q4.35 (于 ε-网计算向量范数)，$M\leqslant a_0/(1-\varepsilon)$；又因 $-\mu\geqslant0$，有

$$E=M-\mu\leqslant\frac{a_0-\mu}{1-\varepsilon}\leqslant\frac{\delta}{1-\varepsilon}。$$

下面设 $\mu\geqslant0$。构造对称矩阵 $\boldsymbol{M}=\boldsymbol{A}^\top\boldsymbol{A}-\mu^2\boldsymbol{I}_n$，则

$$|\boldsymbol{x}^\top\boldsymbol{M}\boldsymbol{x}|=|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-\mu^2|。$$

根据引理 L4.4.2 (于离散网估计对称矩阵的二次型) (对称矩阵二次型于 ε-网的最大化)，可得

$$\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-\mu^2|\leqslant\frac{1}{1-2\varepsilon}\sup_{\boldsymbol{y}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{y}\|_2^2-\mu^2|。$$

对于左侧，注意到

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-\mu^2|=|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|\cdot(\|\boldsymbol{A}\boldsymbol{x}\|_2+\mu),$$

由于 $\mathbb{S}^{n-1}$ 为紧集，因此存在 $\boldsymbol{x}^*\in\mathbb{S}^{n-1}$，使得 $E=|\|\boldsymbol{A}\boldsymbol{x}^*\|_2-\mu|$，从而

$$\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-\mu^2|\geqslant|\|\boldsymbol{A}\boldsymbol{x}^*\|_2^2-\mu^2|=E\cdot(\|\boldsymbol{A}\boldsymbol{x}^*\|_2+\mu)。$$

对于右侧，

$$\begin{aligned}\sup_{\boldsymbol{y}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{y}\|_2^2-\mu^2|&=\sup_{\boldsymbol{y}\in\mathcal{N}}[|\|\boldsymbol{A}\boldsymbol{y}\|_2-\mu|\cdot(\|\boldsymbol{A}\boldsymbol{y}\|_2+\mu)]\\&=\left(\sup_{\boldsymbol{y}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{y}\|_2-\mu|\right)\cdot\left(\sup_{\boldsymbol{y}\in\mathcal{N}}(\|\boldsymbol{A}\boldsymbol{y}\|_2+\mu)\right)\\&\leqslant\delta\cdot(\|\boldsymbol{A}\|+\mu)。\end{aligned}$$

如此，

$$E\cdot(\|\boldsymbol{A}\boldsymbol{x}^*\|_2+\mu)\leqslant\frac{1}{1-2\varepsilon}\delta\cdot(\|\boldsymbol{A}\|+\mu),$$

即

$$E\leqslant\frac{1}{1-2\varepsilon}\delta\underbrace{\frac{\|\boldsymbol{A}\|+\mu}{\|\boldsymbol{A}\boldsymbol{x}^*\|_2+\mu}}_{R}。$$

定义 $g(\boldsymbol{x})=\|\boldsymbol{A}\boldsymbol{x}\|_2$，则其于 $\mathbb{S}^{n-1}$ 的最大值为 $M=\|\boldsymbol{A}\|$，最小值为 $m\geqslant 0$。由于 $E=\max_{\boldsymbol{x}}|g(\boldsymbol{x})-\mu|$ 只能在极值点取得，即 $\|\boldsymbol{A}\boldsymbol{x}^*\|_2=M$ 或 m，因此我们考虑以下情况：

a. 若 $\|\boldsymbol{A}\boldsymbol{x}^*\|_2=M=\|\boldsymbol{A}\|$，则

$$R=\frac{\|\boldsymbol{A}\|+\mu}{\|\boldsymbol{A}\|+\mu}=1\ 从而 E\leqslant\frac{1}{1-2\varepsilon}\delta。$$

b. 若 $\|\boldsymbol{A}\boldsymbol{x}^*\|_2=m$，此时下端的偏离大于上端的偏离，即

$$\mu-m\geqslant M-\mu\ 因而 2\mu\geqslant M+m\geqslant M\ 从而 \mu\geqslant\frac{1}{2}M=\frac{1}{2}\|\boldsymbol{A}\|,$$

则

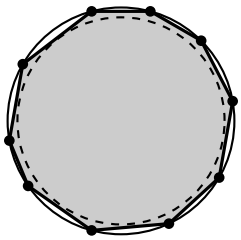
$$R=\frac{M+\mu}{m+\mu}\leqslant\frac{\mu/2+\mu}{0+\mu}=3\ 从而 E\leqslant\frac{3}{1-2\varepsilon}\delta。$$

综上，令 $C=3$，

$$\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|\leqslant\frac{3}{1-2\varepsilon}\sup_{\boldsymbol{x}\in\mathcal{N}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mu|。$$

38 [ε-网的凸包包含性质] 设 $\mathcal{N}$ 为 $\mathbb{S}^{n-1}$ 的 ε-网，其中 $\varepsilon\in(0,1)$。证明：$\mathcal{N}$ 的凸包必定包含半径为 $1-\varepsilon$ 的同心闭球，即

$$(1-\varepsilon)\mathbb{B}_2^n\subset\operatorname{conv}(\mathcal{N})。$$



证明 利用反证法，假设结论不成立，即存在 $\boldsymbol{x}\in(1-\varepsilon)\mathbb{B}_2^n$，满足 $\boldsymbol{x}\notin\operatorname{conv}(\mathcal{N})$。

由于 $\mathbb{S}^{n-1}$ 为紧集，因此 $\mathcal{N}$ 可以取为有限集，此时 $\operatorname{conv}(\mathcal{N})$ 为紧凸集。

根据严格分离定理 [空间的点, 不包含此点的闭凸集，可以被超平面严格分离]，可得存在 $\boldsymbol{\theta}\in\mathbb{S}^{n-1}$，使得

$$\sup_{\boldsymbol{y}\in\operatorname{conv}(\mathcal{N})}\langle\boldsymbol{y},\boldsymbol{\theta}\rangle<\langle\boldsymbol{x},\boldsymbol{\theta}\rangle,$$

由于线性泛函于凸包的上确界即为其于生成集的上确界，因此

$$\sup_{\boldsymbol{y}\in\mathcal{N}}\langle\boldsymbol{y},\boldsymbol{\theta}\rangle<\langle\boldsymbol{x},\boldsymbol{\theta}\rangle,$$

其中

$$\langle\boldsymbol{x},\boldsymbol{\theta}\rangle\leqslant\|\boldsymbol{x}\|_2\|\boldsymbol{\theta}\|_2\leqslant(1-\varepsilon)\cdot 1=1-\varepsilon,$$

因此

$$\sup_{\boldsymbol{y}\in\mathcal{N}}\langle\boldsymbol{y},\boldsymbol{\theta}\rangle<1-\varepsilon。$$

根据 ε-网的定义 (Q4.23 (ε-网的传递性))，可得存在 $\boldsymbol{y}_0\in\mathcal{N}$，使得 $\|\boldsymbol{\theta}-\boldsymbol{y}_0\|_2\leqslant\varepsilon$，因此

$$\begin{aligned}\langle\boldsymbol{y}_0,\boldsymbol{\theta}\rangle&=\langle\boldsymbol{\theta}-(\boldsymbol{\theta}-\boldsymbol{y}_0),\boldsymbol{\theta}\rangle\\&=\|\boldsymbol{\theta}\|_2^2-\langle\boldsymbol{\theta}-\boldsymbol{y}_0,\boldsymbol{\theta}\rangle=1-\langle\boldsymbol{\theta}-\boldsymbol{y}_0,\boldsymbol{\theta}\rangle\\&\geqslant 1-\|\boldsymbol{\theta}-\boldsymbol{y}_0\|_2\|\boldsymbol{\theta}\|_2\geqslant(1-\varepsilon)\cdot 1=1-\varepsilon,\end{aligned}$$

即

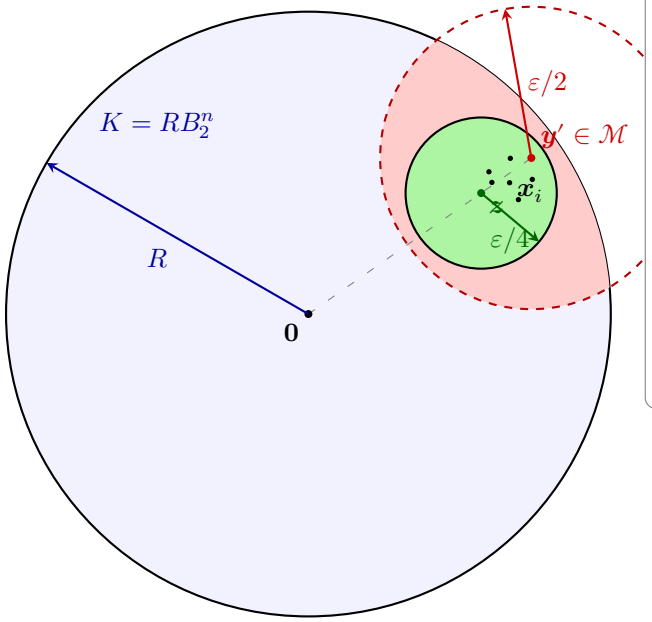
$$\sup_{\boldsymbol{y}\in\mathcal{N}}\langle\boldsymbol{y},\boldsymbol{\theta}\rangle\geqslant 1-\varepsilon,$$

矛盾；如此，$(1-\varepsilon)\mathbb{B}_2^n\subset\operatorname{conv}(\mathcal{N})$。

39 [随机点集构成 ε-网] 设 $\boldsymbol{g}_1,\cdots,\boldsymbol{g}_N$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。对于任意的半径 $R>0$, 精度 $\varepsilon>0$，证明：当 $N\geqslant \mathrm{e}^{C_{R,\varepsilon}n}$ 时，随机点集

$$\mathcal{N}_X=\left\{\frac{\boldsymbol{g}_1}{\sqrt{n}},\cdots,\frac{\boldsymbol{g}_N}{\sqrt{n}}\right\}\cap R\mathbb{B}_2^n$$

以高概率 $1-\mathrm{e}^{-cn}$ 构成中心球 $K=R\mathbb{B}_2^n$ 的 ε-网。



构造证明的几何逻辑：

1. 浅蓝色大球为目标空间 $K=R\mathbb{B}_2^n$。
2. $\boldsymbol{y}'$ 是预先确定的参考 $\varepsilon/2$-网 $\mathcal{M}$ 的一点。
3. 红色虚线圆为 $B(\boldsymbol{y}',\varepsilon/2)$，红色阴影区即为交集 $V_{\boldsymbol{y}'}=B(\boldsymbol{y}',\varepsilon/2)\cap K$。
4. 为了计算概率下界，我们在 $V_{\boldsymbol{y}'}$ 的内部寻找完全包含在内的绿色小球 $B(\boldsymbol{z},\varepsilon/4)$。
5. 通过将 $\boldsymbol{y}'$ 向原点方向收缩距离 $\frac{\varepsilon}{4R}\|\boldsymbol{y}'\|_2$，得到中心 $\boldsymbol{z}$，保证绿色小球不超出蓝色大球边界，红色虚线边界。
6. 若随机采样点 $\boldsymbol{x}_i$ 落于绿色小球，则其必定落于红色交集区，从而成功覆盖 $\boldsymbol{y}'$。

证明 若 $\varepsilon>2R$，则原点本身即为平凡的 ε-网，结论是平凡的；之后只需考虑 $\varepsilon\leqslant 2R$ 的情况。

- 建立离散的参考网

  根据推论 C4.2.11 (Euclidean 球的覆盖数)，可得于 $K=R\mathbb{B}_2^n$ 存在 $(\varepsilon/2)$-网 $\mathcal{M}$，使得

  $$|\mathcal{M}|\leqslant\left(1+\frac{2R}{\varepsilon/2}\right)^n=\left(1+\frac{4R}{\varepsilon}\right)^n。$$

  若 $\mathcal{N}_X$ 为 K 的 ε-网，则对于任意的 $\boldsymbol{y}'\in\mathcal{M}$，均满足

  $$\mathcal{N}_X\cap B(\boldsymbol{y}',\varepsilon/2)\neq\emptyset,$$

  此时对于任意的 $\boldsymbol{y}\in K$，存在 $\boldsymbol{y}'\in\mathcal{M}$，使得 $\|\boldsymbol{y}-\boldsymbol{y}'\|_2\leqslant\varepsilon/2$，存在 $\boldsymbol{x}_i\in\mathcal{N}_X$，使得 $\|\boldsymbol{x}_i-\boldsymbol{y}'\|_2\leqslant\varepsilon/2$，因此

  $$\|\boldsymbol{x}_i-\boldsymbol{y}\|_2\leqslant\|\boldsymbol{x}_i-\boldsymbol{y}'\|_2+\|\boldsymbol{y}'-\boldsymbol{y}\|_2\leqslant\varepsilon。$$

- 构造内部小球以计算概率下界

  设 $\boldsymbol{y}'\in\mathcal{M}$，$V_{\boldsymbol{y}'}=B(\boldsymbol{y}',\varepsilon/2)\cap K$。

  考虑 $B(\boldsymbol{z},\varepsilon/4)$，其中

  $$\boldsymbol{z}=(1-\frac{\varepsilon}{4R})\boldsymbol{y}',$$

  则对于任意的 $\boldsymbol{x}\in B(\boldsymbol{z},\varepsilon/4)$，

  $$\|\boldsymbol{x}\|_2\leqslant\|\boldsymbol{z}\|_2+\frac{\varepsilon}{4}=\left(1-\frac{\varepsilon}{4R}\right)\|\boldsymbol{y}'\|_2+\frac{\varepsilon}{4}\leqslant\left(1-\frac{\varepsilon}{4R}\right)R+\frac{\varepsilon}{4}=R\implies\boldsymbol{x}\in K,$$

  $$\|\boldsymbol{x}-\boldsymbol{y}'\|_2\leqslant\|\boldsymbol{x}-\boldsymbol{z}\|_2+\|\boldsymbol{z}-\boldsymbol{y}'\|_2\leqslant\frac{\varepsilon}{4}+\frac{\varepsilon}{4R}\|\boldsymbol{y}'\|_2\leqslant\frac{\varepsilon}{4}+\frac{\varepsilon}{4}=\frac{\varepsilon}{2}\implies\boldsymbol{x}\in B\left(\boldsymbol{y}',\frac{\varepsilon}{2}\right),$$

  因此 $B(\boldsymbol{z},\varepsilon/4)\subset V_{\boldsymbol{y}'}$。

- 计算单点落于小球的概率下界

  令 $\boldsymbol{x}_1 = \boldsymbol{g}_1/\sqrt{n}$ 为单次随机采样，记 $p_0 = \mathrm{P}\{\boldsymbol{x}_1 \in V_{\boldsymbol{y}'}\}$，则

  $$p_0 = \mathrm{P}\{\boldsymbol{x}_1 \in V_{\boldsymbol{y}'}\} \geqslant \mathrm{P}\{\boldsymbol{x}_1 \in B(\boldsymbol{z}, \varepsilon/4)\}。$$

  由于 $\boldsymbol{x}_1 \in K$，因此 $\|\boldsymbol{x}_1\|_2 \leqslant R$，从而

  $$f(\boldsymbol{x}_1) = \left(\frac{n}{2\pi}\right)^{n/2} \mathrm{e}^{-n\|\boldsymbol{x}_1\|_2^2/2} \geqslant \left(\frac{n}{2\pi}\right)^{n/2} \mathrm{e}^{-nR^2/2}。$$

  利用习题 Q4.27 (Euclidean 球的体积：几何法) (3) 的结论 ($\mathrm{Vol}(\mathbb{B}_2^n) \geqslant (2/\sqrt{n})^n$)，可得

  $$\mathrm{Vol}\left(B\left(\boldsymbol{z}, \frac{\varepsilon}{4}\right)\right) = \left(\frac{\varepsilon}{4}\right)^n \mathrm{Vol}(\mathbb{B}_2^n) \geqslant \left(\frac{\varepsilon}{4}\right)^n \left(\frac{2}{\sqrt{n}}\right)^n = \left(\frac{\varepsilon}{2\sqrt{n}}\right)^n,$$

  因此

  $$p_0 \geqslant \left(\frac{\varepsilon}{2\sqrt{n}}\right)^n \left(\frac{n}{2\pi}\right)^{n/2} \mathrm{e}^{-nR^2/2} = \left(\frac{\varepsilon}{2\sqrt{2\pi}}\right)^n \mathrm{e}^{-nR^2/2} = \mathrm{e}^{-c_1 n}。 \qquad \left(c_1 = \frac{R^2}{2} + \ln\left(\frac{2\sqrt{2\pi}}{\varepsilon}\right)\right)$$

- 根据并集界得出全局界限

  设 $\boldsymbol{y}' \in \mathcal{M}$，$N$ 个点无一落于其 $\varepsilon/2$ 邻域的概率为 $(1-p_0)^N \leqslant \mathrm{e}^{-p_0 N}$。

  对 $\mathcal{M}$ 的所有点根据并集界，可得网络构造失败的概率为

  $$\mathrm{P}(\mathrm{Fail}) \leqslant |\mathcal{M}|\mathrm{e}^{-p_0 N} \leqslant \left(1 + \frac{4R}{\varepsilon}\right)^n \exp(-N\mathrm{e}^{-c_1 n})。$$

  令 $\mathrm{P}(\mathrm{Fail}) \leqslant \mathrm{e}^{-cn}$，其中 $c = 1$，则

  $$\exp\left(n\ln\left(1 + \frac{4R}{\varepsilon}\right) - N\mathrm{e}^{-c_1 n}\right) \leqslant \mathrm{e}^{-n},$$

  解得

  $$N \geqslant \mathrm{e}^{c_1 n} \cdot n\left(\ln\left(1 + \frac{4R}{\varepsilon}\right) + 1\right),$$

  即

  $$N \geqslant \mathrm{e}^{c_1 n} \cdot \mathrm{e}^{n}\left(\ln\left(1 + \frac{4R}{\varepsilon}\right) + 1\right)。$$

  如此，定义

  $$C_{R,\varepsilon} = c_1 + 1 + \ln\left(\ln\left(1 + \frac{4R}{\varepsilon}\right) + 1\right),$$

  则当 $N \geqslant \mathrm{e}^{C_{R,\varepsilon} n}$ 时，随机点集以高概率构成 K 的 ε-网 (w.p. $1 - \mathrm{e}^{-n}$)。

40 [**过多的随机点不处于凸位置**] 于习题 Q3.23 (高维随机点集的凸位置性质)，我们已知若 $N \leqslant \mathrm{e}^{cn}$，则 $\boldsymbol{g}_1, \cdots, \boldsymbol{g}_N$ i.i.d. $\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$ 处于凸位置 (w.h.p.)。

证明其逆命题：存在 $C, c > 0$，使得当 $N \geqslant \mathrm{e}^{Cn}$ 时，$\boldsymbol{g}_1, \cdots, \boldsymbol{g}_N$ 以高概率不处于凸位置 (w.p. $1 - \mathrm{e}^{-cn}$)。

证明 根据习题 Q4.38 (ε-网的凸包包含性质)，可得

$$(R - \varepsilon)\mathbb{B}_2^n \subset \mathrm{conv}(\mathcal{N})。$$

令 $R = 2$，$\varepsilon = 0.5$，我们将点集分为目标点 $\boldsymbol{g}_N$ 和剩余点集 $\mathcal{P} = \{\boldsymbol{g}_1, \cdots, \boldsymbol{g}_{N-1}\}$，之后对空间进行缩放 $1/\sqrt{n}$，并记 $\tilde{\boldsymbol{g}}_i = \boldsymbol{g}_i/\sqrt{n}$，令缩放之后的集合为

$$\tilde{\mathcal{P}} = \left\{\frac{\boldsymbol{g}_1}{\sqrt{n}}, \cdots, \frac{\boldsymbol{g}_{N-1}}{\sqrt{n}}\right\}。$$

对于 $\tilde{\mathcal{P}}$，根据习题 Q4.39 (随机点集构成 ε-网)，令

$$\mathcal{E}_1 = \{\tilde{\mathcal{P}} \cap 2\mathbb{B}_2^n \text{ 构成 } 2\mathbb{B}_2^n \text{ 的 } 0.5\text{-网}\},$$

可得存在 $C_0 = C_{2,0.5}$，使得当 $N - 1 \geqslant \mathrm{e}^{C_0 n}$ 时，$\mathrm{P}(\mathcal{E}_1) \geqslant 1 - \mathrm{e}^{-c_1 n}$，其中 $c_1 > 0$。

当 $\mathcal{E}_1$ 发生时，

$$(2-0.5)\mathbb{B}_2^n \subset \mathrm{conv}(\tilde{\mathcal{P}} \cap 2\mathbb{B}_2^n) \subset \mathrm{conv}(\tilde{\mathcal{P}}),$$

即 $1.5\mathbb{B}_2^n \subset \mathrm{conv}(\tilde{\boldsymbol{g}}_1, \cdots, \tilde{\boldsymbol{g}}_{N-1})$。

对于 $\boldsymbol{g}_N$，令

$$\mathcal{E}_2 = \{\|\boldsymbol{g}_N\|_2 \leqslant 1.5\sqrt{n}\},$$

根据定理 T3.1.1 (范数的集中) [Gaussian 向量范数的浓度不等式]，可得存在 $c_2 > 0$，使得

$$\mathrm{P}\{|\|\boldsymbol{g}_N\|_2 - \sqrt{n}| \geqslant 0.5\sqrt{n}\} \leqslant 2\mathrm{e}^{-c_2 n},$$

即 $\mathrm{P}(\mathcal{E}_2) \geqslant 1 - 2\mathrm{e}^{-c_2 n}$。

当 $\mathcal{E}_2$ 发生时，

$$\tilde{\boldsymbol{g}}_N = \frac{\boldsymbol{g}_N}{\sqrt{n}} \in 1.5\mathbb{B}_2^n。$$

如此，令 $C = C_0 + 1$，当 $N \geqslant \mathrm{e}^{Cn}$ 时，

$$\mathrm{P}(\mathcal{E}_1 \cap \mathcal{E}_2) = 1 - \mathrm{P}(\mathcal{E}_1^c \cup \mathcal{E}_2^c) \geqslant 1 - \mathrm{P}(\mathcal{E}_1^c) - \mathrm{P}(\mathcal{E}_2^c) \geqslant 1 - \mathrm{e}^{-c_1 n} - 2\mathrm{e}^{-c_2 n},$$

令 $c = \min\{c_1, c_2\}/2$，则 $\mathrm{P}(\mathcal{E}_1 \cap \mathcal{E}_2) \geqslant 1 - \mathrm{e}^{-cn}$。

当 $\mathcal{E}_1 \cap \mathcal{E}_2$ 发生时，$\tilde{\boldsymbol{g}}_N \in 1.5\mathbb{B}_2^n$，$1.5\mathbb{B}_2^n \subset \mathrm{conv}(\tilde{\boldsymbol{g}}_1, \cdots, \tilde{\boldsymbol{g}}_{N-1})$，从而

$$\tilde{\boldsymbol{g}}_N \in \mathrm{conv}(\tilde{\boldsymbol{g}}_1, \cdots, \tilde{\boldsymbol{g}}_{N-1}),$$

即

$$\boldsymbol{g}_N \in \mathrm{conv}(\boldsymbol{g}_1, \cdots, \boldsymbol{g}_{N-1})。$$

41 [**随机矩阵的期望算子范数, 奇异值界限**] 设 $m \geqslant n$ 且 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，其行向量 $\boldsymbol{A}_i$ 为相互独立的零均值 sub-Gaussian 随机向量，满足 $\max_i \|\boldsymbol{A}_i\|_{\psi_2} \leqslant K$。假设 $\boldsymbol{A}$ 满足单位协方差归一化条件

$$\frac{1}{m}\mathrm{E}[\boldsymbol{A}^\top \boldsymbol{A}] = \boldsymbol{I}_n。$$

(1) 利用定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界)，证明：

$$\mathrm{E}\|\boldsymbol{A}\| \leqslant CK(\sqrt{m} + \sqrt{n})。$$

(2) 利用定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，证明：

$$\mathrm{E}\left\|\frac{1}{m}\boldsymbol{A}^\top \boldsymbol{A} - \boldsymbol{I}_n\right\| \leqslant CK^2\left(\sqrt{\frac{n}{m}} + \frac{n}{m}\right)。$$

之后推导奇异值的期望界限，

$$\sqrt{m} - CK^2\sqrt{n} \leqslant \mathrm{E}[s_n(\boldsymbol{A})] \leqslant \mathrm{E}[s_1(\boldsymbol{A})] \leqslant \sqrt{m} + CK^2\sqrt{n}。 \qquad (C > 0)$$

证明 (1) 根据定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，可得

$$\begin{aligned}\mathrm{E}\|\boldsymbol{A}\| &\leqslant C\left(\sqrt{\sum_{i=1}^m \|\boldsymbol{A}_i\|_{\psi_2}^2} + \max_i \|\boldsymbol{A}_i\|_{\psi_2} \cdot \sqrt{n}\right) \\ &\leqslant C(\sqrt{mK^2} + K\sqrt{n}) = CK(\sqrt{m} + \sqrt{n})。\end{aligned}$$

(2) 记随机协方差矩阵为

$$\boldsymbol{S} = \frac{1}{m}\boldsymbol{A}^\top \boldsymbol{A},$$

满足 $\mathrm{E}[\boldsymbol{S}] = \boldsymbol{I}_n$，则根据定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，可得当 $m \geqslant n$ 时，

$$\mathrm{E}\|\boldsymbol{S} - \boldsymbol{I}_n\| \leqslant \delta_n = CK^2\left(\sqrt{\frac{n}{m}} + \frac{n}{m}\right)。$$

设 $\sigma_i(\boldsymbol{S})$ 为 $\boldsymbol{S}$ 的特征值，则

$$\sigma_i(\boldsymbol{S}) = s_i\left(\frac{1}{\sqrt{m}}\boldsymbol{A}\right)^2 = \frac{s_i(\boldsymbol{A})^2}{m},$$

利用引理 L4.1.14 (Weyl 不等式) (Weyl 不等式)，可得

$$|\sigma_i(\boldsymbol{S}) - \sigma_i(\boldsymbol{I}_n)| \leqslant \|\boldsymbol{S} - \boldsymbol{I}_n\|,$$

即

$$\left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right| \leqslant \|\boldsymbol{S} - \boldsymbol{I}_n\|,$$

两侧取期望，

$$\mathrm{E}\left[\left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right|\right] \leqslant \mathrm{E}\|\boldsymbol{S} - \boldsymbol{I}_n\| \leqslant \delta_n。$$

令

$$a = \frac{s_i(\boldsymbol{A})^2}{m}。$$

由于 $a \geqslant 0$，可得

$$|\sqrt{a} - 1| = \frac{|a-1|}{\sqrt{a}+1} \leqslant |a-1|。$$

即

$$1 - \left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right| \leqslant \frac{s_i(\boldsymbol{A})}{\sqrt{m}} \leqslant 1 + \left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right|。$$

两侧取期望，可得

$$\mathrm{E}\left[\frac{s_i(\boldsymbol{A})}{\sqrt{m}}\right] \geqslant 1 - \mathrm{E}\left[\left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right|\right] \geqslant 1 - \delta_n,$$

$$\mathrm{E}\left[\frac{s_i(\boldsymbol{A})}{\sqrt{m}}\right] \leqslant 1 + \mathrm{E}\left[\left|\frac{s_i(\boldsymbol{A})^2}{m} - 1\right|\right] \leqslant 1 + \delta_n。$$

由于 $m \geqslant n$，可得

$$\sqrt{m}\delta_n \leqslant CK^2\left(\sqrt{n} + \frac{n}{\sqrt{m}}\right) \leqslant 2CK^2\sqrt{n}。$$

即

$$\sqrt{m} - C'K^2\sqrt{n} \leqslant \mathrm{E}[s_n(\boldsymbol{A})] \leqslant \mathrm{E}[s_1(\boldsymbol{A})] \leqslant \sqrt{m} + C'K^2\sqrt{n}。$$

42 [**随机矩阵算子范数的下界**] 为定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界) 证明一个匹配的下界。设 $\boldsymbol{A} = (A_{ij}) \in \mathbb{R}^{m\times n}$，其中 A_{ij} 是相互独立的标准化 K-sub-Gaussian 随机变量 (即 $\mathrm{E}[A_{ij}] = 0, \mathrm{E}[A_{ij}^2] = 1, \|A_{ij}\|_{\psi_2} \leqslant K$)。证明：对于任意的 $t > 0$，

$$\mathrm{P}\left\{\|\boldsymbol{A}\| \geqslant \frac{1}{2}(\sqrt{m} + \sqrt{n} - t)\right\} \geqslant 1 - 2\exp\left(-\frac{ct^2}{K^4}\right)。 \qquad (c > 0)$$

注释 以下为错误的尝试：

设 $\boldsymbol{x} \in \mathbb{R}^n, \boldsymbol{y} \in \mathbb{R}^m$ 为相互独立的标准正态随机向量，定义 $\bar{\boldsymbol{x}} \in \mathbb{S}^{n-1}$，$\bar{\boldsymbol{y}} \in \mathbb{S}^{m-1}$，则根据算子范数的变分定义 4.1.8，可得

$$\|\boldsymbol{A}\| = \sup_{\bar{\boldsymbol{x}}\in\mathbb{S}^{n-1}, \bar{\boldsymbol{y}}\in\mathbb{S}^{m-1}} \langle \boldsymbol{A}\bar{\boldsymbol{x}}, \bar{\boldsymbol{y}}\rangle \geqslant \frac{\boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x}}{\|\boldsymbol{x}\|_2\|\boldsymbol{y}\|_2}。$$

设 $L = \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x} = \sum_{i,j} A_{ij}x_jy_i$，则 $\boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x}$ 为 K-sub-Gaussian 随机变量，满足

$$\mathrm{E}[L] = \sum_{i,j} A_{ij}\mathrm{E}[x_j]\mathrm{E}[y_i] = 0,$$

$$\mathrm{E}[L^2] = \sum_{i,j} \mathrm{E}[A_{ij}^2]\mathrm{E}[x_j^2]\mathrm{E}[y_i^2] = \sum_{i,j} 1 = mn,$$

但是试图用两个随机向量的双线性型来求下界会引入复杂的耦合问题。

证明 根据算子范数的定义 4.1.8 $\|\boldsymbol{A}\| = \sup_{\|\boldsymbol{x}\|_2=1} \|\boldsymbol{A}\boldsymbol{x}\|_2$，令 $\boldsymbol{x} = \boldsymbol{e}_1 \in \mathbb{R}^n$，则

$$\|\boldsymbol{A}\| \geqslant \|\boldsymbol{A}\boldsymbol{e}_1\|_2 = \|\boldsymbol{A}_{\cdot 1}\|_2;$$

注意到 $\|\boldsymbol{A}\| = \|\boldsymbol{A}^\top\|$，令 $\boldsymbol{x} = \tilde{\boldsymbol{e}}_1 \in \mathbb{R}^m$，则

$$\|\boldsymbol{A}\| = \|\boldsymbol{A}^\top\| \geqslant \|\boldsymbol{A}^\top \tilde{\boldsymbol{e}}_1\|_2 = \|\boldsymbol{A}_{1\cdot}^\top\|_2,$$

因此 $\|\boldsymbol{A}\|$ 的稳健下界为

$$\|\boldsymbol{A}\| \geqslant \frac{1}{2}(\|\boldsymbol{A}_{\cdot 1}\|_2 + \|\boldsymbol{A}_{1\cdot}^\top\|_2)。$$

对于定理 T3.1.1 (范数的集中)，可得

$$\mathrm{P}\{\|\boldsymbol{A}_{\cdot 1}\|_2 \leqslant \sqrt{m} - s\} \leqslant \exp\left(-\frac{cs^2}{K^4}\right)。$$

令 $s = t/2$，则 $\mathcal{E}_1 = \{\|\boldsymbol{A}\| \geqslant \sqrt{m} - t/2\}$ 的概率满足

$$\mathrm{P}(\mathcal{E}_1) \geqslant \mathrm{P}\{\|\boldsymbol{A}_{\cdot 1}\|_2 > \sqrt{m} - t/2\} \geqslant 1 - \exp\left(-\frac{c(t/2)^2}{K^4}\right) = 1 - \exp\left(-\frac{c't^2}{K^4}\right);$$

同理，$\mathcal{E}_2 = \{\|\boldsymbol{A}\| \geqslant \sqrt{n} - t/2\}$ 的概率满足

$$\mathrm{P}(\mathcal{E}_2) \geqslant \mathrm{P}\{\|\boldsymbol{A}_{1\cdot}^\top\|_2 > \sqrt{n} - t/2\} \geqslant 1 - \exp\left(-\frac{c't^2}{K^4}\right)。$$

因此

$$\mathrm{P}(\mathcal{E}_1 \cap \mathcal{E}_2) = 1 - \mathrm{P}(\mathcal{E}_1^c \cup \mathcal{E}_2^c) \geqslant 1 - \mathrm{P}(\mathcal{E}_1^c) - \mathrm{P}(\mathcal{E}_2^c) \geqslant 1 - 2\exp\left(-\frac{c't^2}{K^4}\right)。$$

其中当 $\mathcal{E}_1 \cap \mathcal{E}_2$ 发生时，

$$\|\boldsymbol{A}\| \geqslant \frac{1}{2}\left(\sqrt{m} - \frac{t}{2} + \sqrt{n} - \frac{t}{2}\right) = \frac{1}{2}(\sqrt{m} + \sqrt{n} - t),$$

从而

$$\mathrm{P}\left\{\|\boldsymbol{A}\| \geqslant \frac{1}{2}(\sqrt{m} + \sqrt{n} - t)\right\} \geqslant 1 - 2\exp\left(-\frac{c't^2}{K^4}\right)。$$

43 [**sub-Gaussian 矩阵算子范数的上界：放宽独立性假设**]

(1) 矩阵级别的 sub-Gaussian 性：若将 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 视为 $\mathbb{R}^{m\times n}$ 空间的 K-sub-Gaussian 随机向量[1]，证明：即使没有任意独立性假设，定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界) 的结论依然成立。

(2) 行 (或列) 级别的 sub-Gaussian 性：证明：若 $\boldsymbol{A}$ 的行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m \in \mathbb{R}^n$ 为相互独立, 零均值的 K-sub-Gaussian 随机向量，则定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界) 依然成立。(对于列向量结论亦成立)

注释 回顾定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界) 的 ε-网证明，主要分为三步：

1. 逼近 (Approximation)：选取确定性的 ε-网 $\mathcal{N} \subset \mathbb{S}^{n-1}, \mathcal{M} \subset \mathbb{S}^{m-1}$，将范数转化为 $\sup_{\boldsymbol{x}\in\mathcal{N},\boldsymbol{y}\in\mathcal{M}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$。
2. 集中 (Concentration)：证明对于固定的 $\boldsymbol{x} \in \mathcal{N}, \boldsymbol{y} \in \mathcal{M}$，双线性型 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 满足 sub-Gaussian 尾部界限 $\mathrm{P}\{|Z| \geqslant u\} \leqslant 2\exp(-cu^2/K^2)$。
3. 并集界 (Union Bound)：对所有的网点求并集。

由于步骤 1, 3 是确定性的几何操作，不依赖矩阵元素的随机性假设。因此，我们只需要证明于 (1)(2) 的新假设，步骤 2 的 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 依然满足相同的 sub-Gaussian 范数界限 $\|Z\|_{\psi_2} \leqslant C'K$ 即可。

[1] 原文在定义 K-sub-Gaussian 后重复给出 $K = \|\boldsymbol{A}\|_{\psi_2}$。现删去该重复赋值，因为 K 已由前述定义确定；保留会造成语义重复。

证明 (1) 根据 sub-Gaussian 随机向量范数的定义 (D3.4.1 (sub-Gaussian 随机向量))，可得

$$\|\boldsymbol{A}\|_{\psi_2} = \sup_{\|\boldsymbol{W}\|_F=1} \|\langle \boldsymbol{A}, \boldsymbol{W}\rangle\|_{\psi_2} = K,$$

其中 $\boldsymbol{W} \in \mathbb{R}^{m\times n}$，矩阵内积定义为 $\langle \boldsymbol{A}, \boldsymbol{W}\rangle = \operatorname{tr}(\boldsymbol{W}^\top \boldsymbol{A})$。

对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，$\boldsymbol{y} \in \mathbb{S}^{m-1}$，考虑

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x} = \operatorname{tr}(\boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x}) = \operatorname{tr}(\boldsymbol{x}\boldsymbol{y}^\top \boldsymbol{A}),$$

令秩一矩阵 $\boldsymbol{W} = \boldsymbol{y}\boldsymbol{x}^\top$，则利用习题 Q4.3 (算子范数的特殊情形计算) (1) 的结论，可得

$$\|\boldsymbol{W}\|_F = \|\boldsymbol{y}\boldsymbol{x}^\top\|_F = \|\boldsymbol{y}\|_2 \|\boldsymbol{x}\|_2 = 1 \cdot 1 = 1,$$

因此

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = \langle \boldsymbol{A}, \boldsymbol{y}\boldsymbol{x}^\top\rangle = \langle \boldsymbol{A}, \boldsymbol{W}\rangle,$$

从而

$$\|\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle\|_{\psi_2} = \|\langle \boldsymbol{A}, \boldsymbol{W}\rangle\|_{\psi_2} \leqslant \sup_{\|\boldsymbol{M}\|_F=1} \|\langle \boldsymbol{A}, \boldsymbol{M}\rangle\|_{\psi_2} = K,$$

即双线性形式 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 为 K-sub-Gaussian 随机向量，后续的联合界证明同理于原定理。

(2) 将双线性形式 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 按行展开，

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = \sum_{i=1}^m y_i(\boldsymbol{A}_i^\top \boldsymbol{x}) = \sum_{i=1}^m y_i \langle \boldsymbol{A}_i, \boldsymbol{x}\rangle,$$

令 $Z_i = \langle \boldsymbol{A}_i, \boldsymbol{x}\rangle$，则

$$\|Z_i\|_{\psi_2} = \|\langle \boldsymbol{A}_i, \boldsymbol{x}\rangle\|_{\psi_2} \leqslant \|\boldsymbol{A}_i\|_{\psi_2} \leqslant K,$$

因此 $Z_1, \cdots, Z_m$ 为相互独立的零均值 sub-Gaussian 随机变量，从而根据命题 P2.7.1 (和式的 sub-Gaussian 范数)，可得

$$\|\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle\|_{\psi_2}^2 = \left\|\sum_{i=1}^m y_i Z_i\right\|_{\psi_2}^2 \leqslant C\sum_{i=1}^m \|y_i Z_i\|_{\psi_2}^2 = C\sum_{i=1}^m y_i^2 \|Z_i\|_{\psi_2}^2 \leqslant CK^2 \sum_{i=1}^m y_i^2 = CK^2,$$

即

$$\|Z\|_{\psi_2} \leqslant \sqrt{C}K,$$

即双线性形式 $Z = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle$ 为 K-sub-Gaussian 随机向量，后续的联合界证明同理于原定理。

根据行列的对称性，若列是相互独立的，则只需对 $\boldsymbol{A}^\top$ 利用相同逻辑即可。

44 [**随机矩阵的其他 $p \to q$ 算子范数**] 关于定理 T4.4.3 (独立 sub-Gaussian 矩阵的范数界)，我们研究了随机矩阵的 $2 \to 2$ 算子范数 (即谱范数)。

本题旨在探讨其他的 $p \to q$ 算子范数 (于习题 Q4.18 ($p \to q$ 算子范数) 定义，于习题 Q4.19 ($1 \to \infty$ 与 $1 \to 2$ 算子范数的显式表示), 习题 Q4.20 ($\infty \to 1$ 算子范数的性质, 对偶) 给出了特例)。

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其元素 A_{ij} 为相互独立的标准化 K-sub-Gaussian 随机变量。

(1) 证明：

$$\|\boldsymbol{A}\|_{1\to\infty} \leqslant CK(\sqrt{\ln m} + \sqrt{\ln n})。 \qquad (C > 0)$$

(2) 证明：

$$\|\boldsymbol{A}\|_{1\to 2} = \|\boldsymbol{A}^\top\|_{2\to\infty} \leqslant \sqrt{m} + CK^2\sqrt{\ln n}。 \qquad (C > 0)$$

(注：借助更高级的工具，我们可以处理所有的 $p \to q$ 范数，见后续的习题 Q8.41 (随机矩阵的 $p \to q$ 范数)。)

(3) 证明：(1)(2) 的界限于本质是最优的。具体而言，设 $\boldsymbol{A}$ 的元素为相互独立的标准正态随机变量，证明：

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to\infty} \geqslant c(\sqrt{\ln m} + \sqrt{\ln n}),\ \mathrm{E}\|\boldsymbol{A}\|_{1\to 2} \geqslant c(\sqrt{m} + \sqrt{\ln n})。 \qquad (c > 0)$$

证明 (1) 利用习题 Q4.19 ($1\to\infty$ 与 $1\to 2$ 算子范数的显式表示) (1) 的结论，可得

$$\|\boldsymbol{A}\|_{1\to\infty}=\max_{1\leqslant i\leqslant m,1\leqslant j\leqslant n}|A_{ij}|,$$

由于 A_{ij} 为相互独立的 K-sub-Gaussian 随机变量，因此

$$\mathrm{P}\{|A_{ij}|\geqslant t\}\leqslant 2\exp\left(-\frac{ct^2}{K^2}\right),$$

两侧取并集界，

$$\mathrm{P}\left\{\max_{i,j}|A_{ij}|\geqslant t\right\}=\mathrm{P}\left(\bigcup_{i,j}\{|A_{ij}|\geqslant t\}\right)\leqslant\sum_{i,j}\mathrm{P}\{|A_{ij}|\geqslant t\}\leqslant 2mn\exp\left(-\frac{ct^2}{K^2}\right),$$

令 $t=C_1K\sqrt{\ln(mn)}$，则

$$\mathrm{P}\left\{\max_{i,j}|A_{ij}|\geqslant t\right\}\leqslant 2mn\exp(-cC_1^2\ln(mn))=2(mn)^{1-cC_1^2}。$$

当 C_1 充分大时，$cC_1^2\geqslant 2$，因此

$$\|\boldsymbol{A}\|_{1\to\infty}\leqslant C_1K\sqrt{\ln(mn)}=C_1K\sqrt{\ln m+\ln n}\leqslant C_1K(\sqrt{\ln m}+\sqrt{\ln n})。$$

(2) 对于左侧，利用习题 Q4.18 ($p\to q$ 算子范数) (3) 的结论，可得

$$\|\boldsymbol{A}^\top\|_{p\to q}=\|\boldsymbol{A}\|_{q'\to p'},$$

令 $p=2,q=\infty$，则共轭指数 $q'=1,p'=2$，此时

$$\|\boldsymbol{A}^\top\|_{2\to\infty}=\|\boldsymbol{A}\|_{1\to 2}。$$

对于右侧，利用习题 Q4.19 ($1\to\infty$ 与 $1\to 2$ 算子范数的显式表示) (2) 的结论，可得

$$\|\boldsymbol{A}\|_{1\to 2}=\max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_j\|_2,$$

根据定理 T3.1.1 (范数的集中)，可得对于任意的 $u\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{A}_j\|_2\geqslant\sqrt{m}+u\}\leqslant 2\exp\left(-\frac{c_2u^2}{K^4}\right),\qquad(c_2>0)$$

两侧取并集界，

$$\mathrm{P}\left\{\max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_j\|_2\geqslant\sqrt{m}+u\right\}\leqslant 2n\exp\left(-\frac{c_2u^2}{K^4}\right),$$

令 $u=CK^2\sqrt{\ln n}$，可得

$$\mathrm{P}\left\{\max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_j\|_2\geqslant\sqrt{m}+u\right\}\leqslant 2n\exp(-c_2C^2\ln n)=2n^{1-c_2C^2}。$$

当 C 充分大时，$c_2C^2\geqslant 2$，因此

$$\|\boldsymbol{A}\|_{1\to 2}\leqslant\sqrt{m}+CK^2\sqrt{\ln n}。$$

(3) 不妨设 $A_{ij}\sim N(0,1)$。

- 证明 $1\to\infty$ 范数的下界

  对于 $\|\boldsymbol{A}\|_{1\to\infty}=\max_{i,j}|A_{ij}|$，根据习题 Q2.38 (Gaussian 随机变量的极大值), Q2.39 (sub-Gaussian 分布的刻画：极大值不等式)，令 $N=mn$，可得

  $$\mathrm{E}\|\boldsymbol{A}\|_{1\to\infty}\asymp\sqrt{\ln(mn)}=\sqrt{\ln m+\ln n}\geqslant\frac{1}{\sqrt{2}}(\sqrt{\ln m}+\sqrt{\ln n}),$$

  此时令 $c=1/\sqrt{2}$。

- 证明 $1\to 2$ 范数的下界

  一方面，

  $$\mathrm{E}\left[\max_j\|\boldsymbol{A}_j\|_2\right]\geqslant\mathrm{E}\|\boldsymbol{A}_1\|_2,$$

其中 $\|\boldsymbol{A}_1\|_2^2 \sim \chi^2(m)$，因此根据定理 T3.1.1 (范数的集中)，可得

$$\mathrm{E}\|\boldsymbol{A}_1\|_2 \asymp \sqrt{m}。$$

另一方面，

$$\mathrm{E}\left[\max_j \|\boldsymbol{A}_j\|_2\right] \geqslant \mathrm{E}\left[\max_j |A_{1j}|\right],$$

其中 A_{1j} i.i.d. $\sim N(0,1)$，因此根据定理 T3.1.1 (范数的集中)，可得

$$\mathrm{E}\left[\max_j |A_{1j}|\right] \asymp \sqrt{\ln n}。$$

如此，

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to 2} \geqslant \max(c_1\sqrt{m}, c_2\sqrt{\ln n}) \geqslant \frac{1}{2}(c_1\sqrt{m} + c_2\sqrt{\ln n}) \geqslant c(\sqrt{m} + \sqrt{\ln n}),$$

因此 $\sqrt{m}, \sqrt{\ln n}$ 的阶数增长是必定存在的，即界限是最优的。

45 [**社区发现：改进的谱聚类算法**] 于随机块模型 (SBM) 的社区发现，设 n 为偶数，G 的 n 个顶点被均分为两个隐藏社区。同社区顶点间连边概率为 p，跨社区为 q，其中 $0 \leqslant q < p \leqslant 1$。

定理 T4.5.2 (随机块模型的谱聚类) 在界定误分类顶点数时，不仅假设 $p-q$ 足够大，还假设 q 不能太小。

试设计一个改进版的谱聚类算法，以移除对 q 的下界假设。假设 $n(p-q) \geqslant 4p$ 及 $\sqrt{n}(p-q) \geqslant C_0$，其中 $C_0 > 0$ 为充分大的绝对常数。证明：以高概率，于此算法输出的聚类结果误分类的顶点数最多不超过

$$|M| \leqslant \frac{C}{(p-q)^2}。 \qquad (C>0)$$

证明 设 $\boldsymbol{A} \in \{0,1\}^{n\times n}$ 为 G 的邻接矩阵，真实的社区标签向量记为 $\boldsymbol{x}^* \in \{-1,1\}^n$ (属于社区 1 记为 $+1$，属于社区 2 记为 -1)，则 $\boldsymbol{x}^* \perp \mathbf{1}$。

约定 $\operatorname{sgn}(0) = 1$，构造以下改进算法：

Algorithm 4: 去中心化谱聚类算法 (Decentered Spectral Clustering)

输入: 图 G 的邻接矩阵 $\boldsymbol{A} \in \{0,1\}^{n\times n}$。

输出: 节点的社区标签估计向量 $\hat{\boldsymbol{x}} \in \{-1,1\}^n$。

Step 1: 构造中心化投影矩阵

构造全 1 向量 $\mathbf{1} = (1,1,\cdots,1)^\top \in \mathbb{R}^n$;

$\boldsymbol{P} \leftarrow \boldsymbol{I}_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$; // 构造向 $\mathbf{1}^\perp$ 子空间投影的正交投影算子

Step 2: 矩阵去中心化

$\boldsymbol{A}' \leftarrow \boldsymbol{P}\boldsymbol{A}\boldsymbol{P}$; // 消除度分布 (全连通分量) 的影响

Step 3: 计算主特征向量

计算矩阵 $\boldsymbol{A}'$ 的最大特征值所对应的单位特征向量 $\boldsymbol{u} \in \mathbb{R}^n$;

Step 4: 符号聚类 (Sign Clustering)

for $i = 1$ **to** n **do**

  $\hat{x}_i \leftarrow \operatorname{sgn}(u_i)$; // 根据特征向量的符号划分社区

end

return $\hat{\boldsymbol{x}} = (\hat{x}_1, \hat{x}_2, \cdots, \hat{x}_n)^\top$;

- 谱分析

  设 $\boldsymbol{D} = \mathrm{E}[\boldsymbol{A}]$，则其对角元为 0，非对角元根据标签是否相同取值 p 或 q，即

$$\boldsymbol{D} = \frac{p+q}{2}\mathbf{1}\mathbf{1}^\top + \frac{p-q}{2}\boldsymbol{x}^*\boldsymbol{x}^{*\top} - p\boldsymbol{I}_n。$$

令中心化期望矩阵 $\boldsymbol{D}' = \mathrm{E}[\boldsymbol{A}'] = \boldsymbol{P}\mathrm{E}[\boldsymbol{A}]\boldsymbol{P}$，则 (注意 $\boldsymbol{P}(\boldsymbol{1}\boldsymbol{1}^\top)\boldsymbol{P} = \boldsymbol{O}$，$\boldsymbol{P}(\boldsymbol{x}^*\boldsymbol{x}^{*\top})\boldsymbol{P} = \boldsymbol{x}^*\boldsymbol{x}^{*\top}$)

$$\boldsymbol{D}' = \frac{p-q}{2}\boldsymbol{x}^*\boldsymbol{x}^{*\top} - p\boldsymbol{P}。$$

因此其特征值为

$$\begin{aligned}
\boldsymbol{v}_1 = \frac{1}{\sqrt{n}}\boldsymbol{x}^* &\implies \boldsymbol{D}'\boldsymbol{v}_1 = \left(\frac{n(p-q)}{2} - p\right)\boldsymbol{v}_1 &&\implies \lambda_1 = \frac{n(p-q)}{2} - p,\\
\boldsymbol{v}_2 = \frac{1}{\sqrt{n}}\boldsymbol{1} &\implies \boldsymbol{D}'\boldsymbol{1} = \boldsymbol{0} &&\implies \lambda_2 = 0。\\
\boldsymbol{w} \perp \mathrm{span}(\boldsymbol{1}, \boldsymbol{x}^*) &\implies \boldsymbol{D}'\boldsymbol{w} = -p\boldsymbol{w} &&\implies \lambda_3 = -p,
\end{aligned}$$

即 $\boldsymbol{D}'$ 的最大特征值为 λ_1，其余特征值为 $0, -p$。由假设 $n(p-q) \geqslant 4p$，有 $\lambda_1 \geqslant n(p-q)/4 > 0$，从而最大特征向量为 $\boldsymbol{v}$，其与剩余谱之间的谱间隙为

$$\delta = \lambda_1 - 0 = \frac{n(p-q)}{2} - p。$$

因此

$$\delta \geqslant c_0 n(p-q), \qquad (c_0 > 0)$$

此谱间隙的下界脱离了对 q 的依赖。

- 根据 Davis-Kahan 定理界定特征向量误差

考虑扰动矩阵 $\boldsymbol{A}' - \boldsymbol{D}' = \boldsymbol{P}(\boldsymbol{A} - \boldsymbol{D})\boldsymbol{P}$，容易知道，

$$\|\boldsymbol{A}' - \boldsymbol{D}'\| \leqslant \|\boldsymbol{P}\|^2\|\boldsymbol{A} - \boldsymbol{D}\| = \|\boldsymbol{A} - \boldsymbol{D}\|,$$

其中 $\boldsymbol{A} - \boldsymbol{D}$ 为对称随机矩阵，其上三角元素为相互独立, 零均值的 $O(1)$-sub-Gaussian 随机变量 (即绝对值严格受界于 1)，因此根据推论 C4.4.7 (对称 sub-Gaussian 矩阵的范数界)，可得

$$\|\boldsymbol{A}' - \boldsymbol{D}'\| \leqslant \|\boldsymbol{A} - \boldsymbol{D}\| \leqslant C_1\sqrt{n} \text{ (w.h.p.)}。 \qquad (C_1 > 0)$$

由于 $\boldsymbol{A}'$ 的主特征向量为 $\boldsymbol{u}$，$\boldsymbol{D}'$ 的主特征向量为 $\boldsymbol{v} = \boldsymbol{x}^*/\sqrt{n}$，因此根据 Davis-Kahan 定理 (或 $\sin\Theta$ 定理的特征向量版本)，可得

$$\min_{s\in\{-1,1\}} \|\boldsymbol{u} - s\boldsymbol{v}\|_2 \leqslant \frac{2\sqrt{2}\|\boldsymbol{A}' - \boldsymbol{D}'\|}{\delta},$$

即

$$\min_{s\in\{-1,1\}} \|\boldsymbol{u} - s\boldsymbol{v}\|_2 \leqslant \frac{2\sqrt{2}C_1\sqrt{n}}{c_0 n(p-q)} = \frac{C_2}{\sqrt{n}(p-q)}, \qquad \left(C_2 = \frac{2\sqrt{2}C_1}{c_0} > 0\right)$$

不妨设使得距离最小的全局符号为 $s = 1$，则

$$\|\boldsymbol{u} - \boldsymbol{v}\|_2 \leqslant \frac{C_2}{\sqrt{n}(p-q)}。$$

- 推导误分类顶点数的界限

设 $M \subset \{1, \cdots, n\}$ 为算法产生误分类的顶点下标集合，则对于任意的 $i \in M$，算法给出的符号 $\mathrm{sgn}(u_i)$ 相反于真实符号 $\mathrm{sgn}(v_i)$。

由于真实特征向量 $\boldsymbol{v}$ 满足 $|v_i| = 1/\sqrt{n}$，因此若 u_i 与 v_i 异号，则其距离必定不小于 v_i 到原点的距离，即

$$|u_i - v_i| \geqslant |v_i| = \frac{1}{\sqrt{n}},$$

从而

$$\|\boldsymbol{u} - \boldsymbol{v}\|_2^2 = \sum_{i=1}^n (u_i - v_i)^2 \geqslant \sum_{i\in M}(u_i - v_i)^2 \geqslant \sum_{i\in M}\left(\frac{1}{\sqrt{n}}\right)^2 = \frac{|M|}{n},$$

即

$$\frac{|M|}{n} \leqslant \|\boldsymbol{u}-\boldsymbol{v}\|_2^2 \leqslant \left(\frac{C_2}{\sqrt{n}(p-q)}\right)^2 = \frac{C_2^2}{n(p-q)^2},$$

即

$$|M| \leqslant \frac{C}{(p-q)^2}。 \qquad (C = C_2^2 > 0)$$

46 [随机矩阵双侧界限的替代证明] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，其行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m \in \mathbb{R}^n$ 为相互独立, 零均值, 各向同性的 sub-Gaussian 随机向量，满足 $\max_i \|\boldsymbol{A}_i\|_{\psi_2} \leqslant K$。

利用定理 T3.1.1 (范数的集中), 习题 Q4.37 (ε-网上范数偏离的控制)，给出定理 T4.6.1 (sub-Gaussian 矩阵的双侧界) 的更简单的替代证明：对于任意的 $t \geqslant 0$，满足

$$\sqrt{m} - CK^2(\sqrt{n}+t) \leqslant s_n(\boldsymbol{A}) \leqslant s_1(\boldsymbol{A}) \leqslant \sqrt{m} + CK^2(\sqrt{n}+t) \text{ (w.p. } 1-2\exp(-t^2))。$$

证明 • 于 ε-网根据并集界

设 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，$\boldsymbol{Z} = \boldsymbol{A}\boldsymbol{x} \in \mathbb{R}^m$，令 $Z_i = \langle \boldsymbol{A}_i, \boldsymbol{x}\rangle$，则 $Z_1, \cdots, Z_m$ 是相互独立的，满足：

1. 单位方差：由于 $\boldsymbol{A}_i$ 各向同性，因此

$$\mathrm{E}[Z_i^2] = \mathrm{E}[\boldsymbol{x}^\top \boldsymbol{A}_i \boldsymbol{A}_i^\top \boldsymbol{x}] = \boldsymbol{x}^\top \mathrm{E}[\boldsymbol{A}_i \boldsymbol{A}_i^\top]\boldsymbol{x} = \boldsymbol{x}^\top \boldsymbol{I}_n \boldsymbol{x} = \|\boldsymbol{x}\|_2^2 = 1。$$

2. sub-Gaussian 性：

$$\|Z_i\|_{\psi_2} = \|\langle \boldsymbol{A}_i, \boldsymbol{x}\rangle\|_{\psi_2} \leqslant \|\boldsymbol{A}_i\|_{\psi_2}\|\boldsymbol{x}\|_2 \leqslant K。$$

因此根据定理 T3.1.1 (范数的集中)，可得对于任意的 $s \geqslant 0$，

$$\mathrm{P}\{|\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}| \geqslant s\} \leqslant 2\exp\left(-\frac{c_1 s^2}{K^4}\right)。 \qquad (c_1 > 0)$$

令 $\varepsilon = 1/4$，则根据推论 C4.2.11 (Euclidean 球的覆盖数)，可得存在 1/4-网 $\mathcal{N} \subset \mathbb{S}^{n-1}$，满足 $|\mathcal{N}| \leqslant 9^n$。

对 $\mathcal{N}$ 的所有点根据并集界，

$$\mathrm{P}(\text{Fail}) = \mathrm{P}\left\{\sup_{\boldsymbol{x}\in\mathcal{N}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}| \geqslant s\right\} \leqslant |\mathcal{N}| \cdot 2\exp\left(-\frac{c_1 s^2}{K^4}\right) \leqslant 2\exp\left(n\ln 9 - \frac{c_1 s^2}{K^4}\right),$$

若 $\mathrm{P}(\text{Fail}) \leqslant 2\exp(-t^2)$，则

$$n\ln 9 - \frac{c_1 s^2}{K^4} \leqslant -t^2 \implies s^2 \geqslant \frac{K^4}{c_1}(n\ln 9 + t^2),$$

因此令 $s = C_2 K^2(\sqrt{n}+t)$，可得

$$\mathrm{P}\underbrace{\{\sup_{\boldsymbol{x}\in\mathcal{N}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}| \leqslant C_2K^2(\sqrt{n}+t)\}}_{\mathcal{E}} \geqslant 1-2\exp(-t^2)。$$

• 将离散网扩展至整个球面

根据习题 Q4.37 (ε-网上范数偏离的控制)，令 $\mu = \sqrt{m}$，可得对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，

$$\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}| \leqslant \frac{C_3}{1-2\varepsilon} \sup_{\boldsymbol{x}\in\mathcal{N}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}|, \qquad (C_3 > 0)$$

令 $\varepsilon = 1/4$，可得当 $\mathcal{E}$ 发生时，

$$\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}| \leqslant 2C_3 \cdot C_2K^2(\sqrt{n}+t) =: CK^2(\sqrt{n}+t), \qquad (C = 2C_3C_2 > 0)$$

因此

$$\sqrt{m} - CK^2(\sqrt{n}+t) \leqslant \|\boldsymbol{A}\boldsymbol{x}\|_2 \leqslant \sqrt{m} + CK^2(\sqrt{n}+t)。$$

其中

$$s_1(\boldsymbol{A}) = \sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad s_n(\boldsymbol{A}) = \inf_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{x}\|_2,$$

从而

$$\sqrt{m}-CK^2(\sqrt{n}+t)\leqslant s_n(\boldsymbol{A})\leqslant s_1(\boldsymbol{A})\leqslant\sqrt{m}+CK^2(\sqrt{n}+t)。$$

47 [随机矩阵中间奇异值的下界] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，其行向量 $\boldsymbol{A}_i$ 为相互独立, 零均值, 各向同性的 K-sub-Gaussian 随机向量。利用定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，证明：对于任意的 $t\geqslant 0$，$s_k(\boldsymbol{A})$ 满足

$$s_k(\boldsymbol{A})\geqslant\sqrt{m}-CK^2(\sqrt{k}+t)\ (\text{w.p. } 1-2\exp(-t^2))。\qquad (C>0)$$

证明 作出以下引理：

引理 (奇异值交错定理 / Cauchy Interlacing Theorem) $s_k(\boldsymbol{A})\geqslant s_k(\boldsymbol{A}_k)$。

根据奇异值的极大极小定理，可得

$$s_k(\boldsymbol{A})=\max_{\dim(E)=k}\min_{\boldsymbol{x}\in E,\|\boldsymbol{x}\|_2=1}\|\boldsymbol{A}\boldsymbol{x}\|_2,$$

其中 $E\subset\mathbb{R}^n$ 为 k 维子空间，因此对于任意的 $E_0\subset\mathbb{R}^n$，

$$s_k(\boldsymbol{A})\geqslant\min_{\boldsymbol{x}\in E_0,\|\boldsymbol{x}\|_2=1}\|\boldsymbol{A}\boldsymbol{x}\|_2。$$

令 $E_0=\operatorname{span}(\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_k)$，则对于任意的 $\boldsymbol{x}\in E_0$，之后的 $n-k$ 个坐标均为 0，即

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}_k\tilde{\boldsymbol{x}},$$

其中 $\boldsymbol{A}_k\in\mathbb{R}^{m\times k}$ 由 $\boldsymbol{A}$ 的前 k 列组成，$\tilde{\boldsymbol{x}}\in\mathbb{R}^k$ 为 $\boldsymbol{x}$ 于 E_0 的非零坐标表示，满足 $\|\tilde{\boldsymbol{x}}\|_2=1$，因此

$$s_k(\boldsymbol{A})\geqslant\min_{\tilde{\boldsymbol{x}}\in\mathbb{R}^k,\|\tilde{\boldsymbol{x}}\|_2=1}\|\boldsymbol{A}_k\tilde{\boldsymbol{x}}\|_2=s_{\min}(\boldsymbol{A}_k)=s_k(\boldsymbol{A}_k)。$$

记 $\boldsymbol{A}_k$ 的行向量为 $\tilde{\boldsymbol{A}}_i\in\mathbb{R}^k$，则 $\tilde{\boldsymbol{A}}_i$ 是相互独立, 零均值的，满足：

1. 各向同性：

令 $\boldsymbol{P}=(\boldsymbol{I}_k\mid\boldsymbol{O}_{k\times(n-k)})$ 为截断矩阵，$\tilde{\boldsymbol{A}}_i=\boldsymbol{P}\boldsymbol{A}_i$，则

$$\begin{aligned}\mathrm{E}[\tilde{\boldsymbol{A}}_i\tilde{\boldsymbol{A}}_i^\top]&=\mathrm{E}[(\boldsymbol{P}\boldsymbol{A}_i)(\boldsymbol{P}\boldsymbol{A}_i)^\top]=\mathrm{E}[\boldsymbol{P}\boldsymbol{A}_i\boldsymbol{A}_i^\top\boldsymbol{P}^\top]\\&=\boldsymbol{P}\mathrm{E}[\boldsymbol{A}_i\boldsymbol{A}_i^\top]\boldsymbol{P}^\top=\boldsymbol{P}\boldsymbol{P}^\top\\&=(\boldsymbol{I}_k\mid\boldsymbol{O})\begin{pmatrix}\boldsymbol{I}_k\\\boldsymbol{O}\end{pmatrix}=\boldsymbol{I}_k\boldsymbol{I}_k+\boldsymbol{O}\boldsymbol{O}=\boldsymbol{I}_k。\end{aligned}$$

2. 对于任意的 $\boldsymbol{v}\in\mathbb{S}^{k-1}$，将其末尾补零扩展为 $\boldsymbol{v}'\in\mathbb{S}^{n-1}$，则

$$\|\langle\tilde{\boldsymbol{A}}_i,\boldsymbol{v}\rangle\|_{\psi_2}=\|\langle\boldsymbol{A}_i,\boldsymbol{v}'\rangle\|_{\psi_2}\leqslant\|\boldsymbol{A}_i\|_{\psi_2}\leqslant K,$$

即 $\max_i\|\tilde{\boldsymbol{A}}_i\|_{\psi_2}\leqslant K$。

因此 $\boldsymbol{A}_k\in\mathbb{R}^{m\times k}$ 满足定理 T4.6.1 (sub-Gaussian 矩阵的双侧界) 的条件，根据定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，可得

$$\mathrm{P}\{s_k(\boldsymbol{A}_k)\geqslant\sqrt{m}-CK^2(\sqrt{k}+t)\}\geqslant 1-2\exp(-t^2),$$

其中

$$\{s_k(\boldsymbol{A}_k)\geqslant\sqrt{m}-CK^2(\sqrt{k}+t)\}\subset\{s_k(\boldsymbol{A})\geqslant\sqrt{m}-CK^2(\sqrt{k}+t)\},$$

从而

$$\mathrm{P}\{s_k(\boldsymbol{A})\geqslant\sqrt{m}-CK^2(\sqrt{k}+t)\}\geqslant 1-2\exp(-t^2)。$$

48 [相对误差的协方差估计] 给出定理 T4.7.1 (协方差估计) 的一个更精细的版本，其中误差是相对的而非绝对的。

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m\in\mathbb{R}^n$ 是独立同分布的，其总体协方差矩阵为 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$，假设 $\boldsymbol{\Sigma}$ 是可逆的。

设 $\boldsymbol{X}$ 为 sub-Gaussian 随机向量，满足对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{L^2},\qquad (K\geqslant 1)$$

令

$$\boldsymbol{\Sigma}_m = \frac{1}{m}\sum_{i=1}^{m} \boldsymbol{X}_i \boldsymbol{X}_i^\top,$$

为基于 m 个样本的样本协方差矩阵，证明：对于协方差的相对误差，满足

$$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}}\left|\frac{\boldsymbol{v}^\top\boldsymbol{\Sigma}_m\boldsymbol{v}}{\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}}-1\right|\right] \leqslant CK^2\left(\sqrt{\frac{n}{m}}+\frac{n}{m}\right)。$$

(换而言之，我们得到了 $\boldsymbol{X}$ 于所有一维投影方向的方差的一致相对近似。)

证明 令 $\boldsymbol{u}=\boldsymbol{\Sigma}^{1/2}\boldsymbol{v}$，则

$$\text{(真实方差)}\quad \boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}=\boldsymbol{v}^\top\boldsymbol{\Sigma}^{1/2}\boldsymbol{\Sigma}^{1/2}\boldsymbol{v}=\boldsymbol{u}^\top\boldsymbol{u}=\|\boldsymbol{u}\|_2^2,$$

$$\text{(样本方差与真实方差之差)}\quad \boldsymbol{v}^\top\boldsymbol{\Sigma}_m\boldsymbol{v}-\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}=\boldsymbol{u}^\top\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}\boldsymbol{u}-\boldsymbol{u}^\top\boldsymbol{u}=\boldsymbol{u}^\top(\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}-\boldsymbol{I}_n)\boldsymbol{u},$$

因此根据对称矩阵的 Rayleigh 商刻画 $\|\boldsymbol{M}\|=\sup_{\boldsymbol{u}\neq\boldsymbol{0}}|\boldsymbol{u}^\top\boldsymbol{M}\boldsymbol{u}|/\|\boldsymbol{u}\|_2^2$，可得

$$\sup_{\boldsymbol{v}\neq\boldsymbol{0}}\left|\frac{\boldsymbol{v}^\top\boldsymbol{\Sigma}_m\boldsymbol{v}}{\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}}-1\right| = \sup_{\boldsymbol{u}\neq\boldsymbol{0}}\frac{\left|\boldsymbol{u}^\top\left(\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}-\boldsymbol{I}_n\right)\boldsymbol{u}\right|}{\|\boldsymbol{u}\|_2^2} = \left\|\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}-\boldsymbol{I}_n\right\|,$$

之后只需计算右侧的期望。

令白化随机向量 $\boldsymbol{Z}_i=\boldsymbol{\Sigma}^{-1/2}\boldsymbol{X}_i$，

$$\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}=\frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\Sigma}^{-1/2}\boldsymbol{X}_i)(\boldsymbol{\Sigma}^{-1/2}\boldsymbol{X}_i)^\top=\frac{1}{m}\sum_{i=1}^{m}\boldsymbol{Z}_i\boldsymbol{Z}_i^\top。$$

则 $\boldsymbol{Z}_1,\cdots,\boldsymbol{Z}_m$ 是相互独立的，满足

1. 各向同性：

$$\mathrm{E}[\boldsymbol{Z}_i\boldsymbol{Z}_i^\top]=\boldsymbol{\Sigma}^{-1/2}\mathrm{E}[\boldsymbol{X}_i\boldsymbol{X}_i^\top]\boldsymbol{\Sigma}^{-1/2}=\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1/2}=\boldsymbol{I}_n。$$

2. sub-Gaussian 范数控制：

对于任意的 $\boldsymbol{w}\in\mathbb{S}^{n-1}$，

$$\langle\boldsymbol{Z}_i,\boldsymbol{w}\rangle=\langle\boldsymbol{\Sigma}^{-1/2}\boldsymbol{X}_i,\boldsymbol{w}\rangle=\langle\boldsymbol{X}_i,\boldsymbol{\Sigma}^{-1/2}\boldsymbol{w}\rangle,$$

令 $\boldsymbol{x}=\boldsymbol{\Sigma}^{-1/2}\boldsymbol{w}$，则

$$\|\langle\boldsymbol{X}_i,\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X}_i,\boldsymbol{x}\rangle\|_{L^2},$$

其中

$$\|\langle\boldsymbol{X}_i,\boldsymbol{x}\rangle\|_{L^2}^2=\mathrm{E}[\langle\boldsymbol{X}_i,\boldsymbol{x}\rangle^2]=\boldsymbol{x}^\top\boldsymbol{\Sigma}\boldsymbol{x}=\boldsymbol{w}^\top\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1/2}\boldsymbol{w}=\boldsymbol{w}^\top\boldsymbol{w}=1,$$

因此 $\|\langle\boldsymbol{Z}_i,\boldsymbol{w}\rangle\|_{\psi_2}\leqslant K\cdot 1=K$。

令

$$\boldsymbol{R}_m=\frac{1}{m}\sum_{i=1}^{m}\boldsymbol{Z}_i\boldsymbol{Z}_i^\top-\boldsymbol{I}_n,$$

则

$$\mathrm{E}\left[\sup_{\boldsymbol{v}\neq\boldsymbol{0}}\left|\frac{\boldsymbol{v}^\top\boldsymbol{\Sigma}_m\boldsymbol{v}}{\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}}-1\right|\right]=\mathrm{E}\left\|\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}_m\boldsymbol{\Sigma}^{-1/2}-\boldsymbol{I}_n\right\|=\mathrm{E}\|\boldsymbol{R}_m\|,$$

根据定理 T4.6.1 (sub-Gaussian 矩阵的双侧界)，可得

$$\mathrm{E}\|\boldsymbol{R}_m\|\leqslant CK^2\left(\sqrt{\frac{n}{m}}+\frac{n}{m}\right),$$

即

$$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{R}^n}\left|\frac{\boldsymbol{v}^\top\boldsymbol{\Sigma}_m\boldsymbol{v}}{\boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v}}-1\right|\right]\leqslant CK^2\left(\sqrt{\frac{n}{m}}+\frac{n}{m}\right)。$$

49 [高概率的协方差估计] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量，其协方差矩阵为 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$，满足对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{L^2}。\qquad(K\geqslant 1)$$

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m$ 为 $\boldsymbol{X}$ 的独立同分布的样本，其样本协方差矩阵为

$$\boldsymbol{\Sigma}_m=\frac{1}{m}\sum_{i=1}^m\boldsymbol{X}_i\boldsymbol{X}_i^\top。$$

证明 (如注记 R4.7.3 (高概率界) 所述)：对于任意的 $u\geqslant 0$，以高概率满足

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant CK^2\left(\sqrt{\frac{n+u}{m}}+\frac{n+u}{m}\right)\|\boldsymbol{\Sigma}\|\ (\text{w.p. } 1-2\mathrm{e}^{-u})。\qquad(C>0)$$

证明 不妨设 $\boldsymbol{\Sigma}$ 是可逆的，令白化随机向量 $\boldsymbol{Z}_i=\boldsymbol{\Sigma}^{-1/2}\boldsymbol{X}_i$，满足 $\|\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\boldsymbol{x}\|_2$，则根据定理 T4.7.1 (协方差估计)，可得 $\boldsymbol{Z}_i$ 是相互独立的零均值, 各向同性随机向量，因此

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|=\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{R}_m\boldsymbol{\Sigma}^{1/2}\|\leqslant\|\boldsymbol{\Sigma}\|\cdot\|\boldsymbol{R}_m\|,$$

其中

$$\boldsymbol{R}_m=\frac{1}{m}\sum_{i=1}^m\boldsymbol{Z}_i\boldsymbol{Z}_i^\top-\boldsymbol{I}_n。$$

根据引理 L4.4.2 (于离散网估计对称矩阵的二次型)，令 $\varepsilon=1/4$，可得存在 1/4-网 $\mathcal{N}$，满足 $|\mathcal{N}|\leqslant 9^n$，使得

$$\|\boldsymbol{R}_m\|\leqslant 2\max_{\boldsymbol{x}\in\mathcal{N}}|\langle\boldsymbol{R}_m\boldsymbol{x},\boldsymbol{x}\rangle|=2\max_{\boldsymbol{x}\in\mathcal{N}}\left|\frac{1}{m}\sum_{i=1}^m\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle^2-1\right|。$$

对于 $\boldsymbol{x}\in\mathcal{N}$，令 $Y_i=\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle^2-1$，则：

1. 均值为零：

由于 $\boldsymbol{Z}_i$ 是各向同性的，因此 $\mathrm{E}[\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle^2]=\|\boldsymbol{x}\|_2^2=1$，即 $\mathrm{E}[Y_i]=0$。

2. sub-Exponential 性：

由于 $\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle$ 是 K-sub-Gaussian 随机变量，因此 $\langle\boldsymbol{Z}_i,\boldsymbol{x}\rangle^2$ 是 sub-Exponential 随机变量，满足 $\|Y_i\|_{\psi_1}\leqslant c_1K^2$。因此根据命题 P2.8.1 (sub-Exponential 性质)，可得对于任意的 $\delta\geqslant 0$，

$$\mathrm{P}\left\{\left|\frac{1}{m}\sum_{i=1}^m Y_i\right|\geqslant\delta\right\}\leqslant 2\exp\left(-c_2m\min\left(\frac{\delta^2}{K^4},\frac{\delta}{K^2}\right)\right)。\qquad(c_2>0)$$

两侧取并集界，

$$\begin{aligned}\mathrm{P}(\text{Fail})=\mathrm{P}\left\{\max_{\boldsymbol{x}\in\mathcal{N}}\left|\frac{1}{m}\sum_{i=1}^m Y_i\right|\geqslant\delta\right\}&\leqslant|\mathcal{N}|\cdot 2\exp\left(-c_2m\min\left(\frac{\delta^2}{K^4},\frac{\delta}{K^2}\right)\right)\\&\leqslant 2\exp\left(n\ln 9-c_2m\min\left(\frac{\delta^2}{K^4},\frac{\delta}{K^2}\right)\right)。\end{aligned}$$

若 $\mathrm{P}(\text{Fail})\leqslant 2\mathrm{e}^{-u}$，则

$$c_2m\min\left(\frac{\delta^2}{K^4},\frac{\delta}{K^2}\right)-n\ln 9=u$$

即

$$\min\left(\frac{\delta^2}{K^4},\frac{\delta}{K^2}\right)=\frac{n\ln 9+u}{c_2m}\leqslant c_3\frac{n+u}{m}。\qquad(c_3>0)$$

令 $\alpha = c_3\frac{n+u}{m}$，$x = \frac{\delta}{K^2}$，则

$$\min(x^2, x) = \alpha,$$

a. 若 $\alpha \leqslant 1$，则 $x^2 \leqslant x \implies x^2 = \alpha \implies x = \sqrt{\alpha}$。

b. 若 $\alpha > 1$，则 $x < x^2 \implies x = \alpha$。

因此

$$x \leqslant \sqrt{\alpha} + \alpha,$$

即

$$\delta \leqslant K^2\left(\sqrt{c_3\frac{n+u}{m}} + c_3\frac{n+u}{m}\right) \leqslant C'K^2\left(\sqrt{\frac{n+u}{m}} + \frac{n+u}{m}\right)。 \qquad (C' > 0)$$

综上，

$$\|\boldsymbol{R}_m\| \leqslant 2\delta \leqslant 2C'K^2\left(\sqrt{\frac{n+u}{m}} + \frac{n+u}{m}\right),$$

即

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant CK^2\left(\sqrt{\frac{n+u}{m}} + \frac{n+u}{m}\right)\|\boldsymbol{\Sigma}\| \text{ (w.p. } 1 - 2\mathrm{e}^{-u})。 \qquad (C = 2C')$$

50 [低秩矩阵的覆盖数估计] 秩 r 的 $m \times n$ 矩阵可以通过 SVD 用参数来描述：左奇异向量贡献 mr 个自由度，右奇异向量贡献 nr 个，奇异值贡献 r 个。

由于覆盖数通常随维度呈指数增长 (参考推论 C4.2.11 (Euclidean 球的覆盖数))，我们猜测以下集合的覆盖数

$$M_{m,n,r} = \{\boldsymbol{A} \in \mathbb{R}^{m\times n} : \operatorname{rank}(\boldsymbol{A}) \leqslant r, \|\boldsymbol{A}\|_F \leqslant 1\}$$

会于指数依赖于 $(m+n+1)r$。事实确实如此。

(1) 设 $O_{m,r}$ 为所有列向量相互正交规范的 $m \times r$ 矩阵的集合。证明：对于任意的 $\varepsilon > 0$，在 $\|\cdot\|_{1\to 2}$ 范数下 (即最大列向量的 ℓ^2 范数)，满足

$$\mathcal{N}(O_{m,r}, \|\cdot\|_{1\to 2}, \varepsilon) \leqslant \left(\frac{C}{\varepsilon}\right)^{mr}。 \qquad (C > 0)$$

(2) 证明：对于任意的 $\varepsilon > 0$，在 Frobenius 范数下，其上界满足

$$\mathcal{N}(M_{m,n,r}, \|\cdot\|_F, \varepsilon) \leqslant \left(\frac{C}{\varepsilon}\right)^{(m+n+1)r}。 \qquad (C > 0)$$

(3) 反之，证明：其下界满足

$$\mathcal{N}(M_{m,n,r}, \|\cdot\|_F, \varepsilon) \geqslant \left(\frac{c}{\varepsilon}\right)^{\frac{1}{2}(m+n)r}。 \qquad (c > 0)$$

证明 (1) 设 $\boldsymbol{U} = (\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_r) \in O_{m,r}$，则 $\boldsymbol{u}_i \in \mathbb{S}^{m-1}$ 是正交规范的，因此 $O_{m,r}$ 可以嵌入于 r 个单位球面的 Cartesian 积，即

$$O_{m,r} \subset \mathbb{S}^{m-1} \times \mathbb{S}^{m-1} \times \cdots \times \mathbb{S}^{m-1}。$$

根据推论 C4.2.11 (Euclidean 球的覆盖数)，可得存在 ε-网 $\mathcal{N}_0 \subset \mathbb{S}^{m-1}$，满足 $|\mathcal{N}_0| \leqslant (3/\varepsilon)^m$。

构造 Cartesian 积网 $\mathcal{N} = \mathcal{N}_0 \times \cdots \times \mathcal{N}_0$，满足

$$|\mathcal{N}| = |\mathcal{N}_0|^r \leqslant \left(\frac{3}{\varepsilon}\right)^{mr}。$$

之后分别为 $\boldsymbol{u}_i$ 寻找距离最近的 $\boldsymbol{x}_i \in \mathcal{N}_0$，使得 $\|\boldsymbol{u}_i - \boldsymbol{x}_i\|_2 \leqslant \varepsilon$，令 $\boldsymbol{X} = (\boldsymbol{x}_1, \cdots, \boldsymbol{x}_r) \in \mathcal{N}$，则

$$\|\boldsymbol{U} - \boldsymbol{X}\|_{1\to 2} = \max_{1\leqslant i\leqslant r}\|\boldsymbol{u}_i - \boldsymbol{x}_i\|_2 \leqslant \varepsilon,$$

因此 $\mathcal{N}$ 为 $O_{m,r}$ 在 $\|\cdot\|_{1\to 2}$ 范数下的 ε-网，此时令 $C = 3$。

(2) 设 $\boldsymbol{A}\in M_{m,n,r}$ 的 SVD 形式为 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，其中 $\boldsymbol{U}\in O_{m,r}$，$\boldsymbol{V}\in O_{n,r}$，$\boldsymbol{\Sigma}=\mathrm{diag}(s_1,\cdots,s_r)$。

由于 $\|\boldsymbol{A}\|_F^2=\sum s_i^2\leqslant 1$，因此 $\boldsymbol{s}=(s_1,\cdots,s_r)^\top\in\mathbb{B}_2^r$。

令 $\varepsilon_0=\varepsilon/3$，分别构造内部网：

1. 对于 $O_{m,r}$，令 $\mathcal{N}_U$ 为 $\|\cdot\|_{1\to 2}$ 范数的 ε_0-网，满足 $|\mathcal{N}_U|\leqslant(C/\varepsilon_0)^{mr}$。
2. 对于 $O_{n,r}$，令 $\mathcal{N}_V$ 为 $\|\cdot\|_{1\to 2}$ 范数的 ε_0-网，满足 $|\mathcal{N}_V|\leqslant(C/\varepsilon_0)^{nr}$。
3. 对于 $\mathbb{B}_2^r$，取 Euclidean 范数的 ε_0-网 $\mathcal{N}_\Sigma$，满足 $|\mathcal{N}_\Sigma|\leqslant(3/\varepsilon_0)^r$。

构造 Cartesian 积网

$$\mathcal{W}=\{\tilde{\boldsymbol{U}}\tilde{\boldsymbol{\Sigma}}\tilde{\boldsymbol{V}}^\top:\tilde{\boldsymbol{U}}\in\mathcal{N}_U,\tilde{\boldsymbol{\Sigma}}\in\mathcal{N}_\Sigma,\tilde{\boldsymbol{V}}\in\mathcal{N}_V\},$$

满足 $|\mathcal{W}|\leqslant(C'/\varepsilon)^{(m+n+1)r}$，则对于任意的 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，利用三角不等式，可得

$$\|\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top-\tilde{\boldsymbol{U}}\tilde{\boldsymbol{\Sigma}}\tilde{\boldsymbol{V}}^\top\|_F\leqslant\|(\boldsymbol{U}-\tilde{\boldsymbol{U}})\boldsymbol{\Sigma}\boldsymbol{V}^\top\|_F+\|\tilde{\boldsymbol{U}}(\boldsymbol{\Sigma}-\tilde{\boldsymbol{\Sigma}})\boldsymbol{V}^\top\|_F+\|\tilde{\boldsymbol{U}}\tilde{\boldsymbol{\Sigma}}(\boldsymbol{V}-\tilde{\boldsymbol{V}})^\top\|_F。$$

对于第一项，由于 $\boldsymbol{v}_i$ 是正交的，因此

$$\|(\boldsymbol{U}-\tilde{\boldsymbol{U}})\boldsymbol{\Sigma}\boldsymbol{V}^\top\|_F=\|(\boldsymbol{U}-\tilde{\boldsymbol{U}})\boldsymbol{\Sigma}\|_F=\sqrt{\sum_{i=1}^r s_i^2\|\boldsymbol{u}_i-\tilde{\boldsymbol{u}}_i\|_2^2}\leqslant\varepsilon_0\sqrt{\sum_{i=1}^r s_i^2}\leqslant\varepsilon_0。$$

对于第二项，由于 $\tilde{\boldsymbol{U}}$ 与 $\boldsymbol{v}_i$ 是正交的，因此

$$\|\tilde{\boldsymbol{U}}(\boldsymbol{\Sigma}-\tilde{\boldsymbol{\Sigma}})\boldsymbol{V}^\top\|_F=\|\boldsymbol{\Sigma}-\tilde{\boldsymbol{\Sigma}}\|_F=\|\boldsymbol{s}-\tilde{\boldsymbol{s}}\|_2\leqslant\varepsilon_0。$$

对于第三项，同理，

$$\|\tilde{\boldsymbol{U}}\tilde{\boldsymbol{\Sigma}}(\boldsymbol{V}-\tilde{\boldsymbol{V}})^\top\|_F=\|(\boldsymbol{V}-\tilde{\boldsymbol{V}})\tilde{\boldsymbol{\Sigma}}\|_F\leqslant\varepsilon_0\|\tilde{\boldsymbol{s}}\|_2\leqslant\varepsilon_0。$$

如此，

$$\|(\boldsymbol{U}-\tilde{\boldsymbol{U}})\boldsymbol{\Sigma}\boldsymbol{V}^\top\|_F\leqslant 3\varepsilon_0=\varepsilon,$$

从而 $\mathcal{W}$ 为 ε-网。

(3) (无需计算整个复杂流形的体积，只需于 $M_{m,n,r}$ 嵌入一些简单的 Euclidean 子空间即可。)

- 构造子空间 E_1

  考虑仅前 r 列非零的矩阵集合 $\boldsymbol{A}=(\boldsymbol{X},\boldsymbol{O})$，其中 $\boldsymbol{X}\in\mathbb{R}^{m\times r}$，$\|\boldsymbol{X}\|_F\leqslant 1$，满足 $\mathrm{rank}(\boldsymbol{A})\leqslant r$，$\|\boldsymbol{A}\|_F=\|\boldsymbol{X}\|_F\leqslant 1$，则 $E_1\subset M_{m,n,r}(\mathbb{R})\cong\mathbb{B}_2^{mr}$，因此

$$\mathcal{N}(M_{m,n,r},\|\cdot\|_F,\varepsilon)\geqslant\mathcal{N}(E_1,\|\cdot\|_F,\varepsilon)\geqslant\left(\frac{c}{\varepsilon}\right)^{mr}。$$

- 构造子空间 E_2

  根据对称性，考虑仅前 r 行非零的矩阵集合 $\boldsymbol{A}=(\boldsymbol{Y},\boldsymbol{O})^\top$，则 $E_2\subset M_{m,n,r}(\mathbb{R})\cong\mathbb{B}_2^{nr}$，因此

$$\mathcal{N}(M_{m,n,r},\|\cdot\|_F,\varepsilon)\geqslant\mathcal{N}(E_2,\|\cdot\|_F,\varepsilon)\geqslant\left(\frac{c}{\varepsilon}\right)^{nr}。$$

上述下界必须同时满足，因此

$$\mathcal{N}\geqslant\max\left(\left(\frac{c}{\varepsilon}\right)^{mr},\left(\frac{c}{\varepsilon}\right)^{nr}\right)=\left(\frac{c}{\varepsilon}\right)^{\max(m,n)r}\geqslant\left(\frac{c}{\varepsilon}\right)^{\frac{1}{2}(m+n)r}。$$

51 [**混合 Gaussian 模型的谱聚类保证**] 证明定理 T4.7.5 (Gaussian 混合模型的谱聚类)，该定理保证了谱聚类算法能够成功学习混合 Gaussian 模型。

定理 T4.7.5 (Gaussian 混合模型的谱聚类)：设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m\in\mathbb{R}^n$ 为抽取于 $N(\boldsymbol{\mu},\boldsymbol{I}_n),N(-\boldsymbol{\mu},\boldsymbol{I}_n)$ 的均匀混合模型的独立样本；该混合模型满足 $\mathrm{E}[\boldsymbol{X}]=\boldsymbol{0}$。若样本量满足 $m\geqslant Cn$，中心距离满足 $\|\boldsymbol{\mu}\|_2\geqslant C$，则谱聚类算法以高概率能够正确识别社区 (w.p. 0.99)，误分类点数不超过 1% 的点。

(1) 计算 $\boldsymbol{X}$ 的协方差矩阵 $\boldsymbol{\Sigma}$，并注意到其主特征向量 $\boldsymbol{u}$ 与 $\boldsymbol{\mu}$ 共线。

(2) 由此推出：$\langle\boldsymbol{X}_i,\boldsymbol{u}\rangle$ 的符号能够正确分类大部分点 $\boldsymbol{X}_i$。

(3) 利用协方差估计的结果证明：样本协方差矩阵 $\boldsymbol{\Sigma}_m$ 逼近 $\boldsymbol{\Sigma}$。

(4) 利用定理 T4.1.15 (Davis–Kahan 不等式) 推出：$\boldsymbol{\Sigma}_m$ 的主特征向量 $\boldsymbol{v} = \boldsymbol{v}_1(\boldsymbol{\Sigma}_m)$ 逼近 $\boldsymbol{u}$。

(5) 利用 (2) 推出：$\langle \boldsymbol{X}_i, \boldsymbol{v}\rangle$ 的符号能够正确分类大部分点 $\boldsymbol{X}_i$。

证明 • 分析总体协方差矩阵的结构

设样本的真实隐变量标签为 y_i i.i.d. $\sim$ Rademacher，则

$$\boldsymbol{X}_i = y_i\boldsymbol{\mu} + \boldsymbol{g}_i, \qquad (\boldsymbol{g}_i \sim N(\boldsymbol{0}, \boldsymbol{I}_n))$$

总体协方差矩阵 $\boldsymbol{\Sigma}$ 为

$$\boldsymbol{\Sigma} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \mathrm{E}[(y\boldsymbol{\mu}+\boldsymbol{g})(y\boldsymbol{\mu}+\boldsymbol{g})^\top] = \mathrm{E}[y^2]\boldsymbol{\mu}\boldsymbol{\mu}^\top + \mathrm{E}[\boldsymbol{g}\boldsymbol{g}^\top] = \boldsymbol{\mu}\boldsymbol{\mu}^\top + \boldsymbol{I}_n。$$

对 $\boldsymbol{\Sigma}$ 进行谱分析，

$$\boldsymbol{\Sigma}\boldsymbol{\mu} = (\boldsymbol{\mu}\boldsymbol{\mu}^\top + \boldsymbol{I}_n)\boldsymbol{\mu} = (\|\boldsymbol{\mu}\|_2^2 + 1)\boldsymbol{\mu} \implies \lambda_1 = \|\boldsymbol{\mu}\|_2^2 + 1,$$
$$\boldsymbol{w} \perp \boldsymbol{\mu} \implies \boldsymbol{\Sigma}\boldsymbol{w} = \boldsymbol{w} \implies \lambda_2 = 1,$$

因此第一主特征向量为 $\boldsymbol{u} = \bar{\boldsymbol{\mu}}$，其与 $\boldsymbol{\mu}$ 是共线的。

• 理想特征向量 $\boldsymbol{u}$ 的分类性能

考虑

$$\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle = y_i\langle \boldsymbol{\mu}, \boldsymbol{u}\rangle + \langle \boldsymbol{g}_i, \boldsymbol{u}\rangle = y_i\|\boldsymbol{\mu}\|_2 + Z_i,$$

其中 $Z_i = \langle \boldsymbol{g}_i, \boldsymbol{u}\rangle \sim N(0,1)$。

算法发生误分类，当且仅当 $\mathrm{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle) \neq y_i$，等价于 $y_iZ_i < -\|\boldsymbol{\mu}\|_2$。由于 $y_iZ_i \sim N(0,1)$，可得

$$\begin{aligned} p_{\mathrm{err}} &= \mathrm{P}\{y_iZ_i < -\|\boldsymbol{\mu}\|_2\} \\ &= \mathrm{P}\{Z_i > \|\boldsymbol{\mu}\|_2\} \\ &\leqslant \exp\left(-\frac{\|\boldsymbol{\mu}\|_2^2}{2}\right), \end{aligned}$$

注意到 $\|\boldsymbol{\mu}\|_2 \geqslant C$，因此当 C 充分大时，$p_{\mathrm{err}} \leqslant 0.005$，从而利用定理 T2.3.1 (Chernoff 不等式) (Chernoff 不等式)，可得理想分类器 $\boldsymbol{u}$ 的误分类点数不超过总点数的 0.5%，即

$$\frac{1}{m}\sum_{i=1}^m \mathbf{1}_{\{\mathrm{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle) \neq y_i\}} \leqslant 0.005。$$

• 样本协方差矩阵的逼近

设样本协方差矩阵为

$$\boldsymbol{\Sigma}_m = \frac{1}{m}\sum_{i=1}^m \boldsymbol{X}_i\boldsymbol{X}_i^\top,$$

则 $\boldsymbol{\Sigma}_m$ 为 sub-Gaussian 随机矩阵，因此根据定理 T4.7.1 (协方差估计) (或注记 R4.7.3 (高概率界))，成立

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant C_1\sqrt{\frac{n}{m}}\|\boldsymbol{\Sigma}\| = C_1\sqrt{\frac{n}{m}}(1 + \|\boldsymbol{\mu}\|_2^2) \text{ (w.p. 0.995)}。 \qquad (C_1 > 0)$$

注意到 $m \geqslant Cn$，因此当 C 充分大时，

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant \frac{1}{10}\|\boldsymbol{\mu}\|_2^2。$$

(由于 $\|\boldsymbol{\mu}\|_2 \geqslant C \geqslant 1$，故 $1 + \|\boldsymbol{\mu}\|_2^2 \leqslant 2\|\boldsymbol{\mu}\|_2^2$，上述条件易满足。)

• Davis-Kahan 界定特征向量扰动

令 $\boldsymbol{v}$ 为 $\boldsymbol{\Sigma}_m$ 的第一主特征向量，谱间隙为 $\delta = \lambda_1 - \lambda_2 = \|\boldsymbol{\mu}\|_2^2$，则根据 Davis-Kahan 定理 (结合 $\sin\Theta$ 引理的形式，参考习题 Q4.16 (向量之间的角度与 Euclidean 距离))，可得

$$\min_{s\in\{-1,1\}} \|\boldsymbol{v} - s\boldsymbol{u}\|_2 \leqslant \frac{2\sqrt{2}\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\|}{\delta} \leqslant \frac{2\sqrt{2}\cdot\frac{1}{10}\|\boldsymbol{\mu}\|_2^2}{\|\boldsymbol{\mu}\|_2^2} \leqslant \frac{1}{3}。$$

不妨设符号一致，则 $\boldsymbol{h} = \boldsymbol{v} - \boldsymbol{u}$，满足 $\|\boldsymbol{h}\|_2 \leqslant 1/3$。

将样本协方差估计代入上式，可得

$$\begin{aligned}\|\boldsymbol{h}\|_2 &\leqslant 2\sqrt{2}C_1\sqrt{\frac{n}{m}}\frac{1+\|\boldsymbol{\mu}\|_2^2}{\|\boldsymbol{\mu}\|_2^2}\\ &\leqslant 4\sqrt{2}C_1\sqrt{\frac{n}{m}}。\end{aligned}$$

记 $\varepsilon_0 = 4\sqrt{2}C_1\sqrt{n/m}$。增大题设常数后，可使 $\varepsilon_0 \leqslant 0.01$。此界以样本协方差近似事件为前提，并将用于后续的误分类计数。

- 扰动对分类误差的界定

对于实际的测试统计量 $\langle \boldsymbol{X}_i, \boldsymbol{v}\rangle = \langle \boldsymbol{X}_i, \boldsymbol{u}\rangle + \langle \boldsymbol{X}_i, \boldsymbol{h}\rangle$，若实际分类错误，但理想分类正确，则扰动项改变了符号，即

$$|\langle \boldsymbol{X}_i, \boldsymbol{h}\rangle| \geqslant |\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle|。$$

将投影值位于“决策边界附近”的样本索引定义为

$$S_1 = \left\{ i \in \{1,\cdots,m\} : |\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle| < \frac{1}{2}\|\boldsymbol{\mu}\|_2 \right\},$$

若 $i \in S_1$，则 $|Z_i| > \|\boldsymbol{\mu}\|_2/2$。

由于 $Z_i \sim N(0,1)$，因此利用定理 T2.2.1 (Hoeffding 不等式) (Hoeffding 不等式) (或者其他 Gaussian 尾部概率界限的集中不等式)，可得当 $\|\boldsymbol{\mu}\|_2 \geqslant C$ 时，

$$|S_1| \leqslant 0.001m \text{ (w.h.p.)}。$$

对于剩余部分，考虑因特征向量扰动 $\boldsymbol{h} = \boldsymbol{v} - \boldsymbol{u}$ 而导致符号翻转的样本，定义此类样本的索引集合为

$$S_2 = \{ i \notin S_1 : \operatorname{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{v}\rangle) \neq \operatorname{sgn}(\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle) \},$$

对于任意的 $i \in S_2$，其实际投影 $\langle \boldsymbol{X}_i, \boldsymbol{v}\rangle = \langle \boldsymbol{X}_i, \boldsymbol{u}\rangle + \langle \boldsymbol{X}_i, \boldsymbol{h}\rangle$ 发生了符号反转，因此扰动项的绝对值必须不小于理想投影的绝对值，即

$$|\langle \boldsymbol{X}_i, \boldsymbol{h}\rangle| \geqslant |\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle| \geqslant \frac{1}{2}\|\boldsymbol{\mu}\|_2 \implies \langle \boldsymbol{X}_i, \boldsymbol{h}\rangle^2 \geqslant \frac{1}{4}\|\boldsymbol{\mu}\|_2^2,$$

对 S_2 的所有样本的扰动项平方进行求和，

$$\sum_{i\in S_2}\langle \boldsymbol{X}_i, \boldsymbol{h}\rangle^2 \leqslant \sum_{i=1}^{m}\langle \boldsymbol{X}_i, \boldsymbol{h}\rangle^2 = \boldsymbol{h}^\top\left(\sum_{i=1}^{m}\boldsymbol{X}_i\boldsymbol{X}_i^\top\right)\boldsymbol{h} = m\cdot\boldsymbol{h}^\top\boldsymbol{\Sigma}_m\boldsymbol{h} \leqslant m\cdot\|\boldsymbol{\Sigma}_m\|\|\boldsymbol{h}\|_2^2,$$

其中 $\|\boldsymbol{\Sigma}_m\| \leqslant 2\|\boldsymbol{\Sigma}\| = 2(1+\|\boldsymbol{\mu}\|_2^2)$，$\|\boldsymbol{h}\|_2 \leqslant \varepsilon_0$，因此

$$\sum_{i\in S_2}\langle \boldsymbol{X}_i, \boldsymbol{h}\rangle^2 \leqslant 2m(1+\|\boldsymbol{\mu}\|_2^2)\varepsilon_0^2,$$

从而

$$|S_2|\cdot\frac{1}{4}\|\boldsymbol{\mu}\|_2^2 \leqslant 2m\varepsilon_0^2(1+\|\boldsymbol{\mu}\|_2^2),$$

即

$$|S_2| \leqslant 8m\varepsilon_0^2\frac{1+\|\boldsymbol{\mu}\|_2^2}{\|\boldsymbol{\mu}\|_2^2} \leqslant 16m\varepsilon_0^2。$$

注意到 $\varepsilon_0 \propto \sqrt{n/m}$，因此当 C 充分大时，$\varepsilon_0 \leqslant 0.01$，此时

$$|S_2| \leqslant 16m\cdot 10^{-4} = 0.0016m \leqslant 0.004m。$$

- 三个误差集合给出最终分类界

令 M_0 为理想分类器 $\boldsymbol{u}$ 的误分类集合，M 为实际分类器 $\boldsymbol{v}$ 的误分类集合。前一部分已经可得

$$|M_0| \leqslant 0.005m。$$

对于边界带集合 S_1, 符号翻转集合 S_2，前述估计可得

$$\begin{aligned}|S_1| &\leqslant 0.001m,\\ |S_2| &\leqslant 16m\varepsilon_0^2 \leqslant 0.004m。\end{aligned}$$

若 $i \in M \setminus M_0$，则理想分类器在 i 正确，实际分类器符号不同于理想分类器。若 $i \in S_1$，则此点属于边界带；若 $i \notin S_1$，则 $i \in S_2$。可得

$$M \subset M_0 \cup S_1 \cup S_2。$$

对三个计数事件应用并集界，并增大题设常数，可使下面的结论成立。

$$\begin{aligned} |M| &\leqslant |M_0| + |S_1| + |S_2| \\ &\leqslant (0.005 + 0.001 + 0.004)m \\ &= 0.01m \ (\text{w.h.p.})。 \end{aligned}$$

非独立情形的集中性

5

要点梳理

Section 5.1 球面 Lipschitz 函数的集中 Q5.1 ~ Q5.7

定义 5.1.1 (Lipschitz 函数)

函数 $f:\mathbb{R}^n\to\mathbb{R}$ 称为关于 Euclidean 范数 L-Lipschitz 的，若对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，满足 $|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant L\|\boldsymbol{x}-\boldsymbol{y}\|_2$。最小的此类 L 记作 $\|f\|_{\mathrm{Lip}}$。

例 5.1.2 (向量, 矩阵, 范数定义自然 Lipschitz 函数)

(a) 对固定的向量 $\boldsymbol{a}\in\mathbb{R}^n$，线性泛函 $f(\boldsymbol{x})=\langle\boldsymbol{x},\boldsymbol{a}\rangle$ 的 Lipschitz 范数为 $\|f\|_{\mathrm{Lip}}=\|\boldsymbol{a}\|_2$。(b) 对于任意的矩阵 $\boldsymbol{A}$，线性算子 $f(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}$ 的 Lipschitz 范数为 $\|f\|_{\mathrm{Lip}}=\|\boldsymbol{A}\|$。(c) 对于 $\mathbb{R}^n$ 的任意的范数 $\|\cdot\|$，函数 $f(\boldsymbol{x})=\|\boldsymbol{x}\|$ 的 Lipschitz 范数等于使 $\|\boldsymbol{x}\|\leqslant L\|\boldsymbol{x}\|_2$ 对于任意的 $\boldsymbol{x}$ 成立的最小 L。

定理 5.1.3 (球面 Lipschitz 函数的集中)

设 $\boldsymbol{X}$ 均匀分布于 $\mathbb{R}^n$ 的半径为 $\sqrt{n}$ 的 Euclidean 球面，则对于任意的 1-Lipschitz 函数 $f:\mathbb{R}^n\to\mathbb{R}$，

$$\mathrm{P}\{|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]|\geqslant t\}\leqslant 2\exp(-ct^2)$$

对于任意的 $t\geqslant 0$ 均满足。

定理 5.1.4 ($\mathbb{R}^n$ 的等周不等式)

给定满足 Gaussian 测度 $\gamma_n(A)$ 固定的集合 $A\subset\mathbb{R}^n$，半空间最小化 Gaussian 周长 (Gaussian 度量的 Minkowski 容量)。

定理 5.1.5 (球面的等周不等式)

给定满足球面测度 $\sigma(A)$ 固定的集合 $A\subset\mathbb{S}^{n-1}$，球冠最小化球面周长。

引理 5.1.6 (膨胀)

设 A 为球面 $\mathbb{S}^{n-1}$ 的子集，满足 $\sigma(A)\geqslant 1/2$，则 t-邻域 A_t 满足

$$\sigma(A_t)\geqslant 1-2\exp(-cnt^2)。$$

Section 5.2 其他度量测度空间的集中 Q5.8 ~ Q5.13

定理 5.2.2 (Gaussian 等周不等式)
给定 $\varepsilon>0$, 满足 Gaussian 测度 $\gamma_n(A)$ 固定的集合 $A\subset\mathbb{R}^n$，半空间最小化 $\gamma_n(A_\varepsilon)$，其中 $A_\varepsilon=\{\boldsymbol{x}:\operatorname{dist}(\boldsymbol{x},A)\leqslant\varepsilon\}$。

定理 5.2.3 (Gaussian 集中)
考虑随机向量 $\boldsymbol{X}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，$L$-Lipschitz 函数 $f:\mathbb{R}^n\to\mathbb{R}$，则

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2}\leqslant CL。$$

定理 5.2.5 (Hamming 立方体的集中)
设 $f:\{-1,1\}^n\to\mathbb{R}$ 为满足

$$|f(x)-f(y)|\leqslant\frac{1}{\sqrt{n}}\sum_{i=1}^n|x_i-y_i|,$$

的函数。若 $\boldsymbol{X}$ 均匀分布于 $\{-1,1\}^n$，则

$$\mathrm{P}\{|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]|\geqslant t\}\leqslant 2\exp(-cnt^2)。$$

定理 5.2.6 (对称群的集中)
设 $f:S_n\to\mathbb{R}$ 为对称群关于归一化 Hamming 度量满足 $\|f\|_{\mathrm{Lip}}\leqslant 1$ 的函数。若 π 均匀分布于 S_n，则

$$\mathrm{P}\{|f(\pi)-\mathrm{E}[f(\pi)]|\geqslant t\}\leqslant 2\exp(-cnt^2)。$$

定理 5.2.7 (特殊正交群的集中)
设 $f:SO(n)\to\mathbb{R}$ 为关于 Hilbert–Schmidt 度量 1-Lipschitz 的函数，U 均匀分布于 $SO(n)$，则

$$\mathrm{P}\{|f(U)-\mathrm{E}[f(U)]|\geqslant t\}\leqslant 2\exp(-cnt^2)。$$

定理 5.2.9 (Grassmann 流形的集中)
设 f 为 Grassmann 流形 $G_{n,k}$ 于投影度量下 1-Lipschitz 的函数，E 均匀分布，则

$$\mathrm{P}\{|f(E)-\mathrm{E}[f(E)]|\geqslant t\}\leqslant 2\exp(-cnt^2)。$$

定理 5.2.10 (连续立方体, 球的集中)
设 $\boldsymbol{X}$ 均匀分布于 $[0,1]^n$ 或 $\mathbb{B}_2^n$，则对于任意的 1-Lipschitz 函数 f，

$$\mathrm{P}\{|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]|\geqslant t\}\leqslant 2\exp(-cnt^2)。$$

定理 5.2.12 (Talagrand 集中不等式)
设 $\boldsymbol{X}=(X_1,\cdots,X_n)$ 的坐标独立，f 为 $\mathbb{R}^n$ 的 1-Lipschitz 凸函数，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|f(\boldsymbol{X})-M|\geqslant t\}\leqslant 4\exp(-ct^2),$$

其中 M 为 $f(\boldsymbol{X})$ 的中位数。

Section 5.3 Johnson-Lindenstrauss 引理 Q5.14 ∼ Q5.15

定理 5.3.1 (Johnson–Lindenstrauss 引理)
对于 $\mathbb{R}^n$ 的任意的包含 N 个点的集合 $\mathbb{T}$，任意的 $\varepsilon\in(0,1)$，存在线性映射 $\boldsymbol{Q}:\mathbb{R}^n\to\mathbb{R}^m$ (其中 $m\leqslant C\varepsilon^{-2}\ln N$)，使得对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}$，均满足

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant\|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_2\leqslant(1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

引理 5.3.2 (随机投影)
设 $\boldsymbol{Q}=\frac{1}{\sqrt{m}}\boldsymbol{A}$，其中 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则对于任意的固定 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\mathrm{P}\{(1-\varepsilon)\|\boldsymbol{x}\|_2\leqslant\|\boldsymbol{Q}\boldsymbol{x}\|_2\leqslant(1+\varepsilon)\|\boldsymbol{x}\|_2\}\geqslant 1-2\exp(-cm\varepsilon^2)。$$

Section 5.4 矩阵 Bernstein 不等式 Q5.16 ∼ Q5.24

定理 5.4.1 (矩阵 Bernstein 不等式)
设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为独立, 零均值, n 阶对称随机矩阵，满足 $\|\boldsymbol{X}_i\|\leqslant M$ 几乎必然，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\left\{\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|\geqslant t\right\}\leqslant 2n\cdot\exp\left(-\frac{t^2/2}{\sigma^2+Mt/3}\right),$$

其中 $\sigma^2=\left\|\sum_{i=1}^N\mathrm{E}[\boldsymbol{X}_i^2]\right\|$。

定义 5.4.2 (矩阵的函数)
对于对称矩阵 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，记其特征分解为 $\boldsymbol{A}=\sum_i\lambda_i\boldsymbol{u}_i\boldsymbol{u}_i^\top$；对于函数 $f:\mathbb{R}\to\mathbb{R}$，定义 $f(\boldsymbol{A})=\sum_i f(\lambda_i)\boldsymbol{u}_i\boldsymbol{u}_i^\top$。

定义 5.4.3 (Loewner 序)
对于对称矩阵 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{n\times n}$，若 $\boldsymbol{B}-\boldsymbol{A}$ 为半正定，则记 $\boldsymbol{A}\preceq\boldsymbol{B}$。

命题 5.4.4 (Loewner 序的简单性质)
(i) $\boldsymbol{A}\preceq\boldsymbol{B}$ 蕴含 $\mathrm{tr}(\boldsymbol{A})\leqslant\mathrm{tr}(\boldsymbol{B})$。(ii) 若 $0\preceq\boldsymbol{A}\preceq\boldsymbol{B}$，则 $\|\boldsymbol{A}\|\leqslant\|\boldsymbol{B}\|$。(iii) 若 $0\prec\boldsymbol{A}\preceq\boldsymbol{B}$，则 $\ln\boldsymbol{A}\preceq\ln\boldsymbol{B}$ (对数的算子单调性)；若 $\boldsymbol{I}_n\preceq\boldsymbol{A}$，则 $0\preceq\ln\boldsymbol{A}$。

定理 5.4.7 (Golden–Thompson 不等式)
对于任意的对称矩阵 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{n\times n}$，

$$\mathrm{tr}(\mathrm{e}^{\boldsymbol{A}+\boldsymbol{B}})\leqslant\mathrm{tr}(\mathrm{e}^{\boldsymbol{A}}\mathrm{e}^{\boldsymbol{B}})。$$

定理 5.4.8 (Lieb 不等式)
对于任意的固定的对称矩阵 $\boldsymbol{H}\in\mathbb{R}^{n\times n}$，函数 $\boldsymbol{A}\mapsto\mathrm{tr}[\exp(\boldsymbol{H}+\ln\boldsymbol{A})]$ 于正定矩阵集合是凹的。

引理 5.4.9 (随机矩阵的 Lieb 不等式)
设 $\boldsymbol{H}\in\mathbb{R}^{n\times n}$ 为固定的对称矩阵，则

$$\mathrm{E}\left[\mathrm{tr}\exp\left(\boldsymbol{H}+\sum_{i=1}^N\boldsymbol{X}_i\right)\right]\leqslant\mathrm{tr}\left[\exp\left(\boldsymbol{H}+\sum_{i=1}^N\ln\mathrm{E}[\exp\boldsymbol{X}_i]\right)\right],$$

其中 $\boldsymbol{X}_i$ 为独立随机对称矩阵。

引理 5.4.10 (矩母函数)
对于对称随机矩阵 $\boldsymbol{X}\in\mathbb{R}^{n\times n}$，若 $\mathrm{E}[\boldsymbol{X}]=0$，$\|\mathrm{E}[\boldsymbol{X}^2]\|\leqslant\sigma^2$，则当 $|\lambda|\leqslant 1/M$ (其中 $\|\boldsymbol{X}\|\leqslant M$ a.s.) 时，

$$\mathrm{E}[\mathrm{tr}\exp(\lambda\boldsymbol{X})]\leqslant n\cdot\exp(\lambda^2\sigma^2/2)。$$

定理 5.4.13 (矩阵 Hoeffding 不等式)
设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N\in\mathbb{R}^{n\times n}$ 为独立, 零均值的对称随机矩阵，满足 $\|\boldsymbol{X}_i\|\leqslant M_i$ 几乎必然，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\left\{\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|\geqslant t\right\}\leqslant 2n\cdot\exp\left(-\frac{t^2}{2\sum_{i=1}^N M_i^2}\right)。$$

定理 5.4.14 (矩阵 Khintchine 不等式)

设 $\varepsilon_1,\cdots,\varepsilon_N$ 为独立 Rademacher 随机变量，$\boldsymbol{A}_1,\cdots,\boldsymbol{A}_N$ 为固定的 n 阶对称矩阵，则对于任意的 $p\geqslant 1$，

$$\left(\mathrm{E}\left\|\sum_i \varepsilon_i \boldsymbol{A}_i\right\|^p\right)^{1/p} \leqslant C\sqrt{p+\ln n}\cdot\left\|\sum_i \boldsymbol{A}_i^2\right\|^{1/2}。$$

Section 5.5 稀疏网络的社区检测 Q5.25

定理 5.5.1 (稀疏随机块模型的谱聚类)

考虑 n 个顶点，边概率 a/n, b/n 的 SBM (稀疏区域)。若 $(a-b)^2>C(a+b)$，则利用于邻接矩阵的谱聚类部分恢复社区 (w.h.p.) (误分类顶点的比例为 $o(1)$)。

Section 5.6 一般分布的协方差估计 Q5.26 ~ Q5.32

定理 5.6.1 (一般协方差估计)

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为中心化[1]随机向量，其协方差矩阵为 $\boldsymbol{\Sigma}$，即 $\mathrm{E}[\boldsymbol{X}]=\boldsymbol{0}$。假设对于任意的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，边缘 $\langle\boldsymbol{X},\boldsymbol{v}\rangle$ 的 sub-Exponential 范数至多为 K。令 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为独立副本，

$$\boldsymbol{\Sigma}_N=\frac{1}{N}\sum_{i=1}^N \boldsymbol{X}_i\boldsymbol{X}_i^{\top},$$

为样本协方差，则对于任意的 $t\geqslant 0$，以高概率，

$$\mathrm{P}\left\{\|\boldsymbol{\Sigma}_N-\boldsymbol{\Sigma}\|\leqslant CK^2\max\left(\sqrt{\frac{n+t}{N}},\frac{n+t}{N}\right)\|\boldsymbol{\Sigma}\|\right\}\geqslant 1-2\exp(-ct)。$$

注记 5.6.5 (高概率保证)

证明实际上给出更强的高概率保证：关于定理 T5.6.1 (一般协方差估计) 的设定，对于任意的 $u\geqslant 0$，成立

$$\mathrm{P}\left\{\|\boldsymbol{\Sigma}_N-\boldsymbol{\Sigma}\|\leqslant CK^2 r\frac{\ln n+u}{N}\|\boldsymbol{\Sigma}\|\right\}\geqslant 1-2\mathrm{e}^{-u},$$

其中 $r=\mathrm{tr}(\boldsymbol{\Sigma})/\|\boldsymbol{\Sigma}\|$ 为有效秩。

Section 5.7 有界差分不等式 Q5.1 ~ Q5.32

定理 5.7.1 (有界差分不等式)

设 $\boldsymbol{X}=(X_1,\cdots,X_n)$ 的坐标独立，$f:\mathbb{R}^n\to\mathbb{R}$ 满足有界差分条件：当 $\boldsymbol{x}$, $\boldsymbol{x}'$ 仅在第 i 个坐标不同时，$|f(\boldsymbol{x})-f(\boldsymbol{x}')|\leqslant c_i$，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\geqslant t\}\leqslant\exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right)。$$

习题解答

1 [连续性, 可微性与 Lipschitz 函数的关系]

(1) (Lipschitz 蕴含一致连续) 证明：任意的 Lipschitz 连续的函数必定是一致连续的。

(2) (梯度控制 Lipschitz 范数) 设 $f:\mathbb{R}^n\to\mathbb{R}$ 是可微的。证明：f 满足 Lipschitz 条件 (前提是右侧项有界)，其 Lipschitz 常数 $\|f\|_{\mathrm{Lip}}$ 受其梯度的 Euclidean 范数的上确界控制，

$$\|f\|_{\mathrm{Lip}}\leqslant\sup_{\boldsymbol{x}\in\mathbb{R}^n}\|\nabla f(\boldsymbol{x})\|_2。$$

(3) (反例 1) 构造定义于 $[-1,1]$ 的函数 f，使得其是一致连续的，但不是 Lipschitz 连续的。

(4) (反例 2) 构造定义于 $[-1,1]$ 的函数 f，使得其是 Lipschitz 连续的，但不是处处可微的。

证明 (1) 设 $f:D\to\mathbb{R}^m$ 是 Lipschitz 连续的，即存在 $L\geqslant 0$，使得对于任意的 $\boldsymbol{x},\boldsymbol{y}\in D$，均满足

$$\|f(\boldsymbol{x})-f(\boldsymbol{y})\|\leqslant L\|\boldsymbol{x}-\boldsymbol{y}\|。$$

(注意一致连续的定义为：对于任意的 $\varepsilon>0$，存在 $\delta>0$，使得对于任意的满足 $\|\boldsymbol{x}-\boldsymbol{y}\|<\delta$ 的 $\boldsymbol{x},\boldsymbol{y}\in D$，均满足 $\|f(\boldsymbol{x})-f(\boldsymbol{y})\|<\varepsilon$。)

a. 若 $L=0$，则 f 为常函数，结论是平凡的。

b. 若 $L>0$，则对于任意的 $\varepsilon>0$，令 $\delta=\varepsilon/L$，可得

$$\|f(\boldsymbol{x})-f(\boldsymbol{y})\|\leqslant L\|\boldsymbol{x}-\boldsymbol{y}\|<L\cdot\frac{\varepsilon}{L}=\varepsilon,$$

因此 f 是一致连续的。

(2) 构造辅助函数

$$g(t)=f(\boldsymbol{x}+t(\boldsymbol{y}-\boldsymbol{x})),\qquad(t\in(0,1))$$

则

$$g'(t)=\nabla f(\boldsymbol{x}+t(\boldsymbol{y}-\boldsymbol{x}))^{\top}(\boldsymbol{y}-\boldsymbol{x})。$$

根据 Lagrange 中值定理，可得存在 $\theta\in(0,1)$，使得

$$g(1)-g(0)=g'(\theta)\cdot(1-0),$$

记 $\boldsymbol{z}=\boldsymbol{x}+\theta(\boldsymbol{y}-\boldsymbol{x})$，即

$$f(\boldsymbol{y})-f(\boldsymbol{x})=\nabla f(\boldsymbol{z})^{\top}(\boldsymbol{y}-\boldsymbol{x}),$$

两侧取绝对值，利用 Cauchy 不等式，可得

$$|f(\boldsymbol{y})-f(\boldsymbol{x})|=|\langle\nabla f(\boldsymbol{z}),\boldsymbol{y}-\boldsymbol{x}\rangle|\leqslant\|\nabla f(\boldsymbol{z})\|_2\|\boldsymbol{y}-\boldsymbol{x}\|_2\leqslant\left(\sup_{\boldsymbol{w}\in\mathbb{R}^n}\|\nabla f(\boldsymbol{w})\|_2\right)\|\boldsymbol{y}-\boldsymbol{x}\|_2,$$

因此

$$\|f\|_{\mathrm{Lip}}=\sup_{\boldsymbol{x}\neq\boldsymbol{y}}\frac{|f(\boldsymbol{x})-f(\boldsymbol{y})|}{\|\boldsymbol{x}-\boldsymbol{y}\|_2}\leqslant\sup_{\boldsymbol{x}\in\mathbb{R}^n}\|\nabla f(\boldsymbol{x})\|_2。$$

(若右侧梯度的上确界为无穷大，则结论是平凡的，但此时函数不是全局 Lipschitz 的。当梯度有界时，函数必然是 Lipschitz 连续的。)

(3) 考虑 $f(x)=\sqrt{|x|}$，则 f 于 $[-1,1]$ 一致连续，但是

$$\frac{|f(x)-f(0)|}{|x-0|}=\frac{\sqrt{x}-0}{x}=\frac{1}{\sqrt{x}}\to\infty,$$

即 f 不是 Lipschitz 连续的。

(4) 考虑 $f(x)=|x|$，则对于任意的 $x,y\in[-1,1]$

$$|f(x)-f(y)|=||x|-|y||\leqslant|x-y|,$$

即 f 是 Lipschitz 连续的，但是

$$\lim_{h\to0^+}\frac{|0+h|-|0|}{h}=\lim_{h\to0^+}\frac{h}{h}=1,$$
$$\lim_{h\to0^-}\frac{|0+h|-|0|}{h}=\lim_{h\to0^-}\frac{-h}{h}=-1,$$

即 f 于 0 不可导。

(有界斜率并不意味着曲线必定光滑，可能存在尖角。)

2 [**验证自然 Lipschitz 函数的性质**] 验证例 E5.1.2 (向量, 矩阵, 范数定义自然 Lipschitz 函数) 的全部断言。具体而言，试求以下函数的 Lipschitz 范数 $\|f\|_{\mathrm{Lip}}$。

(1) (线性泛函) 对于任意的 $\boldsymbol{\theta}\in\mathbb{R}^n$，定义线性泛函 $f(\boldsymbol{x})=\langle\boldsymbol{x},\boldsymbol{\theta}\rangle$。证明：$\|f\|_{\mathrm{Lip}}=\|\boldsymbol{\theta}\|_2$。

(2) (线性算子) 对于任意的 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，定义线性算子 $f(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}$。证明：$\|f\|_{\mathrm{Lip}}=\|\boldsymbol{A}\|$。

(3) (一般范数) 对于 $\mathbb{R}^n$ 的任意的范数 $\|\cdot\|$，定义 $f(\boldsymbol{x})=\|\boldsymbol{x}\|$。证明：$\|f\|_{\mathrm{Lip}}$ 即为满足 $\|\boldsymbol{x}\|\leqslant L\|\boldsymbol{x}\|_2$ 的最小常数 L。

证明 Lipschitz 范数的定义为

$$\|f\|_{\mathrm{Lip}}=\sup_{\boldsymbol{x}\neq\boldsymbol{y}}\frac{\|f(\boldsymbol{x})-f(\boldsymbol{y})\|}{\|\boldsymbol{x}-\boldsymbol{y}\|_2},$$

(当值域为 $\mathbb{R}$ 时，分子的范数即为绝对值 $|\cdot|$。)

算子范数的定义为

$$\|\boldsymbol{A}\|=\sup_{\boldsymbol{v}\neq\boldsymbol{0}}\frac{\|\boldsymbol{A}\boldsymbol{v}\|_2}{\|\boldsymbol{v}\|_2},$$

$L_{\min}$ 定义为

$$L_{\min}=\sup_{\boldsymbol{v}\neq\boldsymbol{0}}\frac{\|\boldsymbol{v}\|}{\|\boldsymbol{v}\|_2}。$$

(1) 对于上界，设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，则利用 Cauchy 不等式，可得

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|=|\langle\boldsymbol{x},\boldsymbol{\theta}\rangle-\langle\boldsymbol{y},\boldsymbol{\theta}\rangle|=|\langle\boldsymbol{x}-\boldsymbol{y},\boldsymbol{\theta}\rangle|\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_2\|\boldsymbol{\theta}\|_2,$$

因此 $\|f\|_{\mathrm{Lip}}\leqslant\|\boldsymbol{\theta}\|_2$。

对于下界，若 $\boldsymbol{\theta}=\boldsymbol{0}$，则结论是平凡的；若 $\boldsymbol{\theta}\neq\boldsymbol{0}$，令 $\boldsymbol{x}=\boldsymbol{\theta}$，$\boldsymbol{y}=\boldsymbol{0}$，则

$$\frac{|f(\boldsymbol{\theta})-f(\boldsymbol{0})|}{\|\boldsymbol{\theta}-\boldsymbol{0}\|_2}=\frac{|\langle\boldsymbol{\theta},\boldsymbol{\theta}\rangle|}{\|\boldsymbol{\theta}\|_2}=\frac{\|\boldsymbol{\theta}\|_2^2}{\|\boldsymbol{\theta}\|_2}=\|\boldsymbol{\theta}\|_2,$$

因此 $\|f\|_{\mathrm{Lip}}\geqslant\|\boldsymbol{\theta}\|_2$。

如此，$\|f\|_{\mathrm{Lip}}=\|\boldsymbol{\theta}\|_2$。

(2) 对于上界，设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，则

$$\|f(\boldsymbol{x})-f(\boldsymbol{y})\|_2=\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{A}\boldsymbol{y}\|_2=\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2\leqslant\|\boldsymbol{A}\|\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

因此 $\|f\|_{\mathrm{Lip}}\leqslant\|\boldsymbol{A}\|$。

对于下界，令 $\boldsymbol{y}=\boldsymbol{0}$，则对于任意的 $\boldsymbol{x}\neq\boldsymbol{0}$，

$$\frac{\|f(\boldsymbol{x})-f(\boldsymbol{0})\|_2}{\|\boldsymbol{x}-\boldsymbol{0}\|_2}=\frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2},$$

两侧取上确界，

$$\|f\|_{\mathrm{Lip}}=\sup_{\boldsymbol{x}\neq\boldsymbol{y}}\frac{\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2}{\|\boldsymbol{x}-\boldsymbol{y}\|_2}\geqslant\sup_{\boldsymbol{x}\neq\boldsymbol{0}}\frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2}=\|\boldsymbol{A}\|,$$

因此 $\|f\|_{\mathrm{Lip}}\geqslant\|\boldsymbol{A}\|$。

如此，$\|f\|_{\mathrm{Lip}}=\|\boldsymbol{A}\|$。

(3) 对于上界，设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，则

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|=|\|\boldsymbol{x}\|-\|\boldsymbol{y}\||\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|,$$

因此

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant L_{\min}\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

即 $\|f\|_{\mathrm{Lip}}\leqslant L_{\min}$。

对于下界，同理于 (2) 的结论，令 $\boldsymbol{y}=\boldsymbol{0}$，则对于任意的 $\boldsymbol{x}\neq\boldsymbol{0}$，

$$\frac{|f(\boldsymbol{x})-f(\boldsymbol{0})|}{\|\boldsymbol{x}-\boldsymbol{0}\|_2}=\frac{|\|\boldsymbol{x}\|-0|}{\|\boldsymbol{x}\|_2}=\frac{\|\boldsymbol{x}\|}{\|\boldsymbol{x}\|_2},$$

两侧取上界，

$$\|f\|_{\mathrm{Lip}}\geqslant\sup_{\boldsymbol{x}\neq\boldsymbol{0}}\frac{\|\boldsymbol{x}\|}{\|\boldsymbol{x}\|_2}=L_{\min}。$$

如此，$\|f\|_{\mathrm{Lip}}=L_{\min}$。

3 [**指数级微小集合的膨胀**] 设 σ 为定义于 $\sqrt{n}\mathbb{S}^{n-1}$ 的归一化均匀概率测度，对于任意的 $X\subset\sqrt{n}\mathbb{S}^{n-1}$，定义其 r-邻域为 $X_r=\{\boldsymbol{x}\in\sqrt{n}\mathbb{S}^{n-1}:\mathrm{dist}(\boldsymbol{x},X)\leqslant r\}$。设 $A\subset\sqrt{n}\mathbb{S}^{n-1}$，其测度满足

$$\sigma(A)>2\exp(-cs^2)。\qquad(c,s>0)$$

(1) 试证明：A 经过 s-膨胀后，其测度超过半数，即 $\sigma(A_s)>1/2$。

(2) 由此推导：对于任意的 $t\geqslant s$，A 经过 $2t$-膨胀之后，将占据绝大体积，满足

$$\sigma(A_{2t})\geqslant 1-2\exp(-ct^2)。$$

证明 (1) 称以下结论为分离引理。设 $X,Y\subset\sqrt{n}\mathbb{S}^{n-1}$，满足 $\sigma(Y)\geqslant 1/2$。若 $d(X,Y)=\inf_{\boldsymbol{x}\in X,\boldsymbol{y}\in Y}\|\boldsymbol{x}-\boldsymbol{y}\|_2\geqslant r$，则

$$\sigma(X)\leqslant 2\exp(-cr^2)。$$

根据定理 T5.1.5 (球面的等周不等式)，可得 Y 的闭 t-邻域 $Y_t=\{\boldsymbol{z}:d(\boldsymbol{z},Y)\leqslant t\}$ 的测度满足

$$\sigma(Y_t)\geqslant 1-2\exp(-ct^2)。$$

等价地，考虑其补集 $(Y_t)^c=\{\boldsymbol{z}:d(\boldsymbol{z},Y)>t\}$，则

$$\sigma(\{\boldsymbol{z}:d(\boldsymbol{z},Y)>t\})\leqslant 2\exp(-ct^2)。$$

设 $\boldsymbol{x}\in X$，则 $d(\boldsymbol{x},Y)\geqslant r$，即 $d(\boldsymbol{x},Y)>r-\varepsilon$，其中 $\varepsilon\in(0,r)$，因此

$$X\subset\{\boldsymbol{z}:d(\boldsymbol{z},Y)>r-\varepsilon\}。$$

从而

$$\sigma(X)\leqslant\sigma(\{\boldsymbol{z}:d(\boldsymbol{z},Y)>r-\varepsilon\})\leqslant 2\exp(-c(r-\varepsilon)^2),$$

令 $\varepsilon\to 0^+$，可得 $\sigma(X)\leqslant 2\exp(-cr^2)$。

设 $Y=(A_s)^c$，则 $d(A,Y)\geqslant s$。

利用反证法，假设 $\sigma(A_s)\leqslant 1/2$，则其补集的测度满足

$$\sigma(Y)=1-\sigma(A_s)\geqslant\frac{1}{2},$$

因此根据引理，可得 $\sigma(A)\leqslant 2\exp(-cs^2)$，与 $\sigma(A)>2\exp(-cs^2)$ 矛盾；如此，$\sigma(A_s)>1/2$。

(2) 对 A_s 进行半径为 t 的膨胀，则其测度满足

$$\sigma((A_s)_t)\geqslant 1-2\exp(-ct^2)。$$

根据度量的三角不等式，可得 $(A_s)_t\subset A_{s+t}$，注意 $t\geqslant s$，因此 $A_{s+t}\subset A_{2t}$，即

$$(A_s)_t\subset A_{2t},$$

从而

$$\sigma(A_{2t})\geqslant\sigma((A_s)_t)\geqslant 1-2\exp(-ct^2)。$$

4 [**测地度量的测度集中现象**] 关于定理 T5.1.4 ($\mathbb{R}^n$ 的等周不等式) ($\mathbb{R}^n$ 的等周不等式)，我们给出了关于球面依 Euclidean 度量满足 Lipschitz 连续的函数的测度集中不等式。

证明：此集中结论对于依测地度量满足 Lipschitz 连续的函数亦成立。

注释 Euclidean 度量为两点之间的弦长，记为 $\rho(x,y)=\|x-y\|_2$，Geodesic 度量为两点之间的弧长，记为 $d(x,y)=\theta$，其中 $\theta=\arccos(\langle x,y\rangle)$。

证明 设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{S}^{n-1}$，其测地线距离为 $\theta=d(\boldsymbol{x},\boldsymbol{y})\in[0,\pi]$，则

$$\|\boldsymbol{x}-\boldsymbol{y}\|_2^2=\|\boldsymbol{x}\|_2^2+\|\boldsymbol{y}\|_2^2-2\langle\boldsymbol{x},\boldsymbol{y}\rangle=1+1-2\cos\theta=2(1-\cos\theta)=4\sin^2\frac{\theta}{2},$$

两侧开方，

$$\|\boldsymbol{x}-\boldsymbol{y}\|_2=2\sin\frac{\theta}{2}=2\sin\frac{d(\boldsymbol{x},\boldsymbol{y})}{2}\geqslant 2\left(\frac{2}{\pi}\frac{d(\boldsymbol{x},\boldsymbol{y})}{2}\right)=\frac{2d(\boldsymbol{x},\boldsymbol{y})}{\pi},$$

即

$$d(\boldsymbol{x},\boldsymbol{y})\leqslant\frac{\pi}{2}\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

设 $f:\mathbb{S}^{n-1}\to\mathbb{R}$ 关于测地线度量是 L-Lipschitz 的，则对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{S}^{n-1}$，满足

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant L\cdot d(\boldsymbol{x},\boldsymbol{y})\leqslant L\frac{\pi}{2}\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

因此 f 关于 Euclidean 度量是 $L\pi/2$-Lipschitz 的，记 $L'=L\pi/2$，从而根据定理 T5.1.5 (球面的等周不等式)，可得

$$\mathrm{P}\{|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]|\geqslant t\}\leqslant 2\exp\left(-cn\frac{t^2}{(L')^2}\right)。\qquad (c,C>0)$$

5 [**单位球面的测度集中**] 已知定理 T5.1.4 ($\mathbb{R}^n$ 的等周不等式) ($\mathbb{R}^n$ 的等周不等式) 给出了在缩放球面 $\sqrt{n}\mathbb{S}^{n-1}$ 的 Lipschitz 函数的测度集中不等式。

设 $\boldsymbol{X}\sim U(\mathbb{S}^{n-1})$，$f:\mathbb{S}^{n-1}\to\mathbb{R}$ 为 Lipschitz 连续函数。证明：$f(\boldsymbol{X})$ 的波动可以用其 sub-Gaussian 范数界定，

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2}\leqslant\frac{C\|f\|_{\mathrm{Lip}}}{\sqrt{n}},$$

此结论等价于：对于任意的 $t\geqslant 0$，满足以下 Gaussian 型尾部概率界限，

$$\mathrm{P}\{|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]|\geqslant t\}\leqslant 2\exp\left(-\frac{cnt^2}{\|f\|_{\mathrm{Lip}}^2}\right)。$$

证明 (为了利用定理 T5.1.4 ($\mathbb{R}^n$ 的等周不等式) ($\mathbb{R}^n$ 的等周不等式)，之后只需将单位球面 $\mathbb{S}^{n-1}$ 映射于缩放球面 $\sqrt{n}\mathbb{S}^{n-1}$。)

令 $\boldsymbol{Y}=\sqrt{n}\boldsymbol{X}\sim U(\sqrt{n}\mathbb{S}^{n-1})$，构造辅助函数 $g:\sqrt{n}\mathbb{S}^{n-1}\to\mathbb{R}$ 为

$$g(\boldsymbol{y})=f\left(\frac{\boldsymbol{y}}{\sqrt{n}}\right),$$

则

$$g(\boldsymbol{Y})=f\left(\frac{\sqrt{n}\boldsymbol{X}}{\sqrt{n}}\right)=f(\boldsymbol{X})。$$

对于任意的 $\boldsymbol{y}_1,\boldsymbol{y}_2\in\sqrt{n}\mathbb{S}^{n-1}$，

$$\begin{aligned}|g(\boldsymbol{y}_1)-g(\boldsymbol{y}_2)|&=\left|f\left(\frac{\boldsymbol{y}_1}{\sqrt{n}}\right)-f\left(\frac{\boldsymbol{y}_2}{\sqrt{n}}\right)\right|\\&\leqslant\|f\|_{\mathrm{Lip}}\left\|\frac{\boldsymbol{y}_1}{\sqrt{n}}-\frac{\boldsymbol{y}_2}{\sqrt{n}}\right\|_2\\&\leqslant\frac{\|f\|_{\mathrm{Lip}}}{\sqrt{n}}\|\boldsymbol{y}_1-\boldsymbol{y}_2\|_2,\end{aligned}$$

因此根据定理 T5.1.4 ($\mathbb{R}^n$ 的等周不等式) ($\mathbb{R}^n$ 的等周不等式)，可得

$$\|g(\boldsymbol{Y})-\mathrm{E}[g(\boldsymbol{Y})]\|_{\psi_2}\leqslant C_0\|g\|_{\mathrm{Lip}}\leqslant\frac{C_0\|f\|_{\mathrm{Lip}}}{\sqrt{n}},$$

此时令 $C=C_0$。

根据命题 P2.6.1 (sub-Gaussian 性质)，令 $Z = f(\boldsymbol{X}) - \mathrm{E}[f(\boldsymbol{X})]$，可得

$$\mathrm{P}\{|f(\boldsymbol{X}) - \mathrm{E}[f(\boldsymbol{X})]| \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{(C\|f\|_{\mathrm{Lip}}/\sqrt{n})^2}\right) \qquad \left(K = \frac{C\|f\|_{\mathrm{Lip}}}{\sqrt{n}}, c > 0\right)$$

$$= 2\exp\left(-\frac{c'nt^2}{\|f\|_{\mathrm{Lip}}^2}\right)。 \qquad \left(c' = \frac{c}{C}\right)$$

6 [**均值，中位数集中的等价性**] 设 Z 为 sub-Gaussian 随机变量，其中位数为 M。证明：

$$\|Z - M\|_{\psi_2} \asymp \|Z - \mathrm{E}[Z]\|_{\psi_2}。$$

(此结论说明，于集中不等式，我们可以自由地将均值替换为中位数，反之亦然，而不会改变尾部衰减的阶数。)

证明 我们只需证明

$$c\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant \|Z - M\|_{\psi_2} \leqslant C\|Z - \mathrm{E}[Z]\|_{\psi_2}。$$

- 证明左侧不等式 $c\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant \|Z - M\|_{\psi_2}$

  令 $Y = Z - M$，则 $\mathrm{E}[Y] = \mathrm{E}[Z] - M$，根据 ψ_2 范数的定义 (D2.6.4 (sub-Gaussian 分布)) $\mathrm{E}[\exp(a^2/K^2)] \leqslant 2$，可得

  $$\|\mathrm{E}[Y]\|_{\psi_2} = \frac{|\mathrm{E}[Y]|}{\sqrt{\ln 2}}。$$

  考虑

  $$Z - \mathrm{E}[Z] = (Z - M) - (\mathrm{E}[Z] - M) = Y - \mathrm{E}[Y],$$

  两侧取 ψ_2 范数，

  $$\|Z - \mathrm{E}[Z]\|_{\psi_2} = \|Y - \mathrm{E}[Y]\|_{\psi_2} \leqslant \|Y\|_{\psi_2} + \|\mathrm{E}[Y]\|_{\psi_2} \leqslant \|Y\|_{\psi_2} + \frac{1}{\sqrt{\ln 2}}|\mathrm{E}[Y]|,$$

  其中

  $$|\mathrm{E}[Y]| \leqslant \mathrm{E}[|Y|] \leqslant C_1\|Y\|_{\psi_2}, \qquad (C_1 > 0)$$

  因此

  $$\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant \left(1 + \frac{C_1}{\sqrt{\ln 2}}\right)\|Y\|_{\psi_2} = C_2\|Z - M\|_{\psi_2}, \qquad \left(C_2 = 1 + \frac{C_1}{\sqrt{\ln 2}}\right)$$

  即

  $$c\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant \|Z - M\|_{\psi_2}。 \qquad (c = 1/C_2)$$

- 证明右侧不等式 $\|Z - M\|_{\psi_2} \leqslant C\|Z - \mathrm{E}[Z]\|_{\psi_2}$

  (为了证明右侧上界，之后只需控制均值与中位数之间的绝对偏差 $|\mathrm{E}[Z] - M|$。)

  作出以下引理：

  引理 $|\mathrm{E}[Z] - M| \leqslant C_3\|Z - \mathrm{E}[Z]\|_{\psi_2}$。

  令 $X = Z - \mathrm{E}[Z]$，记 $K = \|X\|_{\psi_2}$。若 $K = 0$，则 $\mathrm{E}[Z] = M$，结论是平凡的；之后只需考虑 $K > 0$ 的情况。

  由于 X 为零均值的 K-sub-Gaussian 随机变量，因此对于任意的 $t \geqslant 0$，

  $$\mathrm{P}\{|X| \geqslant t\} \leqslant 2\exp\left(-\frac{c_0t^2}{K^2}\right), \qquad (c_0 > 0)$$

  记 X 的中位数为 $M(X) = M - \mathrm{E}[Z]$，满足

  $$\mathrm{P}\{X \geqslant M(X)\} \geqslant \frac{1}{2},$$

  $$\mathrm{P}\{X \leqslant M(X)\} \geqslant \frac{1}{2},$$

  讨论 $M(X)$ 的符号：

a. 若 $M(X)>0$，则 X 落于右尾，满足

$$\frac{1}{2}\leqslant \mathrm{P}\{X\geqslant M(X)\}\leqslant \mathrm{P}\{|X|\geqslant M(X)\}\leqslant 2\exp\left(-\frac{c_0M(X)^2}{K^2}\right),$$

即

$$\exp\left(\frac{c_0M(X)^2}{K^2}\right)\leqslant 4,$$

$$M(X)^2\leqslant \frac{\ln 4}{c_0}K^2。$$

b. 若 $M(X)<0$，则 X 落于左尾，满足

$$\frac{1}{2}\leqslant \mathrm{P}\{X\leqslant M(X)\}\leqslant \mathrm{P}\{|X|\geqslant |M(X)|\}\leqslant 2\exp\left(-\frac{c_0|M(X)|^2}{K^2}\right),$$

即

$$\exp\left(\frac{c_0M(X)^2}{K^2}\right)\leqslant 4,$$

$$M(X)^2\leqslant \frac{\ln 4}{c_0}K^2。$$

如此，

$$|\mathrm{E}[Z]-M|=|M(X)|\leqslant C_3K=C_3\|Z-\mathrm{E}[Z]\|_{\psi_2}。\qquad (C_3=\sqrt{(\ln 4)/c_0})$$

对 $Z-M$ 进行拆分，

$$\begin{aligned}\|Z-M\|_{\psi_2}&=\|(Z-\mathrm{E}[Z])+(\mathrm{E}[Z]-M)\|_{\psi_2}\\&\leqslant \|Z-\mathrm{E}[Z]\|_{\psi_2}+\|\mathrm{E}[Z]-M\|_{\psi_2}\\&\leqslant \|Z-\mathrm{E}[Z]\|_{\psi_2}+\frac{1}{\sqrt{\ln 2}}|\mathrm{E}[Z]-M|,\end{aligned}$$

根据引理，可得

$$\|Z-M\|_{\psi_2}\leqslant \|Z-\mathrm{E}[Z]\|_{\psi_2}+\frac{C_3}{\sqrt{\ln 2}}\|Z-\mathrm{E}[Z]\|_{\psi_2}=C\|Z-\mathrm{E}[Z]\|_{\psi_2}。\qquad \left(C=1+\frac{C_3}{\sqrt{\ln 2}}\right)$$

7 [**测度集中，体积膨胀的等价性**] 于 5.1.4 节，我们通过引理 L5.1.6 (膨胀) 推导球面的 Lipschitz 浓度不等式。反转上述逻辑，证明 Lipschitz 浓度始终等价于体积膨胀现象。

设 X 为取值于度量空间 $(\mathbb{T},d)$ 的随机变量 (或向量)，使得对于任意的 Lipschitz 连续函数 $f:\mathbb{T}\to\mathbb{R}$，均满足

$$\|f(X)-\mathrm{E}[f(X)]\|_{\psi_2}\leqslant K\|f\|_{\mathrm{Lip}}。\qquad (K>0)$$

对于任意的子集 $A\subset\mathbb{T}$，定义概率测度 $\sigma(A)=\mathrm{P}\{X\in A\}$。证明：若 $\sigma(A)\geqslant 1/2$，则对于任意的 $t\geqslant 0$，均满足

$$\sigma(A_t)\geqslant 1-2\exp\left(-\frac{ct^2}{K^2}\right)。\qquad (c>0)$$

证明 • 确定距离函数的中位数

由于

$$\mathrm{P}\{X\in A\}=\sigma(A)\geqslant\frac{1}{2},$$

因此当 $X\in A$ 时，其同 A 的距离为 0，即 $f(X)=0$，从而

$$\mathrm{P}\{f(X)\leqslant 0\}\geqslant \mathrm{P}\{X\in A\}\geqslant\frac{1}{2};$$

同时，$\mathrm{P}\{f(X)\geqslant 0\}=1\geqslant 1/2$，从而 0 为 $f(X)$ 的中位数。

• 构造距离函数并验证 Lipschitz 性质

定义 $x \in \mathbb{T}$ 到 A 的距离函数为

$$f(x) = d(x, A) = \inf_{y \in A} d(x, y),$$

则对于任意的 $x, z \in \mathbb{T}$，$y \in A$，

$$d(x, y) \leqslant d(x, z) + d(z, y),$$

两侧对的 $y \in A$ 取下确界，

$$\inf_{y \in A} d(x, y) \leqslant d(x, z) + \inf_{y \in A} d(z, y),$$

$$f(x) \leqslant d(x, z) + f(z),$$

$$f(x) - f(z) \leqslant d(x, z);$$

同理，交换 x, z，可得 $f(z) - f(x) \leqslant d(x, z)$，因此 $|f(x) - f(z)| \leqslant d(x, z)$，即 $\|f\|_{\mathrm{Lip}} \leqslant 1$，从而

$$\|f(X) - \mathrm{E}[f(X)]\|_{\psi_2} \leqslant K\|f\|_{\mathrm{Lip}} \leqslant K。$$

根据习题 Q5.6 (均值, 中位数集中的等价性)，可得

$$\|f(X) - M(f(X))\|_{\psi_2} \leqslant C_1\|f(X) - \mathrm{E}[f(X)]\|_{\psi_2} \leqslant C_1 K,$$

即

$$\|f(X)\|_{\psi_2} \leqslant C_1 K,$$

(注意 $M(f(X)) = 0$。) 根据命题 P2.6.1 (sub-Gaussian 性质)，可得对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{f(X) \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{K^2}\right)。$$

若 $X \notin A_t$，则 $f(X) = \inf_{y \in A} d(X, y) \geqslant t$，因此 $\{X \notin A_t\} \subset \{f(X) \geqslant t\}$，从而

$$\sigma((A_t)^c) = \mathrm{P}\{X \notin A_t\} \leqslant \mathrm{P}\{f(X) \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{K^2}\right),$$

两侧取补集，

$$\sigma(A_t) = 1 - \sigma((A_t)^c) \geqslant 1 - 2\exp\left(-\frac{ct^2}{K^2}\right)。$$

8 [**Gaussian 测度集中定理的证明**] 定理 T5.2.2 (Gaussian 等周不等式) 指出：于 Gaussian 测度均为 $\gamma_n(A)$ 的子集，半空间的 t-邻域的 Gaussian 测度 $\gamma_n(A_t)$ 是最小的。

利用上述定理，证明定理 T5.2.3 (Gaussian 集中)：设 $\boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，函数 $f : \mathbb{R}^n \to \mathbb{R}$ 是依 Euclidean 度量 Lipschitz 连续的，则

$$\|f(\boldsymbol{X}) - \mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2} \leqslant C\|f\|_{\mathrm{Lip}}。 \qquad (C > 0)$$

证明 (考虑由等周不等式经邻域膨胀, 中位数集中至均值集中的标准推导链条。)

- 建立 Gaussian 测度的膨胀引理

  设 γ_n 为 $\mathbb{R}^n$ 的标准 Gaussian 测度，即 $\gamma_n(A) = \mathrm{P}\{\boldsymbol{X} \in A\}$，其中 $\boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，$A \subset \mathbb{R}^n$ 为可测集，满足 $\gamma_n(A) \geqslant 1/2$。令标准半空间 $H = \{\boldsymbol{x} \in \mathbb{R}^n : x_1 \leqslant 0\}$，则 $\gamma_n(H) = 1/2 \leqslant \gamma_n(A)$，因此根据定理 T5.2.2 (Gaussian 等周不等式)，可得对于任意的 $t > 0$，

  $$\gamma_n(A_t) \geqslant \gamma_n(H_t),$$

  其中 $H_t = \{\boldsymbol{x} \in \mathbb{R}^n : x_1 \leqslant t\}$。

  由于

  $$\gamma_n((H_t)^c) = \frac{1}{\sqrt{2\pi}} \int_t^\infty \mathrm{e}^{-x^2/2}\mathrm{d}x \leqslant \frac{1}{2}\mathrm{e}^{-t^2/2} \leqslant \mathrm{e}^{-t^2/2},$$

因此

$$\gamma_n((A_t)^c) \leqslant 1-\gamma_n(H_t) = \gamma_n((H_t)^c) \leqslant \mathrm{e}^{-t^2/2}。 \tag{I}$$

- 基于 Lipschitz 连续性构造水平集的包含关系

设 $L=\|f\|_{\mathrm{Lip}}$，M 为 $f(\boldsymbol{X})$ 的中位数，定义下水平集 $A=\{\boldsymbol{x}\in\mathbb{R}^n : f(\boldsymbol{x})\leqslant M\}$，则 $\gamma_n(A)\geqslant 1/2$。

根据 t-邻域的定义 $A_t=\{\boldsymbol{x}\in\mathbb{R}^n : \mathrm{dist}(\boldsymbol{x},A)\leqslant t\}$，对于任意的 $\boldsymbol{x}\in A_t$，任意的 $\eta>0$，存在 $\boldsymbol{y}\in A$，使得 $\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant t+\eta$，因此

$$f(\boldsymbol{x}) = f(\boldsymbol{y}) + (f(\boldsymbol{x})-f(\boldsymbol{y})) \leqslant f(\boldsymbol{y}) + L\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant M + L(t+\eta)。$$

令 $\eta\downarrow 0$，从而

$$A_t \subset \{\boldsymbol{x}\in\mathbb{R}^n : f(\boldsymbol{x})\leqslant M+Lt\},$$

即

$$\{\boldsymbol{x}\in\mathbb{R}^n : f(\boldsymbol{x}) > M+Lt\} \subset (A_t)^c。 \tag{II}$$

- 推导关于中位数的 sub-Gaussian 尾部界限

对 (II) 的两侧取 Gaussian 测度，利用 (I) 的界限，可得

$$\mathrm{P}\{f(\boldsymbol{X})-M>Lt\} = \gamma_n(\{\boldsymbol{x}\in\mathbb{R}^n : f(\boldsymbol{x})>M+Lt\}) \leqslant \gamma_n((A_t)^c) \leqslant \mathrm{e}^{-t^2/2}。$$

同理，定义上水平集 $B=\{\boldsymbol{x}\in\mathbb{R}^n : f(\boldsymbol{x})\geqslant M\}$，满足 $\gamma_n(B)\geqslant 1/2$，则

$$\mathrm{P}\{f(\boldsymbol{X})-M<-Lt\} \leqslant \mathrm{e}^{-t^2/2}。$$

利用并集界，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|f(\boldsymbol{X})-M|\geqslant Lt\} \leqslant \mathrm{P}\{f(\boldsymbol{X})-M\geqslant Lt\} + \mathrm{P}\{f(\boldsymbol{X})-M\leqslant -Lt\} \leqslant 2\mathrm{e}^{-t^2/2},$$

即

$$\mathrm{P}\{|f(\boldsymbol{X})-M|\geqslant u\} \leqslant 2\exp\left(-\frac{u^2}{2L^2}\right)。 \qquad (u=Lt)$$

根据命题 P2.6.1 (sub-Gaussian 性质)，可得

$$\|f(\boldsymbol{X})-M\|_{\psi_2} \leqslant C_1 L = C_1\|f\|_{\mathrm{Lip}}。 \qquad (C_1>0)$$

- 将中位数界限转换为期望界限

根据习题 Q5.6 (均值, 中位数集中的等价性)，可得

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2} \leqslant C_2\|f(\boldsymbol{X})-M\|_{\psi_2}, \qquad (C_2>0)$$

因此

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2} \leqslant C\|f\|_{\mathrm{Lip}}。 \qquad (C=C_1C_2)$$

9 [**最大值的测度集中**] 于命题 P2.7.6 (sub-Gaussian 随机变量的最大值)，我们估计了 n 个 sub-Gaussian 随机变量最大值的期望。

现在，我们证明最大值高度集中于其期望附近。

(1) 设 $X_1,\cdots,X_n$ i.i.d. $\sim N(0,1)$。证明：

$$\left\|\max_{1\leqslant i\leqslant n} X_i - \mathrm{E}\left[\max_{1\leqslant i\leqslant n} X_i\right]\right\|_{\psi_2} \leqslant C。 \qquad (C>0)$$

(2) 更一般地，设 $X_1,\cdots,X_n$ 为联合正态分布的随机变量 (不要求相互独立)。证明：

$$\left\|\max_{1\leqslant i\leqslant n} X_i - \mathrm{E}\left[\max_{1\leqslant i\leqslant n} X_i\right]\right\|_{\psi_2} \leqslant C\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)}。$$

证明 (1) 设 $\boldsymbol{X}=(X_1,\cdots,X_n)^\top\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，定义 $f:\mathbb{R}^n\to\mathbb{R}$ 为向量各分量的最大值，

$$f(\boldsymbol{x}) = \max_{1\leqslant i\leqslant n} x_i。$$

则 f 是 Lipschitz 连续的，满足 $\|f\|_{\mathrm{Lip}}\leqslant 1$。

(具体证明过程：对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$，设 $f(\boldsymbol{x})$ 于下标 k 取得最大值，即 $f(\boldsymbol{x})=x_k$，则

$$f(\boldsymbol{x})-f(\boldsymbol{y})=x_k-\max_{1\leqslant i\leqslant n}y_i\leqslant x_k-y_k,$$

其中

$$x_k-y_k\leqslant|x_k-y_k|\leqslant\sqrt{\sum_{i=1}^n(x_i-y_i)^2}=\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

因此 $f(\boldsymbol{x})-f(\boldsymbol{y})\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_2$；根据对称性，可得 $f(\boldsymbol{y})-f(\boldsymbol{x})\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_2$，从而

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_2。)$$

根据定理 T5.2.3 (Gaussian 集中)，可得对于 $\boldsymbol{X}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2}\leqslant C\|f\|_{\mathrm{Lip}}\leqslant C,$$

即

$$\left\|\max_{1\leqslant i\leqslant n}X_i-\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\right\|_{\psi_2}\leqslant C。$$

(2) 设 $\boldsymbol{X}=(X_1,\cdots,X_n)^\top\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，则存在 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，满足 $\boldsymbol{A}\boldsymbol{A}^\top=\boldsymbol{\Sigma}$，使得

$$\boldsymbol{X}=\boldsymbol{A}\boldsymbol{g}+\boldsymbol{\mu},$$

其中 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，即

$$X_i=\boldsymbol{a}_i^\top\boldsymbol{g}+\mu_i,$$

其中 $\boldsymbol{a}_i^\top$ 为 $\boldsymbol{A}$ 的第 i 行。

注意到

$$\mathrm{Var}(X_i)=\mathrm{Var}(\boldsymbol{a}_i^\top\boldsymbol{g})=\|\boldsymbol{a}_i\|_2^2,$$

定义 $h:\mathbb{R}^n\to\mathbb{R}$ 为

$$h(\boldsymbol{g})=\max_{1\leqslant i\leqslant n}(\boldsymbol{a}_i^\top\boldsymbol{g}+\mu_i),$$

则 $\max_i X_i=h(\boldsymbol{g})$。

对于任意的 $\boldsymbol{g}_1,\boldsymbol{g}_2\in\mathbb{R}^n$，设 $h(\boldsymbol{g}_1)$ 于下标 k 取得最大值，则

$$\begin{aligned}h(\boldsymbol{g}_1)-h(\boldsymbol{g}_2)&=(\boldsymbol{a}_k^\top\boldsymbol{g}_1+\mu_k)-\max_{1\leqslant j\leqslant n}(\boldsymbol{a}_j^\top\boldsymbol{g}_2+\mu_j)\\&\leqslant(\boldsymbol{a}_k^\top\boldsymbol{g}_1+\mu_k)-(\boldsymbol{a}_k^\top\boldsymbol{g}_2+\mu_k)\\&=\boldsymbol{a}_k^\top(\boldsymbol{g}_1-\boldsymbol{g}_2)\\&\leqslant\|\boldsymbol{a}_k\|_2\|\boldsymbol{g}_1-\boldsymbol{g}_2\|_2,\end{aligned}$$

其中

$$\|\boldsymbol{a}_k\|_2=\sqrt{\mathrm{Var}(X_k)}\leqslant\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)},$$

因此

$$h(\boldsymbol{g}_1)-h(\boldsymbol{g}_2)\leqslant\left(\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)}\right)\|\boldsymbol{g}_1-\boldsymbol{g}_2\|_2,$$

从而根据对称性，可得 h 是 Lipschitz 连续的，满足

$$\|h\|_{\mathrm{Lip}}\leqslant\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)}。$$

根据定理 T5.2.3 (Gaussian 集中)，可得

$$\|h(\boldsymbol{g})-\mathrm{E}[h(\boldsymbol{g})]\|_{\psi_2}\leqslant C\|h\|_{\mathrm{Lip}}\leqslant C\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)},\qquad(C>0)$$

即

$$\left\|\max_{1\leqslant i\leqslant n}X_i-\mathrm{E}\left[\max_{1\leqslant i\leqslant n}X_i\right]\right\|_{\psi_2}\leqslant C\max_{1\leqslant i\leqslant n}\sqrt{\mathrm{Var}(X_i)}。$$

10 [**关于 L^p 范数的测度集中**] 于习题 Q5.6 (均值, 中位数集中的等价性)，我们证明了于集中不等式，均值, 中位数是可以等价替换的。

现在我们证明 L^p 范数也满足类似的替换性质。

设 Z 满足 $\mu = \mathrm{E}[Z] \geqslant 0$。证明：对于任意的 $p \geqslant 1$，

$$\|Z - \|Z\|_{L^p}\|_{\psi_2} \leqslant C\sqrt{p}\|Z - \mathrm{E}[Z]\|_{\psi_2}。$$

证明 设 $X = Z - \mu$，则 X 为零均值的 sub-Gaussian 随机变量。记 $K = \|X\|_{\psi_2}$，若 $K = 0$，则 Z 几乎处处为非负常数；不等式的两侧均为 0，结论是平凡的；之后只需考虑 $K > 0$ 的情况。

利用三角不等式，可得

$$\begin{aligned}\|Z - \|Z\|_{L^p}\|_{\psi_2} &= \|(Z-\mu) + (\mu - \|Z\|_{L^p})\|_{\psi_2} \\ &\leqslant \|Z-\mu\|_{\psi_2} + \|\mu - \|Z\|_{L^p}\|_{\psi_2} \\ &\leqslant K + \frac{1}{\sqrt{\ln 2}}|\mu - \|Z\|_{L^p}|,\end{aligned}$$

之后只需估计 $|\mu - \|Z\|_{L^p}|$ 即可。

对于下界，注意到当 $p \geqslant 1$ 时，函数 $x \mapsto |x|^p$ 为凸函数，因此利用 Jensen 不等式，可得

$$\|Z\|_{L^p} = (\mathrm{E}[|Z|^p])^{1/p} \geqslant |\mathrm{E}[Z]| = |\mu| = \mu,$$

对于上界，利用 Minkowski 不等式，可得

$$\|Z\|_{L^p} = \|\mu + X\|_{L^p} \leqslant \|\mu\|_{L^p} + \|X\|_{L^p} = \mu + \|X\|_{L^p}。$$

如此，

$$|\|Z\|_{L^p} - \mu| \leqslant \|X\|_{L^p}。$$

根据命题 P2.6.1 (sub-Gaussian 性质)，可得

$$\|X\|_{L^p} = (\mathrm{E}[|X|^p])^{1/p} \leqslant C_1 K\sqrt{p},$$

即

$$|\mu - \|Z\|_{L^p}| \leqslant C_1 K\sqrt{p},$$

因此

$$\|Z - \|Z\|_{L^p}\|_{\psi_2} \leqslant K + \frac{C_1 K\sqrt{p}}{\sqrt{\ln 2}} \leqslant C\sqrt{p}\|Z - \mathrm{E}[Z]\|_{\psi_2}。 \qquad \left(C = 1 + \frac{C_1}{\sqrt{\ln 2}}\right)$$

11 [**测度前推：从 Gaussian 分布到均匀分布**] 设 $\Phi(x)$ 为 $N(0,1)$ 的累积分布函数。考虑 n 维标准正态随机向量 $\boldsymbol{Z} = (Z_1, \cdots, Z_n)^\top \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。证明：经过前推映射 $\varphi(\boldsymbol{Z}) = (\Phi(Z_1), \cdots, \Phi(Z_n))^\top$ 之后，此随机向量服从 $U([0,1]^n)$，即

$$\varphi(\boldsymbol{Z}) \sim U([0,1]^n)。$$

证明 由于 $\Phi \in C(\mathbb{R})$ 严格单调递增，并且值域为 $(0,1)$，因此其反函数 $\Phi^{-1} : (0,1) \to \mathbb{R}$ 良定义。对 $u \in (0,1)$，设 $U_i = \Phi(Z_i)$，其中 $Z_i \sim N(0,1)$，则

$$F_{U_i}(u) = \mathrm{P}\{U_i \leqslant u\} = \mathrm{P}\{\Phi(Z_i) \leqslant u\} = \mathrm{P}\{Z_i \leqslant \Phi^{-1}(u)\} = \Phi(\Phi^{-1}(u)) = u,$$

因此 $U_i \sim U(0,1)$。

对于 $\boldsymbol{U} = \varphi(\boldsymbol{Z}) = (U_1, \cdots, U_n)^\top$，由于 $Z_1, \cdots, Z_n$ 是相互独立的，因此 $U_1, \cdots, U_n$ 是相互独立的，从而

$$F_{\boldsymbol{U}}(\boldsymbol{u}) = \prod_{i=1}^n F_{U_i}(u_i) = \prod_{i=1}^n u_i,$$

即 $\varphi(\boldsymbol{Z}) \sim U([0,1]^n)$。

12 [**连续超立方体的测度集中**] 设 $\boldsymbol{X} \sim U([0,1]^n)$。定理 T5.2.10 (连续立方体, 球的集中) 指出：对于任意的 Lipschitz 连续的函数 $f : [0,1]^n \to \mathbb{R}$，随机变量 $f(\boldsymbol{X})$ 满足 sub-Gaussian 集中性质。按照以下步骤证明上述定理：

(1) 利用练习 Q5.11 (测度前推：从 Gaussian 分布到均匀分布) 将 $\boldsymbol{X}$ 表示为 $\boldsymbol{X} = \varphi(\boldsymbol{Z})$。之后，利用定理 T5.2.3 (Gaussian 集中) (Gaussian 集中)，以 $\|f\|_{\mathrm{Lip}}\|\varphi\|_{\mathrm{Lip}}$ 为界控制 $f(\varphi(\boldsymbol{Z}))$ 的偏差。

(2) 证明 $\|\varphi\|_{\mathrm{Lip}}$ 以常数有界，然后完成定理的证明。

证明 • 构造前推映射 φ

令 $\boldsymbol{Z}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，定义 $\varphi:\mathbb{R}^n\to[0,1]^n$ 为

$$\varphi(\boldsymbol{z})=(\Phi(z_1),\Phi(z_2),\cdots,\Phi(z_n))^{\top},$$

根据习题 Q5.11 (测度前推：从 Gaussian 分布到均匀分布)，可得 $\varphi(\boldsymbol{Z})\sim U([0,1]^n)$，因此 $f(\boldsymbol{X})\overset{d}{=}f(\varphi(\boldsymbol{Z}))$。(之后只需考虑 $g(\boldsymbol{Z})=f(\varphi(\boldsymbol{Z}))$ 的集中性质。)

设 $g=f\circ\varphi:\mathbb{R}^n\to\mathbb{R}$，则 g 是 Lipschitz 连续的，满足 $\|g\|_{\mathrm{Lip}}\leqslant\|f\|_{\mathrm{Lip}}\|\varphi\|_{\mathrm{Lip}}$，

(详细证明过程：对于任意的 $\boldsymbol{z}_1,\boldsymbol{z}_2\in\mathbb{R}^n$，

$$\begin{aligned}|g(\boldsymbol{z}_1)-g(\boldsymbol{z}_2)|&=|f(\varphi(\boldsymbol{z}_1))-f(\varphi(\boldsymbol{z}_2))|\\&\leqslant\|f\|_{\mathrm{Lip}}\|\varphi(\boldsymbol{z}_1)-\varphi(\boldsymbol{z}_2)\|_2\\&\leqslant\|f\|_{\mathrm{Lip}}\|\varphi\|_{\mathrm{Lip}}\|\boldsymbol{z}_1-\boldsymbol{z}_2\|_2。\end{aligned}$$

) 因此利用定理 T5.2.3 (Gaussian 集中)，可得

$$\|g(\boldsymbol{Z})-\mathrm{E}[g(\boldsymbol{Z})]\|_{\psi_2}\leqslant c_1\|g\|_{\mathrm{Lip}},\qquad(c_1>0)$$

即

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2}\leqslant c_1\|f\|_{\mathrm{Lip}}\|\varphi\|_{\mathrm{Lip}}。$$

• 界定映射 φ 的 Lipschitz 常数

对于

$$\Phi'(x)=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2},$$

其最大值为

$$\sup_{x\in\mathbb{R}}|\Phi'(x)|=\frac{1}{\sqrt{2\pi}},$$

对于任意的 $x,y\in\mathbb{R}$，根据 Lagrange 中值定理，可得

$$|\Phi(x)-\Phi(y)|\leqslant\frac{1}{\sqrt{2\pi}}|x-y|,$$

从而 Φ 是 Lipschitz 连续的，满足 $\|\Phi\|_{\mathrm{Lip}}=1/\sqrt{2\pi}$。

对于任意的 $\boldsymbol{z}_1,\boldsymbol{z}_2\in\mathbb{R}^n$，

$$\begin{aligned}\|\varphi(\boldsymbol{z}_1)-\varphi(\boldsymbol{z}_2)\|_2^2&=\sum_{i=1}^n(\Phi(z_{1i})-\Phi(z_{2i}))^2\\&\leqslant\sum_{i=1}^n\left(\frac{1}{\sqrt{2\pi}}|z_{1i}-z_{2i}|\right)^2\\&=\frac{1}{2\pi}\sum_{i=1}^n(z_{1i}-z_{2i})^2\\&=\frac{1}{2\pi}\|\boldsymbol{z}_1-\boldsymbol{z}_2\|_2^2,\end{aligned}$$

两侧开方，

$$\|\varphi(\boldsymbol{z}_1)-\varphi(\boldsymbol{z}_2)\|_2\leqslant\frac{1}{\sqrt{2\pi}}\|\boldsymbol{z}_1-\boldsymbol{z}_2\|_2,$$

因此 $\|\varphi\|_{\mathrm{Lip}}\leqslant1/\sqrt{2\pi}$，此时

$$\|f(\boldsymbol{X})-\mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2}\leqslant c_1\cdot\frac{1}{\sqrt{2\pi}}\|f\|_{\mathrm{Lip}}=C\|f\|_{\mathrm{Lip}}。\qquad\left(C=\frac{c_1}{\sqrt{2\pi}}\right)$$

13 [**连续实心球的测度集中**] 定理 T5.2.10 (连续立方体, 球的集中) 指出：若 $\boldsymbol{X}\sim U(\mathbb{B}_2^n)$，$f:\mathbb{B}_2^n\to\mathbb{R}$ 为 Lipschitz 连续函数，

则 $f(\boldsymbol{X})$ 满足 sub-Gaussian 集中性质，其 sub-Gaussian 范数受到 $C\|f\|_{\mathrm{Lip}}/\sqrt{n}$ 的界定。

通过同理于练习 Q5.12 (连续超立方体的测度集中) 的策略，按照以下步骤证明上述定理：

(1) 定义 $\varphi:\mathbb{R}^n\to\mathbb{B}_2^n$，它将 $\mathbb{R}^n$ 的 Gaussian 测度前推为 $\mathbb{B}_2^n$ 的均匀测度。

(2) 验证 φ 的 Lipschitz 范数有界，然后完成定理的证明。

证明 • 利用 Gaussian 集中不等式控制复合函数偏差

将 $\boldsymbol{Z}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$ 分解为 $\boldsymbol{Z}=r\boldsymbol{U}$，其中 $\boldsymbol{U}=\bar{\boldsymbol{Z}}\sim U(\mathbb{S}^{n-1})$，$r=\|\boldsymbol{Z}\|_2$，$r^2\sim\chi^2(n)$，则 $\boldsymbol{U},r$ 相互独立。

同理，将 $\boldsymbol{Y}\sim U(\sqrt{n}\mathbb{B}_2^n)$ 分解为 $\boldsymbol{Y}=\rho\boldsymbol{V}$，其中 $\boldsymbol{V}\sim U(\mathbb{S}^{n-1})$，$\rho\in[0,\sqrt{n}]$ 的密度正比于体积元 ρ^{n-1}，满足

$$F_Y(\rho)=\left(\frac{\rho}{\sqrt{n}}\right)^n,\qquad(\rho\in[0,\sqrt{n}])$$

则 $\boldsymbol{V},\rho$ 是相互独立的。

为了将 $\boldsymbol{Z}$ 映射为 $\boldsymbol{Y}$，令 $\boldsymbol{V}=\boldsymbol{U}$ (保持方向不变)，仅对径向长度施加单调映射 $\rho=g(r)$，满足 $F_Y(\rho)=F_{\chi_n}(r)$，解得

$$\left(\frac{g(r)}{\sqrt{n}}\right)^n=F_{\chi_n}(r),$$

$$g(r)=\sqrt{n}[F_{\chi_n}(r)]^{1/n},$$

因此构造前推映射 $\varphi:\mathbb{R}^n\to\sqrt{n}\mathbb{B}_2^n$ 为

$$\varphi(\boldsymbol{z})=g(\|\boldsymbol{z}\|_2)\frac{\boldsymbol{z}}{\|\boldsymbol{z}\|_2},$$

(当 $\boldsymbol{z}=\boldsymbol{0}$ 时，约定 $\varphi(\boldsymbol{0})=\boldsymbol{0}$) 满足 $\varphi(\boldsymbol{Z})\sim U(\sqrt{n}\mathbb{B}_2^n)$。

• 验证 Lipschitz 性质径向映射的 Lipschitz 常数判定准则

对于径向映射 $\varphi(\boldsymbol{z})$，其 Jacobian 矩阵是对称的，含有两个本征空间，其径向方向的特征值为 $g'(r)$，切向方向的特征值为 $g(r)/r$。

注意到全空间为凸集，因此 φ 的 Lipschitz 范数等于 Jacobian 矩阵算子范数的上确界，

$$\|\varphi\|_{\mathrm{Lip}}=\sup_{r>0}\max\left(g'(r),\frac{g(r)}{r}\right),$$

之后只需证明 $g'(r),g(r)/r$ 均被某个绝对常数 C_0 所界定。界定切向拉伸。

对于 $f_{\chi_n}(t)=c_nt^{n-1}\mathrm{e}^{-t^2/2}$，其中 $c_n=[2^{n/2-1}\Gamma(n/2)]^{-1}$，其累积分布函数为

$$F_{\chi_n}(r)=c_n\int_0^r t^{n-1}\mathrm{e}^{-t^2/2}\mathrm{d}t=c_nr^n\int_0^1 x^{n-1}\mathrm{e}^{-\frac{r^2x^2}{2}}\mathrm{d}x,\qquad(t=rx)$$

将其代入，可得

$$g(r)=\sqrt{n}\left[c_nr^n\int_0^1 x^{n-1}\mathrm{e}^{-\frac{r^2x^2}{2}}\mathrm{d}x\right]^{1/n}=\sqrt{n}c_n^{1/n}r\left[\int_0^1 x^{n-1}\mathrm{e}^{-\frac{r^2x^2}{2}}\mathrm{d}x\right]^{1/n},$$

可得切向比值为

$$\frac{g(r)}{r}=\sqrt{n}c_n^{1/n}\left[\int_0^1 x^{n-1}\mathrm{e}^{-\frac{r^2x^2}{2}}\mathrm{d}x\right]^{1/n},$$

其中

$$\int_0^1 x^{n-1}\mathrm{e}^{-\frac{r^2x^2}{2}}\mathrm{d}x\leqslant\int_0^1 x^{n-1}\mathrm{d}x=\frac{1}{n},$$

利用 Stirling 公式，可得

$$c_n^{1/n}\leqslant\frac{C_1}{\sqrt{n}},\qquad(C_1>0)$$

从而

$$\frac{g(r)}{r} \leqslant \sqrt{n} \cdot \frac{C_1}{\sqrt{n}} \cdot \left(\frac{1}{n}\right)^{1/n} \leqslant C_1。$$

界定径向拉伸。

对 $g(r) = \sqrt{n}[F_{\chi_n}(r)]^{1/n}$ 求导，

$$g'(r) = \sqrt{n} \cdot \frac{1}{n}[F_{\chi_n}(r)]^{\frac{1}{n}-1} f_{\chi_n}(r) = \frac{g(r)}{n} \frac{f_{\chi_n}(r)}{F_{\chi_n}(r)},$$

其中

$$\frac{f_{\chi_n}(r)}{F_{\chi_n}(r)} = \frac{c_n r^{n-1} \mathrm{e}^{-r^2/2}}{c_n r^n \int_0^1 x^{n-1} \mathrm{e}^{-\frac{r^2x^2}{2}} \mathrm{d}x} = \frac{\mathrm{e}^{-r^2/2}}{r \int_0^1 x^{n-1} \mathrm{e}^{-\frac{r^2x^2}{2}} \mathrm{d}x},$$

将其代入，可得

$$g'(r) = \frac{g(r)}{r} \cdot \frac{\mathrm{e}^{-r^2/2}}{n \int_0^1 x^{n-1} \mathrm{e}^{-\frac{r^2x^2}{2}} \mathrm{d}x},$$

其中

$$n \int_0^1 x^{n-1} \mathrm{e}^{-\frac{r^2x^2}{2}} \mathrm{d}x \geqslant \mathrm{e}^{-r^2/2} \int_0^1 \mathrm{d}(x^n) = \mathrm{e}^{-r^2/2},$$

从而

$$g'(r) \leqslant \frac{g(r)}{r} \leqslant C_1。$$

如此，φ 是 Lipschitz 连续的，满足 $\|\varphi\|_{\mathrm{Lip}} \leqslant C_1$。

- 证明定理 T5.2.10 (连续立方体, 球的集中)

回到目标空间单位球 $\mathbb{T} = \mathbb{B}_2^n$。

对于 φ，可得

$$\frac{\varphi(\boldsymbol{Z})}{\sqrt{n}} \sim U(\mathbb{B}_2^n)。$$

令 $\boldsymbol{X} = \varphi(\boldsymbol{Z})/\sqrt{n}$，考虑复合函数 $h(\boldsymbol{z}) = f(\boldsymbol{X}) = f(\varphi(\boldsymbol{z})/\sqrt{n})$，则

$$\|h\|_{\mathrm{Lip}} \leqslant \|f\|_{\mathrm{Lip}} \cdot \frac{1}{\sqrt{n}} \cdot \|\varphi\|_{\mathrm{Lip}} \leqslant \frac{C_1}{\sqrt{n}} \|f\|_{\mathrm{Lip}},$$

因此利用定理 T5.2.3 (Gaussian 集中)，可得

$$\|f(\boldsymbol{X}) - \mathrm{E}[f(\boldsymbol{X})]\|_{\psi_2} = \|h(\boldsymbol{Z}) - \mathrm{E}[h(\boldsymbol{Z})]\|_{\psi_2} \leqslant C_2 \|h\|_{\mathrm{Lip}} \leqslant \frac{C_1 C_2}{\sqrt{n}} \|f\|_{\mathrm{Lip}}, \qquad (C_2 > 0)$$

此时令 $C = C_1 C_2$。

14 [**sub-Gaussian 矩阵的 Johnson-Lindenstrauss 引理**] 设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$，其行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m$ 是相互独立的零均值, 各向同性的随机向量，满足 $\max_i \|\boldsymbol{A}_i\|_{\psi_2} \leqslant K$。定义缩放之后的投影矩阵为 $\boldsymbol{Q} = \boldsymbol{A}/\sqrt{m}$。

(1) 证明定理 T5.3.1 (Johnson–Lindenstrauss 引理) 对于 $\boldsymbol{Q}$ 依然成立。

设 $\mathcal{X} \subset \mathbb{R}^n$ 为任意的 N 点集，误差容忍度 $\varepsilon \in (0,1)$。投影维度满足 $m \geqslant C\varepsilon^{-2} \ln N$ 时，映射 $\boldsymbol{Q}$ 能实现近似等距嵌入，$\mathcal{X}$ 的任意的两点的 Euclidean 距离保持，即对于任意的 $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$，

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_2 \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \text{ (w.h.p.)}。$$

(2) (二值 JL 投影, Binary Johnson-Lindenstrauss) 设 $\boldsymbol{A}$ 的各元素均为独立同分布的 Rademacher 随机变量，证明 (1) 的一般性结论依然成立。此外，简要探讨采用二值随机矩阵进行降维的实际应用价值。

证明 (1) 对于任意的点对 $\boldsymbol{x},\boldsymbol{y}\in\mathcal{X}$，设 $\overline{\boldsymbol{x}-\boldsymbol{y}}\in\mathbb{S}^{n-1}$，则

$$\|\boldsymbol{Q}\overline{\boldsymbol{x}-\boldsymbol{y}}\|_2^2=\frac{1}{m}\|\boldsymbol{A}\overline{\boldsymbol{x}-\boldsymbol{y}}\|_2^2=\frac{1}{m}\sum_{i=1}^{m}\langle\boldsymbol{A}_i,\overline{\boldsymbol{x}-\boldsymbol{y}}\rangle^2,$$

其中 $Z_i=\langle\boldsymbol{A}_i,\overline{\boldsymbol{x}-\boldsymbol{y}}\rangle$ 满足：

1. 独立性：由于 $\boldsymbol{A}_i$ 是相互独立的，因此 $Z_1,\cdots,Z_m$ 是相互独立的。
2. 单位方差：由于 $\boldsymbol{A}_i$ 是各向同性的，因此 $\mathrm{E}[Z_i^2]=\mathrm{E}[\overline{\boldsymbol{x}-\boldsymbol{y}}^\top\boldsymbol{A}_i\boldsymbol{A}_i^\top\overline{\boldsymbol{x}-\boldsymbol{y}}]=\overline{\boldsymbol{x}-\boldsymbol{y}}^\top\mathrm{E}[\boldsymbol{A}_i\boldsymbol{A}_i^\top]\overline{\boldsymbol{x}-\boldsymbol{y}}=\overline{\boldsymbol{x}-\boldsymbol{y}}^\top\boldsymbol{I}_n\overline{\boldsymbol{x}-\boldsymbol{y}}=\|\overline{\boldsymbol{x}-\boldsymbol{y}}\|_2^2=1$。
3. sub-Gaussian 性：$\|Z_i\|_{\psi_2}=\|\langle\boldsymbol{A}_i,\overline{\boldsymbol{x}-\boldsymbol{y}}\rangle\|_{\psi_2}\leqslant\|\boldsymbol{A}_i\|_{\psi_2}\leqslant K$。

因此 Z_i^2-1 是相互独立的零均值 sub-Exponential 随机变量，满足 $\|Z_i^2-1\|_{\psi_1}\leqslant C_1K^2$。

利用命题 P2.8.1 (sub-Exponential 性质)，可得

$$\mathrm{P}\left\{\left|\frac{1}{m}\sum_{i=1}^{m}(Z_i^2-1)\right|\geqslant\varepsilon\right\}\leqslant 2\exp\left(-c_2m\min\left(\frac{\varepsilon^2}{K^4},\frac{\varepsilon}{K^2}\right)\right),$$

即

$$\mathrm{P}\{|\|\boldsymbol{Q}\overline{\boldsymbol{x}-\boldsymbol{y}}\|_2^2-1|\geqslant\varepsilon\}\leqslant 2\exp\left(-\frac{c_3\varepsilon^2m}{K^4}\right),$$

两侧对 $\binom{N}{2}<N^2$ 个点对取并集界，

$$N^2\cdot 2\exp\left(-\frac{c_3\varepsilon^2m}{K^4}\right)\leqslant 2\exp\left(2\ln N-\frac{c_3\varepsilon^2m}{K^4}\right),$$

为了使得上述失败概率极小，令

$$\frac{c_3\varepsilon^2m}{K^4}\geqslant C_0\ln N,$$

$$m\geqslant C\frac{K^4}{\varepsilon^2}\ln N。$$

此时映射 $\boldsymbol{Q}$ 成功等距嵌入的概率趋近于 1。

(2) 设 A_{ij} i.i.d. $\sim$ Rademacher，则

1. 均值为零：由于 $\mathrm{E}[A_{ij}]=0$，因此 $\mathrm{E}[\boldsymbol{A}_i]=\boldsymbol{0}$。
2. 各向同性：若 $j=l$，则 $\mathrm{E}[A_{ij}^2]=1$；若 $j\neq l$，则 $\mathrm{E}[A_{ij}A_{il}]=\mathrm{E}[A_{ij}]\mathrm{E}[A_{il}]=0$，因此 $\mathrm{E}[\boldsymbol{A}_i\boldsymbol{A}_i^\top]=\boldsymbol{I}_n$。
3. sub-Gaussian 性：对于任意的 $\boldsymbol{v}\in\mathbb{S}^{n-1}$，$\langle\boldsymbol{A}_i,\boldsymbol{v}\rangle=\sum_{j=1}^{n}A_{ij}v_j$ 为独立有界变量的线性组合，因此根据 Hoeffding 引理，可得 $\|\boldsymbol{A}_i\|_{\psi_2}\leqslant K'$。

因此 (1) 的条件成立，结论依然成立。

对于高维数据的算法 (如数据库近似搜索, 大规模机器学习降维)，利用标准 Gaussian 矩阵 $\boldsymbol{G}$ 进行降维需要计算密集的浮点数乘法 $\boldsymbol{G}\boldsymbol{x}$，于硬件非常耗时。

若利用二值 JL 矩阵，投影操作 $\frac{1}{\sqrt{m}}\boldsymbol{A}\boldsymbol{x}$ 完全不需要乘法运算，只包含加法, 减法。二值 JL 矩阵使得降维算法不仅于存储实现了极度压缩 (可以用二进制位存储投影矩阵)，而且于 CPU/FPGA 运行的计算速度显著提升。

15 [**Johnson-Lindenstrauss 引理的最优性**] 证明定理 T5.3.1 (Johnson–Lindenstrauss 引理) 要求的维度 $m=O(\ln N)$ 于本质是最优的，即使我们允许利用非线性的降维映射。按照以下步骤证明：

(1) 设 $\boldsymbol{z}_1,\cdots,\boldsymbol{z}_N\in\mathbb{R}^n$，满足当 $i\neq j$ 时，$1<\|\boldsymbol{z}_i-\boldsymbol{z}_j\|_2\leqslant 2$。证明：$N\leqslant 5^n$。

(2) 设 $n<\frac{1}{2}\ln N$。构造 $\mathbb{R}^N$ 的向量 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N$，使得不存在映射 $T:\mathbb{R}^N\to\mathbb{R}^n$ 满足 $0.99\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2\leqslant\|T(\boldsymbol{x}_i)-T(\boldsymbol{x}_j)\|_2\leqslant 1.01\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2$ 对于任意的 $i,j=1,\cdots,N$。

证明 • 证明受限点集的基数上界 $N\leqslant 5^n$

利用体积填充法，设 $\boldsymbol{z}_1,\cdots,\boldsymbol{z}_N\in\mathbb{R}^n$，满足当 $i\neq j$ 时，

$$1<\|\boldsymbol{z}_i-\boldsymbol{z}_j\|_2\leqslant 2,$$

则 $B(\boldsymbol{z}_i, 1/2)$ 是互不相交的。

以 $\boldsymbol{z}_1$ 为参考中心，对于任意的 $\boldsymbol{x} \in B(\boldsymbol{z}_i, 1/2)$，可得

$$\|\boldsymbol{x}-\boldsymbol{z}_1\|_2 \leqslant \|\boldsymbol{x}-\boldsymbol{z}_i\|_2 + \|\boldsymbol{z}_i-\boldsymbol{z}_1\|_2 < 1/2+2 = 5/2,$$

因此 N 个开球 $B(\boldsymbol{z}_i, 1/2)$ 均完全包含于 $B(\boldsymbol{z}_1, 2.5)$，满足

$$\sum_{i=1}^{N} \mathrm{Vol}\left(B\left(\boldsymbol{z}_i, \frac{1}{2}\right)\right) \leqslant \mathrm{Vol}\left(B\left(\boldsymbol{z}_1, \frac{5}{2}\right)\right),$$

令 $\mathrm{Vol}(\mathbb{B}_2^n) = V_n$，则

$$N \cdot \left(\frac{1}{2}\right)^n V_n \leqslant \left(\frac{5}{2}\right)^n V_n,$$

$$N \leqslant 5^n。$$

- 证明降维下界 $O(\ln N)$ 的不可逾越性

设目标维度满足 $n < \frac{1}{2}\ln N$，我们只需构造 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N \in \mathbb{R}^N$，使得不存在任意的映射 $T : \mathbb{R}^N \to \mathbb{R}^n$，满足

$$0.99\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2 \leqslant \|T(\boldsymbol{x}_i)-T(\boldsymbol{x}_j)\|_2 \leqslant 1.01\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2。$$

令 $\boldsymbol{x}_i = \boldsymbol{e}_i$，则

$$\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2 = \sqrt{1^2+1^2} = \sqrt{2},$$

假设存在映射 $T : \mathbb{R}^N \to \mathbb{R}^n$，使得以误差界 $[0.99, 1.01]$ 保持上述向量的距离，则

$$0.99\sqrt{2} \leqslant \|\boldsymbol{y}_i-\boldsymbol{y}_j\|_2 \leqslant 1.01\sqrt{2}。$$

(为了利用 (1) 的结论。对点集 $\{\boldsymbol{y}_i\}$ 进行常数比例的缩放。)

令缩放因子 $\rho = 0.98\sqrt{2}$，定义

$$\boldsymbol{z}_i = \frac{1}{\rho}\boldsymbol{y}_i = \frac{1}{0.98\sqrt{2}}T(\boldsymbol{x}_i),$$

则距离下界为

$$\|\boldsymbol{z}_i-\boldsymbol{z}_j\|_2 \geqslant \frac{0.99\sqrt{2}}{0.98\sqrt{2}} = \frac{99}{98} > 1,$$

距离上界为

$$\|\boldsymbol{z}_i-\boldsymbol{z}_j\|_2 \leqslant \frac{1.01\sqrt{2}}{0.98\sqrt{2}} = \frac{101}{98} \leqslant 2,$$

因此 $1 < \|\boldsymbol{z}_i-\boldsymbol{z}_j\|_2 \leqslant 2$，即为 (1) 的条件，从而利用 (1) 的结论，可得

$$N \leqslant 5^n,$$

$$n \geqslant \frac{1}{\ln 5}\ln N > 0.621 \ln N,$$

与 $n < \frac{1}{2}\ln N$ 矛盾；如此，$n \geqslant C\ln N$ 于阶数是最优的。

16 [**矩阵 Taylor 级数**] 本题我们将利用矩阵函数的谱定义来推导矩阵的 Taylor 级数展开，即定义 D5.4.2 (矩阵的函数)。设 $\boldsymbol{X} \in \mathbb{R}^{n\times n}$ 为对称矩阵。

(1) 对于任意的多项式 $f(x) = a_0 + a_1 x + \cdots + a_p x^p$，证明：

$$f(\boldsymbol{X}) = a_0\boldsymbol{I}_n + a_1\boldsymbol{X} + \cdots + a_p\boldsymbol{X}^p。$$

(2) 更一般地，若 $f(x) = \sum_{k=1}^{\infty} a_k(x-x_0)^k$ 为 $U(x_0)$ 的幂级数，证明：

$$f(\boldsymbol{X}) = \sum_{k=0}^{\infty} a_k(\boldsymbol{X}-x_0\boldsymbol{I}_n)^k。$$

并明确指出上述矩阵级数在什么条件会在 Frobenius 范数收敛。

(3) 证明：

$$\mathrm{e}^{\boldsymbol{X}} = \boldsymbol{I}_n + \boldsymbol{X} + \frac{\boldsymbol{X}^2}{2!} + \cdots + \frac{\boldsymbol{X}^n}{n!} + \cdots。$$

证明 (1) 设 $f(x) = \sum_{k=0}^{p} a_k x^k$，则根据谱定义 (D5.4.2 (矩阵的函数))，可得

$$\begin{aligned} f(\boldsymbol{X}) &= \boldsymbol{Q} \begin{pmatrix} \sum_{k=0}^{p} a_k \lambda_1^k & & \\ & \ddots & \\ & & \sum_{k=0}^{p} a_k \lambda_n^k \end{pmatrix} \boldsymbol{Q}^\top \\ &= \boldsymbol{Q} \left(\sum_{k=0}^{p} a_k \operatorname{diag}(\lambda_1^k, \cdots, \lambda_n^k) \right) \boldsymbol{Q}^\top \\ &= \sum_{k=0}^{p} a_k \boldsymbol{Q} \boldsymbol{\Lambda}^k \boldsymbol{Q}^\top = \sum_{k=0}^{p} a_k \boldsymbol{X}^k。 \end{aligned}$$

(2) 上述矩阵级数是收敛的，当且仅当 $\boldsymbol{X}$ 的谱包含于收敛区间 $(x_0 - R, x_0 + R)$，即 $\|\boldsymbol{X} - x_0 \boldsymbol{I}_n\| < R$。

定义部分和多项式为 $S_N(x) = \sum_{k=0}^{N} a_k (x - x_0)^k$，则利用 (1) 的结论，可得

$$S_N(\boldsymbol{X}) = \sum_{k=0}^{N} a_k (\boldsymbol{X} - x_0 \boldsymbol{I}_n)^k = \boldsymbol{Q} \operatorname{diag}(S_N(\lambda_1), \cdots, S_N(\lambda_n)) \boldsymbol{Q}^\top,$$

之后只需证明 $S_N(\boldsymbol{X}) \to f(\boldsymbol{X})$。

考虑

$$\|f(\boldsymbol{X}) - S_N(\boldsymbol{X})\|_F = \left\| \boldsymbol{Q} \operatorname{diag}(f(\lambda_i) - S_N(\lambda_i)) \boldsymbol{Q}^\top \right\|_F,$$

注意到正交变换不改变 Frobenius 范数，即 $\|\boldsymbol{Q}\boldsymbol{A}\boldsymbol{Q}^\top\|_F = \|\boldsymbol{A}\|_F$，因此

$$\|f(\boldsymbol{X}) - S_N(\boldsymbol{X})\|_F = \|\operatorname{diag}(f(\lambda_i) - S_N(\lambda_i))\|_F = \sqrt{\sum_{i=1}^{n} (f(\lambda_i) - S_N(\lambda_i))^2}。$$

由于 $|\lambda_i - x_0| < R$，因此 $S_N(\lambda_i) \to f(\lambda_i)$，从而

$$\lim_{N \to \infty} \|f(\boldsymbol{X}) - S_N(\boldsymbol{X})\|_F = 0。$$

因此上述矩阵级数在 Frobenius 范数下收敛于 $f(\boldsymbol{X})$。

利用习题 Q4.4 (算子范数与 Frobenius 范数的关系和性质) (1) 的结论，可得 $\|\boldsymbol{A}\| \leqslant \|\boldsymbol{A}\|_F$，因此上述矩阵级数在算子范数下依然是收敛的。

(3) 考虑 $f(x) = \mathrm{e}^x$ 于 $x_0 = 0$ 的 Maclaurin 级数，

$$\mathrm{e}^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots,$$

其收敛半径为 $R = \infty$，因此对于任意的对称矩阵 $\boldsymbol{X}$，其谱包含于 $(-\infty, \infty)$。

利用 (2) 的结论，可得

$$f(\boldsymbol{X}) = \sum_{k=0}^{\infty} \frac{1}{k!} (\boldsymbol{X} - 0 \cdot \boldsymbol{I}_n)^k = \sum_{k=0}^{\infty} \frac{1}{k!} \boldsymbol{X}^k,$$

即

$$\mathrm{e}^{\boldsymbol{X}} = \boldsymbol{I}_n + \boldsymbol{X} + \frac{\boldsymbol{X}^2}{2!} + \cdots + \frac{\boldsymbol{X}^n}{n!} + \cdots。$$

17 [矩阵的单调性] 于实对称矩阵空间，定义 Loewner 偏序：若矩阵 $\boldsymbol{Y} - \boldsymbol{X}$ 为半正定矩阵，则记为 $\boldsymbol{X} \preccurlyeq \boldsymbol{Y}$。

(1) (交换矩阵的保序性) 证明：对于任意的两个满足交换律 (即 $\boldsymbol{X}\boldsymbol{Y} = \boldsymbol{Y}\boldsymbol{X}$) 的对称矩阵 $\boldsymbol{X}, \boldsymbol{Y}$，若 $\boldsymbol{X} \preccurlyeq \boldsymbol{Y}$，则对于任意的单调不减函数 $f : \mathbb{R} \to \mathbb{R}$，均满足 $f(\boldsymbol{X}) \preccurlyeq f(\boldsymbol{Y})$。

(2) (非交换矩阵的失效性) 构造反例，说明当交换律对 $\boldsymbol{X},\boldsymbol{Y}$ 不成立时，(1) 未必成立。

证明 (1) 由于 $\boldsymbol{X},\boldsymbol{Y}$ 均为对称矩阵，满足交换律 $\boldsymbol{XY}=\boldsymbol{YX}$，则 $\boldsymbol{X},\boldsymbol{Y}$ 能被同时正交对角化，即存在正交矩阵 $\boldsymbol{Q}$，满足 $\boldsymbol{QQ}^\top=\boldsymbol{I}$，使得

$$\boldsymbol{X}=\boldsymbol{Q}\boldsymbol{\Lambda}_X\boldsymbol{Q}^\top,\ \boldsymbol{Y}=\boldsymbol{Q}\boldsymbol{\Lambda}_Y\boldsymbol{Q}^\top,$$

其中 $\boldsymbol{\Lambda}_X=\operatorname{diag}(\lambda_1^X,\cdots,\lambda_n^X)$，$\boldsymbol{\Lambda}_Y=\operatorname{diag}(\lambda_1^Y,\cdots,\lambda_n^Y)$，因此

$$\boldsymbol{Y}-\boldsymbol{X}=\boldsymbol{Q}(\boldsymbol{\Lambda}_Y-\boldsymbol{\Lambda}_X)\boldsymbol{Q}^\top\succcurlyeq\boldsymbol{O}。$$

对于任意的 $\boldsymbol{u}\in\mathbb{R}^n$，令 $\boldsymbol{v}=\boldsymbol{Q}^\top\boldsymbol{u}$，则

$$\boldsymbol{u}^\top\boldsymbol{Q}(\boldsymbol{\Lambda}_Y-\boldsymbol{\Lambda}_X)\boldsymbol{Q}^\top\boldsymbol{u}=\boldsymbol{v}^\top(\boldsymbol{\Lambda}_Y-\boldsymbol{\Lambda}_X)\boldsymbol{v}=\sum_{i=1}^n v_i^2(\lambda_i^Y-\lambda_i^X)\geqslant 0,$$

可得 $\lambda_i^X\leqslant\lambda_i^Y$，因此

$$f(\lambda_i^X)\leqslant f(\lambda_i^Y),$$

从而

$$\boldsymbol{u}^\top(f(\boldsymbol{Y})-f(\boldsymbol{X}))\boldsymbol{u}=\boldsymbol{v}^\top(f(\boldsymbol{\Lambda}_Y)-f(\boldsymbol{\Lambda}_X))\boldsymbol{v}=\sum_{i=1}^n v_i^2(f(\lambda_i^Y)-f(\lambda_i^X))\geqslant 0,$$

即 $f(\boldsymbol{Y})-f(\boldsymbol{X})\succcurlyeq\boldsymbol{O}$，即 $f(\boldsymbol{X})\preccurlyeq f(\boldsymbol{Y})$。

(2) 令

$$\boldsymbol{X}=\begin{pmatrix}1&1\\1&1\end{pmatrix},\ \boldsymbol{Y}=\begin{pmatrix}2&1\\1&1\end{pmatrix},$$

则 $\boldsymbol{X}\preccurlyeq\boldsymbol{Y}$，但是 $\boldsymbol{XY}\neq\boldsymbol{YX}$。

令 $f(x)=x^3$，则

$$f(\boldsymbol{Y})-f(\boldsymbol{X})=\boldsymbol{Y}^3-\boldsymbol{X}^3=\begin{pmatrix}13&8\\8&5\end{pmatrix}-\begin{pmatrix}4&4\\4&4\end{pmatrix}=\begin{pmatrix}9&4\\4&1\end{pmatrix},$$

其行列式为 $-7<0$，说明存在负特征值，即不是半正定矩阵，因此 $f(\boldsymbol{X})\not\preccurlyeq f(\boldsymbol{Y})$。

18 [**函数 $1/x$, $\ln x$ 的矩阵单调性**] 设 $\boldsymbol{X},\boldsymbol{Y}\in\mathbb{R}^{n\times n}$ 为对称矩阵。假设 $\boldsymbol{X}$ 为可逆矩阵，满足 Loewner 偏序关系，

$$\boldsymbol{O}\preccurlyeq\boldsymbol{X}\preccurlyeq\boldsymbol{Y}。$$

(1) 证明 $\boldsymbol{Y}$ 为可逆矩阵，其逆矩阵满足反向偏序关系，

$$\boldsymbol{X}^{-1}\succcurlyeq\boldsymbol{Y}^{-1}\succcurlyeq\boldsymbol{O}。$$

(2) 设 $x>0$，证明以下积分恒等式，

$$\ln x=\int_0^\infty\Big(\frac{1}{1+t}-\frac{1}{x+t}\Big)\mathrm{d}t。$$

(3) 根据矩阵函数的定义，将 (2) 推广为矩阵，并利用 (1) 的结论，证明矩阵对数函数的单调性，

$$\ln\boldsymbol{X}\preccurlyeq\ln\boldsymbol{Y}。$$

解答 (1) 证明 $\boldsymbol{Y}^{-1}\succcurlyeq\boldsymbol{O}$

由于 $\boldsymbol{X}$ 为半正定的可逆矩阵，其谱包含于 $(0,\infty)$，因此 $\boldsymbol{X}$ 是严格正定的，即 $\boldsymbol{X}\succ\boldsymbol{O}$。

对于不等式 $\boldsymbol{X}\preccurlyeq\boldsymbol{Y}$，两侧左乘右乘非零向量 $\boldsymbol{v}\in\mathbb{R}^n$，可得

$$\boldsymbol{v}^\top\boldsymbol{Y}\boldsymbol{v}\geqslant\boldsymbol{v}^\top\boldsymbol{X}\boldsymbol{v}>0,$$

因此 $\boldsymbol{Y}$ 是严格正定的，即 $\boldsymbol{Y}$ 的特征值均大于 0，从而 $\boldsymbol{Y}$ 是可逆的，满足 $\boldsymbol{Y}^{-1}\succ\boldsymbol{O}$。

- 证明 $\boldsymbol{X}^{-1}\succcurlyeq\boldsymbol{Y}^{-1}$

由于 $\boldsymbol{X}\succ\boldsymbol{O}$，因此 $\boldsymbol{X}^{1/2},\boldsymbol{X}^{-1/2}$ 为对称正定的。

对于不等式 $\boldsymbol{X} \preccurlyeq \boldsymbol{Y}$。两侧左乘右乘 $\boldsymbol{X}^{-1/2}$，可得

$$\boldsymbol{X}^{-1/2}\boldsymbol{X}\boldsymbol{X}^{-1/2} \preccurlyeq \boldsymbol{X}^{-1/2}\boldsymbol{Y}\boldsymbol{X}^{-1/2},$$

即

$$\boldsymbol{I}_n \preccurlyeq \boldsymbol{X}^{-1/2}\boldsymbol{Y}\boldsymbol{X}^{-1/2}。$$

令 $\boldsymbol{Z} = \boldsymbol{X}^{-1/2}\boldsymbol{Y}\boldsymbol{X}^{-1/2} \succcurlyeq \boldsymbol{I}_n$，则 $\lambda_i(\boldsymbol{Z}) \geqslant 1$，因此 $\boldsymbol{Z}^{-1}$ 的特征值 $1/\lambda_i(\boldsymbol{Z})$ 满足 $0 < 1/\lambda_i(\boldsymbol{Z}) \leqslant 1$，即

$$\begin{aligned}\boldsymbol{Z}^{-1} &\preccurlyeq \boldsymbol{I}_n,\\ (\boldsymbol{X}^{-1/2}\boldsymbol{Y}\boldsymbol{X}^{-1/2})^{-1} &\preccurlyeq \boldsymbol{I}_n,\\ \boldsymbol{Y}^{-1} &\preccurlyeq \boldsymbol{X}^{-1}。\end{aligned}$$

(2) 容易知道，

$$\begin{aligned}\int_0^\infty \left(\frac{1}{1+t} - \frac{1}{x+t}\right)\mathrm{d}t &= \lim_{T\to\infty}\left[\ln(1+t) - \ln(x+t)\right]_0^{\top}\\ &= \lim_{T\to\infty}\left[\ln\left(\frac{1+t}{x+t}\right)\right]_0^{\top}\\ &= \lim_{T\to\infty}\ln\left(\frac{1+t}{x+t}\right) - \ln\left(\frac{1}{x}\right) = \ln x。\end{aligned}$$

(3) 利用 (2) 的结论，可得

$$\ln \boldsymbol{Y} - \ln \boldsymbol{X} = \int_0^\infty ((\boldsymbol{X}+t\boldsymbol{I}_n)^{-1} - (\boldsymbol{Y}+t\boldsymbol{I}_n)^{-1})\mathrm{d}t。$$

由于 $\boldsymbol{O} \prec \boldsymbol{X} \preccurlyeq \boldsymbol{Y}$，当 $t \geqslant 0$ 时，$t\boldsymbol{I}_n \preccurlyeq t\boldsymbol{I}_n$，因此

$$\boldsymbol{O} \prec \boldsymbol{X} + t\boldsymbol{I}_n \preccurlyeq \boldsymbol{Y} + t\boldsymbol{I}_n,$$

利用 (1) 的结论，可得

$$(\boldsymbol{X}+t\boldsymbol{I}_n)^{-1} \succcurlyeq (\boldsymbol{Y}+t\boldsymbol{I}_n)^{-1},$$

两次积分，

$$\int_0^\infty [(\boldsymbol{X}+t\boldsymbol{I}_n)^{-1} - (\boldsymbol{Y}+t\boldsymbol{I}_n)^{-1}]\mathrm{d}t \succcurlyeq \boldsymbol{O},$$

即 $\ln \boldsymbol{X} \preccurlyeq \ln \boldsymbol{Y}$。

19 [**矩阵指数函数的性质**] 设 $\boldsymbol{X}, \boldsymbol{Y} \in \mathbb{R}^{n\times n}$ 为对称矩阵。

(1) 证明：若 $\boldsymbol{X}, \boldsymbol{Y}$ 满足交换律，则

$$\mathrm{e}^{\boldsymbol{X}+\boldsymbol{Y}} = \mathrm{e}^{\boldsymbol{X}}\mathrm{e}^{\boldsymbol{Y}}。$$

(2) 构造反例，使得 $\boldsymbol{X}, \boldsymbol{Y}$ 不满足交换律，满足 $\mathrm{e}^{\boldsymbol{X}+\boldsymbol{Y}} \neq \mathrm{e}^{\boldsymbol{X}}\mathrm{e}^{\boldsymbol{Y}}$。

证明 (1) 根据 Taylor 级数，可得

$$\mathrm{e}^{\boldsymbol{X}} = \sum_{j=0}^\infty \frac{\boldsymbol{X}^j}{j!},\ \mathrm{e}^{\boldsymbol{Y}} = \sum_{k=0}^\infty \frac{\boldsymbol{Y}^k}{k!},$$

根据二项式定理，可得

$$(\boldsymbol{X}+\boldsymbol{Y})^m = \sum_{j=0}^m \binom{m}{j}\boldsymbol{X}^j\boldsymbol{Y}^{m-j},$$

因此

$$\mathrm{e}^{\boldsymbol{X}+\boldsymbol{Y}} = \sum_{m=0}^\infty \frac{(\boldsymbol{X}+\boldsymbol{Y})^m}{m!} = \sum_{m=0}^\infty\sum_{j=0}^m \frac{1}{m!}\binom{m}{j}\boldsymbol{X}^j\boldsymbol{Y}^{m-j} = \sum_{m=0}^\infty\sum_{j=0}^m \frac{\boldsymbol{X}^j}{j!}\frac{\boldsymbol{Y}^{m-j}}{(m-j)!}$$

$$= \sum_{j=0}^{\infty}\sum_{k=0}^{\infty}\frac{\boldsymbol{X}^j}{j!}\frac{\boldsymbol{Y}^k}{k!} = \left(\sum_{j=0}^{\infty}\frac{\boldsymbol{X}^j}{j!}\right)\left(\sum_{k=0}^{\infty}\frac{\boldsymbol{Y}^k}{k!}\right) = \mathrm{e}^{\boldsymbol{X}}\mathrm{e}^{\boldsymbol{Y}}。 \qquad (k=m-j)$$

(2) 令

$$\boldsymbol{X} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix},\ \boldsymbol{Y} = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}。$$

则 $\boldsymbol{XY} \neq \boldsymbol{YX}$。

对于 $\mathrm{e}^{\boldsymbol{X}}$，由于 $\boldsymbol{X}^2 = \boldsymbol{I}$，因此

$$\mathrm{e}^{\boldsymbol{X}} = \cosh(1)\boldsymbol{I} + \sinh(1)\boldsymbol{X} = \begin{pmatrix} \cosh 1 & \sinh 1 \\ \sinh 1 & \cosh 1 \end{pmatrix};$$

对于 $\mathrm{e}^{\boldsymbol{Y}}$，由于 $\boldsymbol{Y}$ 为对角矩阵，因此

$$\mathrm{e}^{\boldsymbol{Y}} = \begin{pmatrix} \mathrm{e}^0 & 0 \\ 0 & \mathrm{e} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & \mathrm{e} \end{pmatrix},$$

从而

$$\mathrm{e}^{\boldsymbol{X}}\mathrm{e}^{\boldsymbol{Y}} = \begin{pmatrix} \cosh 1 & \sinh 1 \\ \sinh 1 & \cosh 1 \end{pmatrix}\begin{pmatrix} 1 & 0 \\ 0 & \mathrm{e} \end{pmatrix} = \begin{pmatrix} \cosh 1 & \mathrm{e}\sinh 1 \\ \sinh 1 & \mathrm{e}\cosh 1 \end{pmatrix}。$$

但是，对于 $\mathrm{e}^{\boldsymbol{X}+\boldsymbol{Y}}$，令 $\boldsymbol{S} = \boldsymbol{X} + \boldsymbol{Y}$，则

$$\mathrm{e}^{\boldsymbol{S}} = \boldsymbol{Q}\begin{pmatrix} \mathrm{e}^{\lambda_1} & 0 \\ 0 & \mathrm{e}^{\lambda_2} \end{pmatrix}\boldsymbol{Q}^{\top},$$

其中 $\boldsymbol{S}$ 的特征值为

$$\det(\lambda\boldsymbol{I} - \boldsymbol{S}) = \lambda^2 - \lambda - 1 = 0,$$

$$\lambda_1 = \frac{1+\sqrt{5}}{2} = \varphi,$$

$$\lambda_2 = \frac{1-\sqrt{5}}{2} = -\frac{1}{\varphi}。$$

利用矩阵指数公式

$$\mathrm{e}^{\boldsymbol{S}} = \frac{\mathrm{e}^{\lambda_1} - \mathrm{e}^{\lambda_2}}{\lambda_1 - \lambda_2}\boldsymbol{S} + \frac{\lambda_1\mathrm{e}^{\lambda_2} - \lambda_2\mathrm{e}^{\lambda_1}}{\lambda_1 - \lambda_2}\boldsymbol{I},$$

其中 $\lambda_1 - \lambda_2 = \sqrt{5}$，可得

$$\mathrm{e}^{\boldsymbol{S}} = \frac{\mathrm{e}^{\varphi} - \mathrm{e}^{-1/\varphi}}{\sqrt{5}}\begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix} + \frac{\varphi\mathrm{e}^{-1/\varphi} - (-1/\varphi)\mathrm{e}^{\varphi}}{\sqrt{5}}\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix},$$

因此 $\mathrm{e}^{\boldsymbol{S}} \neq \mathrm{e}^{\boldsymbol{X}}\mathrm{e}^{\boldsymbol{Y}}$。

20 **[矩阵和的期望算子范数界限]** 设 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_N \in \mathbb{R}^{n\times n}$ 为相互独立的对称矩阵，满足 $\mathrm{E}[\boldsymbol{X}_i] = \boldsymbol{0}$，$\|\boldsymbol{X}_i\| \leqslant K$ (a.s.)。记矩阵方差的算子范数为 $\sigma^2 = \|\sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i^2]\|$。利用定理 T5.4.1 (矩阵 Bernstein 不等式)，证明：

$$\mathrm{E}\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\| \lesssim \sigma\sqrt{\ln n} + K\ln n。$$

证明 令 $S = \|\sum_{i=1}^N \boldsymbol{X}_i\|$，利用定理 T5.4.1 (矩阵 Bernstein 不等式)，可得对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{S \geqslant t\} \leqslant 2n\exp\left(-c\min\left(\frac{t^2}{\sigma^2}, \frac{t}{K}\right)\right), \qquad (c>0)$$

对尾部界限解耦，利用不等式 $\exp(-\min(A,B)) = \max(\mathrm{e}^{-A}, \mathrm{e}^{-B}) \leqslant \mathrm{e}^{-A} + \mathrm{e}^{-B}$，可得

$$\mathrm{P}\{S \geqslant t\} \leqslant 2n \exp\left(-\frac{ct^2}{\sigma^2}\right) + 2n \exp\left(-\frac{ct}{K}\right),$$

(右侧两项均含有 $2n$，之后只需选择阈值，将指数衰减项不仅能将 $2n$ 抵消，还能继续贡献衰减因子，保证积分收敛。具体而言，令

$$2n \exp\left(-\frac{ct^2}{\sigma^2}\right) = \frac{1}{2n}, \qquad t = \sigma\sqrt{\frac{2}{c}\ln(2n)},$$

$$2n \exp\left(-\frac{ct}{K}\right) = \frac{1}{2n}, \qquad t = \frac{2}{c}K\ln(2n),$$

之后定义阈值为上述两项之和即可。) 利用非负随机变量期望的积分恒等式

$$\mathrm{E}[S] = \int_0^\infty \mathrm{P}\{S \geqslant t\}\mathrm{d}t,$$

令阈值 $u = u_1 + u_2$，其中

$$u_1 = \sigma\sqrt{\frac{2}{c}\ln(2n)}, \quad u_2 = \frac{2}{c}K\ln(2n),$$

将积分拆分，

$$\begin{aligned}
\mathrm{E}[S] &= \int_0^u \mathrm{P}\{S \geqslant t\}\mathrm{d}t + \int_u^\infty \mathrm{P}\{S \geqslant t\}\mathrm{d}t \\
&\leqslant u + \int_u^\infty \mathrm{P}\{S \geqslant t\}\mathrm{d}t \\
&= u + \underbrace{\int_u^\infty 2n \exp\left(-\frac{ct^2}{\sigma^2}\right)\mathrm{d}t}_{I_1} + \underbrace{\int_u^\infty 2n \exp\left(-\frac{ct}{K}\right)\mathrm{d}t}_{I_2},
\end{aligned}$$

对于 I_1，

$$\begin{aligned}
I_1 &\leqslant 2n \int_{u_1}^\infty \exp\left(-\frac{ct^2}{\sigma^2}\right)\mathrm{d}t \\
&= 2n \int_0^\infty \exp\left(-\frac{c(u_1^2 + x^2)}{\sigma^2}\right)\mathrm{d}x = 2n \exp\left(-\frac{cu_1^2}{\sigma^2}\right)\int_0^\infty \exp\left(-\frac{cx^2}{\sigma^2}\right)\mathrm{d}x \qquad (t = u_1 + x) \\
&= 2n \cdot \frac{1}{4n^2} \cdot \frac{\sigma}{2}\sqrt{\frac{\pi}{c}} = \frac{\sigma\sqrt{\pi}}{4n\sqrt{c}} = O(\sigma), \\
I_2 &\leqslant 2n \int_{u_2}^\infty \exp\left(-\frac{ct}{K}\right)\mathrm{d}t \\
&= 2n\left[-\frac{K}{c}\exp\left(-\frac{ct}{K}\right)\right]_{u_2}^\infty = 2n\frac{K}{c}\exp\left(-\frac{cu_2}{K}\right) \\
&\leqslant 2n\frac{K}{c}\frac{1}{4n^2} = \frac{K}{2nc} = O(K),
\end{aligned}$$

将其代入，可得

$$\mathrm{E}[S] \leqslant u_1 + u_2 + I_1 + I_2 = \sigma\sqrt{\frac{2}{c}\ln(2n)} + \frac{2}{c}K\ln(2n) + O(\sigma) + O(K),$$

其中 $\ln(2n)=\ln 2+\ln n\asymp 1+\ln n$，$O(\sigma),O(K)$ 均可被主导项的常数系数吸收，从而

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\lesssim\sigma\sqrt{1+\ln n}+K(1+\ln n)。$$

21 [**矩阵 Hoeffding 不等式的证明**] 设 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，$\boldsymbol{A}_1,\cdots,\boldsymbol{A}_N\in\mathbb{R}^{n\times n}$ 为确定性对称矩阵。定义随机矩阵和为 $\boldsymbol{S}=\sum_{i=1}^{N}\varepsilon_i\boldsymbol{A}_i$。仿照矩阵 Bernstein 不等式的证明思路，证明定理 T5.4.13 (矩阵 Hoeffding 不等式)：对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\}\leqslant 2n\exp\left(-\frac{t^2}{2\sigma^2}\right),$$

其中 $\sigma^2=\|\sum_{i=1}^{N}\boldsymbol{A}_i^2\|$。

证明 (标准的证明思路为：依次应用矩阵 Chernoff 界限, 单项的矩阵 MGF 估计, Lieb 定理去耦, 标量函数极值优化。) 矩阵 Chernoff 界限

由于 $\boldsymbol{S}$ 为对称矩阵，因此其算子范数等于其最大绝对特征值，即 $\|\boldsymbol{S}\|=\max(\lambda_{\max}(\boldsymbol{S}),\lambda_{\max}(-\boldsymbol{S}))$。

考虑 $\lambda_{\max}(\boldsymbol{S})$ 的尾概率界限，对于任意的 $\theta>0$，利用定理 T2.3.1 (Chernoff 不等式) (Chernoff 不等式)，可得

$$\begin{aligned}\mathrm{P}\{\lambda_{\max}(\boldsymbol{S})\geqslant t\}&=\mathrm{P}\left\{\mathrm{e}^{\theta\lambda_{\max}(\boldsymbol{S})}\geqslant\mathrm{e}^{\theta t}\right\}\leqslant\mathrm{e}^{-\theta t}\mathrm{E}\left[\mathrm{e}^{\theta\lambda_{\max}(\boldsymbol{S})}\right]\\&\leqslant\mathrm{e}^{-\theta t}\mathrm{E}[\mathrm{tr}(\mathrm{e}^{\theta\boldsymbol{S}})]。\end{aligned}\tag{I}$$

- 利用随机矩阵的 Lieb 不等式处理迹的期望

(矩阵指数 $\mathrm{e}^{\theta\sum_i\varepsilon_i\boldsymbol{A}_i}$ 内部的项一般不交换。根据引理 L5.4.9 (随机矩阵的 Lieb 不等式)，可直接控制其迹的期望。)

根据引理 L5.4.9 (随机矩阵的 Lieb 不等式) 于 $\boldsymbol{H}=\boldsymbol{0}$ 时的情形，可得

$$\mathrm{E}\left[\mathrm{tr}\exp\left(\sum_{i=1}^{N}\boldsymbol{X}_i\right)\right]\leqslant\mathrm{tr}\exp\left(\sum_{i=1}^{N}\ln\mathrm{E}[\mathrm{e}^{\boldsymbol{X}_i}]\right)。\tag{II}$$

(Golden–Thompson 不等式的证明见注释。)

令 $\boldsymbol{X}_i=\theta\varepsilon_i\boldsymbol{A}_i$，之后只需计算 $\mathrm{E}[\mathrm{e}^{\theta\varepsilon_i\boldsymbol{A}_i}]$。容易知道，

$$\mathrm{E}[\mathrm{e}^{\theta\varepsilon_i\boldsymbol{A}_i}]=\frac{1}{2}\mathrm{e}^{\theta\boldsymbol{A}_i}+\frac{1}{2}\mathrm{e}^{-\theta\boldsymbol{A}_i}=\cosh(\theta\boldsymbol{A}_i),$$

注意到 $\cosh(x)\leqslant\mathrm{e}^{x^2/2}$，$\boldsymbol{A}_i$ 为对称矩阵，因此

$$\mathrm{E}[\mathrm{e}^{\theta\varepsilon_i\boldsymbol{A}_i}]\preccurlyeq\exp\left(\frac{\theta^2\boldsymbol{A}_i^2}{2}\right),$$

根据习题 Q5.18 (函数 $1/x$, $\ln x$ 的矩阵单调性)，可得 $\ln(\cdot)$ 为算子单调函数，两侧取对数，

$$\ln\mathrm{E}[\mathrm{e}^{\theta\varepsilon_i\boldsymbol{A}_i}]\preccurlyeq\frac{\theta^2}{2}\boldsymbol{A}_i^2,$$

将其代入于 (II)，可得

$$\mathrm{E}[\mathrm{tr}(\mathrm{e}^{\theta\boldsymbol{S}})]\leqslant\mathrm{tr}\exp\left(\sum_{i=1}^{N}\frac{\theta^2}{2}\boldsymbol{A}_i^2\right)=\mathrm{tr}\exp\left(\frac{\theta^2}{2}\sum_{i=1}^{N}\boldsymbol{A}_i^2\right),$$

其中记方差矩阵 $\boldsymbol{V}=\sum_{i=1}^{N}\boldsymbol{A}_i^2$，满足 $\sigma^2=\|\boldsymbol{V}\|$，则

$$\mathrm{tr}\exp\left(\frac{\theta^2}{2}\boldsymbol{V}\right)\leqslant n\cdot\lambda_{\max}\left(\exp\left(\frac{\theta^2}{2}\boldsymbol{V}\right)\right)=n\exp\left(\frac{\theta^2}{2}\|\boldsymbol{V}\|\right),$$

因此

$$\mathrm{E}[\mathrm{tr}(\mathrm{e}^{\theta\boldsymbol{S}})]\leqslant n\exp\left(\frac{\theta^2\sigma^2}{2}\right),$$

将其代入于 (I)，可得

$$\mathrm{P}\{\lambda_{\max}(\boldsymbol{S}) \geqslant t\} \leqslant n \exp\left(\underbrace{-\theta t + \frac{\theta^2 \sigma^2}{2}}_{f(\theta)} \right),$$

其中

$$\min_{\theta>0} f(\theta) = f\left(\frac{t}{\sigma^2}\right) = -\frac{t^2}{2\sigma^2},$$

从而

$$\mathrm{P}\{\lambda_{\max}(\boldsymbol{S}) \geqslant t\} \leqslant n \exp\left(-\frac{t^2}{2\sigma^2}\right);$$

同理，根据对称性，可得

$$\mathrm{P}\{\lambda_{\max}(-\boldsymbol{S}) \geqslant t\} \leqslant n \exp\left(-\frac{t^2}{2\sigma^2}\right)。$$

如此，利用并集界，可得

$$\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\} = \mathrm{P}\{\max(\lambda_{\max}(\boldsymbol{S}), \lambda_{\max}(-\boldsymbol{S})) \geqslant t\} \leqslant \mathrm{P}\{\lambda_{\max}(\boldsymbol{S}) \geqslant t\} + \mathrm{P}\{\lambda_{\max}(-\boldsymbol{S}) \geqslant t\} \leqslant 2n \exp\left(-\frac{t^2}{2\sigma^2}\right)。$$

注释 对于 Golden-Thompson 不等式的证明：

解法一 Lieb 凹性定理

定理 (Lieb 凹性定理的推论, Elliott H. Lieb, 1973) 设 $\boldsymbol{H}$ 为 Hermite 矩阵，$F(\boldsymbol{X})$ 定义于正定 Hermite 矩阵集合，则

$$F(\boldsymbol{X}) = \mathrm{tr}(\exp(\boldsymbol{H} + \ln \boldsymbol{X}))$$

为严格凹函数。

(于多元微积分，若可微函数 $f(\boldsymbol{x})$ 为凹函数，则其必定被其于任意的 $\boldsymbol{y}$ 的切平面所控制 (即函数图像在切平面的下方)，

$$f(\boldsymbol{x}) \leqslant f(\boldsymbol{y}) + \langle \nabla f(\boldsymbol{y}), \boldsymbol{x} - \boldsymbol{y} \rangle。$$

于实矩阵空间，内积定义为 Hilbert-Schmidt 内积 $\langle \boldsymbol{M}, \boldsymbol{N} \rangle = \mathrm{tr}(\boldsymbol{M}^\top \boldsymbol{N})$，对于 Hermite 阵，其等价于 $\mathrm{tr}(\boldsymbol{MN})$，因此对于凹函数 $F(\boldsymbol{X})$，

$$F(\boldsymbol{X}) \leqslant F(\boldsymbol{Y}) + \mathrm{tr}(\nabla F(\boldsymbol{Y}) \cdot (\boldsymbol{X} - \boldsymbol{Y})),$$

其中 $\boldsymbol{X}, \boldsymbol{Y}$ 为正定矩阵。

为了利用上述性质，我们必须计算 $\nabla F(\boldsymbol{X})$。)

作出以下方向导数公式：

方向导数公式 1 (指数迹的方向导数) 设 $\boldsymbol{M}, \boldsymbol{N}$ 为方阵，则

$$\left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0} \mathrm{tr}(\exp(\boldsymbol{M} + t\boldsymbol{N})) = \mathrm{tr}(\exp(\boldsymbol{M})\boldsymbol{N})。$$

方向导数公式 2 (对数迹的方向导数) 设 $\boldsymbol{C}$ 为正定矩阵，$\boldsymbol{V}$ 为 Hermite 矩阵，则

$$\left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0} \mathrm{tr}(\ln(\boldsymbol{C} + t\boldsymbol{V})) = \mathrm{tr}(\boldsymbol{C}^{-1}\boldsymbol{V})。$$

令 $F(\boldsymbol{X}) = \mathrm{tr}(\exp(\boldsymbol{A} + \ln \boldsymbol{X}))$，则根据 Lieb 定理，可得 $F(\boldsymbol{X})$ 于正定矩阵域是凹的。

令 $\boldsymbol{Y} = \exp(-\boldsymbol{A})$ 为正定 Hermite 矩阵，则

$$F(\boldsymbol{Y}) = \mathrm{tr}(\exp(\boldsymbol{A} + \ln(\exp(-\boldsymbol{A})))) = \mathrm{tr}(\exp(\boldsymbol{A} - \boldsymbol{A})) = \mathrm{tr}(\boldsymbol{I}) = n。$$

F 于 $\boldsymbol{Y}$ 以方向 $\boldsymbol{V}$ 的方向导数为

$$\nabla_{\boldsymbol{V}} F(\boldsymbol{Y}) = \left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0} \mathrm{tr}(\exp(\boldsymbol{A} + \ln(\boldsymbol{Y} + t\boldsymbol{V})))。$$

令 $\boldsymbol{M}(t)=\boldsymbol{A}+\ln(\boldsymbol{Y}+t\boldsymbol{V})$，满足 $\boldsymbol{M}(0)=0$，则根据方向导数公式 1，可得

$$\frac{\mathrm{d}}{\mathrm{d}t}\Big|_{t=0}\operatorname{tr}(\exp(\boldsymbol{M}(t)))=\operatorname{tr}(\exp(\boldsymbol{M}(0))\cdot\boldsymbol{M}'(0))=\operatorname{tr}(\boldsymbol{I}\cdot\boldsymbol{M}'(0))=\operatorname{tr}(\boldsymbol{M}'(0)),$$

根据方向导数公式 2，可得

$$\operatorname{tr}(\boldsymbol{M}'(0))=\frac{\mathrm{d}}{\mathrm{d}t}\Big|_{t=0}\operatorname{tr}(\boldsymbol{A}+\ln(\boldsymbol{Y}+t\boldsymbol{V}))=\frac{\mathrm{d}}{\mathrm{d}t}\Big|_{t=0}\operatorname{tr}(\ln(\boldsymbol{Y}+t\boldsymbol{V}))=\operatorname{tr}(\boldsymbol{Y}^{-1}\boldsymbol{V}),$$

注意到 $\langle\nabla F(\boldsymbol{Y}),\boldsymbol{V}\rangle=\operatorname{tr}(\nabla F(\boldsymbol{Y})\cdot\boldsymbol{V})$，因此

$$\nabla F(\boldsymbol{Y})=\boldsymbol{Y}^{-1}=(\exp(-\boldsymbol{A}))^{-1}=\exp(\boldsymbol{A})。$$

如此，将 $F(\boldsymbol{Y}),\nabla F(\boldsymbol{Y})$ 代入凹性的一阶条件 $F(\boldsymbol{X})\geqslant F(\boldsymbol{Y})+\operatorname{tr}(\nabla F(\boldsymbol{Y})\cdot(\boldsymbol{X}-\boldsymbol{Y}))$，可得

$$\begin{aligned}F(\boldsymbol{X})&\leqslant n+\operatorname{tr}(\exp(\boldsymbol{A})\cdot(\boldsymbol{X}-\exp(-\boldsymbol{A})))\\&\leqslant n+\operatorname{tr}(\exp(\boldsymbol{A})\boldsymbol{X})-\operatorname{tr}(\exp(\boldsymbol{A})\exp(-\boldsymbol{A}))\\&=n+\operatorname{tr}(\exp(\boldsymbol{A})\boldsymbol{X})-n=\operatorname{tr}(\exp(\boldsymbol{A})\boldsymbol{X}),\end{aligned}$$

此时令 $\boldsymbol{X}=\exp(\boldsymbol{B})$，即为

$$\operatorname{tr}(\exp(\boldsymbol{A}+\boldsymbol{B}))\leqslant\operatorname{tr}(\exp(\boldsymbol{A})\exp(\boldsymbol{B}))。$$

解法二　Lie-Trotter 乘积公式

作出以下辅助公式：

辅助公式 1 (Lie-Trotter 乘积公式)　设 $\boldsymbol{X},\boldsymbol{Y}$ 为方阵，则

$$\exp(\boldsymbol{X}+\boldsymbol{Y})=\lim_{n\to\infty}\left(\exp\left(\frac{\boldsymbol{X}}{n}\right)\exp\left(\frac{\boldsymbol{Y}}{n}\right)\right)^n。$$

辅助公式 2 (Weyl 控制不等式于迹的推论)　设 $\boldsymbol{C}\in\mathbb{R}^{n\times n}$，其特征值为 $\lambda_1,\lambda_2,\cdots,\lambda_n$，奇异值为 $\sigma_1,\sigma_2,\cdots,\sigma_n$，则对于任意的 $p\geqslant 1$，

$$\sum_{i=1}^n|\lambda_i|^p\leqslant\sum_{i=1}^n\sigma_i^p。$$

特别地，当 $p=2m$ 时，$\sum_{i=1}^n\sigma_i^{2m}=\operatorname{tr}((\boldsymbol{C}\boldsymbol{C}^*)^m)$。

辅助公式 3　设 $\boldsymbol{X},\boldsymbol{Y}$ 为半正定 Hermite 矩阵，则对于任意的 $k\in\mathbb{Z}_0^+$，

$$\operatorname{tr}((\boldsymbol{X}\boldsymbol{Y})^{2^k})\leqslant\operatorname{tr}(\boldsymbol{X}^{2^k}\boldsymbol{Y}^{2^k})。$$

令 $\boldsymbol{C}=\boldsymbol{X}\boldsymbol{Y}$，则 $\boldsymbol{C}\sim\boldsymbol{X}^{1/2}\boldsymbol{Y}\boldsymbol{X}^{1/2}$，其中 $\boldsymbol{X}^{1/2}\boldsymbol{Y}\boldsymbol{X}^{1/2}$ 为半正定 Hermite 矩阵，因此 $\boldsymbol{C}$ 是半正定的，谱包含于 $[0,\infty)$。利用数学归纳法：当 $m=0$ 时，结论是平凡的；假设当 $m=k-1$ 时，结论成立，即对于任意的半正定 Hermite 矩阵 $\boldsymbol{P},\boldsymbol{Q}$，均满足

$$\operatorname{tr}((\boldsymbol{P}\boldsymbol{Q})^{2^{k-1}})\leqslant\operatorname{tr}(\boldsymbol{P}^{2^{k-1}}\boldsymbol{Q}^{2^{k-1}});$$

则当 $m=k$ 时，左侧为

$$\operatorname{tr}(\boldsymbol{C}^{2^k})=\sum_{i=1}^n\lambda_i^{2^k}=\sum_{i=1}^n|\lambda_i|^{2^k},$$

根据辅助公式 2，令 $p=2^k$，可得

$$\operatorname{tr}(\boldsymbol{C}^{2^k})=\sum_{i=1}^n|\lambda_i|^{2^k}\leqslant\operatorname{tr}((\boldsymbol{C}\boldsymbol{C}^*)^{2^{k-1}})。$$

对于 $\boldsymbol{C}\boldsymbol{C}^*$，

$$\boldsymbol{C}\boldsymbol{C}^*=(\boldsymbol{X}\boldsymbol{Y})(\boldsymbol{X}\boldsymbol{Y})^*=\boldsymbol{X}\boldsymbol{Y}\boldsymbol{Y}^*\boldsymbol{X}^*=\boldsymbol{X}\boldsymbol{Y}^2\boldsymbol{X},$$

两侧取迹，

$$\operatorname{tr}((\boldsymbol{C}\boldsymbol{C}^*)^{2^{k-1}})=\operatorname{tr}((\boldsymbol{X}\boldsymbol{Y}^2\boldsymbol{X})^{2^{k-1}}),$$

其中

$$\begin{aligned}\operatorname{tr}((\boldsymbol{X}\boldsymbol{Y}^2\boldsymbol{X})^{2^{k-1}}) &= \operatorname{tr}(\boldsymbol{X}\boldsymbol{Y}^2\boldsymbol{X}^2\boldsymbol{Y}^2\boldsymbol{X}^2\cdots\boldsymbol{Y}^2\boldsymbol{X}) = \operatorname{tr}(\boldsymbol{Y}^2\boldsymbol{X}^2\boldsymbol{Y}^2\boldsymbol{X}^2\cdots\boldsymbol{Y}^2\boldsymbol{X}^2)\\ &= \operatorname{tr}((\boldsymbol{Y}^2\boldsymbol{X}^2)^{2^{k-1}}) = \operatorname{tr}((\boldsymbol{X}^2\boldsymbol{Y}^2)^{2^{k-1}}),\end{aligned}$$

将其代入，可得

$$\operatorname{tr}((\boldsymbol{X}\boldsymbol{Y})^{2^k}) \leqslant \operatorname{tr}((\boldsymbol{X}^2\boldsymbol{Y}^2)^{2^{k-1}})。 \tag{III}$$

另一方面，令 $\boldsymbol{P}=\boldsymbol{X}^2,\boldsymbol{Q}=\boldsymbol{Y}^2$ 为半正定 Hermite 矩阵，则根据归纳假设，可得

$$\operatorname{tr}((\boldsymbol{P}\boldsymbol{Q})^{2^{k-1}}) \leqslant \operatorname{tr}(\boldsymbol{P}^{2^{k-1}}\boldsymbol{Q}^{2^{k-1}}),$$

即

$$\operatorname{tr}((\boldsymbol{X}^2\boldsymbol{Y}^2)^{2^{k-1}}) \leqslant \operatorname{tr}((\boldsymbol{X}^2)^{2^{k-1}}(\boldsymbol{Y}^2)^{2^{k-1}}) = \operatorname{tr}(\boldsymbol{X}^{2^k}\boldsymbol{Y}^{2^k})。 \tag{IV}$$

联立 (III) 和 (IV)，可得

$$\operatorname{tr}((\boldsymbol{X}\boldsymbol{Y})^{2^k}) \leqslant \operatorname{tr}(\boldsymbol{X}^{2^k}\boldsymbol{Y}^{2^k})。$$

根据辅助公式 1，可得

$$\operatorname{tr}(\exp(\boldsymbol{A}+\boldsymbol{B})) = \operatorname{tr}\left(\lim_{n\to\infty}\left(\exp\left(\frac{\boldsymbol{A}}{n}\right)\exp\left(\frac{\boldsymbol{B}}{n}\right)\right)^n\right) = \lim_{n\to\infty}\operatorname{tr}\left(\left(\exp\left(\frac{\boldsymbol{A}}{n}\right)\exp\left(\frac{\boldsymbol{B}}{n}\right)\right)^n\right),$$

令 $N=2^k$，

$$\operatorname{tr}(\exp(\boldsymbol{A}+\boldsymbol{B})) = \lim_{k\to\infty}\operatorname{tr}\left(\left(\exp\left(\frac{\boldsymbol{A}}{2^k}\right)\exp\left(\frac{\boldsymbol{B}}{2^k}\right)\right)^{2^k}\right)。$$

对于右侧，令

$$\boldsymbol{X}_k = \exp\left(\frac{\boldsymbol{A}}{2^k}\right),\quad \boldsymbol{Y}_k = \exp\left(\frac{\boldsymbol{B}}{2^k}\right),$$

则 $\boldsymbol{X}_k,\boldsymbol{Y}_k$ 为正定 Hermite 矩阵，因此根据辅助公式 3，可得

$$\operatorname{tr}((\boldsymbol{X}_k\boldsymbol{Y}_k)^{2^k}) \leqslant \operatorname{tr}(\boldsymbol{X}_k^{2^k}\boldsymbol{Y}_k^{2^k}),$$

其中

$$\boldsymbol{X}_k^{2^k} = \left(\exp\left(\frac{\boldsymbol{A}}{2^k}\right)\right)^{2^k} = \exp(\boldsymbol{A}),\ \boldsymbol{Y}_k^{2^k} = \left(\exp\left(\frac{\boldsymbol{B}}{2^k}\right)\right)^{2^k} = \exp(\boldsymbol{B}),$$

将其代入，

$$\operatorname{tr}\left(\left(\exp\left(\frac{\boldsymbol{A}}{2^k}\right)\exp\left(\frac{\boldsymbol{B}}{2^k}\right)\right)^{2^k}\right) \leqslant \operatorname{tr}(\exp(\boldsymbol{A})\exp(\boldsymbol{B})),$$

两侧取极限，

$$\lim_{k\to\infty}\operatorname{tr}\left(\left(\exp\left(\frac{\boldsymbol{A}}{2^k}\right)\exp\left(\frac{\boldsymbol{B}}{2^k}\right)\right)^{2^k}\right) \leqslant \operatorname{tr}(\exp(\boldsymbol{A})\exp(\boldsymbol{B})),$$

即

$$\operatorname{tr}(\exp(\boldsymbol{A}+\boldsymbol{B})) \leqslant \operatorname{tr}(\exp(\boldsymbol{A})\exp(\boldsymbol{B}))。$$

22 [**矩阵 Khintchine 不等式的推导**] 设 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，$\boldsymbol{A}_1,\cdots,\boldsymbol{A}_N\in\mathbb{R}^{n\times n}$ 为确定性对称矩阵。令 $\boldsymbol{S}=\sum_{i=1}^N\varepsilon_i\boldsymbol{A}_i$，$\sigma^2=\left\|\sum_{i=1}^N\boldsymbol{A}_i^2\right\|$。利用定理 T5.4.13 (矩阵 Hoeffding 不等式)，证明：对于任意的 $p\geqslant 1$，矩阵 Khintchine 不等式成立，即定理 T5.4.14 (矩阵 Khintchine 不等式)，

$$(\mathrm{E}[\|\boldsymbol{S}\|^p])^{1/p} \leqslant C(\sqrt{p}+\sqrt{\ln n})\sigma。 \tag{$C>0$}$$

证明 利用定理 T5.4.13 (矩阵 Hoeffding 不等式)，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\} \leqslant 2n\exp\left(-\frac{t^2}{2\sigma^2}\right),$$

利用尾部积分公式，可得

$$\begin{aligned}\mathrm{E}[\|\boldsymbol{S}\|^p] &= \int_0^\infty pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\}\mathrm{d}t \\ &= \int_0^{t_0} pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\}\mathrm{d}t + \int_{t_0}^\infty pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\}\mathrm{d}t \\ &\leqslant \int_0^{t_0} pt^{p-1}\mathrm{d}t + \int_{t_0}^\infty pt^{p-1}\cdot 2(m+n)\exp\left(-\frac{t^2}{2\sigma^2}\right)\mathrm{d}t \\ &= \underbrace{t_0^p}_{I_1} + \underbrace{\int_{t_0}^\infty pt^{p-1}\cdot 2n\exp\left(-\frac{t^2}{2\sigma^2}\right)\mathrm{d}t}_{I_2}。\end{aligned}$$

令 $t_0 = \sigma\sqrt{2(\ln(2n)+p)}$，则对于 I_1，

$$I_1 = \sigma^p[2(\ln(2n)+p)]^{p/2} \leqslant C^p\sigma^p(\sqrt{\ln n}+\sqrt{p})^p。$$

对于 I_2，

$$\begin{aligned}I_2 &= 2np(\sigma\sqrt{2})^p\int_{x_0}^\infty x^{p-1}\mathrm{e}^{-x^2}\mathrm{d}x && \left(x=\frac{t}{\sigma\sqrt{2}}\right) \\ &= 2np(\sigma\sqrt{2})^p\cdot\frac{1}{2}\int_{x_0^2}^\infty u^{\frac{p}{2}-1}\mathrm{e}^{-u}\mathrm{d}u。 && (u=x^2)\end{aligned}$$

上述积分项为不完全 Gamma 积分。根据 $t_0 = \sigma\sqrt{2(\ln(2n)+p)}$，可得

$$x_0^2 = \frac{t_0^2}{2\sigma^2} = \ln(2n)+p。$$

令 $x = x_0^2$，并记

$$J_p(x) = \int_x^\infty u^{p/2-1}\mathrm{e}^{-u}\mathrm{d}u。$$

由于 $n \geqslant 1$，$x = \ln(2n)+p \geqslant p$。当 $p \geqslant 2$ 时，分部积分可得

$$\begin{aligned}J_p(x) &= x^{p/2-1}\mathrm{e}^{-x} + \left(\frac{p}{2}-1\right)\int_x^\infty u^{p/2-2}\mathrm{e}^{-u}\mathrm{d}u \\ &\leqslant x^{p/2-1}\mathrm{e}^{-x} + \frac{p/2-1}{x}J_p(x)。\end{aligned}$$

由于 $x \geqslant p$，可得 $J_p(x) \leqslant 2x^{p/2-1}\mathrm{e}^{-x}$。当 $1 \leqslant p \leqslant 2$ 时，$u \geqslant x$ 蕴含 $u^{p/2-1} \leqslant x^{p/2-1}$，因此 $J_p(x) \leqslant 2x^{p/2-1}\mathrm{e}^{-x}$。将此界代入，可得

$$\begin{aligned}I_2 &\leqslant 2np(\sigma\sqrt{2})^p x^{p/2-1}\mathrm{e}^{-x} \\ &= p(\sigma\sqrt{2})^p x^{p/2-1}\mathrm{e}^{-p} \\ &\leqslant C^p\sigma^p(\ln(2n)+p)^{p/2} \\ &\leqslant C^p\sigma^p(\sqrt{\ln n}+\sqrt{p})^p;\end{aligned}$$

如此，

$$\mathrm{E}[\|\boldsymbol{S}\|^p] \leqslant C^p\sigma^p(\sqrt{\ln n}+\sqrt{p})^p,$$

两侧取 $1/p$ 次方，可得

$$(\mathrm{E}\|\boldsymbol{S}\|^p)^{1/p} \leqslant C\sigma(\sqrt{\ln n}+\sqrt{p}),$$

即

$$\left(\mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{A}_i\right\|^p\right)^{1/p} \leqslant C(\sqrt{p}+\sqrt{\ln n})\left\|\sum_{i=1}^N \boldsymbol{A}_i^2\right\|^{1/2}。 \qquad (C>0)$$

23 [矩形矩阵的 Bernstein 不等式] 设 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_N \in \mathbb{R}^{m\times n}$ 是相互独立的，满足 $\mathrm{E}[\boldsymbol{X}_i] = \boldsymbol{0}$，$\|\boldsymbol{X}_i\| \leqslant K$。定义矩阵和的方差参数 σ^2 为

$$\sigma^2 = \left\|\sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i^\top \boldsymbol{X}_i]\right\| + \left\|\sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i \boldsymbol{X}_i^\top]\right\|,$$

证明：对于任意的 $t \geqslant 0$，随机矩阵 $\boldsymbol{S} = \sum_{i=1}^N \boldsymbol{X}_i$ 的算子范数满足

$$\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\} \leqslant 2(m+n)\exp\left(-\frac{t^2/2}{\sigma^2 + Kt/3}\right)。$$

证明 (Bernstein 不等式主要适用于对称矩阵 (其算子范数与其谱半径相关)，处理长方形矩阵的通用手段是利用 Hermitian Dilation 技术。)

对于任意的 $\boldsymbol{X}_i$，构造其对称化形式 $\boldsymbol{H}_i \in \mathbb{R}^{(m+n)\times(m+n)}$ 为

$$\boldsymbol{H}_i = \begin{pmatrix} \boldsymbol{O} & \boldsymbol{X}_i \\ \boldsymbol{X}_i^\top & \boldsymbol{O} \end{pmatrix},$$

其性质如下：

1. 对称性：$\boldsymbol{H}_i = \boldsymbol{H}_i^\top$。

2. 零均值：

$$\mathrm{E}[\boldsymbol{H}_i] = \begin{pmatrix} \boldsymbol{O} & \mathrm{E}[\boldsymbol{X}_i] \\ \mathrm{E}[\boldsymbol{X}_i^\top] & \boldsymbol{O} \end{pmatrix} = \boldsymbol{O}。$$

3. 范数有界：$\|\boldsymbol{H}_i\| = \|\boldsymbol{X}_i\| \leqslant K$。

4. 独立性：由于 $\boldsymbol{X}_i$ 是相互独立的，$\boldsymbol{H}_i$ 是相互独立的。

构造总和矩阵

$$\boldsymbol{S}_H = \sum_{i=1}^N \boldsymbol{H}_i = \begin{pmatrix} \boldsymbol{O} & \boldsymbol{S} \\ \boldsymbol{S}^\top & \boldsymbol{O} \end{pmatrix},$$

满足

$$\|\boldsymbol{S}_H\| = \left\|\begin{pmatrix} \boldsymbol{O} & \boldsymbol{S} \\ \boldsymbol{S}^\top & \boldsymbol{O} \end{pmatrix}\right\| = \|\boldsymbol{S}\|,$$

则求和矩阵的方差参数 σ_H^2 为

$$\sigma_H^2 = \left\|\sum_{i=1}^N \mathrm{E}[\boldsymbol{H}_i^2]\right\| = \left\|\begin{pmatrix} \sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i \boldsymbol{X}_i^\top] & \boldsymbol{O} \\ \boldsymbol{O} & \sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i^\top \boldsymbol{X}_i] \end{pmatrix}\right\| = \max\left(\left\|\sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i \boldsymbol{X}_i^\top]\right\|, \left\|\sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i^\top \boldsymbol{X}_i]\right\|\right)。$$

(由于 $\sigma_H^2 \leqslant \sigma^2$，所以利用 σ^2 作为方差参数的界限是成立的。)

对于对称矩阵 $\boldsymbol{S}_H \in \mathbb{R}^{(m+n)\times(m+n)}$，利用定理 T5.4.1 (矩阵 Bernstein 不等式)，可得

$$\mathrm{P}\{\|\boldsymbol{S}_H\| \geqslant t\} \leqslant 2(m+n)\exp\left(-\frac{t^2/2}{\sigma_H^2 + Kt/3}\right) \leqslant 2(m+n)\exp\left(-\frac{t^2/2}{\sigma^2 + Kt/3}\right),$$

因此

$$\mathrm{P}\{\|\boldsymbol{S}\| \geqslant t\} \leqslant 2(m+n)\exp\left(-\frac{t^2/2}{\sigma^2 + Kt/3}\right)。$$

24 [矩形矩阵的矩阵 Khintchine 不等式] 设 $\varepsilon_1, \cdots, \varepsilon_N$ i.i.d. $\sim$ Rademacher，$\boldsymbol{A}_1, \cdots, \boldsymbol{A}_N \in \mathbb{R}^{m\times n}$ 为确定性矩阵。令随机矩阵和为 $\boldsymbol{S} = \sum_{i=1}^N \varepsilon_i \boldsymbol{A}_i$，定义方差参数 σ^2 为

$$\sigma^2 = \max\left(\left\|\sum_{i=1}^N \boldsymbol{A}_i^\top \boldsymbol{A}_i\right\|, \left\|\sum_{i=1}^N \boldsymbol{A}_i \boldsymbol{A}_i^\top\right\|\right)。$$

令 $d=m+n$。证明：对于任意的 $p\geqslant 1$，

$$(\mathrm{E}[\|\boldsymbol{S}\|^p])^{1/p}\leqslant C\sigma\sqrt{p+\ln d}。\qquad (C>0)$$

证明 利用定理 T5.4.13 (矩阵 Hoeffding 不等式)，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\}\leqslant 2d\exp\left(-\frac{t^2}{2\sigma^2}\right)。$$

利用尾部积分公式，可得

$$\begin{aligned}\mathrm{E}[\|\boldsymbol{S}\|^p]&=\int_0^{\infty}pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\}\mathrm{d}t\\&=\int_0^{t_0}pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\}\mathrm{d}t+\int_{t_0}^{\infty}pt^{p-1}\mathrm{P}\{\|\boldsymbol{S}\|\geqslant t\}\mathrm{d}t\\&\leqslant\int_0^{t_0}pt^{p-1}\mathrm{d}t+\int_{t_0}^{\infty}pt^{p-1}\cdot 2d\exp\left(-\frac{t^2}{2\sigma^2}\right)\mathrm{d}t\\&=\underbrace{t_0^p}_{I_1}+\underbrace{\int_{t_0}^{\infty}pt^{p-1}\cdot 2d\exp\left(-\frac{ct^2}{\sigma^2}\right)\mathrm{d}t}_{I_2}。\end{aligned}$$

令 $t_0=\sigma\sqrt{2\ln(2d)+2p}$，则对于 I_1，利用不等式 $(a+b)^{p/2}\leqslant 2^{p/2-1}(a^{p/2}+b^{p/2})$，可得

$$I_1=\sigma^p[2\ln(2d)+2p]^{p/2}\leqslant C^p\sigma^p(\sqrt{p}+\sqrt{\ln d})^p。$$

对于 I_2，

$$\begin{aligned}I_2&=2dp(\sigma\sqrt{2})^p\int_{x_0}^{\infty}x^{p-1}\mathrm{e}^{-x^2}\mathrm{d}x&\left(x=\frac{t}{\sigma\sqrt{2}}\right)\\&=dp(\sigma\sqrt{2})^p\int_{x_0^2}^{\infty}u^{\frac{p}{2}-1}\mathrm{e}^{-u}\mathrm{d}u。&(u=x^2)\end{aligned}$$

注意到上述积分项即为 $\Gamma(p/2,x_0^2)$，其中

$$t_0=\sigma\sqrt{2(\ln(2d)+p)},$$

$$x_0^2=\frac{t_0^2}{2\sigma^2}=\ln(2d)+p,$$

将其代入，可得

$$\begin{aligned}I_2=dp(\sigma\sqrt{2})^p\int_{x_0^2}^{\infty}u^{\frac{p}{2}-1}\mathrm{e}^{-u}\mathrm{d}u&\\\leqslant C^p\sigma^p[\ln(2d)+p]^{p/2}&\\\leqslant C^p\sigma^p(\sqrt{\ln d}+\sqrt{p})^p。&\end{aligned}$$

如此，

$$\mathrm{E}[\|\boldsymbol{S}\|^p]\leqslant C^p\sigma^p(\sqrt{\ln d}+\sqrt{p})^p,$$

两侧取 $1/p$ 次方，

$$(\mathrm{E}\|\boldsymbol{S}\|^p)^{1/p}\leqslant C\sigma(\sqrt{p}+\sqrt{\ln d}),$$

即

$$(\mathrm{E}\|\boldsymbol{S}\|^p)^{1/p}\leqslant C\sigma\sqrt{p+\ln d}。\qquad (C>0)$$

25 [**无自环的 SBM 模型**] 于 SBM 的定义 D4.5.1 (随机块模型)，$G(n,p,q)$ 允许自环存在，即任意的顶点与其自身连接的概率为 p。

现将定义进行修改：

设 $G=(V,E)$ 为含有 n 个顶点的随机图，将 V 均分为两个社区 C_1,C_2，定义概率矩阵 $\boldsymbol{P}$ 为

$$p_{ij}=p\cdot\mathbf{1}_{\{c_i=c_j\}}+q\cdot\mathbf{1}_{\{c_i\neq c_j\}},$$

邻接矩阵 $\boldsymbol{A}$ 为

$$A_{ij}\sim\begin{cases}0, & i=j,\\ B(p), & i\neq j, c_i=c_j,\\ B(q), & i\neq j, c_i\neq c_j\end{cases},$$

证明：定理 T5.5.1 (稀疏随机块模型的谱聚类) 依然成立。

证明 设 $\boldsymbol{A}$ 为包含自环的邻接矩阵，$\tilde{\boldsymbol{A}}$ 为修改之后的无自环邻接矩阵，则两者仅于对角线有差异，满足

$$\tilde{\boldsymbol{A}}=\boldsymbol{A}-\operatorname{diag}(A_{11},A_{22},\cdots,A_{nn}),$$

其中 A_{ii} i.i.d. $\sim$ Bernoulli(p)，两侧取期望，

$$\mathrm{E}[\tilde{\boldsymbol{A}}]=\mathrm{E}[\boldsymbol{A}]-p\boldsymbol{I}_n。$$

设 $\boldsymbol{D}=\mathrm{E}[\boldsymbol{A}]$，$\tilde{\boldsymbol{D}}=\mathrm{E}[\tilde{\boldsymbol{A}}]$，则 $\tilde{\boldsymbol{D}}=\boldsymbol{D}-p\boldsymbol{I}_n$ 为标量平移变换，因此 $\boldsymbol{D},\tilde{\boldsymbol{D}}$ 的特征向量相同，特征值平移为 $\tilde{\lambda}_i=\lambda_i-p$，谱间隙 $\tilde{\delta}=\delta\asymp n(p-q)=a-b$ 保持不变。根据 Davis-Kahan 定理，可得所需的谱向量估计；其余部分按照定理 T5.5.1 (稀疏随机块模型的谱聚类) 的过程证明。

设带自环的噪声矩阵为 $\boldsymbol{Z}=\boldsymbol{A}-\boldsymbol{D}$，无自环的噪声矩阵为 $\tilde{\boldsymbol{Z}}=\tilde{\boldsymbol{A}}-\tilde{\boldsymbol{D}}$，则

$$\begin{aligned}\tilde{\boldsymbol{Z}}&=(\boldsymbol{A}-\operatorname{diag}(\boldsymbol{A}))-(\boldsymbol{D}-p\boldsymbol{I}_n)\\&=(\boldsymbol{A}-\boldsymbol{D})-(\operatorname{diag}(\boldsymbol{A})-p\boldsymbol{I}_n)\\&=\boldsymbol{Z}-\boldsymbol{\Delta},\end{aligned}$$

其中 $\boldsymbol{\Delta}=\operatorname{diag}(A_{11}-p,\cdots,A_{nn}-p)$ 满足 $\|\boldsymbol{\Delta}\|\leqslant 1$ (由于 $|A_{ii}-p|\leqslant\max(p,1-p)$)，将其代入，可得

$$\|\tilde{\boldsymbol{Z}}\|\leqslant\|\boldsymbol{Z}\|+1\leqslant C\sqrt{a}+1\asymp C\sqrt{a}。$$

26 [**协方差估计的高概率界限, 有效秩**] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为中心化 sub-Gaussian 随机向量，其总体协方差矩阵为 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$，并且几乎处处满足 $\|\boldsymbol{X}\|_2^2\leqslant K^2\operatorname{tr}(\boldsymbol{\Sigma})$，

$$\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{L^2}。\qquad(K\geqslant 1)$$

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m$ 为 $\boldsymbol{X}$ 的独立同分布的样本，样本协方差矩阵为

$$\boldsymbol{\Sigma}_m=\frac{1}{m}\sum_{i=1}^m\boldsymbol{X}_i\boldsymbol{X}_i^\top。$$

定义 $\boldsymbol{\Sigma}$ 的有效秩为

$$r=\begin{cases}\frac{\operatorname{tr}(\boldsymbol{\Sigma})}{\|\boldsymbol{\Sigma}\|}, & \|\boldsymbol{\Sigma}\|>0,\\ 0, & \|\boldsymbol{\Sigma}\|=0\end{cases}\leqslant n,$$

利用定理 T5.4.1 (矩阵 Bernstein 不等式) (矩阵 Bernstein 不等式)，证明注记 R5.6.5 (高概率保证) 的高概率界限：对于任意的 $u\geqslant 0$，以高概率，满足

$$\mathrm{P}\left\{\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant C\left(\sqrt{\frac{K^4r(\ln n+u)}{m}}+\frac{K^2r(\ln n+u)}{m}\right)\|\boldsymbol{\Sigma}\|\right\}\geqslant 1-2\mathrm{e}^{-u}。$$

注释 本题为协方差估计理论的重要结论，它要求我们放弃之前基于 ε-网的证明路径 (由于 ε-网只能给出依赖维度 n 的界限)，转而直接利用矩阵 Bernstein 不等式，从而引入比维度 n 小得多的有效秩 r。

证明 **解法一　有界矩阵 Bernstein 不等式**

定义中心化随机矩阵 $\boldsymbol{Z}_i=\boldsymbol{X}_i\boldsymbol{X}_i^\top-\boldsymbol{\Sigma}$，则样本协方差矩阵, 总体协方差矩阵之差可以表示为上述独立零均值随机矩阵的平均，

$$\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}=\frac{1}{m}\sum_{i=1}^m\boldsymbol{Z}_i。$$

为应用定理 T5.4.1 (矩阵 Bernstein 不等式) (矩阵 Bernstein 不等式)，记

$$\sigma^2 = \left\| \sum_{i=1}^m \mathrm{E}[\boldsymbol{Z}_i^2] \right\|。$$

- 估计方差参数 σ^2

  将 $\mathrm{E}[\boldsymbol{Z}^2]$ 展开，

$$\mathrm{E}[\boldsymbol{Z}^2] = \mathrm{E}[(\boldsymbol{X}\boldsymbol{X}^\top - \boldsymbol{\Sigma})^2] = \mathrm{E}\|\boldsymbol{X}\|_2^2 \boldsymbol{X}\boldsymbol{X}^\top - \boldsymbol{\Sigma}^2 \preceq \mathrm{E}\|\boldsymbol{X}\|_2^2 \boldsymbol{X}\boldsymbol{X}^\top,$$

  因此之后只需估计 $\sup_{\boldsymbol{v}\in\mathbb{S}^{n-1}} \boldsymbol{v}^\top \mathrm{E}\|\boldsymbol{X}\|_2^2 \boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{v}$。令 $\boldsymbol{w}_1, \cdots, \boldsymbol{w}_n$ 为标准正交基，则对于任意的 $\boldsymbol{v} \in \mathbb{S}^{n-1}$，

$$\begin{aligned}
\mathrm{E}\|\boldsymbol{X}\|_2^2 \langle \boldsymbol{X}, \boldsymbol{v}\rangle^2 &= \sum_{j=1}^n \mathrm{E}[\langle \boldsymbol{X}, \boldsymbol{w}_j\rangle^2 \langle \boldsymbol{X}, \boldsymbol{v}\rangle^2] \leqslant \sum_{j=1}^n \sqrt{\mathrm{E}[\langle \boldsymbol{X}, \boldsymbol{w}_j\rangle^4] \mathrm{E}[\langle \boldsymbol{X}, \boldsymbol{v}\rangle^4]} \\
&\leqslant CK^4 \sum_{j=1}^n \langle \boldsymbol{w}_j, \boldsymbol{\Sigma}\boldsymbol{w}_j\rangle \langle \boldsymbol{v}, \boldsymbol{\Sigma}\boldsymbol{v}\rangle = CK^4 \operatorname{tr}(\boldsymbol{\Sigma}) \langle \boldsymbol{v}, \boldsymbol{\Sigma}\boldsymbol{v}\rangle \leqslant CK^4 r \|\boldsymbol{\Sigma}\|^2, \\
\sigma^2 &= \left\| \sum_{i=1}^m \mathrm{E}[\boldsymbol{Z}_i^2] \right\| \leqslant CmK^4 r \|\boldsymbol{\Sigma}\|^2.
\end{aligned}$$

若 $\|\boldsymbol{\Sigma}\| = 0$，则 $\mathrm{E}\|\boldsymbol{X}\|_2^2 = \operatorname{tr}(\boldsymbol{\Sigma}) = 0$，因此 $\boldsymbol{X} = \boldsymbol{0}$ 几乎处处，则结论是平凡的；之后只需考虑 $\|\boldsymbol{\Sigma}\| > 0$ 的情况。此时 $r \geqslant 1$。根据题设，可得

$$\|\boldsymbol{Z}_i\| \leqslant \|\boldsymbol{X}_i\|_2^2 + \|\boldsymbol{\Sigma}\| \leqslant (K^2 r + 1)\|\boldsymbol{\Sigma}\| \leqslant 2K^2 r \|\boldsymbol{\Sigma}\| = M。$$

- 应用有界矩阵 Bernstein 不等式

  根据定理 T5.4.1 (矩阵 Bernstein 不等式) (矩阵 Bernstein 不等式)，对于任意的 $t \geqslant 0$，可得

$$\mathrm{P}\{\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \geqslant t\} = \mathrm{P}\left\{ \left\| \sum_{i=1}^m \boldsymbol{Z}_i \right\| \geqslant mt \right\} \leqslant 2n \exp\left(-\frac{m^2 t^2/2}{\sigma^2 + Mmt/3} \right) \leqslant 2n \exp\left(-c \min\left(\frac{mt^2}{K^4 r \|\boldsymbol{\Sigma}\|^2}, \frac{mt}{K^2 r \|\boldsymbol{\Sigma}\|} \right) \right),$$

  若上述概率不超过 $2\mathrm{e}^{-u}$，则

$$c \min\left(\frac{mt^2}{C_1 K^4 r \|\boldsymbol{\Sigma}\|^2}, \frac{mt}{2K^2 r \|\boldsymbol{\Sigma}\|} \right) \geqslant \ln n + u,$$

  即

$$\begin{aligned}
\frac{mt^2}{C_1 K^4 r \|\boldsymbol{\Sigma}\|^2} &\geqslant \frac{\ln n + u}{c}, \\
t &\geqslant \sqrt{\frac{C_1}{c}} \sqrt{\frac{K^4 r (\ln n + u)}{m}} \|\boldsymbol{\Sigma}\|, \\
\frac{mt}{2K^2 r \|\boldsymbol{\Sigma}\|} &\geqslant \frac{\ln n + u}{c}, \\
t &\geqslant \frac{2}{c} \frac{K^2 r (\ln n + u)}{m} \|\boldsymbol{\Sigma}\|,
\end{aligned}$$

  因此令

$$C = \max\left(\sqrt{\frac{C_1}{c}}, \frac{2}{c} \right), \quad t = C\left(\sqrt{\frac{K^4 r (\ln n + u)}{m}} + \frac{K^2 r (\ln n + u)}{m} \right) \|\boldsymbol{\Sigma}\|,$$

  可得对于任意的 $u \geqslant 0$，成立

$$\mathrm{P}\left\{ \|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant C\left(\sqrt{\frac{K^4 r (\ln n + u)}{m}} + \frac{K^2 r (\ln n + u)}{m} \right) \|\boldsymbol{\Sigma}\| \right\} \geqslant 1 - 2\mathrm{e}^{-u}。$$

解法二　Khintchine 不等式

- 对称化, 矩阵 Khintchine 不等式

记误差矩阵为

$$\boldsymbol{R}_m = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{X}_i\boldsymbol{X}_i^\top - \boldsymbol{\Sigma}),$$

之后只需估计其 L^p 范数 $E_p = (\mathrm{E}\|\boldsymbol{R}_m\|^p)^{1/p}$，其中 $p \geqslant 1$。

引入 $\varepsilon_1, \cdots, \varepsilon_m$ i.i.d. $\sim$ Rademacher，利用对称化不等式，可得

$$E_p \leqslant \frac{2}{m}\left(\mathrm{E}\left\|\sum_{i=1}^{m}\varepsilon_i\boldsymbol{X}_i\boldsymbol{X}_i^\top\right\|^p\right)^{1/p},$$

之后对 ε_i 利用定理 T5.4.14 (矩阵 Khintchine 不等式)，可得

$$E_p \leqslant \frac{C_1\sqrt{p+\ln n}}{m}\left(\mathrm{E}\left\|\sum_{i=1}^{m}(\boldsymbol{X}_i\boldsymbol{X}_i^\top)^2\right\|^{p/2}\right)^{1/p}。 \tag{I}$$

- 计算 E_p 的隐性界

注意到 $(\boldsymbol{X}_i\boldsymbol{X}_i^\top)^2 = \|\boldsymbol{X}_i\|_2^2\boldsymbol{X}_i\boldsymbol{X}_i^\top$，$\left\|\sum_{i=1}^m \boldsymbol{X}_i\boldsymbol{X}_i^\top\right\| \leqslant m(\|\boldsymbol{R}_m\| + \|\boldsymbol{\Sigma}\|)$，因此

$$\begin{aligned}\left\|\sum_{i=1}^{m}\|\boldsymbol{X}_i\|_2^2\boldsymbol{X}_i\boldsymbol{X}_i^\top\right\| &\leqslant \max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\cdot\left\|\sum_{i=1}^{m}\boldsymbol{X}_i\boldsymbol{X}_i^\top\right\| \\ &\leqslant \max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\cdot m(\|\boldsymbol{R}_m\| + \|\boldsymbol{\Sigma}\|) \\ &= Mm(\|\boldsymbol{R}_m\| + \|\boldsymbol{\Sigma}\|), \qquad \left(M = \max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\right)\end{aligned}$$

将其代入于 (I)，可得

$$\begin{aligned}E_p &\leqslant \frac{C_1\sqrt{p+\ln n}}{m}(\mathrm{E}[M^{p/2}\cdot m^{p/2}(\|\boldsymbol{R}_m\| + \|\boldsymbol{\Sigma}\|)^{p/2}])^{1/p} \\ &\leqslant C_1\sqrt{\frac{p+\ln n}{m}}\|M\|_{L^p}^{1/2}\cdot(E_p + \|\boldsymbol{\Sigma}\|)^{1/2}。\end{aligned} \tag{II}$$

令 $\alpha = C_1\sqrt{\frac{p+\ln n}{m}}\|M\|_{L^p}^{1/2}$，$x = E_p$，$c = \|\boldsymbol{\Sigma}\|$，则 (II) 即为

$$x \leqslant \alpha\sqrt{x+c},$$

对其放缩，可得

$$x \leqslant \alpha^2 + \alpha\sqrt{c},$$

即

$$E_p \leqslant \alpha^2 + \alpha\sqrt{\|\boldsymbol{\Sigma}\|} = C_1^2\frac{p+\ln n}{m}\|M\|_{L^p} + C_1\sqrt{\frac{p+\ln n}{m}}\sqrt{\|M\|_{L^p}\|\boldsymbol{\Sigma}\|}, \tag{III}$$

之后只需估计 $\|M\|_{L^p}$。

- 计算 E_p 的显性界

根据题设，对于任意的 i，可得

$$\|\boldsymbol{X}_i\|_2^2 \leqslant K^2\operatorname{tr}(\boldsymbol{\Sigma}) = K^2r\|\boldsymbol{\Sigma}\|,$$

因此

$$\|M\|_{L^p} \leqslant K^2r\|\boldsymbol{\Sigma}\|。 \tag{IV}$$

将其代入于 (III)，可得

$$E_p \leqslant C_1^2\frac{K^2r(p+\ln n)}{m}\|\boldsymbol{\Sigma}\| + C_1\sqrt{\frac{K^2r(p+\ln n)}{m}}\|\boldsymbol{\Sigma}\|$$

$$\leqslant C_5\left(\frac{K^2r(p+\ln n)}{m}+\sqrt{\frac{K^4r(p+\ln n)}{m}}\right)\|\boldsymbol{\Sigma}\|。\tag{V}$$

• 利用 Markov 不等式转化为高概率界

利用命题 P1.6.2 (Markov 不等式) (Markov 不等式)，可得对于任意的 $t>0$，

$$\mathrm{P}\{\|\boldsymbol{R}_m\|\geqslant \mathrm{e}\cdot E_p\}=\mathrm{P}\{\|\boldsymbol{R}_m\|^p\geqslant \mathrm{e}^p\cdot \mathrm{E}\|\boldsymbol{R}_m\|^p\}\leqslant \mathrm{e}^{-p}。$$

令 $p=u+\ln 2$，可得成立

$$\mathrm{P}\left\{\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant C_6\left(\sqrt{\frac{K^4r(u+\ln n)}{m}}+\frac{K^2r(u+\ln n)}{m}\right)\|\boldsymbol{\Sigma}\|\right\}\geqslant 1-2\mathrm{e}^{-u}。$$

注释 解法二中，根据题设，

$$\left\|\sum_{i=1}^m\|\boldsymbol{X}_i\|_2^2\boldsymbol{X}_i\boldsymbol{X}_i^\top\right\|\leqslant\max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\cdot\left\|\sum_{i=1}^m\boldsymbol{X}_i\boldsymbol{X}_i^\top\right\|$$

样本模长的最大值 M 满足 $M\leqslant K^2r\|\boldsymbol{\Sigma}\|$ 几乎处处，因此不引入额外的对数因子。

27 [**有界性假设的必要性**] 证明定理 T5.6.1 (一般协方差估计) 的有界性假设 (即存在 $K\geqslant 1$，使得 $\|\boldsymbol{X}\|_2\leqslant K(\mathrm{E}\|\boldsymbol{X}\|_2^2)^{1/2}$ (a.s.)) 不能忽略。具体而言，构造不满足上述有界性假设的随机向量 $\boldsymbol{X}$，说明即使在样本量 m 相对较大时，$\boldsymbol{\Sigma}_m$ 也无法收敛于总体协方差矩阵 $\boldsymbol{\Sigma}$。

解答 设 $n\geqslant 2$，定义随机向量 $\boldsymbol{X}\in\mathbb{R}^n$ 的分布为

$$\boldsymbol{X}=\begin{cases}\boldsymbol{0}, & p=1-\varepsilon,\\ \sqrt{\dfrac{n}{\varepsilon}}\boldsymbol{e}_i, & p=\dfrac{\varepsilon}{n}\end{cases},$$

则

$$\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]=(1-\varepsilon)\cdot\boldsymbol{0}+\sum_{i=1}^n\frac{\varepsilon}{n}\left(\sqrt{\frac{n}{\varepsilon}}\boldsymbol{e}_i\right)\left(\sqrt{\frac{n}{\varepsilon}}\boldsymbol{e}_i\right)^\top$$

$$=\sum_{i=1}^n\frac{\varepsilon}{n}\cdot\frac{n}{\varepsilon}\cdot\boldsymbol{e}_i\boldsymbol{e}_i^\top=\sum_{i=1}^n\boldsymbol{e}_i\boldsymbol{e}_i^\top=\boldsymbol{I}_n,$$

因此 $\boldsymbol{X}$ 是各向同性的。

但是，当

$$\boldsymbol{X}=\sqrt{\frac{n}{\varepsilon}}\boldsymbol{e}_i,$$

时，$\|\boldsymbol{X}\|_2=\sqrt{\frac{n}{\varepsilon}}$，假设存在 $K>0$，使得 $\|\boldsymbol{X}\|_2\leqslant K\sqrt{n}$ (a.s.)，则

$$\sqrt{\frac{n}{\varepsilon}}\leqslant K\sqrt{n},$$

$$K\geqslant\frac{1}{\sqrt{\varepsilon}},$$

令 $\varepsilon\to 0$，则 K 不存在，矛盾；如此，$\boldsymbol{X}$ 不满足有界性假设。

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m$ 为 $\boldsymbol{X}$ 的独立同分布的样本，则

$$\mathrm{P}\{\boldsymbol{X}_1=\cdots=\boldsymbol{X}_m=\boldsymbol{0}\}=(1-\varepsilon)^m\sim\mathrm{e}^{-\varepsilon m},$$

令 $\varepsilon=1/n$，$m<n$，则

$$\mathrm{P}\{\boldsymbol{\Sigma}_m=0\}=\left(1-\frac{1}{n}\right)^m\sim\mathrm{e}^{-m/n}\sim 1,$$

此时 $\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|=\|\boldsymbol{0}-\boldsymbol{I}_n\|=1$，即 $\boldsymbol{\Sigma}_m\nrightarrow\boldsymbol{\Sigma}$。

28 [协方差估计, 矩阵 Bernstein 不等式的对数因子]

(1) 构造概率分布，使得当 $m \lesssim n\ln n$ 时，样本协方差矩阵 $\boldsymbol{\Sigma}_m$ 使得 $\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| < \|\boldsymbol{\Sigma}\|$ 未必成立 (w.h.p.)。

(2) 对于上述构造，证明矩阵 Bernstein 不等式的对数因子 $\ln n$ 是不可避免的。

解答 (1) 构造随机向量 $\boldsymbol{X} \in \mathbb{R}^n$ 为

$$\mathrm{P}\{\boldsymbol{X} = \boldsymbol{e}_i\} = \frac{1}{n},$$

则总体协方差矩阵为

$$\boldsymbol{\Sigma} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top] = \sum_{i=1}^{n} \frac{1}{n}\boldsymbol{e}_i\boldsymbol{e}_i^\top = \frac{1}{n}\boldsymbol{I}_n,$$

其谱范数为 $\|\boldsymbol{\Sigma}\| = 1/n$。

设 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_m$ 为 m 个独立同分布的样本，则样本协方差矩阵为

$$\boldsymbol{\Sigma}_m = \frac{1}{m}\sum_{j=1}^{m} \boldsymbol{X}_j\boldsymbol{X}_j^\top,$$

注意到 $\boldsymbol{\Sigma}_m$ 为对角矩阵，第 k 个对角元素为 $d_k = \mathrm{count}(k)/m$，其中 $\mathrm{count}(k)$ 为 $\boldsymbol{e}_k$ 出现的次数。

若 $\boldsymbol{e}_k$ 从未出现，即 $\mathrm{count}(k) = 0$，则

$$(\boldsymbol{\Sigma}_m)_{kk} = 0,\ (\boldsymbol{\Sigma})_{kk} = \frac{1}{n},$$

因此

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \geqslant \max_{1\leqslant k\leqslant n} |(\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma})_{kk}| = \frac{1}{n} = \|\boldsymbol{\Sigma}\|。$$

根据“优惠券收集者问题”，当 $m \leqslant \frac{1}{2}n\ln n$ 时，至少存在一个向量未被选取的概率趋于 1，因此若 $m \lesssim n\ln n$，则 $\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \geqslant \|\boldsymbol{\Sigma}\|$ (w.h.p.)。

(2) 假设矩阵 Bernstein 不等式的形式为

$$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \lesssim \|\boldsymbol{\Sigma}\|\sqrt{\frac{n}{m}},$$

若误差 $\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| < \|\boldsymbol{\Sigma}\|$，则 $\sqrt{n/m} < 1$，即 $m > n$。

但是，利用 (1) 的结论，可得即使 $n < m < n\ln n$，$\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \geqslant \|\boldsymbol{\Sigma}\|$ (w.h.p.) 依然成立，因此界限 $m \asymp n$ 并不成立。

29 [有效秩] 设 $\boldsymbol{\Sigma} \in \mathbb{R}^{n\times n}$ 为对称半正定矩阵，其有效秩定义为

$$r(\boldsymbol{\Sigma}) = \frac{\mathrm{tr}(\boldsymbol{\Sigma})}{\|\boldsymbol{\Sigma}\|}。$$

(1) 证明：$1 \leqslant r(\boldsymbol{\Sigma}) \leqslant \mathrm{rank}(\boldsymbol{\Sigma}) \leqslant n$。

(2) 证明上述不等式是紧的，即存在满秩矩阵，使得其有效秩可以任意地接近于 1。

(3) 证明：有效秩为矩阵的连续函数 (在算子范数的意义下)。

(4) 证明：若随机向量 $\boldsymbol{X}$ 取值于 $\mathbb{R}^n$ 的某个 k 维子空间，则其协方差矩阵满足 $\mathrm{rank}(\boldsymbol{\Sigma}) \leqslant k$，进而可得 $r(\boldsymbol{\Sigma}) \leqslant k$。

证明 容易知道，

$$\mathrm{tr}(\boldsymbol{\Sigma}) = \sum_{i=1}^{n}\lambda_i,\ \|\boldsymbol{\Sigma}\| = \lambda_1,\ r(\boldsymbol{\Sigma}) = \frac{\sum_{i=1}^{n}\lambda_i}{\lambda_1}。$$

(1) 容易知道，左右两侧成立，我们只需证明 $r(\boldsymbol{\Sigma}) \leqslant \mathrm{rank}(\boldsymbol{\Sigma})$。

设 $\mathrm{rank}(\boldsymbol{\Sigma}) = k$，则其含有 k 个非零特征值，即 $\lambda_1 \geqslant \lambda_2 \geqslant \cdots \geqslant \lambda_k > 0$，$\lambda_{k+1} = \cdots = \lambda_n = 0$，因此

$$\mathrm{tr}(\boldsymbol{\Sigma}) = \sum_{i=1}^{k}\lambda_i \leqslant \sum_{i=1}^{k}\lambda_1 = k\lambda_1,$$

从而

$$r(\boldsymbol{\Sigma}) = \frac{\operatorname{tr}(\boldsymbol{\Sigma})}{\lambda_1} \leqslant k = \operatorname{rank}(\boldsymbol{\Sigma})。$$

(2) 考虑对角矩阵 $\boldsymbol{\Sigma}_\varepsilon = \operatorname{diag}(1, \varepsilon, \varepsilon, \cdots, \varepsilon)$，则 $\operatorname{rank}(\boldsymbol{\Sigma}_\varepsilon) = n$，$\operatorname{tr}(\boldsymbol{\Sigma}_\varepsilon) = 1 + (n-1)\varepsilon$，可得

$$r(\boldsymbol{\Sigma}_\varepsilon) = \frac{1 + (n-1)\varepsilon}{1} = 1 + (n-1)\varepsilon \to 1,$$

因此，有效秩可以任意地接近于下界 1。

(3) 对于迹函数 $g(\boldsymbol{\Sigma}) = \operatorname{tr}(\boldsymbol{\Sigma})$，其为矩阵元素的线性组合，容易知道，是连续的；对于算子范数 $h(\boldsymbol{\Sigma}) = \|\boldsymbol{\Sigma}\|$，利用引理 L4.1.14 (Weyl 不等式) (Weyl 不等式)，可得特征值为矩阵元素的 Lipschitz 连续函数；因此，有效秩函数 $r(\boldsymbol{\Sigma}) = g(\boldsymbol{\Sigma})/h(\boldsymbol{\Sigma})$ 是连续的。

(相比之下，普通秩函数在矩阵趋于奇异时会发生跳变 (例如当 $\operatorname{diag}(1, \varepsilon) \to \operatorname{diag}(1, 0)$ 时，秩从 2 变为 1)，此性质体现了有效秩的稳定性。)

(4) 设 $\boldsymbol{X}$ 的取值空间为 $S \subset \mathbb{R}^n$，满足 $\dim(S) = k$，则对于任意的 $\boldsymbol{v} \in S^\perp$，$\langle \boldsymbol{X}, \boldsymbol{v} \rangle = 0$，因此

$$\boldsymbol{v}^\top \boldsymbol{\Sigma} \boldsymbol{v} = \mathrm{E}[\boldsymbol{v}^\top \boldsymbol{X} \boldsymbol{X}^\top \boldsymbol{v}] = \mathrm{E}[\langle \boldsymbol{X}, \boldsymbol{v} \rangle^2] = 0,$$

从而 $S^\perp \subset \operatorname{null}(\boldsymbol{\Sigma})$，满足

$$\operatorname{nullity}(\boldsymbol{\Sigma}) \geqslant \dim(S^\perp) = n - k,$$

从而

$$\operatorname{rank}(\boldsymbol{\Sigma}) = n - \operatorname{nullity}(\boldsymbol{\Sigma}) \leqslant n - (n-k) = k,$$

利用 (1) 的结论，可得 $r(\boldsymbol{\Sigma}) \leqslant \operatorname{rank}(\boldsymbol{\Sigma}) \leqslant k$。

30 [**从 Parseval 框架中采样**] 设 $(u_1, \cdots, u_m) \in \mathbb{R}^n$ 为等范 Parseval 框架，即对于任意的 $\boldsymbol{x} \in \mathbb{R}^n$，满足 $\sum_{i=1}^m \langle \boldsymbol{x}, u_i \rangle^2 = \|\boldsymbol{x}\|_2^2$，其中 $\|u_i\|_2^2 = n/m$。

令 $1 \leqslant k \leqslant m$，$S \subset \{1, \cdots, m\}$ 为自 $\{1, \cdots, m\}$ 均匀无放回选取的 k 个指标构成的随机子集。证明：当 $k \gtrsim n \ln n$ 时，$\{u_i\}_{i \in S}$ 构成“近似框架” (w.h.p.)，即存在 $\varepsilon \in (0, 1)$，使得对于任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，

$$(1-\varepsilon)\|\boldsymbol{x}\|_2^2 \leqslant \frac{m}{k} \sum_{i \in S} \langle \boldsymbol{x}, u_i \rangle^2 \leqslant (1+\varepsilon)\|\boldsymbol{x}\|_2^2$$

或者等价地，定义样本框架算子为

$$\boldsymbol{A}_S = \frac{m}{k} \sum_{i \in S} u_i u_i^\top,$$

则 $\|\boldsymbol{A}_S - \boldsymbol{I}_n\| \leqslant \varepsilon$。

注释 本题即为 Rudelson 引理的等范情形的特例。

1999 年，Rudelson 发表论文 Random vectors in the isotropic position。

当时并未发现矩阵 Bernstein 不等式，Rudelson 利用了非交换 Khintchine 不等式配合对称化技术。

证明 记 $Y_i = u_i u_i^\top$，则 $\|Y_i\| = n/m$，

$$\sum_{i=1}^m Y_i = \boldsymbol{I}_n。$$

对于均匀无放回选取的固定大小样本，矩阵 Chernoff 不等式的无放回版本给出

$$\mathrm{P}\left\{ \left\| \frac{m}{k} \sum_{i \in S} Y_i - \boldsymbol{I}_n \right\| \geqslant \varepsilon \right\} \leqslant 2n \exp\left(-c \frac{\varepsilon^2 k}{n} \right)。$$

令 $k \geqslant Cn \ln n$，并令 C 足够大，即可使右侧小于任一给定的常数，从而以高概率有 $\|\boldsymbol{A}_S - \boldsymbol{I}_n\| \leqslant \varepsilon$。

31 [**一般独立行的随机矩阵**] 设 $n \geqslant 2$，$K \geqslant 1$，$\boldsymbol{A} \in \mathbb{R}^{m \times n}$ 为随机矩阵，其行向量 $\boldsymbol{A}_1, \cdots, \boldsymbol{A}_m \in \mathbb{R}^n$ 为相互独立, 各向同性的。

证明：若 $\|\boldsymbol{A}_i\|_2 \leqslant K\sqrt{n}$，$m \geqslant CK^2t^2n\ln n$，则对于任意的 $t \geqslant 1$，$\boldsymbol{A}$ 的最小奇异值 $s_n(\boldsymbol{A})$, 最大奇异值 $s_1(\boldsymbol{A})$ 以高概率满足

$$\mathcal{E}_t = \left\{\sqrt{m} - Kt\sqrt{n\ln n} \leqslant s_n(\boldsymbol{A}) \leqslant s_1(\boldsymbol{A}) \leqslant \sqrt{m} + Kt\sqrt{n\ln n}\right\},$$

$$\mathrm{P}(\mathcal{E}_t) \geqslant 1 - 2n^{-ct^2}。 \qquad (c>0)$$

证明 记样本协方差矩阵

$$\boldsymbol{\Sigma}_m = \frac{1}{m}\boldsymbol{A}^\top\boldsymbol{A},$$

注意到 $s_i^2(\boldsymbol{A}) = \lambda_i(\boldsymbol{A}^\top\boldsymbol{A})$，则

$$s_i(\boldsymbol{A}) = \sqrt{m\cdot\lambda_i(\boldsymbol{\Sigma}_m)}。$$

若 $\|\boldsymbol{\Sigma}_m - \boldsymbol{I}_n\| \leqslant \varepsilon$ (w.h.p.)，则根据扰动理论，可得

$$\sqrt{m(1-\varepsilon)} \leqslant s_n(\boldsymbol{A}) \leqslant s_1(\boldsymbol{A}) \leqslant \sqrt{m(1+\varepsilon)},$$

即

$$\sqrt{m}(1-\varepsilon) \leqslant s_n(\boldsymbol{A}) \leqslant s_1(\boldsymbol{A}) \leqslant \sqrt{m}(1+\varepsilon), \qquad (\mathrm{I})$$

我们只需证明当 $\varepsilon \asymp Kt\sqrt{\frac{n\ln n}{m}}$ 时，上述事件至少 $1-2n^{-ct^2}$ 的概率发生。

- 根据矩阵 Bernstein 不等式

构造中心化随机矩阵 $\boldsymbol{Z}_i = \boldsymbol{A}_i^\top\boldsymbol{A}_i - \boldsymbol{I}_n$，则

$$\boldsymbol{\Sigma}_m - \boldsymbol{I}_n = \frac{1}{m}\sum_{i=1}^m \boldsymbol{Z}_i。$$

对于 sub-Exponential 上界 R，

$$\|\boldsymbol{Z}_i\| = \|\boldsymbol{A}_i^\top\boldsymbol{A}_i - \boldsymbol{I}_n\| \leqslant \|\boldsymbol{A}_i\|_2^2 + 1 \leqslant K^2n + 1 \leqslant 2K^2n,$$

此时令 $R = 2K^2n$。

对于方差参数 σ^2，由于

$$\mathrm{E}[(\boldsymbol{A}_i^\top\boldsymbol{A}_i)^2] \preccurlyeq K^2n\mathrm{E}[\boldsymbol{A}_i^\top\boldsymbol{A}_i] = K^2n\boldsymbol{I}_n,$$

因此

$$\sigma^2 = \left\|\sum_{i=1}^m \mathrm{E}[\boldsymbol{Z}_i^2]\right\| = m\|\mathrm{E}[(\boldsymbol{A}_i^\top\boldsymbol{A}_i - \boldsymbol{I}_n)^2]\| = m\|\mathrm{E}[(\boldsymbol{A}_i^\top\boldsymbol{A}_i)^2] - \boldsymbol{I}_n\| \leqslant mK^2n。$$

如此，利用定理 T5.4.1 (矩阵 Bernstein 不等式) (矩阵 Bernstein 不等式)，可得对于任意的 $\varepsilon > 0$，

$$\mathrm{P}\{\|\boldsymbol{\Sigma}_m - \boldsymbol{I}_n\| \geqslant \varepsilon\} \leqslant 2n\exp\left(-c\min\left(\frac{m^2\varepsilon^2}{mK^2n}, \frac{m\varepsilon}{2K^2n}\right)\right)。$$

令 $\varepsilon = C_0Kt\sqrt{\frac{n\ln n}{m}}$，其中 C_0 为足够大的绝对常数。根据 $m \geqslant CK^2t^2n\ln n$，并令 C 足够大，可得 $0 < \varepsilon \leqslant 1$，

$$\frac{m\varepsilon^2}{K^2n} = C_0^2t^2\ln n,$$

$$\frac{m\varepsilon}{2K^2n} \geqslant \frac{C_0}{2}t^2\ln n.$$

因此，调整绝对常数后，记

$$\mathcal{F}_t = \left\{\|\boldsymbol{\Sigma}_m - \boldsymbol{I}_n\| \leqslant Kt\sqrt{\frac{n\ln n}{m}}\right\},$$

$$\mathrm{P}(\mathcal{F}_t) \geqslant 1 - 2n^{-ct^2}。$$

由于 $\sqrt{1-\varepsilon} \geqslant 1-\varepsilon$，将其代入于 (I)，可得

$$\sqrt{m} - Kt\sqrt{n\ln n} \leqslant s_n(\boldsymbol{A}) \leqslant s_1(\boldsymbol{A}) \leqslant \sqrt{m} + Kt\sqrt{n\ln n}。$$

32 [**矩阵草图**] 一些矩阵 $\boldsymbol{A} \in \mathbb{R}^{N\times n}$ 规模过大，难以直接计算特征值，特征向量。

一种常用的处理技巧是子采样 (Subsampling)，通过随机选取行或列来构造一个小规模矩阵。

设 $\boldsymbol{A}$ 的行向量为 $\boldsymbol{a}_1,\cdots,\boldsymbol{a}_N\in\mathbb{R}^n$，假设行范数相同，即 $\|\boldsymbol{a}_j\|_2^2=\sigma^2$。通过均匀采样 (有放回地) 选择 m 个指标 $j_1,\cdots,j_m$，构造 $\boldsymbol{B}\in\mathbb{R}^{m\times n}$，其行向量为

$$\boldsymbol{b}_k=\sqrt{\frac{N}{m}}\boldsymbol{a}_{j_k}。$$

证明：当 $m\geqslant Cn\ln n$ 时，以高概率，使得

$$\mathcal{G}=\left\{\max_{i=1,\cdots,n}\left|s_i(\boldsymbol{A})^2-s_i(\boldsymbol{B})^2\right|\leqslant 0.1s_1(\boldsymbol{A})^2\right\},$$

$$\mathrm{P}(\mathcal{G})\geqslant 0.9。$$

证明 容易知道，

$$\boldsymbol{A}^\top\boldsymbol{A}=\sum_{j=1}^N\boldsymbol{a}_j\boldsymbol{a}_j^\top,$$

$$\boldsymbol{B}^\top\boldsymbol{B}=\sum_{k=1}^m\boldsymbol{b}_k\boldsymbol{b}_k^\top=\sum_{k=1}^m\left(\sqrt{\frac{N}{m}}\boldsymbol{a}_{j_k}\right)\left(\sqrt{\frac{N}{m}}\boldsymbol{a}_{j_k}\right)^\top=\frac{N}{m}\sum_{k=1}^m\boldsymbol{a}_{j_k}\boldsymbol{a}_{j_k}^\top,$$

其中 j_k 为从 $\{1,\cdots,N\}$ 独立均匀抽取的指标，则

$$\mathrm{E}[\boldsymbol{B}^\top\boldsymbol{B}]=\frac{N}{m}\sum_{k=1}^m\mathrm{E}[\boldsymbol{a}_{j_k}\boldsymbol{a}_{j_k}^\top]=\frac{N}{m}\cdot m\cdot\left(\frac{1}{N}\sum_{j=1}^N\boldsymbol{a}_j\boldsymbol{a}_j^\top\right)=\boldsymbol{A}^\top\boldsymbol{A}。$$

令

$$\boldsymbol{X}_k=\frac{N}{m}\boldsymbol{a}_{j_k}\boldsymbol{a}_{j_k}^\top,$$

中心化随机矩阵 $\boldsymbol{Z}_k=\boldsymbol{X}_k-\frac{1}{m}\boldsymbol{A}^\top\boldsymbol{A}$，则 $\boldsymbol{B}^\top\boldsymbol{B}-\boldsymbol{A}^\top\boldsymbol{A}=\sum_{k=1}^m\boldsymbol{Z}_k$。对于 sub-Exponential 上界 R，由于 $\|\boldsymbol{a}_j\|_2^2=\sigma^2$，因此

$$\|\boldsymbol{X}_k\|=\frac{N}{m}\|\boldsymbol{a}_{j_k}\|_2^2=\frac{N\sigma^2}{m},\quad\left\|\frac{1}{m}\boldsymbol{A}^\top\boldsymbol{A}\right\|\leqslant\frac{N}{m}\max_j\|\boldsymbol{a}_j\|_2^2=\frac{N\sigma^2}{m},$$

从而

$$\|\boldsymbol{Z}_k\|\leqslant\|\boldsymbol{X}_k\|+\left\|\frac{1}{m}\boldsymbol{A}^\top\boldsymbol{A}\right\|\leqslant\frac{2N\sigma^2}{m},$$

此时令 $R=2N\sigma^2/m$。

对于方差参数 σ_{Bern}^2，由于

$$\mathrm{E}[\boldsymbol{X}_1^2]=\mathrm{E}\left[\left(\frac{N}{m}\boldsymbol{a}_{j_1}\boldsymbol{a}_{j_1}^\top\right)^2\right]=\frac{N^2}{m^2}\mathrm{E}\|\boldsymbol{a}_{j_1}\|_2^2\boldsymbol{a}_{j_1}\boldsymbol{a}_{j_1}^\top=\frac{N^2\sigma^2}{m^2}\cdot\frac{1}{N}\sum_{j=1}^N\boldsymbol{a}_j\boldsymbol{a}_j^\top=\frac{N\sigma^2}{m^2}\boldsymbol{A}^\top\boldsymbol{A},$$

因此

$$\sigma_{\mathrm{Bern}}^2=\left\|\sum_{k=1}^m\mathrm{E}[\boldsymbol{Z}_k^2]\right\|=m\|\mathrm{E}[\boldsymbol{Z}_1^2]\|\leqslant m\cdot\frac{N\sigma^2}{m^2}\|\boldsymbol{A}^\top\boldsymbol{A}\|=\frac{N\sigma^2}{m}\|\boldsymbol{A}^\top\boldsymbol{A}\|。$$

由于 $\mathrm{tr}(\boldsymbol{A}^\top\boldsymbol{A})=N\sigma^2$，$\boldsymbol{A}^\top\boldsymbol{A}$ 的秩至多为 n，

$$\|\boldsymbol{A}^\top\boldsymbol{A}\|\geqslant\frac{N\sigma^2}{n}。$$

如此，利用矩阵 Bernstein 不等式，可得对于任意的 $\varepsilon>0$，

$$\mathrm{P}\{\|\boldsymbol{B}^\top\boldsymbol{B}-\boldsymbol{A}^\top\boldsymbol{A}\|\geqslant\varepsilon\|\boldsymbol{A}^\top\boldsymbol{A}\|\}\leqslant 2n\exp\left(-c\min\left(\frac{\varepsilon^2\|\boldsymbol{A}^\top\boldsymbol{A}\|^2}{\sigma_{\mathrm{Bern}}^2},\frac{\varepsilon\|\boldsymbol{A}^\top\boldsymbol{A}\|}{R}\right)\right),$$

令 $\varepsilon=0.1$。当 $0<\varepsilon\leqslant 1$ 时，上述下界使指数的最小值至少为 $c\varepsilon^2m/n$。因此令 $m\geqslant Cn\ln n$，并令 C 足够大，可使概率

上界不超过 0.1，

$$\mathrm{P}\{\|\boldsymbol{B}^\top\boldsymbol{B}-\boldsymbol{A}^\top\boldsymbol{A}\|\geqslant\varepsilon\|\boldsymbol{A}^\top\boldsymbol{A}\|\}\leqslant 0.1,$$

从而根据 Weyl 不等式 (或扰动理论)，可得

$$\max_i|s_i(\boldsymbol{B})^2-s_i(\boldsymbol{A})^2|\leqslant\|\boldsymbol{B}^\top\boldsymbol{B}-\boldsymbol{A}^\top\boldsymbol{A}\|\leqslant 0.1\|\boldsymbol{A}^\top\boldsymbol{A}\|=0.1s_1(\boldsymbol{A})^2。$$

6 二次型，对称化，收缩原理

要点梳理

Section 6.1 解耦 Q6.1 ∼ Q6.4

定理 6.1.1 (解耦)

设 $\boldsymbol{X}$ 为零均值随机矩阵，其元素是相互独立的，$\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 满足 $\operatorname{diag}(\boldsymbol{A}) = \boldsymbol{0}$，则

$$\mathrm{E}[|\boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{X}|] \leqslant 4\mathrm{E}[|\boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{Y}|],$$

其中 $\boldsymbol{Y}$ 为 $\boldsymbol{X}$ 的独立副本。

注记 6.1.2 (无对角项假设)

条件 $\operatorname{diag}(\boldsymbol{A}) = \boldsymbol{0}$ 关于定理 T6.1.1 (解耦) 是必要的。例如，令 $F(x) = x$，$\boldsymbol{A} = \boldsymbol{I}_n$，则左侧为 $\mathrm{E}[\boldsymbol{X}^\top \boldsymbol{X}] = \sum_{i=1}^n \mathrm{E}[X_i^2] > 0$，右侧为 $4\mathbb{E}[\boldsymbol{X}^\top \boldsymbol{Y}] = 0$，上述结论不成立。

但是，解耦定理可以自然推广到含有对角项的一般矩阵。对于任意的 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ (无需 $\operatorname{diag}(\boldsymbol{A}) = \boldsymbol{0}$)，

$$\mathrm{E}\left[F\left(\sum_{i\neq j} a_{ij}X_iX_j\right)\right] \leqslant \mathrm{E}\left[F\left(4\sum_{i,j} a_{ij}X_iX_j\right)\right]。$$

Section 6.2 Hanson-Wright 不等式 Q6.5 ∼ Q6.11

命题 6.2.1 (sub-Gaussian 随机向量的范数)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为随机向量，其元素为相互独立, 中心化的 K-sub-Gaussian 随机变量，则

$$\mathrm{E}\|\boldsymbol{X}\|_2 \leqslant \sqrt{n}，\ \|\|\boldsymbol{X}\|_2 - \sqrt{n}\|_{\psi_2} \leqslant CK^2。$$

定理 6.2.2 (Hanson–Wright 不等式)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为随机向量，其元素为相互独立, 中心化的 K-sub-Gaussian 随机变量，则对于任意的 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$, $t \geqslant 0$，

$$\mathrm{P}\{|\boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{X}]| \geqslant t\} \leqslant 2\exp\left[-c\min\left(\frac{t^2}{K^4\|\boldsymbol{A}\|_F^2}, \frac{t}{K^2\|\boldsymbol{A}\|}\right)\right]。$$

引理 6.2.3 (Gaussian 替换)

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量，其元素为相互独立, 中心化的 K-sub-Gaussian 随机变量，则当 $|\lambda|\leqslant c/(K^2\|\boldsymbol{A}\|)$ 时，

$$\mathrm{E}[\exp(\lambda\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X})]\leqslant\mathrm{E}[\exp(C\lambda K^2\boldsymbol{g}^\top\boldsymbol{A}\boldsymbol{g})],$$

其中 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

引理 6.2.4 (Gaussian 二次型的矩母函数)

设 $\boldsymbol{g},\boldsymbol{g}'$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，$\boldsymbol{A}\in\mathbb{R}^{n\times n}$，则当 $|\lambda|\leqslant 1/2\|\boldsymbol{A}\|$ 时，

$$\mathrm{E}[\exp(\lambda\boldsymbol{g}^\top\boldsymbol{A}\boldsymbol{g}')]\leqslant\exp(\lambda^2\|\boldsymbol{A}\|_F^2)。$$

Section 6.3 对称化 Q6.12 ∼ Q6.22

引理 6.3.1 (构造对称分布)

设 X 为随机变量，$\varepsilon\sim$ Rademacher，则：

(1) $\varepsilon X\overset{d}{=}\varepsilon|X|$ 是对称的。

(2) 若 X 是对称的，则 $\varepsilon X\overset{d}{=}\varepsilon|X|\overset{d}{=}X$。

(3) 若 X' 为 X 的独立副本，则 $X-X'$ 是对称的。

引理 6.3.2 (对称化)

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为相互独立的零均值随机向量，$\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，则

$$\frac{1}{2}\mathrm{E}\left\|\sum_i\varepsilon_i\boldsymbol{X}_i\right\|\leqslant\mathrm{E}\left\|\sum_i\boldsymbol{X}_i\right\|\leqslant 2\mathrm{E}\left\|\sum_i\varepsilon_i\boldsymbol{X}_i\right\|。$$

Section 6.4 非 i.i.d. 元素的随机矩阵 Q6.23 ∼ Q6.30

定理 6.4.1 (非同分布元素随机矩阵的范数)

设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 为对称随机矩阵，其对角线及以上元素为相互独立的零均值随机变量，记 $\boldsymbol{a}_i$ 为 $\boldsymbol{A}$ 的行向量，则

$$\mathrm{E}\left[\max_i\|\boldsymbol{a}_i\|_2\right]\leqslant\mathrm{E}\|\boldsymbol{A}\|\leqslant C\sqrt{\ln n}\cdot\mathrm{E}\left[\max_i\|\boldsymbol{a}_i\|_2\right]。$$

Section 6.5 矩阵补全 Q6.31 ∼ Q6.32

定理 6.5.1 (矩阵补全)

设 $\boldsymbol{X}\in\mathbb{R}^{n\times n}$ 为秩 r 矩阵，其相干度满足以 $\mu(\boldsymbol{X})\leqslant\mu$。从 $\boldsymbol{X}$ 均匀随机地观测到 m 个位置的元素，当 $m\geqslant C\mu^2rn\ln^2 n$ 时，通过核范数极小化，

$$\min_{\boldsymbol{M}\in\mathbb{R}^{n\times n}}\|\boldsymbol{M}\|_*\quad\text{s.t.}\quad m_{ij}=X_{ij},$$

能够以高概率 $1-1/n$ 恢复原始矩阵 $\hat{\boldsymbol{M}}=\boldsymbol{X}$。

Section 6.6 收缩原理 Q6.33 ∼ Q6.38

定理 6.6.1 (收缩原理)

设 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N$ 为确定性向量，$\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$，$\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，则

$$\mathrm{E}\left\|\sum_i a_i\varepsilon_i\boldsymbol{x}_i\right\|\leqslant\|\boldsymbol{a}\|_\infty\cdot\mathrm{E}\left\|\sum_i\varepsilon_i\boldsymbol{x}_i\right\|。$$

引理 6.6.2 (用 Gaussian 随机变量对称化)

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为相互独立的零均值随机向量，$g_1,\cdots,g_N$ i.i.d. $\sim N(0,1)$ 独立于 $\boldsymbol{X}_i$，则

$$\frac{c}{\sqrt{\ln N}}\mathrm{E}\left\|\sum_i g_i\boldsymbol{X}_i\right\|\leqslant\mathrm{E}\left\|\sum_i\boldsymbol{X}_i\right\|\leqslant 3\mathrm{E}\left\|\sum_i g_i\boldsymbol{X}_i\right\|。$$

习题解答

1 [**包含对角项的解耦**] 正如注记 R6.1.2 (无对角项假设) 所述，通常下，定理 T6.1.1 (解耦) 的无对角项 (diagonal-free) 假设不可移除的。但是，我们可以通过放宽常数，将对角项纳入右侧的表达式。

设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，$\{X_n\}$ 为独立同分布的零均值随机变量，F 为凸函数。证明：

$$\mathrm{E}\left[F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)\right]\leqslant\mathrm{E}\left[F\left(4\sum_{i,j}a_{ij}X_iX_j'\right)\right],$$

其中 $\{X_n'\}$ 为 $\{X_n\}$ 的独立副本。

注释 此类解耦不等式的证明遵循固定的套路：

1. 引入独立的 Bernoulli 选择器，将不含对角项的求和改写为选择器化的期望；
2. 利用 Jensen 不等式，将凸函数 F 移入期望内部，可得首层上界；
3. 根据选择器的取值，将指标集划分为 $I\sqcup I^c$，保证求和两侧的随机变量独立，从而用独立副本替换其中一侧而不改变期望，完成解耦；
4. 最后引入第二组独立副本构造辅助变量 U_i,V_j，其分别同分布于 X_i,X_j'，经条件期望可以消去交叉项，将选择器化的期望补全为目标形式。

证明 • 引入 Bernoulli 选择器

引入独立于 $\{X_n\}$ 的随机变量 $\delta_1,\cdots,\delta_n$ i.i.d. $\sim B(1/2)$，则

$$\mathrm{E}_\delta[\delta_i(1-\delta_j)]=\begin{cases}1/4, & i\neq j,\\ 0, & i=j\end{cases},$$

因此

$$\sum_{i\neq j}a_{ij}X_iX_j=4\mathrm{E}_\delta\left[\sum_{i,j}a_{ij}X_i\delta_iX_j(1-\delta_j)\right],$$

从而利用 Jensen 不等式，可得

$$F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)=F\left(\mathrm{E}_\delta\left[4\sum_{i,j}\delta_i(1-\delta_j)a_{ij}X_iX_j\right]\right)\leqslant\mathrm{E}_\delta\left[F\left(4\sum_{i,j}\delta_i(1-\delta_j)a_{ij}X_iX_j\right)\right],$$

两侧对 X 取期望，可得

$$\mathrm{E}_X\left[F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)\right]\leqslant\mathrm{E}_{X,\delta}\left[F\left(4\sum_{i,j}\delta_i(1-\delta_j)a_{ij}X_iX_j\right)\right]。\tag{I}$$

• 解耦相依性

令 $I=\{i:\delta_i=1\}$，$I^c=\{j:\delta_j=0\}$，则由于 $\delta_i(1-\delta_j)\neq 0$ 恰于 $i\in I$, $j\in I^c$ 时成立，此时 (I) 的右侧求和项为

$$\sum_{i,j}\delta_i(1-\delta_j)a_{ij}X_iX_j=\sum_{i\in I}\sum_{j\in I^c}a_{ij}X_iX_j;$$

由于 $I\cap I^c=\varnothing$，因此 $\{X_i\}_{i\in I}\perp\{X_j\}_{j\in I^c}$。

引入 $\{X'_k\}$ 作为 $\{X_k\}$ 的独立副本，则 (I) 的右侧为

$$\begin{aligned}\mathrm{E}_{X,\delta}\left[F\left(4\sum_{i,j}\delta_i(1-\delta_j)a_{ij}X_iX_j\right)\right] &= \mathrm{E}_{X,\delta}\left[F\left(4\sum_{i\in I}\sum_{j\in I^c}a_{ij}X_iX_j\right)\right]\\ &= \mathrm{E}_{X,X',\delta}\left[F\left(4\sum_{i\in I}\sum_{j\in I^c}a_{ij}X_iX'_j\right)\right]\\ &= \mathrm{E}_{X,X',\delta}\left[F\left(4\sum_{i,j}a_{ij}X_i\delta_iX'_j(1-\delta_j)\right)\right],\end{aligned}$$

将其代入于 (I)，可得

$$\mathrm{E}_X\left[F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)\right]\leqslant \mathrm{E}_{X,X',\delta}\left[F\left(4\sum_{i,j}a_{ij}X_i\delta_iX'_j(1-\delta_j)\right)\right]。\tag{II}$$

- 通过条件期望补全对角项

引入 $\{X''_k\}$ 作为 $\{X_k\},\{X'_k\}$ 的独立副本，定义辅助随机变量列

$$U_i=X_i\delta_i+X''_i(1-\delta_i)，\ V_j=X'_j(1-\delta_j)+X''_j\delta_j,$$

则 $\{U_i\}\overset{d}{=}\{X_i\}$，$\{V_j\}\overset{d}{=}\{X'_j\}$，

$$U_iV_j=X_i\delta_iX'_j(1-\delta_j)+X_i\delta_iX''_j\delta_j+X''_i(1-\delta_i)X'_j(1-\delta_j)+X''_i(1-\delta_i)X''_j\delta_j,$$

两侧对 X'' 取条件期望 (利用 $\mathrm{E}[X'']=0$)，

$$\mathrm{E}_{X''}[U_iV_j\mid X,X',\delta]=X_i\delta_iX'_j(1-\delta_j)+0+0+0=X_i\delta_iX'_j(1-\delta_j),$$

利用 Jensen 不等式，可得

$$F\left(4\sum_{i,j}a_{ij}X_i\delta_iX'_j(1-\delta_j)\right)\leqslant \mathrm{E}_{X''}\left[F\left(4\sum_{i,j}a_{ij}U_iV_j\right)\right],$$

对 X,X',δ 取全期望，

$$\mathrm{E}_{X,X',\delta}\left[F\left(4\sum_{i,j}a_{ij}X_i\delta_iX'_j(1-\delta_j)\right)\right]\leqslant \mathrm{E}_{X,X',\delta,X''}\left[F\left(4\sum_{i,j}a_{ij}U_iV_j\right)\right]。\tag{III}$$

如此，联立 (II)(III)，可得

$$\mathrm{E}_X\left[F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)\right]\leqslant \mathrm{E}_{X,X',\delta,X''}\left[F\left(4\sum_{i,j}a_{ij}U_iV_j\right)\right],$$

即

$$\mathrm{E}\left[F\left(\sum_{i\neq j}a_{ij}X_iX_j\right)\right]\leqslant \mathrm{E}\left[F\left(4\sum_{i,j}a_{ij}X_iX'_j\right)\right]。$$

2 [L^p **范数与 sub-Gaussian 解耦**] 设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，$\{X_n\}$ 为相互独立的零均值随机变量，$\{X'_n\}$ 为 $\{X_n\}$ 的独立副本。

(1) 证明：对于任意的 $p\in[1,\infty)$，

$$\left\|\sum_{i,j:i\neq j}a_{ij}X_iX_j\right\|_{L^p}\leqslant 4\left\|\sum_{i,j}a_{ij}X_iX'_j\right\|_{L^p}。$$

(2) 证明：上述不等式对于 ψ_2 范数亦成立，即

$$\left\|\sum_{i,j:i\neq j}a_{ij}X_iX_j\right\|_{\psi_2}\leqslant 4\left\|\sum_{i,j}a_{ij}X_iX'_j\right\|_{\psi_2}。$$

证明 (1) 根据习题 Q6.1 (包含对角项的解耦)，令 $F(x)=|x|^p$，则

$$\begin{aligned}\mathrm{E}\left[\left|\sum_{i\neq j}a_{ij}X_iX_j\right|^p\right]&\leqslant\mathrm{E}\left[\left|4\sum_{i,j}a_{ij}X_iX_j'\right|^p\right]\\&=4^p\cdot\mathrm{E}\left[\left|\sum_{i,j}a_{ij}X_iX_j'\right|^p\right],\end{aligned}$$

两侧开 p 次方，

$$\left(\mathrm{E}\left[\left|\sum_{i\neq j}a_{ij}X_iX_j\right|^p\right]\right)^{1/p}\leqslant 4\cdot\left(\mathrm{E}\left[\left|\sum_{i,j}a_{ij}X_iX_j'\right|^p\right]\right)^{1/p},$$

即

$$\left\|\sum_{i\neq j}a_{ij}X_iX_j\right\|_{L^p}\leqslant 4\left\|\sum_{i,j}a_{ij}X_iX_j'\right\|_{L^p}。$$

(2) 回顾 ψ_2 范数的定义为

$$\|Z\|_{\psi_2}=\sup_{p\geqslant 1}\frac{\|Z\|_{L^p}}{\sqrt{p}},$$

两侧同除以 $\sqrt{p}$，之后取上确界，

$$\sup_{p\geqslant 1}\frac{1}{\sqrt{p}}\left\|\sum_{i\neq j}a_{ij}X_iX_j\right\|_{L^p}\leqslant\sup_{p\geqslant 1}\left(4\cdot\frac{1}{\sqrt{p}}\left\|\sum_{i,j}a_{ij}X_iX_j'\right\|_{L^p}\right),$$

即

$$\left\|\sum_{i\neq j}a_{ij}X_iX_j\right\|_{\psi_2}\leqslant 4\left\|\sum_{i,j}a_{ij}X_iX_j'\right\|_{\psi_2}。$$

3 [**向量, 空间解耦**] 设 $\{X_n\}$ 为相互独立的零均值随机变量，$\{X_n'\}$ 为其独立副本。

(1) 设 $\{\boldsymbol{v}_{ij}\}_{i,j=1}^n$ 定义于向量空间 V。证明：对于任意的凸函数 $F:V\to\mathbb{R}$，

$$\mathrm{E}\left[F\left(\sum_{i\neq j}\boldsymbol{v}_{ij}X_iX_j\right)\right]\leqslant\mathrm{E}\left[F\left(4\sum_{i,j}\boldsymbol{v}_{ij}X_iX_j'\right)\right]。$$

(2) (对内积项解耦) 设 $\{\boldsymbol{X}_i\}_{i=1}^n\subset\mathbb{R}^N$ 为相互独立的零均值随机向量，$\boldsymbol{A}\in\mathbb{R}^{n\times n}$。证明：对于任意的凸函数 $F:\mathbb{R}\to\mathbb{R}$，

$$\mathrm{E}\left[F\left(\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]\leqslant\mathrm{E}\left[F\left(4\sum_{i,j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j'\rangle\right)\right]。$$

(3) (对外积项解耦) 设 $\{\boldsymbol{X}_i\}_{i=1}^n\subset\mathbb{R}^N$ 为相互独立的零均值随机向量，$\boldsymbol{A}\in\mathbb{R}^{n\times n}$。证明：对于任意的凸函数 $F:\mathbb{R}^{N\times N}\to\mathbb{R}$，

$$\mathrm{E}\left[F\left(\sum_{i\neq j}a_{ij}\boldsymbol{X}_i\boldsymbol{X}_j^\top\right)\right]\leqslant\mathrm{E}\left[F\left(4\sum_{i,j}a_{ij}\boldsymbol{X}_i(\boldsymbol{X}_j')^\top\right)\right]。$$

证明 (1) (仅需将习题 Q6.1 (包含对角项的解耦) 的 a_{ij} 替换为 $\boldsymbol{v}_{ij}$ 即可。)

(2) 引入 Bernoulli 选择器，则

$$\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle=4\mathrm{E}_\delta\left[\sum_{i,j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle\delta_i(1-\delta_j)\right],$$

之后利用 Jensen 不等式，将 E_δ 移至 F 的外侧，可得

$$\mathrm{E}_X\left[F\left(\sum_{i\neq j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]\leqslant \mathrm{E}_{X,\delta}\left[F\left(4\sum_{i,j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\delta_i(1-\delta_j)\right)\right]。\tag{I}$$

定义指标集 $I=\{i:\delta_i=1\}$，则

$$\sum_{i,j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\delta_i(1-\delta_j)=\sum_{i\in I}\sum_{j\in I^c}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle。$$

之后将 $\{\boldsymbol{X}_j\}_{j\in I^c}$ 替换为独立副本 $\{\boldsymbol{X}'_j\}_{j\in I^c}$，

$$\mathrm{E}_X\left[F\left(4\sum_{i\in I}\sum_{j\in I^c}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]=\mathrm{E}_{X,X'}\left[F\left(4\sum_{i\in I}\sum_{j\in I^c}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\right)\right],$$

将其代入于 (I)，可得

$$\mathrm{E}_X\left[F\left(\sum_{i\neq j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]\leqslant \mathrm{E}_{X,X',\delta}\left[F\left(4\sum_{i,j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\delta_i(1-\delta_j)\right)\right]。\tag{II}$$

构造独立副本 $\{\boldsymbol{X}''_k\}$，定义辅助变量

$$\boldsymbol{U}_i=\boldsymbol{X}_i\delta_i+\boldsymbol{X}''_i(1-\delta_i),\ \boldsymbol{V}_j=\boldsymbol{X}'_j(1-\delta_j)+\boldsymbol{X}''_j\delta_j,$$

则

$$\langle \boldsymbol{U}_i,\boldsymbol{V}_j\rangle=\langle \boldsymbol{X}_i\delta_i+\boldsymbol{X}''_i(1-\delta_i),\boldsymbol{X}'_j(1-\delta_j)+\boldsymbol{X}''_j\delta_j\rangle,$$

两侧对 X'' 取条件期望，可得

$$\mathrm{E}_{X''}[\langle \boldsymbol{U}_i,\boldsymbol{V}_j\rangle\mid \boldsymbol{X},\boldsymbol{X}',\delta]=\langle \boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\delta_i(1-\delta_j)+0+0+0,$$

因此利用 Jensen 不等式，可得

$$F\left(4\sum_{i,j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\delta_i(1-\delta_j)\right)\leqslant \mathrm{E}_{X''}\left[F\left(4\sum_{i,j}a_{ij}\langle \boldsymbol{U}_i,\boldsymbol{V}_j\rangle\right)\right],$$

即

$$\mathrm{E}\left[F\left(\sum_{i\neq j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]\leqslant \mathrm{E}\left[F\left(4\sum_{i,j}a_{ij}\langle \boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\right)\right]。$$

(3) **解法一　解耦**

(直接将 X_i,X_j 替换为 $\boldsymbol{X}_i,\boldsymbol{X}_j^\top$ 即可，证略。)

解法二　变分表示

将矩阵空间视为有限维向量空间。以下利用变分表示把外积项写成线性泛函，并保持对偶变量同随机变量共同取值。

- 建立期望下的严格变分表示 (Rockafellar 对偶)

  根据 Rockafellar 积分泛函互换定理，可得

$$\mathrm{E}[F(\boldsymbol{S})]=\sup_{\boldsymbol{Y}\in L^\infty}\mathrm{E}[\mathrm{tr}(\boldsymbol{Y}^\top\boldsymbol{S})-F^*(\boldsymbol{Y})],\tag{III}$$

  其中

$$\begin{aligned}\mathrm{tr}(\boldsymbol{Y}^\top\boldsymbol{S})&=\mathrm{tr}\left(\boldsymbol{Y}^\top\sum_{i\neq j}a_{ij}\boldsymbol{X}_i\boldsymbol{X}_j^\top\right)\\&=\sum_{i\neq j}a_{ij}\,\mathrm{tr}(\boldsymbol{Y}^\top\boldsymbol{X}_i\boldsymbol{X}_j^\top)\\&=\sum_{i\neq j}a_{ij}\boldsymbol{X}_j^\top\boldsymbol{Y}^\top\boldsymbol{X}_i\end{aligned}$$

$$= \sum_{i \neq j} a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}_j \rangle。$$

(成功将矩阵外积问题转化为向量内积求和形式，之后的套路与常规解耦类似。)

- 引入 Bernoulli 选择器并利用 Sion 极大极小定理换序

  之后引入 Bernoulli 选择器 $\delta_1, \cdots, \delta_n$ i.i.d. $\sim B(1/2)$，此时

$$\mathrm{E}_{\boldsymbol{X}}[\mathrm{tr}(\boldsymbol{Y}^\top \boldsymbol{S})] = \mathrm{E}_{\boldsymbol{X}} \left[4 \, \mathrm{E}_\delta \sum_{i \neq j} \delta_i (1 - \delta_j) a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}_j \rangle \right],$$

  将其代入于 (III)，可得

$$\mathrm{E}[F(\boldsymbol{S})] = \sup_{\boldsymbol{Y} \in L^\infty} \mathrm{E}_\delta \mathrm{E}_{\boldsymbol{X}} \left[4 \sum_{i \neq j} \delta_i (1 - \delta_j) a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}_j \rangle - F^*(\boldsymbol{Y}) \right]。$$

  由于目标泛函关于测度 P_δ 是线性的 (凸的)，关于对偶变量 $\boldsymbol{Y}$ 是凹的 (根据 $-F^*$ 的凹性)，因此根据 Sion 极大极小定理，可得

$$\mathrm{E}[F(\boldsymbol{S})] \leqslant \mathrm{E}_\delta \left[\sup_{\boldsymbol{Y} \in L^\infty} \mathrm{E}_{\boldsymbol{X}} \left(4 \sum_{i \neq j} \delta_i (1 - \delta_j) a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}_j \rangle - F^*(\boldsymbol{Y}) \right) \right]。$$

- 利用条件独立性代换独立副本

  固定选择器 $\boldsymbol{\delta}$，指标集分解为 $I = \{i \mid \delta_i = 1\}$ 与 $I^c = \{j \mid \delta_j = 0\}$，且 $I \cap I^c = \emptyset$。根据 $\{\boldsymbol{X}_i\}_{i \in I} \perp \{\boldsymbol{X}_j\}_{j \in I^c}$ 的独立性，将 $\{\boldsymbol{X}_j\}_{j \in I^c}$ 替换为独立副本 $\{\boldsymbol{X}'_j\}_{j \in I^c}$，条件期望保持不变：

$$\begin{aligned}
&\mathrm{E}_{\boldsymbol{X}} \left[4 \sum_{i \neq j} \delta_i (1 - \delta_j) a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}_j \rangle \right] \\
&= \mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[4 \sum_{i,j} \delta_i (1 - \delta_j) a_{ij} \langle \boldsymbol{Y}^\top \boldsymbol{X}_i, \boldsymbol{X}'_j \rangle \right] \\
&= \mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[\mathrm{tr} \left(\boldsymbol{Y}^\top \left(4 \sum_{i,j} \delta_i (1 - \delta_j) a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right) \right]。
\end{aligned}$$

- 逆向应用 Rockafellar 对偶与条件期望收缩

  将上述结果代回 $\sup_{\boldsymbol{Y}}$，由 Legendre 变分表示的定义逆向还原，可得

$$\begin{aligned}
&\sup_{\boldsymbol{Y} \in L^\infty} \mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[\mathrm{tr} \left(\boldsymbol{Y}^\top \left(4 \sum_{i,j} \delta_i (1 - \delta_j) a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right) - F^*(\boldsymbol{Y}) \right] \\
&= \mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[F \left(4 \sum_{i,j} \delta_i (1 - \delta_j) a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right]。
\end{aligned}$$

  利用 Jensen 不等式，可得

$$\mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[F \left(4 \sum_{i,j} \delta_i (1 - \delta_j) a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right] \leqslant \mathrm{E}_{\boldsymbol{X}, \boldsymbol{X}'} \left[F \left(4 \sum_{i,j} a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right],$$

  两侧关于 δ 取条件期望，可得

$$\mathrm{E} \left[F \left(\sum_{i \neq j} a_{ij} \boldsymbol{X}_i \boldsymbol{X}_j^\top \right) \right] \leqslant \mathrm{E} \left[F \left(4 \sum_{i,j} a_{ij} \boldsymbol{X}_i (\boldsymbol{X}'_j)^\top \right) \right]。$$

4 [随机子矩阵范数的解耦] 设 $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ 满足 $\mathrm{diag}(\boldsymbol{A}) = \boldsymbol{0}$，Bernoulli 选择器 $\delta_1, \cdots, \delta_n$ i.i.d. $\sim B(p)$。令 $J = \{i : \delta_i = 1\}$ 为对应的随机指标子集，$J' = \{i : \delta'_i = 1\}$ 为 J 的独立副本指标集 (其中 $\{\delta'_i\}$ 与 $\{\delta_i\}$ 独立)。之后定义 $\boldsymbol{A}_{J,J}$

为 $\boldsymbol{A}$ 的行指标，列指标均取自于 J 的子矩阵，其 (i,j) 元素为 $a_{ij}\delta_i\delta_j$。证明：

$$\mathrm{E}\|\boldsymbol{A}_{J,J}\| \leqslant 4\mathrm{E}\|\boldsymbol{A}_{J,J'}\|,$$

其中 $\boldsymbol{A}_{J,J'}$ 为由行指标 J, 列指标 J' 所定义的子矩阵，其 (i,j) 元素为 $a_{ij}\delta_i\delta'_j$。

证明 (定理 T6.1.1 (解耦) 要求随机变量是零均值的。倘若强行对随机变量进行中心化，之后套用解耦定理，则产生的交叉项无法通过条件期望消除。我们考虑利用矩阵谱范数的投影收缩性质。)

设 $\boldsymbol{E}_{ij}$ 为标准基矩阵 (于 (i,j) 位置为 1，其他为 0)，则

$$\boldsymbol{A}_{J,J} = \sum_{i,j=1}^{n} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij} = \sum_{i\neq j} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij},\ \ \boldsymbol{A}_{J,J'} = \sum_{i\neq j} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}。$$

之后只需证明

$$\mathrm{E}_{\delta}\left\|\sum_{i\neq j} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij}\right\| \leqslant 4\mathrm{E}_{\delta,\delta'}\left\|\sum_{i\neq j} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}\right\|。$$

- 引入 Bernoulli 选择器

  引入独立于 $\{\varepsilon_i\}$ 的 $\eta_1,\cdots,\eta_n$ i.i.d. $\sim B(1/2)$，则

  $$\sum_{i\neq j} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij} = 4\mathrm{E}_{\eta}\left[\sum_{i\neq j} a_{ij}\delta_i\eta_i\delta_j(1-\eta_j)\boldsymbol{E}_{ij}\right],$$

  因此利用 Jensen 不等式，可得

  $$\left\|\sum_{i\neq j} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij}\right\| \leqslant \mathrm{E}_{\eta}\left\|4\sum_{i\neq j} a_{ij}\delta_i\eta_i\delta_j(1-\eta_j)\boldsymbol{E}_{ij}\right\|,$$

  两侧对 δ 取期望，

  $$\mathrm{E}_{\delta}\left\|\sum_{i\neq j} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij}\right\| \leqslant \mathrm{E}_{\delta,\eta}\left\|4\sum_{i\neq j} a_{ij}\delta_i\eta_i\delta_j(1-\eta_j)\boldsymbol{E}_{ij}\right\|。 \tag{I}$$

- 根据 Jensen 不等式, 解耦

  令 $I=\{i:\eta_i=1\}$，则由于 $\eta_i(1-\eta_j)\neq 0$ 恰于 $i\in I$, $j\in I^c$ 时成立，此时 (I) 的右侧求和项为

  $$\sum_{i\neq j} a_{ij}\delta_i\eta_i\delta_j(1-\eta_j)\boldsymbol{E}_{ij} = \sum_{i\in I}\sum_{j\in I^c} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij};$$

  由于 $I\cap I^c=\emptyset$，因此 $\{\delta_i\}_{i\in I}\perp\{\delta_j\}_{j\in I^c}$。

  引入 $\{\delta'_j\}_{j\in I^c}$ 为 $\{\delta_j\}_{j\in I^c}$ 的独立副本，则

  $$\begin{aligned}\mathrm{E}_{\delta,\eta}\left\|4\sum_{i\neq j} a_{ij}\delta_i\eta_i\delta_j(1-\eta_j)\boldsymbol{E}_{ij}\right\| &= \mathrm{E}_{\delta}\left\|4\sum_{i\in I}\sum_{j\in I^c} a_{ij}\delta_i\delta_j\boldsymbol{E}_{ij}\right\| \\ &= \mathrm{E}_{\delta,\delta'}\left\|4\sum_{i\in I}\sum_{j\in I^c} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}\right\|。\end{aligned} \tag{II}$$

  (之后我们仅需对 (II) 的右侧求和项进行界定，其仅为目标矩阵 $\boldsymbol{A}_{J,J'}=\sum_{i\neq j} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}$ 的截断。)

  定义对角投影矩阵 $\boldsymbol{P}_I=\mathrm{diag}(\eta_1,\cdots,\eta_n)$，$\boldsymbol{P}_{I^c}=\mathrm{diag}(1-\eta_1,\cdots,1-\eta_n)$，则

  $$\sum_{i\in I}\sum_{j\in I^c} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij} = \boldsymbol{P}_I\left(\sum_{i\neq j} a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}\right)\boldsymbol{P}_{I^c} = \boldsymbol{P}_I\boldsymbol{A}_{J,J'}\boldsymbol{P}_{I^c},$$

  注意到

  $$\left\|\boldsymbol{P}_I\boldsymbol{A}_{J,J'}\boldsymbol{P}_{I^c}\right\| \leqslant \|\boldsymbol{P}_I\|\cdot\|\boldsymbol{A}_{J,J'}\|\cdot\|\boldsymbol{P}_{I^c}\| \leqslant \|\boldsymbol{A}_{J,J'}\|,$$

因此两侧取全期望，可得

$$\mathrm{E}_{\delta,\delta',\eta}\left[4\left\|\sum_{i\in I}\sum_{j\in I^c}a_{ij}\delta_i\delta'_j\boldsymbol{E}_{ij}\right\|\right]\leqslant \mathrm{E}_{\delta,\delta'}[4\|\boldsymbol{A}_{J,J'}\|],$$

即

$$\mathrm{E}\|\boldsymbol{A}_{J,J}\|\leqslant 4\mathrm{E}\|\boldsymbol{A}_{J,J'}\|。$$

5 [关于均值的偏差界限失效] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量，满足 $\|\boldsymbol{X}\|_{\psi_2}\leqslant K$。人们通常直觉地认为 $\|\boldsymbol{X}\|_2$ 的尾部概率界限应当围绕其均值 $\mathrm{E}\|\boldsymbol{X}\|_2\approx\sqrt{n}$ 展开。证明：上述猜想是错误的，构造反例，使得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{X}\|_2\geqslant C(\sqrt{n}+Kt)\}\leqslant \mathrm{e}^{-t^2}。$$

解答 (上述界限隐含了“各向同性”“均值集中于 $\sqrt{n}$ 附近”的假设，但是一般的 sub-Gaussian 随机向量并不满足旋转对称性，导致其范数的浓度分布完全可能偏离此界限。)

令 $n\geqslant 2$，取 $\boldsymbol{u}\in\mathbb{S}^{n-1}$，令 $B\sim\mathrm{Bernoulli}(1/n)$，并定义

$$\boldsymbol{X}=\sqrt{\ln n}\,B\boldsymbol{u}。$$

对于任意的 $\boldsymbol{\theta}\in\mathbb{R}^n$，有 $|\langle\boldsymbol{X},\boldsymbol{\theta}\rangle|\leqslant\sqrt{\ln n}\,\|\boldsymbol{\theta}\|_2$，且根据 sub-Gaussian 范数的定义 (D2.6.4 (sub-Gaussian 分布))，可得

$$\mathrm{E}\exp\left(\frac{\langle\boldsymbol{X},\boldsymbol{\theta}\rangle^2}{\|\boldsymbol{\theta}\|_2^2}\right)\leqslant 1-\frac{1}{n}+\frac{1}{n}\exp(\ln n)\leqslant 2,$$

$$\|\langle\boldsymbol{X},\boldsymbol{\theta}\rangle\|_{\psi_2}\leqslant\|\boldsymbol{\theta}\|_2.$$

因而 $\boldsymbol{X}$ 的 sub-Gaussian 范数有绝对常数界。另一方面，

$$\mathrm{E}\|\boldsymbol{X}\|_2=\frac{\sqrt{\ln n}}{n},\qquad \|\boldsymbol{X}\|_2\leqslant\sqrt{\ln n}<\sqrt{n}.$$

取 K 为上述绝对常数界，并令 $C\geqslant 1$，则对任意 $t\geqslant 0$，事件 $\{\|\boldsymbol{X}\|_2\geqslant C(\sqrt{n}+Kt)\}$ 为空集，因而

$$\mathrm{P}\{\|\boldsymbol{X}\|_2\geqslant C(\sqrt{n}+Kt)\}=0\leqslant\mathrm{e}^{-t^2},$$

但该尾界并不能推出范数的均值接近 $\sqrt{n}$；上述均值计算说明原先的直觉是错误的。

6 [**sub-Gaussian 列随机矩阵范数**]

(1) 将练习 Q3.13 (随机向量的最大范数) 的极大不等式推广到 sub-Gaussian 随机向量，即使其分量之间不独立也成立。设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N\in\mathbb{R}^n$ 为相互独立的 sub-Gaussian 随机向量，满足 $\|\boldsymbol{X}_i\|_{\psi_2}\leqslant K$。证明：

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2\right]\leqslant\max_{1\leqslant i\leqslant N}\mathrm{E}\|\boldsymbol{X}_i\|_2+CK^2\sqrt{\ln N}。$$

(2) 将练习 Q4.44 (随机矩阵的其他 $p\to q$ 算子范数) 中对 $\|\cdot\|_1$ 与 $\|\cdot\|_{1\to 2}$ 范数的界推广到含有相互独立的 sub-Gaussian 列的随机矩阵，即使元素之间不独立也成立。设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为含有相互独立的 sub-Gaussian 列的随机矩阵，即列向量 $\boldsymbol{A}_j\in\mathbb{R}^m$ 满足 $\|\boldsymbol{A}_j\|_{\psi_2}\leqslant K$。证明：

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to\infty}\leqslant CK\sqrt{\ln m+\ln n},$$
$$\mathrm{E}\|\boldsymbol{A}\|_{1\to 2}\leqslant\sqrt{m}+CK^2\sqrt{\ln n}。$$

证明 (1) 利用命题 P2.6.1 (sub-Gaussian 性质) (sub-Gaussian 性质) 的集中不等式形式，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{X}_i\|_2\geqslant\mathrm{E}\|\boldsymbol{X}_i\|_2+t\}\leqslant\exp\left(-\frac{ct^2}{K^4}\right)。$$

(之后只需界定 $\mathrm{E}[\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2]$。)

当 $N=1$ 时，结论由等式直接成立。以下设 $N\geqslant 2$，并令 $m_0=\max_{1\leqslant i\leqslant N}\mathrm{E}\|\boldsymbol{X}_i\|_2$。利用联合界，可得对于任意的

$t \geqslant 0$，

$$\mathrm{P}\left\{\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2 \geqslant m_0 + t\right\} \leqslant \sum_{i=1}^{N}\mathrm{P}\{\|\boldsymbol{X}_i\|_2 \geqslant \mathrm{E}\|\boldsymbol{X}_i\|_2 + t\} \leqslant N\exp\left(-\frac{ct^2}{K^4}\right),$$

因此

$$\begin{aligned}\mathrm{E}\left[\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2\right] &\leqslant m_0 + \int_0^\infty \mathrm{P}\left\{\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2 \geqslant m_0 + t\right\}\mathrm{d}t \\ &\leqslant m_0 + \int_0^\infty \min\left(1, N\exp\left(-\frac{ct^2}{K^4}\right)\right)\mathrm{d}t。\end{aligned}$$

对于右侧积分，将积分于

$$N\exp\left(-\frac{ct^2}{K^4}\right) = 1，\ \text{即}t = K^2\sqrt{\frac{\ln N}{c}},$$

分为两部分，

$$\int_0^\infty \min\left(1, N\exp\left(-\frac{ct^2}{K^4}\right)\right)\mathrm{d}t = \int_0^{K^2\sqrt{\frac{\ln N}{c}}} 1\mathrm{d}t + \int_{K^2\sqrt{\frac{\ln N}{c}}}^\infty N\exp\left(-\frac{ct^2}{K^4}\right)\mathrm{d}t \leqslant CK^2\sqrt{\ln N},$$

将其代入，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant N}\|\boldsymbol{X}_i\|_2\right] \leqslant \max_{1\leqslant i\leqslant N}\mathrm{E}\|\boldsymbol{X}_i\|_2 + CK^2\sqrt{\ln N}。$$

(2) • $1\to\infty$ 范数界限

利用 (1) 的结论，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant m}|A_{ij}|\right] \leqslant CK\sqrt{\ln m}。 \qquad (1\leqslant j\leqslant n)$$

因此对于 $\|\boldsymbol{A}\|_{1\to\infty} = \max_{i,j}|A_{ij}|$，

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to\infty} = \mathrm{E}\left[\max_{1\leqslant j\leqslant n}\max_{1\leqslant i\leqslant m}|A_{ij}|\right] \leqslant CK\sqrt{\ln(mn)} = CK\sqrt{\ln m + \ln n} \leqslant CK(\sqrt{\ln m} + \sqrt{\ln n})。$$

• $1\to 2$ 范数界限

利用 (1) 的结论，可得对于 $\|\boldsymbol{A}\|_{1\to 2} = \max_j\|\boldsymbol{A}_j\|_2$，

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to 2} \leqslant \max_j \mathrm{E}\|\boldsymbol{A}_j\|_2 + CK^2\sqrt{\ln n},$$

其中 $\mathrm{E}\|\boldsymbol{A}_j\|_2 \leqslant \sqrt{\mathrm{E}\|\boldsymbol{A}_j\|_2^2} = \sqrt{m}$，将其代入，可得

$$\mathrm{E}\|\boldsymbol{A}\|_{1\to 2} \leqslant \sqrt{m} + CK^2\sqrt{\ln n}。$$

7 [**Gaussian Hanson-Wright 不等式**] 设 $\boldsymbol{g}\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，$\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 为对称矩阵。证明 Hanson-Wright 不等式的一个替代证明：直接利用 MGF，并且于证明过程不进行对角项, 非对角项的分离，也不利用解耦技巧。

证明 若 $\boldsymbol{A} = \boldsymbol{O}$，则 $Z = 0$，结论是平凡的；之后只需考虑 $\|\boldsymbol{A}\| > 0$ 的情况。

之后只需证明 $Z = \boldsymbol{g}^\top\boldsymbol{A}\boldsymbol{g} - \mathrm{E}[\boldsymbol{g}^\top\boldsymbol{A}\boldsymbol{g}]$ 满足

$$\mathrm{P}\{|Z| \geqslant t\} \leqslant 2\exp\left(-c\min\left(\frac{t^2}{\|\boldsymbol{A}\|_F^2}, \frac{t}{\|\boldsymbol{A}\|}\right)\right)。$$

• 谱分解

由于 $\boldsymbol{A}$ 为实对称矩阵，因此存在正交矩阵 $\boldsymbol{Q}$, 对角矩阵 $\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \cdots, \lambda_n)$，使得 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$。

根据 Gaussian 分布的旋转不变性，定义 $\boldsymbol{g}' = \boldsymbol{Q}^\top\boldsymbol{g}\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，满足 $\{g_i'\}$ 是独立同分布的，则

$$\boldsymbol{g}^\top\boldsymbol{A}\boldsymbol{g} = (\boldsymbol{Q}\boldsymbol{g}')^\top\boldsymbol{A}(\boldsymbol{Q}\boldsymbol{g}') = (\boldsymbol{g}')^\top(\boldsymbol{Q}^\top\boldsymbol{A}\boldsymbol{Q})\boldsymbol{g}' = (\boldsymbol{g}')^\top\boldsymbol{\Lambda}\boldsymbol{g}' = \sum_{i=1}^n\lambda_i(g_i')^2,$$

其均值为

$$\mathrm{E}[\boldsymbol{g}^\top \boldsymbol{A}\boldsymbol{g}] = \sum_{i=1}^{n} \lambda_i \mathrm{E}[(g_i')^2] = \sum_{i=1}^{n} \lambda_i = \mathrm{tr}(\boldsymbol{A}),$$

因此

$$Z = \sum_{i=1}^{n} \lambda_i (g_i')^2 - \sum_{i=1}^{n} \lambda_i = \sum_{i=1}^{n} \lambda_i ((g_i')^2 - 1)。$$

- 计算 MGF

根据独立性，可得

$$\begin{aligned}
\mathrm{E}[\mathrm{e}^{\theta Z}] &= \prod_{i=1}^{n} \mathrm{E}[\mathrm{e}^{\theta\lambda_i((g_i')^2-1)}] \\
&= \prod_{i=1}^{n} (\mathrm{e}^{-\theta\lambda_i}(1-2\theta\lambda_i)^{-1/2}) && (\mathrm{E}[\mathrm{e}^{\theta(g^2-1)}] = \mathrm{e}^{-\theta}(1-2\theta)^{-1/2}) \\
&= \exp\left(-\sum_{i=1}^{n}\left(\theta\lambda_i + \frac{1}{2}\ln(1-2\theta\lambda_i)\right)\right)。
\end{aligned}$$

当 $|2\theta\lambda_i| \leqslant 1/2$ 时 (即 $|\theta| \leqslant 1/(4\|\boldsymbol{A}\|)$)，利用 Taylor 展开，可得

$$\ln(1-2\theta\lambda_i) = -2\theta\lambda_i - \frac{(2\theta\lambda_i)^2}{2} - \sum_{k=3}^{\infty} \frac{(2\theta\lambda_i)^k}{k},$$

此时

$$\begin{aligned}
\theta\lambda_i + \frac{1}{2}\ln(1-2\theta\lambda_i) &= \theta\lambda_i - \theta\lambda_i - \theta^2\lambda_i^2 - \frac{1}{2}\sum_{k=3}^{\infty}\frac{(2\theta\lambda_i)^k}{k} \\
&= -\theta^2\lambda_i^2 - \sum_{k=3}^{\infty}\frac{2^{k-1}\theta^k\lambda_i^k}{k},
\end{aligned}$$

将其代入，可得

$$\mathrm{E}[\mathrm{e}^{\theta Z}] = \exp\left(\theta^2\sum_{i=1}^{n}\lambda_i^2 + \sum_{k=3}^{\infty}\frac{2^{k-1}\theta^k}{k}\sum_{i=1}^{n}\lambda_i^k\right)。$$

- 利用 Chernoff 界

由于

$$\begin{aligned}
(k=2) \quad & \sum_{i=1}^{n}\lambda_i^2 = \|\boldsymbol{A}\|_F^2, \\
(k=3) \quad & \sum_{i=1}^{n}|\lambda_i|^k \leqslant \|\boldsymbol{A}\|^{k-2}\|\boldsymbol{A}\|_F^2,
\end{aligned}$$

因此

$$\mathrm{E}[\mathrm{e}^{\theta Z}] \leqslant \exp\left(\theta^2\|\boldsymbol{A}\|_F^2\sum_{k=2}^{\infty}(2\theta\|\boldsymbol{A}\|)^{k-2}\right) \leqslant \exp\left(\frac{\theta^2\|\boldsymbol{A}\|_F^2}{1-2\theta\|\boldsymbol{A}\|}\right),$$

从而利用定理 T2.3.1 (Chernoff 不等式) (Chernoff 不等式)，可得对于 $0 < \theta \leqslant 1/(4\|\boldsymbol{A}\|)$，

$$\mathrm{P}\{Z \geqslant t\} \leqslant \mathrm{e}^{-\theta t}\mathrm{E}[\mathrm{e}^{\theta Z}] \leqslant \exp\left(-\theta t + \frac{\theta^2\|\boldsymbol{A}\|_F^2}{1-2\theta\|\boldsymbol{A}\|}\right),$$

令

$$\theta = \min\left\{\frac{t}{4\|\boldsymbol{A}\|_F^2}, \frac{1}{4\|\boldsymbol{A}\|}\right\}。$$

则 $0<\theta\leqslant 1/(4\|\boldsymbol{A}\|)$，同时 $1-2\theta\|\boldsymbol{A}\|\geqslant 1/2$，从而

$$\mathrm{P}\{Z\geqslant t\}\leqslant \exp(-\theta t+2\theta^2\|\boldsymbol{A}\|_F^2)。$$

若 $t\leqslant \|\boldsymbol{A}\|_F^2/\|\boldsymbol{A}\|$，则 $\theta=t/(4\|\boldsymbol{A}\|_F^2)$，因此右侧指数至多为 $-t^2/(8\|\boldsymbol{A}\|_F^2)$；若 $t>\|\boldsymbol{A}\|_F^2/\|\boldsymbol{A}\|$，则 $\theta=1/(4\|\boldsymbol{A}\|)$，因此右侧指数至多为 $-t/(8\|\boldsymbol{A}\|)$。因此

$$\mathrm{P}\{Z\geqslant t\}\leqslant \exp\left(-\frac{1}{8}\min\left(\frac{t^2}{\|\boldsymbol{A}\|_F^2},\frac{t}{\|\boldsymbol{A}\|}\right)\right);$$

对 $-Z$ 应用相同证明，

$$\mathrm{P}\{Z\leqslant -t\}\leqslant \exp\left(-c\min\left(\frac{t^2}{\|\boldsymbol{A}\|_F^2},\frac{t}{\|\boldsymbol{A}\|}\right)\right)。$$

如此，

$$\mathrm{P}\{|Z|\geqslant t\}=\mathrm{P}\{Z\geqslant t\}+\mathrm{P}\{Z\leqslant -t\}\leqslant 2\exp\left(-c\min\left(\frac{t^2}{\|\boldsymbol{A}\|_F^2},\frac{t}{\|\boldsymbol{A}\|}\right)\right)。$$

8 **[高维 Hanson-Wright 不等式]** 设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，$\boldsymbol{X}_1,\cdots,\boldsymbol{X}_n\in\mathbb{R}^d$ 为相互独立的零均值随机向量，且每个 $\boldsymbol{X}_i$ 的分量相互独立并满足 $\max_k\|X_{ik}\|_{\psi_2}\leqslant K$。证明：对于任意的 $t\geqslant 0$，

$$\mathrm{P}\left\{\left|\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right|\geqslant t\right\}\leqslant 2\exp\left(-c\min\left(\frac{t^2}{K^4d\|\boldsymbol{A}\|_F^2},\frac{t}{K^2\|\boldsymbol{A}\|}\right)\right)。$$

证明 • 根据 Chernoff 界

对于目标随机变量 $S_{\mathrm{off}}=\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle$，利用定理 T2.3.1 (Chernoff 不等式) (Chernoff 不等式)，可得

$$\mathrm{P}\{S_{\mathrm{off}}\geqslant t\}\leqslant \mathrm{e}^{-\lambda t}\mathrm{E}\left[\exp\left(\lambda\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right],$$

其中利用习题 Q6.3 (向量, 空间解耦) (2) 的结论，令 $F(x)=\exp(\lambda x)$，可得

$$\mathrm{E}\left[\exp\left(\lambda\sum_{i\neq j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}_j\rangle\right)\right]\leqslant \mathrm{E}\left[\exp\left(4\lambda\sum_{i,j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\right)\right],$$

将其代入，可得

$$\mathrm{P}\{S_{\mathrm{off}}\geqslant t\}\leqslant \mathrm{e}^{-\lambda t}\mathrm{E}\left[\exp\left(4\lambda\sum_{i,j}a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}'_j\rangle\right)\right]。\tag{I}$$

• 条件化处理

重排上述指数内部的求和项，

$$\sum_{i,j=1}^n a_{ij}\langle\boldsymbol{X}_i,\boldsymbol{X}'_j\rangle=\sum_{i=1}^n\left\langle\boldsymbol{X}_i,\sum_{j=1}^n a_{ij}\boldsymbol{X}'_j\right\rangle=\sum_{i=1}^n\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle,$$

其中 $\boldsymbol{Y}_i=\sum_{j=1}^n a_{ij}\boldsymbol{X}'_j\in\mathbb{R}^d$。

对 $\boldsymbol{X}'=(\boldsymbol{X}'_1,\cdots,\boldsymbol{X}'_n)$ 取条件期望，可得

$$\mathrm{E}\left[\exp\left(4\lambda\sum_{i=1}^n\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle\right)\right]=\mathrm{E}_{\boldsymbol{X}'}\left[\mathrm{E}_{\boldsymbol{X}}\left[\exp\left(4\lambda\sum_{i=1}^n\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle\right)\,\middle|\,\boldsymbol{X}'\right]\right]。$$

(于给定 $\boldsymbol{X}'$ 的条件，$\boldsymbol{Y}_1,\cdots,\boldsymbol{Y}_n\in\mathbb{R}^d$ 为确定性常向量，此时内层求和 $\sum_{i=1}^n\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle$ 为 n 个相互独立的随机变量之和。)

由于 $\boldsymbol{X}_i$ 为 sub-Gaussian 随机向量，因此其向常向量 $\boldsymbol{Y}_i$ 的投影 $\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle$ 为标量 sub-Gaussian 随机变量，满足

$$\|\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle\|_{\psi_2}\leqslant K\|\boldsymbol{Y}_i\|_2,$$

从而

$$\mathrm{E}_{\boldsymbol{X}_i}[\exp(4\lambda\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle)\mid\boldsymbol{X}']\leqslant\exp(C_1\lambda^2K^2\|\boldsymbol{Y}_i\|_2^2),\qquad(C_1>0)$$

两侧求和，

$$\mathrm{E}_{\boldsymbol{X}}\left[\exp\left(4\lambda\sum_{i=1}^{n}\langle\boldsymbol{X}_i,\boldsymbol{Y}_i\rangle\right)\,\middle|\,\boldsymbol{X}'\right]\leqslant\exp\left(C_1\lambda^2K^2\sum_{i=1}^{n}\|\boldsymbol{Y}_i\|_2^2\right)。\tag{II}$$

联立 (I)(II)，可得

$$\mathrm{P}\{S_{\text{off}}\geqslant t\}\leqslant\mathrm{e}^{-\lambda t}\mathrm{E}_{\boldsymbol{X}'}\left[\exp\left(C_1\lambda^2K^2\sum_{i=1}^{n}\|\boldsymbol{Y}_i\|_2^2\right)\right]。\tag{III}$$

- 解析二次型 $\sum_{i=1}^{n}\|\boldsymbol{Y}_i\|_2^2$

根据 $\boldsymbol{Y}_i$ 的定义 $\boldsymbol{Y}_i=\sum_{j=1}^{n}a_{ij}\boldsymbol{X}'_j$，设 $\mathcal{X}'\in\mathbb{R}^{n\times d}$ 为以 $(\boldsymbol{X}'_1)^\top,\cdots,(\boldsymbol{X}'_n)^\top$ 为行向量的矩阵，则 $\boldsymbol{Y}_i^\top$ 为 $\boldsymbol{A}\mathcal{X}'$ 的第 i 行，满足

$$\sum_{i=1}^{n}\|\boldsymbol{Y}_i\|_2^2=\|\boldsymbol{A}\boldsymbol{X}'\|_F^2=\sum_{k=1}^{d}\|\boldsymbol{A}\boldsymbol{g}_k\|_2^2。$$

设 $\boldsymbol{g}_1,\cdots,\boldsymbol{g}_d\in\mathbb{R}^n$ 为 $\mathcal{X}'$ 的列向量，则 $\boldsymbol{g}_k$ 是相互独立的，其含有相互独立的 K-sub-Gaussian 分量，因此

$$\|\boldsymbol{A}\mathcal{X}'\|_F^2=\sum_{k=1}^{d}\|\boldsymbol{A}\boldsymbol{g}_k\|_2^2=\sum_{k=1}^{d}\boldsymbol{g}_k^\top(\boldsymbol{A}^\top\boldsymbol{A})\boldsymbol{g}_k,$$

从而 (III) 的右侧为

$$\begin{aligned}\mathrm{E}_{\boldsymbol{X}'}\left[\exp\left(C_1\lambda^2K^2\sum_{i=1}^{n}\|\boldsymbol{Y}_i\|_2^2\right)\right]&=\mathrm{E}_{\boldsymbol{X}'}\left[\exp\left(C_1\lambda^2K^2\sum_{k=1}^{d}\boldsymbol{g}_k^\top(\boldsymbol{A}^\top\boldsymbol{A})\boldsymbol{g}_k\right)\right]\\&=\prod_{k=1}^{d}\mathrm{E}_{\boldsymbol{g}_k}[\exp(C_1\lambda^2K^2\cdot\boldsymbol{g}_k^\top(\boldsymbol{A}^\top\boldsymbol{A})\boldsymbol{g}_k)]。\end{aligned}$$

作出以下引理：

引理 (习题 Q6.9 (平方范数的矩母函数)) 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，$\boldsymbol{X}\in\mathbb{R}^n$ 为 K-sub-Gaussian 随机向量，则当 $\alpha\leqslant c/(K^2\|\boldsymbol{A}\|^2)$ 时，

$$\mathrm{E}[\exp(\alpha\|\boldsymbol{A}\boldsymbol{X}\|_2^2)]\leqslant\exp(CK^2\alpha\|\boldsymbol{A}\|_F^2)。$$

根据引理，令 $\alpha=C_1\lambda^2K^2$，则当

$$\lambda\leqslant\frac{c_1}{K^2\|\boldsymbol{A}\|},\qquad\left(C_1\lambda^2K^2\leqslant\frac{c_0}{K^2\|\boldsymbol{A}\|^2}\right)$$

成立时，

$$\mathrm{E}[\exp(\alpha\|\boldsymbol{A}\boldsymbol{g}_k\|_2^2)]\leqslant\exp(C_2\alpha\|\boldsymbol{A}\|_F^2),\qquad(C_2>0)$$

因此

$$\mathrm{E}_{\boldsymbol{X}'}[\exp(C_1\lambda^2K^2\|\boldsymbol{A}\boldsymbol{X}'\|_F^2)]\leqslant\exp(C_3\lambda^2K^4d\|\boldsymbol{A}\|_F^2),$$

将其代入于 (III)，可得

$$\mathrm{P}\{S_{\text{off}}\geqslant t\}\leqslant\exp(\underbrace{-\lambda t+C_3\lambda^2K^4d\|\boldsymbol{A}\|_F^2}_{h(\lambda)})。$$

- 优化 λ (小偏差与大偏差的讨论)

当不考虑约束时，

$$\lambda_0=\frac{t}{2C_3K^4d\|\boldsymbol{A}\|_F^2},$$

对 λ 的取值进行讨论：

a. 小偏差 (sub-Gaussian 界)

若 t 较小，满足

$$\lambda_0 \leqslant \frac{c_1}{K^2\|\boldsymbol{A}\|},$$

将 λ_0 代入于 (III)，可得

$$\mathrm{P}\{S_{\text{off}} \geqslant t\} \leqslant \exp\left(-\frac{t^2}{4C_3K^4d\|\boldsymbol{A}\|_F^2}\right)。$$

b. 大偏差 (sub-Exponential 界)

若 t 较大，使得

$$\lambda_0 > \frac{c_1}{K^2\|\boldsymbol{A}\|},$$

则最小值于边界取得，

$$\begin{aligned} h\left(\frac{c_1}{K^2\|\boldsymbol{A}\|}\right) &= -\frac{c_1t}{K^2\|\boldsymbol{A}\|} + C_3\left(\frac{c_1}{K^2\|\boldsymbol{A}\|}\right)^2 K^4d\|\boldsymbol{A}\|_F^2 \\ &= -\frac{c_1t}{K^2\|\boldsymbol{A}\|} + C_3c_1^2\frac{d\|\boldsymbol{A}\|_F^2}{\|\boldsymbol{A}\|^2} \\ &\leqslant -\frac{c_1t}{K^2\|\boldsymbol{A}\|} + \frac{c_1t}{2K^2\|\boldsymbol{A}\|} = -\frac{c_1}{2}\frac{t}{K^2\|\boldsymbol{A}\|}, \qquad \left(\frac{c_1}{K^2\|\boldsymbol{A}\|} < \frac{t}{2C_3K^4d\|\boldsymbol{A}\|_F^2}\right) \end{aligned}$$

将其代入于 (III)，可得

$$\mathrm{P}\{S_{\text{off}} \geqslant t\} \leqslant \exp\left(-c_2\frac{t}{K^2\|\boldsymbol{A}\|}\right)。$$

如此，

$$\mathrm{P}\{S_{\text{off}} \geqslant t\} \leqslant \exp\left(-c\min\left(\frac{t^2}{K^4d\|\boldsymbol{A}\|_F^2}, \frac{t}{K^2\|\boldsymbol{A}\|}\right)\right),$$

两侧取并集界，可得

$$\mathrm{P}\{|S_{\text{off}}| \geqslant t\} = \mathrm{P}\{S_{\text{off}} \geqslant t\} + \mathrm{P}\{-S_{\text{off}} \geqslant t\} \leqslant 2\exp\left(-c\min\left(\frac{t^2}{K^4d\|\boldsymbol{A}\|_F^2}, \frac{t}{K^2\|\boldsymbol{A}\|}\right)\right)。$$

9 [**平方范数的矩母函数**] 设 $\boldsymbol{B} \in \mathbb{R}^{m\times n}$，$\boldsymbol{X} \in \mathbb{R}^n$ 为零均值的 sub-Gaussian 随机向量，满足 $\|\boldsymbol{X}\|_{\psi_2} \leqslant K$。证明：对于任意的满足 $|\lambda| \leqslant c/K\|\boldsymbol{B}\|$ 的参数 λ，

$$\mathrm{E}[\exp(\lambda^2\|\boldsymbol{B}\boldsymbol{X}\|_2^2)] \leqslant \exp(CK^2\lambda^2\|\boldsymbol{B}\|_F^2)。 \qquad (C, c > 0)$$

注释 **Hanson-Wright 不等式的 MGF 版本** 设 $\boldsymbol{X} \in \mathbb{R}^n$ 为零均值 sub-Gaussian 随机向量，满足 $\|\boldsymbol{X}\|_{\psi_2} \leqslant K$，$\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称矩阵，则对于任意的满足 $|\theta| \cdot K^2\|\boldsymbol{A}\| \leqslant c$ 的参数 θ，

$$\mathrm{E}[\exp(\theta(\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}]))] \leqslant \exp(C\theta^2K^4\|\boldsymbol{A}\|_F^2)。$$

首先进行二次型解耦，设 $\boldsymbol{X}'$ 为 $\boldsymbol{X}$ 的独立副本，则根据定理 T6.1.1 (解耦)，可得对于任意的凸函数 F，

$$\mathrm{E}[F(\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}])] \leqslant \mathrm{E}[F(C_1\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}')],$$

令 $F(x) = \exp(\theta x)$，可得

$$\mathrm{E}[\exp(\theta(\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}]))] \leqslant \mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}[\exp(C_1\theta\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}')], \qquad (\mathrm{I})$$

这是关于二次型 $Q = \boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}'$ 的 MGF。

之后进行条件化，令 $\boldsymbol{Y} = \boldsymbol{A}\boldsymbol{X}'$，则 (I) 的右侧为

$$\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}[\exp(C_1\theta\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}')] = \mathrm{E}_{\boldsymbol{X}'}[\mathrm{E}_{\boldsymbol{X}}[\exp(C_1\theta\langle\boldsymbol{X},\boldsymbol{Y}\rangle) \mid \boldsymbol{X}']],$$

其中对于固定的 $\boldsymbol{X}'$，$\langle\boldsymbol{X},\boldsymbol{Y}\rangle$ 为 sub-Gaussian 随机变量，其 MGF 满足

$$\begin{aligned} \mathrm{E}_{\boldsymbol{X}}[\exp(C_1\theta\langle\boldsymbol{X},\boldsymbol{Y}\rangle)] &\leqslant \exp(C_2(C_1\theta)^2K^2\|\boldsymbol{Y}\|_2^2) && (C_2 > 0) \\ &= \exp(C_3\theta^2K^2\|\boldsymbol{A}\boldsymbol{X}'\|_2^2), && (C_3 = C_1C_2 > 0) \end{aligned}$$

将其代入，可得

$$\mathrm{E}[\exp(\theta(\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}-\mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}]))]\leqslant \mathrm{E}_{\boldsymbol{X}'}[\exp(C_3\theta^2K^2\|\boldsymbol{A}\boldsymbol{X}'\|_2^2)]。\tag{II}$$

令 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，并令其独立于 $\boldsymbol{X}'$。对给定的 $\boldsymbol{X}'$ 应用 Gaussian 矩母函数，再对给定的 $\boldsymbol{g}$ 应用 sub-Gaussian 矩母函数，可得

$$\begin{aligned}\mathrm{E}_{\boldsymbol{X}'}[\exp(C_3\theta^2K^2\|\boldsymbol{A}\boldsymbol{X}'\|_2^2)]&=\mathrm{E}_{\boldsymbol{g}}\mathrm{E}_{\boldsymbol{X}'}\left[\exp(\sqrt{2C_3}|\theta|K\langle\boldsymbol{A}^\top\boldsymbol{g},\boldsymbol{X}'\rangle)\mid\boldsymbol{g}\right]\\&\leqslant\mathrm{E}_{\boldsymbol{g}}[\exp(C_4\theta^2K^4\|\boldsymbol{A}^\top\boldsymbol{g}\|_2^2)].\end{aligned}$$

当 $C_4\theta^2K^4\|\boldsymbol{A}\|^2\leqslant 1/4$ 时，对 $\boldsymbol{A}$ 的奇异值应用 Gaussian 二次型的矩母函数，得到

$$\mathrm{E}_{\boldsymbol{g}}[\exp(C_4\theta^2K^4\|\boldsymbol{A}^\top\boldsymbol{g}\|_2^2)]\leqslant\exp(C_5\theta^2K^4\|\boldsymbol{A}\|_F^2)。$$

取足够小的绝对常数 c，条件 $|\theta|K^2\|\boldsymbol{A}\|\leqslant c$ 保证上述条件，从而得到所述 MGF 界。

证明 令 $\boldsymbol{A}=\boldsymbol{B}^\top\boldsymbol{B}$ 为半正定对称矩阵，将平方范数表示为二次型，

$$\|\boldsymbol{B}\boldsymbol{X}\|_2^2=(\boldsymbol{B}\boldsymbol{X})^\top(\boldsymbol{B}\boldsymbol{X})=\boldsymbol{X}^\top(\boldsymbol{B}^\top\boldsymbol{B})\boldsymbol{X}=\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X},$$

之后只需界定 $Q=\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}$ 的 MGF。

一方面，利用定理 T6.2.2 (Hanson–Wright 不等式) (Hanson–Wright 不等式) 的 MGF 形式，可得对于任意的满足 $|\theta|\cdot K^2\|\boldsymbol{A}\|\leqslant c$ 的参数 θ，

$$\mathrm{E}[\exp(\theta(\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}-\mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}]))]\leqslant\exp(C\theta^2K^4\|\boldsymbol{A}\|_F^2)。$$

令 $\theta=\lambda^2$，注意到 $\|\boldsymbol{A}\|=\|\boldsymbol{B}^\top\boldsymbol{B}\|=\|\boldsymbol{B}\|^2$，因此约束条件等价于

$$\lambda^2K^2\|\boldsymbol{B}\|^2\leqslant c。\tag{III}$$

另一方面，

$$\mathrm{E}[\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}]=\mathrm{E}[\mathrm{tr}(\boldsymbol{A}\boldsymbol{X}\boldsymbol{X}^\top)]=\mathrm{tr}(\boldsymbol{A}\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top])\leqslant K^2\,\mathrm{tr}(\boldsymbol{A})\leqslant K^2\|\boldsymbol{B}\|_F^2。\tag{IV}$$

如此，根据 MGF 的可分性，联立 (III)(IV)，可得

$$\begin{aligned}\mathrm{E}[\exp(\lambda^2Q)]&=\exp(\lambda^2\mathrm{E}[Q])\cdot\mathrm{E}[\exp(\lambda^2(Q-\mathrm{E}[Q]))]\\&\leqslant\exp(\lambda^2K^2\|\boldsymbol{B}\|_F^2)\cdot\exp(C\lambda^4K^4\|\boldsymbol{A}\|_F^2),\end{aligned}$$

其中第二项的指数部分为

$$\begin{aligned}C\lambda^4K^4\|\boldsymbol{A}\|_F^2&\leqslant C\lambda^4K^4(\|\boldsymbol{B}\|^2\|\boldsymbol{B}\|_F^2)\\&=C\cdot(\lambda^2K^2\|\boldsymbol{B}\|^2)\cdot(\lambda^2K^2\|\boldsymbol{B}\|_F^2)\\&\leqslant C\cdot c\cdot\lambda^2K^2\|\boldsymbol{B}\|_F^2,\end{aligned}$$

将其代入，可得

$$\begin{aligned}\mathrm{E}[\exp(\lambda^2\|\boldsymbol{B}\boldsymbol{X}\|_2^2)]&\leqslant\exp(\lambda^2K^2\|\boldsymbol{B}\|_F^2)\cdot\exp(Cc^2\lambda^2K^2\|\boldsymbol{B}\|_F^2)\\&=\exp(C'\lambda^2K^2\|\boldsymbol{B}\|_F^2)。\end{aligned}\qquad(C'=1+Cc>0)$$

10 [**各向异性随机向量的范数**] 让我们将命题 P6.2.1 (sub-Gaussian 随机向量的范数) 推广到各向异性随机向量。

设 $\boldsymbol{B}\in\mathbb{R}^{m\times n}$ 为固定矩阵，$\boldsymbol{X}\in\mathbb{R}^n$ 为零均值 sub-Gaussian 随机向量，满足 $\|\boldsymbol{X}\|_{\psi_2}\leqslant K$。证明：对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{B}\boldsymbol{X}\|_2\geqslant CK(\|\boldsymbol{B}\|_F+t\|\boldsymbol{B}\|)\}\leqslant\mathrm{e}^{-t^2}。\qquad(C>0)$$

证明 • 转化为二次型问题

定义半正定对称矩阵 $\boldsymbol{A}=\boldsymbol{B}^\top\boldsymbol{B}$，则 $\mathrm{tr}(\boldsymbol{A})=\mathrm{tr}(\boldsymbol{B}^\top\boldsymbol{B})=\|\boldsymbol{B}\|_F^2$，$\|\boldsymbol{A}\|=\|\boldsymbol{B}\|^2$。

令 $Q=\|\boldsymbol{B}\boldsymbol{X}\|_2^2=\boldsymbol{X}^\top(\boldsymbol{B}^\top\boldsymbol{B})\boldsymbol{X}=\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}$，则

$$\mathrm{E}[Q]=\mathrm{E}[\mathrm{tr}(\boldsymbol{A}\boldsymbol{X}\boldsymbol{X}^\top)]=\mathrm{tr}(\boldsymbol{A}\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top])\leqslant K^2\,\mathrm{tr}(\boldsymbol{A})=K^2\|\boldsymbol{B}\|_F^2。$$

之后只需控制 $\|\boldsymbol{B}\boldsymbol{X}\|_2\geqslant CK(\|\boldsymbol{B}\|_F+t\|\boldsymbol{B}\|)$，两侧平方，可得证明目标等价为

$$Q\geqslant C^2K^2(\|\boldsymbol{B}\|_F+t\|\boldsymbol{B}\|)^2=C^2K^2(\|\boldsymbol{B}\|_F^2+2t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\|+t^2\|\boldsymbol{B}\|^2)。\tag{I}$$

(之后只需控制 $|Q-\mathrm{E}[Q]|$ 超过某个值 u_0 的概率。)

令偏差目标 $u = Q - \mathrm{E}[Q]$，偏差阈值 $u_0 = C_0K^2(t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\| + t^2\|\boldsymbol{B}\|^2)$，则当 $Q \geqslant \mathrm{E}[Q] + u_0$ 发生时，

$$Q \geqslant K^2\|\boldsymbol{B}\|_F^2 + C_0K^2(t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\| + t^2\|\boldsymbol{B}\|^2)。 \tag{II}$$

（我们只需选取适当的 C，使得 $\mathrm{RHS}_{(\mathrm{II})} \leqslant \mathrm{RHS}_{(\mathrm{I})}$，即可将 $\|\boldsymbol{BX}\|_2$ 的界限问题转化为 $Q - \mathrm{E}[Q] \geqslant u_0$ 的问题。）

- 根据 Hanson-Wright 不等式

利用定理 T6.2.2 (Hanson–Wright 不等式)，可得对于 $u_0 \geqslant 0$，

$$\mathrm{P}\{|Q - \mathrm{E}[Q]| \geqslant u_0\} \leqslant 2\exp\left(-c\min\left(\frac{u_0^2}{K^4\|\boldsymbol{A}\|_F^2}, \frac{u_0}{K^2\|\boldsymbol{A}\|}\right)\right)。$$

其中

$$\frac{u_0^2}{K^4\|\boldsymbol{A}\|_F^2} = \frac{C_0^2K^4(t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\| + t^2\|\boldsymbol{B}\|^2)^2}{K^4\|\boldsymbol{B}^\top\boldsymbol{B}\|_F^2} \geqslant \frac{C_0^2K^4(t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\| + t^2\|\boldsymbol{B}\|^2)^2}{K^4\|\boldsymbol{B}\|^2\|\boldsymbol{B}\|_F^2} = C_0^2\left(t + t^2\frac{\|\boldsymbol{B}\|}{\|\boldsymbol{B}\|_F}\right)^2 \geqslant C_0^2t^2,$$

$$\frac{u_0}{K^2\|\boldsymbol{A}\|} = \frac{C_0K^2(t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\| + t^2\|\boldsymbol{B}\|^2)}{K^2\|\boldsymbol{B}\|^2} = C_0\left(t\frac{\|\boldsymbol{B}\|_F}{\|\boldsymbol{B}\|} + t^2\right) \geqslant C_0t^2,$$

因此

$$\min\left(\frac{u_0^2}{K^4\|\boldsymbol{A}\|_F^2}, \frac{u_0}{K^2\|\boldsymbol{A}\|}\right) \geqslant \min(C_0^2, C_0)\cdot t^2,$$

即

$$\mathrm{P}\{Q - \mathrm{E}[Q] \geqslant u_0\} \leqslant 2\exp(-c't^2), \qquad (c' = c\min(C_0^2, C_0) > 0)$$

从而调整绝对常数，可得

$$\mathrm{P}\{\|\boldsymbol{BX}\|_2 \geqslant CK(\|\boldsymbol{B}\|_F + t\|\boldsymbol{B}\|)\} \leqslant \mathrm{e}^{-t^2}。$$

调整常数时，比对 (I)、(II) 中 $\|\boldsymbol{B}\|_F^2$、$t\|\boldsymbol{B}\|_F\|\boldsymbol{B}\|$ 与 $t^2\|\boldsymbol{B}\|^2$ 的系数。取 $C^2 \geqslant \max(1, C_0)$ 即可满足所需比较。

11 [**高维 Hanson-Wright 不等式**] 这里给出定理 T6.2.2 (Hanson–Wright 不等式) 的一个单侧推论。

设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为对称半正定矩阵，设 $\boldsymbol{X} \in \mathbb{R}^n$ 为分量相互独立的零均值 sub-Gaussian 随机向量，满足 $\max_i \|X_i\|_{\psi_2} \leqslant K$。证明：对于任意的 $s \geqslant 0$，

$$\mathrm{P}\{\boldsymbol{X}^\top\boldsymbol{AX} \geqslant CK^2(\mathrm{tr}(\boldsymbol{A}) + s\|\boldsymbol{A}\|)\} \leqslant \mathrm{e}^{-s}。 \qquad (C > 0)$$

（为与定理 T6.2.2 (Hanson–Wright 不等式) 进行比较，令 $t = CK^2s\|\boldsymbol{A}\|$，并注意到对于各向同性随机向量 $\boldsymbol{X}$，满足 $\mathrm{tr}(\boldsymbol{A}) = \mathrm{E}[\boldsymbol{X}^\top\boldsymbol{AX}]$。）

然后说明：即使 $\boldsymbol{X}$ 各向同性，也仅存在单侧界限。

证明 - 证明过程

同理于习题 Q6.10 (各向异性随机向量的范数)，令 $Q = \boldsymbol{X}^\top\boldsymbol{AX}$，则

$$\mathrm{E}[Q] = \mathrm{E}[\mathrm{tr}(\boldsymbol{AXX}^\top)] = \mathrm{tr}(\boldsymbol{A}\mathrm{E}[\boldsymbol{XX}^\top]) = \mathrm{tr}(\boldsymbol{A\Sigma}) \leqslant \|\boldsymbol{\Sigma}\|\,\mathrm{tr}(\boldsymbol{A}) \leqslant K^2\,\mathrm{tr}(\boldsymbol{A})。$$

对于目标阈值 $T = CK^2(\mathrm{tr}(\boldsymbol{A}) + s\|\boldsymbol{A}\|)$，其中 $C > 1$ (否则 $C - 1 \not> 0$)，考虑偏差量

$$u_0 = T - \mathrm{E}[Q] \geqslant (C-1)K^2\,\mathrm{tr}(\boldsymbol{A}) + CK^2s\|\boldsymbol{A}\|,$$

令 $c_1 = C - 1 > 0$，$c_2 = C > 0$，则

$$u_0 = c_1K^2\,\mathrm{tr}(\boldsymbol{A}) + c_2K^2s\|\boldsymbol{A}\| \geqslant 0。$$

利用定理 T6.2.2 (Hanson–Wright 不等式) (Hanson–Wright 不等式)，可得对于 $u_0 \geqslant 0$，

$$\mathrm{P}\{Q - \mathrm{E}[Q] \geqslant u_0\} \leqslant 2\exp\left(-c\min\left(\frac{u_0^2}{K^4\|\boldsymbol{A}\|_F^2}, \frac{u_0}{K^2\|\boldsymbol{A}\|}\right)\right),$$

其中对于第二项，利用 $\|\boldsymbol{A}\|_F^2 \leqslant \|\boldsymbol{A}\|\,\mathrm{tr}(\boldsymbol{A})$，可得

$$\frac{u_0}{K^2\|\boldsymbol{A}\|} = \frac{c_1K^2\,\mathrm{tr}(\boldsymbol{A}) + c_2K^2s\|\boldsymbol{A}\|}{K^2\|\boldsymbol{A}\|} = c_1\frac{\mathrm{tr}(\boldsymbol{A})}{\|\boldsymbol{A}\|} + c_2s \geqslant c_2s,$$

对于第一项，利用 $(x+y)^2 \geqslant 4xy$，可得

$$\frac{u_0^2}{K^4\|\boldsymbol{A}\|_F^2} \geqslant \frac{(c_1K^2\operatorname{tr}(\boldsymbol{A})+c_2K^2s\|\boldsymbol{A}\|)^2}{K^4\|\boldsymbol{A}\|\operatorname{tr}(\boldsymbol{A})} \geqslant \frac{4c_1c_2K^4s\|\boldsymbol{A}\|\operatorname{tr}(\boldsymbol{A})}{K^4\|\boldsymbol{A}\|\operatorname{tr}(\boldsymbol{A})} = 4c_1c_2s,$$

因此

$$\mathrm{P}\{Q-\mathrm{E}[Q]\geqslant u_0\}\leqslant 2\exp(-c's), \qquad (c'=c\cdot\min(4c_1c_2,c_2)>0)$$

从而调整绝对常数，可得

$$\mathrm{P}\{\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}\geqslant CK^2(\operatorname{tr}(\boldsymbol{A})+s\|\boldsymbol{A}\|)\}\leqslant \mathrm{e}^{-s}。$$

- 关于单侧界限的解释

即使 $\boldsymbol{X}$ 是各向同性的，上述不等式仅存在右尾界。

事实上，由于 $\boldsymbol{A}$ 为对称半正定矩阵，因此 $Q=\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}\geqslant 0$，这使得此随机变量于 0 处被截断，不存在向 $-\infty$ 延伸的概率尾部。

具体而言，二次型 $\boldsymbol{X}^\top\boldsymbol{A}\boldsymbol{X}$ 的分布呈现显著的右偏特征，其概率密度函数于左侧由 0 截断，于右侧以 sub-Exponential 的速度衰减。因此，对于右侧偏离概率 $\mathrm{P}\{Q\geqslant \mathrm{E}[Q]+u\}$，我们可以获得有意义的指数衰减界；但是，对于左侧偏离概率 $\mathrm{P}\{Q\leqslant \mathrm{E}[Q]-u\}$，当 $u>\mathrm{E}[Q]$ 时，此概率为 0，不需要利用 Hanson-Wright 不等式进行复杂的渐近分析。

12 [**均值估计**] 回顾均值估计问题。

考虑定义于 $\mathbb{R}^n$ 的未知分布，其均值为 $\boldsymbol{\mu}$，协方差矩阵为 $\boldsymbol{\Sigma}$。设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为此分布抽取的 N 个独立样本，并假设每个 $\boldsymbol{X}_i-\boldsymbol{\mu}$ 的分量相互独立。我们的目标是利用样本均值

$$\boldsymbol{\mu}_N=\frac{1}{N}\sum_{i=1}^N\boldsymbol{X}_i,$$

估计 $\boldsymbol{\mu}$。进一步假设此分布满足 sub-Gaussian 条件，即对于任意的 $\boldsymbol{u}\in\mathbb{R}^n$，

$$\|\langle\boldsymbol{X}_i-\boldsymbol{\mu},\boldsymbol{u}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X}_i-\boldsymbol{\mu},\boldsymbol{u}\rangle\|_{L_2}。$$

证明：对于任意的 $\alpha\in(0,1)$，

$$\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2\leqslant CK^2\left(\sqrt{\frac{\operatorname{tr}(\boldsymbol{\Sigma})}{N}}+\sqrt{\frac{\|\boldsymbol{\Sigma}\|\ln(1/\alpha)}{N}}\right)\ (\text{w.p. } 1-\alpha)。$$

证明 令 $Z=\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2$，将其分解为

$$Z\leqslant\mathrm{E}[Z]+(Z-\mathrm{E}[Z]),$$

其中 $\mathrm{E}[Z]$ 是确定性的，我们可以直接利用 Jensen 不等式给出上界；$Z-\mathrm{E}[Z]$ 为随机变量对其均值的偏离，之后只需利用集中不等式给出一个高概率上界。

- 期望部分的估计

设 $\boldsymbol{Y}_i=\boldsymbol{X}_i-\boldsymbol{\mu}$ 为均值为 $\boldsymbol{0}$, 协方差为 $\boldsymbol{\Sigma}$ 的相互独立的 sub-Gaussian 随机向量，则

$$\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2=\left\|\frac{1}{N}\sum_{i=1}^N\boldsymbol{Y}_i\right\|_2=\|\bar{\boldsymbol{Y}}\|_2。$$

利用 Jensen 不等式，可得

$$\mathrm{E}\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2\leqslant\sqrt{\mathrm{E}\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2^2}=\sqrt{\mathrm{E}\|\bar{\boldsymbol{Y}}\|_2^2},$$

其中

$$\mathrm{E}\|\bar{\boldsymbol{Y}}\|_2^2=\frac{1}{N^2}\sum_{i=1}^N\mathrm{E}\|\boldsymbol{Y}_i\|_2^2=\frac{1}{N^2}\cdot N\cdot\operatorname{tr}(\boldsymbol{\Sigma})=\frac{\operatorname{tr}(\boldsymbol{\Sigma})}{N},$$

将其代入，可得

$$\mathrm{E}\|\boldsymbol{\mu}_N-\boldsymbol{\mu}\|_2\leqslant\sqrt{\frac{\operatorname{tr}(\boldsymbol{\Sigma})}{N}}。$$

• 尾部概率的估计

记 $\sigma_j^2 = \mathrm{Var}(Y_{1j})$，并令 $\boldsymbol{D} = \mathrm{diag}(\sigma_1, \dots, \sigma_n)$。对于 $\sigma_j > 0$，令

$$Z_j = \frac{1}{\sigma_j \sqrt{N}} \sum_{i=1}^{N} Y_{ij};$$

当 $\sigma_j = 0$ 时，令 $Z_j = 0$。则非退化分量 Z_j 相互独立、中心化且标准化，并满足 $\|Z_j\|_{\psi_2} \leqslant CK$；此外

$$\bar{\boldsymbol{Y}} = \frac{1}{\sqrt{N}} \boldsymbol{D}\boldsymbol{Z}, \qquad \|\boldsymbol{D}\|_F^2 = \mathrm{tr}(\boldsymbol{\Sigma}), \quad \|\boldsymbol{D}\|^2 = \|\boldsymbol{\Sigma}\|。$$

将定理 T3.1.1 (范数的集中) 应用于矩阵 $\boldsymbol{D}/\sqrt{N}$，可得对于任意的 $u \geqslant 0$，

$$\|\bar{\boldsymbol{Y}}\|_2 \leqslant CK^2 \left(\sqrt{\frac{\mathrm{tr}(\boldsymbol{\Sigma})}{N}} + u \sqrt{\frac{\|\boldsymbol{\Sigma}\|}{N}} \right) \ (\text{w.p. } 1 - 2\mathrm{e}^{-cu^2})。$$

令 $u = C\sqrt{\ln(2/\alpha)}$，即可得到所述尾部界。

如此，

$$Z = \|\boldsymbol{\mu}_N - \boldsymbol{\mu}\|_2 \leqslant CK^2 \left(\sqrt{\frac{\mathrm{tr}(\boldsymbol{\Sigma})}{N}} + \sqrt{\frac{\|\boldsymbol{\Sigma}\| \ln(1/\alpha)}{N}} \right) \ (\text{w.p. } 1 - \alpha)。$$

13 [**范数的各向异性集中**] 将定理 T3.1.1 (范数的集中) 推广到各向异性的分布。

设 $\boldsymbol{B} \in \mathbb{R}^{m \times n}$ 为固定矩阵，$\boldsymbol{X} \in \mathbb{R}^n$ 为中心化随机向量，其分量 X_i 是相互独立的标准化 sub-Gaussian 随机变量，记 $\max_i \|X_i\|_{\psi_2} = K$。证明：

$$\big\| \|\boldsymbol{B}\boldsymbol{X}\|_2 - \|\boldsymbol{B}\|_F \big\|_{\psi_2} \leqslant CK^2 \|\boldsymbol{B}\|。$$

证明 引入记号 $Z = f(\boldsymbol{X}) = \|\boldsymbol{B}\boldsymbol{X}\|_2 \geqslant 0$。若 $\boldsymbol{B} = 0$，则结论是平凡的；之后只需考虑 $E = \|\boldsymbol{B}\|_F > 0$ 的情况。

设 $Q = Z^2 = \|\boldsymbol{B}\boldsymbol{X}\|_2^2 = \boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{X}$，其中 $\boldsymbol{A} = \boldsymbol{B}^\top \boldsymbol{B}$，则

$$\mathrm{E}[Q] = \mathrm{tr}(\boldsymbol{A}) = \|\boldsymbol{B}\|_F^2 = E^2。$$

利用定理 T6.2.2 (Hanson–Wright 不等式) (Hanson–Wright 不等式)，可得对于任意的 $u \geqslant 0$，

$$\mathrm{P}\{|Q - E^2| \geqslant u\} \leqslant 2\exp\left(-c \min\left(\frac{u^2}{K^4 \|\boldsymbol{A}\|_F^2}, \frac{u}{K^2 \|\boldsymbol{A}\|} \right) \right),$$

代入 $\|\boldsymbol{A}\| = \|\boldsymbol{B}\|^2$，$\|\boldsymbol{A}\|_F^2 \leqslant \|\boldsymbol{B}\|^2 \|\boldsymbol{B}\|_F^2$，可得

$$\mathrm{P}\{|Z^2 - E^2| \geqslant u\} \leqslant 2\exp\left(-c \min\left(\frac{u^2}{K^4 \|\boldsymbol{B}\|^2 \|\boldsymbol{B}\|_F^2}, \frac{u}{K^2 \|\boldsymbol{B}\|^2} \right) \right)。$$

用 t 界定 $|Z^2 - E^2|$ 的下界：

a. 若 $0 \leqslant t \leqslant E$，则

$$|Z^2 - E^2| = |Z - E|(Z + E) \geqslant t \cdot E,$$

因此 $\{|Z - E| \geqslant t\} \subset \{|Z^2 - E^2| \geqslant tE\}$，满足

$$\begin{aligned} \mathrm{P}\{|Z - E| \geqslant t\} &\leqslant \mathrm{P}\{|Z^2 - E^2| \geqslant t\|\boldsymbol{B}\|_F\} \\ &\leqslant 2\exp\left(-c \min\left(\frac{t^2 \|\boldsymbol{B}\|_F^2}{K^4 \|\boldsymbol{B}\|^2 \|\boldsymbol{B}\|_F^2}, \frac{t\|\boldsymbol{B}\|_F}{K^2 \|\boldsymbol{B}\|^2} \right) \right) \\ &= 2\exp\left(-c \min\left(\frac{t^2}{K^4 \|\boldsymbol{B}\|^2}, \frac{t\|\boldsymbol{B}\|_F}{K^2 \|\boldsymbol{B}\|^2} \right) \right), \end{aligned}$$

其中当 $t \leqslant \|\boldsymbol{B}\|_F$ 时，

$$\frac{t\|\boldsymbol{B}\|_F}{K^2 \|\boldsymbol{B}\|^2} \geqslant \frac{t^2}{K^2 \|\boldsymbol{B}\|^2},$$

从而

$$\mathrm{P}\{|Z-E|\geqslant t\}\leqslant 2\exp\left(-\frac{c't^2}{K^4\|\boldsymbol{B}\|^2}\right)。\tag{I}$$

b. 若 $t>E$，则

$$|Z^2-E^2|=|Z-E|(Z+E)\geqslant t\cdot t=t^2,$$

因此 $\{|Z-E|\geqslant t\}\subset\{|Z^2-E^2|\geqslant t^2\}$，满足

$$\begin{aligned}\mathrm{P}\{|Z-E|\geqslant t\}&\leqslant \mathrm{P}\{|Z^2-E^2|\geqslant t^2\}\\&\leqslant 2\exp\left(-c\min\left(\frac{t^4}{K^4\|\boldsymbol{B}\|^2\|\boldsymbol{B}\|_F^2},\frac{t^2}{K^2\|\boldsymbol{B}\|^2}\right)\right),\end{aligned}$$

其中当 $t>\|\boldsymbol{B}\|_F$ 时，

$$\frac{t^4}{K^4\|\boldsymbol{B}\|^2\|\boldsymbol{B}\|_F^2}>\frac{t^2}{K^4\|\boldsymbol{B}\|^2},$$

从而

$$\mathrm{P}\{|Z-E|\geqslant t\}\leqslant 2\exp\left(-\frac{c't^2}{K^4\|\boldsymbol{B}\|^2}\right)。\tag{II}$$

如此，结合 (I)(II)，可得

$$\mathrm{P}\{|\|\boldsymbol{B}\boldsymbol{X}\|_2-\|\boldsymbol{B}\|_F|\geqslant t\}\leqslant 2\exp\left(-\frac{c't^2}{K^4\|\boldsymbol{B}\|^2}\right),$$

从而根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (i)，可得

$$\|\|\boldsymbol{B}\boldsymbol{X}\|_2-\|\boldsymbol{B}\|_F\|_{\psi_2}\leqslant CK^2\|\boldsymbol{B}\|。$$

14 [**随机向量到子空间的距离**] 设 $E\subset\mathbb{R}^n$ 满足 $\dim(E)=d$，$\boldsymbol{X}\in\mathbb{R}^n$ 为中心化且各向同性的随机向量，即 $\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]=\boldsymbol{I}_n$，其分量 X_i 为相互独立的 sub-Gaussian 随机变量，记 $\max_i\|X_i\|_{\psi_2}=K$。

(1) 证明：$(\mathrm{E}[\mathrm{dist}(\boldsymbol{X},E)^2])^{1/2}=\sqrt{n-d}$。

(2) 利用习题 Q6.13 (范数的各向异性集中)，证明：对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|\operatorname{dist}(\boldsymbol{X},E)-\sqrt{n-d}|>t\}\leqslant 2\exp\left(-\frac{ct^2}{K^4}\right)。$$

证明 (1) 设 $\boldsymbol{P}$ 为到正交补空间 $E^\perp$ 的正交投影矩阵，则

$$\mathrm{dist}(\boldsymbol{X},E)^2=\|\boldsymbol{P}\boldsymbol{X}\|_2^2=(\boldsymbol{P}\boldsymbol{X})^\top(\boldsymbol{P}\boldsymbol{X})=\boldsymbol{X}^\top\boldsymbol{P}^\top\boldsymbol{P}\boldsymbol{X}=\boldsymbol{X}^\top\boldsymbol{P}\boldsymbol{X},$$

因此

$$\mathrm{E}[\mathrm{dist}(\boldsymbol{X},E)^2]=\mathrm{E}[\boldsymbol{X}^\top\boldsymbol{P}\boldsymbol{X}]=\mathrm{E}[\mathrm{tr}(\boldsymbol{X}^\top\boldsymbol{P}\boldsymbol{X})]=\mathrm{tr}(\boldsymbol{P}\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top])=\mathrm{tr}(\boldsymbol{P})=\dim(E^\perp)=n-d,$$

即 $(\mathrm{E}[\mathrm{dist}(\boldsymbol{X},E)^2])^{1/2}=\sqrt{n-d}$。

(2) 若 $d=n$，则 $E=\mathbb{R}^n$，两条结论均直接成立。以下设 $d<n$。容易知道，

$$\|\boldsymbol{P}\|_F=\sqrt{\mathrm{tr}(\boldsymbol{P}^\top\boldsymbol{P})}=\sqrt{\mathrm{tr}(\boldsymbol{P})}=\sqrt{n-d},\ \|\boldsymbol{P}\|=1。$$

根据习题 Q6.13 (范数的各向异性集中)，令 $\boldsymbol{B}=\boldsymbol{P}$，此时 $\|\boldsymbol{P}\boldsymbol{X}\|_2=\mathrm{dist}(\boldsymbol{X},E)$，可得

$$\|\operatorname{dist}(\boldsymbol{X},E)-\sqrt{n-d}\|_{\psi_2}\leqslant CK^2\cdot 1=CK^2。$$

因此 $Z=\mathrm{dist}(\boldsymbol{X},E)-\sqrt{n-d}$ 为 CK^2-sub-Gaussian 随机变量，从而根据 sub-Gaussian 随机变量的等价定义，可得

$$\mathrm{P}\{|\operatorname{dist}(\boldsymbol{X},E)-\sqrt{n-d}|>t\}\leqslant 2\exp\left(-\frac{c_0t^2}{(CK^2)^2}\right)=2\exp\left(-\frac{ct^2}{K^4}\right)。\qquad\left(c=\frac{c_0}{C^2}\right)$$

15 [**随机切割图**] 考虑含有 E 条边的图，将其顶点随机分为两组 (任意的顶点以 1/2 的概率独立分配)。记此图的割 (即跨越两

组的边数) 为 cut，正如命题 P3.6.3 (最大割的 0.5-近似算法) 所述，$\mathrm{E}[\mathrm{cut}] = E/2$。证明：对于任意的 $s \geqslant 1$，

$$\mathrm{P}\left\{\left|\mathrm{cut} - \frac{E}{2}\right| \geqslant s\sqrt{E}\right\} \leqslant 2\mathrm{e}^{-cs}。$$

证明 定义随机向量 $\boldsymbol{X} \in \mathbb{R}^n$，其中 $X_i \sim$ Rademacher 为顶点 i 被分配的组别，则 X_i 为 sub-Gaussian 随机变量。

对于任意的 $e = \{i, j\} \in \mathcal{E}$，其被割断，当且仅当 $X_i \neq X_j$，即 $X_i X_j = -1$，构造指示函数

$$\mathbf{1}_{\{e \text{ 被割}\}} = \frac{1 - X_i X_j}{2},$$

则

$$\mathrm{cut} = \sum_{\{i,j\} \in \mathcal{E}} \frac{1 - X_i X_j}{2} = \frac{E}{2} - \frac{1}{2} \sum_{\{i,j\} \in \mathcal{E}} X_i X_j。$$

设 $\boldsymbol{A}$ 为此图的邻接矩阵，即

$$a_{ij} = \begin{cases} 1, \{i, j\} \in \mathcal{E}, \\ 0, \{i, j\} \notin \mathcal{E} \end{cases}$$

则

$$\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X} = \sum_{i,j} a_{ij} X_i X_j = 2 \sum_{\{i,j\} \in \mathcal{E}} X_i X_j,$$

因此

$$\mathrm{cut} - \frac{E}{2} = -\frac{1}{4} \boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X},$$

(注意到 $\mathrm{E}[\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X}] = \mathrm{tr}(\boldsymbol{A}) = 0$，这与已知条件 $\mathrm{E}[\mathrm{cut}] = E/2$ 一致。)

之后只需估计

$$\mathrm{P}\left\{\frac{1}{4}|\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X}| \geqslant s\sqrt{E}\right\} = \mathrm{P}\{|\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X}| \geqslant 4s\sqrt{E}\}。$$

利用定理 T6.2.2 (Hanson–Wright 不等式) (Hanson–Wright 不等式)，可得对于任意的 $t \geqslant 0$

$$\mathrm{P}\{|\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X}]| \geqslant t\} \leqslant 2\exp\left(-c_0 \min\left(\frac{t^2}{\|\boldsymbol{A}\|_F^2}, \frac{t}{\|\boldsymbol{A}\|}\right)\right),$$

令 $t = 4s\sqrt{E}$，则

$$\frac{t^2}{\|\boldsymbol{A}\|_F^2} = \frac{16 s^2 E}{2E} = 8s^2,$$

$$\frac{t}{\|\boldsymbol{A}\|} \geqslant \frac{t}{\|\boldsymbol{A}\|_F} = \frac{4s\sqrt{E}}{\sqrt{2E}} = 2\sqrt{2}s,$$

因此

$$\mathrm{P}\{|\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X} - \mathrm{E}[\boldsymbol{X}^\top \boldsymbol{A} \boldsymbol{X}]| \geqslant t\} \leqslant 2\exp\left(-c_0 \min(8s^2, 2\sqrt{2}s)\right),$$

即

$$\mathrm{P}\left\{\left|\mathrm{cut} - \frac{E}{2}\right| \geqslant s\sqrt{E}\right\} \leqslant 2\exp(-c_0 \cdot 2\sqrt{2}s) = 2\mathrm{e}^{-cs}。 \qquad (c = 2\sqrt{2}c_0)$$

16 [**构造对称分布**] 证明引理 L6.3.1 (构造对称分布)。

设 X 为随机变量，$\xi \sim$ Rademacher，满足 $X \perp \xi$。

(1) $\xi X \overset{d}{=} \xi |X|$，并且均为对称分布。

(2) 若 X 是对称的，那么 $\xi X, \xi |X| \overset{d}{=} X$。

(3) 若 X' 为 X 的独立副本，则 $X - X'$ 是对称的。

证明 (1) • 证明对称性

对于任意的 $A \in \mathscr{B}(\mathbb{R})$，利用全概率公式，可得

$$\begin{aligned}\mathrm{P}\{\xi X \in A\} &= \mathrm{P}\{\xi X \in A \mid \xi = 1\}\mathrm{P}\{\xi = 1\} + \mathrm{P}\{\xi X \in A \mid \xi = -1\}\mathrm{P}\{\xi = -1\} \\ &= \frac{1}{2}\mathrm{P}\{X \in A\} + \frac{1}{2}\mathrm{P}\{-X \in A\}, \\ \mathrm{P}\{-\xi X \in A\} &= \mathrm{P}\{-\xi X \in A \mid \xi = 1\}\mathrm{P}\{\xi = 1\} + \mathrm{P}\{-\xi X \in A \mid \xi = -1\}\mathrm{P}\{\xi = -1\} \\ &= \frac{1}{2}\mathrm{P}\{X \in A\} + \frac{1}{2}\mathrm{P}\{-X \in A\},\end{aligned}$$

因此 $\mathrm{P}\{\xi X \in A\} = \mathrm{P}\{-\xi X \in A\}$，即 ξX 是对称的。

同理，将 X 替换为 $|X|$，可得

$$\mathrm{P}\{\xi|X| \in A\} = \frac{1}{2}\mathrm{P}\{|X| \in A\} + \frac{1}{2}\mathrm{P}\{-|X| \in A\} = \mathrm{P}\{-\xi|X| \in A\},$$

因此 $\xi|X|$ 是对称的。

- 证明同分布

对于任意的 $A \in \mathscr{B}(\mathbb{R})$，将 X 分解为正、负与零值部分，可得

$$\begin{aligned}\mathrm{P}\{\xi X \in A\} &= \frac{1}{2}\mathrm{P}\{X \in A\} + \frac{1}{2}\mathrm{P}\{-X \in A\} \\ &= \frac{1}{2}\mathrm{P}\{|X| \in A\} + \frac{1}{2}\mathrm{P}\{-|X| \in A\} = \mathrm{P}\{\xi|X| \in A\}。\end{aligned}$$

即 $\xi X \overset{d}{=} \xi|X|$.

(2) 假设 X 是对称的，则对于任意的 $A \in \mathscr{B}(\mathbb{R})$，$\mathrm{P}\{-X \in A\} = \mathrm{P}\{X \in A\}$，因此

$$\begin{aligned}\mathrm{P}\{\xi X \in A\} &= \frac{1}{2}\mathrm{P}\{X \in A\} + \frac{1}{2}\mathrm{P}\{-X \in A\} \\ &= \frac{1}{2}\mathrm{P}\{X \in A\} + \frac{1}{2}\mathrm{P}\{X \in A\} = \mathrm{P}\{X \in A\},\end{aligned}$$

即 $\xi X \overset{d}{=} X$，从而结合 $\xi X \overset{d}{=} \xi|X|$，可得 $\xi|X| \overset{d}{=} X$。

(3) 注意到 $(X, X') \overset{d}{=} (X', X)$，构造函数 $g(u, v) = u - v$，则

$$X - X' = g(X, X') \overset{d}{=} g(X', X) = X' - X = -(X - X'),$$

因此 $X - X'$ 是对称的。

17 [**Bernoulli 分布，指数分布的对称化**] 回顾引理 L6.3.1 (构造对称分布) (3)，若 X' 为 X 的独立副本，则 $X - X'$ 是对称的。之后考虑两种典型情形，分别推导当 X 服从 Bernoulli 分布或指数分布时，随机变量 $X - X'$ 的分布。

(1) 设 $X \sim \mathrm{Bernoulli}(p)$，试求 $X - X'$ 的 PMF。

(2) 设 $X \sim E(1)$。证明 $X - X' \sim \mathrm{Laplace}(0, 1)$。

证明 (1) 令 $Y = X - X'$，则 $\mathrm{supp}(Y) = \{-1, 0, 1\}$。

a. 当 $Y = 1$ 时，

$$\mathrm{P}\{Y = 1\} = \mathrm{P}\{X = 1, X' = 0\} = \mathrm{P}\{X = 1\}\mathrm{P}\{X' = 0\} = p(1 - p)。$$

b. 当 $Y = -1$ 时，

$$\mathrm{P}\{Y = -1\} = \mathrm{P}\{X = 0, X' = 1\} = \mathrm{P}\{X = 0\}\mathrm{P}\{X' = 1\} = (1 - p)p,$$

c. 当 $Y = 0$ 时，

$$\mathrm{P}\{Y = 0\} = \mathrm{P}\{X = 1, X' = 1\} + \mathrm{P}\{X = 0, X' = 0\} = p \cdot p + (1 - p) \cdot (1 - p) = p^2 + (1 - p)^2。$$

如此，

$$\mathrm{P}\{X-X'=y\}=\begin{cases}p(1-p), & y=-1,1\\ p^2+(1-p)^2, & y=0\\ 0, & \text{其他}\end{cases}。$$

容易知道，$\mathrm{P}\{Y=-1\}=\mathrm{P}\{Y=1\}$，从而 $Y=X-X'$ 是关于 0 对称的。

(2) 令 $W=-X'$，则

$$f_X(x)=\begin{cases}\mathrm{e}^{-x}, & x\geqslant 0,\\ 0, & x<0\end{cases}，\quad f_W(w)=f_{X'}(-w)=\begin{cases}\mathrm{e}^{w}, & w\leqslant 0,\\ 0, & w>0\end{cases}。$$

令 $Y=X-X'=X+W$，则

$$f_Y(y)=\int_{-\infty}^{\infty}f_X(x)f_W(y-x)\mathrm{d}x。$$

若密度函数非零，则

$$\begin{aligned}f_X(x)>0 &\implies x\geqslant 0,\\ f_W(y-x)>0 &\implies y-x\leqslant 0 \implies x\geqslant y,\end{aligned}$$

即 $x\geqslant\max(0,y)$。

a. 若 $y\geqslant 0$，则

$$\begin{aligned}f_Y(y)&=\int_{y}^{\infty}\mathrm{e}^{-x}\mathrm{e}^{y-x}\mathrm{d}x=\mathrm{e}^{y}\int_{y}^{\infty}\mathrm{e}^{-2x}\mathrm{d}x=\mathrm{e}^{y}\left[-\frac{1}{2}\mathrm{e}^{-2x}\right]_{y}^{\infty}\\ &=\mathrm{e}^{y}\left(0-\left(-\frac{1}{2}\mathrm{e}^{-2y}\right)\right)=\frac{1}{2}\mathrm{e}^{-y}。\end{aligned}$$

b. 若 $y<0$，

$$\begin{aligned}f_Y(y)&=\int_{0}^{\infty}\mathrm{e}^{-x}\mathrm{e}^{y-x}\mathrm{d}x=\mathrm{e}^{y}\int_{0}^{\infty}\mathrm{e}^{-2x}\mathrm{d}x=\mathrm{e}^{y}\left[-\frac{1}{2}\mathrm{e}^{-2x}\right]_{0}^{\infty}\\ &=\mathrm{e}^{y}\left(0-\left(-\frac{1}{2}\mathrm{e}^{0}\right)\right)=\frac{1}{2}\mathrm{e}^{y},\end{aligned}$$

如此，

$$f_Y(y)=\frac{1}{2}\mathrm{e}^{-|y|},$$

即 $Y\sim\mathrm{Laplace}(0,1)$。

18 [**平移随机向量的范数**] 设 $\boldsymbol{X}$ 为定义于某赋范空间的对称随机向量，$\boldsymbol{v}$ 为此空间的固定向量。证明：

$$\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|\asymp\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|。$$

证明 要证明 $\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|\asymp\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|$，只需证明

$$c_1(\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|)\leqslant\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|\leqslant c_2(\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|)。\qquad(c_1,c_2>0)$$

- 证明上界

  (无需对称性) 利用三角不等式，可得

  $$\|\boldsymbol{X}+\boldsymbol{v}\|\leqslant\|\boldsymbol{X}\|+\|\boldsymbol{v}\|,$$

  两侧取期望，

  $$\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|\leqslant\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|=\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|,$$

  此时令 $c_2=1$。

- 证明下界

对于 $2\boldsymbol{v}$，利用三角不等式，可得

$$\|2\boldsymbol{v}\| = \|\boldsymbol{v}+\boldsymbol{v}+\boldsymbol{X}-\boldsymbol{X}\| = \|(\boldsymbol{v}+\boldsymbol{X})+(\boldsymbol{v}-\boldsymbol{X})\| \leqslant \|\boldsymbol{v}+\boldsymbol{X}\|+\|\boldsymbol{v}-\boldsymbol{X}\|,$$

两侧取期望，

$$2\|\boldsymbol{v}\| \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|+\mathrm{E}\|\boldsymbol{v}-\boldsymbol{X}\|。$$

由于 $\boldsymbol{X} \overset{d}{=} -\boldsymbol{X}$，因此 $\boldsymbol{v}-\boldsymbol{X} \overset{d}{=} \boldsymbol{v}+\boldsymbol{X}$，从而 $\mathrm{E}\|\boldsymbol{v}-\boldsymbol{X}\| = \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|$，将其代入，可得

$$2\|\boldsymbol{v}\| \leqslant 2\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\| \implies \|\boldsymbol{v}\| \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|。 \tag{I}$$

同理，对于 $2\boldsymbol{X}$，

$$\begin{aligned}&\|2\boldsymbol{X}\| = \|\boldsymbol{X}+\boldsymbol{X}+\boldsymbol{v}-\boldsymbol{v}\| = \|(\boldsymbol{X}+\boldsymbol{v})+(\boldsymbol{X}-\boldsymbol{v})\| \leqslant \|\boldsymbol{X}+\boldsymbol{v}\|+\|\boldsymbol{X}-\boldsymbol{v}\| \\ &\implies 2\mathrm{E}\|\boldsymbol{X}\| \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|+\mathrm{E}\|\boldsymbol{X}-\boldsymbol{v}\| \\ &\implies 2\mathrm{E}\|\boldsymbol{X}\| \leqslant 2\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\| \implies \mathrm{E}\|\boldsymbol{X}\| \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|。\end{aligned} \tag{II}$$

联立 (I)(II)，可得

$$\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\| \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|+\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\| = 2\mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\| \implies \frac{1}{2}(\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|) \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\|,$$

此时 $c_1 = 1/2$。

如此，

$$\frac{1}{2}(\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|) \leqslant \mathrm{E}\|\boldsymbol{X}+\boldsymbol{v}\| \leqslant 1\cdot(\mathrm{E}\|\boldsymbol{X}\|+\|\boldsymbol{v}\|)。$$

19 [非零均值的对称化]

(1) 设 $\boldsymbol{X}_i$ 为未必含有零均值的随机向量，证明引理 L6.3.2 (对称化) 的推广形式，

$$\mathrm{E}\left\|\sum_{i=1}^N \boldsymbol{X}_i - \sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i]\right\| \leqslant 2\mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|。$$

其中 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher。

(2) 证明：不存在任意非平凡的反向不等式。

证明 (1) 设 $\boldsymbol{X}_1',\cdots,\boldsymbol{X}_N'$ 为 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 的独立副本，将 $\mathrm{E}[\boldsymbol{X}_i]$ 写为 $\mathrm{E}_{\boldsymbol{X}'}[\boldsymbol{X}_i']$，则中心化随机变量之和为

$$\sum_{i=1}^N \boldsymbol{X}_i - \sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i] = \sum_{i=1}^N \boldsymbol{X}_i - \mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N \boldsymbol{X}_i'\right] = \mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right],$$

两侧取范数，之后对外层变量 $\boldsymbol{X}$ 取期望，

$$\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^N \boldsymbol{X}_i - \sum_{i=1}^N \mathrm{E}[\boldsymbol{X}_i]\right\| = \mathrm{E}_{\boldsymbol{X}}\left\|\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right]\right\|。 \tag{I}$$

对于右侧，利用 Jensen 不等式，可得

$$\mathrm{E}_{\boldsymbol{X}}\left\|\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right]\right\| \leqslant \mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left\|\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right\|,$$

其中

$$\begin{aligned}\mathrm{E}\left\|\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right\| &= \mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')\right\| && (\boldsymbol{X}_i - \boldsymbol{X}_i' \overset{d}{=} \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')) \\ &\leqslant \mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\| + \mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i'\right\| \\ &= 2\mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|,\end{aligned}$$

因此

$$\mathrm{E}_{\boldsymbol{X}}\left\|\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right]\right\|\leqslant 2\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|。\tag{II}$$

联立 (I)(II)，可得

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i-\sum_{i=1}^{N}\mathrm{E}[\boldsymbol{X}_i]\right\|\leqslant 2\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|。$$

(2) 要证明

$$c\cdot\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|\leqslant\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i-\sum_{i=1}^{N}\mathrm{E}[\boldsymbol{X}_i]\right\|\qquad(c>0)$$

不存在，只需构造反例即可。

设 $\boldsymbol{X}_i\equiv\boldsymbol{v}$ 为非零退化向量，满足 $\|\boldsymbol{v}\|>0$，则

$$\mathrm{RHS}=\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i-\sum_{i=1}^{N}\mathrm{E}[\boldsymbol{X}_i]\right\|=\mathrm{E}\|N\boldsymbol{v}-N\boldsymbol{v}\|=0,$$

$$\mathrm{LHS}=\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|=\mathrm{E}\left\|\left(\sum_{i=1}^{N}\varepsilon_i\right)\boldsymbol{v}\right\|=\mathrm{E}\left|\sum_{i=1}^{N}\varepsilon_i\right|\cdot\|\boldsymbol{v}\|,$$

其中 $\sum_{i=1}^{N}\varepsilon_i$ 为一维对称随机游走，满足 $\mathrm{E}|\sum_{i=1}^{N}\varepsilon_i|\asymp\sqrt{N}$，因此

$$\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|\asymp\sqrt{N}\|\boldsymbol{v}\|>0,$$

这是矛盾的；因此引理 L6.3.2 (对称化) 的下界依赖于零均值，倘若忽略零均值的限制，仅可能保留上界，但是下界将失效。

20 [**带有凸函数的对称化**] 证明对称化引理 L6.3.2 (对称化) 的推广形式。

设 $F:\mathbb{R}^+\to\mathbb{R}$ 为单调递增的凸函数，$\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为相互独立的零均值随机向量，$\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher。证明：若将 $\|\cdot\|$ 替换为 $F(\|\cdot\|)$，引理 L6.3.2 (对称化) 的不等式依然成立，即

$$\mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|\right)\right]\leqslant\mathrm{E}\left[F\left(\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\right)\right]\leqslant\mathrm{E}\left[F\left(2\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|\right)\right]。$$

证明 对于任意的 $t\in[0,1]$，

$$G(t\boldsymbol{x}+(1-t)\boldsymbol{y})=F(\|t\boldsymbol{x}+(1-t)\boldsymbol{y}\|)\leqslant F(t\|\boldsymbol{x}\|+(1-t)\|\boldsymbol{y}\|)\leqslant tF(\|\boldsymbol{x}\|)+(1-t)F(\|\boldsymbol{y}\|)=tG(\boldsymbol{x})+(1-t)G(\boldsymbol{y}),$$

因此 G 为凸函数。

- 证明上界

考虑 $\sum_{i=1}^{N}\boldsymbol{X}_i$，进行逆向构造，

$$\sum_{i=1}^{N}\boldsymbol{X}_i=\sum_{i=1}^{N}\boldsymbol{X}_i-\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^{N}\boldsymbol{X}_i'\right]=\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right],$$

利用 Jensen 不等式，可得

$$F\left(\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\right)=F\left(\left\|\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right]\right\|\right)\leqslant\mathrm{E}_{\boldsymbol{X}'}\left[F\left(\left\|\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|\right)\right],$$

两侧对 $\boldsymbol{X}$ 取期望，

$$\mathrm{E}_{\boldsymbol{X}}\left[F\left(\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\right)\right]\leqslant\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left[F\left(\left\|\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|\right)\right]。$$

对于右侧，代入 $\boldsymbol{X}_i - \boldsymbol{X}_i' \overset{d}{=} \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')$，利用三角不等式，可得

$$\begin{aligned}\text{RHS} &= \mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i - \sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i'\right\|\right)\right] \\ &\leqslant \mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\| + \left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i'\right\|\right)\right],\end{aligned}$$

利用凸性不等式

$$F(a+b) = F\left(\frac{1}{2}(2a) + \frac{1}{2}(2b)\right) \leqslant \frac{1}{2}F(2a) + \frac{1}{2}F(2b),$$

可得

$$\begin{aligned}\text{RHS} &\leqslant \frac{1}{2}\mathrm{E}\left[F\left(2\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|\right)\right] + \frac{1}{2}\mathrm{E}\left[F\left(2\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i'\right\|\right)\right] \\ &\leqslant \mathrm{E}\left[F\left(2\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|\right)\right],\end{aligned}$$

因此

$$\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\|\right)\right] \leqslant \mathrm{E}\left[F\left(2\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|\right)\right]。$$

- 证明下界

考虑 $\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i$，进行逆向构造，

$$\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i = \sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \mathrm{E}_{\boldsymbol{X}'}[\boldsymbol{X}_i']) = \mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')\right],$$

利用 Jensen 不等式，可得

$$F\left(\frac{1}{2}\left\|\mathrm{E}_{\boldsymbol{X}'}\left[\sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')\right]\right\|\right) \leqslant \mathrm{E}_{\boldsymbol{X}'}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')\right\|\right)\right],$$

两侧对 $\boldsymbol{X}, \varepsilon$ 取期望，

$$\mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^N \varepsilon_i \boldsymbol{X}_i\right\|\right)\right] \leqslant \mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^N \varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i')\right\|\right)\right]。$$

对于右侧，代入 $\varepsilon_i(\boldsymbol{X}_i - \boldsymbol{X}_i') \overset{d}{=} \boldsymbol{X}_i - \boldsymbol{X}_i'$，利用三角不等式，可得

$$\begin{aligned}\text{RHS} &= \mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^N (\boldsymbol{X}_i - \boldsymbol{X}_i')\right\|\right)\right] \\ &\leqslant \mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\| + \frac{1}{2}\left\|\sum_{i=1}^N \boldsymbol{X}_i'\right\|\right)\right],\end{aligned}$$

利用凸性不等式

$$F(a+b) = F\left(\frac{1}{2}(2a) + \frac{1}{2}(2b)\right) \leqslant \frac{1}{2}F(2a) + \frac{1}{2}F(2b),$$

可得

$$\text{RHS} \leqslant \frac{1}{2}\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\|\right)\right] + \frac{1}{2}\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \boldsymbol{X}_i'\right\|\right)\right] = \mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\|\right)\right],$$

因此

$$\mathrm{E}\left[F\left(\frac{1}{2}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{X}_i\right\|\right)\right]\leqslant\mathrm{E}\left[F\left(\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\right)\right]。$$

21 [**sub-Gaussian 和的对称化**] 设 $X_1,\cdots,X_N$ 为相互独立的零均值随机变量。证明：$\sum_{i=1}^{N}X_i$ 为 sub-Gaussian 随机变量，当且仅当其对称化版本 $\sum_{i=1}^{N}\varepsilon_iX_i$ 是 sub-Gaussian 随机变量，此时

$$c\left\|\sum_{i=1}^{N}\varepsilon_iX_i\right\|_{\psi_2}\leqslant\left\|\sum_{i=1}^{N}X_i\right\|_{\psi_2}\leqslant C\left\|\sum_{i=1}^{N}\varepsilon_iX_i\right\|_{\psi_2}。$$

证明 记 $S=\sum_{i=1}^{N}X_i$，$S_\varepsilon=\sum_{i=1}^{N}\varepsilon_iX_i$，我们之后只需证明

$$c\|S_\varepsilon\|_{\psi_2}\leqslant\|S\|_{\psi_2}\leqslant C\|S_\varepsilon\|_{\psi_2}。$$

(回顾 sub-Gaussian 范数的标准定义

$$\|Z\|_{\psi_2}=\inf\left\{K>0:\mathrm{E}\left[\exp\left(\frac{|Z|^2}{K^2}\right)\right]\leqslant 2\right\},$$

因此构造 $F(x)=\exp(x^2/t^2)$。)

- 证明上界

  若 S_ε 为 sub-Gaussian 随机变量，满足 $\|S_\varepsilon\|_{\psi_2}=K<\infty$，则

  $$\mathrm{E}\left[\exp\left(\frac{|S_\varepsilon|^2}{K^2}\right)\right]\leqslant 2。$$

  根据习题 Q6.20 (带有凸函数的对称化)，令 $F(x)=\exp(x^2/t^2)$，可得

  $$\mathrm{E}\left[\exp\left(\frac{|S|^2}{t^2}\right)\right]\leqslant\mathrm{E}\left[\exp\left(\frac{(2|S_\varepsilon|)^2}{t^2}\right)\right]=\mathrm{E}\left[\exp\left(\frac{4|S_\varepsilon|^2}{t^2}\right)\right],$$

  之后令 $\frac{4}{t^2}=\frac{1}{K^2}$，即 $t=2K$，可得

  $$\mathrm{E}\left[\exp\left(\frac{|S|^2}{(2K)^2}\right)\right]\leqslant\mathrm{E}\left[\exp\left(\frac{|S_\varepsilon|^2}{K^2}\right)\right]\leqslant 2,$$

  因此

  $$\|S\|_{\psi_2}\leqslant 2K=2\|S_\varepsilon\|_{\psi_2},$$

  此时令 $C=2$。

- 证明下界

  若 S 为 sub-Gaussian 随机变量，满足 $\|S\|_{\psi_2}=M<\infty$，则

  $$\mathrm{E}\left[\exp\left(\frac{|S|^2}{M^2}\right)\right]\leqslant 2。$$

  根据习题 Q6.20 (带有凸函数的对称化)，令 $F(x)=\exp(x^2/t^2)$，可得

  $$\mathrm{E}\left[\exp\left(\frac{(|S_\varepsilon|/2)^2}{t^2}\right)\right]\leqslant\mathrm{E}\left[\exp\left(\frac{|S|^2}{t^2}\right)\right],$$

  之后令 $t=M$，可得

  $$\mathrm{E}\left[\exp\left(\frac{|S_\varepsilon|^2}{(2M)^2}\right)\right]\leqslant\mathrm{E}\left[\exp\left(\frac{|S|^2}{M^2}\right)\right]\leqslant 2,$$

  因此

  $$\|S_\varepsilon\|_{\psi_2}\leqslant 2M=2\|S\|_{\psi_2}\implies\frac{1}{2}\|S_\varepsilon\|_{\psi_2}\leqslant\|S\|_{\psi_2},$$

  此时令 $c=1/2$。

22 [**自标准化和**] 设 $X_1,\cdots,X_N$ 为相互独立的对称随机变量。证明：对于任意的 $t>0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right|>t\left(\sum_{i=1}^N X_i^2\right)^{1/2}\right\}\leqslant 2\mathrm{e}^{-t^2/2}。$$

证明 引入独立于 X_i 的 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，则 $X_i\overset{d}{=}\varepsilon_i|X_i|$。

记 $A_i=|X_i|$，则

$$\mathrm{LHS}=\mathrm{P}\left\{\left|\sum_{i=1}^N \varepsilon_i A_i\right|>t\left(\sum_{i=1}^N (\varepsilon_i A_i)^2\right)^{1/2}\right\}=\mathrm{P}\left\{\left|\sum_{i=1}^N \varepsilon_i A_i\right|>t\left(\sum_{i=1}^N A_i^2\right)^{1/2}\right\}。$$

(由于 X_i 可能不存在任意矩，直接对上述概率求界是不可行的。但是，由于 ε_i, A_i 是相互独立的，我们可以采用条件化策略。)

设 $\mathscr{F}=\sigma(A_1,\cdots,A_N)$，利用定理 T2.2.1 (Hoeffding 不等式) (Hoeffding 不等式)，可得对于任意的 $u>0$，

$$\mathrm{P}\left\{\left|\sum_{i=1}^N \varepsilon_i A_i\right|\geqslant u\,\middle|\,\mathscr{F}\right\}\leqslant 2\exp\left(-\frac{u^2}{2\sum_{i=1}^N A_i^2}\right),$$

当 $\sum_{i=1}^N A_i^2=0$ 时，该严格事件为空。以下于 $\sum_{i=1}^N A_i^2>0$ 的条件下代入阈值 $u=t(\sum_{i=1}^N A_i^2)^{1/2}$，可得

$$\mathrm{P}\left\{\left|\sum_{i=1}^N \varepsilon_i A_i\right|>t\left(\sum_{i=1}^N A_i^2\right)^{1/2}\,\middle|\,\mathscr{F}\right\}\leqslant 2\exp\left(-\frac{t^2}{2}\right),$$

两侧去条件化，

$$\mathrm{E}_{\mathscr{F}}\left[\mathrm{P}\left\{\left|\sum_{i=1}^N \varepsilon_i A_i\right|>t\left(\sum_{i=1}^N A_i^2\right)^{1/2}\,\middle|\,\mathscr{F}\right\}\right]\leqslant \mathrm{E}_{\mathscr{F}}[2\mathrm{e}^{-t^2/2}]。$$

即

$$\mathrm{P}\left\{\left|\sum_{i=1}^N X_i\right|>t\left(\sum_{i=1}^N X_i^2\right)^{1/2}\right\}\leqslant 2\mathrm{e}^{-t^2/2}。$$

23 [**Type p 性质**] 提供一个更加宏观的视角：对于赋范空间 X，若存在 $K>0$，使得对于任意的 $N\in\mathbb{Z}^+$, $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N\in X$，均满足

$$\mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|^p\leqslant K^p\sum_{i=1}^N\|\boldsymbol{x}_i\|^p。$$

则称此空间满足 p 型 (Type p) 性质。于习题 Q6.22 (自标准化和), 习题 Q6.23 (Type p 性质)，我们将证明：ℓ^p 空间满足 Type p 性质，当且仅当 $p\in[1,2]$；满足 Type 2 性质，当且仅当 $p\in[2,\infty)$。

设 $p\in[1,2]$。

(1) 设 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N\in\mathbb{R}^n$ 为固定的向量，证明：

$$\mathrm{E}\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|_p^p\leqslant\sum_{i=1}^N\|\boldsymbol{x}_i\|_p^p。$$

(2) 设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N\in\mathbb{R}^n$ 为零均值, 相互独立的随机向量，证明：

$$\mathrm{E}\left\|\sum_{i=1}^N \boldsymbol{X}_i\right\|_p^p\leqslant\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

(3) 举例说明，当 $p>2$ 时，上述结论未必成立。

解答 (1) 设 $\boldsymbol{x}_i=(x_{i1},\cdots,x_{in})\in\mathbb{R}^n$，则

$$\mathrm{E}\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{x}_i\right\|_p^p=\mathrm{E}\left[\sum_{j=1}^n\left|\sum_{i=1}^N\varepsilon_i x_{ij}\right|^p\right]=\sum_{j=1}^n\mathrm{E}\left|\sum_{i=1}^N\varepsilon_i x_{ij}\right|^p。$$

利用 Khintchine 不等式，之后利用不等式 $(\sum a_i)^r\leqslant\sum a_i^r$ $(0\leqslant r\leqslant 1)$，可得

$$\begin{aligned}\mathrm{E}\left|\sum_{i=1}^N\varepsilon_i x_{ij}\right|^p&\leqslant\left(\mathrm{E}\left|\sum_{i=1}^N\varepsilon_i x_{ij}\right|^2\right)^{p/2}=\left(\sum_{i=1}^N x_{ij}^2\right)^{p/2}\\&\leqslant\sum_{i=1}^N(x_{ij}^2)^{p/2}=\sum_{i=1}^N|x_{ij}|^p,\end{aligned}$$

将其代入，可得

$$\mathrm{E}\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{x}_i\right\|_p^p\leqslant\sum_{i=1}^N\|\boldsymbol{x}_i\|_p^p。$$

(2) **解法一**

根据习题 Q6.20 (*带有凸函数的对称化*)，令 $F(t)=t^p$，可得

$$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p\leqslant\mathrm{E}\left[2^p\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{X}_i\right\|_p^p\right]=2^p\mathrm{E}_{\boldsymbol{X}}\left[\mathrm{E}_\varepsilon\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{X}_i\right\|_p^p\right],$$

利用 (1) 的结论，可得

$$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p\leqslant 2^p\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

解法二　对称化技巧

- 倘若 $\boldsymbol{X}_i$ 是对称分布的，可得系数为 1

  若 $\boldsymbol{X}_i\overset{d}{=}-\boldsymbol{X}_i$，则 $\boldsymbol{X}_i\overset{d}{=}\varepsilon_i\boldsymbol{X}_i$。

  利用 (1) 的结论，可得

  $$\mathrm{E}_\varepsilon\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{X}_i\right\|_p^p\leqslant\sum_{i=1}^N\|\boldsymbol{X}_i\|_p^p,$$

  两侧对 $\boldsymbol{X}$ 取期望，可得

  $$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p=\mathrm{E}_{\boldsymbol{X}}\left[\mathrm{E}_\varepsilon\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{X}_i\right\|_p^p\right]\leqslant\mathrm{E}_{\boldsymbol{X}}\left[\sum_{i=1}^N\|\boldsymbol{X}_i\|_p^p\right]=\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

- 倘若只有零均值假设，只能得到系数为 2^p

  引入独立副本 $\boldsymbol{X}_i'$，可得

  $$\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p=\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^N(\boldsymbol{X}_i-\mathrm{E}[\boldsymbol{X}_i'])\right\|_p^p\leqslant\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left\|\sum_{i=1}^N(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^p。$$

  对于右侧，由于 $\boldsymbol{X}_i-\boldsymbol{X}_i'$ 是对称分布的，因此

  $$\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left\|\sum_{i=1}^N(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^p\leqslant\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i-\boldsymbol{X}_i'\|_p^p,$$

  其中利用不等式 $(a+b)^p\leqslant 2^{p-1}(a^p+b^p)$，可得

  $$\mathrm{E}\|\boldsymbol{X}_i-\boldsymbol{X}_i'\|_p^p\leqslant 2^{p-1}\mathrm{E}[(\|\boldsymbol{X}_i\|_p+\|\boldsymbol{X}_i'\|_p)^p]\leqslant 2^{p-1}(2\mathrm{E}\|\boldsymbol{X}_i\|_p^p)=2^p\mathrm{E}\|\boldsymbol{X}_i\|_p^p,$$

将其代入，可得

$$\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i-\boldsymbol{X}_i'\|_p^p\leqslant 2^p\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^p,$$

因此

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^p\leqslant 2^p\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

(3) 取标量空间 $X=\mathbb{R}$，并令 $x_1=\cdots=x_N=1$。若 Type p 不等式成立，则

$$\mathrm{E}\left|\sum_{i=1}^{N}\varepsilon_i\right|^p\leqslant K^pN。$$

另一方面，由 L^p 范数的单调性，

$$\mathrm{E}\left|\sum_{i=1}^{N}\varepsilon_i\right|^p\geqslant\left(\mathrm{E}\left|\sum_{i=1}^{N}\varepsilon_i\right|^2\right)^{p/2}=N^{p/2}。$$

因而 $N^{p/2-1}\leqslant K^p$ 对所有 N 成立；当 $p>2$ 且 $N\to\infty$ 时矛盾。

注释 von Bahr-Esseen 于 1965 年的论文 Inequalities for the rth Absolute Moment of a Sum of Random Variables, $1\leqslant r\leqslant 2$ 指出，对于一般的零均值变量，最优系数是 2；而当随机变量对称时，最佳系数为 1。

- 证明对称化情形 (系数为 1)

当 $p=2$ 时，根据正交性，直接展开平方即得常数 1；当 $p=1$ 时，利用三角不等式即得常数 1；之后只需考虑非平凡的 $p\in(1,2)$。

- 首先考虑标量情形

作出以下引理：

引理 对于 $p\in(0,2)$，

$$|x|^p=C_p\int_0^\infty\frac{1-\cos(tx)}{t^{p+1}}\mathrm{d}t。\qquad\left(C_p=\left(\int_0^\infty\frac{1-\cos u}{u^{p+1}}\mathrm{d}u\right)^{-1}\right)$$

设 $Y_1,\cdots,Y_N$ 为相互独立的对称随机变量，则根据引理，可得

$$\mathrm{E}\left|\sum_{k=1}^{N}Y_k\right|^p=C_p\int_0^\infty\frac{1-\mathrm{E}\left[\cos(t\sum_{k=1}^{N}Y_k)\right]}{t^{p+1}}\mathrm{d}t。$$

注意到

$$\mathrm{E}\left[\cos\left(t\sum_{k=1}^{N}Y_k\right)\right]=\Re\left(\mathrm{E}\left[\exp\left(\mathrm{i}t\sum_{k=1}^{N}Y_k\right)\right]\right)=\Re\left(\prod_{k=1}^{N}\mathrm{E}[\mathrm{e}^{\mathrm{i}tY_k}]\right),$$

由于 Y_k 是对称的，因此特征函数的虚部期望为 $\mathrm{E}[\sin(tY_k)]=0$，此时

$$\varphi_k(t)=\mathrm{E}[\cos(tY_k)],$$

从而

$$1-\mathrm{E}\left[\cos\left(t\sum_{k=1}^{N}Y_k\right)\right]=1-\prod_{k=1}^{N}\varphi_k(t),$$

(我们之后需要对 $1-\prod_{k=1}^{N}\varphi_k(t)$ 放缩。)

利用不等式

$$1-\prod_{k=1}^{N}u_k\leqslant\sum_{k=1}^{N}(1-u_k),\qquad(u_k\leqslant 1)$$

令 $u_k=\varphi_k(t)$，可得

$$\mathrm{E}\left|\sum_{k=1}^N Y_k\right|^p \leqslant C_p\int_0^\infty \frac{\sum_{k=1}^N(1-\mathrm{E}[\cos(tY_k)])}{t^{p+1}}\mathrm{d}t$$
$$=\sum_{k=1}^N\left(C_p\int_0^\infty\frac{1-\mathrm{E}[\cos(tY_k)]}{t^{p+1}}\mathrm{d}t\right)=\sum_{k=1}^N\mathrm{E}|Y_k|^p。$$

- 之后推广至 ℓ_p 范数

设 $\boldsymbol{X}_i=(X_{i1},\cdots,X_{in})\in\mathbb{R}^n$，则

$$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p=\mathrm{E}\left[\sum_{j=1}^n\left|\sum_{i=1}^N X_{ij}\right|^p\right]=\sum_{j=1}^n\mathrm{E}\left|\sum_{i=1}^N X_{ij}\right|^p。$$

对于右侧，利用 (1) 的结论，可得

$$\sum_{j=1}^n\mathrm{E}\left|\sum_{i=1}^N X_{ij}\right|^p\leqslant\sum_{j=1}^n\left(\sum_{i=1}^N\mathrm{E}|X_{ij}|^p\right)=\sum_{i=1}^N\mathrm{E}\left[\sum_{j=1}^n|X_{ij}|^p\right]=\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p,$$

因此

$$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p=\mathrm{E}\left[\sum_{j=1}^n\left|\sum_{i=1}^N X_{ij}\right|^p\right]=\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

- 证明一般情形 (系数为 2)

作出以下引理：

引理 对于 $p\in[1,2]$，

$$|x+y|^p\leqslant|x|^p+p|x|^{p-1}\mathrm{sgn}(x)y+2|y|^p。$$

设 X,Y 为独立随机变量，满足 $\mathrm{E}[Y]=0$，则根据引理，可得

$$|X+Y|^p\leqslant|X|^p+p|X|^{p-1}\mathrm{sgn}(X)Y+2|Y|^p,$$

两侧对 X 取条件期望，

$$\mathrm{E}[|X+Y|^p\mid X]\leqslant|X|^p+p|X|^{p-1}\mathrm{sgn}(X)\mathrm{E}[Y]+2\mathrm{E}[|Y|^p]=|X|^p+2\mathrm{E}[|Y|^p],$$

将其推广至 N 项，设 $Y_1,\cdots,Y_N$ 为相互独立的零均值随机变量，令 $X=\sum_{i=1}^{k-1}Y_i$，$Y=Y_k$，可得

$$\mathrm{E}\left|\sum_{i=1}^k Y_i\right|^p\leqslant\mathrm{E}\left|\sum_{i=1}^{k-1}Y_i\right|^p+2\mathrm{E}|Y_k|^p,$$

利用数学归纳法，可得

$$\mathrm{E}\left|\sum_{i=1}^N Y_i\right|^p\leqslant\mathrm{E}|Y_1|^p+2\mathrm{E}|Y_2|^p+\cdots+2\mathrm{E}|Y_N|^p\leqslant 2\sum_{i=1}^N\mathrm{E}|Y_i|^p。$$

之后将其推广至 ℓ_p 范数，设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为相互独立的零均值随机向量，则

$$\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|_p^p=\mathrm{E}\left[\sum_{j=1}^n\left|\sum_{i=1}^N X_{ij}\right|^p\right]=\sum_{j=1}^n\mathrm{E}\left|\sum_{i=1}^N X_{ij}\right|^p。$$

对于右侧，注意到坐标分量 $X_{1j},\cdots,X_{Nj}$ 是相互独立的零均值随机变量，因此

$$\sum_{j=1}^n\mathrm{E}\left|\sum_{i=1}^N X_{ij}\right|^p\leqslant\sum_{j=1}^n\left(2\sum_{i=1}^N\mathrm{E}|X_{ij}|^p\right)=2\sum_{i=1}^N\mathrm{E}\left[\sum_{j=1}^n|X_{ij}|^p\right]=2\sum_{i=1}^N\mathrm{E}\|\boldsymbol{X}_i\|_p^p,$$

将其代入，可得

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^p \leqslant 2\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

注释 **Burkholder-Davis-Gundy (BDG) 不等式** 定义二次变差为差分平方之和

$$[S]_N=\sum_{i=1}^{N}\Delta_i^2=\sum_{i=1}^{N}Y_i^2,$$

则对于任意的 $p>0$，

$$\mathrm{E}|S_N|^p \leqslant C_p\mathrm{E}[[S]_N^{p/2}]。 \qquad (C_p>0)$$

利用 BDG 不等式，我们可以证明：对于任意的 $p>0$，

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^p \lesssim \sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

注意到

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^p=\mathrm{E}\left[\sum_{j=1}^{n}\left|\sum_{i=1}^{N}X_{ij}\right|^p\right]=\sum_{j=1}^{n}\mathrm{E}\left|\sum_{i=1}^{N}X_{ij}\right|^p, \qquad (\mathrm{I})$$

因此只需证明对于任意的维度 j，

$$\mathrm{E}\left|\sum_{i=1}^{N}X_{ij}\right|^p \lesssim \sum_{i=1}^{N}\mathrm{E}|X_{ij}|^p。$$

设 $Y_i=X_{ij}$，则 $Y_1,\cdots,Y_N$ 是相互独立的零均值随机变量。
定义前缀和 $S_k=\sum_{i=1}^{k}Y_i$, 自然滤波 $\mathscr{F}_k=\sigma(Y_1,\cdots,Y_k)$，则 $\mathrm{E}[Y_k\mid\mathscr{F}_{k-1}]=\mathrm{E}[Y_k]=0$，因此 $\{S_k\}_{k=1}^N$ 为离散时间鞅，其鞅差分为 $\Delta_k=S_k-S_{k-1}=Y_k$。
利用 BDG 不等式，可得

$$\mathrm{E}\left|\sum_{i=1}^{N}Y_i\right|^p \leqslant C_p\mathrm{E}\left[\left(\sum_{i=1}^{N}Y_i^2\right)^{p/2}\right], \qquad (\mathrm{II})$$

注意到 $f(t)=t^{p/2}$ 为凹函数，满足次可加性

$$\left(\sum_{i=1}^{N}a_i\right)^{p/2} \leqslant \sum_{i=1}^{N}a_i^{p/2}, \qquad (a_i\geqslant 0)$$

令 $a_i=Y_i^2\geqslant 0$，可得

$$\left(\sum_{i=1}^{N}Y_i^2\right)^{p/2} \leqslant \sum_{i=1}^{N}(Y_i^2)^{p/2}=\sum_{i=1}^{N}|Y_i|^p, \qquad (\mathrm{III})$$

将其代入于 (II)，可得

$$\mathrm{E}\left|\sum_{i=1}^{N}Y_i\right|^p \leqslant C_p\mathrm{E}\left[\sum_{i=1}^{N}|Y_i|^p\right]=C_p\sum_{i=1}^{N}\mathrm{E}|Y_i|^p,$$

将其代入于 (I)，可得

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^p=\sum_{j=1}^{n}\mathrm{E}\left|\sum_{i=1}^{N}X_{ij}\right|^p \leqslant C_p\sum_{j=1}^{n}\sum_{i=1}^{N}\mathrm{E}|X_{ij}|^p$$

$$= C_p \sum_{i=1}^{N} \left(\sum_{j=1}^{n} \mathrm{E}|X_{ij}|^p \right) = C_p \sum_{i=1}^{N} \mathrm{E}\left[\sum_{j=1}^{n} |X_{ij}|^p \right] = C_p \sum_{i=1}^{N} \mathrm{E}\|\boldsymbol{X}_i\|_p^p。$$

24 [**Type 2 性质**] 设 $p \in [2, \infty)$。[1]

(1) 设 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N \in \mathbb{R}^n$ 为任意的固定向量，证明：

$$\mathrm{E}\left\| \sum_{i=1}^{N} \varepsilon_i \boldsymbol{x}_i \right\|_p^2 \leqslant Cp \sum_{i=1}^{N} \|\boldsymbol{x}_i\|_p^2。 \qquad (C > 0)$$

(2) 将 (1) 进行推广。设 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_N \in \mathbb{R}^n$ 为相互独立的零均值随机向量，证明：

$$\mathrm{E}\left\| \sum_{i=1}^{N} \boldsymbol{X}_i \right\|_p^2 \leqslant Cp \sum_{i=1}^{N} \mathrm{E}\|\boldsymbol{X}_i\|_p^2。 \qquad (C > 0)$$

(3) 举例说明，当 $p < 2$ 时，上述结论未必成立。

证明 (1) 设 $\boldsymbol{x}_i = (x_{i1}, \cdots, x_{in}) \in \mathbb{R}^n$，则

$$\mathrm{E}\left\| \sum_{i=1}^{N} \varepsilon_i \boldsymbol{x}_i \right\|_p^2 = \mathrm{E}\left[\left(\sum_{j=1}^{n} \left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right)^{2/p} \right]。$$

- 根据 Jensen 不等式

  注意到 $2/p \leqslant 1$，函数 $t \mapsto t^{2/p}$ 于 $t \geqslant 0$ 为凹函数，因此根据 Jensen 不等式，将期望移至凹函数的内侧，

$$\mathrm{E}\left[\left(\sum_{j=1}^{n} \left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right)^{2/p} \right] \leqslant \left(\mathrm{E}\left[\sum_{j=1}^{n} \left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right] \right)^{2/p} = \left(\sum_{j=1}^{n} \mathrm{E}\left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right)^{2/p}。 \qquad \text{(I)}$$

- 根据 Khintchine 不等式

  对于内层的标量 Rademacher 和，利用 Khintchine 不等式，可得

$$\left(\mathrm{E}\left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right)^{1/p} \leqslant c_0 \sqrt{p} \left(\sum_{i=1}^{N} x_{ij}^2 \right)^{1/2},$$

  两侧取 p 次方，

$$\mathrm{E}\left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \leqslant (c_0 \sqrt{p})^p \left(\sum_{i=1}^{N} x_{ij}^2 \right)^{p/2},$$

  将其代入于 (I)，可得

$$\begin{aligned} \left(\sum_{j=1}^{n} \mathrm{E}\left| \sum_{i=1}^{N} \varepsilon_i x_{ij} \right|^p \right)^{2/p} &\leqslant \left(\sum_{j=1}^{n} (c_0 \sqrt{p})^p \left(\sum_{i=1}^{N} x_{ij}^2 \right)^{p/2} \right)^{2/p} \\ &=: Cp \left(\sum_{j=1}^{n} \left(\sum_{i=1}^{N} x_{ij}^2 \right)^{p/2} \right)^{2/p}。 \qquad (C = c_0^2)\text{(II)} \end{aligned}$$

- 根据 Minkowski 不等式 (广义三角不等式)

  定义 n 维序列 $\boldsymbol{v}_i = (x_{i1}^2, x_{i2}^2, \cdots, x_{in}^2)$。

  (注意到 $(\sum_{j=1}^{n} |v_j|^{p/2})^{2/p}$ 恰好为 $\boldsymbol{v}_i$ 的 $\ell_{p/2}$ 范数，其中 $p/2 \geqslant 1$，这使得 $\ell_{p/2}$ 空间构成赋范空间。)

[1] 原题干只将 p 称为参数，未要求 $p \geqslant 2$。现改为 $p \in [2, \infty)$。若 $1 \leqslant p < 2$，令 $\boldsymbol{x}_i = \boldsymbol{e}_i \in \ell_p^N$，则左侧为 $N^{2/p}$，右侧为 CpN；当 N 足够大时，此不等式不成立。

利用 Minkowski 不等式，可得

$$\left\|\sum_{i=1}^{N}\boldsymbol{v}_i\right\|_{p/2}\leqslant\sum_{i=1}^{N}\|\boldsymbol{v}_i\|_{p/2},$$

即

$$\left(\sum_{j=1}^{n}\left(\sum_{i=1}^{N}x_{ij}^2\right)^{p/2}\right)^{2/p}\leqslant\sum_{i=1}^{N}\left(\sum_{j=1}^{n}(x_{ij}^2)^{p/2}\right)^{2/p}=\sum_{i=1}^{N}\left(\sum_{j=1}^{n}|x_{ij}|^p\right)^{2/p}=\sum_{i=1}^{N}\|\boldsymbol{x}_i\|_p^2,$$

将其代入于 (II)，可得

$$\mathrm{E}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{x}_i\right\|_p^2\leqslant Cp\sum_{i=1}^{N}\|\boldsymbol{x}_i\|_p^2。$$

(2) (由于范数 $\|\cdot\|_p$ 为凸函数，其平方 $\|\cdot\|_p^2$ 也是凸函数，我们可以直接根据对称化引理。)

引入 $\boldsymbol{X}_i$ 的独立副本 $\boldsymbol{X}_i'$，满足 $\mathrm{E}[\boldsymbol{X}_i']=\boldsymbol{0}$，利用 Jensen 不等式，可得

$$\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^2=\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^{N}(\boldsymbol{X}_i-\mathrm{E}[\boldsymbol{X}_i'])\right\|_p^2\leqslant\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left\|\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^2。$$

对于右侧，引入 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，可得

$$\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}'}\left\|\sum_{i=1}^{N}(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^2=\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}',\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^2。$$

条件化固定 $\boldsymbol{X},\boldsymbol{X}'$，将 $(\boldsymbol{X}_i-\boldsymbol{X}_i')$ 视为固定的向量，利用 (1) 的结论，可得

$$\mathrm{E}_{\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^2\leqslant Cp\sum_{i=1}^{N}\|\boldsymbol{X}_i-\boldsymbol{X}_i'\|_p^2,$$

其中利用三角不等式和 $(a+b)^2\leqslant 2(a^2+b^2)$，可得

$$\mathrm{E}\|\boldsymbol{X}_i-\boldsymbol{X}_i'\|_p^2\leqslant 2\mathrm{E}\|\boldsymbol{X}_i\|_p^2+2\mathrm{E}\|\boldsymbol{X}_i'\|_p^2=4\mathrm{E}\|\boldsymbol{X}_i\|_p^2,$$

将其代入，可得

$$\mathrm{E}_{\boldsymbol{X},\boldsymbol{X}',\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i(\boldsymbol{X}_i-\boldsymbol{X}_i')\right\|_p^2\leqslant C'p\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^2,\qquad(C'=4C)$$

因此

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_p^2\leqslant C'p\sum_{i=1}^{N}\mathrm{E}\|\boldsymbol{X}_i\|_p^2。$$

(3) 令 $n=N$，$\boldsymbol{x}_i=\boldsymbol{e}_i$，则对于右侧，

$$\mathrm{RHS}=Cp\sum_{i=1}^{N}\|\boldsymbol{e}_i\|_p^2=Cp\sum_{i=1}^{N}1^2=Cp\cdot N;$$

对于左侧，由于

$$\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{e}_i\right\|_p=\left(\sum_{i=1}^{N}|\varepsilon_i|^p\right)^{1/p}=\left(\sum_{i=1}^{N}1\right)^{1/p}=N^{1/p},$$

因此

$$\mathrm{LHS}=\mathrm{E}[(N^{1/p})^2]=N^{2/p}。$$

如此，

$$N^{\frac{2}{p}-1} \leqslant Cp,$$

当 $N \to \infty$ 时，上述不等式不成立。

25 [近似 ℓ^p-Carathéodory 定理] 陈述并证明定理 T0.1.2 (近似 Caratheodory 定理) 在 ℓ^p 范数下的推广版本，涵盖所有 $p \in [1, \infty)$ 的情况。

注释 **近似 ℓ^p-Carathéodory 定理** 设 $\mathbb{T} \subset \mathbb{B}_p^n$，则对于任意的 $\boldsymbol{x} \in \operatorname{conv}(\mathbb{T})$，存在 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_k \in \mathbb{T}$ (允许重复)，使得：

1. 当 $p \in [1, 2]$ 时，

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_p \leqslant \frac{4}{k^{1-1/p}}。$$

2. 当 $p \in [2, \infty)$ 时，

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_p \leqslant C\sqrt{\frac{p}{k}}。$$

证明

- 构造概率模型

对于 $\boldsymbol{x} \in \operatorname{conv}(\mathbb{T})$，设

$$\boldsymbol{x} = \sum_{i=1}^{m} \lambda_i \boldsymbol{z}_i,$$

其中 $\boldsymbol{z}_i \in \mathbb{T}$，$\lambda_i \geqslant 0$，$\sum_{i=1}^{m} \lambda_i = 1$。

将凸组合系数 λ_i 视为概率，定义随机向量 $\boldsymbol{Z}$，使其以概率 λ_i 取值为 $\boldsymbol{z}_i$，即

$$\mathrm{P}\{\boldsymbol{Z} = \boldsymbol{z}_i\} = \lambda_i,$$

则 $\mathrm{E}[\boldsymbol{Z}] = \sum_{i=1}^{m} \lambda_i \boldsymbol{z}_i = \boldsymbol{x}$，$\|\boldsymbol{Z}\|_p \leqslant 1$ (a.s.)。

设 $\boldsymbol{Z}_1, \cdots, \boldsymbol{Z}_k$ 为 $\boldsymbol{Z}$ 的独立副本，定义中心化随机向量

$$\boldsymbol{X}_j = \boldsymbol{Z}_j - \boldsymbol{x},$$

则 $\boldsymbol{X}_1, \cdots, \boldsymbol{X}_k$ 为相互独立的零均值随机向量，其范数满足

$$\|\boldsymbol{X}_j\|_p = \|\boldsymbol{Z}_j - \boldsymbol{x}\|_p \leqslant \|\boldsymbol{Z}_j\|_p + \|\boldsymbol{x}\|_p \leqslant 1 + 1 = 2。$$

- 当 $p \in [1, 2]$ 时，(利用 Type p 性质)

根据习题 Q6.23 (Type p 性质) (2)，可得

$$\mathrm{E}\left\| \sum_{j=1}^{k} \boldsymbol{X}_j \right\|_p^p \leqslant 2^p \sum_{j=1}^{k} \mathrm{E}\|\boldsymbol{X}_j\|_p^p \leqslant 2^p \sum_{j=1}^{k} 2^p = k4^p。$$

因此经验均值的误差为

$$\mathrm{E}\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{Z}_j \right\|_p^p = \mathrm{E}\left\| \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{X}_j \right\|_p^p = \frac{1}{k^p} \mathrm{E}\left\| \sum_{j=1}^{k} \boldsymbol{X}_j \right\|_p^p \leqslant \frac{k4^p}{k^p} = \frac{4^p}{k^{p-1}},$$

从而根据概率方法 (若非负随机变量的期望小于等于 V，则于此样本空间，必定存在至少一个样本点，使得此随机变量的取值小于等于 V)，存在一组具体的实现 $\boldsymbol{x}_1, \cdots, \boldsymbol{x}_k \in \mathbb{T}$，使得

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_p^p \leqslant \frac{4^p}{k^{p-1}},$$

两侧取 $1/p$ 次方，

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_p \leqslant \frac{4}{k^{1-1/p}}。$$

- 当 $p\in[2,\infty)$ 时 (利用 Type 2 性质)

  利用习题 Q6.24 (Type 2 性质) (2) 的结论，可得

$$\mathrm{E}\left\|\sum_{j=1}^{k}\boldsymbol{X}_j\right\|_p^2\leqslant C_0p\sum_{j=1}^{k}\mathrm{E}\|\boldsymbol{X}_j\|_p^2\leqslant C_0p\sum_{j=1}^{k}4=4C_0pk,\qquad(C_0>0)$$

  因此经验均值的误差为

$$\mathrm{E}\left\|\boldsymbol{x}-\frac{1}{k}\sum_{j=1}^{k}\boldsymbol{Z}_j\right\|_p^2=\frac{1}{k^2}\mathrm{E}\left\|\sum_{j=1}^{k}\boldsymbol{X}_j\right\|_p^2\leqslant\frac{4C_0pk}{k^2}=\frac{4C_0p}{k},$$

  从而存在一组具体的实现 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_k\in\mathbb{T}$，使得

$$\left\|\boldsymbol{x}-\frac{1}{k}\sum_{j=1}^{k}\boldsymbol{x}_j\right\|_p^2\leqslant\frac{4C_0p}{k},$$

  两侧开方，

$$\left\|\boldsymbol{x}-\frac{1}{k}\sum_{j=1}^{k}\boldsymbol{x}_j\right\|_p\leqslant C\sqrt{\frac{p}{k}}。\qquad(C=2\sqrt{C_0})$$

26 [**Marcinkiewicz-Zygmund 不等式**] 设 $X_1,\cdots,X_N$ 为相互独立的零均值随机变量，$p\in[2,\infty)$，证明：

$$\left\|\sum_{i=1}^{N}X_i\right\|_{L^p}^2\leqslant Cp\sum_{i=1}^{N}\|X_i\|_{L^p}^2。\qquad(C>0)$$

证明 - 引入对称化

  引入 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，根据习题 Q6.20 (带有凸函数的对称化)，令 $F(x)=x^p$，可得 L^p 范数的对称化原理

$$\left\|\sum_{i=1}^{N}X_i\right\|_{L^p}\leqslant2\left\|\sum_{i=1}^{N}\varepsilon_iX_i\right\|_{L^p},$$

  两侧平方，

$$\left\|\sum_{i=1}^{N}X_i\right\|_{L^p}^2\leqslant4\left\|\sum_{i=1}^{N}\varepsilon_iX_i\right\|_{L^p}^2,\qquad(\mathrm{I})$$

  我们只需对右侧进行约束。

- 条件化与 Khintchine 不等式

  对于 (I) 的右侧，将其展开，

$$\left\|\sum_{i=1}^{N}\varepsilon_iX_i\right\|_{L^p}^p=\mathrm{E}_{\boldsymbol{X}}\left[\mathrm{E}_{\varepsilon}\left|\sum_{i=1}^{N}\varepsilon_iX_i\right|^p\right],$$

  利用 Khintchine 不等式，可得

$$\left(\mathrm{E}_{\varepsilon}\left|\sum_{i=1}^{N}\varepsilon_iX_i\right|^p\right)^{1/p}\leqslant c_0\sqrt{p}\left(\sum_{i=1}^{N}X_i^2\right)^{1/2},$$

  两侧取 p 次方，将其代入，

$$\mathrm{E}_{\boldsymbol{X}}\left[\mathrm{E}_{\varepsilon}\left|\sum_{i=1}^{N}\varepsilon_iX_i\right|^p\right]\leqslant\mathrm{E}_{\boldsymbol{X}}\left[(c_0\sqrt{p})^p\left(\sum_{i=1}^{N}X_i^2\right)^{p/2}\right]。$$

两侧取 $2/p$ 次方，将大期望还原为 L^p 范数的平方形式，

$$\left\|\sum_{i=1}^N \varepsilon_i X_i\right\|_{L^p}^2 \leqslant c_0^2 p \left(\mathrm{E}\left[\left(\sum_{i=1}^N X_i^2\right)^{p/2}\right]\right)^{2/p}。 \tag{II}$$

- 根据 Minkowski 不等式化简

  注意到 (II) 的右侧恰好为 $\sum_{i=1}^N X_i^2$ 的 $L^{p/2}$ 范数，即

$$\left(\mathrm{E}\left[\left(\sum_{i=1}^N X_i^2\right)^{p/2}\right]\right)^{2/p} = \left\|\sum_{i=1}^N X_i^2\right\|_{L^{p/2}},$$

  利用 Minkowski 不等式，可得

$$\left\|\sum_{i=1}^N X_i^2\right\|_{L^{p/2}} \leqslant \sum_{i=1}^N \left\|X_i^2\right\|_{L^{p/2}} = \sum_{i=1}^N \|X_i\|_{L^p}^2,$$

  将其代入，

$$\left(\mathrm{E}\left[\left(\sum_{i=1}^N X_i^2\right)^{p/2}\right]\right)^{2/p} \leqslant \sum_{i=1}^N \|X_i\|_{L^p}^2。 \tag{III}$$

  将 (III) 代入于 (II)，之后代入于 (I)，可得

$$\left\|\sum_{i=1}^N X_i\right\|_{L^p}^2 \leqslant 4\left\|\sum_{i=1}^N \varepsilon_i X_i\right\|_{L^p}^2 \leqslant 4\left(c_0^2 p \sum_{i=1}^N \|X_i\|_{L^p}^2\right),$$

  即

$$\left\|\sum_{i=1}^N X_i\right\|_{L^p}^2 \leqslant Cp \sum_{i=1}^N \|X_i\|_{L^p}^2。 \qquad (C = 4c_0^2)$$

注释 本体的证明逻辑与习题 Q6.24 (Type 2 性质) (2) 高度相同。区别在于习题 Q6.24 (Type 2 性质) 为 $\mathbb{R}^n$ 的 ℓ^p 范数，习题 Q6.26 (Marcinkiewicz-Zygmund 不等式) 为概率空间 Ω 的 L^p 范数。这说明了无论在哪种空间，只要幂次大于等于 2 (即 $p \geqslant 2$)，即天然满足 Type 2 性质。

27 [**有限矩条件的范数集中性**] 在更弱的，仅需有限矩存在的条件，证明定理 T3.1.1 (范数的集中) 的变体版本。

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为随机向量，其元素 X_i 是相互独立的[2]，满足 $\mathrm{E}[X_i^2] = 1$，存在 $p \geqslant 2, K \geqslant 0$，使得 $\|X_i\|_{L^{2p}} \leqslant K$。证明：

$$\left\|\|\boldsymbol{X}\|_2 - \sqrt{n}\right\|_{L^p} \leqslant C\sqrt{p}K^2。 \qquad (C > 0)$$

证明 首先将代数线性化，

$$\left|\|\boldsymbol{X}\|_2 - \sqrt{n}\right| = \frac{\left|\|\boldsymbol{X}\|_2^2 - n\right|}{\|\boldsymbol{X}\|_2 + \sqrt{n}} \leqslant \frac{\left|\|\boldsymbol{X}\|_2^2 - n\right|}{\sqrt{n}},$$

两侧取 L^p 范数，

$$\left\|\|\boldsymbol{X}\|_2 - \sqrt{n}\right\|_{L^p} \leqslant \frac{1}{\sqrt{n}}\left\|\|\boldsymbol{X}\|_2^2 - n\right\|_{L^p}。 \tag{I}$$

对于右侧，令 $Y_i = X_i^2 - 1$ 为相互独立的零均值随机变量，则

$$\|\boldsymbol{X}\|_2^2 - n = \sum_{i=1}^n X_i^2 - \sum_{i=1}^n \mathrm{E}[X_i^2] = \sum_{i=1}^n (X_i^2 - 1) = \sum_{i=1}^n Y_i,$$

[2]原题干只要求各坐标满足矩条件，未要求相互独立。现补充独立性条件。否则，令任意的 X_i 均等于随机变量 Z，其中 $\mathrm{P}\{Z = 0\} = \mathrm{P}\{Z = \sqrt{2}\} = 1/2$。此时 $\mathrm{E}[Z^2] = 1$，各矩有限，但 $\left\|\|\boldsymbol{X}\|_2 - \sqrt{n}\right\|_{L^p}$ 同 $\sqrt{n}$ 同阶，不能由只依赖于 p, K 的右侧控制。

(I) 的右侧即为

$$\frac{1}{\sqrt{n}}\left\|\sum_{i=1}^{n} Y_i\right\|_{L^p}。$$

利用 Marcinkiewicz-Zygmund 不等式，可得

$$\left\|\sum_{i=1}^{n} Y_i\right\|_{L^p}^2 \leqslant C_0 p \sum_{i=1}^{n} \|Y_i\|_{L^p}^2,$$

两侧开方，

$$\left\|\sum_{i=1}^{n} Y_i\right\|_{L^p} \leqslant \sqrt{C_0 p}\left(\sum_{i=1}^{n} \|Y_i\|_{L^p}^2\right)^{1/2}, \tag{II}$$

之后只需估计 $\|Y_i\|_{L^p}$。

利用 Jensen 不等式，可得

$$1 = \mathrm{E}[X_i^2] = \|X_i\|_{L^2}^2 \leqslant \|X_i\|_{L^{2p}}^2 \leqslant K^2,$$

解得 $K \geqslant 1$。

利用三角不等式，可得

$$\|Y_i\|_{L^p} = \|X_i^2 - 1\|_{L^p} \leqslant \|X_i^2\|_{L^p} + \|1\|_{L^p} = \|X_i^2\|_{L^p} + 1 = \|X_i\|_{L^{2p}}^2 + 1 \leqslant K^2 + 1 \leqslant 2K^2,$$

将其代入于 (II)，可得

$$\left\|\sum_{i=1}^{n} Y_i\right\|_{L^p} \leqslant \sqrt{C_0 p}\left(\sum_{i=1}^{n} (2K^2)^2\right)^{1/2} = \sqrt{C_0 p}(n \cdot 4K^4)^{1/2} = \sqrt{C_0 p} \cdot 2K^2\sqrt{n},$$

将其代入于 (I)，可得

$$\big\|\|\boldsymbol{X}\|_2 - \sqrt{n}\big\|_{L^p} \leqslant \frac{1}{\sqrt{n}}(2\sqrt{C_0}\sqrt{p}K^2\sqrt{n}) = C\sqrt{p}K^2。 \qquad (C = 2\sqrt{C_0})$$

28 [矩形随机矩阵的范数] 将定理 T6.4.1 (非同分布元素随机矩阵的范数) 推广至非对称的矩形矩阵。

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其元素是相互独立, 零均值的。证明：其算子范数的期望近似等于其行向量, 列向量的 Euclidean 范数最大值的期望 (至多相差一个对数因子)，即

$$\mathrm{E}\left[\max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\}\right] \leqslant \mathrm{E}\|\boldsymbol{A}\| \leqslant C\sqrt{\ln(m+n)}\mathrm{E}\left[\max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\}\right]。 \qquad (C > 0)$$

证明 • 证明下界

设 $\boldsymbol{e}_j \in \mathbb{R}^n$ 为第 j 个标准基向量，则 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{A}_{*j}$，因此根据算子范数的定义 (Q4.20 ($\infty \to 1$ 算子范数的性质, 对偶))，可得

$$\|\boldsymbol{A}\| \geqslant \frac{\|\boldsymbol{A}\boldsymbol{e}_j\|_2}{\|\boldsymbol{e}_j\|_2} = \|\boldsymbol{A}_{*j}\|_2。$$

同理，考虑 $\boldsymbol{A}^\top$，设 $\boldsymbol{u}_i \in \mathbb{R}^m$ 为第 i 个标准基向量，则 $\boldsymbol{A}^\top\boldsymbol{u}_i = (\boldsymbol{A}_{i*})^\top$，因此

$$\|\boldsymbol{A}\| = \|\boldsymbol{A}^\top\| \geqslant \|\boldsymbol{A}^\top\boldsymbol{u}_i\|_2 = \|\boldsymbol{A}_{i*}\|_2。$$

如此，

$$\|\boldsymbol{A}\| \geqslant \max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\},$$

两侧取期望，

$$\mathrm{E}\|\boldsymbol{A}\| \geqslant \mathrm{E}\left[\max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\}\right]。$$

• 证明上界

构造分块矩阵 $\tilde{\boldsymbol{A}} \in \mathbb{R}^{(m+n)\times(m+n)}$ 为

$$\tilde{\boldsymbol{A}} = \begin{pmatrix} \boldsymbol{0}_{m\times m} & \boldsymbol{A}_{m\times n} \\ \boldsymbol{A}_{n\times m}^{\top} & \boldsymbol{0}_{n\times n} \end{pmatrix},$$

则 $\tilde{\boldsymbol{A}}$ 为对称矩阵，其元素是相互独立, 零均值的，满足定理 T6.4.1 (非同分布元素随机矩阵的范数) 的条件。

由分块矩阵的平方可得

$$\tilde{\boldsymbol{A}}^2 = \begin{pmatrix} \boldsymbol{0} & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{0} \end{pmatrix}\begin{pmatrix} \boldsymbol{0} & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{0} \end{pmatrix} = \begin{pmatrix} \boldsymbol{A}\boldsymbol{A}^{\top} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{A}^{\top}\boldsymbol{A} \end{pmatrix},$$

因此

$$\|\tilde{\boldsymbol{A}}\|^2 = \|\tilde{\boldsymbol{A}}^2\| = \max(\|\boldsymbol{A}\boldsymbol{A}^{\top}\|, \|\boldsymbol{A}^{\top}\boldsymbol{A}\|) = \max(\|\boldsymbol{A}\|^2, \|\boldsymbol{A}\|^2) = \|\boldsymbol{A}\|^2,$$

解得 $\|\tilde{\boldsymbol{A}}\| = \|\boldsymbol{A}\|$。

之后考虑 $\tilde{\boldsymbol{A}}_{k*}$:

a. 当 $1 \leqslant k \leqslant m$ 时，$\tilde{\boldsymbol{A}}_{k*} = (\boldsymbol{0}, \boldsymbol{A}_{k*})$，其 Euclidean 范数为 $\|\boldsymbol{A}_{k*}\|_2$。

b. 当 $m+1 \leqslant k \leqslant m+n$ 时，设 $j = k-m$，则 $\tilde{\boldsymbol{A}}_{k*} = ((\boldsymbol{A}^{\top})_{j*}, \boldsymbol{0})$。由于 $\boldsymbol{A}^{\top}$ 的第 j 行恰好为 $\boldsymbol{A}$ 的第 j 列，因此其 Euclidean 范数为 $\|\boldsymbol{A}_{*j}\|_2$。

因此

$$\max_k \|\tilde{\boldsymbol{A}}_{k*}\|_2 = \max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\},$$

从而根据定理 T6.4.1 (非同分布元素随机矩阵的范数)，令 $N = m+n$，可得

$$\mathrm{E}\|\tilde{\boldsymbol{A}}\| \leqslant C\sqrt{\ln N}\cdot \mathrm{E}\left[\max_k \|\tilde{\boldsymbol{A}}_{k*}\|_2\right],$$

即

$$\mathrm{E}\|\boldsymbol{A}\| \leqslant C\sqrt{\ln(m+n)}\mathrm{E}\left[\max\left\{\max_{1\leqslant i\leqslant m}\|\boldsymbol{A}_{i*}\|_2, \max_{1\leqslant j\leqslant n}\|\boldsymbol{A}_{*j}\|_2\right\}\right]。$$

29 [对数因子是不可移除的] 证明定理 T6.4.1 (非同分布元素随机矩阵的范数) 的对数因子通常不能被完全移除。构造满足上述定理假设条件 (即对称矩阵，对角线及以上元素是相互独立, 零均值的) 的随机矩阵 $\boldsymbol{A}$，使得

$$\mathrm{E}\|\boldsymbol{A}\| \geqslant c\ln^{1/4}(n)\cdot \mathrm{E}\left[\max_i \|\boldsymbol{A}_{i*}\|_2\right]。$$

证明 (之后只需构造矩阵，使得其最大行范数非常小 (且集中)，但是其算子范数却由于多个独立块的极值效应而变得很大。)

考虑构造分块对角矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，设 n 为充分大的整数，选择块的大小为 $m = \lfloor\sqrt{\ln n}\rfloor$，令 $K = \lfloor n/m\rfloor$，使用 K 个 $m\times m$ 对角块，并将剩余坐标填为 0，不影响量级，记这些对角块为

$$\boldsymbol{A} = \mathrm{diag}(\boldsymbol{D}_1, \boldsymbol{D}_2, \cdots, \boldsymbol{D}_K)。$$

设

$$(\boldsymbol{D}_k)_{ij} = \begin{cases} 0, & i = j, \\ \varepsilon_{ij}^{(k)}, & i < j, \\ \varepsilon_{ji}^{(k)}, & i > j \end{cases},$$

其中各块的 $\varepsilon_{ij}^{(k)}$ i.i.d. $\sim$ Rademacher，并且各块之间相互独立，则 $\boldsymbol{A}$ 符合定理 T6.4.1 (非同分布元素随机矩阵的范数) 的假设。

- 计算最大行范数 $\mathrm{E}[\max_i \|\boldsymbol{A}_{i*}\|_2]$

容易知道，

$$\|\boldsymbol{A}_{i*}\|_2 = \sqrt{\sum_{j\neq i}(\boldsymbol{D}_k)_{ij}^2} = \sqrt{m-1}$$

因此

$$\mathrm{E}\left[\max_i \|\boldsymbol{A}_{i*}\|_2\right] = \sqrt{m-1} \leqslant \sqrt{m} \leqslant (\ln n)^{1/4}。$$

- 计算算子范数的下界 $\mathrm{E}\|\boldsymbol{A}\|$

记 $r = m(m-1)/2$，并令 $\mathcal{E}_k$ 表示第 k 个块的所有上三角非对角元均为 1 的事件。则

$$\mathrm{P}(\mathcal{E}_k) = 2^{-r}, \qquad \mathrm{P}\{\bigcup_{k=1}^{K} \mathcal{E}_k\} = 1 - (1-2^{-r})^K.$$

由于 $m = \lfloor\sqrt{\ln n}\rfloor$，有 $K2^{-r} \to \infty$，故当 n 足够大时，上式至少为 $1/2$。在事件 $\mathcal{E}_k$ 上，$\boldsymbol{D}_k = 11^\top - \boldsymbol{I}$，从而 $\|\boldsymbol{D}_k\| = m-1$。因此

$$\mathrm{E}\|\boldsymbol{A}\| = \mathrm{E}\left[\max_{1\leqslant k\leqslant K} \|\boldsymbol{D}_k\|\right] \geqslant \frac{m-1}{2}.$$

如此，

$$\frac{\mathrm{E}\|\boldsymbol{A}\|}{\mathrm{E}[\max_i \|\boldsymbol{A}_{i*}\|_2]} \geqslant \frac{(m-1)/2}{\sqrt{m-1}} = \frac{1}{2}\sqrt{m-1} \gtrsim (\ln n)^{1/4},$$

即

$$\mathrm{E}\|\boldsymbol{A}\| \geqslant c\ln^{1/4}(n) \cdot \mathrm{E}\left[\max_i \|\boldsymbol{A}_{i*}\|_2\right]。$$

30 [随机矩阵的行范数] 设 δ_{ij} i.i.d. $\sim B(p)$，其中 $i,j = 1,\cdots,n$，$np \geqslant \ln n$。证明：

$$\mathrm{E}\left[\max_{i\leqslant n} \sum_{j=1}^{n} (\delta_{ij}-p)^2\right] \leqslant Cpn。 \qquad (C>0)$$

证明 **解法一 Bernstein 不等式**

令 $Z_{ij} = (\delta_{ij}-p)^2$，则

$$Z_{ij} = \begin{cases} (1-p)^2, \text{ w.p. } p, \\ p^2, \qquad \text{w.p. } 1-p \end{cases},$$

其数字特征为

$$\mu = p(1-p)^2 + (1-p)p^2 = p(1-p),$$
$$\sigma^2 = [p(1-p)^4 + (1-p)p^4] - [p(1-p)]^2 = p(1-p)(1-2p)^2,$$

因此 $\sigma^2 \leqslant p$，$|Z_{ij}-\mu| \leqslant \max((1-p)^2, p^2) \leqslant 1$。

设 $S_i = \sum_{j=1}^n Z_{ij}$，则 $\mathrm{E}[S_i] = np(1-p) \leqslant np$，利用定理 T2.9.5 (有界分布的 Bernstein 不等式) (有界分布的 Bernstein 不等式)，可得对于任意的 $t>0$，

$$\mathrm{P}\{|S_i - \mathrm{E}[S_i]| \geqslant t\} \leqslant 2\exp\left(-\frac{t^2/2}{n\sigma^2 + t/3}\right),$$

两侧取并集界，

$$\mathrm{P}\left\{\max_i |S_i - \mathrm{E}[S_i]| \geqslant t\right\} \leqslant n \cdot 2\exp\left(-\frac{t^2}{2(np+t/3)}\right)。$$

根据期望的积分表示 $\mathrm{E}[Y] \leqslant y_0 + \int_{y_0}^{\infty} \mathrm{P}\{Y>t\}\mathrm{d}t$，令 $Y = \max_i S_i$；注意到 $\max_i \mathrm{E}[S_i] = n\mu \leqslant np$，令 $t_0 = np$，则

$$\begin{aligned}
\mathrm{E}\left[\max_i S_i\right] &\leqslant np + \int_{np}^{\infty} \mathrm{P}\left\{\max_i S_i > np + t\right\}\mathrm{d}t \\
&\leqslant np + \int_{np}^{\infty} \mathrm{P}\left\{\max_i |S_i - \mathrm{E}[S_i]| > t\right\}\mathrm{d}t \\
&\leqslant np + \int_0^{\infty} 2n\exp\left(-\frac{t^2}{2np + 2t/3}\right)\mathrm{d}t。
\end{aligned}$$

设 $M = \max_{1\leqslant i\leqslant n}(S_i - \mathrm{E}[S_i])$，考虑其非负部分的期望，

$$\mathrm{E}[M_+] = \int_0^\infty \mathrm{P}\{M_+ \geqslant t\}\mathrm{d}t = \int_0^\infty \mathrm{P}\Big\{\max_{1\leqslant i\leqslant n}(S_i - \mathrm{E}[S_i]) \geqslant t\Big\}\mathrm{d}t,$$

令阈值 $t_0 = 6pn$，将上述积分拆分，

$$\begin{aligned}\mathrm{E}[M_+] &\leqslant \int_0^{t_0} 1\mathrm{d}t + \int_{t_0}^\infty n\exp\left(-\frac{t^2}{2np + 2t/3}\right)\mathrm{d}t \\ &\leqslant \int_0^{t_0} 1\mathrm{d}t + \int_{t_0}^\infty n\exp\left(-\frac{t^2}{2np + 2t/3}\right)\mathrm{d}t \\ &\leqslant 6pn + \int_{6pn}^\infty n\exp\left(-\frac{t}{3}\right)\mathrm{d}t = 6pn + 3n\exp(-2pn),\end{aligned}$$

其中

$$3n\exp(-2pn) = 3n\exp(-pn)\exp(-pn) \leqslant 3n\exp(-\ln n)\exp(-pn) = 3\exp(-pn) \leqslant 3,$$

将其代入，可得 $\mathrm{E}[M_+] \leqslant 6pn + 3$，即 $\mathrm{E}[M_+] \leqslant cpn$。

利用三角不等式，可得

$$\max_{1\leqslant i\leqslant n} S_i \leqslant \max_{1\leqslant i\leqslant n}(S_i - \mathrm{E}[S_i]) + \max_{1\leqslant i\leqslant n}\mathrm{E}[S_i] \leqslant M_+ + pn,$$

两侧取期望，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}\sum_{j=1}^n(\delta_{ij} - p)^2\right] \leqslant \mathrm{E}[M_+] + np \leqslant Cpn。 \qquad (C = c + 1)$$

解法二　MGF 约束

容易知道，

$$\begin{aligned}(\delta_{ij} - p)^2 &= \delta_{ij}^2 - 2p\delta_{ij} + p^2 \\ &= \delta_{ij} - 2p\delta_{ij} + p^2 = (1 - 2p)\delta_{ij} + p^2,\end{aligned}$$

两侧求和，令 $T_i = \sum_{j=1}^n \delta_{ij} \sim B(n, p)$，可得

$$\begin{aligned}\sum_{j=1}^n(\delta_{ij} - p)^2 &= \sum_{j=1}^n((1 - 2p)\delta_{ij} + p^2) = (1 - 2p)\sum_{j=1}^n\delta_{ij} + np^2 \\ &= (1 - 2p)T_i + np^2 \leqslant T_i + np,\end{aligned}$$

因此

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}\sum_{j=1}^n(\delta_{ij} - p)^2\right] \leqslant \mathrm{E}\Big[\max_{1\leqslant i\leqslant n}(T_i + np)\Big] = \mathrm{E}\Big[\max_{1\leqslant i\leqslant n}T_i\Big] + np,$$

之后只需证明 $\mathrm{E}[\max_i T_i] \leqslant C'pn$ 即可。

利用 Jensen 不等式，令 $F(x) = \exp(\lambda x)$，其中 $\lambda > 0$，可得

$$\exp\Big(\lambda\mathrm{E}\Big[\max_i T_i\Big]\Big) \leqslant \mathrm{E}\Big[\exp\Big(\lambda\max_i T_i\Big)\Big] = \mathrm{E}\Big[\max_i \mathrm{e}^{\lambda T_i}\Big] \leqslant \mathrm{E}\left[\sum_{i=1}^n \mathrm{e}^{\lambda T_i}\right] = n\cdot\mathrm{E}[\mathrm{e}^{\lambda T_1}],$$

两侧取对数，除以 λ，可得

$$\mathrm{E}\Big[\max_i T_i\Big] \leqslant \frac{\ln n}{\lambda} + \frac{1}{\lambda}\ln\mathrm{E}[\mathrm{e}^{\lambda T_1}],$$

其中

$$\mathrm{E}[\mathrm{e}^{\lambda T_1}] = \prod_{j=1}^n \mathrm{E}[\mathrm{e}^{\lambda\delta_{1j}}] = ((1 - p) + p\mathrm{e}^\lambda)^n = (1 + p(\mathrm{e}^\lambda - 1))^n$$

$$\leqslant (\mathrm{e}^{p(\mathrm{e}^{\lambda}-1)})^n = \exp(np(\mathrm{e}^{\lambda}-1)),$$

将其代入，可得

$$\begin{aligned}\mathrm{E}\left[\max_i T_i\right] &\leqslant \frac{\ln n}{\lambda} + \frac{1}{\lambda}\ln(\exp(np(\mathrm{e}^{\lambda}-1))) = \frac{\ln n}{\lambda} + \frac{np(\mathrm{e}^{\lambda}-1)}{\lambda} \\ &\leqslant \frac{pn}{\lambda} + \frac{np(\mathrm{e}^{\lambda}-1)}{\lambda} = \frac{\mathrm{e}^{\lambda}}{\lambda}pn。\end{aligned}$$

如此，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}\sum_{j=1}^{n}(\delta_{ij}-p)^2\right] \leqslant \mathrm{E}\left[\max_{1\leqslant i\leqslant n} T_i\right] + np \leqslant \frac{\mathrm{e}^{\lambda}}{\lambda}\cdot pn + np = Cpn。 \qquad \left(C = \frac{\mathrm{e}^{\lambda}}{\lambda}+1\right)$$

31 [矩形矩阵的矩阵完备化] 陈述并证明定理 T6.5.1 (矩阵补全) 针对一般矩阵的推广版本。

注释 **矩形矩阵完备化** 设 $n_1, n_2 \geqslant 2$，$\boldsymbol{A} \in \mathbb{R}^{n_1\times n_2}$ 为固定矩阵，记 $r = \mathrm{rank}(\boldsymbol{A})$。取 $0 < p \leqslant 1$，独立地以概率 p 观测每个元素位置，记 δ_{ij} i.i.d. $\sim B(p)$，并令 $s = pn_1n_2$ 为期望观测数，之后定义稀疏观测矩阵 $\boldsymbol{Y} \in \mathbb{R}^{n_1\times n_2}$ 为

$$Y_{ij} = \delta_{ij}a_{ij} = \begin{cases} a_{ij}, \delta_{ij} = 1, \\ 0, \quad \delta_{ij} = 0 \end{cases}。$$

设 $\hat{\boldsymbol{A}}$ 为 $p^{-1}\boldsymbol{Y}$ ($\boldsymbol{A}$ 的无偏估计) 的最佳秩 r 逼近。记 $n = \max(n_1, n_2)$，若期望观测数满足 $s \geqslant C'n\ln n$，则

$$\mathrm{E}\left[\frac{1}{\sqrt{n_1n_2}}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|_F\right] \leqslant C\sqrt{\frac{rn\ln n}{s}}\|\boldsymbol{A}\|_{\infty}。$$

证明 根据 Eckart-Young-Mirsky 定理，可得 $\|\hat{\boldsymbol{A}} - p^{-1}\boldsymbol{Y}\| \leqslant \|\boldsymbol{A} - p^{-1}\boldsymbol{Y}\|$，因此

$$\|\hat{\boldsymbol{A}} - \boldsymbol{A}\| \leqslant \|\hat{\boldsymbol{A}} - p^{-1}\boldsymbol{Y}\| + \|p^{-1}\boldsymbol{Y} - \boldsymbol{A}\| \leqslant 2\|p^{-1}\boldsymbol{Y} - \boldsymbol{A}\| = \frac{2}{p}\|\boldsymbol{Y} - p\boldsymbol{A}\|,$$

两侧取期望，

$$\mathrm{E}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\| \leqslant \frac{2}{p}\mathrm{E}\|\boldsymbol{Y} - p\boldsymbol{A}\|, \tag{I}$$

令 $\boldsymbol{Z} = \boldsymbol{Y} - p\boldsymbol{A}$。(之后只需界定 $\mathrm{E}\|\boldsymbol{Z}\|$。)

根据习题 Q6.28 (矩形随机矩阵的范数)，可得

$$\mathrm{E}\|\boldsymbol{Z}\| \leqslant C_1\sqrt{\ln(n_1+n_2)}\left(\mathrm{E}\left[\max_{1\leqslant i\leqslant n_1}\|\boldsymbol{Z}_{i*}\|_2\right] + \mathrm{E}\left[\max_{1\leqslant j\leqslant n_2}\|\boldsymbol{Z}_{*j}\|_2\right]\right), \tag{II}$$

之后只需界定 $\boldsymbol{Z}$ 的行范数, 列范数。

- 界定行范数, 列范数

  对于行范数，

$$\|\boldsymbol{Z}_{i*}\|_2^2 = \sum_{j=1}^{n_2}(\delta_{ij}-p)^2A_{ij}^2 \leqslant \|\boldsymbol{A}\|_{\infty}^2\sum_{j=1}^{n_2}(\delta_{ij}-p)^2,$$

  其中根据习题 Q6.30 (随机矩阵的行范数)，可得当 $pn_2 \geqslant C'\ln n_1$ 时，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n_1}\sum_{j=1}^{n_2}(\delta_{ij}-p)^2\right] \leqslant C_2pn_2。$$

  将其代入，之后利用 Jensen 不等式 $\mathrm{E}[\sqrt{W}] \leqslant \sqrt{\mathrm{E}[W]}$，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n_1}\|\boldsymbol{Z}_{i*}\|_2\right] \leqslant \sqrt{C_2pn_2}\|\boldsymbol{A}\|_{\infty}。 \tag{III}$$

  同理，对于列范数，当 $pn_1 \geqslant C'\ln n_2$ 时，

$$\mathrm{E}\left[\max_{1\leqslant j\leqslant n_2}\|\boldsymbol{Z}_{*j}\|_2\right] \leqslant \sqrt{C_3pn_1}\|\boldsymbol{A}\|_{\infty}。 \tag{IV}$$

若 (III)(IV) 同时成立，则 $pn \geqslant C_4 \ln n$，代入 $p = s/n_1 n_2$，可得 $s \geqslant C' n \ln n$。

将 (III)(IV) 代入于 (II)，可得

$$\mathrm{E}\|\boldsymbol{Z}\| \leqslant C_5 \sqrt{\ln n}(\sqrt{pn_2} + \sqrt{pn_1})\|\boldsymbol{A}\|_\infty \leqslant C_6 \sqrt{pn \ln n}\|\boldsymbol{A}\|_\infty,$$

将其代入于 (I)，可得

$$\mathrm{E}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\| \leqslant \frac{2}{p} C_6 \sqrt{pn \ln n}\|\boldsymbol{A}\|_\infty = C_7 \sqrt{\frac{n \ln n}{p}}\|\boldsymbol{A}\|_\infty。 \tag{V}$$

- 利用低秩假设过渡到 Frobenius 范数

由于 $\mathrm{rank}(\boldsymbol{A}), \mathrm{rank}(\hat{\boldsymbol{A}}) \leqslant r$，因此 $\mathrm{rank}(\hat{\boldsymbol{A}} - \boldsymbol{A}) \leqslant 2r$，满足

$$\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|_F \leqslant \sqrt{2r}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|,$$

两侧取期望，结合 (V)，可得

$$\mathrm{E}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|_F \leqslant C_8 \sqrt{r} \sqrt{\frac{n \ln n}{p}}\|\boldsymbol{A}\|_\infty = C_8 \sqrt{\frac{rn \ln n}{p}}\|\boldsymbol{A}\|_\infty,$$

两侧除以 $\sqrt{n_1 n_2}$，

$$\mathrm{E}\left[\frac{1}{\sqrt{n_1 n_2}}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|_F\right] \leqslant C_8 \frac{1}{\sqrt{n_1 n_2}} \sqrt{\frac{rn \ln n}{p}}\|\boldsymbol{A}\|_\infty = C_8 \sqrt{\frac{rn \ln n}{pn_1 n_2}}\|\boldsymbol{A}\|_\infty,$$

即

$$\mathrm{E}\left[\frac{1}{\sqrt{n_1 n_2}}\|\hat{\boldsymbol{A}} - \boldsymbol{A}\|_F\right] \leqslant C \sqrt{\frac{rn \ln n}{s}}\|\boldsymbol{A}\|_\infty。$$

注释 在独立有放回观测模型中也可作如下估计。令 $(I_k, J_k)_{k=1}^s$ 为独立且均匀分布于所有满足 $1 \leqslant i \leqslant n_1$、$1 \leqslant j \leqslant n_2$ 的指标对，并令 $\boldsymbol{Y}^{(k)} = A_{I_k J_k} \boldsymbol{e}_{I_k} \boldsymbol{e}_{J_k}^\top$，$\boldsymbol{Z}_k = (n_1 n_2/s)\boldsymbol{Y}^{(k)} - \boldsymbol{A}/s$。则 $\boldsymbol{v}_i = \sum_{k=1}^s \varepsilon_k (\boldsymbol{Z}_k)_{i*}$ 为 sub-Gaussian 随机向量，满足

$$\|\boldsymbol{v}_i\|_{\psi_2} \lesssim \sqrt{\sum_{k=1}^s \|(\boldsymbol{Z}_k)_{i*}\|_2^2},$$

根据 sub-Gaussian 随机变量最大值的标准上界，引入因子 $\sqrt{\ln n_1}$，可得

$$\mathrm{E}_\varepsilon\left[\max_{1 \leqslant i \leqslant n_1} \|\boldsymbol{v}_i\|_2\right] \lesssim \sqrt{\ln n_1} \cdot \max_{1 \leqslant i \leqslant n_1} \sqrt{\sum_{k=1}^s \|(\boldsymbol{Z}_k)_{i*}\|_2^2},$$

两侧关于 $\boldsymbol{Z}$ 取期望，之后利用 Jensen 不等式，可得

$$\mathrm{E}\left[\max_{1 \leqslant i \leqslant n_1} \left\|\sum_{k=1}^s \varepsilon_k (\boldsymbol{Z}_k)_{i*}\right\|_2\right] \lesssim \sqrt{\ln n_1} \cdot \sqrt{\mathrm{E}_{\boldsymbol{Z}}\left[\max_{1 \leqslant i \leqslant n_1} \sum_{k=1}^s \|(\boldsymbol{Z}_k)_{i*}\|_2^2\right]}。 \tag{I}$$

(我们考虑拆解 $\boldsymbol{Z}_k$，并引入指示变量。)

根据定义，$\boldsymbol{Y}^{(k)}$ 为仅含 1 个非零元素的极稀疏矩阵。

利用不等式 $(a-b)^2 \leqslant 2a^2 + 2b^2$，可得

$$\|(\boldsymbol{Z}_k)_{i*}\|_2^2 \leqslant 2\left(\frac{n_1 n_2}{s}\right)^2 \|(\boldsymbol{Y}^{(k)})_{i*}\|_2^2 + \frac{2}{s^2}\|\boldsymbol{a}_{i*}\|_2^2。$$

设示性变量 $\delta_i^{(k)}$ 表示第 k 次采样是否选中矩阵的第 i 行，则

$$\|(\boldsymbol{Y}^{(k)})_{i*}\|_2^2 \leqslant \|\boldsymbol{A}\|_\infty^2 \cdot \delta_i^{(k)},$$

将其代入，之后对 s 次采样求和，可得

$$\sum_{k=1}^s \|(\boldsymbol{Z}_k)_{i*}\|_2^2 \leqslant 2\left(\frac{n_1 n_2}{s}\right)^2 \|\boldsymbol{A}\|_\infty^2 \sum_{k=1}^s \delta_i^{(k)} + \frac{2}{s}\|\boldsymbol{a}_{i*}\|_2^2。$$

令 $S_i = \sum_{k=1}^{s} \delta_i^{(k)} \sim B(s, 1/n_1)$，则根据二项分布的 Chernoff 集中界，当 $s \geqslant n_1 \ln n_1$ 时，

$$\mathrm{E}_{\boldsymbol{Z}}\left[\max_{1\leqslant i\leqslant n_1} \sum_{k=1}^{s} \delta_i^{(k)}\right] \lesssim \frac{s}{n_1},$$

将其代入，可得

$$\mathrm{E}_{\boldsymbol{Z}}\left[\max_{1\leqslant i\leqslant n_1} \sum_{k=1}^{s} \|(\boldsymbol{Z}_k)_{i*}\|_2^2\right] \lesssim \left(\frac{n_1 n_2}{s}\right)^2 \|\boldsymbol{A}\|_\infty^2 \left(\frac{s}{n_1}\right) = \frac{n_1 n_2^2}{s}\|\boldsymbol{A}\|_\infty^2。 \tag{II}$$

将 (II) 代入于 (I)，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n_1} \left\|\sum_{k=1}^{s} \varepsilon_k (\boldsymbol{Z}_k)_{i*}\right\|_2\right] \lesssim \sqrt{\ln n_1} \cdot \sqrt{\frac{n_1 n_2^2}{s}\|\boldsymbol{A}\|_\infty^2} = \frac{n_2\sqrt{n_1 \ln n_1}}{\sqrt{s}}\|\boldsymbol{A}\|_\infty。$$

同理，当 $s \geqslant n_2 \ln n_2$ 时，

$$\mathrm{E}\left[\max_{1\leqslant j\leqslant n_2} \left\|\sum_{k=1}^{s} \varepsilon_k (\boldsymbol{Z}_k)_{*j}\right\|_2\right] \lesssim \sqrt{\ln n_2} \cdot \sqrt{\left(\frac{n_1 n_2}{s}\right)^2 \|\boldsymbol{A}\|_\infty^2 \left(\frac{s}{n_2}\right)} = \frac{n_1\sqrt{n_2 \ln n_2}}{\sqrt{s}}\|\boldsymbol{A}\|_\infty。$$

32 [**带噪声观测的矩阵完备化**] 将定理 T6.5.1 (矩阵补全) 推广至带有噪声观测的情形。

具体而言，设 $\boldsymbol{X} \in \mathbb{R}^{n\times n}$ 为固定矩阵，满足 $\operatorname{rank}(\boldsymbol{X}) \leqslant r$，噪声 ν_{ij} 为相互独立且独立于观测变量 δ_{ij} 的零均值 sub-Gaussian 随机变量，满足 $\max_{i,j} \|\nu_{ij}\|_{\psi_2} \leqslant K$。

我们观测到的不是 $\boldsymbol{X}$ 的部分元素，而是这些元素加上噪声之后的版本。定义观测矩阵 $\boldsymbol{Y}$ 为

$$Y_{ij} = \delta_{ij}(X_{ij} + \nu_{ij}),$$

其中 δ_{ij} i.i.d. $\sim B(p)$ 表示是否观测位置 (i,j)，且 $\{\delta_{ij}\}$ 与 $\{\nu_{ij}\}$ 相互独立。设 $\hat{\boldsymbol{X}}$ 为 $p^{-1}\boldsymbol{Y}$ 的最佳秩 r 逼近，令 $m = pn^2$ 为期望观测条目总数。证明：若 $m \geqslant C' n \ln n$，则

$$\mathrm{E}\left[\frac{1}{n}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F\right] \leqslant C\sqrt{\frac{rn\ln n}{m}}(\|\boldsymbol{X}\|_\infty + K)。 \qquad (C > 0)$$

证明 若 $K = 0$，则噪声几乎处处为零，结论由习题 Q6.31 (矩形矩阵的矩阵完备化) 得到。以下设 $K > 0$。同理于习题 Q6.31 (矩形矩阵的矩阵完备化)，根据 Eckart-Young-Mirsky 定理，可得

$$\begin{aligned}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\| &\leqslant \|\hat{\boldsymbol{X}} - p^{-1}\boldsymbol{Y}\| + \|p^{-1}\boldsymbol{Y} - \boldsymbol{X}\| \\ &\leqslant 2\|p^{-1}\boldsymbol{Y} - \boldsymbol{X}\| = \frac{2}{p}\|\boldsymbol{Y} - p\boldsymbol{X}\|。\end{aligned}$$

对于 $\boldsymbol{Z} = \boldsymbol{Y} - p\boldsymbol{X}$，其第 (i,j) 个元素为

$$Z_{ij} = \delta_{ij}(X_{ij} + \nu_{ij}) - pX_{ij} = (\delta_{ij} - p)X_{ij} + \delta_{ij}\nu_{ij},$$

将其拆分为 $\boldsymbol{Z} = \boldsymbol{Z}^{(1)} + \boldsymbol{Z}^{(2)}$，其中 (信号误差矩阵) $Z_{ij}^{(1)} = (\delta_{ij} - p)X_{ij}$，(噪声误差矩阵) $Z_{ij}^{(2)} = \delta_{ij}\nu_{ij}$，则利用三角不等式，可得

$$\mathrm{E}\|\boldsymbol{Z}\| \leqslant \mathrm{E}\|\boldsymbol{Z}^{(1)}\| + \mathrm{E}\|\boldsymbol{Z}^{(2)}\|,$$

之后只需界定 $\mathrm{E}\|\boldsymbol{Z}^{(1)}\|, \mathrm{E}\|\boldsymbol{Z}^{(2)}\|$。

对于 $\boldsymbol{Z}^{(1)}$，根据定理 T6.5.1 (矩阵补全)，可得

$$\mathrm{E}\|\boldsymbol{Z}^{(1)}\| \leqslant C_1\sqrt{pn\ln n}\|\boldsymbol{X}\|_\infty。 \tag{I}$$

对于 $\boldsymbol{Z}^{(2)}$，根据习题 Q6.28 (矩形随机矩阵的范数)，可得

$$\mathrm{E}\|\boldsymbol{Z}^{(2)}\| \leqslant C_2\sqrt{\ln n}\left(\mathrm{E}\left[\max_{1\leqslant i\leqslant n} \|(\boldsymbol{Z}^{(2)})_{i*}\|_2\right] + \mathrm{E}\left[\max_{1\leqslant j\leqslant n} \|(\boldsymbol{Z}^{(2)})_{*j}\|_2\right]\right)。 \tag{II}$$

(根据对称性，我们只需计算行范数的上界即可。)

作出以下推断：

推断 令 $S_i = \|(\boldsymbol{Z}^{(2)})_{i*}\|_2^2 = \sum_{j=1}^n \delta_{ij}\nu_{ij}^2$，则

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n} S_i\right] \leqslant CpnK^2。$$

令 $W_{ij} = \delta_{ij}\nu_{ij}^2$。

由于 ν_{ij} 为 sub-Gaussian 随机变量，因此 ν_{ij}^2 为 sub-Exponential 随机变量，满足

$$\mathrm{E}[\nu_{ij}^2] \leqslant c_1K^2，\ \mathrm{E}[\nu_{ij}^4] \leqslant c_2K^4，\ \|\nu_{ij}^2\|_{\psi_1} \leqslant c_3K^2，$$

从而 W_{ij} 的数字特征为

$$\mathrm{E}[W_{ij}] = \mathrm{E}[\delta_{ij}]\mathrm{E}[\nu_{ij}^2] \leqslant p\cdot c_1K^2，$$
$$\mathrm{Var}(W_{ij}) \leqslant \mathrm{E}[W_{ij}^2] = \mathrm{E}[\delta_{ij}^2]\mathrm{E}[\nu_{ij}^4] = p\cdot\mathrm{E}[\nu_{ij}^4] \leqslant c_2pK^4。$$

此外，由于 ν_{ij}^2 为 sub-Exponential 随机变量，因此 $\delta_{ij}\nu_{ij}^2$ 为 sub-Exponential 随机变量，满足 $\|W_{ij}\|_{\psi_1} = \|\delta_{ij}\nu_{ij}^2\|_{\psi_1} \leqslant c_3K^2$。

定义中心化变量 $Y_{ij} = W_{ij} - \mathrm{E}[W_{ij}]$，则 $\mathrm{E}[Y_{ij}] = 0$，$v_j = \mathrm{Var}(Y_{ij}) \leqslant c_2pK^4$，$\|Y_{ij}\|_{\psi_1} \leqslant c_4K^2$。

对于第 i 行的和的波动部分 $M_i = \sum_{j=1}^n Y_{ij} = S_i - \mathrm{E}[S_i]$，利用定理 T2.9.1 (sub-Exponential Bernstein 不等式) (sub-Exponential Bernstein 不等式)，可得对于任意的 $t \geqslant 0$，

$$\begin{aligned}\mathrm{P}\{|M_i| \geqslant t\} &\leqslant 2\exp\left(-c\min\left(\frac{t^2}{\sum_{j=1}^n v_j}, \frac{t}{\max_j\|Y_{ij}\|_{\psi_1}}\right)\right)\\ &\leqslant 2\exp\left(-c\min\left(\frac{t^2}{pnK^4}, \frac{t}{K^2}\right)\right),\end{aligned}$$

令 $M = \max_{1\leqslant i\leqslant n}|M_i|$，利用并集界，可得

$$\mathrm{P}\{M \geqslant t\} \leqslant \sum_{i=1}^n \mathrm{P}\{|M_i| \geqslant t\} \leqslant 2n\exp\left(-c\min\left(\frac{t^2}{pnK^4}, \frac{t}{K^2}\right)\right)。$$

为了有效地计算 $\mathrm{E}[M] = \int_0^\infty \mathrm{P}\{M \geqslant t\}\mathrm{d}t$，之后只需寻找阶段点 t_0，使得指数部分满足

$$\min\left(\frac{t^2}{pnK^4}, \frac{t}{K^2}\right) = \ln n，$$

解得 $t \asymp \max(\sqrt{pn\ln n}K^2, (\ln n)K^2)$，因此令 $t_0 = C_0pnK^2$，可得

$$\mathrm{P}\{M \geqslant t\} \leqslant \sum_{i=1}^n \mathrm{P}\{|M_i| \geqslant t\} \leqslant 2n\exp\left(-c\min\left(\frac{t^2}{pnK^4}, \frac{t}{K^2}\right)\right)，$$

$$\begin{aligned}\mathrm{E}[M] &= \int_0^{t_0} \mathrm{P}\{M \geqslant t\}\mathrm{d}t + \int_{t_0}^\infty \mathrm{P}\{M \geqslant t\}\mathrm{d}t\\ &\leqslant t_0 + \int_{t_0}^\infty 2n\exp\left(-c\min\left(\frac{t^2}{pnK^4}, \frac{t}{K^2}\right)\right)\mathrm{d}t\\ &= C_0pnK^2 + \int_{t_0}^\infty 2n\exp\left(-c\frac{t}{K^2}\right)\mathrm{d}t,\end{aligned}$$

其中当 $C_0 \geqslant 3/c$ 时，

$$\begin{aligned}\int_{t_0}^\infty 2n\exp\left(-c\frac{t}{K^2}\right)\mathrm{d}t &= 2n\frac{K^2}{c}\exp\left(-c\frac{t_0}{K^2}\right)\\ &\leqslant 2n\frac{K^2}{c}\exp(-cC_0pn) \leqslant 2n\frac{K^2}{c}\exp(-3\ln n) = \frac{2K^2}{cn^2} \to 0，\end{aligned}$$

将其代入，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|S_i - \mathrm{E}[S_i]|\right] = \mathrm{E}[M] \leqslant C_0pnK^2 + o(1) \leqslant C_1pnK^2。$$

如此，利用 $\max_i S_i \leqslant \max_i |S_i - \mathrm{E}[S_i]| + \max_i \mathrm{E}[S_i]$，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n} S_i\right] \leqslant c_1 pnK^2 + C_1 pnK^2 = (c_1 + C_1)pnK^2 = C_6 pnK^2。$$

根据推断，利用 Jensen 不等式 $\mathrm{E}[\sqrt{S}] \leqslant \sqrt{\mathrm{E}[S]}$，可得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n} \|(\boldsymbol{Z}^{(2)})_{i*}\|_2\right] \leqslant \sqrt{\mathrm{E}\left[\max_{1\leqslant i\leqslant n} S_i\right]} \leqslant C_7\sqrt{pn}K,$$

将其代入于 (II)，可得

$$\mathrm{E}\|\boldsymbol{Z}^{(2)}\| \leqslant C_8\sqrt{\ln n}\cdot\sqrt{pn}K = C_8\sqrt{pn\ln n}K。 \tag{III}$$

如此，联立 (I)(III)，可得

$$\mathrm{E}\|\boldsymbol{Z}\| \leqslant \mathrm{E}\|\boldsymbol{Z}^{(1)}\| + \mathrm{E}\|\boldsymbol{Z}^{(2)}\| \leqslant C_9\sqrt{pn\ln n}(\|\boldsymbol{X}\|_\infty + K),$$

利用不等式 $\|\boldsymbol{M}\|_F \leqslant \sqrt{\mathrm{rank}(\boldsymbol{M})}\|\boldsymbol{M}\|$，可得

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\| \leqslant \frac{2}{p}C_9\sqrt{pn\ln n}(\|\boldsymbol{X}\|_\infty + K) = C_{10}\sqrt{\frac{n\ln n}{p}}(\|\boldsymbol{X}\|_\infty + K),$$

由秩界，$\mathrm{rank}(\hat{\boldsymbol{X}} - \boldsymbol{X}) \leqslant 2r$，故

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant \sqrt{2r}\,\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\| \leqslant C_{11}\sqrt{\frac{rn\ln n}{p}}(\|\boldsymbol{X}\|_\infty + K)。$$

两侧除以 n，

$$\mathrm{E}\left[\frac{1}{n}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F\right] \leqslant \frac{1}{n}C_{11}\sqrt{\frac{rn\ln n}{p}}(\|\boldsymbol{X}\|_\infty + K) = C_{11}\sqrt{\frac{rn\ln n}{pn^2}}(\|\boldsymbol{X}\|_\infty + K),$$

即

$$\mathrm{E}\left[\frac{1}{n}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F\right] \leqslant C\sqrt{\frac{rn\ln n}{m}}(\|\boldsymbol{X}\|_\infty + K),$$

条件 $pn \geqslant \ln n$ 等价于

$$m \geqslant n^2\frac{\ln n}{n} = n\ln n。$$

33 于随机矩阵理论，很少有不对矩阵分布做任意假设就能成立的普适性结果。本题旨在证明其中一个：适用于无界随机矩阵的矩阵 Bernstein 不等式变体。(从更广阔的视角来看，该不等式本质上说明：对于 $p \geqslant 2$，L_p 空间具有 type 2 性质，正如我们于练习 Q6.24 (Type 2 性质) 考察的 ℓ_p 空间那样。)

设 $\boldsymbol{Z}_1, \cdots, \boldsymbol{Z}_N \in \mathbb{R}^{n\times n}$ 为相互独立的半正定随机矩阵。令 $\boldsymbol{S} = \sum_{i=1}^N \boldsymbol{Z}_i$。证明：

$$\mathrm{E}\|\boldsymbol{S} - \mathrm{E}[\boldsymbol{S}]\| \leqslant C(\sqrt{\|\mathrm{E}[\boldsymbol{S}]\|\cdot L} + L), \qquad (C > 0)$$

其中 $L = \ln(n)\mathrm{E}[\max_{1\leqslant i\leqslant N}\|\boldsymbol{Z}_i\|]$。

证明 • 对称化, 矩阵 Khintchine 不等式

令中心化矩阵 $\boldsymbol{V}_i = \boldsymbol{Z}_i - \mathrm{E}[\boldsymbol{Z}_i]$，我们只需界定 $\mathrm{E}\left\|\sum_{i=1}^N \boldsymbol{V}_i\right\|$。

引入 $\varepsilon_1, \cdots, \varepsilon_N$ i.i.d. $\sim$ Rademacher，则根据对称化引理，可得

$$\mathrm{E}\|\boldsymbol{S} - \mathrm{E}[\boldsymbol{S}]\| \leqslant 2\mathrm{E}_{\boldsymbol{Z},\varepsilon}\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{Z}_i\right\|。$$

对于右侧，利用定理 T5.4.14 (矩阵 Khintchine 不等式) (矩阵 Khintchine 不等式)，可得

$$\mathrm{E}_\varepsilon\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{Z}_i\right\| \leqslant c_K\sqrt{\ln n}\left\|\sum_{i=1}^N \boldsymbol{Z}_i^2\right\|^{1/2}, \qquad (c_K > 0)$$

两侧对 $\boldsymbol{Z}$ 取期望，可得

$$\mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\| \leqslant 2c_K\sqrt{\ln n}\cdot \mathrm{E}_{\boldsymbol{Z}}\left[\left\|\sum_{i=1}^N \boldsymbol{Z}_i^2\right\|^{1/2}\right]。 \tag{I}$$

- 利用半正定性约束方差项

令 $R=\max_{1\leqslant i\leqslant N}\|\boldsymbol{Z}_i\|$，则 $\boldsymbol{Z}_i^2 \preccurlyeq \|\boldsymbol{Z}_i\|\boldsymbol{Z}_i \preccurlyeq R\boldsymbol{Z}_i$，两侧求和，可得

$$\sum_{i=1}^N \boldsymbol{Z}_i^2 \preccurlyeq R\sum_{i=1}^N \boldsymbol{Z}_i = R\boldsymbol{S},$$

因此

$$\left\|\sum_{i=1}^N \boldsymbol{Z}_i^2\right\| \leqslant \|R\boldsymbol{S}\| = R\|\boldsymbol{S}\|,$$

将其代入于 (I)，利用 Jensen 不等式，可得

$$\mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\| \leqslant 2c_K\sqrt{\ln n}\cdot\sqrt{\mathrm{E}[R\|\boldsymbol{S}\|]},$$

之后利用 Cauchy 不等式 $\mathrm{E}[\sqrt{R\|\boldsymbol{S}\|}] \leqslant \sqrt{\mathrm{E}[R]}\cdot\sqrt{\mathrm{E}\|\boldsymbol{S}\|}$，令 $L=\ln n\cdot\mathrm{E}[R]$，可得

$$\mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\| \leqslant C_1\sqrt{L}\cdot\sqrt{\mathrm{E}\|\boldsymbol{S}\|}。 \tag{II}$$

- 求解关于期望的代数不等式

利用三角不等式，可得

$$\mathrm{E}\|\boldsymbol{S}\| \leqslant \mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\| + \|\mathrm{E}[\boldsymbol{S}]\|,$$

令 $E=\mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\|$，将其代入于 (II)，可得

$$E \leqslant C_1\sqrt{L}\sqrt{E+\|\mathrm{E}[\boldsymbol{S}]\|},$$

两侧平方，

$$E^2 \leqslant C_1^2L(E+\|\mathrm{E}[\boldsymbol{S}]\|) = C_1^2LE + C_1^2L\|\mathrm{E}[\boldsymbol{S}]\|,$$

即为关于 E 的二次不等式

$$E^2 - (C_1^2L)E - C_1^2L\|\mathrm{E}[\boldsymbol{S}]\| \leqslant 0,$$

利用不等式 $\sqrt{a^2+b^2}\leqslant a+b$，解得

$$E \leqslant \frac{C_1^2L+\sqrt{C_1^4L^2+4C_1^2L\|\mathrm{E}[\boldsymbol{S}]\|}}{2} \leqslant \frac{C_1^2L+C_1^2L+2C_1\sqrt{L\|\mathrm{E}[\boldsymbol{S}]\|}}{2} = C_1^2L + C_1\sqrt{L\|\mathrm{E}[\boldsymbol{S}]\|},$$

即

$$\mathrm{E}\|\boldsymbol{S}-\mathrm{E}[\boldsymbol{S}]\| \leqslant C(L+\sqrt{L\|\mathrm{E}[\boldsymbol{S}]\|})。 \qquad (C=\max(C_1^2,C_1))$$

34 [**无界分布的协方差估计**] 设 $\boldsymbol{X}\in\mathbb{R}^n$ 为中心化[3]随机向量，其非零[4]协方差矩阵为 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$，$\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m$ 为 $\boldsymbol{X}$ 的独立副本，其样本协方差矩阵为

$$\boldsymbol{\Sigma}_m = \frac{1}{m}\sum_{i=1}^m \boldsymbol{X}_i\boldsymbol{X}_i^\top,$$

满足存在 $K\geqslant 1$，使得

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\right] \leqslant K^2\mathrm{E}\|\boldsymbol{X}\|_2^2。$$

定义有效秩为 $r=\mathrm{tr}(\boldsymbol{\Sigma})/\|\boldsymbol{\Sigma}\|$。证明：

$$\mathrm{E}\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\| \leqslant C\left(\sqrt{\frac{K^2r\ln n}{m}}+\frac{K^2r\ln n}{m}\right)\|\boldsymbol{\Sigma}\|。 \qquad (C>0)$$

[3]原题干未陈述 $\boldsymbol{X}$ 的中心化条件。现补充此条件，使 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]$ 确为协方差矩阵；一般情形下，协方差应为 $\mathrm{E}[(\boldsymbol{X}-\mathrm{E}[\boldsymbol{X}])(\boldsymbol{X}-\mathrm{E}[\boldsymbol{X}])^\top]$。

[4]原题干未要求协方差矩阵非零。现补充此条件。后文定义有效秩 $r=\mathrm{tr}(\boldsymbol{\Sigma})/\|\boldsymbol{\Sigma}\|$；若 $\boldsymbol{\Sigma}=\boldsymbol{0}$，此比值为 $0/0$，没有定义。

证明 根据习题 Q6.33，令 $\boldsymbol{Z}_i = \boldsymbol{X}_i\boldsymbol{X}_i^\top$，$\boldsymbol{S} = \sum_{i=1}^m \boldsymbol{Z}_i = m\boldsymbol{\Sigma}_m$，可得

$$\mathrm{E}\|\boldsymbol{S} - \mathrm{E}[\boldsymbol{S}]\| \leqslant C_0(\sqrt{\|\mathrm{E}[\boldsymbol{S}]\| \cdot L} + L)。$$

代入 $\mathrm{E}[\boldsymbol{S}] = m\mathrm{E}[\boldsymbol{X}_1\boldsymbol{X}_1^\top] = m\boldsymbol{\Sigma}$，$\|\mathrm{E}[\boldsymbol{S}]\| = m\|\boldsymbol{\Sigma}\|$，

$$\begin{aligned} L &= \ln(n)\mathrm{E}\left[\max_{1\leqslant i\leqslant m}\|\boldsymbol{Z}_i\|\right] = \ln(n)\mathrm{E}\left[\max_{1\leqslant i\leqslant m}\|\boldsymbol{X}_i\|_2^2\right] \\ &\leqslant K^2\ln(n)\mathrm{E}[\mathrm{tr}(\boldsymbol{X}\boldsymbol{X}^\top)] = K^2\ln(n)\,\mathrm{tr}(\boldsymbol{\Sigma}) \leqslant K^2 r\ln(n)\|\boldsymbol{\Sigma}\|, \end{aligned}$$

可得

$$\mathrm{E}\|m\boldsymbol{\Sigma}_m - m\boldsymbol{\Sigma}\| \leqslant C_0(\sqrt{(m\|\boldsymbol{\Sigma}\|)\cdot(K^2 r\ln n\|\boldsymbol{\Sigma}\|)} + K^2 r\ln(n)\|\boldsymbol{\Sigma}\|),$$

即

$$\mathrm{E}\|\boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}\| \leqslant C_0\left(\sqrt{\frac{K^2 r\ln n}{m}} + \frac{K^2 r\ln n}{m}\right)\|\boldsymbol{\Sigma}\|。$$

35 [**Rademacher 级数期望的凸性**] 设 $\boldsymbol{z}_1,\cdots,\boldsymbol{z}_N$ 为固定的向量，$\boldsymbol{a} = (a_1,\cdots,a_N) \in \mathbb{R}^N$。设 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher。证明：

$$f(\boldsymbol{a}) = \mathrm{E}\left\|\sum_{i=1}^N a_i\varepsilon_i\boldsymbol{z}_i\right\|$$

于 $\mathbb{R}^N$ 为凸函数。

证明 要证明 $f(\boldsymbol{a})$ 为凸函数，只需证明对于任意的 $\boldsymbol{a},\boldsymbol{b}\in\mathbb{R}^N$, $\lambda\in[0,1]$，

$$f(\lambda\boldsymbol{a} + (1-\lambda)\boldsymbol{b}) \leqslant \lambda f(\boldsymbol{a}) + (1-\lambda)f(\boldsymbol{b})。$$

容易知道，

$$\begin{aligned} f(\lambda\boldsymbol{a} + (1-\lambda)\boldsymbol{b}) &= \mathrm{E}\left\|\sum_{i=1}^N(\lambda a_i + (1-\lambda)b_i)\varepsilon_i\boldsymbol{z}_i\right\| \\ &= \mathrm{E}\left\|\sum_{i=1}^N \lambda a_i\varepsilon_i\boldsymbol{z}_i + \sum_{i=1}^N(1-\lambda)b_i\varepsilon_i\boldsymbol{z}_i\right\| \\ &\leqslant \mathrm{E}\left\|\sum_{i=1}^N \lambda a_i\varepsilon_i\boldsymbol{z}_i\right\| + \mathrm{E}\left\|\sum_{i=1}^N(1-\lambda)b_i\varepsilon_i\boldsymbol{z}_i\right\| \\ &= \lambda f(\boldsymbol{a}) + (1-\lambda)f(\boldsymbol{b})。 \end{aligned}$$

注释 事实上，范数 $\|\cdot\|$ 为凸函数，映射 $\boldsymbol{a}\mapsto\sum a_i\varepsilon_i\boldsymbol{z}_i$ 为线性映射，凸函数与线性映射的复合仍然为凸函数，期望算子 E 保持凸性，因此结论是平凡的。

36 [**一般分布的收缩原理**] 设 $\boldsymbol{a} = (a_1,\cdots,a_N)\in\mathbb{R}^N$ 为系数向量，$\boldsymbol{X}_1,\cdots,\boldsymbol{X}_N$ 为相互独立的零均值随机向量。证明：

$$\mathrm{E}\left\|\sum_{i=1}^N a_i\boldsymbol{X}_i\right\| \leqslant 4\|\boldsymbol{a}\|_\infty\cdot\mathrm{E}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|。$$

证明 根据引理 L6.3.2 (对称化) 的上界，可得

$$\mathrm{E}\left\|\sum_{i=1}^N a_i\boldsymbol{X}_i\right\| \leqslant 2\mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^N\varepsilon_i a_i\boldsymbol{X}_i\right\|; \tag{I}$$

根据引理 L6.3.2 (对称化) 的下界，可得

$$\mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^N\varepsilon_i\boldsymbol{X}_i\right\| \leqslant 2\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^N\boldsymbol{X}_i\right\|。 \tag{II}$$

根据定理 T6.6.1 (收缩原理)，可得

$$\mathrm{E}_{\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i a_i \boldsymbol{X}_i\right\| \leqslant \|\boldsymbol{a}\|_{\infty}\cdot \mathrm{E}_{\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i \boldsymbol{X}_i\right\|,$$

两侧关于 $\boldsymbol{X}$ 取期望，

$$\mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i a_i \boldsymbol{X}_i\right\| \leqslant \|\boldsymbol{a}\|_{\infty}\cdot \mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i \boldsymbol{X}_i\right\|。 \tag{III}$$

将 (I)(II) 代入于 (III)，可得

$$\begin{aligned}
\mathrm{E}\left\|\sum_{i=1}^{N} a_i \boldsymbol{X}_i\right\| &\leqslant 2\cdot\left(\mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i a_i \boldsymbol{X}_i\right\|\right)\\
&\leqslant 2\cdot\left(\|\boldsymbol{a}\|_{\infty}\cdot\mathrm{E}_{\boldsymbol{X},\varepsilon}\left\|\sum_{i=1}^{N}\varepsilon_i \boldsymbol{X}_i\right\|\right)\\
&\leqslant 2\cdot\|\boldsymbol{a}\|_{\infty}\cdot\left(2\cdot\mathrm{E}_{\boldsymbol{X}}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|\right)\\
&= 4\|\boldsymbol{a}\|_{\infty}\cdot\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|。
\end{aligned}$$

37 [**Gaussian 对称化的对数因子是不可避免的**] 设 $N\geqslant 2^5$。于引理 L6.6.2 (用 Gaussian 随机变量对称化)，我们证明了对于任意的相互独立的零均值随机向量 $X_1,\cdots,X_N$，

$$\frac{c}{\sqrt{\ln N}}\mathrm{E}\left\|\sum_{i=1}^{N} g_i X_i\right\| \leqslant \mathrm{E}\left\|\sum_{i=1}^{N} X_i\right\|, \qquad (c>0)$$

其中 $g_1,\cdots,g_N\sim N(0,1)$ 独立于 $X_1,\cdots,X_N$。

构造赋范空间及其特定的随机向量 $X_1,\cdots,X_N$，证明一般情况，不等式左侧的惩罚因子 $\sqrt{\ln N}$ 是最优的。

证明 考虑赋范空间 ℓ_{∞}^{N}，其范数为 $\|\boldsymbol{v}\|_{\infty}=\max_{1\leqslant i\leqslant N}|v_i|$。

设 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，令 $\boldsymbol{e}_1,\cdots,\boldsymbol{e}_N\in\mathbb{R}^N$ 为标准正交基向量，定义

$$\boldsymbol{X}_i=\varepsilon_i\boldsymbol{e}_i,$$

则 $\boldsymbol{X}_i$ 是相互独立的, 零均值的。

对于原始期望范数，

$$\sum_{i=1}^{N}\boldsymbol{X}_i=\sum_{i=1}^{N}\varepsilon_i\boldsymbol{e}_i=(\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_N)^{\top},$$

因此

$$\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_{\infty}=\max_{1\leqslant i\leqslant N}|\varepsilon_i|,$$

从而

$$\mathrm{E}\left\|\sum_{i=1}^{N}\boldsymbol{X}_i\right\|_{\infty}=\mathrm{E}[1]=1。 \tag{I}$$

对于 Gaussian 加权和的期望范数，

$$\sum_{i=1}^{N} g_i\boldsymbol{X}_i=\sum_{i=1}^{N} g_i\varepsilon_i\boldsymbol{e}_i=(g_1\varepsilon_1,g_2\varepsilon_2,\cdots,g_N\varepsilon_N)^{\top},$$

[5] 原题干未限制 N 的取值。现补充 $N\geqslant 2$。由于结论含有 $1/\sqrt{\ln N}$，当 $N=1$ 时，$\ln N=0$，此表达式没有定义。

因此

$$\left\|\sum_{i=1}^N g_i \boldsymbol{X}_i\right\|_\infty = \max_{1\leqslant i\leqslant N}|g_i\varepsilon_i| = \max_{1\leqslant i\leqslant N}|g_i|,$$

从而根据 Gaussian 极值的性质 $\mathrm{E}[\max_{1\leqslant i\leqslant N}|g_i|]\geqslant c'\sqrt{\ln N}$，可得

$$\mathrm{E}\left\|\sum_{i=1}^N g_i \boldsymbol{X}_i\right\|_\infty = \mathrm{E}\left[\max_{1\leqslant i\leqslant N}|g_i|\right]\geqslant c'\sqrt{\ln N}。\tag{II}$$

联立 (I)(II)，可得

$$\frac{c}{f(N)}\cdot(c'\sqrt{\ln N})\leqslant 1 \implies f(N)\geqslant (c\cdot c')\sqrt{\ln N}。$$

38 [**凸函数的对称化, 收缩原理**] 设 $F:\mathbb{R}^+\to\mathbb{R}$ 为递增的凸函数。将定理 T6.6.1 (收缩原理), 引理 L6.6.2 (用 Gaussian 随机变量对称化) 的范数 $\|\cdot\|$ 替换为 $F(\|\cdot\|)$，之后证明推广的结论。

具体而言，设 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N$ 为固定的向量，$\boldsymbol{a}=(a_1,\cdots,a_N)\in\mathbb{R}^N$ 为系数向量，$\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher，$g_1,\cdots,g_N$ i.i.d. $\sim N(0,1)$。证明：

(1) [**推广的收缩原理**]

$$\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N a_i\varepsilon_i\boldsymbol{x}_i\right\|\right)\right]\leqslant \mathrm{E}\left[F\left(\|\boldsymbol{a}\|_\infty\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]。$$

(2) [**推广的 Gaussian 对称化 (上界)**]

$$\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]\leqslant \mathrm{E}\left[F\left(\sqrt{\frac{\pi}{2}}\left\|\sum_{i=1}^N g_i\boldsymbol{x}_i\right\|\right)\right]。$$

(3) [**推广的 Gaussian 对称化 (下界)**]

$$\mathrm{E}\left[F\left(\left\|\sum_{i=1}^N g_i\boldsymbol{x}_i\right\|\right)\right]\leqslant \mathrm{E}_{\boldsymbol{g},\varepsilon}\left[F\left(\|\boldsymbol{g}\|_\infty\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]。$$

证明 (1) 令 $G(\boldsymbol{v})=F(\|\boldsymbol{v}\|)$ 为凸函数，定义 $f(\boldsymbol{a})=\mathrm{E}_\varepsilon[G(\sum_{i=1}^N a_i\varepsilon_i\boldsymbol{x}_i)]$，则 $f(\boldsymbol{a})$ 为关于 $\boldsymbol{a}$ 的凸函数，因此 f 在其定义域 $[-\|\boldsymbol{a}\|_\infty,\|\boldsymbol{a}\|_\infty]^N$ 的最大值必定于顶点取得。

令 $M=\|\boldsymbol{a}\|_\infty$，顶点 $\boldsymbol{v}=(Ms_1,\cdots,Ms_N)$，其中 $s_i\in\{-1,1\}$，则

$$f(\boldsymbol{v})\geqslant f(\boldsymbol{a}),$$

其中

$$f(\boldsymbol{v})=\mathrm{E}_\varepsilon\left[F\left(\left\|\sum_{i=1}^N (Ms_i)\varepsilon_i\boldsymbol{x}_i\right\|\right)\right]=\mathrm{E}_\varepsilon\left[F\left(M\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]=\mathrm{E}_\varepsilon\left[F\left(\|\boldsymbol{a}\|_\infty\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right],$$

将其代入，可得

$$\mathrm{E}\left[F\left(\|\boldsymbol{a}\|_\infty\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]\geqslant \mathrm{E}\left[F\left(\left\|\sum_{i=1}^N a_i\varepsilon_i\boldsymbol{x}_i\right\|\right)\right]。$$

(2) 对于 $g_i\sim N(0,1)$，其绝对值的期望为 $\mathrm{E}[|g_i|]=\sqrt{2/\pi}$，令 $c=\sqrt{2/\pi}$，则 $c^{-1}\mathrm{E}[|g_i|]=1$。

对于左侧，

$$\begin{aligned}\mathrm{E}_\varepsilon\left[F\left(\left\|\sum_{i=1}^N \varepsilon_i\boldsymbol{x}_i\right\|\right)\right]&=\mathrm{E}_\varepsilon\left[F\left(\left\|\sum_{i=1}^N \varepsilon_i\left(\frac{1}{c}\mathrm{E}_{\boldsymbol{g}}[|g_i|]\right)\boldsymbol{x}_i\right\|\right)\right]\\&=\mathrm{E}_\varepsilon\left[F\left(\frac{1}{c}\left\|\mathrm{E}_{\boldsymbol{g}}\left[\sum_{i=1}^N \varepsilon_i|g_i|\boldsymbol{x}_i\right]\right\|\right)\right],\end{aligned}$$

利用 Jensen 不等式，可得

$$\begin{aligned}\mathrm{E}_{\varepsilon}\left[F\left(\frac{1}{c}\left\|\mathrm{E}_{\boldsymbol{g}}\left[\sum_{i=1}^{N}\varepsilon_i|g_i|\boldsymbol{x}_i\right]\right\|\right)\right] &\leqslant \mathrm{E}_{\varepsilon}\left[\mathrm{E}_{\boldsymbol{g}}\left[F\left(\frac{1}{c}\left\|\sum_{i=1}^{N}\varepsilon_i|g_i|\boldsymbol{x}_i\right\|\right)\right]\right]\\ &= \mathrm{E}_{\varepsilon,\boldsymbol{g}}\left[F\left(\sqrt{\frac{\pi}{2}}\left\|\sum_{i=1}^{N}\varepsilon_i|g_i|\boldsymbol{x}_i\right\|\right)\right]\\ &= \mathrm{E}_{\boldsymbol{g}}\left[F\left(\sqrt{\frac{\pi}{2}}\left\|\sum_{i=1}^{N}g_i\boldsymbol{x}_i\right\|\right)\right],\end{aligned}$$

因此

$$\mathrm{E}\left[F\left(\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{x}_i\right\|\right)\right] \leqslant \mathrm{E}\left[F\left(\sqrt{\frac{\pi}{2}}\left\|\sum_{i=1}^{N}g_i\boldsymbol{x}_i\right\|\right)\right]。$$

(3) 对于左侧，

$$\mathrm{E}_{\boldsymbol{g}}\left[F\left(\left\|\sum_{i=1}^{N}g_i\boldsymbol{x}_i\right\|\right)\right] = \mathrm{E}_{\boldsymbol{g},\varepsilon}\left[F\left(\left\|\sum_{i=1}^{N}|g_i|\varepsilon_i\boldsymbol{x}_i\right\|\right)\right]。$$

于给定 $\boldsymbol{g}$ 的条件，利用 (1) 的结论，可得

$$\mathrm{E}_{\varepsilon}\left[F\left(\left\|\sum_{i=1}^{N}|g_i|\varepsilon_i\boldsymbol{x}_i\right\|\right)\middle|\boldsymbol{g}\right] \leqslant \mathrm{E}_{\varepsilon}\left[F\left(\max_i|g_i|\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{x}_i\right\|\right)\middle|\boldsymbol{g}\right] = \mathrm{E}_{\varepsilon}\left[F\left(\|\boldsymbol{g}\|_{\infty}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{x}_i\right\|\right)\middle|\boldsymbol{g}\right],$$

两侧关于 $\boldsymbol{g}$ 取期望，

$$\mathrm{E}_{\boldsymbol{g},\varepsilon}\left[F\left(\left\|\sum_{i=1}^{N}|g_i|\varepsilon_i\boldsymbol{x}_i\right\|\right)\right] \leqslant \mathrm{E}_{\boldsymbol{g},\varepsilon}\left[F\left(\|\boldsymbol{g}\|_{\infty}\left\|\sum_{i=1}^{N}\varepsilon_i\boldsymbol{x}_i\right\|\right)\right]。$$

7 随机过程

要点梳理

Section 7.1 基本概念, 例子 Q7.1 ~ Q7.5

定义 7.1.1 (随机过程)

设 $(\Omega, \mathscr{F}, \mathrm{P})$ 为概率空间，$\mathbb{T}$ 为指标集。若对于任意的 $t \in \mathbb{T}$，X_t 均为定义于此空间的随机变量，则称族 $(X_t : t \in \mathbb{T})$ 为随机过程。

例 7.1.3 (随机游走)

若 $\mathbb{T} = \mathbb{N}$，离散时间的随机过程 $(X_n)_{n\in\mathbb{N}}$ 即为一列随机变量。随机游走是其中重要的例子，定义为

$$X_n = \sum_{i=1}^{n} Z_i,$$

其中增量 Z_i 为相互独立的零均值随机变量。

定义 7.1.9 (Gaussian 过程)

随机过程 $(X_t)_{t\in\mathbb{T}}$ 称为 Gaussian 过程，若对于任意的有限子集 $\mathbb{T}_0 \subset \mathbb{T}$，随机向量 $(X_t)_{t\in\mathbb{T}_0}$ 服从正态分布。等价地，任意的有限线性组合 $\sum_{t\in\mathbb{T}_0} a_t X_t$ 均为正态随机变量。

定理 7.1.11 (Gaussian 过程的集中)

设 $(X_t)_{t\in\mathbb{T}}$ 为有限集 $\mathbb{T}$ 的 Gaussian 过程，则

$$\| \sup_{t\in\mathbb{T}} X_t - \mathrm{E}\left[\sup_t X_t\right] \|_{\psi_2} \leqslant C \sup_{t\in\mathbb{T}} \sqrt{\mathrm{Var}(X_t)}.$$

引理 7.1.12 (Gaussian 随机向量)

设 $\boldsymbol{X} \in \mathbb{R}^n$ 为零均值 Gaussian 随机向量，则存在点 $\boldsymbol{t}_1, \cdots, \boldsymbol{t}_n \in \mathbb{R}^n$，使得

$$\boldsymbol{X} \overset{\text{dist}}{=} (\langle \boldsymbol{g}, \boldsymbol{t}_i \rangle)_{i=1}^n,$$

其中 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。

Section 7.2 Slepian, Sudakov-Fernique, Gordon Q7.6 ~ Q7.10

定理 7.2.2 (Slepian 不等式)

设 $(X_t : t \in \mathbb{T}), (Y_t : t \in \mathbb{T})$ 为零均值 Gaussian 过程，满足 $\mathrm{E}[X_t^2] = \mathrm{E}[Y_t^2]$。若对于任意的 $t, s \in \mathbb{T}$，均满足 $\mathrm{E}[(X_t - X_s)^2] \leqslant \mathrm{E}[(Y_t - Y_s)^2]$，则

$$\text{对于任意的 } \tau \in \mathbb{R},\ \mathrm{P}\left\{\sup_t X_t \geqslant \tau\right\} \leqslant \mathrm{P}\left\{\sup_t Y_t \geqslant \tau\right\}。$$

$$\mathrm{E}\left[\sup_t X_t\right] \leqslant \mathrm{E}\left[\sup_t Y_t\right]。$$

引理 7.2.3 (Gaussian 分部积分)

设 $X \sim N(0,1)$，则对于任意的可微函数 $f : \mathbb{R} \to \mathbb{R}$，

$$\mathrm{E}[Xf(X)] = \mathrm{E}[f'(X)],$$

假设两个期望均存在并且有限。

引理 7.2.4 (多元 Gaussian 分部积分)

设 $\boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{\Sigma})$，则

$$\mathrm{E}[\boldsymbol{X} f(\boldsymbol{X})] = \boldsymbol{\Sigma} \cdot \mathrm{E}[\nabla f(\boldsymbol{X})],$$

$$\mathrm{E}[X_i f(\boldsymbol{X})] = \sum_{j=1}^{n} \Sigma_{ij} \mathrm{E}\left[\frac{\partial f}{\partial x_j}(\boldsymbol{X})\right]。$$

引理 7.2.5 (Gaussian 插值)

考虑两个独立的 Gaussian 随机向量 $\boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{\Sigma}_X)$，$\boldsymbol{Y} \sim N(\boldsymbol{0}, \boldsymbol{\Sigma}_Y)$。定义 $\boldsymbol{Z}(u) = \sqrt{u}\boldsymbol{X} + \sqrt{1-u}\boldsymbol{Y}$，$u \in [0,1]$，则对于任意的二次可微的 f，

$$\frac{d}{du}\mathrm{E}[f(\boldsymbol{Z}(u))] = \frac{1}{2}\sum_{i,j}(\Sigma_{ij}^X - \Sigma_{ij}^Y)\mathrm{E}\left[\frac{\partial^2 f}{\partial x_i \partial x_j}(\boldsymbol{Z}(u))\right]。$$

引理 7.2.6 (Slepian 不等式，函数形式)

考虑 $\mathbb{R}^n$ 的两个零均值 Gaussian 随机向量 $\boldsymbol{X}, \boldsymbol{Y}$，满足 $\mathrm{E}[X_i^2] = \mathrm{E}[Y_i^2]$，对于任意的 i, j，均满足 $\mathrm{E}[(X_i - X_j)^2] \leqslant \mathrm{E}[(Y_i - Y_j)^2]$。对于满足 $\frac{\partial^2 f}{\partial x_i \partial x_j} \geqslant 0$ $(i \neq j)$ 的二次可微函数 f，

$$\mathrm{E}[f(\boldsymbol{X})] \geqslant \mathrm{E}[f(\boldsymbol{Y})]。$$

定理 7.2.7 (Slepian 不等式)

设 $\boldsymbol{X}$，$\boldsymbol{Y}$ 为引理 L7.2.6 (Slepian 不等式，函数形式) 的 Gaussian 随机向量，则

$$\text{对于任意的 } \tau \geqslant 0,\ \mathrm{P}\left\{\max_i X_i \geqslant \tau\right\} \leqslant \mathrm{P}\left\{\max_i Y_i \geqslant \tau\right\}。$$

$$\mathrm{E}\left[\max_i X_i\right] \leqslant \mathrm{E}\left[\max_i Y_i\right]。$$

定理 7.2.8 (Sudakov–Fernique 不等式)

设 $(X_t), (Y_t)$ 为零均值 Gaussian 过程。若对于任意的 $t, s \in \mathbb{T}$，均满足 $\mathrm{E}[(X_t - X_s)^2] \leqslant \mathrm{E}[(Y_t - Y_s)^2]$，则

$$\mathrm{E}\left[\sup_t X_t\right] \leqslant \mathrm{E}\left[\sup_t Y_t\right]。$$

定理 7.2.9 (Gordon 不等式)

设 $(X_{ut}:u\in\mathbb{U},t\in\mathbb{T}),(Y_{ut}:u\in\mathbb{U},t\in\mathbb{T})$ 为零均值 Gaussian 过程。若对于任意的 $u\in\mathbb{U}$, $t,s\in\mathbb{T}$，均满足

$$\mathrm{E}[(X_{ut}-X_{us})^2]\leqslant\mathrm{E}[(Y_{ut}-Y_{us})^2],$$

对于任意的 $u\neq v$, $t,s\in\mathbb{T}$，均满足

$$\mathrm{E}[(X_{ut}-X_{vs})^2]\geqslant\mathrm{E}[(Y_{ut}-Y_{vs})^2],$$

则

$$\mathrm{E}\left[\inf_u\sup_t X_{ut}\right]\leqslant\mathrm{E}\left[\inf_u\sup_t Y_{ut}\right]。$$

Section 7.3 Gaussian 矩阵的精确界 Q7.11 ~ Q7.13

定理 7.3.1 (Gaussian 随机矩阵的范数)
设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则

$$\mathrm{E}\|\boldsymbol{A}\|\leqslant\sqrt{m}+\sqrt{n}。$$

推论 7.3.2 (Gaussian 随机矩阵的范数：尾部)
设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{\|\boldsymbol{A}\|\geqslant\sqrt{m}+\sqrt{n}+t\}\leqslant 2\exp(-ct^2)。$$

Section 7.4 Sudakov 不等式 Q7.14

定理 7.4.1 (Sudakov 不等式)
设 $(X_t)_{t\in\mathbb{T}}$ 为零均值 Gaussian 过程，则对于任意的 $\varepsilon\geqslant 0$，

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\geqslant c\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)},$$

其中 $d(t,s)=\|X_t-X_s\|_{L_2}$。

推论 7.4.2 ($\mathbb{R}^n$ 的 Sudakov 不等式)
设 $\mathbb{T}\subset\mathbb{R}^n$，则对于任意的 $\varepsilon>0$，

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}\langle\boldsymbol{g},t\rangle\right]\geqslant c\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)},$$

其中 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

推论 7.4.3 (多面体的覆盖数)
设 P 为 $\mathbb{B}_2^n$ 的 N 个顶点的多面体，则对于任意的 $\varepsilon>0$，

$$\mathcal{N}(P,\varepsilon)\leqslant N^{C/\varepsilon^2}。$$

Section 7.5 Gaussian 宽度 Q7.15 ~ Q7.23

定义 7.5.1 (Gaussian 宽度)
设 $\mathbb{T}\subset\mathbb{R}^n$，其 Gaussian 宽度定义为

$$w(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right],$$

其中 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

命题 7.5.2 (Gaussian 宽度的简单性质)

(i) $w(\mathbb{T})$ 在平移下不变。(ii) 对于任意的有界集 $\mathbb{T}$，$w(\mathbb{T})<\infty$。(iii) $w(\operatorname{conv}(\mathbb{T}))=w(\mathbb{T})$。(iv) 对于独立的上确界，$w(\mathbb{T}+S)=w(\mathbb{T})+w(S)$。

定义 7.5.4 (球面宽度)
球面宽度为 $w_S(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{\theta},\boldsymbol{x}\rangle\right]$，其中 $\boldsymbol{\theta}$ 均匀分布于 $\mathbb{S}^{n-1}$。

引理 7.5.5 (Gaussian 宽度, 球面宽度)
对于任意的 $\mathbb{T}\subset\mathbb{R}^n$，

$$cw_S(\mathbb{T})\leqslant\frac{1}{\sqrt{n}}w(\mathbb{T})\leqslant Cw_S(\mathbb{T})。$$

引理 7.5.11 (Gaussian 宽度的几乎等价形式)
对于任意的集合 $\mathbb{T}\subset\mathbb{R}^n$，以下量在绝对常数倍的意义下等价：(i) $w(\mathbb{T})$；(ii) $\mathrm{E}\left[\sup_{t\in\mathbb{T}}|\langle\boldsymbol{g},t\rangle|\right]$；(iii) $\sqrt{\mathrm{E}\left[\sup_{t\in\mathbb{T}}\langle\boldsymbol{g},t\rangle^2\right]}$。

定义 7.5.12 (有效维数)
对于有界集 $\mathbb{T}\subset\mathbb{R}^n$，有效维数为 $d(\mathbb{T})=(w(\mathbb{T})/\operatorname{rad}(\mathbb{T}))^2$，其中 $\operatorname{rad}(\mathbb{T})=\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2$。

Section 7.6 集合的随机投影 Q7.24 ~ Q7.27

定理 7.6.1 (集合的随机投影的大小)
设 $\mathbb{T}\subset\mathbb{R}^n$，$\boldsymbol{G}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则

$$\mathrm{E}[\operatorname{rad}(\boldsymbol{G}\mathbb{T})]\leqslant\frac{w(\mathbb{T})}{\sqrt{m}}+\operatorname{rad}(\mathbb{T}),$$

$$\mathrm{E}[w(\boldsymbol{G}\mathbb{T})]\leqslant C\sqrt{m}\cdot w(\mathbb{T})+Cm\cdot\operatorname{rad}(\mathbb{T})。$$

习题解答

1 [**协方差, 增量**] 考虑随机过程 $(X_t)_{t\in\mathbb{T}}$。
(1) 假设常数零随机变量 0 属于此过程，试用度量 $d(t,s)=\|X_t-X_s\|_{L^2}$ 以表示协方差函数 $\Sigma(t,s)=\mathrm{E}[X_tX_s]$。
(2) 假设对于此过程的任意的随机变量 X_t，一定包含其相反数 $-X_t$，试用度量 $d(t,s)=\|X_t-X_s\|_{L^2}$ 以表示协方差函数 $\Sigma(t,s)=\mathrm{E}[X_tX_s]$。
(3) 举例说明，若忽略上述假设，则未必仅通过度量结构恢复协方差函数。

解答 (1) 将度量的平方展开，

$$d(t,s)^2=\mathrm{E}[(X_t-X_s)^2]=\mathrm{E}[X_t^2]+\mathrm{E}[X_s^2]-2\mathrm{E}[X_tX_s],$$

解得

$$\Sigma(t,s)=\mathrm{E}[X_tX_s]=\frac{1}{2}(\mathrm{E}[X_t^2]+\mathrm{E}[X_s^2]-d(t,s)^2)。\tag{I}$$

若存在 $t_0\in\mathbb{T}$，使得 $X_{t_0}\equiv0$，则

$$d(t,t_0)^2=\mathrm{E}[(X_t-X_{t_0})^2]=\mathrm{E}[(X_t-0)^2]=\mathrm{E}[X_t^2],$$

同理，$\mathrm{E}[X_s^2]=d(s,t_0)^2$，将其代入于 (I)，可得

$$\Sigma(t,s)=\frac{1}{2}(d(t,t_0)^2+d(s,t_0)^2-d(t,s)^2),$$

即为极化恒等式。

(2) 容易知道，

$$d(t,s)^2=\mathrm{E}[(X_t-X_s)^2]=\mathrm{E}[X_t^2]+\mathrm{E}[X_s^2]-2\mathrm{E}[X_tX_s]。\tag{II}$$

若存在 $s^*\in\mathbb{T}$，使得 $X_{s^*}=-X_s$，则

$$\begin{aligned}d(t,s^*)^2&=\mathrm{E}[X_t^2]+\mathrm{E}[X_s^2]+2\mathrm{E}[X_tX_s]\\&=\mathrm{E}[X_t^2]+\mathrm{E}[X_s^2]+2\mathrm{E}[X_tX_s],\end{aligned}\tag{III}$$

联立 (II)(III)，可得

$$d(t,s^*)^2-d(t,s)^2=4\mathrm{E}[X_tX_s],$$

解得

$$\Sigma(t,s)=\frac{1}{4}(d(t,s^*)^2-d(t,s)^2)。$$

(3) (若对整个随机过程增加整体的随机位移，变量之间的距离不会改变，但协方差将会改变。)

设 $\mathbb{T}=\{1,2\}$。

定义随机过程 X 为

$$X_1=0，\ X_2=1，$$

则 $d_X(1,2)^2=\mathrm{E}[(0-1)^2]=1$，$\Sigma_X(1,2)=\mathrm{E}[X_1X_2]=\mathrm{E}[0\cdot1]=0$。

之后随机过程 Y 为

$$Y_1=X_1+Z，\ Y_2=X_2+Z，$$

其中 Z 满足 $\mathrm{E}[Z]=0$，$\mathrm{E}[Z^2]=c\neq0$，则 $d_Y(1,2)^2=\mathrm{E}[(Y_1-Y_2)^2]=\mathrm{E}[(Z-(1+Z))^2]=\mathrm{E}[(-1)^2]=1$，$\Sigma_Y(1,2)=\mathrm{E}[Y_1Y_2]=\mathrm{E}[Z(1+Z)]=\mathrm{E}[Z]+\mathrm{E}[Z^2]=0+c=c\neq\Sigma_X$。

注释 极化恒等式为联系范数与内积的桥梁。本题即为极化恒等式于随机过程的体现。

2 [**随机过程的对称化**] 设 $X_1(t),\cdots,X_N(t)$ 是定义于 $\mathbb{T}$ 的 N 个相互独立的零均值随机过程。设 $\varepsilon_1,\cdots,\varepsilon_N$ i.i.d. $\sim$ Rademacher 独立于 X_i。证明：

$$\frac{1}{2}\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_iX_i(t)\right|\right]\leqslant\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^NX_i(t)\right|\right]\leqslant2\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_iX_i(t)\right|\right]。$$

证明 容易知道，$\Phi(Y)=\sup_{t\in\mathbb{T}}|Y(t)|$ 为凸函数。

- 证明右侧不等式

引入独立同分布的副本 $X_1'(t),\cdots,X_N'(t)$，之后利用 Jensen 不等式, 三角不等式，可得

$$\begin{aligned}\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^NX_i(t)\right|\right]&=\mathrm{E}_X\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N(X_i(t)-\mathrm{E}_{X'}[X_i'(t)])\right|\right]\\&\leqslant\mathrm{E}_{X,X'}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N(X_i(t)-X_i'(t))\right|\right]\\&=\mathrm{E}_{X,X',\varepsilon}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_i(X_i(t)-X_i'(t))\right|\right]\\&\leqslant\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_iX_i(t)\right|+\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_iX_i'(t)\right|\right]\\&=2\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^N\varepsilon_iX_i(t)\right|\right]。\end{aligned}$$

- 证明左侧不等式

同理，引入独立同分布的副本 $X_1'(t),\cdots,X_N'(t)$，之后利用 Jensen 不等式, 三角不等式，可得

$$\begin{aligned}
\mathrm{E}_{X,\varepsilon}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}\varepsilon_i X_i(t)\right|\right] &= \mathrm{E}_{X,\varepsilon}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}\varepsilon_i (X_i(t)-\mathrm{E}_{X'}[X_i'(t)])\right|\right]\\
&\leqslant \mathrm{E}_{X,X',\varepsilon}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}\varepsilon_i (X_i(t)-X_i'(t))\right|\right]\\
&= \mathrm{E}_{X,X'}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}(X_i(t)-X_i'(t))\right|\right]\\
&= \mathrm{E}_{X,X'}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}(X_i(t)-X_i'(t))\right|\right]\\
&\leqslant \mathrm{E}_{X,X'}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}X_i(t)\right|+\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}(-X_i'(t))\right|\right]\\
&= 2\mathrm{E}\left[\sup_{t\in\mathbb{T}}\left|\sum_{i=1}^{N}X_i(t)\right|\right]。
\end{aligned}$$

注释 本题说明，若将随机过程视为赋范空间 $L^\infty(\mathbb{T})$ 的随机向量，有限维空间的对称化技术于无穷维空间仍适用。

3 [**Talagrand 收缩原理**] 设 $\mathbb{T}\subset\mathbb{R}^n$，其元素记为 $\boldsymbol{t}=(t_1,\cdots,t_n)$。设 $\varphi_i:\mathbb{R}\to\mathbb{R}$ 为收缩映射 (即满足 $\|\varphi_i\|_{\mathrm{Lip}}\leqslant 1$)。$\varepsilon_1,\cdots,\varepsilon_n$ i.i.d. $\sim$ Rademacher。证明：

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i\varphi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i t_i\right]。$$

按照以下步骤证明：

(1) 先设 $n=2$。考虑子集 $\mathbb{T}\subset\mathbb{R}^2$, 收缩映射 $\varphi:\mathbb{R}\to\mathbb{R}$，证明：

$$\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+\varphi(t_2))+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-\varphi(t_2))\leqslant\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+t_2)+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-t_2)。$$

(2) 对 n 利用归纳法，完成证明。

证明 • 首先证明二维情形

我们首先证明

$$\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+\varphi(t_2))+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-\varphi(t_2))\leqslant\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+t_2)+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-t_2)。$$

引入独立的变量 $\boldsymbol{s},\boldsymbol{t}\in\mathbb{T}$，则左侧为

$$\begin{aligned}
\mathrm{LHS} &= \sup_{\boldsymbol{s}\in\mathbb{T}}(s_1+\varphi(s_2))+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-\varphi(t_2)) = \sup_{\boldsymbol{s},\boldsymbol{t}\in\mathbb{T}}(s_1+t_1+\varphi(s_2)-\varphi(t_2))\\
&\leqslant \sup_{\boldsymbol{s},\boldsymbol{t}\in\mathbb{T}}(s_1+t_1+|s_2-t_2|)。
\end{aligned}$$

a. 若 $s_2\geqslant t_2$，则

$$s_1+t_1+|s_2-t_2|=(s_1+s_2)+(t_1-t_2)\leqslant\sup_{\boldsymbol{u}\in\mathbb{T}}(u_1+u_2)+\sup_{\boldsymbol{v}\in\mathbb{T}}(v_1-v_2).$$

b. 若 $s_2<t_2$，则

$$s_1+t_1+|s_2-t_2|=(t_1+t_2)+(s_1-s_2)\leqslant\sup_{\boldsymbol{u}\in\mathbb{T}}(u_1+u_2)+\sup_{\boldsymbol{v}\in\mathbb{T}}(v_1-v_2).$$

如此，

$$s_1+t_1+\varphi(s_2)-\varphi(t_2)\leqslant\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+t_2)+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-t_2),$$

两侧对 $\boldsymbol{s},\boldsymbol{t}\in\mathbb{T}$ 取上确界，可得

$$\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+\varphi(t_2))+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-\varphi(t_2))\leqslant\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1+t_2)+\sup_{\boldsymbol{t}\in\mathbb{T}}(t_1-t_2)。\tag{I}$$

- 之后考虑一般情况

之后只需证明

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i\varphi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i t_i\right]。$$

定义随机过程 $Y_k(\boldsymbol{t})$ 为

$$Y_k(\boldsymbol{t})=\sum_{i=1}^{k}\varepsilon_i\varphi_i(t_i)+\sum_{i=k+1}^{n}\varepsilon_i t_i,$$

则证明目标即为

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_n(\boldsymbol{t})\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_0(\boldsymbol{t})\right],$$

利用递推，我们只需证明对于任意的 $1\leqslant k\leqslant n$，存在单步的递推下降关系，即

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_k(\boldsymbol{t})\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_{k-1}(\boldsymbol{t})\right]。$$

令

$$f_{k-1}(\boldsymbol{t})=\sum_{i=1}^{k-1}\varepsilon_i\varphi_i(t_i)+\sum_{i=k+1}^{n}\varepsilon_i t_i,$$

则 $_k(\boldsymbol{t})=f_{k-1}(\boldsymbol{t})+\varepsilon_k\varphi_k(t_k)$，$Y_{k-1}(\boldsymbol{t})=f_{k-1}(\boldsymbol{t})+\varepsilon_k t_k$。

条件化除了 ε_k 外的任意 Rademacher 变量 $\varepsilon_1,\cdots,\varepsilon_{k-1},\varepsilon_{k+1},\cdots,\varepsilon_n$，对 $Y_k(\boldsymbol{t})$ 的上确界取条件期望，

$$\mathrm{E}_{\varepsilon_k}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+\varepsilon_k\varphi_k(t_k))\right]=\frac{1}{2}\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+\varphi_k(t_k))+\frac{1}{2}\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})-\varphi_k(t_k)),$$

对于右侧，利用 (I) 的结论，可得

$$\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+\varphi_k(t_k))+\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})-\varphi_k(t_k))\leqslant\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+t_k)+\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})-t_k),$$

将其代入，可得

$$\begin{aligned}\mathrm{E}_{\varepsilon_k}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_k(\boldsymbol{t})\right]&\leqslant\frac{1}{2}\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+t_k)+\frac{1}{2}\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})-t_k)\\&=\mathrm{E}_{\varepsilon_k}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}(f_{k-1}(\boldsymbol{t})+\varepsilon_k t_k)\right]\\&=\mathrm{E}_{\varepsilon_k}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_{k-1}(\boldsymbol{t})\right],\end{aligned}$$

之后对剩余的 ε 取期望，

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_k(\boldsymbol{t})\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_{k-1}(\boldsymbol{t})\right]。$$

如此，

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_n(\boldsymbol{t})\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_{n-1}(\boldsymbol{t})\right]\leqslant\cdots\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_1(\boldsymbol{t})\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_0(\boldsymbol{t})\right],$$

即

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i\varphi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^{n}\varepsilon_i t_i\right]。$$

4 [**一般 Talagrand 收缩原理**] 推广习题 Q7.3 (Talagrand 收缩原理) 的 Talagrand 收缩原理。

设 $\mathbb{T}\subset\mathbb{R}^n$，$\varphi_i:\mathbb{R}\to\mathbb{R}$ 为任意的 Lipschitz 函数，$\varepsilon_1,\cdots,\varepsilon_n$ i.i.d. $\sim$ Rademacher。陈述并证明推广后的一般 Talagrand 收缩原理不等式。

注释 我们将给出两个层级的推广结论。

全局界限的 Talagrand 收缩原理 令 $L=\max_{1\leqslant i\leqslant n}\|\varphi_i\|_{\mathrm{Lip}}$，则

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i\varphi_i(t_i)\right]\leqslant L\cdot\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i t_i\right].$$

分量界限的 Talagrand 收缩原理 令 $L_i=\|\varphi_i\|_{\mathrm{Lip}}$，则

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i\varphi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i L_i t_i\right].$$

证明 若 $L=0$，则 φ_i 均为常数函数，此时

$$\mathrm{E}_\varepsilon\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i c_i\right]=\mathrm{E}_\varepsilon\left[\sum_{i=1}^n\varepsilon_i c_i\right]=0,$$

容易知道，上式成立。

若 $L>0$，定义 $\psi_i(x)=\frac{1}{L}\varphi_i(x)$，满足 $\|\psi_i\|_{\mathrm{Lip}}\leqslant 1$，则根据习题 Q7.3 (Talagrand 收缩原理)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i\psi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i t_i\right],$$

即

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i\varphi_i(t_i)\right]\leqslant L\cdot\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i t_i\right].$$

若 $L_i=0$，则 $\varphi_i(t_i)$ 是常数，其对 Rademacher 期望的贡献为 0，因此不妨设 $L_i>0$。

构造通过对角矩阵线性变换获得的新集合 $\mathbb{S}\subset\mathbb{R}^n$ 为

$$\mathbb{S}=\{\boldsymbol{s}=(L_1t_1,L_2t_2,\cdots,L_nt_n):\boldsymbol{t}\in\mathbb{T}\},$$

定义 $h_i(s)=\varphi_i(\frac{s}{L_i})$，则

$$|h_i(u)-h_i(v)|=\left|\varphi_i\left(\frac{u}{L_i}\right)-\varphi_i\left(\frac{v}{L_i}\right)\right|\leqslant L_i\left|\frac{u}{L_i}-\frac{v}{L_i}\right|=|u-v|,$$

可得 $\|h_i\|_{\mathrm{Lip}}\leqslant 1$，因此根据习题 Q7.3 (Talagrand 收缩原理)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{s}\in\mathbb{S}}\sum_{i=1}^n\varepsilon_i h_i(s_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{s}\in\mathbb{S}}\sum_{i=1}^n\varepsilon_i s_i\right],$$

对于左侧，$h_i(s_i)=h_i(L_it_i)=\varphi_i(t_i)$；对于右侧，$s_i=L_it_i$；将其代入，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i\varphi_i(t_i)\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{i=1}^n\varepsilon_i L_i t_i\right].$$

注释 本题说明收缩映射并不改变 Rademacher 复杂度的结构，仅仅是对 $\mathbb{T}$ 于各个坐标轴进行尺度缩放。

5 [**将随机游走表示为典范过程**] 考虑例 E7.1.3 (随机游走) 的 N 步 Gaussian 随机游走，其增量为 Z_i i.i.d. $\sim N(0,1)$。将随机游走表示为 $\mathbb{T}\subset\mathbb{R}^N$ 的典范 Gaussian 过程。

解答 设 $(X_n)_{n=1}^N$ 为 N 步标准 Gaussian 随机游走，注意到

$$X_n=\sum_{i=1}^n Z_i=Z_1\cdot 1+Z_2\cdot 1+\cdots+Z_n\cdot 1+Z_{n+1}\cdot 0+\cdots+Z_N\cdot 0,$$

因此定义 $\boldsymbol{t}_n = \sum_{i=1}^n \boldsymbol{e}_i$，即

$$\boldsymbol{t}_n = (\underbrace{1,1,\cdots,1}_{n},\underbrace{0,\cdots,0}_{N-n}),$$

其构成指标集 $\mathbb{T} = \{\boldsymbol{t}_1, \boldsymbol{t}_2, \cdots, \boldsymbol{t}_N\} \subset \mathbb{R}^N$ (若要求包含起点 X_0，则将 $\boldsymbol{t}_0 = (0,\cdots,0)$ 加入于 $\mathbb{T}$)，从而标准 Gaussian 随机游走 $(X_n)_{n=1}^N$ 等价于典范 Gaussian 过程 $(\langle \boldsymbol{Z}, \boldsymbol{t}\rangle)_{\boldsymbol{t}\in\mathbb{T}}$。

6 [多元 Gaussian 分部积分] 证明引理 L7.2.4 (多元 Gaussian 分部积分)，亦名多元 Stein 引理。

多元 Stein 引理 设 $\boldsymbol{X} \sim N_n(\boldsymbol{0}, \boldsymbol{\Sigma})$，对于任意的可微函数 $f : \mathbb{R}^n \to \mathbb{R}$，假设以下期望均存在并且有限，则

$$\mathrm{E}[\boldsymbol{X} f(\boldsymbol{X})] = \boldsymbol{\Sigma} \cdot \mathrm{E}[\nabla f(\boldsymbol{X})],$$

其等价于以下分量形式，

$$\mathrm{E}[X_i f(\boldsymbol{X})] = \sum_{j=1}^n \Sigma_{ij} \mathrm{E}\left[\frac{\partial f}{\partial x_j}(\boldsymbol{X})\right].$$

证明 由于 $\boldsymbol{\Sigma}$ 为半正定对称矩阵，因此存在 $\boldsymbol{A} = \boldsymbol{\Sigma}^{1/2}$，使得 $\boldsymbol{A}\boldsymbol{A}^\top = \boldsymbol{\Sigma}$。

令 $\boldsymbol{X} = \boldsymbol{A}\boldsymbol{g}$，其中 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则 $\mathrm{E}[\boldsymbol{A}\boldsymbol{g}(\boldsymbol{A}\boldsymbol{g})^\top] = \boldsymbol{A}\mathrm{E}[\boldsymbol{g}\boldsymbol{g}^\top]\boldsymbol{A}^\top = \boldsymbol{A}\boldsymbol{I}_n\boldsymbol{A}^\top = \boldsymbol{\Sigma}$，因此 $\boldsymbol{X} \overset{d}{=} \boldsymbol{A}\boldsymbol{g}$，即

$$X_i = \sum_{k=1}^n A_{ik} g_k。$$

考虑第 i 个分量的期望，

$$\mathrm{E}[X_i f(\boldsymbol{X})] = \mathrm{E}\left[\left(\sum_{k=1}^n A_{ik} g_k\right) f(\boldsymbol{A}\boldsymbol{g})\right] = \sum_{k=1}^n A_{ik} \mathrm{E}[g_k f(\boldsymbol{A}\boldsymbol{g})], \tag{I}$$

之后只需计算 $\mathrm{E}[g_k f(\boldsymbol{A}\boldsymbol{g})]$。

根据一元 Stein 引理，可得

$$\mathrm{E}[g_k f(\boldsymbol{A}\boldsymbol{g})] = \mathrm{E}\left[\frac{\partial}{\partial g_k} f(\boldsymbol{A}\boldsymbol{g})\right],$$

其中

$$\begin{aligned}
\frac{\partial}{\partial g_k} f(\boldsymbol{A}\boldsymbol{g}) &= \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\boldsymbol{A}\boldsymbol{g}) \cdot \frac{\partial (\boldsymbol{A}\boldsymbol{g})_j}{\partial g_k} \\
&= \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\boldsymbol{A}\boldsymbol{g}) \cdot \frac{\partial \boldsymbol{X}_j}{\partial g_k} \\
&= \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\boldsymbol{A}\boldsymbol{g}) \cdot \frac{\partial \sum_{l=1}^n A_{jl} g_l}{\partial g_k} \\
&= \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\boldsymbol{X}) \cdot A_{jk},
\end{aligned}$$

将其代入，可得

$$\mathrm{E}[g_k f(\boldsymbol{A}\boldsymbol{g})] = \mathrm{E}\left[\sum_{j=1}^n A_{jk} \frac{\partial f}{\partial x_j}(\boldsymbol{X})\right], \tag{II}$$

将其代入于 (I)，可得

$$\begin{aligned}
\mathrm{E}[X_i f(\boldsymbol{X})] &= \sum_{k=1}^n A_{ik} \left(\sum_{j=1}^n A_{jk} \mathrm{E}\left[\frac{\partial f}{\partial x_j}(\boldsymbol{X})\right]\right) \\
&= \sum_{j=1}^n \left(\sum_{k=1}^n A_{ik} A_{jk}\right) \mathrm{E}\left[\frac{\partial f}{\partial x_j}(\boldsymbol{X})\right]
\end{aligned}$$

$$= \sum_{j=1}^{n} \Sigma_{ij} \mathrm{E}\left[\frac{\partial f}{\partial x_j}(\boldsymbol{X})\right] \qquad \left(\sum_{k=1}^{n} A_{ik}A_{jk} = \Sigma_{ij}\right)$$
$$= \boldsymbol{\Sigma} \cdot \mathrm{E}[\nabla f(\boldsymbol{X})]。$$

7 [**期望对数配分函数的求导**] 于证明 Sudakov-Fernique 定理 (定理 T7.2.8 (Sudakov–Fernique 不等式)) 的过程，之后只需证明一个关键步骤：对于插值 Gaussian 过程 $\boldsymbol{Z}(u) = \sqrt{u}\boldsymbol{X} + \sqrt{1-u}\boldsymbol{Y}$ (其中 $u \in [0,1]$)，对数配分函数

$$f(\boldsymbol{x}) = \frac{1}{\beta} \ln \sum_{i=1}^{n} \mathrm{e}^{\beta x_i},$$

满足单调性

$$\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f(\boldsymbol{Z}(u))] \leqslant 0。$$

(前提假设为 $\boldsymbol{X}, \boldsymbol{Y}$ 为相互独立的零均值多元 Gaussian 向量，满足 $\mathrm{E}[(X_i - X_j)^2] \leqslant \mathrm{E}[(Y_i - Y_j)^2]$。)

按以下步骤，证明以上结论：

(1) 对函数 f 求导，证明：

$$\frac{\partial f}{\partial x_i} = \frac{\mathrm{e}^{\beta x_i}}{\sum_k \mathrm{e}^{\beta x_k}} = p_i(\boldsymbol{x}), \quad \frac{\partial^2 f}{\partial x_i \partial x_j} = \beta(\delta_{ij} p_i(\boldsymbol{x}) - p_i(\boldsymbol{x}) p_j(\boldsymbol{x})),$$

其中 δ_{ij} 为 Kronecker δ 符号。

(2) 根据引理 L7.2.5 (Gaussian 插值)，化简表达式为

$$\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f(\boldsymbol{Z}(u))] = \frac{\beta}{4} \sum_{i \neq j} (\mathrm{E}[(X_i - X_j)^2] - \mathrm{E}[(Y_i - Y_j)^2]) \mathrm{E}[p_i(\boldsymbol{Z}(u)) p_j(\boldsymbol{Z}(u))]。$$

(3) 说明根据题设条件，上述表达式是非正的。

证明 (1) 令配分函数 $S(\boldsymbol{x}) = \sum_{k=1}^{n} \mathrm{e}^{\beta x_k}$，则 $f(\boldsymbol{x}) = \frac{1}{\beta} \ln S(\boldsymbol{x})$。

一阶偏导数为

$$\frac{\partial f}{\partial x_i} = \frac{1}{\beta} \cdot \frac{1}{S(\boldsymbol{x})} \cdot \frac{\partial S}{\partial x_i} = \frac{1}{\beta} \frac{1}{S(\boldsymbol{x})} (\beta \mathrm{e}^{\beta x_i}) = \frac{\mathrm{e}^{\beta x_i}}{\sum_{k=1}^{n} \mathrm{e}^{\beta x_k}} = p_i(\boldsymbol{x}),$$

注意到 $p_i(\boldsymbol{x})$ 满足 $p_i(\boldsymbol{x}) > 0$，$\sum_{k=1}^{n} p_k(\boldsymbol{x}) = 1$，因此其构成概率分布 (即 Softmax 函数)。

对二阶偏导数的情况讨论：

a. 当 $i = j$ 时，

$$\frac{\partial p_i}{\partial x_i} = \frac{(\beta \mathrm{e}^{\beta x_i}) S(\boldsymbol{x}) - \mathrm{e}^{\beta x_i} (\beta \mathrm{e}^{\beta x_i})}{[S(\boldsymbol{x})]^2} = \beta \left(\frac{\mathrm{e}^{\beta x_i}}{S(\boldsymbol{x})} - \left(\frac{\mathrm{e}^{\beta x_i}}{S(\boldsymbol{x})} \right)^2 \right) = \beta(p_i - p_i^2)。$$

b. 当 $i \neq j$ 时，

$$\frac{\partial p_i}{\partial x_j} = \frac{0 \cdot S(\boldsymbol{x}) - \mathrm{e}^{\beta x_i} (\beta \mathrm{e}^{\beta x_j})}{[S(\boldsymbol{x})]^2} = -\beta \left(\frac{\mathrm{e}^{\beta x_i}}{S(\boldsymbol{x})} \right) \left(\frac{\mathrm{e}^{\beta x_j}}{S(\boldsymbol{x})} \right) = -\beta p_i p_j。$$

如此，

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \beta(\delta_{ij} p_i(\boldsymbol{x}) - p_i(\boldsymbol{x}) p_j(\boldsymbol{x}))。 \tag{I}$$

(2) 根据引理 L7.2.5 (Gaussian 插值)，可得对于相互独立的零均值 Gaussian 向量 $\boldsymbol{X}, \boldsymbol{Y}$，过程 $\boldsymbol{Z}(u) = \sqrt{u}\boldsymbol{X} + \sqrt{1-u}\boldsymbol{Y}$ 满足

$$\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f(\boldsymbol{Z}(u))] = \frac{1}{2} \sum_{i,j=1}^{n} (\mathrm{E}[X_i X_j] - \mathrm{E}[Y_i Y_j]) \mathrm{E}\left[\frac{\partial^2 f}{\partial x_i \partial x_j}(\boldsymbol{Z}(u))\right],$$

为了书写简洁，令 $C_{ij} = \mathrm{E}[X_iX_j] - \mathrm{E}[Y_iY_j]$，省略期望内部变量 $\boldsymbol{Z}(u)$，利用 (1) 的结论，可得

$$\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f] = \frac{1}{2}\sum_{i,j=1}^{n} C_{ij}\mathrm{E}[\beta(\delta_{ij}p_i - p_ip_j)] = \frac{\beta}{2}\mathrm{E}\left[\sum_{i,j=1}^{n} C_{ij}(\delta_{ij}p_i - p_ip_j)\right]。 \tag{II}$$

对于内部的求和项，将其拆分为对角线 ($i=j$), 非对角线 ($i\neq j$)，

$$\sum_{i,j=1}^{n} C_{ij}(\delta_{ij}p_i - p_ip_j) = \sum_{i=1}^{n} C_{ii}(p_i - p_i^2) - \sum_{i\neq j} C_{ij}p_ip_j。$$

其中

$$p_i - p_i^2 = p_i(1-p_i) = p_i\sum_{j\neq i} p_j = \sum_{j\neq i} p_ip_j,$$

将其代入，可得

$$\begin{aligned}
\sum_{i,j=1}^{n} C_{ij}(\delta_{ij}p_i - p_ip_j) &= \sum_{i=1}^{n} C_{ii}\left(\sum_{j\neq i} p_ip_j\right) - \sum_{i\neq j} C_{ij}p_ip_j \\
&= \sum_{i\neq j} C_{ii}p_ip_j - \sum_{i\neq j} C_{ij}p_ip_j \\
&= \sum_{i\neq j}\frac{1}{2}(C_{ii}+C_{jj})p_ip_j - \sum_{i\neq j} C_{ij}p_ip_j \\
&= \frac{1}{2}\sum_{i\neq j}(C_{ii}+C_{jj}-2C_{ij})p_ip_j,
\end{aligned}$$

其中

$$\begin{aligned}
C_{ii}+C_{jj}-2C_{ij} &= (\mathrm{E}[X_i^2]-\mathrm{E}[Y_i^2]) + (\mathrm{E}[X_j^2]-\mathrm{E}[Y_j^2]) - 2(\mathrm{E}[X_iX_j]-\mathrm{E}[Y_iY_j]) \\
&= (\mathrm{E}[X_i^2] - 2\mathrm{E}[X_iX_j] + \mathrm{E}[X_j^2]) - (\mathrm{E}[Y_i^2] - 2\mathrm{E}[Y_iY_j] + \mathrm{E}[Y_j^2]) \\
&= \mathrm{E}[(X_i-X_j)^2] - \mathrm{E}[(Y_i-Y_j)^2],
\end{aligned}$$

将其代入于 (II)，可得

$$\begin{aligned}
\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f] &= \frac{\beta}{2}\mathrm{E}\left[\frac{1}{2}\sum_{i\neq j}(\mathrm{E}[(X_i-X_j)^2] - \mathrm{E}[(Y_i-Y_j)^2])p_ip_j\right] \\
&= \frac{\beta}{4}\sum_{i\neq j}(\mathrm{E}[(X_i-X_j)^2] - \mathrm{E}[(Y_i-Y_j)^2])\mathrm{E}[p_i(\boldsymbol{Z}(u))p_j(\boldsymbol{Z}(u))]。
\end{aligned}$$

(3) 根据 Sudakov-Fernique 定理的假设条件，随机过程的增量二阶矩满足 $\mathrm{E}[(X_i-X_j)^2] \leqslant \mathrm{E}[(Y_i-Y_j)^2]$，因此

$$\mathrm{E}[(X_i-X_j)^2] - \mathrm{E}[(Y_i-Y_j)^2] \leqslant 0。$$

由于 $p_i(\boldsymbol{x}), p_j(\boldsymbol{x}) > 0$，因此

$$\mathrm{E}[p_i(\boldsymbol{Z}(u))p_j(\boldsymbol{Z}(u))] > 0。$$

如此，

$$\frac{\mathrm{d}}{\mathrm{d}u}\mathrm{E}[f(\boldsymbol{Z}(u))] \leqslant 0。$$

8 [**Gaussian 收缩不等式**] 本题是练习 Q7.3 (Talagrand 收缩原理) 中 Talagrand 收缩原理的 Gaussian 版本。

设 $\mathbb{T}\subset\mathbb{R}^n$，$g_1,\cdots,g_n$ i.i.d. $\sim N(0,1)$，$\varphi_i:\mathbb{R}\to\mathbb{R}$ 为收缩映射，即满足 $\|\varphi_i\|_{\mathrm{Lip}} \leqslant 1$。利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，证明：

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}\sum_{i=1}^{n} g_i\varphi_i(t_i)\right] \leqslant \mathrm{E}\left[\sup_{t\in\mathbb{T}}\sum_{i=1}^{n} g_it_i\right]。$$

证明 对于任意的 $\boldsymbol{t}=(t_1,\cdots,t_n)\in\mathbb{T}$，定义随机过程 $(X_t)_{t\in\mathbb{T}},(Y_t)_{t\in\mathbb{T}}$ 为

$$X_t=\sum_{i=1}^n g_i\varphi_i(t_i),\quad Y_t=\sum_{i=1}^n g_i t_i,$$

则 $(X_t),(Y_t)$ 均为零均值 Gaussian 过程。

利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，可得对于任意的 t,s，

$$\mathrm{E}[(X_t-X_s)^2]\leqslant\mathrm{E}[(Y_t-Y_s)^2],$$

因此

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant\mathrm{E}\left[\sup_{t\in\mathbb{T}}Y_t\right],$$

我们只需证明 Sudakov-Fernique 条件成立即可。

对于 $\mathrm{E}[(X_t-X_s)^2],\mathrm{E}[(Y_t-Y_s)^2]$，代入 $\mathrm{Cov}(g_i,g_j)=0\ (i\neq j)$，$\mathrm{Var}(g_i)=1$，可得

$$\mathrm{E}[(X_t-X_s)^2]=\mathrm{E}\left[\left(\sum_{i=1}^n g_i(\varphi_i(t_i)-\varphi_i(s_i))\right)^2\right]=\sum_{i=1}^n(\varphi_i(t_i)-\varphi_i(s_i))^2,$$

$$\mathrm{E}[(Y_t-Y_s)^2]=\mathrm{E}\left[\left(\sum_{i=1}^n g_i(t_i-s_i)\right)^2\right]=\sum_{i=1}^n(t_i-s_i)^2,$$

由于 φ_i 为收缩映射，因此

$$(\varphi_i(t_i)-\varphi_i(s_i))^2\leqslant(t_i-s_i)^2,$$

两侧求和，

$$\sum_{i=1}^n(\varphi_i(t_i)-\varphi_i(s_i))^2\leqslant\sum_{i=1}^n(t_i-s_i)^2,$$

即为 Sudakov-Fernique 条件，

$$\mathrm{E}[(X_t-X_s)^2]\leqslant\mathrm{E}[(Y_t-Y_s)^2]。$$

注释 从物理意义而言，若通过收缩映射对参数空间 $\mathbb{T}$ 进行压缩，则此空间的 Gaussian 复杂性不会增加。

与 Talagrand 映射不同，Talagrand 收缩原理适用于 Rademacher 随机变量，但是此版本专门针对 Gaussian 随机变量。由于 Gaussian 分布的旋转不变性，利用 Sudakov-Fernique 不等式证明 Gaussian 版本往往比证明 Rademacher 版本更为直接。

9 [**Gordon 不等式**] 于附加的等方差假设 (对于任意的 u,t，均满足 $\mathrm{E}[X_{ut}^2]=\mathrm{E}[Y_{ut}^2]$)，证明定理 T7.2.9 (Gordon 不等式)。

Gordon 不等式 设 $(X_{ut}),(Y_{ut})$ 为由有限指标对 (u,t) 索引的零均值 Gaussian 过程，其中 $u\in\mathbb{U}$，$t\in\mathbb{T}$，满足：

i. 同组内增量较小：对于任意的 $u\in\mathbb{U}$，t,s，

$$\mathrm{E}[(X_{ut}-X_{us})^2]\leqslant\mathrm{E}[(Y_{ut}-Y_{us})^2];$$

ii. 跨组间增量较大：对于任意的 $u\neq v$，t,s，

$$\mathrm{E}[(X_{ut}-X_{vs})^2]\geqslant\mathrm{E}[(Y_{ut}-Y_{vs})^2];$$

则

$$\mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}X_{ut}\right]\leqslant\mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}Y_{ut}\right]。$$

(正如 Sudakov-Fernique 不等式，Gordon 不等式的等方差假设实际上是可以忽略的，但本题不要求证明忽略假设之后的情形。)

解答 记增量二阶矩的差值为

$$\Delta_{ut,vs}=\mathrm{E}[(X_{ut}-X_{vs})^2]-\mathrm{E}[(Y_{ut}-Y_{vs})^2],$$

则

$$\Delta_{ut,us}\begin{cases}\leqslant 0 & u=v\\ \geqslant 0 & u\neq v\end{cases},$$

此时于等方差假设，协方差的差值 $C_{ut,vs}=\mathrm{E}[X_{ut}X_{vs}]-\mathrm{E}[Y_{ut}Y_{vs}]$ 可以表示为

$$C_{ut,vs}=-\frac{1}{2}\Delta_{ut,vs}。$$

- 构造平滑逼近函数

  (为了逼近 $\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}x_{ut}$，之后只需对其构造平滑逼近函数。)

  引入参数 $\beta,\gamma>0$，构造嵌套的对数配分函数为

$$f(\boldsymbol{x})=-\frac{1}{\beta}\ln\sum_{u\in\mathbb{U}}\exp\left(-\frac{\beta}{\gamma}\ln\sum_{t\in\mathbb{T}}\mathrm{e}^{\gamma x_{ut}}\right),$$

  则当 $\gamma\to\infty$ 时，内部趋于 $\max_{t\in\mathbb{T}}x_{ut}$；之后当 $\beta\to\infty$ 时，外部趋于 $\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}x_{ut}$。

  之后定义相关的 Softmax 权重为

$$\left(\text{组内权重，满足}\sum_{t\in\mathbb{T}}p_{ut}=1\right)\quad p_{ut}=\frac{\mathrm{e}^{\gamma x_{ut}}}{\sum_{s\in\mathbb{T}}\mathrm{e}^{\gamma x_{us}}},$$

$$\left(\text{组间权重，满足}\sum_{u\in\mathbb{U}}q_{u}=1\right)\quad q_{u}=\frac{\left(\sum_{s\in\mathbb{T}}\mathrm{e}^{\gamma x_{us}}\right)^{-\beta/\gamma}}{\sum_{v}\left(\sum_{s\in\mathbb{T}}\mathrm{e}^{\gamma x_{vs}}\right)^{-\beta/\gamma}},$$

  令全局权重 $w_{ut}=q_up_{ut}$，则 $\sum_{u\in\mathbb{U},t\in\mathbb{T}}w_{ut}=1$。

- 计算偏导数

  (过程与练习 Q7.7 (期望对数配分函数的求导) 类似。)

  一阶偏导数为

$$\frac{\partial f}{\partial x_{ut}}=q_up_{ut}=w_{ut}。$$

  对二阶偏导数讨论：

  a. 若 $u\neq v$，则跨组求导，

$$\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}}=\beta q_up_{ut}q_vp_{vs}=\beta w_{ut}w_{vs}。$$

  b. 若 $u=v$，则组内求导，

$$\frac{\partial^2 f}{\partial x_{ut}\partial x_{us}}=\gamma q_u(\delta_{ts}p_{ut}-p_{ut}p_{us})-\beta q_u(1-q_u)p_{ut}p_{us}。$$

- 根据 Gaussian 插值

  设插值过程 $\boldsymbol{Z}(r)=\sqrt{r}\boldsymbol{X}+\sqrt{1-r}\boldsymbol{Y}$，其中 $r\in[0,1]$，则根据 Gaussian 插值引理，可得

$$\frac{\mathrm{d}}{\mathrm{d}r}\mathrm{E}[f(\boldsymbol{Z}(r))]=\frac{1}{2}\sum_{u,t}\sum_{v,s}C_{ut,vs}\mathrm{E}\left[\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}}\right],$$

  将内部求和拆分为

$$\Sigma=\Sigma_{u\neq v}+\Sigma_{u=v}。$$

  对于组间部分 $\Sigma_{u\neq v}$，

$$\Sigma_{u\neq v}=\sum_{u\neq v}\sum_{t,s}\left(-\frac{1}{2}\Delta_{ut,vs}\right)(\beta w_{ut}w_{vs})=-\frac{\beta}{2}\sum_{u\neq v,t,s}\Delta_{ut,vs}w_{ut}w_{vs}\leqslant 0。$$

对于组内部分 $\Sigma_{u=v}$，

$$\Sigma_{u=v}=\sum_u\sum_{t,s}C_{ut,us}[\gamma q_u(\delta_{ts}p_{ut}-p_{ut}p_{us})-\beta q_u(1-q_u)p_{ut}p_{us}],$$

对于第一项，代入练习 Q7.7 (期望对数配分函数的求导) 的对称化恒等式

$$\sum_{t,s}C_{ts}(\delta_{ts}p_t-p_tp_s)=\frac{1}{2}\sum_{t,s}(C_{tt}+C_{ss}-2C_{ts})p_tp_s=\frac{1}{2}\sum_{t,s}\Delta_{ts}p_tp_s,$$

对于第二项，直接代入 $C_{ut,us}=-\frac{1}{2}\Delta_{ut,us}$，可得

$$\begin{aligned}\Sigma_{u=v}&=\gamma\sum_u q_u\left(\frac{1}{2}\sum_{t,s}\Delta_{ut,us}p_{ut}p_{us}\right)-\beta\sum_u q_u(1-q_u)\sum_{t,s}\left(-\frac{1}{2}\Delta_{ut,us}\right)p_{ut}p_{us}\\&=\sum_u\left[\frac{\gamma}{2}q_u+\frac{\beta}{2}q_u(1-q_u)\right]\sum_{t,s}\Delta_{ut,us}p_{ut}p_{us}\leqslant 0。\end{aligned}$$

如此，

$$\frac{\mathrm{d}}{\mathrm{d}r}\mathrm{E}[f(\boldsymbol{Z}(r))]=\frac{1}{2}\mathrm{E}[\Sigma_{u\neq v}+\Sigma_{u=v}]\leqslant 0,$$

可得随着 r 从 0 增加到 1，过程从 $\boldsymbol{Y}$ 平滑过渡到 $\boldsymbol{X}$，期望的平滑逼近函数是单调递减的，因此

$$\mathrm{E}[f(\boldsymbol{X})]\leqslant\mathrm{E}[f(\boldsymbol{Y})],$$

令 $\gamma,\beta\to\infty$，

$$\mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}X_{ut}\right]\leqslant\mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}}Y_{ut}\right]。$$

注释 忽略等方差假设的完整证明过程：

额外定义单点方差之差为

$$V_{ut}=\mathrm{E}[X_{ut}^2]-\mathrm{E}[Y_{ut}^2],$$

则

$$C_{ut,vs}=\frac{1}{2}(V_{ut}+V_{vs}-\Delta_{ut,vs})。$$

(平滑逼近函数的构造过程与之前相同，在此省略。)

定义插值过程 $\boldsymbol{Z}(r)=\sqrt{r}\boldsymbol{X}+\sqrt{1-r}\boldsymbol{Y}$，其中 $r\in[0,1]$，则根据 Gaussian 插值引理，可得

$$\frac{\mathrm{d}}{\mathrm{d}r}\mathrm{E}[f(\boldsymbol{Z}(r))]=\frac{1}{2}\sum_{u,t}\sum_{v,s}C_{ut,vs}\mathrm{E}\left[\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}}\right]。$$

将期望内部拆分为包含 V 的部分 S_V, 包含 Δ 的部分 S_Δ，其表达式为

$$S_V=\frac{1}{4}\sum_{u,t}\sum_{v,s}(V_{ut}+V_{vs})\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}},$$

$$\begin{aligned}S_\Delta=&-\frac{1}{4}\sum_{u\neq v}\sum_{t,s}\Delta_{ut,vs}\beta w_{ut}w_{vs}\\&-\frac{1}{4}\sum_u\sum_{t,s}\Delta_{ut,us}(\gamma q_u(\delta_{ts}p_{ut}-p_{ut}p_{us})-\beta q_u(1-q_u)p_{ut}p_{us})。\end{aligned}$$

- 计算 S_V

对于 S_V，注意到 $(u,t),(v,s)$ 满足对称性

$$\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}}=\frac{\partial^2 f}{\partial x_{vs}\partial x_{ut}},$$

因此

$$S_V = \frac{1}{2}\sum_{u,t} V_{ut}\left(\sum_{v,s}\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}}\right)。$$

将内层的二阶导数求和拆分为 $v \neq u, v = u$，

$$\begin{aligned}\sum_{v,s}\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}} &= \sum_{v\neq u}\sum_{s}\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}} + \sum_{s}\frac{\partial^2 f}{\partial x_{ut}\partial x_{us}} \\ &= \sum_{v\neq u}\sum_{s\in\mathbb{T}}\beta w_{ut}w_{vs} + \sum_{s\in\mathbb{T}}(\gamma q_u(\delta_{ts}p_{ut} - p_{ut}p_{us}) - \beta q_u(1-q_u)p_{ut}p_{us}),\end{aligned}$$

其中

$$\sum_{v\neq u}\sum_{s}\beta w_{ut}q_v p_{vs} = \beta w_{ut}\sum_{v\neq u} q_v\left(\sum_s p_{vs}\right) = \beta w_{ut}\sum_{v\neq u} q_v = \beta w_{ut}(1-q_u),$$

$$\sum_{s}\gamma q_u(\delta_{ts}p_{ut} - p_{ut}p_{us}) = \gamma q_u\left(\sum_s \delta_{ts}p_{ut} - p_{ut}\sum_s p_{us}\right) = \gamma q_u(p_{ut}\cdot 1 - p_{ut}\cdot 1) = 0,$$

$$\sum_{s} -\beta q_u(1-q_u)p_{ut}p_{us} = -\beta q_u(1-q_u)p_{ut}\left(\sum_s p_{us}\right) = -\beta q_u p_{ut}(1-q_u) = -\beta w_{ut}(1-q_u),$$

将其代入，可得

$$\sum_{v,s}\frac{\partial^2 f}{\partial x_{ut}\partial x_{vs}} = \beta w_{ut}(1-q_u) + 0 - \beta w_{ut}(1-q_u) \equiv 0,$$

上述求和为零，因此方差差异的影响在偏导数求和后抵消。

- 计算 S_Δ

将 S_Δ 的求和拆分为 $v \neq u$，$v = u$，

$$\begin{aligned}S_\Delta = &-\frac{1}{4}\sum_{u\neq v}\sum_{t,s}\Delta_{ut,vs}\beta w_{ut}w_{vs} \\ &-\frac{1}{4}\sum_{u}\sum_{t,s}\Delta_{ut,us}(\gamma q_u(\delta_{ts}p_{ut} - p_{ut}p_{us}) - \beta q_u(1-q_u)p_{ut}p_{us})。\end{aligned}$$

对于组间项 $(u \neq v)$，容易知道，

$$-\frac{1}{4}\sum_{u\neq v}\sum_{t,s}\Delta_{ut,vs}(\beta w_{ut}w_{vs}) \leqslant 0。$$

对于组内项 $(u = v)$，利用恒等式 $\sum_{t,s}\Delta_{ut,us}\delta_{ts}p_{ut} = \sum_t \Delta_{ut,ut}p_{ut} = 0$，可得

$$-\frac{1}{4}\sum_{u}\sum_{t,s}\Delta_{ut,us}(\gamma q_u(\delta_{ts}p_{ut} - p_{ut}p_{us}) - \beta q_u(1-q_u)p_{ut}p_{us}) = \sum_u\left(\frac{\gamma}{4}q_u + \frac{\beta}{4}q_u(1-q_u)\right)\sum_{t,s}\Delta_{ut,us}p_{ut}p_{us} \leqslant 0。$$

如此，$S_\Delta \leqslant 0$。

如此，

$$\frac{\mathrm{d}}{\mathrm{d}r}\mathrm{E}[f(\boldsymbol{Z}(r))] \leqslant 0,$$

从而

$$\mathrm{E}[f(\boldsymbol{X})] \leqslant \mathrm{E}[f(\boldsymbol{Y})],$$

令 $\gamma, \beta \to \infty$，

$$\mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}} X_{ut}\right] \leqslant \mathrm{E}\left[\min_{u\in\mathbb{U}}\max_{t\in\mathbb{T}} Y_{ut}\right]。$$

10 [**秩一矩阵间的 Frobenius 距离**] 关于定理 T7.3.1 (Gaussian 随机矩阵的范数) 的证明，我们利用了以下界限。

设 $\boldsymbol{u},\boldsymbol{w}\in\mathbb{S}^{n-1}$，$\boldsymbol{v},\boldsymbol{z}\in\mathbb{S}^{m-1}$。证明：

$$\|\boldsymbol{u}\boldsymbol{v}^\top-\boldsymbol{w}\boldsymbol{z}^\top\|_F^2\leqslant\|\boldsymbol{u}-\boldsymbol{w}\|_2^2+\|\boldsymbol{v}-\boldsymbol{z}\|_2^2。$$

注释 对于秩一矩阵 $\boldsymbol{a}\boldsymbol{b}^\top,\boldsymbol{c}\boldsymbol{d}^\top$，其 Frobenius 内积满足

$$\langle\boldsymbol{a}\boldsymbol{b}^\top,\boldsymbol{c}\boldsymbol{d}^\top\rangle_F=\operatorname{tr}((\boldsymbol{a}\boldsymbol{b}^\top)^\top(\boldsymbol{c}\boldsymbol{d}^\top))=\operatorname{tr}(\boldsymbol{b}\boldsymbol{a}^\top\boldsymbol{c}\boldsymbol{d}^\top)=(\boldsymbol{a}^\top\boldsymbol{c})(\boldsymbol{b}^\top\boldsymbol{d})。$$

证明 对于左侧，

$$\begin{aligned}\text{LHS}&=\|\boldsymbol{u}\boldsymbol{v}^\top-\boldsymbol{w}\boldsymbol{z}^\top\|_F^2\\&=\|\boldsymbol{u}\boldsymbol{v}^\top\|_F^2+\|\boldsymbol{w}\boldsymbol{z}^\top\|_F^2-2\langle\boldsymbol{u}\boldsymbol{v}^\top,\boldsymbol{w}\boldsymbol{z}^\top\rangle_F\\&=(\boldsymbol{u}^\top\boldsymbol{u})(\boldsymbol{v}^\top\boldsymbol{v})+(\boldsymbol{w}^\top\boldsymbol{w})(\boldsymbol{z}^\top\boldsymbol{z})-2(\boldsymbol{u}^\top\boldsymbol{w})(\boldsymbol{v}^\top\boldsymbol{z})\\&=1\cdot1+1\cdot1-2(\boldsymbol{u}^\top\boldsymbol{w})(\boldsymbol{v}^\top\boldsymbol{z})=2-2(\boldsymbol{u}^\top\boldsymbol{w})(\boldsymbol{v}^\top\boldsymbol{z})。\end{aligned}$$

对于右侧，

$$\begin{aligned}\text{RHS}&=\|\boldsymbol{u}-\boldsymbol{w}\|_2^2+\|\boldsymbol{v}-\boldsymbol{z}\|_2^2\\&=(\|\boldsymbol{u}\|_2^2+\|\boldsymbol{w}\|_2^2-2\boldsymbol{u}^\top\boldsymbol{w})+(\|\boldsymbol{v}\|_2^2+\|\boldsymbol{z}\|_2^2-2\boldsymbol{v}^\top\boldsymbol{z})\\&=(1+1-2\boldsymbol{u}^\top\boldsymbol{w})+(1+1-2\boldsymbol{v}^\top\boldsymbol{z})=4-2\boldsymbol{u}^\top\boldsymbol{w}-2\boldsymbol{v}^\top\boldsymbol{z}。\end{aligned}$$

要证明 LHS $\leqslant$ RHS，只需证明

$$\begin{aligned}2-2(\boldsymbol{u}^\top\boldsymbol{w})(\boldsymbol{v}^\top\boldsymbol{z})&\leqslant4-2\boldsymbol{u}^\top\boldsymbol{w}-2\boldsymbol{v}^\top\boldsymbol{z}\\\text{RHS}-\text{LHS}=2(1-\boldsymbol{u}^\top\boldsymbol{w})(1-\boldsymbol{v}^\top\boldsymbol{z})&\geqslant0.\end{aligned}$$

由于

$$|\boldsymbol{u}^\top\boldsymbol{w}|\leqslant\|\boldsymbol{u}\|_2\|\boldsymbol{w}\|_2=1，\ |\boldsymbol{v}^\top\boldsymbol{z}|\leqslant\|\boldsymbol{v}\|_2\|\boldsymbol{z}\|_2=1，$$

因此

$$(1-\boldsymbol{u}^\top\boldsymbol{w})(1-\boldsymbol{v}^\top\boldsymbol{z})\geqslant0。$$

11 [**GOE 随机矩阵的范数**] 将 7.3 节的证明方法利用于对称矩阵的情形。

设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$ 为 Gaussian 随机矩阵，其主对角线，对角线以上的元素是相互独立的，满足

$$A_{ij}\sim\begin{cases}N(0,2),i=j,\\N(0,1),i<j\end{cases}。$$

(此恰好为练习 Q3.19 (GOE 随机矩阵) 的 Gaussian 正交系综。)

(1) (期望界限) 利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，证明：

$$\mathrm{E}\|\boldsymbol{A}\|\leqslant2\sqrt{n}。$$

(2) (高概率界限) 利用集中不等式，将 (1) 的期望界限提升为高概率界限。证明：对于任意的 $t\geqslant0$，

$$\mathrm{P}\{\|\boldsymbol{A}\|\geqslant2\sqrt{n}+t\}\leqslant2\exp(-ct^2)。\qquad(c>0)$$

证明 (1) 由于 $\boldsymbol{A}$ 为实对称矩阵，因此

$$\|\boldsymbol{A}\|=\sup_{\boldsymbol{u}\in\mathbb{S}^{n-1}}|\langle\boldsymbol{A}\boldsymbol{u},\boldsymbol{u}\rangle|。$$

(为了去掉绝对值符号以便于根据 Gaussian 过程的工具，考虑引入符号变量。)

引入符号变量 $\sigma\in\{-1,1\}$，定义扩充指标集 $\mathbb{T}=\{(\boldsymbol{u},\sigma):\boldsymbol{u}\in\mathbb{S}^{n-1},\sigma\in\{-1,1\}\}$，构造定义于 $\mathbb{T}$ 的零均值 Gaussian 过程 $(X_{\boldsymbol{u},\sigma})$ 为

$$X_{\boldsymbol{u},\sigma}=\sigma\langle\boldsymbol{A}\boldsymbol{u},\boldsymbol{u}\rangle=\sigma\sum_{i,j=1}^{n}A_{ij}u_iu_j,$$

则 $\sup_{(\boldsymbol{u},\sigma)\in\mathbb{T}}X_{\boldsymbol{u},\sigma}=\|\boldsymbol{A}\|$。

• 计算 $(X_{\boldsymbol{u},\sigma})$ 的增量二阶矩

设 $(\boldsymbol{u},\sigma),(\boldsymbol{w},\tau)\in\mathbb{T}$，令对称矩阵 $\boldsymbol{M}=\sigma\boldsymbol{u}\boldsymbol{u}^\top-\tau\boldsymbol{w}\boldsymbol{w}^\top$，则增量可以表示为

$$X_{\boldsymbol{u},\sigma}-X_{\boldsymbol{w},\tau}=\sum_{i,j=1}^{n}A_{ij}M_{ij},$$

根据 $\boldsymbol{A}$ 的对称性，将求和进行拆分，

$$\sum_{i,j=1}^{n}A_{ij}M_{ij}=\sum_{i=1}^{n}A_{ii}M_{ii}+2\sum_{i<j}A_{ij}M_{ij},$$

计算二阶矩，代入 $\mathrm{Var}(A_{ii})=2,\mathrm{Var}(A_{ij})=1$，可得

$$\begin{aligned}\mathrm{E}[(X_{\boldsymbol{u},\sigma}-X_{\boldsymbol{w},\tau})^2]&=\sum_{i=1}^{n}\mathrm{Var}(A_{ii})M_{ii}^2+4\sum_{i<j}\mathrm{Var}(A_{ij})M_{ij}^2\\&=2\sum_{i=1}^{n}M_{ii}^2+4\sum_{i<j}M_{ij}^2\\&=2\left(\sum_{i=1}^{n}M_{ii}^2+2\sum_{i<j}M_{ij}^2\right)\\&=2\|\boldsymbol{M}\|_F^2,\end{aligned}$$

我们只需计算 $2\|\boldsymbol{M}\|_F^2$。

计算 $2\|\boldsymbol{M}\|_F^2$，代入 $\|\boldsymbol{u}\|_2=\|\boldsymbol{w}\|_2=1$，$\sigma^2=\tau^2=1$，可得

$$\begin{aligned}2\|\boldsymbol{M}\|_F^2&=2(\sigma^2\|\boldsymbol{u}\boldsymbol{u}^\top\|_F^2+\tau^2\|\boldsymbol{w}\boldsymbol{w}^\top\|_F^2-2\sigma\tau\langle\boldsymbol{u}\boldsymbol{u}^\top,\boldsymbol{w}\boldsymbol{w}^\top\rangle_F)\\&=2(1+1-2\sigma\tau(\boldsymbol{u}^\top\boldsymbol{w})^2)\\&=4(1-\sigma\tau(\boldsymbol{u}^\top\boldsymbol{w})^2),\end{aligned}$$

令 $y=\sigma\tau(\boldsymbol{u}^\top\boldsymbol{w})\in[-1,1]$，则

$$4(1-y^2)=4(1-y)(1+y)\leqslant 8(1-y),$$

因此

$$\mathrm{E}[(X_{\boldsymbol{u},\sigma}-X_{\boldsymbol{w},\tau})^2]\leqslant 8(1-\sigma\tau\boldsymbol{u}^\top\boldsymbol{w})=4\|\sigma\boldsymbol{u}-\tau\boldsymbol{w}\|_2^2。$$

- 构造比较过程并根据 Sudakov-Fernique 不等式

(之后只需构造一个更简单的典范 Gaussian 过程 $(Y_{\boldsymbol{u},\sigma})$，使其增量恰好为 $4\|\sigma\boldsymbol{u}-\tau\boldsymbol{w}\|_2^2$。)

设 $\boldsymbol{g}\sim N(\boldsymbol{0},4\boldsymbol{I}_n)$，即 $\boldsymbol{g}=2\boldsymbol{h}$，其中 $\boldsymbol{h}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，定义过程 $Y_{\boldsymbol{u},\sigma}=\langle\boldsymbol{g},\sigma\boldsymbol{u}\rangle$，则其增量二阶矩为

$$\mathrm{E}[(Y_{\boldsymbol{u},\sigma}-Y_{\boldsymbol{w},\tau})^2]=\mathrm{E}[\langle\boldsymbol{g},\sigma\boldsymbol{u}-\tau\boldsymbol{w}\rangle^2]=4\|\sigma\boldsymbol{u}-\tau\boldsymbol{w}\|_2^2,$$

因此

$$\mathrm{E}[(X_{\boldsymbol{u},\sigma}-X_{\boldsymbol{w},\tau})^2]\leqslant\mathrm{E}[(Y_{\boldsymbol{u},\sigma}-Y_{\boldsymbol{w},\tau})^2],$$

即为 Sudakov-Fernique 条件。

利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，可得

$$\begin{aligned}\mathrm{E}\|\boldsymbol{A}\|&=\mathrm{E}\left[\sup_{(\boldsymbol{u},\sigma)\in\mathbb{T}}X_{\boldsymbol{u},\sigma}\right]\\&\leqslant\mathrm{E}\left[\sup_{(\boldsymbol{u},\sigma)\in\mathbb{T}}Y_{\boldsymbol{u},\sigma}\right]=\mathrm{E}\left[\sup_{\boldsymbol{u}\in\mathbb{S}^{n-1},\sigma\in\{-1,1\}}\sigma\langle 2\boldsymbol{h},\boldsymbol{u}\rangle\right]\\&=2\mathrm{E}\left[\sup_{\boldsymbol{u}\in\mathbb{S}^{n-1}}|\langle\boldsymbol{h},\boldsymbol{u}\rangle|\right]\\&=2\mathrm{E}\|\boldsymbol{h}\|_2。\end{aligned}$$

利用 Jensen 不等式，可得 $\mathrm{E}\|\boldsymbol{h}\|_2\leqslant(\mathrm{E}\|\boldsymbol{h}\|_2^2)^{1/2}=\sqrt{n}$，因此 $\mathrm{E}\|\boldsymbol{A}\|\leqslant 2\sqrt{n}$。

(2) (为了利用 Gaussian 集中不等式，我们将 $\boldsymbol{A}$ 视为定义于相互独立的标准正态分布向量的函数。)

GOE 矩阵含有 $m=n(n+1)/2$ 个独立元素，设 $\boldsymbol{x}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$，将 $\boldsymbol{A}$ 显式地参数化为 $\boldsymbol{x}$ 的函数 $\boldsymbol{A}(\boldsymbol{x})$，则

$$A_{ii}=\begin{cases}\sqrt{2}x_{ii}, & i=j,\\ x_{ij}, & i<j\end{cases}。$$

定义 $f(\boldsymbol{x})=\|\boldsymbol{A}(\boldsymbol{x})\|$，则对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^m$，

$$|f(\boldsymbol{x})-f(\boldsymbol{y})|=|\|\boldsymbol{A}(\boldsymbol{x})\|-\|\boldsymbol{A}(\boldsymbol{y})\||\leqslant\|\boldsymbol{A}(\boldsymbol{x})-\boldsymbol{A}(\boldsymbol{y})\|\leqslant\|\boldsymbol{A}(\boldsymbol{x})-\boldsymbol{A}(\boldsymbol{y})\|_F,$$

其中

$$\begin{aligned}\|\boldsymbol{A}(\boldsymbol{x})-\boldsymbol{A}(\boldsymbol{y})\|_F^2&=\sum_{i=1}^n(A_{ii}(\boldsymbol{x})-A_{ii}(\boldsymbol{y}))^2+2\sum_{i<j}(A_{ij}(\boldsymbol{x})-A_{ij}(\boldsymbol{y}))^2\\&=\sum_{i=1}^n(\sqrt{2}x_{ii}-\sqrt{2}y_{ii})^2+2\sum_{i<j}(x_{ij}-y_{ij})^2\\&=2\sum_{i=1}^n(x_{ii}-y_{ii})^2+2\sum_{i<j}(x_{ij}-y_{ij})^2\\&=2\|\boldsymbol{x}-\boldsymbol{y}\|_2^2,\end{aligned}$$

因此 $|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant\sqrt{2}\|\boldsymbol{x}-\boldsymbol{y}\|_2$，可得 $\|f\|_{\mathrm{Lip}}=\sqrt{2}$。

利用定理 T7.1.11 (Gaussian 过程的集中) (Gaussian 过程的集中)，可得

$$\mathrm{P}\{f(\boldsymbol{x})\geqslant\mathrm{E}[f(\boldsymbol{x})]+t\}\leqslant\exp\left(-\frac{t^2}{2L^2}\right),$$

即

$$\mathrm{P}\{\|\boldsymbol{A}\|\geqslant\mathrm{E}\|\boldsymbol{A}\|+t\}\leqslant\exp\left(-\frac{t^2}{4}\right),$$

利用 (1) 的结论，可得

$$\mathrm{P}\{\|\boldsymbol{A}\|\geqslant2\sqrt{n}+t\}\leqslant\mathrm{P}\{\|\boldsymbol{A}\|\geqslant\mathrm{E}\|\boldsymbol{A}\|+t\}\leqslant\exp\left(-\frac{t^2}{4}\right),$$

此时令 $c=1/4$。

12 [**Gaussian 向量的范数**] 设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。证明：

$$f(n)=\mathrm{E}\|\boldsymbol{g}\|_2-\sqrt{n}$$

当 $n\geqslant C$ 时是递增的，其中 $C>0$。

解答 我们只需证明存在 $C>0$，使得当 $n\geqslant C$ 时，$f(n+1)\geqslant f(n)$，即

$$\mathrm{E}\|\boldsymbol{g}_{n+1}\|_2-\mathrm{E}\|\boldsymbol{g}_n\|_2\geqslant\sqrt{n+1}-\sqrt{n},$$

令 $a_n=\mathrm{E}\|\boldsymbol{g}_n\|_2$，则证明目标即为

$$a_{n+1}-a_n\geqslant\sqrt{n+1}-\sqrt{n}。\tag{I}$$

- 进行代数变换

由于 $\|\boldsymbol{g}_n\|_2^2\sim\chi^2(n)$，因此

$$a_n=\sqrt{2}\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}。$$

由于

$$\begin{aligned}a_na_{n+1}&=\left(\sqrt{2}\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}\right)\left(\sqrt{2}\frac{\Gamma\left(\frac{n+2}{2}\right)}{\Gamma\left(\frac{n+1}{2}\right)}\right)=2\frac{\Gamma\left(\frac{n}{2}+1\right)}{\Gamma\left(\frac{n}{2}\right)}\\&=2\left(\frac{n}{2}\right)=n,\end{aligned}\qquad(\Gamma(x+1)=x\Gamma(x))$$

因此 (I) 即为

$$\frac{n}{a_n} - a_n \geqslant \sqrt{n+1} - \sqrt{n},$$

即为

$$n - a_n^2 \geqslant a_n(\sqrt{n+1} - \sqrt{n}) = \frac{a_n}{\sqrt{n+1}+\sqrt{n}}, \tag{II}$$

其中左侧 $n - a_n^2 = \mathrm{E}\|\boldsymbol{g}_n\|_2^2 - (\mathrm{E}\|\boldsymbol{g}_n\|_2)^2$ 恰好为 $\mathrm{Var}(\|\boldsymbol{g}_n\|_2)$。

- 利用渐近展开计算两侧

根据 Stirling 公式，可得当 $z \to \infty$ 时，

$$\frac{\Gamma(z+\alpha)}{\Gamma(z)} = z^\alpha\left(1 + \frac{\alpha(\alpha-1)}{2z} + \frac{\alpha(\alpha-1)(\alpha-2)(3\alpha-1)}{24z^2} + O(z^{-3})\right)。$$

对于 (II) 的左侧，令 $z = n/2$，$\alpha = 1/2$，可得

$$\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} = \sqrt{\frac{n}{2}}\left(1 - \frac{1}{8(n/2)} + \frac{1}{128(n/2)^2} + O(n^{-3})\right) = \sqrt{\frac{n}{2}}\left(1 - \frac{1}{4n} + \frac{1}{32n^2} + O(n^{-3})\right)。$$

两侧平方，

$$\begin{aligned}
a_n^2 &= 2\left(\frac{n}{2}\right)\left(1 - \frac{1}{4n} + \frac{1}{32n^2} + O(n^{-3})\right)^2 \\
&= n\left(1 - \frac{1}{2n} + \left(\frac{1}{16} + \frac{2}{32}\right)\frac{1}{n^2} + O(n^{-3})\right) \\
&= n\left(1 - \frac{1}{2n} + \frac{1}{8n^2} + O(n^{-3})\right) \\
&= n - \frac{1}{2} + \frac{1}{8n} + O(n^{-2}),
\end{aligned}$$

因此

$$\mathrm{LHS} = n - a_n^2 = \frac{1}{2} - \frac{1}{8n} + O(n^{-2})。$$

对于 (II) 的右侧，由于

$$\begin{aligned}
a_n &= \sqrt{a_n^2} = \sqrt{n}\sqrt{1 - \frac{1}{2n} + O(n^{-2})} = \sqrt{n}\left(1 - \frac{1}{4n} + O(n^{-2})\right), \\
\sqrt{n+1} + \sqrt{n} &= \sqrt{n}\left(\sqrt{1 + \frac{1}{n}} + 1\right) = \sqrt{n}\left(2 + \frac{1}{2n} + O(n^{-2})\right),
\end{aligned}$$

因此

$$\begin{aligned}
\mathrm{RHS} &= \frac{\sqrt{n}(1 - 1/4n + O(n^{-2}))}{\sqrt{n}(2 + 1/2n + O(n^{-2}))} \\
&= \frac{1}{2}\frac{1 - 1/4n + O(n^{-2})}{1 + 1/4n + O(n^{-2})} \\
&= \frac{1}{2}\left(1 - \frac{1}{4n}\right)\left(1 - \frac{1}{4n}\right) + O(n^{-2}) \\
&= \frac{1}{2}\left(1 - \frac{1}{2n}\right) + O(n^{-2}) \\
&= \frac{1}{2} - \frac{1}{4n} + O(n^{-2})。
\end{aligned}$$

如此，

$$\mathrm{LHS} - \mathrm{RHS} = \left(\frac{1}{2} - \frac{1}{8n}\right) - \left(\frac{1}{2} - \frac{1}{4n}\right) + O(n^{-2}) = \frac{1}{8n} + O(n^{-2}) \gtrsim 0。$$

13 [**Gaussian 矩阵的最小奇异值**] 设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。我们将利用定理 T7.2.9 (Gordon 不等式) 推导其最小奇异值 $s_n(\boldsymbol{A})$ 的精确下界。不妨设 $m \geqslant n \geqslant C$。

(1) (期望界限) 证明：

$$\mathrm{E}[s_n(\boldsymbol{A})] \geqslant \sqrt{m} - \sqrt{n}。$$

(2) (高概率界限) 利用集中不等式，将期望界限提升为高概率界限。证明：对于任意的 $t \geqslant 0$，

$$\mathrm{P}\{s_n(\boldsymbol{A}) \leqslant \sqrt{m} - \sqrt{n} - t\} \leqslant 2\exp(-ct^2)。 \qquad (c > 0)$$

证明 (1) 根据最小奇异值的定义，可得

$$s_n(\boldsymbol{A}) = \min_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad \|\boldsymbol{A}\boldsymbol{x}\|_2 = \max_{\boldsymbol{y}\in\mathbb{S}^{m-1}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle,$$

因此

$$s_n(\boldsymbol{A}) = \min_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \max_{\boldsymbol{y}\in\mathbb{S}^{m-1}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle。$$

定义 $\mathbb{U} = \mathbb{S}^{n-1}$，$\mathbb{T} = \mathbb{S}^{m-1}$，构造定义于 $\mathbb{U}\times\mathbb{T}$ 的零均值 Gaussian 过程 $(Y_{\boldsymbol{x}\boldsymbol{y}})$ 为

$$Y_{\boldsymbol{x}\boldsymbol{y}} = \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = \sum_{i=1}^{m}\sum_{j=1}^{n} A_{ij}x_j y_i,$$

则

$$\mathrm{E}\left[\min_{\boldsymbol{x}} \max_{\boldsymbol{y}} Y_{\boldsymbol{x}\boldsymbol{y}}\right] = \mathrm{E}[s_n(\boldsymbol{A})]。$$

之后引入相互独立的标准 Gaussian 向量 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_m), \boldsymbol{h} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，构造比较过程 $(X_{\boldsymbol{x}\boldsymbol{y}})$ 为

$$X_{\boldsymbol{x}\boldsymbol{y}} = \langle \boldsymbol{g}, \boldsymbol{y}\rangle + \langle \boldsymbol{h}, \boldsymbol{x}\rangle,$$

则

$$\begin{aligned}
\mathrm{E}\left[\min_{\boldsymbol{x}\in\mathbb{U}} \max_{\boldsymbol{y}\in\mathbb{T}} X_{\boldsymbol{x}\boldsymbol{y}}\right] &= \mathrm{E}\left[\min_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \max_{\boldsymbol{y}\in\mathbb{S}^{m-1}} (\langle \boldsymbol{g}, \boldsymbol{y}\rangle + \langle \boldsymbol{h}, \boldsymbol{x}\rangle)\right] \\
&= \mathrm{E}\left[\max_{\boldsymbol{y}\in\mathbb{S}^{m-1}} \langle \boldsymbol{g}, \boldsymbol{y}\rangle + \min_{\boldsymbol{x}\in\mathbb{S}^{n-1}} \langle \boldsymbol{h}, \boldsymbol{x}\rangle\right] \\
&= \mathrm{E}\|\boldsymbol{g}\|_2 - \mathrm{E}\|\boldsymbol{h}\|_2 \\
&= \mathrm{E}\|\boldsymbol{g}\|_2 - \mathrm{E}\|\boldsymbol{h}\|_2。
\end{aligned}$$

验证 Gordon 不等式的条件，

$$\begin{aligned}
\mathrm{E}[(Y_{\boldsymbol{x}\boldsymbol{y}} - Y_{\boldsymbol{u}\boldsymbol{v}})^2] &= \mathrm{E}[\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle - \langle \boldsymbol{A}\boldsymbol{u}, \boldsymbol{v}\rangle]^2 = \|\boldsymbol{y}\boldsymbol{x}^\top - \boldsymbol{v}\boldsymbol{u}^\top\|_F^2, \\
\mathrm{E}[(X_{\boldsymbol{x}\boldsymbol{y}} - X_{\boldsymbol{u}\boldsymbol{v}})^2] &= \mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{y} - \boldsymbol{v}\rangle + \langle \boldsymbol{h}, \boldsymbol{x} - \boldsymbol{u}\rangle]^2 = \|\boldsymbol{y} - \boldsymbol{v}\|_2^2 + \|\boldsymbol{x} - \boldsymbol{u}\|_2^2,
\end{aligned}$$

a. (组内条件) 当 $\boldsymbol{x} = \boldsymbol{u}$ 时，过程 Y 的增量为

$$\|\boldsymbol{y}\boldsymbol{x}^\top - \boldsymbol{v}\boldsymbol{x}^\top\|_F^2 = \|(\boldsymbol{y} - \boldsymbol{v})\boldsymbol{x}^\top\|_F^2 = \|\boldsymbol{y} - \boldsymbol{v}\|_2^2\|\boldsymbol{x}\|_2^2 = \|\boldsymbol{y} - \boldsymbol{v}\|_2^2,$$

过程 X 的增量为

$$\|\boldsymbol{y} - \boldsymbol{v}\|_2^2 + \|\boldsymbol{x} - \boldsymbol{x}\|_2^2 = \|\boldsymbol{y} - \boldsymbol{v}\|_2^2,$$

因此 $\mathrm{E}[(X_{\boldsymbol{x}\boldsymbol{y}} - X_{\boldsymbol{x}\boldsymbol{v}})^2] \leqslant \mathrm{E}[(Y_{\boldsymbol{x}\boldsymbol{y}} - Y_{\boldsymbol{x}\boldsymbol{v}})^2]$。

b. (组间条件) 当 $\boldsymbol{x} \neq \boldsymbol{u}$ 时，要证明 $\mathrm{E}[(X_{\boldsymbol{x}\boldsymbol{y}} - X_{\boldsymbol{u}\boldsymbol{v}})^2] \geqslant \mathrm{E}[(Y_{\boldsymbol{x}\boldsymbol{y}} - Y_{\boldsymbol{u}\boldsymbol{v}})^2]$，只需证明

$$\|\boldsymbol{x} - \boldsymbol{u}\|_2^2 + \|\boldsymbol{y} - \boldsymbol{v}\|_2^2 \geqslant \|\boldsymbol{y}\boldsymbol{x}^\top - \boldsymbol{v}\boldsymbol{u}^\top\|_F^2,$$

即为习题 Q7.10 (秩一矩阵间的 Frobenius 距离)。

如此，利用定理 T7.2.9 (Gordon 不等式) (Gordon 不等式)，可得

$$\mathrm{E}\left[\min_{\boldsymbol{x}\in\mathbb{U}} \max_{\boldsymbol{y}\in\mathbb{T}} X_{\boldsymbol{x}\boldsymbol{y}}\right] \leqslant \mathrm{E}\left[\min_{\boldsymbol{x}\in\mathbb{U}} \max_{\boldsymbol{y}\in\mathbb{T}} Y_{\boldsymbol{x}\boldsymbol{y}}\right],$$

即

$$\mathrm{E}[s_n(\boldsymbol{A})] \geqslant \mathrm{E}\|\boldsymbol{g}\|_2 - \mathrm{E}\|\boldsymbol{h}\|_2。$$

根据习题 Q7.12 (Gaussian 向量的范数)，当 $k \geqslant C$ 时，$f(k) = \mathrm{E}\|\boldsymbol{g}_k\|_2 - \sqrt{k}$ 是单调递增的，因此 $f(m) \geqslant f(n)$，即

$$\mathrm{E}\|\boldsymbol{g}\|_2 - \sqrt{m} \geqslant \mathrm{E}\|\boldsymbol{h}\|_2 - \sqrt{n},$$

即

$$\mathrm{E}\|\boldsymbol{g}\|_2 - \mathrm{E}\|\boldsymbol{h}\|_2 \geqslant \sqrt{m} - \sqrt{n},$$

即

$$\mathrm{E}[s_n(\boldsymbol{A})] \geqslant \sqrt{m} - \sqrt{n}。$$

(2) (为了将期望结果提升为高概率界限，我们利用标准的 Gaussian 集中不等式。将 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 视为 mn 个独立的标准 Gaussian 变量构成的向量。)

定义 $F(\boldsymbol{A}) = s_n(\boldsymbol{A})$，根据 Weyl 不等式，可得

$$|s_n(\boldsymbol{A}) - s_n(\boldsymbol{B})| \leqslant \|\boldsymbol{A} - \boldsymbol{B}\|,$$

其中 $\|\boldsymbol{A} - \boldsymbol{B}\| \leqslant \|\boldsymbol{A} - \boldsymbol{B}\|_F$，因此

$$|F(\boldsymbol{A}) - F(\boldsymbol{B})| \leqslant \|\boldsymbol{A} - \boldsymbol{B}\|_F,$$

可得 $\|F\|_{\mathrm{Lip}} = 1$。

利用定理 T7.1.11 (Gaussian 过程的集中) (Gaussian 过程的集中)，可得

$$\mathrm{P}\{F(\boldsymbol{A}) \leqslant \mathrm{E}[F(\boldsymbol{A})] - t\} \leqslant \exp\left(-\frac{t^2}{2L^2}\right),$$

即

$$\mathrm{P}\{s_n(\boldsymbol{A}) \leqslant \mathrm{E}[s_n(\boldsymbol{A})] - t\} \leqslant \exp\left(-\frac{t^2}{2}\right),$$

利用 (1) 的结论，可得

$$\mathrm{P}\{s_n(\boldsymbol{A}) \leqslant \sqrt{m} - \sqrt{n} - t\} \leqslant \mathrm{P}\{s_n(\boldsymbol{A}) \leqslant \mathrm{E}[s_n(\boldsymbol{A})] - t\} \leqslant \exp\left(-\frac{t^2}{2}\right)。$$

14 [**非紧致集合的 Sudakov 不等式**] 设 $(X_t)_{t\in\mathbb{T}}$ 为零均值 Gaussian 过程，其典范度量定义为

$$d(t,s) = \|X_t - X_s\|_{L^2} = \sqrt{\mathrm{E}[(X_t - X_s)^2]}。$$

证明：若度量空间 $(\mathbb{T}, d)$ 不是相对紧致的 (即存在 $\varepsilon > 0$，使得覆盖数 $\mathcal{N}(\mathbb{T}, d, \varepsilon) = \infty$)，则

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}} X_t\right] = \infty。$$

注释 **覆盖数** 若存在有限点集 $\{x_1, x_2, \cdots, x_N\} \subset \mathbb{T}$，使得对于任意的 $x \in \mathbb{T}$，存在 x_i，满足 $d(x, x_i) \leqslant \varepsilon$，则称其为 ε-覆盖。于各个可能的 ε-覆盖，覆盖数 $\mathcal{N}(\mathbb{T}, d, \varepsilon)$ 定义为点数最少的数量。

分离数 若存在有限点集 $\{y_1, y_2, \cdots, y_M\} \subset \mathbb{T}$，使得对于任意的 $y_i \neq y_j$，均满足 $d(y_i, y_j) \geqslant \varepsilon$，则称其为 ε-分离集。于各个可能的 ε-分离集，分离数 $\mathcal{M}(\mathbb{T}, d, \varepsilon)$ 定义为点数最多的数量。

容易知道，

$$\mathcal{N}(\mathbb{T}, d, \varepsilon) \leqslant \mathcal{M}(\mathbb{T}, d, \varepsilon)。$$

证明 由于 $(\mathbb{T}, d)$ 不是相对紧致的，因此存在 $\varepsilon > 0$，使得覆盖数满足 $\mathcal{N}(\mathbb{T}, d, \varepsilon) = \infty$，从而分离数满足

$$\mathcal{M}(\mathbb{T}, d, \varepsilon) = \infty,$$

从而对于任意的 N，存在大小为 N 的有限子集 $\mathbb{T}_N = \{t_1, t_2, \cdots, t_N\} \subset \mathbb{T}$，使得对于任意的 $t_i \neq t_j \in \mathbb{T}_N$，

$$d(t_i, t_j) = \sqrt{\mathrm{E}[(X_{t_i} - X_{t_j})^2]} \geqslant \varepsilon,$$

即为 Sudakov 条件。

对于 $\mathbb{T}_N$，利用定理 T7.4.1 (Sudakov 不等式) (Sudakov 不等式)，可得

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}_N} X_t\right] \geqslant c\cdot\varepsilon\cdot\sqrt{\ln|\mathbb{T}_N|},$$

即

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}} X_t\right] \geqslant c\varepsilon\sqrt{\ln N}。$$

由于 $\mathbb{T}_N\subset\mathbb{T}$，因此

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}} X_t\right] \geqslant \mathrm{E}\left[\sup_{t\in\mathbb{T}_N} X_t\right],$$

令 $N\to\infty$，可得

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}} X_t\right] \geqslant \lim_{N\to\infty} c\varepsilon\sqrt{\ln N}=\infty。$$

15 [**Gaussian 宽度的基本性质**] 设 $\mathbb{T},\mathbb{S}\subset\mathbb{R}^n$，$\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。定义 $\mathbb{T}$ 的 Gaussian 宽度为

$$w(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}\rangle\right]。$$

证明性质 P7.5.2 (Gaussian 宽度的简单性质) 的七个基本性质。

(1) 有限性：$w(\mathbb{T})$ 是有限的，当且仅当 $\mathbb{T}$ 是有界的。

(2) (刚体不变性) 对于任意的正交矩阵 $\boldsymbol{U}$, 平移向量 $\boldsymbol{y}\in\mathbb{R}^n$，$w(\boldsymbol{U}\mathbb{T}+\boldsymbol{y})=w(\mathbb{T})$。

(3) (凸包) $w(\mathrm{conv}(\mathbb{T}))=w(\mathbb{T})$。

(4) (Minkowski 和与缩放) $w(\mathbb{T}+\mathbb{S})=w(\mathbb{T})+w(\mathbb{S})$；$w(a\mathbb{T})=|a|w(\mathbb{T})$。

(5) (对称性)

$$w(\mathbb{T})=\frac{1}{2}w(\mathbb{T}-\mathbb{T})=\frac{1}{2}\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}-\boldsymbol{y}\rangle\right]。$$

(6) (宽度与直径)

$$\frac{1}{\sqrt{2\pi}}\,\mathrm{diam}(\mathbb{T})\leqslant w(\mathbb{T})\leqslant\frac{\sqrt{n}}{2}\,\mathrm{diam}(\mathbb{T}),$$

其中 $\mathrm{diam}(\mathbb{T})=\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\|\boldsymbol{x}-\boldsymbol{y}\|_2$。

(7) (线性映射) 对于任意的 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，$w(\boldsymbol{A}\mathbb{T})\leqslant\|\boldsymbol{A}\|w(\mathbb{T})$。

证明 (1) 设 $\mathbb{T}$ 是有界的，则存在半径 $R<\infty$，使得对于任意的 $\boldsymbol{t}\in\mathbb{T}$，均满足 $\|\boldsymbol{t}\|_2\leqslant R$。

利用 Cauchy 不等式，可得

$$w(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}\rangle\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{g}\|_2\|\boldsymbol{t}\|_2\right]\leqslant R\cdot\mathrm{E}\|\boldsymbol{g}\|_2,$$

代入 $\mathrm{E}\|\boldsymbol{g}\|_2\leqslant\sqrt{\mathrm{E}\|\boldsymbol{g}\|_2^2}=\sqrt{n}$，可得 $w(\mathbb{T})\leqslant R\sqrt{n}<\infty$。

反之，$\mathbb{T}$ 无界时，存在 $\{\boldsymbol{t}_k\}\subset\mathbb{T}$，使得 $\|\boldsymbol{t}_k\|_2\to\infty$。取子列后，可设 $\boldsymbol{t}_k/\|\boldsymbol{t}_k\|_2\to\boldsymbol{u}\in\mathbb{S}^{n-1}$。于事件 $\{\langle\boldsymbol{g},\boldsymbol{u}\rangle>0\}$，$\langle\boldsymbol{g},\boldsymbol{t}_k\rangle\to\infty$。此事件以正概率发生，因此

$$\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}\rangle=\infty$$

以正概率成立，从而 $w(\mathbb{T})=\infty$。如此，$w(\mathbb{T})$ 有限时，$\mathbb{T}$ 是有界的。

(2) 根据 Gaussian 宽度的定义 (D7.5.1 (Gaussian 宽度))，可得

$$w(\boldsymbol{U}\mathbb{T}+\boldsymbol{y})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{U}\boldsymbol{t}+\boldsymbol{y}\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}(\langle\boldsymbol{g},\boldsymbol{U}\boldsymbol{t}\rangle+\langle\boldsymbol{g},\boldsymbol{y}\rangle)\right]$$

$$= \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{U}^\top \boldsymbol{g}, \boldsymbol{t}\rangle\right] + \mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{y}\rangle]。$$

对于第二项，$\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{y}\rangle] = \langle \mathrm{E}[\boldsymbol{g}], \boldsymbol{y}\rangle = 0$；对于第一项，由于 $\boldsymbol{U}^\top \boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，因此

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{U}^\top \boldsymbol{g}, \boldsymbol{t}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle\right] = w(\mathbb{T})；$$

从而

$$w(\boldsymbol{U}\mathbb{T} + \boldsymbol{y}) = w(\mathbb{T}) + 0 = w(\mathbb{T})。$$

(3) 一方面，由于 $\mathbb{T} \subset \mathrm{conv}(\mathbb{T})$，因此 $w(\mathbb{T}) \leqslant w(\mathrm{conv}(\mathbb{T}))$。

另一方面，对于任意的 $\boldsymbol{x} = \sum_{i=1}^n \lambda_i \boldsymbol{t}_i \in \mathrm{conv}(\mathbb{T})$，

$$\langle \boldsymbol{g}, \boldsymbol{x}\rangle = \sum_{i=1}^n \lambda_i \langle \boldsymbol{g}, \boldsymbol{t}_i\rangle \leqslant \sum_{i=1}^n \lambda_i \sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle = \sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle,$$

因此 $w(\mathrm{conv}(\mathbb{T})) \leqslant w(\mathbb{T})$。

如此，$w(\mathrm{conv}(\mathbb{T})) = w(\mathbb{T})$。

(4) 对于 Minkowski 和，

$$\begin{aligned} w(\mathbb{T}+\mathbb{S}) &= \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle \boldsymbol{g}, \boldsymbol{x}+\boldsymbol{y}\rangle\right] \\ &= \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}(\langle \boldsymbol{g}, \boldsymbol{x}\rangle + \langle \boldsymbol{g}, \boldsymbol{y}\rangle)\right] \\ &= \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{x}\rangle + \sup_{\boldsymbol{y}\in\mathbb{S}}\langle \boldsymbol{g}, \boldsymbol{y}\rangle\right] \\ &= \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{x}\rangle\right] + \mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{S}}\langle \boldsymbol{g}, \boldsymbol{y}\rangle\right] = w(\mathbb{T}) + w(\mathbb{S})。 \end{aligned}$$

对于 Minkowski 缩放，

$$w(a\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, a\boldsymbol{t}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle a\boldsymbol{g}, \boldsymbol{t}\rangle\right] = |a| w(\mathbb{T})。$$

(5) 利用 Minkowski 缩放性，可得

$$w(-\mathbb{T}) = |-1| w(\mathbb{T}) = w(\mathbb{T}),$$

因此

$$\frac{1}{2} w(\mathbb{T}-\mathbb{T}) = \frac{1}{2}(w(\mathbb{T}) + w(-\mathbb{T})) = \frac{1}{2}(w(\mathbb{T}) + w(\mathbb{T})) = w(\mathbb{T}),$$

其中

$$\frac{1}{2} w(\mathbb{T}-\mathbb{T}) = \frac{1}{2}\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{v}\rangle\right] = \frac{1}{2}\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{x}-\boldsymbol{y}\rangle\right]。$$

(6) 对于下界，设 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{T}$，则利用 (5) 的结论，可得

$$w(\mathbb{T}) = \frac{1}{2}\mathrm{E}\left[\sup_{\boldsymbol{u},\boldsymbol{v}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{u}-\boldsymbol{v}\rangle\right] \geqslant \frac{1}{2}\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{x}-\boldsymbol{y}\rangle \vee \langle \boldsymbol{g}, \boldsymbol{y}-\boldsymbol{x}\rangle] = \frac{1}{2}\mathrm{E}[|\langle \boldsymbol{g}, \boldsymbol{x}-\boldsymbol{y}\rangle|],$$

其中 $\langle \boldsymbol{g}, \boldsymbol{x}-\boldsymbol{y}\rangle \sim N(0, \|\boldsymbol{x}-\boldsymbol{y}\|_2^2)$，因此

$$w(\mathbb{T}) \geqslant \frac{1}{2}\sqrt{\frac{2}{\pi}}\|\boldsymbol{x}-\boldsymbol{y}\|_2 = \frac{1}{\sqrt{2\pi}}\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

两侧对 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}$ 取上确界，

$$w(\mathbb{T})\geqslant\frac{1}{\sqrt{2\pi}}\operatorname{diam}(\mathbb{T})。$$

(以下给出较弱的上界：

对于上界，对于固定的 $\boldsymbol{y}_0\in\mathbb{T}$，设 $\boldsymbol{t}\in\mathbb{T}$，则 $\|\boldsymbol{t}-\boldsymbol{y}_0\|_2\leqslant\operatorname{diam}(\mathbb{T})$。

利用平移不变性，可得

$$\begin{aligned}w(\mathbb{T})=w(\mathbb{T}-\boldsymbol{y}_0)&=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}-\boldsymbol{y}_0\rangle\right]\\&\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{g}\|_2\|\boldsymbol{t}-\boldsymbol{y}_0\|_2\right]\leqslant\mathrm{E}\|\boldsymbol{g}\|_2\cdot\operatorname{diam}(\mathbb{T})。\end{aligned}$$

为取得系数 $\sqrt{n}/2$，利用对称性。)

对于上界，利用对称性，可得

$$w(\mathbb{T})=\frac{1}{2}w(\mathbb{T}-\mathbb{T})=\frac{1}{2}\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}-\boldsymbol{y}\rangle\right]\leqslant\frac{1}{2}\mathrm{E}\|\boldsymbol{g}\|_2\sup_{\boldsymbol{x},\boldsymbol{y}}\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant\frac{\sqrt{n}}{2}\operatorname{diam}(\mathbb{T})。$$

(7) 根据 Gaussian 宽度的定义 (D7.5.1 (Gaussian 宽度))，可得

$$w(\boldsymbol{A}\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{A}\boldsymbol{t}\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{A}^{\top}\boldsymbol{g},\boldsymbol{t}\rangle\right],$$

其中 $\boldsymbol{A}^{\top}\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{A}^{\top}\boldsymbol{A})$。

构造比较过程 $X_{\boldsymbol{t}}=\langle\boldsymbol{A}^{\top}\boldsymbol{g},\boldsymbol{t}\rangle$，则其增量二阶矩为

$$\mathrm{E}[(X_{\boldsymbol{t}}-X_{\boldsymbol{s}})^2]=\mathrm{E}[\langle\boldsymbol{A}^{\top}\boldsymbol{g},\boldsymbol{t}-\boldsymbol{s}\rangle^2]=\mathrm{E}[\langle\boldsymbol{g},\boldsymbol{A}(\boldsymbol{t}-\boldsymbol{s})\rangle^2]=\|\boldsymbol{A}(\boldsymbol{t}-\boldsymbol{s})\|_2^2\leqslant\|\boldsymbol{A}\|^2\|\boldsymbol{t}-\boldsymbol{s}\|_2^2。$$

之后构造过程 $Y_{\boldsymbol{t}}=\|\boldsymbol{A}\|\langle\boldsymbol{h},\boldsymbol{t}\rangle$，其中 $\boldsymbol{h}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则其增量二阶矩为

$$\mathrm{E}[(Y_{\boldsymbol{t}}-Y_{\boldsymbol{s}})^2]=\|\boldsymbol{A}\|^2\mathrm{E}[\langle\boldsymbol{h},\boldsymbol{t}-\boldsymbol{s}\rangle^2]=\|\boldsymbol{A}\|^2\|\boldsymbol{t}-\boldsymbol{s}\|_2^2,$$

因此

$$\mathrm{E}[(X_{\boldsymbol{t}}-X_{\boldsymbol{s}})^2]\leqslant\mathrm{E}[(Y_{\boldsymbol{t}}-Y_{\boldsymbol{s}})^2],$$

即为 Sudakov-Fernique 条件。

利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，可得

$$w(\boldsymbol{A}\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}X_{\boldsymbol{t}}\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}Y_{\boldsymbol{t}}\right]=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{A}\|\langle\boldsymbol{h},\boldsymbol{t}\rangle\right]=\|\boldsymbol{A}\|w(\mathbb{T})。$$

16 [**Gaussian 宽度, 直径的最优性**] 于性质 P7.5.2 (Gaussian 宽度的简单性质) (6)，已知对于 $\mathbb{T}\subset\mathbb{R}^n$，

$$\frac{1}{\sqrt{2\pi}}\operatorname{diam}(\mathbb{T})\leqslant w(\mathbb{T})\leqslant\frac{\sqrt{n}}{2}\operatorname{diam}(\mathbb{T})$$

举例证明，上述不等式的下界, 上界均可达到 (至多相差一个绝对常数因子)。

证明 (为了证明界限的紧性，之后只需于 $\mathbb{R}^n$ 寻找极端的几何体，其中下界对应于极度“狭窄”的一维物体，上界对应于在各个方向都充分“饱满”的物体。)

- 证明下界可达 (一维线段)

  构造 $\mathbb{T}_1$ 为 $\mathbb{R}^n$ 为沿第一个坐标轴的单位线段，即

  $$\mathbb{T}_1=\{t\boldsymbol{e}_1:t\in[-1,1]\},$$

  则 $\operatorname{diam}(\mathbb{T}_1)=\|\boldsymbol{e}_1-(-\boldsymbol{e}_1)\|_2=\|2\boldsymbol{e}_1\|_2=2$。

  设 $\boldsymbol{g}=(g_1,\cdots,g_n)\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则

  $$w(\mathbb{T}_1)=\mathrm{E}\left[\sup_{t\in[-1,1]}\langle\boldsymbol{g},t\boldsymbol{e}_1\rangle\right]=\mathrm{E}\left[\sup_{t\in[-1,1]}tg_1\right]=\mathrm{E}[|g_1|]=\sqrt{\frac{2}{\pi}},$$

因此

$$\frac{1}{\sqrt{2\pi}}\operatorname{diam}(\mathbb{T}_1)=\sqrt{\frac{2}{\pi}}=w(\mathbb{T}_1)。$$

- 证明上界可达 (Euclidean 单位球)

  构造 $\mathbb{T}_2$ 为 $\mathbb{R}^n$ 的 Euclidean 单位球，即

$$\mathbb{T}_2=\mathbb{B}_2^n=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_2\leqslant 1\},$$

  则 $\operatorname{diam}(\mathbb{T}_2)=2$。

  设 $\boldsymbol{g}=(g_1,\cdots,g_n)\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则

$$w(\mathbb{T}_2)=\mathrm{E}\left[\sup_{\|\boldsymbol{x}\|_2\leqslant 1}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right]=\mathrm{E}\|\boldsymbol{g}\|_2\gtrsim\sqrt{n},$$

  因此

$$\frac{\sqrt{n}}{2}\operatorname{diam}(\mathbb{T}_2)=\sqrt{n}\asymp w(\mathbb{T}_2)。$$

17 [ℓ^p 球的 **Gaussian 宽度**] 设 $1\leqslant p\leqslant\infty$。考虑 $\mathbb{B}_p^n=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_p\leqslant 1\}$，证明：

$$w(\mathbb{B}_p^n)\asymp\begin{cases}\sqrt{p'}n^{1/p'}, & p'\leqslant\ln n,\\ \sqrt{\ln n}, & p'\geqslant\ln n\end{cases}。$$

其中 p' 为 p 的共轭指数。

证明 当 $n=2$ 时，任意的 $\ell^{p'}$ 范数于 $\mathbb{R}^2$ 彼此等价，因此结论两侧均为绝对常数阶，这是平凡的；之后只需考虑 $n\geqslant 3$ 的情况。

设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，Gaussian 宽度的定义为

$$w(\mathbb{B}_p^n)=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{B}_p^n}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right],$$

其中根据对偶范数的定义，可得

$$\sup_{\|\boldsymbol{x}\|_p\leqslant 1}\langle\boldsymbol{g},\boldsymbol{x}\rangle=\|\boldsymbol{g}\|_{p'}=\left(\sum_{i=1}^n|g_i|^{p'}\right)^{1/p'},$$

因此 $w(\mathbb{B}_p^n)=\mathrm{E}\|\boldsymbol{g}\|_{p'}$。建立全局界限。

对于 $p'\geqslant 1$，$f(x)=x^{p'}$ 为凸函数，因此利用 Jensen 不等式，可得

$$\begin{aligned}\mathrm{E}\|\boldsymbol{g}\|_{p'}\leqslant(\mathrm{E}\|\boldsymbol{g}\|_{p'}^{p'})^{1/p'}&=\left[\mathrm{E}\left[\sum_{i=1}^n|g_i|^{p'}\right]\right]^{1/p'}\\&=(n\mathrm{E}[|g_1|^{p'}])^{1/p'}=n^{1/p'}(\mathrm{E}[|g_1|^{p'}])^{1/p'}=n^{1/p'}\|g_1\|_{L_{p'}}\\&\leqslant C\sqrt{p'}n^{1/p'}。\qquad(\|g\|_{L_q}\asymp\sqrt{q})\ \text{(I)}\end{aligned}$$

之后对 p' 的取值范围进行讨论。

a. 当 $p'\geqslant\ln n$ 时，对于下界，

$$\mathrm{E}\|\boldsymbol{g}\|_{p'}\geqslant\mathrm{E}\|\boldsymbol{g}\|_\infty\asymp\sqrt{\ln n},$$

对于上界，利用 (I) 的结论，可得

$$\mathrm{E}\|\boldsymbol{g}\|_{p'}\leqslant\mathrm{E}\|\boldsymbol{g}\|_{\ln n}\leqslant C\sqrt{\ln n}\cdot n^{1/\ln n}=C\mathrm{e}\sqrt{\ln n}\asymp\sqrt{\ln n}。$$

如此，$w(\mathbb{B}_p^n)\asymp\sqrt{\ln n}$。

b. 当 $1\leqslant p'\leqslant\ln n$ 时，对于上界，利用 (I) 的结论，可得

$$w(\mathbb{B}_p^n)\leqslant C\sqrt{p'}n^{1/p'},$$

之后只需估计下界。

(考虑利用 Paley-Zygmund 不等式给出严格下界。)

令 $S=\sum_{i=1}^n |g_i|^{p'}$，则其数字特征为

$$\begin{aligned}\mathrm{E}[S] &= n\mathrm{E}[|g|^{p'}],\\ \mathrm{E}[S^2] &= n\mathrm{E}[|g|^{2p'}]+n(n-1)(\mathrm{E}[|g|^{p'}])^2。\end{aligned}$$

利用 Paley-Zygmund 不等式，可得对于任意的 $\theta\in(0,1)$，

$$\mathrm{P}\{S>\theta\mathrm{E}[S]\}\geqslant(1-\theta)^2\frac{(\mathrm{E}[S])^2}{\mathrm{E}[S^2]}。$$

对于右侧，代入 $\mathrm{E}[|g|^q]\asymp(q/\mathrm{e})^{q/2}$，可得

$$\frac{\mathrm{E}[|g|^{2p'}]}{(\mathrm{E}[|g|^{p'}])^2}\asymp\frac{(2p'/\mathrm{e})^{p'}}{(p'/\mathrm{e})^{p'}}=2^{p'},$$

因此

$$\frac{\mathrm{E}[S^2]}{(\mathrm{E}[S])^2}=\frac{n\mathrm{E}[|g|^{2p'}]}{n^2(\mathrm{E}[|g|^{p'}])^2}+\frac{n(n-1)}{n^2}\leqslant\frac{C2^{p'}}{n}+1\leqslant\frac{Cn^{\ln 2}}{n}+1\to 1,$$

从而存在 $M>0$，使得

$$\frac{\mathrm{E}[S^2]}{(\mathrm{E}[S])^2}\leqslant M。$$

令 $\theta=1/2$，可得

$$\mathrm{P}\left\{S>\frac{1}{2}\mathrm{E}[S]\right\}\geqslant\frac{1}{4M}>0,$$

利用命题 P1.6.2 (Markov 不等式) (Markov 不等式)，可得

$$\begin{aligned}\mathrm{E}\|\boldsymbol{g}\|_{p'}=\mathrm{E}[S^{1/p'}] &\geqslant \mathrm{P}\left\{S>\frac{1}{2}\mathrm{E}[S]\right\}\cdot\left(\frac{1}{2}\mathrm{E}[S]\right)^{1/p'}\\ &\geqslant\frac{1}{4M}\left(\frac{1}{2}n\mathrm{E}[|g|^{p'}]\right)^{1/p'}=\frac{1}{4M}\left(\frac{1}{2}\right)^{1/p'}n^{1/p'}\|g\|_{L_{p'}}\\ &\geqslant c\sqrt{p'}n^{1/p'}。\end{aligned}$$

如此，$w(\mathbb{B}_p^n)\asymp\sqrt{p'}n^{1/p'}$。

18 [**核范数**] 设 $\boldsymbol{A}\in\mathbb{R}^{n\times n}$，其奇异值为 $s_1\geqslant s_2\geqslant\cdots\geqslant s_n\geqslant 0$。已知算子范数 $\|\boldsymbol{A}\|$ 为奇异值的 ℓ^∞ 范数 (最大奇异值)，而 Frobenius 范数 $\|\boldsymbol{A}\|_F$ 为奇异值的 ℓ^2 范数 (见引理 L4.1.11 (通过奇异值表示矩阵范数))。定义核范数为其奇异值的 ℓ^1 范数，即

$$\|\boldsymbol{A}\|_*=\sum_{i=1}^n s_i(\boldsymbol{A})。$$

(1) 正如向量的 ℓ^1 范数, ℓ^∞ 范数是对偶的 (见练习 Q1.19 (ℓ_p 范数的对偶性)(b))，证明：核范数, 算子范数是对偶的，即

$$\|\boldsymbol{A}\|_*=\max_{\|\boldsymbol{B}\|\leqslant 1}\langle\boldsymbol{A},\boldsymbol{B}\rangle。$$

(2) 利用 (1) 的结论，证明核范数 $\|\cdot\|_*$ 为合法的范数。

证明 设 $\boldsymbol{A}$ 的 SVD 为 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，其中 $\boldsymbol{U},\boldsymbol{V}$ 为正交矩阵，$\boldsymbol{\Sigma}=\mathrm{diag}(s_1,\cdots,s_n)$ 为包含非负奇异值的对角矩阵。

(1) 设 $\|\boldsymbol{B}\|\leqslant 1$，则

$$\langle\boldsymbol{A},\boldsymbol{B}\rangle=\mathrm{tr}(\boldsymbol{A}^\top\boldsymbol{B})=\mathrm{tr}(\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{U}^\top\boldsymbol{B})=\mathrm{tr}(\boldsymbol{\Sigma}\boldsymbol{U}^\top\boldsymbol{B}\boldsymbol{V})。$$

令 $\boldsymbol{C}=\boldsymbol{U}^\top\boldsymbol{B}\boldsymbol{V}$，则

$$\|\boldsymbol{C}\|=\|\boldsymbol{U}^\top\boldsymbol{B}\boldsymbol{V}\|\leqslant\|\boldsymbol{U}^\top\|\|\boldsymbol{B}\|\|\boldsymbol{V}\|=1\cdot\|\boldsymbol{B}\|\cdot 1\leqslant 1,$$

将其代入，可得

$$\langle \boldsymbol{A}, \boldsymbol{B} \rangle = \operatorname{tr}(\boldsymbol{\Sigma C}) = \sum_{i=1}^{n} s_i c_{ii} \leqslant \sum_{i=1}^{n} s_i |c_{ii}| \leqslant \sum_{i=1}^{n} s_i = \|\boldsymbol{A}\|_*,$$

因此对于任意的 $\|\boldsymbol{B}\| \leqslant 1$，均满足 $\langle \boldsymbol{A}, \boldsymbol{B} \rangle \leqslant \|\boldsymbol{A}\|_*$。

(之后只需证明最大值的可达性，我们只需构造 $\boldsymbol{B}^*$，使得 $\langle \boldsymbol{A}, \boldsymbol{B}^* \rangle = \|\boldsymbol{A}\|_*$。)

令 $\boldsymbol{C} = \boldsymbol{U}^\top \boldsymbol{B}^* \boldsymbol{V} = \boldsymbol{I}$，即 $\boldsymbol{B}^* = \boldsymbol{U}\boldsymbol{V}^\top$，则 $\|\boldsymbol{B}^*\| = 1 \leqslant 1$，

$$\langle \boldsymbol{A}, \boldsymbol{B}^* \rangle = \operatorname{tr}(\boldsymbol{V\Sigma U}^\top \cdot \boldsymbol{UV}^\top) = \operatorname{tr}(\boldsymbol{V\Sigma V}^\top) = \operatorname{tr}(\boldsymbol{\Sigma}) = \sum_{i=1}^{n} s_i = \|\boldsymbol{A}\|_*。$$

如此，

$$\|\boldsymbol{A}\|_* = \max_{\|\boldsymbol{B}\| \leqslant 1} \langle \boldsymbol{A}, \boldsymbol{B} \rangle。$$

(2) 1. (正定性)

若 $s_i \geqslant 0$，则 $\|\boldsymbol{A}\|_* = \sum_{i=1}^{n} s_i \geqslant 0$；若 $\|\boldsymbol{A}\|_* = 0$，则 $s_i = 0$，可得 $\boldsymbol{A} = \boldsymbol{0}$。

(也可以通过对偶式进行证明。若 $\boldsymbol{B} = \boldsymbol{0}$，则 $\|\boldsymbol{A}\|_* \geqslant 0$；若 $\max_{\|\boldsymbol{B}\| \leqslant 1} \langle \boldsymbol{A}, \boldsymbol{B} \rangle = 0$，则令 $\boldsymbol{B} = \boldsymbol{A}/\|\boldsymbol{A}\|$，可得 $\boldsymbol{A} = \boldsymbol{0}$。)

2. (绝对齐次性)

若 $c \geqslant 0$，则

$$\|c\boldsymbol{A}\|_* = \max_{\|\boldsymbol{B}\| \leqslant 1} \langle c\boldsymbol{A}, \boldsymbol{B} \rangle = \max_{\|\boldsymbol{B}\| \leqslant 1} c\langle \boldsymbol{A}, \boldsymbol{B} \rangle = c\|\boldsymbol{A}\|_*。$$

若 $c < 0$，则

$$\|c\boldsymbol{A}\|_* = \max_{\|\boldsymbol{B}\| \leqslant 1} |c| \langle \boldsymbol{A}, -\boldsymbol{B} \rangle = |c| \max_{\|\boldsymbol{B}\| \leqslant 1} \langle \boldsymbol{A}, \boldsymbol{B} \rangle = |c| \|\boldsymbol{A}\|_*。$$

3. (三角不等式)

设 $\boldsymbol{A}, \boldsymbol{C} \in \mathbb{R}^{n \times n}$，则

$$\begin{aligned} \|\boldsymbol{A} + \boldsymbol{C}\|_* &= \max_{\|\boldsymbol{B}\| \leqslant 1} \langle \boldsymbol{A} + \boldsymbol{C}, \boldsymbol{B} \rangle \\ &= \max_{\|\boldsymbol{B}\| \leqslant 1} (\langle \boldsymbol{A}, \boldsymbol{B} \rangle + \langle \boldsymbol{C}, \boldsymbol{B} \rangle) \\ &\leqslant \max_{\|\boldsymbol{B}_1\| \leqslant 1} \langle \boldsymbol{A}, \boldsymbol{B}_1 \rangle + \max_{\|\boldsymbol{B}_2\| \leqslant 1} \langle \boldsymbol{C}, \boldsymbol{B}_2 \rangle \\ &= \|\boldsymbol{A}\|_* + \|\boldsymbol{C}\|_*。 \end{aligned}$$

19 [**算子范数单位球的 Gaussian 宽度**] 设 $\mathbb{T}$ 为 $\mathbb{R}^{n \times n}$ 矩阵空间的算子范数的单位球，即

$$\mathbb{T} = \{\boldsymbol{B} \in \mathbb{R}^{n \times n} : \|\boldsymbol{B}\| \leqslant 1\}。$$

证明：

$$w(\mathbb{T}) \asymp n^{3/2}。$$

证明 根据 Gaussian 宽度的定义 (D7.5.1 (Gaussian 宽度))，可得

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{B} \in \mathbb{T}} \langle \boldsymbol{G}, \boldsymbol{B} \rangle\right] = \mathrm{E}\left[\max_{\|\boldsymbol{B}\| \leqslant 1} \langle \boldsymbol{G}, \boldsymbol{B} \rangle\right],$$

根据习题 Q7.18 (核范数)，可得

$$w(\mathbb{T}) = \mathrm{E}\|\boldsymbol{G}\|_* = \mathrm{E}\left[\sum_{i=1}^{n} s_i(\boldsymbol{G})\right],$$

之后只需估计 $n \times n$ 标准 Gaussian 矩阵奇异值之和的期望。

- 证明上界 $w(\mathbb{T}) \lesssim n^{3/2}$

对于奇异值向量 $(s_1,\cdots,s_n)$, 全 1 向量 $(1,\cdots,1)$，利用 Cauchy 不等式，可得

$$\sum_{i=1}^n s_i\cdot 1\leqslant\left(\sum_{i=1}^n s_i^2\right)^{1/2}\left(\sum_{i=1}^n 1^2\right)^{1/2},$$

即

$$\|\boldsymbol{G}\|_*\leqslant\sqrt{n}\|\boldsymbol{G}\|_F,$$

两侧取期望，

$$\mathrm{E}\|\boldsymbol{G}\|_*\leqslant\sqrt{n}\mathrm{E}\|\boldsymbol{G}\|_F。$$

其中

$$\mathrm{E}\|\boldsymbol{G}\|_F\leqslant\sqrt{\mathrm{E}\|\boldsymbol{G}\|_F^2}=\sqrt{\sum_{i=1}^n\sum_{j=1}^n\mathrm{E}[G_{ij}^2]}=n,$$

将其代入，可得 $w(\mathbb{T})\leqslant n^{3/2}$。

- 证明下界 $w(\mathbb{T})\gtrsim n^{3/2}$

由于

$$\|\boldsymbol{G}\|_F^2=\sum_{i=1}^n s_i^2\leqslant\left(\max_i s_i\right)\left(\sum_{i=1}^n s_i\right)=\|\boldsymbol{G}\|\cdot\|\boldsymbol{G}\|_*,$$

因此

$$\|\boldsymbol{G}\|_*\geqslant\frac{\|\boldsymbol{G}\|_F^2}{\|\boldsymbol{G}\|}。\tag{I}$$

(我们不能直接将期望拆分为分子, 分母。为了处理分母的算子范数，我们引入高概率的“良性事件” $\mathcal{E}$。)

对于分母，根据定理 T7.3.1 (Gaussian 随机矩阵的范数)，可得

$$\mathrm{E}\|\boldsymbol{G}\|\leqslant 2\sqrt{n}。$$

根据定理 T5.2.3 (Gaussian 集中)，可得

$$\mathrm{P}\{\|\boldsymbol{G}\|\geqslant\mathrm{E}\|\boldsymbol{G}\|+t\}\leqslant\exp\left(-\frac{t^2}{2}\right),$$

令 $t=\sqrt{n}$，可得

$$\mathrm{P}\{\|\boldsymbol{G}\|\geqslant 3\sqrt{n}\}\leqslant\exp\left(-\frac{1}{2}n\right)。$$

定义 $\mathcal{E}=\{\|\boldsymbol{G}\|\leqslant 3\sqrt{n}\}$，则

$$\mathrm{E}\|\boldsymbol{G}\|_*\geqslant\mathrm{E}\|\boldsymbol{G}\|_*\mathbf{1}_{\mathcal{E}}\geqslant\mathrm{E}\left[\frac{\|\boldsymbol{G}\|_F^2}{\|\boldsymbol{G}\|}\mathbf{1}_{\mathcal{E}}\right]\geqslant\frac{1}{3\sqrt{n}}\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}}。$$

对于右侧，

$$\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}}=\mathrm{E}\|\boldsymbol{G}\|_F^2-\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}^c}=n^2-\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}^c},\tag{II}$$

其中利用 Cauchy 不等式，可得

$$\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}^c}\leqslant\sqrt{\mathrm{E}\|\boldsymbol{G}\|_F^4}\sqrt{\mathrm{P}(\mathcal{E}^c)}\leqslant\sqrt{3n^4}\cdot\sqrt{\mathrm{e}^{-n/2}}=\sqrt{3}n^2\mathrm{e}^{-n/2}\lesssim\frac{1}{2}n^2,$$

(由于 $\|\boldsymbol{G}\|_F^2\sim\chi^2(n^2)$，因此其二阶矩 $\mathrm{E}\|\boldsymbol{G}\|_F^4=\mathrm{Var}(\|\boldsymbol{G}\|_F^2)+(\mathrm{E}\|\boldsymbol{G}\|_F^2)^2=2n^2+n^4\leqslant 3n^4$。)

将其代入于 (I)，可得

$$\mathrm{E}\|\boldsymbol{G}\|_F^2\mathbf{1}_{\mathcal{E}}\geqslant n^2-\frac{1}{2}n^2=\frac{1}{2}n^2,$$

将其代入于 (II)，可得

$$\mathrm{E}\|\boldsymbol{G}\|_* \geqslant \frac{1}{3\sqrt{n}} \cdot \frac{1}{2} n^2 = \frac{1}{6} n^{3/2},$$

从而 $w(\mathbb{T}) \gtrsim n^{3/2}$。

如此，$w(\mathbb{T}) \asymp n^{3/2}$。

20 **[Gaussian 宽度与 Gaussian 复杂度]** 证明引理 L7.5.11 (Gaussian 宽度的几乎等价形式) 未给出证明的一个结论。

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$。定义 $\mathbb{T} \subset \mathbb{R}^n$ 的 Gaussian 宽度为 $w(\mathbb{T}) = \mathrm{E}\big[\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{t}\rangle\big]$，Gaussian 复杂度为 $\gamma(\mathbb{T}) = \mathrm{E}\big[\sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t}\rangle|\big]$。证明：对于任意的 $\boldsymbol{y} \in \mathbb{T}$，

$$\gamma(\mathbb{T}) \asymp w(\mathbb{T}) + \|\boldsymbol{y}\|_2。$$

注释 Gaussian 宽度 $w(\mathbb{T})$ 衡量的是集合的内在几何大小，满足平移不变性；

Gaussian 复杂度 $\gamma(\mathbb{T})$ 衡量的是集合的向量于 Gaussian 投影的最大绝对幅度，不满足平移不变性，其大小取决于集合离原点的距离。

证明 • 证明上界 $\gamma(\mathbb{T}) \lesssim w(\mathbb{T}) + \|\boldsymbol{y}\|_2$

设 $\boldsymbol{y} \in \mathbb{T}$，对于任意的 $\boldsymbol{t} \in \mathbb{T}$，将其分解为 $\boldsymbol{t} = (\boldsymbol{t} - \boldsymbol{y}) + \boldsymbol{y}$，根据 Gaussian 复杂度的定义，可得

$$\begin{aligned}
\gamma(\mathbb{T}) &= \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t}\rangle|\right] \\
&= \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t} - \boldsymbol{y}\rangle + \langle \boldsymbol{g}, \boldsymbol{y}\rangle|\right] \\
&\leqslant \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} (|\langle \boldsymbol{g}, \boldsymbol{t} - \boldsymbol{y}\rangle| + |\langle \boldsymbol{g}, \boldsymbol{y}\rangle|)\right] \\
&= \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t} - \boldsymbol{y}\rangle|\right] + \mathrm{E}[|\langle \boldsymbol{g}, \boldsymbol{y}\rangle|]。
\end{aligned}$$

对于第二项，由于 $\langle \boldsymbol{g}, \boldsymbol{y}\rangle \sim N(0, \|\boldsymbol{y}\|_2^2)$，因此

$$\mathrm{E}[|\langle \boldsymbol{g}, \boldsymbol{y}\rangle|] = \sqrt{\frac{2}{\pi}} \|\boldsymbol{y}\|_2。$$

对于第一项，设 $\mathbb{T}' = \mathbb{T} - \boldsymbol{y}$，则 $\boldsymbol{0} \in \mathbb{T}'$ (由 $\boldsymbol{y} \in \mathbb{T}$)，因此 (对于包含原点的集合，内积的上确界必然是非负的)

$$\sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle \boldsymbol{g}, \boldsymbol{t}'\rangle, \sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle -\boldsymbol{g}, \boldsymbol{t}'\rangle \geqslant 0,$$

从而

$$\begin{aligned}
\sup_{\boldsymbol{t}'\in\mathbb{T}'} |\langle \boldsymbol{g}, \boldsymbol{t}'\rangle| &= \max\left(\sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle \boldsymbol{g}, \boldsymbol{t}'\rangle, \sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle -\boldsymbol{g}, \boldsymbol{t}'\rangle\right) \\
&\leqslant \sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle \boldsymbol{g}, \boldsymbol{t}'\rangle + \sup_{\boldsymbol{t}'\in\mathbb{T}'} \langle -\boldsymbol{g}, \boldsymbol{t}'\rangle,
\end{aligned}$$

两侧取期望 (注意 $\boldsymbol{g} \overset{d}{=} -\boldsymbol{g}$)，之后根据 Gaussian 宽度的平移不变性 (Q7.15 (Gaussian 宽度的基本性质) (2))，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{t}'\in\mathbb{T}'} |\langle \boldsymbol{g}, \boldsymbol{t}'\rangle|\right] \leqslant w(\mathbb{T}') + w(\mathbb{T}') = 2w(\mathbb{T}') = 2w(\mathbb{T})。$$

如此，

$$\gamma(\mathbb{T}) \leqslant 2w(\mathbb{T}) + \sqrt{\frac{2}{\pi}} \|\boldsymbol{y}\|_2 \leqslant 2(w(\mathbb{T}) + \|\boldsymbol{y}\|_2)。$$

• 证明下界 $w(\mathbb{T}) + \|\boldsymbol{y}\|_2 \lesssim \gamma(\mathbb{T})$

对于第一项，容易知道，

$$\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{t}\rangle \leqslant \sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t}\rangle|,$$

两侧取期望，

$$w(\mathbb{T}) \leqslant \gamma(\mathbb{T})。$$

对于第二项，容易知道，

$$\sup_{\boldsymbol{t}\in\mathbb{T}} |\langle \boldsymbol{g}, \boldsymbol{t}\rangle| \geqslant |\langle \boldsymbol{g}, \boldsymbol{y}\rangle|,$$

两侧取期望，

$$\gamma(\mathbb{T}) \geqslant \mathrm{E}[|\langle \boldsymbol{g}, \boldsymbol{y}\rangle|] = \sqrt{\frac{2}{\pi}}\|\boldsymbol{y}\|_2,$$

$$\|\boldsymbol{y}\|_2 \leqslant \sqrt{\frac{\pi}{2}}\gamma(\mathbb{T})。$$

如此，

$$w(\mathbb{T}) + \|\boldsymbol{y}\|_2 \leqslant \gamma(\mathbb{T}) + \sqrt{\frac{\pi}{2}}\gamma(\mathbb{T}) = \left(1 + \sqrt{\frac{\pi}{2}}\right)\gamma(\mathbb{T})。$$

21 [**有效维度, 代数维度**] 我们在定义 D7.5.12 (有效维数) 引入有限集合 $\mathbb{T} \subset \mathbb{R}^n$ 的有效维度的概念，

$$d(\mathbb{T}) = \left(\frac{w(\mathbb{T})}{\sup_{\boldsymbol{t}\in\mathbb{T}} \|\boldsymbol{t}\|_2}\right)^2,$$

(1) 证明：有效维度总是被线性代数维度所控制，即

$$d(\mathbb{T}) \leqslant \dim(\mathbb{T})。$$

(2) 证明：当 $\mathbb{T} \subset \mathbb{R}^n$ 为线性子空间的 Euclidean 球时，上述不等式取等 (在渐近等价的意义下)。

证明 (1) 设 $\dim(\mathbb{T}) = k$，则存在 k 维线性子空间 V，满足 $\mathbb{T} \subset V \subset \mathbb{R}^n$。

设 $\boldsymbol{P}$ 为从 $\mathbb{R}^n$ 向 V 的正交投影矩阵，满足对于任意的 $\boldsymbol{t} \in \mathbb{T}$，$\boldsymbol{P}\boldsymbol{t} = \boldsymbol{t}$。

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则 $\mathbb{T}$ 的 Gaussian 宽度为

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{t}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{P}\boldsymbol{t}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{P}\boldsymbol{g}, \boldsymbol{t}\rangle\right]。$$

利用 Cauchy 不等式，可得

$$\langle \boldsymbol{P}\boldsymbol{g}, \boldsymbol{t}\rangle \leqslant \|\boldsymbol{P}\boldsymbol{g}\|_2 \|\boldsymbol{t}\|_2,$$

两侧取上确界，

$$\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{P}\boldsymbol{g}, \boldsymbol{t}\rangle \leqslant \|\boldsymbol{P}\boldsymbol{g}\|_2 \left(\sup_{\boldsymbol{t}\in\mathbb{T}} \|\boldsymbol{t}\|_2\right),$$

之后两侧取期望，

$$w(\mathbb{T}) \leqslant \mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2 \cdot \sup_{\boldsymbol{t}\in\mathbb{T}} \|\boldsymbol{t}\|_2,$$

之后只需计算 $\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2$。

利用 Jensen 不等式，可得

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2 \leqslant \sqrt{\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2^2},$$

其中

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2^2 = \mathrm{tr}(\mathrm{Cov}(\boldsymbol{P}\boldsymbol{g})) = \mathrm{tr}(\boldsymbol{P}\boldsymbol{I}_n\boldsymbol{P}^\top) = \mathrm{tr}(\boldsymbol{P}) = k,$$

将其代入，可得

$$w(\mathbb{T}) \leqslant \sqrt{k} \cdot \sup_{\boldsymbol{t}\in\mathbb{T}} \|\boldsymbol{t}\|_2。$$

因此

$$d(\mathbb{T}) = \left(\frac{w(\mathbb{T})}{\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{t}\|_2}\right)^2 \leqslant (\sqrt{k})^2 = k。$$

(2) 设 $\mathbb{T} = \{\boldsymbol{t} \in V : \|\boldsymbol{t}\|_2 \leqslant R\}$，则 $\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{t}\|_2 = R$。

$\mathbb{T}$ 的 Gaussian 宽度为

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{P}\boldsymbol{g}, \boldsymbol{t}\rangle\right],$$

其中当 $\boldsymbol{t}, \boldsymbol{P}\boldsymbol{g}$ 的方向相同时，内积取得最大值，此时，长度为最大半径 R，

$$\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{P}\boldsymbol{g}, \boldsymbol{t}\rangle = \left\langle \boldsymbol{P}\boldsymbol{g}, R\frac{\boldsymbol{P}\boldsymbol{g}}{\|\boldsymbol{P}\boldsymbol{g}\|_2}\right\rangle = R\|\boldsymbol{P}\boldsymbol{g}\|_2,$$

两侧取期望，

$$w(\mathbb{T}) = R\cdot \mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2,$$

有效维度 $d(\mathbb{T})$ 为

$$d(\mathbb{T}) = \left(\frac{w(\mathbb{T})}{\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{t}\|_2}\right)^2 = \left(\frac{R\cdot \mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2}{R}\right)^2 = (\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2)^2,$$

注意到 $\boldsymbol{P}\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_k)$，根据习题 Q7.12 (Gaussian 向量的范数)，可得

$$(\mathrm{E}\|\boldsymbol{P}\boldsymbol{g}\|_2)^2 \sim k - \frac{1}{2} + O(k^{-1}),$$

因此

$$d(\mathbb{T}) \asymp k = \dim(\mathbb{T})。$$

22 [**有限集合的有效维度**] 设有限集合 $\mathbb{T} \subset \mathbb{R}^n$，证明：

$$d(\mathbb{T}) \leqslant C\ln|\mathbb{T}|。 \qquad (C > 0)$$

证明 • 提取最大范数

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则 $\mathbb{T}$ 的 Gaussian 宽度为

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle\right]。$$

令 $X_{\boldsymbol{t}} = \langle \boldsymbol{g}, \boldsymbol{t}\rangle$ 为零均值 Gaussian 随机变量，则其方差为

$$\mathrm{Var}(X_{\boldsymbol{t}}) = \mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{t}\rangle^2] = \|\boldsymbol{t}\|_2^2,$$

记 $R = \max_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{t}\|_2$，则 $X_{\boldsymbol{t}} \sim N(0, \sigma_{\boldsymbol{t}}^2)$，其中 $\sigma_{\boldsymbol{t}} \leqslant R$。若 $R = 0$，则 $\mathbb{T} = \{\boldsymbol{0}\}$，则结论是平凡的；之后只需考虑 $R > 0$ 的情况。

• 利用矩母函数, 并集界求极大值的期望

对于任意的 $\lambda > 0$，

$$\begin{aligned}\exp(\lambda \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} X_{\boldsymbol{t}}\right]) &\leqslant \mathrm{E}\left[\exp\left(\lambda \sup_{\boldsymbol{t}\in\mathbb{T}} X_{\boldsymbol{t}}\right)\right] = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\exp(\lambda X_{\boldsymbol{t}})\right] \\ &\leqslant \mathrm{E}\left[\sum_{\boldsymbol{t}\in\mathbb{T}}\exp(\lambda X_{\boldsymbol{t}})\right] = \sum_{\boldsymbol{t}\in\mathbb{T}}\mathrm{E}[\exp(\lambda X_{\boldsymbol{t}})] \\ &\leqslant \sum_{\boldsymbol{t}\in\mathbb{T}}\exp\left(\frac{\lambda^2 R^2}{2}\right) = |\mathbb{T}|\exp\left(\frac{\lambda^2 R^2}{2}\right),\end{aligned}$$

两侧取对数，之后除以 λ，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} X_{\boldsymbol{t}}\right] \leqslant \frac{\ln|\mathbb{T}|}{\lambda} + \frac{\lambda R^2}{2},$$

右侧的最优参数为 $\lambda_0=\frac{\sqrt{2\ln|\mathbb{T}|}}{R}$，将其代入，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}X_{\boldsymbol{t}}\right]\leqslant\frac{\ln|\mathbb{T}|}{\frac{\sqrt{2\ln|\mathbb{T}|}}{R}}+\frac{\frac{\sqrt{2\ln|\mathbb{T}|}}{R}\cdot R^2}{2}=\frac{R}{\sqrt{2}}\sqrt{\ln|\mathbb{T}|}+\frac{R}{\sqrt{2}}\sqrt{\ln|\mathbb{T}|}=\sqrt{2}R\sqrt{\ln|\mathbb{T}|},$$

(此处假设 $|\mathbb{T}|\geqslant 2$；若 $|\mathbb{T}|=1$，则 $\ln|\mathbb{T}|=0$，此时 $w(\mathbb{T})=\mathrm{E}[\langle\boldsymbol{g},\boldsymbol{t}\rangle]=0$，容易知道，上式成立。)

将其代入，可得

$$w(\mathbb{T})\leqslant\sqrt{2}R\sqrt{\ln|\mathbb{T}|},$$

因此

$$d(\mathbb{T})=\left(\frac{w(\mathbb{T})}{\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{t}\|_2}\right)^2=\left(\frac{w(\mathbb{T})}{R}\right)^2\leqslant\left(\frac{\sqrt{2}R\sqrt{\ln|\mathbb{T}|}}{R}\right)^2=2\ln|\mathbb{T}|,$$

此时令 $C=2$。

23 [**椭球体的 Gaussian 宽度，有效维度**] 椭球体是对 $\mathbb{B}_2^n$ 施加矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的线性变换像，即集合 $\boldsymbol{A}(\mathbb{B}_2^n)$。证明关于此椭球体的以下性质：

(1) (Gaussian 宽度) $\boldsymbol{A}(\mathbb{B}_2^n)$ 的 Gaussian 宽度渐近等价于 $\boldsymbol{A}$ 的 Frobenius 范数，即

$$w(\boldsymbol{A}(\mathbb{B}_2^n))\asymp\|\boldsymbol{A}\|_F。$$

(2) (有效维度) $\boldsymbol{A}(\mathbb{B}_2^n)$ 的有效维度在渐近意义下恰好等于 $\boldsymbol{A}^\top\boldsymbol{A}$ 的有效秩 (即 $\boldsymbol{A}$ 的稳定秩)，

$$d(\boldsymbol{A}(\mathbb{B}_2^n))\asymp r(\boldsymbol{A}^\top\boldsymbol{A})=s(\boldsymbol{A})。$$

其中有效维度, 稳定秩分别定义为

$$d(\mathbb{T})\asymp\frac{w(\mathbb{T})^2}{\operatorname{diam}(\mathbb{T})^2},\quad s(\boldsymbol{A})=\frac{\|\boldsymbol{A}\|_F^2}{\|\boldsymbol{A}\|^2}。$$

注释 **引理** (Gaussian 二次型的矩等价性 / Kahane-Khintchine 不等式的特例) 设 $\boldsymbol{M}\in\mathbb{R}^{m\times n}$，$\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则

$$\mathrm{E}\|\boldsymbol{M}\boldsymbol{g}\|_2\geqslant c\sqrt{\mathrm{E}\|\boldsymbol{M}\boldsymbol{g}\|_2^2}。\qquad(c>0)$$

(证明过程与习题 Q7.17 (ℓ^p 球的 Gaussian 宽度) 的情况 b. 的下界证明类似。)

令 $S=\|\boldsymbol{M}\boldsymbol{g}\|_2^2=\boldsymbol{g}^\top\boldsymbol{M}^\top\boldsymbol{M}\boldsymbol{g}$，注意到 $\boldsymbol{M}^\top\boldsymbol{M}$ 为对称半正定矩阵，将其进行正交分解 $\boldsymbol{M}^\top\boldsymbol{M}=\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^\top$，其中 $\boldsymbol{U}$ 为正交矩阵，$\boldsymbol{\Lambda}=\operatorname{diag}(\lambda_1,\cdots,\lambda_n)$ 为特征值矩阵，可得

$$S=\boldsymbol{g}^\top\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^\top\boldsymbol{g}=(\boldsymbol{U}^\top\boldsymbol{g})^\top\boldsymbol{\Lambda}(\boldsymbol{U}^\top\boldsymbol{g}),$$

根据 Gaussian 分布的旋转不变性，可得 $\tilde{\boldsymbol{g}}=\boldsymbol{U}^\top\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I})$，因此

$$S=\sum_{i=1}^n\lambda_i\tilde{g}_i^2,$$

从而 S 的数字特征为

$$\mathrm{E}[S]=\sum_{i=1}^n\lambda_i\mathrm{E}[\tilde{g}_i^2]=\sum_{i=1}^n\lambda_i,$$

$$\operatorname{Var}(S)=\sum_{i=1}^n\lambda_i^2\operatorname{Var}(\tilde{g}_i^2)=2\sum_{i=1}^n\lambda_i^2,$$

$$\mathrm{E}[S^2]=\operatorname{Var}(S)+(\mathrm{E}[S])^2=2\sum_{i=1}^n\lambda_i^2+\left(\sum_{i=1}^n\lambda_i\right)^2。$$

利用 Paley-Zygmund 不等式，可得对于任意的 $\theta\in(0,1)$，

$$\mathrm{P}\{S>\theta\mathrm{E}[S]\}\geqslant(1-\theta)^2\frac{(\mathrm{E}[S])^2}{\mathrm{E}[\mathbb{S}^2]},$$

其中

$$\frac{\mathrm{E}[S^2]}{(\mathrm{E}[S])^2}=\frac{2\sum_{i=1}^n\lambda_i^2+\left(\sum_{i=1}^n\lambda_i\right)^2}{\left(\sum_{i=1}^n\lambda_i\right)^2}=2\frac{\sum_{i=1}^n\lambda_i^2}{\left(\sum_{i=1}^n\lambda_i\right)^2}+1\leqslant 2\cdot 1+1=3,$$

将其代入，可得

$$\mathrm{P}\{S>\theta\mathrm{E}[S]\}\geqslant\frac{1}{3}(1-\theta)^2,$$

之后令 $\theta=1/2$，可得

$$\mathrm{P}\left\{S>\frac{1}{2}\mathrm{E}[S]\right\}\geqslant\left(1-\frac{1}{2}\right)^2\cdot\frac{1}{3}=\frac{1}{12}。$$

将上述高概率事件转化为 $\mathrm{E}[\sqrt{S}]$ 的下界，

$$\begin{aligned}\mathrm{E}[\sqrt{S}]&\geqslant\mathrm{E}\left[\sqrt{S}\cdot\mathbf{1}_{\{S>\frac{1}{2}\mathrm{E}[S]\}}\right]\\&\geqslant\sqrt{\frac{1}{2}\mathrm{E}[S]}\cdot\mathrm{P}\left\{S>\frac{1}{2}\mathrm{E}[S]\right\}\\&\geqslant\sqrt{\frac{1}{2}\mathrm{E}[S]}\cdot\frac{1}{12}=\frac{1}{12\sqrt{2}}\sqrt{\mathrm{E}[S]}。\end{aligned}$$

即

$$\mathrm{E}\|\boldsymbol{M}\boldsymbol{g}\|_2\geqslant\frac{1}{12\sqrt{2}}\sqrt{\mathrm{E}\|\boldsymbol{M}\boldsymbol{g}\|_2^2}。$$

证明 (1) 令 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$。根据 Gaussian 宽度的定义，可得

$$w(\boldsymbol{A}(\mathbb{B}_2^n))=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{B}_2^n}\langle\boldsymbol{g},\boldsymbol{A}\boldsymbol{x}\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{B}_2^n}\langle\boldsymbol{A}^\top\boldsymbol{g},\boldsymbol{x}\rangle\right]=\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2。$$

容易验证

$$\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2^2=\mathrm{tr}(\boldsymbol{A}\boldsymbol{A}^\top)=\|\boldsymbol{A}\|_F^2。$$

对于上界，利用 Jensen 不等式，可得

$$\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2\leqslant\sqrt{\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2^2}=\sqrt{\|\boldsymbol{A}\|_F^2}=\|\boldsymbol{A}\|_F。$$

对于下界，根据 Gaussian 二次型的矩等价性，可得

$$\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2\geqslant c\|\boldsymbol{A}\|_F。$$

如此，

$$\mathrm{E}\|\boldsymbol{A}^\top\boldsymbol{g}\|_2\geqslant c\|\boldsymbol{A}\|_F。$$

(2) 对于分子，利用 (1) 的结论，可得

$$w(\boldsymbol{A}(\mathbb{B}_2^n))^2\asymp\|\boldsymbol{A}\|_F^2。$$

对于分母，由于线性变换之后的椭球体为关于原点对称的凸体，因此其直径由距离原点最远的点决定，即

$$\mathrm{diam}(\boldsymbol{A}(\mathbb{B}_2^n))=2\sup_{\boldsymbol{x}\in\mathbb{B}_2^n}\|\boldsymbol{A}\boldsymbol{x}\|_2=2\|\boldsymbol{A}\|。$$

如此，

$$d(\boldsymbol{A}(\mathbb{B}_2^n))\asymp\frac{w(\boldsymbol{A}(\mathbb{B}_2^n))^2}{\mathrm{diam}(\boldsymbol{A}(\mathbb{B}_2^n))^2}\asymp\frac{\|\boldsymbol{A}\|_F^2}{\|\boldsymbol{A}\|^2}=s(\boldsymbol{A})。$$

之后令 $\boldsymbol{\Sigma}=\boldsymbol{A}^\top\boldsymbol{A}$，可得其有效秩为

$$r(\boldsymbol{\Sigma})=\frac{\mathrm{tr}(\boldsymbol{\Sigma})}{\|\boldsymbol{\Sigma}\|},$$

$\|\boldsymbol{A}^\top\boldsymbol{A}\|=\|\boldsymbol{A}\|^2$，则

$$d(\boldsymbol{A}(\mathbb{B}_2^n))\asymp s(\boldsymbol{A})=r(\boldsymbol{A}^\top\boldsymbol{A}),$$

因此

$$d(\boldsymbol{A}(\mathbb{B}_2^n)) \asymp r(\boldsymbol{A}^\top \boldsymbol{A}) = s(\boldsymbol{A})。$$

24 [于球面对随机向量进行建模] 设 $1 \leqslant m \leqslant n$，$\boldsymbol{z} \in \mathbb{S}^{m-1}$，$\boldsymbol{U} \sim U(O(n))$ 为均匀分布于 n 维正交群 $O(n)$ 的随机正交矩阵 (即为 Haar 测度)。

设 $\boldsymbol{B} \in \mathbb{R}^{n\times m}$，其由 $\boldsymbol{U}$ 的前 m 列构成。证明：

$$\boldsymbol{B}\boldsymbol{z} \sim U(\mathbb{S}^{n-1})。$$

证明 (考虑利用维度填充 (Padding) 技巧，将其直接转化为正交群 Haar 测度的基本性质来证明。)

- 维度填充

  设随机正交矩阵 $\boldsymbol{U}$ 的列向量为 $\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_n$，则 $\boldsymbol{B} = (\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_m)$，可得

  $$\boldsymbol{B}\boldsymbol{z} = z_1\boldsymbol{u}_1 + z_2\boldsymbol{u}_2 + \cdots + z_m\boldsymbol{u}_m$$

  构造填充值后固定向量 $\tilde{\boldsymbol{z}}$ 为

  $$\tilde{\boldsymbol{z}} = \begin{pmatrix} z_1 \\ \vdots \\ z_m \\ 0 \\ \vdots \\ 0 \end{pmatrix} \in \mathbb{S}^{n-1},$$

  则

  $$\boldsymbol{U}\tilde{\boldsymbol{z}} = (\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_n)\begin{pmatrix} z_1 \\ \vdots \\ z_m \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \sum_{i=1}^{m} z_i\boldsymbol{u}_i + \sum_{j=m+1}^{n} 0 \cdot \boldsymbol{u}_j = \boldsymbol{B}\boldsymbol{z},$$

  之后只需证明 $\boldsymbol{x} = \boldsymbol{U}\tilde{\boldsymbol{z}} \sim U(\mathbb{S}^{n-1})$。

- 利用正交群的旋转不变性

  (若 $\operatorname{supp}(\boldsymbol{x}) \subset \mathbb{S}^{n-1}$，其分布对于任意的正交变换 (旋转或反射) 均保持不变，则 $x \sim U(\mathbb{S}^{n-1})$。)

  由于

  $$\|\boldsymbol{x}\|_2^2 = \|\boldsymbol{U}\tilde{\boldsymbol{z}}\|_2^2 = (\boldsymbol{U}\tilde{\boldsymbol{z}})^\top(\boldsymbol{U}\tilde{\boldsymbol{z}}) = \tilde{\boldsymbol{z}}^\top\boldsymbol{U}^\top\boldsymbol{U}\tilde{\boldsymbol{z}} = \tilde{\boldsymbol{z}}^\top\boldsymbol{I}_n\tilde{\boldsymbol{z}} = \|\tilde{\boldsymbol{z}}\|_2^2 = 1,$$

  因此 $\boldsymbol{x} \in \mathbb{S}^{n-1}$。

  设 $\boldsymbol{V} \in O(n)$ 为固定的正交矩阵，则 $\boldsymbol{V}\boldsymbol{x} \overset{d}{=} \boldsymbol{x}$，因此

  $$\boldsymbol{V}\boldsymbol{x} = \boldsymbol{V}(\boldsymbol{U}\tilde{\boldsymbol{z}}) = (\boldsymbol{V}\boldsymbol{U})\tilde{\boldsymbol{z}} \overset{d}{=} \boldsymbol{U}\tilde{\boldsymbol{z}} = \boldsymbol{x}。$$

  如此，$\boldsymbol{B}\boldsymbol{z} = \boldsymbol{x} \sim U(\mathbb{S}^{n-1})$。

注释 本题介绍了一种生成球面均匀分布随机向量的高效采样算法。即使仅利用高维空间的部分旋转变换 $\boldsymbol{B}$，只要将其作用于相应维度的固定单位向量，所生成的随机向量于全空间依然严格保持各向同性。

25 [集合的 Gaussian 投影] 设 $\boldsymbol{G} \in \mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。

证明定理 T7.6.1 (集合的随机投影的大小) 的一个版本：对于集合 $\mathbb{T} \subset \mathbb{R}^n$，直径的期望满足 Chevet 型不等式的渐近等价关系，

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})] \asymp w(\mathbb{T}) + \sqrt{m}\operatorname{diam}(\mathbb{T})。$$

- 定义差集 $\mathbb{T}' = \mathbb{T} - \mathbb{T} = \{\boldsymbol{x} - \boldsymbol{y} : \boldsymbol{x}, \boldsymbol{y} \in \mathbb{T}\}$，则投影之后的直径为

  $$\operatorname{diam}(\boldsymbol{G}\mathbb{T}) = \sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}} \|\boldsymbol{G}\boldsymbol{x} - \boldsymbol{G}\boldsymbol{y}\|_2 = \sup_{\boldsymbol{v}\in\mathbb{T}'} \|\boldsymbol{G}\boldsymbol{v}\|_2,$$

差集的直径即为原直径，

$$\sup_{\boldsymbol{v}\in\mathbb{T}'}\|\boldsymbol{v}\|_2=\operatorname{diam}(\mathbb{T})=D,$$

差集的 Gaussian 宽度为原 Gaussian 宽度的 2 倍，

$$w(\mathbb{T}')=\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}-\boldsymbol{y}\rangle\right]=2w(\mathbb{T})。$$

- 证明上界 $\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]\lesssim w(\mathbb{T})+\sqrt{m}\operatorname{diam}(\mathbb{T})$

  对于

  $$\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]=\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\|\boldsymbol{G}\boldsymbol{v}\|_2\right]=\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{m-1}}\langle\boldsymbol{G}\boldsymbol{v},\boldsymbol{w}\rangle\right],$$

  定义目标 Gaussian 过程 $X_{\boldsymbol{v},\boldsymbol{w}}=\langle\boldsymbol{G}\boldsymbol{v},\boldsymbol{w}\rangle$，比较 Gaussian 过程 $Y_{\boldsymbol{v},\boldsymbol{w}}=\langle\boldsymbol{g},\boldsymbol{v}\rangle+D\langle\boldsymbol{h},\boldsymbol{w}\rangle$，其中 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$, $\boldsymbol{h}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$ 相互独立，则

  $$\begin{aligned}\mathrm{E}[(X_{\boldsymbol{v},\boldsymbol{w}}-X_{\boldsymbol{v}',\boldsymbol{w}'})^2]&=\mathrm{E}[(\langle\boldsymbol{G}\boldsymbol{v},\boldsymbol{w}\rangle-\langle\boldsymbol{G}\boldsymbol{v}',\boldsymbol{w}'\rangle)^2]\\&=\|\boldsymbol{w}\boldsymbol{v}^\top-\boldsymbol{w}'\boldsymbol{v}'^\top\|_F^2\\&=\|\boldsymbol{v}\|_2^2\|\boldsymbol{w}\|_2^2+\|\boldsymbol{v}'\|_2^2\|\boldsymbol{w}'\|_2^2-2\langle\boldsymbol{v},\boldsymbol{v}'\rangle\langle\boldsymbol{w},\boldsymbol{w}'\rangle\\&=\|\boldsymbol{v}\|_2^2+\|\boldsymbol{v}'\|_2^2-2\langle\boldsymbol{v},\boldsymbol{v}'\rangle\langle\boldsymbol{w},\boldsymbol{w}'\rangle,\\\mathrm{E}[(Y_{\boldsymbol{v},\boldsymbol{w}}-Y_{\boldsymbol{v}',\boldsymbol{w}'})^2]&=\mathrm{E}[\langle\boldsymbol{g},\boldsymbol{v}-\boldsymbol{v}'\rangle^2]+D^2\mathrm{E}[\langle\boldsymbol{h},\boldsymbol{w}-\boldsymbol{w}'\rangle^2]\\&=\|\boldsymbol{v}-\boldsymbol{v}'\|_2^2+D^2\|\boldsymbol{w}-\boldsymbol{w}'\|_2^2\\&=\|\boldsymbol{v}\|_2^2+\|\boldsymbol{v}'\|_2^2-2\langle\boldsymbol{v},\boldsymbol{v}'\rangle+2D^2-2D^2\langle\boldsymbol{w},\boldsymbol{w}'\rangle,\end{aligned}$$

  因此

  $$\begin{aligned}\mathrm{E}[(Y_{\boldsymbol{v},\boldsymbol{w}}-Y_{\boldsymbol{v}',\boldsymbol{w}'})^2]-\mathrm{E}[(X_{\boldsymbol{v},\boldsymbol{w}}-X_{\boldsymbol{v}',\boldsymbol{w}'})^2]&=2D^2-2D^2\langle\boldsymbol{w},\boldsymbol{w}'\rangle-2\langle\boldsymbol{v},\boldsymbol{v}'\rangle+2\langle\boldsymbol{v},\boldsymbol{v}'\rangle\langle\boldsymbol{w},\boldsymbol{w}'\rangle\\&=2(D^2-\langle\boldsymbol{v},\boldsymbol{v}'\rangle)(1-\langle\boldsymbol{w},\boldsymbol{w}'\rangle),\end{aligned}$$

  其中 $\langle\boldsymbol{v},\boldsymbol{v}'\rangle\leqslant\|\boldsymbol{v}\|_2\|\boldsymbol{v}'\|_2\leqslant D^2$，$\langle\boldsymbol{w},\boldsymbol{w}'\rangle\leqslant 1$，将其代入，可得

  $$\mathrm{E}[(Y_{\boldsymbol{v},\boldsymbol{w}}-Y_{\boldsymbol{v}',\boldsymbol{w}'})^2]-\mathrm{E}[(X_{\boldsymbol{v},\boldsymbol{w}}-X_{\boldsymbol{v}',\boldsymbol{w}'})^2]\geqslant 0,$$

  从而 Sudakov-Fernique 条件满足。

  利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，可得

  $$\begin{aligned}\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]&\leqslant\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}',\boldsymbol{w}\in\mathbb{S}^{m-1}}Y_{\boldsymbol{v},\boldsymbol{w}}\right]\\&=\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{g},\boldsymbol{v}\rangle\right]+D\cdot\mathrm{E}\left[\sup_{\boldsymbol{w}\in\mathbb{S}^{m-1}}\langle\boldsymbol{h},\boldsymbol{w}\rangle\right]\\&=w(\mathbb{T}')+\operatorname{diam}(\mathbb{T})\cdot\mathrm{E}\|\boldsymbol{h}\|_2\\&\leqslant 2w(\mathbb{T})+\sqrt{m}\operatorname{diam}(\mathbb{T})\\&\lesssim w(\mathbb{T})+\sqrt{m}\operatorname{diam}(\mathbb{T})。\end{aligned}$$

- 证明下界 $\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]\gtrsim w(\mathbb{T})+\sqrt{m}\operatorname{diam}(\mathbb{T})$

  (由于右侧两项均非负，因此只需分别证明它大于 $w(\mathbb{T}),\sqrt{m}\operatorname{diam}(\mathbb{T})$ 即可。)

  首先证明大于 $w(\mathbb{T})$，令 $\boldsymbol{e}_1=(1,0,\cdots,0)^\top\in\mathbb{R}^m$，则

  $$\operatorname{diam}(\boldsymbol{G}\mathbb{T})=\sup_{\boldsymbol{v}\in\mathbb{T}'}\|\boldsymbol{G}\boldsymbol{v}\|_2\geqslant\sup_{\boldsymbol{v}\in\mathbb{T}'}|\langle\boldsymbol{G}\boldsymbol{v},\boldsymbol{e}_1\rangle|\geqslant\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{G}^\top\boldsymbol{e}_1,\boldsymbol{v}\rangle=\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{g}_1,\boldsymbol{v}\rangle,$$

  两侧取期望，

  $$\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]\geqslant\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{g}_1,\boldsymbol{v}\rangle\right]=w(\mathbb{T}')=2w(\mathbb{T})\gtrsim w(\mathbb{T})。$$

之后证明大于 $\sqrt{m}\operatorname{diam}(\mathbb{T})$，考虑集合的距离最远的一对点，即存在 $\boldsymbol{v}_0 \in \mathbb{T}'$，使得 $\|\boldsymbol{v}_0\|_2 = \operatorname{diam}(\mathbb{T})$，则

$$\operatorname{diam}(\boldsymbol{G}\mathbb{T}) = \sup_{\boldsymbol{v}\in\mathbb{T}'} \|\boldsymbol{G}\boldsymbol{v}\|_2 \geqslant \|\boldsymbol{G}\boldsymbol{v}_0\|_2。$$

由于 $\boldsymbol{G}$ 的各行是相互独立的，因此 $\boldsymbol{G}\boldsymbol{v}_0 \in \mathbb{R}^m$ 的分量服从 $N(0, \|\boldsymbol{v}_0\|_2^2)$，从而

$$\boldsymbol{G}\boldsymbol{v}_0 \overset{d}{=} \|\boldsymbol{v}_0\|_2 \boldsymbol{h},$$

其中 $\boldsymbol{h} \sim N(\boldsymbol{0}, \boldsymbol{I}_m)$，两侧取期望，

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})] \geqslant \mathrm{E}\|\boldsymbol{G}\boldsymbol{v}_0\|_2 = \|\boldsymbol{v}_0\|_2 \mathrm{E}\|\boldsymbol{h}\|_2 = \operatorname{diam}(\mathbb{T})\mathrm{E}\|\boldsymbol{h}\|_2 \asymp \sqrt{m}\operatorname{diam}(\mathbb{T})。$$

26 [**集合的随机投影：下界**] 设集合 $\mathbb{T} \subset \mathbb{R}^n$，$\boldsymbol{P}$ 为从 $\mathbb{R}^n$ 向随机 m 维子空间 $E \sim U(G_{n,m})$ 的正交投影矩阵，其中 $U(G_{n,m})$ 表示 Grassmann 流形 $G_{n,m}$ 的均匀分布。证明：

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})] \geqslant c\left[w_s(\mathbb{T}) + \sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T})\right]。$$

$$w_s(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}} \langle \boldsymbol{\theta}, \boldsymbol{t}\rangle\right]。 \qquad (\boldsymbol{\theta} \sim U(\mathbb{S}^{n-1}))$$

注释 上题的 Gaussian 投影是非保范数的，会拉伸空间；本题的正交投影是保范数的，投影之后的直径天然不可能超过原直径。

证明 定义差集 $\mathbb{T}' = \mathbb{T} - \mathbb{T}$，其直径 $\operatorname{diam}(\mathbb{T}') = \operatorname{diam}(\mathbb{T})$，则投影之后的直径为

$$\operatorname{diam}(\boldsymbol{P}\mathbb{T}) = \sup_{\boldsymbol{v}\in\mathbb{T}'} \|\boldsymbol{P}\boldsymbol{v}\|_2。$$

- 证明 $\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})] \gtrsim \sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T})$

  考虑集合的距离最远的一对点，即存在 $\boldsymbol{v}_0 \in \mathbb{T}'$，使得 $\|\boldsymbol{v}_0\|_2 = \operatorname{diam}(\mathbb{T})$，则

  $$\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})] = \mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'} \|\boldsymbol{P}\boldsymbol{v}\|_2\right] \geqslant \mathrm{E}\|\boldsymbol{P}\boldsymbol{v}_0\|_2,$$

  设 $\boldsymbol{h}_1, \cdots, \boldsymbol{h}_m$ 是随机子空间 E 的一组随机标准正交基，则

  $$\|\boldsymbol{P}\boldsymbol{v}_0\|_2^2 = \sum_{i=1}^m \langle \boldsymbol{v}_0, \boldsymbol{h}_i\rangle^2$$

  两侧取期望，

  $$\mathrm{E}\|\boldsymbol{P}\boldsymbol{v}_0\|_2^2 = \sum_{i=1}^m \mathrm{E}[\langle \boldsymbol{v}_0, \boldsymbol{h}_i\rangle^2] = m \cdot \mathrm{E}[\langle \boldsymbol{v}_0, \boldsymbol{h}_1\rangle^2],$$

  其中 $\boldsymbol{h}_1 \sim U(\mathbb{S}^{n-1})$，满足

  $$\mathrm{E}[\langle \boldsymbol{v}_0, \boldsymbol{h}_1\rangle^2] = \frac{\|\boldsymbol{v}_0\|_2^2}{n},$$

  将其代入，可得

  $$\mathrm{E}\|\boldsymbol{P}\boldsymbol{v}_0\|_2^2 = \frac{m}{n}\|\boldsymbol{v}_0\|_2^2 = \frac{m}{n}\operatorname{diam}(\mathbb{T})^2。$$

  根据 Gaussian 二次型的矩等价性，可得

  $$\mathrm{E}\|\boldsymbol{P}\boldsymbol{v}_0\|_2 \geqslant c_1\sqrt{\mathrm{E}\|\boldsymbol{P}\boldsymbol{v}_0\|_2^2} \geqslant c_1\sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T})。$$

- 证明 $\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})] \gtrsim w_s(\mathbb{T})$

  (一个关键的概率等价：于随机子空间 E 随机抽取一个单位向量，等价于首先于全局 $\mathbb{S}^{n-1}$ 随机抽取一个向量，之后将其投影于 E，最后归一化。此方法称为随机子空间的随机方向。)

  对于

  $$\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})] = \mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'} \|\boldsymbol{P}\boldsymbol{v}\|_2\right] = \mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'} \sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E} \langle \boldsymbol{v}, \boldsymbol{w}\rangle\right],$$

(此处 sup 的范围为投影子空间 E 的单位球面。)

我们只需证明

$$\mathrm{E}_E\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\right]\geqslant c_2\mathrm{E}_{\boldsymbol{\theta}}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\theta}\rangle\right]。$$

由于

$$\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle=\|\boldsymbol{P}_E\boldsymbol{v}\|_2,$$

因此证明目标即为

$$\mathrm{E}_E\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\|\boldsymbol{P}_E\boldsymbol{v}\|_2\right]\geqslant\mathrm{E}_{\boldsymbol{\theta}}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\theta}\rangle\right]。$$

对于固定的 m 维子空间 E，随机抽取单位向量 $\boldsymbol{\varphi}\sim U(\mathbb{S}^{n-1}\cap E)$，则

$$\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\geqslant\langle\boldsymbol{v},\boldsymbol{\varphi}\rangle,$$

两侧对 $\boldsymbol{v}\in\mathbb{T}'$ 取上确界，

$$\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\geqslant\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\varphi}\rangle。$$

将 E 固定，对 $\boldsymbol{\varphi}$ 取条件期望，

$$\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\geqslant\mathrm{E}_{\boldsymbol{\varphi}|E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\varphi}\rangle\right],$$

之后两侧对 $E\sim U(G_{n,m})$ 取期望，

$$\mathrm{E}_E\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\right]\geqslant\mathrm{E}_E\left[\mathrm{E}_{\boldsymbol{\varphi}|E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\varphi}\rangle\right]\right]。\tag{I}$$

对于 (I) 的右侧，注意到其为一个典型的两步随机生成过程：

1. 首先于 $\mathbb{R}^n$ 均匀随机地选取一个 m 维子空间 E；
2. 之后于子空间 E 均匀随机地选取单位方向 $\boldsymbol{\varphi}$；

因此根据正交群 $O(n)$ 作用的旋转不变性 (Haar 测度的高度对称性)，可得

$$\boldsymbol{\varphi}\overset{d}{=}\boldsymbol{\theta}\sim U(\mathbb{S}^{n-1}),$$

从而

$$\mathrm{E}_E\left[\mathrm{E}_{\boldsymbol{\varphi}|E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\varphi}\rangle\right]\right]=\mathrm{E}_{\boldsymbol{\theta}}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\theta}\rangle\right],$$

将其代入于 (I)，可得

$$\mathrm{E}_E\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\sup_{\boldsymbol{w}\in\mathbb{S}^{n-1}\cap E}\langle\boldsymbol{v},\boldsymbol{w}\rangle\right]\geqslant\mathrm{E}_{\boldsymbol{\theta}}\left[\sup_{\boldsymbol{v}\in\mathbb{T}'}\langle\boldsymbol{v},\boldsymbol{\theta}\rangle\right]。$$

如此，

$$\mathrm{E}[\mathrm{diam}(\boldsymbol{P}\mathbb{T})]\geqslant\max\left(c_1\sqrt{\frac{m}{n}}\,\mathrm{diam}(\mathbb{T}),2c_2w_s(\mathbb{T})\right)\geqslant c\left(w_s(\mathbb{T})+\sqrt{\frac{m}{n}}\,\mathrm{diam}(\mathbb{T})\right),\qquad\left(c=\frac{1}{2}\min(c_1,2c_2)\right)$$

27 [**矩阵草图**] 假设我们有一个非常大的 $n\times k$ 矩阵 $\boldsymbol{A}$。以下两种方法可以在不牺牲算子范数精度 (在渐近意义下) 的前提对其进行降维。

(1) (随机正交投影) 设 $\boldsymbol{P}$ 为从 $\mathbb{R}^n$ 到随机 m 维子空间的正交投影矩阵，此子空间于 Grassmann 流形 $G_{n,m}$ 均匀选取。证明：

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{A}\|\asymp\frac{1}{\sqrt{n}}\|\boldsymbol{A}\|_F+\sqrt{\frac{m}{n}}\|\boldsymbol{A}\|。$$

(2) (Gaussian 随机矩阵投影) 设 $\boldsymbol{G}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。请证明：

$$\mathrm{E}\|\boldsymbol{G}\boldsymbol{A}\|\asymp\|\boldsymbol{A}\|_F+\sqrt{m}\|\boldsymbol{A}\|。$$

注释 符号 $\asymp$ 表示两侧的值在忽略正的绝对常数倍数后是等价的。

证明 • 将矩阵范数转化为集合直径

设 $\mathbb{T}=\boldsymbol{A}(\mathbb{B}_2^k)$ 为 $\mathbb{R}^n$ 的椭球体集合，则对于任意的矩阵 $\boldsymbol{M}$，其算子范数为

$$\|\boldsymbol{M}\boldsymbol{A}\|=\sup_{\boldsymbol{x}\in\mathbb{B}_2^k}\|\boldsymbol{M}\boldsymbol{A}\boldsymbol{x}\|_2=\sup_{\boldsymbol{t}\in\mathbb{T}}\|\boldsymbol{M}\boldsymbol{t}\|_2。$$

由于 $\mathbb{T}$ 关于原点对称，因此其半径即为算子范数，其直径为半径的两倍，

$$\operatorname{diam}(\boldsymbol{M}\mathbb{T})=2\|\boldsymbol{M}\boldsymbol{A}\|。$$

(特别地，当 $\boldsymbol{M}=\boldsymbol{I}_n$ 时，$\operatorname{diam}(\mathbb{T})=2\|\boldsymbol{A}\|$。)

• 计算 Gaussian 宽度 $w(\mathbb{T})$, 球面宽度 $w_s(\mathbb{T})$

利用习题 Q7.23 (椭球体的 Gaussian 宽度, 有效维度) (1) 的结论，对于椭球体 $\mathbb{T}=\boldsymbol{A}(\mathbb{B}_2^k)$，其 Gaussian 宽度渐近等价于生成矩阵的 Frobenius 范数，

$$w(\mathbb{T})\asymp\|\boldsymbol{A}\|_F。$$

注意到 $\boldsymbol{g}\overset{d}{=}\|\boldsymbol{g}\|_2\boldsymbol{\theta}$，其中 $\|\boldsymbol{g}\|_2\perp\boldsymbol{\theta}\sim U(\mathbb{S}^{n-1})$，因此

$$\begin{aligned}w(\mathbb{T})&=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\|\boldsymbol{g}\|_2\boldsymbol{\theta},\boldsymbol{t}\rangle\right]\\&=\mathrm{E}\|\boldsymbol{g}\|_2\cdot\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{\theta},\boldsymbol{t}\rangle\right]=\mathrm{E}\|\boldsymbol{g}\|_2\cdot w_s(\mathbb{T}),\end{aligned}$$

即

$$w_s(\mathbb{T})=\frac{w(\mathbb{T})}{\mathrm{E}\|\boldsymbol{g}\|_2}\asymp\frac{\|\boldsymbol{A}\|_F}{\sqrt{n}}。$$

(1) 根据习题 Q9.8 (随机投影的集合大小), 习题 Q7.26 (集合的随机投影：下界)，可得

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})]\asymp w_s(\mathbb{T})+\sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T}),$$

即

$$2\mathrm{E}\|\boldsymbol{P}\boldsymbol{A}\|\asymp\frac{1}{\sqrt{n}}\|\boldsymbol{A}\|_F+\sqrt{\frac{m}{n}}(2\|\boldsymbol{A}\|)。$$

即

$$\mathrm{E}\|\boldsymbol{P}\boldsymbol{A}\|\asymp\frac{1}{\sqrt{n}}\|\boldsymbol{A}\|_F+\sqrt{\frac{m}{n}}\|\boldsymbol{A}\|。$$

• 根据习题 Q7.25 (集合的 Gaussian 投影)，可得

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{G}\mathbb{T})]\asymp w(\mathbb{T})+\sqrt{m}\operatorname{diam}(\mathbb{T}),$$

即

$$2\mathrm{E}\|\boldsymbol{G}\boldsymbol{A}\|\asymp\|\boldsymbol{A}\|_F+\sqrt{m}(2\|\boldsymbol{A}\|)。$$

即

$$\mathrm{E}\|\boldsymbol{G}\boldsymbol{A}\|\asymp\|\boldsymbol{A}\|_F+\sqrt{m}\|\boldsymbol{A}\|。$$

注释 对比 (1)(2)，可得 Gaussian 投影即正交投影于尺度放大了约 $\sqrt{n}$ 倍。由于 $\boldsymbol{P}$ 是正交投影 (保范数)，因此其期望范数受到严重压缩；但是 $\boldsymbol{G}$ 的各行都是期望长度 $\sqrt{n}$ 的独立 Gaussian 向量，它起到了拉伸的作用。于实际的降维算法，两种草图矩阵由于其良好的几何保距特性，均被广泛采用。

8 链化

要点梳理

Section 8.1 Dudley 不等式 Q8.1 ~ Q8.8

定义 8.1.1 (sub-Gaussian 增量)

称随机过程 $(X_t)_{t\in\mathbb{T}}$ 含有 sub-Gaussian 增量，若存在 $K\geqslant 0$，使得对于任意的 $t,s\in\mathbb{T}$，均满足 $\|X_t-X_s\|_{\psi_2}\leqslant Kd(t,s)$，其中 d 为 $\mathbb{T}$ 的度量。

定理 8.1.3 (Dudley 积分不等式)

设 $(X_t)_{t\in\mathbb{T}}$ 为关于度量 d 含有 sub-Gaussian 增量的随机过程，则

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant CK\int_0^{\operatorname{diam}(\mathbb{T})}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}d\varepsilon。$$

定理 8.1.4 (离散 Dudley 不等式)

设 $(X_t)_{t\in\mathbb{T}}$ 为有限集 $\mathbb{T}$ 含有 sub-Gaussian 增量的随机过程：$\|X_t-X_s\|_{\psi_2}\leqslant Kd(t,s)$，则

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant CK\sum_{k\geqslant 0}\delta_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\delta_k)},$$

其中 (δ_k) 为从 $\operatorname{diam}(\mathbb{T})/2$ 开始的几何递减尺度序列。

注记 8.1.6 (Dudley 不等式：高概率界)

链化实际上给出高概率界：设 $\mathbb{T}$ 为有限集，则对于任意的 $u\geqslant 0$，以高概率，

$$\sup_{t,s\in\mathbb{T}}|X_t-X_s|\leqslant CK\left(\int_0^{\operatorname{diam}(\mathbb{T})}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}d\varepsilon+u\cdot\operatorname{diam}(\mathbb{T})\right)\ (\text{w.p. } 1-2\exp(-u^2))。$$

注记 8.1.7 (Dudley 积分的极限)

虽然 Dudley 积分对 ε 从 0 积到 ∞，但可将其截断于 $\mathbb{T}$ 的直径：当 $\varepsilon>\operatorname{diam}(\mathbb{T})$ 时，单个 ε-球即可覆盖 $\mathbb{T}$，因此 $\ln\mathcal{N}(\mathbb{T},d,\varepsilon)=0$。因此积分上界可改为 $\operatorname{diam}(\mathbb{T})$。

定理 8.1.8 ($\mathbb{R}^n$ 的 Dudley 不等式)

设 $\mathbb{T}\subset\mathbb{R}^n$，则

$$\mathrm{E}\left[\sup_{x\in\mathbb{T}}\langle g,x\rangle\right]\leqslant C\int_0^{\mathrm{diam}(\mathbb{T})}\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)}d\varepsilon,$$

其中 $g\sim N(\mathbf{0},\boldsymbol{I}_n)$。

Section 8.2 经验过程 Q8.9 ~ Q8.11

定理 8.2.3 (Lipschitz 大数定律)

设 $\mathcal{F}$ 为 $\mathbb{R}^n$ 的 L-Lipschitz 函数的类，$X_1,\cdots,X_N$ 为独立同分布的随机向量，则

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{N}\sum_{i=1}^N f(X_i)-\mathrm{E}[f(X)]\right|\right]\leqslant CL\frac{w(\mathbb{T})}{\sqrt{N}},$$

其中 $\mathbb{T}=\{X_1,\cdots,X_N\}$ 为经验支撑集。

定义 8.2.5 (经验过程)

由函数类 $\mathcal{F}$ 索引的经验过程是随机变量族

$$\left(\frac{1}{\sqrt{N}}\sum_{i=1}^N(f(X_i)-\mathrm{E}[f(X)])\right)_{f\in\mathcal{F}},$$

其中 $X_1,\cdots,X_N$ 为独立同分布的随机变量。

Section 8.3 VC 维数 Q8.12 ~ Q8.24

定义 8.3.1 (VC 维数)

设 $\mathcal{F}$ 为集合 $\mathcal{X}$ 取值于 $\{0,1\}$ 的函数类。$\mathcal{F}$ 的 VC 维数，记作 $\mathrm{vc}(\mathcal{F})$，是最大的整数 n，使得存在 $x_1,\cdots,x_n\in\mathcal{X}$ 被 $\mathcal{F}$ 打散，即对于这些点的任意的二值标记，均存在 $f\in\mathcal{F}$ 与其匹配。若不存在此类最大的 n，则 $\mathrm{vc}(\mathcal{F})=\infty$。

例 8.3.5 (半空间)

$\mathbb{R}^n$ 的半空间为形如 $\{\boldsymbol{x}:\langle\boldsymbol{a},\boldsymbol{x}\rangle\leqslant b\}$ 的集合，其中 $\boldsymbol{a}\in\mathbb{R}^n,b\in\mathbb{R}$。设 $\mathcal{F}$ 为 $\mathbb{R}^n$ 的任意半空间的示性函数类，则 $\mathrm{vc}(\mathcal{F})=n+1$。

引理 8.3.7 (Pajor 引理)

对于取值于 $\{0,1\}$ 的 VC 类 $\mathcal{F}$，$\mathcal{F}$ 于任意的 n 个点的不同投影的个数以 $\sum_{i=0}^{\mathrm{vc}(\mathcal{F})}\binom{n}{i}$ 为界。

引理 8.3.9 (Sauer–Shelah 引理)

对于 VC 维数为 d 的类 $\mathcal{F}$，增长函数满足

$$\Pi_{\mathcal{F}}(n)\leqslant\sum_{i=0}^d\binom{n}{i}\leqslant\left(\frac{en}{d}\right)^d$$

$(n\geqslant d)$。

定义 8.3.10 (增长函数)

取值于 $\{0,1\}$ 的函数类 $\mathcal{F}$ 的增长函数为 $\Pi_{\mathcal{F}}(n)=\max_{x_1,\cdots,x_n\in\mathcal{X}}|\{(f(x_1),\cdots,f(x_n)):f\in\mathcal{F}\}|$，即 $\mathcal{F}$ 于 n 个点可产生的不同标记的最大个数。

命题 8.3.11 (VC 稳定性)

(i) 向 $\mathcal{F}$ 添加有限个函数，VC 维数的增加不超过所添加函数的个数。(ii) VC 类的交, 并, 补仍为 VC 类。(iii) 若 $\mathcal{F}$ 为 VC 函数类，则其下方图的类也是 VC 的。

定理 8.3.13 (通过 VC 维数给出的覆盖数)

设 $\mathcal{F}$ 为一致有界的函数类，$\mathrm{vc}(\mathcal{F}) = d$，则关于经验 L_2 度量的覆盖数满足

$$\mathcal{N}(\mathcal{F}, \varepsilon, L_2(P_n)) \leqslant \left(\frac{C}{\varepsilon}\right)^{2d}$$

($\varepsilon \in (0,1)$)。

引理 8.3.14 (降维)

由 VC 类索引的经验过程可通过限制于大小与 VC 维数成正比的数据随机子集来近似。

定理 8.3.15 (VC 大数定律)

设 $\mathcal{F}$ 为取值于 $\{0,1\}$ 的函数类，VC 维数为 d，则对于任意的 $\varepsilon \in (0,1)$，

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{N}\sum_{i=1}^{N} f(X_i) - \mathrm{E}[f(X)]\right|\right] \leqslant C\sqrt{\frac{d}{N}}。$$

定理 8.3.17 (Glivenko–Cantelli 定理)

经验 CDF

$$F_N(t) = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}_{\{X_i \leqslant t\}},$$

一致收敛于真实 CDF：

$$\sup_{t\in\mathbb{R}} |F_N(t) - F(t)| \to 0$$

当 $N \to \infty$ 时，几乎必然成立。

注记 8.3.19 (一致 Glivenko-Cantelli 类)

定义于集合 Ω 的实值函数族 $\mathcal{F}$ 称为一致 Glivenko-Cantelli 类，若对于任意的 $\varepsilon > 0$，

$$\lim_{n\to\infty}\sup_{\mu}\sup \mathrm{P}\left\{\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}f(X)\right| > \varepsilon\right\} = 0,$$

其中上确界取遍 Ω 的任意概率测度 μ，$X, X_1, \cdots, X_n$ 为服从分布 μ 的独立同分布的样本。定理 T8.3.15 (VC 大数定律) 结合 Markov 不等式可推出：任意具有有限 VC 维度的 Boolean 函数族均为一致 Glivenko-Cantelli 类。其逆命题也成立 (见练习 Q8.28 (一致 Glivenko-Cantelli 类, 有限 VC 维度))，因而两者等价。

Section 8.4 统计学习理论 Q8.25 ~ Q8.32

定义 8.4.3 (经验风险最小化)

给定损失函数 ℓ，假设类 $\mathcal{F}$，经验风险最小化器 (ERM) 为

$$\hat{f} = \arg\min_{f\in\mathcal{F}} \frac{1}{N}\sum_{i=1}^{N} \ell(f(X_i), Y_i)。$$

定理 8.4.5 (VC 泛化界)

设 $\mathcal{F}$ 为取值于 $\{0,1\}$ 的函数类，VC 维数为 d，令 $R(f) = \mathrm{P}\{f(X) \neq Y\}$ 为真实风险，则以高概率对于任意的 $f \in \mathcal{F}$，均满足

$$R(f) \leqslant \hat{R}_N(f) + C\sqrt{\frac{d + \ln(1/\delta)}{N}} \ (\text{w.p. } 1-\delta),$$

其中 $\hat{R}_N$ 为经验风险。

Section 8.5 一般链式方法 Q8.35 ~ Q8.38

定义 8.5.1 (γ_2 泛函)

对于度量空间 $(\mathbb{T},d)$，$\gamma_2(\mathbb{T},d)=\inf_{(\mathbb{T}_k)}\sup_{t\in\mathbb{T}}\sum_{k=0}^{\infty}2^{k/2}\operatorname{diam}(\mathbb{T}_k,d)$，其中下确界取遍 $\mathbb{T}$ 的满足特定容许性条件的任意划分序列 $(\mathbb{T}_k)$，$\operatorname{diam}(\mathbb{T}_k,d)$ 为于尺度 k 包含 t 的划分元素的直径。

定理 8.5.2 (一般链式界)

设 $(X_t)_{t\in\mathbb{T}}$ 为零均值随机过程，含有 sub-Gaussian 增量：$\|X_t-X_s\|_{\psi_2}\leqslant Kd(t,s)$，则

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant CK\gamma_2(\mathbb{T},d)。$$

注记 8.5.4 (Generic Chaining：高概率界)

定理 T8.5.2 (一般链式界) 只给出期望界，但 Generic Chaining 实际上给出高概率界——我们在注记 R8.1.6 (Dudley 不等式：高概率界) 中已经见识过这一逻辑。设 $\mathbb{T}$ 为有限集，则对于任意的 $u\geqslant 0$，事件

$$\sup_{t,s\in\mathbb{T}}|X_t-X_s|\leqslant CK(\gamma_2(\mathbb{T},d)+u\cdot\operatorname{diam}(\mathbb{T}))\ (\text{w.p. } 1-2\exp(-u^2))。$$

你将于练习 Q8.35 (Generic Chaining 的高概率界限) 证明它。

定理 8.5.5 (Talagrand 控制测度定理)

对于 $\mathbb{T}$ 典范度量 $d(t,s)=\|X_t-X_s\|_{L_2}$ 的 Gaussian 过程 (X_t)，

$$c\gamma_2(\mathbb{T},d)\leqslant\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant C\gamma_2(\mathbb{T},d)。$$

推论 8.5.6 (Talagrand 比较不等式)

设 (X_t) 和 (Y_t) 为 $\mathbb{T}$ 的两个 Gaussian 过程，$d_X(t,s)=\|X_t-X_s\|_{L_2}$，$d_Y(t,s)=\|Y_t-Y_s\|_{L_2}$。若对于任意的 $t,s\in\mathbb{T}$，均满足 $d_X(t,s)\leqslant d_Y(t,s)$，则

$$\mathrm{E}\left[\sup_t X_t\right]\leqslant C\mathrm{E}\left[\sup_t Y_t\right]。$$

推论 8.5.8 (Talagrand 比较不等式：几何形式)

设 $\mathbb{T}\subset\mathbb{R}^n$ 和 $\mathbb{S}\subset\mathbb{R}^n$ 满足 $\mathbb{T}\subset\operatorname{conv}(\mathbb{S})$，则

$$w(\mathbb{T})\leqslant Cw(\mathbb{S})。$$

Section 8.6 Chevet 不等式 Q8.39 ∼ Q8.41

定理 8.6.1 (sub-Gaussian Chevet 不等式)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其元素为相互独立的标准化 K-sub-Gaussian 随机变量，则对于任意的 $\mathbb{T}\subset\mathbb{S}^{n-1}$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{A}\boldsymbol{x}\|_2\right]\leqslant CK(w(\mathbb{T})+\sqrt{m}\cdot\operatorname{rad}(\mathbb{T}))。$$

习题解答

1 [**Dudley 不等式：高概率界限**] 修改 8.1 节的链化证明，以推导注记 R8.1.6 (Dudley 不等式：高概率界) 的 Dudley 不等式的高概率版本。

根据以下方式进行证明：

(1) 首先将增量界限 (8.11) 升级为以下的高概率版本，证明：对于任意的尺度 $k \geqslant 1$, 参数 $z_k \geqslant 0$，相邻网格之间的最大投影增量以高概率满足

$$\sup_{t\in\mathbb{T}} |X_{\pi_k(t)} - X_{\pi_{k-1}(t)}| \leqslant CK\varepsilon_{k-1}(\sqrt{\ln|\mathbb{T}_k|} + z_k) \text{ (w.p. } 1-2\exp(-z_k^2)\text{)。} \qquad (C>0)$$

(2) 之后选取合适的衰减序列 z_k，对于任意的链化层级 k 利用并集界，证明：对于任意的 $u \geqslant 0$，随机过程的全局振幅以高概率满足

$$\sup_{t,s\in\mathbb{T}} |X_t - X_s| \leqslant CK\left[\int_0^\infty \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon + u\cdot\operatorname{diam}(\mathbb{T})\right] \text{ (w.p. } 1-2\exp(-u^2)\text{)。}$$

证明 • 链化结构设定

设 $\varepsilon_k = 2^{-k}$，则存在 $\kappa\in\mathbb{Z}$，满足 $\varepsilon_\kappa \geqslant \operatorname{diam}(\mathbb{T}) > \varepsilon_{\kappa+1}$。

对于任意的 $k \geqslant \kappa$，设 $\mathbb{T}_k$ 为 $\mathbb{T}$ 的最小 ε_k-网，则 $|\mathbb{T}_k| = \mathcal{N}(\mathbb{T},d,\varepsilon_k)$。

(特别地，由于 $\varepsilon_\kappa \geqslant \operatorname{diam}(\mathbb{T})$，我们可以取 $|\mathbb{T}_\kappa| = 1$，设其唯一元素为 t_0。)

定义投影映射 $\pi_k(t)$ 为 $\mathbb{T}_k$ 与 t 距离最近的点，则 $d(t,\pi_k(t)) \leqslant \varepsilon_k$。

由于 $\mathbb{T}$ 是有限集，因此存在充分大的 $K_{\max}$，使得 $\varepsilon_{K_{\max}}$ 小于 $\mathbb{T}$ 的任意的两点间的最小距离，此时 $\mathbb{T}_{K_{\max}} = \mathbb{T}, \pi_{K_{\max}}(t) = t$。

• 单层级的高概率界限

固定 $k > \kappa$，之后只需界定增量 $\Delta_k(t) = X_{\pi_k(t)} - X_{\pi_{k-1}(t)}$。

对于任意的 $t\in\mathbb{T}$，其对应的增量端点对 $(\pi_k(t),\pi_{k-1}(t)) \in \mathbb{T}_k\times\mathbb{T}_{k-1}$。因此上述的增量对的数量最多为 $|\mathbb{T}_k||\mathbb{T}_{k-1}| \leqslant |\mathbb{T}_k|^2$。

端点之间的距离受三角不等式控制，

$$d(\pi_k(t),\pi_{k-1}(t)) \leqslant d(\pi_k(t),t) + d(t,\pi_{k-1}(t)) \leqslant \varepsilon_k + \varepsilon_{k-1} = \frac{3}{2}\varepsilon_{k-1} \leqslant 2\varepsilon_{k-1},$$

因此增量的 sub-Gaussian 范数满足 $\|\Delta_k(t)\|_{\psi_2} \leqslant K\cdot 2\varepsilon_{k-1}$，从而利用 sub-Gaussian 随机变量的尾部不等式，可得

$$\mathrm{P}\{|\Delta_k(t)| > s\} \leqslant 2\exp\left(-\frac{c_0 s^2}{(2K\varepsilon_{k-1})^2}\right), \qquad (c_0>0)$$

两侧取并集界，

$$\mathrm{P}\left\{\sup_{t\in\mathbb{T}}|\Delta_k(t)| > s\right\} \leqslant 2|\mathbb{T}_k|^2\exp\left(-\frac{c_0 s^2}{4K^2\varepsilon_{k-1}^2}\right) = 2\exp\left(2\ln|\mathbb{T}_k| - \frac{c_0 s^2}{4K^2\varepsilon_{k-1}^2}\right),$$

若上述失效概率等于 $2\exp(-z_k^2)$，则

$$\frac{c_0 s^2}{4K^2\varepsilon_{k-1}^2} - 2\ln|\mathbb{T}_k| = z_k^2 \implies s^2 = \frac{4K^2\varepsilon_{k-1}^2}{c_0}(z_k^2 + 2\ln|\mathbb{T}_k|)$$
$$\implies s \leqslant \frac{2}{\sqrt{c_0}}K\varepsilon_{k-1}(z_k + \sqrt{2}\sqrt{\ln|\mathbb{T}_k|}) \leqslant CK\varepsilon_{k-1}\left[\sqrt{\ln|\mathbb{T}_k|} + z_k\right]。$$

利用基本不等式 $\sqrt{a^2+b^2} \leqslant a+b$ (当 $a,b\geqslant 0$)，可得：

$$s \leqslant \frac{2}{\sqrt{c_0}}K\varepsilon_{k-1}(z_k + \sqrt{2}\sqrt{\ln|\mathbb{T}_k|}) \leqslant CK\varepsilon_{k-1}(\sqrt{\ln|\mathbb{T}_k|} + z_k)。 \qquad \left(C = \frac{2\sqrt{2}}{\sqrt{c_0}}\right)$$

• 选择 z_k 并联合所有层级

(由于 $X_t - X_{t_0} = \sum_{k=\kappa+1}^{K_{\max}}\Delta_k(t)$，我们希望利用并集界，保证任意的 $k\in(\kappa,K_{\max}]$ 的增量界限同时成立。具体而言，之后只需选择 z_k，使得总失效概率 $\sum_k 2\exp(-z_k^2) \leqslant 2\exp(-u^2)$。)

对于 $k = \kappa+1,\kappa+2,\cdots$，构造

$$z_k = u + \sqrt{k-\kappa},$$

则总失效概率为

$$\sum_{k=\kappa+1}^{K_{\max}} 2\exp(-z_k^2) \leqslant 2\sum_{j=1}^{\infty}\exp(-(u+\sqrt{j})^2)$$

$$\leqslant \exp(-u^2)\sum_{j=1}^{\infty}\mathrm{e}^{-j} \qquad ((u+\sqrt{j})^2 \geqslant u^2+j)$$

$$= \exp(-u^2)\frac{\mathrm{e}^{-1}}{1-\mathrm{e}^{-1}} < \exp(-u^2),$$

因此，任意层级的界限均成立 (w.p. $1-2\exp(-u^2)$)。

- 求和并转化为积分

对于任意的 $t,s\in\mathbb{T}$，

$$|X_t - X_s| \leqslant |X_t - X_{t_0}| + |X_s - X_{t_0}| \leqslant 2\sup_t |X_t - X_{t_0}|,$$

其中

$$|X_t - X_{t_0}| \leqslant \sum_{k=\kappa+1}^{K_{\max}} |\Delta_k(t)| \leqslant CK\sum_{k=\kappa+1}^{K_{\max}} \varepsilon_{k-1}(\sqrt{\ln|\mathbb{T}_k|} + u + \sqrt{k-\kappa}),$$

我们将右侧级数拆分为三个部分 S_1, S_2, S_3。

对于 S_1，

$$S_1 = CK\sum_{k=\kappa+1}^{K_{\max}} 2\varepsilon_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)} \leqslant 4CK\int_0^{\infty}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon$$

对于 S_2，

$$S_2 = CKu\sum_{k=\kappa+1}^{\infty}\varepsilon_{k-1} = CKu\varepsilon_\kappa\sum_{j=1}^{\infty}2^{-j+1} = 2CKu\varepsilon_\kappa \leqslant 4CKu\cdot\mathrm{diam}(\mathbb{T})。$$

对于 S_3，

$$S_3 = CK\sum_{k=\kappa+1}^{\infty}\varepsilon_{k-1}\sqrt{k-\kappa} = CK\varepsilon_\kappa\sum_{j=1}^{\infty}2^{-j+1}\sqrt{j}$$

$$\leqslant c_1CK\varepsilon_\kappa \leqslant 2c_1CK\cdot\mathrm{diam}(\mathbb{T})。 \qquad \left(\sum_{j=1}^{\infty}2^{-j+1}\sqrt{j} = c_1\right)$$

若 $|\mathbb{T}|\geqslant 2$，则对于 $\varepsilon < \mathrm{diam}(\mathbb{T})/2$，覆盖数 $\mathcal{N}\geqslant 2$，即 $\ln\mathcal{N}\geqslant\ln 2$，因此

$$\int_0^{\infty}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon \geqslant \int_0^{\mathrm{diam}(\mathbb{T})/2}\sqrt{\ln 2}\mathrm{d}\varepsilon = \frac{\sqrt{\ln 2}}{2}\mathrm{diam}(\mathbb{T}),$$

从而

$$S_3 \leqslant C'K\int_0^{\infty}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon。$$

如此，

$$\sup_{t,s\in\mathbb{T}}|X_t - X_s| \leqslant C^*K\left[\int_0^{\infty}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon + u\cdot\mathrm{diam}(\mathbb{T})\right] \text{ (w.p. } 1-2\exp(-u^2))。 \qquad (C^*>0)$$

2 [**Gaussian 过程的 Dudley 高概率界限**] 对于一般的 sub-Gaussian 过程，获取高概率版本的 Dudley 不等式需要修改链化证明 (正如练习 Q8.1 (Dudley 不等式：高概率界限) 所示)。

但如果假设 $(X_t)_{t\in\mathbb{T}}$ 为零均值 Gaussian 过程，我们可以通过一条更简单的路径得到高概率界限。

结合期望版本的 Dudley 不等式, Gaussian 过程的集中不等式 (定理 T7.1.11 (Gaussian 过程的集中))，给出注记 R8.1.6 (Dudley

不等式：高概率界) 的高概率界限结果的另一种证明。

具体而言，对于定义于有限度量空间 $(\mathbb{T}, d)$ 的零均值 Gaussian 过程，其中度量为 $d(t,s) = \|X_t - X_s\|_{L^2}$，证明：对于任意的 $u \geqslant 0$，

$$\sup_{t,s\in\mathbb{T}} |X_t - X_s| \leqslant C\left[\int_0^\infty \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon + u \cdot \operatorname{diam}(\mathbb{T})\right] \text{ (w.p. } 1 - 2\exp(-u^2)) \qquad (C > 0)$$

证明 定义 Gaussian 过程于 $\mathbb{T}$ 的最大增量为 (由于取了两点，我们可以于乘积空间 $\mathbb{T} \times \mathbb{T}$ 考虑)

$$Z = \sup_{t,s\in\mathbb{T}} (X_t - X_s) = \sup_{t,s\in\mathbb{T}} |X_t - X_s|。$$

(注：由于 Gaussian 过程是对称的，上确界 $\sup_{t,s}(X_t - X_s)$ 与 $\sup_{t,s}|X_t - X_s|$ 精确相等。)

- 期望界限

  利用定理 T8.1.3 (Dudley 积分不等式) (Dudley 积分不等式)，可得

  $$\mathrm{E}[Z] = \mathrm{E}\left[\sup_{t,s\in\mathbb{T}} |X_t - X_s|\right] \leqslant C_1 \int_0^\infty \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon。 \qquad \text{(I)}$$

- 波动界限

  利用 Gaussian 过程的集中不等式 (定理 T7.1.11 (Gaussian 过程的集中))，可得

  $$\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant C_2 \sup_{t,s\in\mathbb{T}} \sqrt{\operatorname{Var}(X_t - X_s)}。$$

  其中

  $$\operatorname{Var}(X_t - X_s) = \mathrm{E}[(X_t - X_s)^2] = d(t,s)^2。$$

  将其代入，可得

  $$\sup_{t,s\in\mathbb{T}} \sqrt{\operatorname{Var}(X_t - X_s)} = \sup_{t,s\in\mathbb{T}} d(t,s) = \operatorname{diam}(\mathbb{T})。$$

  因此

  $$\|Z - \mathrm{E}[Z]\|_{\psi_2} \leqslant C_2 \cdot \operatorname{diam}(\mathbb{T})。$$

- 根据 sub-Gaussian 尾部不等式

  根据 sub-Gaussian 随机变量的尾部概率定义，对于任意的 $s \geqslant 0$，

  $$\mathrm{P}\{Z \geqslant \mathrm{E}[Z] + s\} \leqslant 2\exp\left(-\frac{cs^2}{\|Z - \mathrm{E}[Z]\|_{\psi_2}^2}\right) \leqslant 2\exp\left(-\frac{cs^2}{C_2^2 \cdot \operatorname{diam}(\mathbb{T})^2}\right)。 \qquad (c > 0)$$

  若上述失效概率等于 $2\exp(-u^2)$，则

  $$\frac{cs^2}{C_2^2 \cdot \operatorname{diam}(\mathbb{T})^2} = u^2 \implies s = \frac{C_2}{\sqrt{c}} u \cdot \operatorname{diam}(\mathbb{T}) = C_3 u \cdot \operatorname{diam}(\mathbb{T})。 \qquad \left(C_3 = \frac{C_2}{\sqrt{c}}\right)$$

  因此

  $$Z \leqslant \mathrm{E}[Z] + C_3 u \cdot \operatorname{diam}(\mathbb{T}) \text{ (w.p. } 1 - 2\exp(-u^2))。$$

  将其代入于 (I)，可得

  $$\sup_{t,s\in\mathbb{T}} |X_t - X_s| \leqslant C_1 \int_0^\infty \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon + C_3 u \cdot \operatorname{diam}(\mathbb{T}) \text{ (w.p. } 1 - 2\exp(-u^2)),$$

  即

  $$\sup_{t,s\in\mathbb{T}} |X_t - X_s| \leqslant C\left[\int_0^\infty \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon + u \cdot \operatorname{diam}(\mathbb{T})\right] \text{ (w.p. } 1 - 2\exp(-u^2))。 \qquad (C = \max(C_1, C_3))$$

3 [**Dudley 积分与 Dudley 和是等价的**] 关于定理 T8.1.4 (离散 Dudley 不等式) 的证明，我们将 Dudley 和 (离散形式) 放缩为 Dudley 积分 (连续形式) 的上界。

证明，这两种形式在忽略绝对常数因子的意义下是等价的，

$$\sum_{k\in\mathbb{Z}} 2^{-k}\sqrt{\ln \mathcal{N}(\mathbb{T},d,2^{-k})} \asymp \int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon。$$

证明 • 证明 Dudley 和 $\lesssim$ Dudley 积分

将 2^{-k} 写成积分 $\int_{2^{-k-1}}^{2^{-k}} 2\mathrm{d}\varepsilon$。

$$\sum_{k\in\mathbb{Z}} 2^{-k} f(2^{-k}) = \sum_{k\in\mathbb{Z}} f(2^{-k}) \int_{2^{-k-1}}^{2^{-k}} 2\mathrm{d}\varepsilon = 2\sum_{k\in\mathbb{Z}} \int_{2^{-k-1}}^{2^{-k}} f(2^{-k})\mathrm{d}\varepsilon。$$

对于任意的 $\varepsilon\in[2^{-k-1},2^{-k}]$，由于 f 是递减的，因此 $f(2^{-k})\leqslant f(\varepsilon)$，从而

$$2\sum_{k\in\mathbb{Z}} \int_{2^{-k-1}}^{2^{-k}} f(2^{-k})\mathrm{d}\varepsilon \leqslant 2\sum_{k\in\mathbb{Z}} \int_{2^{-k-1}}^{2^{-k}} f(\varepsilon)\mathrm{d}\varepsilon,$$

将全部区间的积分合并，

$$2\sum_{k\in\mathbb{Z}} \int_{2^{-k-1}}^{2^{-k}} f(\varepsilon)\mathrm{d}\varepsilon = 2\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon,$$

(假设 ε 充分大，满足 $\varepsilon>\operatorname{diam}(\mathbb{T})$，此时 $\mathcal{N}=1$，积分收敛。)

即

$$2\sum_{k\in\mathbb{Z}} \int_{2^{-k-1}}^{2^{-k}} f(2^{-k})\mathrm{d}\varepsilon \leqslant 2\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon。$$

• 证明 Dudley 积分 $\lesssim$ Dudley 和

将积分拆分为二进区间的求和，

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon = \sum_{k\in\mathbb{Z}} \int_{2^{-k}}^{2^{-k+1}} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon。$$

对于任意的 $\varepsilon\in[2^{-k-1},2^{-k}]$，由于 f 是递减的，因此 $f(\varepsilon)\geqslant f(2^{-k+1})$，从而

$$\begin{aligned}
\int_0^{\infty} f(\varepsilon)\mathrm{d}\varepsilon &\geqslant \sum_{k\in\mathbb{Z}} \int_{2^{-k}}^{2^{-k+1}} f(2^{-k+1})\mathrm{d}\varepsilon = \sum_{k\in\mathbb{Z}} f(2^{-k+1})\cdot(2^{-k+1}-2^{-k}) \\
&= \sum_{k\in\mathbb{Z}} 2^{-k} f(2^{-k+1}) \\
&= \sum_{j\in\mathbb{Z}} 2^{-(j+1)} f(2^{-j}) = \frac{1}{2}\sum_{j\in\mathbb{Z}} 2^{-j} f(2^{-j}), \qquad (j=k-1)
\end{aligned}$$

即

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon \geqslant \frac{1}{2}\sum_{k\in\mathbb{Z}} 2^{-k}\sqrt{\ln \mathcal{N}(\mathbb{T},d,2^{-k})}。$$

4 [**Dudley 不等式可能非常松弛**] 设 $n\geqslant 2$，$\boldsymbol{e}_k$ 为 $\mathbb{R}^n$ 的标准正交基向量，定义 $\mathbb{T}\subset\mathbb{R}^n$ 为

$$\mathbb{T} = \left\{ \frac{\boldsymbol{e}_k}{\sqrt{1+\ln k}} : k=1,\cdots,n \right\}。$$

证明以下两个相互冲突的结论：

(1) 存在不依赖维度 n 的绝对常数 C，使得 Gaussian 宽度是有界的，即 $w(\mathbb{T})\leqslant C$。

(2) 当 $n\to\infty$ 时，其 Dudley 积分发散，即

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon \to \infty。$$

证明 (1) 设 $\boldsymbol{g}=(g_1,\cdots,g_n)\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则根据 Gaussian 宽度的定义 (D7.5.1 (Gaussian 宽度))，可得

$$w(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{t}\rangle\right]=\mathrm{E}\left[\max_{1\leqslant k\leqslant n}\left\langle\boldsymbol{g},\frac{\boldsymbol{e}_k}{\sqrt{1+\ln k}}\right\rangle\right]=\mathrm{E}\left[\max_{1\leqslant k\leqslant n}\frac{g_k}{\sqrt{1+\ln k}}\right],$$

令 $X_k=\frac{g_k}{\sqrt{1+\ln k}}$。(之后只需计算 $\mathrm{E}[\max_k X_k]$。)

利用标准 Gaussian 变量的尾部不等式 $\mathrm{P}\{g_k>t\}\leqslant\exp(-t^2/2)$，可得

$$\mathrm{P}\{X_k>u\}=\mathrm{P}\{g_k>u\sqrt{1+\ln k}\}\leqslant\exp\left(-\frac{u^2(1+\ln k)}{2}\right)=\mathrm{e}^{-u^2/2}\cdot\mathrm{e}^{-\frac{u^2}{2}\ln k}=\mathrm{e}^{-u^2/2}\frac{1}{k^{u^2/2}},$$

两侧取并集界，

$$\mathrm{P}\left\{\max_{1\leqslant k\leqslant n}X_k>u\right\}\leqslant\sum_{k=1}^{n}\mathrm{P}\{X_k>u\}\leqslant\mathrm{e}^{-u^2/2}\sum_{k=1}^{n}\frac{1}{k^{u^2/2}}。$$

(为了使得右侧级数 $\sum_{k=1}^{\infty}k^{-u^2/2}$ 收敛，令 $u^2/2\geqslant 2$，即 $u\geqslant 2$。此时

$$\sum_{k=1}^{\infty}k^{-u^2/2}\leqslant\sum_{k=1}^{\infty}k^{-2}=\frac{\pi^2}{6}<2,$$

从而概率尾界不超过 $2\mathrm{e}^{-u^2/2}$。) 令 $Y=\max_{1\leqslant k\leqslant n}X_k$。由于 $Y\leqslant Y_+$，将 Y_+ 的尾积分拆分为两部分，

$$\begin{aligned}\mathrm{E}[Y]\leqslant\mathrm{E}[Y_+]&=\int_0^{\infty}\mathrm{P}\{Y>u\}\mathrm{d}u\\&\leqslant\int_0^2 1\mathrm{d}u+\int_2^{\infty}\mathrm{P}\left\{\max_k X_k>u\right\}\mathrm{d}u\\&\leqslant 2+\int_2^{\infty}2\mathrm{e}^{-u^2/2}\mathrm{d}u\leqslant 2+\int_{-\infty}^{\infty}\mathrm{e}^{-u^2/2}\mathrm{d}u=2+\sqrt{2\pi},\end{aligned}$$

此时令 $C=2+\sqrt{2\pi}$。

(2) 设

$$\boldsymbol{t}_k=\frac{\boldsymbol{e}_k}{\sqrt{1+\ln k}}\in\mathbb{T},$$

则

$$d(\boldsymbol{t}_i,\boldsymbol{t}_j)^2=\|\boldsymbol{t}_i-\boldsymbol{t}_j\|_2^2=\|\boldsymbol{t}_i\|_2^2+\|\boldsymbol{t}_j\|_2^2=\frac{1}{1+\ln i}+\frac{1}{1+\ln j}。$$

为了建立覆盖数的下界，考虑前 m 个点组成的子集 $\mathbb{T}_m=\{\boldsymbol{t}_1,\cdots,\boldsymbol{t}_m\}$，其中 $m\leqslant n$，则对于任意的 $i\neq j\leqslant m$，

$$d(\boldsymbol{t}_i,\boldsymbol{t}_j)\geqslant\sqrt{\frac{1}{1+\ln m}+\frac{1}{1+\ln m}}=\sqrt{\frac{2}{1+\ln m}},$$

定义临界半径

$$r_m=\frac{1}{2}\sqrt{\frac{2}{1+\ln m}}=\frac{1}{\sqrt{2(1+\ln m)}},$$

则 $\mathrm{dist}(\mathbb{T}_m)\geqslant 2r_m$。对于任意的 $\varepsilon<r_m$，每个半径为 ε 的闭球至多包含 $\mathbb{T}_m$ 的一个点，因此

$$\mathcal{N}(\mathbb{T},d,\varepsilon)\geqslant m,$$

从而

$$I_n=\int_0^{\infty}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon\geqslant\sum_{m=2}^{n-1}\int_{r_{m+1}}^{r_m}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon\geqslant\sum_{m=2}^{n-1}\sqrt{\ln m}\cdot(r_m-r_{m+1}),$$

之后只需估计间距 r_m-r_{m+1}。令 $h(x)=\frac{1}{\sqrt{2(1+\ln x)}}$。

根据 Lagrange 中值定理，可得存在 $c_m\in(m,m+1)$，使得

$$h(m)-h(m+1)=-h'(c_m),$$

其中

$$h'(x)=\frac{1}{\sqrt{2}}\left(-\frac{1}{2}\right)(1+\ln x)^{-3/2}\cdot\frac{1}{x}=-\frac{1}{2\sqrt{2}x(1+\ln x)^{3/2}},$$

将其代入，可得

$$r_m-r_{m+1}\geqslant\frac{1}{2\sqrt{2}(m+1)(1+\ln(m+1))^{3/2}},$$

因此

$$\begin{aligned}I_n&\geqslant\frac{1}{2\sqrt{2}}\sum_{m=2}^{n-1}\frac{\sqrt{\ln m}}{(m+1)(1+\ln(m+1))^{3/2}}\\&\sim\frac{1}{2\sqrt{2}}\sum_{m=2}^{n-1}\frac{\sqrt{\ln m}}{m(\ln m)^{3/2}}=\frac{1}{2\sqrt{2}}\sum_{m=2}^{n-1}\frac{1}{m\ln m}\to\infty。\end{aligned}$$

注释 产生这种反常现象的原因在于，Dudley 不等式基于 ε-网来度量复杂度。对于这种极其稀疏的“尖刺”几何体，覆盖它需要指数级数量的微小球体，导致对数覆盖数激增；但在 Gaussian 投影，绝大多数方向的尖刺于与 Gaussian 向量积时都衰减了，因此其实际上的 Gaussian 宽度非常小。

5 [**Dudley 与 Sudakov 不等式在对数因子下是紧致的**] 已知对于 $n\geqslant 2$ 且集合 $\mathbb{T}\subset\mathbb{R}^n$，推论 C7.4.2 ($\mathbb{R}^n$ 的 Sudakov 不等式), 定理 T8.1.8 ($\mathbb{R}^n$ 的 Dudley 不等式) 分别给出了 Gaussian 宽度 $w(\mathbb{T})$ 的下界，上界，

$$s(\mathbb{T})\lesssim w(\mathbb{T})\lesssim d(\mathbb{T})。$$

其中单尺度特征值 $s(\mathbb{T})$, 多尺度积分 $d(\mathbb{T})$ 分别定义为

$$s(\mathbb{T})=\sup_{\varepsilon>0}\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)},\quad d(\mathbb{T})=\int_0^\infty\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)}\mathrm{d}\varepsilon。$$

证明：上述界限在相差一个对数因子的意义下是等价的，

$$s(\mathbb{T})\leqslant d(\mathbb{T})\leqslant C\ln(n)s(\mathbb{T})。\qquad(C>0)$$

证明 (注：对于 $n=1$ 的情况，$\ln(n)=0$，此时右侧理解为绝对常数 $C\cdot s(\mathbb{T})$。为书写统一，后文推导默认 $n\geqslant 2$。)

- 证明下界 $s(\mathbb{T})\leqslant d(\mathbb{T})$

  由于覆盖数 $\mathcal{N}(\mathbb{T},x)$ 关于半径 x 是递减的，因此对于任意的 $\varepsilon>0$，

  $$\begin{aligned}d(\mathbb{T})&=\int_0^\infty\sqrt{\ln\mathcal{N}(\mathbb{T},x)}\mathrm{d}x\geqslant\int_0^\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},x)}\mathrm{d}x\\&\geqslant\int_0^\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)}\mathrm{d}x=\varepsilon\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)},\end{aligned}$$

  两侧对 ε 取上确界，

  $$s(\mathbb{T})\leqslant d(\mathbb{T})。$$

- 建立 $\mathrm{diam}(\mathbb{T})$, $s(\mathbb{T})$ 的关系

  令 $D=\mathrm{diam}(\mathbb{T})$。若 $D=0$，则 $s(\mathbb{T})=d(\mathbb{T})=0$，结论是平凡的；之后只需考虑 $D>0$ 的情况。

  令覆盖半径为 $\varepsilon=D/3$，则

  $$\mathcal{N}\left(\mathbb{T},\frac{D}{3}\right)\geqslant 2,$$

  将其代入于 $s(\mathbb{T})$ 的定义，可得

  $$s(\mathbb{T})\geqslant\frac{D}{3}\sqrt{\ln\mathcal{N}\left(\mathbb{T},\frac{D}{3}\right)}\geqslant\frac{D}{3}\sqrt{\ln 2},$$

  即

  $$D\leqslant C_0 s(\mathbb{T})。\qquad(C_0=3/\sqrt{\ln 2})$$

- 证明上界 $d(\mathbb{T})\leqslant C\ln(n)s(\mathbb{T})$

注意到当 $\varepsilon > D$ 时，只需 1 个半径为 ε 的球即可覆盖 $\mathbb{T}$，此时 $\ln \mathcal{N}(\mathbb{T}, \varepsilon) = \ln 1 = 0$，因此 Dudley 积分仅于 $[0, D]$ 有效，

$$d(\mathbb{T}) = \int_0^D \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)} \mathrm{d}\varepsilon。$$

将其于 $\varepsilon = D/n$ 拆分，

$$d(\mathbb{T}) = \underbrace{\int_0^{D/n} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)} \mathrm{d}\varepsilon}_{I_{\text{small}}} + \underbrace{\int_{D/n}^D \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)} \mathrm{d}\varepsilon}_{I_{\text{large}}}。$$

对于 I_{large}，将被积函数配凑为 $s(\mathbb{T})$ 的形式

$$\begin{aligned} I_{\text{large}} &= \int_{D/n}^D \frac{1}{\varepsilon} (\varepsilon \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}) \mathrm{d}\varepsilon \\ &\leqslant \int_{D/n}^D \frac{s(\mathbb{T})}{\varepsilon} \mathrm{d}\varepsilon = s(\mathbb{T}) \left(\ln D - \ln \frac{D}{n} \right) = s(\mathbb{T}) \ln(n)。 \end{aligned}$$

对于 I_{small}，注意到当 $\varepsilon \leqslant D$ 时，

$$\mathcal{N}(\mathbb{T}, \varepsilon) \leqslant \left(1 + \frac{2D}{\varepsilon}\right)^n \leqslant \left(\frac{3D}{\varepsilon}\right)^n,$$

因此

$$\begin{aligned} I_{\text{small}} &\leqslant \int_0^{D/n} \sqrt{n \ln \left(\frac{3D}{\varepsilon}\right)} \mathrm{d}\varepsilon \\ &= \sqrt{n} \int_{\ln(3n)}^{\infty} \sqrt{y} (3D \mathrm{e}^{-y}) \mathrm{d}y = 3D\sqrt{n} \int_{\ln(3n)}^{\infty} \sqrt{y} \mathrm{e}^{-y} \mathrm{d}y。 \qquad \left(y = \ln\left(\tfrac{3D}{\varepsilon}\right)\right) \end{aligned}$$

对于右侧积分，注意到当 $y \geqslant A$ 时，$\sqrt{y} \leqslant y/\sqrt{A}$，令 $A = \ln(3n)$，可得

$$\int_A^{\infty} \sqrt{y} \mathrm{e}^{-y} \mathrm{d}y \leqslant \frac{1}{\sqrt{A}} \int_A^{\infty} y \mathrm{e}^{-y} \mathrm{d}y = \frac{1}{\sqrt{A}} (A+1) \mathrm{e}^{-A} = \frac{A+1}{A} \sqrt{A} \mathrm{e}^{-A} \leqslant 2\sqrt{A} \mathrm{e}^{-A},$$

将其代入，可得

$$\begin{aligned} I_{\text{small}} &\leqslant 3D\sqrt{n} \left(2\sqrt{\ln(3n)} \cdot \frac{1}{3n} \right) = 2D \frac{\sqrt{\ln(3n)}}{\sqrt{n}} \\ &\leqslant 2C_0 s(\mathbb{T}) \frac{\sqrt{\ln(3n)}}{\sqrt{n}} = C_1 s(\mathbb{T})。 \end{aligned}$$

如此，

$$d(\mathbb{T}) = I_{\text{large}} + I_{\text{small}} \leqslant s(\mathbb{T}) \ln(n) + C_1 s(\mathbb{T}) \leqslant C \ln(n) s(\mathbb{T})。$$

注释 本题揭示了一个反直觉但于高维空间普遍成立的事实：对于 Euclidean 空间的任意的有界集合，基于单尺度的 Sudakov 下界与基于多尺度积分的 Dudley 上界，在忽略一个对数因子 $\ln(n)$ 之后是等价的。这意味着于 $\mathbb{R}^n$，很多时候我们不需要做复杂的 Dudley 积分，只需找到让 $\varepsilon\sqrt{\ln \mathcal{N}}$ 最大的单一尺度，即可在对数精度下刻画其 Gaussian 宽度。

6 [**积分限精细化的 Dudley 不等式**] 设 $\mathbb{T} \subset \mathbb{R}^n$。根据注记 R8.1.7 (Dudley 积分的极限)，我们已知 Dudley 积分式 (8.17) 的上限可以设定为 $\operatorname{diam}(\mathbb{T})$。同时，优化积分的下限也很有价值，因为当 $\varepsilon \to 0$ 时，积分将可能发散。

证明：对于任意的集合 $\mathbb{T} \subset \mathbb{R}^n$，其 Gaussian 宽度满足以下含有截断积分限的 Dudley 不等式，

$$w(\mathbb{T}) \leqslant C \int_a^b \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)} \mathrm{d}\varepsilon。 \qquad (C, c > 0)$$

其中，积分上限 $b = \operatorname{diam}(\mathbb{T})$，积分下限 $a = \frac{cw(\mathbb{T})}{\sqrt{n}}$。

证明 (我们不于无穷小尺度继续链化，而是考虑对截断进行链化，在尺度降至某个阈值 a 时强制停止，并将最后剩余的微小残

差通过 $\mathbb{R}^n$ 的全局 Euclidean 性质进行界定。)

- 构造不同尺度的网

  设 $D=\operatorname{diam}(\mathbb{T})$，定义二进尺度序列 $\varepsilon_k = D2^{-k}$，令 $\mathcal{N}_k$ 为 $\mathbb{T}$ 的最小 ε_k-网，则 $|\mathcal{N}_k| = \mathcal{N}(\mathbb{T}, d, \varepsilon_k)$。

  (特别地，对于 $\varepsilon_0 = D$，我们只需一个点即可覆盖 $\mathbb{T}$，即 $|\mathcal{N}_0| = 1$。)

  对于任意的 $\boldsymbol{t}\in\mathbb{T}$，定义投影映射 $\pi_k(\boldsymbol{t})\in\mathcal{N}_k$ 为网格距离 $\boldsymbol{t}$ 最近的点，满足 $\|\boldsymbol{t}-\pi_k(\boldsymbol{t})\|_2 \leqslant \varepsilon_k$。

- 进行链式分解

  给定目标截断尺度 $a>0$，则存在 K，使得 $\varepsilon_K \leqslant a < \varepsilon_{K-1}$，于第 K 步强制停止链化展开 (望远镜求和)，可得

$$\boldsymbol{t} = \pi_0(\boldsymbol{t}) + \sum_{k=1}^{K}(\pi_k(\boldsymbol{t}) - \pi_{k-1}(\boldsymbol{t})) + (\boldsymbol{t}-\pi_K(\boldsymbol{t})),$$

  令 $\boldsymbol{g}\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，将上述分解代入 Gaussian 宽度的定义，可得

$$\begin{aligned} w(\mathbb{T}) &= \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}\rangle\right] \\ &\leqslant \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \pi_0(\boldsymbol{t})\rangle\right] + \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\sum_{k=1}^{K}\langle \boldsymbol{g}, \pi_k(\boldsymbol{t})-\pi_{k-1}(\boldsymbol{t})\rangle\right] + \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}-\pi_K(\boldsymbol{t})\rangle\right] \\ &\leqslant \underbrace{\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \pi_0(\boldsymbol{t})\rangle\right]}_{I_0} + \underbrace{\sum_{k=1}^{K}\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \pi_k(\boldsymbol{t})-\pi_{k-1}(\boldsymbol{t})\rangle\right]}_{I_{\text{chain}}} + \underbrace{\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}-\pi_K(\boldsymbol{t})\rangle\right]}_{I_{\text{rem}}}。 \end{aligned}$$

1. 对于 I_0，由于 $\mathcal{N}_0$ 仅含有一个点，不妨设为 $\boldsymbol{t}_0$，则

$$\mathrm{E}[\langle \boldsymbol{g}, \boldsymbol{t}_0\rangle] = \langle \mathrm{E}[\boldsymbol{g}], \boldsymbol{t}_0\rangle = 0,$$

   因此 $I_0 = 0$。

2. 对于 I_{chain}，考虑单项

$$E_k = \mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \pi_k(\boldsymbol{t})-\pi_{k-1}(\boldsymbol{t})\rangle\right],$$

   记 $\boldsymbol{v}_k(\boldsymbol{t}) = \pi_k(\boldsymbol{t}) - \pi_{k-1}(\boldsymbol{t})$ 所构成的集合为 $\Delta_k = \{\boldsymbol{v}_k(\boldsymbol{t}) : \boldsymbol{t}\in\mathbb{T}\}$，满足 $|\Delta_k| \leqslant |\mathcal{N}_k||\mathcal{N}_{k-1}| \leqslant |\mathcal{N}_k|^2$，则

$$E_k = \mathrm{E}\left[\max_{\boldsymbol{v}\in\Delta_k}\langle \boldsymbol{g}, \boldsymbol{v}\rangle\right]。$$

   由于

$$X_{\boldsymbol{v}} = \langle \boldsymbol{g}, \boldsymbol{v}\rangle \sim N(0, \|\boldsymbol{v}\|_2^2),$$

   其中

$$\|\boldsymbol{v}\|_2 = \|\pi_k(\boldsymbol{t}) - \pi_{k-1}(\boldsymbol{t})\|_2 \leqslant \varepsilon_k + \varepsilon_{k-1} = 3\varepsilon_k,$$

   因此根据 Gaussian 极大值引理 $\mathrm{E}[\max_{1\leqslant i\leqslant N} X_i] \leqslant c\cdot\sigma\cdot\sqrt{\ln N}$，可得

$$\begin{aligned} E_k &\leqslant c\cdot(3\varepsilon_{k-1})\cdot\sqrt{\ln(|\mathcal{N}_k|^2)} \\ &=: C_1\cdot\varepsilon_{k-1}\cdot\sqrt{\ln|\mathcal{N}_k|}, \qquad (C_1 = 3\sqrt{2}c) \end{aligned}$$

   两侧求和，可得

$$I_{\text{chain}} \leqslant C_1\sum_{k=1}^{K}\varepsilon_{k-1}\sqrt{\ln|\mathcal{N}_k|} = C_1\sum_{k=1}^{K}\varepsilon_{k-1}\sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon_k)}。$$

   根据习题 Q8.3 (Dudley 积分与 Dudley 和是等价的)，将积分下限替换为 $a\in[\varepsilon_K, 2\varepsilon_K)$ (最多只损失常数倍的精度，具体证明细节见注释)，可得

$$I_{\text{chain}} \leqslant C_2\int_a^D \sqrt{\ln\mathcal{N}(\mathbb{T},\varepsilon)}\mathrm{d}\varepsilon。 \qquad (C_2>0)$$

3. 对于残差项 I_{rem}，利用 Cauchy 不等式，可得

$$\langle \boldsymbol{g}, \boldsymbol{t}-\pi_K(\boldsymbol{t})\rangle \leqslant \|\boldsymbol{g}\|_2 \cdot \|\boldsymbol{t}-\pi_K(\boldsymbol{t})\|_2 \leqslant \|\boldsymbol{g}\|_2 \varepsilon_K,$$

两侧取上确界，期望，

$$\mathrm{E}\left[\sup_{\boldsymbol{t}\in\mathbb{T}}\langle \boldsymbol{g}, \boldsymbol{t}-\pi_K(\boldsymbol{t})\rangle\right] \leqslant \mathrm{E}\|\boldsymbol{g}\|_2 \cdot \varepsilon_K \leqslant \sqrt{\mathrm{E}\|\boldsymbol{g}\|_2^2} \cdot \varepsilon_K = \sqrt{n}\varepsilon_K。$$

如此，对于任意的停止尺度 $a>0$，

$$w(\mathbb{T}) \leqslant C_1 \sum_{k=1}^{K} \varepsilon_k \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon_k)} + \sqrt{n}\varepsilon_K。 \tag{I}$$

- 选择最优的截断层数 K

(要使得截断误差被 $\frac{1}{2}w(\mathbb{T})$ 吸收，则 $\sqrt{n}\varepsilon_K \leqslant \frac{1}{2}w(\mathbb{T})$，即 $\varepsilon_K \leqslant \frac{w(\mathbb{T})}{2\sqrt{n}}$。)

根据 Gaussian 宽度的基本性质 (P7.5.2 (Gaussian 宽度的简单性质)) $w(\mathbb{T}) \leqslant \sqrt{n} \cdot \operatorname{diam}(\mathbb{T}) = \sqrt{n}D$，可得

$$\frac{w(\mathbb{T})}{2\sqrt{n}} \leqslant \frac{1}{2}D = \varepsilon_1,$$

因此存在 $K \in \mathbb{Z}^+$，使得

$$\varepsilon_K \leqslant \frac{w(\mathbb{T})}{2\sqrt{n}} < \varepsilon_{K-1},$$

将其代入于 (I)，可得

$$w(\mathbb{T}) \leqslant C_1 \sum_{k=1}^{K} \varepsilon_k \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon_k)} + \frac{1}{2}w(\mathbb{T}),$$

即

$$w(\mathbb{T}) \leqslant 2C_1 \sum_{k=1}^{K} \varepsilon_k \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon_k)}。$$

- 将离散求和转化为积分

当 $\varepsilon \in [\varepsilon_{k+1}, \varepsilon_k]$ 时，$\mathcal{N}(\mathbb{T}, \varepsilon) \geqslant \mathcal{N}(\mathbb{T}, \varepsilon_k)$，因此

$$\int_{\varepsilon_{k+1}}^{\varepsilon_k} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon \geqslant (\varepsilon_k - \varepsilon_{k+1})\sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon_k)} = \frac{1}{2}\varepsilon_k \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon_k)},$$

两侧求和，

$$w(\mathbb{T}) \leqslant 4C_1 \sum_{k=1}^{K} \int_{\varepsilon_{k+1}}^{\varepsilon_k} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon = 4C_1 \int_{\varepsilon_{K+1}}^{\varepsilon_1} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon。$$

(之后确定积分的上下限。)

对于上限，由于 $\varepsilon_1 = D/2 \leqslant D = \operatorname{diam}(\mathbb{T})$，因此将上限放宽至 $b = \operatorname{diam}(\mathbb{T})$。

对于下限，由于

$$\varepsilon_{K+1} = \frac{1}{4}\varepsilon_{K-1} > \frac{1}{4} \cdot \frac{w(\mathbb{T})}{2\sqrt{n}} = \frac{1}{8}\frac{w(\mathbb{T})}{\sqrt{n}},$$

因此令积分下限 $a = c\frac{w(\mathbb{T})}{\sqrt{n}}$，其中 $c = 1/8$，则 $a < \varepsilon_{K+1}$。

如此，

$$\int_{\varepsilon_{K+1}}^{\varepsilon_1} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon \leqslant \int_{a}^{b} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon,$$

即

$$w(\mathbb{T}) \leqslant C \int_{a}^{b} \sqrt{\ln \mathcal{N}(\mathbb{T}, \varepsilon)}\mathrm{d}\varepsilon, \qquad (C = 4C_1)$$

其中 $b=\operatorname{diam}(\mathbb{T})$，$a=\frac{cw(\mathbb{T})}{\sqrt{n}}$。

7 [**sub-Exponential Dudley 不等式**] 设 $(\mathbb{T},d)$ 为有限度量空间，或过程 $(X_t)_{t\in\mathbb{T}}$ 可分且下述各尺度的覆盖数有限。证明下述定理 T8.1.3 (Dudley 积分不等式) 的 sub-Exponential 版本：假设零均值随机过程 $(X_t)_{t\in\mathbb{T}}$ 的增量不再满足标准形式的 sub-Gaussian 分布，而是满足 sub-Exponential 的衰减特性。具体而言，存在常数 $K>0$，使得对于任意的 $t,s\in\mathbb{T}$，其增量的 sub-Exponential 范数 $\|\cdot\|_{\psi_1}$ 满足

$$\|X_t-X_s\|_{\psi_1}\leqslant Kd(t,s)。$$

证明 sub-Exponential 版本的 Dudley 不等式：

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant CK\int_0^\infty \ln\mathcal{N}(\mathbb{T},d,\varepsilon)\mathrm{d}\varepsilon。\qquad (C>0)$$

注释 **sub-Exponential 极大值引理** 设 $Z_1,\cdots,Z_N$ 为零均值随机变量 (未必相互独立)，满足 $\|Z_i\|_{\psi_1}\leqslant M$，则

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant N}Z_i\right]\leqslant cM\ln(N+1)。$$

证明 首先考虑有限的 $\mathbb{T}$。由于 $\mathbb{T}$ 有限，存在 k_0，使得当 $k\geqslant k_0$ 时 $\mathcal{N}_k=\mathbb{T}$，因此 $\pi_k(t)=t$，下述望远镜级数是有限和。

设 $D=\operatorname{diam}(\mathbb{T})$，定义二进尺度序列 $\varepsilon_k=D2^{-k}$，令 $\mathcal{N}_k$ 为 $\mathbb{T}$ 的最小 ε_k-网，则 $|\mathcal{N}_k|=\mathcal{N}(\mathbb{T},d,\varepsilon_k)$。

对于 $\varepsilon_0=D$，我们只需一个点即可覆盖 $\mathbb{T}$，因此 $|\mathcal{N}_0|=1$，设此唯一元素为 t_0。

对于任意的 $t\in\mathbb{T}$，定义投影映射 $\pi_k(t)\in\mathcal{N}_k$ 为网格距离 t 最近的点。

将 X_t 展开为望远镜级数，

$$X_t=X_{t_0}+\sum_{k=1}^{\infty}(X_{\pi_k(t)}-X_{\pi_{k-1}(t)})。$$

两侧取上确界并求期望，代入 $\mathrm{E}[X_{t_0}]=0$，可得

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant\sum_{k=1}^{\infty}\mathrm{E}\left[\sup_{t\in\mathbb{T}}(X_{\pi_k(t)}-X_{\pi_{k-1}(t)})\right]。$$

考虑单步增量 $\Delta_k(t)=X_{\pi_k(t)}-X_{\pi_{k-1}(t)}$，其至多有 $|\mathcal{N}_k||\mathcal{N}_{k-1}|\leqslant|\mathcal{N}_k|^2$ 种取值，对应的两点之间距离为

$$d(\pi_k(t),\pi_{k-1}(t))\leqslant d(\pi_k(t),t)+d(t,\pi_{k-1}(t))\leqslant\varepsilon_k+\varepsilon_{k-1}\leqslant 2\varepsilon_{k-1},$$

因此根据 sub-Exponential 条件，可得

$$\|\Delta_k(t)\|_{\psi_1}\leqslant Kd(\pi_k(t),\pi_{k-1}(t))\leqslant 2K\varepsilon_{k-1},$$

从而利用 sub-Exponential 极大值引理，可得

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}\Delta_k(t)\right]\leqslant c(2K\varepsilon_{k-1})\ln(|\mathcal{N}_k|^2)=4cK\varepsilon_{k-1}\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k),$$

即

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant C_1K\sum_{k=1}^{\infty}\varepsilon_{k-1}\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)。\qquad (C_1=4c)$$

对于右侧，令 $f(\varepsilon)=\ln\mathcal{N}(\mathbb{T},d,\varepsilon)$，则

$$\sum_{k=1}^{\infty}\varepsilon_{k-1}f(\varepsilon_k)=4\sum_{k=1}^{\infty}(\varepsilon_k-\varepsilon_{k+1})f(\varepsilon_k)\leqslant 4\int_0^{\varepsilon_1}\ln\mathcal{N}(\mathbb{T},d,\varepsilon)\mathrm{d}\varepsilon,$$

将积分上限扩展到 ∞，

$$\mathrm{E}\left[\sup_{t\in\mathbb{T}}X_t\right]\leqslant CK\int_0^\infty\ln\mathcal{N}(\mathbb{T},d,\varepsilon)\mathrm{d}\varepsilon。\qquad (C=4C_1)$$

对于可分过程，令 $\mathbb{T}_m$ 为包含 t_0 的递增有限子集，使得 $\sup_{t\in\mathbb{T}_m}X_t\uparrow\sup_{t\in\mathbb{T}}X_t$ 几乎处处成立。将有限情形应用于 $\mathbb{T}_m$，并利用 $\mathcal{N}(\mathbb{T}_m,d,\varepsilon)\leqslant\mathcal{N}(\mathbb{T},d,\varepsilon)$。由于 $\sup_{t\in\mathbb{T}_m}X_t-X_{t_0}\geqslant 0$ 单调收敛，取极限即可得相同结论。

注释 于标准 Dudley 不等式，过程是 sub-Gaussian 的，极大值的期望代价是 $\sqrt{\ln N}$。于 sub-Exponential 版本的 Dudley 不等式，极大值的期望代价上升为 $\ln N$。

8 [**局部 Dudley 不等式**] 设 $(\mathbb{T},d)$ 为有限度量空间，或过程可分且所显示的覆盖数有限。设 $(X_t)_{t\in\mathbb{T}}$ 为含有 sub-Gaussian 增量的随机过程，即存在 $K>0$，使得对于任意的 $s,t\in\mathbb{T}$，均满足 $\|X_s-X_t\|_{\psi_2}\leqslant Kd(s,t)$。给定半径 $\delta>0$，证明：

$$\mathrm{E}\left[\sup_{\substack{s,t\in\mathbb{T}\\ d(s,t)\leqslant\delta}}|X_s-X_t|\right]\leqslant CK\int_0^\delta\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon。$$

证明 首先考虑有限的 $\mathbb{T}$。由于 $\mathbb{T}$ 有限，存在 k_0，使得当 $k\geqslant k_0$ 时 $\mathcal{N}_k=\mathbb{T}$，因此 $\pi_k(t)=t$，下述望远镜级数是有限和。

构造不同尺度的网。

定义尺度序列 $\varepsilon_k=\delta 2^{-k}$，令 $\mathcal{N}_k\subset\mathbb{T}$ 为 $\mathbb{T}$ 在度量 d 的意义下的最小 ε_k-网，则 $|\mathcal{N}_k|=\mathcal{N}(\mathbb{T},d,\varepsilon_k)$。

对于任意的 $t\in\mathbb{T}$，定义投影 $\pi_k(t)\in\mathcal{N}_k$ 为 $\mathcal{N}_k$ 距离 t 最近的点，则 $d(t,\pi_k(t))\leqslant\varepsilon_k$。

- 进行链式展开

对于任意的满足 $d(s,t)\leqslant\delta$ 的 $s,t\in\mathbb{T}$，将增量 X_s-X_t 进行望远镜级数展开，

$$X_s-X_t=(X_{\pi_0(s)}-X_{\pi_0(t)})+\sum_{k=1}^\infty(X_{\pi_k(s)}-X_{\pi_{k-1}(s)})-\sum_{k=1}^\infty(X_{\pi_k(t)}-X_{\pi_{k-1}(t)}),$$

两侧取上确界，之后利用三角不等式，可得

$$\sup_{d(s,t)\leqslant\delta}|X_s-X_t|\leqslant\sup_{(v,w)\in E_0}|X_v-X_w|+2\sum_{k=1}^\infty\sup_{(v,w)\in E_k}|X_v-X_w|,$$

其中 $E_0=\{(\pi_0(s),\pi_0(t)):d(s,t)\leqslant\delta\}$，$E_k=\{(\pi_k(u),\pi_{k-1}(u)):u\in\mathbb{T}\}$。

(之后利用 sub-Gaussian 极大值引理进行界定。)

对于第二项，根据 sub-Gaussian 极大值引理，可得

$$\mathrm{E}\left[\sup_{(v,w)\in E_k}|X_v-X_w|\right]\leqslant C'Kd(v,w)\sqrt{\ln(|E_k|)},$$

代入 $d(v,w)\leqslant 3\varepsilon_k$，$|E_k|\leqslant|\mathcal{N}_k|^2$，可得

$$\mathrm{E}\left[\sup_{(v,w)\in E_k}|X_v-X_w|\right]\leqslant C'K(3\varepsilon_k)\sqrt{\ln(|\mathcal{N}_k|^2)}=3\sqrt{2}C'K\varepsilon_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)}。$$

同理，对于第一项，代入 $3\varepsilon_0=3\delta$，可得

$$\mathrm{E}\left[\sup_{(v,w)\in E_0}|X_v-X_w|\right]\leqslant 3\sqrt{2}C'K\delta\sqrt{\ln\mathcal{N}(\mathbb{T},d,\delta)}。$$

如此，

$$\mathrm{E}\left[\sup_{d(s,t)\leqslant\delta}|X_s-X_t|\right]\leqslant C_1K\sum_{k=0}^\infty\varepsilon_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)}。\qquad(C_1=6\sqrt{2}C')$$

- 将求和转化为积分

当 $\varepsilon\in[\varepsilon_{k+1},\varepsilon_k]$ 时，$\mathcal{N}(\mathbb{T},d,\varepsilon)\geqslant\mathcal{N}(\mathbb{T},d,\varepsilon_k)$，因此

$$\int_{\varepsilon_{k+1}}^{\varepsilon_k}\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon\geqslant(\varepsilon_k-\varepsilon_{k+1})\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)}=\frac{1}{2}\varepsilon_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)},$$

两侧求和，代入 $\varepsilon_0=\delta,\varepsilon_\infty=0$，可得

$$\int_0^\delta\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon\geqslant\frac{1}{2}\sum_{k=0}^\infty\varepsilon_k\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon_k)},$$

因此

$$\mathrm{E}\left[\sup_{d(s,t)\leqslant\delta}|X_s-X_t|\right]\leqslant 2C_1K\int_0^\delta\sqrt{\ln\mathcal{N}(\mathbb{T},d,\varepsilon)}\mathrm{d}\varepsilon,$$

此时令 $C=2C_1$。

对于可分过程，令 $\mathbb{T}_m$ 为递增有限子集，使得左侧随机变量几乎处处递增至原过程相应的左侧随机变量。将有限情形应用于 $\mathbb{T}_m$，并利用 $\mathcal{N}(\mathbb{T}_m,d,\varepsilon)\leqslant\mathcal{N}(\mathbb{T},d,\varepsilon)$。由于各左侧随机变量非负，利用单调收敛定理取极限，即得结论。

9 **[Lipschitz 函数族的覆盖数]** 考虑定义于 $[0,1]$, 取值于 $[0,1]$ 的 Lipschitz 常数不超过 1 的函数族，

$$\mathcal{F}=\{f:[0,1]\to[0,1]:\|f\|_{\mathrm{Lip}}\leqslant 1\}。$$

证明：对于任意的 $\varepsilon\in(0,1)$，此函数族在 L^∞ 范数下的覆盖数满足

$$\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant\mathrm{e}^{C/\varepsilon}。\qquad(C>0)$$

证明 • 将函数映射于离散格点

选择整数 $N=\lceil 2/\varepsilon\rceil$ 作为网格的划分数，于定义域 $[0,1]$ 构造等距网格点 $x_k=\frac{k}{N}$。(之后于值域 $[0,1]$ 构造离散取值集合 $Y_N=\{0,\frac{1}{N},\cdots,1\}$。)

(对于任意的 $f\in\mathcal{F}$，将其于 x_k 的真实取值 $f(x_k)$ 投影至距离最近的离散值域格点。)

定义序列 $\boldsymbol{v}=(v_0,v_1,\cdots,v_N)$，其中 $v_k\in Y_N$ 满足 $|f(x_k)-v_k|\leqslant\frac{1}{2N}$，则真实函数值满足

$$|f(x_k)-f(x_{k-1})|\leqslant|x_k-x_{k-1}|=\frac{1}{N},$$

因此三角不等式，可得

$$\begin{aligned}|v_k-v_{k-1}|&\leqslant|v_k-f(x_k)|+|f(x_k)-f(x_{k-1})|+|f(x_{k-1})-v_{k-1}|\\&\leqslant\frac{1}{2N}+\frac{1}{N}+\frac{1}{2N}=\frac{2}{N},\end{aligned}$$

由于 $v_k,v_{k-1}\in Y_N$，因此整数 $N(v_k-v_{k-1})$ 取值于 $\{-2,-1,0,1,2\}$。

(计算满足差值约束的序列 $\boldsymbol{v}$ 的总数。)

起点 v_0 于 Y_N 任意地选取，其可能的取值为 $N+1$ 种；对于 v_k $(k\geqslant 1)$，在给定 v_{k-1} 之后，其可能的取值最多为 5 种；因此全部可能的有效离散序列 $\boldsymbol{v}$ 的总数最多为 $(N+1)5^N$。

• 构造 ε-网并进行误差分析

(对于任意的有效的序列 $\boldsymbol{v}$，通过线性插值，构造分段仿射函数 $g_{\boldsymbol{v}}:[0,1]\to[0,1]$。)

对于任意的 $x\in[x_{k-1},x_k]$，将其表示为 $x=(1-t)x_{k-1}+tx_k$ $(t\in[0,1])$，之后定义 $g_{\boldsymbol{v}}(x)=(1-t)v_{k-1}+tv_k$，则逼近误差为

$$\begin{aligned}|f(x)-g_{\boldsymbol{v}}(x)|&=|f(x)-((1-t)v_{k-1}+tv_k)|\\&=|(1-t)(f(x)-v_{k-1})+t(f(x)-v_k)|\\&\leqslant(1-t)|f(x)-v_{k-1}|+t|f(x)-v_k|。\end{aligned}$$

其中

$$\begin{aligned}|f(x)-v_{k-1}|&\leqslant|f(x)-f(x_{k-1})|+|f(x_{k-1})-v_{k-1}|\\&\leqslant(x-x_{k-1})+\frac{1}{2N}\leqslant\frac{3}{2N},\\|f(x)-v_k|&\leqslant|f(x)-f(x_k)|+|f(x_k)-v_k|\\&\leqslant(x-x_k)+\frac{1}{2N}\leqslant\frac{3}{2N},\end{aligned}$$

将其代入，可得

$$|f(x)-g_{\boldsymbol{v}}(x)|\leqslant\frac{3}{2N},$$

即于 $[0,1]$ 满足

$$\|f-g_{\boldsymbol{v}}\|_{L^\infty}\leqslant\frac{3}{2N},$$

代入 $N=\lceil 2/\varepsilon\rceil\geqslant 2/\varepsilon$，可得

$$\|f-g_{\boldsymbol{v}}\|_{L^\infty}\leqslant\frac{3}{4}\varepsilon<\varepsilon,$$

因此 $\mathcal{G}=\{g_{\boldsymbol{v}}\}$ 构成 $\mathcal{F}$ 在 L^∞ 范数下的 ε-网，从而

$$\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant|\mathcal{G}|\leqslant(N+1)5^N。$$

两侧取对数，

$$\begin{aligned}\ln|\mathcal{G}|&\leqslant\ln(N+1)+N\ln 5\\&\leqslant N+N\ln 5=N(1+\ln 5),\end{aligned}$$

代入

$$N=\lceil 2/\varepsilon\rceil\leqslant\frac{2}{\varepsilon}+1<\frac{3}{\varepsilon},$$

可得

$$\ln|\mathcal{G}|\leqslant\frac{3(1+\ln 5)}{\varepsilon},$$

即

$$\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant\mathrm{e}^{C/\varepsilon}。\qquad(C=3(1+\ln 5))$$

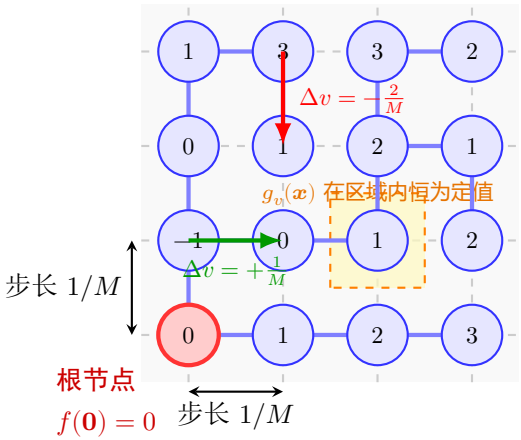
注释 本题结论可以进行推广：

高维 Lipschitz 函数族在一致范数下的覆盖数估计 设空间维度 $d\geqslant 1$。定义函数族 $\mathcal{F}$ 为

$$\mathcal{F}=\{f:[0,1]^d\to\mathbb{R}:|f(\boldsymbol{x})-f(\boldsymbol{y})|\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_\infty,f(\boldsymbol{0})=0\}。$$

则对于任意的 $\varepsilon\in(0,1)$，其在一致范数 $\|\cdot\|_{L^\infty}$ 下的覆盖数满足

$$\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant C_d\varepsilon^{-d}。\qquad(C_d>0)$$



1. 网格化 (V)

将 $[0,1]^d$ 划分为步长 $1/M$ 的网格。

2. 离散映射 (v_f)

将函数于节点的取值 $f(\boldsymbol{p})$ 舍入到 $\frac{1}{M}\mathbb{Z}$。

(注：左图圆圈内的整数即代表分子)

3. 增量限制

由于 f 为 Lipschitz 函数，相邻网格点的真实值差异 $\leqslant 1/M$。考虑到两端各自 $1/(2M)$ 的舍入误差，离散值的增量被限制为

$$|v_f(\boldsymbol{p})-v_f(\boldsymbol{q})|\leqslant\frac{2}{M},$$

$\Rightarrow$ 沿着边的状态转移只有 5 种可能，

$$\Delta v\in\{-2,-1,0,1,2\}。$$

4. 全局状态计数

根节点固定为 0，整个配置由生成树上的 $|V|-1$ 条边的增量唯一决定，

$$|\mathcal{V}|\leqslant 5^{|V|-1}\leqslant 5^{3^d\varepsilon^{-d}}。$$

证明 (为了避免由于各点独立离散化而产生额外的 $\ln(1/\varepsilon)$ 因子，我们将定义域离散化为网格，并利用图论的生成树结构。由于

函数满足题设的 Lipschitz 性质，沿着生成树相邻网格点的函数值增量是受限的。我们通过限制这些增量的离散状态，从而对函数族进行有效计数。)

- 构造定义域的离散网格, 图结构

选择整数 $M = \lceil 1/\varepsilon \rceil$，于 $[0,1]^d$ 构造等距网格 V，

$$V = \left\{ \left(\frac{i_1}{M}, \frac{i_2}{M}, \cdots, \frac{i_d}{M} \right) : i_k \in \{0, 1, \cdots, M\} \right\},$$

则网格点总数为

$$|V| = (M+1)^d < \left(\frac{1}{\varepsilon} + 2 \right)^d < \left(\frac{3}{\varepsilon} \right)^d = 3^d \varepsilon^{-d}。$$

将 V 视无向图的顶点集，具体而言，对于任意的网格点 $\boldsymbol{p}, \boldsymbol{q} \in V$，若其一致范数距离满足 $\|\boldsymbol{p} - \boldsymbol{q}\|_\infty = 1/M$，将其视为一条边，则 V 是连通的。

于 V 选择以原点 $\mathbf{0}$ 为根节点的生成树，记为 T，则 T 含有 $|V| - 1$ 条边。

- 将函数投影到离散网格状态

对于任意的 $f \in \mathcal{F}$，考虑将其于网格点的真实取值四舍五入至 $1/M$ 的整数倍。具体而言，定义网格的离散函数 $v_f : V \to \frac{1}{M}\mathbb{Z}$，满足对于任意的 $\boldsymbol{p} \in V$，

$$v_f(\boldsymbol{p}) = \frac{1}{M} \operatorname{round}(M f(\boldsymbol{p}))，$$

则网格点产生的值域投影误差为

$$|f(\boldsymbol{p}) - v_f(\boldsymbol{p})| \leqslant \frac{1}{2M}，$$

(计算有效的离散状态 v_f 的总数。)

由于 $f(\mathbf{0}) = 0$，因此 $v_f(\mathbf{0}) = 0$。

对于任意的 $\boldsymbol{p}, \boldsymbol{q} \in V$，利用三角不等式，可得

$$\begin{aligned} |v_f(\boldsymbol{p}) - v_f(\boldsymbol{q})| &\leqslant |v_f(\boldsymbol{p}) - f(\boldsymbol{p})| + |f(\boldsymbol{p}) - f(\boldsymbol{q})| + |f(\boldsymbol{q}) - v_f(\boldsymbol{q})| \\ &\leqslant \frac{1}{2M} + \|\boldsymbol{p} - \boldsymbol{q}\|_\infty + \frac{1}{2M} = \frac{1}{2M} + \frac{1}{M} + \frac{1}{2M} = \frac{2}{M}。 \end{aligned}$$

其中 $v_f(\boldsymbol{p}), v_f(\boldsymbol{q})$ 均为 $1/M$ 的整数倍，从而整数 $M(v_f(\boldsymbol{p}) - v_f(\boldsymbol{q}))$ 取值于 $\{-2, -1, 0, 1, 2\}$。

离散状态配置 v_f 由根节点 (固定为 $\mathbf{0}$) 以及沿着生成树 T 的 $|V| - 1$ 条边的增量所唯一确定，因此全部可能生成的离散配置的集合 $\mathcal{V}$ 的大小受限于

$$|\mathcal{V}| \leqslant 5^{|V|-1} \leqslant 5^{|V|} \leqslant 5^{3^d \varepsilon^{-d}}。$$

- 利用离散状态构造 ε-网

对于任意的 $v \in \mathcal{V}$，将其扩展为定义于 $[0,1]^d$ 的连续域函数 g_v。

对于任意的 $\boldsymbol{x} \in [0,1]^d$，令 $\boldsymbol{p}_{\boldsymbol{x}}$ 为网格 V 的距离 $\boldsymbol{x}$ 最近的网格点，则

$$\|\boldsymbol{x} - \boldsymbol{p}_{\boldsymbol{x}}\|_\infty \leqslant \frac{1}{2M}，$$

定义分块常数函数

$$g_v(\boldsymbol{x}) = v(\boldsymbol{p}_{\boldsymbol{x}})，$$

若离散配置 v_f 是由原函数 f 生成的，则对于任意的 $\boldsymbol{x} \in [0,1]^d$，

$$\begin{aligned} |f(\boldsymbol{x}) - g_{v_f}(\boldsymbol{x})| = |f(\boldsymbol{x}) - v_f(\boldsymbol{p}_{\boldsymbol{x}})| &\leqslant |f(\boldsymbol{x}) - f(\boldsymbol{p}_{\boldsymbol{x}})| + |f(\boldsymbol{p}_{\boldsymbol{x}}) - v_f(\boldsymbol{p}_{\boldsymbol{x}})| \\ &\leqslant \|\boldsymbol{x} - \boldsymbol{p}_{\boldsymbol{x}}\|_\infty + \frac{1}{2M} \leqslant \frac{1}{2M} + \frac{1}{2M} = \frac{1}{M} < \varepsilon，\end{aligned}$$

即 $\|f-g_{v_f}\|_{L^\infty}\leqslant\varepsilon$，因此 $\mathcal{G}=\{g_v:v\in\mathcal{V}\}$ 构成 $\mathcal{F}$ 的外 ε-网，从而

$$\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant|\mathcal{V}|\leqslant 5^{3^d\varepsilon^{-d}}。$$

两侧取对数，

$$\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant 3^d\ln(5)\varepsilon^{-d}。$$

此时令 $C_d=3^d\ln 5$。

10 [**高维 Lipschitz 大数定律**] 将定理 T8.2.3 (Lipschitz 大数定律) 推广到高维。

考虑定义于 $d\geqslant 2$ 维单位立方体 $[0,1]^d$ 的实值函数族 $\mathcal{F}$，其于度量空间 $(\mathbb{R}^d,\|\cdot\|_\infty)$ 满足 L-Lipschitz 条件，于原点取值为零，

$$\mathcal{F}=\{f:[0,1]^d\to\mathbb{R}:\|f\|_{\mathrm{Lip}}\leqslant L,f(\mathbf{0})=0\}。$$

设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_n$ 为取值于 $[0,1]^d$ 的独立同分布的随机向量。证明：

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^n f(\boldsymbol{X}_i)-\mathrm{E}[f(\boldsymbol{X}_1)]\right|\right]\leqslant C_dL\begin{cases}n^{-1/2}\ln n, & d=2,\\ n^{-1/d}, & d\geqslant 3\end{cases}。$$

按照以下步骤证明 (不妨设 $L=1$)：

(1) 将覆盖数的界推广到高维：

$$\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant \mathrm{e}^{C/\varepsilon^d}。$$

(2) 若直接将此界代入 Dudley 积分，积分会因 $\varepsilon=0$ 处的奇异性而发散。为修复这一点，证明如下精细化的界：对于任意的 $\delta\in[0,1]$，

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}|X_f|\right]\leqslant\delta+\frac{C}{\sqrt{n}}\int_\delta^1\sqrt{\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)}\mathrm{d}\varepsilon。$$

证明 • 确立高维覆盖数界限

利用齐次性，不妨设 $L=1$。

对于定义于 $[0,1]^d$ 的满足 $f(\mathbf{0})=0$ 的 1-Lipschitz 函数族 $\mathcal{F}$，根据习题 Q8.9 (Lipschitz 函数族的覆盖数) 的注释，可得对于任意的 $\varepsilon\in(0,1)$，

$$\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)\leqslant C_d\varepsilon^{-d}。\tag{I}$$

• 对称化, 截断 Dudley 积分

令

$$Z=\sup_{f\in\mathcal{F}}|\frac{1}{n}\sum_{i=1}^n f(\boldsymbol{X}_i)-\mathrm{E}[f(\boldsymbol{X}_1)]|,$$

引入独立同分布的 Rademacher 随机变量列 $\sigma_i\in\{-1,1\}$，则根据对称化引理，可得

$$\mathrm{E}[Z]\leqslant 2\mathrm{E}_{\boldsymbol{X}}\mathrm{E}_\sigma\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^n\sigma_i f(\boldsymbol{X}_i)\right|\right]。$$

固定样本 $\boldsymbol{X}_i$，则条件经验过程

$$Y_f=\frac{1}{n}\sum_{i=1}^n\sigma_i f(\boldsymbol{X}_i),$$

的增量满足方差代理

$$\frac{1}{n^2}\sum_{i=1}^n(f(\boldsymbol{X}_i)-g(\boldsymbol{X}_i))^2\leqslant\frac{1}{n}\|f-g\|_{L^\infty}^2,$$

因此 Y_f 在度量 $\frac{1}{\sqrt{n}}\|\cdot\|_{L^\infty}$ 的意义下满足 sub-Gaussian 增量。

给定截断水平 $\delta\in(0,1)$，令 $\pi_\delta(f)$ 为 L^∞ 范数的 δ-网距离 f 最近的函数，将 Y_f 进行分解，

$$Y_f=(Y_f-Y_{\pi_\delta(f)})+Y_{\pi_\delta(f)}。$$

对于尾部截断误差，利用三角不等式，可得

$$\sup_{f\in\mathcal{F}}|Y_f - Y_{\pi_\delta(f)}| \leqslant \sup_{f\in\mathcal{F}}\frac{1}{n}\sum_{i=1}^{n}|\sigma_i|\cdot|f(\boldsymbol{X}_i)-\pi_\delta(f)(\boldsymbol{X}_i)| \leqslant \|f-\pi_\delta(f)\|_{L^\infty} \leqslant \delta。$$

对于头部离散网部分，利用 Dudley 链式法则，可得

$$\mathrm{E}_\sigma\left[\sup_{f\in\mathcal{F}}|Y_{\pi_\delta(f)}|\right] \leqslant C'\int_{\delta/\sqrt{n}}^{1/\sqrt{n}}\sqrt{\ln\mathcal{N}\left(\mathcal{F},\frac{1}{\sqrt{n}}\|\cdot\|_{L^\infty},u\right)}\mathrm{d}u = \frac{C'}{\sqrt{n}}\int_\delta^1\sqrt{\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)}\mathrm{d}\varepsilon。$$

如此，

$$\mathrm{E}[Z] \leqslant 2\delta + \frac{2C'}{\sqrt{n}}\int_\delta^1\sqrt{\ln\mathcal{N}(\mathcal{F},\|\cdot\|_{L^\infty},\varepsilon)}\mathrm{d}\varepsilon。 \tag{II}$$

联立 (I)(II)，可得

$$\mathrm{E}[Z] \leqslant 2\delta + \frac{C_1}{\sqrt{n}}\int_\delta^1\varepsilon^{-d/2}\mathrm{d}\varepsilon。 \tag{III}$$

a. 当 $d=2$ 时，$\int_\delta^1\varepsilon^{-d/2}\mathrm{d}\varepsilon = \ln(1/\delta)$，此时

$$\mathrm{E}[Z] \leqslant 2\delta + \frac{C_1}{\sqrt{n}}\ln(1/\delta)。$$

(为平衡两项) 之后令 $\delta = n^{-1/2}$，可得

$$\mathrm{E}[Z] \leqslant 2n^{-1/2} + \frac{C_1}{\sqrt{n}}\ln(\sqrt{n}) \leqslant C_2 n^{-1/2}\ln n。$$

b. 当 $d\geqslant 3$ 时，

$$\int_\delta^1\varepsilon^{-d/2}\mathrm{d}\varepsilon \leqslant \frac{2}{d-2}\delta^{1-d/2},$$

此时

$$\mathrm{E}[Z] \leqslant 2\delta + \frac{C_3}{\sqrt{n}}\delta^{1-d/2},$$

(为平衡两项) 之后令 $\delta = \frac{1}{\sqrt{n}}\delta^{1-d/2}$，即 $\delta = n^{-1/d}$，可得

$$\mathrm{E}[Z] \leqslant 2n^{-1/d} + \frac{C_3}{\sqrt{n}}(n^{-1/d})^{(2-d)/2} = 2n^{-1/d} + C_3 n^{-1/2}n^{-1/d+1/2} = (2+C_3)n^{-1/d}。$$

综上，当 $L=1$ 时，

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(\boldsymbol{X}_i) - \mathrm{E}[f(\boldsymbol{X}_1)]\right|\right] \leqslant C_d\begin{cases}n^{-1/2}\ln n, & d=2,\\ n^{-1/d}, & d\geqslant 3\end{cases},$$

对于一般情况，

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(\boldsymbol{X}_i) - \mathrm{E}[f(\boldsymbol{X}_1)]\right|\right] \leqslant C_d L\begin{cases}n^{-1/2}\ln n, & d=2,\\ n^{-1/d}, & d\geqslant 3\end{cases}。$$

11 [**经验过程的对称化引理**] 修改对称化引理 L6.3.2 (对称化) 的证明，得到如下版本的对称化引理。

设 Ω 为论域，$\mathcal{F}$ 为定义于 Ω 的实值函数族。设 $X, X_1, \cdots, X_n$ 为取值于 Ω 的独立同分布的随机变量。证明：

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i) - \mathrm{E}[f(X)]\right|\right] \leqslant 2\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i f(X_i)\right|\right],$$

其中 $\varepsilon_1, \cdots, \varepsilon_n$ i.i.d. $\sim$ Rademacher 独立于 $X_1, \cdots, X_n$。

证明 设 $X_1',\cdots,X_n'$ 为 $X_1,\cdots,X_n$ 的独立同分布的副本，则 $\mathrm{E}[f(X)]=\mathrm{E}_{X'}[f(X_i')]$，因此

$$\frac{1}{n}\sum_{i=1}^{n}f(X_i)-\mathrm{E}[f(X)]=\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-\mathrm{E}_{X'}[f(X_i')])=\mathrm{E}_{X'}\left[\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-f(X_i'))\right]。$$

定义凸泛函 $\Phi(Z)=\sup_{f\in\mathcal{F}}|Z_f|$，则利用 Jensen 不等式，可得

$$\sup_{f\in\mathcal{F}}\left|\mathrm{E}_{X'}\left[\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-f(X_i'))\right]\right|\leqslant\mathrm{E}_{X'}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-f(X_i'))\right|\right],$$

两侧关于 X 取期望，

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i)-\mathrm{E}[f(X)]\right|\right]\leqslant\mathrm{E}_{X,X'}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-f(X_i'))\right|\right]。$$

之后引入独立的 Rademacher 随机变量 $\varepsilon_i\in\{-1,1\}$，则 $f(X_i)-f(X_i')\overset{d}{=}\varepsilon_i(f(X_i)-f(X_i'))$，因此

$$\mathrm{E}_{X,X'}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-f(X_i'))\right|\right]=\mathrm{E}_{X,X',\varepsilon}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i(f(X_i)-f(X_i'))\right|\right],$$

其中右侧为

$$\begin{aligned}\mathrm{E}_{X,X',\varepsilon}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i(f(X_i)-f(X_i'))\right|\right]&\leqslant\mathrm{E}_{X,\varepsilon}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i f(X_i)\right|\right]+\mathrm{E}_{X',\varepsilon}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i f(X_i')\right|\right]\\&\leqslant 2\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i f(X_i)\right|\right],\end{aligned}$$

将其代入，可得

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i)-\mathrm{E}[f(X)]\right|\right]\leqslant 2\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i f(X_i)\right|\right]。$$

12 **[双区间并集的 VC 维度]** 于实数轴 $\mathbb{R}$，考虑由 2 个闭区间之并构成的集合族 $\mathcal{C}=\{[a,b]\cup[c,d]:a,b,c,d\in\mathbb{R}\}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\mathrm{vc}(\mathcal{F})=4。$$

证明 证明存在性。

于 $\mathbb{R}$ 选择 4 个严格递增的点所构成的集合 $\mathbb{S}=\{x_1,x_2,x_3,x_4\}$，其中 $x_1<x_2<x_3<x_4$。我们只需证明对于任意的 $\mathbb{S}'\subset\mathbb{S}$，均存在 $A\in\mathcal{C}$，使得 $A\cap\mathbb{S}=\mathbb{S}'$。

$\mathbb{S}'$ 根据其含有点的连续性可以分为以下几类，我们分别构造对应的双区间并集 A：

a. 当 $\mathbb{S}'=\emptyset$ 时，选取 $A=[x_1-2,x_1-1]\cup[x_1-2,x_1-1]$，则 $A\cap\mathbb{S}=\emptyset$。

b. 当 $\mathbb{S}'$ 含有 1 个连续段时，(例如 $\{x_1\}$, $\{x_2,x_3\}$, $\{x_1,x_2,x_3,x_4\}$)，对于任意的形如 $\{x_i,\cdots,x_j\}$ $(i\leqslant j)$ 的连续子集，只需一个区间即可覆盖。选取 $A=[x_i,x_j]\cup\emptyset$，则 $A\cap\mathbb{S}=\mathbb{S}'$。

c. 当 $\mathbb{S}'$ 含有 2 个分离的连续段时，则于 4 个点的集合，存在以下情况：

1. 对于 $\{x_1,x_3\}$ 令 $A=[x_1,x_1]\cup[x_3,x_3]$；
2. 对于 $\{x_1,x_4\}$，选取 $A=[x_1,x_1]\cup[x_4,x_4]$；
3. 对于 $\{x_2,x_4\}$，选取 $A=[x_2,x_2]\cup[x_4,x_4]$；
4. 对于 $\{x_1,x_2,x_4\}$，选取 $A=[x_1,x_2]\cup[x_4,x_4]$；
5. 对于 $\{x_1,x_3,x_4\}$，选取 $A=[x_1,x_1]\cup[x_3,x_4]$。

由于 $\mathcal{C}$ 允许利用 2 个区间，因此我们总是可以用第一个区间覆盖第一段，第二个区间覆盖第二段。

如此，$\mathbb{S}$ 的全部 $2^4=16$ 个子集均可被 $\mathcal{C}$ 切分，因此 $\mathbb{S}$ 被 $\mathcal{F}$ 打散，即 $\mathrm{vc}(\mathcal{F})\geqslant 4$。

证明最优性。

利用反证法，假设存在含有 5 个点的集合 $\mathbb{S}=\{x_1,x_2,x_3,x_4,x_5\}$ 可以被 $\mathcal{F}$ 打散，不妨设 $x_1<x_2<x_3<x_4<x_5$，则对于任意的 $\mathbb{S}'\subset\mathbb{S}$，存在 $A=I_1\cup I_2\in\mathcal{C}$ (其中 I_1,I_2 为闭区间)，使得 $A\cap\mathbb{S}=\mathbb{S}'$。

构造特定的交替子集 $\mathbb{S}'=\{x_1,x_3,x_5\}$。由于 $A\cap\mathbb{S}=\mathbb{S}'$，因此 $x_1\in A$，$x_2\notin A$，$x_3\in A$，$x_4\notin A$，$x_5\in A$。

考虑 $x_1\in A=I_1\cup I_2$，不妨设 $x_1\in I_1$。由于 $x_2\notin A$，因此 $x_2\notin I_1$，从而 $\sup I_1<x_2$，即对于任意的 $y\geqslant x_2$，均满足 $y\notin I_1$。

考虑 $x_3\in A$。根据前面的推论，可得 $x_3\notin I_1$。由于 $x_3\in I_1\cup I_2$，因此 $x_3\in I_2$。

考虑 $x_4\notin A$。由于 $x_4\notin I_2$，因此 $\sup I_2<x_4$，从而对于任意的 $y\geqslant x_4$，均满足 $y\notin I_2$。

最后考虑 $x_5\in A$，即 $x_5\in I_1\cup I_2$。由于 $x_5>x_2$，因此 $x_5\notin I_1$；由于 $x_5>x_4$，因此 $x_5\notin I_2$，从而 $x_5\notin I_1\cup I_2=A$，矛盾；

如此，不存在任意的含有 5 个点的集合可以被 $\mathcal{F}$ 打散，从而 $\mathrm{vc}(\mathcal{F})\leqslant 4$，即 $\mathrm{vc}(\mathcal{F})=4$。

13 [**二维圆盘的 VC 维度**] 于二维 Euclidean 空间 $\mathbb{R}^2$，考虑由任意闭圆盘构成的集合族 $\mathcal{C}=\{\boldsymbol{x}\in\mathbb{R}^2:\|\boldsymbol{x}-\boldsymbol{c}\|_2\leqslant r,\boldsymbol{c}\in\mathbb{R}^2,r\geqslant 0\}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\mathrm{vc}(\mathcal{F})=3。$$

证明 证明存在性。

于 $\mathbb{R}^2$ 选取 3 个不共线的点所构成的集合 $\mathbb{S}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3\}$ (例如构成一个等边三角形的三个顶点)。我们只需证明 $\mathbb{S}$ 的全部 $2^3=8$ 个子集 $\mathbb{S}'$ 均可以通过某个闭圆盘进行截取。

a. 当 $\mathbb{S}'=\emptyset$ 时，选取半径为 0, 远离 $\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3$ 的圆盘；

b. 当 $\mathbb{S}'$ 含有 1 个点时，(例如 $\{\boldsymbol{x}_1\}$)，选取以 $\boldsymbol{x}_1$ 为圆心, 半径充分的圆盘；

c. 当 $\mathbb{S}'$ 含有 2 个点时，(例如 $\{\boldsymbol{x}_1,\boldsymbol{x}_2\}$)，选取以线段 $\boldsymbol{x}_1\boldsymbol{x}_2$ 的中点为圆心，半径为 $\frac{1}{2}\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2$ 的圆盘。不妨设 $\boldsymbol{x}_1\boldsymbol{x}_2$ 为锐角所对应的边 (即以 $\boldsymbol{x}_3$ 为顶点的角 $\angle\boldsymbol{x}_1\boldsymbol{x}_3\boldsymbol{x}_2$ 为锐角)，则圆盘不含有 $\boldsymbol{x}_3$；

d. 当 $\mathbb{S}'$ 含有 3 个点时，(例即 $\mathbb{S}$)，选取三个点构成的三角形的外接圆圆盘。

如此，$\mathrm{vc}(\mathcal{F})\geqslant 3$。

证明最优性。

利用反证法，假设存在含有 4 个点的集合 $\mathbb{S}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3,\boldsymbol{x}_4\}$ 可以被 $\mathcal{F}$ 打散，则对于平面的 4 个点，其几何构型仅可能属于以下两种情况之一，我们将分别证明这两种情况均产生矛盾：

a. 存在一个点于其余三个点的凸包

不妨设 $\boldsymbol{x}_4\in\mathrm{conv}(\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3)$。

由于 $\mathbb{S}$ 可以被打散，因此存在圆盘 $D\in\mathcal{C}$，使得能够单独截取子集 $\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3\}$，即 $\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3\in D$，$\boldsymbol{x}_4\notin D$。

但是，闭圆盘 D 为凸集，若 $\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3\in D$，则 $\mathrm{conv}(\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3)\subset D$，即 $\boldsymbol{x}_4\in D$，矛盾；如此，此情况不可能。

b. 4 个点构成凸四边形的四个顶点

不妨设这四个点按顺时针顺序排列为 $\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3,\boldsymbol{x}_4$。凸四边形的内角和为 2π，故可设对角内角满足

$$\angle\boldsymbol{x}_1\boldsymbol{x}_2\boldsymbol{x}_3+\angle\boldsymbol{x}_1\boldsymbol{x}_4\boldsymbol{x}_3\geqslant\pi.$$

若该集合被打散，则存在闭圆盘 D 包含 $\boldsymbol{x}_1,\boldsymbol{x}_3$，排除 $\boldsymbol{x}_2,\boldsymbol{x}_4$。使用圆盘–弦引理：当闭圆盘包含弦端点 a,b，而点 z,w 位于圆盘外部且分居直线 ab 两侧时，有 $\angle azb+\angle awb<\pi$。该引理由圆的幂定理和圆周角定理直接得到：外部点对弦 ab 的张角严格小于同侧边界圆弧的圆周角，而两侧边界圆周角之和为 π。取 $a=\boldsymbol{x}_1$，$b=\boldsymbol{x}_3$，$z=\boldsymbol{x}_2$，$w=\boldsymbol{x}_4$，便有

$$\angle\boldsymbol{x}_1\boldsymbol{x}_2\boldsymbol{x}_3+\angle\boldsymbol{x}_1\boldsymbol{x}_4\boldsymbol{x}_3<\pi,$$

与前述内角和下界矛盾；故凸四边形情形也不能被打散。

如此，不存在任意的含有 4 个点的集合可以被 $\mathcal{F}$ 打散，从而 $\mathrm{vc}(\mathcal{F})\leqslant 3$，即 $\mathrm{vc}(\mathcal{F})=3$。

14 [**轴对齐矩形的 VC 维度**] 于二维 Euclidean 空间 $\mathbb{R}^2$，考虑由任意闭的轴对齐矩形构成的集合族 $\mathcal{C}=\{[a,b]\times[c,d]:a,b,c,d\in\mathbb{R},a\leqslant b,c\leqslant d\}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\mathrm{vc}(\mathcal{F})=4。$$

证明 证明存在性。

于 $\mathbb{R}^2$ 选取呈菱形分布的 4 个点所构成的集合 $\mathbb{S}=\{\boldsymbol{p}_1,\boldsymbol{p}_2,\boldsymbol{p}_3,\boldsymbol{p}_4\}$，其坐标分别为 $\boldsymbol{p}_1=(0,1)$，$\boldsymbol{p}_2=(1,0)$，$\boldsymbol{p}_3=(0,-1)$，

$\boldsymbol{p}_4=(-1,0)$。我们只需证明对于任意的 $\mathbb{S}'\subset\mathbb{S}$，均存在 $R\in\mathcal{C}$，使得 $R\cap\mathbb{S}=\mathbb{S}'$。

同理于习题 Q8.12 (双区间并集的 VC 维度)，对 $\mathbb{S}'$ 含有点的个数进行分类讨论，我们分别构造对应的轴对齐矩形 R：

a. 当 $\mathbb{S}'$ 含有 0 个点时，选取 $R=[2,3]\times[2,3]$，则 $R\cap\mathbb{S}=\emptyset$。

b. 当 $\mathbb{S}'$ 含有 1 个点时，(例如 $\{\boldsymbol{p}_1\}$)，选取以 $\boldsymbol{p}_1$ 为中心, 边长充分小的矩形。

c. 当 $\mathbb{S}'$ 含有 2 个点时，存在以下情况：

1. 对于相邻点 (例如 $\{\boldsymbol{p}_1,\boldsymbol{p}_2\}$)，选取包围它们的最小矩形 $R=[0,1]\times[0,1]$，则 $R\notin\boldsymbol{p}_3,\boldsymbol{p}_4$。
2. 对于相对点 (例如 $\{\boldsymbol{p}_1,\boldsymbol{p}_3\}$)，选取矩形 $R=[-0.1,0.1]\times[-1,1]$，则 $R\notin\boldsymbol{p}_2,\boldsymbol{p}_4$ (排除了 x 坐标为 1 和 -1 的点)。

d. 当 $\mathbb{S}'$ 含有 3 个点时，(例如 $\{\boldsymbol{p}_1,\boldsymbol{p}_2,\boldsymbol{p}_3\}$)，选取这三个点的最小外接矩形 $R=[0,1]\times[-1,1]$，则 $R\notin\boldsymbol{p}_4$。

e. 当 $\mathbb{S}'$ 含有 4 个点时，(即 $\mathbb{S}$)，选取 $R=[-1,1]\times[-1,1]$。

如此，$\mathbb{S}$ 的全部 $2^4=16$ 个子集均可被 $\mathcal{C}$ 切分，因此 $\mathbb{S}$ 被 $\mathcal{F}$ 打散，即 $\mathrm{vc}(\mathcal{F})\geqslant 4$。

证明最优性。

利用反证法，假设存在含有 5 个点的集合 $\mathbb{S}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3,\boldsymbol{x}_4,\boldsymbol{x}_5\}$ 可以被 $\mathcal{F}$ 打散。

对于这 5 个点，考虑其于 x 轴, y 轴的坐标极值，设含有最小 x 坐标, 最大 x 坐标, 最小 y 坐标, 最大 y 坐标的点分别为 $\boldsymbol{x}_{\text{left}},\boldsymbol{x}_{\text{right}},\boldsymbol{x}_{\text{bottom}},\boldsymbol{x}_{\text{top}}$，定义由极值点构成的子集为 $\mathbb{S}_{\text{ext}}=\{\boldsymbol{x}_{\text{left}},\boldsymbol{x}_{\text{right}},\boldsymbol{x}_{\text{bottom}},\boldsymbol{x}_{\text{top}}\}\subset\mathbb{S}$。

(注意某个点可能同时占据两个极值，因此 $|\mathbb{S}_{\text{ext}}|\leqslant 4$。)

由于 $\mathbb{S}$ 含有 5 个点，因此存在 $\boldsymbol{p}_{\text{inner}}$，满足 $\boldsymbol{p}_{\text{inner}}\in\mathbb{S}$，$\boldsymbol{p}_{\text{inner}}\notin\mathbb{S}_{\text{ext}}$。

由于 $\mathbb{S}$ 可以被打散，因此存在轴对齐矩形 $R=[a,b]\times[c,d]\in\mathcal{C}$，使得能够单独截取出子集 $\mathbb{S}_{\text{ext}}$，排除 $\boldsymbol{p}_{\text{inner}}$，即 $\mathbb{S}_{\text{ext}}\subset R$，$\boldsymbol{p}_{\text{inner}}\notin R$。

考虑 $R=[a,b]\times[c,d]\supset\mathbb{S}$。由于 $\boldsymbol{x}_{\text{left}}\in R$，因此 $a\leqslant\boldsymbol{x}_{\text{left}}$ 的 x 坐标；由于 $\boldsymbol{x}_{\text{right}}\in R$，因此 $b\geqslant\boldsymbol{x}_{\text{right}}$ 的 x 坐标；由于 $\boldsymbol{x}_{\text{bottom}}\in R$，因此 $c\leqslant\boldsymbol{x}_{\text{bottom}}$ 的 y 坐标；由于 $\boldsymbol{x}_{\text{top}}\in R$，因此 $d\geqslant\boldsymbol{x}_{\text{top}}$ 的 y 坐标；从而 R 的边界必然含有了整个集合 $\mathbb{S}$ 的最小外接矩形。

由于 $\boldsymbol{p}_{\text{inner}}$ 的坐标受到这些极值的限制 (其 x 坐标位于左右极值之间，y 坐标位于上下极值之间)，因此 $\boldsymbol{p}_{\text{inner}}\in R$，矛盾；

如此，不存在任意的含有 5 个点的集合可以被 $\mathcal{F}$ 打散，从而 $\mathrm{vc}(\mathcal{F})\leqslant 4$，即 $\mathrm{vc}(\mathcal{F})=4$。

15 [**轴对齐正方形的 VC 维度**] 于二维 Euclidean 空间 $\mathbb{R}^2$，考虑由任意闭的轴对齐正方形构成的集合族 $\mathcal{C}=\{[a,a+l]\times[b,b+l]:a,b\in\mathbb{R},l\geqslant 0\}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\mathrm{vc}(\mathcal{F})=3。$$

证明 • 证明存在性

于 $\mathbb{R}^2$ 选取 3 个点所构成的集合 $\mathbb{S}=\{\boldsymbol{p}_1,\boldsymbol{p}_2,\boldsymbol{p}_3\}$，其坐标分别为 $\boldsymbol{p}_1=(1,0)$，$\boldsymbol{p}_2=(-1,0)$，$\boldsymbol{p}_3=(0,1)$。我们只需证明对于任意的 $\mathbb{S}'\subset\mathbb{S}$，均存在正方形 $Q\in\mathcal{C}$，使得 $Q\cap\mathbb{S}=\mathbb{S}'$。

根据 $\mathbb{S}'$ 含有点的个数进行分类讨论，分别构造对应的正方形 Q：

a. 当 $\mathbb{S}'$ 含有 0 个点时，选取 $Q=[10,11]\times[10,11]$，则 $Q\cap\mathbb{S}=\emptyset$。

b. 当 $\mathbb{S}'$ 含有 1 个点时，存在以下情况：

1. 对于 $\{\boldsymbol{p}_1\}$，选取 $Q=[0.5,1.5]\times[-0.5,0.5]$；
2. 对于 $\{\boldsymbol{p}_2\}$，选取 $Q=[-1.5,-0.5]\times[-0.5,0.5]$；
3. 对于 $\{\boldsymbol{p}_3\}$，选取 $Q=[-0.5,0.5]\times[0.5,1.5]$。

c. 当 $\mathbb{S}'$ 含有 2 个点时，存在以下情况：

1. 对于 $\{\boldsymbol{p}_1,\boldsymbol{p}_2\}$，选取边长为 2.2 的正方形 $Q=[-1.1,1.1]\times[-1.5,0.5]$。其覆盖了 $(1,0)$ 和 $(-1,0)$，由于最高点 $y=0.5<1$，排除了 $\boldsymbol{p}_3(0,1)$；
2. 对于 $\{\boldsymbol{p}_1,\boldsymbol{p}_3\}$，选取 $Q=[0,1.5]\times[0,1.5]$，则 $Q\notin\boldsymbol{p}_2$；
3. 对于 $\{\boldsymbol{p}_2,\boldsymbol{p}_3\}$，选取 $Q=[-1.5,0]\times[0,1.5]$，则 $Q\notin\boldsymbol{p}_1$。

d. 当 $\mathbb{S}'$ 含有 3 个点时，(即 $\mathbb{S}$)，选取 $Q=[-1,1]\times[-1,1]$。

如此，$\mathbb{S}$ 的全部 $2^3=8$ 个子集均可被 $\mathcal{C}$ 切分，因此 $\mathbb{S}$ 被 $\mathcal{F}$ 打散，即 $\mathrm{vc}(\mathcal{F})\geqslant 3$。

• 证明最优性

利用反证法，假设存在含有 4 个点的集合 $\mathbb{S}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_3,\boldsymbol{x}_4\}$ 可以被 $\mathcal{F}$ 打散。

考虑这 4 个点于坐标轴的极值，设 $x_{\min},x_{\max}$ 为 x 坐标的最小值, 最大值，$y_{\min},y_{\max}$ 为 y 坐标的最小值, 最大值。定义宽 $W=x_{\max}-x_{\min}$，高 $H=y_{\max}-y_{\min}$。分为两种情况讨论：

a. 4 个点没有各自占据独立的极值位置

即存在 $\boldsymbol{p}_{\text{inner}}\in\mathbb{S}$ 不是最左侧, 最右侧, 最上侧, 最下侧的点，则 $\boldsymbol{p}_{\text{inner}}$ 必定落于其他 3 个点界定的最小外接矩形。

由于 $\mathbb{S}$ 可以被打散，因此存在正方形能截取出不含有 $\boldsymbol{p}_{\text{inner}}$ 的其余 3 个点。

然而，任意覆盖那 3 个外围点的正方形，必然覆盖它们的最小外接矩形，从而不可避免地含有 $\boldsymbol{p}_{\text{inner}}$，矛盾；如此，此情况不可能。

b. 4 个点恰好各自占据了一个极值

设四个点分别为 $\boldsymbol{p}_{\text{left}},\boldsymbol{p}_{\text{right}},\boldsymbol{p}_{\text{bottom}},\boldsymbol{p}_{\text{top}}$。不妨设 $W\geqslant H$ (若 $H>W$，则可通过交换 x,y 轴，得到相同结论)。

考虑截取子集 $\mathbb{S}'=\{\boldsymbol{p}_{\text{left}},\boldsymbol{p}_{\text{right}}\}$。假设存在正方形 $Q=[a,a+l]\times[b,b+l]$ 满足 $Q\cap\mathbb{S}=\mathbb{S}'$。

由于 $\boldsymbol{p}_{\text{left}},\boldsymbol{p}_{\text{right}}\in Q$，因此 $a\leqslant x_{\min}$，$a+l\geqslant x_{\max}$，从而正方形边长满足 $l\geqslant x_{\max}-x_{\min}=W$。

由于 $\boldsymbol{p}_{\text{left}}\in Q$，因此其纵坐标必定位于正方形，即 $b\leqslant\boldsymbol{p}_{\text{left}}^{(y)}\leqslant b+l$。

(为了排除 $\boldsymbol{p}_{\text{top}}$，由于其横坐标在 $[x_{\min},x_{\max}]\subset[a,a+l]$ 范围，只能让其纵坐标落于 $[b,b+l]$ 以外；同理，为了排除 $\boldsymbol{p}_{\text{bottom}}$，其纵坐标必须严格落于下方。)

由于 $\boldsymbol{p}_{\text{top}}^{(y)}=y_{\max}\geqslant\boldsymbol{p}_{\text{left}}^{(y)}\geqslant b$，因此必须严格落于方，即

$$y_{\max}>b+l;$$

同理，

$$y_{\min}<b;$$

从而

$$H=y_{\max}-y_{\min}>(b+l)-b=l。$$

即 $H>l>W$，这与 $W\geqslant H$ 矛盾；如此，此情况不可能。

如此，不存在任意的含有 4 个点的集合可以被 $\mathcal{F}$ 打散，从而 $\text{vc}(\mathcal{F})\leqslant 3$，即 $\text{vc}(\mathcal{F})=3$。

16 [**凸多边形的 VC 维度**] 于二维 Euclidean 空间 $\mathbb{R}^2$，考虑由任意凸多边形构成的集合族 $\mathcal{C}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\text{vc}(\mathcal{F})=\infty。$$

证明 对于任意的 $N\geqslant 1$，于 $\mathbb{R}^2$ 的单位圆周 $C=\{\boldsymbol{x}\in\mathbb{R}^2:\|\boldsymbol{x}\|_2=1\}$ 选取 N 个不同的点，构成集合 $\mathbb{S}=\{\boldsymbol{p}_1,\boldsymbol{p}_2,\cdots,\boldsymbol{p}_N\}$。

证明任意的子集可被截取

对于 $\mathbb{S}$ 的任意的子集 $\mathbb{S}'\subset\mathbb{S}$，我们只需构造凸多边形 $P\in\mathcal{C}$，使得 $P\cap\mathbb{S}=\mathbb{S}'$。

根据 $\mathbb{S}'$ 含有元素的个数，进行分类讨论：

a. 当 $|\mathbb{S}'|\geqslant 3$ 时，定义 $P=\text{conv}(\mathbb{S}')$。由于 $\mathbb{S}'$ 含有至少 3 个圆周的离散点，其凸包必然构成非退化的凸多边形，并且此多边形的顶点恰好为 $\mathbb{S}'$ 的点，因此 $P\in\mathcal{C}$，$\mathbb{S}'\subset P$。

对于任意的 $\boldsymbol{q}\in\mathbb{S}\setminus\mathbb{S}'$，由于 $\boldsymbol{q}$ 位于单位圆周 C，根据圆的凸性，圆周上任意的多个点的凸包，其全部边，内部点均严格位于圆的内部。既然 $\boldsymbol{q}$ 于圆周，不为凸包 P 的顶点，因此 $\boldsymbol{q}\notin P$，从而 $P\cap\mathbb{S}=\mathbb{S}'$。

b. 当 $|\mathbb{S}'|\leqslant 2$ 时，由于三角形为最简单的凸多边形 (属于集合族 $\mathcal{C}$)，我们利用极小的三角形处理边界情况：

1. 当 $\mathbb{S}'=\emptyset$ 时，于单位圆外构造不同圆相交的三角形 P，则 $P\cap\mathbb{S}=\emptyset$。
2. 当 $\mathbb{S}'=\{\boldsymbol{p}_i\}$ 时，以 $\boldsymbol{p}_i$ 为中心，构造边长充分小的三角形 P，则 $P\cap\mathbb{S}=\{\boldsymbol{p}_i\}$。
3. 当 $\mathbb{S}'=\{\boldsymbol{p}_i,\boldsymbol{p}_j\}$ 时，构造含有线段 $\boldsymbol{p}_i\boldsymbol{p}_j$ 的狭窄三角形 P，通过控制宽度使其排除 $\mathbb{S}$ 的其余 $N-2$ 个点，则 $P\cap\mathbb{S}=\{\boldsymbol{p}_i,\boldsymbol{p}_j\}$。

如此，无论正整数 N 取何值，我们总能于圆周选取 N 个点，使得其全部 2^N 个子集均可被特定的凸多边形截取，即 $\mathbb{S}$ 被 $\mathcal{F}$ 打散，从而 $\text{vc}(\mathcal{F})\geqslant N$，即 $\text{vc}(\mathcal{F})=\infty$。

17 [**半空间的 VC 维度**] 证明例 E8.3.5 (半空间) 的结果。于 n 维 Euclidean 空间 $\mathbb{R}^n$，考虑由任意闭半空间构成的集合族

$\mathcal{C}=\{\{\boldsymbol{x}\in\mathbb{R}^n:\boldsymbol{w}^\top\boldsymbol{x}+b\geqslant 0\}:\boldsymbol{w}\in\mathbb{R}^n,b\in\mathbb{R}\}$。令 $\mathcal{F}=\{\mathbf{1}_A:A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 所对应的示性函数族。证明：$\mathcal{F}$ 的 Vapnik-Chervonenkis 维度为

$$\mathrm{vc}(\mathcal{F})=n+1。$$

证明 • 证明存在性

于 $\mathbb{R}^n$ 选取原点 $\mathbf{0}$ 以及 n 个标准正交基向量 $\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_n$，构成含有 $n+1$ 个点的集合 $\mathbb{S}=\{\mathbf{0},\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_n\}$。我们只需证明对于任意的 $\mathbb{S}'\subset\mathbb{S}$，均存在 $\boldsymbol{w},b$，使得由 $\boldsymbol{w}^\top\boldsymbol{x}+b\geqslant 0$ 定义的半空间恰好含有 $\mathbb{S}'$，排除 $\mathbb{S}\setminus\mathbb{S}'$。

定义目标分类标签 y_i 为

$$y_i=\begin{cases}1, & \boldsymbol{e}_i\in\mathbb{S}',\\ -1, & \boldsymbol{e}_i\notin\mathbb{S}'\end{cases},$$

令权重向量 $\boldsymbol{w}=(y_1,y_2,\cdots,y_n)^\top$，构造半空间的参数为

$$b=\begin{cases}0.5, & \mathbf{0}\in\mathbb{S}',\\ -0.5, & \mathbf{0}\notin\mathbb{S}'\end{cases}。$$

验证此构造的正确性：

a. 对于原点 $\boldsymbol{x}=\mathbf{0}$，$\boldsymbol{w}^\top\mathbf{0}+b=b$。由于 $\mathbf{0}\in\mathbb{S}'$ 时 $b=0.5>0$ (被含有)，$\mathbf{0}\notin\mathbb{S}'$ 时 $b=-0.5<0$ (被排除)，因此符合要求。

b. 对于基向量 $\boldsymbol{x}=\boldsymbol{e}_i$，$\boldsymbol{w}^\top\boldsymbol{e}_i+b=y_i+b$。由于 $\boldsymbol{e}_i\in\mathbb{S}'$ 时 $y_i=1$，无论 $b=0.5$ 或 -0.5，$y_i+b\geqslant 0.5>0$ (被含有)；由于 $\boldsymbol{e}_i\notin\mathbb{S}'$ 时 $y_i=-1$，无论 $b=0.5$ 或 -0.5，$y_i+b\leqslant -0.5<0$ (被排除)，因此符合要求。

如此，$\mathbb{S}$ 的全部 2^{n+1} 个子集均可被 $\mathcal{C}$ 切分，从而 $\mathbb{S}$ 被 $\mathcal{F}$ 打散，即 $\mathrm{vc}(\mathcal{F})\geqslant n+1$。

• 证明最优性

利用反证法，假设存在含有 $n+2$ 个点的集合 $V=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_{n+2}\}\subset\mathbb{R}^n$ 可以被 $\mathcal{F}$ 打散。

考虑以下关于系数 $\alpha_1,\alpha_2,\cdots,\alpha_{n+2}$ 的线性方程组，

$$\sum_{i=1}^{n+2}\alpha_i\boldsymbol{x}_i=\mathbf{0},\quad \sum_{i=1}^{n+2}\alpha_i=0,$$

其为含有 $n+1$ 个齐次线性方程 (前式提供 n 个，后式提供 1 个) 但含有 $n+2$ 个未知数的系统，由于未知数多于方程个数，因此方程组必定存在非零解 $(\alpha_1,\cdots,\alpha_{n+2})\neq\mathbf{0}$，从而系数 $\alpha_1,\cdots,\alpha_{n+2}$ 必定有正有负。

将下标集合划分为 $I=I^+\sqcup I^-$，其中

$$I^+=\{i:\alpha_i>0\},\quad I^-=\{i:\alpha_i\leqslant 0\},$$

令 $A=\sum_{i\in I^+}\alpha_i>0$，则 $\sum_{i\in I^-}\alpha_i=-A$。

构造

$$\boldsymbol{p}=\sum_{i\in I^+}\frac{\alpha_i}{A}\boldsymbol{x}_i=\sum_{i\in I^-}\frac{-\alpha_i}{A}\boldsymbol{x}_i,$$

其中左侧为 $V^+=\{\boldsymbol{x}_i:i\in I^+\}$ 的凸组合，右侧为 $V^-=\{\boldsymbol{x}_i:i\in I^-\}$ 的凸组合，则 $\boldsymbol{p}\in\mathrm{conv}(V^+),\mathrm{conv}(V^-)$。

(即为 Radon 定理，$\mathrm{conv}(V^+)\cap\mathrm{conv}(V^-)\neq\emptyset$。)

由于 V 可以被 $\mathcal{F}$ 打散，因此存在半空间 $H=\{\boldsymbol{x}:\boldsymbol{w}^\top\boldsymbol{x}+b\geqslant 0\}$ 将 V^+,V^- 分隔，即 $V^+\subset H,V^-\subset H^c$，从而 $\mathrm{conv}(V^+)\subset H,\mathrm{conv}(V^-)\subset H^c$，从而 $\boldsymbol{p}\in H,\boldsymbol{p}\in H^c$，即 $\boldsymbol{p}\in H\cap H^c=\emptyset$，矛盾；

如此，不存在任意的含有 $n+2$ 个点的集合可以被 $\mathcal{F}$ 打散，从而 $\mathrm{vc}(\mathcal{F})\leqslant n+1$，即 $\mathrm{vc}(\mathcal{F})=n+1$。

18 [**VC 维度, 代数维度的关系**] 设 Ω 为给定论域，$\mathcal{F}$ 为定义于 Ω 的 Boolean 函数族 (即函数取值于 $\{0,1\}$ 或 $\{-1,1\}$)。将 $\mathcal{F}$ 视为 $\mathbb{R}$ 的函数向量空间的子集。证明：对于任意的有限维度的 Boolean 函数族 $\mathcal{F}$，其 Vapnik-Chervonenkis 维度 $\mathrm{vc}(\mathcal{F})$ 满足

$$\mathrm{vc}(\mathcal{F})\leqslant\dim(\mathcal{F})。$$

证明 不妨设 Boolean 函数族取值于 $\{0,1\}$。设 $\dim(\mathcal{F})=d$。若 $d=\infty$，则结论是平凡的；之后只需考虑 $d<\infty$ 的情况。

利用反证法，假设 $\mathrm{vc}(\mathcal{F})>d$，则根据 Vapnik-Chervonenkis 维度的定义，存在至少含有 $n=d+1$ 个点的集合 $\mathbb{S}=$

$\{x_1, x_2, \cdots, x_n\} \subset \Omega$ 能够被 $\mathcal{F}$ 打散。

考虑取值映射 $E : \mathcal{F} \to \mathbb{R}^n$，定义为对于任意的 $f \in \mathcal{F}$，

$$E(f) = (f(x_1), f(x_2), \cdots, f(x_n))^\top。$$

则 $\dim(\operatorname{span}\{E(f) : f \in \mathcal{F}\}) \leqslant d$。

由于 $n = d + 1 > d$，因此存在非零的正交向量，即存在非零向量 $\boldsymbol{a} = (a_1, a_2, \cdots, a_n)^\top \in \mathbb{R}^n$，使得对于任意的 $f \in \mathcal{F}$，均满足

$$\boldsymbol{a}^\top E(f) = \sum_{i=1}^{n} a_i f(x_i) = 0。 \tag{I}$$

由于 $\boldsymbol{a} \neq \boldsymbol{0}$，因此将下标集合划分为 $I = I^+ \sqcup I^-$，其中

$$I^+ = \{i : a_i > 0\}, \quad I^- = \{i : a_i < 0\},$$

I^+, I^- 至少存在一个非空。

利用 $\mathbb{S}$ 被打散的性质，分两种情况讨论：

a. 当 $I^+ \neq \emptyset$ 时，由于 $\mathbb{S}$ 被打散，因此存在 $f_+ \in \mathcal{F}$，使得

$$f_+(x_i) = \begin{cases} 1, i \in I^+, \\ 0, i \notin I^+ \end{cases}$$

将其代入于 (I)，

$$0 = \sum_{i=1}^{n} a_i f_+(x_i) = \sum_{i \in I^+} a_i \cdot 1 + \sum_{i \notin I^+} a_i \cdot 0 = \sum_{i \in I^+} a_i > 0,$$

矛盾；如此，此情况不可能。

b. 当 $I^+ = \emptyset$ 时，即 $I^- \neq \emptyset$，由于 $\mathbb{S}$ 被打散，因此存在 $f_- \in \mathcal{F}$，使得

$$f_-(x_i) = \begin{cases} 1, i \in I^-, \\ 0, i \notin I^- \end{cases}$$

将其代入于 (I)，

$$0 = \sum_{i=1}^{n} a_i f_-(x_i) = \sum_{i \in I^-} a_i \cdot 1 = \sum_{i \in I^-} a_i < 0,$$

矛盾；如此，此情况不可能。

如此，$\operatorname{vc}(\mathcal{F}) \leqslant \dim(\mathcal{F})$。

19 [**定理 (Pajor 引理与 Sauer-Shelah 引理的紧性)**] 证明 Pajor 引理 L8.3.7 (Pajor 引理) 与 Sauer–Shelah 引理 L8.3.9 (Sauer–Shelah 引理) 均为紧的。设 $\Omega = \{1, 2, \cdots, n\}$ 为包含 n 个元素的有限集合。考虑集族 $\mathcal{F} = \{A \subset \Omega : |A| \leqslant d\}$，其中 $0 \leqslant d \leqslant n$。证明：以下不等式均取到严格等号，

$$|\mathcal{F}| = |\{\Lambda \subset \Omega : \Lambda \text{ 被 } \mathcal{F} \text{ 打散}\}| = \sum_{k=0}^{\operatorname{vc}(\mathcal{F})} \binom{n}{k}。$$

证明 容易知道，

$$|\mathcal{F}| = \sum_{k=0}^{d} \binom{n}{k}。$$

- 被打散集合的刻画

  设 $\mathcal{S} = \{\Lambda \subset \Omega : \Lambda \text{ 被 } \mathcal{F} \text{ 打散}\}$，则 Λ 被 $\mathcal{F}$ 打散，当且仅当对于任意的 $\Lambda' \subset \Lambda$，存在 $A \in \mathcal{F}$，使得 $A \cap \Lambda = \Lambda'$。

  a. 若 $|\Lambda| \leqslant d$，则对于任意的 $\Lambda' \subset \Lambda$，满足 $|\Lambda'| \leqslant |\Lambda| \leqslant d$。

  选取 $A = \Lambda' \in \mathcal{F}$，满足 $A \cap \Lambda = \Lambda'$，则 $|\Lambda| \leqslant d$ 的所有集合均被 $\mathcal{F}$ 打散。

b. 若 $|\Lambda|>d$，若 Λ 被打散，则存在 $A\in\mathcal{F}$，使得 $A\cap\Lambda=\Lambda$，即 $\Lambda\subset A$，因此 $|A|\geqslant|\Lambda|>d$，这与 $|A|\leqslant d$ 矛盾；此时 Λ 不能被打散。

如此，被打散集合系为 $\mathcal{S}=\{\Lambda\subset\Omega:|\Lambda|\leqslant d\}$，其基数为 $|\mathcal{S}|=\sum_{k=0}^{d}\binom{n}{k}$。

- Pajor 引理与 Sauer-Shelah 引理的紧性验证

由于 $|\mathcal{F}|=|\mathcal{S}|$，因此 Pajor 引理取到等号。

由于任意的基数小于等于 d 的集合均能被打散，任意的基数大于 d 的集合均不能被打散，因此 $\mathrm{vc}(\mathcal{F})=d$。从而根据 Sauer-Shelah 引理，可得

$$\sum_{k=0}^{\mathrm{vc}(\mathcal{F})}\binom{n}{k}=\sum_{k=0}^{d}\binom{n}{k}=|\mathcal{F}|,$$

Sauer-Shelah 引理取到等号。

注释 对于 Hamming 球构成的集族 $\mathcal{S}$，Pajor 引理和 Sauer-Shelah 引理的不等式均退化为严格等式。

20 [**VC 维度二分律**] 设 $\mathcal{F}$ 为定义于论域 Ω 的 Boolean 函数族，其增长函数 $\Pi_{\mathcal{F}}(n)$ 定义为 $\mathcal{F}$ 于 Ω 的任意的 n 元子集上能够诱导的不同 Boolean 赋值组合的最大数量，即

$$\Pi_{\mathcal{F}}(n)=\max_{\mathbb{S}\subset\Omega,|\mathbb{S}|=n}|\{(f(x_1),f(x_2),\cdots,f(x_n)):f\in\mathcal{F},x_i\in\mathbb{S}\}|。$$

证明：增长函数 $\Pi_{\mathcal{F}}(n)$ 只能呈多项式增长或指数增长，不存在中间状态，即证明以下两个命题必居其一：

i. $\Pi_{\mathcal{F}}(n)=2^n$；

ii. 存在多项式 $p(n)$，使得 $\Pi_{\mathcal{F}}(n)\leqslant p(n)$。

证明 对于任意的函数族 $\mathcal{F}$，其 VC 维度或者为 $\mathrm{vc}(\mathcal{F})=\infty$，或者为 $\mathrm{vc}(\mathcal{F})=d$。

a. 若 $d=0$，则 $\mathcal{F}$ 于每个单点上只能诱导一种标记，因而 $\mathcal{F}$ 只能含有一个函数，结论成立；之后只需考虑 $d\geqslant1$。

a. 假设 $\mathrm{vc}(\mathcal{F})=\infty$，则对于任意的 $n\in\mathbb{Z}^+$，论域 Ω 存在至少大小为 n 的子集 $\mathbb{S}$，使得能够被 $\mathcal{F}$ 完全打散。

根据打散的定义，$\mathcal{F}$ 于 $\mathbb{S}$ 的限制能够产生所有 2^n 种可能的 Boolean 赋值组合。由于 $\Pi_{\mathcal{F}}(n)$ 为所有大小为 n 的子集能够产生的最大组合数，长度为 n 的 Boolean 向量总组合数的上限为 2^n，因此 $\Pi_{\mathcal{F}}(n)=2^n$，对应于指数增长。

b. 假设 $\mathrm{vc}(\mathcal{F})=d$，则根据 Sauer-Shelah 引理，可得对于任意的 $n\in\mathbb{Z}^+$，$\mathcal{F}$ 的增长函数被限定为

$$\Pi_{\mathcal{F}}(n)\leqslant\sum_{i=0}^{d}\binom{n}{i}。$$

利用不等式 $\binom{n}{i}\leqslant\frac{n^i}{i!}\leqslant n^i$，可得

$$\Pi_{\mathcal{F}}(n)\leqslant\sum_{i=0}^{d}n^i\leqslant\sum_{i=0}^{d}n^d=(d+1)n^d。$$

定义多项式 $p(n)=(d+1)n^d$，其为关于 n 的最高次幂为 d 的多项式，因此 $\Pi_{\mathcal{F}}(n)\leqslant p(n)$，对应于多项式增长。

21 [**VC 维度的组合稳定性**] 在命题 P8.3.11 (VC 稳定性) 中，我们观察到将两个函数族逐点取最小或最大组合时 VC 维度的稳定性。

现在将其推广到任意多个函数族, 任意组合方式。设 Ω 为给定论域，$\mathcal{F}_1,\mathcal{F}_2,\cdots,\mathcal{F}_k$ 为定义于 Ω 的 $k\geqslant2$ 个 Boolean 函数族。给定固定的 Boolean 组合函数 $\varphi:\{0,1\}^k\to\{0,1\}$，通过 φ 将上述 k 个函数族组合为新的 Boolean 函数族

$$\mathcal{F}=\{\boldsymbol{x}\mapsto\varphi(f_1(\boldsymbol{x}),\cdots,f_k(\boldsymbol{x})):f_i\in\mathcal{F}_i,i=1,\cdots,k\}。$$

证明：若对于任意的 $i\in\{1,\cdots,k\}$，均满足 $\mathrm{vc}(\mathcal{F}_i)\leqslant d$，则组合函数族 $\mathcal{F}$ 的 Vapnik-Chervonenkis 维度满足

$$\mathrm{vc}(\mathcal{F})\leqslant Cdk\ln k。\qquad(C>0)$$

证明 (*若 $d=0$，则每个函数族于每个单点上只能诱导一种标记，因而组合函数族也只能含有一个函数，结论成立；之后只需考虑 $d\geqslant1$。若 $n\leqslant d$，则结论是平凡的；之后只需考虑 $n>d$ 的情况。*)

- 根据 Sauer-Shelah 引理

设 $\mathbb{S}\subset\Omega$ 为含有 n 个元素的有限子集。定义函数族 $\mathcal{H}$ 于 $\mathbb{S}$ 的增长函数 $\Pi_{\mathcal{H}}(n)$ 为 $\mathcal{H}$ 限制于 $\mathbb{S}$ 所能产生的不同 Boolean

向量的最大数量。

对于任意的组合之后的函数 $f=\varphi(f_1,\cdots,f_k)\in\mathcal{F}$，其于 $\mathbb{S}$ 的输出向量完全由 k 个底层函数 $(f_1,\cdots,f_k)$ 于 $\mathbb{S}$ 的输出向量所唯一确定，因此 $\mathcal{F}$ 于 $\mathbb{S}$ 产生的不同输出模式的总数不超过底层各函数族于 $\mathbb{S}$ 输出模式数量之积，即

$$\Pi_{\mathcal{F}}(n)\leqslant\prod_{i=1}^{k}\Pi_{\mathcal{F}_i}(n)。\tag{I}$$

根据 Sauer-Shelah 引理，当 $n\geqslant d$ 时，

$$\Pi_{\mathcal{F}_i}(n)\leqslant\sum_{j=0}^{d}\binom{n}{j}\leqslant\left(\frac{\mathrm{e}n}{d}\right)^{d},$$

将其代入于 (I)，可得

$$\Pi_{\mathcal{F}}(n)\leqslant\prod_{i=1}^{k}\left(\frac{\mathrm{e}n}{d}\right)^{d}=\left(\frac{\mathrm{e}n}{d}\right)^{dk}。\tag{II}$$

- 建立 VC 维度的超越不等式

若 $\mathrm{vc}(\mathcal{F})=n$，则存在含有 n 个元素的集合被 $\mathcal{F}$ 完全打散，使得 $\mathcal{F}$ 于此集合能够产生所有 2^n 种模式，即 $\Pi_{\mathcal{F}}(n)=2^n$，将其代入于 (II)，可得

$$2^n\leqslant\left(\frac{\mathrm{e}n}{d}\right)^{dk}。$$

两侧取对数，

$$n\ln 2\leqslant dk\ln\left(\frac{\mathrm{e}n}{d}\right)。$$

两侧同除以 $d\ln 2$，令 $u=\frac{n}{d}$, $a=\frac{k}{\ln 2}$，可得

$$u\leqslant a\ln(\mathrm{e}u)=a(1+\ln u),$$

利用不等式 $\ln u<2\sqrt{u}$，可得

$$u\leqslant a(1+2\sqrt{u}),\tag{III}$$

即

$$(\sqrt{u})^2-2a\sqrt{u}-a\leqslant 0,$$

解得 $\sqrt{u}\leqslant a+\sqrt{a^2+a}$。

- 利用 Bootstrapping 求解

由于 $k\geqslant 2$，因此 $a=\frac{k}{\ln 2}>2$，从而 $\sqrt{u}\leqslant a+\sqrt{a^2+a}<a+\sqrt{a^2+a^2}<2.5a$，即

$$u\leqslant 6.25a^2。\tag{IV}$$

利用 Bootstrapping，将粗略上界 (IV) 代入于 (III)，可得

$$u\leqslant a(1+\ln(6.25a^2))=a(1+\ln 6.25+2\ln a)。$$

由于 $a\geqslant\frac{2}{\ln 2}\approx 2.88$，因此 $1+\ln 6.25\approx 2.83\leqslant 3\ln a$，将其代入，可得

$$u\leqslant a(3\ln a+2\ln a)=5a\ln a,$$

即

$$\frac{n}{d}\leqslant 5\left(\frac{k}{\ln 2}\right)\ln\left(\frac{k}{\ln 2}\right)。$$

由于 $k\geqslant 2$，$\ln k\geqslant 0.69$，因此 $\ln(\frac{1}{\ln 2})\approx 0.36\leqslant 0.6\ln k$，可得右侧为

$$5\left(\frac{k}{\ln 2}\right)\ln\left(\frac{k}{\ln 2}\right)=\frac{5}{\ln 2}k\left(\ln k+\ln\left(\frac{1}{\ln 2}\right)\right)\leqslant\frac{5}{\ln 2}k(\ln k+0.6\ln k)=\frac{8}{\ln 2}k\ln k,$$

即

$$\frac{n}{d}\leqslant\frac{8}{\ln 2}k\ln k,$$

两侧同乘 d，

$$\mathrm{vc}(\mathcal{F}) = n \leqslant Cdk\ln k。 \qquad \left(C = \frac{8}{\ln 2}\right)$$

22 [**并集的 VC 维度**] 设 $\mathcal{F},\mathcal{G}$ 为定义于论域 Ω 的两个 Boolean 函数族 (或等价地，子集族)。

(1) 证明：并集的 VC 维度满足

$$\mathrm{vc}(\mathcal{F}\cup\mathcal{G}) \leqslant \mathrm{vc}(\mathcal{F}) + \mathrm{vc}(\mathcal{G}) + 1。$$

(2) 构造上述不等式的等号成立的实例，使得 $\mathrm{vc}(\mathcal{F}), \mathrm{vc}(\mathcal{G}) > 0$，满足

$$\mathrm{vc}(\mathcal{F}\cup\mathcal{G}) = \mathrm{vc}(\mathcal{F}) + \mathrm{vc}(\mathcal{G}) + 1。$$

证明 (1) 设 $\mathrm{vc}(\mathcal{F}) = d_1$, $\mathrm{vc}(\mathcal{G}) = d_2$。若 d_1, d_2 其中之一为 ∞，则结论是平凡的；之后只需考虑 $d_1, d_2 < \infty$。

令 $\Pi_{\mathcal{H}}(\mathbb{S})$ 表示函数族 $\mathcal{H}$ 于 $\mathbb{S}$ 能够诱导出的不同 Boolean 赋值组合的数量，则 $\Pi_{\mathcal{F}\cup\mathcal{G}}(\mathbb{S}) \leqslant \Pi_{\mathcal{F}}(\mathbb{S}) + \Pi_{\mathcal{G}}(\mathbb{S})$。

由于 $|\mathbb{S}| = n = d_1 + d_2 + 2$，因此根据 Sauer-Shelah 引理，可得

$$\Pi_{\mathcal{F}}(\mathbb{S}) \leqslant \sum_{i=0}^{d_1}\binom{n}{i}, \quad \Pi_{\mathcal{G}}(\mathbb{S}) \leqslant \sum_{j=0}^{d_2}\binom{n}{j}。$$

其中

$$\sum_{j=0}^{d_2}\binom{n}{j} = \sum_{k=d_1+2}^{n}\binom{n}{k}, \qquad (k = n - j)$$

因此根据二项式定理 $\sum_{m=0}^{n}\binom{n}{m} = 2^n$，可得

$$\Pi_{\mathcal{F}}(\mathbb{S}) + \Pi_{\mathcal{G}}(\mathbb{S}) \leqslant \sum_{i=0}^{d_1}\binom{n}{i} + \sum_{k=d_1+2}^{n}\binom{n}{k} = 2^n - \binom{n}{d_1+1} < 2^n,$$

因此 $\mathcal{F}\cup\mathcal{G}$ 无法于 $\mathbb{S}$ 产生所有 2^n 种组合，即 $\mathbb{S}$ 不能被 $\mathcal{F}\cup\mathcal{G}$ 打散，从而

$$\mathrm{vc}(\mathcal{F}\cup\mathcal{G}) \leqslant d_1 + d_2 + 1 = \mathrm{vc}(\mathcal{F}) + \mathrm{vc}(\mathcal{G}) + 1。$$

(2) 令论域 Ω 为含有 $n = d_1 + d_2 + 1$ 个元素的有限集合。定义

$$\mathcal{F} = \{A \subset \Omega : |A| \leqslant d_1\},$$
$$\mathcal{G} = \{B \subset \Omega : |B| \geqslant d_1 + 1\}。$$

对于 $\mathcal{F}$，其含有所有大小不超过 d_1 的子集，可打散任意大小为 d_1 的集合；但无法提供大小为 d_1+1 的集合自身，因此不能打散大小为 d_1+1 的集合，从而

$$\mathrm{vc}(\mathcal{F}) = d_1 > 0。$$

对于 $\mathcal{G}$，考虑大小为 d_2 的集合 $\mathbb{S}$，对于任意的 $\mathbb{S}' \subset \mathbb{S}$，构造 $B = \mathbb{S}' \cup (\Omega \setminus \mathbb{S})$，则

$$|B| = |\mathbb{S}'| + (n - d_2) = |\mathbb{S}'| + d_1 + 1 \geqslant d_1 + 1,$$

满足 $B \in \mathcal{G}$，$B \cap \mathbb{S} = \mathbb{S}'$，因此 $\mathbb{S}$ 被打散。

若打散大小为 d_2+1 的集合 $\mathbb{S}$，则需截取 $\emptyset$，要求存在 $B \in \mathcal{G}$，使得 $B\cap\mathbb{S} = \emptyset$，即 $B \subset \Omega\setminus\mathbb{S}$，因此 $|B| \leqslant n - d_2 - 1 = d_1$，这与 $|B| \geqslant d_1 + 1$ 矛盾；如此，

$$\mathrm{vc}(\mathcal{G}) = d_2 > 0。$$

对于 $\mathcal{F}\cup\mathcal{G}$，其恰好含有 Ω 的所有可能子集，即 $\mathcal{F}\cup\mathcal{G} = 2^{\Omega}$。因此能够完美打散 Ω，

$$\mathrm{vc}(\mathcal{F}\cup\mathcal{G}) = |\Omega| = d_1 + d_2 + 1 = \mathrm{vc}(\mathcal{F}) + \mathrm{vc}(\mathcal{G}) + 1。$$

23 [**大尺度的覆盖数**] 定理 T8.3.13 (通过 VC 维数给出的覆盖数) 的陈述针对 $\varepsilon \in (0,1)$。当 ε 更大时，成立何种界？

设 Ω 为论域，μ 为定义于 Ω 的概率测度。设 $\mathcal{F}$ 为定义于 Ω 的 Boolean 函数族 (即对于任意的 $f \in \mathcal{F}, x \in \Omega$，满足 $f(x) \in \{0,1\}$)。当允许的覆盖球半径 $\varepsilon \geqslant 1$ 时，试求 $\mathcal{F}$ 在 $L^2(\mu)$ 范数下的覆盖数 $\mathcal{N}(\mathcal{F}, L^2(\mu), \varepsilon)$ 的上界。

证明 设 $f,g\in\mathcal{F}$，满足 $f(x),g(x)\in\{0,1\}$，则 f,g 的平方距离为

$$|f(x)-g(x)|^2\leqslant 1,$$

因此 $L^2(\mu)$ 距离为

$$\|f-g\|_{L^2(\mu)}^2=\int_\Omega|f(x)-g(x)|^2\mathrm{d}\mu(x)\leqslant\int_\Omega 1\mathrm{d}\mu(x)=1。$$

若 $\mathcal{F}=\emptyset$，则 $\mathcal{N}(\mathcal{F},L^2(\mu),\varepsilon)=0$。(之后只需考虑 $\mathcal{F}\neq\emptyset$ 的情况。)

设 $f_0\in\mathcal{F}$，构造以 f_0 为球心, 半径为 $\varepsilon\geqslant 1$ 的闭球 $B(f_0,\varepsilon)$，则当 $\varepsilon\geqslant 1$ 时，

$$\|f-f_0\|_{L^2(\mu)}\leqslant 1\leqslant\varepsilon。$$

即 $f\in B(f_0,\varepsilon)$，因此 $\mathcal{F}\subset B(f_0,\varepsilon)$，从而

$$\mathcal{N}(\mathcal{F},L^2(\mu),\varepsilon)\leqslant 1,$$

即 $\mathcal{N}(\mathcal{F},L^2(\mu),\varepsilon)=1$。

24 [**更简单更弱的 VC 大数定律**] 直接利用 Sauer-Shelah 引理 (而非 Pajor 引理) 证明定理 T8.3.15 (VC 大数定律) 的较弱版本，其不等式右边为

$$C\sqrt{\frac{d}{n}\ln\frac{\mathrm{e}n}{d}},$$

其中 $d=\mathrm{vc}(\mathcal{F})$，并假设 $1\leqslant d\leqslant n$。

证明 (对称化)。

记 $\Delta=\mathrm{E}\left[\sup_{f\in\mathcal{F}}|R_n(f)-R(f)|\right]$。根据对称化引理，可得

$$\Delta\leqslant 2\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^n\varepsilon_i f(X_i)\right|\right],$$

其中 ε_i 为独立 Rademacher 变量，独立于样本 X_i。

条件于样本 $X_1,\cdots,X_n$，函数类 $\mathcal{F}$ 于样本的限制 $\{(f(X_1),\cdots,f(X_n)):f\in\mathcal{F}\}$ 至多包含 $\Pi_{\mathcal{F}}(n)$ 种模式。根据 Sauer-Shelah 引理，$\Pi_{\mathcal{F}}(n)\leqslant(\mathrm{e}n/d)^d$。

(并集界与尾部积分)。

对于固定 f，由 $f(X_i)\in\{0,1\}$ 和 Hoeffding 不等式，可得

$$\mathrm{P}\left\{\left|\frac{1}{n}\sum_{i=1}^n\varepsilon_i f(X_i)\right|\geqslant t\right\}\leqslant 2\mathrm{e}^{-cnt^2}。$$

对所有模式取并集界，可得

$$\mathrm{P}\left\{\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^n\varepsilon_i f(X_i)\right|\geqslant t\right\}\leqslant 2(\mathrm{e}n/d)^d\mathrm{e}^{-cnt^2}。$$

令 $t_0=\sqrt{\frac{d\ln(\mathrm{e}n/d)+\ln 2}{cn}}$。根据尾部积分，

$$\begin{aligned}\Delta&\leqslant 2t_0+2\int_{t_0}^\infty\exp(-cn(t^2-t_0^2))\mathrm{d}t\\&\leqslant 2t_0+\frac{1}{cnt_0}\leqslant C\sqrt{\frac{d}{n}\ln\frac{\mathrm{e}n}{d}},\end{aligned}$$

即定理 T8.3.15 (VC 大数定律) 的较弱版本成立。

25 [**一维边缘分布的一致估计**] 设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m\in\mathbb{R}^n$ 为独立同分布的随机向量。证明：通过 m 个样本的经验累积分布函数去一致地估计所有一维投影方向 $\boldsymbol{u}\in\mathbb{S}^{n-1}$ 的边缘分布 $\langle\boldsymbol{X},\boldsymbol{u}\rangle$，其最大偏差的期望满足

$$\mathrm{E}\left[\sup_{\boldsymbol{u}\in\mathbb{S}^{n-1},t\in\mathbb{R}}\left|\frac{1}{m}\sum_{i=1}^m\mathbf{1}_{\{\langle\boldsymbol{X}_i,\boldsymbol{u}\rangle\leqslant t\}}-\mathrm{P}\{\langle\boldsymbol{X},\boldsymbol{u}\rangle\leqslant t\}\right|\right]\lesssim\sqrt{\frac{n}{m}}。$$

证明 (记经验过程上确界为 Δ。)

设 $\boldsymbol{u}\in\mathbb{S}^{n-1}, t\in\mathbb{R}$，定义 $f_{\boldsymbol{u},t}:\mathbb{R}^n\to\{0,1\}$ 为

$$f_{\boldsymbol{u},t}(\boldsymbol{x})=\mathbf{1}_{\{\langle\boldsymbol{x},\boldsymbol{u}\rangle\leqslant t\}},$$

令 $\mathcal{F}=\{f_{\boldsymbol{u},t}:\boldsymbol{u}\in\mathbb{S}^{n-1},t\in\mathbb{R}\}$。

对于 $f=f_{\boldsymbol{u},t}\in\mathcal{F}$，其于样本 $\boldsymbol{X}$ 的期望为 $\mathrm{E}[f(\boldsymbol{X})]=\mathrm{P}\{\langle\boldsymbol{X},\boldsymbol{u}\rangle\leqslant t\}$，经验平均为

$$\frac{1}{m}\sum_{i=1}^m f(\boldsymbol{X}_i)=\frac{1}{m}\sum_{i=1}^m\mathbf{1}_{\{\langle\boldsymbol{X}_i,\boldsymbol{u}\rangle\leqslant t\}},$$

因此证明目标即为

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{m}\sum_{i=1}^m f(\boldsymbol{X}_i)-\mathrm{E}[f(\boldsymbol{X})]\right|\right]\lesssim\sqrt{\frac{n}{m}}。$$

根据定理 T8.3.15 (VC 大数定律)，可得

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{m}\sum_{i=1}^m f(\boldsymbol{X}_i)-\mathrm{E}[f(\boldsymbol{X})]\right|\right]\leqslant C_1\sqrt{\frac{\mathrm{vc}(\mathcal{F})}{m}},$$

其中根据习题 Q8.17 (半空间的 VC 维度)，可得

$$\mathrm{vc}(\mathcal{F})=n+1,$$

将其代入，可得

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{m}\sum_{i=1}^m f(\boldsymbol{X}_i)-\mathrm{E}[f(\boldsymbol{X})]\right|\right]\leqslant C_1\sqrt{\frac{n+1}{m}}\leqslant\sqrt{2}C_1\sqrt{\frac{n}{m}}。$$

26 [**单位二进制位数量化, 局部敏感哈希**] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。定义映射 $\Phi:\mathbb{S}^{n-1}\to\{-1,1\}^m$ 为

$$\Phi(\boldsymbol{u})=\mathrm{sgn}(\boldsymbol{A}\boldsymbol{u}),$$

其中 $\mathrm{sgn}(\cdot)$ 逐坐标作用于向量。

(1) 证明：对于任意的 $\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}$，

$$\mathrm{E}\left[\frac{1}{m}d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))\right]=\frac{1}{\pi}\rho(\boldsymbol{u},\boldsymbol{v})。$$

其中 $d(\cdot,\cdot)$ 为 Hamming 距离，$\rho(\cdot,\cdot)$ 为球面测地线距离。

(2) 利用定理 T8.3.15 (VC 大数定律)，证明：对于任意的 $\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}$，

$$\sup_{\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}}\left|\frac{1}{m}d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))-\frac{1}{\pi}\rho(\boldsymbol{u},\boldsymbol{v})\right|\lesssim\sqrt{\frac{n}{m}}\ (\text{w.p. }0.99)。$$

证明 (1) 设 $\boldsymbol{A}$ 的第 i 行为 $\boldsymbol{A}_i^\top$，其中 $\boldsymbol{A}_1,\cdots,\boldsymbol{A}_m$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_n)$。

对于 Hamming 距离 $d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))$，其对应于分量符号不同的个数，将其表示为示性函数之和，

$$d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))=\sum_{i=1}^m\mathbf{1}_{\{\mathrm{sgn}(\langle\boldsymbol{A}_i,\boldsymbol{u}\rangle)\neq\mathrm{sgn}(\langle\boldsymbol{A}_i,\boldsymbol{v}\rangle)\}},$$

两端取期望，

$$\mathrm{E}\left[\frac{1}{m}d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))\right]=\mathrm{P}\{\mathrm{sgn}(\langle\boldsymbol{A}_1,\boldsymbol{u}\rangle)\neq\mathrm{sgn}(\langle\boldsymbol{A}_1,\boldsymbol{v}\rangle)\}。$$

根据标准 Gaussian 分布的旋转不变性，将坐标系旋转，使得 $\boldsymbol{u},\boldsymbol{v}$ 所在的平面张成前两个坐标轴，则 $\boldsymbol{A}_1$ 的投影为标准二维 Gaussian 向量。

(内积符号相反的几何意义为：与 $\boldsymbol{A}_1$ 垂直的超平面恰好从 $\boldsymbol{u},\boldsymbol{v}$ 间的夹角穿过。)

由于标准 Gaussian 向量是各向同性的，因此上述概率等于夹角, 半圆弧度 π 的比值，即

$$\mathrm{P}\{\mathrm{sgn}(\langle\boldsymbol{A}_1,\boldsymbol{u}\rangle)\neq\mathrm{sgn}(\langle\boldsymbol{A}_1,\boldsymbol{v}\rangle)\}=\frac{\rho(\boldsymbol{u},\boldsymbol{v})}{\pi},$$

将其代入，可得

$$\mathrm{E}\left[\frac{1}{m}d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))\right]=\frac{1}{\pi}\rho(\boldsymbol{u},\boldsymbol{v})。$$

(2) 设 $(\boldsymbol{u},\boldsymbol{v})\in\mathbb{S}^{n-1}\times\mathbb{S}^{n-1}$，对于 $\boldsymbol{x}\in\mathbb{R}^n$，定义

$$f_{\boldsymbol{u},\boldsymbol{v}}(\boldsymbol{x})=\mathbf{1}_{\{\mathrm{sgn}(\langle\boldsymbol{x},\boldsymbol{u}\rangle)\neq\mathrm{sgn}(\langle\boldsymbol{x},\boldsymbol{v}\rangle)\}}。$$

令 $\mathcal{F}=\{f_{\boldsymbol{u},\boldsymbol{v}}:\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}\}$。

同理于习题 Q8.24 (更简单更弱的 VC 大数定律)，对于 $f=f_{\boldsymbol{u},\boldsymbol{v}}\in\mathcal{F}$，其于 $\boldsymbol{A}$ 的期望为

$$\mathrm{E}[f_{\boldsymbol{u},\boldsymbol{v}}(\boldsymbol{A})]=\frac{1}{\pi}\rho(\boldsymbol{u},\boldsymbol{v}),$$

经验均值为 $\frac{1}{m}d(\Phi(\boldsymbol{u}),\Phi(\boldsymbol{v}))$，则证明目标转化为

$$\underbrace{\sup_{f\in\mathcal{F}}\left|\frac{1}{m}\sum_{i=1}^{m}f(\boldsymbol{A}_i)-\mathrm{E}[f(\boldsymbol{A})]\right|}_{\Delta}\lesssim\sqrt{\frac{n}{m}}\ (\text{w.p. }0.99)。$$

根据定理 T8.3.15 (VC 大数定律)，可得

$$\mathrm{E}[\Delta]\leqslant C_1\sqrt{\frac{\mathrm{vc}(\mathcal{F})}{m}}。\tag{I}$$

注意到 $f_{\boldsymbol{u},\boldsymbol{v}}(\boldsymbol{x})$ 本质上为异或逻辑运算，

$$f_{\boldsymbol{u},\boldsymbol{v}}(\boldsymbol{x})=\mathbf{1}_{\{\langle\boldsymbol{x},\boldsymbol{u}\rangle\geqslant0\}}\oplus\mathbf{1}_{\{\langle\boldsymbol{x},\boldsymbol{v}\rangle\geqslant0\}},$$

(无偏置半空间族的 VC 维度为 n，$\mathcal{F}$ 为由 $k=2$ 个半空间族组合而成) 因此根据 VC 维度的稳定性定理，可得

$$\mathrm{vc}(\mathcal{F})\leqslant C_2n。\tag{II}$$

将 (II) 代入于 (I)，可得

$$\mathrm{E}[\Delta]\leqslant C_3\sqrt{\frac{n}{m}}。$$

利用命题 P1.6.2 (Markov 不等式) (Markov 不等式)，可得对于任意的 $t>0$，

$$\mathrm{P}\{\Delta\geqslant t\}\leqslant\frac{\mathrm{E}[\Delta]}{t},$$

若上述概率不超过 0.01，则 $t\geqslant100\mathrm{E}[\Delta]$，此时令 $t=100C_3\sqrt{\frac{n}{m}}$。

27 [**无矩假设的随机矩阵最小奇异值**] 大多数随机矩阵的结果都对分布作了不错的假设——例如 sub-Gaussian 尾部 (见定理 T4.6.1 (sub-Gaussian 矩阵的双侧界))，或至少有限二阶矩 (见练习 Q5.31 (一般独立行的随机矩阵))。

而本题将利用 VC 理论 (具体而言，定理 T8.3.15 (VC 大数定律)) 的力量，证明：即使对分布完全不作矩假设，高瘦随机矩阵也具有良好的可逆性。设 $\varepsilon,\delta>0$。设随机向量 $\boldsymbol{X}\in\mathbb{R}^n$ 满足反集中性质，即对于任意的 $\boldsymbol{u}\in\mathbb{S}^{n-1}$，均满足

$$\mathrm{P}\{|\langle\boldsymbol{X},\boldsymbol{u}\rangle|\geqslant\varepsilon\}\geqslant\delta。$$

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量独立同分布地取自 $\boldsymbol{X}$。

(1) 证明：存在 $C>0$，使得当行数 $m\geqslant C\delta^{-2}n$ 时，$\boldsymbol{A}$ 的最小奇异值以高概率满足

$$s_n(\boldsymbol{A})\geqslant0.99\varepsilon\sqrt{\delta m}\ (\text{w.p. }0.99)。$$

(2) 证明 (1) 的界限是最优的。具体而言，对于任意的正整数 $m\geqslant n$, $\varepsilon>0$, $\delta<1/3$，构造特定的满足反集中性质的随机向量 $\boldsymbol{X}$，使得

$$\mathrm{E}[s_n(\boldsymbol{A})]\leqslant1.01\varepsilon\sqrt{\delta m}。$$

证明 (1) 矩阵 $\boldsymbol{A}$ 的最小奇异值为

$$s_n(\boldsymbol{A})^2=\inf_{\boldsymbol{u}\in\mathbb{S}^{n-1}}\sum_{i=1}^{m}\langle\boldsymbol{X}_i,\boldsymbol{u}\rangle^2。$$

当 $|\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle| \geqslant \varepsilon$ 时，$s_n(\boldsymbol{A})^2 \geqslant \varepsilon^2$，考虑引入示性函数进行放缩，

$$\sum_{i=1}^m \langle \boldsymbol{X}_i, \boldsymbol{u}\rangle^2 \geqslant \varepsilon^2 \sum_{i=1}^m \mathbf{1}_{\{|\langle \boldsymbol{X}_i, \boldsymbol{u}\rangle| \geqslant \varepsilon\}}。$$

定义参数化的 Boolean 函数族 $\mathcal{F} = \{f_{\boldsymbol{u}} : \boldsymbol{u} \in \mathbb{S}^{n-1}\}$，其中 $f_{\boldsymbol{u}}(\boldsymbol{x}) = \mathbf{1}_{\{|\langle \boldsymbol{x}, \boldsymbol{u}\rangle| \geqslant \varepsilon\}}$，则 $\mathcal{F}$ 为两个互斥半空间的并集，因此根据 VC 维度的稳定性定理，可得

$$\operatorname{vc}(\mathcal{F}) \leqslant C_1 n。 \qquad (C_1 > 0)$$

由题设的反集中性质，真实期望为

$$\mathrm{E}[f_{\boldsymbol{u}}(\boldsymbol{X})] = \mathrm{P}\{|\langle \boldsymbol{X}, \boldsymbol{u}\rangle| \geqslant \varepsilon\} \geqslant \delta,$$

因此根据 VC 大数定律，可得

$$\mathrm{E}[\Delta] \leqslant C_2 \sqrt{\frac{n}{m}}。$$

利用命题 P1.6.2 (Markov 不等式) (Markov 不等式)，令 $t = 100\mathrm{E}[\Delta]$，则

$$\mathrm{P}\left\{\Delta \leqslant 100 C_2 \sqrt{\frac{n}{m}}\right\} \geqslant 0.99,$$

因此对于任意的 $\boldsymbol{u} \in \mathbb{S}^{n-1}$，

$$\frac{1}{m}\sum_{i=1}^m f_{\boldsymbol{u}}(\boldsymbol{X}_i) \geqslant \mathrm{E}[f_{\boldsymbol{u}}(\boldsymbol{X})] - 100 C_2 \sqrt{\frac{n}{m}} \geqslant \delta - 100 C_2 \sqrt{\frac{n}{m}}。$$

上式的右侧至少为 $0.99^2\delta$，即

$$m \geqslant \left(\frac{100 C_2}{1 - 0.99^2}\right)^2 \delta^{-2} n。$$

(2) 令 $c = 1 - \frac{1}{1.01}$，即 $\frac{1}{1-c} = 1.01$。定义 $\boldsymbol{X} \in \mathbb{R}^n$ 为混合分布：以概率 δ 取值 $\pm\frac{\varepsilon}{1-c}\boldsymbol{e}_1$；以概率 $1-\delta$ 取值于子空间 $\operatorname{span}(\boldsymbol{e}_2, \cdots, \boldsymbol{e}_n)$ 的多维 Gaussian 分布 $N(\boldsymbol{0}, M^2 \boldsymbol{I}_{n-1})$ (第一坐标恒为 0，且 M 足够大)。

验证反集中假设：

a. 当 $|u_1| \geqslant 1 - c$ 时，仅考虑第一种成分。由于

$$|\langle \boldsymbol{X}, \boldsymbol{u}\rangle| = \frac{\varepsilon}{1-c}|u_1| \geqslant \varepsilon,$$

以概率 1 满足条件。因此总概率 $\mathrm{P} \geqslant \delta$。

b. 当 $|u_1| < 1 - c$ 时，仅考虑第二种成分。由于 $\sum_{j=2}^n u_j^2 = 1 - u_1^2 > 2c - c^2 > c$，条件内积服从一维正态分布 $N(0, \sigma^2)$，其中 $\sigma^2 > M^2 c$。选取足够大的常数 M，使得概率

$$\mathrm{P}\{|N(0,\sigma^2)| \geqslant \varepsilon\} \geqslant \frac{\delta}{1-\delta}。$$

因此总概率

$$\mathrm{P} \geqslant (1-\delta)\frac{\delta}{1-\delta} = \delta。$$

(之后计算奇异值的期望。)

由于 $s_n(\boldsymbol{A})^2 \leqslant \|\boldsymbol{A}\boldsymbol{e}_1\|_2^2 = \sum_{i=1}^m X_{i1}^2$。第一分量 X_{i1} 仅于成分 1 非零，其期望为 $\mathrm{E}[X_{i1}^2] = \frac{\delta\varepsilon^2}{(1-c)^2}$。

利用 Jensen 不等式，

$$\mathrm{E}[s_n(\boldsymbol{A})] \leqslant \mathrm{E}\left[\sqrt{\sum_{i=1}^m X_{i1}^2}\right] \leqslant \sqrt{\mathrm{E}\left[\sum_{i=1}^m X_{i1}^2\right]} = \sqrt{m\frac{\delta\varepsilon^2}{(1-c)^2}}。$$

即得 $\mathrm{E}[s_n(\boldsymbol{A})] \leqslant 1.01\varepsilon\sqrt{\delta m}$。

28 [**一致 Glivenko-Cantelli 类, 有限 VC 维度**] 在注记 R8.3.19 (一致 Glivenko-Cantelli 类) 中我们指出：Boolean 函数族若有有限 VC 维度，则为一致 Glivenko-Cantelli 类。

证明其逆命题：设 $\mathcal{F}$ 为定义于论域 Ω 的 Boolean 函数族。称 $\mathcal{F}$ 为一致 Glivenko-Cantelli (uGC) 类，若对于 Ω 的任意的概率测度 μ，当 $X_1, X_2, \cdots, X_n \overset{\text{i.i.d.}}{\sim} \mu$ 的数量 $n \to \infty$ 时，满足

$$\lim_{n\to\infty} \sup_{\mu} \mathrm{E}_{X_1,\cdots,X_n\sim\mu}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}_{\mu}[f(X_1)]\right|\right] = 0。$$

证明：若 Boolean 函数族 $\mathcal{F}$ 是一个 uGC 类，则其 Vapnik-Chervonenkis 维度必然有限，即 $\mathrm{vc}(\mathcal{F}) < \infty$。

证明 • 构造离散测度

利用反证法，假设 $\mathrm{vc}(\mathcal{F}) = \infty$，则对于任意的 $n \geqslant 1$，存在大小为 n 的子集 $\mathbb{S}_n = \{x_1, x_2, \cdots, x_n\} \subset \Omega$ 能够被 $\mathcal{F}$ 打散。于 $\mathbb{S}_n$ 定义均匀离散概率测度 μ_n，即

$$\mu_n(\{x_j\}) = \frac{1}{n}, \qquad (j = 1, 2, \cdots, n)$$

之后从 μ_n 独立同分布地抽取 n 个样本 $X_1, X_2, \cdots, X_n$，令 $V = \{X_1, X_2, \cdots, X_n\}$ 为实际观测到的不重复点集，$U = \mathbb{S}_n \setminus V$ 为从未被选中的点集。

• 寻找“最坏情况”函数

由于 $\mathbb{S}_n$ 被 $\mathcal{F}$ 打散，因此对于 $\mathbb{S}_n$ 的任意的子集，于 $\mathcal{F}$ 必定存在函数能够将此子集的点标记为 1，将子集外的点标记为 0。

特别地，对于未观测集合 $U \subset \mathbb{S}_n$，必定存在特定的函数 $f^* \in \mathcal{F}$，满足

$$f^*(x) = \begin{cases} 1, x \in U, \\ 0, x \in V。 \end{cases}$$

• 计算经验偏差

(*考虑 f^* 于样本的表现。*)

一方面，由于 $X_i \in V$，因此其经验均值为

$$\frac{1}{n}\sum_{i=1}^{n} f^*(X_i) = 0。$$

另一方面，f^* 于真实测度 μ_n 的期望为

$$\mathrm{E}_{\mu_n}[f^*(X_1)] = \sum_{j=1}^{n} f^*(x_j)\mu_n(\{x_j\}) = \frac{|U|}{n},$$

因此测度 μ_n, 函数 f^* 的偏差为

$$\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}_{\mu_n}[f(X_1)]\right| \geqslant \left|0 - \frac{|U|}{n}\right| = \frac{|U|}{n},$$

两侧取期望，

$$\mathrm{E}_{X_1,\cdots,X_n\sim\mu_n}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}_{\mu_n}[f(X_1)]\right|\right] \geqslant \frac{\mathrm{E}[|U|]}{n}。$$

(*之后计算 $\mathrm{E}[|U|]$。*)

对于 $x_j \in \mathbb{S}_n$，其于单次抽样未被抽的概率为 $1 - \frac{1}{n}$，因此

$$\mathrm{E}[|U|] = \sum_{j=1}^{n} \mathrm{P}\{x_j \notin V\} = n\left(1 - \frac{1}{n}\right)^n,$$

将其代入，

$$\mathrm{E}_{X_1,\cdots,X_n\sim\mu_n}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}_{\mu_n}[f(X_1)]\right|\right] \geqslant \left(1 - \frac{1}{n}\right)^n,$$

两侧取极限，

$$\lim_{n\to\infty}\sup_{\mu}\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i)-\mathrm{E}_{\mu}[f(X_1)]\right|\right]\geqslant\frac{1}{\mathrm{e}}>0,$$

这与 UGC 类的极限趋于 0 矛盾；如此，$\mathrm{vc}(\mathcal{F})<\infty$。

29 [**平方误差函数族的 VC 维度**] 设 $\mathcal{F}$ 为定义于论域 Ω 的 Boolean 函数族。给定固定的 Boolean 函数 $h:\Omega\to\{0,1\}$，定义新的 Boolean 函数族 $\mathcal{G}$ 为

$$\mathcal{G}=\{(f-h)^2:f\in\mathcal{F}\}。$$

证明：$\mathcal{G}$ 的 Vapnik-Chervonenkis 维度满足 $\mathrm{vc}(\mathcal{G})=\mathrm{vc}(\mathcal{F})$。

注释 对于 $x\in\Omega$，考虑映射 $\phi_x:y\mapsto(y-h(x))^2$，其中 $y\in\{0,1\}$。

a. 当 $h(x)=0$ 时，$\phi_x(y)=y^2=y$，为恒等映射。

b. 当 $h(x)=1$ 时，

$$\phi_x(y)=(y-1)^2=\begin{cases}1,\,y=0,\\0,\,y=1,\end{cases}$$

等价于逻辑非操作 $\phi_x(y)=1-y$，因此映射 $\phi_x:\{0,1\}\to\{0,1\}$ 为双射。

证明 考虑有限样本的投影集。

设 $\mathbb{S}=\{x_1,x_2,\cdots,x_n\}\subset\Omega$，定义函数族 $\mathcal{F},\mathcal{G}$ 于 $\mathbb{S}$ 的投影为

$$P_{\mathcal{F}}(\mathbb{S})=\{(f(x_1),f(x_2),\cdots,f(x_n)):f\in\mathcal{F}\}\subset\{0,1\}^n,$$
$$P_{\mathcal{G}}(\mathbb{S})=\{((f(x_1)-h(x_1))^2,\cdots,(f(x_n)-h(x_n))^2):f\in\mathcal{F}\}\subset\{0,1\}^n。$$

设 h 于 $\mathbb{S}$ 产生固定的 Boolean 向量为 $\boldsymbol{b}=(h(x_1),\cdots,h(x_n))$，定义 $T:\{0,1\}^n\to\{0,1\}^n$ 为

$$T(\boldsymbol{v})=((v_1-b_1)^2,\cdots,(v_n-b_n)^2)。$$

(由于 T 于任意的分量均为双射，因此 $T:\{0,1\}^n\to\{0,1\}^n$ 为双射。)

则

$$P_{\mathcal{G}}(\mathbb{S})=\{T(\boldsymbol{v}):\boldsymbol{v}\in P_{\mathcal{F}}(\mathbb{S})\}=T(P_{\mathcal{F}}(\mathbb{S}))。$$

推导打散的等价性。

根据打散的定义，$\mathbb{S}$ 被 $\mathcal{F}$ 打散，当且仅当 $|P_{\mathcal{F}}(\mathbb{S})|=2^n$。

注意到 T 为双射算子，因此

$$|P_{\mathcal{F}}(\mathbb{S})|=2^n\iff|P_{\mathcal{G}}(\mathbb{S})|=|T(P_{\mathcal{F}}(\mathbb{S}))|=2^n,$$

从而 $\mathbb{S}$ 能够被 $\mathcal{F}$ 打散，当且仅当 $\mathbb{S}$ 能够被 $\mathcal{G}$ 打散，从而 $\mathrm{vc}(\mathcal{G})=\mathrm{vc}(\mathcal{F})$。

30 [**基于随机标签的 VC 一致收敛定理**] 于 8.4 节的学习问题设定，我们假设标签 $T(X)$ 完全由 X 决定，这于现实很少成立。例如，认为诊断 $T(X)\in\{0,1\}$ 完全由健康数据 X 决定是不现实的；更常见的是，标签 Y 只是与 X 相关的随机变量。

尝试将学习理论 (直至定理 T8.4.5 (VC 泛化界)) 推广到形如 (X_i,Y_i) 的训练数据。$\mathcal{F}$ 为定义于特征空间 Ω 的 Boolean 假设函数族，其 Vapnik-Chervonenkis 维度为 $d=\mathrm{vc}(\mathcal{F})<\infty$。设 $Z=(X,Y)$ 为定义于增广样本空间 $\mathcal{Z}=\Omega\times\{0,1\}$ 的随机变量对，$Z_1,\cdots,Z_n=(X_1,Y_1),\cdots,(X_n,Y_n)$ 为独立同分布的训练样本。对于任意的假设函数 $f\in\mathcal{F}$，定义其真实风险, 经验风险分别为

$$R(f)=\mathrm{E}_{(X,Y)}[(f(X)-Y)^2],\ R_n(f)=\frac{1}{n}\sum_{i=1}^{n}(f(X_i)-Y_i)^2。$$

证明：在此随机标签的设定，经验风险于整个函数族一致收敛于真实风险，即

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}|R_n(f)-R(f)|\right]\leqslant C\sqrt{\frac{\mathrm{vc}(\mathcal{F})}{n}}。$$

证明 • 构造增广空间的误差函数族

对于任意的 $f \in \mathcal{F}$，定义对应的误差函数 $g_f : \mathcal{Z} \to \{0,1\}$ 为

$$g_f(Z) = g_f(X,Y) = (f(X) - Y)^2。$$

由于 $f(X), Y \in \{0,1\}$，其平方误差等价于指示函数 $\mathbf{1}_{\{f(X) \neq Y\}}$，因此 g_f 为 Boolean 函数。

定义新的误差函数族 $\mathcal{G} = \{g_f : f \in \mathcal{F}\}$，则

$$R(f) = \mathrm{E}[g_f(Z)]，\ R_n(f) = \frac{1}{n}\sum_{i=1}^{n} g_f(Z_i)，$$

证明目标转化为

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}} |R_n(f) - R(f)|\right] = \mathrm{E}\left[\sup_{g\in\mathcal{G}} \left|\frac{1}{n}\sum_{i=1}^{n} g(Z_i) - \mathrm{E}[g(Z)]\right|\right]。$$

- 界定新函数族 $\mathcal{G}$ 的 VC 维度

假设 $\mathcal{G}$ 能够打散有限子集 $\mathbb{S} = \{z_1, \cdots, z_m\} \subset \mathcal{Z}$，其中 $z_i = (x_i, y_i)$，则 $\mathbb{S}$ 的特征元素 $x_1, \cdots, x_m$ 必定互不相同。

(否则，存在 $i \neq j$ 使得 $x_i = x_j$，因此 $y_i \neq y_j$，从而对于任意的 $f \in \mathcal{F}$，输出 $f(x_i) = f(x_j)$，此时误差必定一个为 0 一个为 1，从而无法同时输出 $(0,0)$ 或 $(1,1)$。)

令 $\mathbb{S}_X = \{x_1, \cdots, x_m\} \subset \Omega$ 为 $\mathbb{S}$ 于 Ω 的投影，则 $|\mathbb{S}_X| = m$ (由于 x_i 是互不相同的)。

由于 $\mathbb{S}$ 能够被 $\mathcal{G}$ 打散，因此当 f 遍历 $\mathcal{F}$ 时，向量序列

$$((f(x_1) - y_1)^2, \cdots, (f(x_m) - y_m)^2)$$

能够取遍 $\{0,1\}^m$ 的所有 2^m 种组合。

注意到 $v \mapsto (v - y_i)^2$ 为双射，因此误差向量取遍 $\{0,1\}^m$，当且仅当底层的特征向量序列

$$(f(x_1), \cdots, f(x_m))$$

也能取遍 $\{0,1\}^m$ 的所有组合，从而 $\mathbb{S}_X$ 能够被原假设族 $\mathcal{F}$ 打散。

由于 $\mathcal{F}$ 能打散大小为 m 的集合，因此 $m \leqslant \mathrm{vc}(\mathcal{F})$，即 $\mathrm{vc}(\mathcal{G}) \leqslant \mathrm{vc}(\mathcal{F})$。

根据最优 VC 大数定律，可得

$$\mathrm{E}\left[\sup_{g\in\mathcal{G}} \left|\frac{1}{n}\sum_{i=1}^{n} g(Z_i) - \mathrm{E}[g(Z)]\right|\right] \leqslant C\sqrt{\frac{\mathrm{vc}(\mathcal{G})}{n}}, \qquad (C > 0)$$

代入 $\mathrm{vc}(\mathcal{G}) \leqslant \mathrm{vc}(\mathcal{F})$，即为

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}} |R_n(f) - R(f)|\right] \leqslant C\sqrt{\frac{\mathrm{vc}(\mathcal{F})}{n}}。$$

31 [**学习 Lipschitz 函数**] 设 $T : [0,1] \to [0,1]$ 为 Lipschitz 常数不超过 1 的函数。考虑假设类

$$\mathcal{F} = \{f : [0,1] \to [0,1],\ f_{\mathrm{Lip}} \leqslant 1\},$$

并假设 $T \in \mathcal{F}$。设 $X_1, \cdots, X_n$ i.i.d. $\sim \mathrm{Unif}[0,1]$ 为独立均匀样本，观测标签 $T(X_i)$。证明：8.4.2 节的经验风险最小化算法满足类似定理 T8.4.5 (VC 泛化界) 的泛化界：

$$\mathrm{E}[R(f_n)] \leqslant R(f) + \frac{C}{\sqrt{n}},$$

其中 $R(f) = \mathrm{E}|f(X) - T(X)|$ ($X \sim \mathrm{Unif}[0,1]$) 为真实风险。

证明 - (损失函数族与覆盖数)

对 $f \in \mathcal{F}$ 定义 $g_f(x) = |f(x) - T(x)|$，则 $R(f) = \mathrm{E}[g_f(X)]$，

$$R_n(f) = \frac{1}{n}\sum_{i=1}^{n} g_f(X_i)。$$

由于 f, T 均为 1-Lipschitz，g_f 的 Lipschitz 常数不超过 2，并且取值于 $[0,1]$。

(估计 $\mathcal{G}=\{g_f : f\in\mathcal{F}\}$ 的覆盖数。)

固定 $0<\varepsilon\leqslant 1$，令 $\{x_j\}_{j=1}^{L}$ 为 $[0,1]$ 的等距 $\varepsilon/6$-网，其中 $L=\lceil 6/\varepsilon\rceil+1\leqslant 7/\varepsilon$，对于任意的 $g\in\mathcal{G}$，令 $q_j\in[0,1]$ 的 $\varepsilon/6$-网，使得 $|g(x_j)-q_j|\leqslant\varepsilon/6$。以 (x_j,q_j) 为节点定义分段仿射函数 h_g。当 $x\in[x_j,x_{j+1}]$ 时，由于 g 为 2-Lipschitz，可得 g 同连接 $(x_j,g(x_j)),(x_{j+1},g(x_{j+1}))$ 的线段相差至多 $2\varepsilon/6$；量化后的分段仿射函数相差至多 $\varepsilon/6$。因此 $\|g-h_g\|_\infty\leqslant\varepsilon/2$。定义 $\mathcal{H}_\varepsilon$ 为量化配置所对应的函数族。若 $B_\infty(h,\varepsilon/2)\cap\mathcal{G}\neq\emptyset$，令 $g_h\in B_\infty(h,\varepsilon/2)\cap\mathcal{G}$。所取的函数族为 $\mathcal{G}$ 的 ε-网。各 q_j 至多有 $7/\varepsilon$ 个取值，因此

$$\mathcal{N}(\mathcal{G},\|\cdot\|_\infty,\varepsilon)\leqslant(7/\varepsilon)^{7/\varepsilon},$$
$$\ln\mathcal{N}(\mathcal{G},\|\cdot\|_\infty,\varepsilon)\leqslant\frac{7}{\varepsilon}\ln\frac{7}{\varepsilon}。$$

- (对称化与 Dudley 链式)

根据对称化引理，可得

$$\mathrm{E}\left[\sup_{g\in\mathcal{G}}|R_n(g)-R(g)|\right]\leqslant 2\mathrm{E}\left[\sup_{g\in\mathcal{G}}\left|\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i g(X_i)\right|\right]。$$

定义

$$Z(g)=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\varepsilon_i g(X_i),$$

其为 $\mathcal{G}$ 的 sub-Gaussian 过程，因为

$$\mathrm{E}|Z(g)-Z(g')|^2=\frac{1}{n}\sum_{i=1}^{n}(g(X_i)-g'(X_i))^2\leqslant\|g-g'\|_\infty^2。$$

根据 Dudley 不等式 (定理 T8.1.4 (离散 Dudley 不等式))，可得

$$\begin{aligned}\mathrm{E}\left[\sup_{g\in\mathcal{G}}|Z(g)|\right]&\leqslant C\int_0^\infty\sqrt{\ln\mathcal{N}(\mathcal{G},\|\cdot\|_\infty,\varepsilon)}\mathrm{d}\varepsilon\\&\leqslant C\int_0^1\varepsilon^{-1/2}\sqrt{\ln(1/\varepsilon)}\mathrm{d}\varepsilon\leqslant C',\end{aligned}$$

其中最后一步的积分收敛 (令 $u=\ln(1/\varepsilon)$，可得 $\int_0^\infty u^{1/2}\mathrm{e}^{-u/2}\mathrm{d}u=2^{3/2}\Gamma(3/2)<\infty$)。

- (ERM 最优性)

由于 $T\in\mathcal{F}$，标签无噪声，$R_n(f_n)\leqslant R_n(T)=0$，因此 $R_n(f_n)=0$。从而

$$\mathrm{E}[R(f_n)]=\mathrm{E}[R(f_n)-R_n(f_n)]\leqslant\mathrm{E}\left[\sup_{g\in\mathcal{G}}|R_n(g)-R(g)|\right]\leqslant\frac{C}{\sqrt{n}},$$

此外，$R(T)=0\leqslant R(f)$，因此

$$\mathrm{E}[R(f_n)]\leqslant R(f)+\frac{C}{\sqrt{n}}。$$

32 [**有限样本的不可学习性**] 定理 T8.4.5 (VC 泛化界) 说明：要学好，训练样本数 n 至少应同假设类的 VC 维度相当。

设 $\mathcal{F}$ 为定义于论域 Ω 的 Boolean 函数族，其 Vapnik-Chervonenkis 维度为 $d=\mathrm{vc}(\mathcal{F})\geqslant 2$。学习算法 $\mathcal{A}$ 接受 n 个由目标函数 $f^*\in\mathcal{F}$ 标记的独立同分布的样本 $\mathbb{S}=\{(x_1,f^*(x_1)),\cdots,(x_n,f^*(x_n))\}$ $(x_i\sim\mu)$，输出假设函数 $h_{\mathbb{S}}:\Omega\to\{0,1\}$。定义真实风险为 $R(h_{\mathbb{S}})=\mathrm{P}_{x\sim\mu}(h_{\mathbb{S}}(x)\neq f^*(x))$。

证明：若训练样本量 $n<\frac{d}{2}$，则存在 Ω 的概率分布 μ，使得对于任意的学习算法 $\mathcal{A}$，均存在“最坏情况”的目标函数 $f^*\in\mathcal{F}$，满足 Minimax 下界

$$\inf_{\mathcal{A}}\sup_{f^*\in\mathcal{F}}\mathrm{E}_{\mathbb{S}\sim\mu^n}[R(\mathcal{A}(\mathbb{S}))]\geqslant\frac{1}{4}。$$

证明 由于 $\mathrm{vc}(\mathcal{F})=d$，因此存在 $C=\{c_1,c_2,\cdots,c_d\}\subset\Omega$ 能够被 $\mathcal{F}$ 打散，即 $\mathcal{F}$ 能够于其实现所有 2^d 种可能的 Boolean 组合。

(构造对抗分布 μ。)

构造仅集中于集合 C 的均匀概率测度 μ 为

$$\mu(\{x\}) = \begin{cases} 1/d, & x \in C, \\ 0, & x \notin C \end{cases}。$$

- 计算给定样本的条件期望误差

(要证明 $\sup_{f^* \in \mathcal{F}} \mathrm{E}_{\mathbb{S}}[R(\mathcal{A}(\mathbb{S}))] \geqslant 1/4$，我们考虑利用概率方法，若随机分布的平均误差不小于 $1/4$，则至少存在 f^*，其误差不小于 $1/4$。)

于 $\mathcal{F}$ 能够诱导 C 的所有标记的 2^d 个函数，均匀随机抽取一个作为目标函数 f^*，此时对于 $c_i \in C$，$f^*(c_i)$ i.i.d. $\sim$ Bernoulli$(1/2)$。

设算法 $\mathcal{A}$ 接收的训练集特征序列为 $\mathbb{S} = (x_1, \cdots, x_n)$，令 $U = \{x_1, \cdots, x_n\} \subset C$ 为样本集包含的不重复元素的集合，则 $|U| \leqslant n$ (由于总抽样次数为 n)。

计算于固定特征序列 $\mathbb{S}$ 的条件，关于随机目标函数 f^* 的期望风险，

$$\mathrm{E}_{f^*}[R(h_{\mathbb{S}}) \mid \mathbb{S}] = \mathrm{E}_{f^*}\left[\sum_{i=1}^{d} \mathbf{1}_{\{h_{\mathbb{S}}(c_i) \neq f^*(c_i)\}} \mu(\{c_i\}) \mid \mathbb{S}\right] = \frac{1}{d} \sum_{i=1}^{d} \mathrm{E}_{f^*}[\mathbf{1}_{\{h_{\mathbb{S}}(c_i) \neq f^*(c_i)\}} \mid \mathbb{S}]。$$

其中：

a. 对于已观测点 $c_i \in U$，由于误差非负，$\mathrm{E}_{f^*}[\mathbf{1}_{\{h_{\mathbb{S}}(c_i) \neq f^*(c_i)\}} \mid \mathbb{S}] \geqslant 0$。

b. 对于未观测点 $c_i \notin U$，由于 f^* 于 C 取值是独立均匀的，因此给定 U 的标签不能提供关于 c_i 的任意信息，从而无论算法输出 $h_{\mathbb{S}}(c_i)$ 为何，猜错概率等于 $1/2$，即 $\mathrm{E}_{f^*}[\mathbf{1}_{\{h_{\mathbb{S}}(c_i) \neq f^*(c_i)\}} \mid \mathbb{S}] = 1/2$。

将其代入，可得

$$\mathrm{E}_{f^*}[R(h_{\mathbb{S}}) \mid \mathbb{S}] \geqslant \frac{1}{d} \sum_{c_i \in U} 0 + \frac{1}{d} \sum_{c_i \notin U} \frac{1}{2} = \frac{|C \setminus U|}{2d}。$$

- 代入样本量条件导出下界

由于 $|U| \leqslant n$，未观测点数量 $|C \setminus U| = d - |U| \geqslant d - n$。代入得

$$\mathrm{E}_{f^*}[R(h_{\mathbb{S}}) \mid \mathbb{S}] \geqslant \frac{d-n}{2d} = \frac{1}{2} - \frac{n}{2d} > \frac{1}{2} - \frac{1}{4} = \frac{1}{4}。$$

对 $\mathbb{S}$ 的分布取期望，

$$\mathrm{E}_{f^*}\mathrm{E}_{\mathbb{S}}[R(\mathcal{A}(\mathbb{S}))] > \frac{1}{4}。$$

根据平均值原理，可得存在特定的目标函数 $f_0^* \in \mathcal{F}$，使得算法的期望误差大于 $1/4$，即对于任意的算法 $\mathcal{A}$，均满足

$$\sup_{f^* \in \mathcal{F}} \mathrm{E}_{\mathbb{S} \sim \mu^n}[R(\mathcal{A}(\mathbb{S}))] \geqslant \frac{1}{4},$$

对于任意的算法 $\mathcal{A}$ 取下确界，

$$\inf_{\mathcal{A}} \sup_{f^* \in \mathcal{F}} \mathrm{E}_{\mathbb{S} \sim \mu^n}[R(\mathcal{A}(\mathbb{S}))] \geqslant \frac{1}{4}。$$

33 [γ_2 **泛函受控于 Dudley 积分**] 设 $(\mathbb{T}, d)$ 为度量空间。定义集合序列 $(\mathbb{T}_n)_{n=0}^{\infty}$ 为容许序列，若其满足 $\mathbb{T}_n \subset \mathbb{T}$，$|\mathbb{T}_0| = 1$，对于所有 $n \geqslant 1$ 有 $|\mathbb{T}_n| \leqslant 2^{2^n}$。定义度量空间 $\mathbb{T}$ 的 Talagrand γ_2 泛函为

$$\gamma_2(\mathbb{T}, d) = \inf_{(\mathbb{T}_n)} \sup_{t \in \mathbb{T}} \sum_{n=0}^{\infty} 2^{n/2} d(t, \mathbb{T}_n),$$

其中下确界遍历所有可能的容许序列 $(\mathbb{T}_n)$，并且 $d(t, \mathbb{T}_n) = \inf_{s \in \mathbb{T}_n} d(t, s)$。令 $\mathcal{N}(\mathbb{T}, d, \varepsilon)$ 表示度量空间的覆盖数。证明：存在绝对常数 $C > 0$，使得 γ_2 泛函受控于 Dudley 积分，

$$\gamma_2(\mathbb{T}, d) \leqslant C \int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)} \mathrm{d}\varepsilon。$$

证明 • 构造特定的容许序列

定义基数阈值序列为

$$N_0 = 1, N_n = 2^{2^n}, \qquad (n \geqslant 1)$$

若 Dudley 积分为 $+\infty$，结论成立；之后假定 Dudley 积分有限。由于覆盖数关于半径单调，任意的正半径处的覆盖数均有限，可得 $\mathbb{T}$ 全有界。临界覆盖半径 ε_n 为

$$\varepsilon_n = \inf\{\varepsilon > 0 : \mathcal{N}(\mathbb{T}, d, \varepsilon) \leqslant N_n\}, \qquad (n \geqslant 0)$$

固定 $\eta > 0$。根据下确界的定义，对于任意的 n，存在 $r_n < \varepsilon_n + \eta 2^{-n}$，使得 $\mathcal{N}(\mathbb{T}, d, r_n) \leqslant N_n$。因此存在基数不超过 N_n 的集合 $\mathbb{T}_n \subset \mathbb{T}$，构成 $\mathbb{T}$ 的 r_n-网，即对于任意的 $t \in \mathbb{T}$，均满足

$$d(t, \mathbb{T}_n) \leqslant r_n < \varepsilon_n + \eta 2^{-n}。$$

由于 $|\mathbb{T}_0| \leqslant N_0 = 1$，$|\mathbb{T}_n| \leqslant N_n = 2^{2^n}$，因此 $(\mathbb{T}_n)_{n=0}^{\infty}$ 为合法的容许序列。

将 $(\mathbb{T}_n)$ 代入 γ_2 泛函的定义，可得

$$\begin{aligned}\gamma_2(\mathbb{T}, d) \leqslant \sup_{t\in\mathbb{T}} \sum_{n=0}^{\infty} 2^{n/2} d(t, \mathbb{T}_n) &\leqslant \sum_{n=0}^{\infty} 2^{n/2}(\varepsilon_n + \eta 2^{-n}) \\ &= \sum_{n=0}^{\infty} 2^{n/2}\varepsilon_n + \eta \sum_{n=0}^{\infty} 2^{-n/2}。\end{aligned}$$

令 $\eta \downarrow 0$，可得

$$\gamma_2(\mathbb{T}, d) \leqslant \sum_{n=0}^{\infty} 2^{n/2}\varepsilon_n。 \qquad \text{(I)}$$

• 利用 Dudley 积分下界控制级数

将 Dudley 积分拆分为 $(\varepsilon_{n+1}, \varepsilon_n]$ 的分段积分之和，

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon \geqslant \sum_{n=0}^{\infty} \int_{\varepsilon_{n+1}}^{\varepsilon_n} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon,$$

当 $\varepsilon \in (\varepsilon_{n+1}, \varepsilon_n)$ 时，由于 $\varepsilon < \varepsilon_n$，因此 $\mathcal{N}(\mathbb{T}, d, \varepsilon) > N_n$。

a. 当 $n = 0$ 时，$N_0 = 1$，可得 $\mathcal{N} \geqslant 2$。此时 $\sqrt{\ln \mathcal{N}} \geqslant \sqrt{\ln 2} = 2^{0/2}\sqrt{\ln 2}$。

b. 当 $n \geqslant 1$ 时，$N_n = 2^{2^n}$，可得 $\sqrt{\ln \mathcal{N}} > \sqrt{\ln(2^{2^n})} = \sqrt{2^n \ln 2} = 2^{n/2}\sqrt{\ln 2}$。

因此

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon \geqslant \sqrt{\ln 2} \sum_{n=0}^{\infty} (\varepsilon_n - \varepsilon_{n+1}) 2^{n/2}。 \qquad \text{(II)}$$

(*考虑对右侧级数进行* Abel *变换。*)

对于右侧，

$$\begin{aligned}\sum_{n=0}^{\infty} (\varepsilon_n - \varepsilon_{n+1}) 2^{n/2} &= \varepsilon_0 + \sum_{n=1}^{\infty} \varepsilon_n (2^{n/2} - 2^{(n-1)/2}) \\ &= \varepsilon_0 + \sum_{n=1}^{\infty} \varepsilon_n 2^{n/2}(1 - 1/\sqrt{2}),\end{aligned}$$

令 $c = 1 - 1/\sqrt{2} \in (0, 1)$，则

$$\varepsilon_0 + c\sum_{n=1}^{\infty} \varepsilon_n 2^{n/2} \geqslant c\varepsilon_0 2^{0/2} + c\sum_{n=1}^{\infty} \varepsilon_n 2^{n/2} = c\sum_{n=0}^{\infty} 2^{n/2}\varepsilon_n,$$

将其代入于 (II)，可得

$$\int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon \geqslant c\sqrt{\ln 2} \sum_{n=0}^{\infty} 2^{n/2}\varepsilon_n,$$

即

$$\sum_{n=0}^{\infty} 2^{n/2}\varepsilon_n \leqslant \frac{1}{c\sqrt{\ln 2}} \int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon,$$

将其代入于 (I)，可得

$$\gamma_2(\mathbb{T}, d) \leqslant C \int_0^{\infty} \sqrt{\ln \mathcal{N}(\mathbb{T}, d, \varepsilon)}\mathrm{d}\varepsilon。 \qquad \left(C = \frac{2}{c\sqrt{\ln 2}}\right)$$

34 [γ_2 **泛函严格优于 Dudley 离散和的实例**] 有时 γ_2 泛函可以显著小于 Dudley 离散和。为看到这一点，回顾练习 Q8.4 (Dudley 不等式可能非常松弛) 的例子。

于 $\mathbb{R}^n$ 赋予标准 Euclidean 度量 $d(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\|_2$。令 $\boldsymbol{e}_1, \cdots, \boldsymbol{e}_n$ 为 $\mathbb{R}^n$ 的标准正交基。定义

$$\mathbb{T} = \{\boldsymbol{0}\} \cup \left\{ \frac{\boldsymbol{e}_k}{\sqrt{1 + \ln k}} : k = 1, \cdots, n \right\}。$$

容许序列 $(\mathbb{T}_m)_{m=0}^{\infty}$ 满足 $\mathbb{T}_m \subset \mathbb{T}$，$|\mathbb{T}_0| = 1, |\mathbb{T}_m| \leqslant 2^{2^m}$ $(m \geqslant 1)$。

(1) 证明：$\mathbb{T}$ 的 γ_2 泛函于 $n \to \infty$ 时保持一致有界，即构造容许序列 $(\mathbb{T}_m)$，使得

$$\gamma_2(\mathbb{T}, d) = \inf_{(\mathbb{T}_m)} \sup_{\boldsymbol{t} \in \mathbb{T}} \sum_{m=0}^{\infty} 2^{m/2} d(\boldsymbol{t}, \mathbb{T}_m) \leqslant C。$$

(2) 证明：若将上确界操作置于级数求和内部 (即 Dudley 离散和)，此界限随维度 $n \to \infty$ 发散，

$$\inf_{(\mathbb{T}_m)} \sum_{m=0}^{\infty} 2^{m/2} \sup_{\boldsymbol{t} \in \mathbb{T}} d(\boldsymbol{t}, \mathbb{T}_m) \to \infty。$$

证明 (1) 构造基数阈值序列为 $N_m = 2^{2^m}$，令 $\boldsymbol{t}_k = \frac{\boldsymbol{e}_k}{\sqrt{1+\ln k}}$，定义

$$\mathbb{T}_0 = \{\boldsymbol{0}\}, \quad \mathbb{T}_m = \{\boldsymbol{0}\} \cup \{\boldsymbol{t}_k : 1 \leqslant k \leqslant \min(n, N_m - 1)\}, \qquad (m \geqslant 1)$$

则 $|\mathbb{T}_m| \leqslant N_m = 2^{2^m}$，因此 $(\mathbb{T}_m)_{m=0}^{\infty}$ 为合法的容许序列。

对于 $\boldsymbol{t}_k \in \mathbb{T}$ 和层级 m，若 $k \leqslant N_m - 1$，$\boldsymbol{t}_k \in \mathbb{T}_m$，距离 $d(\boldsymbol{t}_k, \mathbb{T}_m) = 0$。若 $k > N_m - 1$，$\boldsymbol{t}_k \notin \mathbb{T}_m$，由于正交性，在 $\mathbb{T}_m$ 中距离最近的点必然为 $\boldsymbol{0}$，从而

$$d(\boldsymbol{t}_k, \mathbb{T}_m) = \|\boldsymbol{t}_k\|_2 = \frac{1}{\sqrt{1 + \ln k}}。$$

(计算级数和的上界)

设 $S(\boldsymbol{t}) = \sum_{m=0}^{\infty} 2^{m/2} d(\boldsymbol{t}, \mathbb{T}_m)$。若 $\boldsymbol{t} = \boldsymbol{0}$，则 $S(\boldsymbol{0}) = 0$。对于非零点 $\boldsymbol{t}_k$，级数仅当 $2^{2^m} \leqslant k$ (即 $2^m \leqslant \frac{\ln k}{\ln 2}$) 时项不为 0。设 M_k 为满足条件的最大整数，则 $2^{M_k} \leqslant \frac{\ln k}{\ln 2}$。

对几何级数求和，

$$\begin{aligned} S(\boldsymbol{t}_k) &= \sum_{m=0}^{M_k} 2^{m/2} \frac{1}{\sqrt{1 + \ln k}} = \frac{1}{\sqrt{1 + \ln k}} \cdot \frac{(\sqrt{2})^{M_k+1} - 1}{\sqrt{2} - 1} \\ &\leqslant \frac{\sqrt{2}}{\sqrt{2} - 1} \frac{2^{M_k/2}}{\sqrt{1 + \ln k}} \leqslant \frac{\sqrt{2}}{(\sqrt{2} - 1)\sqrt{\ln 2}} \frac{\sqrt{\ln k}}{\sqrt{1 + \ln k}} \leqslant \frac{\sqrt{2}}{(\sqrt{2} - 1)\sqrt{\ln 2}}, \end{aligned}$$

因此

$$\gamma_2(\mathbb{T}, d) \leqslant \sup_{\boldsymbol{t} \in \mathbb{T}} S(\boldsymbol{t}) \leqslant \frac{\sqrt{2}}{(\sqrt{2} - 1)\sqrt{\ln 2}}。$$

(2) (确立单层覆盖半径的下界。)

令 $R_m = \sup_{\boldsymbol{t} \in \mathbb{T}} d(\boldsymbol{t}, \mathbb{T}_m)$。于 $\mathbb{T}$ 选取前 K 个点构成子集 $\mathbb{T}'$ $(K \leqslant n)$。

对于任意的 $\boldsymbol{t}_i, \boldsymbol{t}_j \in \mathbb{T}'$，其距离下界为

$$\|\boldsymbol{t}_i - \boldsymbol{t}_j\|_2 = \sqrt{\|\boldsymbol{t}_i\|_2^2 + \|\boldsymbol{t}_j\|_2^2} \geqslant \sqrt{2}\|\boldsymbol{t}_K\|_2 = \frac{\sqrt{2}}{\sqrt{1+\ln K}}。$$

(若 $R_m < \frac{1}{\sqrt{2(1+\ln K)}}$，半径为 R_m 的球最多只能覆盖 1 个点，此时覆盖 $\mathbb{T}'$ 至少需要 K 个球，即 $|\mathbb{T}_m| \geqslant K$。)

若 $K > |\mathbb{T}_m|$，则 $R_m \geqslant \frac{1}{\sqrt{2(1+\ln K)}}$，令 $K = 2^{2^m}+1 \leqslant n$，可得

$$R_m \geqslant \frac{1}{\sqrt{2(1+\ln(2^{2^m}+1))}}。$$

(证明 Dudley 离散和发散。)

对于满足 $2^{2^m}+1 \leqslant n$ 的整数 m，

$$R_m \geqslant \frac{1}{\sqrt{2(1+(2^m+1)\ln 2)}} \geqslant \frac{c}{2^{m/2}},$$

即 $2^{m/2}R_m \geqslant c$。

令 $M_n = \lfloor \log_2(\log_2(n-1)) \rfloor$ 为满足条件的最大整数 m，则 Dudley 离散和为

$$D_n \geqslant \sum_{m=0}^{M_n} 2^{m/2}R_m \geqslant \sum_{m=0}^{M_n} c = c(M_n+1) \to \infty。$$

35 [**Generic Chaining 的高概率界限**] 证明注记 R8.5.4 (Generic Chaining：高概率界) 的结果。设 $(X_t)_{t\in\mathbb{T}}$ 为定义于度量空间 $(\mathbb{T}, d)$ 的随机过程，其含有 sub-Gaussian 增量，即对于任意的 $s, t \in \mathbb{T}$，

$$\mathrm{P}\{|X_s - X_t| \geqslant x\} \leqslant 2\exp\left(-\frac{x^2}{K^2 d(s,t)^2}\right)。 \qquad (K>0)$$

令 $\gamma_2(\mathbb{T}, d)$ 为 $(\mathbb{T}, d)$ 的 Talagrand 泛函，$D = \mathrm{diam}(\mathbb{T})$。选取 $t_0 \in \mathbb{T}$。证明：对于任意的 $u \geqslant 1$，

$$\sup_{t\in\mathbb{T}} |X_t - X_{t_0}| \leqslant CK(\gamma_2(\mathbb{T}, d) + uD) \text{ (w.p. } 1 - c\mathrm{e}^{-u^2})。$$

证明 (我们利用改进的链式法则，不再从第 0 层开始逐层逼近，而是考虑“首次跃进”，

$$t_0 \to \pi_\kappa(t) \to \pi_{\kappa+1}(t) \to \cdots \to t,$$

其中起点层级 κ 的选择满足 $2^{\kappa/2} \asymp u$。)

- 定义容许序列, 选取跃进层级 κ

  根据 γ_2 泛函的定义 (D8.5.1 (γ_2 泛函))，存在容许序列 $(\mathbb{T}_n)_{n=0}^{\infty}$ (满足 $|\mathbb{T}_0| = 1$，$|\mathbb{T}_n| \leqslant 2^{2^n}$)，使得

  $$\sup_{t\in\mathbb{T}} \sum_{n=0}^{\infty} 2^{n/2} d(t, \mathbb{T}_n) \leqslant 2\gamma_2(\mathbb{T}, d)。$$

  对于 $u \geqslant 1$，选取 $\kappa \in \mathbb{Z}_0^+$ 为满足 $2^{\kappa/2} \geqslant u$ 的最小整数，则 $u \leqslant 2^{\kappa/2} < \sqrt{2}u$，两侧平方，可得

  $$u^2 \leqslant 2^\kappa < 2u^2。$$

  对于任意的 $t \in \mathbb{T}$，令 $\pi_n(t)$ 为网 $\mathbb{T}_n$ 与 t 距离最近的点，将增量进行望远镜级数展开 (从第 κ 层开始)，

  $$X_t - X_{t_0} = (X_{\pi_\kappa(t)} - X_{t_0}) + \sum_{n=\kappa}^{\infty} (X_{\pi_{n+1}(t)} - X_{\pi_n(t)})。$$

  (之后只需界定首次跃进, 后续链条的概率即可。)

- 界定“首次跃进”的概率

  对于任意的 $v \in \mathbb{T}_\kappa$，其中 $|\mathbb{T}_\kappa| \leqslant 2^{2^\kappa}$，定义良性事件

  $$\mathcal{E}_0 = \{\forall v \in \mathbb{T}_\kappa,\ |X_v - X_{t_0}| \leqslant C_0 KDu\},$$

则根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (i)，两侧取并集，可得上述事件不发生的概率为

$$\mathrm{P}(\mathcal{E}_0^c) \leqslant \sum_{v\in\mathbb{T}_\kappa} \mathrm{P}\{|X_v - X_{t_0}| > C_0 K D u\} \leqslant 2^{2^\kappa}\cdot 2\exp\left(-\frac{C_0^2K^2D^2u^2}{K^2D^2}\right) = 2\exp(2^\kappa \ln 2 - C_0^2u^2),$$

其中指数部分为

$$2\exp(2^\kappa\ln 2 - C_0^2u^2) < 2\exp(2u^2\ln 2 - C_0^2u^2) = 2\exp(-u^2(C_0^2 - 2\ln 2)),$$

此时令 $C_0 = 2$，使得 $C_0^2 - 2\ln 2 \geqslant 1$，可得 $\mathrm{P}(\mathcal{E}_0^c) \leqslant 2\mathrm{e}^{-u^2}$。

- 界定后续链条的概率

对于任意的点对 $(s,w)\in\mathbb{T}_{n+1}\times\mathbb{T}_n$，其中 $|\mathbb{T}_{n+1}|\cdot|\mathbb{T}_n| \leqslant 2^{3\cdot 2^n}$，定义良性事件

$$\mathcal{E}_n = \{\forall s\in\mathbb{T}_{n+1}, \forall w\in\mathbb{T}_n,\ |X_s - X_w| \leqslant C_1K2^{n/2}d(s,w)\},$$

则根据命题 P2.6.1 (sub-Gaussian 性质) 的性质 (i)，两侧取并集，可得上述事件不发生的概率为

$$\mathrm{P}(\mathcal{E}_n^c) \leqslant 2^{3\cdot 2^n}\cdot 2\exp\left(-\frac{C_1^2K^2 2^n d(s,w)^2}{K^2 d(s,w)^2}\right) = 2\exp(-2^n(C_1^2 - 3\ln 2))。$$

此时令 $C_1 = 3$，使得 $C_1^2 - 3\ln 2 \geqslant 2$，可得 $\mathrm{P}(\mathcal{E}_n^c) \leqslant 2\exp(-2\cdot 2^n)$。

将所有 $n\geqslant\kappa$ 的失效概率求和，受其首项主导，

$$\sum_{n=\kappa}^{\infty}\mathrm{P}(\mathcal{E}_n^c) \leqslant 2\sum_{m=0}^{\infty}\exp(-2(2^\kappa+m)) \leqslant 3\exp(-2\cdot 2^\kappa) \leqslant 3\mathrm{e}^{-2u^2} \leqslant 3\mathrm{e}^{-u^2}。$$

- 在良性事件下完成路径组装

定义良性事件 $\mathcal{E} = \mathcal{E}_0 \cap \bigcap_{n=\kappa}^{\infty}\mathcal{E}_n$，则

$$\mathrm{P}(\mathcal{E}) \geqslant 1 - \mathrm{P}(\mathcal{E}_0^c) - \sum_{n=\kappa}^{\infty}\mathrm{P}(\mathcal{E}_n^c) \geqslant 1 - 2\mathrm{e}^{-u^2} - 3\mathrm{e}^{-u^2} = 1 - 5\mathrm{e}^{-u^2}。$$

若 $\mathcal{E}$ 发生，则对于任意的 $t\in\mathbb{T}$，利用三角不等式 $d(\pi_{n+1}(t),\pi_n(t)) \leqslant d(t,\mathbb{T}_{n+1}) + d(t,\mathbb{T}_n)$，可得

$$|X_t - X_{t_0}| \leqslant C_0KDu + \sum_{n=\kappa}^{\infty} C_1K2^{n/2}(d(t,\mathbb{T}_{n+1}) + d(t,\mathbb{T}_n))。$$

其中

$$\sum_{n=\kappa}^{\infty} C_1K2^{n/2}(d(t,\mathbb{T}_{n+1}) + d(t,\mathbb{T}_n)) \leqslant 2C_1K\sum_{m=0}^{\infty}2^{m/2}d(t,\mathbb{T}_m) \leqslant 4C_1K\gamma_2(\mathbb{T},d),$$

将其代入，可得

$$|X_t - X_{t_0}| \leqslant K(C_0Du + 4C_1\gamma_2(\mathbb{T},d)),$$

此时令 $C = \max(C_0, 4C_1)$，$c = 5$，两侧取上确界，可得

$$\sup_{t\in\mathbb{T}}|X_t - X_{t_0}| \leqslant CK(\gamma_2(\mathbb{T},d) + uD)\ (\text{w.p. } 1 - c\mathrm{e}^{-u^2})。$$

36 [**经验过程：一般链式界**] 迄今为止，我们只对两类函数族界定了经验过程：Lipschitz 类 (见定理 T8.2.3 (Lipschitz 大数定律))，具有有限 VC 维度的 Boolean 类 (见定理 T8.3.15 (VC 大数定律))。

现在转向一般情形。设 $\mathcal{F}$ 为包含零函数且定义于论域 Ω 的实值函数族，$X, X_1, \cdots, X_n$ 为 Ω 的独立同分布的随机变量。设 d 为定义于 $\mathcal{F}$ 的度量，满足 sub-Gaussian 增量条件，即对于任意的 $f,g\in\mathcal{F}$，均满足

$$\|f(X) - g(X)\|_{\psi_2} \leqslant d(f,g),$$

(例如选取 $d(f,g) = C\|f-g\|_{L^\infty}$，即可满足此条件。) 证明：

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i) - \mathrm{E}[f(X)]\right|\right] \leqslant \frac{C\gamma_2(\mathcal{F},d)}{\sqrt{n}}。 \qquad (C>0)$$

证明 对于任意的 $f \in \mathcal{F}$，定义

$$Z_f = \frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}[f(X)],$$

则 $(Z_f)_{f\in\mathcal{F}}$ 为由 $\mathcal{F}$ 索引的中心化随机过程。(之后只需界定 $\mathrm{E}\left[\sup_{f\in\mathcal{F}}|Z_f|\right]$。)

- 计算过程增量的 sub-Gaussian 范数

  考虑增量

$$Z_f - Z_g = \frac{1}{n}\sum_{i=1}^{n}(f(X_i) - g(X_i)) - \mathrm{E}[f(X) - g(X)],$$

  令 $W_i = f(X_i) - g(X_i)$，则

$$Z_f - Z_g = \frac{1}{n}\sum_{i=1}^{n}(W_i - \mathrm{E}[W_i])。$$

  根据 sub-Gaussian 增量条件，可得

$$\|W_i\|_{\psi_2} = \|f(X) - g(X)\|_{\psi_2} \leqslant d(f,g)。$$

  因此

$$\|W_i - \mathrm{E}[W_i]\|_{\psi_2} \leqslant c_1\|W_i\|_{\psi_2} \leqslant c_1 d(f,g)。$$

  从而

$$\begin{aligned}\left\|\sum_{i=1}^{n}(W_i - \mathrm{E}[W_i])\right\|_{\psi_2}^2 &\leqslant c_2\sum_{i=1}^{n}\|W_i - \mathrm{E}[W_i]\|_{\psi_2}^2 \\ &\leqslant c_2\sum_{i=1}^{n}(c_1 d(f,g))^2 = c_1^2 c_2 n d(f,g)^2。\end{aligned}$$

  两端开方，之后除以 n，可得

$$\|Z_f - Z_g\|_{\psi_2} = \frac{1}{n}\left\|\sum_{i=1}^{n}(W_i - \mathrm{E}[W_i])\right\|_{\psi_2} \leqslant \frac{c_1\sqrt{c_2}}{\sqrt{n}} d(f,g),$$

  即

$$\|Z_f - Z_g\|_{\psi_2} \leqslant \frac{K}{\sqrt{n}} d(f,g)。 \qquad (K = c_1\sqrt{c_2})$$

  从而 $(Z_f)_{f\in\mathcal{F}}$ 关于新度量 $d'(f,g) = \frac{K}{\sqrt{n}}d(f,g)$ 满足 sub-Gaussian 增量。

- 根据一般链式定理

  根据 Talagrand 的一般链式定理 (若中心化过程 (Z_f) 的增量满足 $\|Z_f - Z_g\|_{\psi_2} \leqslant d'(f,g)$，则其上确界期望受控于度量空间 $(\mathcal{F}, d')$ 的 γ_2 泛函)，可得

$$\begin{aligned}\mathrm{E}\left[\sup_{f\in\mathcal{F}} Z_f\right] &\leqslant C'\gamma_2(\mathcal{F}, d') \\ &= C'\gamma_2\left(\mathcal{F}, \frac{K}{\sqrt{n}}d\right) = \frac{C'K}{\sqrt{n}}\gamma_2(\mathcal{F}, d)。\end{aligned}$$

  由于 $\mathbf{0} \in \mathcal{F}$ 且 $Z_0 = 0$，对带符号的指标集 $\mathcal{F}\times\{-1,1\}$ 应用同一锚定链式估计。对于同一份的两个指标，其增量由 d' 控制；对于相反符号的两个指标，有

$$\|Z_f + Z_g\|_{\psi_2} \leqslant d'(f,\mathbf{0}) + d'(g,\mathbf{0})。$$

  因而通过零函数连接两份指标集所得的两份度量空间的 γ_2 泛函至多是 $\gamma_2(\mathcal{F}, d')$ 的绝对常数倍，且

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathrm{E}[f(X)]\right|\right] \leqslant \frac{C\gamma_2(\mathcal{F}, d)}{\sqrt{n}}。 \qquad (C > 0)$$

37 [**定理 (Talagrand 比较不等式的几何形式)**] 让我们探讨推论 C8.5.8 (Talagrand 比较不等式：几何形式) 的一些有用的变体。

设 $(X_x)_{x\in\mathbb{T}}$ 为定义于 $\mathbb{T}\subset\mathbb{R}^n$ 的随机过程 (不必为零均值)，满足 $X_0=0$ (隐含 $0\in\mathbb{T}$ 或考虑 $\mathbb{T}\cup\{0\}$)。假设其增量满足 sub-Gaussian 条件，即对于任意的 $x,y\in\mathbb{T}\cup\{0\}$，均满足 $\|X_x-X_y\|_{\psi_2}\leqslant K\|x-y\|_2$。

(1) (期望界) 证明：

$$\mathrm{E}\left[\sup_{x\in\mathbb{T}}|X_x|\right]\leqslant CK\gamma(\mathbb{T}),$$

其中 $\gamma(\mathbb{T})=\mathrm{E}\left[\sup_{x\in\mathbb{T}}|\langle g,x\rangle|\right]$ 为 $\mathbb{T}$ 的 Gaussian 复杂度。

(2) (高概率界) 证明：对于任意的 $u\geqslant 1$，

$$\sup_{x\in\mathbb{T}}|X_x|\leqslant CK(w(\mathbb{T})+u\cdot\mathrm{rad}(\mathbb{T}))\ (\text{w.p. } 1-2\mathrm{e}^{-u^2}),$$

其中 $w(\mathbb{T})$ 为 Gaussian 宽度，$\mathrm{rad}(\mathbb{T})=\sup_{x\in\mathbb{T}}\|x\|_2$。

(3) (矩界) 对于任意的 $p\geqslant 1$，利用 (1)(2) 的结论，证明：

$$\left(\mathrm{E}\left[\sup_{x\in\mathbb{T}}|X_x|^p\right]\right)^{1/p}\leqslant C\sqrt{p}K\gamma(\mathbb{T})。$$

证明 (1) (由于 $X_{\mathbf{0}}=0$) 设 $\mathbb{T}'=\mathbb{T}\cup\{\mathbf{0}\}$，则

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}|=\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}-X_{\mathbf{0}}|\leqslant\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}'}|X_{\boldsymbol{x}}-X_{\boldsymbol{y}}|,$$

两侧取期望，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}|\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}'}|X_{\boldsymbol{x}}-X_{\boldsymbol{y}}|\right]。$$

根据 Talagrand 一般链式定理，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}'}|X_{\boldsymbol{x}}-X_{\boldsymbol{y}}|\right]\leqslant C_1K\gamma_2(\mathbb{T}',\|\cdot\|_2);\tag{I}$$

根据主测度定理 (于 Euclidean 空间 γ_2 泛函与 Gaussian 宽度等价)，可得

$$\gamma_2(\mathbb{T}',\|\cdot\|_2)\leqslant C_2w(\mathbb{T}')=C_2\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}\cup\{\mathbf{0}\}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right],\tag{II}$$

其中

$$\begin{aligned}\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}\cup\{\mathbf{0}\}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right]&=\mathrm{E}\left[\max(0,\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle)\right]\\&\leqslant\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\langle\boldsymbol{g},\boldsymbol{x}\rangle|\right]=\gamma(\mathbb{T}),\end{aligned}$$

将其代入于 (II)，可得

$$\gamma_2(\mathbb{T}',\|\cdot\|_2)\leqslant C_2w(\mathbb{T}')=C_2\gamma(\mathbb{T})。\tag{III}$$

联立 (I)(III)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}|\right]\leqslant C_1C_2K\gamma(\mathbb{T}),$$

此时令 $C=C_1C_2$。

(2) 根据一般链式定理，对扩充集合 $\mathbb{T}'$ 根据高概率形式，可得

$$\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}'}|X_{\boldsymbol{x}}-X_{\boldsymbol{y}}|\leqslant C_1K(\gamma_2(\mathbb{T}')+u\cdot\mathrm{diam}(\mathbb{T}'))\ (\text{w.p. } 1-2\mathrm{e}^{-u^2}),\tag{IV}$$

(由于 $\mathbf{0}\in\mathbb{T}'$，$X_{\mathbf{0}}=0$，容易知道，上式左侧控制了 $\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}|$。)

其中对于直径项，

$$\operatorname{diam}(\mathbb{T}') \leqslant 2\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2 = 2\operatorname{rad}(\mathbb{T}); \tag{V}$$

对于泛函项，

$$\gamma_2(\mathbb{T}') \leqslant C_2 w(\mathbb{T}\cup\{\mathbf{0}\})。 \tag{VI}$$

(之后只需将 $w(\mathbb{T}\cup\{\mathbf{0}\})$ 分解为 $w(\mathbb{T})$ 的形式。)

令 $S=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle \boldsymbol{g},\boldsymbol{x}\rangle$，则

$$w(\mathbb{T}) = \mathrm{E}[S]，\ w(\mathbb{T}\cup\{0\}) = \mathrm{E}[\max(0,S)]，$$

利用恒等式 $\max(0,S)=S+\max(0,-S)$，两侧取期望，可得

$$w(\mathbb{T}\cup\{\mathbf{0}\}) = w(\mathbb{T}) + \mathrm{E}[\max(0,-S)]；$$

对于任意的 $\boldsymbol{x}_0\in\mathbb{T}$，$-S\leqslant -\langle \boldsymbol{g},\boldsymbol{x}_0\rangle$，因此

$$\mathrm{E}[\max(0,-S)] \leqslant \mathrm{E}[\max(0,-\langle \boldsymbol{g},\boldsymbol{x}_0\rangle)] = \frac{1}{2}\mathrm{E}[|\langle \boldsymbol{g},\boldsymbol{x}_0\rangle|] = \frac{1}{\sqrt{2\pi}}\|\boldsymbol{x}_0\|_2 \leqslant \frac{1}{\sqrt{2\pi}}\operatorname{rad}(\mathbb{T})，$$

将其代入于 (VI)，可得

$$w(\mathbb{T}\cup\{\mathbf{0}\}) \leqslant w(\mathbb{T}) + C_3\operatorname{rad}(\mathbb{T})。 \tag{VII}$$

将 (V)(VII) 代入于 (IV)，可得

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}| \leqslant C_1K(C_2(w(\mathbb{T})+C_3\operatorname{rad}(\mathbb{T}))+2u\cdot\operatorname{rad}(\mathbb{T})) \leqslant C_4Kw(\mathbb{T}) + C_4K(C_3+2u)\operatorname{rad}(\mathbb{T})\ (\text{w.p. } 1-2\mathrm{e}^{-u^2})，$$

由于 $u\geqslant 1$，取 $C_5=C_3+2$，则 $C_3+2u\leqslant C_5u$，此时

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}| \leqslant C_4Kw(\mathbb{T}) + C_4C_5Ku\operatorname{rad}(\mathbb{T})\ (\text{w.p. } 1-2\mathrm{e}^{-u^2})，$$

令 $C=\max(C_4,C_4C_5)$。

(3) 令 $Z=\sup_{\boldsymbol{x}\in\mathbb{T}}|X_{\boldsymbol{x}}|$。

根据一般链式定理的高概率形式，可得对于任意的 $u\geqslant 0$，

$$\mathrm{P}\{Z > C_1Kw(\mathbb{T}) + C_1K\operatorname{rad}(\mathbb{T})\cdot u\} \leqslant 2\mathrm{e}^{-u^2}，$$

因此

$$Z \leqslant C_1Kw(\mathbb{T}) + C_1K\operatorname{rad}(\mathbb{T})\cdot\xi\ (\text{a.s.})，$$

其中 $\xi\geqslant 0$ 满足 $\mathrm{P}\{\xi>u\}\leqslant 2\mathrm{e}^{-u^2}$。

利用 Minkowski 不等式，可得

$$\|Z\|_{L_p} \leqslant \|C_1Kw(\mathbb{T})\|_{L_p} + \|C_1K\operatorname{rad}(\mathbb{T})\cdot\xi\|_{L_p} = C_1Kw(\mathbb{T}) + C_1K\operatorname{rad}(\mathbb{T})\cdot\|\xi\|_{L_p}。 \tag{VIII}$$

(之后只需计算 $\|\xi\|_{L_p}$。)

利用非负随机变量期望的积分公式，可得

$$\begin{aligned}\mathrm{E}[\xi^p] &= \int_0^\infty pu^{p-1}\mathrm{P}\{\xi>u\}\mathrm{d}u \leqslant \int_0^\infty pu^{p-1}2\mathrm{e}^{-u^2}\mathrm{d}u \qquad (t=u^2)\\ &= \int_0^\infty pt^{\frac{p-1}{2}}\mathrm{e}^{-t}t^{-\frac{1}{2}}\mathrm{d}t = p\int_0^\infty t^{\frac{p}{2}-1}\mathrm{e}^{-t}\mathrm{d}t = p\cdot\Gamma\left(\frac{p}{2}\right)，\end{aligned}$$

因此

$$\|\xi\|_{L_p} = (p\cdot\Gamma(p/2))^{1/p} \leqslant C_2\sqrt{p}，$$

将其代入于 (VIII)，可得

$$(\mathrm{E}[Z^p])^{1/p} \leqslant C_1Kw(\mathbb{T}) + C_1C_2K\operatorname{rad}(\mathbb{T})\sqrt{p}。 \tag{IX}$$

(之后统一通过 $\gamma(\mathbb{T})$ 进行放缩。)

对于 $w(\mathbb{T})$，利用 (1) 的结论，可得

$$w(\mathbb{T}) \leqslant \gamma(\mathbb{T});$$

对于 $\mathrm{rad}(\mathbb{T})$，设 $\boldsymbol{x} \in \mathbb{T}$，则 $\langle \boldsymbol{g}, \boldsymbol{x} \rangle \sim N(0, \|\boldsymbol{x}\|_2^2)$，其绝对值期望为 $\mathrm{E}[|\langle \boldsymbol{g}, \boldsymbol{x} \rangle|] = \sqrt{2/\pi}\|\boldsymbol{x}\|_2$，两侧取上确界，可得

$$\mathrm{rad}(\mathbb{T}) \leqslant \sqrt{\frac{\pi}{2}}\gamma(\mathbb{T});$$

将其代入于 (IX)，可得

$$(\mathrm{E}[Z^p])^{1/p} \leqslant C_1 K \gamma(\mathbb{T}) + C_1 C_2 \sqrt{\frac{\pi}{2}} K \sqrt{p} \gamma(\mathbb{T}),$$

即

$$\left(\mathrm{E}\left[\sup_{x \in \mathbb{T}} |X_x|^p\right]\right)^{1/p} \leqslant C\sqrt{p} K \gamma(\mathbb{T})。$$

38 [**随机向量的期望 L^p 范数**] 于练习 Q3.5 (随机向量的期望 ℓ^p 范数)，我们给出了坐标相互独立的 sub-Gaussian 随机向量的期望 L^p 范数的最优界。

现在忽略独立性假设，设 $\boldsymbol{X} \in \mathbb{R}^N$ 为 sub-Gaussian 随机向量，其 sub-Gaussian 范数为 $K = \|\boldsymbol{X}\|_{\psi_2}$，其中 $N \geqslant 2$。证明：对于任意的 $p \in [1, \infty]$，

$$\mathrm{E}\|\boldsymbol{X}\|_p \leqslant \begin{cases} CK\sqrt{p}N^{1/p}, & p \leqslant \ln N, \\ CK\sqrt{\ln N}, & p \geqslant \ln N \end{cases}。 \qquad (C > 0)$$

证明 对于 sub-Gaussian 随机变量 $X_i = \langle \boldsymbol{X}, \boldsymbol{e}_i \rangle$，其绝对值的 p 阶矩受到其 ψ_2 范数的控制，即对于任意的 $p \geqslant 1$，

$$(\mathrm{E}[|X_i|^p])^{1/p} \leqslant C_0 K \sqrt{p} \implies \mathrm{E}[|X_i|^p] \leqslant C_0^p K^p p^{p/2}。 \qquad \text{(I)}$$

- 当 $p \leqslant \ln N$ 时，

$$\mathrm{E}\|\boldsymbol{X}\|_p = \mathrm{E}\left[\left(\sum_{i=1}^N |X_i|^p\right)^{1/p}\right]。$$

利用 Jensen 不等式，令 $\varphi(x) = x^{1/p}$，可得

$$\begin{aligned} \mathrm{E}\left[\left(\sum_{i=1}^N |X_i|^p\right)^{1/p}\right] &\leqslant \left(\mathrm{E}\left[\sum_{i=1}^N |X_i|^p\right]\right)^{1/p} \\ &= \left(\sum_{i=1}^N \mathrm{E}[|X_i|^p]\right)^{1/p}, \end{aligned} \qquad \text{(II)}$$

(此步不需要独立性假设。) 将 (I) 代入于 (II)，可得

$$\left(\sum_{i=1}^N \mathrm{E}[|X_i|^p]\right)^{1/p} \leqslant \left(\sum_{i=1}^N C_0^p K^p p^{p/2}\right)^{1/p} = (N \cdot C_0^p K^p p^{p/2})^{1/p},$$

即

$$\mathrm{E}\|\boldsymbol{X}\|_p \leqslant C_0 K \sqrt{p} N^{1/p}。$$

- 当 $p \geqslant \ln N$ 时

根据范数的单调性，可得

$$\|\boldsymbol{X}\|_p \leqslant \|\boldsymbol{X}\|_{\ln N} \text{ (a.s.)},$$

两侧取期望，将情形 a. 的结论利用于 $q = \ln N$，可得

$$\mathrm{E}\|\boldsymbol{X}\|_p \leqslant \mathrm{E}\|\boldsymbol{X}\|_{\ln N} \leqslant C_0 K \sqrt{\ln N} \cdot N^{\frac{1}{\ln N}},$$

即

$$\mathrm{E}\|\boldsymbol{X}\|_p \leqslant C_0 K\sqrt{\ln N}\cdot \mathrm{e} =: CK\sqrt{\ln N}。 \qquad (C = C_0\mathrm{e})$$

39 [**Gaussian Chevet 不等式**] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\mathbb{T}\subset\mathbb{R}^n$, $\mathbb{S}\subset\mathbb{R}^m$ 为包含 $\mathbf{0}$ 的关于 $\mathbf{0}$ 对称的集合。

(1) 证明：定理 T8.6.1 (sub-Gaussian Chevet 不等式) 在精确常数为 1 时成立，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right] \leqslant w(\mathbb{T})\operatorname{rad}(\mathbb{S}) + w(\mathbb{S})\operatorname{rad}(\mathbb{T})。$$

(2) 证明其逆向不等式亦成立，即

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right] \geqslant c[w(\mathbb{T})\operatorname{rad}(\mathbb{S}) + w(\mathbb{S})\operatorname{rad}(\mathbb{T})]。 \qquad (c>0)$$

证明 (1) 定义目标 Gaussian 过程 $(X_{\boldsymbol{x},\boldsymbol{y}})_{(\boldsymbol{x},\boldsymbol{y})\in\mathbb{T}\times\mathbb{S}}$ 为

$$X_{\boldsymbol{x},\boldsymbol{y}} = \langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle,$$

引入独立于 $\boldsymbol{A}$ 的 Gaussian 随机向量 $\boldsymbol{g}\sim N(\mathbf{0},\boldsymbol{I}_n), \boldsymbol{h}\sim N(\mathbf{0},\boldsymbol{I}_m)$，之后构造比较 Gaussian 过程 $(Y_{\boldsymbol{x},\boldsymbol{y}})_{(\boldsymbol{x},\boldsymbol{y})\in\mathbb{T}\times\mathbb{S}}$ 为

$$Y_{\boldsymbol{x},\boldsymbol{y}} = \|\boldsymbol{y}\|_2\langle\boldsymbol{g},\boldsymbol{x}\rangle + \|\boldsymbol{x}\|_2\langle\boldsymbol{h},\boldsymbol{y}\rangle;$$

则 $\mathrm{E}[X_{\boldsymbol{x},\boldsymbol{y}}] = \mathrm{E}[Y_{\boldsymbol{x},\boldsymbol{y}}] = 0$。

X 的增量方差为

$$\begin{aligned}\mathrm{E}[(X_{\boldsymbol{x},\boldsymbol{y}} - X_{\boldsymbol{u},\boldsymbol{v}})^2] &= \mathrm{E}\left[\left(\sum_{i,j}A_{ij}(x_jy_i - u_jv_i)\right)^2\right] = \sum_{i,j}(x_jy_i - u_jv_i)^2\\ &= \|\boldsymbol{x}\|_2^2\|\boldsymbol{y}\|_2^2 + \|\boldsymbol{u}\|_2^2\|\boldsymbol{v}\|_2^2 - 2\langle\boldsymbol{x},\boldsymbol{u}\rangle\langle\boldsymbol{y},\boldsymbol{v}\rangle,\end{aligned}$$

Y 的增量方差为

$$\begin{aligned}\mathrm{E}[(Y_{\boldsymbol{x},\boldsymbol{y}} - Y_{\boldsymbol{u},\boldsymbol{v}})^2] &= \mathrm{E}[\langle\boldsymbol{g},\|\boldsymbol{y}\|_2\boldsymbol{x} - \|\boldsymbol{v}\|_2\boldsymbol{u}\rangle^2] + \mathrm{E}[\langle\boldsymbol{h},\|\boldsymbol{x}\|_2\boldsymbol{y} - \|\boldsymbol{u}\|_2\boldsymbol{v}\rangle^2]\\ &= \|\|\boldsymbol{y}\|_2\boldsymbol{x} - \|\boldsymbol{v}\|_2\boldsymbol{u}\|_2^2 + \|\|\boldsymbol{x}\|_2\boldsymbol{y} - \|\boldsymbol{u}\|_2\boldsymbol{v}\|_2^2\\ &= 2\|\boldsymbol{x}\|_2^2\|\boldsymbol{y}\|_2^2 + 2\|\boldsymbol{u}\|_2^2\|\boldsymbol{v}\|_2^2 - 2\|\boldsymbol{y}\|_2\|\boldsymbol{v}\|_2\langle\boldsymbol{x},\boldsymbol{u}\rangle - 2\|\boldsymbol{x}\|_2\|\boldsymbol{u}\|_2\langle\boldsymbol{y},\boldsymbol{v}\rangle,\end{aligned}$$

其差值为

$$\begin{aligned}&\mathrm{E}[(Y_{\boldsymbol{x},\boldsymbol{y}} - Y_{\boldsymbol{u},\boldsymbol{v}})^2] - \mathrm{E}[(X_{\boldsymbol{x},\boldsymbol{y}} - X_{\boldsymbol{u},\boldsymbol{v}})^2]\\ &= (\|\boldsymbol{x}\|_2\|\boldsymbol{v}\|_2 - \|\boldsymbol{u}\|_2\|\boldsymbol{y}\|_2)^2 + 2\|\boldsymbol{x}\|_2\|\boldsymbol{u}\|_2\|\boldsymbol{y}\|_2\|\boldsymbol{v}\|_2 - 2\|\boldsymbol{y}\|_2\|\boldsymbol{v}\|_2\langle\boldsymbol{x},\boldsymbol{u}\rangle - 2\|\boldsymbol{x}\|_2\|\boldsymbol{u}\|_2\langle\boldsymbol{y},\boldsymbol{v}\rangle + 2\langle\boldsymbol{x},\boldsymbol{u}\rangle\langle\boldsymbol{y},\boldsymbol{v}\rangle\\ &= (\|\boldsymbol{x}\|_2\|\boldsymbol{v}\|_2 - \|\boldsymbol{u}\|_2\|\boldsymbol{y}\|_2)^2 + 2(\|\boldsymbol{x}\|_2\|\boldsymbol{u}\|_2 - \langle\boldsymbol{x},\boldsymbol{u}\rangle)(\|\boldsymbol{y}\|_2\|\boldsymbol{v}\|_2 - \langle\boldsymbol{y},\boldsymbol{v}\rangle) \geqslant 0。\end{aligned}$$

满足 Sudakov-Fernique 条件，因此

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}X_{\boldsymbol{x},\boldsymbol{y}}\right] \leqslant \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}Y_{\boldsymbol{x},\boldsymbol{y}}\right]。$$

对于右侧，

$$\begin{aligned}\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}Y_{\boldsymbol{x},\boldsymbol{y}}\right] &= \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}(\|\boldsymbol{y}\|_2\langle\boldsymbol{g},\boldsymbol{x}\rangle + \|\boldsymbol{x}\|_2\langle\boldsymbol{h},\boldsymbol{y}\rangle)\right]\\ &\leqslant \mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{S}}\|\boldsymbol{y}\|_2\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle + \sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2\sup_{\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{h},\boldsymbol{y}\rangle\right]\\ &= \operatorname{rad}(\mathbb{S})\cdot\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right] + \operatorname{rad}(\mathbb{T})\cdot\mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{h},\boldsymbol{y}\rangle\right]\\ &= w(\mathbb{T})\operatorname{rad}(\mathbb{S}) + w(\mathbb{S})\operatorname{rad}(\mathbb{T}),\end{aligned}$$

将其代入，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right]\leqslant w(\mathbb{T})\operatorname{rad}(\mathbb{S})+w(\mathbb{S})\operatorname{rad}(\mathbb{T})。$$

(2) 对于任意的 $\varepsilon>0$，存在 $\boldsymbol{y}_\varepsilon\in\mathbb{S}$，使得 $\|\boldsymbol{y}_\varepsilon\|_2\geqslant\operatorname{rad}(\mathbb{S})-\varepsilon$，将双上确界限制于 $\boldsymbol{y}_\varepsilon$ 以获取下界，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right]\geqslant\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}_\varepsilon\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{A}^\top\boldsymbol{y}_\varepsilon\rangle\right],$$

注意到 $\boldsymbol{A}^\top\boldsymbol{y}_\varepsilon\overset{d}{=}\|\boldsymbol{y}_\varepsilon\|_2\boldsymbol{g}\sim N(\boldsymbol{0},\|\boldsymbol{y}_\varepsilon\|_2^2\boldsymbol{I}_n)$，因此

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{A}^\top\boldsymbol{y}_\varepsilon\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\|\boldsymbol{y}_\varepsilon\|_2\boldsymbol{g}\rangle\right]=\|\boldsymbol{y}_\varepsilon\|_2 w(\mathbb{T})\geqslant(\operatorname{rad}(\mathbb{S})-\varepsilon)w(\mathbb{T}),$$

将其代入，令 $\varepsilon\to0^+$，可得

$$\mathrm{E}[\sup\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle]\geqslant w(\mathbb{T})\operatorname{rad}(\mathbb{S})。\tag{I}$$

同理，对于任意的 $\varepsilon>0$，存在 $\boldsymbol{x}_\varepsilon\in\mathbb{T}$，使得 $\|\boldsymbol{x}_\varepsilon\|_2\geqslant\operatorname{rad}(\mathbb{T})-\varepsilon$，利用对称性 $\boldsymbol{A}\boldsymbol{x}_\varepsilon\overset{d}{=}\|\boldsymbol{x}_\varepsilon\|_2\boldsymbol{h}$，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right]\geqslant\mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x}_\varepsilon,\boldsymbol{y}\rangle\right]=\|\boldsymbol{x}_\varepsilon\|_2 w(\mathbb{S})\geqslant(\operatorname{rad}(\mathbb{T})-\varepsilon)w(\mathbb{S}),$$

令 $\varepsilon\to0^+$，可得

$$\mathrm{E}[\sup\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle]\geqslant w(\mathbb{S})\operatorname{rad}(\mathbb{T})。\tag{II}$$

联立 (I)(II)，可得 (若 $Z\geqslant a,b\geqslant0$，则 $Z\geqslant\max(a,b)\geqslant\frac{1}{2}(a+b)$)

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\right]\geqslant\frac{1}{2}[w(\mathbb{T})\operatorname{rad}(\mathbb{S})+w(\mathbb{S})\operatorname{rad}(\mathbb{T})],$$

此时令 $c=1/2$。

40 [**Chevet 不等式：高概率版本**] 关于定理 T8.6.1 (sub-Gaussian Chevet 不等式) 的假设，设 $\mathbb{T}\subset\mathbb{S}^{n-1}$，$\mathbb{S}\subset\mathbb{S}^{m-1}$。证明：对于任意的 $u\geqslant0$，

$$\sup_{\boldsymbol{x}\in\mathbb{T},\boldsymbol{y}\in\mathbb{S}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle\leqslant CK(w(\mathbb{T})+w(\mathbb{S})+u)\ (\text{w.p. } 1-2\mathrm{e}^{-u^2})。$$

证明 • (定义乘积空间的 sub-Gaussian 过程)

不妨设 $K=1$。定义 $X_{(\boldsymbol{x},\boldsymbol{y})}=\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle$，$(\boldsymbol{x},\boldsymbol{y})\in\mathbb{T}\times\mathbb{S}$，并补充定义 $X_{(\boldsymbol{0},\boldsymbol{0})}=0$。

由于 A_{ij} 独立, 零均值, sub-Gaussian，由 sub-Gaussian 变量的线性组合引理，可得

$$\|X_{(\boldsymbol{x},\boldsymbol{y})}-X_{(\boldsymbol{x}',\boldsymbol{y}')}\|_{\psi_2}\leqslant C\sqrt{\sum_{i,j}(x_jy_i-x'_jy'_i)^2}=C\|\boldsymbol{x}\otimes\boldsymbol{y}-\boldsymbol{x}'\otimes\boldsymbol{y}'\|_F,$$

而

$$\begin{aligned}\|\boldsymbol{x}\otimes\boldsymbol{y}-\boldsymbol{x}'\otimes\boldsymbol{y}'\|_F&\leqslant\|(\boldsymbol{x}-\boldsymbol{x}')\otimes\boldsymbol{y}\|_F+\|\boldsymbol{x}'\otimes(\boldsymbol{y}-\boldsymbol{y}')\|_F\\&\leqslant\|\boldsymbol{x}-\boldsymbol{x}'\|_2\|\boldsymbol{y}\|_2+\|\boldsymbol{x}'\|_2\|\boldsymbol{y}-\boldsymbol{y}'\|_2\\&\leqslant\|\boldsymbol{x}-\boldsymbol{x}'\|_2+\|\boldsymbol{y}-\boldsymbol{y}'\|_2\leqslant\sqrt{2}\|(\boldsymbol{x},\boldsymbol{y})-(\boldsymbol{x}',\boldsymbol{y}')\|_2,\end{aligned}$$

其中 $\|\cdot\|_2$ 于最后一行为 $\mathbb{R}^{n+m}$ 的 Euclidean 范数 (因 $\boldsymbol{x},\boldsymbol{x}',\boldsymbol{y},\boldsymbol{y}'$ 均于单位球面)。因此 X 为 $\mathbb{T}\times\mathbb{S}$ 上关于 Euclidean 度量的 sub-Gaussian 过程，满足 $X_{(\boldsymbol{0},\boldsymbol{0})}=0$。

• (根据高概率 Talagrand 比较)

对集合 $\mathbb{T}\times\mathbb{S}\subset\mathbb{R}^{n+m}$ 根据习题 Q8.37 (定理 (Talagrand 比较不等式的几何形式)) 的 (2) (高概率界)，可得

$$\sup_{(\boldsymbol{x},\boldsymbol{y})\in\mathbb{T}\times\mathbb{S}}X_{(\boldsymbol{x},\boldsymbol{y})}\leqslant CK(w(\mathbb{T}\times\mathbb{S})+u\cdot\operatorname{rad}(\mathbb{T}\times\mathbb{S}))\ (\text{w.p. } 1-2\mathrm{e}^{-u^2})。$$

• (计算几何参数)

令 $\boldsymbol{g}_n \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，$\boldsymbol{g}_m \sim N(\boldsymbol{0}, \boldsymbol{I}_m)$ 独立，则 $\mathbb{T} \times \mathbb{S}$ 的 Gaussian 宽度为

$$w(\mathbb{T} \times \mathbb{S}) = \mathrm{E}\left[\sup_{(\boldsymbol{x},\boldsymbol{y}) \in \mathbb{T} \times \mathbb{S}} [\langle \boldsymbol{g}_n, \boldsymbol{x} \rangle + \langle \boldsymbol{g}_m, \boldsymbol{y} \rangle]\right] \leqslant w(\mathbb{T}) + w(\mathbb{S}),$$

半径

$$\operatorname{rad}(\mathbb{T} \times \mathbb{S}) = \sup_{(\boldsymbol{x},\boldsymbol{y}) \in \mathbb{T} \times \mathbb{S}} \sqrt{\|\boldsymbol{x}\|_2^2 + \|\boldsymbol{y}\|_2^2} = \sqrt{\operatorname{rad}(\mathbb{T})^2 + \operatorname{rad}(\mathbb{S})^2} \leqslant \sqrt{2}。$$

将其代入，并吸收常数 ($\sqrt{2}u$ 归入 Cu)，可得

$$\sup_{\boldsymbol{x} \in \mathbb{T}, \boldsymbol{y} \in \mathbb{S}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y} \rangle \leqslant CK(w(\mathbb{T}) + w(\mathbb{S}) + u) \text{ (w.p. } 1 - 2\mathrm{e}^{-u^2})。$$

41 [**随机矩阵的 $p \to q$ 范数**] 在习题 Q4.44 (随机矩阵的其他 $p \to q$ 算子范数) 中，我们仅讨论了随机矩阵针对少数特定指数 (例如 $2 \to 2, 1 \to 2$) 的算子范数；本题旨在利用 Gaussian 宽度与 Chevet 不等式，建立适用于全体参数 $p, q \in [1, \infty]$ 的统一双侧估计。

设 $m, n \geqslant 2$，p', q' 分别为 $p, q \in [1, \infty]$ 的 Hölder 共轭，定义 ℓ^p 单位球的 Euclidean 半径函数 $r(n, p)$, 标准 Gaussian 宽度函数 $w(n, p)$ 分别为

$$r(n,p) = \begin{cases} 1, & p \in [1,2], \\ n^{1/2-1/p}, & p \in [2, \infty] \end{cases}, \quad w(n,p) = \begin{cases} \sqrt{p} n^{1/p}, & p \in [1, \ln n], \\ \sqrt{\ln n}, & p \in [\ln n, \infty] \end{cases}。$$

(1) 设 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ 为随机矩阵，其行向量 $\boldsymbol{A}_i$ 为相互独立的零均值 K-sub-Gaussian 随机向量。证明：

$$\mathrm{E}\|\boldsymbol{A}\|_{p \to q} \leqslant CK[r(n,p)w(m,q) + r(m,q')w(n,p')]。 \qquad (C > 0)$$

(2) 证明：(1) 的界限对于 Gaussian 矩阵是紧致的。具体而言，设 $\boldsymbol{A}$ 为标准 Gaussian 随机矩阵，则

$$\mathrm{E}\|\boldsymbol{A}\|_{p \to q} \geqslant c[r(n,p)w(m,q) + r(m,q')w(n,p')]。 \qquad (c > 0)$$

证明 (首先计算几何参数。)

根据算子范数的定义, ℓ^q 范数的对偶性，可得

$$\|\boldsymbol{A}\|_{p \to q} = \sup_{\boldsymbol{x} \in \mathbb{B}_p^n} \|\boldsymbol{A}\boldsymbol{x}\|_q = \sup_{\boldsymbol{x} \in \mathbb{B}_p^n} \sup_{\boldsymbol{y} \in \mathbb{B}_{q'}^m} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y} \rangle。$$

令 $\mathbb{T} = \mathbb{B}_p^n, \mathbb{S} = \mathbb{B}_{q'}^m$。计算两集合的半径 $\operatorname{rad}(\cdot)$，即 ℓ^2 范数的最大值。对于 $\mathbb{T}$：若 $1 \leqslant p \leqslant 2$，最大值为 1；若 $p \geqslant 2$，由 Hölder 不等式 $\|\boldsymbol{x}\|_2 \leqslant n^{\frac{1}{2}-\frac{1}{p}}$。因此 $\operatorname{rad}(\mathbb{T}) = r(n,p)$，同理 $\operatorname{rad}(\mathbb{S}) = r(m,q')$。

计算 Gaussian 宽度 $w(\cdot)$。设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n), \boldsymbol{h} \sim N(\boldsymbol{0}, \boldsymbol{I}_m)$，

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{x} \in \mathbb{B}_p^n} \langle \boldsymbol{g}, \boldsymbol{x} \rangle\right] = \mathrm{E}\|\boldsymbol{g}\|_{p'}, \quad w(\mathbb{S}) = \mathrm{E}\left[\sup_{\boldsymbol{y} \in \mathbb{B}_{q'}^m} \langle \boldsymbol{h}, \boldsymbol{y} \rangle\right] = \mathrm{E}\|\boldsymbol{h}\|_q。$$

由于标准 Gaussian 向量期望 ℓ^k 范数的最优阶为 $w(n,k)$，因此 $w(\mathbb{T}) \asymp w(n,p'), w(\mathbb{S}) \asymp w(m,q)$。

(1) 已知 $\boldsymbol{A}$ 具独立零均值 sub-Gaussian 行向量。根据定理 T8.6.1 (sub-Gaussian Chevet 不等式) (sub-Gaussian Chevet 不等式)，

$$\mathrm{E}\left[\sup_{\boldsymbol{x} \in \mathbb{T}, \boldsymbol{y} \in \mathbb{S}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y} \rangle\right] \leqslant CK[w(\mathbb{T}) \operatorname{rad}(\mathbb{S}) + w(\mathbb{S}) \operatorname{rad}(\mathbb{T})]。$$

代入几何参数得 $w(\mathbb{T}) \operatorname{rad}(\mathbb{S}) \leqslant C_1 w(n,p') r(m,q')$ 和 $w(\mathbb{S}) \operatorname{rad}(\mathbb{T}) \leqslant C_2 w(m,q) r(n,p)$。合并即得结论。

(2) 对于 Gaussian 矩阵，令 $\boldsymbol{y}_0 \in \mathbb{S}$ 使得 $\|\boldsymbol{y}_0\|_2 = \operatorname{rad}(\mathbb{S}) = r(m,q')$，

$$\mathrm{E}\|\boldsymbol{A}\|_{p \to q} \geqslant \mathrm{E}\left[\sup_{\boldsymbol{x} \in \mathbb{T}} \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}_0 \rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{x} \in \mathbb{T}} \langle \boldsymbol{x}, \boldsymbol{A}^\top \boldsymbol{y}_0 \rangle\right]。$$

随机向量 $\boldsymbol{A}^\top \boldsymbol{y}_0 \sim N(\boldsymbol{0}, \|\boldsymbol{y}_0\|_2^2 \boldsymbol{I}_n)$，依分布等于 $\|\boldsymbol{y}_0\|_2 \boldsymbol{g}$。从而

$$\mathrm{E}\left[\sup_{\boldsymbol{x} \in \mathbb{T}} \langle \boldsymbol{x}, \|\boldsymbol{y}_0\|_2 \boldsymbol{g} \rangle\right] = \|\boldsymbol{y}_0\|_2 w(\mathbb{T}) = r(m,q') \mathrm{E}\|\boldsymbol{g}\|_{p'}。$$

因此 $\mathrm{E}\|\boldsymbol{A}\|_{p\to q} \geqslant c_1 r(m,q')w(n,p')$。
同理，令 $\boldsymbol{x}_0 \in \mathbb{T}$ 使得 $\|\boldsymbol{x}_0\|_2 = \mathrm{rad}(\mathbb{T}) = r(n,p)$，

$$\mathrm{E}\|\boldsymbol{A}\|_{p\to q} \geqslant \mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{S}} \langle \boldsymbol{A}\boldsymbol{x}_0, \boldsymbol{y}\rangle\right] = \|\boldsymbol{x}_0\|_2 w(\mathbb{S}) = r(n,p)\mathrm{E}\|\boldsymbol{h}\|_q。$$

因此 $\mathrm{E}\|\boldsymbol{A}\|_{p\to q} \geqslant c_2 r(n,p)w(m,q)$。
对于非负数 a, b，

$$\max(a,b) \geqslant \frac{1}{2}(a+b)。$$

令 $c = \frac{1}{2}\min(c_1, c_2)$，即得结论。

9 随机矩阵于集合的偏差

要点梳理

Section 9.1 矩阵偏离不等式 Q9.1 ~ Q9.5

定理 9.1.1 (矩阵偏离不等式)

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其元素为相互独立的标准化 K-sub-Gaussian 随机变量，则对于任意的 $\mathbb{T} \subset \mathbb{R}^n$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \left|\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}\|\boldsymbol{x}\|_2\right|\right] \leqslant CK^2 w(\mathbb{T})。$$

定理 9.1.2 (sub-Gaussian 增量)

在定理 T9.1.1 (矩阵偏离不等式) 的条件下，过程 $\boldsymbol{X}_{\boldsymbol{x}} = \|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}\|\boldsymbol{x}\|_2$ 关于 Euclidean 度量含有 sub-Gaussian 增量，

$$\|\boldsymbol{X}_{\boldsymbol{x}} - \boldsymbol{X}_{\boldsymbol{y}}\|_{\psi_2} \leqslant CK^2\|\boldsymbol{x} - \boldsymbol{y}\|_2。$$

注记 9.1.5 (矩阵偏差的平方)

对于二次过程 $\|\boldsymbol{A}\boldsymbol{x}\|_2^2$ 的偏差，根据定理 T9.1.1 (矩阵偏离不等式)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \left|\|\boldsymbol{A}\boldsymbol{x}\|_2^2 - m\|\boldsymbol{x}\|_2^2\right|\right] \leqslant CK^4\gamma(\mathbb{T})^2 + CK^2\sqrt{m}\,\mathrm{rad}(\mathbb{T})\gamma(\mathbb{T})。$$

练习 Q9.3 (二次矩阵偏差) 证明上述结论。练习 Q9.5 (二次经验过程) 将矩阵偏离不等式推广至经验过程，练习 Q9.6 (随机投影的偏差) 证明其随机投影版本。

Section 9.2 随机矩阵, 协方差估计, JL Q9.6 ~ Q9.11

命题 9.2.1 (集合的随机投影的大小)

设 $\mathbb{T} \subset \mathbb{R}^n$，$\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为 sub-Gaussian 矩阵，则

$$\mathrm{E}[\mathrm{rad}(\boldsymbol{A}\mathbb{T})] \leqslant (1+\varepsilon)\sqrt{m}\cdot\mathrm{rad}(\mathbb{T}) + CK^2 w(\mathbb{T})。$$

定理 9.2.2 (低维分布的协方差估计)

设 $\boldsymbol{X}\in\mathbb{R}^n$ 为 sub-Gaussian 随机向量，其分布集中于 d 维子空间。对于 N 个独立副本，当 $N\geqslant Cd/\varepsilon^2$ 时，样本协方差 $\boldsymbol{\Sigma}_N$ 满足

$$\|\boldsymbol{\Sigma}_N-\boldsymbol{\Sigma}\|\leqslant\varepsilon\|\boldsymbol{\Sigma}\|\ (\text{w.h.p.})。$$

注记 9.2.3 (协方差估计：高概率保证)

类似于注记 R4.7.3 (高概率界) 与 R5.6.5 (高概率保证)，定理 T9.2.2 (低维分布的协方差估计) 的期望界可以升级为高概率界：对于任意的 $u\geqslant 0$，

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant CK^4\left(\sqrt{\frac{r+u}{m}}+\frac{r+u}{m}\right)\|\boldsymbol{\Sigma}\|\ (\text{w.h.p. } 1-2\mathrm{e}^{-u}),$$

其中 r 为 $\boldsymbol{\Sigma}$ 的有效秩。练习 Q9.9 (高概率的协方差估计) 证明上述结论。

引理 9.2.4 (加性 Johnson–Lindenstrauss 引理)

设 $\mathbb{T}\subset\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 sub-Gaussian 矩阵，其中 $m\geqslant C\varepsilon^{-2}w(\mathbb{T})^2/\operatorname{rad}(\mathbb{T})^2$，则映射 $\boldsymbol{x}\mapsto\frac{1}{\sqrt{m}}\boldsymbol{A}\boldsymbol{x}$ 近似保持范数：对于任意的 $\boldsymbol{x}\in\mathbb{T}$，

$$\left|\frac{1}{\sqrt{m}}\|\boldsymbol{A}\boldsymbol{x}\|_2-\|\boldsymbol{x}\|_2\right|\leqslant\varepsilon\operatorname{rad}(\mathbb{T})。$$

Section 9.3 随机截面：M^* 界, 逃逸定理 Q9.12 ∼ Q9.16

定理 9.3.1 (M^* 界)

设 $\mathbb{T}\subset\mathbb{S}^{n-1}$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|\right]\leqslant C\cdot w(\mathbb{T})。$$

不仅如此，存在 $\mathbb{T}'\subset\mathbb{T}$，使得当 $\boldsymbol{x}\in\mathbb{T}'$ 时，上述偏离反向成立 (下界 M^*)。

定理 9.3.4 (逃逸定理)

设 $\mathbb{T}\subset\mathbb{S}^{n-1}$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，则

$$\min_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{A}\boldsymbol{x}\|_2\geqslant C^{-1}\sqrt{m}-Cw(\mathbb{T})\ (\text{w.h.p.})。$$

特别地，当测量数 (行数) 满足 $m\geqslant C_0w(\mathbb{T})^2$ 时，$\mathbb{T}\cap\ker\boldsymbol{A}=\emptyset$，实现“逃逸”。

Section 9.4 高维线性模型 Q9.17 ∼ Q9.21

定理 9.4.4 (约束恢复)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 Gaussian 矩阵，$\mathbb{T}\subset\mathbb{R}^n$ 为凸对称集，$\|\cdot\|_{\mathbb{T}}$ 为以 $\mathbb{T}$ 为单位球的范数。对于任意的 $\boldsymbol{x}\in\mathbb{T}$，考虑

$$\hat{\boldsymbol{x}}\in\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\|\boldsymbol{z}\|_{\mathbb{T}}\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{z}=\boldsymbol{A}\boldsymbol{x}。$$

若 $m\geqslant Cw(\mathbb{T})^2$，则 $\hat{\boldsymbol{x}}=\boldsymbol{x}$ (w.h.p.)。

注记 9.4.7 (无约束优化)

在解上施加严格约束 (如 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$ 与 $\boldsymbol{x}\in\mathbb{T}$)，在存在噪声或 $\mathbb{T}$ 选取不当时可能使可行集为空。给定带噪声的测量 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{w}$，可改为求解下述无约束凸优化问题：

$$\min_{\boldsymbol{x}\in\mathbb{R}^n}\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{x}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}},$$

其中 $\|\cdot\|_{\mathbb{T}}$ 为任意的范数，$\lambda>0$ 用于调节拟合观测 $\boldsymbol{y}$, 保持解 $\boldsymbol{x}$ 的结构 (即 $\|\boldsymbol{x}\|_{\mathbb{T}}$ 小) 之间的权衡。

推论 9.4.8 (稀疏恢复)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 Gaussian 矩阵，其中 $m\geqslant Cs\ln(en/s)$。则任意的 s-稀疏向量 $\boldsymbol{x}\in\mathbb{R}^n$ 均为下述问题的唯一解 (w.h.p.)：

$$\arg\min_{\boldsymbol{y}\in\mathbb{R}^n}\|\boldsymbol{y}\|_1\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}。$$

推论 9.4.11 (低秩矩阵恢复)

设 $\mathcal{A}$ 为从 $n\times n$ 矩阵到 $\mathbb{R}^m$ 的线性映射，元素为独立 Gaussian 变量，其中 $m\geqslant Crn$，则任意的秩 r 矩阵均可通过核范数最小化从 $\mathcal{A}(\boldsymbol{X})$ 恢复。

Section 9.5 精确稀疏恢复 Q9.22 ∼ Q9.33

定理 9.5.1 (精确稀疏恢复)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 sub-Gaussian 矩阵，其中 $m\geqslant Cs\ln(en/s)$。则任意的 s-稀疏向量 $\boldsymbol{x}$ 均为下述问题的唯一最小化器 (w.h.p.)：

$$\arg\min_{\boldsymbol{y}\in\mathbb{R}^n}\|\boldsymbol{y}\|_1\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}。$$

引理 9.5.2 (误差于 $\boldsymbol{x}$ 的支撑集更重)

设 $\boldsymbol{x}$ 为 s-稀疏，$\operatorname{supp}(\boldsymbol{x})=\mathbb{S}$，$\boldsymbol{h}$ 为 ℓ_1 最小化的误差向量，则

$$\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\leqslant\|\boldsymbol{h}_{\mathbb{S}}\|_1。$$

引理 9.5.3 (误差近似稀疏)

根据零空间性质，误差 $\boldsymbol{h}$ 满足

$$\|\boldsymbol{h}\|_2\leqslant C\frac{\|\boldsymbol{A}\boldsymbol{h}\|_2}{\sqrt{m}},$$

当 $\boldsymbol{A}$ 于近似稀疏向量为近似等距时，此量可被忽略。

定义 9.5.5 (限制等距性质)

矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 满足阶数为 s, 常数为 δ_s 的限制等距性质 (RIP)，若对于任意的 s-稀疏向量 $\boldsymbol{x}$，均有 $(1-\delta_s)\|\boldsymbol{x}\|_2^2\leqslant\|\boldsymbol{A}\boldsymbol{x}\|_2^2\leqslant(1+\delta_s)\|\boldsymbol{x}\|_2^2$。

定理 9.5.6 (RIP 蕴含精确恢复)

若 $\boldsymbol{A}$ 满足阶数为 $2s$、常数为 $\delta_{2s}<1/3$ 的 RIP，则任意的 s-稀疏向量 $\boldsymbol{x}$ 均为下述问题的唯一最小化器：

$$\arg\min_{\boldsymbol{y}\in\mathbb{R}^n}\|\boldsymbol{y}\|_1\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}。$$

定理 9.5.7 (随机矩阵满足 RIP)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 sub-Gaussian 矩阵，则 $\frac{1}{\sqrt{m}}\boldsymbol{A}$ 满足阶数为 s, 常数为 δ 的 RIP，只需 $m\geqslant C\delta^{-2}s\ln(en/s)$ (w.h.p.)。

Section 9.6 一般范数的随机矩阵偏离 Q9.34 ∼ Q9.40

定义 9.6.1 (一般次可加函数)

本节考虑的函数 $f:\mathbb{R}^n\to\mathbb{R}$ 不必为范数；只要求其满足正齐次性, 次可加性，并由 Euclidean 范数控制。

定理 9.6.3 (一般矩阵偏离不等式)

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。设 $f:\mathbb{R}^m\to\mathbb{R}$ 为正齐次, 次可加的函数，并且存在 $b\in\mathbb{R}$，使得对于任意的 $\boldsymbol{x}\in\mathbb{R}^m$，均满足 $f(\boldsymbol{x})\leqslant b\|\boldsymbol{x}\|_2$，则对于任意的子集 $\mathbb{T}\subset\mathbb{R}^n$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\right]\leqslant Cb\gamma(\mathbb{T}),$$

其中 $\gamma(\mathbb{T})$ 为 $\mathbb{T}$ 的 Gaussian 复杂度 (见 7.5.3 节)。

定理 9.6.4 (sub-Gaussian 增量)

在定理 T9.6.3 (一般矩阵偏离不等式) 的条件下，随机过程 $Z_{\boldsymbol{x}} = f(\boldsymbol{A}\boldsymbol{x}) - \mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]$ 满足 sub-Gaussian 增量条件：

$$\|Z_{\boldsymbol{x}} - Z_{\boldsymbol{y}}\|_{\psi_2} \leqslant Cb\|\boldsymbol{x} - \boldsymbol{y}\|_2 \quad \text{对于任意的 } \boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n。$$

Section 9.7 双侧 Chevet 与 Dvoretzky-Milman Q9.41 ~ Q9.43

定理 9.7.1 (双侧 Chevet 不等式)

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\mathbb{T} \subset \mathbb{R}^n, \mathbb{S} \subset \mathbb{R}^m$ 为任意的集合，则

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \sup_{\boldsymbol{y}\in\mathbb{S}} |\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle - w(\mathbb{S})\|\boldsymbol{x}\|_2|\right] \leqslant C\gamma(\mathbb{T})\,\mathrm{rad}(\mathbb{S}),$$

其中 $\gamma(\mathbb{T})$ 为 $\mathbb{T}$ 的 Gaussian 复杂度 (见 7.5.3 节)，$\mathrm{rad}(\mathbb{T}) = \sup_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{x}\|_2$ 为 $\mathbb{T}$ 的半径。

定理 9.7.2 (Dvoretzky–Milman 定理)

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\mathbb{T} \subset \mathbb{R}^n$，则以高概率，

$$r_-\mathbb{B}_2^m \subset \mathrm{conv}(\boldsymbol{A}\mathbb{T}) \subset r_+\mathbb{B}_2^m \text{ (w.h.p. 0.99)},$$

其中 $r_\pm = w(\mathbb{T}) \pm C\sqrt{m}\cdot\mathrm{rad}(\mathbb{T})$。左侧包含关系仅当 $r_- \geqslant 0$ 时，才成立；右侧包含始终成立。

习题解答

1 [逆三角不等式] 证明定理 T9.1.2 (sub-Gaussian 增量) 时所用的以下几何事实。

设 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$ 满足 $1 = \|\boldsymbol{x}\|_2 \leqslant \|\boldsymbol{y}\|_2$，并定义 $\bar{\boldsymbol{y}} = \boldsymbol{y}/\|\boldsymbol{y}\|_2$。证明：

$$\|\boldsymbol{x} - \boldsymbol{y}\|_2 \leqslant \|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2 + \|\bar{\boldsymbol{y}} - \boldsymbol{y}\|_2 \leqslant \sqrt{2}\|\boldsymbol{x} - \boldsymbol{y}\|_2。$$

证明 左侧即为 Euclidean 范数的标准三角不等式，我们只需证明右侧即可。

令 $\boldsymbol{y} = R\bar{\boldsymbol{y}}$，其中 $R = \|\boldsymbol{y}\|_2 \geqslant 1$，则

$$\begin{aligned}\langle \boldsymbol{x} - \bar{\boldsymbol{y}}, \boldsymbol{y} - \bar{\boldsymbol{y}}\rangle &= \langle \boldsymbol{x} - \bar{\boldsymbol{y}}, (R-1)\bar{\boldsymbol{y}}\rangle = (R-1)(\langle \boldsymbol{x}, \bar{\boldsymbol{y}}\rangle - \langle \bar{\boldsymbol{y}}, \bar{\boldsymbol{y}}\rangle)\\ &= (R-1)(\langle \boldsymbol{x}, \bar{\boldsymbol{y}}\rangle - 1) \leqslant 0,\end{aligned}$$

由于

$$\begin{aligned}\|\boldsymbol{x} - \boldsymbol{y}\|_2^2 &= \|(\boldsymbol{x} - \bar{\boldsymbol{y}}) - (\boldsymbol{y} - \bar{\boldsymbol{y}})\|_2^2\\ &= \|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2^2 + \|\boldsymbol{y} - \bar{\boldsymbol{y}}\|_2^2 - 2\langle \boldsymbol{x} - \bar{\boldsymbol{y}}, \boldsymbol{y} - \bar{\boldsymbol{y}}\rangle\\ &\geqslant \|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2^2 + \|\boldsymbol{y} - \bar{\boldsymbol{y}}\|_2^2。\end{aligned}$$

因此利用代数不等式 $(A+B)^2 \leqslant 2(A^2+B^2)$，可得

$$(\|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2 + \|\bar{\boldsymbol{y}} - \boldsymbol{y}\|_2)^2 \leqslant 2(\|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2^2 + \|\bar{\boldsymbol{y}} - \boldsymbol{y}\|_2^2) \leqslant 2\|\boldsymbol{x} - \boldsymbol{y}\|_2^2,$$

即

$$\|\boldsymbol{x} - \bar{\boldsymbol{y}}\|_2 + \|\bar{\boldsymbol{y}} - \boldsymbol{y}\|_2 \leqslant \sqrt{2}\|\boldsymbol{x} - \boldsymbol{y}\|_2。$$

2 [矩阵偏差不等式] 根据定理 T9.1.1 (矩阵偏离不等式)，推导中心化版本的矩阵偏差不等式。

设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立, 各向同性的 K-sub-Gaussian 随机向量。对于任意的 $\mathbb{T} \subset \mathbb{R}^n$，已知标准矩阵偏差不等式为

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} |\|\boldsymbol{A}\boldsymbol{x}\|_2 - \sqrt{m}\|\boldsymbol{x}\|_2|\right] \leqslant C_1K^2\gamma(\mathbb{T}), \qquad (C_1 > 0)$$

证明中心化版本的矩阵偏差不等式，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\right]\leqslant CK^2\gamma(\mathbb{T})。\qquad(C>0)$$

证明 固定 $\boldsymbol{x}\in\mathbb{T}$，利用三角不等式，引入 $\sqrt{m}\|\boldsymbol{x}\|_2$，将误差进行拆分，

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\leqslant|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|+|\sqrt{m}\|\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|。$$

对于第二项，

$$\begin{aligned}|\sqrt{m}\|\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|&=|\mathrm{E}[\sqrt{m}\|\boldsymbol{x}\|_2-\|\boldsymbol{A}\boldsymbol{x}\|_2]\\&\leqslant\mathrm{E}[|\sqrt{m}\|\boldsymbol{x}\|_2-\|\boldsymbol{A}\boldsymbol{x}\|_2|]\\&\leqslant\mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{T}}|\sqrt{m}\|\boldsymbol{y}\|_2-\|\boldsymbol{A}\boldsymbol{y}\|_2|\right]=\Delta,\end{aligned}$$

将其代入，可得

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\leqslant|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|+\Delta。$$

两侧取上确界，之后两侧取期望，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]+\Delta=2\Delta。$$

利用定理 T9.1.1 (矩阵偏离不等式) (矩阵偏离不等式) 的标准形式 $\Delta\leqslant C_1K^2\gamma(\mathbb{T})$，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\right]\leqslant2C_1K^2\gamma(\mathbb{T}),$$

此时令 $C=2C_1$。

3 [二次矩阵偏差] 证明注记 R9.1.5 (矩阵偏差的平方) 的结论。

在定理 T9.1.1 (矩阵偏离不等式) 的条件下，设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立, 各向同性的 K-sub-Gaussian 随机向量。证明：对于任意的 $\mathbb{T}\subset\mathbb{R}^n$，二次形式的矩阵偏差满足以下上界，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|\right]\leqslant CK^4\gamma(\mathbb{T})^2+CK^2\sqrt{m}\,\mathrm{rad}(\mathbb{T})\gamma(\mathbb{T})。\qquad(C>0)$$

证明 设 $\boldsymbol{x}\in\mathbb{T}$，将目标函数改写为

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|=|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\cdot(\|\boldsymbol{A}\boldsymbol{x}\|_2+\sqrt{m}\|\boldsymbol{x}\|_2)。$$

定义范数偏离过程 $Z_{\boldsymbol{x}}=|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|$，其上确界 $Z=\sup_{\boldsymbol{x}\in\mathbb{T}}Z_{\boldsymbol{x}}$，则利用三角不等式，可得

$$\|\boldsymbol{A}\boldsymbol{x}\|_2\leqslant\sqrt{m}\|\boldsymbol{x}\|_2+Z_{\boldsymbol{x}},$$

将其代入，

$$\|\boldsymbol{A}\boldsymbol{x}\|_2+\sqrt{m}\|\boldsymbol{x}\|_2\leqslant Z_{\boldsymbol{x}}+2\sqrt{m}\|\boldsymbol{x}\|_2,$$

因此二次偏差的上界为

$$|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|\leqslant Z_{\boldsymbol{x}}(Z_{\boldsymbol{x}}+2\sqrt{m}\|\boldsymbol{x}\|_2)=Z_{\boldsymbol{x}}^2+2\sqrt{m}\|\boldsymbol{x}\|_2Z_{\boldsymbol{x}}。$$

- 取上确界, 期望

  两侧取上确界，

  $$\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|\leqslant\sup_{\boldsymbol{x}\in\mathbb{T}}(Z_{\boldsymbol{x}}^2)+2\sqrt{m}\sup_{\boldsymbol{x}\in\mathbb{T}}(\|\boldsymbol{x}\|_2Z_{\boldsymbol{x}}),$$

  其中 $\sup Z_{\boldsymbol{x}}^2=Z^2$，$\sup(\|\boldsymbol{x}\|_2Z_{\boldsymbol{x}})\leqslant(\sup\|\boldsymbol{x}\|_2)\cdot(\sup Z_{\boldsymbol{x}})=\mathrm{rad}(\mathbb{T})\cdot Z$，将其代入，可得

  $$\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|\leqslant Z^2+2\sqrt{m}\,\mathrm{rad}(\mathbb{T})Z,$$

  两侧取期望，

  $$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2^2-m\|\boldsymbol{x}\|_2^2|\right]\leqslant\mathrm{E}[Z^2]+2\sqrt{m}\,\mathrm{rad}(\mathbb{T})\mathrm{E}[Z]。\qquad(\mathrm{I})$$

- 计算矩并代入

利用定理 T9.1.1 (矩阵偏离不等式) (矩阵偏离不等式)，可得

$$\mathrm{E}[Z] \leqslant C_1 K^2 \gamma(\mathbb{T})。$$

利用推论 C8.5.6 (Talagrand 比较不等式) (Talagrand 比较不等式) 的矩界版本，可得

$$\|Z\|_{L_p} \leqslant C_2 \sqrt{p} K^2 \gamma(\mathbb{T}),$$

令 $p=2$，可得

$$\mathrm{E}[Z^2] \leqslant (C_2\sqrt{2}K^2\gamma(\mathbb{T}))^2 = 2C_2^2 K^4 \gamma(\mathbb{T})^2;$$

将其代入于 (I)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} |\|\boldsymbol{A}\boldsymbol{x}\|_2^2 - m\|\boldsymbol{x}\|_2^2|\right] \leqslant 2C_2^2K^4\gamma(\mathbb{T})^2 + 2\sqrt{m}\,\mathrm{rad}(\mathbb{T})(C_1K^2\gamma(\mathbb{T}))。$$

此时令 $C = \max(2C_2^2, 2C_1)$。

4 [**各向异性矩阵偏差**] 关于定理 T9.1.1 (矩阵偏离不等式)，随机矩阵的行向量是各向同性的。去掉此假设。

设 $\boldsymbol{B} \in \mathbb{R}^{m\times n}$ 为随机矩阵，其行向量 $\boldsymbol{B}_i$ 是相互独立的，满足 $\mathrm{E}[\boldsymbol{B}_i\boldsymbol{B}_i^\top] = \boldsymbol{\Sigma}$。假设对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，满足 sub-Gaussian 条件 $\|\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle\|_{\psi_2} \leqslant K\|\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle\|_{L_2}$。证明：对于任意的 $\mathbb{T}\subset\mathbb{R}^n$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} |\|\boldsymbol{B}\boldsymbol{x}\|_2 - \sqrt{m}\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2|\right] \leqslant CK^2\gamma(\boldsymbol{\Sigma}^{1/2}\mathbb{T})。 \qquad (C>0)$$

证明 容易知道，

$$\begin{aligned}\|\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle\|_{L_2}^2 &= \mathrm{E}[\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle^2] = \mathrm{E}[\boldsymbol{x}^\top \boldsymbol{B}_i\boldsymbol{B}_i^\top \boldsymbol{x}] = \boldsymbol{x}^\top \mathrm{E}[\boldsymbol{B}_i\boldsymbol{B}_i^\top]\boldsymbol{x} = \boldsymbol{x}^\top\boldsymbol{\Sigma}\boldsymbol{x}\\ &= \boldsymbol{x}^\top\boldsymbol{\Sigma}^{1/2}\boldsymbol{\Sigma}^{1/2}\boldsymbol{x} = \|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2^2。\end{aligned}$$

因此 sub-Gaussian 条件为

$$\|\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle\|_{\psi_2} \leqslant K\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2。$$

- 在协方差的像空间上白化

  记 $R = \mathrm{im}(\boldsymbol{\Sigma})$，$P_R$ 为到 R 的正交投影。若 $\boldsymbol{v}\in R^\perp = \ker(\boldsymbol{\Sigma})$，则

  $$\mathrm{E}[\langle \boldsymbol{B}_i, \boldsymbol{v}\rangle^2] = \boldsymbol{v}^\top\boldsymbol{\Sigma}\boldsymbol{v} = 0,$$

  因而 $\langle \boldsymbol{B}_i, \boldsymbol{v}\rangle = 0$ 几乎处处成立。对 $R^\perp$ 的一组正交基同时应用此结论，可得 $\boldsymbol{B}_i = \boldsymbol{P}_R\boldsymbol{B}_i$ 几乎处处成立。

  将 $S = \boldsymbol{\Sigma}^{1/2}|_R : R\to R$ 视为 R 的可逆算子，并定义 $\boldsymbol{A}_i = S^{-1}\boldsymbol{B}_i \in R$。因此，对于任意的 $\boldsymbol{u}\in R$，

  $$\mathrm{E}[\langle \boldsymbol{A}_i, \boldsymbol{u}\rangle^2] = \mathrm{E}[\langle \boldsymbol{B}_i, S^{-1}\boldsymbol{u}\rangle^2] = \|SS^{-1}\boldsymbol{u}\|_2^2 = \|\boldsymbol{u}\|_2^2$$

  且

  $$\|\langle \boldsymbol{A}_i, \boldsymbol{u}\rangle\|_{\psi_2} \leqslant K\|SS^{-1}\boldsymbol{u}\|_2 = K\|\boldsymbol{u}\|_2。$$

  因此 $\boldsymbol{A}_i$ 为 R 的相互独立、各向同性的 K-sub-Gaussian 随机向量。

- 应用标准矩阵偏差定理

  对于任意的 $\boldsymbol{x}\in\mathbb{T}$，由 $\boldsymbol{B}_i = \boldsymbol{P}_R\boldsymbol{B}_i$ 可得

  $$\begin{aligned}\langle \boldsymbol{B}_i, \boldsymbol{x}\rangle &= \langle \boldsymbol{A}_i, S\boldsymbol{P}_R\boldsymbol{x}\rangle,\\ S\boldsymbol{P}_R\boldsymbol{x} &= \boldsymbol{\Sigma}^{1/2}\boldsymbol{x}.\end{aligned}$$

  因此于 R 将标准矩阵偏差定理应用于集合 $\mathbb{T}' = \boldsymbol{\Sigma}^{1/2}\mathbb{T}$，即可得

  $$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} |\|\boldsymbol{B}\boldsymbol{x}\|_2 - \sqrt{m}\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2|\right] \leqslant CK^2\gamma(\mathbb{T}') = CK^2\gamma(\boldsymbol{\Sigma}^{1/2}\mathbb{T})。$$

5 [**二次经验过程**] 习题 Q8.36 (经验过程：一般链式界) 界定了任意的 sub-Gaussian 过程的经验均值, 样本均值偏差。

将定理 T9.1.1 (矩阵偏离不等式) 推广至 L_2 均值。设 $\mathcal{F}$ 为定义于论域 Ω 的星形实值函数族，$X_1,\cdots,X_m$ 为 Ω 的独立同分布随机变量。考虑 $\mathcal{F}$ 的 L_2 度量 $d(f,g) = (\mathrm{E}[(f(X_1)-g(X_1))^2])^{1/2}$，假设过程增量满足 sub-Gaussian 条件 $\|f(X_1)-g(X_1)\|_{\psi_2} \leqslant Kd(f,g)$。

(1) 证明：

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}\left|\left(\frac{1}{m}\sum_{i=1}^{m}f(X_i)^2\right)^{1/2}-(\mathrm{E}[f(X_1)^2])^{1/2}\right|\right]\leqslant\frac{CK^2\gamma_2(\mathcal{F},d)}{\sqrt{m}}。\qquad(C>0)$$

(2) 当 $\mathbb{T}\subset\mathbb{S}^{n-1}$ 时，此结论蕴含标准矩阵偏差定理，试分析其原因。

证明 (1) 将目标不等式的两侧同乘 $\sqrt{m}$，定义以 0 为起点的随机过程 $(Z_f)_{f\in\mathcal{F}}$ 为

$$Z_f=\left(\sum_{i=1}^{m}f(X_i)^2\right)^{1/2}-\sqrt{m}\|f\|_{L_2},$$

其中 $\|f\|_{L_2}=(\mathrm{E}[f(X_1)^2])^{1/2}=d(f,0)$。

- 证明相同范数情形的 sub-Gaussian 增量

  假设 $f,g\in\mathcal{F}$ 满足 $\|f\|_{L_2}=\|g\|_{L_2}=r>0$。此时 $\sqrt{m}\|f\|_{L_2}=\sqrt{m}\|g\|_{L_2}$，均值项相互抵消，

$$\begin{aligned}Z_f-Z_g&=\left(\sum_{i=1}^{m}f(X_i)^2\right)^{1/2}-\left(\sum_{i=1}^{m}g(X_i)^2\right)^{1/2}\\&=\frac{\sum_{i=1}^{m}(f(X_i)^2-g(X_i)^2)}{\left(\sum_{i=1}^{m}f(X_i)^2\right)^{1/2}+\left(\sum_{i=1}^{m}g(X_i)^2\right)^{1/2}}=\frac{N}{D}。\end{aligned}$$

  - 分析分子 N

    令 $W_i=f(X_i)^2-g(X_i)^2=(f(X_i)-g(X_i))(f(X_i)+g(X_i))$，则 W_i 为独立同分布的零均值 sub-Exponential 随机变量。(由于 $\|f\|_{L_2}=\|g\|_{L_2}$，因此 $\mathrm{E}[W_i]=0$；由于 $f(X_i)-g(X_i),f(X_i)+g(X_i)$ 为 sub-Gaussian 随机变量，因此 W_i 为 sub-Exponential 随机变量。)

    由于

$$\begin{aligned}\|f(X_i)-g(X_i)\|_{\psi_2}&\leqslant Kd(f,g),\\\|f(X_i)+g(X_i)\|_{\psi_2}&\leqslant\|f(X_i)\|_{\psi_2}+\|g(X_i)\|_{\psi_2}\leqslant 2Kr,\end{aligned}$$

    因此利用 sub-Gaussian 随机变量乘积的 ψ_1 范数界，可得

$$\|W_i\|_{\psi_1}\leqslant C_0\|f(X_i)-g(X_i)\|_{\psi_2}\cdot\|f(X_i)+g(X_i)\|_{\psi_2}\leqslant C_0Kd(f,g)\cdot 2Kr=2C_0K^2rd(f,g)。$$

    从而利用定理 T2.9.1 (sub-Exponential Bernstein 不等式) (sub-Exponential Bernstein 不等式)，可得对于任意的 $t\geqslant 0$，

$$\mathrm{P}\{|N|\geqslant t\}\leqslant 2\exp\left(-c\min\left(\frac{t^2}{m(2C_0K^2rd(f,g))^2},\frac{t}{2C_0K^2rd(f,g)}\right)\right)。$$

  - 分析分母 D

    (由于分子 N 为 sub-Exponential 随机变量 (尾部厚于 sub-Gaussian)，而之后只需证明比值 $\frac{N}{D}$ 为 sub-Gaussian 随机变量 (尾部薄于 sub-Exponential)，因此考虑分区间讨论。)

    令 $U_i=r^2-f(X_i)^2$，则 U_i 为零均值 sub-exponential 变量，满足 $\|U_i\|_{\psi_1}\leqslant c_0K^2r^2$。

    (根据星形性，令 $g=0$，可得 $f(X_i)$ 为 sub-Gaussian 随机变量，因此 $f(X_i)^2$ 为 sub-Exponential 随机变量，因此 $\|U_i\|_{\psi_1}\leqslant c_0K^2r^2$。)

    注意到

$$\sum_{i=1}^{m}f(X_i)^2=\sum_{i=1}^{m}(r^2-U_i)=mr^2-\sum_{i=1}^{m}U_i,$$

    因此

$$\mathrm{P}\left\{\sum_{i=1}^{m}f(X_i)^2\leqslant\frac{1}{4}mr^2\right\}=\mathrm{P}\left\{\sum_{i=1}^{m}U_i\geqslant\frac{3}{4}mr^2\right\}。$$

对 $\sum_{i=1}^m U_i$ 利用定理 T2.9.1 (sub-Exponential Bernstein 不等式) (sub-Exponential Bernstein 不等式)，可得对于任意的 $t \geqslant 0$，

$$\mathrm{P}\left\{\sum_{i=1}^m U_i \geqslant t\right\} \leqslant 2\exp\left(-c\min\left(\frac{t^2}{m\|U_i\|_{\psi_1}^2}, \frac{t}{\|U_i\|_{\psi_1}}\right)\right)。 \tag{I}$$

令 $t = \frac{3}{4}mr^2$，代入 $\|U_i\|_{\psi_1} \leqslant c_0 K^2 r^2$，可得

$$\begin{aligned}\mathrm{P}\left\{\sum_{i=1}^m U_i \geqslant t\right\} &\leqslant 2\exp\left(-c\min\left(\frac{9}{16c_0^2}\cdot\frac{m}{K^4}, \frac{3}{4c_0}\cdot\frac{m}{K^2}\right)\right)\\ &\leqslant 2\exp\left(-\frac{c_1 m}{K^4}\right),\end{aligned}$$

将其代入于 (I)，可得

$$\mathrm{P}\left\{\sum_{i=1}^m f(X_i)^2 \leqslant \frac{1}{4}mr^2\right\} \leqslant 2\exp\left(-\frac{c_1 m}{K^4}\right);$$

同理，

$$\mathrm{P}\left\{\sum_{i=1}^m g(X_i)^2 \leqslant \frac{1}{4}mr^2\right\} \leqslant 2\exp\left(-\frac{c_1' m}{K^4}\right)。$$

当 $D=0$ 时，$f(X_i)=g(X_i)=0$ 对所有 i 成立，因而 $N=0$；以下在 $D>0$ 上使用比值 N/D，并在 $D=0$ 时将其定义为 0。定义良性事件

$$\mathcal{E} = \left\{\sum_{i=1}^m f(X_i)^2 \geqslant \frac{1}{4}mr^2\right\} \cap \left\{\sum_{i=1}^m g(X_i)^2 \geqslant \frac{1}{4}mr^2\right\},$$

1. 坏事件 $\mathcal{E}^c$ 发生的概率为 $\mathrm{P}(\mathcal{E}^c) \leqslant 4\exp(-\frac{c_1 m}{K^4})$；
2. 当 $\mathcal{E}$ 发生时，$D = (\sum_{i=1}^m f(X_i)^2)^{1/2} + (\sum_{i=1}^m g(X_i)^2)^{1/2} \geqslant \sqrt{m}r$。

(之后估计尾概率 $\mathrm{P}\{|Z_f - Z_g| \geqslant u\}$。)

根据 u 的取值进行讨论：

a. 当 $u \leqslant 2\sqrt{m}d(f,g)$ 时，若 $\mathcal{E}$ 发生，则 $D \geqslant \sqrt{m}r$，此时 $\frac{|N|}{D} \leqslant \frac{|N|}{\sqrt{m}r}$，因此

$$\mathrm{P}\left\{\frac{|N|}{D} \geqslant u\right\} \leqslant \mathrm{P}\{|N| \geqslant u\sqrt{m}r\} + \mathrm{P}(\mathcal{E}^c)。$$

对于第一项，利用定理 T2.9.1 (sub-Exponential Bernstein 不等式) (sub-Exponential Bernstein 不等式)，令 $t = u\sqrt{m}r$，可得

$$\begin{aligned}\mathrm{P}\{|N| \geqslant u\sqrt{m}r\} &\leqslant 2\exp\left(-c\min\left(\frac{u^2}{4C_0^2K^4d(f,g)^2}, \frac{u\sqrt{m}}{2C_0K^2d(f,g)}\right)\right)\\ &\asymp 2\exp\left(-c\min\left(\frac{u^2}{K^4d(f,g)^2}, \frac{u\sqrt{m}}{K^2d(f,g)}\right)\right),\end{aligned}$$

其中

$$\frac{u^2}{K^4d(f,g)^2} \Big/ \frac{u\sqrt{m}}{K^2d(f,g)} = \frac{u}{K^2\sqrt{m}d(f,g)} \leqslant \frac{2}{K^2},$$

指数项由二次项主导，因此

$$\mathrm{P}\{|N| \geqslant u\sqrt{m}r\} \leqslant 2\exp\left(-\frac{c_2u^2}{K^4d(f,g)^2}\right),$$

由于 $u^2 \leqslant 4md(f,g)^2$，因此 $\mathrm{P}(\mathcal{E}^c) \leqslant 4\exp(-\frac{c_1u^2}{4K^4d(f,g)^2})$。将两项合并，可得

$$\mathrm{P}\{|Z_f - Z_g| \geqslant u\} \leqslant C\exp\left(-\frac{c_3u^2}{K^4d(f,g)^2}\right)。$$

b. 当 $u > 2\sqrt{m}d(f,g)$ 时，令 $\boldsymbol{a} = (f(X_1), \cdots, f(X_m))^\top$, $\boldsymbol{b} = (g(X_1), \cdots, g(X_m))^\top$，则

$$|Z_f - Z_g| = \big|\|\boldsymbol{a}\|_2 - \|\boldsymbol{b}\|_2\big| \leqslant \|\boldsymbol{a} - \boldsymbol{b}\|_2 \leqslant \left(\sum_{i=1}^m (f(X_i) - g(X_i))^2\right)^{1/2},$$

因此

$$\mathrm{P}\{|Z_f - Z_g| \geqslant u\} \leqslant \mathrm{P}\left\{\sum_{i=1}^m (f(X_i) - g(X_i))^2 \geqslant u^2\right\}。$$

令 $V_i = (f(X_i) - g(X_i))^2 - d(f,g)^2$，则 V_i 为独立同分布的零均值 sub-Exponential 随机变量，满足 $\|V_i\|_{\psi_1} \leqslant c_4 K^2 d(f,g)^2$，因此利用定理 T2.9.1 (sub-Exponential Bernstein 不等式) (sub-Exponential Bernstein 不等式)，可得

$$\mathrm{P}\left\{\sum_{i=1}^m V_i \geqslant t\right\} \leqslant 2\exp\left(-c\min\left(\frac{t^2}{mK^4 d(f,g)^4}, \frac{t}{K^2 d(f,g)^2}\right)\right)。$$

令 $t = u^2 - md(f,g)^2$。当 $u > 2\sqrt{m}d(f,g)$ 时，$t > \frac{3}{4}u^2$。不妨设 $K \geqslant 1$，将其代入，可得

$$\begin{aligned}
\mathrm{P}\{|Z_f - Z_g| \geqslant u\} &\leqslant 2\exp\left(-c\min\left(\frac{t^2}{mK^4 d(f,g)^4}, \frac{t}{K^2 d(f,g)^2}\right)\right) \\
&\leqslant 2\exp\left(-c\min\left(\frac{u^4}{mK^4 d(f,g)^4}, \frac{u^2}{K^2 d(f,g)^2}\right)\right) \\
&\leqslant 2\exp\left(-\frac{c_5 u^2}{K^4 d(f,g)^2}\right),
\end{aligned}$$

如此，对于任意的 $u \geqslant 0$，

$$\mathrm{P}\{|Z_f - Z_g| \geqslant u\} \leqslant C\exp\left(-\frac{c_6 u^2}{K^4 d(f,g)^2}\right),$$

从而根据 ψ_2 范数的等价刻画，可得

$$\|Z_f - Z_g\|_{\psi_2} \leqslant C_1 K^2 d(f,g)。 \tag{II}$$

- 利用径向缩放扩展至任意的范数，比较不等式

对于任意的 $f, g \in \mathcal{F}$，不妨设 $0 < \|f\|_{L_2} \leqslant \|g\|_{L_2}$。

由于 $\mathcal{F}$ 为星形集，令 $\bar{g} = \frac{\|f\|_{L_2}}{\|g\|_{L_2}} g \in \mathcal{F}$，则 $\|\bar{g}\|_{L_2} = \|f\|_{L_2}$。

将增量分解为

$$Z_f - Z_g = (Z_f - Z_{\bar{g}}) + (Z_{\bar{g}} - Z_g),$$

对于第一项 (同范数部分)，利用 (II) 的结论，可得

$$\|Z_f - Z_{\bar{g}}\|_{\psi_2} \leqslant C_1 K^2 d(f,\bar{g})。 \tag{III}$$

对于第二项 (径向缩放部分)，注意到 $g = \frac{\|g\|_{L_2}}{\|f\|_{L_2}}\bar{g}$，因此 $Z_g = \frac{\|g\|_{L_2}}{\|f\|_{L_2}} Z_{\bar{g}}$，可得

$$Z_{\bar{g}} - Z_g = \left(1 - \frac{\|g\|_{L_2}}{\|f\|_{L_2}}\right) Z_{\bar{g}}。$$

(星形性保证 $0 \in \mathcal{F}$，$Z_0 = 0$) 利用 (II) 的结论，可得 $\|Z_{\bar{g}}\|_{\psi_2} = \|Z_{\bar{g}} - Z_0\|_{\psi_2} \leqslant C_1 K^2 \|\bar{g}\|_{L_2}$，因此

$$\|Z_{\bar{g}} - Z_g\|_{\psi_2} \leqslant C_1 K^2 \left|1 - \frac{\|g\|_{L_2}}{\|f\|_{L_2}}\right| \|\bar{g}\|_{L_2} = C_1 K^2 |\|f\|_{L_2} - \|g\|_{L_2}| = C_1 K^2 d(\bar{g}, g)。 \tag{IV}$$

联立 (III)(IV)，可得

$$\|Z_f - Z_g\|_{\psi_2} \leqslant C_1 K^2 (d(f,\bar{g}) + d(\bar{g},g))。$$

利用逆三角不等式 $d(f,\bar{g})+d(\bar{g},g)\leqslant\sqrt{2}d(f,g)$ (见习题 Q9.1 (逆三角不等式))，可得

$$\|Z_f-Z_g\|_{\psi_2}\leqslant\sqrt{2}C_1K^2d(f,g)=C_2K^2d(f,g)。$$

由于 $Z_0=0$，因此 $(Z_f)_{f\in\mathcal{F}},(-Z_f)_{f\in\mathcal{F}}$ 均以 0 为起点，共享增量界 $C_2K^2d(f,g)$，从而利用推论 C8.5.6 (Talagrand 比较不等式) (Talagrand 比较不等式)，可得

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}Z_f\right],\mathrm{E}\left[\sup_{f\in\mathcal{F}}(-Z_f)\right]\leqslant C_3C_2K^2\gamma_2(\mathcal{F},d),$$

从而

$$\mathrm{E}\left[\sup_{f\in\mathcal{F}}|Z_f|\right]\leqslant\mathrm{E}\left[\sup_{f\in\mathcal{F}}Z_f\right]+\mathrm{E}\left[\sup_{f\in\mathcal{F}}(-Z_f)\right]\leqslant 2C_3C_2K^2\gamma_2(\mathcal{F},d),$$

此时令 $C=2C_3C_2$。

(2) 令 $\boldsymbol{X}\in\mathbb{R}^n$ 为各向同性的随机向量，其与 $\boldsymbol{A}$ 的行向量同分布，则 $\boldsymbol{A}_1,\cdots,\boldsymbol{A}_m$ 为 $\boldsymbol{X}$ 的独立同分布的样本。

设 $\mathbb{T}\subset\mathbb{S}^{n-1}$，定义线性函数族

$$\mathcal{F}=\{f_{\boldsymbol{x}}(\boldsymbol{w})=\langle\boldsymbol{x},\boldsymbol{w}\rangle:\boldsymbol{x}\in\mathbb{T}\}。$$

则

$$d(f_{\boldsymbol{x}},f_{\boldsymbol{y}})^2=\mathrm{E}[\langle\boldsymbol{x}-\boldsymbol{y},\boldsymbol{X}\rangle^2]=(\boldsymbol{x}-\boldsymbol{y})^\top\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top](\boldsymbol{x}-\boldsymbol{y})=\|\boldsymbol{x}-\boldsymbol{y}\|_2^2,$$

即 $d=\|\cdot\|_2$，因此 $\gamma_2(\mathcal{F},d)\asymp\gamma(\mathbb{T})$。

根据题目假设，可得

$$\|f_{\boldsymbol{x}}(\boldsymbol{X})-f_{\boldsymbol{y}}(\boldsymbol{X})\|_{\psi_2}=\|\langle\boldsymbol{x}-\boldsymbol{y},\boldsymbol{X}\rangle\|_{\psi_2}\leqslant K\|\boldsymbol{x}-\boldsymbol{y}\|_2=Kd(f_{\boldsymbol{x}},f_{\boldsymbol{y}})。$$

对于任意的 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，由于 $\|f_{\boldsymbol{x}}\|_{L_2}^2=\mathrm{E}[\langle\boldsymbol{x},\boldsymbol{X}\rangle^2]=\|\boldsymbol{x}\|_2^2=1$，$\sum_{i=1}^m f_{\boldsymbol{x}}(\boldsymbol{X}_i)^2=\|\boldsymbol{A}\boldsymbol{x}\|_2^2$，因此

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\sqrt{m}}-1\right|\right]\leqslant\frac{CK^2\gamma_2(\mathcal{F},d)}{\sqrt{m}}\asymp\frac{CK^2\gamma(\mathbb{T})}{\sqrt{m}},$$

两侧同乘 $\sqrt{m}$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}|\right]\leqslant CK^2\gamma(\mathbb{T})。$$

6 [**随机投影的偏差**] 证明定理 T9.1.1 (矩阵偏离不等式) 的随机投影版本。设 $\boldsymbol{P}$ 为 $\mathbb{R}^n$ 向 m 维子空间的正交投影矩阵，其中子空间于 Grassmannian 流形 $G_{n,m}$ 是均匀分布的。证明：对于任意的集合 $\mathbb{T}\subset\mathbb{R}^n$，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{\frac{m}{n}}\|\boldsymbol{x}\|_2\right|\right]\leqslant\frac{C\gamma(\mathbb{T})}{\sqrt{n}}。\qquad(C>0)$$

证明 目标不等式的两侧同乘 $\sqrt{n}$，我们只需证明

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\sqrt{n}\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]\leqslant C\gamma(\mathbb{T})。$$

- 建立随机投影与 Gaussian 矩阵的联系

  令 $\boldsymbol{G}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 矩阵，并作极分解 $\boldsymbol{G}=\boldsymbol{H}\boldsymbol{V}^\top$，其中 $\boldsymbol{H}=(\boldsymbol{G}\boldsymbol{G}^\top)^{1/2}$，$\boldsymbol{V}\in\mathbb{R}^{n\times m}$ 满足 $\boldsymbol{V}^\top\boldsymbol{V}=\boldsymbol{I}_m$。

  根据 Gaussian 分布的旋转不变性，可得：

  1. $\boldsymbol{V}$ 的列空间于 $G_{n,m}$ 是均匀分布的，因此 $\boldsymbol{P}=\boldsymbol{V}\boldsymbol{V}^\top$。
  2. $\boldsymbol{V}$ 与 $\boldsymbol{H}$ 是相互独立的，且 $\boldsymbol{H}^2=\boldsymbol{G}\boldsymbol{G}^\top\sim W_m(n,\boldsymbol{I}_m)$。

  此外，

  对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，令 $\boldsymbol{u}_{\boldsymbol{x}}=\boldsymbol{V}^\top\boldsymbol{x}\in\mathbb{R}^m$，则

  $$\|\boldsymbol{P}\boldsymbol{x}\|_2=\|\boldsymbol{V}\boldsymbol{V}^\top\boldsymbol{x}\|_2=\|\boldsymbol{u}_{\boldsymbol{x}}\|_2,\ \|\boldsymbol{G}\boldsymbol{x}\|_2=\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2。$$

- 利用三角不等式拆分误差

将偏差项 $|\sqrt{n}\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|$ 进行拆分，

$$\begin{aligned}|\sqrt{n}\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2| &= |\sqrt{n}\|\boldsymbol{u}_{\boldsymbol{x}}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2| \\ &\leqslant |\sqrt{n}\|\boldsymbol{u}_{\boldsymbol{x}}\|_2-\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2|+|\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2| \\ &\leqslant |\sqrt{n}\|\boldsymbol{u}_{\boldsymbol{x}}\|_2-\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2|+|\|\boldsymbol{G}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|。\end{aligned}$$

两侧取上确界，期望，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\sqrt{n}\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]\leqslant\underbrace{\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2-\sqrt{n}\|\boldsymbol{u}_{\boldsymbol{x}}\|_2|\right]}_{I_1}+\underbrace{\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{G}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]}_{I_2}。$$

- 分别界定两项误差

对于 I_2，根据标准矩阵偏差定理，可得

$$\mathrm{E}_{\boldsymbol{G}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{G}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]\leqslant C_1\gamma(\mathbb{T})。$$

对于 I_1，条件化 $\boldsymbol{V}$，则 $\mathbb{U}=\{\boldsymbol{u}_{\boldsymbol{x}}=\boldsymbol{V}^{\top}\boldsymbol{x}:\boldsymbol{x}\in\mathbb{T}\}\subset\mathbb{R}^m$ 为确定的有界子集。

引入标准 Gaussian 矩阵 $\tilde{\boldsymbol{G}}\in\mathbb{R}^{n\times m}$。由 $\boldsymbol{H}^2\overset{d}{=}\tilde{\boldsymbol{G}}^{\top}\tilde{\boldsymbol{G}}$，对于任意 $\boldsymbol{u}$ 有 $\|\boldsymbol{H}\boldsymbol{u}\|_2^2\overset{d}{=}\|\tilde{\boldsymbol{G}}\boldsymbol{u}\|_2^2$，因此

$$\mathrm{E}_{\boldsymbol{H}}\left[\sup_{\boldsymbol{u}\in\mathbb{U}}|\|\boldsymbol{H}\boldsymbol{u}\|_2-\sqrt{n}\|\boldsymbol{u}\|_2|\right]=\mathrm{E}_{\tilde{\boldsymbol{G}}}\left[\sup_{\boldsymbol{u}\in\mathbb{U}}|\|\tilde{\boldsymbol{G}}\boldsymbol{u}\|_2-\sqrt{n}\|\boldsymbol{u}\|_2|\right]。$$

从而根据标准矩阵偏差定理，可得

$$\mathrm{E}_{\boldsymbol{H}}\left[\sup_{\boldsymbol{u}\in\mathbb{U}}|\|\boldsymbol{H}\boldsymbol{u}\|_2-\sqrt{n}\|\boldsymbol{u}\|_2|\right]\leqslant C_2\gamma(\mathbb{U})。$$

(之后只需将 $\gamma(\mathbb{U})$ 通过 $\gamma(\mathbb{T})$ 表示。)

设 $\boldsymbol{h}\sim N(\boldsymbol{0},\boldsymbol{I}_m)$，满足 $\boldsymbol{V}\boldsymbol{h}\overset{d}{=}\boldsymbol{P}\boldsymbol{g}$ ($\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$)，则

$$\gamma(\mathbb{U})=\mathrm{E}_{\boldsymbol{h}}\left[\sup_{\boldsymbol{u}\in\mathbb{U}}\langle\boldsymbol{h},\boldsymbol{u}\rangle\right]=\mathrm{E}_{\boldsymbol{h}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{V}\boldsymbol{h},\boldsymbol{x}\rangle\right]=\mathrm{E}_{\boldsymbol{h}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{P}\boldsymbol{x}\rangle\right]=\mathrm{E}_{\boldsymbol{g}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{P}\boldsymbol{x}\rangle\right]。$$

比较中心化 Gaussian 过程 $X_{\boldsymbol{x}}=\langle\boldsymbol{g},\boldsymbol{P}\boldsymbol{x}\rangle, Y_{\boldsymbol{x}}=\langle\boldsymbol{g},\boldsymbol{x}\rangle$，由于

$$\mathrm{E}[(X_{\boldsymbol{x}}-X_{\boldsymbol{y}})^2]=\|\boldsymbol{P}(\boldsymbol{x}-\boldsymbol{y})\|_2^2\leqslant\|\boldsymbol{x}-\boldsymbol{y}\|_2^2=\mathrm{E}[(Y_{\boldsymbol{x}}-Y_{\boldsymbol{y}})^2],$$

因此利用定理 T7.2.8 (Sudakov–Fernique 不等式) (Sudakov–Fernique 不等式)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}X_{\boldsymbol{x}}\right]\leqslant\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}Y_{\boldsymbol{x}}\right]，\text{因此}\gamma(\mathbb{U})\leqslant\gamma(\mathbb{T}),$$

从而解除对 $\boldsymbol{V}$ 的条件化，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{H}\boldsymbol{u}_{\boldsymbol{x}}\|_2-\sqrt{n}\|\boldsymbol{u}_{\boldsymbol{x}}\|_2|\right]\leqslant C_2\gamma(\mathbb{T})。$$

如此，

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\sqrt{n}\|\boldsymbol{P}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2|\right]\leqslant C_2\gamma(\mathbb{T})+C_1\gamma(\mathbb{T})=(C_1+C_2)\gamma(\mathbb{T}),$$

此时令 $C=C_1+C_2$。

7 [**投影的大小：高概率界**] 给出命题 P9.2.1 (集合的随机投影的大小) 的高概率版本。

设 $\mathbb{T}\subset\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立、各向同性的 K-sub-Gaussian 随机向量。考虑缩放随机线性算子 $\boldsymbol{Q}=\frac{1}{\sqrt{n}}\boldsymbol{A}$。证明：对于任意的 $\varepsilon>0$，

$$\operatorname{diam}(\boldsymbol{Q}\mathbb{T})\leqslant(1+\varepsilon)\sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T})+CK^2w_s(\mathbb{T})\left(\text{w.h.p. }1-2\exp\left(-\frac{c\varepsilon^2m}{K^4}\right)\right)。$$

证明 引入高概率矩阵偏差不等式

根据矩阵偏差不等式的高概率形式，可得对于任意的有界集合 $\mathbb{S}\subset\mathbb{R}^n$，$u\geqslant0$，

$$\sup_{\boldsymbol{z}\in\mathbb{S}}|\|\boldsymbol{A}\boldsymbol{z}\|_2-\sqrt{m}\|\boldsymbol{z}\|_2|\leqslant C_1K^2\gamma(\mathbb{S})+C_1K^2u\cdot\operatorname{rad}(\mathbb{S})\ (\text{w.h.p. }1-2\exp(-u^2))。\tag{I}$$

- 对差集 $\mathbb{T}-\mathbb{T}$ 利用不等式

  令 $\mathbb{S}=\mathbb{T}-\mathbb{T}$，则半径为

  $$\operatorname{rad}(\mathbb{T}-\mathbb{T})=\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\|\boldsymbol{x}-\boldsymbol{y}\|_2=\operatorname{diam}(\mathbb{T}),$$

  Gaussian 复杂度为

  $$\gamma(\mathbb{T}-\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}-\boldsymbol{y}\rangle\right]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right]+\mathrm{E}\left[\sup_{\boldsymbol{y}\in\mathbb{T}}\langle\boldsymbol{g},-\boldsymbol{y}\rangle\right]=2w(\mathbb{T}),$$

  将其代入于 (I)，可得

  $$\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\left|\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2-\sqrt{m}\|\boldsymbol{x}-\boldsymbol{y}\|_2\right|\leqslant 2C_1K^2w(\mathbb{T})+C_1K^2u\cdot\operatorname{diam}(\mathbb{T})\ (\text{w.h.p. } 1-2\exp(-u^2))。\tag{II}$$

- 推导 $\boldsymbol{A}\mathbb{T}$ 的直径

  利用三角不等式，可得

  $$\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2\leqslant\sqrt{m}\|\boldsymbol{x}-\boldsymbol{y}\|_2+\left|\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2-\sqrt{m}\|\boldsymbol{x}-\boldsymbol{y}\|_2\right|,$$

  两侧于 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}$ 取上确界，

  $$\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{A}\boldsymbol{y}\|_2\leqslant\sqrt{m}\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\|\boldsymbol{x}-\boldsymbol{y}\|_2+\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\left|\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2-\sqrt{m}\|\boldsymbol{x}-\boldsymbol{y}\|_2\right|。\tag{III}$$

  左侧即为 $\operatorname{diam}(\boldsymbol{A}\mathbb{T})$。

  联立 (II)(III)，可得

  $$\operatorname{diam}(\boldsymbol{A}\mathbb{T})\leqslant\sqrt{m}\operatorname{diam}(\mathbb{T})+2C_1K^2w(\mathbb{T})+C_1K^2u\cdot\operatorname{diam}(\mathbb{T})\ (\text{w.h.p. } 1-2\exp(-u^2)),$$

  即

  $$\operatorname{diam}(\boldsymbol{A}\mathbb{T})\leqslant(\sqrt{m}+C_1K^2u)\operatorname{diam}(\mathbb{T})+2C_1K^2w(\mathbb{T})。$$

- 缩放至投影矩阵

  进行代换 $\boldsymbol{Q}=\frac{1}{\sqrt{n}}\boldsymbol{A}$，此时

  $$\operatorname{diam}(\boldsymbol{Q}\mathbb{T})=\frac{1}{\sqrt{n}}\operatorname{diam}(\boldsymbol{A}\mathbb{T}),$$

  两侧同除以 $\sqrt{n}$，可得

  $$\operatorname{diam}(\boldsymbol{Q}\mathbb{T})\leqslant\left(\sqrt{\frac{m}{n}}+\frac{C_1K^2u}{\sqrt{n}}\right)\operatorname{diam}(\mathbb{T})+2C_1K^2\frac{w(\mathbb{T})}{\sqrt{n}}。$$

  由球面宽度的定义 (D7.5.4 (球面宽度))，$w_s(\mathbb{T})\asymp\frac{w(\mathbb{T})}{\sqrt{n}}$；将比较常数吸收进 C，

  $$\operatorname{diam}(\boldsymbol{Q}\mathbb{T})\leqslant\left(\sqrt{\frac{m}{n}}+\frac{C_1K^2u}{\sqrt{n}}\right)\operatorname{diam}(\mathbb{T})+CK^2w_s(\mathbb{T})。$$

  令 $\frac{C_1K^2u}{\sqrt{n}}=\varepsilon\sqrt{\frac{m}{n}}$，解得 $u=\frac{\varepsilon\sqrt{m}}{C_1K^2}$，此时

  $$1-2\exp(-u^2)\geqslant 1-2\exp\left(-\left(\frac{\varepsilon\sqrt{m}}{C_1K^2}\right)^2\right)=1-2\exp\left(-\frac{\varepsilon^2m}{C_1^2K^4}\right),$$

  此时令 $c=1/C_1^2$。

8 [**随机投影的集合大小**] 证明命题 P9.2.1 (集合的随机投影的大小) 在 7.6 节所考虑的 $\boldsymbol{P}$ 原始模型的版本。

设 $\mathbb{T}\subset\mathbb{R}^n$，设 $\boldsymbol{P}$ 为 $\mathbb{R}^n$ 到 m 维子空间 E 的正交投影矩阵，满足 $E\sim U(G_{n,m})$，其中 $G_{n,m}$ 为 Grassmannian 流形。证明：

$$\mathrm{E}[\operatorname{diam}(\boldsymbol{P}\mathbb{T})]\leqslant\sqrt{\frac{m}{n}}\operatorname{diam}(\mathbb{T})+Cw_s(\mathbb{T})。\qquad(C>0)$$

其中 $w_s(\mathbb{T})$ 为集合的球面宽度。

(注意到与独立坐标的 sub-Gaussian 投影不同，真正的正交投影不需要 sub-Gaussian 范数 K^2 项。)

证明 • 引入随机投影的偏差不等式

根据练习 Q9.6 (随机投影的偏差) 的结论，对于 $\mathbb{R}^n$ 的任意的子集 $\mathbb{S}$，均匀随机正交投影 $\boldsymbol{P}$ 满足偏差界限

$$\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{S}}\left|\|\boldsymbol{P}\boldsymbol{z}\|_2-\sqrt{\frac{m}{n}}\|\boldsymbol{z}\|_2\right|\right]\leqslant\frac{C_1\gamma(\mathbb{S})}{\sqrt{n}}。$$

利用三角不等式，可得

$$\|\boldsymbol{P}\boldsymbol{z}\|_2\leqslant\sqrt{\frac{m}{n}}\|\boldsymbol{z}\|_2+\left|\|\boldsymbol{P}\boldsymbol{z}\|_2-\sqrt{\frac{m}{n}}\|\boldsymbol{z}\|_2\right|,$$

于集合 $\mathbb{S}$ 取上确界, 期望，可将其改写为关于集合半径 $\mathrm{rad}(\mathbb{S})=\sup_{\boldsymbol{z}\in\mathbb{S}}\|\boldsymbol{z}\|_2$ 的形式：

$$\mathrm{E}[\mathrm{rad}(\boldsymbol{P}\mathbb{S})]\leqslant\sqrt{\frac{m}{n}}\,\mathrm{rad}(\mathbb{S})+\frac{C_1\gamma(\mathbb{S})}{\sqrt{n}}。\tag{I}$$

• 利用不等式于差集 $\mathbb{T}-\mathbb{T}$

将 (I) 利用于差集 $\mathbb{S}=\mathbb{T}-\mathbb{T}$，此时半径为

$$\mathrm{rad}(\mathbb{T}-\mathbb{T})=\sup_{\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}}\|\boldsymbol{x}-\boldsymbol{y}\|_2=\mathrm{diam}(\mathbb{T})。$$

同理，由于 $\boldsymbol{P}$ 为线性映射，$\boldsymbol{P}(\mathbb{T}-\mathbb{T})=\boldsymbol{P}\mathbb{T}-\boldsymbol{P}\mathbb{T}$，投影之后的半径为

$$\mathrm{rad}(\boldsymbol{P}(\mathbb{T}-\mathbb{T}))=\mathrm{diam}(\boldsymbol{P}\mathbb{T})。$$

对于 Gaussian 复杂度，

$$\gamma(\mathbb{T}-\mathbb{T})=2w(\mathbb{T}),$$

将其代入于 (I)，可得

$$\mathrm{E}[\mathrm{diam}(\boldsymbol{P}\mathbb{T})]\leqslant\sqrt{\frac{m}{n}}\,\mathrm{diam}(\mathbb{T})+\frac{2C_1w(\mathbb{T})}{\sqrt{n}}。$$

由球面宽度的定义，$w_s(\mathbb{T})\asymp\frac{w(\mathbb{T})}{\sqrt{n}}$；将比较常数吸收进 C。

9 [**高概率的协方差估计**] 证明注记 R9.2.3 (协方差估计：高概率保证) 的协方差估计保证。设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_m\in\mathbb{R}^n$ 为独立同分布的零均值随机向量，其协方差矩阵为 $\boldsymbol{\Sigma}=\mathrm{E}[\boldsymbol{X}\boldsymbol{X}^\top]\neq 0$[1]。假设对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，$\boldsymbol{X}$ 满足 sub-Gaussian 条件 $\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{\psi_2}\leqslant K\|\langle\boldsymbol{X},\boldsymbol{x}\rangle\|_{L_2}$。若 $\boldsymbol{\Sigma}=0$，结论平凡成立。

定义样本协方差矩阵

$$\boldsymbol{\Sigma}_m=\frac{1}{m}\sum_{i=1}^m\boldsymbol{X}_i\boldsymbol{X}_i^\top,$$

设有效秩 $r=\mathrm{tr}(\boldsymbol{\Sigma})/\|\boldsymbol{\Sigma}\|$。证明：对于任意的 $u\geqslant 0$，

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant CK^4\left(\sqrt{\frac{r+u}{m}}+\frac{r+u}{m}\right)\|\boldsymbol{\Sigma}\|\ (\text{w.h.p. } 1-2\mathrm{e}^{-u})。\qquad(C>0)$$

证明 • 白化, 问题转换

将算子范数改写为 $\mathbb{S}^{n-1}$ 的二次型上确界，

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}\left|\boldsymbol{x}^\top\boldsymbol{\Sigma}_m\boldsymbol{x}-\boldsymbol{x}^\top\boldsymbol{\Sigma}\boldsymbol{x}\right|=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}\left|\frac{1}{m}\sum_{i=1}^m\langle\boldsymbol{X}_i,\boldsymbol{x}\rangle^2-\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2^2\right|。$$

记 $R=\mathrm{im}(\boldsymbol{\Sigma})$，并令 $\boldsymbol{A}_i=\boldsymbol{\Sigma}^{\dagger/2}\boldsymbol{X}_i$。则 $\mathrm{Cov}(\boldsymbol{A}_i)=\boldsymbol{P}_R$，故 $\boldsymbol{A}_i$ 在子空间 R 上各向同性；又由于 $\boldsymbol{X}_i\in R$ 几乎处处成立，$\boldsymbol{X}_i=\boldsymbol{\Sigma}^{1/2}\boldsymbol{A}_i$。因此可在 R 上应用矩阵偏差不等式，此时

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|=\frac{1}{m}\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}|\|\boldsymbol{A}\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2^2-m\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2^2|。$$

定义椭球集合 $\mathbb{T}=\boldsymbol{\Sigma}^{1/2}\mathbb{S}^{n-1}$。令 $\boldsymbol{z}=\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\in\mathbb{T}$，问题转化为 $\boldsymbol{A}$ 于 $\mathbb{T}$ 的二次矩阵偏差，

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|=\frac{1}{m}\sup_{\boldsymbol{z}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{z}\|_2^2-m\|\boldsymbol{z}\|_2^2|。$$

- 根据高概率矩阵偏差不等式

定义线性偏差上确界 $Z=\sup_{\boldsymbol{z}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{z}\|_2-\sqrt{m}\|\boldsymbol{z}\|_2|$。根据矩阵偏差不等式的高概率版本，存在常数 C_1，对于任意的 $t\geqslant 0$，成立

$$Z\leqslant C_1K^2(\gamma(\mathbb{T})+t\cdot\mathrm{rad}(\mathbb{T}))\ (\text{w.h.p. } 1-2\mathrm{e}^{-t^2})。$$

利用 $|a^2-b^2|\leqslant|a-b|^2+2b|a-b|$，二次偏差被 Z 控制：

$$\sup_{\boldsymbol{z}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{z}\|_2^2-m\|\boldsymbol{z}\|_2^2|\leqslant Z^2+2\sqrt{m}\,\mathrm{rad}(\mathbb{T})Z。$$

代入高概率界限，成立

$$\sup_{\boldsymbol{z}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{z}\|_2^2-m\|\boldsymbol{z}\|_2^2|\leqslant[C_1K^2(\gamma(\mathbb{T})+t\cdot\mathrm{rad}(\mathbb{T}))]^2+2\sqrt{m}\,\mathrm{rad}(\mathbb{T})[C_1K^2(\gamma(\mathbb{T})+t\cdot\mathrm{rad}(\mathbb{T}))]\ (\text{w.h.p. } 1-2\mathrm{e}^{-t^2})。$$

- 计算几何量并化简

集合 $\mathbb{T}$ 的半径为 $\mathrm{rad}(\mathbb{T})=\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\|_2=\|\boldsymbol{\Sigma}\|^{1/2}$。

对于 Gaussian 复杂度，利用 Jensen 不等式，

$$\gamma(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{S}^{n-1}}\langle\boldsymbol{g},\boldsymbol{\Sigma}^{1/2}\boldsymbol{x}\rangle\right]=\mathrm{E}\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{g}\|_2\leqslant(\mathrm{E}\|\boldsymbol{\Sigma}^{1/2}\boldsymbol{g}\|_2^2)^{1/2}=(\mathrm{tr}(\boldsymbol{\Sigma}))^{1/2}。$$

代入有效秩 $r=\mathrm{tr}(\boldsymbol{\Sigma})/\|\boldsymbol{\Sigma}\|$，$\gamma(\mathbb{T})\leqslant\sqrt{r\|\boldsymbol{\Sigma}\|}=\sqrt{r}\cdot\mathrm{rad}(\mathbb{T})$。

令 $v=\gamma(\mathbb{T})+t\cdot\mathrm{rad}(\mathbb{T})$，则 $v\leqslant(\sqrt{r}+t)\|\boldsymbol{\Sigma}\|^{1/2}$，

$$\begin{aligned}&(\text{平方项})\quad v^2\leqslant 2(r+t^2)\|\boldsymbol{\Sigma}\|,\\&(\text{交叉项})\quad 2\sqrt{m}\,\mathrm{rad}(\mathbb{T})v\leqslant 2\sqrt{2}\sqrt{m}\sqrt{r+t^2}\|\boldsymbol{\Sigma}\|,\end{aligned}$$

将其代入二次偏差界，并利用 $K\geqslant 1$ (否则以 $\max(K,1)$ 替代 K) 提取常数 C_2，

$$\sup_{\boldsymbol{z}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{z}\|_2^2-m\|\boldsymbol{z}\|_2^2|\leqslant C_2K^4((r+t^2)+\sqrt{m}\sqrt{r+t^2})\|\boldsymbol{\Sigma}\|。$$

两端除以 m 得到 $\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|$ 的界限：

$$\|\boldsymbol{\Sigma}_m-\boldsymbol{\Sigma}\|\leqslant C_2K^4\left(\frac{r+t^2}{m}+\sqrt{\frac{r+t^2}{m}}\right)\|\boldsymbol{\Sigma}\|\ (\text{w.h.p. } 1-2\mathrm{e}^{-t^2})。$$

令 $u=t^2$，则事件成立概率至少为 $1-2\mathrm{e}^{-u}$，最后令 $C=C_2$。

10 [从矩阵偏差到 **Johnson-Lindenstrauss**] 利用定理 T9.1.1 (矩阵偏离不等式)，给出练习 Q5.14 (sub-Gaussian 矩阵的 Johnson-Lindenstrauss 引理) 的另一种解法。

设 $\mathcal{X}=\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N\}\subset\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立, 零均值, 各向同性的 K-sub-Gaussian 随机向量。定义降维投影矩阵为 $\boldsymbol{Q}=\frac{1}{\sqrt{m}}\boldsymbol{A}$。给定容差参数 $\varepsilon\in(0,1)$，试求目标维度 m 的下界，使得等距映射条件

$$(1-\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2\leqslant\|\boldsymbol{Q}\boldsymbol{x}_i-\boldsymbol{Q}\boldsymbol{x}_j\|_2\leqslant(1+\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2\ (\text{w.h.p.})。$$

证明 - 构造单位球面的差集 $\mathbb{T}$

定义 $\mathbb{T}$ 为由 $\mathcal{X}$ 中任意两个不同点之差的归一化向量构成的集合，即

$$\mathbb{T}=\left\{\overline{\boldsymbol{x}_i-\boldsymbol{x}_j}:\boldsymbol{x}_i,\boldsymbol{x}_j\in\mathcal{X},i\neq j\right\},$$

则 $\mathbb{T}\subset\mathbb{S}^{n-1}$，$|\mathbb{T}|\leqslant\frac{N(N-1)}{2}<N^2$。(之后只需证明对于任意的 $\boldsymbol{z}\in\mathbb{T}$，均满足 $|\|\boldsymbol{Q}\boldsymbol{z}\|_2-1|<\varepsilon$。)

由于 $\mathbb{T}\subset\mathbb{S}^{n-1}$，对于任意的 $\boldsymbol{z}\in\mathbb{T}$，$\|\boldsymbol{z}\|_2=1$。从而半径 $\mathrm{rad}(\mathbb{T})=1$。

对于 Gaussian 复杂度 $\gamma(\mathbb{T})$，利用有限集 Gaussian 极大值不等式，存在常数 C_0 使得

$$\gamma(\mathbb{T})=\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{z}\rangle\right]\leqslant C_0\sqrt{\ln|\mathbb{T}|}\cdot\sup_{\boldsymbol{z}\in\mathbb{T}}\|\boldsymbol{z}\|_2。$$

代入 $|\mathbb{T}|<N^2$ 和 $\|\boldsymbol{z}\|_2=1$，可得 $\gamma(\mathbb{T})\leqslant C_0\sqrt{\ln(N^2)}=C_0\sqrt{2\ln N}=C_1\sqrt{\ln N}$。

- 根据高概率矩阵偏差不等式

  根据矩阵偏差不等式高概率版本，对于 sub-Gaussian 矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，集合 $\mathbb{T}$ 及任意的 $u\geqslant 0$，成立

$$\sup_{\boldsymbol{z}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{z}\|_2-\sqrt{m}\|\boldsymbol{z}\|_2\right|\leqslant C_2K^2(\gamma(\mathbb{T})+u\cdot\mathrm{rad}(\mathbb{T}))\ (\text{w.h.p. } 1-2\mathrm{e}^{-u^2})。$$

  代入 $\|\boldsymbol{z}\|_2=1,\mathrm{rad}(\mathbb{T})=1$ 与 $\gamma(\mathbb{T})$ 的上界，可化简为

$$\sup_{\boldsymbol{z}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{z}\|_2-\sqrt{m}\right|\leqslant C_2K^2(C_1\sqrt{\ln N}+u)。\tag{I}$$

- 确定目标维度 m 并量化概率

  (JL 引理要求

$$C_2K^2(C_1\sqrt{\ln N}+u)\leqslant\varepsilon\sqrt{m},$$

  考虑将其一分为二，要求期望部分和尾部概率部分分别小于 $\frac{\varepsilon}{2}\sqrt{m}$。)

  1. 期望部分的控制 (决定 m 的下界)

     令

$$C_2C_1K^2\sqrt{\ln N}\leqslant\frac{\varepsilon}{2}\sqrt{m}，\text{因此}m\geqslant\frac{4C_1^2C_2^2K^4}{\varepsilon^2}\ln N,$$

     令 $C=4C_1^2C_2^2$，可得 $m\geqslant C\varepsilon^{-2}K^4\ln N$。

  2. 对于尾部概率的控制 (决定 u 的取值)

     令

$$C_2K^2u=\frac{\varepsilon}{2}\sqrt{m}，\text{因此}u=\frac{\varepsilon\sqrt{m}}{2C_2K^2},$$

     将其代入于概率下界 $1-2\mathrm{e}^{-u^2}$，成功的概率至少为

$$1-2\exp\left(-\frac{\varepsilon^2m}{4C_2^2K^4}\right)=1-2\exp\left(-\frac{c\varepsilon^2m}{K^4}\right)。\qquad\left(c=\frac{1}{4C_2^2}\right)$$

  在上述高概率事件成立的前提，对于任意的 $\boldsymbol{z}\in\mathbb{T}$，

$$\left|\|\boldsymbol{A}\boldsymbol{z}\|_2-\sqrt{m}\right|\leqslant\varepsilon\sqrt{m}，\text{因此}\left|\|\boldsymbol{Q}\boldsymbol{z}\|_2-1\right|\leqslant\varepsilon,$$

  代入 $\boldsymbol{z}=\overline{\boldsymbol{x}_i-\boldsymbol{x}_j}$，可得

$$\boldsymbol{Q}\boldsymbol{z}=\frac{\boldsymbol{Q}\boldsymbol{x}_i-\boldsymbol{Q}\boldsymbol{x}_j}{\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2},$$

  两侧同乘 $\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2$，即为

$$(1-\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2\leqslant\|\boldsymbol{Q}\boldsymbol{x}_i-\boldsymbol{Q}\boldsymbol{x}_j\|_2\leqslant(1+\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2\ (\text{w.h.p. } 1-2\exp(-c\varepsilon^2m/K^4))。$$

  如此，当目标降维维度满足 $m\geqslant C\varepsilon^{-2}K^4\ln N$ 时，等距映射性质成立。

11 [**加性 Johnson–Lindenstrauss 引理**] 证明引理 L9.2.4 (加性 Johnson–Lindenstrauss 引理) 的误差必须是绝对的，而非相对的。

证明：若 $X=\mathrm{conv}(\mathbb{T})\subset\mathbb{R}^n$ 存在非空内部，则当 $m<n$ 时，不存在 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，使得对于任意的 $\boldsymbol{x},\boldsymbol{y}\in X$，满足

$$\left|\frac{1}{\sqrt{m}}\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2-\|\boldsymbol{x}-\boldsymbol{y}\|_2\right|\leqslant\varepsilon\|\boldsymbol{x}-\boldsymbol{y}\|_2。\qquad(0<\varepsilon<1)$$

证明 解法一

(当 $m<n$ 时，$\dim(\ker\boldsymbol{A})=n-\mathrm{rank}(\boldsymbol{A})\geqslant n-m\geqslant 1$，因此必定存在非零向量，使得被 $\boldsymbol{A}$ 映射为零。

同时，注意到非空内部包含各个方向的局部位移 (X 包含开球，沿任意方向的微小位移均落于 $X-X$)。因此，令 $\boldsymbol{v}\in\ker\boldsymbol{A}$ 为充分小的非零向量，之后构造

$$\boldsymbol{x}=\boldsymbol{x}_0+\boldsymbol{v},\ \boldsymbol{y}=\boldsymbol{x}_0\in X,$$

其投影距离为 0，但是真实距离为 $\|\boldsymbol{v}\|_2>0$，与相对误差界的正下界矛盾；如此，相对误差界不可能成立。)

利用反证法，假设存在 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ $(m<n)$，$\varepsilon\in(0,1)$，使得对于任意的 $\boldsymbol{x},\boldsymbol{y}\in X$，上述相对误差界均成立，均满足

$$\left|\frac{1}{\sqrt{m}}\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2-\|\boldsymbol{x}-\boldsymbol{y}\|_2\right|\leqslant\varepsilon\|\boldsymbol{x}-\boldsymbol{y}\|_2,\qquad(0<\varepsilon<1)$$

则左侧的下界为

$$\frac{1}{\sqrt{m}}\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2\geqslant(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。\qquad(\mathrm{I})$$

由于 $\operatorname{int}(X)\neq\emptyset$，根据内部的定义，可得存在 $\boldsymbol{x}_0\in X$，半径 $r>0$，使得整个开球落于 X，即

$$\boldsymbol{x}_0+r\mathbb{B}_2^n=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}-\boldsymbol{x}_0\|_2<r\}\subset X。$$

考虑线性映射 $\boldsymbol{A}:\mathbb{R}^n\to\mathbb{R}^m$，则根据秩–零度定理，可得

$$\dim(\ker\boldsymbol{A})=n-\operatorname{rank}(\boldsymbol{A})\geqslant n-m,$$

其中 $m<n$，因此 $\dim(\ker\boldsymbol{A})\geqslant1$，从而存在非零向量 $\boldsymbol{v}_0\in\ker\boldsymbol{A}$，满足 $\boldsymbol{A}\boldsymbol{v}_0=\boldsymbol{0}$。

记 $\overline{\boldsymbol{v}_0}=\boldsymbol{v}_0/\|\boldsymbol{v}_0\|_2$，令 $\boldsymbol{v}=\frac{r}{2}\overline{\boldsymbol{v}_0}$，满足：

1. $\|\boldsymbol{v}\|_2=\frac{r}{2}<r$；
2. $\boldsymbol{v}\in\ker\boldsymbol{A}$，可得 $\boldsymbol{A}\boldsymbol{v}=\boldsymbol{0}$；

之后构造

$$\boldsymbol{x}=\boldsymbol{x}_0+\boldsymbol{v},\ \boldsymbol{y}=\boldsymbol{x}_0\in X,$$

则 $\|\boldsymbol{x}-\boldsymbol{x}_0\|_2=\|\boldsymbol{v}\|_2=\frac{r}{2}<r$，因此 $\boldsymbol{x}\in\boldsymbol{x}_0+r\mathbb{B}_2^n\subset X$。

对于上述构造的 $\boldsymbol{x},\boldsymbol{y}$，由于 $\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})=\boldsymbol{A}\boldsymbol{v}=\boldsymbol{0}$，因此

$$\frac{1}{\sqrt{m}}\|\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\|_2=0,$$

将其代入于 (I)，可得

$$\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant\varepsilon\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

矛盾；如此，当 $m<n$ 时，不存在 $\boldsymbol{A}$，使得于内部非空的集合 X 实现相对误差界。

解法二　归一化差集

设 $\mathbb{T}$ 为归一化差向量集合，即

$$\mathbb{T}=\{\overline{\boldsymbol{x}-\boldsymbol{y}}:\boldsymbol{x},\boldsymbol{y}\in X,\boldsymbol{x}\neq\boldsymbol{y}\}。$$

当 $X\supset\boldsymbol{x}_0+r\mathbb{B}_2^n$ 时，对于任意的 $\boldsymbol{u}\in\mathbb{S}^{n-1}$，令 $\boldsymbol{x}=\boldsymbol{x}_0+\frac{r}{2}\boldsymbol{u}\in\boldsymbol{x}_0+r\mathbb{B}_2^n\subset X$，$\boldsymbol{y}=\boldsymbol{x}_0\in X$，则

$$\overline{\boldsymbol{x}-\boldsymbol{y}}=\overline{\frac{r}{2}\boldsymbol{u}}=\boldsymbol{u},$$

可得 $\mathbb{T}\supset\mathbb{S}^{n-1}$，从而 $\operatorname{conv}(\mathbb{T})\supset\mathbb{B}_2^n$，特别地其内部非空。

由于 $m<n$，因此根据秩–零度定理，可得 $\dim(\ker\boldsymbol{A})\geqslant1$，从而 $\mathbb{T}\cap\ker\boldsymbol{A}\neq\emptyset$，即存在单位向量 $\boldsymbol{u}^*\in\mathbb{T}\cap\ker\boldsymbol{A}$，满足 $\|\boldsymbol{u}^*\|_2=1$，$\boldsymbol{A}\boldsymbol{u}^*=\boldsymbol{0}$，从而

$$\left|\frac{1}{\sqrt{m}}\|\boldsymbol{A}\boldsymbol{u}^*\|_2-\|\boldsymbol{u}^*\|_2\right|=|0-1|=1,$$

与 $\varepsilon<1$ 矛盾；如此，相对误差界于内部非空的集合 X 不成立。

注释　经典 JL 引理处理有限点集 $(|X|=N)$，其差向量方向至多为 $\binom{N}{2}$ 个。随机投影子空间几乎必然避开这些方向，因此可实现相对误差。

加性 JL 引理处理一般集合 (如流形, 凸体, 有界无限集)。若集合含有内部，则差方向覆盖全方向 $\mathbb{S}^{n-1}$；维数限制使零空间同此连续方向集相交，故相对误差失效，只能得到绝对误差 $\delta=\mathcal{O}(w(X)/\sqrt{m})$。

12 [M^* **界：仿射截面**] 将定理 T9.3.1 (M^* 界) 从过原点的截面推广到任意的仿射截面。

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。证明：对于任意的集合 $\mathbb{T}\subset\mathbb{R}^n$，

$$\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{R}^n}\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\right]\leqslant\frac{Cw(\mathbb{T})}{\sqrt{m}}。$$

证明 （若 $\boldsymbol{x},\boldsymbol{y}\in\boldsymbol{z}+\ker\boldsymbol{A}$，则 $\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})=\boldsymbol{0}$，此时 $\boldsymbol{x}-\boldsymbol{y}$ 必定落于过原点的线性子空间 $\ker\boldsymbol{A}$（不依赖于 $\boldsymbol{z}$），因此各个截面的直径均可由差集 $(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}$ 的尺度控制。

之后利用矩阵偏离不等式，当 $\boldsymbol{u}\in\ker\boldsymbol{A}$ 时，$\|\boldsymbol{A}\boldsymbol{u}\|_2=0$，可以将 Euclidean 长度 $\|\boldsymbol{u}\|_2$ 与 Gaussian 宽度 $w(\mathbb{T})$ 结合。）

- 消除仿射平移 $\boldsymbol{z}$，将直径归约为差集

  固定 $\boldsymbol{z}\in\mathbb{R}^n$，若 $\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})=\emptyset$ 或为单点集，则其直径为 0，结论是平凡的；之后只需考虑 $\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})\neq\emptyset$ 的情况。

  若 $\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})\neq\emptyset$，设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})$。

  i. 由于 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}$，因此 $\boldsymbol{x}-\boldsymbol{y}\in\mathbb{T}-\mathbb{T}$；

  ii. 由于 $\boldsymbol{x},\boldsymbol{y}\in\boldsymbol{z}+\ker\boldsymbol{A}$，因此存在 $\boldsymbol{k}_1,\boldsymbol{k}_2\in\ker\boldsymbol{A}$，使得 $\boldsymbol{x}=\boldsymbol{z}+\boldsymbol{k}_1,\boldsymbol{y}=\boldsymbol{z}+\boldsymbol{k}_2$，从而 $\boldsymbol{x}-\boldsymbol{y}=\boldsymbol{k}_1-\boldsymbol{k}_2\in\ker\boldsymbol{A}$，即 $\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})=\boldsymbol{0}$；

  因此对于任意的 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})$，

  $$\boldsymbol{x}-\boldsymbol{y}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}。$$

  从而

  $$\|\boldsymbol{x}-\boldsymbol{y}\|_2\leqslant\sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\|\boldsymbol{u}\|_2,$$

  左侧对 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})$ 取上确界，可得

  $$\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\leqslant\sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\|\boldsymbol{u}\|_2。$$

  注意到 $\sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\|\boldsymbol{u}\|_2$ 不依赖平移向量 $\boldsymbol{z}$，从而对 $\boldsymbol{z}\in\mathbb{R}^n$ 取上确界，

  $$\sup_{\boldsymbol{z}\in\mathbb{R}^n}\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\leqslant\sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\|\boldsymbol{u}\|_2。\tag{I}$$

- 利用核空间性质构造偏差项

  对于任意的 $\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}$，由于 $\boldsymbol{u}\in\ker\boldsymbol{A}$，因此 $\boldsymbol{A}\boldsymbol{u}=\boldsymbol{0}$，即 $\|\boldsymbol{A}\boldsymbol{u}\|_2=0$，从而

  $$\sqrt{m}\|\boldsymbol{u}\|_2=|\|\boldsymbol{A}\boldsymbol{u}\|_2-\sqrt{m}\|\boldsymbol{u}\|_2|。$$

  注意到 $(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}\subset\mathbb{T}-\mathbb{T}$，两侧取上确界，可得

  $$\sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\sqrt{m}\|\boldsymbol{u}\|_2\leqslant\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2|。$$

  两侧同除以 $\sqrt{m}$，将其代入于 (I)，可得

  $$\sup_{\boldsymbol{z}\in\mathbb{R}^n}\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\leqslant\frac{1}{\sqrt{m}}\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2|。\tag{II}$$

- 根据矩阵偏离不等式

  对 (II) 的两侧取期望，

  $$\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{R}^n}\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\right]\leqslant\frac{1}{\sqrt{m}}\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2|\right],\tag{III}$$

  根据定理 T9.1.1 (矩阵偏离不等式)，令 $\mathbb{S}=\mathbb{T}-\mathbb{T}$，可得

  $$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2|\right]\leqslant C_0w(\mathbb{T}-\mathbb{T}),\qquad(C_0>0)$$

  即

  $$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2|\right]\leqslant 2C_0w(\mathbb{T})。\tag{IV}$$

将 (III) 代入于 (IV)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{R}^n}\operatorname{diam}(\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A}))\right]\leqslant\frac{2C_0w(\mathbb{T})}{\sqrt{m}}=\frac{Cw(\mathbb{T})}{\sqrt{m}}。$$

注释 $\ker\boldsymbol{A}$ 为 $n-m$ 维随机子空间。对于任意的 $\boldsymbol{z}$，M^* 界将随机切片 $\mathbb{T}\cap(\boldsymbol{z}+\ker\boldsymbol{A})$ 的直径压缩至 $\mathcal{O}(w(\mathbb{T})/\sqrt{m})$。

对于线性逆问题，观测模型为 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}_0$，同观测的解构成仿射子空间 $\boldsymbol{x}_0+\ker\boldsymbol{A}$。若先验信息将未知信号限制于凸集 $\mathbb{T}$，则此定理对任意的真值信号 $\boldsymbol{x}_0$ 给出一致的重构误差界。

13 [M^* **界：高概率版本**] 证明定理 T9.3.1 (M^* 界) 的高概率版本。

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\mathbb{T}\subset\mathbb{S}^{n-1}$。证明：对于任意的 $u\geqslant0$，

$$\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|\leqslant C(w(\mathbb{T})+u)\ (\text{w.h.p. } 1-2\mathrm{e}^{-u^2})。$$

注释 本题为推导 M^* 截面直径界定理 T9.3.1 (M^* 界) 的高概率版本的关键一步：

若 $\boldsymbol{x}\in(K-K)\cap\ker\boldsymbol{A}$，则 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，可得

$$\sqrt{m}\|\boldsymbol{x}\|_2=\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\|\boldsymbol{x}\|_2\right|\leqslant C(w(K-K)+u\cdot\operatorname{rad}(K-K)),$$

两侧同除以 $\sqrt{m}$，

$$\operatorname{diam}(K\cap\ker\boldsymbol{A})\leqslant\frac{C'(w(K)+u\cdot\operatorname{diam}(K))}{\sqrt{m}}\ (\text{w.h.p. } 1-2\mathrm{e}^{-u^2})。$$

证明 (定义 $F(\boldsymbol{A})=\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|$，并将 $\boldsymbol{A}$ 视为 $\mathbb{R}^{mn}$ 的 Gaussian 随机向量。矩阵偏离不等式给出 $\mathrm{E}[F(\boldsymbol{A})]\leqslant C_0w(\mathbb{T})$；Gaussian 集中不等式将此期望界提升为高概率界。)

- 定义目标泛函并证明其 1-Lipschitz 性质

  定义

  $$F(\boldsymbol{A})=\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|。$$

  矩阵空间 $\mathbb{R}^{m\times n}$ 赋予 Frobenius 范数 $\|\boldsymbol{M}\|_F=\sqrt{\sum_{i,j}M_{ij}^2}$，则其与 $\mathbb{R}^{mn}$ 的标准 Euclidean 范数等价。

  对于任意的 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{m\times n}$，固定 $\boldsymbol{x}\in\mathbb{T}\subset\mathbb{S}^{n-1}$，利用反三角不等式，可得

  $$\begin{aligned}\left|\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|-\left|\|\boldsymbol{B}\boldsymbol{x}\|_2-\sqrt{m}\right|\right|&\leqslant\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\|\boldsymbol{B}\boldsymbol{x}\|_2\right| && (\text{绝对值的反三角不等式})\\&\leqslant\|(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{x}\|_2 && (\text{Euclidean 范数的反三角不等式})\\&\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|_F。\end{aligned}$$

  两侧对 $\boldsymbol{x}\in\mathbb{T}$ 取上确界，利用性质 $|\sup f-\sup g|\leqslant\sup|f-g|$，可得

  $$|F(\boldsymbol{A})-F(\boldsymbol{B})|=\left|\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|-\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{B}\boldsymbol{x}\|_2-\sqrt{m}\right|\right|\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|_F。$$

  因此 $F:\mathbb{R}^{m\times n}\to\mathbb{R}$ 为关于 Frobenius 范数的 1-Lipschitz 函数。

- 控制泛函的数学期望

  根据定理 T9.1.1 (矩阵偏离不等式)，可得

  $$\mathrm{E}[F(\boldsymbol{A})]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\left|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}\right|\right]\leqslant C_0w(\mathbb{T})。\tag{I}$$

  根据定理 T5.2.3 (Gaussian 集中)，可得

  $$\mathrm{P}\{|F(\boldsymbol{A})-\mathrm{E}[F(\boldsymbol{A})]|\geqslant t\}\leqslant2\exp\left(-\frac{t^2}{2}\right),\tag{II}$$

  即

  $$\mathrm{P}\{F(\boldsymbol{A})\geqslant\mathrm{E}[F(\boldsymbol{A})]+t\}\leqslant2\exp\left(-\frac{t^2}{2}\right)。$$

令 $t=\sqrt{2}u$，即 $t^2/2=u^2$，则

$$F(\boldsymbol{A})\leqslant \mathrm{E}[F(\boldsymbol{A})]+\sqrt{2}u \text{ (w.h.p. } 1-2\mathrm{e}^{-u^2}\text{)。} \tag{III}$$

将 (I) 代入于 (III)，可得

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}|\leqslant C_0 w(\mathbb{T})+\sqrt{2}u\leqslant C(w(\mathbb{T})+u) \text{ (w.h.p. } 1-2\mathrm{e}^{-u^2}\text{)。} \quad \left(C=\max(C_0,\sqrt{2})\right)$$

14 [切 p 球] 设 E 为随机 k 维子空间，其中 $1\leqslant k\leqslant 0.99n$，

(1) 证明：对于任意的 $p\in(1,\infty)$，

$$\mathrm{E}[\mathrm{diam}(\mathbb{B}_p^n\cap E)]\lesssim_p n^{\frac{1}{2}-\frac{1}{p}}。$$

(2) 证明：E 等价于 $\mathbb{B}_p^n$ 的内接 Euclidean 球半径 ($p\leqslant 2$), 外接 Euclidean 球半径 ($p\geqslant 2$)。

证明 (1) 将随机截面同 M^* 界相联系

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。

令 $m=n-k$ (即截面的余维数)，则根据正态分布的旋转不变性，可得 $\dim\ker\boldsymbol{A}=n-m=k$，$\ker\boldsymbol{A}\sim U(G(n,k))$ (即 Haar 测度)，因此 $E\overset{d}{=}\ker\boldsymbol{A}$。

根据定理 T9.3.1 (M^* 界)，令 $\mathbb{T}=\mathbb{B}_p^n$，可得

$$\mathrm{E}[\mathrm{diam}(\mathbb{B}_p^n\cap E)]\leqslant\frac{10Cw(\mathbb{B}_p^n)}{\sqrt{n}}。 \tag{I}$$

(由于 $k\leqslant 0.99n$，因此余维数满足 $m=n-k\geqslant 0.01n$，可得 $\sqrt{m}\geqslant 0.1\sqrt{n}$。)

之后只需计算 $w(\mathbb{B}_p^n)$。

- 计算 ℓ_p 球的 Gaussian 宽度 $w(\mathbb{B}_p^n)$

  设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，则根据 Hölder 对偶性，可得

$$w(\mathbb{B}_p^n)=\mathrm{E}_{\boldsymbol{g}}\left[\sup_{\boldsymbol{x}\in\mathbb{B}_p^n}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right]=\mathrm{E}[\|\boldsymbol{g}\|_q]=\mathrm{E}\left[\left(\sum_{i=1}^n|g_i|^q\right)^{\frac{1}{q}}\right], \quad \left(\frac{1}{p}+\frac{1}{q}=1\right)$$

  因此利用 Jensen 不等式，可得

$$w(\mathbb{B}_p^n)\leqslant\mathrm{E}\left[\sum_{i=1}^n|g_i|^q\right]^{\frac{1}{q}}=n^{\frac{1}{q}}\mathrm{E}[|g_1|^q]^{\frac{1}{q}}\leqslant C_p n^{1-\frac{1}{p}}。 \tag{II}$$

  其中

$$C_p=\mathrm{E}[|g_1|^q]^{\frac{1}{q}}=\sqrt{2}\left(\frac{\Gamma\left(\frac{q+1}{2}\right)}{\sqrt{\pi}}\right)^{\frac{1}{q}}<\infty。$$

将 (II) 代入于 (I)，可得

$$\mathrm{E}[\mathrm{diam}(\mathbb{B}_p^n\cap E)]\leqslant\frac{10CC_p n^{1-\frac{1}{p}}}{n^{\frac{1}{2}}}=(10CC_p)n^{\frac{1}{2}-\frac{1}{p}}。$$

因此

$$\mathrm{E}[\mathrm{diam}(\mathbb{B}_p^n\cap E)]\lesssim_p n^{\frac{1}{2}-\frac{1}{p}}。$$

(2) 设内接半径 r_{in} 为满足 $\mathbb{B}_2^n(r)\subset\mathbb{B}_p^n$ 的最大 r，外接半径 R_{out} 为满足 $\mathbb{B}_p^n\subset\mathbb{B}_2^n(R)$ 的最小 R。

a. 当 $1\leqslant p\leqslant 2$ 时，$r_{\mathrm{in}}=n^{\frac{1}{2}-\frac{1}{p}}$ (由体对角线方向决定，于 $\boldsymbol{x}=(\pm n^{-1/p},\cdots,\pm n^{-1/p})$ 取得)，外接半径 $R_{\mathrm{out}}=1$ (由坐标轴极值点决定，于标准基 $\boldsymbol{e}_i$ 取得)，此时截面直径界精确等价于内接球半径 r_{in}。

b. 当 $p\geqslant 2$ 时，内接半径 $r_{\mathrm{in}}=1$ (于标准基 $\boldsymbol{e}_i$ 取得)，外接半径 $R_{\mathrm{out}}=n^{\frac{1}{2}-\frac{1}{p}}$ (于 $\boldsymbol{x}=(\pm n^{-1/p},\cdots,\pm n^{-1/p})$ 取得)，此时截面直径界精确等价于外接球半径 R_{out}。

图 (1) $1 \leqslant p \leqslant 2$ (例：$p = 1$)

随机子空间避开尖峰：截面直径 $\asymp r_{\text{in}} = n^{\frac{1}{2}-\frac{1}{p}}$

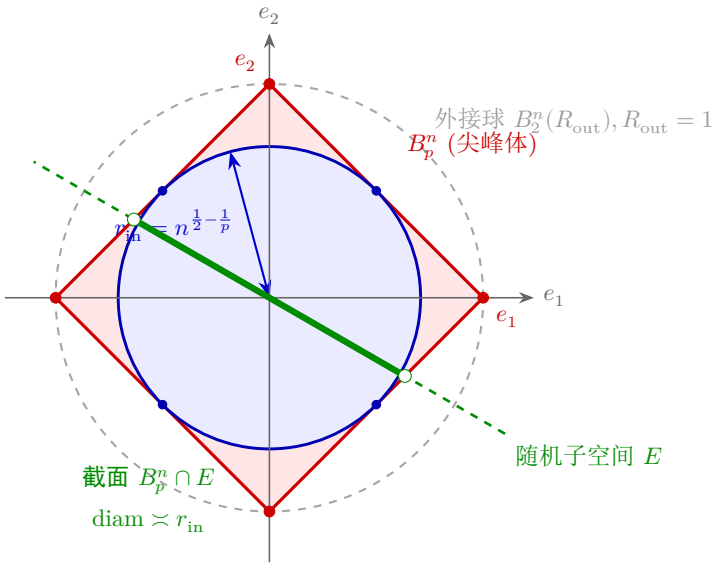
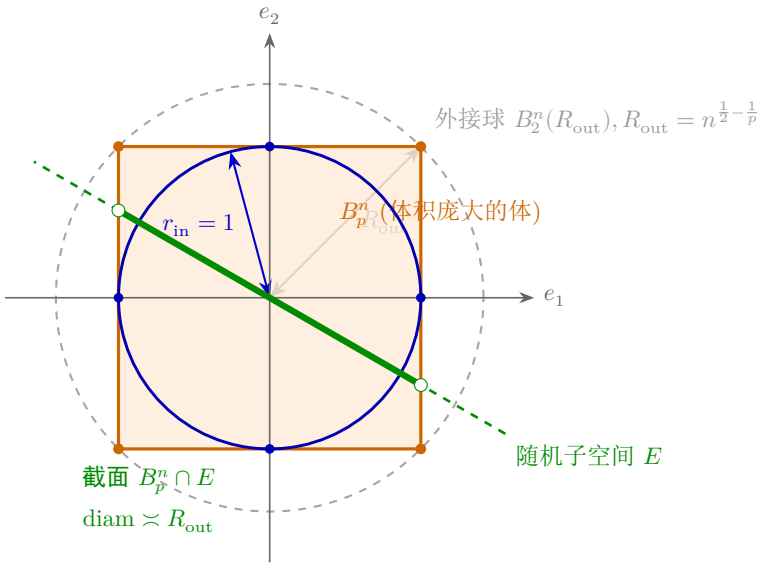


图 (2) $p \geqslant 2$ (例：$p = \infty$)

体积庞大的体：截面直径 $\asymp R_{\text{out}} = n^{\frac{1}{2}-\frac{1}{p}}$



注释 Kashin 截面定理, Dvoretzky 定理表明，ℓ_1 球 (或一般 ℓ_p 球) 的宏观维度随机截面近似各向同性 Euclidean 球。其尺度由内接 Euclidean 球半径控制。

15 [逃逸定理的紧性] 证明定理 T9.3.4 (逃逸定理) 于 $1 \leqslant m \leqslant n$ 的一般情形下最优。

令测试集合 $\mathbb{T} = V \cap \mathbb{S}^{n-1}$ 为 $\mathbb{R}^n$ 的 d 维线性子空间 V 的单位球面 $(1 \leqslant d \leqslant n)$。(之后说明逃逸定理给出的维数阈值在这一族例子中具有正确的量级。)

证明 • 计算子空间球面 $\mathbb{T}$ 的 Gaussian 宽度 $w(\mathbb{T})$

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，$\boldsymbol{P}_V$ 为到 V 的正交投影，则

$$w(\mathbb{T}) = \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{x}\rangle\right] = \mathrm{E}\left[\sup_{\boldsymbol{x}\in V, \|\boldsymbol{x}\|_2=1} \langle \boldsymbol{P}_V \boldsymbol{g}, \boldsymbol{x}\rangle\right] = \mathrm{E}[\|\boldsymbol{P}_V \boldsymbol{g}\|_2]。$$

由于 $\dim V = d$，因此 $\boldsymbol{P}_V \boldsymbol{g} \overset{d}{=} \boldsymbol{g}_d \sim N(\boldsymbol{0}, \boldsymbol{I}_d)$，因此 d 维标准 Gaussian 向量模长的期望满足

$$\mathrm{E}[\|\boldsymbol{g}_d\|_2] = \sqrt{2}\frac{\Gamma\left(\frac{d+1}{2}\right)}{\Gamma\left(\frac{d}{2}\right)} = \sqrt{d}\left(1 - O\left(\frac{1}{d}\right)\right) \asymp \sqrt{d},$$

从而 $w(\mathbb{T}) \asymp \sqrt{d}$，即 $w(\mathbb{T})^2 \asymp d$。

根据定理 T9.3.4 (逃逸定理)，可得预测的下界为

$$\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 \geqslant C^{-1}\sqrt{m} - Cw(\mathbb{T}) \geqslant C^{-1}\sqrt{m} - C\sqrt{d}, \tag{I}$$

保证发生逃逸 (即 $\mathbb{T} \cap \ker \boldsymbol{A} = \emptyset$) 所需的测量数条件为

$$C^{-1}\sqrt{m} - Cw(\mathbb{T}) > 0 \quad \text{只要} \quad m \geqslant C_0 w(\mathbb{T})^2 \asymp d。 \tag{II}$$

• 分析 $\mathbb{T} \cap \ker \boldsymbol{A} = \emptyset$ 的成立条件

a. 当 $m < d$ 时 (无法逃逸的刚性障碍)，根据 Grassmann 子空间维数公式，可得

$$\dim(V \cap \ker \boldsymbol{A}) \geqslant \dim V + \dim \ker \boldsymbol{A} - n。$$

其中根据秩–零度定理，可得 $\dim \ker \boldsymbol{A} = n - \mathrm{rank}(\boldsymbol{A}) \geqslant n - m$，因此

$$\dim(V \cap \ker \boldsymbol{A}) \geqslant d + (n - m) - n = d - m \geqslant 1。$$

从而 $V \cap \ker \boldsymbol{A} \neq \{\boldsymbol{0}\}$ (a.s.)。

如此，当 $m < d$ 时，必定存在单位向量 $\boldsymbol{x} \in \mathbb{T}$，使得 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，即

$$\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 = 0,$$

- 利用正交基归约为标准 Gaussian 矩阵的极小奇异值

设 $\{\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_d\} \subset \mathbb{R}^n$ 为 V 的一组标准正交基，令 $\boldsymbol{U} = [\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_d]$，则子空间可表示为

$$V = \mathrm{im}(\boldsymbol{U}) = \{\boldsymbol{U}\boldsymbol{z} : \boldsymbol{z} \in \mathbb{R}^d\}。$$

注意到 $\boldsymbol{U}$ 为等距嵌入 ($\|\boldsymbol{U}\boldsymbol{z}\|_2 = \|\boldsymbol{z}\|_2$)，因此

$$\mathbb{T} = \{\boldsymbol{U}\boldsymbol{z} : \boldsymbol{z} \in \mathbb{S}^{d-1}\}。$$

令 $\boldsymbol{G} = \boldsymbol{A}\boldsymbol{U} \in \mathbb{R}^{m\times d}$，设 $\boldsymbol{A}$ 的第 i 行向量为 $\boldsymbol{A}_i$ i.i.d. $\sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，则 $\boldsymbol{G}$ 的第 i 行向量为

$$\boldsymbol{g}_i = \boldsymbol{U}^\top \boldsymbol{A}_i \text{ i.i.d. } \sim N(\boldsymbol{0}, \boldsymbol{U}^\top \boldsymbol{I}_n \boldsymbol{U}) = N(\boldsymbol{0}, \boldsymbol{U}^\top \boldsymbol{U}) = N(\boldsymbol{0}, \boldsymbol{I}_d)。$$

因此 $\boldsymbol{G}$ 为标准 Gaussian 随机矩阵，从而

$$\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \min_{\boldsymbol{z}\in\mathbb{S}^{d-1}} \|\boldsymbol{A}(\boldsymbol{U}\boldsymbol{z})\|_2 = \min_{\boldsymbol{z}\in\mathbb{S}^{d-1}} \|\boldsymbol{G}\boldsymbol{z}\|_2 = \sigma_{\min}(\boldsymbol{G})。 \tag{III}$$

- 对极小奇异值 $\sigma_{\min}(\boldsymbol{G})$ 的非渐近分类讨论

a. 当 $m < d$ 时 (*代数维数障碍，无法逃逸*)，由于 $\boldsymbol{G} \in \mathbb{R}^{m\times d}$，因此根据线性代数秩–零度定理，可得

$$\mathrm{rank}(\boldsymbol{G}) \leqslant m < d，\text{因此 } \dim(\ker \boldsymbol{G}) = d - \mathrm{rank}(\boldsymbol{G}) \geqslant d - m \geqslant 1。$$

即零空间 $\ker \boldsymbol{G}$ 中必定存在非零向量。

令 $\boldsymbol{z}_0 \in \ker \boldsymbol{G} \cap \mathbb{S}^{d-1}$，则 $\|\boldsymbol{G}\boldsymbol{z}_0\|_2 = 0$，将其代入于 (III)，可得

$$\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \sigma_{\min}(\boldsymbol{G}) \equiv 0 \text{ (a.s.)}。$$

b. 当 $m \geqslant d$ 时 (*非渐近下界与 Gaussian 集中*)，根据定理 7.3.2 (Gordon 极小极大定理)，可得

$$\mathrm{E}[\sigma_{\min}(\boldsymbol{G})] \geqslant \sqrt{m} - \sqrt{d}。 \tag{IV}$$

因此利用奇异值的反三角不等式，可得对于任意的 $\boldsymbol{G}_1, \boldsymbol{G}_2 \in \mathbb{R}^{m\times d}$，

$$|\sigma_{\min}(\boldsymbol{G}_1) - \sigma_{\min}(\boldsymbol{G}_2)| \leqslant \|\boldsymbol{G}_1 - \boldsymbol{G}_2\|_{\mathrm{op}} \leqslant \|\boldsymbol{G}_1 - \boldsymbol{G}_2\|_F。$$

即映射 $\boldsymbol{G} \mapsto \sigma_{\min}(\boldsymbol{G})$ 关于 Frobenius 范数为 1-Lipschitz，从而根据定理 5.2.2 (Gaussian 测度集中)，可得

$$\mathrm{P}\big\{\sigma_{\min}(\boldsymbol{G}) \leqslant \sqrt{m} - \sqrt{d} - t\big\} \leqslant \exp\Big(-\frac{t^2}{2}\Big)。 \tag{V}$$

设测量数满足严格过采样 $m \geqslant (1+\varepsilon)d$，此时 $\sqrt{m} - \sqrt{d} \geqslant (\sqrt{1+\varepsilon} - 1)\sqrt{d} > 0$，令 $t = \frac{1}{2}(\sqrt{m} - \sqrt{d})$，则

$$\mathrm{P}\left\{\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 \geqslant \frac{\sqrt{m} - \sqrt{d}}{2}\right\} \geqslant 1 - \exp\left(-\frac{(\sqrt{m} - \sqrt{d})^2}{8}\right)。 \tag{VI}$$

特别地，当 $m \geqslant 2d$ 时，

$$\min_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{x}\|_2 \geqslant c_\varepsilon \sqrt{m} > 0 \text{ (w.h.p.1} - \mathrm{e}^{-cm})。$$

16 [**把贴纸贴到足球上**] 证明逃逸定理的以下版本。

设 $\mathbb{T} \subset \mathbb{S}^{n-1}$ (*把 $\mathbb{T}$ 想象成足球的贴纸*)，$X \subset \mathbb{S}^{n-1}$ 为 N 点集 (*像墨迹*)。证明：若

$$\sigma_{n-1}(\mathbb{T}) < \frac{1}{N},$$

其中 σ_{n-1} 为球面的归一化面积，则存在旋转 $U \in O(n)$，使得

$$U\mathbb{T} \cap X = \emptyset。$$

(*即我们可以放置贴纸而不覆盖任意墨迹。*)

证明 单点被覆盖的概率

固定 $\boldsymbol{x} \in X$，“点 $\boldsymbol{x}$ 落于旋转后的贴纸 $U\mathbb{T}$”等价于

$$\boldsymbol{x} \in U\mathbb{T} \text{当且仅当} U^{-1}\boldsymbol{x} \in \mathbb{T}。$$

由于 $U \sim \mathrm{Haar}(O(n))$，其逆矩阵 $U^{-1} = U^{\top}$ 同样于 $O(n)$ 服从 Haar 分布。根据球面测度的旋转不变性，对于固定任意的 $\boldsymbol{x} \in \mathbb{S}^{n-1}$，随机向量 $Y = U^{-1}\boldsymbol{x}$ 于单位球面 $\mathbb{S}^{n-1}$ 服从均匀分布 (即其概率分布正是归一化球面测度 σ_{n-1})。因此，随机贴纸覆盖点 $\boldsymbol{x}$ 的概率恰好等于 $\mathbb{T}$ 的球面测度：

$$\mathrm{P}\{\boldsymbol{x} \in U\mathbb{T}\} = \mathrm{P}\{U^{-1}\boldsymbol{x} \in \mathbb{T}\} = \sigma_{n-1}(\mathbb{T})。 \tag{I}$$

解法一　联合界

贴纸同点集相交 (即覆盖了至少一个点) 的事件为

$$\{U\mathbb{T} \cap X \neq \emptyset\} = \bigcup_{\boldsymbol{x} \in X} \{\boldsymbol{x} \in U\mathbb{T}\}。$$

根据概率的次可加性 (并集界，布尔不等式)，可得

$$\mathrm{P}\{U\mathbb{T} \cap X \neq \emptyset\} = \mathrm{P}\{\bigcup_{\boldsymbol{x} \in X} \{\boldsymbol{x} \in U\mathbb{T}\}\} \leqslant \sum_{\boldsymbol{x} \in X} \mathrm{P}\{\boldsymbol{x} \in U\mathbb{T}\}。$$

将其代入于 (I)，可得

$$\mathrm{P}\{U\mathbb{T} \cap X \neq \emptyset\} \leqslant \sum_{\boldsymbol{x} \in X} \sigma_{n-1}(\mathbb{T}) = N \cdot \sigma_{n-1}(\mathbb{T}) < N \cdot \frac{1}{N} = 1,$$

因此其对立事件 (即完全不相交) 的概率为

$$\mathrm{P}\{U\mathbb{T} \cap X = \emptyset\} = 1 - \mathrm{P}\{U\mathbb{T} \cap X \neq \emptyset\} > 1 - 1 = 0,$$

从而于样本空间 $O(n)$ 至少存在正交变换 $U \in O(n)$，使得 $U\mathbb{T} \cap X = \emptyset$。**解法二　期望的概率方法**

设 K 为被旋转贴纸 $U\mathbb{T}$ 覆盖的墨迹点的总数，即

$$K = |U\mathbb{T} \cap X| = \sum_{\boldsymbol{x} \in X} 1_{\{\boldsymbol{x} \in U\mathbb{T}\}}。$$

则

$$\mathrm{E}[K] = \sum_{\boldsymbol{x} \in X} \mathrm{E}[1_{\{\boldsymbol{x} \in U\mathbb{T}\}}] = \sum_{\boldsymbol{x} \in X} \mathrm{P}\{\boldsymbol{x} \in U\mathbb{T}\} = N \cdot \sigma_{n-1}(\mathbb{T}) < N \cdot \frac{1}{N} = 1。$$

因此

$$\mathrm{P}\{K = 0\} > 0，\text{因此} \mathrm{P}\{U\mathbb{T} \cap X = \emptyset\} > 0。$$

从而必定存在 $U \in O(n)$，使得 $U\mathbb{T} \cap X = \emptyset$。

注释　连续-几何版本 (Gordon 逃逸定理)：连续子空间 E 逃避连续集合 $\mathbb{T}$ ($E \cap \mathbb{T} = \emptyset$)，测度工具为 Gaussian 宽度 $w(\mathbb{T})$ 同余维数 m，判据为 $m \gtrsim w(\mathbb{T})^2$。

离散-测度版本 (本题，贴纸同墨迹)：随机旋转 $U\mathbb{T}$ 逃避离散点集 X ($U\mathbb{T} \cap X = \emptyset$)，测度工具为球面归一化面积 $\sigma_{n-1}(\mathbb{T})$ 同点数 N，判据为 $\sigma_{n-1}(\mathbb{T}) < 1/N$。

无论是连续子空间还是离散点对，只要目标集合的高维容量 (球面测度或 Gaussian 宽度) 足够小，高维旋转群, 随机投影的各向同性就能保证空间中存在充分的自由度将二者彻底错开。

17 [**约束恢复：均方误差**] 证明定理 T9.4.4 (约束恢复) 的均方误差界

$$\mathrm{E}\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2^2 \leqslant \frac{CK^4 w(\mathbb{T})^2}{m}。$$

证明　• 建立均方误差同偏差泛函的关系

(题设条件为：设 $\hat{\boldsymbol{x}}, \boldsymbol{x} \in \mathbb{T}$，则 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}\boldsymbol{x} = \boldsymbol{y}$。因此 $\hat{\boldsymbol{x}} - \boldsymbol{x} \in \mathbb{T} - \mathbb{T}$，$\boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x}) = \boldsymbol{0}$，从而 $\hat{\boldsymbol{x}} - \boldsymbol{x} \in (\mathbb{T} - \mathbb{T}) \cap \ker \boldsymbol{A}$。)

令 $\boldsymbol{u} = \hat{\boldsymbol{x}} - \boldsymbol{x}$，对于任意的 $\boldsymbol{u} \in (\mathbb{T} - \mathbb{T}) \cap \ker \boldsymbol{A}$，由于 $\boldsymbol{A}\boldsymbol{u} = \boldsymbol{0}$ (即 $\|\boldsymbol{A}\boldsymbol{u}\|_2 = 0$)，因此

$$\sqrt{m}\|\boldsymbol{u}\|_2 = \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big| \leqslant \sup_{\boldsymbol{v} \in \mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{v}\|_2 - \sqrt{m}\|\boldsymbol{v}\|_2\big|。$$

因此

$$\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \frac{1}{\sqrt{m}} \sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|。$$

两侧取平方，

$$\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2 \leqslant \frac{1}{m}\left(\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right)^2。$$

之后两侧取期望，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2] \leqslant \frac{1}{m}\mathrm{E}[Y^2], \tag{I}$$

其中

$$Y=\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|。$$

之后只需控制 $\mathrm{E}[Y],\mathrm{E}[Y^2]$。

- 控制随机变量 Y 的一阶矩, 二阶矩

根据方差的定义，可得二阶矩的分解

$$\mathrm{E}[Y^2]=(\mathrm{E}[Y])^2+\mathrm{Var}(Y)。 \tag{II}$$

对于 $\mathrm{E}[Y]$，根据定理 T9.1.1 (矩阵偏离不等式)，可得

$$\mathrm{E}[Y]=\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right] \leqslant C_1K^2w(\mathbb{T}-\mathbb{T}) \leqslant 2C_1K^2w(\mathbb{T}),$$

因此

$$(\mathrm{E}[Y])^2 \leqslant 4C_1^2K^4w(\mathbb{T})^2。 \tag{III}$$

对于 $\mathrm{Var}(Y)$：根据 sub-Gaussian 集中不等式 (习题 Q9.13 (M^* 界：高概率版本))，可得

$$\mathrm{P}\{|Y-\mathrm{E}[Y]| \geqslant t\} \leqslant 2\exp\left(-\frac{ct^2}{K^4\,\mathrm{rad}(\mathbb{T}-\mathbb{T})^2}\right)=2\exp\left(-\frac{ct^2}{K^4\,\mathrm{diam}(\mathbb{T})^2}\right)。$$

因此

$$\mathrm{Var}(Y)=\mathrm{E}[(Y-\mathrm{E}[Y])^2]=\int_0^\infty 2t\mathrm{P}\{|Y-\mathrm{E}[Y]| \geqslant t\}\mathrm{d}t \leqslant C_2K^4\,\mathrm{diam}(\mathbb{T})^2。 \tag{IV}$$

之后只需控制 $\mathrm{diam}(\mathbb{T})$。

- 利用 Gaussian 宽度控制集合直径 $\mathrm{diam}(\mathbb{T})$

对于任意的 $\boldsymbol{x}_1,\boldsymbol{x}_2\in\mathbb{T}$，令 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$，可得

$$w(\mathbb{T})=\frac{1}{2}w(\mathbb{T}-\mathbb{T}) \geqslant \frac{1}{2}\mathrm{E}[|\langle \boldsymbol{g},\boldsymbol{x}_1-\boldsymbol{x}_2\rangle|]=\frac{1}{2}\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2\mathrm{E}[|g_1|]=\frac{1}{\sqrt{2\pi}}\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2,$$

两侧对 $\boldsymbol{x}_1,\boldsymbol{x}_2\in\mathbb{T}$ 取上确界，可得

$$\mathrm{diam}(\mathbb{T}) \leqslant \sqrt{2\pi}w(\mathbb{T})。 \tag{V}$$

将 (V) 代入于 (IV)，可得

$$\mathrm{Var}(Y) \leqslant 2\pi C_2K^4w(\mathbb{T})^2。 \tag{VI}$$

- 代入整合得出结论

将 (III), (VI) 代入于 (II)，可得

$$\mathrm{E}[Y^2] \leqslant 4C_1^2K^4w(\mathbb{T})^2+2\pi C_2K^4w(\mathbb{T})^2=:C'K^4w(\mathbb{T})^2, \qquad (C'=4C_1^2+2\pi C_2)$$

将其代入于 (I)，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2] \leqslant \frac{C'K^4w(\mathbb{T})^2}{m}=:\frac{Cw(\mathbb{T})^2}{m}。 \qquad (C=C'K^4)$$

注释 利用 Cauchy-Schwarz 不等式, Jensen 不等式，可得

$$(\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2)^2 \leqslant \mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2] \leqslant \frac{Cw(\mathbb{T})^2}{m}，\text{因此}\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \frac{\sqrt{C}w(\mathbb{T})}{\sqrt{m}}。$$

这说明二阶均方误差界是更强的保证。

在压缩感知 (Compressed Sensing) 中，若 $\mathbb{T}=\sqrt{s}\mathbb{B}_1^n \cap \mathbb{B}_2^n$ (稀疏信号先验)，已知 $w(\mathbb{T})^2 \asymp s\ln(n/s)$，代入本题结论，即可直接得到稀疏恢复的经典 MSE 收敛率

$$\mathrm{MSE}=\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2] \lesssim \frac{s\ln(\mathrm{e}n/s)}{m}。$$

18 [**通过优化恢复**] 设 $\mathbb{T}=\{\boldsymbol{z}\in\mathbb{R}^n:\|\boldsymbol{z}\|_{\mathbb{T}}\leqslant 1\}$ 为于 $\mathbb{R}^n$ 的范数 $\|\cdot\|_{\mathbb{T}}$ 的单位球，$\boldsymbol{x}\in\mathbb{T}$ 为未知信号，观测 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}\in\mathbb{R}^m$，其中 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 矩阵。考虑通过求解以下范数最小化凸优化问题，估计信号：

$$\hat{\boldsymbol{x}}\in\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\|\boldsymbol{z}\|_{\mathbb{T}} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z}=\boldsymbol{y}。$$

证明：定理 T9.4.4 (约束恢复) 的误差界对此优化程序的解亦成立，

$$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \frac{CK^2w(\mathbb{T})}{\sqrt{m}}，\ \mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2 \leqslant \frac{CK^4w(\mathbb{T})^2}{m}。$$

证明 (信号 $\boldsymbol{x}$ 可行且 $\|\boldsymbol{x}\|_{\mathbb{T}}\leqslant 1$；最优性给出 $\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant\|\boldsymbol{x}\|_{\mathbb{T}}$，故 $\hat{\boldsymbol{x}}\in\mathbb{T}$。)

- 将误差向量归约至截面几何

  设 $\boldsymbol{x},\hat{\boldsymbol{x}}\in\mathbb{T}$，满足 $\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，则

  $$\hat{\boldsymbol{x}}-\boldsymbol{x}\in\mathbb{T}-\mathbb{T}，\ \boldsymbol{A}(\hat{\boldsymbol{x}}-\boldsymbol{x})=\boldsymbol{0}，\text{因此}\hat{\boldsymbol{x}}-\boldsymbol{x}\in\ker\boldsymbol{A}，$$

  因此 $\hat{\boldsymbol{x}}-\boldsymbol{x}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}$，即 $\boldsymbol{x},\hat{\boldsymbol{x}}\in\mathbb{T}\cap(\boldsymbol{x}+\ker\boldsymbol{A})$，从而

  $$\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \operatorname{diam}(\mathbb{T}\cap(\boldsymbol{x}+\ker\boldsymbol{A})) \leqslant \sup_{\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}}\|\boldsymbol{u}\|_2。 \tag{I}$$

- 根据矩阵偏离不等式得出误差上界

  对于任意的 $\boldsymbol{u}\in(\mathbb{T}-\mathbb{T})\cap\ker\boldsymbol{A}$，由于 $\boldsymbol{A}\boldsymbol{u}=\boldsymbol{0}$，因此

  $$\sqrt{m}\|\boldsymbol{u}\|_2=\big|\|\boldsymbol{A}\boldsymbol{u}\|_2-\sqrt{m}\|\boldsymbol{u}\|_2\big| \leqslant \sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|,$$

  两侧同除以 $\sqrt{m}$，代入于 (I)，之后两侧取期望，可得

  $$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant \frac{1}{\sqrt{m}}\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right],$$

  根据定理 T9.1.1 (矩阵偏离不等式)，可得

  $$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}-\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right] \leqslant C_1K^2w(\mathbb{T}-\mathbb{T})=2C_1K^2w(\mathbb{T}),$$

  即

  $$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \frac{CK^2w(\mathbb{T})}{\sqrt{m}}。 \qquad (C=2C_1)$$

  同理，根据习题 Q9.17 (约束恢复：均方误差)，可得

  $$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2^2 \leqslant \frac{C'K^4w(\mathbb{T})^2}{m}。$$

注释 若真值信号 $\boldsymbol{x}\neq\boldsymbol{0}$ 不于单位球，令 $\boldsymbol{x}_0=\boldsymbol{x}/\|\boldsymbol{x}\|_{\mathbb{T}}\in\mathbb{T}$，则其解为 $\hat{\boldsymbol{x}}_0=\hat{\boldsymbol{x}}/\|\boldsymbol{x}\|_{\mathbb{T}}$，可直接推广为相对误差界，

$$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2 \leqslant \frac{CK^2w(\mathbb{T})}{\sqrt{m}}\|\boldsymbol{x}\|_{\mathbb{T}}。$$

在压缩感知基追踪 (Basis Pursuit) 中，令 $\|\cdot\|_{\mathbb{T}}=\|\cdot\|_1$，$\mathbb{T}=\mathbb{B}_1^n$，优化问题即转化为经典基追踪：

$$\arg\min\|\boldsymbol{z}\|_1 \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z}=\boldsymbol{y}。$$

若 $\boldsymbol{x}$ 为 s-稀疏信号并且归一化 $\|\boldsymbol{x}\|_1 \leqslant 1$，则其 Gaussian 宽度满足 $w(\mathbb{B}_1^n) \asymp \sqrt{\ln n}$。

19 [**约束优化**] 将定理 T9.4.4 (约束恢复) 推广至噪声模型：

$$\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{w},$$

其中 $\boldsymbol{w}$ 为未知噪声向量 (甚至可能依赖于 $\boldsymbol{A}$)。
在 $\mathbb{T}$ 中选取使观测残差最小的向量：

$$\hat{\boldsymbol{x}} \in \arg\min_{\boldsymbol{z}\in\mathbb{T}} \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{z}\|_2。$$

证明：解 $\hat{\boldsymbol{x}}$ 满足

$$\mathrm{E}\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \lesssim \frac{K^2 w(\mathbb{T}) + \mathrm{E}\|\boldsymbol{w}\|_2}{\sqrt{m}}。$$

证明

- 利用最优性控制 $\|\boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2$

  由最优性，

  $$\|\boldsymbol{y} - \boldsymbol{A}\hat{\boldsymbol{x}}\| \leqslant \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|,$$

  代入 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{w}$，可得

  $$\|\boldsymbol{w} - \boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2 \leqslant \|\boldsymbol{w}\|_2。$$

  对于左侧，利用 Euclidean 范数的反三角不等式 $\|\boldsymbol{a} - \boldsymbol{b}\|_2 \geqslant \|\boldsymbol{a}\|_2 - \|\boldsymbol{b}\|_2$，可得

  $$\|\boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2 - \|\boldsymbol{w}\|_2 \leqslant \|\boldsymbol{w} - \boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2,$$

  将其代入，可得

  $$\|\boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2 \leqslant 2\|\boldsymbol{w}\|_2。 \tag{I}$$

- 根据矩阵偏离不等式建立下界

  令误差向量为 $\boldsymbol{h} = \hat{\boldsymbol{x}} - \boldsymbol{x} \in \mathbb{T} - \mathbb{T}$。

  利用实数绝对值不等式 $a - b \leqslant |a - b|$，可得

  $$\sqrt{m}\|\boldsymbol{h}\|_2 - \|\boldsymbol{A}\boldsymbol{h}\|_2 \leqslant \big|\|\boldsymbol{A}\boldsymbol{h}\|_2 - \sqrt{m}\|\boldsymbol{h}\|_2\big|。$$

  两侧对 $\boldsymbol{h} \in \mathbb{T} - \mathbb{T}$ 取上确界，

  $$\sqrt{m}\|\boldsymbol{h}\|_2 - \|\boldsymbol{A}\boldsymbol{h}\|_2 \leqslant \sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|,$$

  即

  $$\sqrt{m}\|\boldsymbol{h}\|_2 \leqslant \|\boldsymbol{A}\boldsymbol{h}\|_2 + \sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|。 \tag{II}$$

  将 (I) 代入于 (II)，可得

  $$\sqrt{m}\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \leqslant 2\|\boldsymbol{w}\|_2 + \sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|。$$

  两侧除以 $\sqrt{m}$，

  $$\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \leqslant \frac{2\|\boldsymbol{w}\|_2}{\sqrt{m}} + \frac{1}{\sqrt{m}} \sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|, \tag{III}$$

  之后两侧取期望，

  $$\mathrm{E}[\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2] \leqslant \frac{2\mathrm{E}[\|\boldsymbol{w}\|_2]}{\sqrt{m}} + \frac{1}{\sqrt{m}} \mathrm{E}\left[\sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|\right]。 \tag{IV}$$

  根据定理 T9.1.1 (矩阵偏离不等式)，可得

  $$\mathrm{E}\left[\sup_{\boldsymbol{u}\in\mathbb{T}-\mathbb{T}} \big|\|\boldsymbol{A}\boldsymbol{u}\|_2 - \sqrt{m}\|\boldsymbol{u}\|_2\big|\right] \leqslant C_0 K^2 w(\mathbb{T} - \mathbb{T}) = 2C_0 K^2 w(\mathbb{T}),$$

代入于 (IV)，可得

$$\begin{aligned}\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] &\leqslant \frac{4C_0K^2w(\mathbb{T})+2\mathrm{E}[\|\boldsymbol{w}\|_2]}{\sqrt{m}}\\ &\leqslant C\frac{K^2w(\mathbb{T})+\mathrm{E}\|\boldsymbol{w}\|_2}{\sqrt{m}}。\end{aligned}\qquad (C=\max(4C_0,2))$$

注释 事实上，在统计恢复理论中，

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \lesssim \underbrace{\frac{K^2w(\mathbb{T})}{\sqrt{m}}}_{\text{结构欠采样误差}} + \underbrace{\frac{\mathrm{E}\|\boldsymbol{w}\|_2}{\sqrt{m}}}_{\text{噪声扰动误差}}。$$

当 $m \gtrsim K^4w(\mathbb{T})^2$ 时，第一项被压制；第二项衡量噪声对解的扰动，若 $\boldsymbol{w}\sim N(\boldsymbol{0},\sigma^2\boldsymbol{I}_m)$，则 $\|\boldsymbol{w}\|_2\sim\sigma\sqrt{m}$ (w.h.p.)，此时 $\|\boldsymbol{w}\|_2/\sqrt{m}\sim\sigma$，这说明此带约束最小二乘算法达到了噪声水平 σ 的最优收敛率。

20 [无约束优化] 严格陈述并证明注记 R9.4.7 (无约束优化)。对于带噪声恢复，约束 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$ 可能不可行；通过惩罚残差构造无约束恢复程序。

设 $\boldsymbol{x}\in\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立, 各向同性的 K-sub-Gaussian 随机向量。考虑噪声线性模型

$$\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{w},$$

其中 $\boldsymbol{x}\neq\boldsymbol{0}$ 与 $\boldsymbol{w}\neq\boldsymbol{0}$ 为固定向量。为通过 $\boldsymbol{y},\boldsymbol{A}$ 恢复 $\boldsymbol{x}$，考虑无约束凸问题

$$\hat{\boldsymbol{x}}\in\arg\min_{\boldsymbol{x}\in\mathbb{R}^n}\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{x}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}},$$

其中 $\|\cdot\|_{\mathbb{T}}$ 为任意的范数。取理论上的 oracle 参数 $\lambda=\|\boldsymbol{w}\|_2^2/\|\boldsymbol{x}\|_{\mathbb{T}}$；此参数依赖于未知的真值与噪声，仅用于建立基准界。证明解 $\hat{\boldsymbol{x}}$ 满足

$$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2\lesssim\frac{K^2w(\mathbb{T})\|\boldsymbol{x}\|_{\mathbb{T}}+\|\boldsymbol{w}\|_2}{\sqrt{m}},$$

其中 $\mathbb{T}$ 为 $\|\cdot\|_{\mathbb{T}}$ 的单位球。

证明 • 建立优化问题的基本不等式

令误差向量为 $\boldsymbol{h}=\hat{\boldsymbol{x}}-\boldsymbol{x}$，则

$$\boldsymbol{y}-\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}。$$

题设已经排除了 $\boldsymbol{x}=\boldsymbol{0}$ 与 $\boldsymbol{w}=\boldsymbol{0}$ 的退化情形。

由于 $\hat{\boldsymbol{x}}$ 是无约束目标函数的全局极小值点，因此

$$\|\boldsymbol{y}-\boldsymbol{A}\hat{\boldsymbol{x}}\|_2^2+\lambda\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{x}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}},$$

即

$$\|\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}\|_2^2+\lambda\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant\|\boldsymbol{w}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}}。\qquad (\mathrm{I})$$

• 双向控制先验范数同残差

(首先控制误差向量的先验范数 $\|\boldsymbol{h}\|_{\mathbb{T}}$。)

利用 (I) 的结论，可得

$$\lambda\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant\|\boldsymbol{w}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}}，\text{因此}\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant\|\boldsymbol{x}\|_{\mathbb{T}}+\frac{\|\boldsymbol{w}\|_2^2}{\lambda},$$

令调谐参数 $\lambda=\|\boldsymbol{w}\|_2^2/\|\boldsymbol{x}\|_{\mathbb{T}}$，可得 $\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}\leqslant2\|\boldsymbol{x}\|_{\mathbb{T}}$，因此利用三角不等式，可得

$$\|\boldsymbol{h}\|_{\mathbb{T}}\leqslant\|\hat{\boldsymbol{x}}\|_{\mathbb{T}}+\|\boldsymbol{x}\|_{\mathbb{T}}\leqslant3\|\boldsymbol{x}\|_{\mathbb{T}},\qquad (\mathrm{II})$$

从而误差向量落入按比例缩放的单位球 $\boldsymbol{h}=\hat{\boldsymbol{x}}-\boldsymbol{x}\in3\|\boldsymbol{x}\|_{\mathbb{T}}\cdot\mathbb{T}$。

(之后控制预测残差 $\|\boldsymbol{A}\boldsymbol{h}\|_2$。)

同理，利用 (I) 的结论，可得

$$\|\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}\|_2^2\leqslant\|\boldsymbol{w}\|_2^2+\lambda\|\boldsymbol{x}\|_{\mathbb{T}},$$

代入 $\lambda=\|\boldsymbol{w}\|_2^2/\|\boldsymbol{x}\|_{\mathbb{T}}$ (即 $\lambda\|\boldsymbol{x}\|_{\mathbb{T}}=\|\boldsymbol{w}\|_2^2$)，可得

$$\|\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}\|_2^2\leqslant 2\|\boldsymbol{w}\|_2^2，\text{因此}\|\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}\|_2\leqslant\sqrt{2}\|\boldsymbol{w}\|_2。$$

因此利用反三角不等式 $\|\boldsymbol{A}\boldsymbol{h}\|_2-\|\boldsymbol{w}\|_2\leqslant\|\boldsymbol{w}-\boldsymbol{A}\boldsymbol{h}\|_2$，可得

$$\|\boldsymbol{A}\boldsymbol{h}\|_2\leqslant(\sqrt{2}+1)\|\boldsymbol{w}\|_2。\tag{III}$$

- 根据矩阵偏离不等式

定义缩放之后的集合 $\mathbb{S}=3\|\boldsymbol{x}\|_{\mathbb{T}}\cdot\mathbb{T}$，则 $\boldsymbol{h}\in\mathbb{S}$。

对于 $\boldsymbol{h}\in\mathbb{S}$，利用三角不等式，

$$\sqrt{m}\|\boldsymbol{h}\|_2\leqslant\|\boldsymbol{A}\boldsymbol{h}\|_2+\sup_{\boldsymbol{u}\in\mathbb{S}}\big|\|\boldsymbol{A}\boldsymbol{u}\|_2-\sqrt{m}\|\boldsymbol{u}\|_2\big|,\tag{IV}$$

将 (IV) 代入于 (III)，可得

$$\sqrt{m}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2\leqslant(\sqrt{2}+1)\|\boldsymbol{w}\|_2+\sup_{\boldsymbol{u}\in3\|\boldsymbol{x}\|_{\mathbb{T}}\cdot\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{u}\|_2-\sqrt{m}\|\boldsymbol{u}\|_2\big|,$$

其中

$$\sup_{\boldsymbol{u}\in c\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{u}\|_2-\sqrt{m}\|\boldsymbol{u}\|_2\big|=c\sup_{\boldsymbol{v}\in\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|,$$

两侧同除以 $\sqrt{m}$，

$$\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2\leqslant\frac{(\sqrt{2}+1)\|\boldsymbol{w}\|_2}{\sqrt{m}}+\frac{3\|\boldsymbol{x}\|_{\mathbb{T}}}{\sqrt{m}}\sup_{\boldsymbol{v}\in\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|。\tag{V}$$

对 (V) 的两侧取期望，

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant\frac{(\sqrt{2}+1)\mathrm{E}[\|\boldsymbol{w}\|_2]}{\sqrt{m}}+\frac{3\|\boldsymbol{x}\|_{\mathbb{T}}}{\sqrt{m}}\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right],$$

其中根据定理 T9.1.1 (矩阵偏离不等式)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{v}\in\mathbb{T}}\big|\|\boldsymbol{A}\boldsymbol{v}\|_2-\sqrt{m}\|\boldsymbol{v}\|_2\big|\right]\leqslant C_0K^2w(\mathbb{T})。$$

将其代入，可得

$$\begin{aligned}\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]&\leqslant\frac{3C_0K^2w(\mathbb{T})\|\boldsymbol{x}\|_{\mathbb{T}}}{\sqrt{m}}+\frac{(\sqrt{2}+1)\mathrm{E}[\|\boldsymbol{w}\|_2]}{\sqrt{m}}\\&\lesssim\frac{K^2w(\mathbb{T})\|\boldsymbol{x}\|_{\mathbb{T}}+\|\boldsymbol{w}\|_2}{\sqrt{m}}。\end{aligned}$$

注释 对于统计机器学习，若取 $\|\cdot\|_{\mathbb{T}}=\|\cdot\|_1$，则此优化问题即为经典 LASSO 算法

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\frac{1}{2}\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{z}\|_2^2+\lambda\|\boldsymbol{z}\|_1。$$

21 [**Lasso**] 将习题 Q9.20 (无约束优化) 特化于 ℓ_1 范数，分析 Lasso 稀疏回归方法。

设 $\boldsymbol{x}\in\mathbb{R}^n$ 为 s-稀疏向量，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量为相互独立, 各向同性的 K-sub-Gaussian 随机向量。考虑噪声线性模型

$$\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{w}。$$

为通过 $\boldsymbol{y},\boldsymbol{A}$ 恢复 $\boldsymbol{x}$，考虑以下无约束凸问题：

$$\arg\min_{\boldsymbol{x}\in\mathbb{R}^n}\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{x}\|_2^2+\lambda\|\boldsymbol{x}\|_1。$$

证明：在 $\boldsymbol{x}\neq\boldsymbol{0}$ 与 $\boldsymbol{w}\neq\boldsymbol{0}$ 时，取 oracle 参数 $\lambda=\|\boldsymbol{w}\|_2^2/\|\boldsymbol{x}\|_1$，则解 $\hat{\boldsymbol{x}}$ 满足

$$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2\lesssim\frac{K^2\sqrt{s\ln n}\|\boldsymbol{x}\|_1+\|\boldsymbol{w}\|_2}{\sqrt{m}}。$$

证明 根据习题 Q9.20 (无约束优化)，可得对于任意的范数 $\|\cdot\|_{\mathbb{T}}$，若令调谐参数 $\lambda=\|\boldsymbol{w}\|_2^2/\|\boldsymbol{x}\|_{\mathbb{T}}$，则无约束优化程序

$$\hat{\boldsymbol{x}}\in\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}(\|\boldsymbol{y}-\boldsymbol{A}\boldsymbol{z}\|_2^2+\lambda\|\boldsymbol{z}\|_{\mathbb{T}})$$

的解 $\hat{\boldsymbol{x}}$ 严格满足误差界

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant C\frac{K^2w(\mathbb{T})\|\boldsymbol{x}\|_{\mathbb{T}}+\|\boldsymbol{w}\|_2}{\sqrt{m}}。\tag{I}$$

对于 Lasso 算法，令惩罚范数为 $\|\cdot\|_{\mathbb{T}}=\|\cdot\|_1$，此时 $\mathbb{T}=\mathbb{B}_1^n$，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant C\frac{K^2w(\mathbb{B}_1^n)\|\boldsymbol{x}\|_1+\|\boldsymbol{w}\|_2}{\sqrt{m}}.\tag{II}$$

根据 Gaussian 宽度的定义，设 $\boldsymbol{g}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$ 为标准 Gaussian 随机向量：

$$w(\mathbb{B}_1^n)=\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{B}_1^n}\langle\boldsymbol{g},\boldsymbol{z}\rangle\right]=\mathrm{E}\|\boldsymbol{g}\|_\infty=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|g_i|\right],$$

则利用 Jensen 不等式，可得对于任意的 $\beta>0$，

$$\mathrm{e}^{\beta\mathrm{E}[\max_{1\leqslant i\leqslant n}|g_i|]}\leqslant\mathrm{E}\left[\exp\left(\beta\max_{1\leqslant i\leqslant n}|g_i|\right)\right]\leqslant\sum_{i=1}^n\mathrm{E}[\mathrm{e}^{\beta|g_i|}]\leqslant 2n\exp\left(\frac{\beta^2}{2}\right)。$$

两侧取对数并同除以 β，

$$\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|g_i|\right]\leqslant\frac{\ln(2n)}{\beta}+\frac{\beta}{2}。$$

右侧的最优参数为 $\beta_0=\sqrt{2\ln(2n)}$，将其代入，可得

$$w(\mathbb{B}_1^n)=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|g_i|\right]\leqslant\sqrt{2\ln(2n)}\leqslant C_0\sqrt{\ln n}.\tag{III}$$

将 (III) 代入于 (II)，可得

$$\begin{aligned}\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]&\leqslant C\frac{C_0K^2\sqrt{\ln n}\|\boldsymbol{x}\|_1+\|\boldsymbol{w}\|_2}{\sqrt{m}}\\&\lesssim\frac{K^2\sqrt{s\ln n}\|\boldsymbol{x}\|_1+\|\boldsymbol{w}\|_2}{\sqrt{m}}。\end{aligned}$$

注释 对于任意的 s-稀疏向量 $\boldsymbol{x}$，利用 Cauchy-Schwarz 不等式，可得

$$\|\boldsymbol{x}\|_1=\sum_{i\in\mathrm{supp}(\boldsymbol{x})}|x_i|\leqslant\sqrt{s}\left(\sum_{i\in\mathrm{supp}(\boldsymbol{x})}x_i^2\right)^{1/2}=\sqrt{s}\|\boldsymbol{x}\|_2,$$

因此

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\lesssim\frac{K^2s\sqrt{\ln n}\|\boldsymbol{x}\|_2+\|\boldsymbol{w}\|_2}{\sqrt{m}},$$

这说明若保证相对估计误差控制于 ε，所需的测量样本数仅需 $m\gtrsim s^2\ln n$ (若结合切锥局部 Gaussian 宽度分析，可进一步优化至 $m\gtrsim s\ln(n/s)$)。

22 [**稀疏恢复问题是良定义的**] 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 满行秩，并给出一般位置的合理定义。

(1) 证明：若 $m\geqslant 2s$，则方程 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$ 至多存在 1 个 s-稀疏解 (若解存在)。

(2) 若 (1) 成立，且已知 $\mathrm{supp}(\boldsymbol{x})$ (即哪些分量为非零)，试求高效地计算 $\boldsymbol{x}$ 的方案。

证明 (1) 称矩阵 $\boldsymbol{A}$ 位于一般位置，若其任意的 m 个列向量均线性无关 (等价地，$\mathrm{spark}(\boldsymbol{A})=m+1$；在 $m\leqslant n$ 且满行秩时，这也等价于任意 $m\times m$ 阶子式的行列式非零；若 $\boldsymbol{A}$ 的列从连续分布独立抽样，例如 Gaussian 随机矩阵，则以概率 1 处于一般位置)。

利用反证法，假设存在互不相同的 s-稀疏解 $\boldsymbol{x}_1,\boldsymbol{x}_2\in\mathbb{R}^n$，均满足观测方程 $\boldsymbol{A}\boldsymbol{x}_1=\boldsymbol{A}\boldsymbol{x}_2=\boldsymbol{y}$，$\|\boldsymbol{x}_1\|_0,\|\boldsymbol{x}_2\|_0\leqslant s$。

令 $\boldsymbol{h}=\boldsymbol{x}_1-\boldsymbol{x}_2$。

1. 由于

$$\boldsymbol{A}\boldsymbol{h}=\boldsymbol{A}(\boldsymbol{x}_1-\boldsymbol{x}_2)=\boldsymbol{A}\boldsymbol{x}_1-\boldsymbol{A}\boldsymbol{x}_2=\boldsymbol{y}-\boldsymbol{y}=\boldsymbol{0},$$

因此 $\boldsymbol{h}\in\ker\boldsymbol{A}$。

2. 由于

$$\operatorname{supp}(\boldsymbol{h})=\operatorname{supp}(\boldsymbol{x}_1-\boldsymbol{x}_2)\subset\operatorname{supp}(\boldsymbol{x}_1)\cup\operatorname{supp}(\boldsymbol{x}_2),$$

因此 $\|\boldsymbol{h}\|_0=|\operatorname{supp}(\boldsymbol{h})|\leqslant|\operatorname{supp}(\boldsymbol{x}_1)|+|\operatorname{supp}(\boldsymbol{x}_2)|\leqslant s+s=2s\leqslant m$。

将方程 $\boldsymbol{A}\boldsymbol{h}=\boldsymbol{0}$ 限制于非零分量集合 $\mathbb{S}_0=\operatorname{supp}(\boldsymbol{h})$，可得

$$\boldsymbol{A}\boldsymbol{h}=\sum_{j\in\mathbb{S}_0}h_j\boldsymbol{a}_j=\boldsymbol{A}_{\mathbb{S}_0}\boldsymbol{h}_{\mathbb{S}_0}=\boldsymbol{0},$$

其中 $\boldsymbol{A}_{\mathbb{S}_0}\in\mathbb{R}^{m\times|\mathbb{S}_0|}$ 为 $\boldsymbol{A}$ 限制到 $\mathbb{S}_0$ 的子矩阵，$\boldsymbol{h}_{\mathbb{S}_0}\in\mathbb{R}^{|\mathbb{S}_0|}$ 为 $\boldsymbol{h}$ 限制于 $\mathbb{S}_0$ 的非零分量向量。

由于 $|\mathbb{S}_0|\leqslant m$，$\boldsymbol{A}$ 位于一般位置，因此列向量 $\{\boldsymbol{a}_j\}_{j\in\mathbb{S}_0}$ 是线性无关的，即 $\boldsymbol{A}_{\mathbb{S}_0}$ 满列秩，从而齐次方程组 $\boldsymbol{A}_{\mathbb{S}_0}\boldsymbol{h}_{\mathbb{S}_0}=\boldsymbol{0}$ 只有零解，可得 $\boldsymbol{h}_{\mathbb{S}_0}=\boldsymbol{0}$。

注意到 $\boldsymbol{h}$ 于 $\mathbb{S}_0$ 以外的分量本身为 0，因此 $\boldsymbol{h}=\boldsymbol{0}$，即 $\boldsymbol{x}_1=\boldsymbol{x}_2$。这与假设 $\boldsymbol{x}_1\neq\boldsymbol{x}_2$ 矛盾；如此，当 $m\geqslant 2s$ 时，方程 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$ 至多存在 1 个 s-稀疏解。

(2) 设 $\mathbb{S}=\operatorname{supp}(\boldsymbol{x})\subset\{1,2,\cdots,n\}$，$|\mathbb{S}|=k\leqslant s\leqslant m/2$。

由于 $\mathbb{S}$ 以外的分量均为 0，因此原方程简化为

$$\boldsymbol{y}=\boldsymbol{A}_{\mathbb{S}}\boldsymbol{x}_{\mathbb{S}},$$

其中 $\boldsymbol{A}_{\mathbb{S}}\in\mathbb{R}^{m\times k}$ 为 $\boldsymbol{A}$ 限制到 $\mathbb{S}$ 的列子矩阵，$\boldsymbol{x}_{\mathbb{S}}\in\mathbb{R}^k$ 为待求的非零向量。

由于 $\boldsymbol{A}$ 位于一般位置，$k\leqslant m$，因此 $\boldsymbol{A}_{\mathbb{S}}$ 满列秩，可得 $\boldsymbol{A}_{\mathbb{S}}^{\top}\boldsymbol{A}_{\mathbb{S}}\in\mathbb{R}^{k\times k}$ 对称正定可逆，从而解有唯一的闭式表达

$$\boldsymbol{x}_{\mathbb{S}}=(\boldsymbol{A}_{\mathbb{S}}^{\top}\boldsymbol{A}_{\mathbb{S}})^{-1}\boldsymbol{A}_{\mathbb{S}}^{\top}\boldsymbol{y}=\boldsymbol{A}_{\mathbb{S}}^{\dagger}\boldsymbol{y}。$$

(直接计算逆矩阵 $(\boldsymbol{A}_{\mathbb{S}}^{\top}\boldsymbol{A}_{\mathbb{S}})^{-1}$ 容易导致数值病态，此处利用 QR 分解。)

1. 提取子矩阵 $\boldsymbol{A}_{\mathbb{S}}$，计算其经济型 QR 分解 $\boldsymbol{A}_{\mathbb{S}}=\boldsymbol{Q}\boldsymbol{R}$，其中 $\boldsymbol{Q}\in\mathbb{R}^{m\times k}$ 满足 $\boldsymbol{Q}^{\top}\boldsymbol{Q}=\boldsymbol{I}_k$，$\boldsymbol{R}\in\mathbb{R}^{k\times k}$ 为上三角可逆矩阵。

2. 计算 $\boldsymbol{c}=\boldsymbol{Q}^{\top}\boldsymbol{y}\in\mathbb{R}^k$，通过回代法求解上三角方程组 $\boldsymbol{R}\boldsymbol{x}_{\mathbb{S}}=\boldsymbol{c}$；最后重构全向量 $\boldsymbol{x}$，于 $\mathbb{S}$ 填入 $\boldsymbol{x}_{\mathbb{S}}$，其余位置置 0。

QR 分解 (利用 Householder 变换或 Gram-Schmidt 正交化) 的计算复杂度为 $O(mk^2)$，正交投影 $\boldsymbol{c}=\boldsymbol{Q}^{\top}\boldsymbol{y}$ 为 $O(mk)$，回代求解为 $O(k^2)$，总时间复杂度为 $O(mk^2)\leqslant O(ms^2)$。由于在压缩感知场景中，稀疏度极小 ($s\ll n$)，因此计算耗时仅与小规模矩阵 $m\times k$ 相关，运算速度极快。

注释 对于 (1)，在信息论中，$m\geqslant 2s$ 是保证信号无歧义恢复的绝对下界 (自由度守恒：任一非零元需要 1 个测量确定位置，1 个测量确定数值)；先知最优性 (Oracle Property)。

对于 (2)，其解被称为 Oracle 最小二乘估计量。若观测包含 Gaussian 白噪声 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{w}$ ($\boldsymbol{w}\sim N(\boldsymbol{0},\sigma^2\boldsymbol{I})$)，则

$$\mathrm{E}[\|\boldsymbol{x}_{\mathbb{S}}-\boldsymbol{x}_{\mathbb{S}}^*\|_2^2\mid\boldsymbol{A}]=\sigma^2\operatorname{tr}((\boldsymbol{A}_{\mathbb{S}}^{\top}\boldsymbol{A}_{\mathbb{S}})^{-1})。$$

若进一步有 $\sigma_{\min}(\boldsymbol{A}_{\mathbb{S}}),\sigma_{\max}(\boldsymbol{A}_{\mathbb{S}})\asymp\sqrt{m}$，则

$$\mathrm{E}[\|\boldsymbol{x}_{\mathbb{S}}-\boldsymbol{x}_{\mathbb{S}}^*\|_2^2\mid\boldsymbol{A}]\asymp\sigma^2k/m;$$

此条件式达到 Cramér–Rao 下界。

23 [**当 $0\leqslant p<1$ 时的 p 范数**] (9.21) 将 $\|\boldsymbol{x}\|_0$ 定义为向量 $\boldsymbol{x}$ 的非零分量个数。

(1) 证明：$\|\cdot\|_0$ 不是于 $\mathbb{R}^n$ 的范数。

(2) 证明：若 $0<p<1$，则 $\|\cdot\|_p$ 不是 $\mathbb{R}^n$ 的范数 (图 9.10 显示单位球不是凸的)。

(3) 证明：对于任意的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$\|\boldsymbol{x}\|_0=\lim_{p\to0^+}\|\boldsymbol{x}\|_p^p。$$

证明 (1) 令 $\boldsymbol{x}=\boldsymbol{e}_1=(1,0,\cdots,0)$, $\alpha=2$，则 $\|\alpha\boldsymbol{x}\|_0=\|(2,0,\cdots,0)\|_0=1$，但是 $|\alpha|\cdot\|\boldsymbol{x}\|_0=2\cdot1=2$，即

$$\|\alpha\boldsymbol{x}\|_0=1\neq2=|\alpha|\cdot\|\boldsymbol{x}\|_0,$$

因此 $\|\cdot\|_0$ 不是于 $\mathbb{R}^n$ 的范数。(通常称其为 ℓ_0 伪范数或计数度量)

(2) 令 $\boldsymbol{x}=\boldsymbol{e}_1$，$\boldsymbol{y}=\boldsymbol{e}_2$，则 $\|\boldsymbol{x}\|_p=\|\boldsymbol{y}\|_p=1$，但是 $\|\boldsymbol{x}+\boldsymbol{y}\|_p=(1^p+1^p)^{1/p}=2^{1/p}>2^1=2$，即

$$\|\boldsymbol{x}+\boldsymbol{y}\|_p\not\leqslant\|\boldsymbol{x}\|_p+\|\boldsymbol{y}\|_p=2,$$

因此 $\|\cdot\|_p$ 不是范数。

(或者利用几何验证。当 $0<p<1$ 时，令 $\boldsymbol{e}_1,\boldsymbol{e}_2\in\mathbb{B}_p^n$，其中 $\boldsymbol{m}=\frac{1}{2}\boldsymbol{e}_1+\frac{1}{2}\boldsymbol{e}_2$ 满足

$$\|\boldsymbol{m}\|_p=\left(2\cdot\left(\frac{1}{2}\right)^p\right)^{1/p}=2^{1/p-1}>1,$$

即中点落于单位球的外部，这与任意范数的闭单位球必定为凸集所矛盾。)

(3) 对固定的 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$，若 $x_i\neq0$，则 $|x_i|^p=\mathrm{e}^{p\ln|x_i|}\to1$ $(p\to0^+)$；若 $x_i=0$，则 $|x_i|^p=0$ 恒成立。因此，有限项求和同极限过程可以交换：

$$\|\boldsymbol{x}\|_p^p=\sum_{i=1}^n|x_i|^p\to\sum_{i=1}^n\mathbf{1}_{\{x_i\neq0\}}=\#\{i:x_i\neq0\}=\|\boldsymbol{x}\|_0。$$

注释 $\|\cdot\|_0$ 记为 ℓ_p 伪范数在 $p\to0^+$ 时的代数极限。

当 $p\in(0,1)$ 时，ℓ_p 极小化逼近 ℓ_0，但仍非凸；$p=1$ 是保证目标函数为凸函数的最小临界点 (凸包边界)，因此用 ℓ_1 范数替代 ℓ_0 范数 (Basis Pursuit / Lasso) 是将非凸组合转化为高维凸优化的最紧的松弛方案。

24 [**近似稀疏恢复**] 将推论 C9.4.8 (稀疏恢复) 推广至近似稀疏信号。

(1) 证明：任意的 s-稀疏信号 $\boldsymbol{x}$ 可通过求解以下优化问题

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\|\boldsymbol{z}\|_1\quad\text{s.t.}\quad\boldsymbol{y}=\boldsymbol{A}\boldsymbol{z}$$

通过测量 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$ 恢复，其解 $\hat{\boldsymbol{x}}$ 的恢复误差为

$$\mathrm{E}\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2\leqslant CK^2\sqrt{\frac{s\ln n}{m}}\|\boldsymbol{x}\|_2。$$

(2) 证明：上述结论对于近似稀疏信号仍然成立。

证明 (1) 根据习题 Q9.18 (通过优化恢复)，可得对于 $\mathbb{R}^n$ 的任意的范数 $\|\cdot\|_{\mathbb{T}}$ (其单位球为 $\mathbb{T}$)，凸优化程序

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\|\boldsymbol{z}\|_1\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{z}=\boldsymbol{A}\boldsymbol{x}$$

的估计解 $\hat{\boldsymbol{x}}$ 满足

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant\frac{C_1K^2w(\mathbb{T})}{\sqrt{m}}\|\boldsymbol{x}\|_{\mathbb{T}},$$

将范数特化为 ℓ_1 范数 $\|\cdot\|_1$，其单位球为交叉多面体 $\mathbb{T}=\mathbb{B}_1^n$，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant\frac{C_1K^2w(\mathbb{B}_1^n)}{\sqrt{m}}\|\boldsymbol{x}\|_1,\tag{I}$$

之后只需计算 $w(\mathbb{B}_1^n),\|\boldsymbol{x}\|_1$。

对于 $w(\mathbb{B}_1^n)$，

$$w(\mathbb{B}_1^n)=\mathrm{E}\left[\sup_{\boldsymbol{z}\in\mathbb{B}_1^n}\langle\boldsymbol{g},\boldsymbol{z}\rangle\right]=\mathrm{E}[\|\boldsymbol{g}\|_\infty]=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}|g_i|\right]\leqslant C_0\sqrt{\ln n};$$

对于 $\|\boldsymbol{x}\|_1$，由于 $\boldsymbol{x}$ 为 s-稀疏向量，其非零元个数满足 $|\operatorname{supp}(\boldsymbol{x})|\leqslant s$，因此利用 Cauchy-Schwarz 不等式，可得

$$\|\boldsymbol{x}\|_1=\sum_{i\in\operatorname{supp}(\boldsymbol{x})}1\cdot|x_i|\leqslant\sqrt{|\operatorname{supp}(\boldsymbol{x})|}\left(\sum_{i\in\operatorname{supp}(\boldsymbol{x})}x_i^2\right)^{1/2}\leqslant\sqrt{s}\|\boldsymbol{x}\|_2;$$

将其代入于 (I)，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant \frac{C_2K^2\sqrt{\ln n}}{\sqrt{m}} \cdot (\sqrt{s}\|\boldsymbol{x}\|_2) = CK^2\sqrt{\frac{s\ln n}{m}}\|\boldsymbol{x}\|_2。$$

(2) 设 $\mathbb{S} \subset \{1,2,\cdots,n\}$ 为 $\boldsymbol{x}$ 的绝对值最大的 s 个分量所在的索引集合，$\boldsymbol{x}_s = \boldsymbol{x}|_{\mathbb{S}}$ 为最佳 s-项逼近，则尾部误差向量为 $\boldsymbol{x}-\boldsymbol{x}_s$，逼近误差记为 $\sigma_s(\boldsymbol{x})_1 = \|\boldsymbol{x}-\boldsymbol{x}_s\|_1$。

我们只需证明：对于任意的信号 $\boldsymbol{x} \in \mathbb{R}^n$ (无需严格稀疏)，凸优化问题

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1 \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x}$$

的解 $\hat{\boldsymbol{x}}$ 满足

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant CK^2\left(\sqrt{\frac{s\ln n}{m}}\|\boldsymbol{x}\|_2 + \frac{\sqrt{\ln n}}{\sqrt{m}}\|\boldsymbol{x}-\boldsymbol{x}_s\|_1\right)。$$

同理于 (1) 的结论，可得对于任意的信号 $\boldsymbol{x} \in \mathbb{R}^n$ (无论是否稀疏)，优化解 $\hat{\boldsymbol{x}}$ 均满足

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant \frac{C_2K^2\sqrt{\ln n}}{\sqrt{m}}\|\boldsymbol{x}\|_1。 \tag{II}$$

利用三角不等式，可得

$$\|\boldsymbol{x}\|_1 \leqslant \|\boldsymbol{x}_s\|_1 + \|\boldsymbol{x}-\boldsymbol{x}_s\|_1;$$

对于主干 $\boldsymbol{x}_s$，$|\mathrm{supp}(\boldsymbol{x}_s)| = s$ ($\|\boldsymbol{x}_s\|_0 \leqslant s$)，因此利用 Cauchy-Schwarz 不等式，可得

$$\|\boldsymbol{x}_s\|_1 \leqslant \sqrt{s}\|\boldsymbol{x}_s\|_2 \leqslant \sqrt{s}\|\boldsymbol{x}\|_2;$$

将其代入，可得

$$\|\boldsymbol{x}\|_1 \leqslant \sqrt{s}\|\boldsymbol{x}\|_2 + \|\boldsymbol{x}-\boldsymbol{x}_s\|_1; \tag{III}$$

将 (III) 代入于 (II)，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant \frac{C_2K^2\sqrt{\ln n}}{\sqrt{m}}(\sqrt{s}\|\boldsymbol{x}\|_2 + \|\boldsymbol{x}-\boldsymbol{x}_s\|_1) = CK^2\left(\sqrt{\frac{s\ln n}{m}}\|\boldsymbol{x}\|_2 + \frac{\sqrt{\ln n}}{\sqrt{m}}\|\boldsymbol{x}-\boldsymbol{x}_s\|_1\right)。$$

注释 观察恢复误差的结构，

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2] \leqslant K^2\left(\sqrt{\frac{s\ln n}{m}}\|\boldsymbol{x}\|_2 + \frac{\sqrt{\ln n}}{\sqrt{m}}\|\boldsymbol{x}-\boldsymbol{x}_s\|_1\right),$$

第一项为主干稀疏部分的重构误差，第二项为非稀疏尾部引起的模型截断误差，可得恢复误差满足以下性质：

1. 退化一致性：若 $\boldsymbol{x}$ 为 s-稀疏向量，则 $\|\boldsymbol{x}-\boldsymbol{x}_s\|_1 = 0$，退化为 (1) 的结论。
2. 渐近最优性 (Instance Optimality)：当测量数满足压缩感知标准临界阶 $m \asymp s\ln n$ 时，第一项衰减为 $O(\|\boldsymbol{x}\|_2)$，第二项转化为

$$\frac{\sqrt{\ln n}}{\sqrt{s\ln n}}\|\boldsymbol{x}-\boldsymbol{x}_s\|_1 = \frac{\|\boldsymbol{x}-\boldsymbol{x}_s\|_1}{\sqrt{s}},$$

即经典压缩感知的 Stechkin 逼近界。这说明即使信号存在非稀疏扰动，算法恢复也是鲁棒的。

25 [稀疏向量集合的凸化] 设

$$\mathbb{S}_{n,s} = \{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\|_0 \leqslant s,\ \|\boldsymbol{x}\|_2 \leqslant 1\}$$

为单位 s-稀疏向量的集合，

$$\mathbb{T}_{n,s} = \sqrt{s}\mathbb{B}_1^n \cap \mathbb{B}_2^n = \{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\|_1 \leqslant \sqrt{s},\ \|\boldsymbol{x}\|_2 \leqslant 1\}$$

为截断的 ℓ_1 球。证明：

$$\mathrm{conv}(\mathbb{S}_{n,s}) \subset \mathbb{T}_{n,s} \subset 2\,\mathrm{conv}(\mathbb{S}_{n,s})。$$

证明 证明 $\mathrm{conv}(\mathbb{S}_{n,s}) \subset \mathbb{T}_{n,s}$

设 $\boldsymbol{x}\in\mathbb{S}_{n,s}$，则 $\|\boldsymbol{x}\|_2\leqslant 1$，$\|\boldsymbol{x}\|_0=|\operatorname{supp}(\boldsymbol{x})|\leqslant s$。
利用 Cauchy-Schwarz 不等式，可得

$$\|\boldsymbol{x}\|_1=\sum_{j\in\operatorname{supp}(\boldsymbol{x})}1\cdot|x_j|\leqslant\sqrt{|\operatorname{supp}(\boldsymbol{x})|}\left(\sum_{j\in\operatorname{supp}(\boldsymbol{x})}x_j^2\right)^{1/2}\leqslant\sqrt{s}\|\boldsymbol{x}\|_2\leqslant\sqrt{s},$$

因此 $\|\boldsymbol{x}\|_1\leqslant\sqrt{s}$，$\|\boldsymbol{x}\|_2\leqslant 1$，即 $\boldsymbol{x}\in\mathbb{T}_{n,s}$，从而 $\mathbb{S}_{n,s}\subset\mathbb{T}_{n,s}$，可得 $\operatorname{conv}(\mathbb{S}_{n,s})\subset\mathbb{T}_{n,s}$。

- 证明 $\mathbb{T}_{n,s}\subset 2\operatorname{conv}(\mathbb{S}_{n,s})$

  设 $\boldsymbol{x}\in\mathbb{T}_{n,s}$，若 $\boldsymbol{x}=\boldsymbol{0}$，则结论是平凡的；之后只需考虑 $\boldsymbol{x}\neq\boldsymbol{0}$ 的情况。
  （将 $\operatorname{supp}(\boldsymbol{x})$ 划分为互不相交的子集 $I_1\sqcup I_2\sqcup\cdots$，其中 I_1 索引 $\boldsymbol{x}$ 的 s 个最大系数，I_2 索引随后的 s 个最大系数，依此类推。我们只需证明 $\sum_i\|\boldsymbol{x}_{I_i}\|_2\leqslant 2$，其中 $\boldsymbol{x}_I\in\mathbb{R}^I$ 表示 $\boldsymbol{x}$ 于集合 I 的限制。）
  不妨设 $\boldsymbol{x}$ 的分量以模长降序排列，即

$$|x_1|\geqslant|x_2|\geqslant\cdots\geqslant|x_n|,$$

  之后将指标集划分为 $\{1,2,\cdots,n\}=I_1\sqcup I_2\sqcup\cdots$，其中 $I_1=\{1,\cdots,s\}$，$I_2=\{s+1,\cdots,2s\}$，依此类推。
  令 $\boldsymbol{x}_{I_i}\in\mathbb{R}^n$ 为 $\boldsymbol{x}$ 于 I_i 的截断向量（于 I_i 与 $\boldsymbol{x}$ 一致，其余坐标置 0），则

$$\boldsymbol{x}=\sum_{i\geqslant 1}\boldsymbol{x}_{I_i},$$

  $\|\boldsymbol{x}_{I_i}\|_0=|I_i|\leqslant s$。

  - 估计各分块的 Euclidean 范数并求和

    记 $d_i=\|\boldsymbol{x}_{I_i}\|_2$。
    1. 对于首块，由于 $\|\boldsymbol{x}\|_2\leqslant 1$，因此 $d_1\leqslant 1$。
    2. 对于后续块 I_i $(i\geqslant 2)$，设 $j\in I_i,l\in I_{i-1}$，则 $|x_j|\leqslant|x_l|$，因此

$$|x_j|\leqslant\frac{1}{s}\sum_{l\in I_{i-1}}|x_l|=\frac{\|\boldsymbol{x}_{I_{i-1}}\|_1}{s},$$

    从而

$$d_i=\|\boldsymbol{x}_{I_i}\|_2=\left(\sum_{j\in I_i}x_j^2\right)^{1/2}\leqslant\left(|I_i|\cdot\left(\frac{\|\boldsymbol{x}_{I_{i-1}}\|_1}{s}\right)^2\right)^{1/2}\leqslant\frac{\|\boldsymbol{x}_{I_{i-1}}\|_1}{\sqrt{s}}。$$

    由于各块互不相交，ℓ_1 范数可加，可得

$$\sum_{i\geqslant 2}\|\boldsymbol{x}_{I_{i-1}}\|_1\leqslant\|\boldsymbol{x}\|_1,$$

    从而

$$\sum_{i\geqslant 1}d_i\leqslant d_1+\frac{1}{\sqrt{s}}\sum_{i\geqslant 2}\|\boldsymbol{x}_{I_{i-1}}\|_1\leqslant\|\boldsymbol{x}\|_2+\frac{\|\boldsymbol{x}\|_1}{\sqrt{s}}\leqslant 1+\frac{\sqrt{s}}{\sqrt{s}}=2。\tag{II}$$

  - 构造凸组合得出第二个包含

    对于满足 $d_i>0$ 的项，令 $\overline{\boldsymbol{x}_{I_i}}\in\mathbb{S}_{n,s}$，则 $\|\overline{\boldsymbol{x}_{I_i}}\|_0=|I_i|\leqslant s$。
    将 $\boldsymbol{x}$ 改写为

$$\boldsymbol{x}=\sum_i\boldsymbol{x}_{I_i}=\sum_i d_i\overline{\boldsymbol{x}_{I_i}}=\left(\sum_i d_i\right)\sum_i\frac{d_i}{\sum_j d_j}\overline{\boldsymbol{x}_{I_i}}。$$

    令 $M=\sum_i d_i\leqslant 2$（利用 (II) 的结论），$\boldsymbol{v}=\sum_i\frac{d_i}{\sum_j d_j}\overline{\boldsymbol{x}_{I_i}}$，则 $\boldsymbol{v}$ 为 $\mathbb{S}_{n,s}$ 元素的凸组合，即 $\boldsymbol{v}\in\operatorname{conv}(\mathbb{S}_{n,s})$。
    由于 $\boldsymbol{0}\in\operatorname{conv}(\mathbb{S}_{n,s})$，因此

$$\boldsymbol{x}=M\boldsymbol{v}=\left(1-\frac{M}{2}\right)\cdot\boldsymbol{0}+\frac{M}{2}\cdot(2\boldsymbol{v})\in 2\operatorname{conv}(\mathbb{S}_{n,s})。$$

从而 $\mathbb{T}_{n,s} \subset 2\operatorname{conv}(\mathbb{S}_{n,s})$。

26 [稀疏恢复的对数改进] (1) 利用习题 Q9.25 (稀疏向量集合的凸化)，证明：

$$w(\mathbb{T}_{n,s}) \leqslant 2w(\mathbb{S}_{n,s}) \leqslant C\sqrt{s\ln(en/s)}。$$

(2) 考虑有界先验下的恢复程序：对任意的 $\boldsymbol{x} \in \mathbb{S}_{n,s}$，令

$$\hat{\boldsymbol{x}} \in \arg\min_{\boldsymbol{z}\in\mathbb{T}_{n,s}} \|\boldsymbol{z}\|_1 \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x}。$$

利用 (1) 的结论，证明该稀疏恢复保证的对数因子可改进为

$$\mathrm{E}\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \leqslant CK^2\sqrt{\frac{s\ln(en/s)}{m}}。$$

因此 $m \gtrsim s\ln(en/s)$ 个测量就足够了。

证明 (1) 证明 $w(\mathbb{T}_{n,s}) \leqslant 2w(\mathbb{S}_{n,s})$

根据习题 Q9.25 (稀疏向量集合的凸化)，可得 $\mathbb{T}_{n,s} \subset 2\operatorname{conv}(\mathbb{S}_{n,s})$，两侧取 Gaussian 宽度，

$$w(\mathbb{T}_{n,s}) \leqslant w(2\operatorname{conv}(\mathbb{S}_{n,s})) = 2w(\operatorname{conv}(\mathbb{S}_{n,s})) = 2w(\mathbb{S}_{n,s})。$$

- 证明 $w(\mathbb{S}_{n,s}) \leqslant C\sqrt{s\ln(en/s)}$

设 $\boldsymbol{g} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$，注意到

$$\sup_{\boldsymbol{x}\in\mathbb{S}_{n,s}} \langle \boldsymbol{g}, \boldsymbol{x}\rangle = \max_{|I|=s} \|\boldsymbol{g}_I\|_2,$$

因此

$$w(\mathbb{S}_{n,s}) = \mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{S}_{n,s}} \langle \boldsymbol{g}, \boldsymbol{x}\rangle\right] = \mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2\right],$$

利用 Jensen 不等式，可得

$$w(\mathbb{S}_{n,s}) = \mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2\right] \leqslant \sqrt{\mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right]}。 \tag{I}$$

(之后只需控制 $\mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right]$ 即可。)

注意到 $\|\boldsymbol{g}_I\|_2^2 = \sum_{i\in I} g_i^2 \sim \chi^2(s)$。对极大值根据并集界，可得

$$\mathrm{E}\left[\exp\left(\lambda \max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right)\right] \leqslant \sum_{|I|=s} \mathrm{E}[\mathrm{e}^{\lambda\|\boldsymbol{g}_I\|_2^2}] = \binom{n}{s}(1-2\lambda)^{-s/2} \leqslant \left(\frac{en}{s}\right)^s (1-2\lambda)^{-s/2}。$$

两侧取对数并同除以 λ，

$$\mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right] \leqslant \frac{s}{\lambda}\ln\left(\frac{en}{s}\right) + \frac{s}{2\lambda}\ln\left(\frac{1}{1-2\lambda}\right)。$$

令 $\lambda = 1/4$ (此时 $1-2\lambda = 1/2$)，可得

$$\mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right] \leqslant 4s\ln\left(\frac{en}{s}\right) + 2s\ln 2 \leqslant C_0^2 s\ln\left(\frac{en}{s}\right), \tag{II}$$

将其代入于 (I)，可得

$$w(\mathbb{S}_{n,s}) = \mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2\right] \leqslant \sqrt{\mathrm{E}\left[\max_{|I|=s} \|\boldsymbol{g}_I\|_2^2\right]} \leqslant C_0\sqrt{s\ln\left(\frac{en}{s}\right)}。 \tag{III}$$

联立 (I)(III)，可得 $w(\mathbb{T}_{n,s}) \leqslant 2w(\mathbb{S}_{n,s}) \leqslant C\sqrt{s\ln(en/s)}$。

(2) - 利用于稀疏恢复：锥约束

设 $\boldsymbol{x} \in \mathbb{S}_{n,s}$，令 $\hat{\boldsymbol{x}}$ 满足

$$\hat{\boldsymbol{x}} \in \arg\min_{\boldsymbol{z}\in\mathbb{T}_{n,s}} \|\boldsymbol{z}\|_1 \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x},$$

记误差向量 $\boldsymbol{h}=\hat{\boldsymbol{x}}-\boldsymbol{x}$，则根据 $\hat{\boldsymbol{x}}$ 的极小性，可得 $\|\hat{\boldsymbol{x}}\|_1\leqslant\|\boldsymbol{x}\|_1$。

令误差向量 $\boldsymbol{h}=\hat{\boldsymbol{x}}-\boldsymbol{x}$，$\mathbb{S}=\operatorname{supp}(\boldsymbol{x})$，由于

$$\|\boldsymbol{x}\|_1=\|\boldsymbol{x}_{\mathbb{S}}\|_1\geqslant\|\hat{\boldsymbol{x}}\|_1=\|\boldsymbol{x}_{\mathbb{S}}+\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\geqslant\|\boldsymbol{x}_{\mathbb{S}}\|_1-\|\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{h}_{\mathbb{S}^c}\|_1,$$

因此 $\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\leqslant\|\boldsymbol{h}_{\mathbb{S}}\|_1$，从而

$$\|\boldsymbol{h}\|_1=\|\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\leqslant2\|\boldsymbol{h}_{\mathbb{S}}\|_1\leqslant2\sqrt{s}\|\boldsymbol{h}_{\mathbb{S}}\|_2\leqslant2\sqrt{s}\|\boldsymbol{h}\|_2。$$

若 $\boldsymbol{h}\neq\boldsymbol{0}$，记其归一化向量为 $\bar{\boldsymbol{h}}=\boldsymbol{h}/\|\boldsymbol{h}\|_2$，则 $\|\bar{\boldsymbol{h}}\|_2=1$，$\|\bar{\boldsymbol{h}}\|_1=\|\boldsymbol{h}\|_1/\|\boldsymbol{h}\|_2\leqslant2\sqrt{s}$，即

$$\bar{\boldsymbol{h}}\in2(\sqrt{s}\mathbb{B}_1^n\cap\mathbb{B}_2^n)=2\mathbb{T}_{n,s}。$$

- 利用于稀疏恢复：M^* 界，最终界

由于 $\boldsymbol{x},\hat{\boldsymbol{x}}\in\mathbb{T}_{n,s}$ 且 $\boldsymbol{A}\boldsymbol{h}=\boldsymbol{0}$，有 $\boldsymbol{h}\in2\mathbb{T}_{n,s}\cap\ker\boldsymbol{A}$。

根据定理 T9.3.1 (M^* 界)，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant\mathrm{E}[\operatorname{diam}(2\mathbb{T}_{n,s}\cap\ker\boldsymbol{A})]\leqslant\frac{C_1K^2w(2\mathbb{T}_{n,s})}{\sqrt{m}}=\frac{2C_1K^2w(\mathbb{T}_{n,s})}{\sqrt{m}}。\tag{IV}$$

将其代入于 (IV)，可得

$$\mathrm{E}[\|\hat{\boldsymbol{x}}-\boldsymbol{x}\|_2]\leqslant\frac{2C_1K^2\cdot C\sqrt{s\ln(en/s)}}{\sqrt{m}}=C'K^2\sqrt{\frac{s\ln(en/s)}{m}}。$$

这即为 $\boldsymbol{x}\in\mathbb{S}_{n,s}$ 时所需的结论。

27 [**稀疏向量的 Gaussian 宽度**] 设

$$\mathbb{S}_{n,s}=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_0\leqslant s,\ \|\boldsymbol{x}\|_2\leqslant1\}$$

为单位 s-稀疏向量集合，其截断的 ℓ_1 球 (近似凸包) 为

$$\mathbb{T}_{n,s}=\sqrt{s}\mathbb{B}_1^n\cap\mathbb{B}_2^n=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_1\leqslant\sqrt{s},\ \|\boldsymbol{x}\|_2\leqslant1\}。$$

证明：

$$w(\mathbb{T}_{n,s})\asymp w(\mathbb{S}_{n,s})\asymp\sqrt{s\ln(en/s)},$$

证明 根据习题 Q9.25 (稀疏向量集合的凸化)，可得 $\operatorname{conv}(\mathbb{S}_{n,s})\subset\mathbb{T}_{n,s}\subset2\operatorname{conv}(\mathbb{S}_{n,s})$，两侧取 Gaussian 宽度，

$$w(\operatorname{conv}(\mathbb{S}_{n,s}))\leqslant w(\mathbb{T}_{n,s})\leqslant w(2\operatorname{conv}(\mathbb{S}_{n,s})),$$

即

$$w(\mathbb{S}_{n,s})\leqslant w(\mathbb{T}_{n,s})\leqslant2w(\mathbb{S}_{n,s}),$$

即 $w(\mathbb{T}_{n,s})\asymp w(\mathbb{S}_{n,s})$。

(之后只需估计 $w(\mathbb{S}_{n,s})$。) 证明上界 $w(\mathbb{S}_{n,s})\leqslant C\sqrt{s\ln(en/s)}$

同理于习题 Q9.25 (稀疏向量集合的凸化) 的第 (1) 问，可得

$$w(\mathbb{S}_{n,s})=\mathrm{E}\left[\max_{|I|=s}\|\boldsymbol{g}_I\|_2\right]\leqslant\sqrt{\mathrm{E}\left[\max_{|I|=s}\|\boldsymbol{g}_I\|_2^2\right]}\leqslant C_1\sqrt{s\ln\left(\frac{en}{s}\right)}。\tag{II}$$

- 下界：$w(\mathbb{S}_{n,s})\geqslant c\sqrt{s\ln(en/s)}$

设 $|g|_{(1)}\geqslant|g|_{(2)}\geqslant\cdots\geqslant|g|_{(n)}$ 为分量模长 $|g_1|,\cdots,|g_n|$ 的降序次序统计，则

$$\max_{|I|=s}\|\boldsymbol{g}_I\|_2=\sqrt{\sum_{i=1}^{s}|g|_{(i)}^2}\geqslant\sqrt{s\cdot|g|_{(s)}^2}=\sqrt{s}|g|_{(s)}。\tag{III}$$

对 s 的取值分情况讨论：

a. 若 $s\geqslant n/4$ (高维稠密情形)。此时 $\ln(en/s)\leqslant\ln(4\mathrm{e})=O(1)$，即 $\sqrt{s\ln(en/s)}\asymp\sqrt{s}$。由于 $\mathbb{S}_{n,s}$ 包含前 s 个坐标张成的单位球 $\mathbb{B}_2^s$，可得

$$w(\mathbb{S}_{n,s})\geqslant\mathrm{E}[\|\boldsymbol{g}_s\|_2]=\sqrt{2}\frac{\Gamma((s+1)/2)}{\Gamma(s/2)}\geqslant c_0\sqrt{s}\geqslant c_1\sqrt{s\ln(en/s)}。$$

b. 若 $s<n/4$ (典型稀疏情形)，设单个标准正态变量的尾概率为 $p(t)=\mathrm{P}\{|g_1|\geqslant t\}$，则根据介值定理，可得存在 $t_0>0$，使得

$$p(t_0)=\frac{2s}{n},$$

利用 Mills 比率，可得

$$t_0\geqslant c_2\sqrt{\ln en/s}。$$

构造计数随机变量

$$N(t_0)=\sum_{i=1}^{n}\mathbf{1}_{\{|g_i|\geqslant t_0\}}\sim B(n,p(t_0)),$$

满足 $\mathrm{E}[N(t_0)]=np(t_0)=2s$，则 $\{N(t_0)\geqslant s\}=\{|g|_{(s)}\geqslant t_0\}$。

利用定理 T2.3.1 (Chernoff 不等式) (Chernoff 不等式) 的二项分布集中形式，令 $\delta=1/2$，可得

$$\mathrm{P}\{N(t_0)\geqslant s\}\geqslant 1-\mathrm{e}^{-s/4}\geqslant 1-\mathrm{e}^{-1/4}\geqslant\frac{1}{5},$$

因此

$$\mathrm{E}[|g|_{(s)}]\geqslant t_0\cdot\mathrm{P}\{|g|_{(s)}\geqslant t_0\}\geqslant t_0\cdot\mathrm{P}\{N(t_0)\geqslant s\}\geqslant\frac{1}{5}t_0\geqslant c_3\sqrt{\ln(en/s)},\tag{IV}$$

将 (IV) 代入于 (III)，可得

$$w(\mathbb{S}_{n,s})\geqslant\sqrt{s}\mathrm{E}[|g|_{(s)}]\geqslant c\sqrt{s\ln(en/s)}。\tag{V}$$

如此，

$$c\sqrt{s\ln(en/s)}\leqslant w(\mathbb{S}_{n,s})\leqslant w(\mathbb{T}_{n,s})\leqslant 2w(\mathbb{S}_{n,s})\leqslant C\sqrt{s\ln(en/s)}。$$

即 $w(\mathbb{T}_{n,s})\asymp w(\mathbb{S}_{n,s})\asymp\sqrt{s\ln(en/s)}$。

28 [**Garnaev–Gluskin 定理**] 改进 ℓ_1 球随机截面的界 (9.3.2) 的对数因子为

$$\mathrm{E}[\mathrm{diam}(\mathbb{B}_1^n\cap E)]\lesssim\frac{K^2\sqrt{\ln(en/m)}}{\sqrt{m}},$$

其中 $E=\ker\boldsymbol{A}$ 为随机子空间。假设 $1\leqslant m\leqslant c_0n$ 且 $K\geqslant 1$。特别地，(9.13) 的对数因子可以被去掉。

证明 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的行向量相互独立，均为各向同性的 K-sub-Gaussian 向量。

- 构造截断的 ℓ_1 球并归一化

  令 s 为 $[1,n]$ 中的整数，并令 $\mathbb{T}_{n,s}=\sqrt{s}\mathbb{B}_1^n\cap\mathbb{B}_2^n$。设非零向量 $\boldsymbol{x}\in\mathbb{B}_1^n\cap\ker\boldsymbol{A}$，满足 $\|\boldsymbol{x}\|_2>1/\sqrt{s}$。记其归一化向量为 $\bar{\boldsymbol{x}}=\boldsymbol{x}/\|\boldsymbol{x}\|_2$，则

  $$\|\bar{\boldsymbol{x}}\|_2=1,\ \|\bar{\boldsymbol{x}}\|_1=\frac{\|\boldsymbol{x}\|_1}{\|\boldsymbol{x}\|_2}\leqslant\frac{1}{\|\boldsymbol{x}\|_2}<\sqrt{s},\ \boldsymbol{A}\bar{\boldsymbol{x}}=\frac{1}{\|\boldsymbol{x}\|_2}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0},$$

  因此 $\bar{\boldsymbol{x}}\in\mathbb{T}_{n,s}\cap\mathbb{S}^{n-1}\cap\ker\boldsymbol{A}$。从而若 $\mathbb{T}_{n,s}\cap\mathbb{S}^{n-1}\cap\ker\boldsymbol{A}=\emptyset$，则

  $$\sup_{\boldsymbol{x}\in\mathbb{B}_1^n\cap\ker\boldsymbol{A}}\|\boldsymbol{x}\|_2\leqslant\frac{1}{\sqrt{s}}。$$

- 利用矩阵偏差不等式确定参数 s

  同理于习题 Q9.25 (稀疏向量集合的凸化) 的第 (1) 问，可得

  $$w(\mathbb{T}_{n,s})\leqslant C_0\sqrt{s\ln\left(\frac{en}{s}\right)}。$$

  对集合 $\mathbb{T}_{n,s}\cap\mathbb{S}^{n-1}$ 应用高概率矩阵偏差界，得到

  $$\inf_{\boldsymbol{v}\in\mathbb{T}_{n,s}\cap\mathbb{S}^{n-1}}\|\boldsymbol{A}\boldsymbol{v}\|_2\geqslant c_1\sqrt{m}-C_1K^2\sqrt{s\ln\left(\frac{en}{s}\right)}\quad(\text{w.h.p. }1-2\mathrm{e}^{-c_1m/K^4})。$$

因而只要

$$m \geqslant C_2 K^4 s \ln\left(\frac{en}{s}\right),$$

则

$$\mathbb{T}_{n,s} \cap \mathbb{S}^{n-1} \cap \ker \boldsymbol{A} = \emptyset \text{ (w.h.p. } 1 - 2\exp(-cm/K^4)).$$

若 $m \geqslant C_3 K^4 \ln(en/m)$，取

$$s = \left\lfloor c_3 \frac{m}{K^4 \ln(en/m)} \right\rfloor,$$

其中 $c_3 > 0$ 足够小。调整常数后，$1 \leqslant s \leqslant n$ 且 $s\ln(en/s) \leqslant c_4 m/K^4$，故上述逃逸事件成立。在上述事件上，

$$\operatorname{diam}(\mathbb{B}_1^n \cap \ker \boldsymbol{A}) \leqslant \frac{2}{\sqrt{s}} \leqslant C \frac{K^2 \sqrt{\ln(en/m)}}{\sqrt{m}}.$$

记上述逃逸事件为 $\mathcal{G}$。由于 $\mathbb{B}_1^n \cap E \subset \mathbb{B}_1^n$，因此其直径至多为 2。从而

$$\begin{aligned} \mathrm{E}[\operatorname{diam}(\mathbb{B}_1^n \cap E)] &\leqslant \frac{2}{\sqrt{s}} + 2\mathrm{P}(\mathcal{G}^c) \\ &\leqslant C \frac{K^2 \sqrt{\ln(en/m)}}{\sqrt{m}} + 4\exp(-cm/K^4). \end{aligned}$$

当 $m < C_3 K^4 \ln(en/m)$ 时，目标右侧通过增大绝对常数即可覆盖 $\operatorname{diam}(\mathbb{B}_1^n \cap E) \leqslant 2$；否则第二项可被第一项吸收，从而得到所证结论。当 $m = \Theta(n)$ 时，$\ln(en/m) = O(1)$，因此

$$\mathrm{E}[\operatorname{diam}(\mathbb{B}_1^n \cap E)] \lesssim \frac{1}{\sqrt{m}} \asymp \frac{1}{\sqrt{n}},$$

即可摘除对数因子，恢复 Kashin 截面定理的最优尺度。

29 [**低秩矩阵恢复的扩展**] 证明推论 C9.4.11 (低秩矩阵恢复) 的以下推广。

(1) 证明推论 C9.4.11 (低秩矩阵恢复) 的结论对于以下优化程序也成立：

最小化$\|\boldsymbol{X}\|_*$ 满足$y_i = \langle \boldsymbol{A}_i, \boldsymbol{X} \rangle,\ i = 1, \cdots, m$。

(2) 将矩阵恢复结果推广到近似低秩矩阵。

(3) 将矩阵恢复结果推广到 $d_1 \times d_2$ 矩阵。

证明 (1) 精确低秩恢复

将矩阵空间 $\mathbb{R}^{n\times n}$ 视同 n^2 维 Euclidean 空间 (配备 Frobenius 范数 $\|\cdot\|_F$)。根据习题 Q9.18 (通过优化恢复) 的通用凸优化恢复定理，可得对于任意的范数单位球 $\mathbb{T}$，凸优化求解器

$$\arg\min_{\boldsymbol{Z} \in \mathbb{R}^{n\times n}} \|\boldsymbol{Z}\|_{\mathbb{T}} \quad \text{s.t.} \quad \mathcal{A}(\boldsymbol{Z}) = \mathcal{A}(\boldsymbol{X})$$

时，恢复误差满足

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant \frac{C_0 K^2 w(\mathbb{T})}{\sqrt{m}} \|\boldsymbol{X}\|_{\mathbb{T}}. \tag{I}$$

取范数为核范数 $\|\cdot\|_*$，单位球 $\mathbb{B}_* = \{\boldsymbol{Z} \in \mathbb{R}^{n\times n} : \|\boldsymbol{Z}\|_* \leqslant 1\}$。根据核范数与算子范数的对偶性 (核范数是谱范数的对偶范数)，对标准 Gaussian 矩阵 $\boldsymbol{G}$ (元素独立同分布 $N(\boldsymbol{0}, 1)$)，可得

$$w(\mathbb{B}_*) = \mathrm{E}\left[\sup_{\boldsymbol{Z} \in \mathbb{B}_*} \langle \boldsymbol{G}, \boldsymbol{Z} \rangle\right] = \mathrm{E}[\|\boldsymbol{G}\|_{\mathrm{op}}] \leqslant \sqrt{n} + \sqrt{n} = 2\sqrt{n}, \tag{II}$$

其中最后一步是 Gaussian 矩阵算子范数的经典界 (Gordon 定理)。设 $\boldsymbol{X}$ 的奇异值为 $\sigma_1 \geqslant \sigma_2 \geqslant \cdots \geqslant \sigma_n \geqslant 0$。由于 $\operatorname{rank}(\boldsymbol{X}) \leqslant r$，奇异值向量 $\sigma(\boldsymbol{X}) \in \mathbb{R}^n$ 为 r-稀疏向量，根据 Cauchy–Schwarz 不等式：

$$\|\boldsymbol{X}\|_* = \|\sigma(\boldsymbol{X})\|_1 = \sum_{i=1}^{r} \sigma_i \leqslant \sqrt{r}\left(\sum_{i=1}^{r} \sigma_i^2\right)^{1/2} = \sqrt{r}\|\boldsymbol{X}\|_F. \tag{III}$$

将 (II) 和 (III) 代入于 (I)，令 $C = 2C_0$，可得

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant \frac{2C_0K^2\sqrt{n}}{\sqrt{m}} \cdot \sqrt{r}\|\boldsymbol{X}\|_F = CK^2\sqrt{\frac{rn}{m}}\|\boldsymbol{X}\|_F。 \tag{IV}$$

上式只给出稳定的相对误差界，不能单独推出精确恢复。以下利用核范数的下降锥证明精确恢复。

设 $\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ 为秩至多 r 的奇异值分解，并令

$$T = \{\boldsymbol{U}\boldsymbol{M}^\top + \boldsymbol{N}\boldsymbol{V}^\top : \ \boldsymbol{M}, \boldsymbol{N} \in \mathbb{R}^{n\times r}\}$$

为 $\boldsymbol{X}$ 处秩 r 矩阵流形的切空间。若扰动 $\boldsymbol{H}$ 属于核范数于 $\boldsymbol{X}$ 的下降锥，则核范数的可分解性给出

$$\|\boldsymbol{P}_{T^\perp}\boldsymbol{H}\|_* \leqslant \|\boldsymbol{P}_T\boldsymbol{H}\|_*.$$

又 $\operatorname{rank}(\boldsymbol{P}_T\boldsymbol{H}) \leqslant 2r$，故对于满足 $\|\boldsymbol{H}\|_F = 1$ 的下降方向，

$$\|\boldsymbol{H}\|_* \leqslant 2\|\boldsymbol{P}_T\boldsymbol{H}\|_* \leqslant 2\sqrt{2r}\|\boldsymbol{P}_T\boldsymbol{H}\|_F \leqslant 2\sqrt{2r}.$$

令 $\mathcal{D}(\boldsymbol{X})$ 表示该下降锥。对标准 Gaussian 矩阵 $\boldsymbol{G}$，利用核范数与算子范数的对偶性，可得

$$w(\mathcal{D}(\boldsymbol{X}) \cap \mathbb{S}^{n^2-1}) \leqslant 2\sqrt{2r}\,\mathrm{E}\|\boldsymbol{G}\|_{\mathrm{op}} \leqslant C\sqrt{rn}. \tag{V}$$

将测量算子按矩阵向量化为 $m \times n^2$ 的标准 Gaussian 矩阵。由定理 T9.3.4 (逃逸定理) 与 (V)，当 $m \geqslant Crn$ 时，以高概率有

$$\ker \mathcal{A} \cap \mathcal{D}(\boldsymbol{X}) = \{\boldsymbol{0}\}.$$

因而不存在非零可行扰动使核范数不增，故 $\boldsymbol{X}$ 是核范数最小化问题的唯一解。这证明了推论 C9.4.11 (低秩矩阵恢复) 的精确恢复结论。

(2) 近似低秩恢复

设 $\boldsymbol{X}$ 为一般的矩阵，$\boldsymbol{X}_r$ 为其最优秩 r 逼近 (SVD 截断，Eckart–Young–Mirsky 定理)，记核范数逼近误差 $\|\boldsymbol{X} - \boldsymbol{X}_r\|_* = \sum_{i=r+1}^{n}\sigma_i(\boldsymbol{X})$。将 (II) 代入于 (I)，可得对于任意的矩阵 $\boldsymbol{X}$ 均成立

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant \frac{CK^2\sqrt{n}}{\sqrt{m}}\|\boldsymbol{X}\|_*。$$

将 $\boldsymbol{X}$ 拆解为 $\boldsymbol{X} = \boldsymbol{X}_r + (\boldsymbol{X} - \boldsymbol{X}_r)$，根据核范数的三角不等式：

$$\|\boldsymbol{X}\|_* \leqslant \|\boldsymbol{X}_r\|_* + \|\boldsymbol{X} - \boldsymbol{X}_r\|_* \leqslant \sqrt{r}\|\boldsymbol{X}\|_F + \|\boldsymbol{X} - \boldsymbol{X}_r\|_*,$$

其中第二步由 (III) 和 $\|\boldsymbol{X}_r\|_F \leqslant \|\boldsymbol{X}\|_F$。将其代入，可得

$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant CK^2\left(\sqrt{\frac{rn}{m}}\|\boldsymbol{X}\|_F + \sqrt{\frac{n}{m}}\|\boldsymbol{X} - \boldsymbol{X}_r\|_*\right)。 \tag{VI}$$

当 $m \asymp rn$ 时，尾部误差项化为 $\|\boldsymbol{X} - \boldsymbol{X}_r\|_*/\sqrt{r}$，为稀疏恢复 Stechkin 最优逼近界的矩阵版本。

(3) 长方 $d_1 \times d_2$ 矩阵

对 $d_1 \times d_2$ 矩阵 ($r \leqslant \min(d_1, d_2)$)，核范数单位球 $\mathbb{B}_*$ 的 Gaussian 宽度为

$$w(\mathbb{B}_*) = \mathrm{E}[\|\boldsymbol{G}\|_{\mathrm{op}}] \leqslant \sqrt{d_1} + \sqrt{d_2}, \tag{VII}$$

同理代入于 (I) 并利用 (III)，可得

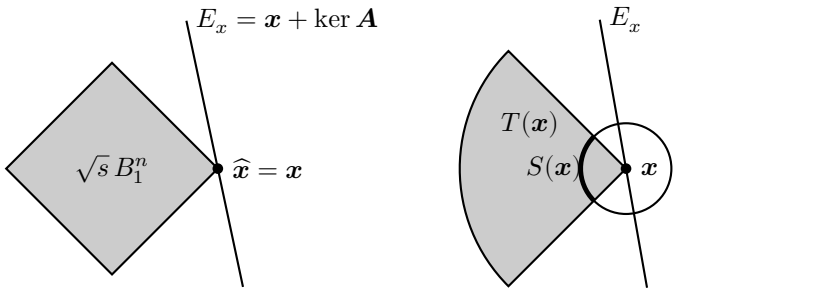
$$\mathrm{E}\|\hat{\boldsymbol{X}} - \boldsymbol{X}\|_F \leqslant \frac{C_0K^2(\sqrt{d_1} + \sqrt{d_2})}{\sqrt{m}}\sqrt{r}\|\boldsymbol{X}\|_F \leqslant CK^2\sqrt{\frac{r(d_1+d_2)}{m}}\|\boldsymbol{X}\|_F, \tag{VIII}$$

因此所需测量数为 $m \geqslant C_\varepsilon K^4 r(d_1 + d_2)$，恰好等于秩 r 矩阵流形的代数自由度 $\dim(\mathcal{M}_r) = r(d_1 + d_2 - r)$ 的量级：核范数凸松弛仅需此量级的测量数即可稳健重构高维长方低秩矩阵。

注释 核范数极小化经凸松弛恢复低秩矩阵。所需测量数为秩 r 矩阵流形自由度 $r(d_1 + d_2 - r)$ 的量级 (方阵情形为 rn)，远小于环境维数 d_1d_2。

这同稀疏恢复的 $s\ln(\mathrm{e}n/s)$ 样本复杂度遵循同一原则：低复杂度集合凸包的 Gaussian 宽度决定样本复杂度；于此，核范数单位球满足 $w(\mathbb{B}_*) \leqslant \sqrt{d_1} + \sqrt{d_2}$。

30 [**精确稀疏恢复的几何**] 给出定理 T9.5.1 (精确稀疏恢复) 证明的几何解释 (见图 9.7b)。此证明对切锥 $\mathbb{T}(\boldsymbol{x})$ 及其球面部分 $\mathbb{S}(\boldsymbol{x})$ 说明了什么?



(a) 当随机子空间 E_x 在点 $\boldsymbol{x}$ 处与 ℓ_1 球相切时，即发生精确稀疏恢复。

(b) 相切发生当且仅当 E_x 与 ℓ_1 球在点 $\boldsymbol{x}$ 处的切锥 $T(\boldsymbol{x})$ 的球面部分 $S(\boldsymbol{x})$ 不相交。

图 9.7 精确稀疏恢复

证明 图 9.7(a) 的几何含义：严格相切当且仅当精确恢复

凸优化问题的可行域是过点 $\boldsymbol{x}$ 的仿射子空间 $E_{\boldsymbol{x}} = \boldsymbol{x} + \ker \boldsymbol{A} = \{\boldsymbol{z} \in \mathbb{R}^n : \boldsymbol{A}\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x}\}$。目标函数的次水平集是半径为 $\|\boldsymbol{x}\|_1$ 的 ℓ_1 范数球 $B = \{\boldsymbol{z} \in \mathbb{R}^n : \|\boldsymbol{z}\|_1 \leqslant \|\boldsymbol{x}\|_1\}$。精确恢复 $\hat{\boldsymbol{x}} = \boldsymbol{x}$ 成立，当且仅当 $\boldsymbol{x}$ 是可行域内唯一的极小值点。于几何，可得仿射平面 $E_{\boldsymbol{x}}$ 与 ℓ_1 球 B 相交于且仅相交于孤立点 $\boldsymbol{x}$，即

$$(\boldsymbol{x} + \ker \boldsymbol{A}) \cap \{\boldsymbol{z} \in \mathbb{R}^n : \|\boldsymbol{z}\|_1 \leqslant \|\boldsymbol{x}\|_1\} = \{\boldsymbol{x}\}。$$

此时 $E_{\boldsymbol{x}}$ 是经过 $\boldsymbol{x}$ 的仿射可行截面；它一般不是 ℓ_1 球的支撑超平面。

- 图 9.7(b) 的几何含义：切锥转化当且仅当逃逸

  考察误差向量 $\boldsymbol{h} = \hat{\boldsymbol{x}} - \boldsymbol{x}$：根据可行性 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}\boldsymbol{x}$，可得 $\boldsymbol{A}\boldsymbol{h} = \boldsymbol{0}$，即 $\boldsymbol{h} \in \ker \boldsymbol{A}$；根据最优性 $\|\hat{\boldsymbol{x}}\|_1 \leqslant \|\boldsymbol{x}\|_1$，可得 $\boldsymbol{x} + \boldsymbol{h} \in B$。定义 ℓ_1 范数于 $\boldsymbol{x}$ 的切锥 (下降锥，Tangent Cone / Descent Cone) 为使范数不增的全部方向：

  $$\mathbb{T}(\boldsymbol{x}) = \operatorname{cone}(B - \boldsymbol{x}) = \{\boldsymbol{h} \in \mathbb{R}^n : \exists t > 0 \text{ 使得} \|\boldsymbol{x} + t\boldsymbol{h}\|_1 \leqslant \|\boldsymbol{x}\|_1\}。$$

  严格相切 (即不存在非零可行扰动 $\boldsymbol{h} \neq \boldsymbol{0}$) 等价于

  $$\mathbb{T}(\boldsymbol{x}) \cap \ker \boldsymbol{A} = \{\boldsymbol{0}\}。$$

  将切锥同 Euclidean 单位球面相交，得到其球面截面：

  $$\mathbb{S}(\boldsymbol{x}) = \mathbb{T}(\boldsymbol{x}) \cap \mathbb{S}^{n-1}。$$

  因此，精确恢复等价于：随机子空间 $\ker \boldsymbol{A}$ 彻底避开集合 $\mathbb{S}(\boldsymbol{x})$，即 $\mathbb{S}(\boldsymbol{x}) \cap \ker \boldsymbol{A} = \emptyset$。

- 定理 T9.5.1 (精确稀疏恢复) 的证明对切锥 $\mathbb{T}(\boldsymbol{x})$ 及 $\mathbb{S}(\boldsymbol{x})$ 说明了什么

  定理的证明通过精细的代数放缩，揭示了切锥 $\mathbb{T}(\boldsymbol{x})$ 及其球面截面 $\mathbb{S}(\boldsymbol{x})$ 的四个关键几何性质。

  第一，结构性质 ($\operatorname{supp}(\boldsymbol{x})$ 的支配)：对于 s-稀疏信号 $\boldsymbol{x}$ ($\operatorname{supp}(\boldsymbol{x}) = \mathbb{S}$，$|\mathbb{S}| \leqslant s$)，任取切锥方向 $\boldsymbol{h} \in \mathbb{T}(\boldsymbol{x})$。存在 $t > 0$ 使得

  $$\|\boldsymbol{x}_{\mathbb{S}} + t\boldsymbol{h}_{\mathbb{S}}\|_1 + t\|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant \|\boldsymbol{x}_{\mathbb{S}}\|_1。$$

  结合反三角不等式并除以 t，得到 $\|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant \|\boldsymbol{h}_{\mathbb{S}}\|_1$。可得切锥 $\mathbb{T}(\boldsymbol{x})$ 并不是张角很大的宽锥，其中每个方向均被严格限制于“$\mathbb{S}^c$ 的能量必须小于等于 $\mathbb{S}$ 的能量”这一狭窄区域。进而锥内任一向量的 ℓ_1 范数受 Euclidean 范数严格控制：

  $$\|\boldsymbol{h}\|_1 = \|\boldsymbol{h}_{\mathbb{S}}\|_1 + \|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant 2\|\boldsymbol{h}_{\mathbb{S}}\|_1 \leqslant 2\sqrt{s}\|\boldsymbol{h}_{\mathbb{S}}\|_2 \leqslant 2\sqrt{s}\|\boldsymbol{h}\|_2。$$

  第二，包络性质：对于球面部分 $\mathbb{S}(\boldsymbol{x}) = \mathbb{T}(\boldsymbol{x}) \cap \mathbb{S}^{n-1}$ 的任意的 $\boldsymbol{u} \in \mathbb{S}(\boldsymbol{x})$，满足 $\|\boldsymbol{u}\|_2 = 1$，$\|\boldsymbol{u}\|_1 \leqslant 2\sqrt{s}$。根据截断 ℓ_1 Euclidean 球 $\mathbb{T}_{n,s} = \sqrt{s}\mathbb{B}_1^n \cap \mathbb{B}_2^n$ 的定义，证明揭示了如下包含关系：

  $$\mathbb{S}(\boldsymbol{x}) \subset 2(\sqrt{s}\mathbb{B}_1^n \cap \mathbb{B}_2^n) = 2\mathbb{T}_{n,s}。$$

尽管球面 $\mathbb{S}^{n-1}$ 是一个 $n-1$ 维的高维对象，但切锥于其的投影 $\mathbb{S}(\boldsymbol{x})$ 被完全束缚在截断球 $2\mathbb{T}_{n,s}$ 这一"低有效维数"的凸几何体。

第三，测度性质 (极小的 Gaussian 宽度)：结合习题 Q9.26 (稀疏恢复的对数改进) 与 Q9.27 (稀疏向量的 Gaussian 宽度) 对截断球 Gaussian 宽度的估计，证明实际上给出了 $\mathbb{S}(\boldsymbol{x})$ Gaussian 宽度的严格上界：

$$w(\mathbb{S}(\boldsymbol{x})) \leqslant 2w(\mathbb{T}_{n,s}) \leqslant C\sqrt{s\ln(en/s)} \leqslant C'\sqrt{s\ln n}。$$

Gaussian 宽度刻画了集合于球面的"平均立体角/有效截面积"。由当前估计只能得到 $w(\mathbb{S}(\boldsymbol{x})) \lesssim \sqrt{s\ln n}$；这说明 $\mathbb{S}(\boldsymbol{x})$ 于高维球面 $\mathbb{S}^{n-1}$ 所占的球面测度呈指数级微小。

第四，相变机制 (触发矩阵偏差下界的几何阈值)：由独立各向同性 K-sub-Gaussian 行向量的高概率矩阵偏差界可知，若随机核空间要以高概率避开球面集合 $\mathbb{S}(\boldsymbol{x})$ (即 $\mathbb{S}(\boldsymbol{x}) \cap \ker \boldsymbol{A} = \emptyset$)，测量数 (余维数) 只需满足

$$m \geqslant CK^4 \cdot w(\mathbb{S}(\boldsymbol{x}))^2。$$

将 $w(\mathbb{S}(\boldsymbol{x})) \leqslant C\sqrt{s\ln n}$ 代入，即得到测量数条件 $m \geqslant C'K^4 s\ln n$。

几何结论：只要测量维数 m 达到切锥球面部分 Gaussian 宽度的平方阶 $w(\mathbb{S}(\boldsymbol{x}))^2$，高维随机子空间 $\ker \boldsymbol{A}$ 就以高概率避开该球面截面，使得仿射可行截面同 ℓ_1 球仅于 $\boldsymbol{x}$ 相交，从而锁定唯一的精确解。

注释 仿射子空间 $E_{\boldsymbol{x}} = \boldsymbol{x} + \ker \boldsymbol{A}$ 包含全部同观测的候选解。切锥 $\mathbb{T}(\boldsymbol{x})$ 收集目标函数于 $\boldsymbol{x}$ 的下降方向，且满足 $\|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant \|\boldsymbol{h}_{\mathbb{S}}\|_1$。球面切锥 $\mathbb{S}(\boldsymbol{x}) = \mathbb{T}(\boldsymbol{x}) \cap \mathbb{S}^{n-1}$ 被包含于 $2\mathbb{T}_{n,s}$，其 Gaussian 宽度满足 $w \lesssim \sqrt{s\ln n}$。精确恢复等价于 $\mathbb{S}(\boldsymbol{x}) \cap \ker \boldsymbol{A} = \emptyset$，故当 $m \gtrsim s\ln n$ 时随机核空间以高概率避开此集合。

31 [**带噪稀疏恢复**] 将定理 T9.5.1 (精确稀疏恢复) 推广至带噪声的测量 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{w}$，并相应修改恢复程序 (9.27)。

考虑带噪声的高维线性观测模型 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{w}$，其中 $\boldsymbol{x} \in \mathbb{R}^n$ 为未知的 s-稀疏信号 ($\|\boldsymbol{x}\|_0 \leqslant s$)，$\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为随机测量矩阵 (其行向量 $\boldsymbol{A}_i$ 为相互独立、各向同性的 K-sub-Gaussian 随机向量)，$\boldsymbol{w} \in \mathbb{R}^m$ 为未知加性噪声，满足确定性约束 $\|\boldsymbol{w}\|_2 \leqslant \varepsilon$。任务：(1) 相应地修改无噪恢复程序 (9.27) 以适应噪声模型；(2) 将定理 T9.5.1 (精确稀疏恢复) 推广到带噪情形，陈述并严格证明相应的恢复误差界，并明确所用的高概率矩阵偏差事件。

证明 • 修改恢复程序：基追踪去噪 (BPDN)

于无噪情形，程序 (9.27) 采用严格等式约束：

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1 \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{z} = \boldsymbol{y}。$$

在带噪情形 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{w}$，由于 $\|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|_2 = \|\boldsymbol{w}\|_2 \leqslant \varepsilon$，真值 $\boldsymbol{x}$ 通常不再满足硬等式约束 $\boldsymbol{A}\boldsymbol{z} = \boldsymbol{y}$。

因此，最自然的鲁棒化方案是将等式约束放宽为 ℓ_2 范数球的容差约束。由此得到经典的基追踪去噪 (Basis Pursuit Denoising, BPDN) 凸优化程序：

$$\hat{\boldsymbol{x}} \in \arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1 \quad \text{满足} \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{z}\|_2 \leqslant \varepsilon。$$

• 可行性同残差控制

令恢复误差向量为 $\boldsymbol{h} = \hat{\boldsymbol{x}} - \boldsymbol{x}$。若 $\boldsymbol{h} = \boldsymbol{0}$，则误差为 0，结论是平凡的；之后只需考虑 $\boldsymbol{h} \neq \boldsymbol{0}$ 的情况。

第一，可行性：由于 $\|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|_2 = \|\boldsymbol{w}\|_2 \leqslant \varepsilon$，真值 $\boldsymbol{x}$ 自身满足约束条件 $\|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|_2 \leqslant \varepsilon$，因此 $\boldsymbol{x}$ 是优化问题的一个可行解。

第二，残差控制：根据优化解 $\hat{\boldsymbol{x}}$ 的可行性，可得 $\|\boldsymbol{y} - \boldsymbol{A}\hat{\boldsymbol{x}}\|_2 \leqslant \varepsilon$。根据三角不等式，

$$\begin{aligned} \|\boldsymbol{A}\boldsymbol{h}\|_2 &= \|\boldsymbol{A}(\hat{\boldsymbol{x}} - \boldsymbol{x})\|_2 \\ &= \|(\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}) - (\boldsymbol{y} - \boldsymbol{A}\hat{\boldsymbol{x}})\|_2 \\ &\leqslant \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|_2 + \|\boldsymbol{y} - \boldsymbol{A}\hat{\boldsymbol{x}}\|_2 \leqslant 2\varepsilon。 \end{aligned} \tag{I}$$

• 最优性推出误差方向属于切锥

由于 $\hat{\boldsymbol{x}}$ 是目标函数 $\|\boldsymbol{z}\|_1$ 的全局极小值点，$\boldsymbol{x}$ 为可行解，可得 $\|\hat{\boldsymbol{x}}\|_1 \leqslant \|\boldsymbol{x}\|_1$。

设 $\mathbb{S} = \operatorname{supp}(\boldsymbol{x})$ ($|\mathbb{S}| \leqslant s$)。将全向量拆分为 $\mathbb{S}$ 同补集：

$$\|\boldsymbol{x}_{\mathbb{S}}\|_1 \geqslant \|\hat{\boldsymbol{x}}\|_1 = \|\boldsymbol{x}_{\mathbb{S}} + \boldsymbol{h}_{\mathbb{S}}\|_1 + \|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \geqslant \|\boldsymbol{x}_{\mathbb{S}}\|_1 - \|\boldsymbol{h}_{\mathbb{S}}\|_1 + \|\boldsymbol{h}_{\mathbb{S}^c}\|_1。$$

两侧消去 $\|\boldsymbol{x}_{\mathbb{S}}\|_1$：

$$\|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant \|\boldsymbol{h}_{\mathbb{S}}\|_1。$$

由此得到误差向量全 ℓ_1 范数的界：

$$\|\boldsymbol{h}\|_1 = \|\boldsymbol{h}_{\mathbb{S}}\|_1 + \|\boldsymbol{h}_{\mathbb{S}^c}\|_1 \leqslant 2\|\boldsymbol{h}_{\mathbb{S}}\|_1 \leqslant 2\sqrt{s}\|\boldsymbol{h}_{\mathbb{S}}\|_2 \leqslant 2\sqrt{s}\|\boldsymbol{h}\|_2。$$

记误差向量的归一化向量为 $\bar{\boldsymbol{h}} = \frac{\boldsymbol{h}}{\|\boldsymbol{h}\|_2}$，则 $\|\bar{\boldsymbol{h}}\|_2 = 1$，$\|\bar{\boldsymbol{h}}\|_1 = \frac{\|\boldsymbol{h}\|_1}{\|\boldsymbol{h}\|_2} \leqslant 2\sqrt{s}$。

根据截断 ℓ_1 球 $\mathbb{T}_{n,s} = \{\boldsymbol{z} \in \mathbb{R}^n : \|\boldsymbol{z}\|_1 \leqslant \sqrt{s},\ \|\boldsymbol{z}\|_2 \leqslant 1\}$ 的定义，得到

$$\bar{\boldsymbol{h}} \in 2\mathbb{T}_{n,s} \cap \mathbb{S}^{n-1}。 \tag{II}$$

- 根据矩阵偏差不等式建立下界

令 $\mathbb{T} = 2\mathbb{T}_{n,s} \cap \mathbb{S}^{n-1}$。由独立各向同性 K-sub-Gaussian 行向量的高概率矩阵偏差界，可得

$$\min_{\boldsymbol{v}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{v}\|_2 \geqslant C_1^{-1}\sqrt{m} - C_1K^2 w(\mathbb{T}) \ (\text{w.h.p. } 1 - 2\mathrm{e}^{-cm/K^4})。 \tag{III}$$

在习题 Q9.26 (稀疏恢复的对数改进) 与 Q9.27 (稀疏向量的 Gaussian 宽度) 中，我们已经严格证明了此集合的 Gaussian 宽度满足

$$w(\mathbb{T}) = w(2\mathbb{T}_{n,s} \cap \mathbb{S}^{n-1}) \leqslant 2w(\mathbb{T}_{n,s}) \leqslant C_2\sqrt{s\ln\left(\frac{\mathrm{e}n}{s}\right)}。$$

当测量数满足

$$m \geqslant (2C_1^2C_2)^2K^4 s\ln\left(\frac{\mathrm{e}n}{s}\right) = C_0K^4 s\ln\left(\frac{\mathrm{e}n}{s}\right)$$

时，第二项被第一项的一半控制：$C_1K^2w(\mathbb{T}) \leqslant \frac{1}{2C_1}\sqrt{m}$。代入于 (III)，可得

$$\min_{\boldsymbol{v}\in\mathbb{T}} \|\boldsymbol{A}\boldsymbol{v}\|_2 \geqslant \frac{1}{2C_1}\sqrt{m} = c_0\sqrt{m}。 \tag{IV}$$

- 综合上下界导出恢复误差

由于归一化向量 $\bar{\boldsymbol{h}} \in \mathbb{T}$，利用 (IV) 的各向同性下界，可得

$$\|\boldsymbol{A}\boldsymbol{h}\|_2 = \|\boldsymbol{h}\|_2\|\boldsymbol{A}\bar{\boldsymbol{h}}\|_2 \geqslant c_0\sqrt{m}\|\boldsymbol{h}\|_2。 \tag{V}$$

将第一步得到的残差上界 $\|\boldsymbol{A}\boldsymbol{h}\|_2 \leqslant 2\varepsilon$ ((I)) 代入 (V)：

$$c_0\sqrt{m}\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \leqslant 2\varepsilon。$$

两侧同除以 $c_0\sqrt{m}$，令 $C = \frac{2}{c_0}$：

$$\|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2 \leqslant \frac{C\varepsilon}{\sqrt{m}}。$$

注释 可行域 $\{\boldsymbol{z} : \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{z}\|_2 \leqslant \varepsilon\}$ 同时包含真值 $\boldsymbol{x}$ 与 BPDN 解 $\hat{\boldsymbol{x}}$。矩阵 $\boldsymbol{A}$ 于切锥 $\mathbb{T}(\boldsymbol{x})$ 的下界将误差限制为 $\mathcal{O}(\varepsilon/\sqrt{m})$。当 $\varepsilon \to 0$ 时，该误差界趋于零，并退化为定理 T9.5.1 (精确稀疏恢复) 的结论 $\hat{\boldsymbol{x}} = \boldsymbol{x}$。

32 [**零空间性质**] 定义确保精确恢复的零空间性质。

称 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 满足阶为 s 的零空间性质，若对于任意的非零向量 $\boldsymbol{h} \in \ker\boldsymbol{A}$，任意的 s 元子集 $\mathbb{S} \subset \{1,\cdots,n\}$，均满足

$$\|\boldsymbol{h}_{\mathbb{S}}\|_1 < \|\boldsymbol{h}_{\mathbb{S}^c}\|_1,$$

其中 $\boldsymbol{h}_{\mathbb{S}} \in \mathbb{R}^n$ 表示 $\boldsymbol{h}$ 于集合 $\mathbb{S}$ 的限制 ($\mathbb{S}^c$ 以外分量置 0)。

(1) 证明：$\boldsymbol{A}$ 满足阶为 s 的零空间性质，当且仅当任意的 s-稀疏向量 $\boldsymbol{x} \in \mathbb{R}^n$ 均为 ℓ_1 最小化问题

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1 \text{ s.t. } \boldsymbol{A}\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x}$$

的唯一全局最优解。

(2) 将命题精确化，证明：当测量数满足 $m \geqslant CK^4 s\ln(\mathrm{e}n/s)$ 时，由相互独立, 各向同性的 sub-Gaussian 行向量所构成的随机矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 以高概率满足阶为 s 的零空间性质。

证明 (1) • 零空间性质推出唯一恢复

设 $\boldsymbol{A}$ 满足阶为 s 的零空间性质，我们只需证明对于任意的 s-稀疏向量 $\boldsymbol{x}\in\mathbb{R}^n$，其他满足

$$\boldsymbol{A}\boldsymbol{z}=\boldsymbol{A}\boldsymbol{x}\ \text{其中}\ \boldsymbol{z}\neq\boldsymbol{x}$$

的可行解均满足 $\|\boldsymbol{z}\|_1>\|\boldsymbol{x}\|_1$。

令扰动误差向量为 $\boldsymbol{h}=\boldsymbol{z}-\boldsymbol{x}\neq\boldsymbol{0}$，则 $\boldsymbol{A}(\boldsymbol{z}-\boldsymbol{x})=\boldsymbol{A}\boldsymbol{h}=\boldsymbol{0}$，因此 $\boldsymbol{h}\in\ker\boldsymbol{A}\setminus\{\boldsymbol{0}\}$。

利用反三角不等式，可得可行解 $\boldsymbol{z}=\boldsymbol{x}+\boldsymbol{h}$ 的 ℓ_1 范数满足

$$\begin{aligned}\|\boldsymbol{z}\|_1&=\|\boldsymbol{x}+\boldsymbol{h}\|_1=\|\boldsymbol{x}_{\mathbb{S}}+\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{x}_{\mathbb{S}^c}+\boldsymbol{h}_{\mathbb{S}^c}\|_1\\&=\|\boldsymbol{x}_{\mathbb{S}}+\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\\&\geqslant\|\boldsymbol{x}\|_1-\|\boldsymbol{h}_{\mathbb{S}}\|_1+\|\boldsymbol{h}_{\mathbb{S}^c}\|_1=\|\boldsymbol{x}\|_1+(\|\boldsymbol{h}_{\mathbb{S}^c}\|_1-\|\boldsymbol{h}_{\mathbb{S}}\|_1),\end{aligned}$$

由于 $\boldsymbol{h}\in\ker\boldsymbol{A}\setminus\{\boldsymbol{0}\}$，$|\mathbb{S}|\leqslant s$，因此 $\|\boldsymbol{h}_{\mathbb{S}^c}\|_1-\|\boldsymbol{h}_{\mathbb{S}}\|_1>0$，可得 $\|\boldsymbol{z}\|_1>\|\boldsymbol{x}\|_1$，即 $\boldsymbol{x}$ 为唯一的极小值解。

- 唯一恢复推出零空间性质

利用反证法：假设任意的 s-稀疏向量都是基追踪问题的唯一解。

若 $\boldsymbol{A}$ 不满足阶为 s 的零空间性质，则存在非零向量 $\boldsymbol{h}\in\ker\boldsymbol{A}\setminus\{\boldsymbol{0}\}$，子集 $\mathbb{S}\subset\{1,\cdots,n\}$ $(|\mathbb{S}|\leqslant s)$，使得 $\|\boldsymbol{h}_{\mathbb{S}}\|_1\geqslant\|\boldsymbol{h}_{\mathbb{S}^c}\|_1$。

构造 s-稀疏测试信号 $\boldsymbol{x}=-\boldsymbol{h}_{\mathbb{S}}$，$\boldsymbol{z}=\boldsymbol{x}+\boldsymbol{h}=-\boldsymbol{h}_{\mathbb{S}}+\boldsymbol{h}=\boldsymbol{h}_{\mathbb{S}^c}$，满足：

1. 可行性：$\boldsymbol{A}\boldsymbol{z}=\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{h})=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{A}\boldsymbol{h}=\boldsymbol{A}\boldsymbol{x}$；

2. 非同一性：由于 $\boldsymbol{h}\neq\boldsymbol{0}$，因此 $\boldsymbol{z}\neq\boldsymbol{x}$。

由于 $\boldsymbol{x}$ 为满足 $\boldsymbol{A}\boldsymbol{z}=\boldsymbol{A}\boldsymbol{x}$ 的唯一 ℓ_1 范数最小化解，因此 $\|\boldsymbol{x}\|_1<\|\boldsymbol{z}\|_1$，其中

$$\|\boldsymbol{x}\|_1=\|-\boldsymbol{h}_{\mathbb{S}}\|_1=\|\boldsymbol{h}_{\mathbb{S}}\|_1,\ \|\boldsymbol{z}\|_1=\|\boldsymbol{h}_{\mathbb{S}^c}\|_1,$$

将其代入，可得 $\|\boldsymbol{h}_{\mathbb{S}}\|_1<\|\boldsymbol{h}_{\mathbb{S}^c}\|_1$，矛盾；如此，$\boldsymbol{A}$ 满足阶为 s 的零空间性质。

(2) 设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为随机矩阵，其行向量 $\boldsymbol{A}_i$ 为相互独立, 各向同性的 K-sub-Gaussian 随机向量。存在绝对常数 $C_0,c>0$，使得若测量数满足 $m\geqslant C_0K^4s\ln(\frac{en}{s})$，则矩阵 $\boldsymbol{A}$ 满足阶为 s 的零空间性质 $(\text{w.h.p. }1-2\mathrm{e}^{-cm/K^4})$。

第一，定义违背零空间性质的不良方向锥。向量 $\boldsymbol{h}\in\mathbb{R}^n$ 违背阶为 s 的零空间性质，当且仅当存在 $|\mathbb{S}|\leqslant s$ 使得 $\|\boldsymbol{h}_{\mathbb{S}}\|_1\geqslant\|\boldsymbol{h}_{\mathbb{S}^c}\|_1$。定义由不良方向构成的集合 (锥)：

$$\mathcal{C}_s=\{\boldsymbol{h}\in\mathbb{R}^n:\exists\mathbb{S}\subset\{1,\cdots,n\},\ |\mathbb{S}|\leqslant s,\ \text{使得}\|\boldsymbol{h}_{\mathbb{S}^c}\|_1\leqslant\|\boldsymbol{h}_{\mathbb{S}}\|_1\}。$$

矩阵 $\boldsymbol{A}$ 满足零空间性质，等价于零空间不存在任意非零不良方向：

$$\ker\boldsymbol{A}\cap\mathcal{C}_s=\{\boldsymbol{0}\}\text{当且仅当}\ker\boldsymbol{A}\cap(\mathcal{C}_s\cap\mathbb{S}^{n-1})=\emptyset。\tag{I}$$

第二，将不良球面方向嵌入截断 ℓ_1 球 $\mathbb{T}_{n,s}$。设 $\boldsymbol{u}\in\mathcal{C}_s\cap\mathbb{S}^{n-1}$ 为单位向量 $(\|\boldsymbol{u}\|_2=1)$。根据不良方向的定义，可得

$$\|\boldsymbol{u}\|_1=\|\boldsymbol{u}_{\mathbb{S}}\|_1+\|\boldsymbol{u}_{\mathbb{S}^c}\|_1\leqslant2\|\boldsymbol{u}_{\mathbb{S}}\|_1。$$

利用 Cauchy–Schwarz 不等式 (由于 $|\mathbb{S}|\leqslant s$)：

$$\|\boldsymbol{u}\|_1\leqslant2\sqrt{s}\|\boldsymbol{u}_{\mathbb{S}}\|_2\leqslant2\sqrt{s}\|\boldsymbol{u}\|_2=2\sqrt{s}。$$

根据截断 ℓ_1 Euclidean 球 $\mathbb{T}_{n,s}=\{\boldsymbol{z}\in\mathbb{R}^n:\|\boldsymbol{z}\|_1\leqslant\sqrt{s},\ \|\boldsymbol{z}\|_2\leqslant1\}$ 的定义，立即得到包含关系：

$$\mathcal{C}_s\cap\mathbb{S}^{n-1}\subset2\mathbb{T}_{n,s}\cap\mathbb{S}^{n-1}。\tag{II}$$

第三，控制不良集合的 Gaussian 宽度。在习题 Q9.26 (稀疏恢复的对数改进) 和 Q9.27 (稀疏向量的 Gaussian 宽度) 中，我们已经证明截断球的 Gaussian 宽度满足

$$w(\mathcal{C}_s\cap\mathbb{S}^{n-1})\leqslant w(2\mathbb{T}_{n,s})=2w(\mathbb{T}_{n,s})\leqslant C_1\sqrt{s\ln\left(\frac{en}{s}\right)}。$$

第四，应用高概率矩阵偏差界。对于球面子集 $\mathcal{T}=\mathcal{C}_s\cap\mathbb{S}^{n-1}$，若测量数满足 $m\geqslant CK^4\cdot w(\mathcal{T})^2$，则随机子空间 $\ker\boldsymbol{A}$ 与 $\mathcal{T}$ 不相交 (即 $\ker\boldsymbol{A}\cap\mathcal{T}=\emptyset$) 的概率至少为 $1-2\mathrm{e}^{-cm/K^4}$。代入 Gaussian 宽度的上界 $w(\mathcal{T})^2\leqslant C_1^2s\ln(\frac{en}{s})$，因此只要选取 $C_0\geqslant CC_1^2$，当 $m\geqslant C_0K^4s\ln(\frac{en}{s})$ 时，得到

$$\ker\boldsymbol{A}\cap(\mathcal{C}_s\cap\mathbb{S}^{n-1})=\emptyset\ (\text{w.h.p. }1-2\mathrm{e}^{-cm/K^4})。$$

利用 (I) 的等价性，此严格保证了矩阵 $\boldsymbol{A}$ 满足阶为 s 的零空间性质。

33 [**随机投影满足 RIP**] 设 $\boldsymbol{P}$ 为 $\mathbb{R}^n$ 向随机 m 维子空间的正交投影，其中此子空间于 Grassmann 流形均匀分布。

定义缩放后的投影算子 $\boldsymbol{Q}=\sqrt{\frac{n}{m}}\boldsymbol{P}$。

(1) 证明 RIP：对于任意的 $\delta\in(0,1)$，当测量维数满足 $m\geqslant C\delta^{-2}s\ln(\frac{12en}{\delta s})$ 时，$\boldsymbol{Q}$ 满足阶数为 s，常数为 δ 的受限等距性质 (w.h.p.) (RIP)，即对于任意一个满足 $\|\boldsymbol{x}\|_0\leqslant s$ 的 $\boldsymbol{x}\in\mathbb{R}^n$，

$$(1-\delta)\|\boldsymbol{x}\|_2^2\leqslant\left\|\sqrt{\frac{n}{m}}\boldsymbol{P}\boldsymbol{x}\right\|_2^2\leqslant(1+\delta)\|\boldsymbol{x}\|_2^2。$$

(2) 精确稀疏恢复：利用 (1) 的结论，推出定理 T9.5.1 (精确稀疏恢复) 的随机投影版本，即若 $m\geqslant Cs\ln(\frac{en}{s})$，则任意的 s-稀疏向量 $\boldsymbol{x}\in\mathbb{R}^n$ 均为凸优化程序 (w.h.p.)

$$\hat{\boldsymbol{x}}\in\arg\min_{\boldsymbol{z}\in\mathbb{R}^n}\|\boldsymbol{z}\|_1\ \text{满足}\boldsymbol{P}\boldsymbol{z}=\boldsymbol{P}\boldsymbol{x}$$

的唯一最优解 ($\hat{\boldsymbol{x}}=\boldsymbol{x}$)。

证明 (1) • 单点投影长度的测度集中 (JL 引理基础)

根据定理 T5.3.1 (Johnson–Lindenstrauss 引理)，对于任意的固定 $\boldsymbol{x}\in\mathbb{S}^{n-1}$，由于子空间于 Grassmann 流形均匀分布，正交投影的模长平方期望为

$$\mathrm{E}[\|\boldsymbol{P}\boldsymbol{x}\|_2^2]=\frac{m}{n}。$$

引入标准归一化算子 $\boldsymbol{Q}=\sqrt{\frac{n}{m}}\boldsymbol{P}$，使得 $\mathrm{E}[\|\boldsymbol{Q}\boldsymbol{x}\|_2^2]=\|\boldsymbol{x}\|_2^2=1$。根据球面测度集中，对于任意的 $t\in(0,1)$，可得

$$\mathrm{P}\left|\left\|\sqrt{\frac{n}{m}}\boldsymbol{P}\boldsymbol{x}\right\|_2^2-1\right|\geqslant t\leqslant 2\mathrm{e}^{-c_1mt^2},\tag{I}$$

其中 $c_1>0$ 为绝对常数。

构造 s-稀疏单位球面的 ε-网

考虑任意的单位 s-稀疏向量构成的集合

$$\mathbb{S}_{n,s}=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{x}\|_0\leqslant s,\ \|\boldsymbol{x}\|_2=1\},$$

它是由 $\binom{n}{s}$ 个 s 维单位 Euclidean 球面组成的联合体。取网格精度参数 $\varepsilon_0=\frac{\delta}{4}$。设一个固定的 s 维坐标子空间，其单位球面的 ε_0-网的大小至多为 $(1+\frac{2}{\varepsilon_0})^s\leqslant(\frac{3}{\varepsilon_0})^s$；由于 supp 至多有 $\binom{n}{s}\leqslant(\frac{en}{s})^s$ 个，因此整个集合 $\mathbb{S}_{n,s}$ 的 ε_0-网 $\mathcal{N}$ 的总容量满足

$$|\mathcal{N}|\leqslant\binom{n}{s}\left(\frac{3}{\varepsilon_0}\right)^s\leqslant\left(\frac{en}{s}\right)^s\left(\frac{12}{\delta}\right)^s=\exp\left(s\ln\left(\frac{12en}{\delta s}\right)\right)。\tag{II}$$

• 联合界，连续化逼近

对网格 $\mathcal{N}$ 的任意的点利用 (I) 的结论 (取 $t=\delta/2$) 并取联合界：

$$\mathrm{P}\max_{\boldsymbol{z}\in\mathcal{N}}\left|\|\boldsymbol{Q}\boldsymbol{z}\|_2^2-1\right|\geqslant\frac{\delta}{2}\leqslant|\mathcal{N}|\cdot2\mathrm{e}^{-c_1m(\delta/2)^2}\leqslant2\exp\left(s\ln\left(\frac{12en}{\delta s}\right)-\frac{c_1}{4}\delta^2m\right)。$$

当测量数满足

$$m\geqslant\frac{8}{c_1}\delta^{-2}s\ln\left(\frac{12en}{\delta s}\right)$$

时，成立 $\max_{\boldsymbol{z}\in\mathcal{N}}\left|\|\boldsymbol{Q}\boldsymbol{z}\|_2^2-1\right|\leqslant\frac{\delta}{2}$ (w.h.p. $1-2\mathrm{e}^{-c_2\delta^2m}$)。根据引理 L4.4.1 (于离散网估计算子范数)，对同一 s 维子空间的任意的向量 $\boldsymbol{x}\in\mathbb{S}_{n,s}$，必有

$$\sup_{\boldsymbol{x}\in\mathbb{S}_{n,s}}\left|\|\boldsymbol{Q}\boldsymbol{x}\|_2^2-1\right|\leqslant\frac{\delta/2}{1-2\varepsilon_0}=\frac{\delta/2}{1-\delta/2}\leqslant\delta。\qquad(\delta<1)\tag{III}$$

根据正齐次性，对于任意的 s-稀疏向量 $\boldsymbol{x}\in\mathbb{R}^n$ (范数不限)，均满足

$$(1-\delta)\|\boldsymbol{x}\|_2^2\leqslant\|\boldsymbol{Q}\boldsymbol{x}\|_2^2\leqslant(1+\delta)\|\boldsymbol{x}\|_2^2。$$

(2) • 根据定理 T9.5.6 (RIP 蕴含精确恢复)

于第 (1) 问，将稀疏度取为 $2s$，将 RIP 常数固定为 $\delta_{2s}=1/4$ (容易知道 $\delta_{2s}=1/4<1/3$)。根据第 (1) 问的测量数

条件

$$m \geqslant C \cdot (1/4)^{-2}(2s)\ln\left(\frac{\mathrm{e}n}{2s}\right) = C_0 s \ln\left(\frac{\mathrm{e}n}{s}\right),$$

算子 $\boldsymbol{Q} = \sqrt{\frac{n}{m}}\boldsymbol{P}$ 满足阶数为 $2s$，常数为 $\delta_{2s} \leqslant 1/4 < 1/3$ 的 RIP（w.h.p. $1 - 2\mathrm{e}^{-cm}$）。根据定理 T9.5.6 (RIP 蕴含精确恢复)，可知任意的 s-稀疏向量 $\boldsymbol{x}$ 是优化问题

$$\arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1 \text{ s.t. } \boldsymbol{Q}\boldsymbol{z} = \boldsymbol{Q}\boldsymbol{x}$$

的唯一解。

约束条件的代数等价性

由于标量 $\sqrt{n/m} > 0$，线性约束是严格等价的：

$$\boldsymbol{Q}\boldsymbol{z} = \boldsymbol{Q}\boldsymbol{x} \text{当且仅当} \sqrt{\frac{n}{m}}\boldsymbol{P}\boldsymbol{z} = \sqrt{\frac{n}{m}}\boldsymbol{P}\boldsymbol{x} \text{当且仅当} \boldsymbol{P}\boldsymbol{z} = \boldsymbol{P}\boldsymbol{x}。$$

因此 $\boldsymbol{x}$ 是原优化程序 $\hat{\boldsymbol{x}} \in \arg\min_{\boldsymbol{z}\in\mathbb{R}^n} \|\boldsymbol{z}\|_1$ (满足 $\boldsymbol{P}\boldsymbol{z} = \boldsymbol{P}\boldsymbol{x}$) 的唯一精确解 ($\hat{\boldsymbol{x}} = \boldsymbol{x}$)。

注释 Gaussian 矩阵 $\boldsymbol{A}$ 的行空间于 Grassmann 流形各向同性均匀分布。

本题说明，无论从代数矩阵采样 $\boldsymbol{A}\boldsymbol{x}$ 出发，还是从纯几何正交投影 $\boldsymbol{P}\boldsymbol{x}$ 出发，受限等距性质与精确稀疏恢复的相变阈值 $m \asymp s\ln(\mathrm{e}n/s)$ 于数学完全一致。

34 [**次可加性**] 设 $f : V \to \mathbb{R}$ 为向量空间 V 的次可加函数。证明对于任意的 $x, y \in V$，

$$f(x) - f(y) \leqslant f(x - y)。$$

证明 构造拆分

设 $x, y \in V$。由于 V 是向量空间，差向量 $x - y \in V$，将向量 x 恒等拆分为

$$x = (x - y) + y。$$

根据次可加性

令 $a = x - y \in V$，$b = y \in V$。根据次可加性的定义，可得

$$f(x) = f((x - y) + y) \leqslant f(x - y) + f(y)。$$

移项化简

不等式两侧减去 $f(y)$，即得

$$f(x) - f(y) \leqslant f(x - y)。$$

注释 若 $f(-u) = f(u)$，交换 x, y 并用对称性可得

$$f(y) - f(x) \leqslant f(x - y),$$

因此

$$|f(x) - f(y)| \leqslant f(x - y)。$$

特别地，范数满足 $|\|x\| - \|y\|| \leqslant \|x - y\|$。此不等式将 $\|\boldsymbol{A}\boldsymbol{x}\|_2$ 与 $\|\boldsymbol{A}\boldsymbol{y}\|_2$ 的差归约为 $\|\boldsymbol{A}(\boldsymbol{x} - \boldsymbol{y})\|_2$。

35 [**各向异性分布的一般矩阵偏离**] 将定理 T9.6.3 (一般矩阵偏离不等式) 推广至行向量独立同分布于 $N(\boldsymbol{0}, \Sigma)$ 的 $m \times n$ 矩阵 $\boldsymbol{A}$，证明

设 $\boldsymbol{G} \in \mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵。设 $f : \mathbb{R}^m \to \mathbb{R}$ 为正齐次，次可加的函数，存在 $b > 0$ 满足对于任意的 $v \in \mathbb{R}^m$ 均满足 $f(v) \leqslant b\|v\|_2$，则对于任意的集合 $\mathbb{S} \subset \mathbb{R}^n$，恒成立

$$\mathrm{E}\left[\sup_{u\in\mathbb{S}} |f(\boldsymbol{G}u) - \mathrm{E}[f(\boldsymbol{G}u)]|\right] \leqslant Cb\gamma(\mathbb{S}),$$

其中 $\gamma(\mathbb{S}) = w(\mathbb{S}) = \mathrm{E}_g[\sup_{u\in\mathbb{S}}\langle g, u\rangle]$ 为集合的 Gaussian 宽度 (定理 T9.6.3 (一般矩阵偏离不等式))。设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为各向异性 Gaussian 随机矩阵，其行向量独立同分布于均值为零，协方差矩阵为 $\Sigma \in \mathbb{R}^{n\times n}$ ($\Sigma \succeq 0$) 的多元正态分布，即 $\boldsymbol{A}_i$ i.i.d. $\sim N(\boldsymbol{0}, \Sigma)$。

证明对于任意的集合 $\mathbb{T}\subset\mathbb{R}^n$，恒成立

$$\mathrm{E}\left[\sup_{x\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\right]\leqslant Cb\gamma(\Sigma^{1/2}\mathbb{T}),$$

其中 $\Sigma^{1/2}$ 为半正定对称协方差矩阵 Σ 的主平方根，$\Sigma^{1/2}\mathbb{T}=\{\Sigma^{1/2}x:x\in\mathbb{T}\}$ 为形变后的集合。

证明 协方差白化分解

由于 $\Sigma\in\mathbb{R}^{n\times n}$ 是对称半正定协方差矩阵 ($\Sigma\succeq 0$)，根据谱定理，可得正交对角化 $\Sigma=\boldsymbol{U}\Lambda\boldsymbol{U}^\top$。其主平方根定义为 $\Sigma^{1/2}=\boldsymbol{U}\Lambda^{1/2}\boldsymbol{U}^\top$，满足 $\Sigma^{1/2}$ 对称 ($(\Sigma^{1/2})^\top=\Sigma^{1/2}$)，$\Sigma^{1/2}\Sigma^{1/2}=\Sigma$。

设 $\boldsymbol{Z}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$ 为标准各向同性 Gaussian 向量，则线性变换向量满足 $\Sigma^{1/2}\boldsymbol{Z}\sim N(\boldsymbol{0},\Sigma^{1/2}\boldsymbol{I}_n(\Sigma^{1/2})^\top)=N(\boldsymbol{0},\Sigma)$。因此，矩阵 $\boldsymbol{A}$ 的任意一行 $\boldsymbol{A}_i$ 于分布等价于独立标准 Gaussian 向量 $\boldsymbol{G}_i\sim N(\boldsymbol{0},\boldsymbol{I}_n)$ 经 $\Sigma^{1/2}$ 的变换。设 $\boldsymbol{G}\in\mathbb{R}^{m\times n}$ 为元素独立同分布于 $N(0,1)$ 的标准各向同性 Gaussian 矩阵，由于行向量相互独立同分布，因此全矩阵满足同分布关系：

$$\boldsymbol{A}\overset{d}{=}\boldsymbol{G}\Sigma^{1/2}。\tag{I}$$

随机过程的几何集合变量替换

对于任意的固定向量 $\boldsymbol{x}\in\mathbb{T}\subset\mathbb{R}^n$，利用 (I)，矩阵乘法的结合律：

$$\boldsymbol{A}\boldsymbol{x}\overset{d}{=}(\boldsymbol{G}\Sigma^{1/2})\boldsymbol{x}=\boldsymbol{G}(\Sigma^{1/2}\boldsymbol{x})。$$

令变换后的向量为 $\boldsymbol{u}=\Sigma^{1/2}\boldsymbol{x}\in\mathbb{R}^n$。当 $\boldsymbol{x}$ 遍历集合 $\mathbb{T}$ 时，$\boldsymbol{u}$ 恰好遍历形变集合 $\mathbb{T}'=\Sigma^{1/2}\mathbb{T}=\{\Sigma^{1/2}\boldsymbol{x}:\boldsymbol{x}\in\mathbb{T}\}\subset\mathbb{R}^n$。因此，目标随机过程的上确界于联合分布完全等价：

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\overset{d}{=}\sup_{\boldsymbol{u}\in\Sigma^{1/2}\mathbb{T}}|f(\boldsymbol{G}\boldsymbol{u})-\mathrm{E}[f(\boldsymbol{G}\boldsymbol{u})]|。\tag{II}$$

- 根据定理 T9.6.3 (一般矩阵偏离不等式) 得出结论

对 (II) 的两侧取期望：

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\right]=\mathrm{E}\left[\sup_{\boldsymbol{u}\in\Sigma^{1/2}\mathbb{T}}|f(\boldsymbol{G}\boldsymbol{u})-\mathrm{E}[f(\boldsymbol{G}\boldsymbol{u})]|\right]。\tag{III}$$

注意此时 $\boldsymbol{G}$ 是元素独立同分布于 $N(0,1)$ 的标准 Gaussian 随机矩阵，函数 f 满足正齐次，次可加，$f(v)\leqslant b\|v\|_2$，作用的集合为 $\Sigma^{1/2}\mathbb{T}$。直接根据定理 T9.6.3 (一般矩阵偏离不等式) 于标准 Gaussian 矩阵 $\boldsymbol{G}$，集合 $\Sigma^{1/2}\mathbb{T}$：

$$\mathrm{E}\left[\sup_{\boldsymbol{u}\in\Sigma^{1/2}\mathbb{T}}|f(\boldsymbol{G}\boldsymbol{u})-\mathrm{E}[f(\boldsymbol{G}\boldsymbol{u})]|\right]\leqslant Cb\gamma(\Sigma^{1/2}\mathbb{T})。\tag{IV}$$

将 (IV) 代入于 (III)，可得

$$\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\right]\leqslant Cb\gamma(\Sigma^{1/2}\mathbb{T})。$$

注释 各向异性情形等价于将集合替换为 $\Sigma^{1/2}\mathbb{T}$ 后的各向同性情形。取 $f(v)=\|v\|_2$，$b=1$，即得 $\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\mathrm{E}\|\boldsymbol{A}\boldsymbol{x}\|_2|\right]\leqslant Cw(\Sigma^{1/2}\mathbb{T})$。

36 [一般矩阵偏离：高概率版本] 证明定理 T9.6.3 (一般矩阵偏离不等式) 的高概率版本。

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵 (元素 A_{ij} i.i.d. $\sim N(0,1)$)，$f:\mathbb{R}^m\to\mathbb{R}$ 为正齐次，次可加的函数；存在 $b>0$，对于任意的 $v\in\mathbb{R}^m$ 均满足 $f(v)\leqslant b\|v\|_2$，$\mathbb{T}\subset\mathbb{R}^n$ 为任意的子集，其 Euclidean 半径记为 $\mathrm{rad}(\mathbb{T})=\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2$，Gaussian 宽度记为 $\gamma(\mathbb{T})=w(\mathbb{T})=\mathrm{E}_g[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle g,\boldsymbol{x}\rangle]$。证明存在绝对常数 $C>0$，使得对于任意一个参数 $u\geqslant 0$，以高概率成立

$$\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\leqslant Cb(\gamma(\mathbb{T})+u\,\mathrm{rad}(\mathbb{T}))\ (\text{w.h.p. } 1-2\mathrm{e}^{-u^2})。$$

证明 利用习题 Q9.34 (次可加性) 证明 f 的 b-Lipschitz 连续性

$f:\mathbb{R}^m\to\mathbb{R}$ 是次可加函数，满足 $f(z)\leqslant b\|z\|_2$。对于任意的 $v,w\in\mathbb{R}^m$：根据习题 Q9.34 (次可加性) 的结论，$f(v)-f(w)\leqslant f(v-w)$；结合上界条件 $f(v-w)\leqslant b\|v-w\|_2$，可得 $f(v)-f(w)\leqslant b\|v-w\|_2$。交换 v, w 的角色，同理可得 $f(w)-f(v)\leqslant b\|w-v\|_2=b\|v-w\|_2$，即 $f(v)-f(w)\geqslant -b\|v-w\|_2$。综合两式，得到

$$|f(v)-f(w)|\leqslant b\|v-w\|_2。\tag{I}$$

由此严格证明了函数 f 是 b-Lipschitz 连续的。

- 证明目标泛函 $F(\boldsymbol{A})$ 的 Lipschitz 连续性

  在矩阵空间 $\mathbb{R}^{m\times n}$ (赋予 Frobenius 范数 $\|\boldsymbol{M}\|_F=\sqrt{\sum_{ij}\boldsymbol{M}_{ij}^2}$) 上定义泛函

  $$F(\boldsymbol{A})=\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|。$$

  设 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{m\times n}$ 为任意的两个矩阵。

  第一，定义确定性函数 $\mu(\boldsymbol{x})=\mathrm{E}_{\boldsymbol{G}}f(\boldsymbol{G}\boldsymbol{x})$，其中 $\boldsymbol{G}$ 为标准 Gaussian 矩阵。对于 $\boldsymbol{A}$ 的每个实现，中心化过程为 $f(\boldsymbol{A}\boldsymbol{x})-\mu(\boldsymbol{x})$；此处不涉及任意的确定矩阵 $\boldsymbol{B}$ 的分布。

  第二，点态扰动控制：对于任意的固定点 $\boldsymbol{x}\in\mathbb{T}$，根据绝对值的反三角不等式以及 (I)，

  $$||f(\boldsymbol{A}\boldsymbol{x})-\mu(\boldsymbol{x})|-|f(\boldsymbol{B}\boldsymbol{x})-\mu(\boldsymbol{x})||\leqslant|f(\boldsymbol{A}\boldsymbol{x})-f(\boldsymbol{B}\boldsymbol{x})|\leqslant b\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{B}\boldsymbol{x}\|_2=b\|(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{x}\|_2。$$

  第三，利用范数相容性以及集合半径：根据算子范数同 Frobenius 范数的关系 ($\|\boldsymbol{M}\|_{op}\leqslant\|\boldsymbol{M}\|_F$)，

  $$\|(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|_{op}\|\boldsymbol{x}\|_2\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|_F\cdot\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2=\mathrm{rad}(\mathbb{T})\|\boldsymbol{A}-\boldsymbol{B}\|_F。$$

  第四，取上确界：根据 $|\sup g-\sup h|\leqslant\sup|g-h|$，对于任意的 $\boldsymbol{x}\in\mathbb{T}$ 取上确界：

  $$|F(\boldsymbol{A})-F(\boldsymbol{B})|\leqslant b\,\mathrm{rad}(\mathbb{T})\|\boldsymbol{A}-\boldsymbol{B}\|_F。\tag{II}$$

  因此 F 是关于 Frobenius 范数的 L-Lipschitz 函数，其 Lipschitz 常数为 $L=b\,\mathrm{rad}(\mathbb{T})$。

- 根据定理 T5.2.2 (Gaussian 等周不等式)

  将矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 拉直为高维向量 $\mathrm{vec}(\boldsymbol{A})\in\mathbb{R}^{mn}$。由于 A_{ij} i.i.d. $\sim N(0,1)$，因此 $\mathrm{vec}(\boldsymbol{A})\sim N(\boldsymbol{0},\boldsymbol{I}_{mn})$ 是标准 Gaussian 随机向量。

  根据定理 T5.2.2 (Gaussian 等周不等式)，对 $\mathbb{R}^N$ 的任意的 L-Lipschitz 函数 F，标准正态向量 $\boldsymbol{G}\sim N(\boldsymbol{0},\boldsymbol{I}_N)$，对于任意的 $t\geqslant0$ 均满足

  $$\mathrm{P}|F(\boldsymbol{G})-\mathrm{E}[F(\boldsymbol{G})]|\geqslant t\leqslant2\exp\left(-\frac{t^2}{2L^2}\right)。$$

  将 $L=b\,\mathrm{rad}(\mathbb{T})$ 代入，单边尾部界满足

  $$\mathrm{P}F(\boldsymbol{A})\geqslant\mathrm{E}[F(\boldsymbol{A})]+t\leqslant2\exp\left(-\frac{t^2}{2b^2\,\mathrm{rad}(\mathbb{T})^2}\right)。\tag{III}$$

- 代入期望上界整合结论

  根据定理 T9.6.3 (一般矩阵偏离不等式)，存在绝对常数 $C_0>0$，使得

  $$\mathrm{E}[F(\boldsymbol{A})]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\right]\leqslant C_0b\gamma(\mathbb{T})。$$

  令 $t=\sqrt{2}u\cdot b\,\mathrm{rad}(\mathbb{T})$，此时指数项恰好为

  $$\frac{t^2}{2b^2\,\mathrm{rad}(\mathbb{T})^2}=\frac{2u^2b^2\,\mathrm{rad}(\mathbb{T})^2}{2b^2\,\mathrm{rad}(\mathbb{T})^2}=u^2。$$

  利用 (III) 的结论，可得

  $$F(\boldsymbol{A})\leqslant\mathrm{E}[F(\boldsymbol{A})]+\sqrt{2}ub\,\mathrm{rad}(\mathbb{T})\leqslant C_0b\gamma(\mathbb{T})+\sqrt{2}ub\,\mathrm{rad}(\mathbb{T})\ (\text{w.h.p. }1-2\mathrm{e}^{-u^2})。$$

  取绝对常数 $C=\max(C_0,\sqrt{2})$，即证得

  $$\sup_{\boldsymbol{x}\in\mathbb{T}}|f(\boldsymbol{A}\boldsymbol{x})-\mathrm{E}[f(\boldsymbol{A}\boldsymbol{x})]|\leqslant Cb(\gamma(\mathbb{T})+u\,\mathrm{rad}(\mathbb{T}))。$$

注释 取 $f(v)=\|v\|_2$，$b=1$ 且 $\mathbb{T}\subset\mathbb{S}^{n-1}$，便恢复习题 Q9.13 ($M^*$ 界：高概率版本) 的界 $\sup_{\boldsymbol{x}\in\mathbb{T}}|\|\boldsymbol{A}\boldsymbol{x}\|_2-\sqrt{m}|\leqslant C(w(\mathbb{T})+u)$。一般形式中，$b\gamma(\mathbb{T})$ 控制平均复杂度，$ub\,\mathrm{rad}(\mathbb{T})$ 控制偏差尺度。

37 [**一般范数的 Johnson–Lindenstrauss 引理**] 经典 Johnson–Lindenstrauss 引理说明，Euclidean 空间的任意的 N 点集合 $\boldsymbol{X}\subset\mathbb{R}^n$ 可经随机线性映射以 $(1\pm\varepsilon)$ 的相对精度嵌入低维 Euclidean 空间 $(\mathbb{R}^m,\|\cdot\|_2)$，其中 $N\geqslant2^2$ 且 $m\gtrsim\varepsilon^{-2}\ln N$。

利用定理 T9.6.3 (一般矩阵偏离不等式)，将目标空间推广到配备任意的范数 $\|\cdot\|$ 的赋范向量空间 $(\mathbb{R}^m, \|\cdot\|)$，严格陈述并证明一般范数的 Johnson–Lindenstrauss 降维引理。

证明 构造归一化差向量集合 $\mathbb{T}$ 为

$$\mathbb{T} = \{\overline{\boldsymbol{x}-\boldsymbol{y}} : \boldsymbol{x}, \boldsymbol{y} \in \boldsymbol{X},\ \boldsymbol{x} \neq \boldsymbol{y}\} \subset \mathbb{S}^{n-1}。$$

则 $|\mathbb{T}| \leqslant \binom{N}{2} = \frac{N(N-1)}{2} < N^2$，$\operatorname{rad}(\mathbb{T}) = 1$，

$$w(\mathbb{T}) = \mathrm{E}_g\left[\max_{\boldsymbol{u}\in\mathbb{T}} \langle g, \boldsymbol{u}\rangle\right] \leqslant \sqrt{2\ln|\mathbb{T}|} \leqslant \sqrt{2\ln(N^2)} = 2\sqrt{\ln N}。 \tag{I}$$

验证函数条件并计算均值

令 $f : \mathbb{R}^m \to \mathbb{R}$ 为目标范数 $f(v) = \|v\|$。

1. 正齐次性：对于任意的 $\alpha \geqslant 0$，$f(\alpha v) = \|\alpha v\| = \alpha\|v\| = \alpha f(v)$。
2. 次可加性：利用范数三角不等式，可得 $f(u+v) = \|u+v\| \leqslant \|u\| + \|v\| = f(u) + f(v)$；有界条件：根据 b 的定义，对于任意的 $v \in \mathbb{R}^m$，均满足 $f(v) = \|v\| \leqslant b\|v\|_2$。

对于任意的固定 $\boldsymbol{u} \in \mathbb{T} \subset \mathbb{S}^{n-1}$ ($\|\boldsymbol{u}\|_2 = 1$)，由于 $\boldsymbol{A}$ 为标准 Gaussian 矩阵，投影向量 $\boldsymbol{A}\boldsymbol{u} \sim N(\boldsymbol{0}, \boldsymbol{I}_m)$ 与 $\boldsymbol{g}_m$ 同分布。因此均值函数为

$$\mathrm{E}[f(\boldsymbol{A}\boldsymbol{u})] = \mathrm{E}[\|\boldsymbol{A}\boldsymbol{u}\|] = \mathrm{E}[\|\boldsymbol{g}_m\|] = h_m, \tag{II}$$

其中 $h_m = \mathrm{E}[\|\boldsymbol{g}_m\|]$ 为标准 Gaussian 向量的期望范数 (均值宽度)。

- 根据一般矩阵偏差不等式的高概率版本 (习题 Q9.36 (一般矩阵偏离：高概率版本))

  根据习题 Q9.36 (一般矩阵偏离：高概率版本)，对于任意一个参数 $t \geqslant 0$，成立

  $$\sup_{\boldsymbol{u}\in\mathbb{T}} |\|\boldsymbol{A}\boldsymbol{u}\| - \mathrm{E}[\|\boldsymbol{A}\boldsymbol{u}\|]| \leqslant C_0 b(w(\mathbb{T}) + t\operatorname{rad}(\mathbb{T})) \text{ (w.h.p. } 1 - 2\mathrm{e}^{-t^2})。$$

  将 (I) 的 $w(\mathbb{T}) \leqslant 2\sqrt{\ln N}$，(II) 的均值 h_m 以及 $\operatorname{rad}(\mathbb{T}) = 1$ 代入，可得

  $$\sup_{\boldsymbol{u}\in\mathbb{T}} |\|\boldsymbol{A}\boldsymbol{u}\| - h_m| \leqslant C_0 b(2\sqrt{\ln N} + t)。$$

  选取参数 $t = \sqrt{\ln N}$，此时失败概率为 $2\mathrm{e}^{-t^2} = 2\mathrm{e}^{-\ln N} = \frac{2}{N}$。因此，成立

  $$\sup_{\boldsymbol{u}\in\mathbb{T}} |\|\boldsymbol{A}\boldsymbol{u}\| - h_m| \leqslant 3C_0 b\sqrt{\ln N} \left(\text{w.h.p. } 1 - \frac{2}{N}\right)。 \tag{III}$$

- 两侧归一化并还原点对距离

  将 (III) 两侧除以期望尺度因子 h_m：

  $$\sup_{\boldsymbol{u}\in\mathbb{T}} \left| \frac{\|\boldsymbol{A}\boldsymbol{u}\|}{h_m} - 1 \right| \leqslant \frac{3C_0 b\sqrt{\ln N}}{h_m}。$$

  若目标维数满足题目条件

  $$\left(\frac{h_m}{b}\right)^2 \geqslant \frac{(3C_0)^2}{\varepsilon^2}\ln N = C\varepsilon^{-2}\ln N \text{当且仅当} \frac{3C_0 b\sqrt{\ln N}}{h_m} \leqslant \varepsilon,$$

  则立即得到

  $$\sup_{\boldsymbol{u}\in\mathbb{T}} \left| \left\| \frac{1}{h_m}\boldsymbol{A}\boldsymbol{u} \right\| - 1 \right| \leqslant \varepsilon。$$

  将单位差向量 $\overline{\boldsymbol{x}-\boldsymbol{y}} \in \mathbb{T}$ 代入，根据范数的绝对齐次性，对于任意的 $\boldsymbol{x} \neq \boldsymbol{y} \in \boldsymbol{X}$ 同乘 $\|\boldsymbol{x}-\boldsymbol{y}\|_2$：

  $$\left| \left\| \frac{1}{h_m}\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y}) \right\| - \|\boldsymbol{x}-\boldsymbol{y}\|_2 \right| \leqslant \varepsilon\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

  展开绝对值即得

  $$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \left\| \frac{1}{h_m}\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y}) \right\| \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

注释 对 ℓ_2 与 ℓ_1，$(h_m/b)^2 \asymp m$，故所需维数为 $m \gtrsim \varepsilon^{-2}\ln N$。

对 ℓ_∞，$(h_m/b)^2 \asymp \ln m$，故 $m \gtrsim N^{C/\varepsilon^2}$。

临界量 $(h_m/b)^2$ 决定一般范数的降维尺度。

38 [ℓ_1 **范数的 Johnson–Lindenstrauss 引理**] 将习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 特化于 ℓ_1 范数。令 X 为 $\mathbb{R}^n$ 的 N 点集合，$\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 为 Gaussian 矩阵 (元素独立同分布 $N(0,1)$)，$\varepsilon \in (0,1)$。假设

$$m \geqslant C_\varepsilon \ln N。$$

证明矩阵 (w.h.p.)

$$\boldsymbol{Q} = \sqrt{\frac{\pi}{2}}\frac{1}{m}\boldsymbol{A}$$

满足

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_1 \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \text{ 对于任意的} \boldsymbol{x},\boldsymbol{y} \in X。$$

证明 • 计算 Gaussian 均值宽度 h_m，归一化算子 $\boldsymbol{Q}$

设 $\boldsymbol{g}_m = (g_1, g_2, \cdots, g_m) \sim N(\boldsymbol{0}, \boldsymbol{I}_m)$ 为标准 Gaussian 随机向量。

第一，计算单个标准正态变量的一阶绝对矩 $\mathrm{E}[|g_1|]$：

$$\mathrm{E}[|g_1|] = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}|t|\mathrm{e}^{-t^2/2}dt = \frac{2}{\sqrt{2\pi}}\int_0^{+\infty} t\mathrm{e}^{-t^2/2}dt = \sqrt{\frac{2}{\pi}}\left[-\mathrm{e}^{-t^2/2}\right]_0^{+\infty} = \sqrt{\frac{2}{\pi}}。$$

第二，由于期望是线性的，因此 ℓ_1 范数的期望值 h_m 为

$$h_m = \mathrm{E}[\|\boldsymbol{g}_m\|_1] = \mathrm{E}\left[\sum_{i=1}^m |g_i|\right] = \sum_{i=1}^m \mathrm{E}[|g_i|] = m\sqrt{\frac{2}{\pi}} = \sqrt{\frac{2}{\pi}}m。 \tag{I}$$

第三，根据习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 的归一化形式 $\boldsymbol{Q} = \frac{1}{h_m}\boldsymbol{A}$，将其代入 (I)：

$$\boldsymbol{Q} = \frac{1}{\sqrt{\frac{2}{\pi}}m}\boldsymbol{A} = \sqrt{\frac{\pi}{2}}\frac{1}{m}\boldsymbol{A}, \tag{II}$$

由此精确推导出了题目中给出的矩阵 $\boldsymbol{Q}$ 的形式。

计算外接 Euclidean 比例常数 b

根据参数 b 的定义，结合 Cauchy–Schwarz 不等式：对于任意的 $v = (v_1, \cdots, v_m) \in \mathbb{S}^{m-1}$ (即 $\|v\|_2 = 1$)，

$$\|v\|_1 = \sum_{i=1}^m |v_i| \leqslant \left(\sum_{i=1}^m 1^2\right)^{1/2}\left(\sum_{i=1}^m v_i^2\right)^{1/2} = \sqrt{m}\|v\|_2 = \sqrt{m}。$$

当选取 $v = (\frac{1}{\sqrt{m}}, \cdots, \frac{1}{\sqrt{m}})$ 时，等号成立。因此

$$b = \sup_{\|v\|_2=1}\|v\|_1 = \sqrt{m}。 \tag{III}$$

• 计算临界有效维数并导出所需维数条件

利用 (I)，(III)，计算关键几何比值：

$$\frac{h_m}{b} = \frac{\sqrt{\frac{2}{\pi}}m}{\sqrt{m}} = \sqrt{\frac{2}{\pi}}\sqrt{m}。$$

两侧平方：

$$\left(\frac{h_m}{b}\right)^2 = \frac{2}{\pi}m。 \tag{IV}$$

根据习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 证明的一般范数 JL 定理，$(\frac{h_m}{b})^2 \geqslant C_0\varepsilon^{-2}\ln N$ 是 $(1\pm\varepsilon)$ 等距嵌入的充分条件。将 (IV) 代入，可得

$$\frac{2}{\pi}m \geqslant C_0\varepsilon^{-2}\ln N \text{当且仅当} m \geqslant \left(\frac{\pi}{2}C_0\varepsilon^{-2}\right)\ln N = C_\varepsilon \ln N。 \tag{V}$$

- 得出最终结论

  在条件 (V) 成立时，直接套用习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 的定理结论，对于任意的 $\boldsymbol{x},\boldsymbol{y}\in X$ 成立

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}(\boldsymbol{x}-\boldsymbol{y})\|_1 \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \left(\text{w.h.p. } 1-\frac{2}{N}\right)。$$

  根据线性性 $\boldsymbol{Q}(\boldsymbol{x}-\boldsymbol{y})=\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}$，即

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_1 \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

注释 $\ell_2\to\ell_1$ 嵌入保持 Euclidean 距离所需的维数仍为 $m=\mathcal{O}(\varepsilon^{-2}\ln N)$。

39 [嵌入 ℓ_∞] 将习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 特化于 ℓ_∞ 范数。令 X 为 $\mathbb{R}^n$ 的 N 点集合，$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为 Gaussian 矩阵 (元素独立同分布 $N(0,1)$)，$\varepsilon\in(0,1)$。假设

$$m\geqslant N^{C_\varepsilon}。$$

证明以高概率，矩阵

$$\boldsymbol{Q}=\frac{1}{h_m}\boldsymbol{A},\qquad h_m=\mathrm{E}\|\boldsymbol{g}_m\|_\infty \left(\text{w.h.p. } 1-\frac{2}{N}\right)$$

实现从 $(\mathbb{R}^n,\|\cdot\|_2)$ 到 $(\mathbb{R}^m,\|\cdot\|_\infty)$ 的近等距嵌入，即对于任意的 $\boldsymbol{x},\boldsymbol{y}\in X$ 满足

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_\infty \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

注意此时 $m\geqslant N$，因此 $\boldsymbol{Q}$ 不是降维映射而是高维近等距嵌入。

证明 计算外接 Euclidean 比例常数 b

根据 ℓ_∞ 范数与 ℓ_2 范数的关系：对于任意的 $v=(v_1,v_2,\cdots,v_m)\in\mathbb{S}^{m-1}$ (即 $\sum_{i=1}^m v_i^2=1$)，

$$\|v\|_\infty=\max_{1\leqslant i\leqslant m}|v_i|\leqslant\sqrt{\sum_{i=1}^m v_i^2}=\|v\|_2=1。$$

取标准基向量 $v=\boldsymbol{e}_1=(1,0,\cdots,0)$ 时，$\|\boldsymbol{e}_1\|_2=1$，$\|\boldsymbol{e}_1\|_\infty=1$，等号成立。因此

$$b=\sup_{\|v\|_2=1}\|v\|_\infty=1。\tag{I}$$

- 计算 Gaussian 均值宽度 h_m 并确定算子 $\boldsymbol{Q}$

  设 $\boldsymbol{g}_m=(g_1,g_2,\cdots,g_m)\sim N(\boldsymbol{0},\boldsymbol{I}_m)$ 为标准 Gaussian 随机向量。

  第一，计算极值期望 h_m：

$$h_m=\mathrm{E}[\|\boldsymbol{g}_m\|_\infty]=\mathrm{E}\left[\max_{1\leqslant i\leqslant m}|g_i|\right]。$$

  根据标准正态极值理论，对 m 个独立标准正态变量的绝对值最大值，当 $m\geqslant 2$ 时存在正常数 $c_1,c_2>0$ 满足

$$c_1\sqrt{\ln m}\leqslant h_m\leqslant c_2\sqrt{\ln m}。\tag{II}$$

  第二，确定缩放矩阵 $\boldsymbol{Q}$ 的形式：利用习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 的结论，归一化映射为 $\boldsymbol{Q}=\frac{1}{h_m}\boldsymbol{A}$。利用 (II) 的结论，

$$\boldsymbol{Q}=\frac{1}{h_m}\boldsymbol{A}\asymp(\ln m)^{-1/2}\boldsymbol{A},\tag{III}$$

  其中比例因子随 m 变化，但由两个绝对正常数一致夹逼。

- 计算临界比值并推导维数条件 $m\geqslant N^{C_\varepsilon}$

  利用 (I) ($b=1$) 和 (II) ($h_m\geqslant c_1\sqrt{\ln m}$) 的结论，临界几何比值为

$$\left(\frac{h_m}{b}\right)^2=\frac{h_m^2}{1^2}\geqslant c_1^2\ln m。\tag{IV}$$

  根据习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理)，要使 $(1\pm\varepsilon)$ 近等距嵌入成立，需满足 $(\frac{h_m}{b})^2\geqslant C_0\varepsilon^{-2}\ln N$ (w.h.p. 1−

$\frac{2}{N}$)。结合 (IV)，只需满足

$$c_1^2 \ln m \geqslant C_0 \varepsilon^{-2} \ln N \text{当且仅当} \ln m \geqslant \left(\frac{C_0}{c_1^2}\varepsilon^{-2}\right) \ln N。$$

定义常数 $C_\varepsilon = \frac{C_0}{c_1^2}\varepsilon^{-2} = \mathcal{O}(\varepsilon^{-2})$。两侧取指数：

$$m \geqslant \exp(C_\varepsilon \ln N) = N^{C_\varepsilon}。 \tag{V}$$

- 得出结论

在条件 (V) 成立时，直接根据习题 Q9.37 (一般范数的 Johnson–Lindenstrauss 引理) 的定理，对于任意的点对 $\boldsymbol{x}, \boldsymbol{y} \in X$ 均成立

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \left\|\frac{1}{h_m}\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})\right\|_\infty \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \left(\text{w.h.p. } 1-\frac{2}{N}\right)。$$

将 $\boldsymbol{Q} = \frac{1}{h_m}\boldsymbol{A}$ 代入，即得

$$(1-\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2 \leqslant \|\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{Q}\boldsymbol{y}\|_\infty \leqslant (1+\varepsilon)\|\boldsymbol{x}-\boldsymbol{y}\|_2。$$

注释 对 ℓ_∞^m，Gaussian 宽度仅以 $\sqrt{\ln m}$ 增长，因此 Dvoretzky 临界维数为 $\asymp \ln m$。

要嵌入 $\asymp \ln N$ 维的 Euclidean 几何，必须有 $m \geqslant N^{C_\varepsilon}$。

40 [**凸包与支撑函数的对偶性**] 证明对非空闭有界集 $V \subset \mathbb{R}^m$，其支撑函数接近 Euclid 范数当且仅当其凸包接近 Euclid 球。具体地，对 $r_-, r_+ \geqslant 0$，证明

$$r_-\mathbb{B}_2^m \subset \operatorname{conv}(V) \subset r_+\mathbb{B}_2^m$$

当且仅当

$$r_-\|\boldsymbol{y}\|_2 \leqslant \sup_{\boldsymbol{x}\in V}\langle \boldsymbol{x}, \boldsymbol{y}\rangle \leqslant r_+\|\boldsymbol{y}\|_2 \text{ 对于任意的} \boldsymbol{y} \in \mathbb{R}^m。$$

证明

- 支撑函数的基本性质

集合 $S \subset \mathbb{R}^m$ 的支撑函数定义为

$$h_S(\boldsymbol{y}) = \sup_{\boldsymbol{x}\in S}\langle \boldsymbol{x}, \boldsymbol{y}\rangle。 \qquad (\boldsymbol{y} \in \mathbb{R}^m)$$

本证明利用凸分析的三个基本性质。

第一，凸包不变性：由于线性函数 $\langle \cdot, \boldsymbol{y}\rangle$ 于集合 V 及其凸包 $\operatorname{conv}(V)$ 取得相同的上确界：

$$h_V(\boldsymbol{y}) = \sup_{\boldsymbol{x}\in V}\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \sup_{\boldsymbol{x}\in \operatorname{conv}(V)}\langle \boldsymbol{x}, \boldsymbol{y}\rangle = h_{\operatorname{conv}(V)}(\boldsymbol{y})。$$

第二，紧凸性：由于 V 是紧集 (闭且有界)，因此 $K = \operatorname{conv}(V)$ 同样是 $\mathbb{R}^m$ 的非空紧凸集。

第三，Euclidean 球的支撑函数：根据 Cauchy–Schwarz 不等式，半径为 r 的 Euclidean 球 $r\mathbb{B}_2^m$ 的支撑函数为

$$h_{r\mathbb{B}_2^m}(\boldsymbol{y}) = \sup_{\|\boldsymbol{x}\|_2\leqslant r}\langle \boldsymbol{x}, \boldsymbol{y}\rangle = r\|\boldsymbol{y}\|_2。$$

因此，待证命题等价于对非空紧凸集 $K = \operatorname{conv}(V)$ 证明

$$r_-\mathbb{B}_2^m \subset K \subset r_+\mathbb{B}_2^m \text{当且仅当} r_-\|\boldsymbol{y}\|_2 \leqslant h_K(\boldsymbol{y}) \leqslant r_+\|\boldsymbol{y}\|_2。 \qquad (\boldsymbol{y} \in \mathbb{R}^m)$$

- 外包含等价性 $K \subset r_+\mathbb{B}_2^m$ 当且仅当 $h_K(\boldsymbol{y}) \leqslant r_+\|\boldsymbol{y}\|_2$

必要性：假设 $K \subset r_+\mathbb{B}_2^m$。对于任意的 $\boldsymbol{y} \in \mathbb{R}^m$，

$$h_K(\boldsymbol{y}) = \sup_{\boldsymbol{x}\in K}\langle \boldsymbol{x}, \boldsymbol{y}\rangle \leqslant \sup_{\boldsymbol{x}\in r_+\mathbb{B}_2^m}\langle \boldsymbol{x}, \boldsymbol{y}\rangle = r_+\|\boldsymbol{y}\|_2。$$

充分性：假设对于任意的 $\boldsymbol{y} \in \mathbb{R}^m$，均满足 $h_K(\boldsymbol{y}) \leqslant r_+\|\boldsymbol{y}\|_2$。目标是证明任意的点 $\boldsymbol{x} \in K$ 均满足 $\|\boldsymbol{x}\|_2 \leqslant r_+$。设 $\boldsymbol{x} \in K$。若 $\boldsymbol{x} = \boldsymbol{0}$，则结论是平凡的；之后只需考虑 $\boldsymbol{x} \neq \boldsymbol{0}$ 的情况，于假设选取测试向量 $\boldsymbol{y} = \boldsymbol{x}$：

$$\|\boldsymbol{x}\|_2^2 = \langle \boldsymbol{x}, \boldsymbol{x}\rangle \leqslant \sup_{\boldsymbol{z}\in K}\langle \boldsymbol{z}, \boldsymbol{x}\rangle = h_K(\boldsymbol{x}) \leqslant r_+\|\boldsymbol{x}\|_2。$$

两侧同除以正数 $\|\boldsymbol{x}\|_2$，立即得到 $\|\boldsymbol{x}\|_2 \leqslant r_+$。由此可知 K 的任意点的 Euclidean 模长均不超过 r_+，即 $K \subset r_+\mathbb{B}_2^m$。

由此证得

$$\operatorname{conv}(V) \subset r_+\mathbb{B}_2^m \text{当且仅当} \sup_{\boldsymbol{x}\in V}\langle \boldsymbol{x},\boldsymbol{y}\rangle \leqslant r_+\|\boldsymbol{y}\|_2。 \qquad (\boldsymbol{y}\in\mathbb{R}^m)\text{(I)}$$

- 内包含等价性 $r_-\mathbb{B}_2^m \subset K$当且仅当$h_K(\boldsymbol{y}) \geqslant r_-\|\boldsymbol{y}\|_2$

  必要性：假设 $r_-\mathbb{B}_2^m \subset K$。对于任意的 $\boldsymbol{y}\in\mathbb{R}^m$，

  $$h_K(\boldsymbol{y}) = \sup_{\boldsymbol{x}\in K}\langle \boldsymbol{x},\boldsymbol{y}\rangle \geqslant \sup_{\boldsymbol{x}\in r_-\mathbb{B}_2^m}\langle \boldsymbol{x},\boldsymbol{y}\rangle = r_-\|\boldsymbol{y}\|_2。$$

  充分性：假设对于任意的 $\boldsymbol{y}\in\mathbb{R}^m$，均满足 $h_K(\boldsymbol{y}) \geqslant r_-\|\boldsymbol{y}\|_2$，证明如下。

  若 $r_- = 0$，则 $r_-\mathbb{B}_2^m = \{\boldsymbol{0}\}$。若 $\boldsymbol{0}\notin K$，根据凸集严格分离定理，可得存在 $\boldsymbol{y}_0$，使得 $h_K(\boldsymbol{y}_0) < \langle \boldsymbol{0},\boldsymbol{y}_0\rangle = 0$，同 $h_K(\boldsymbol{y}_0) \geqslant r_-\|\boldsymbol{y}_0\|_2 = 0$ 矛盾；如此，$\boldsymbol{0}\in K$。

  之后只需考虑 $r_- > 0$ 的情况。利用反证法，假设 $r_-\mathbb{B}_2^m \not\subset K$，则存在点 $\boldsymbol{x}_0 \in r_-\mathbb{B}_2^m$ 满足 $\boldsymbol{x}_0\notin K$。由于 K 是 $\mathbb{R}^m$ 的非空闭凸集，单点集 $\{\boldsymbol{x}_0\}$ 是不与 K 相交的紧凸集，根据超平面严格分离定理，可得必定存在一个非零方向向量 $\boldsymbol{y}_0\in\mathbb{R}^m$ $(\boldsymbol{y}_0\neq\boldsymbol{0})$，实数 $\alpha\in\mathbb{R}$，使得超平面严格将 K 同 $\boldsymbol{x}_0$ 分离：

  $$\sup_{\boldsymbol{x}\in K}\langle \boldsymbol{x},\boldsymbol{y}_0\rangle < \alpha < \langle \boldsymbol{x}_0,\boldsymbol{y}_0\rangle,$$

  即

  $$h_K(\boldsymbol{y}_0) < \langle \boldsymbol{x}_0,\boldsymbol{y}_0\rangle。 \qquad \text{(II)}$$

  另一方面，由于 $\boldsymbol{x}_0\in r_-\mathbb{B}_2^m$ (即 $\|\boldsymbol{x}_0\|_2\leqslant r_-$)，因此根据 Cauchy–Schwarz 不等式，

  $$\langle \boldsymbol{x}_0,\boldsymbol{y}_0\rangle \leqslant \|\boldsymbol{x}_0\|_2\|\boldsymbol{y}_0\|_2 \leqslant r_-\|\boldsymbol{y}_0\|_2。 \qquad \text{(III)}$$

  将其代入于 (II)，可得 $h_K(\boldsymbol{y}_0) < r_-\|\boldsymbol{y}_0\|_2$。此结果同已知假设“对于任意的 $\boldsymbol{y}\in\mathbb{R}^m$ 恒成立 $h_K(\boldsymbol{y}) \geqslant r_-\|\boldsymbol{y}\|_2$”发生直接矛盾；如此，假设不成立，必须有 $r_-\mathbb{B}_2^m \subset K = \operatorname{conv}(V)$。

  由此证得

  $$r_-\mathbb{B}_2^m \subset \operatorname{conv}(V) \text{当且仅当} \sup_{\boldsymbol{x}\in V}\langle \boldsymbol{x},\boldsymbol{y}\rangle \geqslant r_-\|\boldsymbol{y}\|_2。 \qquad (\boldsymbol{y}\in\mathbb{R}^m)\text{(IV)}$$

综合结论

综合 (I)，(IV)，充要条件全部成立：

$$r_-\mathbb{B}_2^m \subset \operatorname{conv}(V) \subset r_+\mathbb{B}_2^m \text{当且仅当} r_-\|\boldsymbol{y}\|_2 \leqslant \sup_{\boldsymbol{x}\in V}\langle \boldsymbol{x},\boldsymbol{y}\rangle \leqslant r_+\|\boldsymbol{y}\|_2。 \qquad (\boldsymbol{y}\in\mathbb{R}^m)$$

注释 支撑函数 h_K 唯一确定闭凸集 K。因此，若 $h_K(\boldsymbol{y})$ 于任意的方向均被 $(1\pm\varepsilon)\|\boldsymbol{y}\|_2$ 夹逼，则 K 被相应的 Euclidean 球夹逼。

41 [**Dvoretzky–Milman 定理的高概率版本**] 证明定理 T9.7.2 (Dvoretzky–Milman 定理) 的高概率版本。

设 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 为标准 Gaussian 随机矩阵，$\mathbb{T}\subset\mathbb{R}^n$ 为非空紧集。证明：对于任意的 $u\geqslant 0$，$\mathbb{T}$ 的 Gaussian 随机投影 $\operatorname{conv}(\boldsymbol{A}\mathbb{T})$ 以高概率被两个同心 Euclidean 球紧密夹逼，即

$$r_-(u)\mathbb{B}_2^m \subset \operatorname{conv}(\boldsymbol{A}\mathbb{T}) \subset r_+(u)\mathbb{B}_2^m \text{ (w.h.p. } 1-2\mathrm{e}^{-u^2}), \qquad (C>0)$$

其中内外半径分别为

$$r_\pm(u) = w(\mathbb{T}) \pm C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})。$$

(注：右侧外包含始终成立；左侧内包含在 $r_-(u)\geqslant 0$ 时成立。)

证明 利用凸几何对偶性转化问题 (习题 Q9.40 (凸包与支撑函数的对偶性))

令 $V = \boldsymbol{A}\mathbb{T}\subset\mathbb{R}^m$。由于 $\mathbb{T}$ 有界，V 也是有界的。根据习题 Q9.40 (凸包与支撑函数的对偶性)，

$$r_-\mathbb{B}_2^m \subset \operatorname{conv}(\boldsymbol{A}\mathbb{T}) \subset r_+\mathbb{B}_2^m \text{当且仅当} r_-\|\boldsymbol{y}\|_2 \leqslant \sup_{\boldsymbol{z}\in\boldsymbol{A}\mathbb{T}}\langle \boldsymbol{z},\boldsymbol{y}\rangle \leqslant r_+\|\boldsymbol{y}\|_2 \ (\forall \boldsymbol{y}\in\mathbb{R}^m)。$$

根据正齐次性，只需对于任意的 $\boldsymbol{y}\in\mathbb{S}^{m-1}$ (即 $\|\boldsymbol{y}\|_2=1$) 证明：

$$r_-(u)\leqslant\sup_{\boldsymbol{z}\in\boldsymbol{A}\mathbb{T}}\langle\boldsymbol{z},\boldsymbol{y}\rangle\leqslant r_+(u)\ (\forall\boldsymbol{y}\in\mathbb{S}^{m-1})。\tag{I}$$

- 将投影支撑函数改写为转置 Gaussian 矩阵的作用

  对于任意的固定 $\boldsymbol{y}\in\mathbb{S}^{m-1}$，利用矩阵内积的伴随性质：

$$\sup_{\boldsymbol{z}\in\boldsymbol{A}\mathbb{T}}\langle\boldsymbol{z},\boldsymbol{y}\rangle=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{y}\rangle=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{A}^\top\boldsymbol{y}\rangle。$$

  定义 $\mathbb{T}$ 的支撑函数 $f:\mathbb{R}^n\to\mathbb{R}$：

$$f(\boldsymbol{v})=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{v}\rangle\ (\boldsymbol{v}\in\mathbb{R}^n)。$$

  第一，验证函数 f 的几何性质：正齐次性，对于任意的 $\alpha\geqslant0$，$f(\alpha\boldsymbol{v})=\alpha f(\boldsymbol{v})$；次可加性，$f(\boldsymbol{u}+\boldsymbol{v})\leqslant f(\boldsymbol{u})+f(\boldsymbol{v})$；有界条件，根据 Cauchy–Schwarz 不等式

$$f(\boldsymbol{v})=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{v}\rangle\leqslant\left(\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2\right)\|\boldsymbol{v}\|_2=\operatorname{rad}(\mathbb{T})\|\boldsymbol{v}\|_2,$$

  因此比例常数为 $b=\operatorname{rad}(\mathbb{T})$。第二，计算期望均值。对于任意的固定 $\boldsymbol{y}\in\mathbb{S}^{m-1}$ ($\|\boldsymbol{y}\|_2=1$)，由于 $\boldsymbol{A}$ 为标准 Gaussian 矩阵，转置向量 $\boldsymbol{A}^\top\boldsymbol{y}\sim N(\boldsymbol{0},\boldsymbol{I}_n)$ 是 $\mathbb{R}^n$ 的标准 Gaussian 随机向量。因此

$$\mathrm{E}[f(\boldsymbol{A}^\top\boldsymbol{y})]=\mathrm{E}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{A}^\top\boldsymbol{y}\rangle\right]=\mathrm{E}_{\boldsymbol{g}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{g}\rangle\right]=w(\mathbb{T})。\tag{II}$$

  注意到此期望值对于任意的 $\boldsymbol{y}\in\mathbb{S}^{m-1}$ 均为恒定常数 $w(\mathbb{T})$。

根据一般矩阵偏差不等式的高概率版本 (习题 Q9.36 (一般矩阵偏离：高概率版本))

考察转置矩阵 $\boldsymbol{B}=\boldsymbol{A}^\top\in\mathbb{R}^{n\times m}$。矩阵 $\boldsymbol{B}$ 的元素独立同分布于 $N(0,1)$。将习题 Q9.36 (一般矩阵偏离：高概率版本) 利用于矩阵 $\boldsymbol{B}\in\mathbb{R}^{n\times m}$，定义于 $\mathbb{R}^n$ 的泛函 $f(\boldsymbol{v})=\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{v}\rangle$ (常数 $b=\operatorname{rad}(\mathbb{T})$)，作用的集合为 Euclidean 单位球面 $\mathbb{S}=\mathbb{S}^{m-1}\subset\mathbb{R}^m$。计算集合 $\mathbb{S}=\mathbb{S}^{m-1}$ 的两个几何特征量：集合半径 $\operatorname{rad}(\mathbb{S})=\operatorname{rad}(\mathbb{S}^{m-1})=1$；Gaussian 复杂度 $\gamma(\mathbb{S})=w(\mathbb{S}^{m-1})=\mathrm{E}_{\boldsymbol{g}_m}\|\boldsymbol{g}_m\|_2\leqslant\sqrt{m}$ (其中 $\boldsymbol{g}_m\sim N(\boldsymbol{0},\boldsymbol{I}_m)$)。根据习题 Q9.36 (一般矩阵偏离：高概率版本) 的高概率界，对于任意的 $u\geqslant0$，满足

$$\sup_{\boldsymbol{y}\in\mathbb{S}^{m-1}}|f(\boldsymbol{B}\boldsymbol{y})-\mathrm{E}[f(\boldsymbol{B}\boldsymbol{y})]|\leqslant C_0b(\gamma(\mathbb{S})+u\operatorname{rad}(\mathbb{S}))\leqslant C_0\operatorname{rad}(\mathbb{T})(\sqrt{m}+u)=C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})\ (\text{w.h.p. }1-2\mathrm{e}^{-u^2})。\tag{III}$$

- 结合对偶性得出最终几何夹逼界

  利用 (II) 的结论，将 $\mathrm{E}[f(\boldsymbol{B}\boldsymbol{y})]=w(\mathbb{T})$ 代入 (III)，成立

$$\sup_{\boldsymbol{y}\in\mathbb{S}^{m-1}}\left|\sup_{\boldsymbol{z}\in\boldsymbol{A}\mathbb{T}}\langle\boldsymbol{z},\boldsymbol{y}\rangle-w(\mathbb{T})\right|\leqslant C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})\ (\text{w.h.p. }1-2\mathrm{e}^{-u^2})。$$

  展开绝对值不等式，对于任意的 $\boldsymbol{y}\in\mathbb{S}^{m-1}$ 一致成立

$$w(\mathbb{T})-C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})\leqslant\sup_{\boldsymbol{z}\in\boldsymbol{A}\mathbb{T}}\langle\boldsymbol{z},\boldsymbol{y}\rangle\leqslant w(\mathbb{T})+C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})。$$

  令内外半径 $r_\pm(u)=w(\mathbb{T})\pm C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})$。再次根据习题 Q9.40 (凸包与支撑函数的对偶性) 的对偶等价性，上述支撑函数的不等式精确等价于空间包含关系

$$r_-(u)\mathbb{B}_2^m\subset\operatorname{conv}(\boldsymbol{A}\mathbb{T})\subset r_+(u)\mathbb{B}_2^m。$$

注释 若 m 满足 Dvoretzky 临界维数条件

$$m\leqslant c\varepsilon^2\left(\frac{w(\mathbb{T})}{\operatorname{rad}(\mathbb{T})}\right)^2,$$

令 $u=\sqrt{m}$，此时波动项满足

$$C(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})\leqslant2C\sqrt{m}\operatorname{rad}(\mathbb{T})\leqslant\varepsilon w(\mathbb{T})。$$

则随机 m 维投影 $\operatorname{conv}(\boldsymbol{A}\mathbb{T})$ 满足 (w.h.p. $1-2\mathrm{e}^{-m}$)

$$(1-\varepsilon)w(\mathbb{T})\mathbb{B}_2^m \subset \operatorname{conv}(\boldsymbol{A}\mathbb{T}) \subset (1+\varepsilon)w(\mathbb{T})\mathbb{B}_2^m。$$

因而得到 Dvoretzky–Milman 定理的高概率形式。

42 [**Gaussian 云接近圆**] 设 $\boldsymbol{g}_1,\cdots,\boldsymbol{g}_n$ i.i.d. $\sim N(\boldsymbol{0},\boldsymbol{I}_m)$。证明：若 $m \leqslant c\ln n$，其中 $c=c_\varepsilon>0$，则存在只依赖于 ε 的常数，使得凸包

$$K=\operatorname{conv}(\boldsymbol{g}_1,\boldsymbol{g}_2,\cdots,\boldsymbol{g}_n)\subset\mathbb{R}^m$$

(w.h.p.) 为各向同性的 Euclidean 球体 (见图 9.9 右)，即存在半径 $R\asymp\sqrt{\ln n}$，满足

$$(1-\varepsilon)R\mathbb{B}_2^m \subset \operatorname{conv}(\boldsymbol{g}_1,\cdots,\boldsymbol{g}_n) \subset (1+\varepsilon)R\mathbb{B}_2^m。$$



图 9.9 8 维立方体的平面随机投影 (左) 与 10^4 个 Gaussian 点的平面随机投影 (右)

证明 将 Gaussian 点云表示为 Gaussian 矩阵对标准基的投影

设 $\boldsymbol{A}=(\boldsymbol{g}_1,\cdots,\boldsymbol{g}_n)\in\mathbb{R}^{m\times n}$，则 A_{ij} i.i.d. $\sim N(0,1)$。

设 $\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n$ 为 $\mathbb{R}^n$ 的标准正交基，构造离散集合 $\mathbb{T}=\{\boldsymbol{e}_1,\cdots,\boldsymbol{e}_n\}\subset\mathbb{R}^n$，则 $\boldsymbol{A}\mathbb{T}=\{\boldsymbol{g}_1,\cdots,\boldsymbol{g}_n\}$，因此

$$\operatorname{conv}(\boldsymbol{g}_1,\cdots,\boldsymbol{g}_n)=\operatorname{conv}(\boldsymbol{A}\mathbb{T})。$$

- 计算 $\mathbb{T}$ 的特征量

  对于 $\operatorname{rad}(\mathbb{T})$，

  $$\operatorname{rad}(\mathbb{T})=\sup_{\boldsymbol{x}\in\mathbb{T}}\|\boldsymbol{x}\|_2=1。$$

  对于 $w(\mathbb{T})$，根据极值 Gaussian 变量的期望渐近理论 (上界：命题 P2.7.6 (sub-Gaussian 随机变量的最大值)；下界：习题 Q2.38 (Gaussian 随机变量的极大值))，可得

  $$w(\mathbb{T})=\mathrm{E}_{\boldsymbol{g}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{g},\boldsymbol{x}\rangle\right]=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}\langle\boldsymbol{g},\boldsymbol{e}_i\rangle\right]=\mathrm{E}\left[\max_{1\leqslant i\leqslant n}g_i\right]=\sqrt{2\ln n}(1+o(1)),$$

  即 $w(\mathbb{T})\asymp\sqrt{\ln n}$。

- 根据 Dvoretzky–Milman 定理 (习题 Q9.41 (Dvoretzky–Milman 定理的高概率版本))

  根据习题 Q9.41 (Dvoretzky–Milman 定理的高概率版本)，可得对于任意的 $u\geqslant 0$，

  $$r_-(u)\mathbb{B}_2^m\subset\operatorname{conv}(\boldsymbol{A}\mathbb{T})\subset r_+(u)\mathbb{B}_2^m \text{ (w.h.p. } 1-2\mathrm{e}^{-u^2}),$$

  其中

  $$r_\pm(u)=w(\mathbb{T})\pm C_1(\sqrt{m}+u)\operatorname{rad}(\mathbb{T})=w(\mathbb{T})\pm C_1(\sqrt{m}+u), \tag{I}$$

  之后只需控制波动区间 $C_1(\sqrt{m}+u)$ 即可。

  令 $u=\sqrt{m}$，则波动项为 $C_1(\sqrt{m}+u)=2C_1\sqrt{m}$。若该项不超过 $\varepsilon w(\mathbb{T})$，则

  $$2C_1\sqrt{m}\leqslant\varepsilon w(\mathbb{T})，\text{因此}2C_1\sqrt{m}\leqslant\varepsilon c_0\sqrt{\ln n}，\text{因此}\sqrt{m}\leqslant\frac{\varepsilon c_0}{2C_1}\sqrt{\ln n}，\text{因此}m\leqslant\underbrace{\left(\frac{c_0^2}{4C_1^2}\varepsilon^2\right)}_{c_\varepsilon}\ln n, \tag{II}$$

将 (II) 代入于 (I)，可得

$$r_-(u) \geqslant (1-\varepsilon)w(\mathbb{T})$$
$$r_+(u) \leqslant (1+\varepsilon)w(\mathbb{T})。$$

如此，令标称半径 $R = w(\mathbb{T}) \asymp \sqrt{\ln n}$，可得

$$(1-\varepsilon)R\mathbb{B}_2^m \subset \operatorname{conv}(\boldsymbol{g}_1, \boldsymbol{g}_2, \cdots, \boldsymbol{g}_n) \subset (1+\varepsilon)R\mathbb{B}_2^m \text{ (w.h.p. } 1-2\mathrm{e}^{-m})。$$

43 [**真正的随机投影**] 将 Gaussian 投影的 Dvoretzky–Milman 定理改写为真正随机正交投影的版本。

设 $E \sim U(G(n,m))$ (Grassmann 流形 $G(n,m)$ 以 Haar 测度均匀选取的随机 m 维线性子空间)，$\boldsymbol{P}: \mathbb{R}^n \to E$ 为向 E 的正交投影算子。设 $\mathbb{T} \subset \mathbb{R}^n$，定义其 Euclidean 外接半径、球面平均宽度分别为

$$\operatorname{rad}(\mathbb{T}) = \sup_{\boldsymbol{x}\in\mathbb{T}} \|\boldsymbol{x}\|_2, \quad w_s(\mathbb{T}) = \mathrm{E}_{\boldsymbol{\theta}}\left(\sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{\theta}, \boldsymbol{x}\rangle\right),$$

其中 $\boldsymbol{\theta} \sim U(\mathbb{S}^{n-1})$。证明：若 $0 < \varepsilon < 1$ 且满足以下充分维数条件，

$$m \ln\left(1 + \frac{8\operatorname{rad}(\mathbb{T})}{\varepsilon w_s(\mathbb{T})}\right) \leqslant c\varepsilon^2 n \left(\frac{w_s(\mathbb{T})}{\operatorname{rad}(\mathbb{T})}\right)^2,$$

则投影凸包 $\operatorname{conv}(\boldsymbol{P}\mathbb{T})$ 逼近子空间 E 的半径为 $w_s(\mathbb{T})$ 的 Euclidean 球 $B = w_s(\mathbb{T})B_2(E)$，即

$$(1-\varepsilon)B \subset \operatorname{conv}(\boldsymbol{P}\mathbb{T}) \subset (1+\varepsilon)B \text{ (w.h.p. } 1-2\mathrm{e}^{-c_0 m})。$$

注释 利用以下引理。

引理 (Gaussian 宽度同球面宽度的关系)

$$w_s(\mathbb{T}) \asymp \frac{w(\mathbb{T})}{\sqrt{n}}。$$

同理于习题 Q7.27 (矩阵草图)，进行极坐标分解 $\boldsymbol{g} = \|\boldsymbol{g}\|_2\boldsymbol{\theta}$，其模长 $\|\boldsymbol{g}\|_2$ 独立于 $\boldsymbol{\theta} = \boldsymbol{g}/\|\boldsymbol{g}\|_2 \sim U(\mathbb{S}^{n-1})$，则

$$w(\mathbb{T}) = \mathrm{E}_{\boldsymbol{g}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{g}, \boldsymbol{x}\rangle\right] = \mathrm{E}[\|\boldsymbol{g}\|_2] \cdot \mathrm{E}_{\boldsymbol{\theta}}\left[\sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{\theta}, \boldsymbol{x}\rangle\right] = \mathrm{E}[\|\boldsymbol{g}\|_2] \cdot w_s(\mathbb{T}),$$

其中

$$\mathrm{E}[\|\boldsymbol{g}\|_2] = \sqrt{2}\frac{\Gamma((n+1)/2)}{\Gamma(n/2)} = \sqrt{n}\left(1 - O\left(\frac{1}{n}\right)\right) \asymp \sqrt{n},$$

将其代入，可得

$$w_s(\mathbb{T}) = \frac{w(\mathbb{T})}{\mathrm{E}\|\boldsymbol{g}\|_2} \asymp \frac{w(\mathbb{T})}{\sqrt{n}}。$$

证明 • 根据凸几何对偶性转化问题

记 E 的单位球面为 $\mathbb{S}(E) = E \cap \mathbb{S}^{n-1}$，其对应的闭单位 Euclidean 球为 $B_2(E) = \{\boldsymbol{y} \in E : \|\boldsymbol{y}\|_2 \leqslant 1\}$，则根据习题 Q9.40 (凸包与支撑函数的对偶性)，令 $V = \boldsymbol{P}\mathbb{T}$，可得

$$(1-\varepsilon)w_s(\mathbb{T})B_2(E) \subset \operatorname{conv}(\boldsymbol{P}\mathbb{T}) \subset (1+\varepsilon)w_s(\mathbb{T})B_2(E)$$

成立，当且仅当对于任意的 $\boldsymbol{y} \in \mathbb{S}(E)$，均满足

$$(1-\varepsilon)w_s(\mathbb{T}) \leqslant \sup_{\boldsymbol{z}\in\boldsymbol{P}\mathbb{T}} \langle \boldsymbol{z}, \boldsymbol{y}\rangle \leqslant (1+\varepsilon)w_s(\mathbb{T})。 \tag{I}$$

对于任意的 $\boldsymbol{y} \in \mathbb{S}(E)$，由于

$$\sup_{\boldsymbol{z}\in\boldsymbol{P}\mathbb{T}} \langle \boldsymbol{z}, \boldsymbol{y}\rangle = \sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{P}\boldsymbol{x}, \boldsymbol{y}\rangle = \sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{x}, \boldsymbol{P}\boldsymbol{y}\rangle = \sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{x}, \boldsymbol{y}\rangle = h_{\mathbb{T}}(\boldsymbol{y}), \tag{II}$$

因此投影集合 $\boldsymbol{P}\mathbb{T}$ 于方向 $\boldsymbol{y}$ 的支撑函数，等价于原集合 $\mathbb{T}$ 于方向 $\boldsymbol{y}$ 的支撑函数 $h_{\mathbb{T}}(\boldsymbol{y})$。

由于 $E \sim U(G(n,m))$，因此 $\boldsymbol{y} \sim U(\mathbb{S}^{n-1})$，从而

$$\mathrm{E}[h_{\mathbb{T}}(\boldsymbol{y})] = \mathrm{E}_{\boldsymbol{\theta}\sim U(\mathbb{S}^{n-1})}\left(\sup_{\boldsymbol{x}\in\mathbb{T}} \langle \boldsymbol{x}, \boldsymbol{\theta}\rangle\right) = w_s(\mathbb{T})。 \tag{III}$$

之后只需考虑支撑函数 $h_{\mathbb{T}}: \mathbb{S}^{n-1} \to \mathbb{R}$。

对比维度	Gaussian 随机投影	真实正交投影
投影算子	矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ (元素 i.i.d. $\sim N(0,1)$)	算子 $\boldsymbol{P}:\mathbb{R}^n\to E$ ($E\sim\mathrm{Haar}(G(n,m))$)
投影后球体半径	$R=w(\mathbb{T})$ (Gaussian 宽度)	$R=w_s(\mathbb{T})\asymp\frac{w(\mathbb{T})}{\sqrt{n}}$ (球面平均宽度)
尺度关系本质	矩阵各行的模长为 $\|\boldsymbol{A}_i\|_2\asymp\sqrt{n}$	等距保范的缩放映射，多除了因子 $\sqrt{n}$
充分维数条件	$m\asymp\varepsilon^2(\frac{w(\mathbb{T})}{\mathrm{rad}(\mathbb{T})})^2$	$\frac{m\ln(1+8r/(\varepsilon w_s))}{\lesssim\varepsilon^2 n(w_s/r)^2}$，其中 $r=\mathrm{rad}(\mathbb{T})$，$w_s=w_s(\mathbb{T})$

根据球面测度集中不等式

对于任意的 $\boldsymbol{u},\boldsymbol{v}\in\mathbb{S}^{n-1}$，利用 Cauchy–Schwarz 不等式，可得

$$|h_{\mathbb{T}}(\boldsymbol{u})-h_{\mathbb{T}}(\boldsymbol{v})|=\left|\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{u}\rangle-\sup_{\boldsymbol{x}\in\mathbb{T}}\langle\boldsymbol{x},\boldsymbol{v}\rangle\right|\leqslant\sup_{\boldsymbol{x}\in\mathbb{T}}|\langle\boldsymbol{x},\boldsymbol{u}-\boldsymbol{v}\rangle|\leqslant\mathrm{rad}(\mathbb{T})\|\boldsymbol{u}-\boldsymbol{v}\|_2。$$

因此 $h_{\mathbb{T}}$ 为 $L=\mathrm{rad}(\mathbb{T})$-Lipschitz 函数，从而根据定理 T5.1.4 ($\mathbb{R}^n$ 的等周不等式) ($\mathbb{R}^n$ 的等周不等式)，可得对于任意的 $t>0$，

$$\mathrm{P}\{|h_{\mathbb{T}}(\boldsymbol{\theta})-w_s(\mathbb{T})|\geqslant t\}\leqslant 2\exp\left(-\frac{c_1nt^2}{\mathrm{rad}(\mathbb{T})^2}\right)。\tag{IV}$$

- 于固定参考球面构造网并取联合界

  固定 m 维子空间 E_0 及其上的 η-网 $\mathcal{N}_0$，其中

  $$\eta=\frac{\varepsilon w_s(\mathbb{T})}{4\,\mathrm{rad}(\mathbb{T})}。$$

  取 Haar 正交变换 $\boldsymbol{U}$，令 $E=\boldsymbol{U}E_0$, $\mathcal{N}=\boldsymbol{U}\mathcal{N}_0$。则 $\mathcal{N}$ 是 $\mathbb{S}(E)$ 的 η-网，且其容量满足

  $$|\mathcal{N}|=|\mathcal{N}_0|\leqslant\left(1+\frac{2}{\eta}\right)^m=\left(1+\frac{8\,\mathrm{rad}(\mathbb{T})}{\varepsilon w_s(\mathbb{T})}\right)^m。$$

  对每个 $\boldsymbol{y}_0\in\mathcal{N}_0$，$\boldsymbol{U}\boldsymbol{y}_0\sim U(\mathbb{S}^{n-1})$；无须这些随机向量相互独立。令 $t=\varepsilon w_s(\mathbb{T})/2$，由 (IV) 与联合界可得

  $$\begin{aligned}\mathrm{P}\left\{\max_{\boldsymbol{y}\in\mathcal{N}}|h_{\mathbb{T}}(\boldsymbol{y})-w_s(\mathbb{T})|\geqslant\frac{\varepsilon}{2}w_s(\mathbb{T})\right\}&\leqslant|\mathcal{N}|\cdot 2\exp\left(-\frac{c_1n(\varepsilon w_s(\mathbb{T})/2)^2}{\mathrm{rad}(\mathbb{T})^2}\right)\\&\leqslant 2\exp\left(m\ln\left(1+\frac{8\,\mathrm{rad}(\mathbb{T})}{\varepsilon w_s(\mathbb{T})}\right)-\frac{c_1\varepsilon^2}{4}n\left(\frac{w_s(\mathbb{T})}{\mathrm{rad}(\mathbb{T})}\right)^2\right)。\end{aligned}$$

  由维数条件，取充分小的绝对常数 c 后，上式中的指数至多为 $-c_0m$，从而

  $$\max_{\boldsymbol{y}\in\mathcal{N}}|h_{\mathbb{T}}(\boldsymbol{y})-w_s(\mathbb{T})|\leqslant\frac{\varepsilon}{2}w_s(\mathbb{T})\ (\text{w.h.p. }1-2\mathrm{e}^{-c_0m})。\tag{V}$$

- 连续化逼近同对偶闭环

  对任意的 $\boldsymbol{y}\in\mathbb{S}(E)$，取 $\boldsymbol{y}_0\in\mathcal{N}$ 使 $\|\boldsymbol{y}-\boldsymbol{y}_0\|_2\leqslant\eta$。由 $h_{\mathbb{T}}$ 的 Lipschitz 性及 (V)，

  $$|h_{\mathbb{T}}(\boldsymbol{y})-w_s(\mathbb{T})|\leqslant|h_{\mathbb{T}}(\boldsymbol{y}_0)-w_s(\mathbb{T})|+\mathrm{rad}(\mathbb{T})\eta\leqslant\frac{3\varepsilon}{4}w_s(\mathbb{T})\leqslant\varepsilon w_s(\mathbb{T}),$$

  即

  $$(1-\varepsilon)w_s(\mathbb{T})\leqslant h_{\mathbb{T}}(\boldsymbol{y})=\sup_{\boldsymbol{z}\in\boldsymbol{P}\mathbb{T}}\langle\boldsymbol{z},\boldsymbol{y}\rangle\leqslant(1+\varepsilon)w_s(\mathbb{T}),$$

  将其代入于 (I)，可得

  $$(1-\varepsilon)w_s(\mathbb{T})B_2(E)\subset\mathrm{conv}(\boldsymbol{P}\mathbb{T})\subset(1+\varepsilon)w_s(\mathbb{T})B_2(E)。$$

注释 定理 T9.7.2 (Dvoretzky–Milman 定理) 与真实正交投影的对比如下：